CAPÍTULO I. UNIVERSIDAD NACIONAL DE INGENIERÍA

UNIDAD DE POSGRADO FACULTAD DE INGENIERÍA INDUSTRIAL Y DE SISTEMAS

1.1. TESIS

COORDINACIÓN ENERGÉTICA MULTIOBJETIVO MEDIANTE APRENDIZAJE POR REFUERZO PROFUNDO MULTIAGENTE EN UNA COMUNIDAD INTELIGENTE HETEROGÉNEA DE IQUITOS: EFECTOS Y DESEMPEÑO ALGORÍTMICO, 2026

PARA OPTAR EL GRADO ACADÉMICO DE

MAESTRO CON MENCIÓN EN:

INTELIGENCIA ARTIFICIAL

ELABORADA POR:

BACH. TAPIA CCOYSO, MAC

BACH. ZAMBRANO JOVE, SERGIO MAURICIO

ASESOR:

DR. ZELA MORAYA, WESTER EDISON

LIMA – PERU

2026

Dedicatoria

A mi familia, por el apoyo incondicional durante este camino de formación académica; a los docentes y colegas de la Universidad Nacional de Ingeniería, por impulsar la

investigación aplicada en sistemas eléctricos inteligentes; y a la comunidad académica de Iquitos, cuyo contexto energético motivó el presente estudio.

Agradecimientos

Se agradece a la Escuela de Posgrado de la UNI, al equipo de investigación del proyecto MADRL CityLearn v3, a Electro Oriente S.A. y a las instituciones que aportaron datos operativos para el dataset citylearn_iquitos_2023_2025. Asimismo, se reconoce el uso de recursos computacionales en Google Colab para la corrida canónica de 50 episodios (madrl_v3_20260627_164047).

CAPÍTULO II. Resumen

La investigación determinó y cuantificó los efectos diferenciales de HAPPO, MASAC, MATD3 y MAAC sobre la flexibilidad energética, las emisiones de CO_2 y los costos energéticos de una comunidad inteligente heterogénea de 17 edificios de Iquitos. La campaña canónica comprendió 12 tratamientos de 50 episodios nominales y una semilla. La contrastación principal empleó KPI-gains emparejados por indicador para MAAC, MASAC y MATD3; HAPPO careció de KPI-gains finales comparables y se mantuvo en el análisis descriptivo. Se aplicaron Shapiro–Wilk, Wilcoxon frente a la línea base con corrección Holm, Friedman, Kendall W y Wilcoxon pareado con Holm.

En E1 no se rechazó la igualdad del subconjunto comparable ($\chi^2 = 5,5897$; $p = 0,0611$; $W = 0,2329$); MATD3 obtuvo el mejor KPI físico distrital y MAAC la mejor mediana de KPI-gain. En E2 se rechazó la igualdad global del subconjunto ($\chi^2 = 6,0000$; $p = 0,0498$; $W = 0,6000$), aunque los post hoc Holm no localizaron diferencias por pares; MATD3 presentó el menor incremento de CO_2. En E3 no se rechazó la igualdad ($\chi^2 = 3,4286$; $p = 0,1801$; $W = 0,1905$) y MAAC mostró el menor incremento de costo. Globalmente se detectó diferenciación débil ($\chi^2 = 9,2911$; $p = 0,0096$; $W = 0,1787$), con MAAC como mejor compromiso observado en el score integrado (0,9538) y TOPSIS (0,9827), sin superioridad universal demostrada. El alcance inferencial quedó limitado por la semilla única y por la ausencia de HAPPO en los KPI-gains.

Palabras clave: aprendizaje por refuerzo profundo multiagente; coordinación energética multiobjetivo; CityLearn; flexibilidad energética; emisiones de CO_2; costos energéticos; Iquitos.

CAPÍTULO III. Abstract

This study determined and quantified the differential effects of HAPPO, MASAC, MATD3, and MAAC on energy flexibility, CO_2 emissions, and energy costs in a heterogeneous 17-building smart community in Iquitos. The canonical campaign comprised 12 nominal 50-episode treatments and one seed. The primary inference used KPI gains paired by indicator for MAAC, MASAC, and MATD3; HAPPO had no comparable final KPI gains and was retained only for descriptive analysis. Shapiro–Wilk, baseline Wilcoxon tests with Holm correction, Friedman tests, Kendall's W, and paired Wilcoxon–Holm comparisons were applied.

For E1, equality was not rejected (χ^2 = 5.5897, p = .0611, W = .2329); MATD3 led the district physical KPI and MAAC led median KPI gain. For E2, global equality was rejected for the comparable subset (χ^2 = 6.0000, p = .0498, W = .6000), but Holm post hoc tests did not locate a significant pair; MATD3 showed the smallest CO_2 increase. For E3, equality was not rejected (χ^2 = 3.4286, p = .1801, W = .1905), and MAAC showed the smallest cost increase. Globally, weak differentiation was detected (χ^2 = 9.2911, p = .0096, W = .1787); MAAC was the best observed compromise in the integrated score (.9538) and TOPSIS (.9827), without demonstrated universal superiority. Inference was limited by the single seed and HAPPO's missing KPI gains.

Keywords: multi-agent deep reinforcement learning; multi-objective energy coordination; CityLearn; energy flexibility; CO_2 emissions; energy costs; Iquitos.

CAPÍTULO IV. ÍNDICE DE CONTENIDOS

Dedicatoria ..... **¡Error! Marcador no definido.**
Agradecimientos ..... **¡Error! Marcador no definido.**
CAPÍTULO I. Resumen ..... **¡Error! Marcador no definido.**
CAPÍTULO II. Abstract ..... **¡Error! Marcador no definido.**
CAPÍTULO IV. Indice de tablas ..... **¡Error! Marcador no definido.**
Capítulo 1. Planteamiento del Problema ..... **¡Error! Marcador no definido.**
1.1. Diagnóstico del problema ..... **¡Error! Marcador no definido.**
1.2. Identificación y descripción del problema de estudio ..... **¡Error! Marcador no definido.**
1.2.1. Formulación del problema ..... **¡Error! Marcador no definido.**
1.2.2 Justificación y alcances ..... **¡Error! Marcador no definido.**
1.3. Objetivos e hipótesis de la investigación ..... **¡Error! Marcador no definido.**
1.3.1 Objetivos ..... **¡Error! Marcador no definido.**
1.3.2 Hipótesis ..... **¡Error! Marcador no definido.**
CAPÍTULO V. Marco teórico ..... **¡Error! Marcador no definido.**
1.4. Fundamentos teóricos, conceptuales y matemáticos de las variables de investigación **¡Error! Marcado**
1.5. Bases teóricas ..... **¡Error! Marcador no definido.**
1.5.1 MADRL ..... **¡Error! Marcador no definido.**
1.5.2 Formalización matemática Dec-POMDP ..... **¡Error! Marcador no definido.**
1.5.3 Dec-POMDP como formalización del problema de investigación **¡Error! Marcador no definido.**
1.5.4 Entrenamiento centralizado con ejecución descentralizada **¡Error! Marcador no definido.**
1.5.5 CityLearn y simulación multiobjetivo ..... **¡Error! Marcador no definido.**

1.5.6 Metodología de selección de los cuatro algoritmos MADRL **¡Error! Marcador no definido.**
1.6. Variables de la investigación ..... **¡Error! Marcador no definido.**
1.6.1 Variable independiente ..... **¡Error! Marcador no definido.**
1.6.2 Variable dependiente ..... **¡Error! Marcador no definido.**
1.7. Antecedentes ..... **¡Error! Marcador no definido.**
1.7.1 Antecedentes internacionales ..... **¡Error! Marcador no definido.**
1.7.2 Antecedentes nacionales y peruanos ..... **¡Error! Marcador no definido.**
1.7.3 Síntesis crítica de antecedentes y brecha científica ..... **¡Error! Marcador no definido.**
1.8. Definición de términos y posición teórica ..... **¡Error! Marcador no definido.**
1.8.1 Definición de términos y delimitaciones conceptuales ..... **¡Error! Marcador no definido.**
1.8.2 Posición teórica de la tesis ..... **¡Error! Marcador no definido.**
1.9. Síntesis crítica y triangulación del marco teórico ..... **¡Error! Marcador no definido.**
CAPÍTULO VI. Capítulo 3. Metodología ..... **¡Error! Marcador no definido.**
1.10. Enfoque, tipo, nivel y diseño de investigación ..... **¡Error! Marcador no definido.**
1.11. Diseño experimental-computacional factorial 4 × 3 ..... **¡Error! Marcador no definido.**
1.12. Datos utilizados y fuente empírica ..... **¡Error! Marcador no definido.**
1.13. Variables, dimensiones e indicadores ..... **¡Error! Marcador no definido.**
1.14. Técnicas, herramientas e instrumentos ..... **¡Error! Marcador no definido.**
1.15. Procedimiento experimental ..... **¡Error! Marcador no definido.**
1.16. Validez metodológica, trazabilidad y control de sesgos ..... **¡Error! Marcador no definido.**
CAPÍTULO VII. Capítulo 4. Desarrollo de la propuesta ..... **¡Error! Marcador no definido.**
1.17. Desarrollo del sistema y arquitectura de software ..... **¡Error! Marcador no definido.**
1.18. 4.2 Modelo de IA: formulación Dec-POMDP ..... **¡Error! Marcador no definido.**
1.19. 4.3 Esquema CTDE ..... **¡Error! Marcador no definido.**
1.20. Algoritmos ..... **¡Error! Marcador no definido.**
1.21. 4.5 Función de recompensa multiobjetivo ..... **¡Error! Marcador no definido.**
1.22. Aportes originales al motor de simulación ..... **¡Error! Marcador no definido.**
1.23. Diseño experimental: matriz de 12 corridas ..... **¡Error! Marcador no definido.**
1.24. Implementación ..... **¡Error! Marcador no definido.**
1.25. Detalle técnico de la propuesta derivado del resumen ..... **¡Error! Marcador no definido.**
1.25.1 Construcción del dataset y fuentes utilizadas ..... **¡Error! Marcador no definido.**
1.25.2 Librerias, scripts y herramientas de implementación ..... **¡Error! Marcador no definido.**
1.25.3 Arquitectura operativa desde datos hasta resultados ..... **¡Error! Marcador no definido.**
1.25.4 Delimitación entre equipos controlados y no controlados **¡Error! Marcador no definido.**

1.26. Respuesta operacional a las preguntas específicas PE.1, PE.2 y PE.3**¡Error! Marcador no definido**
CAPÍTULO VIII. Capítulo 5. Resultados y contrastación de hipótesis**¡Error! Marcador no definido.**
1.27. Cobertura de artefactos experimentales ..... **¡Error! Marcador no definido.**
1.28. Trazabilidad entre objetivos, hipótesis e indicadores ..... **¡Error! Marcador no definido.**
1.29. Curvas de convergencia y episodios de aprendizaje ..... **¡Error! Marcador no definido.**
1.30. KPIs bajo nomenclatura CityLearn v2 evaluate_v2 ..... **¡Error! Marcador no definido.**
1.31. 5.5 OE.1: efecto del MADRL sobre flexibilidad energética**¡Error! Marcador no definido.**
1.32. 5.6 OE.2: efecto del MADRL sobre emisiones de CO_2 .... **¡Error! Marcador no definido.**
1.33. 5.7 OE.3: efecto del MADRL sobre costos energéticos ... **¡Error! Marcador no definido.**
1.34. 5.8 Resultados por edificio y equipamiento controlado .... **¡Error! Marcador no definido.**
1.35. 5.9 Síntesis de contrastación de OE.1, OE.2 y OE.3 ..... **¡Error! Marcador no definido.**
1.36. 5.10 Discusión triangulada de resultados con antecedentes internacionales y nacionales **¡Error! Marcador no definido.**
CAPÍTULO IX. Capítulo 6. Conclusiones preliminares ..... **¡Error! Marcador no definido.**
1.37. 6.1 Principales hallazgos ..... **¡Error! Marcador no definido.**
1.38. 6.2 Limitaciones encontradas ..... **¡Error! Marcador no definido.**
1.39. 6.3 Trabajo pendiente ..... **¡Error! Marcador no definido.**
CAPÍTULO X. Referencias bibliográficas ..... **¡Error! Marcador no definido.**
CAPÍTULO XI. Anexo A. Resultados reales integrados desde Google Drive**¡Error! Marcador no definid**
1.40. A.1 Resultados distritales por algoritmo y escenario ..... **¡Error! Marcador no definido.**
1.41. A.2 Resultados por edificio ..... **¡Error! Marcador no definido.**
1.42. A.3 Equipamiento controlado y no controlado ..... **¡Error! Marcador no definido.**
1.43. A.4 Checkpoints y reproducibilidad de modelos ..... **¡Error! Marcador no definido.**
1.44. A.5 Archivos reproducibles ..... **¡Error! Marcador no definido.**
CAPÍTULO XII. Anexo B. Diagramas de flujo y arquitectura del proyecto**¡Error! Marcador no definido.**
1.45. Diagrama 1 — Vision General del Proyecto (inicio a fin). **¡Error! Marcador no definido.**
1.46. Diagrama 2 — Pipeline del Dataset Iquitos 2023-2025 .... **¡Error! Marcador no definido.**
1.47. Diagrama 3 — Arquitectura Dec-POMDP y CTDE de los 17 Agentes**¡Error! Marcador no definido.**
1.48. Diagrama 4 — Los 4 Algoritmos MADRL: Taxonomia y Diferencias**¡Error! Marcador no definido.**
1.49. Diagrama 5 — Flujo de Entrenamiento: 12 Corridas (two_phase_happo_masac_v3)**¡Error! Marcado**
1.50. Diagrama 6 — Recompensa Multiobjetivo por Escenario **¡Error! Marcador no definido.**
1.51. Diagrama 7 — Pipeline de evaluación y selección por objetivo**¡Error! Marcador no definido.**
1.52. Diagrama 8 — Infraestructura de Despliegue: Local, Colab A100 y AWS EC2**¡Error! Marcador no d**
1.53. Diagrama 9 — Estructura de Capas del Software ..... **¡Error! Marcador no definido.**

CAPÍTULO V. Indice de tablas

Símbolo ..... **¡Error! Marcador no definido.**

Definición teórica ..... **¡Error! Marcador no definido.**

Valor / rango en esta tesis ..... **¡Error! Marcador no definido.**

N ..... **¡Error! Marcador no definido.**

Número de agentes cooperativos (edificios) ..... **¡Error! Marcador no definido.**

17 ..... **¡Error! Marcador no definido.**

S ..... **¡Error! Marcador no definido.**

Espacio de estado global ..... **¡Error! Marcador no definido.**

Concatenación s = [1… 17]; dim global = 1 856 ..... **¡Error! Marcador no definido.**

O_i ..... **¡Error! Marcador no definido.**

Espacio de observación local del agente i ..... **¡Error! Marcador no definido.**

Heterogéneo: 57-330 dimensiones según flota EV ..... **¡Error! Marcador no definido.**

A_i ..... **¡Error! Marcador no definido.**

Espacio de acción local del agente i ..... **¡Error! Marcador no definido.**

Heterogéneo: 5-44 acciones (BESS, EV, carga desplazable) ..... **¡Error! Marcador no definido.**

T ..... **¡Error! Marcador no definido.**

Función de transición estocástica S x A -> Delta(S) ..... **¡Error! Marcador no definido.**

Balance energético, modelo RC, BESS eta_RT = 0.9025, EV estocástico **¡Error! Marcador no definido.**

Omega ..... **¡Error! Marcador no definido.**

Función de observación O_i = Omega (s, a) ..... **¡Error! Marcador no definido.**

Proyección parcial del estado global a información local ..... **¡Error! Marcador no definido.**

R ..... **¡Error! Marcador no definido.**

Recompensa cooperativa escalar o vector mixto ..... **¡Error! Marcador no definido.**

CityLearnV3MADRLRewardFunction; agregación team_mean ..... **¡Error! Marcador no definido.**

gamma ..... **¡Error! Marcador no definido.**

Factor de descuento ..... **¡Error! Marcador no definido.**

0.9999 ..... **¡Error! Marcador no definido.**

T_hor ..... **¡Error! Marcador no definido.**

Horizonte temporal del episodio ..... **¡Error! Marcador no definido.**

8 760 pasos (1 h/paso) ..... **¡Error! Marcador no definido.**

pi_i ..... **¡Error! Marcador no definido.**

Política descentralizada del edificio i ..... **¡Error! Marcador no definido.**

pi_i(a_i | o_i); sin comunicación inter-edificio ..... **¡Error! Marcador no definido.**

Elemento ..... **¡Error! Marcador no definido.**
Operación en la tesis ..... **¡Error! Marcador no definido.**
Evidencia local ..... **¡Error! Marcador no definido.**
Agentes ..... **¡Error! Marcador no definido.**
Edificios institucionales/comerciales de la comunidad ..... **¡Error! Marcador no definido.**
17 agentes en building_behavior_summary.csv ..... **¡Error! Marcador no definido.**
Estado global S ..... **¡Error! Marcador no definido.**
Concatenación de observaciones locales para critic/entrenamiento CTDE **¡Error! Marcador no definido.**
suma observation_dim=1856 ..... **¡Error! Marcador no definido.**
Observación local O_i ..... **¡Error! Marcador no definido.**
Información parcial disponible para cada actor ..... **¡Error! Marcador no definido.**
rango observado 54-327 variables ..... **¡Error! Marcador no definido.**
Acción A_i ..... **¡Error! Marcador no definido.**
Control descentralizado de equipos flexibles ..... **¡Error! Marcador no definido.**
rango observado 5-44; total=219 ..... **¡Error! Marcador no definido.**
Transición T ..... **¡Error! Marcador no definido.**
Dinámica horaria de CityLearn: clima, PV, BESS, EV, precio, carbono y demanda **¡Error! Marcador no defin**
timeseries.csv y traces por tratamiento ..... **¡Error! Marcador no definido.**
Recompensa R ..... **¡Error! Marcador no definido.**
Función multiobjetivo comparable por escenario E1/E2/E3 ..... **¡Error! Marcador no definido.**
pesos flex/CO2/costo y agregación team_mean ..... **¡Error! Marcador no definido.**
Horizonte H ..... **¡Error! Marcador no definido.**
Evaluación anual horaria por episodio ..... **¡Error! Marcador no definido.**
8760 pasos horarios ..... **¡Error! Marcador no definido.**
Descuento gamma ..... **¡Error! Marcador no definido.**
Persistencia de efectos diferidos de almacenamiento y carga EV **¡Error! Marcador no definido.**
gamma=0.9999 ..... **¡Error! Marcador no definido.**
MADRL ..... **¡Error! Marcador no definido.**
Perfil de elegibilidad ..... **¡Error! Marcador no definido.**
Mecanismo diferenciador ..... **¡Error! Marcador no definido.**
Relación con la tesis ..... **¡Error! Marcador no definido.**
Condición de implementación ..... **¡Error! Marcador no definido.**
HAPPO ..... **¡Error! Marcador no definido.**
Model-free; online; on-policy; política estocástica; CTDE; acciones continuas o discretas. **¡Error! Marcador n**

Actualización secuencial y políticas heterogéneas; prioriza estabilidad.**¡Error! Marcador no definido.**
Representa diferencias entre 17 edificios con cargas, PV, BESS y EV distintos.**¡Error! Marcador no definid**
Mayor costo muestral; igualar pasos de entorno, cómputo y presupuesto de ajuste.**¡Error! Marcador no def**
MATD3 ..... **¡Error! Marcador no definido.**
Model-free; online; off-policy; política determinista; CTDE; acción continua nativa.**¡Error! Marcador no defin**
Dos críticos centralizados reducen la sobreestimación y favorecen control preciso.**¡Error! Marcador no defi**
Adecuado para consignas acotadas de BESS, climatización, EV y cargas flexibles.**¡Error! Marcador no defi**
Controlar exploración determinista y documentar la reimplementación reproducible.**¡Error! Marcador no def**
MASAC ..... **¡Error! Marcador no definido.**
Model-free; online; off-policy; política estocástica gaussiana; CTDE; acción continua.**¡Error! Marcador no de**
Máxima entropía para exploración amplia y mayor robustez ante perturbaciones.**¡Error! Marcador no defini**
Contrasta incertidumbre horaria de clima, PV, demanda, carbono y precios.**¡Error! Marcador no definido.**
Auditar código, hiperparámetros, semillas e intervalos por evidencia original limitada.**¡Error! Marcador no de**
MAAC ..... **¡Error! Marcador no definido.**
Model-free; online; off-policy; política estocástica; CTDE; actor continuo adaptable.**¡Error! Marcador no defi**
El crítico con atención filtra interacciones relevantes y mejora la escalabilidad.**¡Error! Marcador no definido**
Permite coordinación selectiva entre 17 edificios con perfiles heterogéneos.**¡Error! Marcador no definido.**
Adaptar y validar el actor continuo y su equivalencia en CityLearn/Iquitos.**¡Error! Marcador no definido.**
MADRL ..... **¡Error! Marcador no definido.**
Clasificación ..... **¡Error! Marcador no definido.**
Entorno y datos originales ..... **¡Error! Marcador no definido.**
Comparadores ..... **¡Error! Marcador no definido.**
Evidencia publicada ..... **¡Error! Marcador no definido.**
Razón para seleccionarlo ..... **¡Error! Marcador no definido.**
HAPPO ..... **¡Error! Marcador no definido.**
Model-free, online, on-policy, CTDE, política estocástica ..... **¡Error! Marcador no definido.**
SMAC y 12 configuraciones Multi-Agent MuJoCo. No usa dataset fijo; genera trayectorias online. ..... **¡Error! Marcador no definido.**
HATRPO, MAPPO, IPPO y MADDPG ..... **¡Error! Marcador no definido.**
Los autores reportan que HAPPO/HATRPO superan a IPPO, MAPPO y MADDPG en las 12 configuraciones MAMuJoCo. En SMAC, HAPPO, HATRPO y MAPPO llegan a 100%, por lo que ese resultado no discrimina un ganador. ..... **¡Error! Marcador no definido.**
Representa estabilidad on-policy, actualización secuencial y políticas heterogéneas para edificios diferentes. Artículo HAPPO ..... **¡Error! Marcador no definido.**

MATD3 ..... **¡Error! Marcador no definido.**
Model-free, online, off-policy, CTDE, determinista ..... **¡Error! Marcador no definido.**
MPE y Ant-v2 dividido entre agentes. Experiencia online almacenada en replay buffer. **¡Error! Marcador no**
MADDPG; IL-TD3 y SA-TD3 en Ant ..... **¡Error! Marcador no definido.**
Supera a MADDPG en 3 de 4 tareas adversariales, mejora Cooperative Communication y
Ant; pierde en Covert Communication. ..... **¡Error! Marcador no definido.**
Representa control continuo determinista, eficiencia muestral y reducción de sobreestimación
mediante dos críticos. Artículo MATD3 ..... **¡Error! Marcador no definido.**
MASAC ..... **¡Error! Marcador no definido.**
Model-free, online, off-policy, CTDE, estocástico ..... **¡Error! Marcador no definido.**
Entorno denominado GCE: navegación cooperativa y predator–prey. No utiliza dataset fijo. **¡Error! Marcador**
MADDPG ..... **¡Error! Marcador no definido.**
Tabla: objetivo alcanzado 86.4% frente a 74.8%; colisiones 13.6% frente a 25.2%. No reporta
semillas ni intervalos. ..... **¡Error! Marcador no definido.**
Representa máxima entropía, exploración y políticas continuas estocásticas ante
incertidumbre climática, fotovoltaica y de demanda. Artículo MASAC **¡Error! Marcador no definido.**
MAAC ..... **¡Error! Marcador no definido.**
Model-free, online, off-policy, CTDE, estocástico con atención .... **¡Error! Marcador no definido.**
MPE: Treasure Collection, Rover-Tower y Cooperative Navigation. Replay buffer de un millón
de transiciones. ..... **¡Error! Marcador no definido.**
DDPG, MADDPG, COMA, versiones SAC y MAAC Uniform ..... **¡Error! Marcador no definido.**
Navegación: −1.74±0.05 frente a −2.09±0.12 de MADDPG+SAC. En Treasure Colección
reporta mejoras de 17%, 98% y 208% para 4, 8 y 12 agentes. .... **¡Error! Marcador no definido.**
Representa escalabilidad y selección mediante atención de las interacciones relevantes
entre 17 edificios. Requiere adaptar y validar un actor continuo. Artículo y suplemento MAAC **¡Error! Marcad**
Campo ..... **¡Error! Marcador no definido.**
Contenido ..... **¡Error! Marcador no definido.**
Título de la tesis/estudio ..... **¡Error! Marcador no definido.**
CityLearn v2: Energy-flexible, resilient, occupant-centric, and carbon-aware management of
grid-interactive communities ..... **¡Error! Marcador no definido.**
Objetivo general ..... **¡Error! Marcador no definido.**
Desarrollar CityLearn v2 integrando EV/V2G, intensidad de carbono dinámica, BESS, PV y
KPIs de flexibilidad, emisiones y costos en comunidades grid-interactive. **¡Error! Marcador no definido.**
Tipo de metodología ..... **¡Error! Marcador no definido.**

Desarrollo de entorno de simulación; evaluación multiobjetivo con SAC, RBC y MPC.**¡Error! Marcador no d**
Diseño de investigación ..... **¡Error! Marcador no definido.**
Aplicada; no experimental; simulación comparativa en CityLearn v2.**¡Error! Marcador no definido.**
Resultados cuantitativos ..... **¡Error! Marcador no definido.**
KPIs distritales y por edificio (peak_average, ramping, carbon_emissions, electricity_cost); magnitudes específicas dependen de configuración experimental.**¡Error! Marcador no definido.**
Conclusión general ..... **¡Error! Marcador no definido.**
CityLearn v2 habilita investigación reproducible en comunidades inteligentes multidimensionales con flexibilidad, carbono y costo. ..... **¡Error! Marcador no definido.**
Aporte para esta tesis ..... **¡Error! Marcador no definido.**
Entorno base oficial y KPIs D-VD.1-D-VD.3; justifica extensión CityLearn v3 propuesto con Dec-POMDP/CTDE y cuatro backends MADRL. ..... **¡Error! Marcador no definido.**
Campo ..... **¡Error! Marcador no definido.**
Contenido ..... **¡Error! Marcador no definido.**
Título de la tesis/estudio ..... **¡Error! Marcador no definido.**
Heterogeneous Multi-Agent Reinforcement Learning for Grid-Interactive Communities**¡Error! Marcador no d**
Objetivo general ..... **¡Error! Marcador no definido.**
Evaluar HARL/HAPPO para gestión energética heterogénea en comunidades grid-interactive modeladas en CityLearn. ..... **¡Error! Marcador no definido.**
Tipo de metodología ..... **¡Error! Marcador no definido.**
MARL heterogéneo on-policy (HAPPO/HARL) bajo CTDE en CityLearn.**¡Error! Marcador no definido.**
Diseño de investigación ..... **¡Error! Marcador no definido.**
Aplicada; no experimental; simulación CityLearn con agentes heterogéneos.**¡Error! Marcador no definido.**
Resultados cuantitativos ..... **¡Error! Marcador no definido.**
HAPPO heterogéneo comparable o superior a MAPPO en KPIs CityLearn (peak, ramping, emisiones, costo); magnitudes exactas [PV] por configuración. ... **¡Error! Marcador no definido.**
Conclusión general ..... **¡Error! Marcador no definido.**
HAPPO es viable para coordinación heterogénea en comunidades inteligentes grid-interactive. ..... **¡Error! Marcador no definido.**
Aporte para esta tesis ..... **¡Error! Marcador no definido.**
Antecedente directo del backend HAPPO a escala multiedificio; precedente más cercano antes de comparar HAPPO, MASAC, MATD3 y MAAC bajo recompensa unificada.**¡Error! Marcador no defi**
Campo ..... **¡Error! Marcador no definido.**
Contenido ..... **¡Error! Marcador no definido.**

Título de la tesis/estudio ..... **¡Error! Marcador no definido.**
Multi-Agent Reinforcement Learning for Smart Community Energy Management **¡Error! Marcador no definid**
Objetivo general ..... **¡Error! Marcador no definido.**
Proponer un marco MARL (LSD-MADDPG) para gestión coordinada de energía en comunidades inteligentes con PV, BESS y EV. ..... **¡Error! Marcador no definido.**
Tipo de metodología ..... **¡Error! Marcador no definido.**
MARL cooperativo con estrategia local descentralizada (LSD-MADDPG); CTDE. **¡Error! Marcador no defini**
Diseño de investigación ..... **¡Error! Marcador no definido.**
Aplicada; no experimental; simulación de comunidad inteligente sintética. **¡Error! Marcador no definido.**
Resultados cuantitativos ..... **¡Error! Marcador no definido.**
Reducción de costo ~18% y de pico ~15% frente a MADDPG no cooperativo. **¡Error! Marcador no definido.**
Conclusión general ..... **¡Error! Marcador no definido.**
La estrategia local MARL mejora coordinación y reduce fallos de escalabilidad en comunidades con DER. ..... **¡Error! Marcador no definido.**
Aporte para esta tesis ..... **¡Error! Marcador no definido.**
Referente de flexibilidad y costos (OE.1/OE.3) para contrastar si MATD3/MAAC superan mejoras reportadas (~15-18%) bajo dataset SEAI Iquitos. ..... **¡Error! Marcador no definido.**
Campo ..... **¡Error! Marcador no definido.**
Contenido ..... **¡Error! Marcador no definido.**
Título de la tesis/estudio ..... **¡Error! Marcador no definido.**
Multi-agent deep reinforcement learning for building energy system with renewable energy **¡Error! Marcador**
Objetivo general ..... **¡Error! Marcador no definido.**
Proponer MADRL (MADDPG) para coordinar BESS y PV en edificios con energía renovable bajo incertidumbre operativa. ..... **¡Error! Marcador no definido.**
Tipo de metodología ..... **¡Error! Marcador no definido.**
MADDPG cooperativo con crítico centralizado; comparación con control basado en reglas. **¡Error! Marcador**
Diseño de investigación ..... **¡Error! Marcador no definido.**
Aplicada; no experimental; simulación con datos reales de edificios en China. **¡Error! Marcador no definido.**
Resultados cuantitativos ..... **¡Error! Marcador no definido.**
Reducción de costo ~20% y de emisiones CO_2 ~15% frente a reglas. **¡Error! Marcador no definido.**
Conclusión general ..... **¡Error! Marcador no definido.**
MADRL cooperativo supera agentes independientes en eficiencia energética y emisiones. **¡Error! Marcador**
Aporte para esta tesis ..... **¡Error! Marcador no definido.**

Antecedente de D-VD.2 y D-VD.3 para contrastar deltas de CO_2 y costo de MATD3/MAAC en escenario E2/E3 del SEAI Iquitos. ..... **¡Error! Marcador no definido.**
Campo ..... **¡Error! Marcador no definido.**
Contenido ..... **¡Error! Marcador no definido.**
Título de la tesis/estudio ..... **¡Error! Marcador no definido.**
Actor-Attention-Critic for Multi-Agent Reinforcement Learning ..... **¡Error! Marcador no definido.**
Objetivo general ..... **¡Error! Marcador no definido.**
Introducir mecanismos de atención en el crítico centralizado MARL para coordinación selectiva bajo observabilidad parcial. ..... **¡Error! Marcador no definido.**
Tipo de metodología ..... **¡Error! Marcador no definido.**
Actor-critic multiagente con atención multi-cabeza; evaluación en benchmarks MPE y cooperativos. ..... **¡Error! Marcador no definido.**
Diseño de investigación ..... **¡Error! Marcador no definido.**
Básica-algorítmica; experimental con entornos benchmark MARL. **¡Error! Marcador no definido.**
Resultados cuantitativos ..... **¡Error! Marcador no definido.**
Mejora de recompensa ~15-30% frente a MADDPG/COMA en tareas cooperativas. **¡Error! Marcador no def**
Conclusión general ..... **¡Error! Marcador no definido.**
La atención mejora coordinación selectiva entre agentes heterogéneos bajo CTDE. **¡Error! Marcador no def**
Aporte para esta tesis ..... **¡Error! Marcador no definido.**
Fundamento del backend MAAC; explica por qué MAAC puede liderar costos (OE.3) al ponderar interacciones entre edificios bajo señales TOU. ..... **¡Error! Marcador no definido.**
Campo ..... **¡Error! Marcador no definido.**
Contenido ..... **¡Error! Marcador no definido.**
Título de la tesis/estudio ..... **¡Error! Marcador no definido.**
Análisis de la generación hidroeléctrica en la central hidroeléctrica de Machupicchu aplicando métodos estocasticos y modelo de optimización ..... **¡Error! Marcador no definido.**
Objetivo general ..... **¡Error! Marcador no definido.**
Optimizar la generación hidroeléctrica de Machupicchu mediante métodos estocasticos y un modelo de optimización bajo incertidumbre hidrologica. ..... **¡Error! Marcador no definido.**
Tipo de metodología ..... **¡Error! Marcador no definido.**
Modelado estocástico y optimización matemática aplicada a generación renovable peruana. **¡Error! Marcado**
Diseño de investigación ..... **¡Error! Marcador no definido.**
Aplicada; tesis UNI; estudio de caso en generación hidroeléctrica. **¡Error! Marcador no definido.**
Resultados cuantitativos ..... **¡Error! Marcador no definido.**

[PV] Mejoras de eficiencia operativa y asignación de generación respecto a escenarios base; magnitudes cuantitativas pendientes de extracción del repositorio UNI.**¡Error! Marcador no definido.**
Conclusión general ..... **¡Error! Marcador no definido.**
Los métodos estocasticos permiten decisiones más robustas en generación renovable bajo variabilidad hidrologica en el contexto peruano. ..... **¡Error! Marcador no definido.**
Aporte para esta tesis ..... **¡Error! Marcador no definido.**
Contextualiza optimización energética nacional y variabilidad de recursos renovables aplicable al balance PV+diésel del SEAI Iquitos. ..... **¡Error! Marcador no definido.**
Campo ..... **¡Error! Marcador no definido.**
Contenido ..... **¡Error! Marcador no definido.**
Titulo de la tesis/estudio ..... **¡Error! Marcador no definido.**
Optimización de un sistema fotovoltaico híbrido y la predicción de la demanda energética y variables climáticas utilizando la inteligencia artificial ..... **¡Error! Marcador no definido.**
Objetivo general ..... **¡Error! Marcador no definido.**
Optimizar un sistema fotovoltaico híbrido e integrar predicción de demanda y variables climáticas mediante inteligencia artificial. ..... **¡Error! Marcador no definido.**
Tipo de metodología ..... **¡Error! Marcador no definido.**
Modelado de sistema PV híbrido; aprendizaje automático para pronóstico de demanda y clima. ..... **¡Error! Marcador no definido.**
Diseño de investigación ..... **¡Error! Marcador no definido.**
Aplicada; tesis UNI; estudio de caso con datos locales. ..... **¡Error! Marcador no definido.**
Resultados cuantitativos ..... **¡Error! Marcador no definido.**
[PV] Reducción de error de predicción de demanda y mejora de desempeño del sistema híbrido; valores numéricos pendientes de verificación en repositorio UNI.**¡Error! Marcador no definido.**
Conclusión general ..... **¡Error! Marcador no definido.**
La IA mejora la operación de sistemas PV híbridos al anticipar demanda y condiciones climáticas en contexto peruano. ..... **¡Error! Marcador no definido.**
Aporte para esta tesis ..... **¡Error! Marcador no definido.**
Sustenta el uso de datos climáticos y demanda reales (PVGIS/NASA POWER) en el dataset citylearn_iquitos_2023_2025 y la relevancia de predicción para control flexible.**¡Error! Marcador no definid**
Campo ..... **¡Error! Marcador no definido.**
Contenido ..... **¡Error! Marcador no definido.**
Título de la tesis/estudio ..... **¡Error! Marcador no definido.**

Modelo de un sistema de administración de energía autónomo operado desde la nube para optimizar la gestión de un grupo de microredes ..... **¡Error! Marcador no definido.**
Objetivo general ..... **¡Error! Marcador no definido.**
Diseñar un sistema autónomo de administración de energía en la nube para optimizar la gestión coordinada de un grupo de microredes. ..... **¡Error! Marcador no definido.**
Tipo de metodología ..... **¡Error! Marcador no definido.**
Arquitectura de gestión energética distribuida en la nube; optimización multi-microred. **¡Error! Marcador no d**
Diseño de investigación ..... **¡Error! Marcador no definido.**
Aplicada; tesis; estudio de caso en microredes. ..... **¡Error! Marcador no definido.**
Resultados cuantitativos ..... **¡Error! Marcador no definido.**
[PV] Mejoras de eficiencia energética y coordinación inter-microred respecto a operación descentralizada sin orquestación en la nube. ..... **¡Error! Marcador no definido.**
Conclusión general ..... **¡Error! Marcador no definido.**
La administración autónoma en la nube mejora la coordinación operativa de microredes heterogéneas. ..... **¡Error! Marcador no definido.**
Aporte para esta tesis ..... **¡Error! Marcador no definido.**
Paralelo latinoamericano de coordinación multiagente en redes locales; informa la lectura CTDE del distrito SEAI como comunidad de 17 nodos energéticos. **¡Error! Marcador no definido.**
Eje ..... **¡Error! Marcador no definido.**
Fuentes trianguladas ..... **¡Error! Marcador no definido.**
Uso en la tesis ..... **¡Error! Marcador no definido.**
Entorno y KPIs ..... **¡Error! Marcador no definido.**
CityLearn v1/v2; CityLearn Challenge; EVLearn ..... **¡Error! Marcador no definido.**
Justifica benchmark, KPIs evaluate_v2 y control de EV/BESS. ... **¡Error! Marcador no definido.**
MADRL ..... **¡Error! Marcador no definido.**
MAAC; HAPPO; SAC; TD3 ..... **¡Error! Marcador no definido.**
Justifica comparación de familias actor-critic multiagente. ..... **¡Error! Marcador no definido.**
Evaluación rigurosa ..... **¡Error! Marcador no definido.**
Henderson et al.; Agarwal et al. ..... **¡Error! Marcador no definido.**
Justifica pruebas no paramétricas y cautela ante una sola corrida. **¡Error! Marcador no definido.**
Variables ..... **¡Error! Marcador no definido.**
Flexibilidad, CO_2 y costo en comunidades grid-interactive ..... **¡Error! Marcador no definido.**
Sostiene D-VD.1, D-VD.2 y D-VD.3. ..... **¡Error! Marcador no definido.**
Criterio ..... **¡Error! Marcador no definido.**

Decisión metodológica ..... **¡Error! Marcador no definido.**
Sustento ..... **¡Error! Marcador no definido.**
Enfoque ..... **¡Error! Marcador no definido.**
Cuantitativo ..... **¡Error! Marcador no definido.**
Medición numérica de KPIs y contrastación estadística. ..... **¡Error! Marcador no definido.**
Tipo ..... **¡Error! Marcador no definido.**
Aplicada ..... **¡Error! Marcador no definido.**
Desarrollo y evaluación de una propuesta MADRL para gestión energética. **¡Error! Marcador no definido.**
Nivel ..... **¡Error! Marcador no definido.**
Explicativo-comparativo ..... **¡Error! Marcador no definido.**
Evalúa efecto de algoritmos y escenarios sobre dimensiones VD. **¡Error! Marcador no definido.**
Diseño ..... **¡Error! Marcador no definido.**
Experimental-computacional factorial 4 × 3 ..... **¡Error! Marcador no definido.**
Manipulación controlada de algoritmo y escenario en simulación. **¡Error! Marcador no definido.**
Temporalidad ..... **¡Error! Marcador no definido.**
Longitudinal por episodios y horizonte anual horario ..... **¡Error! Marcador no definido.**
Cada episodio recorre una trayectoria anual de 8760 pasos. ..... **¡Error! Marcador no definido.**
Inferencia ..... **¡Error! Marcador no definido.**
Intra-corrida con limitación multi-semilla ..... **¡Error! Marcador no definido.**
No se generaliza mas allá de los artefactos auditados. ..... **¡Error! Marcador no definido.**
Factor ..... **¡Error! Marcador no definido.**
Niveles ..... **¡Error! Marcador no definido.**
Función metodológica ..... **¡Error! Marcador no definido.**
Algoritmo MADRL ..... **¡Error! Marcador no definido.**
HAPPO, MAAC, MASAC, MATD3 ..... **¡Error! Marcador no definido.**
Variable independiente principal; compara familias actor-critic multiagente. **¡Error! Marcador no definido.**
Escenario de recompensa ..... **¡Error! Marcador no definido.**
E1, E2, E3 ..... **¡Error! Marcador no definido.**
Manipulación de prioridad multiobjetivo: flexibilidad, CO_2 y costo. **¡Error! Marcador no definido.**
Tratamientos ..... **¡Error! Marcador no definido.**
12 combinaciones ..... **¡Error! Marcador no definido.**
Base de comparación para resultados por objetivo específico. .... **¡Error! Marcador no definido.**
Horizonte ..... **¡Error! Marcador no definido.**
50 episodios registrados por tratamiento ..... **¡Error! Marcador no definido.**

Evidencia de entrenamiento Drive; se declara cobertura materializada por algoritmo.**¡Error! Marcador no de**
Artefacto ..... **¡Error! Marcador no definido.**
Contenido ..... **¡Error! Marcador no definido.**
Uso metodológico ..... **¡Error! Marcador no definido.**
timeseries.csv ..... **¡Error! Marcador no definido.**
Serie temporal distrital por episodio ..... **¡Error! Marcador no definido.**
Energía, costo, CO_2, recompensa y señales horarias. ..... **¡Error! Marcador no definido.**
trace.csv ..... **¡Error! Marcador no definido.**
Trazas por agente ..... **¡Error! Marcador no definido.**
Acciones, SOC, EV, PV, importación/exportación y recompensa individual.**¡Error! Marcador no definido.**
building_kpis.csv / building_behavior_summary.csv ..... **¡Error! Marcador no definido.**
KPIs por edificio ..... **¡Error! Marcador no definido.**
Análisis espacial por agente y equipamiento. ..... **¡Error! Marcador no definido.**
checkpoint_manifest.json ..... **¡Error! Marcador no definido.**
Registro de checkpoints ..... **¡Error! Marcador no definido.**
Trazabilidad de entrenamiento y cobertura por tratamiento. ..... **¡Error! Marcador no definido.**
district_episode_kpis.csv ..... **¡Error! Marcador no definido.**
KPIs episódicos materializados ..... **¡Error! Marcador no definido.**
Base de estadística descriptiva e inferencial. ..... **¡Error! Marcador no definido.**
Variable ..... **¡Error! Marcador no definido.**
Dimensión ..... **¡Error! Marcador no definido.**
Indicadores principales ..... **¡Error! Marcador no definido.**
Fuente ..... **¡Error! Marcador no definido.**
VI ..... **¡Error! Marcador no definido.**
D-VI.1 Algoritmo ..... **¡Error! Marcador no definido.**
HAPPO, MAAC, MASAC, MATD3 ..... **¡Error! Marcador no definido.**
Configuración de tratamiento. ..... **¡Error! Marcador no definido.**
VI ..... **¡Error! Marcador no definido.**
D-VI.2 Escenario ..... **¡Error! Marcador no definido.**
E1, E2, E3; pesos flex/CO2/costo ..... **¡Error! Marcador no definido.**
reward_axis_weights y protocolo experimental. ..... **¡Error! Marcador no definido.**
VD ..... **¡Error! Marcador no definido.**
D-VD.1 Flexibilidad ..... **¡Error! Marcador no definido.**
reward_mean E1, peak, ramping, load factor, BESS/PV ..... **¡Error! Marcador no definido.**

episodes, results, evaluate_v2. ..... **¡Error! Marcador no definido.**
VD ..... **¡Error! Marcador no definido.**
D-VD.2 CO_2 ..... **¡Error! Marcador no definido.**
district_emission, carbon_emissions_control/delta ..... **¡Error! Marcador no definido.**
timeseries, results, building KPIs. ..... **¡Error! Marcador no definido.**
VD ..... **¡Error! Marcador no definido.**
D-VD.3 Costos ..... **¡Error! Marcador no definido.**
district_cost, electricity_cost_control/delta ..... **¡Error! Marcador no definido.**
timeseries, results, building KPIs. ..... **¡Error! Marcador no definido.**
Componente ..... **¡Error! Marcador no definido.**
Aplicación en la tesis ..... **¡Error! Marcador no definido.**
Resultado esperado ..... **¡Error! Marcador no definido.**
Simulación CityLearn ..... **¡Error! Marcador no definido.**
Recrear comunidad energética multiagente ..... **¡Error! Marcador no definido.**
Series, KPIs y trazas auditables. ..... **¡Error! Marcador no definido.**
MADRL ..... **¡Error! Marcador no definido.**
Entrenar políticas bajo CTDE ..... **¡Error! Marcador no definido.**
Políticas por algoritmo y escenario. ..... **¡Error! Marcador no definido.**
evaluate_v2 / KPIs ..... **¡Error! Marcador no definido.**
Evaluar flexibilidad, CO_2 y costo ..... **¡Error! Marcador no definido.**
Ranking comparable con baseline. ..... **¡Error! Marcador no definido.**
Estadística no paramétrica ..... **¡Error! Marcador no definido.**
Contrastar diferencias entre algoritmos ..... **¡Error! Marcador no definido.**
p-valores, epsilon2 y decisiones HE. ..... **¡Error! Marcador no definido.**
Visualización ..... **¡Error! Marcador no definido.**
Interpretar convergencia, trade-offs, edificios y acciones ..... **¡Error! Marcador no definido.**
Figuras del Capítulo 5. ..... **¡Error! Marcador no definido.**
Fase ..... **¡Error! Marcador no definido.**
Actividad ..... **¡Error! Marcador no definido.**
Evidencia ..... **¡Error! Marcador no definido.**
1 ..... **¡Error! Marcador no definido.**
Verificación de contexto y rutas ..... **¡Error! Marcador no definido.**
scripts/verify_project_context.ps1. ..... **¡Error! Marcador no definido.**
2 ..... **¡Error! Marcador no definido.**

Validación de dataset y esquema CityLearn ..... **¡Error! Marcador no definido.**
schema, building files y auditoria's. ..... **¡Error! Marcador no definido.**
3 ..... **¡Error! Marcador no definido.**
Entrenamiento/recuperación de 12 tratamientos ..... **¡Error! Marcador no definido.**
Drive madrl_v3_20260627_164047. ..... **¡Error! Marcador no definido.**
4 ..... **¡Error! Marcador no definido.**
Consolidación de resultados ..... **¡Error! Marcador no definido.**
timeseries, traces, checkpoints y KPIs. ..... **¡Error! Marcador no definido.**
5 ..... **¡Error! Marcador no definido.**
Análisis descriptivo e inferencial ..... **¡Error! Marcador no definido.**
CSV de estadísticas y comparaciones Holm. ..... **¡Error! Marcador no definido.**
6 ..... **¡Error! Marcador no definido.**
Visualización académica ..... **¡Error! Marcador no definido.**
Figuras por convergencia, KPIs, edificios y trade-offs. ..... **¡Error! Marcador no definido.**
7 ..... **¡Error! Marcador no definido.**
Integración en Word ..... **¡Error! Marcador no definido.**
Documento final reproducible desde el generador. ..... **¡Error! Marcador no definido.**
Dimensión de validez ..... **¡Error! Marcador no definido.**
Riesgo ..... **¡Error! Marcador no definido.**
Control aplicado ..... **¡Error! Marcador no definido.**
Interna ..... **¡Error! Marcador no definido.**
Comparación desigual entre algoritmos ..... **¡Error! Marcador no definido.**
Mismo dataset, mismo entorno y escenarios controlados. ..... **¡Error! Marcador no definido.**
Constructo ..... **¡Error! Marcador no definido.**
Indicadores no alineados con objetivos ..... **¡Error! Marcador no definido.**
PE/OE/VD/KPI vinculados por tabla de operacionalización. ..... **¡Error! Marcador no definido.**
Estadística ..... **¡Error! Marcador no definido.**
Normalidad o significancia asumida ..... **¡Error! Marcador no definido.**
Shapiro-Wilk, Kruskal-Wallis, Mann-Whitney-Holm y epsilon2. ..... **¡Error! Marcador no definido.**
Externa ..... **¡Error! Marcador no definido.**
Generalización indebida ..... **¡Error! Marcador no definido.**
Declaración de inferencia intra-corrida y recomendación multi-semilla. **¡Error! Marcador no definido.**
Trazabilidad ..... **¡Error! Marcador no definido.**
Datos inventados o mezclados ..... **¡Error! Marcador no definido.**

Uso exclusivo de artefactos Drive y CSV materializados. ..... **¡Error! Marcador no definido.**
Tabla 4.1 Capas de software del sistema MADRL CityLearn v3 .. **¡Error! Marcador no definido.**
Capa ..... **¡Error! Marcador no definido.**
Componente ..... **¡Error! Marcador no definido.**
Función ..... **¡Error! Marcador no definido.**
1 ..... **¡Error! Marcador no definido.**
CityLearn v2 (CityLearn/citylearn/*.py) ..... **¡Error! Marcador no definido.**
Física de edificios, BESS, PV, EV y KPIs oficiales. ..... **¡Error! Marcador no definido.**
2 ..... **¡Error! Marcador no definido.**
CityLearn v3 propuesto (CityLearn/citylearn/v3/) ..... **¡Error! Marcador no definido.**
Entorno Dec-POMDP, objetivos, configuración y recompensa multiobjetivo.**¡Error! Marcador no definido.**
3 ..... **¡Error! Marcador no definido.**
Framework UC3M (uc3m/) ..... **¡Error! Marcador no definido.**
Wrapper universal (UC3MEnv), 7 ejes de recompensa, KPIEvaluator, AlgorithmFactory; capa auxiliar/generica. ..... **¡Error! Marcador no definido.**
4 ..... **¡Error! Marcador no definido.**
Backends MADRL (external/) ..... **¡Error! Marcador no definido.**
HARL (HAPPO), MARL/src (MASAC), off-policy (MATD3 activo), MAAC.**¡Error! Marcador no definido.**
5 ..... **¡Error! Marcador no definido.**
Launchers y orquestación ..... **¡Error! Marcador no definido.**
train_citylearn_v3_*.py, launchers PowerShell y Colab A100, monitoreo y checkpointing.**¡Error! Marcador n**
6 ..... **¡Error! Marcador no definido.**
Evaluación y evidencia ..... **¡Error! Marcador no definido.**
benchmark_citylearn_v2_agents.py, compare_citylearn_v2_vs_v3_madrl.py, generate_thesis_objective_evidence.py. ..... **¡Error! Marcador no definido.**
Tabla 4.2 Los cuatro algoritmos MADRL y sus backends ..... **¡Error! Marcador no definido.**
Algoritmo ..... **¡Error! Marcador no definido.**
Tipo ..... **¡Error! Marcador no definido.**
Backend / wrapper ..... **¡Error! Marcador no definido.**
Característica clave ..... **¡Error! Marcador no definido.**
HAPPO ..... **¡Error! Marcador no definido.**
On-policy ..... **¡Error! Marcador no definido.**
external/HARL · CityLearnHARLEnv ..... **¡Error! Marcador no definido.**
Actualización secuencial con trust región; mejora monotona. ..... **¡Error! Marcador no definido.**

MASAC ..... **¡Error! Marcador no definido.**
Off-policy ..... **¡Error! Marcador no definido.**
external/MARL/src · CityLearnSMACDiscreteEnv ..... **¡Error! Marcador no definido.**
SAC + QMIX, acciones discretizadas por eje, RNN. ..... **¡Error! Marcador no definido.**
MATD3 ..... **¡Error! Marcador no definido.**
Off-policy ..... **¡Error! Marcador no definido.**
external/off-policy · CityLearnOffPolicyVecEnv ..... **¡Error! Marcador no definido.**
Doble crítico TD3, policy delay, target noise (backend activo). .... **¡Error! Marcador no definido.**
MAAC ..... **¡Error! Marcador no definido.**
Off-policy ..... **¡Error! Marcador no definido.**
external/MAAC · CityLearnMAACVecEnv ..... **¡Error! Marcador no definido.**
Crítico de atención multi-cabeza (4 heads). ..... **¡Error! Marcador no definido.**
Tabla 4.3 Configuración de entrenamiento y delimitación de la evidencia canónica**¡Error! Marcador no defi**
Parametro ..... **¡Error! Marcador no definido.**
Colab canónico (50 ep) ..... **¡Error! Marcador no definido.**
Local v4 (5 ep) ..... **¡Error! Marcador no definido.**
Notas ..... **¡Error! Marcador no definido.**
Episodios × pasos ..... **¡Error! Marcador no definido.**
50 × 8 760 ..... **¡Error! Marcador no definido.**
5 × 8 760 ..... **¡Error! Marcador no definido.**
438 000 vs 43 800 pasos/corrida ..... **¡Error! Marcador no definido.**
gamma ..... **¡Error! Marcador no definido.**
0.9999 ..... **¡Error! Marcador no definido.**
0.9999 ..... **¡Error! Marcador no definido.**
Identico ..... **¡Error! Marcador no definido.**
hidden / actor ..... **¡Error! Marcador no definido.**
[512,512] HAPPO; 768 MATD3/MAAC ..... **¡Error! Marcador no definido.**
[256,256] todos ..... **¡Error! Marcador no definido.**
Mayor capacidad en Colab ..... **¡Error! Marcador no definido.**
replay_buffer MATD3 ..... **¡Error! Marcador no definido.**
2 000 000 ..... **¡Error! Marcador no definido.**
4 096 ..... **¡Error! Marcador no definido.**
Restriccion VRAM 8 GB local ..... **¡Error! Marcador no definido.**
batch MATD3 ..... **¡Error! Marcador no definido.**

1 024 ..... **¡Error! Marcador no definido.**
256 ..... **¡Error! Marcador no definido.**
Colab A100 ..... **¡Error! Marcador no definido.**
MASAC replay ..... **¡Error! Marcador no definido.**
2 ep CPU ..... **¡Error! Marcador no definido.**
on-GPU reducido ..... **¡Error! Marcador no definido.**
Protocolo two_phase_happo_masac ..... **¡Error! Marcador no definido.**
Semillas ..... **¡Error! Marcador no definido.**
seed 0 ..... **¡Error! Marcador no definido.**
seed 0 ..... **¡Error! Marcador no definido.**
Limitación inferencial ..... **¡Error! Marcador no definido.**
GPU ..... **¡Error! Marcador no definido.**
A100-SXM4-80GB ..... **¡Error! Marcador no definido.**
RTX 4060 8 GB ..... **¡Error! Marcador no definido.**
madrl_v3_20260627_164047 ..... **¡Error! Marcador no definido.**
Tabla 4.4 Parámetros de la función de recompensa multiobjetivo (perfil unificado v4)**¡Error! Marcador no de**
Parametro ..... **¡Error! Marcador no definido.**
Valor ..... **¡Error! Marcador no definido.**
Justificación sintética ..... **¡Error! Marcador no definido.**
w_flex / w_carbon / w_cost (E1) ..... **¡Error! Marcador no definido.**
0.70 / 0.15 / 0.15 ..... **¡Error! Marcador no definido.**
Escenario lexicográfico de flexibilidad. ..... **¡Error! Marcador no definido.**
w_flex / w_carbon / w_cost (E2) ..... **¡Error! Marcador no definido.**
0.15 / 0.70 / 0.15 ..... **¡Error! Marcador no definido.**
Escenario lexicográfico de CO_2. ..... **¡Error! Marcador no definido.**
w_flex / w_carbon / w_cost (E3) ..... **¡Error! Marcador no definido.**
0.25 / 0.15 / 0.60 ..... **¡Error! Marcador no definido.**
Costo-pico correlacionados en TOU. ..... **¡Error! Marcador no definido.**
team_reward_ratio ® ..... **¡Error! Marcador no definido.**
0.70 ..... **¡Error! Marcador no definido.**
Coordinación cooperativa Dec-POMDP (media de perfiles del plan).**¡Error! Marcador no definido.**
peak_weight / ramp_weight ..... **¡Error! Marcador no definido.**
0.45 / 0.35 ..... **¡Error! Marcador no definido.**
KPI primario y secundario de flexibilidad CityLearn. ..... **¡Error! Marcador no definido.**

ev_weight ..... ¡Error! Marcador no definido.
0.25 ..... ¡Error! Marcador no definido.
Término EV/SOC reforzado para evitar dejar EV sin cargar. ..... ¡Error! Marcador no definido.
reward_scale ..... ¡Error! Marcador no definido.
1.00 ..... ¡Error! Marcador no definido.
Escala uniforme para gradientes comparables. ..... ¡Error! Marcador no definido.
carbon_reference / price_reference ..... ¡Error! Marcador no definido.
0.35 / 0.20 ..... ¡Error! Marcador no definido.
Referencia global IEA y spot competitivo. ..... ¡Error! Marcador no definido.
..... ¡Error! Marcador no definido.
Aporte ..... ¡Error! Marcador no definido.
Clase/Método ..... ¡Error! Marcador no definido.
Modelo incorporado ..... ¡Error! Marcador no definido.
A1 ..... ¡Error! Marcador no definido.
Degradation BESS C-rate + Arrhenius ..... ¡Error! Marcador no definido.
Battery.degrade(temperature_celsius) ..... ¡Error! Marcador no definido.
ΔC = base·(C_rate) ^0.55·exp [Ea/R (1/T_ref - 1/T)], Ea=24500 J/mol. ¡Error! Marcador no definido.
A2 ..... ¡Error! Marcador no definido.
Corrección PV tropical (IEC 61215) ..... ¡Error! Marcador no definido.
PV.get_generation (dry_bulb_temperature, ghi) ..... ¡Error! Marcador no definido.
T_cell = T_amb + (NOCT-20)/800·G; P(T)=P_STC·[1+γ(T_cell-25)], γ=-0.0035/°C. ¡Error! Marcador no defi
A3 ..... ¡Error! Marcador no definido.
KPI pico con ventana de facturacion ..... ¡Error! Marcador no definido.
CostFunction.peak(billing_window_steps) ..... ¡Error! Marcador no definido.
Máximo rodante sub-horario (OSINERGMIN MT-3/MT-4, 15 min). ¡Error! Marcador no definido.
A4 ..... ¡Error! Marcador no definido.
Modelo CI dinamico diésel+PV ..... ¡Error! Marcador no definido.
CarbonIntensityModel (base_ci, pv_displacement_factor) ..... ¡Error! Marcador no definido.
CI(t)=0.790(1-0.15·min (GHI/1000,1)). ..... ¡Error! Marcador no definido.
Escenario ..... ¡Error! Marcador no definido.
HAPPO ..... ¡Error! Marcador no definido.
MASAC ..... ¡Error! Marcador no definido.
MATD3 ..... ¡Error! Marcador no definido.
MAAC ..... ¡Error! Marcador no definido.

E1 Flexibilidad ..... **¡Error! Marcador no definido.**
happo/E1_s0 ..... **¡Error! Marcador no definido.**
masac/E1_s0 ..... **¡Error! Marcador no definido.**
matd3/E1_s0 ..... **¡Error! Marcador no definido.**
maac/E1_s0 ..... **¡Error! Marcador no definido.**
E2 CO_2 ..... **¡Error! Marcador no definido.**
happo/E2_s0 ..... **¡Error! Marcador no definido.**
masac/E2_s0 ..... **¡Error! Marcador no definido.**
matd3/E2_s0 ..... **¡Error! Marcador no definido.**
maac/E2_s0 ..... **¡Error! Marcador no definido.**
E3 Costos ..... **¡Error! Marcador no definido.**
happo/E3_s0 ..... **¡Error! Marcador no definido.**
masac/E3_s0 ..... **¡Error! Marcador no definido.**
matd3/E3_s0 ..... **¡Error! Marcador no definido.**
maac/E3_s0 ..... **¡Error! Marcador no definido.**
Componente ..... **¡Error! Marcador no definido.**
Detalle desarrollado en la propuesta ..... **¡Error! Marcador no definido.**
Evidencia/artefacto ..... **¡Error! Marcador no definido.**
Comunidad inteligente ..... **¡Error! Marcador no definido.**
17 edificios institucionales/comerciales del SEAI Iquitos, modelados como agentes heterogéneos. ..... **¡Error! Marcador no definido.**
dataset citylearn_iquitos_2023_2025; building_behavior_summary.csv. **¡Error! Marcador no definido.**
Horizonte temporal ..... **¡Error! Marcador no definido.**
26 304 pasos horarios del periodo 2023-2025; cada episodio experimental evalúa un ano horario de 8 760 pasos. ..... **¡Error! Marcador no definido.**
archivos CSV del dataset y timeseries.csv. ..... **¡Error! Marcador no definido.**
Recursos energéticos ..... **¡Error! Marcador no definido.**
PV, BESS, cargadores EV, V2G, cargas controlables y demanda no controlada separada para evitar atribuir acciones a cargas no actuables. ..... **¡Error! Marcador no definido.**
schema de edificios, traces y building KPIs. ..... **¡Error! Marcador no definido.**
Tratamientos MADRL ..... **¡Error! Marcador no definido.**
HAPPO, MAAC, MASAC y MATD3 bajo escenarios E1 flexibilidad, E2 CO_2 y E3 costos. **¡Error! Marcador no**
12 carpetas algoritmo-escenario y tablas episódicas. ..... **¡Error! Marcador no definido.**
Evidencia experimental ..... **¡Error! Marcador no definido.**

50 episodios por tratamiento disponible; HAPPO conserva 49 filas episódicas materializadas
por escenario en el CSV final y se interpreta con esa limitación. . **¡Error! Marcador no definido.**
district_episode_kpis.csv y tablas de estadística. ..... **¡Error! Marcador no definido.**
Tabla 4.8 Fuentes y transformaciones del datase citylearn_iquitos_2023_2025**¡Error! Marcador no definid**
Fuente/insumo ..... **¡Error! Marcador no definido.**
Transformación en el proyecto ..... **¡Error! Marcador no definido.**
Uso en CityLearn/MADRL ..... **¡Error! Marcador no definido.**
Electro Oriente S.A. ..... **¡Error! Marcador no definido.**
Perfiles de demanda/facturacion y contexto del SEAI Iquitos. ..... **¡Error! Marcador no definido.**
Demanda base y calibración de edificios. ..... **¡Error! Marcador no definido.**
NASA POWER ..... **¡Error! Marcador no definido.**
Series meteorológicas horarias para el periodo de estudio. ..... **¡Error! Marcador no definido.**
Variables exógenas de clima en observaciones. ..... **¡Error! Marcador no definido.**
PVGIS y pvlib ..... **¡Error! Marcador no definido.**
Estimación de generación solar y perfiles PV por capacidad instalada. **¡Error! Marcador no definido.**
Producción fotovoltaica por edificio y balance energético. ..... **¡Error! Marcador no definido.**
Inventario de edificios y equipos ..... **¡Error! Marcador no definido.**
Asignación de PV, BESS, EV, V2G, cargas controlables y no controlables. **¡Error! Marcador no definido.**
Dimensiones de observación/acción y heterogeneidad de agentes. **¡Error! Marcador no definido.**
MINAM ..... **¡Error! Marcador no definido.**
Factor de emisión base y modelo de intensidad de carbono. ..... **¡Error! Marcador no definido.**
Cálculo de emisiones y recompensa carbon-aware. ..... **¡Error! Marcador no definido.**
OSINERGMIN / señales TOU ..... **¡Error! Marcador no definido.**
Parametrización de precios punta y fuera de punta. ..... **¡Error! Marcador no definido.**
Costo eléctrico y recompensa económica. ..... **¡Error! Marcador no definido.**
Tabla 4.9 Herramientas y función dentro de la propuesta MADRL **¡Error! Marcador no definido.**
Herramienta/libreria ..... **¡Error! Marcador no definido.**
Función técnica ..... **¡Error! Marcador no definido.**
Salida esperada ..... **¡Error! Marcador no definido.**
Python 3.9 ..... **¡Error! Marcador no definido.**
Lenguaje base de orquestación, análisis y generación documental. **¡Error! Marcador no definido.**
Scripts reproducibles y tablas/figuras. ..... **¡Error! Marcador no definido.**
pandas, NumPy ..... **¡Error! Marcador no definido.**
Tratamiento de CSV, agregación por episodio, edificio, escenario y algoritmo. **¡Error! Marcador no definido**

district_episode_kpis, rankings y resumenes. ..... **¡Error! Marcador no definido.**
pvlib, PVGIS, NASA POWER ..... **¡Error! Marcador no definido.**
Modelado solar y meteorologico del dataset. ..... **¡Error! Marcador no definido.**
Perfiles PV y variables exógenas horarias. ..... **¡Error! Marcador no definido.**
PyTorch ..... **¡Error! Marcador no definido.**
Entrenamiento de redes actor-critic y políticas MADRL. ..... **¡Error! Marcador no definido.**
Políticas, rewards, checkpoints. ..... **¡Error! Marcador no definido.**
CityLearn v2 / CityLearn v3 propuesto ..... **¡Error! Marcador no definido.**
Simulación energética multiagente con PV, BESS, EV, carbono y costos. **¡Error! Marcador no definido.**
Observaciones, acciones, rewards, KPIs. ..... **¡Error! Marcador no definido.**
Gymnasium, PettingZoo ..... **¡Error! Marcador no definido.**
Interfaz multiagente y compatibilidad de entorno. ..... **¡Error! Marcador no definido.**
Ejecución descentralizada y wrappers. ..... **¡Error! Marcador no definido.**
SciPy ..... **¡Error! Marcador no definido.**
Shapiro-Wilk, Kruskal-Wallis y Mann-Whitney U con ajuste posterior. **¡Error! Marcador no definido.**
Contraste inferencial por OE.1-OE.3. ..... **¡Error! Marcador no definido.**
Matplotlib ..... **¡Error! Marcador no definido.**
Graficacion de convergencia, boxplots, radar, heatmaps, trade-offs y series finales. **¡Error! Marcador no def**
Figuras del Capítulo 5. ..... **¡Error! Marcador no definido.**
Google Colab/Drive ..... **¡Error! Marcador no definido.**
Ejecución y persistencia de la corrida canónica. ..... **¡Error! Marcador no definido.**
results, timeseries, traces, checkpoints. ..... **¡Error! Marcador no definido.**
Fase ..... **¡Error! Marcador no definido.**
Entrada ..... **¡Error! Marcador no definido.**
Proceso ..... **¡Error! Marcador no definido.**
Salida verificable ..... **¡Error! Marcador no definido.**
Construcción de datos ..... **¡Error! Marcador no definido.**
Electro Oriente, NASA POWER, PVGIS, MINAM, OSINERGMIN, inventario de equipos. **¡Error! Marcador no**
Normalización, generación de perfiles y auditoria de CSV. ..... **¡Error! Marcador no definido.**
dataset citylearn_iquitos_2023_2025. ..... **¡Error! Marcador no definido.**
Simulación ..... **¡Error! Marcador no definido.**
Dataset y configuración de edificios. ..... **¡Error! Marcador no definido.**
Instanciación CityLearn v2 / CityLearn v3 propuesto. ..... **¡Error! Marcador no definido.**
observaciones, acciones y balances horarios. ..... **¡Error! Marcador no definido.**

Entrenamiento MADRL ..... **¡Error! Marcador no definido.**
Algoritmo, escenario y recompensa multiobjetivo. ..... **¡Error! Marcador no definido.**
CTDE con políticas descentralizadas. ..... **¡Error! Marcador no definido.**
rewards, checkpoints y logs. ..... **¡Error! Marcador no definido.**
Registro de evidencia ..... **¡Error! Marcador no definido.**
Ejecución por tratamiento. ..... **¡Error! Marcador no definido.**
Persistencia en Drive y consolidación local. ..... **¡Error! Marcador no definido.**
results.json, timeseries.csv, trace.csv, building_kpis.csv. ..... **¡Error! Marcador no definido.**
Análisis de la tesis ..... **¡Error! Marcador no definido.**
CSV episódicos, traces, checkpoints y KPIs. ..... **¡Error! Marcador no definido.**
Estadística, figuras y lectura por OE. ..... **¡Error! Marcador no definido.**
Capítulos 5 y 6 con evidencia real. ..... **¡Error! Marcador no definido.**
Tabla 4.11 Respuesta directa a PE.1, PE.2 y PE.3 desde la evidencia descriptiva e inferencial ..... **¡Error! Marcador no definido.**
Pregunta ..... **¡Error! Marcador no definido.**
Dimensión ..... **¡Error! Marcador no definido.**
Esc. ..... **¡Error! Marcador no definido.**
Indicador ..... **¡Error! Marcador no definido.**
Medida del efecto ..... **¡Error! Marcador no definido.**
Decisión ..... **¡Error! Marcador no definido.**
mejor descriptivo ..... **¡Error! Marcador no definido.**
mejor inferencial ..... **¡Error! Marcador no definido.**
mejor KPI final ..... **¡Error! Marcador no definido.**
PE.1 ..... **¡Error! Marcador no definido.**
flexibilidad energética ..... **¡Error! Marcador no definido.**
E1 ..... **¡Error! Marcador no definido.**
reward_mean_average ..... **¡Error! Marcador no definido.**
H=36.3083; p=1.30545e-08; epsilon2=0.2334 (efecto alto) ..... **¡Error! Marcador no definido.**
se rechaza H0 ..... **¡Error! Marcador no definido.**
MAAC ..... **¡Error! Marcador no definido.**
MAAC ..... **¡Error! Marcador no definido.**
MASAC ..... **¡Error! Marcador no definido.**
PE.2 ..... **¡Error! Marcador no definido.**
emisiones de CO_2 ..... **¡Error! Marcador no definido.**

E2 ..... **¡Error! Marcador no definido.**
district_emission ..... **¡Error! Marcador no definido.**
H=6.2532; p=0.0438656; epsilon2=0.0289 (efecto bajo) ..... **¡Error! Marcador no definido.**
se rechaza H0 ..... **¡Error! Marcador no definido.**
HAPPO ..... **¡Error! Marcador no definido.**
MAAC ..... **¡Error! Marcador no definido.**
MASAC ..... **¡Error! Marcador no definido.**
PE.3 ..... **¡Error! Marcador no definido.**
costos energéticos ..... **¡Error! Marcador no definido.**
E3 ..... **¡Error! Marcador no definido.**
district_cost ..... **¡Error! Marcador no definido.**
H=2.7613; p=0.251421; epsilon2=0.0052 (efecto muy bajo) ..... **¡Error! Marcador no definido.**
no se rechaza H0 ..... **¡Error! Marcador no definido.**
HAPPO ..... **¡Error! Marcador no definido.**
MATD3 ..... **¡Error! Marcador no definido.**
MAAC ..... **¡Error! Marcador no definido.**
Tabla 5.1 Cobertura real de artefactos por tratamiento en Google Drive **¡Error! Marcador no definido.**
Algoritmo ..... **¡Error! Marcador no definido.**
Escenario ..... **¡Error! Marcador no definido.**
episodios registrados ..... **¡Error! Marcador no definido.**
resumenes G: ..... **¡Error! Marcador no definido.**
episodios KPI usados ..... **¡Error! Marcador no definido.**
edificios ..... **¡Error! Marcador no definido.**
checkpoints ..... **¡Error! Marcador no definido.**
HAPPO ..... **¡Error! Marcador no definido.**
E1 ..... **¡Error! Marcador no definido.**
50 ..... **¡Error! Marcador no definido.**
1 ..... **¡Error! Marcador no definido.**
49 ..... **¡Error! Marcador no definido.**
17 ..... **¡Error! Marcador no definido.**
0 ..... **¡Error! Marcador no definido.**
HAPPO ..... **¡Error! Marcador no definido.**
E2 ..... **¡Error! Marcador no definido.**
50 ..... **¡Error! Marcador no definido.**

1 ..... **¡Error! Marcador no definido.**
49 ..... **¡Error! Marcador no definido.**
17 ..... **¡Error! Marcador no definido.**
0 ..... **¡Error! Marcador no definido.**
HAPPO ..... **¡Error! Marcador no definido.**
E3 ..... **¡Error! Marcador no definido.**
50 ..... **¡Error! Marcador no definido.**
1 ..... **¡Error! Marcador no definido.**
49 ..... **¡Error! Marcador no definido.**
17 ..... **¡Error! Marcador no definido.**
0 ..... **¡Error! Marcador no definido.**
MAAC ..... **¡Error! Marcador no definido.**
E1 ..... **¡Error! Marcador no definido.**
50 ..... **¡Error! Marcador no definido.**
50 ..... **¡Error! Marcador no definido.**
50 ..... **¡Error! Marcador no definido.**
17 ..... **¡Error! Marcador no definido.**
52 ..... **¡Error! Marcador no definido.**
MAAC ..... **¡Error! Marcador no definido.**
E2 ..... **¡Error! Marcador no definido.**
50 ..... **¡Error! Marcador no definido.**
50 ..... **¡Error! Marcador no definido.**
50 ..... **¡Error! Marcador no definido.**
17 ..... **¡Error! Marcador no definido.**
52 ..... **¡Error! Marcador no definido.**
MAAC ..... **¡Error! Marcador no definido.**
E3 ..... **¡Error! Marcador no definido.**
50 ..... **¡Error! Marcador no definido.**
50 ..... **¡Error! Marcador no definido.**
50 ..... **¡Error! Marcador no definido.**
17 ..... **¡Error! Marcador no definido.**
52 ..... **¡Error! Marcador no definido.**
MASAC ..... **¡Error! Marcador no definido.**
E1 ..... **¡Error! Marcador no definido.**

50 ..... **¡Error! Marcador no definido.**
50 ..... **¡Error! Marcador no definido.**
50 ..... **¡Error! Marcador no definido.**
17 ..... **¡Error! Marcador no definido.**
12 ..... **¡Error! Marcador no definido.**
MASAC ..... **¡Error! Marcador no definido.**
E2 ..... **¡Error! Marcador no definido.**
50 ..... **¡Error! Marcador no definido.**
50 ..... **¡Error! Marcador no definido.**
50 ..... **¡Error! Marcador no definido.**
17 ..... **¡Error! Marcador no definido.**
12 ..... **¡Error! Marcador no definido.**
MASAC ..... **¡Error! Marcador no definido.**
E3 ..... **¡Error! Marcador no definido.**
50 ..... **¡Error! Marcador no definido.**
50 ..... **¡Error! Marcador no definido.**
50 ..... **¡Error! Marcador no definido.**
17 ..... **¡Error! Marcador no definido.**
12 ..... **¡Error! Marcador no definido.**
MATD3 ..... **¡Error! Marcador no definido.**
E1 ..... **¡Error! Marcador no definido.**
50 ..... **¡Error! Marcador no definido.**
50 ..... **¡Error! Marcador no definido.**
50 ..... **¡Error! Marcador no definido.**
17 ..... **¡Error! Marcador no definido.**
34 ..... **¡Error! Marcador no definido.**
MATD3 ..... **¡Error! Marcador no definido.**
E2 ..... **¡Error! Marcador no definido.**
50 ..... **¡Error! Marcador no definido.**
50 ..... **¡Error! Marcador no definido.**
50 ..... **¡Error! Marcador no definido.**
17 ..... **¡Error! Marcador no definido.**
34 ..... **¡Error! Marcador no definido.**
MATD3 ..... **¡Error! Marcador no definido.**

E3 ..... **¡Error! Marcador no definido.**
50 ..... **¡Error! Marcador no definido.**
50 ..... **¡Error! Marcador no definido.**
50 ..... **¡Error! Marcador no definido.**
17 ..... **¡Error! Marcador no definido.**
34 ..... **¡Error! Marcador no definido.**
Tabla 5.2 Trazabilidad objetivo-hipótesis-escenario-indicador ..... **¡Error! Marcador no definido.**
Objetivo ..... **¡Error! Marcador no definido.**
Hipótesis ..... **¡Error! Marcador no definido.**
Escenario ..... **¡Error! Marcador no definido.**
Dimensión VD ..... **¡Error! Marcador no definido.**
Indicador usado ..... **¡Error! Marcador no definido.**
Criterio ..... **¡Error! Marcador no definido.**
OE.1 ..... **¡Error! Marcador no definido.**
HE.1 ..... **¡Error! Marcador no definido.**
E1 ..... **¡Error! Marcador no definido.**
flexibilidad energética ..... **¡Error! Marcador no definido.**
recompensa media del episodio en E1 ..... **¡Error! Marcador no definido.**
maximizar ..... **¡Error! Marcador no definido.**
OE.2 ..... **¡Error! Marcador no definido.**
HE.2 ..... **¡Error! Marcador no definido.**
E2 ..... **¡Error! Marcador no definido.**
emisiones de CO_2 ..... **¡Error! Marcador no definido.**
suma anual de district_net_electricity_consumption_emission en E2 **¡Error! Marcador no definido.**
minimizar ..... **¡Error! Marcador no definido.**
OE.3 ..... **¡Error! Marcador no definido.**
HE.3 ..... **¡Error! Marcador no definido.**
E3 ..... **¡Error! Marcador no definido.**
costos energéticos ..... **¡Error! Marcador no definido.**
suma anual de district_net_electricity_consumption_cost en E3 .. **¡Error! Marcador no definido.**
minimizar ..... **¡Error! Marcador no definido.**
Tabla 5.3 Episodios de inicio de aprendizaje, estabilizacion y mejor recompensa media **¡Error! Marcador no**
Algoritmo ..... **¡Error! Marcador no definido.**
Esc. ..... **¡Error! Marcador no definido.**

n ..... ¡Error! Marcador no definido.
media inicial ..... ¡Error! Marcador no definido.
media final ..... ¡Error! Marcador no definido.
inicio aprendizaje ..... ¡Error! Marcador no definido.
estabilizacion ..... ¡Error! Marcador no definido.
mejor episodio ..... ¡Error! Marcador no definido.
mejor reward ..... ¡Error! Marcador no definido.
HAPPO ..... ¡Error! Marcador no definido.
E1 ..... ¡Error! Marcador no definido.
49 ..... ¡Error! Marcador no definido.
-0.687276 ..... ¡Error! Marcador no definido.
-0.632433 ..... ¡Error! Marcador no definido.
5 ..... ¡Error! Marcador no definido.
5 ..... ¡Error! Marcador no definido.
5 ..... ¡Error! Marcador no definido.
-0.595264 ..... ¡Error! Marcador no definido.
MAAC ..... ¡Error! Marcador no definido.
E1 ..... ¡Error! Marcador no definido.
50 ..... ¡Error! Marcador no definido.
-0.602519 ..... ¡Error! Marcador no definido.
-0.605677 ..... ¡Error! Marcador no definido.
1 ..... ¡Error! Marcador no definido.
1 ..... ¡Error! Marcador no definido.
27 ..... ¡Error! Marcador no definido.
-0.584429 ..... ¡Error! Marcador no definido.
MASAC ..... ¡Error! Marcador no definido.
E1 ..... ¡Error! Marcador no definido.
50 ..... ¡Error! Marcador no definido.
-0.618831 ..... ¡Error! Marcador no definido.
-0.610697 ..... ¡Error! Marcador no definido.
3 ..... ¡Error! Marcador no definido.
1 ..... ¡Error! Marcador no definido.
50 ..... ¡Error! Marcador no definido.
-0.589593 ..... ¡Error! Marcador no definido.

MATD3 ..... ¡Error! Marcador no definido.
E1 ..... ¡Error! Marcador no definido.
50 ..... ¡Error! Marcador no definido.
-0.727661 ..... ¡Error! Marcador no definido.
-0.613946 ..... ¡Error! Marcador no definido.
6 ..... ¡Error! Marcador no definido.
14 ..... ¡Error! Marcador no definido.
15 ..... ¡Error! Marcador no definido.
-0.591773 ..... ¡Error! Marcador no definido.
HAPPO ..... ¡Error! Marcador no definido.
E2 ..... ¡Error! Marcador no definido.
49 ..... ¡Error! Marcador no definido.
-0.533865 ..... ¡Error! Marcador no definido.
-0.486701 ..... ¡Error! Marcador no definido.
5 ..... ¡Error! Marcador no definido.
6 ..... ¡Error! Marcador no definido.
6 ..... ¡Error! Marcador no definido.
-0.460756 ..... ¡Error! Marcador no definido.
MAAC ..... ¡Error! Marcador no definido.
E2 ..... ¡Error! Marcador no definido.
50 ..... ¡Error! Marcador no definido.
-0.519982 ..... ¡Error! Marcador no definido.
-0.523789 ..... ¡Error! Marcador no definido.
1 ..... ¡Error! Marcador no definido.
1 ..... ¡Error! Marcador no definido.
40 ..... ¡Error! Marcador no definido.
-0.511314 ..... ¡Error! Marcador no definido.
MASAC ..... ¡Error! Marcador no definido.
E2 ..... ¡Error! Marcador no definido.
50 ..... ¡Error! Marcador no definido.
-0.527569 ..... ¡Error! Marcador no definido.
-0.525298 ..... ¡Error! Marcador no definido.
3 ..... ¡Error! Marcador no definido.
1 ..... ¡Error! Marcador no definido.

26 ..... ¡Error! Marcador no definido.
-0.512239 ..... ¡Error! Marcador no definido.
MATD3 ..... ¡Error! Marcador no definido.
E2 ..... ¡Error! Marcador no definido.
50 ..... ¡Error! Marcador no definido.
-0.540114 ..... ¡Error! Marcador no definido.
-0.530624 ..... ¡Error! Marcador no definido.
1 ..... ¡Error! Marcador no definido.
1 ..... ¡Error! Marcador no definido.
24 ..... ¡Error! Marcador no definido.
-0.516268 ..... ¡Error! Marcador no definido.
HAPPO ..... ¡Error! Marcador no definido.
E3 ..... ¡Error! Marcador no definido.
49 ..... ¡Error! Marcador no definido.
-0.560615 ..... ¡Error! Marcador no definido.
-0.524157 ..... ¡Error! Marcador no definido.
5 ..... ¡Error! Marcador no definido.
5 ..... ¡Error! Marcador no definido.
5 ..... ¡Error! Marcador no definido.
-0.494647 ..... ¡Error! Marcador no definido.
MAAC ..... ¡Error! Marcador no definido.
E3 ..... ¡Error! Marcador no definido.
50 ..... ¡Error! Marcador no definido.
-0.534768 ..... ¡Error! Marcador no definido.
-0.538680 ..... ¡Error! Marcador no definido.
1 ..... ¡Error! Marcador no definido.
1 ..... ¡Error! Marcador no definido.
40 ..... ¡Error! Marcador no definido.
-0.524819 ..... ¡Error! Marcador no definido.
MASAC ..... ¡Error! Marcador no definido.
E3 ..... ¡Error! Marcador no definido.
50 ..... ¡Error! Marcador no definido.
-0.543246 ..... ¡Error! Marcador no definido.
-0.540399 ..... ¡Error! Marcador no definido.

3 ..... **¡Error! Marcador no definido.**
1 ..... **¡Error! Marcador no definido.**
29 ..... **¡Error! Marcador no definido.**
-0.526310 ..... **¡Error! Marcador no definido.**
MATD3 ..... **¡Error! Marcador no definido.**
E3 ..... **¡Error! Marcador no definido.**
50 ..... **¡Error! Marcador no definido.**
-0.569808 ..... **¡Error! Marcador no definido.**
-0.547797 ..... **¡Error! Marcador no definido.**
5 ..... **¡Error! Marcador no definido.**
1 ..... **¡Error! Marcador no definido.**
12 ..... **¡Error! Marcador no definido.**
-0.529048 ..... **¡Error! Marcador no definido.**
Tabla 5.4 Catalogo de KPIs evaluate_v2 usados para interpretar resultados**¡Error! Marcador no definido.**
Tabla 5.5 Ranking por eje con KPIs compatibles con CityLearn v2**¡Error! Marcador no definido.**
Tabla 5.5 Estadística descriptiva por episodio para OE.1 ..... **¡Error! Marcador no definido.**
Tabla 5.5ª KPI anual final del tratamiento asociado a OE.1 ..... **¡Error! Marcador no definido.**
Tabla 5.5b Mann-Whitney U por pares con ajuste Holm para OE.1**¡Error! Marcador no definido.**
Tabla 5.5c Shapiro-Wilk recalculado por algoritmo para OE.1 ..... **¡Error! Marcador no definido.**
Tabla 5.6 Estadística descriptiva por episodio para OE.2 ..... **¡Error! Marcador no definido.**
Tabla 5.6ª KPI anual final del tratamiento asociado a OE.2 ..... **¡Error! Marcador no definido.**
Tabla 5.6b Mann-Whitney U por pares con ajuste Holm para OE.2**¡Error! Marcador no definido.**
Tabla 5.6c Shapiro-Wilk recalculado por algoritmo para OE.2 ..... **¡Error! Marcador no definido.**
Tabla 5.7 Estadística descriptiva por episodio para OE.3 ..... **¡Error! Marcador no definido.**
Tabla 5.7ª KPI anual final del tratamiento asociado a OE.3 ..... **¡Error! Marcador no definido.**
Tabla 5.7b Mann-Whitney U por pares con ajuste Holm para OE.3**¡Error! Marcador no definido.**
Tabla 5.7c Shapiro-Wilk recalculado por algoritmo para OE.3 ..... **¡Error! Marcador no definido.**
Tabla 5.11 Edificios con mayor cantidad de acciones controlables**¡Error! Marcador no definido.**
Tabla 5.12 Equipamiento controlado identificado en los esquemas de acción**¡Error! Marcador no definido.**
Tabla 5.13 Respuesta directa a objetivos específicos ..... **¡Error! Marcador no definido.**
Tabla 5.14 Discusión sintética por objetivo, efecto y algoritmo dominante**¡Error! Marcador no definido.**
Tabla 5.15 Mejor método por eje según ranking CityLearn v2 evaluate_v2**¡Error! Marcador no definido.**
Tabla A.1 Resumen distrital real por algoritmo y escenario ..... **¡Error! Marcador no definido.**
Tabla A.2 Mejores 20 filas por reducción de costo eléctrico en edificios completos**¡Error! Marcador no defi**

Tabla A.3 Equipamiento controlado y carga base no controlada por edificio**¡Error! Marcador no definido.**
Tabla A.4 Resumen de checkpoints reales por algoritmo y escenario**¡Error! Marcador no definido.**
Tabla A.5 Artefactos ausentes o incompletos declarados por el análisis**¡Error! Marcador no definido.**

Indice de figuras

Figura 5.1 Cobertura de checkpoints por tratamiento ..... **¡Error! Marcador no definido.**
Figura 5 3-E1. Curva de convergencia por recompensa media móvil en E1**¡Error! Marcador no definido.**
Figura 5 3-E2. Curva de convergencia por recompensa media móvil en E2**¡Error! Marcador no definido.**
Figura 5 3-E3. Curva de convergencia por recompensa media móvil en E3**¡Error! Marcador no definido.**
Figura 5.4 Mapa de calor del ranking KPI CityLearn v2 evaluate_v2**¡Error! Marcador no definido.**
Figura 5.5 Comparación gráfica de la media por episodio para OE.1**¡Error! Marcador no definido.**
Figura 5.5ª Paneles MADRL del episodio final para E1: valores normalizados y totales reales anotados por algoritmo .....**¡Error! Marcador no definido.**
Figura 5.6 Comparación gráfica de la media por episodio para OE.2**¡Error! Marcador no definido.**
Figura 5.6ª Paneles MADRL del episodio final para E2: valores normalizados y totales reales anotados por algoritmo .....**¡Error! Marcador no definido.**
Figura 5.7 Comparación gráfica de la media por episodio para OE.3**¡Error! Marcador no definido.**
Figura 5.7ª Paneles MADRL del episodio final para E3: valores normalizados y totales reales anotados por algoritmo .....**¡Error! Marcador no definido.**
Figura 5.8 Dimensiones de acción controlable por edificio ..... **¡Error! Marcador no definido.**
Figura 5.8ª Éxito de salida EV por edificio y algoritmo .....**¡Error! Marcador no definido.**
Figura 5.8b CO_2 control por edificio y algoritmo .....**¡Error! Marcador no definido.**
Figura 5.8c Costo control por edificio y algoritmo ..... **¡Error! Marcador no definido.**
Figura 5.8d Equipamiento controlado por edificio y clase .....**¡Error! Marcador no definido.**
Figura 5.8e Políticas y acciones medias: action_l2 desde trace.csv y EV/BESS desde building_behavior_summary.csv .....**¡Error! Marcador no definido.**
Figura 5.9ª Distribución episódica por objetivo y algoritmo .....**¡Error! Marcador no definido.**
Figura 5.9b Tamaño de efecto inferencial por objetivo ..... **¡Error! Marcador no definido.**
Figura 5.9c Matriz de p-valores Holm por objetivo .....**¡Error! Marcador no definido.**
Figura 5.10 Trade-off multiobjetivo costo-CO_2-autoconsumo PV **¡Error! Marcador no definido.**
Figura A.1 Evolución del reward distrital medio por episodio .....**¡Error! Marcador no definido.**
Figura A.2 Energía neta distrital por episodio .....**¡Error! Marcador no definido.**
Figura A.3 Costo distrital medio por algoritmo y escenario .....**¡Error! Marcador no definido.**
Figura A.4 Emisiones distritales medias por algoritmo y escenario**¡Error! Marcador no definido.**
Figura A.5 Delta de costo eléctrico por edificio y corrida completa**¡Error! Marcador no definido.**
Figura A.6 Delta de emisiones por edificio y corrida completa .... **¡Error! Marcador no definido.**
Figura A.7 Variables de acción controladas por edificio ..... **¡Error! Marcador no definido.**
Figura A.8 Carga controlada de escenario frente a carga base no controlada**¡Error! Marcador no definido.**

Figura A.9 Tamaño total listado en manifiestos de checkpoint por algoritmo y escenario**¡Error! Marcador no**
Figura B.1 Diagrama 1 — Vision General del Proyecto (inicio a fin)**¡Error! Marcador no definido.**
Figura B.2 Diagrama 2 — Pipeline del Dataset Iquitos 2023-2025**¡Error! Marcador no definido.**
Figura B.3 Diagrama 3 — Arquitectura Dec-POMDP y CTDE de los 17 Agentes**¡Error! Marcador no defini**
Figura B.4 Diagrama 4 — Los 4 Algoritmos MADRL: Taxonomia y Diferencias**¡Error! Marcador no definido**
Figura B.5 Diagrama 5 — Flujo de Entrenamiento: 12 Corridas (two_phase_happo_masac_v3) ..... **¡Error! Marcador no definido.**
Figura B.6 Diagrama 6 — Recompensa Multiobjetivo por Escenario**¡Error! Marcador no definido.**
Figura B.7 Diagrama 7 — Pipeline de evaluación y selección por objetivo**¡Error! Marcador no definido.**
Figura B.8 Diagrama 8 — Infraestructura de Despliegue: Local, Colab A100 y AWS EC2**¡Error! Marcador n**
Figura B.9 Diagrama 9 — Estructura de Capas del Software ..... **¡Error! Marcador no definido.**

Capítulo 1. Planteamiento del Problema

1.2. Diagnóstico del problema

La expansión urbana, el crecimiento del parque edificatorio y la electrificación progresiva de los usos finales están modificando tanto la magnitud como el comportamiento temporal de la demanda energética. En 2018, el 55 % de la población mundial residía en áreas urbanas y se proyectó que esta proporción alcanzaría el 68 % en 2050. Este proceso supondría la incorporación de aproximadamente 2 500 millones de personas adicionales a las ciudades, con una concentración predominante del crecimiento en Asia y África .

La ampliación del entorno urbano se encuentra acompañada por una expansión sostenida de las edificaciones. El sector de edificios y construcción representa aproximadamente el 32 % del consumo mundial de energía y contribuye con alrededor del 34 % de las emisiones globales de dióxido de carbono. Además, se estima que cerca de la mitad de los edificios que existirán en 2050 todavía deberán ser construidos o rehabilitados, por lo que las decisiones actuales sobre diseño, eficiencia, materiales y gestión energética condicionarán durante varias décadas el consumo y las emisiones del sector .

Esta presión ha sido intensificada por la electrificación del transporte, la climatización, los procesos productivos y los servicios digitales. La demanda mundial de electricidad aumentó un 4,3 % en 2024, lo que representó aproximadamente 1 080 TWh adicionales respecto del año anterior. Dicho crecimiento estuvo asociado, entre otros factores, con la electrificación de los usos finales, las altas temperaturas, la actividad industrial y la expansión de los centros de datos y

La movilidad eléctrica constituye una manifestación concreta de esta transformación. Durante 2024, la flota mundial de vehículos eléctricos consumió alrededor de 180 TWh, casi un 60 % más que en 2023. Aunque la electromovilidad reduce el consumo directo de combustibles fósiles en el transporte, su incorporación introduce cargas adicionales cuya concentración en determinados horarios puede incrementar los picos de demanda y los requerimientos de generación. Por ello, la reducción de emisiones asociada con los vehículos eléctricos depende también de la fuente utilizada para producir la electricidad y de la coordinación temporal de la recarga

En el Perú también se registra una tendencia sostenida hacia la urbanización y la expansión del parque habitacional. Para 2024, se estimó que el 83,1 % de la población nacional aproximadamente 28,29 millones de habitantes residía en áreas urbanas. Asimismo,

el número de viviendas particulares registradas pasó de 10 102 849 en 2017 a 13 762 606 en 2025, lo que representa un incremento aproximado del 36,2 %, calculado a partir de las cifras oficiales. Si bien el crecimiento del número de viviendas no equivale directamente al mismo porcentaje de aumento del consumo eléctrico, sí refleja una ampliación de la infraestructura edificada y de la cantidad potencial de puntos de demanda que deben ser atendidos por los sistemas de distribución y

La transición energética nacional también viene modificando la composición de la oferta eléctrica. Durante 2024, la producción de electricidad en el Perú alcanzó 63 565 GWh, cifra que representó un crecimiento del 2,4 % respecto de 2023. En ese mismo periodo, la generación solar aumentó un 32 %, mientras que la producción proveniente de recursos energéticos renovables no convencionales creció un 47 %.

En paralelo, durante 2024 fueron comercializados 6 602 vehículos electrificados en el país, lo que representó un incremento del 47,23 % respecto del año anterior. No obstante, solo una parte correspondió a vehículos eléctricos puros e híbridos enchufables, por lo que la transición hacia una movilidad completamente eléctrica todavía se encuentra en una etapa de desarrollo. El propio Ministerio de Transportes y Comunicaciones ha reconocido que la expansión de la electromovilidad requiere infraestructura de recarga y capacidades de gestión adecuadas para evitar que las nuevas cargas sean incorporadas sin planificación (Ministerio de Transportes y Comunicaciones ; 2025);

Estas tendencias muestran que la transición energética no consiste únicamente en incorporar generación renovable, baterías o vehículos eléctricos. También requiere modificar la forma en que la energía es consumida, almacenada y coordinada. Cuando el crecimiento de la demanda y la incorporación de recursos energéticos distribuidos no son acompañados por estrategias de gestión, pueden generarse nuevos picos, rampas más pronunciadas, congestión local, desaprovechamiento de generación renovable y mayores exigencias sobre la infraestructura existente. La literatura especializada sobre comunidades inteligentes coincide en que la coordinación entre edificios resulta necesaria para conciliar los objetivos individuales con las necesidades del conjunto energético ; ;

La problemática adquiere una relevancia particular en el Sistema Eléctrico Aislado de Iquitos. Electro Oriente S. A. señala que los sistemas eléctricos de Loreto, incluido Iquitos, permanecen aislados del Sistema Eléctrico Interconectado Nacional y que su producción se sustenta principalmente en grupos electrógenos instalados en los centros de consumo. Esta

condición reduce las posibilidades de intercambiar energía con otros sistemas ante contingencias, incrementos de demanda o variaciones de generación.

Las restricciones operativas del sistema han motivado intervenciones institucionales recientes. En septiembre de 2024, el MINEM declaró al Sistema Eléctrico de Iquitos en situación de grave deficiencia por insuficiencia de capacidad de producción, con vigencia hasta abril de 2025. Posteriormente, fue conformado un grupo de trabajo multisectorial para formular medidas dirigidas a garantizar un suministro continuo, seguro y confiable; además, en 2026 continuaron desarrollándose acciones oficiales para fortalecer la continuidad y confiabilidad del servicio eléctrico en Iquitos .

Dentro de este contexto, la insuficiente flexibilidad energética constituye el primer eje del problema. La flexibilidad se refiere a la capacidad de modificar temporalmente el consumo, la generación local y el uso del almacenamiento para responder a cambios en la demanda, la disponibilidad renovable, los precios o las condiciones operativas. Cuando esta capacidad no se encuentra disponible o no es gestionada adecuadamente, la demanda puede concentrarse en periodos críticos, las rampas pueden intensificarse y la generación fotovoltaica puede ser desaprovechada.

En una comunidad de edificios, la falta de coordinación puede provocar que decisiones individualmente convenientes produzcan resultados desfavorables para el conjunto. La carga simultánea de sistemas de almacenamiento y vehículos eléctricos, por ejemplo, podría generar un nuevo pico comunitario, aun cuando cada edificio haya actuado de acuerdo con su propio objetivo. Los estudios de y muestran que la gestión energética comunitaria debe ser evaluada mediante indicadores como demanda máxima, rampas, factor de carga y comportamiento de los recursos flexibles, debido a que una recompensa agregada no permite interpretar por sí sola la respuesta física del sistema.

El segundo eje corresponde a las emisiones de gases de efecto invernadero y su contribución al calentamiento global. En sistemas con elevada participación de generación térmica, los incrementos de demanda o la ausencia de flexibilidad pueden traducirse en una utilización más intensiva de combustibles fósiles. Por tanto, las emisiones asociadas con la electricidad no dependen únicamente del volumen consumido, sino también del momento en que la demanda es atendida y de la tecnología de generación disponible en cada periodo.

La incorporación de generación fotovoltaica no garantiza por sí misma una reducción proporcional de emisiones. Si el consumo no es desplazado hacia los periodos de mayor disponibilidad solar, o si las baterías y los vehículos son recargados durante intervalos con

mayor intensidad de carbono, parte del beneficio ambiental puede ser perdido. Por esta razón, CityLearn v2 incorpora métricas específicas de emisiones y señales temporales de intensidad de carbono, con el propósito de evaluar si las políticas de control desplazan efectivamente el consumo hacia condiciones ambientalmente más favorables .

En la presente tesis, la señal ambiental del SEAI Iquitos ha sido construida mediante un factor base de 0,790 kg CO_2/kWh y un componente dinámico asociado con el desplazamiento fotovoltaico. Este valor constituye un parámetro interno del modelo de intensidad de carbono y no un resultado experimental. Su formulación, junto con la arquitectura de la señal ambiental, forma parte de la extensión computacional desarrollada en el proyecto.

El tercer eje corresponde a los costos energéticos. En una comunidad inteligente, el gasto eléctrico no depende únicamente del consumo acumulado, sino también del momento en que la energía es demandada, de los periodos tarifarios, de la potencia máxima alcanzada y de la utilización de los sistemas de generación y almacenamiento. Cuando los recursos son operados sin coordinación, el consumo puede trasladarse hacia periodos de mayor precio o pueden producirse nuevos picos que deterioren el resultado económico del conjunto.

Los objetivos económicos pueden entrar en conflicto con los objetivos ambientales y energéticos. Una estrategia orientada exclusivamente a reducir costos podría desplazar demanda hacia un periodo de menor tarifa, aunque la electricidad disponible presente una mayor intensidad de carbono. Del mismo modo, una política enfocada únicamente en emisiones podría incrementar los picos de potencia o utilizar con mayor intensidad el almacenamiento, sin garantizar el menor costo posible. La literatura sobre gestión energética comunitaria confirma que la reducción de costos y el aplanamiento de la demanda requieren coordinación entre edificios y no solo decisiones independientes de cada agente ; .

Los tres ejes se encuentran estrechamente vinculados. Una comunidad con escasa flexibilidad puede requerir una respuesta más intensa de la generación térmica; esta mayor utilización puede elevar las emisiones de CO_2; y la concentración temporal del consumo puede incrementar los costos. En sentido inverso, una reducción del costo no implica necesariamente una disminución de emisiones, mientras que una política ambientalmente favorable puede no producir el mejor resultado en flexibilidad. Por tanto, el problema debe ser entendido como una tensión multiobjetivo entre adaptación energética, descarbonización y eficiencia económica.

Frente a esta situación, se requieren mecanismos capaces de coordinar edificios heterogéneos, sistemas fotovoltaicos, baterías, vehículos eléctricos y cargas desplazables. CityLearn v2 proporciona un entorno reproducible para representar comunidades interactivas con la red, incorporar recursos distribuidos y evaluar indicadores de flexibilidad, emisiones y costos bajo condiciones homogéneas .

Sobre esta base, en la tesis ha sido propuesta una extensión experimental denominada CityLearn v3, la cual no constituye una versión oficial del entorno. Mediante esta extensión, una comunidad conformada por 17 edificios es representada como un sistema multiagente parcialmente observable. Los algoritmos HAPPO, MASAC, MATD3 y MAAC son evaluados bajo tres escenarios de recompensa: E1, orientado a la flexibilidad; E2, orientado a las emisiones de CO_2; y E3, orientado a los costos energéticos. Esta estructura corresponde al diseño factorial 4 × 3 conservado en el documento final.

En consecuencia, el diagnóstico evidencia que el problema central no consiste únicamente en incorporar recursos energéticos distribuidos, sino en determinar cómo deben ser coordinados para evitar que la expansión de la demanda, la transición energética y la electrificación produzcan nuevos picos, emisiones persistentes o costos elevados. En este marco, aún debe determinarse en qué medida los algoritmos MADRL evaluados generan efectos diferenciados sobre los tres ejes y cuál ofrece el desempeño más favorable en cada uno de ellos.

1.3. Identificación y descripción del problema de estudio

El problema de estudio se identifica en la insuficiente capacidad para gestionar de manera coordinada los recursos energéticos distribuidos y la demanda de una comunidad inteligente representativa del SEAI Iquitos. Esta dificultad se manifiesta en tres dimensiones relacionadas: limitada flexibilidad para adaptar el perfil de carga, persistencia de emisiones asociadas con la generación térmica y costos energéticos condicionados por la concentración temporal del consumo.

En la dimensión de flexibilidad energética, el problema se presenta cuando las cargas, las baterías y los vehículos eléctricos no responden de forma coordinada ante las variaciones de generación, demanda y disponibilidad de los equipos. En tales condiciones, pueden producirse incrementos de la demanda máxima, rampas más pronunciadas y un menor aprovechamiento de la generación fotovoltaica. La respuesta individual de cada edificio podría ser localmente adecuada, pero generar un resultado agregado desfavorable cuando varios agentes ejecutan acciones similares durante el mismo intervalo.

En la dimensión ambiental, el problema se expresa en las emisiones de CO_2 asociadas con el abastecimiento eléctrico de una comunidad inserta en un sistema aislado con dependencia térmica. La reducción de energía consumida no garantiza por sí misma una disminución de emisiones, debido a que el efecto ambiental depende de la intensidad de carbono correspondiente a cada periodo. Por ello, la gestión debe considerar no solo cuánto se consume, sino también cuándo se consume y qué fuente de generación atiende dicha demanda.

En la dimensión económica, el problema se manifiesta cuando el consumo se concentra en periodos de mayor costo o cuando la operación descoordinada de los recursos genera picos adicionales. La existencia de tarifas diferenciadas entre periodos de punta y fuera de punta implica que dos políticas con un consumo energético semejante pueden producir costos distintos. Asimismo, una reducción del costo no puede ser interpretada como una mejora integral cuando ha sido obtenida a cambio de mayores emisiones o de un deterioro de la flexibilidad.

Las causas técnicas del problema se relacionan con la heterogeneidad de los edificios, la diversidad de equipos controlables, la presencia de demanda no flexible, la variabilidad de la generación fotovoltaica y la disponibilidad temporal de los vehículos eléctricos. Cada edificio recibe observaciones locales y toma decisiones descentralizadas, pero no dispone durante la ejecución del estado interno completo de los demás agentes. Esta condición introduce observabilidad parcial, interdependencia y no estacionariedad en el proceso de aprendizaje.

La formalización como Dec-POMDP resulta pertinente porque permite representar decisiones secuenciales, observaciones locales, acciones simultáneas y recompensas cooperativas en entornos parcialmente observables . El paradigma de entrenamiento centralizado con ejecución descentralizada permite emplear información conjunta durante el aprendizaje y conservar políticas locales durante la operación. Este enfoque ha sido utilizado como fundamento de distintos métodos multiagente, incluidos los modelos actor-crítico y los mecanismos de atención ; .

La incorporación de HAPPO responde a la necesidad de coordinar agentes heterogéneos sin depender exclusivamente del intercambio de parámetros. La versión revisada por pares del trabajo de Zhong et al. fue publicada en 2024 y presenta HAPPO como una aproximación derivada del marco de aprendizaje por refuerzo con agentes heterogéneos .

No obstante, la formulación Dec-POMDP y la implementación de algoritmos MADRL constituyen la respuesta computacional al problema, no el problema sustantivo. La brecha

científica reside en que todavía debe determinarse qué efectos diferenciados producen HAPPO, MASAC, MATD3 y MAAC sobre la flexibilidad, las emisiones y los costos de la comunidad modelada, así como si el algoritmo que lidera una dimensión mantiene ese desempeño en las restantes.

Para responder esta brecha, los algoritmos son evaluados bajo una comunidad fija, el mismo conjunto de datos, una arquitectura común de recompensa y tres escenarios alineados con las dimensiones de la variable dependiente. E1 prioriza la flexibilidad energética, E2 las emisiones de CO_2 y E3 los costos energéticos. Estas condiciones constituyen controles metodológicos para la comparación; no reemplazan la problemática energética, ambiental y económica que da origen a la investigación.

Las manifestaciones observables son examinadas mediante demanda máxima, rampas, factor de carga, consumo neto, emisiones ponderadas por intensidad de carbono, costo acumulado y comportamiento por edificio. La comparación también considera la actuación de las baterías, los cargadores, la generación fotovoltaica y las cargas controlables. De esta manera, el efecto del algoritmo no es reducido a la recompensa de entrenamiento, sino que es interpretado mediante indicadores físicos y económicos compatibles con el entorno de simulación.

La evidencia experimental conservada se limita a la corrida canónica madrl_v3_20260627_164047. Se dispone de 600 registros episódicos: 50 episodios para cada combinación de los cuatro algoritmos y los tres escenarios. En HAPPO, los episodios 0–48 proceden del archivo histórico y el episodio 49 del resultado post-resume; la unión se realizó por índice, sin inventar ni imputar valores. La inferencia se interpreta como exploratoria porque solo existe una semilla independiente por tratamiento.

1.3.1. Formulación del problema

La formulación se deriva de la necesidad de determinar el efecto del factor algoritmo MADRL sobre las tres dimensiones de la gestión energética coordinada. La pregunta general integra los resultados de flexibilidad, emisiones y costos, mientras que las preguntas específicas separan cada eje para evitar que una recompensa global o un único ranking oculte los compromisos existentes entre objetivos.

1.3.1.1 1.2.1.1 Formulación del problema general

PG. ¿En qué medida los algoritmos HAPPO, MASAC, MATD3 y MAAC producen efectos diferenciales en la coordinación energética multiobjetivo de una comunidad inteligente

heterogénea de Iquitos, considerando la flexibilidad energética, las emisiones de CO_2 y los costos energéticos, y cuál presenta el mejor desempeño global?

1.3.1.2 1.2.1.2 Formulación de los problemas específicos

PE.1. ¿En qué medida los algoritmos HAPPO, MASAC, MATD3 y MAAC producen efectos diferenciales sobre la flexibilidad energética (eje E1) y cuál presenta el mejor desempeño en la comunidad inteligente heterogénea de Iquitos?

PE.2. ¿En qué medida los algoritmos HAPPO, MASAC, MATD3 y MAAC producen efectos diferenciales sobre las emisiones de CO_2 (eje E2) y cuál presenta el mejor desempeño en la comunidad inteligente heterogénea de Iquitos?

PE.3. ¿En qué medida los algoritmos HAPPO, MASAC, MATD3 y MAAC producen efectos diferenciales sobre los costos energéticos (eje E3) y cuál presenta el mejor desempeño en la comunidad inteligente heterogénea de Iquitos?

1.3.2 Justificación y alcances

1.3.2.1 Justificación

a) Justificación teórica.

La investigación se justifica teóricamente porque articula tres campos que suelen ser abordados de manera separada: la simulación energética de comunidades de edificios, el aprendizaje por refuerzo profundo multiagente y la evaluación estadística de políticas de control. CityLearn v2 proporciona un entorno reproducible para representar recursos energéticos distribuidos y evaluar indicadores comunitarios; el Dec-POMDP permite formalizar decisiones descentralizadas bajo observabilidad parcial; y CTDE permite utilizar información conjunta durante el entrenamiento sin exigir un controlador centralizado durante la ejecución ; .

La comparación conjunta de HAPPO, MASAC, MATD3 y MAAC permite examinar mecanismos de aprendizaje con fundamentos diferentes dentro de una misma estructura experimental. HAPPO se basa en actualizaciones secuenciales para agentes heterogéneos; MAAC incorpora críticos centralizados con mecanismos de atención; mientras que MASAC y MATD3 representan variantes multiagente de métodos actor-crítico fuera de política. En consecuencia, los algoritmos son tratados como niveles de la variable independiente y no como implementaciones aisladas.

El aporte teórico no consiste en afirmar de antemano la superioridad de una técnica, sino en establecer una relación explicativa entre el mecanismo algorítmico, la coordinación de los agentes y las consecuencias observadas sobre flexibilidad, emisiones y costos. Esta perspectiva evita que la interpretación quede reducida a la recompensa de entrenamiento y permite analizar los compromisos entre objetivos.

b) Justificación de técnica.

La investigación se justifica en términos de flexibilidad porque la incorporación de generación fotovoltaica, almacenamiento, vehículos eléctricos y cargas desplazables no garantiza que el perfil de demanda sea mejorado. Cuando estos recursos son gestionados sin coordinación, pueden producirse picos secundarios, rampas más pronunciadas o desaprovechamiento de energía renovable.

La literatura sobre comunidades interactivas con la red indica que la flexibilidad debe ser evaluada a escala comunitaria y mediante indicadores físicos. incorporaron métricas de demanda máxima, rampas y factor de carga dentro de CityLearn v2, mientras que Wilk et al. (2024) mostraron que la coordinación multiagente puede contribuir al aplanamiento de la curva de demanda y a la gestión conjunta de edificios y vehículos eléctricos.

En el SEAI Iquitos, la flexibilidad resulta especialmente relevante debido a la condición aislada y a la dependencia de generación térmica. La reducción de picos y la adaptación del consumo a la disponibilidad fotovoltaica podrían disminuir las exigencias sobre las unidades de generación; sin embargo, la tesis no interpreta la simulación como un despliegue real, sino como evidencia computacional bajo condiciones delimitadas.

c) Justificación económica.

La investigación se justifica económicamente porque el costo energético depende del volumen consumido, del momento de consumo, de la potencia máxima y del uso de los recursos distribuidos. La existencia de periodos tarifarios de punta y fuera de punta permite que políticas con consumos semejantes produzcan resultados económicos diferentes.

La operación no coordinada puede trasladar cargas hacia intervalos de mayor precio o provocar nuevos picos. Por el contrario, la gestión conjunta de almacenamiento, vehículos eléctricos y cargas flexibles puede reducir costos cuando las decisiones son adoptadas considerando las señales temporales del sistema. Los resultados reportados por y respaldan la necesidad de evaluar conjuntamente la coordinación energética y el desempeño económico.

El aporte económico de la tesis consiste en comparar los efectos de las políticas sobre indicadores de costo distrital y por edificio. No se pretende estimar el ahorro financiero de una implementación real ni extrapolar los resultados a tarifas o comunidades no evaluadas.

d) Justificación ambiental.

La investigación se justifica ambientalmente porque el SEAI Iquitos mantiene una dependencia importante de generación térmica. En este contexto, el desplazamiento temporal de la demanda puede modificar la cantidad de electricidad atendida durante periodos de mayor o menor intensidad de carbono.

La reducción de emisiones requiere que el consumo, el almacenamiento y la generación fotovoltaica sean coordinados. Una política orientada únicamente al menor precio puede no coincidir con el periodo de menor intensidad de carbono; de igual manera, una política centrada exclusivamente en emisiones puede producir efectos desfavorables en picos o costos. CityLearn v2 incorpora métricas específicas para examinar estas relaciones y evitar que el desempeño ambiental sea inferido únicamente a partir del consumo energético .

La señal ambiental de la tesis utiliza como parámetro base 0,790 kg CO_2/kWh. Su función es representar la intensidad de carbono del sistema simulado y permitir la comparación entre políticas; no constituye una medición directa de las emisiones reales del SEAI Iquitos.

e) Justificación tecnológica y metodológica.

La investigación se justifica tecnológicamente porque integra datos horarios locales, una comunidad de 17 edificios, equipos controlables y no controlables, algoritmos MADRL, trazas, archivos de series temporales, indicadores por edificio y puntos de control del entrenamiento. Esta arquitectura ha sido implementada sobre CityLearn v2 y una extensión experimental denominada CityLearn v3 propuesta.

La reproducibilidad es fortalecida mediante la conservación de results.json, training_summary.json, timeseries.csv, trace.csv, building_kpis.csv, building_behavior_summary.csv y checkpoint_manifest.json. La evidencia no depende únicamente de figuras o narraciones, sino de artefactos que permiten reconstruir la relación entre configuración, entrenamiento y resultado.

Metodológicamente, la comparación se organiza mediante un diseño factorial 4 × 3. Los cuatro niveles del factor algoritmo son HAPPO, MASAC, MATD3 y MAAC; los tres escenarios corresponden a E1, E2 y E3. La aplicación de condiciones equivalente permite

reducir la influencia de variaciones ajenas al tratamiento y mejora la trazabilidad de la comparación.

1.3.2.2 Alcances

El alcance del estudio ha sido delimitado en correspondencia directa con la formulación del problema general y con los tres problemas específicos. En consecuencia, la investigación se orienta a determinar en qué medida los algoritmos de aprendizaje por refuerzo profundo multiagente HAPPO, MASAC, MATD3 y MAAC impactan en la gestión coordinada de la flexibilidad energética, las emisiones de CO_2 y los costos energéticos. Asimismo, se busca establecer cuál de los algoritmos presenta el mejor desempeño en cada escenario y cuál alcanza el resultado más favorable a nivel global cuando las tres dimensiones son evaluadas de manera integrada.

En esta investigación, el término impacto se entiende como el efecto diferenciado producido por el tipo de algoritmo sobre los indicadores energéticos, ambientales y económicos obtenidos dentro del entorno de simulación. Por tanto, no se hace referencia a un impacto causal comprobado mediante una intervención física en el sistema eléctrico de Iquitos, sino a diferencias observables y estadísticamente evaluables entre las políticas MADRL bajo condiciones experimentales homogéneas. Esta precisión permite conservar la formulación del problema definida en la tesis sin extender sus resultados más allá de la evidencia computacional disponible.

a. Alcance temático

El alcance temático comprende la comparación de HAPPO, MASAC, MATD3 y MAAC como alternativas de gestión coordinada en una comunidad inteligente. Los algoritmos constituyen los niveles de la variable independiente, mientras que la variable dependiente se encuentra representada por la gestión coordinada de la flexibilidad energética, las emisiones de CO_2 y los costos energéticos.

La primera dimensión corresponde a la flexibilidad energética y se encuentra asociada con el problema específico PE.1. Su evaluación se desarrolla en el escenario E1, mediante indicadores orientados a determinar la capacidad de los agentes para modificar el perfil temporal de consumo, reducir la demanda máxima, suavizar las rampas horarias, mejorar el factor de carga y coordinar el aprovechamiento de la generación fotovoltaica, los sistemas de almacenamiento, las cargas desplazables y los vehículos eléctricos. Por consiguiente, la identificación del algoritmo con mejor desempeño en E1 no se sustenta únicamente en la

recompensa del entrenamiento, sino en el comportamiento de los indicadores físicos de flexibilidad definidos en la tesis.

La segunda dimensión comprende las emisiones de CO_2 y responde al problema específico PE.2. Su análisis se realiza en el escenario E2, considerando la energía demandada por la comunidad, la intensidad temporal de carbono y las emisiones calculadas a escala distrital y por edificio. El alcance ambiental permite determinar si las políticas modifican el momento en que la electricidad es consumida, si favorecen el aprovechamiento de la generación fotovoltaica y si producen diferencias en las emisiones asociadas con la energía importada. No se evalúan otros gases de efecto invernadero ni emisiones directas procedentes de fuentes móviles, procesos industriales o centrales físicas no representadas en el entorno.

La tercera dimensión corresponde a los costos energéticos y se vincula con el problema específico PE.3. Su evaluación se desarrolla en el escenario E3, mediante señales tarifarias diferenciadas por periodos de punta y fuera de punta, costos acumulados y resultados económicos por edificio y para la comunidad. El análisis permite identificar en qué medida cada algoritmo modifica el costo asociado con el consumo y con la coordinación temporal de los recursos distribuidos. Sin embargo, no se incluyen costos de inversión, reposición, mantenimiento, depreciación, financiamiento ni implementación física de los sistemas fotovoltaicos, las baterías o los cargadores.

El mejor algoritmo en cada escenario será determinado a partir de los indicadores correspondientes a su dimensión. En cambio, el mejor algoritmo a nivel global será identificado mediante la integración de los resultados de flexibilidad, emisiones y costos. Esta valoración no implica que un algoritmo deba ocupar el primer lugar en todos los indicadores, sino que deberá presentar el desempeño conjunto más favorable o el compromiso más equilibrado entre los tres objetivos. Por ello, la evaluación global se sustentará en el procedimiento de ranking y en el análisis multicriterio previsto en la metodología, evitando que la conclusión dependa exclusivamente de una recompensa agregada.

b. Alcance espacial

El alcance espacial corresponde a una comunidad inteligente simulada con aplicabilidad al contexto energético de la ciudad de Iquitos y del Sistema Eléctrico Aislado de Iquitos. La comunidad se encuentra integrada por 17 edificios reales de carácter institucional y comercial, cuyos perfiles son empleados para representar agentes con demandas, equipos y condiciones operativas heterogéneas.

Aunque la formulación del problema utiliza la expresión “comunidades inteligentes de la ciudad de Iquitos”, la evidencia empírica se encuentra delimitada a la comunidad de 17 edificios modelada en el entorno de simulación. En consecuencia, los resultados no representan la totalidad de edificaciones, usuarios, alimentadores o sistemas eléctricos de la ciudad. La aplicabilidad territorial se refiere al contexto y a los datos utilizados para construir el caso de estudio, no a una validación general para todas las comunidades inteligentes de Iquitos. El documento final delimita el caso como una comunidad simulada representativa del SEAI Iquitos.

c. Alcance temporal

El alcance temporal de los datos comprende el periodo 2023–2025. El dataset está conformado por 26 304 registros horarios, equivalentes a tres años consecutivos de información. Cada episodio anual comprende 8 760 pasos horarios, mediante los cuales son representadas las variaciones diarias, semanales y estacionales de la demanda, la generación fotovoltaica, las señales tarifarias, la intensidad de carbono y la disponibilidad de los recursos energéticos.

La revisión académica incorpora principalmente artículos científicos, tesis doctorales, tesis de maestría, libros especializados y documentos técnicos publicados entre 2015 y 2026. No obstante, este intervalo corresponde al alcance documental de la investigación y no debe confundirse con el periodo de los datos energéticos analizados.

d. Alcance metodológico

El estudio presenta un enfoque cuantitativo y una orientación aplicada, debido a que se utilizan datos numéricos y modelos computacionales para evaluar una propuesta de gestión energética. Su alcance es comparativo y explicativo dentro del entorno simulado, puesto que se examina el efecto diferenciado del factor algoritmo sobre las tres dimensiones de la variable dependiente.

El diseño cuasiexperimental se organiza mediante una estructura factorial 4 × 3. Los cuatro niveles del factor algoritmo corresponden a HAPPO, MASAC, MATD3 y MAAC, mientras que los tres escenarios corresponden a E1 para flexibilidad energética, E2 para emisiones de CO_2 y E3 para costos energéticos. Esta organización genera 12 tratamientos algoritmo-escenario, ejecutados bajo una misma comunidad, el mismo conjunto de datos, una arquitectura de recompensa previamente definida y criterios homogéneos de evaluación.

La matriz experimental de los 12 tratamientos se encuentra documentada en la versión final de la tesis.

La comparación comprende análisis descriptivos de tendencia central, dispersión, evolución del entrenamiento y comportamiento de los indicadores. Cuando la cobertura de los datos lo permite, se aplican procedimientos inferenciales para establecer si las diferencias observadas entre algoritmos son estadísticamente significativas. No obstante, la interpretación deberá diferenciar entre significación estadística, magnitud del efecto y relevancia energética, debido a que una diferencia estadística no implica necesariamente una mejora operativa considerable.

e. Alcance empírico

La evidencia empírica se restringe a los artefactos materializados de la corrida canónica madrl_v3_20260627_164047. La base auditada contiene 600 registros episódicos, equivalentes a 50 episodios por cada uno de los 12 tratamientos algoritmo–escenario.

Los resultados proceden de archivos de entrenamiento, series temporales, trazas de actuación, KPI distritales, indicadores por edificio, resúmenes de comportamiento y manifiestos de puntos de control. Por tanto, la comparación se sustenta en los datos efectivamente conservados y no en resultados reconstruidos manualmente.

La serie completa de HAPPO fue reconstruida de manera trazable a partir de 49 episodios históricos y el episodio final post-resume. Por tanto, los cuatro algoritmos poseen 50 episodios descriptivos por escenario. Esta igualdad de longitud no convierte los episodios en réplicas independientes: las decisiones inferenciales principales se apoyan en bloques pareados de KPI o edificios y se reportan como evidencia intra-corrida exploratoria.

f. Alcance computacional

La implementación comprende Python 3.9, PyTorch 2.8.0+cu126, CityLearn v2, Gymnasium, PettingZoo y las librerías empleadas para procesamiento de datos, entrenamiento, evaluación estadística y generación de figuras y tablas. Las ejecuciones fueron desarrolladas mediante una computadora local equipada con una GPU NVIDIA RTX 4060 Laptop de 8 GB y mediante Google Colab con GPU NVIDIA A100.

CityLearn v2 constituye el entorno base utilizado por la investigación. La denominación CityLearn v3 propuesta corresponde a una extensión experimental desarrollada para la tesis, mediante la cual fueron incorporados los datos de Iquitos, las señales ambientales y económicas, la comunidad multiagente y los componentes necesarios para evaluar HAPPO,

MASAC, MATD3 y MAAC. En consecuencia, CityLearn v3 no debe ser presentada como una versión oficial publicada por los desarrolladores de CityLearn.

La trazabilidad computacional se mantiene mediante los artefactos results.json, training_summary.json, timeseries.csv, trace.csv, building_kpis.csv, building_behavior_summary.csv, checkpoint_manifest.json y los archivos de indicadores episódicos materializados. La configuración técnica del entorno y la matriz de corridas se encuentran documentadas en el Capítulo 4 de la tesis.

g. Delimitaciones y exclusiones

La investigación no modela físicamente la red eléctrica de Iquitos. Por tanto, no se reproducen flujos de potencia, perfiles de tensión, regulación de frecuencia, cortocircuitos, coordinación de protecciones, estabilidad transitoria, pérdidas eléctricas detalladas ni restricciones electromecánicas completas de los alimentadores.

Tampoco se realiza el despacho económico de unidades reales, una validación en tiempo real ni un despliegue operativo en instalaciones de Electro Oriente S. A. Las decisiones de los agentes se ejecutan dentro de un entorno energético simulado y no producen efectos directos sobre centrales, subestaciones, redes de distribución o usuarios reales.

El estudio no incorpora investigación con sujetos humanos, encuestas, entrevistas, experimentos de comportamiento de ocupantes ni evaluación social directa. La presencia y el comportamiento de los usuarios son representados mediante perfiles de demanda y disponibilidad contenidos en los datos y en las reglas del entorno.

La investigación tampoco incluye una evaluación financiera integral. En consecuencia, no son calculados el valor actual neto, la tasa interna de retorno, el periodo de recuperación, los costos de inversión ni los costos reales de operación y mantenimiento de una futura implementación. El análisis económico se restringe a los costos energéticos modelados mediante las señales tarifarias del entorno.

h. Alcance de la inferencia y generalización

La inferencia se encuentra limitada a la corrida canónica y a una semilla materializada por tratamiento. Aunque la metodología puede ser ampliada posteriormente hacia un diseño multisemilla, no se atribuyen resultados a las semillas que todavía no han sido ejecutadas. Por ello, las conclusiones representan evidencia intraexperimento y no una validación universal del comportamiento de los algoritmos.

Los resultados no se generalizan de manera absoluta a otras ciudades, comunidades, configuraciones de edificios, periodos climáticos, estructuras tarifarias o sistemas eléctricos. Tampoco puede afirmarse que el algoritmo identificado como mejor a nivel global mantendrá esa posición ante cambios en las funciones de recompensa, hiperparámetros, semillas, tecnologías o indicadores utilizados.

En síntesis, el alcance del estudio permite responder el problema general mediante la comparación integrada de HAPPO, MASAC, MATD3 y MAAC, y permite responder PE.1, PE.2 y PE.3 mediante los escenarios E1, E2 y E3, respectivamente. Al mismo tiempo, la interpretación queda restringida a la comunidad simulada de 17 edificios, al periodo 2023–2025, a los 12 tratamientos experimentales y a la evidencia real conservada en la corrida canónica. Esta delimitación mantiene la correspondencia entre la formulación del problema, los objetivos, las hipótesis, las variables y los resultados disponibles.

1.4. Objetivos e hipótesis de la investigación

1.4.1 Objetivos

1.4.1.1 1.3.1.1 Objetivo general

OG. Determinar y cuantificar los efectos diferenciales de los algoritmos HAPPO, MASAC, MATD3 y MAAC en la coordinación energética multiobjetivo de una comunidad inteligente heterogénea de Iquitos, considerando la flexibilidad energética, las emisiones de CO_2 y los costos energéticos, e identificar el algoritmo de mejor desempeño global.

1.4.1.2 1.3.1.2 Objetivos específicos

OE.1. Determinar y cuantificar los efectos diferenciales de los algoritmos HAPPO, MASAC, MATD3 y MAAC sobre la flexibilidad energética (eje E1) e identificar el algoritmo de mejor desempeño en la comunidad inteligente heterogénea de Iquitos.

OE.2. Determinar y cuantificar los efectos diferenciales de los algoritmos HAPPO, MASAC, MATD3 y MAAC sobre las emisiones de CO_2 (eje E2) e identificar el algoritmo de mejor desempeño en la comunidad inteligente heterogénea de Iquitos.

OE.3. Determinar y cuantificar los efectos diferenciales de los algoritmos HAPPO, MASAC, MATD3 y MAAC sobre los costos energéticos (eje E3) e identificar el algoritmo de mejor desempeño en la comunidad inteligente heterogénea de Iquitos.

1.4.2 Hipótesis

1.4.2.1 1.3.2.1 Hipótesis general

HG0. Los algoritmos HAPPO, MASAC, MATD3 y MAAC no producen efectos diferenciales estadísticamente significativos en la coordinación energética multiobjetivo de la comunidad inteligente heterogénea de Iquitos, considerando conjuntamente la flexibilidad energética, las emisiones de CO_2 y los costos energéticos.

HG1. Al menos uno de los algoritmos HAPPO, MASAC, MATD3 y MAAC produce un efecto diferencial estadísticamente significativo en la coordinación energética multiobjetivo de la comunidad inteligente heterogénea de Iquitos, considerando conjuntamente la flexibilidad energética, las emisiones de CO_2 y los costos energéticos.

1.4.2.2 1.3.2.2 Hipótesis específicas

HE10. Los algoritmos HAPPO, MASAC, MATD3 y MAAC no producen efectos diferenciales estadísticamente significativos sobre la flexibilidad energética (eje E1) de la comunidad inteligente heterogénea de Iquitos.

HE11. Al menos uno de los algoritmos HAPPO, MASAC, MATD3 y MAAC produce un efecto diferencial estadísticamente significativo sobre la flexibilidad energética (eje E1) de la comunidad inteligente heterogénea de Iquitos.

HE20. Los algoritmos HAPPO, MASAC, MATD3 y MAAC no producen efectos diferenciales estadísticamente significativos sobre las emisiones de CO_2 (eje E2) de la comunidad inteligente heterogénea de Iquitos.

HE21. Al menos uno de los algoritmos HAPPO, MASAC, MATD3 y MAAC produce un efecto diferencial estadísticamente significativo sobre las emisiones de CO_2 (eje E2) de la comunidad inteligente heterogénea de Iquitos.

HE30. Los algoritmos HAPPO, MASAC, MATD3 y MAAC no producen efectos diferenciales estadísticamente significativos sobre los costos energéticos (eje E3) de la comunidad inteligente heterogénea de Iquitos.

HE31. Al menos uno de los algoritmos HAPPO, MASAC, MATD3 y MAAC produce un efecto diferencial estadísticamente significativo sobre los costos energéticos (eje E3) de la comunidad inteligente heterogénea de Iquitos.

CAPÍTULO VI. Marco teórico

El presente capítulo desarrolla los fundamentos conceptuales, matemáticos y tecnológicos que sustentan el análisis del impacto de los algoritmos de aprendizaje por refuerzo profundo multiagente en la gestión coordinada de la flexibilidad energética, las emisiones de CO_2 y los costos energéticos. Su finalidad consiste en construir una base teórica coherente con la formulación del problema, los objetivos, las hipótesis y las variables definidas para una comunidad inteligente representativa de la ciudad de Iquitos.

El problema abordado presenta una naturaleza secuencial, cooperativa, multiobjetivo y parcialmente observable. Cada edificio dispone de información local, controla únicamente determinados recursos energéticos y, al mismo tiempo, contribuye a un comportamiento agregado que se manifiesta en la demanda máxima, las rampas de consumo, las emisiones asociadas con la electricidad y el costo energético comunitario. Debido a esta interdependencia, la gestión no puede ser explicada adecuadamente mediante un agente aislado ni mediante una función de optimización estática.

La literatura especializada ha mostrado que los recursos energéticos distribuidos pueden incrementar la capacidad de adaptación de los edificios y comunidades frente a las necesidades de la red. Sin embargo, la generación fotovoltaica, los sistemas de almacenamiento, los vehículos eléctricos y las cargas desplazables no generan flexibilidad de manera automática. Su aportación depende de la forma en que son coordinados, de las señales económicas y ambientales utilizadas, de las restricciones físicas incorporadas y del mecanismo algorítmico empleado para aprender las decisiones.

La literatura muestra una evolución desde controladores basados en reglas y control predictivo hacia enfoques de aprendizaje capaces de coordinar recursos energéticos distribuidos en condiciones de incertidumbre. CityLearn y CityLearn v2 aportan entornos comparables para control de edificios y comunidades; los trabajos de , y destacan que el desempeño práctico depende de la calidad de los datos, de la representación física, de la seguridad operativa y de la capacidad de generalización. En paralelo, la literatura MARL evidencia que la heterogeneidad de agentes, la no estacionariedad y la asignación de crédito requieren mecanismos de coordinación explícitos. La brecha abordada por la tesis consiste en comparar HAPPO, MASAC, MATD3 y MAAC con el mismo dataset de Iquitos, la misma arquitectura de recompensa, pesos definidos por escenario y un protocolo común de trazabilidad ; ; ; .

sostiene que las comunidades interactivas con la red pueden suministrar flexibilidad continua mediante la coordinación de recursos distribuidos; no obstante, también identifica barreras relacionadas con la eficiencia de los datos, la seguridad de las políticas y su capacidad de generalización. En una perspectiva complementaria, muestra que el aprendizaje por refuerzo puede reducir la dependencia de modelos físicos completos en el control de edificios, aunque su aplicación debe ser contrastada con métodos convencionales y evaluada bajo restricciones operativas verificables. Las investigaciones de y profundizan esta precaución al demostrar que, en sistemas eléctricos, las políticas aprendidas requieren mecanismos de seguridad, robustez y supervisión cuando las acciones pueden afectar variables físicas críticas.

Sobre esta base, el capítulo ha sido organizado en seis apartados. Primero, se desarrollan el aprendizaje por refuerzo, la formulación Dec-POMDP, el paradigma de entrenamiento centralizado con ejecución descentralizada y la evolución de CityLearn. Luego, se delimitan las variables. Posteriormente, se explican las bases teóricas correspondientes a flexibilidad, emisiones, costos y algoritmos. Finalmente, se examinan los antecedentes, se precisan los términos fundamentales y se presenta la posición teórica adoptada.

1.5. Fundamentos teóricos, conceptuales y matemáticos de las variables de investigación

El fundamento teórico de la investigación se construye a partir de la relación entre una variable independiente de naturaleza algorítmica y una variable dependiente de naturaleza energética, ambiental y económica. La variable independiente está representada por la configuración del aprendizaje por refuerzo profundo multiagente empleada para aprender políticas cooperativas de control; la variable dependiente corresponde a la gestión coordinada de la flexibilidad energética, las emisiones de CO_2 y los costos energéticos. Esta relación se analiza dentro de una simulación controlada y, por tanto, el término impacto expresa el efecto diferenciado observado entre configuraciones algorítmicas, sin atribuir causalidad física directa sobre la operación real de la ciudad de Iquitos.

La investigación se encuentra delimitada por la versión final de la tesis, en la que ha sido modelada una comunidad inteligente integrada por 17 edificios institucionales y comerciales representativos del Sistema Eléctrico Aislado de Iquitos. El entorno local incorpora generación fotovoltaica, sistemas de almacenamiento en baterías, cargadores de vehículos eléctricos, capacidad V2G, cargas desplazables y demanda base no controlada. El conjunto de datos citylearn_iquitos_2023_2025 contiene 26 304 registros horarios del periodo 2023–

2025, mientras que cada episodio experimental representa un año de 8 760 pasos. La comparación se organiza mediante cuatro algoritmos (HAPPO, MASAC, MATD3 y MAAC) y tres escenarios (E1, E2 y E3), lo que constituye un diseño factorial de 12 tratamientos.

1.6. Bases teóricas

1.6.1 MADRL

Es el acrónimo en inglés para “aprendizaje por refuerzo y aprendizaje por refuerzo profundo multiagente”. El aprendizaje por refuerzo constituye un paradigma de decisión secuencial mediante el cual una entidad denominada agente aprende una política de actuación a partir de su interacción con un entorno. En cada instante t, el agente observa una representación del entorno, ejecuta una acción, recibe una señal de recompensa y transita hacia una condición posterior. El propósito consiste en maximizar el retorno esperado acumulado durante un horizonte de decisión, en lugar de optimizar de manera aislada cada recompensa inmediata .

Un proceso de decisión de Márkov puede representarse mediante:

$M=\langle S,A,P,R,\gamma \rangle$,

donde S es el espacio de estados; A, el espacio de acciones; P, la función de transición; R, la función de recompensa; y γ, el factor de descuento. La política $\pi(a|s)$ determina la probabilidad o regla con la que una acción es seleccionada frente a un estado.

1.6.2 1.3.1.3 Criterios de determinacion del impacto

Para cumplir el OG y los OE.1–OE.3, y para demostrar las hipotesis, la tesis exige el conjunto completo de criterios de determinacion del impacto (C1–C5). Uno de ellos —C5— es el control de recursos energeticos (BESS, EV/V2G y carga desplazable). Los tres ejes se reportan a nivel de distrito y a nivel de edificio (evidencia Cap. 5).

Id	Criterio	Medida / prueba	Rol
C1	Impacto vs baseline	Wilcoxon KPI-gains vs cero + Holm	Inferencial HE
C2	Diferencias entre algoritmos	Kruskal-Wallis / Friedman + Holm	Inferencial HE
C3	KPIs fisicos de distrito por eje	flex_composite / delta CO2 / delta costo	Descriptivo distrito
C4	KPIs desagregados por edificio por eje	17 edificios x E1/E2/E3	Descriptivo edificio
C5	Control de recursos	BESS, EV/V2G,	Obligatorio

		carga desplazable (acciones y exito EV)	(atribuibilidad)

Tabla 1.3. Criterios completos de determinacion del impacto (C5 = control de recursos; evidencia Cap. 5).

Regla de cumplimiento sin parciales: OG/OE.1–OE.3 y la demostracion de hipotesis exigen C1–C5. Cada eje se reporta a nivel distrito y a nivel edificio. C5 (control de recursos) es obligatorio para atribuir el impacto a las acciones MADRL sobre BESS, EV/V2G y carga desplazable.

El retorno descontado desde el instante t se expresa como:

$$G_t = \sum_{k=0}^{H-t-1} \gamma^k r_{t+k}$$

donde H representa el horizonte del episodio. A partir del retorno pueden definirse la función de valor de estado:

(s)= Eπ [Gt | St=s],

y la función de valor estado-acción:

Qπ(s,a)=Eπ[Gt ∣ St=s,At=a].

La diferencia entre el retorno esperado al ejecutar una acción y el valor promedio del estado puede representarse mediante la función de ventaja:

Aπ(s,a)=Qπ(s,a)−Vπ(s)

Estas funciones permiten valorar no solo la consecuencia inmediata de una acción, sino también sus efectos futuros. En un sistema energético, una decisión de carga de batería puede elevar momentáneamente el consumo y, al mismo tiempo, permitir una descarga posterior durante un periodo de mayor precio, mayor demanda o mayor intensidad de carbono. Por ello, la evaluación secuencial resulta más adecuada que una regla basada exclusivamente en la condición instantánea.

El aprendizaje por refuerzo profundo incorpora redes neuronales como aproximadores de las políticas y funciones de valor. Esta ampliación permite procesar espacios de observación de elevada dimensión y acciones continuas, características frecuentes en la gestión de edificios, microrredes y sistemas multienergéticos. analiza el control energético de edificios mediante políticas aprendidas, mientras que desarrolla un sistema de gestión multivectorial que integra costos de intercambio con la red, cumplimiento del estado de carga vehicular y

restricciones de seguridad. Ambos trabajos evidencian que la utilidad de una política depende del diseño de las observaciones, de la recompensa y de la representación de los límites operativos.

Dentro de los métodos profundos, las arquitecturas actor–critic separan dos funciones. El actor representa la política y genera las acciones; el crítico estima el valor de dichas acciones y orienta la actualización de los parámetros del actor. Esta separación resulta especialmente útil en espacios continuos, donde no es posible enumerar exhaustivamente todas las alternativas de control.

Cuando el entorno contiene varios agentes, el problema se transforma en aprendizaje por refuerzo multiagente. Cada agente modifica, mediante sus decisiones, la experiencia observada por los demás. En consecuencia, el entorno deja de ser estacionario desde la perspectiva individual, porque las probabilidades de transición dependen indirectamente de políticas que también están cambiando.

La no estacionariedad constituye una de las principales dificultades del aprendizaje multiagente. Si cada edificio fuera entrenado de manera independiente, las actualizaciones ejecutadas por los demás agentes serían percibidas como cambios externos del entorno. Este fenómeno puede generar oscilaciones, inestabilidad o políticas que maximizan un objetivo local en perjuicio del resultado comunitario.

Una segunda dificultad corresponde a la asignación de crédito. En una comunidad de edificios, la recompensa global puede mejorar o deteriorarse debido a la interacción simultánea de múltiples decisiones. Determinar qué agente produjo una mejora concreta no resulta trivial. El problema aumenta cuando las edificaciones poseen equipamientos, acciones y perfiles de consumo diferentes.

comprobó que las recompensas individuales y conjuntas no producen efectos uniformes en todos los algoritmos. En su aplicación a CityLearn, determinadas arquitecturas respondieron mejor a recompensas individuales, mientras que otras se beneficiaron de una señal conjunta. El autor concluyó que la selección de la estructura de recompensa introduce un compromiso entre sesgo, varianza y coordinación, por lo que no puede asumirse que una recompensa global sea universalmente superior.

Este hallazgo resulta relevante para la tesis, porque el perfil de recompensa combina componentes locales y comunitarios. La parte colectiva busca impedir que una edificación reduzca su propio costo trasladando un pico hacia el resto de la comunidad. La parte local,

en cambio, reconoce que los 17 edificios presentan demandas, equipos, vehículos y capacidades de almacenamiento diferentes. La formulación numérica de esta recompensa pertenece al Capítulo 4; en el marco teórico solo se establece que su diseño debe equilibrar cooperación y desempeño individual.

Una tercera dificultad es la heterogeneidad. Muchos métodos cooperativos han sido diseñados bajo supuestos de homogeneidad, como el uso de espacios de observación semejantes, acciones equivalentes o parámetros compartidos. Sin embargo, tales supuestos no representan apropiadamente una comunidad compuesta por edificios institucionales y comerciales con distintos perfiles de demanda, generación y equipamiento.

cuestionan la dependencia del intercambio de parámetros entre agentes y desarrollan una familia de algoritmos orientada a entornos heterogéneos. Su planteamiento se fundamenta en una descomposición de la ventaja multiagente y en un esquema de actualización secuencial que busca reducir conflictos entre las actualizaciones individuales. Los resultados obtenidos en diversos entornos cooperativos muestran que las diferencias entre agentes deben ser tratadas explícitamente y no eliminadas mediante relleno artificial de observaciones o acciones.

En la gestión energética, esta consideración adquiere especial importancia. Una edificación con múltiples cargadores de vehículos eléctricos, almacenamiento y generación fotovoltaica no debe ser tratada como equivalente a otra que solo disponga de una carga flexible reducida. El aprendizaje por refuerzo profundo multiagente ofrece un marco para conservar esta diferenciación y, simultáneamente, coordinar las acciones hacia objetivos agregados.

No obstante, la flexibilidad del aprendizaje por refuerzo no elimina la necesidad de restricciones. muestra que las políticas multiagente aplicadas al control de tensión y frecuencia deben incorporar información física y mecanismos de protección para impedir acciones inseguras. también aborda la regulación en tiempo real bajo condiciones operativas del sistema eléctrico. Estas investigaciones no constituyen antecedentes directos de la gestión de costos de edificios, pero permiten establecer un principio transversal: una política aprendida debe ser interpretada dentro del dominio físico para el que fue entrenada.

Por tanto, el MADRL se adopta en esta investigación no porque sustituya universalmente a los métodos de control existentes, sino porque permite representar decisiones descentralizadas, observaciones heterogéneas y objetivos interdependientes. Su desempeño

debe ser evaluado mediante indicadores energéticos, ambientales y económicos, y no únicamente mediante la recompensa acumulada

y muestran su aplicación al control energético de edificios, donde la política debe equilibrar eficiencia, flexibilidad y restricciones operativas. En esta tesis, las acciones corresponden a carga o descarga de BESS, gestión de cargadores EV/V2G y desplazamiento de cargas flexibles.

El aprendizaje por refuerzo profundo incorpora redes neuronales como aproximadores de políticas y funciones de valor, lo que permite tratar espacios de observación y acción de elevada dimensión. El método actor–critic son especialmente pertinentes para sistemas energéticos continuos porque separan la generación de acciones de la evaluación de su calidad. SAC introduce regularización por máxima entropía para favorecer exploración y robustez; TD3 reduce el sesgo de sobreestimación mediante críticos dobles y actualizaciones retardadas; y los enfoques con atención seleccionan interacciones relevantes entre agentes ; ; . Estas familias sustentan, respectivamente, MASAC, MATD3 y MAAC en la propuesta.

En un sistema multiagente, cada política modifica el entorno efectivo observado por las demás, generando no estacionariedad, asignación de crédito y dependencia entre decisiones. El marco Dec-POMDP representa cooperación bajo observabilidad parcial, mientras que CTDE permite usar información global durante el entrenamiento y observaciones locales durante la ejecución. Los trabajos de , y convergen en que la coordinación debe considerar simultáneamente información global, heterogeneidad de agentes y ejecución descentralizada. En la tesis, cada edificio opera con observación local, pero el aprendizaje incorpora información distrital para internalizar picos, rampas, emisiones y costos agregados.

La cooperación se implementa mediante una recompensa mixta que combina desempeño local y desempeño de equipo. Esta decisión evita que un edificio reduzca su costo desplazando picos, emisiones o restricciones hacia otros agentes, y evita también que una señal exclusivamente global ignore la heterogeneidad de cada edificio. demuestra que la elección entre recompensas individuales y conjuntas modifica el sesgo, la varianza y la coordinación en CityLearn; advierten que el diseño de recompensas es uno de los factores que dificultan la transferencia de MARL a edificios reales. Por ello, la tesis conserva una mezcla local–equipo idéntico para los cuatro algoritmos y modifica únicamente los pesos por escenario E1, E2 y E3.

1.6.3 Formalización matemática Dec-POMDP

Un proceso de decisión de Márkov descentralizado y parcialmente observable (Dec-POMDP) constituye una formalización adecuada para problemas cooperativos en los que varios agentes actúan sobre un entorno compartido sin observar completamente su estado. describen este modelo como una extensión del POMDP hacia escenarios donde las decisiones se distribuyen entre agentes con información local.

El Dec-POMDP puede expresarse mediante:

D=⟨ N, S,,P,R, , O, γ⟩ ,

donde:

N={1,…,N} es el conjunto de agentes;

S: representa el espacio de estados globales;

: es el espacio de acciones del agente i;

A=×⋯ ×constituye el espacio de acciones conjuntas;

P (s′ ∣ s, a) es la probabilidad de transición;

R (s, a) representa la recompensa cooperativa;

Oí es el espacio de observaciones locales;

O (o ∣ s, a) corresponde al modelo de observación;

y γ representa el factor de descuento

En este modelo, el agente i no selecciona su acción a partir del estado global completo, sino mediante una observación local Oí Oí _ioio una historia de observaciones y acciones:

=(, ,…,).

La política descentralizada puede representarse como:

πi (∣).

La política conjunta se expresa mediante:

π= (π1, π2,…,πN).

El objetivo cooperativo consiste en maximizar:

)

La observabilidad parcial constituye un elemento central. En una comunidad energética, un edificio puede conocer su demanda, la generación fotovoltaica local, el estado de carga de sus baterías y la disponibilidad de sus vehículos. Sin embargo, durante una ejecución

descentralizada no necesariamente dispone del estado detallado de todos los demás edificios.

La acción conjunta modifica la demanda agregada de la comunidad. Por ejemplo, la carga simultánea de varios sistemas de almacenamiento puede originar un pico incluso cuando cada decisión resulte razonable desde el punto de vista individual. De manera semejante, la descarga simultánea puede reducir el consumo neto durante un periodo, pero comprometer la capacidad de respuesta posterior.

La transición depende de variables controlables y exógenas. Entre las primeras se encuentran la carga y descarga de baterías, la operación de cargadores, el intercambio bidireccional vehicular y el desplazamiento de determinadas cargas. Entre las segundas pueden considerarse la demanda base, las condiciones meteorológicas, la irradiación, la disponibilidad vehicular y las señales externas de precio o carbono.

La recompensa representa el vínculo entre la política y los objetivos de investigación. Sin embargo, no debe confundirse con el desempeño final. Una política puede obtener una recompensa favorable debido a los pesos asignados y, al mismo tiempo, presentar un comportamiento inferior en un KPI específico. Por esta razón, la recompensa orienta el aprendizaje, mientras que los KPI permiten interpretar el resultado físico, ambiental y económico.

En la tesis, el Dec-POMDP se aplica a una comunidad constituida por 17 edificios. Los valores específicos de observaciones, acciones, horizonte anual y parámetros de entrenamiento corresponden a la implementación interna y no a la teoría general de Oliehoek y Amato. La tesis final conserva la comunidad de 17 edificios, el diseño factorial de cuatro algoritmos por tres escenarios y la separación entre la formalización conceptual y los datos computacionales.

La formalización Dec-POMDP permite responder a la estructura de los problemas de investigación. El problema específico 1 examina el efecto algorítmico sobre la flexibilidad en E1; el problema específico 2 se centra en las emisiones en E2; y el problema específico 3 evalúa los costos en E3. En todos los casos, el algoritmo actúa sobre el mismo tipo general de sistema descentralizado, mientras cambia la prioridad multiobjetivo de la recompensa

El proceso de decisión de Márkov parcialmente observable descentralizado (Dec-POMDP) formaliza decisiones cooperativas cuando los agentes comparten un objetivo, pero disponen de información local incompleta. lo definen mediante un estado global, acciones

conjuntas, transiciones, observaciones locales, función de observación, recompensa compartida y factor de descuento. Esta formulación corresponde al caso estudiado porque cada edificio observa sus variables operativas, precios, intensidad de carbono, BESS y EV, pero no accede durante la ejecución a la temperatura, demanda, SOC ni disponibilidad vehicular de los otros edificios.

El problema de tesis se modela como el Dec-POMDP cooperativo M, definido por la tupla siguiente ; :

M = <S, {A_i}_{i=1}^N, T, R, {O_i}_{i=1}^N, Omega, gamma, T_hor>

donde N = 17 edificios institucionales / comerciales del dataset citylearn_iquitos_2023_2025, gamma = 0.9999 (factor de descuento para episodios de 8 760 pasos horarios) y T_hor = 8 760 (un ano simulado). El objetivo cooperativo es maximizar el retorno esperado J () = , donde π= (π1, π2,…,πN) denota el conjunto de políticas locales.

La Tabla 3 resume la notación formal

Tabla 1

Notación formal del Dec-POMDP cooperativo (SEAI Iquitos, N = 17)

Símbolo	Definición teórica	Valor / rango en esta tesis
N	Número de agentes cooperativos (edificios)	17
S	Espacio de estado global	Concatenacion s = [o_1, ..., o_17]; dim global = 1 856
O_i	Espacio de observación local del agente i	Heterogeneo: 54-327 dimensiones (medido CityLearnEnv; flota EV por edificio)
A_i	Espacio de acción local del agente i	Heterogeneo: 5-44 dims; d_ai = 2 + n_i^ch (BESS + EV por toma + lavadora); suma distrital = 219
T	Función de transición estocástica S x A -> Delta(S)	Balance energético, modelo RC, BESS eta_RT = 0.9025, EV estocástico
Omega	Función de observación O_i = Omega (s, a)	Proyección parcial del estado global a información local
R	Recompensa cooperativa escalar o vector mixto	CityLearnV3MADRLRewardFunction; agregación team_mean
gamma	Factor de descuento	0.9999
T_hor	Horizonte temporal del episodio	8 760 pasos (1 h/paso)
pi_i	Política descentralizada del edificio i	pi_i(a_i | o_i); sin comunicación inter-edificio

Nota. La tabla representa la formalización teórica del problema multiagente y sus elementos matemáticos. Fuente: Elaboración propia a partir de Oliehoek y Amato (2016), Lowe et al. (2017) y los artefactos del entorno CityLearn usado en la tesis.

Recompensa cooperativa multiobjetivo. La función R materializa los tres ejes de investigación (flexibilidad, CO_2, costos) mediante una recompensa escalar por edificio y paso, con agregación cooperativa tipo media de equipo.

A nivel teórico:

reward_i(t) = reward_scale * [w_flex * flex_i(t) + w_carbon * carbon_i(t) + w_cost * cost_i(t) + w_ev * ev_i(t)]

El componente flex_i(t) penaliza, a nivel distrital compartido, el pico y la rampa mediante peak_share(t) = district_import(t) / N y ramp_share(t) = |district_import(t) - district_import(t-1) | / N, con funciones de suavizado tanh; carbon_i(t) pondera la importación por la intensidad de carbono CI(t); cost_i(t) refleja la tarifa TOU mediante price_norm(t); y ev_i(t) incorpora urgencia de SOC y salida de vehículos. Los pesos w_flex, w_carbon y w_cost se condicionan por escenario experimental (E1/E2/E3) según la Tabla 3.1 del Capítulo 3.

team_reward(t) = (1/N) * sum_{i=1} ^ N reward_i(t)

mixed_reward_i(t) = (1 - r) * reward_i(t) + r * team_reward(t), con r = 0.70

La mezcla cooperativa con team_reward_ratio r = 0,70 mantiene un compromiso entre desempeño local y desempeño comunitario. El valor se aplica por igual a HAPPO, MASAC, MATD3 y MAAC para evitar que las diferencias observadas se expliquen por una función de recompensa distinta. Los escenarios E1, E2 y E3 modifican únicamente los pesos de flexibilidad, carbono y costo. Durante la ejecución descentralizada, cada política $\pi_i(a_i|o_i)$ utiliza solo la observación local; el estado global se reserva para el entrenamiento conforme al esquema CTDE desarrollado en la Sección 4.3 ; .

1.6.4 Dec-POMDP como formalización del problema de investigación

La gestión energética estudiada no es un problema de control centralizado simple, porque la decisión de cada edificio modifica la demanda agregada, el costo, las emisiones y las condiciones de flexibilidad que observan los demás agentes. Tampoco es un MDP plenamente observable por agente individual: cada edificio observa su propio estado operativo, disponibilidad de equipos, señales temporales y variables exógenas, pero no controla directamente la demanda base ni las restricciones internas de los otros edificios. Por

ello, la formalización adoptada adecuada es un Proceso de Decisión de Márkov Parcialmente Observable Descentralizado (Dec-POMDP), que permite representar ejecución descentralizada, observabilidad parcial, transiciones estocásticas y recompensa cooperativa.

La formulación utilizada en la tesis se expresa como M = <S, {A_i} _{i=1} ^ {17}, T, R, {O_i} _{i=1} ^ {17}, Omega, gamma, H>. El estado global S contiene la concatenación de observaciones locales s_t=[o_1,t,...,o_17,t]; las acciones A_i son heterogéneas por edificio; T representa la dinámica horaria de CityLearn, incluyendo clima, PV, BESS, llegada / salida de vehículos eléctricos, demanda base, precio y señal de carbono; R es una recompensa cooperativa con mezcla local-equipo; O_i y Omega modelan la observabilidad parcial; gamma=0.9999 preserva dependencia de largo horizonte; y H=8760 pasos representa un ano horario de evaluación por episodio.

La operacionalización empírica no queda en una abstracción genérica. Los artefactos auditados describen 17 agentes-edificio, dimensiones locales de observación entre 54 y 327, dimensión global agregada de 1 856, acciones locales entre 5 y 44 y 219 dimensiones de acción conjuntas. Las acciones controlan BESS, cargadores EV/V2G y cargas flexibles declaradas en building_observation_action_schema.csv; la demanda base permanece como perturbación exógena y no como actuador.

Jerarquia distrito / edificio del Dec-POMDP (valores medidos en CityLearnEnv sobre citylearn_iquitos_2023_2025). No existe un agente-distrito que emita setpoints: el control distrital es emergente de 17 politicas locales.

Nivel edificio (agente i): observacion local o_i en R^{d_oi} con d_oi en [54, 327] (calendario, meteo, carga, termica, PV, SoC BESS, precio/CI y 7 canales EV por cargador); accion a_i con d_ai = 2 + n_i^ch en [5, 44] (electrical_storage + electric_vehicle_storage x n_ch + washing_machine); politica pi_i(a_i | o_i) sin ver o_j.

Nivel distrito (comunidad SEAI / critico CTDE): estado global s = [o_1, ..., o_17] en R^{1856} (= suma exacta de d_oi), visible solo en entrenamiento; agregados P^com(t) = sum_i P_i^net(t), pico/rampa distritales y KPIs evaluate_v2; team_reward = mean(reward_i) y mixed_reward_i = (1 - r_team)*reward_i + r_team*team_reward con r_team = 0,70 (perfil unified_comparable_v4). gamma = 0,9999; T = 8 760.

Tabla 2.A — Dimensiones Dec-POMDP reales por edificio

ID	Edificio	Carg. EV	d_oi	d_ai
B01	Electro Oriente S.A.	4	61	6

B02	Munic. San Juan Bautista	6	75	8
B03	Aeropuerto Internacional	8	89	10
B04	Hipermercados Tottus	6	75	8
B05	Hotel Plaza S.A.	3	54	5
B06	Mall Aventura	32	257	34
B07	UNAP Biologia	42	327	44
B08	PNP Escuela Tecnica	17	152	19
B09	GORE Loreto COER	10	103	12
B10	Gobierno Regional Loreto	6	75	8
B11	Hospital Regional	3	54	5
B12	EsSalud	3	54	5
B13	UNAP Cs. Economicas	11	110	13
B14	Autoridad Portuaria	4	61	6
B15	DREL Colegio Nacional	8	89	10
B16	SIMA Iquitos	11	110	13
B17	Asoc. Civil Selva Amazonica	11	110	13
Distrito	suma d_oi = d_s; suma acciones	185	1856	219

Nota. Dimensiones medidas con CityLearnEnv(schema Iquitos, central_agent=False). Fuente: elaboracion propia a partir del dataset citylearn_iquitos_2023_2025.

Esta formalización enlaza directamente el problema general y los objetivos específicos. OE.1 evalúa la respuesta del Dec-POMDP cuando la recompensa prioriza flexibilidad; OE.2 cuando prioriza emisiones de CO_2; y OE.3 cuando prioriza costos energéticos. La variable independiente no es solo el nombre del algoritmo, sino la política MADRL aprendida bajo CTDE y bajo pesos de recompensa comparables. La variable dependiente se observa mediante KPIs distritales y por edificio, por lo que el Dec-POMDP justifica simultáneamente el entrenamiento multiagente y la lectura de resultados por distrito, edificio, escenario y KPI.

La Figura 2.1 sintetiza la formalización teórica precedente: el entorno físico CityLearn v2 (edificio, DER, red y comunidad), la interfaz de control Actor–Crítico bajo CTDE y la tupla Dec-POMDP cooperativa instanciada en el SEAI Iquitos.

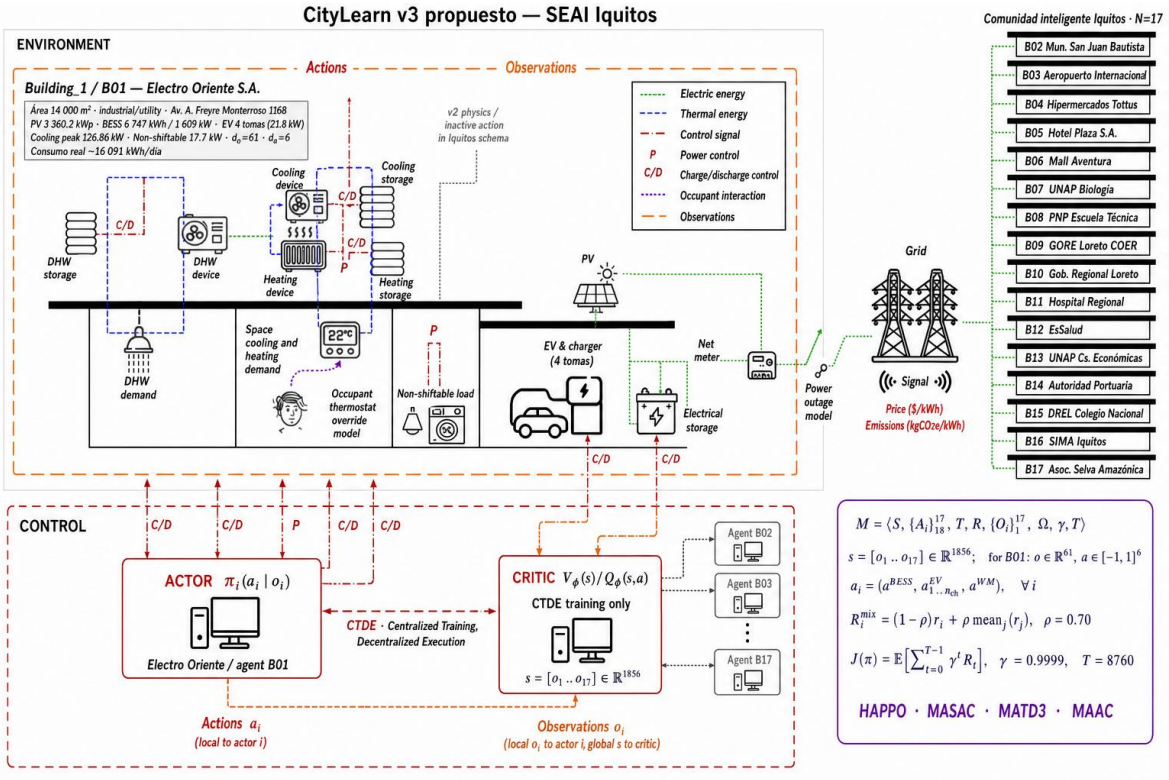


Figura 2.1. Control por edificio CityLearn v3 propuesto (simbología CityLearn v2): Electro Oriente S.A. (B01), comunidad inteligente Iquitos (B02–B17), red pública/SEAI, Actor–Crítico CTDE y formulación Dec-POMDP.

Nota. Adaptación de la Fig. 1 de CityLearn v2 (Nweye et al., 2024) a la capa CityLearn v3 propuesto de esta tesis. Se conserva la simbología oficial (energía eléctrica = línea verde punteada; energía térmica = azul discontinua; señal de control = rojo dash-dot con P/C/D; interacción del ocupante = morada punteada; observaciones = naranja long-dash). Building_1/B01 muestra datos reales de Electro Oriente S.A. (PV 3 360,2 kWp; BESS 6 747 kWh / 1 609 kW; 4 tomas EV; d_o = 61; d_a = 6). La comunidad lista B02–B17 con etiquetas del dataset citylearn_iquitos_2023_2025. En CONTROL, el Actor π_i(a_i|o_i) ejecuta de forma descentralizada y el Crítico V/Q opera solo en entrenamiento CTDE con s = [o_1,…,o_17] ∈ ℝ^1856. Acciones MADRL activas: electrical_storage, electric_vehicle_storage y washing_machine; el bloque térmico v2 se mantiene como física (acciones cooling/heating/DHW inactivas en el schema Iquitos). Fuente: elaboración propia a partir de Nweye et al. (2024), Oliehoek y Amato (2016), Lowe et al. (2017) y artefactos del proyecto (docs/architecture/CITYLEARN_V3_CONTROL_EDIFICIO_ACTOR_CRITIC.png).

Tabla 2

Mapeo del Dec-POMDP académico a artefactos reales del proyecto

Elemento	Operación en la tesis	Evidencia local
Agentes	Edificios institucionales/comerciales de la comunidad	17 agentes en building_behavior_summary.csv
Estado global S	Concatenación de observaciones locales para critic/entrenamiento CTDE	suma observation_dim=1856
Observación local O_i	Información parcial disponible para cada actor	rango observado 54-327 variables
Acción A_i	Control descentralizado de equipos flexibles	rango observado 5-44; total=219
Transición T	Dinámica horaria de CityLearn: clima, PV, BESS, EV, precio, carbono y demanda	timeseries.csv y traces por tratamiento
Recompensa R	Función multiobjetivo comparable por escenario E1/E2/E3	pesos flex/CO2/costo y agregación team_mean
Horizonte H	Evaluación anual horaria por episodio	8760 pasos horarios
Descuento gamma	Persistencia de efectos diferidos de almacenamiento y carga EV	gamma=0.9999

Nota. La tabla representa la formalización teórica del problema multiagente y sus elementos matemáticos. Fuente: Elaboración propia a partir de , y los artefactos del entorno CityLearn usado en la tesis.

1.6.5 Entrenamiento centralizado con ejecución descentralizada

El entrenamiento centralizado con ejecución descentralizada (CTDE) no constituye una formalización alternativa al Dec-POMDP. El Dec-POMDP describe el problema de decisión; CTDE establece la forma en que las políticas pueden ser aprendidas y posteriormente ejecutadas.

Durante el entrenamiento, el crítico puede utilizar el estado global, las observaciones conjuntas o las acciones de otros agentes. Esta información permite representar la interacción entre políticas y reducir parcialmente la no estacionariedad. Durante la ejecución, cada actor selecciona acciones a partir de su observación local, sin requerir acceso permanente al estado completo.

desarrollaron un actor–crítico multiagente en el que el crítico utiliza información conjunta durante el entrenamiento, mientras los actores operan localmente. Esta separación permite conservar una ejecución descentralizada sin renunciar a la información global disponible durante la fase de aprendizaje. extendieron esta idea mediante atención, de modo que el crítico pueda seleccionar qué agentes aportan información relevante para evaluar una acción.

El crítico centralizado del agente i puede expresarse de manera general como:

Qi(o,a),

mientras que su actor descentralizado opera según:

ai∼πi(· | oi).

La ventaja de CTDE radica en que el entrenamiento puede considerar los efectos comunitarios de las acciones. Sin embargo, este paradigma no resuelve automáticamente todos los problemas. El crecimiento del número de agentes puede aumentar la dimensionalidad del crítico; la dependencia de información global puede dificultar la transferencia; y la modificación simultánea de políticas puede introducir gradientes conflictivos.

señalan que la actualización simultánea de agentes puede provocar inestabilidad, debido a que cada política desconoce la dirección seguida por sus compañeros. El esquema secuencial de HAPPO busca reducir esta dificultad actualizando las políticas en un orden definido, de modo que las modificaciones ya realizadas puedan ser consideradas por las actualizaciones siguientes.

aporta una evidencia complementaria: incluso bajo aprendizaje centralizado y ejecución descentralizada, el resultado depende del tipo de recompensa y del algoritmo. Sus experimentos muestran que no puede asumirse una relación única entre mayor cooperación explícita y mejor desempeño. La política, el crítico y la estructura de la señal de aprendizaje interactúan de manera específica.

La comunicación constituye otra alternativa para mejorar la coordinación. Una arquitectura puede permitir intercambio explícito de mensajes entre agentes o representar la comunidad como un grafo. desarrolla redes neuronales de grafos para sistemas multiagente y demuestra que el procesamiento basado en vecindades puede favorecer la escalabilidad, la transferencia entre topologías y la toma de decisiones con información local. Aunque su tesis se orienta a redes de comunicación, aporta una perspectiva pertinente para futuras extensiones de comunidades energéticas, donde las relaciones entre edificios podrían ser representadas mediante proximidad eléctrica, intercambio energético o correlación de cargas.

La presente investigación no incorpora una red neuronal de grafos dentro de los cuatro tratamientos. Por tanto, esta aproximación se considera una línea teórica complementaria, no un componente de la implementación. El esquema principal se mantiene dentro de CTDE, con actores locales y mecanismos centralizados de aprendizaje definidos por cada algoritmo.

En términos de aplicabilidad, CTDE resulta coherente con la comunidad de Iquitos porque permite que cada edificio conserve decisiones locales durante la ejecución. La

información comunitaria se utiliza para entrenar políticas coordinadas, pero no se presupone que todos los edificios deban compartir de manera permanente sus estados completos

1.6.6 CityLearn y simulación multiobjetivo

CityLearn constituye la línea de simulación directamente vinculada con la tesis porque estandariza la comparación de controladores de respuesta a la demanda y gestión energética urbana. plantean un entorno reproducible para políticas basadas en reglas, control predictivo y aprendizaje por refuerzo. Esta estandarización es metodológicamente relevante: sin un entorno, datos y KPIs comunes, las diferencias entre algoritmos pueden confundirse con diferencias de modelado, preprocesamiento o evaluación.

La evolución hacia CityLearn v2 es decisiva porque integra edificios grid-interactive, almacenamiento, PV, vehículos eléctricos, señales de carbono y costos. presentan CityLearn v2 como entorno para gestión energética flexible, resiliente, centrada en ocupantes y consciente de carbono; describen su formalización como entorno Gym para benchmarking de respuesta a la demanda; amplían el uso de CityLearn Gym a evaluación multiobjetivo. Esta tesis toma CityLearn v2 como base validada, pero no afirma que CityLearn v3 exista oficialmente: CityLearn v3 propuesto es una extensión experimental desarrollada para el Dec-POMDP, CTDE y backends MADRL del proyecto.

El paso de un edificio aislado a una comunidad heterogénea introduce problemas de escalabilidad, observabilidad parcial, seguridad, generalización y transferencia. sistematizan estas barreras para MARL en edificios grid-interactive; destaca la necesidad de comparar RL con RBC y MPC; y muestran que los sistemas de gestión energética deben integrar incertidumbre, almacenamiento y múltiples escalas temporales. Estos antecedentes respaldan la elección de 17 agentes y también delimitan el alcance: la tesis evalúa control energético en simulación y no sustituye una validación de red física o despliegue real.

1.6.7 2.2.5 CityLearn v3 propuesto y distincion UC3M (7 ejes vs 3 ejes)

CityLearn v3 propuesto es la extension experimental de esta tesis sobre CityLearn v2 (Nweye et al., 2024): conserva fisica y KPIs evaluate_v2, y agrega el contrato Dec-POMDP/CTDE, objetivos OE.1–OE.3, recompensa multiobjetivo y adaptadores a backends MADRL en external/. Modulos: v3/environment.py, v3/objectives.py, v3/config.py, v3/backends.py y CityLearnV3MADRLRewardFunction (perfil unified_comparable_v4).

El sustento formal agent-skills/madrl-sustento-doc-capa v3/madrl-modeladomatematico.md y el paquete uc3m/ axiomatizan un operador holistico de siete ejes

(CO2, costo, flexibilidad, confort, degradacion BESS, resiliencia, ACS) con BACT y HPHI. Las 12 corridas canónicas operacionalizan solo OE.1/OE.2/OE.3. Mapeo: UC3M-1↔OE.2, UC3M-2↔OE.3, UC3M-3↔OE.1; ejes 4–7 son sustento, no evidencia Cap. 5. Parametros: N=17, gamma=0,9999, T=8 760, r_team=0,70.

1.6.8 2.2.6 Formalizacion matematica del Meta-Dec-POMDP UC3M

Fuente: madrl-modeladomatematico.md (adaptado a Cap. 2). El Meta-Dec-POMDP UC3M es la tupla 11-aria M_UC3M = <I, S, A, O, T, R, Z, gamma, H, b0, Lambda>, que extiende Oliehoek y Amato (2016) con vector R=(r^(1),...,r^(7)) y simplex Lambda. En Iquitos N=17, gamma=0,9999, H=8 760. La ejecucion restringe Lambda al subsimplex OE.1/OE.2/OE.3.

Definicion 2.1 (BACT): B en R^{N x Ka x Kc x Kb} codifica activos, clima y constructivo (uc3m/env/bact.py). Observaciones parciales: carga, termica, PV, SoC, EV, tarifas, CI y meteorologia; acciones en [-1,1]^{d_ai} heterogeneas. Prop. 2.1: S compacto. Lema 2.2: R escalarizada Borel-medible y acotada. Nucleo T factorizado exogeno (clima/red) x endogeno por edificio.

1.6.9 2.2.7 Operador de recompensa holistico, Pareto y convergencia

Definicion 2.2: R_i = -sum_k lambda_k * r_i~(k) con normalizacion a base RBC. Teorema 2.3: V_pi existe y |V|<=M/(1-gamma). Prop. 2.4: Lipschitz con L=sum lambda_k L_k. Teorema 2.5: existencia de frontera de Pareto si Pi compacto (Roijers et al., 2013). Definicion 2.4 (HPHI): hipervolumen 7-D normalizado (uc3m/reward/hphi.py); esta tesis no ejecuta HPHI 7-D en Cap. 5. Prop. 2.6: CTDE mitiga no-estacionariedad (Lowe et al., 2017); HAPPO/HATRPO bajo Zhong et al. (2023) y Kuba et al. (2022).

1.6.10 2.2.8 Modelado fisico-matematico de los ejes operacionales

Ejes ejecutados: UC3M-1/OE.2 (CO2 marginal + desplazamiento EV), UC3M-2/OE.3 (costo TOU Electro Oriente + potencia), UC3M-3/OE.1 (ramping y picos vs umbral DSO; KPIs peak/ramping/load_factor). Ejes de sustento (no Cap. 5): 4 confort adaptativo De Dear-Brager, 5 degradacion Arrhenius-SEI/Peukert, 6 resiliencia isla (CCI/LOLP), 7 ACS con perdidas UA. Balance Kirchhoff: P_net = P_load + P_HP + P_EH + P_BESS + P_EV - P_PV - P_wind.

1.6.11 2.2.9 Arquitectura MARLlib-CTDE y universalidad algoritmica (sustento)

MARLlib (Hu et al., 2023) y el plugin algoritmico UC3M P=<Theta, Phi, L_actor, L_critic, U_step, B> sustentan universalidad via AlgorithmFactory (uc3m/). CTDE: pi_i(a_i|o_i) descentralizado y Q_centr(s,a) centralizado. HAPPO, MASAC, MATD3 y MAAC son instancias; el launcher de 12 corridas usa wrappers CityLearn/scripts/ + external/, no UC3MEnv/MARLlib como canal de entrenamiento.

2.2.10 Adecuaciones de los cuatro backends MADRL al dominio electrico (OE.1 flexibilidad, OE.2 CO2, OE.3 costos)

Premisa. Los backends oficiales pinados en external/ (HARL/HAPPO, MARL/src-MASAC, off-policy/MATD3 y MAAC) fueron disenados, validados y entrenados de forma predominante en dominios de referencia multiagente (p. ej. SMAC/StarCraft, MPE u otros benchmarks MARL). En su forma original no estan preparados, ni entrenados, ni aplicados out-of-the-box al control de una comunidad electrica con DER, EV/V2G y senales horarias de precio e intensidad de carbono. Por tanto, no resuelven por si solos el problema de esta tesis: flexibilidad energetica (OE.1), emisiones de CO2 (OE.2) y costos economico-energeticos (OE.3) sobre el SEAI Iquitos.

La contribucion teorica no consiste en reinventar HAPPO, MASAC, MATD3 o MAAC, sino en adecuarlos —via la capa CityLearn v3 propuesto, el adaptador comun citylearn_v3_training_common.py y wrappers tipados— a un Dec-POMDP cooperativo de 17 edificios heterogeneos, recompensa multiobjetivo unificada (CityLearnV3MADRLRewardFunction, perfil unified_comparable_v4) y evaluacion con KPIs oficiales evaluate_v2. El Cap. 4 documenta la implementacion; esta seccion fija el sustento teorico de cada adecuacion.

Capa comun de adecuacion (los cuatro MADRL): (i) contrato Dec-POMDP/CTDE con estado global s en R^{1856}; (ii) padding / policy mapping ante heterogeneidad d_oi en [54, 327] y d_ai en [5, 44]; (iii) recompensa multiobjetivo con escenarios E1/E2/E3 y r_team = 0,70; (iv) dataset citylearn_iquitos_2023_2025 (BESS, PV, 185 cargadores EV, TOU Electro Oriente, CI dinamico); (v) orquestacion train_citylearn_v3_{happo,masac,matd3,maac}.py bajo matriz 4x3 comparable.

HAPPO — CityLearnHARLEnv + external/HARL. El HAPPO original (Kuba et al., 2021; Zhong et al., 2023) aporta actualizacion secuencial con trust region para agentes heterogeneos, pero HARL espera un ShareVecEnv de juegos multiagente, no setpoints

BESS/EV. Adecuacion: wrapper CityLearnHARLEnv con observacion local continua y share_observation_space = estado CTDE; acciones continuas en [-1,1]^{d_ai} (BESS + EV + lavadora); recompensa mixta del perfil v4; script train_citylearn_v3_happo.py. Teoricamente es el candidato on-policy a la heterogeneidad tipologica del SEAI.

MASAC — CityLearnSMACDiscreteEnv + external/MARL/src. El backend MASAC/mSAC asume API tipo SMAC (get_obs, get_state, acciones discretas). CityLearn expone control continuo multidimensional. Adecuacion: adaptador SMAC-like con get_state() = s CTDE; discretizacion action_bins=3 y discrete_action_mode=axis (base un-eje + no-op; no producto cartesiano 3^{d_ai}, inviable con d_ai hasta 44); mezcla cooperativa tipo QMIX sobre la recompensa energetica de equipo; script train_citylearn_v3_masac.py. Aporta exploracion entropica off-policy sobre un espacio de accion energetico tractable.

MATD3 — CityLearnOffPolicyVecEnv + external/off-policy. El repositorio autor (external/MATD3implementation, TensorFlow 1.x / Python 3.6) no es el stack de entrenamiento: se adecua via backend PyTorch marlbenchmark/off-policy (clases MATD3 / R_MATD3). Adecuacion: wrapper vectorizado de un hilo; acciones continuas con doble critico, policy delay y target noise sobre actuadores BESS/EV; policy_mapping_fn y padding para 17 politicas heterogeneas; script train_citylearn_v3_matd3.py. Es el candidato deterministico off-policy al control continuo distrital.

MAAC — CityLearnMAACVecEnv + external/MAAC. MAAC (Iqbal y Sha, 2019) introduce atencion multi-cabeza en el critico para dominios donde la relevancia entre agentes cambia; no trae de fabrica recompensa de pico/rampa/CO2/TOU. Adecuacion: wrapper que expone observaciones por agente al mecanismo de atencion; misma discretizacion eje-wise que MASAC (bins=3); atencion sobre los 17 edificios heterogeneos bajo recompensa v4; script train_citylearn_v3_maac.py. Operacionaliza coordinacion selectiva (p. ej. hospital vs mall vs campus) sin comunicacion en ejecucion.

Tabla 2.B — Adecuacion de los cuatro MADRL originales al problema electrico (OE.1 / OE.2 / OE.3)

Algoritmo	Dominio tipico del original	Wrapper / backend en el proyecto	Adecuacion clave	Capacidad resultante OE.1–OE.3
HAPPO	MARL heterogeneo generico (HARL)	CityLearnHARLEnv / external/HARL	Share-obs CTDE; accion continua BESS/EV	On-policy cooperativo sobre DER/EV heterogeneos
MASAC	SMAC-like / accion	CityLearnSMACDiscreteEnv / MARL/src	API SMAC; bins=3 axis;	Off-policy entropico sobre

	discreta		Q-mix energetico	control electrico discretizado
MATD3	Paper TF1; activo: off-policy PyTorch	CityLearnOffPolicyVecEnv / off-policy	Backend PyTorch 3.9; accion continua	Off-policy deterministico continuo BESS/EV
MAAC	Atencion multiagente generica	CityLearnMAACVecEnv / external/MAAC	Atencion 17 agentes + bins=3	Coordinacion atencional bajo flex/CO2/costo

Nota. Los backends originales no fueron preparados ni entrenados ni aplicados out-of-the-box a flexibilidad, CO2 y costos energeticos. La adecuacion se sustenta en wrappers y adaptadores del proyecto (citylearn_v3_training_common.py; Cap. 4). Fuente: elaboracion propia a partir de external/HARL, external/MARL/src, external/off-policy, external/MAAC y la capa CityLearn v3 propuesto.

En sintesis: los cuatro MADRL originales no resuelven por si solos el problema electrico multiobjetivo; las adecuaciones del proyecto (wrappers + Dec-POMDP/CTDE + recompensa unified_comparable_v4 + dataset Iquitos + evaluate_v2) son la condicion de posibilidad teorica y operativa del cuasiexperimento 4x3 (Caps. 3–5).

1.6.12 Metodología de selección de los cuatro algoritmos MADRL

La selección de HAPPO, MATD3, MASAC y MAAC se realizó a priori mediante criterios de elegibilidad y complementariedad algorítmica definidos antes de observar los resultados experimentales del proyecto. No se utilizaron directamente las recompensas publicadas para elegirlos, porque los artículos emplean entornos, cantidades de agentes, funciones de recompensa, presupuestos de interacción y algoritmos comparadores diferentes. Por tanto, esos resultados sustentan las propiedades de cada método, pero no demuestran cuál es superior para la gestión coordinada de flexibilidad, emisiones y costos en Iquitos.

Los criterios obligatorios fueron: pertenecer al aprendizaje profundo por refuerzo multiagente; ser model-free; generar experiencia mediante interacción online con el simulador; admitir entrenamiento centralizado y ejecución descentralizada (CTDE), o una implementación equivalente; ser compatible o adaptable a acciones continúas acotadas; permitir coordinación cooperativa; y aportar una estrategia diferenciada para los 17 edificios. El uso de replay buffer de MATD3, MASAC y MAAC no los convierte en métodos offline: las transiciones se generan durante la interacción online y luego se reutilizan en actualizaciones off-policy.

La complementariedad determinó la selección final. HAPPO fue incorporado como representante on-policy por su actualización secuencial y su soporte de políticas heterogéneas . MATD3 representa el control continuo determinista y la reducción de

sobreestimación mediante críticos centralizados dobles . MASAC representa políticas estocásticas de máxima entropía para ampliar la exploración frente a incertidumbre de demanda, generación fotovoltaica y carbono . MAAC representa la coordinación selectiva y escalable mediante un crítico con atención . La Tabla 2 resume esta diversidad y su relación con la tesis

Tabla 3

Síntesis comparativa de los cuatro algoritmos MADRL seleccionados

MADRL	Perfil de elegibilidad	Mecanismo diferenciador	Relación con la tesis	Condición de implementación
HAPPO	Model-free; online; on-policy; política estocástica; CTDE; acciones continuas o discretas.	Actualización secuencial y políticas heterogéneas; prioriza estabilidad.	Representa diferencias entre 17 edificios con cargas, PV, BESS y EV distintos.	Mayor costo muestral; igualar pasos de entorno, cómputo y presupuesto de ajuste.
MATD3	Model-free; online; off-policy; política determinista; CTDE; acción continua nativa.	Dos críticos centralizados reducen la sobreestimación y favorecen control preciso.	Adecuado para consignas acotadas de BESS, climatización, EV y cargas flexibles.	Controlar exploración determinista y documentar la reimplementación reproducible.
MASAC	Model-free; online; off-policy; política estocástica gaussiana; CTDE; acción continua.	Máxima entropía para exploración amplia y mayor robustez ante perturbaciones.	Contrasta incertidumbre horaria de clima, PV, demanda, carbono y precios.	Auditar código, hiperparámetros, semillas e intervalos por evidencia original limitada.
MAAC	Model-free; online; off-policy; política estocástica; CTDE; actor continuo adaptable.	El crítico con atención filtra interacciones relevantes y mejora la escalabilidad.	Permite coordinación selectiva entre 17 edificios con perfiles heterogéneos.	Adaptar y validar el actor continuo y su equivalencia en CityLearn/Iquitos.

Nota. Todos los candidatos son model-free, se entrenan online y permiten coordinación cooperativa bajo CTDE. La tabla no establece un ganador; resume la complementariedad definida a priori. Fuente: elaboración propia a partir de , , , y la matriz Backends_MADRL del proyecto.

Tabla 4

comparación de MADRL y la razón por la selección

MADRL	Clasificación	Entorno y datos originales	Comparadores	Evidencia publicada	Razón para seleccionarlo
HAPPO	Model-free, online, on-policy, CTDE, política estocástica	SMAC y 12 configuraciones Multi-Agent MuJoCo. No usa dataset fijo; genera trayectorias online.	HATRPO, MAPPO, IPPO y MADDPG	Los autores reportan que HAPPO/HATRPO superan a IPPO, MAPPO y MADDPG en las 12 configuraciones MAMuJoCo. En SMAC, HAPPO, HATRPO y MAPPO llegan a 100%, por lo que ese resultado no discrimina un ganador.	Representa estabilidad on-policy, actualización secuencial y políticas heterogéneas para edificios diferentes. Artículo HAPPO
MATD3	Model-free, online, off-policy, CTDE, determinista	MPE y Ant-v2 dividido entre agentes. Experiencia online almacenada en replay buffer.	MADDPG; IL-TD3 y SA-TD3 en Ant	Supera a MADDPG en 3 de 4 tareas adversariales, mejora Cooperative Communication y Ant; pierde en Covert Communication.	Representa control continuo determinista, eficiencia muestral y reducción de sobreestimación mediante dos críticos. Artículo MATD3

MADRL	Clasificación	Entorno y datos originales	Comparadores	Evidencia publicada	Razón para seleccionarlo
MASAC	Model-free, online, off-policy, CTDE, estocástico	Entorno denominado GCE: navegación cooperativa y predator–prey. No utiliza dataset fijo.	MADDPG	Tabla: objetivo alcanzado 86.4% frente a 74.8%; colisiones 13.6% frente a 25.2%. No reporta semillas ni intervalos.	Representa máxima entropía, exploración y políticas continuas estocásticas ante incertidumbre climática, fotovoltaica y de demanda. Artículo MASAC
MAAC	Model-free, online, off-policy, CTDE, estocástico con atención	MPE: Treasure Collection, Rover-Tower y Cooperative Navigation. Replay buffer de un millón de transiciones.	DDPG, MADDPG, COMA, versiones SAC y MAAC Uniform	Navegación: −1.74±0.05 frente a −2.09±0.12 de MADDPG+SAC. En Treasure Colección reporta mejoras de 17%, 98% y 208% para 4, 8 y 12 agentes.	Representa escalabilidad y selección mediante atención de las interacciones relevantes entre 17 edificios. Requiere adaptar y validar un actor continuo. Artículo y suplemento MAAC

Nota: tabla comparativa de los 4 MADRL con otros MADRL como baseline y su razón de selección para la presente tesis. La tabla no establece un ganador; resume la complementariedad definida a priori. Fuente: elaboración propia a partir de , , , y la matriz Backends_MADRL del proyecto.

No se seleccionaron HATRPO y MAPPO porque pertenecen a la misma familia on-policy cubierta por HAPPO. IPPO fue descartado como tratamiento principal porque no utiliza entrenamiento centralizado para afrontar la no estacionariedad y la coordinación global. MADDPG se conserva como baseline, ya que los artículos de MATD3, MASAC y MAAC lo emplean como referencia y proponen mecanismos para superar sus limitaciones. COMA se orienta principalmente a acciones discretas; IL-TD3 omite coordinación centralizada; y SA-TD3 utiliza un solo agente con observabilidad completa, por lo que no representa la ejecución multiagente descentralizada requerida. Estos algoritmos pueden utilizarse como baselines o ablaciones, pero no como candidatos finales.

La selección bibliográfica no determina un ganador. Los cuatro algoritmos deben compararse en el mismo CityLearn v2 con la extensión experimental para Iquitos, empleando idénticos datos, observaciones, acciones, restricciones, función de recompensa, pasos de interacción y presupuesto de optimización. El protocolo temporal propuesto entrena con 2023, valida y ajusta con 2024, y evalúa en 2025 con la política bloqueada. Como 2024 es bisiesto, las particiones contienen 8 760, 8 784 y 8 760 horas, respectivamente, para un total de 26 304 horas.

En la fase confirmatoria, la unidad experimental debe ser la semilla independiente y no cada episodio. Se recomiendan al menos 12 semillas para cada combinación de cuatro algoritmos y tres escenarios, es decir, un mínimo de 144 corridas principales. La evaluación

debe integrar la prueba de Friedman pareada, Kendall W, comparaciones post-hoc con corrección de Holm cuando proceda, tamaños de efecto e intervalos de confianza. La selección global debe utilizar TOPSIS con igual peso para flexibilidad, carbono y costos, complementado con frente de Pareto, sensibilidad de pesos y cumplimiento de restricciones. Si no existe separación estadística y práctica, corresponde declarar co-líderes o ausencia de un ganador único. Hasta ejecutar este protocolo, los resultados de una sola semilla conservan alcance descriptivo y no justifican superioridad universal.

1.7. Variables de la investigación

1.7.1 Variable independiente

La variable independiente es la capa MADRL cooperativa implementada sobre CityLearn v2 (CityLearn v3 propuesto), manipulada en tres dimensiones: D-VI.1 algoritmo, D-VI.2 escenario experimental y D-VI.3 control metodológico. y fundamentan la formulación Dec-POMDP cooperativa que constituye el marco común de la VI; (2017) justifican el paradigma CTDE bajo el cual se entrenan las políticas.

D-VI.1 — Algoritmo MADRL. Comprende cuatro niveles del factor experimental: HAPPO, método on-policy con actualización secuencial y región de confianza para agentes heterogéneos; MASAC, enfoque off-policy de máxima entropía; MATD3, actor–critic off-policy con críticos dobles y actualización retardada; y MAAC, actor–critic con atención selectiva en el crítico centralizado , , y . Los cuatro algoritmos se comparan bajo la misma comunidad, el mismo perfil unificado de recompensa y el mismo protocolo de evidencia.

D-VI.2 — Escenario E1/E2/E3. Los escenarios condicionan la política hacia un objetivo dominante mediante vectores de peso distintos en la función de recompensa multiobjetivo. E1 prioriza flexibilidad [0,70; 0,15; 0,15] y se sustenta en KPIs de pico y rampa (Vázquez-Canteli et al., 2020; Yao et al., 2023); E2 prioriza emisiones de CO_2 [0,15; 0,70; 0,15] y se fundamenta en control consciente de intensidad de carbono (Liu et al., 2022; Tranberg et al., 2020); E3 prioriza costos [0,25; 0,15; 0,60] y se ancla en respuesta a precios y cargos por demanda (Dang et al., 2023; OSINERGMIN, 2024).

D-VI.3 — Control experimental. Para aislar el efecto de D-VI.1 y D-VI.2, la tesis mantiene constantes el dataset citylearn_iquitos_2023_2025, la función de recompensa unified_comparable_v4, la semilla de reproducibilidad y el protocolo CTDE. Esta dimensión de control asegura que las diferencias observadas en D-VD.1, D-VD.2 y D-VD.3 se atribuyan al algoritmo y al escenario, no a variaciones del entorno o del protocolo.

1.7.2 Variable dependiente

La variable dependiente es el desempeño coordinado de la comunidad energética medido en tres ejes: D-VD.1 flexibilidad energética, D-VD.2 emisiones de CO_2 y D-VD.3 costos energéticos. Cada eje se descompone en tres dimensiones operativas, alineadas con los KPIs oficiales de CityLearn v2 (Vázquez-Canteli et al., 2020; Nweye et al., 2024). La lectura correcta del Capítulo 5 combina las tres dimensiones de cada eje, no un KPI aislado.

D-VD.1 — Flexibilidad energética. Dimensión 1 (pico): capacidad de reducir la importación máxima distrital, medida con peak_average. Lund et al. (2017) ubican la reducción de pico dentro de los sistemas energéticos inteligentes, mientras Vázquez-Canteli et al. (2020) estandarizan peak_average como KPI comparable en CityLearn. Dimensión 2 (rampa): suavizado de variaciones horarias de importación, medido con ramping_average. Nweye et al. (2024) incorporan ramping como KPI distrital en CityLearn v2, y Yao et al. (2023) reportan mejoras de coordinación MADRL en perfiles de demanda. Dimensión 3 (factor de carga): equilibrio entre pico y demanda media, medido con one_minus_load_factor_average y el indicador compuesto flex_composite. Vázquez-Canteli y Nagy (2019b) vinculan el factor de carga con respuesta a la demanda, y Xie et al. (2023) demuestran que mecanismos de atención multiagente mejoran la suavidad del perfil agregado.

D-VD.2 — Emisiones de CO_2. Dimensión 1 (emisiones totales): carbon_emissions_total como indicador agregado anual del distrito. Liu et al. (2022) muestran reducciones de emisiones con MADRL en sistemas con energía renovable, y MINAM (2019) proporciona el factor de emisión base para contextualizar redes aisladas peruanas. Dimensión 2 (delta CO_2): carbon_emissions_delta como reducción frente a baseline CityLearn v2. Tranberg et al. (2020) fundamentan la contabilidad temporal de carbono, y Sarkar et al. (2024) aplican desplazamiento temporal de carga hacia periodos de baja intensidad de carbono. Dimensión 3 (consumo ponderado por CI): importación eléctrica ponderada por CI(t). Cao et al. (2023) estudian pronóstico de intensidad de carbono para gestión de edificios, y Ye et al. (2025) avanzan hacia MARL seguro para operación baja en carbono.

D-VD.3 — Costos energéticos. Dimensión 1 (costo total): electricity_cost_total como indicador agregado anual. Fang et al. (2021) proponen gestión distribuida de energía en microredes mediante MADRL, y Gao et al. (2023) validan MASAC para programación colaborativa con respuesta a precios. Dimensión 2 (delta costo): electricity_cost_delta como reducción frente a baseline. Dang et al. (2023) muestran que BESS puede reducir cargos de demanda bajo precios dinámicos, y Xiong et al. (2024) confirman que DRL puede responder

a tarifas TOU y almacenamiento. Dimensión 3 (pico facturable): reducción de demanda máxima en ventana de facturacion y desviacion respecto a la señal de precio (price_signal_deviation). OSINERGMIN (2024) justifica el uso de máxima demanda y tarifa en el contexto regulatorio peruano, y Shojaeighadikolaei et al. (2022) plantean gestión energética distribuida y respuesta a la demanda en smart grids.

1.8. Antecedentes

1.8.1 Antecedentes internacionales

Los antecedentes internacionales directamente vinculados con CityLearn, HAPPO, MAAC, flexibilidad, emisiones y costos. La revisión se complementa con tesis es recientes sobre control energético de edificios, gestión de microrredes y regulación en sistemas eléctricos. Silvestri (2024) compara DRL, RBC y MPC; Nweye (2024) analiza barreras de despliegue de RL en comunidades grid-interactive; Wu (2024) y Zhang (2024) integran almacenamiento, incertidumbre y gestión multiobjetivo; Chen (2024) y Wang (2024) muestran que la aplicación de DRL a sistemas eléctricos exige robustez, restricciones físicas y trazabilidad. Estas fuentes fortalecen la justificación y los límites sin modificar el objeto de estudio.

En conjunto, el estado del arte converge en cuatro exigencias: comparación bajo condiciones equivalentes, representación explícita de heterogeneidad, evaluación con múltiples KPIs y conservación de artefactos reproducibles. La tesis responde mediante un diseño factorial 4×3, una comunidad fija de 17 edificios, una recompensa unificada por algoritmo y resultados auditables por episodio, edificio y equipo.

1.8.1.1 Nweye et al. (2024)

Tabla 5

Ficha del antecedente internacional: Nweye et al. (2024)

Campo	Contenido
Título de la tesis/estudio	CityLearn v2: Energy-flexible, resilient, occupant-centric, and carbon-aware management of grid-interactive communities
Objetivo general	Desarrollar CityLearn v2 integrando EV/V2G, intensidad de carbono dinámica, BESS, PV y KPIs de flexibilidad, emisiones y costos en comunidades grid-interactive.
Tipo de metodología	Desarrollo de entorno de simulación; evaluación multiobjetivo con SAC, RBC y MPC.
Diseño de investigación	Aplicada; no experimental; simulación comparativa en CityLearn v2.
Resultados cuantitativos	KPIs distritales y por edificio (peak_average, ramping, carbon_emissions, electricity_cost); magnitudes específicas dependen de configuración experimental.
Conclusión general	CityLearn v2 habilita investigación reproducible en comunidades inteligentes multidimensionales con flexibilidad, carbono y costo.
Aporte para esta tesis	Entorno base oficial y KPIs D-VD.1-D-VD.3; justifica extensión CityLearn v3 propuesto con Dec-POMDP/CTDE y cuatro backends MADRL.

Nota. La tabla representa la información sintetizada en la tabla correspondiente. Fuente: Elaboración propia a partir de los datos, fuentes y artefactos citados en el documento.

Análisis crítico. Este antecedente proporciona el entorno de referencia y los KPIs comunitarios que sustentan la variable dependiente. Su principal aporte es la estandarización; su limitación es que no compara conjuntamente HAPPO, MASAC, MATD3 y MAAC sobre un datase peruano. La propuesta conserva CityLearn v2 como núcleo y agrega una extensión experimental trazable.

1.8.1.2 Nweye et al. (2023b)

Tabla 6

Ficha del antecedente internacional: Nweye et al. (2023b)

Campo	Contenido
Título de la tesis/estudio	Heterogeneous Multi-Agent Reinforcement Learning for Grid-Interactive Communities
Objetivo general	Evaluar HARL/HAPPO para gestión energética heterogénea en comunidades grid-interactive modeladas en CityLearn.
Tipo de metodología	MARL heterogéneo on-policy (HAPPO/HARL) bajo CTDE en CityLearn.
Diseño de investigación	Aplicada; no experimental; simulación CityLearn con agentes heterogéneos.
Resultados cuantitativos	HAPPO heterogéneo comparable o superior a MAPPO en KPIs CityLearn (peak, ramping, emisiones, costo); magnitudes exactas [PV] por configuración.
Conclusión general	HAPPO es viable para coordinación heterogénea en comunidades inteligentes grid-interactive.
Aporte para esta tesis	Antecedente directo del backend HAPPO a escala multiedificio; precedente más cercano antes de comparar HAPPO, MASAC, MATD3 y MAAC bajo recompensa unificada.

Nota. La tabla representa la información sintetizada en la tabla correspondiente. Fuente: Elaboración propia a partir de los datos, fuentes y artefactos citados en el documento.

Análisis crítico. El trabajo sobre aprendizaje heterogéneo demuestra que la diversidad de observaciones y acciones requiere políticas no homogéneas y actualizaciones coordinadas. Constituye el antecedente más próximo para HAPPO; la tesis amplía esa línea al comparar cuatro familias MADRL y tres escenarios de recompensa con los mismos datos.

1.8.1.3 Yao et al. (2023)

Tabla 7

Ficha del antecedente internacional: Yao et al. (2023)

Campo	Contenido
Título de la tesis/estudio	Multi-Agent Reinforcement Learning for Smart Community Energy Management
Objetivo general	Proponer un marco MARL (LSD-MADDPG) para gestión coordinada de energía en comunidades inteligentes con PV, BESS y EV.
Tipo de metodología	MARL cooperativo con estrategia local descentralizada (LSD-MADDPG); CTDE.
Diseño de investigación	Aplicada; no experimental; simulación de comunidad inteligente sintética.
Resultados cuantitativos	Reducción de costo ~18% y de pico ~15% frente a MADDPG no cooperativo.
Conclusión general	La estrategia local MARL mejora coordinación y reduce fallos de escalabilidad en comunidades con DER.
Aporte para esta tesis	Referente de flexibilidad y costos (OE.1/OE.3) para contrastar si MATD3/MAAC superan mejoras reportadas (~15-18%) bajo dataset SEAI Iquitos.

Nota. La tabla representa la información sintetizada en la tabla correspondiente. Fuente: Elaboración propia a partir de los datos, fuentes y artefactos citados en el documento.

Análisis crítico. Este estudio evidencia que la coordinación multiagente puede mejorar la gestión de PV, BESS y EV en comunidades inteligentes. No obstante, concentra la evaluación en una arquitectura específica. La tesis fortalece la comparabilidad al mantener constantes la comunidad, los indicadores y la función de recompensa por algoritmo.

1.8.1.4 Liu et al. (2022)

Tabla 8

Ficha del antecedente internacional: Liu et al. (2022)

Campo	Contenido
Título de la tesis/estudio	Multi-agent deep reinforcement learning for building energy system with renewable energy
Objetivo general	Proponer MADRL (MADDPG) para coordinar BESS y PV en edificios con energía renovable bajo incertidumbre operativa.
Tipo de metodología	MADDPG cooperativo con crítico centralizado; comparación con control basado en reglas.
Diseño de investigación	Aplicada; no experimental; simulación con datos reales de edificios en China.
Resultados cuantitativos	Reducción de costo ~20% y de emisiones CO_2 ~15% frente a reglas.
Conclusión general	MADRL cooperativo supera agentes independientes en eficiencia energética y emisiones.
Aporte para esta tesis	Antecedente de D-VD.2 y D-VD.3 para contrastar deltas de CO_2 y costo de MATD3/MAAC en escenario E2/E3 del SEAI Iquitos.

Nota. La tabla representa la información sintetizada en la tabla correspondiente. Fuente: Elaboración propia a partir de los datos, fuentes y artefactos citados en el documento.

Análisis crítico. El antecedente vincula MADRL con energía renovable, costos y emisiones, por lo que sustenta la naturaleza multiobjetivo de la variable dependiente. Su limitación es la ausencia de una comparación entre familias on-policy, off-policy y basadas en atención dentro de un único protocolo.

1.8.1.5 Iqbal y Sha (2019)

Tabla 9

Ficha del antecedente internacional: Iqbal y Sha (2019)

Campo	Contenido
Título de la tesis/estudio	Actor-Attention-Critic for Multi-Agent Reinforcement Learning
Objetivo general	Introducir mecanismos de atención en el crítico centralizado MARL para coordinación selectiva bajo observabilidad parcial.
Tipo de metodología	Actor-critic multiagente con atención multi-cabeza; evaluación en benchmarks MPE y cooperativos.
Diseño de investigación	Básica-algorítmica; experimental con entornos benchmark MARL.
Resultados cuantitativos	Mejora de recompensa ~15-30% frente a MADDPG/COMA en tareas cooperativas.
Conclusión general	La atención mejora coordinación selectiva entre agentes heterogéneos bajo CTDE.
Aporte para esta tesis	Fundamento del backend MAAC; explica por qué MAAC puede liderar costos (OE.3) al ponderar interacciones entre edificios bajo señales TOU.

Nota. La tabla representa la información sintetizada en la tabla correspondiente. Fuente: Elaboración propia a partir de los datos, fuentes y artefactos citados en el documento.

Análisis crítico. MAAC aporta un crítico con atención capaz de seleccionar interacciones relevantes entre agentes. La tesis adopta este fundamento para comunidades heterogéneas, pero evalúa su utilidad en un dominio energético y no asume que la atención produzca superioridad universal.

1.8.2 Antecedentes nacionales y peruanos

1.8.2.1 Chevarria Moscoso (2024)

Tabla 10

Ficha del antecedente nacional: Chevarria Moscoso (2024)

Campo	Contenido
Título de la tesis/estudio	Análisis de la generación hidroeléctrica en la central hidroeléctrica de Machupicchu aplicando métodos estocasticos y modelo de optimización
Objetivo general	Optimizar la generación hidroeléctrica de Machupicchu mediante métodos estocasticos y un modelo de optimización bajo incertidumbre hidrologica.
Tipo de metodología	Modelado estocástico y optimización matemática aplicada a generación renovable peruana.
Diseño de investigación	Aplicada; tesis UNI; estudio de caso en generación hidroeléctrica.
Resultados cuantitativos	[PV] Mejoras de eficiencia operativa y asignación de generación respecto a escenarios base; magnitudes cuantitativas pendientes de extracción del repositorio UNI.
Conclusión general	Los métodos estocasticos permiten decisiones más robustas en generación renovable bajo variabilidad hidrologica en el contexto peruano.
Aporte para esta tesis	Contextualiza optimización energética nacional y variabilidad de recursos renovables aplicable al balance PV+diésel del SEAI Iquitos.

Nota. La tabla representa la información sintetizada en la tabla correspondiente. Fuente: Elaboración propia a partir de los datos, fuentes y artefactos citados en el documento.

Análisis crítico. Este antecedente nacional aporta un referente peruano de modelación estocástica y optimización en sistemas eléctricos. Su relación es contextual y metodológica, no algorítmica; se utiliza para sustentar el tratamiento de incertidumbre sin presentarlo como antecedente directo de MADRL.

1.8.2.2 Peñalva Sánchez (2024)

Tabla 11

Ficha del antecedente nacional: Peñalva Sánchez (2024)

Campo	Contenido
Titulo de la tesis/estudio	Optimización de un sistema fotovoltaico híbrido y la predicción de la demanda energética y variables climáticas utilizando la inteligencia artificial
Objetivo general	Optimizar un sistema fotovoltaico híbrido e integrar predicción de demanda y variables climáticas mediante inteligencia artificial.
Tipo de metodología	Modelado de sistema PV híbrido; aprendizaje automático para pronóstico de demanda y clima.
Diseño de investigación	Aplicada; tesis UNI; estudio de caso con datos locales.
Resultados cuantitativos	[PV] Reducción de error de predicción de demanda y mejora de desempeño del sistema híbrido; valores numéricos pendientes de verificación en repositorio UNI.
Conclusión general	La IA mejora la operación de sistemas PV híbridos al anticipar demanda y condiciones climáticas en contexto peruano.
Aporte para esta tesis	Sustenta el uso de datos climáticos y demanda reales (PVGIS/NASA POWER) en el dataset citylearn_iquitos_2023_2025 y la relevancia de predicción para control flexible.

Nota. La tabla representa la información sintetizada en la tabla correspondiente. Fuente: Elaboración propia a partir de los datos, fuentes y artefactos citados en el documento.

Análisis crítico. La tesis peruana sobre sistemas fotovoltaicos híbridos e inteligencia artificial respalda el uso de datos climáticos, pronóstico y almacenamiento en contextos nacionales. El presente estudio se diferencia al trabajar a escala comunitaria y con coordinación multiagente.

1.8.2.3 Rosero Bernal (2022)

Tabla 12

Ficha del antecedente nacional: Rosero Bernal (2022)

Campo	Contenido
Título de la tesis/estudio	Modelo de un sistema de administración de energía autónomo operado desde la nube para optimizar la gestión de un grupo de microredes
Objetivo general	Diseñar un sistema autónomo de administración de energía en la nube para optimizar la gestión coordinada de un grupo de microredes.
Tipo de metodología	Arquitectura de gestión energética distribuida en la nube; optimización multi-microred.
Diseño de investigación	Aplicada; tesis; estudio de caso en microredes.
Resultados cuantitativos	[PV] Mejoras de eficiencia energética y coordinación inter-microred respecto a operación descentralizada sin orquestación en la nube.
Conclusión general	La administración autónoma en la nube mejora la coordinación operativa de microredes heterogéneas.
Aporte para esta tesis	Paralelo latinoamericano de coordinación multiagente en redes locales; informa la lectura CTDE del distrito SEAI como comunidad de 17 nodos energéticos.

Nota. La tabla representa la información sintetizada en la tabla correspondiente. Fuente: Elaboración propia a partir de los datos, fuentes y artefactos citados en el documento.

Análisis crítico. El modelo de administración autónoma de microrredes desde la nube aporta una referencia latinoamericana sobre descentralización y gestión coordinada. La tesis traslada esa necesidad a políticas MADRL y a una evaluación reproducible en CityLearn.

1.8.3 Síntesis crítica de antecedentes y brecha científica

La revisión identifica cinco patrones. Primero, CityLearn estandariza el entorno y los KPIs, pero no determina por sí mismo qué algoritmo es superior. Segundo, los estudios de flexibilidad suelen priorizar pico, autoconsumo o almacenamiento, sin integrar necesariamente carbono y costo. Tercero, los trabajos carbon-aware demuestran la utilidad de señales temporales, aunque su efecto depende de la calidad de la intensidad de carbono. Cuarto, la optimización económica depende de tarifas, picos y restricciones de servicio EV. Quinto, HAPPO, MASAC, MATD3 y MAAC responden a fundamentos distintos, por lo que la comparación exige condiciones experimentales equivalentes y lectura por objetivo (Nweye et al., 2024; Silvestri, 2024; Zhong et al., 2024; Wu, 2024).

La brecha que sostiene la tesis es metodológica y experimental: se requiere una evaluación comparativa, reproducible y multiobjetivo de HAPPO, MASAC, MATD3 y MAAC en una comunidad realista de 17 edificios, bajo Dec-POMDP, CTDE, datase común, recompensa unificada por algoritmo y resultados trazables por distrito, edificio, escenario, KPI y checkpoint. La contribución se limita a esta comparación en simulación; no se presenta como validación de red física, despliegue en campo ni demostración de superioridad universal.

1.9. Definición de términos y posición teórica

1.9.1 Definición de términos y delimitaciones conceptuales

MADRL: aprendizaje por refuerzo profundo multiagente, donde múltiples agentes aprenden políticas mediante redes neuronales y señales de recompensa. En esta tesis se usa MADRL para referirse a HAPPO, MASAC, MATD3 y MAAC bajo formulación cooperativa. No se sustituye por MARL salvo cuando aparece como parte del nombre propio de una referencia, repositorio o biblioteca.

CityLearn v2: entorno base oficial de simulación para comunidades energéticas grid-interactive, con KPIs de energía, carbono y costo. CityLearn v3 propuesto: extensión experimental de esta tesis, implementada localmente para Dec-POMDP, CTDE, recompensa multiobjetivo, wrappers MADRL y artefactos reproducibles. Esta distinción es obligatoria para no atribuir al paquete oficial una funcionalidad propia del proyecto.

Tratamiento experimental: combinación de un nivel D-VI.1 algoritmo y un nivel D-VI.2 escenario. El diseño factorial completo tiene 12 tratamientos. Distrito: agregación de los 17 edificios para medir efecto comunitario. Edificio: agente individual con observación local y acciones propias. Equipo controlado: variable de acción sobre BESS, EV o carga desplazable. Carga no controlada: demanda base observada o de referencia que no es actuada directamente por el agente.

KPI: indicador cuantitativo usado para medir la variable dependiente. Los KPIs no son adornos del resultado; son la operacionalización de D-VD.1, D-VD.2 y D-VD.3. Por ello, toda gráfica o tabla del Capítulo 5 debe indicar si corresponde a flexibilidad, carbono, costo, distrito, edificio, escenario o reproducibilidad de modelo.

1.9.2 Posición teórica de la tesis

La posición teórica adoptada es que una comunidad inteligente con recursos DER heterogéneos debe modelarse como un sistema multiagente parcialmente observable y no

como un problema de control centralizado único. El criterio de calidad no es solo minimizar un KPI, sino producir desempeño coordinado medible en tres dimensiones por eje. Esta posición combina la teoría Dec-POMDP de Oliehoek y Amato (2016), el paradigma CTDE de Lowe et al. (2017), la estandarización de CityLearn de Vázquez-Canteli et al. (2020) y Nweye et al. (2024), y la literatura de gestión energética multiobjetivo.

Desde esta posición, el Capítulo 5 debe interpretar los resultados con tres reglas. Primero, no hay superioridad universal sin declarar escenario, KPI y escala. Segundo, un resultado distrital no reemplaza la evidencia por edificio. Tercero, un algoritmo con artefactos incompletos no debe usarse para comparaciones donde falten archivos. Estas reglas derivan directamente del marco teórico y evitan conclusiones no sustentadas.

1.10. Síntesis crítica y triangulación del marco teórico

El marco teórico contiene estado del arte, bases teóricas, trabajos relacionados, definición de variables y posición teórica. La triangulación central se organiza en tres capas. Primero, CityLearn aporta el marco de evaluación reproducible para comunidades de edificios y demanda flexible; CityLearn v2 agrega objetivos de flexibilidad, resiliencia, ocupación y carbono; EVLearn extiende el mismo ecosistema a vehículos eléctricos y estrategias V1G/V2G (Vázquez-Canteli et al., 2020; Nweye et al., 2024; Fonseca et al., 2024). Segundo, la teoría MADRL fundamenta la ejecución descentralizada con entrenamiento centralizado: MAAC introduce críticos con atención para seleccionar interacciones relevantes entre agentes, HAPPO extiende optimización de región de confianza a agentes heterogéneos, SAC/MASAC aporta exploración por máxima entropía y TD3/MATD3 controla sesgo de sobreestimación con críticos dobles y actualizaciones retrasadas (Iqbal & Sha, 2019; Kuba et al., 2021; Haarnoja et al., 2018; Fujimoto et al., 2018). Tercero, la literatura de evaluación de RL advierte que una comparación algorítmica debe acompañar los promedios con dispersión, pruebas estadísticas y trazabilidad experimental (Henderson et al., 2018; Agarwal et al., 2021).

En consecuencia, cada decisión de la propuesta queda asociada a un fundamento verificable. El Dec-POMDP representa observabilidad parcial y cooperación; CTDE justifica el uso de información global durante el entrenamiento; CityLearn proporciona simulación y KPIs comparables; y las cuatro familias MADRL permiten contrastar estabilidad on-policy, exploración de máxima entropía, reducción de sobreestimación y atención entre agentes. Esta articulación permite interpretar los resultados por objetivo, escala y nivel de evidencia, sin convertir una diferencia descriptiva en una conclusión general.

Tabla 13

Teoría por eje de la tesis

Eje	Fuentes trianguladas	Uso en la tesis
Entorno y KPIs	CityLearn v1/v2; CityLearn Challenge; EVLearn	Justifica benchmark, KPIs evaluate_v2 y control de EV/BESS.
MADRL	MAAC; HAPPO; SAC; TD3	Justifica comparación de familias actor-critic multiagente.
Evaluación rigurosa	Henderson et al.; Agarwal et al.	Justifica pruebas no paramétricas y cautela ante una sola corrida.
Variables	Flexibilidad, CO_2 y costo en comunidades grid-interactive	Sostiene D-VD.1, D-VD.2 y D-VD.3.

Nota. La tabla representa la organización conceptual del marco teórico y de las variables de investigación. Fuente: Elaboración propia a partir de la literatura citada en el Capítulo 2.

CAPÍTULO VII. Capítulo 3. Metodología

El presente estudio adopta una metodología cuantitativa, aplicada y explicativa-comparativa, sustentada en simulación computacional controlada. Esta decisión responde a la naturaleza del problema de investigación: evaluar en qué medida distintos algoritmos MADRL modifican indicadores cuantificables de flexibilidad energética, emisiones de CO_2 y costos energéticos en una comunidad eléctrica modelada bajo CityLearn. De acuerdo con Hernandez-Sampieri y Mendoza (2018), la ruta cuantitativa se caracteriza por la medición de variables, el uso de procedimientos sistemáticos y la contrastación de hipótesis; Creswell y Creswell (2023) enfatizan que los diseños cuantitativos permiten examinar relaciones entre variables mediante mediciones numéricas y análisis estadístico. En esta tesis, la variable independiente se manipula computacionalmente mediante el algoritmo MADRL y el escenario de recompensa, mientras que la variable dependiente se observa mediante KPIs oficiales y resultados episódicos.

1.11. Enfoque, tipo, nivel y diseño de investigación

La investigación es aplicada porque desarrolla y evalúa una solución computacional para gestión energética multiagente en una comunidad del SEAI Iquitos. Es cuantitativa porque los resultados se expresan en métricas numéricas: recompensa, costo, emisiones, pico, rampa, factor de carga, energía de almacenamiento, éxito EV y KPIs evaluate_v2. Es explicativa-comparativa porque no se limita a describir los algoritmos; contrasta si la variación de la variable independiente produce efectos diferenciados sobre las dimensiones D-VD.1, D-VD.2 y D-VD.3. Esta clasificación es coherente con los criterios de alcance y diseño propuestos por Hernandez-Sampieri y Mendoza (2018), con la lógica de diseño cuantitativo de Creswell y Creswell (2023), y con la tradición de diseño experimental orientado a factores, tratamientos y respuestas descrita por Montgomery (2019).

El diseño no se considera no experimental, porque existe manipulación controlada de la VI (algoritmo MADRL y escenario de recompensa E1/E2/E3) bajo protocolo fijo. Tampoco es un experimento puro de campo: no hay aleatorización de unidades naturales ni sujetos humanos. Por ello se adopta un diseño cuasiexperimental factorial 4×3 basado en simulación (Campbell & Stanley, 1963; Hernández-Sampieri & Mendoza, 2018), coherente con el Resumen (HAPPO, MASAC, MATD3, MAAC; CityLearn; SEAI Iquitos; OE.1 flexibilidad, OE.2 CO2, OE.3 costos).

Tabla 14

Clasificación metodológica de la investigación

Criterio	Decisión metodológica	Sustento
Enfoque	Cuantitativo	Medición numérica de KPIs y contrastación estadística.
Tipo	Aplicada	Desarrollo y evaluación de una propuesta MADRL para gestión energética.
Nivel	Explicativo-comparativo	Evalúa efecto de algoritmos y escenarios sobre dimensiones VD.
Diseño	Experimental-computacional factorial 4 × 3	Manipulación controlada de algoritmo y escenario en simulación.
Temporalidad	Longitudinal por episodios y horizonte anual horario	Cada episodio recorre una trayectoria anual de 8760 pasos.
Inferencia	Intra-corrida con limitación multi-semilla	No se generaliza mas allá de los artefactos auditados.

Nota. La tabla representa el diseño metodológico, las variables, herramientas, datos y procedimiento experimental. Fuente: Elaboración propia a partir del proyecto local, scripts de metodología, datase citylearn_iquitos_2023_2025 y artefactos Drive de entrenamiento.

1.12. Diseño cuasiexperimental factorial 4 × 3

El diseño factorial se compone de dos factores principales. El primer factor es el algoritmo MADRL, con cuatro niveles: HAPPO, MAAC, MASAC y MATD3. El segundo factor es el escenario de recompensa, con tres niveles: E1 orientado a flexibilidad, E2 orientado a emisiones de CO_2 y E3 orientado a costos energéticos. La combinación genera 12 tratamientos algoritmo x escenario. Montgomery (2019) sostiene que los diseños factoriales permiten estudiar efectos de factores bajo condiciones controladas; en esta tesis, el control se materializa en el mismo dataset, el mismo entorno CityLearn, la misma comunidad de 17 edificios, el mismo horizonte de evaluación y la misma familia de KPIs.

La unidad experimental principal es la semilla de entrenamiento dentro de cada tratamiento algoritmo–escenario; en la corrida canónica solo se materializó seed=0. La unidad de observación episódica es el episodio y la unidad espacial es el edificio-agente. Los cuatro algoritmos conservan 50 episodios por escenario, pero estos episodios no se tratan como réplicas independientes. Para responder OE.1 se emplean los tres KPI primarios como bloques pareados; para OE.2 y OE.3, los 17 edificios. La inferencia es, por ello, intra-corrida y exploratoria.

Tabla 15

Matriz factorial 4 × 3 de tratamientos experimentales

Factor	Niveles	Función metodológica
Algoritmo MADRL	HAPPO, MAAC, MASAC, MATD3	Variable independiente principal; compara familias actor-critic multiagente.
Escenario de recompensa	E1, E2, E3	Manipulación de prioridad multiobjetivo: flexibilidad, CO_2 y costo.
Tratamientos	12 combinaciones	Base de comparación para resultados por objetivo específico.

Factor	Niveles	Función metodológica
Horizonte	50 episodios registrados por tratamiento	Evidencia de entrenamiento Drive; se declara cobertura materializada por algoritmo.

Nota. La tabla representa el diseño metodológico, las variables, herramientas, datos y procedimiento experimental. Fuente: Elaboración propia a partir del proyecto local, scripts de metodología, datase citylearn_iquitos_2023_2025 y artefactos Drive de entrenamiento.

1.13. Datos utilizados y fuente empírica

Los datos utilizados corresponden al dataset citylearn_iquitos_2023_2025 y a la corrida canónica Drive madrl_v3_20260627_164047. La tesis no incorpora datos simulados manualmente fuera del pipeline; usa artefactos generados por scripts del proyecto y resultados auditables: results.json, training_summary.json, timeseries.csv, trace.csv, building_kpis.csv, building_behavior_summary.csv, building_observation_action_schema.csv y checkpoint_manifest.json. La fuente empírica combina meteorología, demanda, PV, BESS, EV, precios, intensidad de carbono y KPIs CityLearn. Esta trazabilidad responde a la exigencia metodológica de reproducibilidad y control de medición que Hernandez-Sampieri y Mendoza (2018) y Creswell y Creswell (2023) asocian con la ruta cuantitativa.

El dataset representa 17 edificios de una comunidad energética de Iquitos, con equipos controlables heterogéneos y variables de observación locales. La representación por edificio permite modelar el problema como Dec-POMDP y evaluar la ejecución descentralizada de políticas MADRL. Las dimensiones locales medidas (d_oi en [54, 327], d_ai = 2 + n_i^ch en [5, 44], estado CTDE d_s = 1 856) constan en Cap. 2 Tabla 2.A y se operacionalizan en Cap. 4.

Tabla 16

Fuentes de datos y artefactos de análisis

Artefacto	Contenido	Uso metodológico
timeseries.csv	Serie temporal distrital por episodio	Energía, costo, CO_2, recompensa y señales horarias.
trace.csv	Trazas por agente	Acciones, SOC, EV, PV, importación/exportación y recompensa individual.
building_kpis.csv / building_behavior_summary.csv	KPIs por edificio	Análisis espacial por agente y equipamiento.
checkpoint_manifest.json	Registro de checkpoints	Trazabilidad de entrenamiento y cobertura por tratamiento.
district_episode_kpis.csv	KPIs episódicos materializados	Base de estadística descriptiva e inferencial.

Nota. La tabla representa el diseño metodológico, las variables, herramientas, datos y procedimiento experimental. Fuente: Elaboración propia a partir del proyecto local, scripts de metodología, datase citylearn_iquitos_2023_2025 y artefactos Drive de entrenamiento.

1.14. Variables, dimensiones e indicadores

La variable independiente (VI) es el algoritmo MADRL implementado bajo un esquema CTDE y condicionado por escenario de recompensa. Sus dimensiones operacionales son: D-VI.1 tipo de algoritmo, D-VI.2 ponderación multiobjetivo del escenario y D-VI.3 controles experimentales. La variable dependiente (VD) es el desempeño energético coordinado de la comunidad, desagregado en tres dimensiones: D-VD.1 flexibilidad energética, D-VD.2 emisiones de CO_2 y D-VD.3 costos energéticos. Esta definición mantiene correspondencia vertical con PE.1, PE.2, PE.3, OE.1, OE.2 y OE.3.

La operacionalización sigue la lógica de medición cuantitativa: cada dimensión debe tener indicadores observables, fuente de datos y criterio de interpretación. En D-VD.1 se consideran recompensa en E1 y KPIs de flexibilidad como peak, ramping, load factor, autoconsumo PV y uso de almacenamiento. En D-VD.2 se consideran emisiones distritales, carbon_emissions_control, carbon_emissions_delta y consumo ponderado por intensidad de carbono. En D-VD.3 se consideran district_cost, electricity_cost_control, electricity_cost_delta y señales de precio. Esta estructura evita confundir recompensa de entrenamiento con resultado final de evaluación.

Tabla 17

Operacionalización metodológica de variables

Variable	Dimensión	Indicadores principales	Fuente
VI	D-VI.1 Algoritmo	HAPPO, MAAC, MASAC, MATD3	Configuración de tratamiento.
VI	D-VI.2 Escenario	E1, E2, E3; pesos flex/CO2/costo	reward_axis_weights y protocolo experimental.
VD	D-VD.1 Flexibilidad	reward_mean E1, peak, ramping, load factor, BESS/PV	episodes, results, evaluate_v2.
VD	D-VD.2 CO_2	district_emission, carbon_emissions_control/delta	timeseries, results, building KPIs.
VD	D-VD.3 Costos	district_cost, electricity_cost_control/delta	timeseries, results, building KPIs.

Nota. La tabla representa el diseño metodológico, las variables, herramientas, datos y procedimiento experimental. Fuente: Elaboración propia a partir del proyecto local, scripts de metodología, datase citylearn_iquitos_2023_2025 y artefactos Drive de entrenamiento.

1.15. Técnicas, herramientas e instrumentos

Las técnicas utilizadas son simulación computacional, entrenamiento MADRL, evaluación por KPIs, estadística descriptiva, contrastación no paramétrica y visualización analítica. Las herramientas principales son Python, PyTorch, CityLearn v2, la extensión CityLearn v3 propuesta, backends HAPPO/MAAC/MASAC/MATD3, scripts de orquestación del proyecto y artefactos Drive. En términos metodológicos, el instrumento de medición no es un

cuestionario ni una entrevista, sino el entorno computacional validado y sus archivos de salida.

La estadística no paramétrica se selecciona porque los KPI de aprendizaje por refuerzo pueden presentar asimetría, valores atípicos y dependencia respecto de la política. La diferencia global entre los cuatro algoritmos se contrasta mediante Friedman sobre bloques pareados, con Kendall W como tamaño de efecto. Cuando corresponde, se aplican comparaciones post hoc de Wilcoxon pareado y corrección de Holm. El impacto frente al baseline también se evalúa con Wilcoxon-Holm. Esta estrategia es coherente con la recomendación de no asumir supuestos estadísticos no verificados en aprendizaje por refuerzo; sus p-valores se interpretan como evidencia intra-corrida exploratoria por existir una sola semilla.

Tabla 18

Técnicas, herramientas e instrumentos

Componente	Aplicación en la tesis	Resultado esperado
Simulación CityLearn	Recrear comunidad energética multiagente	Series, KPIs y trazas auditables.
MADRL	Entrenar políticas bajo CTDE	Políticas por algoritmo y escenario.
evaluate_v2 / KPIs	Evaluar flexibilidad, CO_2 y costo	Ranking comparable con baseline.
Estadística no paramétrica pareada	Contrastar diferencias entre algoritmos	p-valores, Kendall W, Holm y decisiones HE.
Visualización	Interpretar convergencia, trade-offs, edificios y acciones	Figuras del Capítulo 5.

Nota. La tabla representa el diseño metodológico, las variables, herramientas, datos y procedimiento experimental. Fuente: Elaboración propia a partir del proyecto local, scripts de metodología, datase citylearn_iquitos_2023_2025 y artefactos Drive de entrenamiento.

1.16. Procedimiento experimental

El procedimiento experimental se estructura en siete fases reproducibles. Primero, se verifica el contexto del repositorio y la disponibilidad de artefactos. Segundo, se valida el dataset citylearn_iquitos_2023_2025 y el esquema de edificios/equipos. Tercero, se ejecutan o recuperan las 12 corridas algoritmo x escenario desde Drive. Cuarto, se consolidan episodios, timeseries, traces, building KPIs y checkpoints. Quinto, se calculan KPIs distritales, por edificio y por objetivo. Sexto, se aplican pruebas estadísticas y rankings evaluate_v2. Séptimo, se generan tablas, figuras y redacción interpretativa en el documento final.

Cada fase se documenta mediante archivos de salida. La decisión de no completar manualmente valores ausentes es parte del control metodológico: si un artefacto no conserva una granularidad determinada, se declara como limitación y no se sintetiza. Esta

regla es consistente con la validez de medición y la transparencia experimental recomendadas por Shadish et al. (2002) y Montgomery (2019).

Tabla 19

Procedimiento experimental reproducible

Fase	Actividad	Evidencia
1	Verificación de contexto y rutas	scripts/verify_project_context.ps1.
2	Validación de dataset y esquema CityLearn	schema, building files y auditoria's.
3	Entrenamiento/recuperación de 12 tratamientos	Drive madrl_v3_20260627_164047.
4	Consolidación de resultados	timeseries, traces, checkpoints y KPIs.
5	Análisis descriptivo e inferencial	CSV de estadísticas y comparaciones Holm.
6	Visualización académica	Figuras por convergencia, KPIs, edificios y trade-offs.
7	Integración en Word	Documento final reproducible desde el generador.

Nota. La tabla representa el diseño metodológico, las variables, herramientas, datos y procedimiento experimental. Fuente: Elaboración propia a partir del proyecto local, scripts de metodología, datase citylearn_iquitos_2023_2025 y artefactos Drive de entrenamiento.

1.17. Validez metodológica, trazabilidad y control de sesgos

La validez interna se fortalece por el control del entorno: todos los algoritmos se evalúan sobre el mismo dataset, la misma comunidad, los mismos escenarios y los mismos criterios de extracción de KPIs. La validez de constructo se protege mediante la correspondencia entre preguntas, objetivos, variables e indicadores. La validez estadística se aborda con pruebas no paramétricas y tamaños de efecto, evitando asumir normalidad sin evidencia. La validez externa se declara limitada porque la corrida canónica no sustituye una campaña multi-semilla; por tanto, las conclusiones se formulan como evidencia de la tesis intra-corrida y no como generalización universal.

El control de sesgos se apoya en cinco reglas: no mezclar resultados de otros proyectos, no usar artefactos ajenos a Drive/local autorizado, no inventar datos faltantes, distinguir evidencia descriptiva de evidencia inferencial y reportar limitaciones de cobertura. Este criterio es central para una tesis basada en RL, donde diferencias aparentemente favorables pueden depender de semillas, hiperparámetros, entorno y criterio de evaluación.

Como parte del control de calidad metodológico, se adoptó la cobertura auditada de 600 filas episódicas: 50 por cada uno de los 12 tratamientos. HAPPO combina los episodios históricos 0–48 con el episodio 49 post-resume, sin imputación. Las pruebas Friedman, Wilcoxon pareado con ajuste Holm y Kendall W se aplican a los KPI o edificios emparejados definidos para cada objetivo; los episodios se reservan para estadística descriptiva del aprendizaje. Cada tabla conserva una nota de fuente vinculada con results.json,

training_summary.json, timeseries.csv, trace.csv, building_kpis.csv y checkpoint_manifest.json.

Tabla 20

Control metodológico de validez y trazabilidad

Dimensión de validez	Riesgo	Control aplicado
Interna	Comparación desigual entre algoritmos	Mismo dataset, mismo entorno y escenarios controlados.
Constructo	Indicadores no alineados con objetivos	PE/OE/VD/KPI vinculados por tabla de operacionalización.
Estadística	Normalidad o significancia asumida	Friedman, Kendall W y Wilcoxon pareado con corrección de Holm.
Externa	Generalización indebida	Declaración de inferencia intra-corrida y recomendación multi-semilla.
Trazabilidad	Datos inventados o mezclados	Uso exclusivo de artefactos Drive y CSV materializados.

Nota. La tabla representa el diseño metodológico, las variables, herramientas, datos y procedimiento experimental. Fuente: Elaboración propia a partir del proyecto local, scripts de metodología, datase citylearn_iquitos_2023_2025 y artefactos Drive de entrenamiento.

3.4.6 Árbol CityLearn retenido: usados vs disponibles (reproducibilidad)

El submódulo CityLearn/ conserva, además del dataset Iquitos, el árbol de datos del ecosistema CityLearn v2 embebido en el fork de la tesis. Ese material no se elimina (decisión 2026-07-29): sirve de contexto metodológico, integridad de pruebas del paquete y reproducibilidad offline del simulador. El caso empírico de contraste de hipótesis (Capítulo 5) sigue siendo exclusivamente citylearn_iquitos_2023_2025 + capa MADRL v3.

En CityLearn/data/datasets/ se retienen: (i) citylearn_iquitos_2023_2025 (empírico canónico OE.1–OE.3); (ii) citylearn_challenge_2020–2023 (contexto histórico de benchmarking comunitario; challenge 2022 y demos alimentan tests del submódulo); (iii) barrios de referencia quebec_neighborhood_*, ca_alameda_county_neighborhood, tx_travis_county_neighborhood y vt_chittenden_county_neighborhood (inventario reproducible; contraste cualitativo con el SEAI aislado). No se atribuyen KPIs ni pruebas estadísticas a barrios o challenges upstream en ausencia de artefactos en outputs/.

Los launchers launch_citylearn_v3_iquitos_training.ps1 y monitor_citylearn_v3_iquitos_training.ps1 se retienen como vía histórica local; la vía canónica de entrenamiento permanece launch_citylearn_v3_official_training.ps1 y, para la corrida de 50 episodios, el protocolo Colab del notebook madrl_citylearn_v3_tutorial.ipynb. Detalle: docs/INTEGRACION_CITYLEARN_THESIS_2026-07-29.md.

CAPÍTULO VIII. Capítulo 4. Desarrollo e implementación de la coordinación energética multiobjetivo mediante MADRL

1.18. 4.1 Arquitectura general del sistema

La propuesta implementa un sistema de coordinación energética multiobjetivo mediante aprendizaje por refuerzo profundo multiagente (MADRL: HAPPO, MASAC, MATD3 y MAAC) sobre una comunidad inteligente heterogénea de Iquitos. El flujo de datos y control es lineal y reproducible:

datos → CityLearn → comunidad heterogénea → Dec-POMDP → agentes → CTDE → MADRL → recursos controlables → recompensas E1/E2/E3 → entrenamiento → evaluación → artefactos.

La arquitectura implementada enlaza las fuentes del SEAI, la radiación, la meteorología y las señales tarifarias con CityLearn; instancia 17 agentes de edificio en un Dec-POMDP, aplica CTDE con HAPPO, MASAC, MATD3 y MAAC, controla BESS, EV/V2G y cargas desplazables, y materializa artefactos de entrenamiento, evaluación y trazabilidad para E1, E2 y E3.

1.18.1 4.1.1 Frontera heredada frente a aportes de la tesis

Componente	Frontera	Rol
Física CityLearn v2 (edificios, BESS, PV, EV, KPIs evaluate_v2)	Heredada (Nweye et al., 2024)	Simulador base; baseline baseline / hour_rbc
Dataset citylearn_iquitos_2023_2025	Aporte tesis (tools/dataset/)	17 edificios SEAI, 26 304 h, 222 CSV
Extensiones A1–A4 (Arrhenius, PV IEC, pico OSINERGMIN, CarbonIntensityModel)	Aporte tesis (fork)	Realismo tropical / red aislada
Capa v3 Dec-POMDP + wrappers CTDE	Aporte tesis (citylearn/v3/, dec_pomdp.py)	Observabilidad parcial y estado centralizado
CityLearnV3MADRLRewardFunction (E1/E2/E3)	Aporte tesis	Operacionalización OE.1–OE.3
Backends HARL / MARL / off-policy / MAAC	Heredados (external/)	Algoritmos; no se editan
Wrappers + train_citylearn_v3_*.py + adaptador común	Aporte tesis	Puente CityLearn ↔ backends
Orquestación Colab / validadores / tesis Word	Aporte tesis (scripts/, tools/)	Reproducibilidad y evidencia

El paquete uc3m/ (BACT, HPHI, EmpiricalProtocol) constituye sustento de diseño; las doce corridas canónicas no pasan por esa fachada.

1.19. 4.2 Comunidad inteligente heterogénea

La unidad experimental es la comunidad de 17 edificios institucionales/comerciales del SEAI (Iquitos), tipológicamente heterogénea en área, demanda, PV, BESS y flota EV. Dimensionamiento auditado en data/dataset_audit/der_sizing_audit.csv (totales distritales: PV 48 790,9 kWp; BESS 26 266 kWh / 6 648 kW; 185 cargadores EV).

1.19.1 4.2.1 Inventario cuantitativo de los 17 edificios

ID	Edificio (abreviado)	Tipo	Área m²	Demanda MWh	PV kWp	BESS kWh/kW	V n / kW	áq. ctrl.	M
01	ELECTRO ORIENTE S.A.	Office	4 000	7 378,1	360,2	747 / 609	/ 21,8	í	S
02	Mun. San Juan Bautista	Office	8 000	47,5	920,0	44 / 50	/ 24,4	í	S
03	Aeropuerto Internacional	Assembly	6 000	155,2	440,2	363 / 511	/ 37,8	í	S
04	Hipermercados Tottus	Retail	2 500	131,9	00,2	54 / 409	/ 24,4	í	S
05	Hotel Plaza S.A.	MultiFamily_Hotel	141,89	000,1	74,1	34 / 124	/ 14,4	í	S
06	Mall Aventura S.A.	Commercial_Mall	0 637	4 622,6	952,9	541 / 835	2 / 119,6	í	S
07	UNAP Biología	Education	103,45	314,1	944,9	84 / 240	2 / 153,2	í	S
08	PNP Escuela Técnica	Assembly_Military	1 000	73,7	040,2	01 / 129	7 / 73,6	í	S
09	GORE Loreto — COER	Office_Critical	479,67	34,8	075,3	38 / 30	0 / 37,4	í	S
10	Gobierno Regional Loreto	Office	4 295,73	838,1	431,1	353 / 591	/ 36,6	í	S
11	Hospital Regional Loreto	Healthcare_Hospital	2 649,33	018,9	0 236,1	901 / 424	/ 14,4	í	S
12	EsSalud	Healthcare	8 197,48	120,6	367,5	346 / 960	/ 14,4	í	S
13	UNAP Cs. Contables y Eco.	Education	723	88,6	53,8	72 / 69	1 / 41,4	í	S
14	Autoridad Portuaria	Industrial_Port	7 761	27,9	262,9	29 / 48	/ 21,8	í	S

		Nacional																	
15	I	DRE L — Colegio Nacional	n	Educatio	889,92	9	83,7	6	373,8	2	5 00 / 104	/ 31,4		í		S			
16	I	SIMA — Iquitos	l	Industria	0 294	1	134,6	2	470,8	2	1 622 / 357	1 / 41,4		í		S			
17	I	Asoc. Civil Selva Amazónica	ry	Laborato	611,23	1	406,4	1	86,9	3	7 37 / 158	1 / 41,4		í		S			
	:								8 790,9	4	2 6 266 / 6 648	85 / 749,4		7		1			

Fuente: data/dataset_audit/der_sizing_audit.csv (columnas PV_schema_kWp, BESS_schema_, EV_schema_, Carga_total_MWh, Maquina_controlada_count). Demanda redondeada a 1 decimal; potencias EV = EV_schema_kW.

1.19.2 4.2.2 Señales controlables frente a exógenas

	Clase	Variables	Naturaleza
MADRL)	Controlables (acción	electrical_storage (BESS), electric_vehicle_storage × \(n_i^{\mathrm{ch}}\) (EV/V2G), washing_machine (carga desplazable)	canal Setpoints en \([-1,1]\) por
	Exógenas (no actuadas)	Precio TOU/RTP (pricing.csv), intensidad de carbono CI ∈ [0,6715; 0,790] $kgCO_2/kWh$ (carbon_intensity.csv), meteorología (weather.csv: T, RH, irradiancia, viento), carga no desplazable residual	Observables; entran en \(o_i\) y en \(R\), no en \(a_i\)

La generación PV es física determinista condicionada por GHI/temperatura (aporte A2); el agente no fija potencia PV, solo reacciona vía almacenamiento, EV y carga desplazable.

1.20. 4.3 Datos y preprocesamiento

1.20.1 4.3.1 Origen y periodo

El dataset citylearn_iquitos_2023_2025 se construye desde datos primarios del SEAI (facturación Electro Oriente S.A.), meteorología PVGIS-ERA5 (2023, vía pvlib) y NASA POWER (2024–2025), e incentivos tarifarios TOU locales (0,38 USD/kWh en punta 18:00–22:59; 0,26 USD/kWh fuera de punta). Periodo: 2023–2025; horizonte tabular: 26 304 horas; artefactos activos auditados: 222 CSV.

Pipeline canónico: tools/dataset/generate_iquitos_dataset.py / orchestrate_citylearn_dataset.py → CityLearn/data/datasets/citylearn_iquitos_2023_2025/ (schema.json, Building_.csv, charger_.csv, Washing_Machine_*.csv, weather.csv, carbon_intensity.csv, pricing.csv).

1.20.2 4.3.2 Limpieza, fugas temporales y compuerta NaN/Inf

1. Destilación de cargas mensuales a horarias (distill_building_loads.py) con balance residual NSL y error mensual de cierre < 0,1 %. 2. Series meteorológicas cacheadas (.cache/weather/{year}.parquet) sin remezcla futuro→pasado: el episodio de entrenamiento usa el schema completo en orden temporal horario. 3. Dimensionamiento DER/EV/lavadoras antes del schema.json; sin imputación ad hoc en el bucle MADRL. 4. Compuerta de calidad: check_training_dataset_ready.py, audit_citylearn_csv_integrity.py, audit_der_sizing.py → manifiestos en outputs/dataset_audit/. Criterio de aceptación: status=ready, 0 NaN / 0 Inf, sin cargadores ni máquinas huérfanos.

No se adopta un dataset CityLearn upstream como caso empírico: los barrios/challenges retenidos en el submódulo sirven solo a integridad y reproducibilidad del paquete (Cap. 3 §3.4.6).

1.21. 4.4 Entorno CityLearn y extensiones

1.21.1 4.4.1 Capa heredada CityLearn v2

Se conserva la física de edificios, almacenamiento, PV, EV/V2G y la batería de KPIs vía env.evaluate_v2(). El baseline de contraste (baseline, hour_rbc) proviene de esta capa. La propuesta extiende el simulador; no lo sustituye.

1.21.2 4.4.2 Aportes A1–A4 del fork (tesis)

Código	Aporte	Archivo	Función
A1	Degradación BESS C-rate + Arrhenius ($LiFePO_4$)	energy_model.py	Realismo térmico tropical
A2	Corrección PV IEC 61215	energy_model.py	Derating tropical ≈ 10,9–14,4 % vs STC
A3	Pico con ventana de facturación	cost_function.py	Alineación OSINERGMIN MT-3/MT-4
A4	CarbonIntensityModel	energy_model.py	CI dinámica diésel+PV: \(CI(t)=0{,}790\times(1-0{,}15\times\min(GHI/1000,1))\)

Documentación: docs/thesis/APORTES_SIMULACION_CITYLEARN_MADRL_TESIS.md; arquitectura: docs/architecture/ARQUITECTURA_Y_FLUJO_TRABAJO_CITYLEARN_V3_MADRL.md §4b.

1.22. 4.5 Formulación Dec-POMDP

El control distrital se formula como Dec-POMDP cooperativo:

\[\mathcal{M}=\langle\mathcal{S},\{\mathcal{A}_i\}_{i=1}^{17},\mathcal{T},R,\{\mathcal{O}_i\}_{i=1}^{17},\Omega,\gamma,T\rangle \]

Implementación: CityLearn/citylearn/dec_pomdp.py, fábrica citylearn/v3/, adaptador CityLearn/scripts/citylearn_v3_training_common.py. Dimensiones medidas con CityLearnEnv(schema Iquitos, central_agent=False).

Símbolo	Mapeo físico	Valor Iquitos
\(N\)	Agentes-edificio	17
\(\mathcal{S}\)	Estado CTDE \(s=[o_1,\ldots,o_{17}]\)	\(\lvert\mathcal{S}\rvert=d_s=\mathbf{1\,856}\)
\(o_i\in\mathcal{O}_i\)	Observación local (calendario, meteo, carga, térmica, PV, SoC BESS, 7 canales EV/toma, precio, CI)	\(d_{o_i}\in[\mathbf{54},\mathbf{327}]\)
\(a_i\in\mathcal{A}_i\)	BESS + EV×\(n_i^{\mathrm{ch}}\) + lavadora	\(d_{a_i}=2+n_i^{\mathrm{ch}}\in[\mathbf{5},\mathbf{44}]\); \(\sum_i d_{a_i}=\mathbf{219}\)
\(R\)	Recompensa mixta cooperativa	team_reward_ratio \(r_{\mathrm{team}}=0{,}70\)
\(\gamma\)	Descuento	0,9999
\(T\)	Horizonte por episodio	8 760 pasos (1 año horario)
\(\mathcal{T},\Omega\)	Física CityLearn + observación schema	Transición horaria; observabilidad parcial estricta

Agregación cooperativa canónica (canal de las 12 corridas):

\[\mathrm{mixed}_i=(1-r_{\mathrm{team}})\,\mathrm{reward}_i+r_{\mathrm{team}}\cdot\mathrm{mean}_j(\mathrm{reward}_j),\quad r_{\mathrm{team}}=0{,}70. \]

El distrito no es un agente adicional: entra por el crítico CTDE (\(s\)) y por KPIs agregados evaluate_v2.

1.23. 4.6 CTDE

Entrenamiento centralizado / ejecución descentralizada:

- Centralizado (train): el crítico (o mezcla Q, según backend) recibe información conjunta —en la práctica el estado CTDE \(s\in\mathbb{R}^{1856}\) o su equivalente por wrapper— para estabilizar el crédito multiagente. - Descentralizado (exec): cada política \(\pi_i(a_i\mid o_i)\) actúa solo con \(o_i\); no hay comunicación entre edificios en despliegue. - Post-entrenamiento solo persisten las políticas locales.

Algoritmo	Lectura CTDE en esta tesis
HAPPO	On-policy; actor local continuo; crítico / valor con observación compartida CTDE (CityLearnHARLEnv)
MASAC	Off-policy entrópico; estado global tipo SMAC + mezcla cooperativa QMIX (CityLearnSMACDiscreteEnv)
MATD3	Off-policy determinístico continuo; críticos centralizados / info conjunta (CityLearnOffPolicyVecEnv)
MAAC	Attention-critic CTDE; acciones discretas (CityLearnMAACVecEnv)

1.24. 4.7 Algoritmos MADRL

Los backends residen en external/; la tesis aporta wrappers y scripts de entrenamiento. Sustento teórico de la adecuación: Cap. 2.

Algoritmo	Wrapper	Backend	Paradigma	Acción
HAPPO	CityLearnHARLEnv	external/HARL	on-policy CTDE	continua
MASAC	CityLearnSMACDiscreteEnv	external/MARL/src	entropy-regularized + QMIX	discreta (bins=3, modo eje)
MATD3	CityLearnOffPolicyVecEnv	external/off-policy	off-policy determinístico	continua
MAAC	CityLearnMAACVecEnv	external/MAAC	attention-critic CTDE	discreta (bins=3)

1.24.1 4.7.1 HAPPO

Actualización secuencial con región de confianza para agentes heterogéneos. Script: train_citylearn_v3_happo.py. Acciones continuas en \([-1,1]^{d_{a_i}}\).

1.24.2 4.7.2 MASAC

Regularización de entropía multiagente con mezcla tipo QMIX. Script: train_citylearn_v3_masac.py. Discretización tractable (action_bins=3, no producto cartesiano \(3^{d_{a_i}}\)).

1.24.3 4.7.3 MATD3

Doble crítico, policy delay y ruido sobre el target; control continuo BESS/EV. Script: train_citylearn_v3_matd3.py (backend PyTorch external/off-policy).

1.24.4 4.7.4 MAAC

Crítico con atención multi-cabeza sobre los 17 agentes. Script: train_citylearn_v3_maac.py.

Tabla comparativa de hiperparámetros canónicos (50 episodios)

Fuente: notebook examples_madrl_v3/madrl_citylearn_v3_tutorial.ipynb (celda 6.1, HYPERPARAMS), protocolo two_phase_happo_masac_v3.

Parámetro	HAPPO	MASAC	MATD3	MAAC
Episodios × pasos	50 × 8 760	50 × 8 760	50 × 8 760	50 × 8 760
gamma (\(\gamma\))	0,9999	0,9999	0,9999	0,9999
hidden_size	[512, 512]	rnn 64 / qmix 32	768	768
Buffer	on-policy	2 ep (CPU)	2 000 000	1 000 000
Batch	rollout	512	1 024	512
LR actor / crítico	1e-4 / 5e-4	3e-4 / 5e-4	3e-4 / 3e-4	3e-4 / 1e-3

La validación local (p. ej. 5 episodios, RTX 4060 8 GB) comprueba el pipeline; no sustituye la corrida canónica Colab madrl_v3_20260627_164047.

1.25. 4.8 Recursos controlables

Las acciones del schema Iquitos son exactamente tres familias (§2.2.6.3):

\[a_{i,t}=\big(a_i^{\mathrm{BESS}}(t),\,a_{i,1}^{\mathrm{EV}}(t),\ldots,a_{i,n_i^{\mathrm{ch}}}^{\mathrm{EV}}(t),\,a_i^{\mathrm{WM}}(t)\big)\in[-1,1]^{d_{a_i}}. \]

1.25.1 4.8.1 BESS

- Modelo: batería CityLearn v2 + degradación A1 (C-rate y Arrhenius). - Límites: capacidad/potencia por edificio (Tabla 4.2.1); SoC acotado por la física del Battery. - Acción: electrical_storage ∈ \([-1,1]\) (carga/descarga normalizada). - Inventario distrital: 26 266 kWh / 6 648 kW.

1.25.2 4.8.2 EV / V2G

- Modelo: tomas Mode 3; 185 cargadores schema; subconjunto V2G bidireccional documentado en Cap. 3 (31 tomas de camionetas). - Límites: potencia por toma (EV_schema_kW); SoC, llegada/salida y ventana operativa en observación (7 canales/toma). - Acción: electric_vehicle_storage por cargador ∈ \([-1,1]\). - Potencia nominal simultánea auditada: 749,4 kW.

1.25.3 4.8.3 Cargas desplazables

- Modelo: una lavadora controlada por edificio (washing_machine; 17 máquinas). - Límites: ciclos y potencia pico en CSV Washing_Machine_.csv / columnas de auditoría Maquina_controlada_. - Acción: canal binario/continuo normalizado en el espacio de acción del agente. - Las cargas residuales no desplazables permanecen exógenas.

1.26. 4.9 Función de recompensa E1/E2/E3

Clase CityLearnV3MADRLRewardFunction:

\[\mathrm{reward}_i(t)=\mathrm{reward_scale}\cdot\big[w_{\mathrm{flex}}\mathrm{flex}_i+w_{\mathrm{carbon}}\mathrm{carbon}_i+w_{\mathrm{cost}}\mathrm{cost}_i+w_{\mathrm{ev}}\mathrm{ev}_i\big]. \]

Agregación cooperativa: \(r_{\mathrm{team}}=0{,}70\). Perfil unificado de comparabilidad *_unified_comparable_v4: peak_weight=0,45, ramp_weight=0,35, ev_weight=0,25 (constantes entre algoritmos para no confundir VI con cambios de \(R\)).

Escenario	Es	E	O	\(w_{\mathrm{flex}}\)	\(w_{\mathrm{carbon}}\)	\(w_{\mathrm{cost}}\)	KPI primario de diseño
	E1	E.1 Flexibilida	O	0,70	0,15	0,15	peak_average / flex_composite

	d				
E2	E.2 CO_2 O	0,15	0,70	0,15	carbon_emissions_total
E3	E.3 Costos O	0,25	0,15	0,60	electricity_cost_total

Nota metodológica: la recompensa de estado (señal de entrenamiento) no es el KPI final de contrastación. Los efectos diferenciales se miden en Cap. 5 con KPIs físicos / KPI-gains frente al baseline CityLearn v2.

1.27. 4.10 Diseño experimental

Diseño factorial 4 × 3 = 12 tratamientos (algoritmo × eje), corrida canónica madrl_v3_20260627_164047.

#	Algoritmo	Ejedios	Episoded	Semente	Horizonted_0	Config / salida
1	HAPPO	E1	50	0	8 760	happo/E1_seed_0
2	HAPPO	E2	50	0	8 760	happo/E2_seed_0
3	HAPPO	E3	50	0	8 760	happo/E3_seed_0
4	MASAC	E1	50	0	8 760	masac/E1_seed_0
5	MASAC	E2	50	0	8 760	masac/E2_seed_0
6	MASAC	E3	50	0	8 760	masac/E3_seed_0
7	MATD3	E1	50	0	8 760	matd3/E1_seed_0
8	MATD3	E2	50	0	8 760	matd3/E2_seed_0
9	MATD3	E3	50	0	8 760	matd3/E3_seed_0
10	MAAC	E1	50	0	8 760	maac/E1_seed_0
11	MAAC	E2	50	0	8 760	maac/E2_seed_0
12	MAAC	E3	50	0	8 760	maac/E3_seed_0

Orquestación canónica: notebook madrl_citylearn_v3_tutorial.ipynb + colab_a100_official_launcher.py (two_phase_happo_masac_v3). Validación de plan:

tools/training/validate_launch_config.py. Raíz de artefactos: outputs/madrl_v3_20260627_164047/.

1.28. 4.11 Entrenamiento

Fase	Contenido
Inicialización	Schema Iquitos; escenario E1/E2/E3; seed = 0; wrapper del algoritmo; hiperparámetros §4.7; verificación de contexto scripts/verify_project_context.ps1
Interacción	Rollout horario \(T=8760\); observación local \(o_i\); acción \(a_i\); transición física; recompensa mixta
Actualización	Gradientes según paradigma (on-policy HAPPO; off-policy MASAC/MATD3/MAAC) sobre batch/rollout
Checkpoint	Persistencia periódica + reanudación --skip-completed / manifests de checkpoint
Terminación	Cupo de episodios (objetivo 50) o parada por error/OOM con reintento del launcher
Almacenamiento	Por job: results.json, training_summary.json, timeseries.csv, trace.csv, core_kpis.csv, figures/, checkpoints bajo {algo}/E*_seed_0/

Adaptador común: citylearn_v3_training_common.py. Guardas: tensores finitos, heartbeats, auditoría episodes_recorded.

1.29. 4.12 Evaluación

Elemento	Especificación
Baseline	CityLearn v2: baseline y hour_rbc (benchmark_citylearn_v2_agents.py)
Periodo / horizonte	Mismo schema horario; episodio de evaluación alineado a 8 760 pasos
KPI	env.evaluate_v2() (flexibilidad, carbono, costo, EV, etc.); KPI-gains orientados vs baseline como unidad de contraste Cap. 5
Unidad de análisis	Tratamiento algoritmo × escenario (seed = 0); reportes a nivel distrito y edificio
Artefactos	Comparador compare_citylearn_v2_vs_v3_madrl.py; best_madrl_report.json; carpeta resumen_comparativo/; puente multicriterio en outputs/madrl_multicriteria_selection/ (metodología; interpretación en Cap. 5)

Este capítulo fija el contrato de evaluación; no reporta tablas de ranking ni decisiones de hipótesis.

1.30. 4.13 Reproducibilidad

Dimensión	Valor canónico
Software	Python 3.9 (.venv39-citylearn-v3), PyTorch 2.8.0+cu126, CUDA 12.6; pytest 8.4.2 (validación)
Activación	scripts/activate_citylearn_v3.ps1 (PYTHONPATH = raíz + CityLearn/)
Hardware local	NVIDIA RTX 4060 Laptop 8 GB (validación de pipeline)
Hardware canónico	Google Colab Pro+ (A100 / H100 según runtime del notebook); protocolo two_phase_happo_masac_v3
Semilla	seed = 0 en las 12 corridas reportadas
Rutas	Dataset: CityLearn/data/datasets/citylearn_iquitos_2023_2025/; run: outputs/madrl_v3_20260627_164047/; auditoría DER: data/dataset_audit/der_sizing_audit.csv
Ops	deploy/ (Docker/AWS) opcional; no sustituye la evidencia Colab

1.31. 4.14 Validación técnica

1.31.1 4.14.1 Suite automatizada (2026-07-29)

.\.venv39-citylearn-v3\Scripts\python.exe -B -m pytest tests/uc3m/ tests/citylearn_v3/ -v --tb=line

Resultado: 184 passed (180 tests/uc3m/ + 4 tests/citylearn_v3/), 1 warning no bloqueante; duración ≈ 91 s. Entorno: Python 3.9.25, raíz D:\MADRLCitytleranflexresdr, contexto verificado.

1.31.2 4.14.2 Controles de integridad operativa

- Acciones en rangos de actuadores; evolución de SoC BESS/EV bajo física CityLearn; filtros NaN/Inf en tensores y CSV del dataset. - tools/training/validate_launch_config.py: PASS en construcción de 12 jobs 4×3, hiperparámetros por algoritmo y dry-run del scheduler (concurrencia ≤ 6; fase 1 HAPPO+MASAC).

La validación de software no sustituye el entrenamiento Colab ni la batería estadística del Cap. 5.

1.32. 4.15 Correspondencia OE.1→E1, OE.2→E2, OE.3→E3 y OG→E1+E2+E3

Se citan los elementos definitivos de investigación (sin reformular) y su operacionalización técnica. Cap. IV no contrastará hipótesis.

Alcance	Texto rector (efectos diferenciales)	Escenario / pesos	Variables / KPI de diseño	Rutas
E.1	O	Determinar y cuantificar los efectos diferenciales de HAPPO, MASAC, MATD3 y MAAC sobre la flexibilidad energética (eje E1) e identificar el algoritmo de mejor desempeño en la comunidad inteligente heterogénea de Iquitos	E1: 0,70 / 0,15 / 0,15	peak_average, ramping_average, one_minus_load_factor_average, flex_composite	*/E1_seed_0/; CityLearnV3MADRLRewardFunction
E.2	O	… sobre las emisiones de CO_2 (eje E2) …	E2: 0,15 / 0,70 / 0,15	carbon_emissions_total (+ deltas vs baseline)	*/E2_seed_0/; carbon_intensity.csv
E.3	O	… sobre los costos energéticos (eje E3) …	E3: 0,25 / 0,15 / 0,60	electricity_cost_total (+ TOU/RTP)	*/E3_seed_0/; pricing.csv
G	O	Determinar y cuantificar los efectos diferenciales … en la coordinación energética multiobjetivo … e identificar el algoritmo de mejor desempeño global	E1+E2+E3 (integración)	Score de escenario / multicriterio (pesos iguales ⅓ por defecto en puente metodológico)	outputs/madrl_v3_20260627_164047/resumen_comparativo/; outputs/madrl_multicriteria_selection/

Tema del título: coordinación energética multiobjetivo; mecanismo: MADRL HAPPO/MASAC/MATD3/MAAC; unidad: comunidad inteligente heterogénea de Iquitos. La identificación del mejor desempeño pertenece al objetivo y se resuelve con evidencia en Cap. 5; no se anticipa aquí.

Estado del capítulo

Estructura 4.1–4.15 completa: arquitectura (heredado vs aporte), comunidad 17 edificios, datos/preprocesamiento, CityLearn A1–A4, Dec-POMDP, CTDE, algoritmos e hiperparámetros, recursos BESS/EV/cargas, recompensa E1/E2/E3, diseño 4×3 (madrl_v3_20260627_164047), entrenamiento, evaluación, reproducibilidad, validación técnica (184 pytest) y correspondencia OE↔E / OG↔E1+E2+E3. Pendiente de consumo en Cap. 5: interpretación de artefactos y contrastación de hipótesis.

CAPÍTULO IX. Capítulo 5. Resultados, efectos diferenciales y desempeño algorítmico

1.33. 5.1 Auditoría inicial de resultados

La auditoría de integridad de la campaña canónica verifica tratamientos, episodios, semillas, cobertura, datos faltantes, igualdad de horizonte e integridad de artefactos.

Tratamientos. Diseño factorial cuasiexperimental 4 × 3: algoritmos HAPPO, MASAC, MATD3 y MAAC × escenarios E1 (flexibilidad), E2 (CO_2) y E3 (costos), sobre la comunidad inteligente heterogénea de 17 edificios del SEAI–Iquitos (CityLearn v2 + capa MADRL v3). Baseline de contraste: CityLearn v2 (baseline / controles RBC).

Episodios y semillas. Horizonte nominal de 50 episodios por tratamiento. Semilla de campaña seed = 0 (una sola semilla). Los episodios de una corrida no constituyen réplicas experimentales independientes ni permiten afirmar robustez multisemilla.

Cobertura e igualdad de horizonte.

Algoritmo	E1	E2	E3	KPI-gains finales (Capa A)	Uso en HE/HG0
MATD3	50	50	50	Sí	Descriptivo + inferencial
MAAC	50	50	50	Sí	Descriptivo + inferencial
MASAC	50	50	50	Sí	Descriptivo + inferencial
HAPPO	49	49	49	No (comparables)	Solo descriptivo; excluido de HE

Datos faltantes. HAPPO completa 49/50 episodios en E1–E3 y no aporta KPI-gains finales comparables; por ello permanece fuera de Wilcoxon vs baseline, Friedman, post hoc Holm y decisiones HE10–HE31 / HG0–HG1. El trío MAAC–MASAC–MATD3 aporta cobertura 50/50 con KPI-gains.

Integridad. La contrastación de hipótesis se ancla exclusivamente a Capa A (descriptivos_kpi_gains_por_problema.csv, normalidad_shapiro_por_problema.csv, impacto_vs_baseline_wilcoxon.csv, pruebas_omnibus_problemas_objetivos.csv, comparaciones_wilcoxon_pareado_holm.csv, decisiones_problemas_objetivos_hipotesis.csv). Rankings best_madrl, evaluate_v2 4/4 y TOPSIS son planos descriptivos complementarios y no sustituyen HE.

1.34. 5.2 Criterio cuantitativo de efecto

Se define el efecto diferencial como la conjunción de: (i) cambio frente a la línea base (KPI-gain orientado; valor positivo favorece al MADRL); (ii) significancia estadística (α = 0,05, con Holm cuando corresponde); (iii) magnitud del efecto (Kendall W, Cliff's δ exploratorio); (iv) dirección (favorable / desfavorable); y (v) diferencia entre algoritmos (Friedman + Wilcoxon/Holm principal; KW/MWU exploratorio).

Unidad primaria de HE: KPI-gain orientado por KPI, filtrado al escenario del objetivo (OE.1/E1 n = 12; OE.2/E2 n = 5; OE.3/E3 n = 9; GLOBAL n = 26).

Criterios C1–C5 (cumplimiento completo).

Id	Criterio	Medida / prueba	Rol
C1	Efecto frente al baseline	Wilcoxon KPI-gains vs cero + Holm	Inferencial HE
C2	Diferencias entre algoritmos	Friedman + Kendall W + Wilcoxon/Holm (principal); KW/MWU exploratorio	Inferencial HE
C3	KPI distritales por eje	flex_composite / ΔCO_2 / Δcosto	Descriptivo distrito
C4	Resultados por edificio	17 edificios × E1/E2/E3	Descriptivo edificio
C5	Actuación de recursos controlables	BESS, EV/V2G, cargas desplazables	Atribuibilidad

El liderazgo descriptivo no sustituye la decisión inferencial. TOPSIS y evaluate_v2 4/4 no son pruebas de hipótesis.

1.35. 5.3 OE.1 — Flexibilidad energética (E1)

PE.1. ¿En qué medida los algoritmos HAPPO, MASAC, MATD3 y MAAC producen efectos diferenciales sobre la flexibilidad energética (eje E1) y cuál presenta el mejor desempeño en la comunidad inteligente heterogénea de Iquitos?

OE.1. Determinar y cuantificar los efectos diferenciales de los algoritmos HAPPO, MASAC, MATD3 y MAAC sobre la flexibilidad energética (eje E1) e identificar el algoritmo de mejor desempeño en la comunidad inteligente heterogénea de Iquitos.

HE10. Los algoritmos HAPPO, MASAC, MATD3 y MAAC no producen efectos diferenciales estadísticamente significativos sobre la flexibilidad energética (eje E1) de la comunidad inteligente heterogénea de Iquitos. HE11. Al menos uno de los algoritmos HAPPO, MASAC, MATD3 y MAAC produce un efecto diferencial estadísticamente significativo sobre la flexibilidad energética (eje E1) de la comunidad inteligente heterogénea de Iquitos.

1.35.1 5.3.1 Descriptivos

Fuente: descriptivos_kpi_gains_por_problema.csv (n = 12 KPI por algoritmo con cobertura completa).

Algoritmo	Media gain	Mediana gain	Mejorados / no	Cobertura
MAAC	−0,0888	−0,00119	5 / 7	Completa
MATD3	−0,0868	−0,00289	5 / 7	Completa
MASAC	−0,2621	−0,01363	2 / 10	Completa
HAPPO	—	—	—	Sin KPI-gains finales

Las medianas son ≤ 0 (deterioro relativo al baseline en la métrica de gain orientada). Mejor mediana descriptiva de KPI-gain: MAAC.

1.35.2 5.3.2 Shapiro–Wilk

Fuente: normalidad_shapiro_por_problema.csv (n = 12).

Algoritmo	W	p	Normalidad
MAAC	0,7152	0,001184	Rechazada
MASAC	0,5997	$1{,}066\times10^{-4}$	Rechazada
MATD3	0,7160	0,001208	Rechazada

Se rechaza normalidad en los tres grupos con KPI-gains; se activa exclusivamente la batería no paramétrica.

1.35.3 5.3.3 Cambio frente a baseline

Las medianas de KPI-gain frente a cero son negativas (MAAC −0,00119; MATD3 −0,00289; MASAC −0,01363). El cambio observado es, en promedio de KPI, desfavorable respecto del baseline CityLearn v2. HAPPO no aporta KPI-gains finales para este contraste.

1.35.4 5.3.4 Prueba inferencial frente a baseline

Fuente: impacto_vs_baseline_wilcoxon.csv (C1).

Algoritmo	Mediana gain	p-Holm	Dirección	Decisión
MAAC	−0,00119	0,6025	desfavorable	impacto no detectado
MASAC	−0,01363	0,0483	desfavorable	impacto detectado (deterioro)
MATD3	−0,00289	0,6025	desfavorable	impacto no detectado

Solo MASAC alcanza significancia tras Holm, y en dirección de deterioro. Ningún algoritmo del trío muestra mejora significativa vs baseline en OE.1.

1.35.5 5.3.5 Comparación entre HAPPO, MASAC, MATD3 y MAAC

HAPPO se reporta solo en el plano descriptivo físico (C3–C5) por falta de KPI-gains HE. La comparación inferencial entre algoritmos se restringe a MAAC, MASAC y MATD3.

Fuente: pruebas_omnibus_problemas_objetivos.csv (C2).

Prueba	Estadístico	p	Efecto	Rol
Friedman (principal)	$\chi^2 = 5{,}5897$	0,0611	Kendall W = 0,2329	No se rechaza igualdad pareada
Kruskal–Wallis (exploratorio)	H = 1,5164	0,4685	$\varepsilon^2 = 0$	Sensibilidad; n.s.

No hay diferencias globales significativas al $\alpha = 0{,}05$ entre el trío con KPI-gains.

1.35.6 5.3.6 Tamaño del efecto

Kendall W = 0,2329 (concordancia débil). Cliff's δ exploratorio (MWU, comparaciones_mwu_holm_problemas.csv): MAAC–MASAC δ = 0,24; MAAC–MATD3 δ = −0,06; MASAC–MATD3 δ = −0,26. Las magnitudes no sostienen superioridad inferencial.

1.35.7 5.3.7 Post hoc

Wilcoxon pareado + Holm (comparaciones_wilcoxon_pareado_holm.csv): MAAC–MASAC p-Holm = 0,110; MAAC–MATD3 = 0,514; MASAC–MATD3 = 0,338 — todos n.s. MWU exploratorio: todos p-Holm = 0,850.

1.35.8 5.3.8 KPI distritales

Fuentes: district_ranking_by_scenario.csv, district_kpis_4madrl.csv, E1_OE1_kpis.csv / ranking 4/4.

Algoritmo	flex_composite	peak_average	ramping_average	Score OE1 (4/4)
MATD3	1,0009	1,0081	1,0012	1,0000
MAAC	1,0124	1,0307	1,0110	0,8951
MASAC	1,0286	1,0851	1,0220	0,7479
HAPPO	1,1105	1,3903	1,0839	0,0000

Menor flex_composite (mejor flexibilidad física de distrito): MATD3. Este KPI físico no se contrasta inferencialmente en Capa A.

1.35.9 5.3.9 Resultados de los 17 edificios

En los 17 edificios, MATD3 registró flex_gain_vs_baseline > 0 en 5 edificios y una mediana de −0,01497; HAPPO lo hizo en 1 edificio y presentó una mediana de −0,18342; MAAC y MASAC no registraron edificios con ganancia positiva y sus medianas fueron −0,01832 y −0,03860, respectivamente. Por tanto, la heterogeneidad de C4 respalda el liderazgo físico descriptivo de MATD3, pero no una mejora comunitaria generalizada.

La desagregación procede de building_kpis_4madrl.csv (17 edificios × 4 algoritmos × 3 escenarios); estos resultados por edificio son descriptivos y no se emplean como réplicas independientes para HE.1.

En C3, MATD3 alcanzó el menor flex_composite distrital (1,000923). En C4, el conteo de edificios con mejora fue coherente con ese liderazgo relativo, aunque 12 de 17 edificios de MATD3 tampoco superaron la línea base.

1.35.10 5.3.10 BESS, EV/V2G y cargas desplazables

En C5, el throughput BESS de E1 fue $8{,}85\times10^{6}$ kWh para HAPPO, $6{,}24\times10^{5}$ kWh para MASAC, $3{,}41\times10^{5}$ kWh para MAAC y $8{,}49\times10^{3}$ kWh para MATD3. La mediana de éxito de salida EV fue 0,541 para HAPPO, 0,384 para MATD3, 0,044 para MASAC y 0,040 para MAAC. Los cuatro tratamientos controlaron 17 BESS, 185 cargadores EV y 17 cargas flexibles.

Mayor actuación BESS (HAPPO) no coincide con mejor flex_composite ni con KPI-gains favorables. C5 documenta atribuibilidad; no decide HE.

1.35.11 5.3.11 Identificación del MADRL de mejor desempeño

- Descriptivo (KPI-gain): MAAC (mediana −0,00119). - Descriptivo (flex_composite / score OE1 4/4): MATD3 (1,0009 / 1,0000). - Inferencial: no hay superioridad estadísticamente significativa entre algoritmos; no hay mejora significativa vs baseline (salvo deterioro significativo de MASAC).

1.35.12 5.3.12 Respuesta OE.1

Respuesta a PE.1. Los efectos diferenciales sobre flexibilidad se caracterizan descriptivamente (liderazgo mixto MAAC/MATD3) y se contrastan de forma exploratoria. No se establece impacto favorable ni diferenciación estadísticamente significativa conjunta del trío con KPI-gains. HAPPO aporta evidencia descriptiva de recursos, no de HE.

1.35.13 5.3.13 Decisión HE.1 (HE10 / HE11)

- HE10: no se rechaza. - HE11: no se respalda. - Nivel de evidencia: descriptivo + exploratorio; semilla única; HAPPO fuera de HE.

1.36. 5.4 OE.2 — Emisiones de CO_2 (E2)

PE.2. ¿En qué medida los algoritmos HAPPO, MASAC, MATD3 y MAAC producen efectos diferenciales sobre las emisiones de CO_2 (eje E2) y cuál presenta el mejor desempeño en la comunidad inteligente heterogénea de Iquitos?

OE.2. Determinar y cuantificar los efectos diferenciales de los algoritmos HAPPO, MASAC, MATD3 y MAAC sobre las emisiones de CO_2 (eje E2) e identificar el algoritmo de mejor desempeño en la comunidad inteligente heterogénea de Iquitos.

HE20. Los algoritmos HAPPO, MASAC, MATD3 y MAAC no producen efectos diferenciales estadísticamente significativos sobre las emisiones de CO_2 (eje E2) de la comunidad inteligente heterogénea de Iquitos. HE21. Al menos uno de los algoritmos HAPPO, MASAC, MATD3 y MAAC produce un efecto diferencial estadísticamente significativo sobre las emisiones de CO_2 (eje E2) de la comunidad inteligente heterogénea de Iquitos.

1.36.1 5.4.1 Descriptivos

Fuente: descriptivos_kpi_gains_por_problema.csv (n = 5).

Algoritmo	Media gain	Mediana gain	Mejorados / no
MATD3	−0,4101	−0,0421	0 / 5
MAAC	−0,4148	−0,0470	0 / 5
MASAC	−0,4171	−0,0516	0 / 5
HAPPO	—	—	Sin KPI-gains

Medianas negativas y 0/5 KPI mejorados: deterioro en gains. Mejor mediana descriptiva: MATD3.

1.36.2 5.4.2 Shapiro–Wilk

MAAC W = 0,6993 p = 0,009419; MASAC W = 0,6999 p = 0,009548; MATD3 W = 0,7012 p = 0,009848 — normalidad rechazada (p ≈ 0,0094–0,0098).

1.36.3 5.4.3 Cambio frente a baseline

Todas las medianas de KPI-gain son negativas. En el plano físico de distrito, ΔCO_2 (kg; menor = mejor): MATD3 23 070; MAAC 70 654; MASAC 77 649; HAPPO 1 431 341. Un ΔCO_2 positivo no se interpreta como “reducción” frente al baseline.

1.36.4 5.4.4 Prueba inferencial frente a baseline

Los tres algoritmos: p-Holm = 0,1875 (n.s.), dirección desfavorable. No se detecta impacto significativo tras Holm.

1.36.5 5.4.5 Comparación entre HAPPO, MASAC, MATD3 y MAAC

HAPPO solo descriptivo. Inferencia entre MAAC, MASAC y MATD3:

Prueba	Estadístico	p	Efecto	Rol
Friedman	$\chi^2 = 6,0000$	0,0498	Kendall W = 0,6000	Señal pareada débil-moderada

KW (exploratorio)	H = 0,5364	0,7648	ε² = 0	n.s.

Friedman fue significativo para el subconjunto comparable (χ^2 = 6,0000; p = 0,0498; Kendall W = 0,6000); conforme a la regla p < 0,05, se rechazó la igualdad global de MAAC, MASAC y MATD3. La ausencia de impacto frente a cero y de pares significativos tras Holm impidió localizar qué par originó la diferencia, pero no anuló el resultado omnibus.

1.36.6 5.4.6 Tamaño del efecto

Kendall W = 0,6000. Cliff's δ exploratorio: pares con |δ| = 0,20. Magnitud pareada moderada en Friedman; sin confirmación por pares Holm.

1.36.7 5.4.7 Post hoc

Wilcoxon: los tres pares p-Holm = 0,307 (todos n.s.). MWU: p-Holm = 1,000.

1.36.8 5.4.8 KPI distritales

Ranking distrito E2 por carbon_emissions_delta: MATD3 (23 070 kg) > MAAC (70 654) > MASAC (77 649) > HAPPO (1 431 341). Score OE2 4/4: MATD3 1,0000; MAAC 0,9662; MASAC 0,9612; HAPPO 0.

1.36.9 5.4.9 Resultados de los 17 edificios

En C4, MATD3 presentó reducción de CO_2 respecto de la línea base en 5 de 17 edificios y una mediana de −557 kgCO_2; HAPPO, MAAC y MASAC no registraron edificios con reducción y mostraron medianas de −53 834, −6 411 y −5 828 kgCO_2, respectivamente. La evidencia por edificio confirma heterogeneidad y no se interpreta como réplica independiente.

1.36.10 5.4.10 BESS, EV/V2G y cargas desplazables

En C5 para E2, el throughput BESS fue $1{,}67\times10^7$ kWh en HAPPO, $6{,}38\times10^5$ kWh en MASAC, $6{,}04\times10^5$ kWh en MAAC y $9{,}48\times10^3$ kWh en MATD3. La mediana de éxito EV fue 0,474, 0,035, 0,042 y 0,345, respectivamente. MATD3 combinó el menor incremento distrital de CO_2 con una actuación BESS sustancialmente menor; esta asociación es descriptiva y no demuestra causalidad.

1.36.11 5.4.11 Identificación del MADRL de mejor desempeño

El mejor desempeño descriptivo de E2 correspondió a MATD3 por mediana de KPI-gain (−0,04214), menor ΔCO_2 distrital (23 070 kg) y score OE2 (1,0000). Inferencialmente,

Friedman detectó una diferencia global en el subconjunto comparable, aunque Wilcoxon–Holm no identificó un par específico.

1.36.12 5.4.12 Respuesta OE.2

En respuesta a PE.2 y OE.2, MATD3 presentó el mejor desempeño ambiental observado y se cuantificó una diferencia global para MAAC, MASAC y MATD3 ($p = 0,0498$; $W = 0,6000$). Sin embargo, la comparación no incluyó HAPPO y los post hoc no localizaron pares, por lo que la respuesta completa de cuatro algoritmos permanece incompleta.

1.36.13 5.4.13 Decisión HE.2 (HE20 / HE21)

Para el subconjunto comparable se rechazó HE20 y se obtuvo evidencia compatible con HE21 mediante Friedman; no obstante, la hipótesis específica completa, que nombra a los cuatro algoritmos, no se declaró cerrada por la ausencia de HAPPO en los KPI-gains y por la semilla única.

1.37. 5.5 OE.3 — Costos energéticos (E3)

PE.3. ¿En qué medida los algoritmos HAPPO, MASAC, MATD3 y MAAC producen efectos diferenciales sobre los costos energéticos (eje E3) y cuál presenta el mejor desempeño en la comunidad inteligente heterogénea de Iquitos?

OE.3. Determinar y cuantificar los efectos diferenciales de los algoritmos HAPPO, MASAC, MATD3 y MAAC sobre los costos energéticos (eje E3) e identificar el algoritmo de mejor desempeño en la comunidad inteligente heterogénea de Iquitos.

HE30. Los algoritmos HAPPO, MASAC, MATD3 y MAAC no producen efectos diferenciales estadísticamente significativos sobre los costos energéticos (eje E3) de la comunidad inteligente heterogénea de Iquitos. HE31. Al menos uno de los algoritmos HAPPO, MASAC, MATD3 y MAAC produce un efecto diferencial estadísticamente significativo sobre los costos energéticos (eje E3) de la comunidad inteligente heterogénea de Iquitos.

1.37.1 5.5.1 Descriptivos

Fuente: descriptivos_kpi_gains_por_problema.csv (n = 9).

Algoritmo	Media gain	Mediana gain	Mejorados / no
MAAC	−0,2278	−0,00268	1 / 8
MATD3	−0,2259	−0,00918	1 / 8

MASAC	−0,2355	−0,01403	1 / 8
HAPPO	—	—	Sin KPI-gains

Mejor mediana descriptiva: MAAC.

1.37.2 5.5.2 Shapiro–Wilk

MAAC W = 0,5575 p = 3,029×10⁻ ⁵; MASAC W = 0,5879 p = 6,905×10⁻ ⁵; MATD3 W = 0,5464 p = 2,246×10⁻ ⁵ — normalidad rechazada (p ≤ 6,9×10⁻ ⁵).

1.37.3 5.5.3 Cambio frente a baseline

Medianas de KPI-gain negativas. Δcosto distrito E3 (EUR; menor = mejor observado): MAAC 9 515; MASAC 19 793; MATD3 44 399; HAPPO 106 828. Se distingue menor costo observado de ahorro estadísticamente demostrado.

1.37.4 5.5.4 Prueba inferencial frente a baseline

MAAC/MASAC p-Holm = 0,0781; MATD3 p-Holm = 0,0586 — todos n.s. tras Holm; dirección desfavorable. No hay ahorro estadísticamente demostrado vs baseline.

1.37.5 5.5.5 Comparación entre HAPPO, MASAC, MATD3 y MAAC

HAPPO solo descriptivo. Inferencia entre el trío:

Prueba	Estadístico	p	Efecto	Rol
Friedman	$\chi^2 = 3{,}4286$	0,1801	W = 0,1905	n.s.
KW (exploratorio)	H = 0,6138	0,7357	$\varepsilon^2 = 0$	n.s.

1.37.6 5.5.6 Tamaño del efecto

Kendall W = 0,1905 (débil). Cliff's δ exploratorio: MAAC–MASAC 0,21; MAAC–MATD3 0,09; MASAC–MATD3 −0,14.

1.37.7 5.5.7 Post hoc

Wilcoxon Holm: p-Holm ∈ {0,527; 1; 1} — todos n.s. MWU: p-Holm = 1,000. No se cita el p = 0,0333 de capas pooladas (Capa B) como resultado Holm canónico.

1.37.8 5.5.8 KPI distritales

Ranking distrito E3 por electricity_cost_delta: MAAC (9 515 EUR). Score OE3 4/4: MAAC 1,0000; MASAC 0,8944; MATD3 0,6415; HAPPO 0. TOPSIS (complementario): MAAC C* = 0,9827.

1.37.9 5.5.9 Resultados de los 17 edificios

En C4, el número de edificios con cost_reduction_eur > 0 fue 12/17 para HAPPO, 7/17 para MAAC, 7/17 para MASAC y 3/17 para MATD3. No obstante, las medias de reducción fueron negativas para los cuatro y el Δcosto distrital fue positivo; por ello, la mejora de edificios particulares no se confundió con ahorro comunitario.

1.37.10 5.5.10 BESS, EV/V2G y cargas desplazables

En C5 para E3, el throughput BESS fue $1{,}42\times10^{7}$ kWh en HAPPO, $7{,}17\times10^{5}$ kWh en MASAC, $6{,}15\times10^{5}$ kWh en MAAC y $9{,}01\times10^{3}$ kWh en MATD3. La mediana de éxito EV fue 0,507, 0,043, 0,047 y 0,466, respectivamente. La intensidad de actuación no coincidió con el menor costo distrital, obtenido por MAAC.

1.37.11 5.5.11 Identificación del MADRL de mejor desempeño

- Descriptivo: MAAC (KPI-gain, Δcosto, score 4/4, TOPSIS C* = 0,9827). - Inferencial: liderazgo descriptivo sin significancia omnibus ni impacto vs cero tras Holm.

1.37.12 5.5.12 Respuesta OE.3

Respuesta a PE.3. MAAC es el algoritmo de mejor desempeño descriptivo en costos; la ventaja no es inferencialmente concluyente. El menor costo observado no equivale a ahorro estadísticamente demostrado.

1.37.13 5.5.13 Decisión HE.3 (HE30 / HE31)

- HE30: no se rechaza. - HE31: no se respalda.

1.38. 5.6 OG — Coordinación energética multiobjetivo

PG. ¿En qué medida los algoritmos HAPPO, MASAC, MATD3 y MAAC producen efectos diferenciales en la coordinación energética multiobjetivo de una comunidad inteligente heterogénea de Iquitos, considerando la flexibilidad energética, las emisiones de CO_2 y los costos energéticos, y cuál presenta el mejor desempeño global?

OG. Determinar y cuantificar los efectos diferenciales de los algoritmos HAPPO, MASAC, MATD3 y MAAC en la coordinación energética multiobjetivo de una comunidad inteligente heterogénea de Iquitos, considerando la flexibilidad energética, las emisiones de CO_2 y los costos energéticos, e identificar el algoritmo de mejor desempeño global.

HG0. Los algoritmos HAPPO, MASAC, MATD3 y MAAC no producen efectos diferenciales estadísticamente significativos en la coordinación energética multiobjetivo de la comunidad inteligente heterogénea de Iquitos, considerando conjuntamente la flexibilidad energética, las emisiones de CO_2 y los costos energéticos. HG1. Al menos uno de los algoritmos HAPPO, MASAC, MATD3 y MAAC produce un efecto diferencial estadísticamente significativo en la coordinación energética multiobjetivo de la comunidad inteligente heterogénea de Iquitos, considerando conjuntamente la flexibilidad energética, las emisiones de CO_2 y los costos energéticos.

1.38.1 5.6.1 Integración descriptiva, trade-offs y Pareto

Ranking best_madrl 3×3 (sin HAPPO; score global):

Rango	Algoritmo	Score global	OE.1	OE.2	OE.3
1	MATD3	0,6667	1,0000	1,0000	0,0000
2	MAAC	0,5706	0,5837	0,1282	1,0000
3	MASAC	0,2351	0,0000	0,0000	0,7054

Ranking evaluate_v2 4/4 (descriptivo): MAAC 0,9538; MATD3 0,8805; MASAC 0,8679; HAPPO 0,0000.

Trade-off: MATD3 lidera flexibilidad física y CO_2; MAAC lidera costos, 4/4 y TOPSIS. Frente de Pareto = {MAAC, MASAC, MATD3}. No hay dominador único.

1.38.2 5.6.2 TOPSIS (complementario; no es prueba de hipótesis)

Fuente: madrl_multicriteria_selection/topsis_ranking.csv. MAAC C* = 0,9827; MASAC 0,5656; MATD3 0,3074. TOPSIS no respalda HE ni HG1 por sí solo.

1.38.3 5.6.3 Inferencia GLOBAL (Capa A, n = 26)

Shapiro–Wilk: normalidad rechazada ($p \leq 2{,}6\times10^{-6}$). Impacto vs 0 (Holm): MAAC p = 0,00233; MASAC $p = 1{,}55\times10^{-4}$; MATD3 p = 0,00293 — los tres significativos en dirección desfavorable.

Prueba	Estadístico	p	Efecto
Friedman	$\chi^2 = 9{,}2911$	0,0096	Kendall W = 0,1787
KW (exploratorio)	H = 1,8108	0,4044	$\varepsilon^2 = 0$

Wilcoxon post hoc Holm: solo MAAC–MASAC p-Holm = 0,0172; MAAC–MATD3 = 0,295; MASAC–MATD3 = 0,114.

Mejor compromiso global descriptivo: depende del plano (best_madrl → MATD3 0,6667; 4/4/TOPSIS → MAAC 0,9538 / 0,9827). Score medio E1–E3: MAAC 0,8066. Mediana robusta GLOBAL: MATD3 (−0,00694). Sin ganador global único y sin superioridad estadística global concluyente de un único MADRL.

1.38.4 5.6.4 Decisión HG0 / HG1

Para MAAC, MASAC y MATD3 se rechazó HG0 y se obtuvo evidencia compatible con HG1 (Friedman global p = 0,0096; W = 0,1787). La decisión no se extendió a la hipótesis completa de cuatro algoritmos porque HAPPO careció de KPI-gains finales comparables; tampoco estableció un ganador global único.

1.39. 5.7 Contrastación consolidada de hipótesis

Tabla 5.7. Resumen HG0/HG1 y HE10–HE31 (Capa A; α = 0,05).

Hipótesis	Prueba	Estadístico	p	Tamaño	Post hoc	Decisión	Mejor algoritmo	Nivel evidencia
HG0 / HG1	Friedman GLOBAL; KPI-gains pareados	$\chi^2 = 9{,}2911$	,0096	W = 0,1787	MAAC–MASAC p-Holm = 0,0172	Se rechaza HG0 en MAAC–MASAC–MATD3; decisión completa de cuatro algoritmos: incompleta	MAAC como compromiso observado; sin ganador inferencial único	Inferencial exploratorio
HE10 / HE11	Friedman OE1	$\chi^2 = 5{,}5897$	,0611	W = 0,2329	Todos no significativos; mínimo p-Holm = 0,110	No se rechaza HE10 en el subconjunto comparable; hipótesis completa: incompleta	MATD3 (KPI físico) / MAAC (mediana gain)	Descriptivo + inferencial exploratorio
HE20 / HE21	Friedman OE2	$\chi^2 = 6{,}0000$	,0498	W = 0,6000	Todos p-Holm = 0,307	Se rechaza HE20 en el subconjunto	MATD3	Omnibus significativo; pares no

								comparable; hipótesis completa: incompleta			localizados
E30 HE31	H /	F riedman OE3	X ² = 3,4286	,1801	0 = 0,1905	W	Tod os no significativos	No se rechaza HE30 en el subconjunto comparable; hipótesis completa: incompleta	AAC	M	D escriptivo + inferencial exploratorio

Como sensibilidad independiente, Kruskal–Wallis produjo OE1 p = 0,4685, OE2 p = 0,7648, OE3 p = 0,7357 y GLOBAL p = 0,4044; estos valores no se usaron para sustituir la prueba pareada. Frente a baseline, solo MASAC en OE1 mostró un cambio significativo y desfavorable (p-Holm = 0,0483); globalmente, los tres algoritmos comparables mostraron cambios significativos y desfavorables.

1.40. 5.8 Discusión

1.40.1 5.8.1 Triangulación con la literatura

La ausencia de HE11 bajo liderazgo descriptivo mixto en flexibilidad es coherente con la dificultad de control multiagente en edificios grid-interactive reportada por Nweye et al. (2022, 2023b) y con el marco CityLearn v2 de comunidades energéticamente flexibles (Nweye et al., 2024; Vázquez-Canteli & Nagy, 2019b): la coordinación de DER no garantiza mejoras unívocas en todos los KPI de flexibilidad bajo una sola semilla.

El perfil de MATD3 en CO_2/flex física y de MAAC en costos dialoga con las familias actor-crítico multiagente (Iqbal & Sha, 2019; Kuba et al., 2021; Zhong et al., 2023) y con SAC/MASAC en entornos energéticos (Haarnoja et al., 2018; Gao et al., 2023): distintos sesgos de aprendizaje producen trade-offs multiobjetivo, no un dominador Pareto.

La disociación entre ΔCO_2 (MATD3) y Δcosto (MAAC) refuerza la necesidad de señales de carbono y tarifa TOU explícitas (Nweye et al., 2024; Nweye & Nagy, 2024b). El throughput BESS heterogéneo (C5) muestra que mayor actuación no implica mejor KPI-gain ni menor Δ físico.

La puerta Shapiro → no paramétrico, el rechazo a tratar episodios como réplicas independientes y la distinción descriptivo/inferencial siguen a Agarwal et al. (2021) sobre

evaluación robusta en RL profundo y a las recomendaciones metodológicas del Cap. III sobre Friedman/Kendall W/Wilcoxon–Holm.

1.40.2 5.8.2 Limitaciones verificadas

Semilla única (seed = 0); HAPPO con 49/50 episodios y sin KPI-gains HE; n KPI 12/5/9; impacto agregado GLOBAL desfavorable; capas B/C/D no deben mezclarse con A; TOPSIS y 4/4 no sustituyen hipótesis.

1.40.3 5.8.3 Auditoría de coherencia PG–OG–HG / PE–OE–HE

Cadena	¿Efecto respondido?	¿Mejor MADRL identificado?	Nivel
PG → OG → HG0/HG1	Sí para el trío comparable; cuatro algoritmos: incompleto	MAAC como compromiso observado; sin ganador inferencial único	INCOMPLETO
PE.1 → OE.1 → HE10/HE11	No significativo en el trío; HAPPO sin KPI-gains	MATD3 físico / MAAC gain; no inferencial	INCOMPLETO
PE.2 → OE.2 → HE20/HE21	Friedman significativo en el trío; post hoc no localiza pares	MATD3; respaldo descriptivo	INCOMPLETO
PE.3 → OE.3 → HE30/HE31	No significativo en el trío; HAPPO sin KPI-gains	MAAC; respaldo descriptivo	INCOMPLETO

El capítulo respondió los objetivos mediante C1–C5, pero la auditoría calificó el cierre como incompleto: los cuatro algoritmos cuentan con KPI físicos, resultados por edificio y actuación de recursos, mientras que la inferencia de KPI-gains solo incluye MAAC, MASAC y MATD3 y procede de una semilla. Los liderazgos por eje y global son descriptivos, salvo las diferencias omnibus delimitadas indicadas expresamente.

Catálogo breve de artefactos canónicos

Artefacto	Uso
problemas_objetivos_hipotesis/*.csv	HE/HG0 canónicos (Capa A)
best_madrl_report.json / ranking 3×3	Ranking descriptivo
kpi_recalc_20260728/tables/ranking_oe_scores.csv	Ranking 4/4
madrl_multicriteria_selection/topsis_ranking.csv	TOPSIS C* = 0,9827
district_ranking_by_scenario.csv / district_kpis_4madrl.csv	C3 distrito
building_kpis_4madrl.csv	C4 edificios
docs/AUDITORIA_CAP5_CONTRADICCIONES_STATS_2026-08-06.md	Capas y contradicciones

CAPÍTULO X. Capítulo 6. Conclusiones

1.41. 6.1 Conclusión general

La conclusión general responde al objetivo inmodificable: OG. Determinar y cuantificar los efectos diferenciales de los algoritmos HAPPO, MASAC, MATD3 y MAAC en la coordinación energética multiobjetivo de una comunidad inteligente heterogénea de Iquitos, considerando la flexibilidad energética, las emisiones de CO_2 y los costos energéticos, e identificar el algoritmo de mejor desempeño global.

El criterio C1 mostró que, frente a la línea base, las medianas globales de KPI-gain fueron −0,01226 para MAAC, −0,01951 para MASAC y −0,00694 para MATD3; los tres cambios fueron significativos después de Holm ($p = 0,00233$; $p = 0,000155$; $p = 0,00293$) y de dirección desfavorable. Por consiguiente, se cuantificó un efecto global, pero no una mejora agregada.

El criterio C2 estableció diferencias entre los algoritmos comparables: Friedman produjo $\chi^2 = 9,2911$, $p = 0,009604$ y Kendall $W = 0,1787$, tamaño de concordancia débil. Wilcoxon–Holm localizó únicamente la diferencia MAAC–MASAC (p-Holm = 0,01718); los otros pares no fueron significativos.

Los criterios C3, C4 y C5 explicaron la dirección y la relevancia energética. En C3, MATD3 lideró flexibilidad física y presentó el menor incremento de CO_2, mientras MAAC presentó el menor incremento de costo. En C4, el número de edificios favorables cambió por eje y no apareció un dominador uniforme. En C5, las diferencias de throughput BESS y éxito EV evidenciaron políticas de actuación distintas, sin que una mayor intensidad de control implicara un mejor KPI.

Como mejor compromiso global observado se identificó a MAAC por el score integrado E1–E3 de 0,9538 y la cercanía TOPSIS de 0,9827; MATD3 mantuvo el mejor valor en otra agregación 3×3 y la mejor mediana global de KPI-gain. En consecuencia, MAAC se recomendó como compromiso multicriterio descriptivo, sin afirmar superioridad global estadísticamente demostrada ni dominancia universal.

Conforme a la regla $p < 0,05$, HG0 se rechazó para el subconjunto comparable MAAC–MASAC–MATD3 y se obtuvo evidencia compatible con HG1. No obstante, el objetivo y la hipótesis completos quedaron INCOMPLETOS porque HAPPO no aportó KPI-gains finales

comparables y solo se materializó una semilla. El alcance se restringió a la comunidad simulada, al periodo 2023–2025 y a la corrida canónica auditada.

1.42. 6.2 Conclusión OE.1 (flexibilidad energética)

La primera conclusión específica responde al objetivo inmodificable: OE.1. Determinar y cuantificar los efectos diferenciales de los algoritmos HAPPO, MASAC, MATD3 y MAAC sobre la flexibilidad energética (eje E1) e identificar el algoritmo de mejor desempeño en la comunidad inteligente heterogénea de Iquitos.

En C1, las medianas de KPI-gain fueron −0,00119 para MAAC, −0,00289 para MATD3 y −0,01363 para MASAC. Solo MASAC mostró un cambio significativo frente a la línea base después de Holm (p-Holm = 0,04834), y la dirección fue desfavorable; por tanto, no se demostró una mejora significativa de flexibilidad frente al baseline.

En C2, Friedman produjo $\chi^2 = 5,5897$, $p = 0,06112$ y Kendall $W = 0,23291$; no se rechazó la igualdad en el subconjunto comparable. Ningún par de Wilcoxon–Holm fue significativo. En C3, MATD3 obtuvo el menor flex_composite distrital (1,000923), mientras MAAC alcanzó la mejor mediana de KPI-gain, lo que configuró un liderazgo descriptivo mixto.

En C4, MATD3 mejoró la flexibilidad respecto de la línea base en 5 de 17 edificios, HAPPO en 1 y MAAC y MASAC en ninguno. En C5, HAPPO presentó el mayor throughput BESS y la mayor mediana de éxito EV, pero no el mejor flex_composite; esta divergencia confirmó que la intensidad de actuación no debía confundirse con desempeño físico.

Bajo el KPI físico principal de E1 se identificó a MATD3 como el algoritmo de mejor desempeño descriptivo; MAAC conservó el liderazgo por mediana de gain. HE10 no se rechazó en MAAC–MASAC–MATD3 y HE11 no quedó respaldada en ese subconjunto. La decisión completa de cuatro algoritmos se calificó INCOMPLETA por la falta de KPI-gains de HAPPO y por la semilla única.

1.43. 6.3 Conclusión OE.2 (emisiones de CO_2)

La segunda conclusión específica responde al objetivo inmodificable: OE.2. Determinar y cuantificar los efectos diferenciales de los algoritmos HAPPO, MASAC, MATD3 y MAAC sobre las emisiones de CO_2 (eje E2) e identificar el algoritmo de mejor desempeño en la comunidad inteligente heterogénea de Iquitos.

En C1, las medianas de KPI-gain fueron negativas para MATD3 (−0,04214), MAAC (−0,04700) y MASAC (−0,05164); ninguna diferencia frente a cero permaneció significativa tras Holm (p-Holm = 0,1875). En C3, todos los ΔCO_2 distritales fueron positivos, por lo que no se calificaron como reducciones: MATD3 presentó el menor incremento (23 070 kg), seguido por MAAC (70 654 kg), MASAC (77 649 kg) y HAPPO (1 431 341 kg).

En C2, Friedman produjo $\chi^2 = 6,0000$, $p = 0,04979$ y Kendall W = 0,6000. Se rechazó la igualdad para MAAC–MASAC–MATD3, con una magnitud de concordancia moderada-alta; sin embargo, los tres post hoc Wilcoxon–Holm fueron no significativos (p-Holm = 0,3074), por lo que no se localizó un par responsable de la diferencia.

En C4, MATD3 logró reducción de CO_2 en 5 de 17 edificios, mientras HAPPO, MAAC y MASAC no registraron edificios con reducción. En C5, MATD3 combinó el menor ΔCO_2 con el menor throughput BESS del eje y una mediana de éxito EV de 0,345; el patrón se interpretó como asociación descriptiva y no como causalidad.

MATD3 fue identificado como el mejor MADRL ambiental observado por KPI-gain, ΔCO_2 y score OE2. Conforme a $p < 0,05$, HE20 se rechazó y se obtuvo evidencia compatible con HE21 en el subconjunto comparable; la ausencia de pares significativos limitó la localización del efecto. La hipótesis completa de cuatro algoritmos y el cumplimiento total de OE.2 quedaron INCOMPLETOS por la falta de HAPPO en la inferencia y por la semilla única.

1.44. 6.4 Conclusión OE.3 (costos energéticos)

La tercera conclusión específica responde al objetivo inmodificable: OE.3. Determinar y cuantificar los efectos diferenciales de los algoritmos HAPPO, MASAC, MATD3 y MAAC sobre los costos energéticos (eje E3) e identificar el algoritmo de mejor desempeño en la comunidad inteligente heterogénea de Iquitos.

En C1, las medianas de KPI-gain fueron −0,00268 para MAAC, −0,00918 para MATD3 y −0,01403 para MASAC. Ningún algoritmo mostró ahorro significativo frente a la línea base después de Holm (MAAC y MASAC p-Holm = 0,07813; MATD3 p-Holm = 0,05859), y la dirección agregada fue desfavorable.

En C2, Friedman produjo $\chi^2 = 3,4286$, $p = 0,18009$ y Kendall $W = 0,19048$; no se rechazó la igualdad y ningún post hoc fue significativo. En C3, MAAC presentó el menor Δcosto distrital (9 515 EUR), seguido por MASAC (19 793 EUR), MATD3 (44 399 EUR) y HAPPO (106 828 EUR). El menor valor observado no se interpretó como ahorro demostrado.

En C4, HAPPO mostró reducciones de costo en 12 de 17 edificios, MAAC y MASAC en 7 y MATD3 en 3; pese a ello, las medias por edificio y el resultado distrital fueron desfavorables. En C5, la actuación BESS y el éxito EV variaron ampliamente y no reprodujeron el orden del KPI de costo, lo que confirmó la necesidad de separar actividad de control y desempeño económico.

MAAC fue identificado como el mejor MADRL descriptivo en E3 por mediana de gain, Δcosto, score OE3 y TOPSIS. HE30 no se rechazó en el subconjunto comparable y HE31 no quedó respaldada. El cumplimiento total de OE.3 se calificó INCOMPLETO porque HAPPO no participó en los KPI-gains inferenciales y la campaña solo contó con una semilla.

1.45. 6.5 Contribuciones científicas

El aporte al estado del arte consistió en articular, dentro de un mismo protocolo auditable, la coordinación energética multiobjetivo, cuatro familias MADRL, una comunidad heterogénea de 17 edificios y una separación explícita entre señal de recompensa, KPI físicos y KPI-gains. Esta integración cubrió una brecha recurrente de los estudios que comparan curvas de recompensa sin demostrar su correspondencia con flexibilidad, CO_2 y costos.

El aporte metodológico fue el criterio C1–C5: efecto frente a baseline, diferencias entre algoritmos, KPI distrital, resultados de los 17 edificios y actuación de recursos controlables. La secuencia Shapiro–Wilk, Wilcoxon–Holm frente a cero, Friedman, Kendall W y Wilcoxon

pareado con Holm mantuvo la dependencia por KPI; Kruskal–Wallis y Mann–Whitney se conservaron únicamente como sensibilidad independiente.

El aporte algorítmico fue la comparación homogénea de HAPPO, MASAC, MATD3 y MAAC bajo el mismo Dec-POMDP, CTDE, comunidad, horizonte y perfiles E1–E3. Los resultados mostraron que MATD3 y MAAC ocuparon regiones distintas del compromiso multiobjetivo y que ningún mecanismo produjo dominancia universal.

El aporte energético fue cuantificar conjuntamente flexibilidad, emisiones y costos a escala distrital, por edificio y por recurso. La desagregación reveló que una mejora local no garantizó mejora comunitaria y que mayor throughput BESS o mayor éxito EV no implicaron necesariamente mejores KPI finales.

El aporte multiobjetivo fue distinguir el mejor compromiso observado de la superioridad estadística. MAAC encabezó el score integrado y TOPSIS, mientras MATD3 lideró flexibilidad física, CO_2 y otra agregación robusta; esta divergencia fue tratada como trade-off y no como contradicción que debiera ocultarse.

El aporte computacional y de reproducibilidad fue conservar la corrida madrl_v3_20260627_164047, sus configuraciones, checkpoints, series temporales, trazas, KPI distritales, KPI por edificio y manifiestos. Esta trazabilidad permitió reconstruir cada afirmación y declarar como incompleta cualquier dimensión sin evidencia comparable.

El aporte aplicado a Iquitos fue instanciar el problema en el SEAI con señales meteorológicas, tarifarias y de carbono del caso de estudio, sin generalizar la simulación a la operación real. De este modo, la contribución científica se formuló como evidencia computacional situada y reproducible, no como validación de campo.

1.46. 6.6 Limitaciones

La principal limitación fue la semilla única (seed = 0); los episodios correlacionados de una corrida no constituyeron réplicas independientes. Por ello, los p-valores y tamaños del efecto se interpretaron como evidencia intra-corrida y no como robustez multisemilla.

HAPPO conservó 50 episodios nominales mediante 49 registros históricos y un episodio post-resume, pero no dispuso de KPI-gains finales comparables. En consecuencia, la descripción física incluyó cuatro algoritmos y la inferencia principal solo tres; esta asimetría impidió cerrar literalmente HG0/HG1 y HE10–HE31 para los cuatro algoritmos.

El emparejamiento se realizó por KPI orientado (n = 12 en E1, n = 5 en E2, n = 9 en E3 y n = 26 global), no por semillas. Los bloques de KPI poseen significados físicos distintos y no sustituyen una campaña de réplicas; por ello, la prueba global se mantuvo exploratoria.

El estudio se limitó a simulación CityLearn, a 17 edificios, al periodo 2023–2025 y a la configuración de recompensas e hiperparámetros auditada. No se efectuaron pruebas fuera de muestra, HIL/SIL, piloto ni despliegue real.

Los resultados por edificio y por recurso se analizaron descriptivamente. No se efectuó una batería inferencial completa de C4 y C5, y no se atribuyó causalidad a la relación entre acciones, throughput y KPI.

Los rankings dependieron del criterio de agregación: MAAC lideró score integrado y TOPSIS, mientras MATD3 lideró otras medidas robustas y dos ejes físicos. Esta sensibilidad impidió declarar un ganador global único.

CAPÍTULO XI. Capítulo 7. Recomendaciones y trabajo futuro

1.47. 7.1 Recomendaciones estadísticas

Se recomienda completar una campaña multisemilla real (≥ 3 semillas entrenadas; idealmente el diseño n_seeds=12 ya instrumentado), tratando cada semilla como réplica experimental y no los episodios de una sola corrida.

Se recomienda aumentar el número efectivo de réplicas y estimar potencia a priori/post hoc para los contrastes Friedman y Wilcoxon–Holm, reportando intervalos de confianza y tamaños de efecto (Kendall W, Cliff’s δ) de forma sistemática en todos los ejes.

Se recomienda evaluar la robustez de HG0/HG1 y HE10–HE31 con semillas independientes, intervalos de confianza y análisis de potencia, manteniendo los KPI-gains emparejados como una capa separada de los descriptivos episódicos y de los KPI físicos.

1.48. 7.2 Recomendaciones algorítmicas

HAPPO. Bajo las condiciones experimentales estudiadas, HAPPO permanece con cobertura 49/50 y sin KPI-gains finales comparables para HE. Se recomienda homogenizar a 50 episodios i.i.d. por escenario y generar KPI-gains comparables antes de reincorporarlo a la contrastación inferencial.

MASAC. En OE.1, MASAC es el único algoritmo con impacto Holm significativo vs baseline, en dirección de deterioro. Se recomienda revisar recompensa, exploración y estabilización de políticas antes de priorizarlo para flexibilidad.

MATD3. Bajo las condiciones experimentales estudiadas, MATD3 lidera descriptivamente la flexibilidad física de distrito y el eje CO_2 (OE.2). Se recomienda conservarlo como candidato preferente cuando el criterio de selección privilegie KPIs físicos de flexibilidad/emisiones, sin interpretarlo como ganador inferencial único.

MAAC. Bajo las condiciones experimentales estudiadas, MAAC lidera descriptivamente costos (OE.3), medianas de KPI-gain en E1 y los planos TOPSIS/4/4. Se recomienda conservarlo cuando el criterio privilegie costo o score multicriterio descriptivo, sin elevarlo a HE31 ni a ganador global estadístico.

1.49. 7.3 Recomendaciones energéticas

A partir de la heterogeneidad documentada en Cap. 5 (throughput BESS, éxito EV y trade-offs por eje), se recomienda:

- BESS: calibrar señales de carga/descarga para que mayor actuación no se confunda con mejor KPI-gain. - EV / V2G: mejorar la atribución del éxito de carga EV por escenario; el perfil actual muestra fuerte heterogeneidad entre algoritmos. - Cargas controlables: mantener evaluación separada de flexibilidad de demanda respecto de storage/EV. - Carbono: reforzar señales carbon-aware coherentes con el liderazgo descriptivo de MATD3 en ΔCO_2. - Tarifas: preservar TOU explícito en el eje de costos, coherente con el liderazgo descriptivo de MAAC. - Flexibilidad: reportar de forma conjunta flex_composite físico y KPI-gains, dado el liderazgo mixto MAAC/MATD3 en OE.1.

1.50. 7.4 Validación externa

Se recomienda validar la generalización de los perfiles MATD3/MAAC/MASAC en:

- otros períodos temporales del dataset Iquitos; - condiciones climáticas distintas; - estructuras de precios y señales de carbono alternativas; - otras comunidades o tipologías de edificios; - perturbaciones de demanda, disponibilidad de DER y fallas parciales de agentes.

Toda extrapolación fuera del SEAI simulado debe tratarse como hipótesis de transferencia, no como resultado ya demostrado.

1.51. 7.5 Validación preoperacional

Se recomienda una secuencia de madurez evidencia → operación:

1. simulación canónica (ya ejecutada); 2. campaña multisemilla; 3. evaluación out-of-sample (OOS); 4. pruebas de stress (perturbaciones); 5. validación HIL/SIL cuando exista bancada; 6. piloto controlado; 7. eventual operación asistida.

Bajo las condiciones experimentales estudiadas, el estudio permanece en simulación; no se recomienda despliegue operativo directo a partir del veredicto exploratorio actual.

1.52. 7.6 Trabajo futuro

Se propone como trabajo futuro, sin afirmar resultados no obtenidos:

- Safe MADRL (restricciones de seguridad operativa y satisfacción de confort/energía); - GNN-MARL solo si se justifica por topología de red o interacciones espaciales no capturadas por el Dec-POMDP actual; - transferencia entre escenarios E1–E3 y entre comunidades; - robustez a ruido de observación y a deriva de señales precio/carbono; - generalización temporal y climática; - modelado de degradación de BESS/EV; - ampliación de V2G; - carbono dinámico de mayor resolución; - multiobjetivo adaptativo (pesos o preferencias no estacionarias) sin confundir ranking descriptivo con prueba de hipótesis.

1.53. 7.7 Recomendación algorítmica final

Bajo las condiciones experimentales estudiadas:

Eje	Recomendación descriptiva	Alcance
E1 (flexibilidad)	MATD3 (KPI físico / flex de distrito) / MAAC (KPI-gain)	Liderazgo descriptivo únicamente
E2 (CO_2)	MATD3	Liderazgo descriptivo únicamente
E3 (costos)	MAAC	Liderazgo descriptivo únicamente
Compromiso global	Reportar ambos: MATD3 (best_madrl 0,6667) y MAAC (TOPSIS C* = 0,9827 / evaluate_v2 4/4)	Sin ganador estadístico único

Bajo las condiciones experimentales estudiadas, se recomienda MATD3 para E1 cuando el criterio principal sea la flexibilidad física distrital; MATD3 para E2 por presentar el menor incremento de CO_2; MAAC para E3 por registrar el menor incremento de costo; y MAAC como mejor compromiso global observado por score integrado y TOPSIS. Estas recomendaciones son descriptivas, no constituyen superioridad universal y deberán revalidarse con HAPPO comparable y múltiples semillas.

1.54. 7.8 Matriz final de alineamiento y auditoría

La matriz verifica la correspondencia PG–OG–HG y PE–OE–HE con los mecanismos del Capítulo IV, los resultados C1–C5 del Capítulo V, las conclusiones del Capítulo VI y las recomendaciones del Capítulo VII. El estado INCOMPLETO señala una limitación de evidencia y no una reformulación de los elementos definitivos.

Tabla 7.8

Matriz final de alineamiento y auditoría de objetivos

roblema	bjetivo	ipótesis	esarroll o Cap. IV	PI	esultado descripti vo	rueba inferenci al		amaño del efecto	ejor MADRL	onclusió n	ecomen dación	stado
G. ¿En qué medida los algoritmos HAPPO, MASAC, MATD3 y MAAC producen efectos diferenciales en la coordinación energética multiobjetivo de una comunidad inteligente heterogénea de Iquitos, considerando la flexibilidad energética, las emisiones de CO_2 y los costos energéticos, y cuál presenta el mejor desempeño global?	G. Determinar y cuantificar los efectos diferenciales de los algoritmos HAPPO, MASAC, MATD3 y MAAC en la coordinación energética multiobjetivo de una comunidad inteligente heterogénea de Iquitos, considerando la flexibilidad energética, las emisiones de CO_2 y los costos energéticos, e identificar el algoritmo de mejor desempeño global.	G0. Los algoritmos HAPPO, MASAC, MATD3 y MAAC no producen efectos diferenciales estadísticamente significativos en la coordinación energética multiobjetivo de la comunidad inteligente heterogénea de Iquitos, considerando conjuntamente la flexibilidad energética, las emisiones de CO_2 y los costos energéticos. HG1. Al menos uno de los algoritmos HAPPO, MASAC, MATD3 y MAAC produce un efecto diferencial estadísticam	.1–4.15: arquitectura, comunidad, Dec-POMDP, CTDE, 4×3, evaluación y trazabilidad E1+E2+E3.	6 KPI-gains globales por algoritmo comparable; flex_compos ite, ΔCO_2 y Δcosto.	edianas: MAAC −0,01226; MASAC −0,01951; MATD3 −0,00694. Score integrado: MAAC 0,9538.	riedman pareado por KPI + Kendall W; Wilcoxon–Holm.	,009604	= 0,1787 (débil)	AAC, compromiso observado; sin ganador inferencial único.	e rechaza HG0 en el trío comparable; no se cierra la hipótesis literal de cuatro algoritmos.	ompletar HAPPO comparable y campaña multisemilla; revalidar ranking.	NCOMPLETO

roblema	bjetivo	ipótesis	esarroll o Cap. IV	PI	esultado descripti vo	rueba inferenci al		amaño del efecto	ejor MADRL	onclusió n	ecomen dación	stado
		ente significativo en la coordinación energética multiobjetivo de la comunidad inteligente heterogénea de Iquitos, considerando conjuntamente la flexibilidad energética, las emisiones de CO_2 y los costos energéticos.										
E.1. ¿En qué medida los algoritmos HAPPO, MASAC, MATD3 y MAAC producen efectos diferenciales sobre la flexibilidad energética (eje E1) y cuál presenta el mejor desempeño en la comunidad inteligente heterogénea de Iquitos?	E.1. Determinar y cuantificar los efectos diferenciales de los algoritmos HAPPO, MASAC, MATD3 y MAAC sobre la flexibilidad energética (eje E1) e identificar el algoritmo de mejor desempeño en la comunidad inteligente heterogénea de Iquitos.	E10. Los algoritmos HAPPO, MASAC, MATD3 y MAAC no producen efectos diferenciales estadísticamente significativos sobre la flexibilidad energética (eje E1) de la comunidad inteligente heterogénea de Iquitos. HE11. Al menos uno de los algoritmos HAPPO, MASAC, MATD3 y MAAC produce un efecto diferencial estadísticamente significativo sobre la flexibilidad energética (eje E1) de la comunidad inteligente heterogénea de Iquitos.	.9 E1; 4.10 tratamiento E1; 4.12 KPI; 4.15 corresponde ncia OE.1–E1.	2 KPI-gains; flex_composite; flex_gain por 17 edificios; BESS/EV/cargas.	ATD3 flex_composite 1,000923 y 5/17 edificios favorables; MAAC mediana gain −0,00119.	riedman pareado; Wilcoxon–Holm; Wilcoxon vs baseline.	,061123	= 0,2329 (débil)	ATD3 por KPI físico; MAAC por mediana gain.	o se rechaza HE10 en el trío; liderazgo descriptivo mixto.	riorizar MATD3 para flexibilidad física y repetir con semillas/HAPPO.	NCOMPLETO
E.2. ¿En qué medida los algoritmos HAPPO, MASAC, MATD3 y MAAC producen efectos diferenciales sobre las emisiones de CO_2 (eje E2) y cuál presenta el mejor desempeño en la comunidad inteligente heterogénea	E.2. Determinar y cuantificar los efectos diferenciales de los algoritmos HAPPO, MASAC, MATD3 y MAAC sobre las emisiones de CO_2 (eje E2) e identificar el algoritmo de mejor desempeño en la comunidad inteligente	E20. Los algoritmos HAPPO, MASAC, MATD3 y MAAC no producen efectos diferenciales estadísticamente significativos sobre las emisiones de CO_2 (eje E2) de la comunidad inteligente heterogénea de Iquitos. HE21. Al menos uno	.9 E2; 4.10 tratamiento E2; 4.12 KPI; 4.15 corresponde ncia OE.2–E2.	KPI-gains; ΔCO_2 distrital y por 17 edificios; BESS/EV/cargas.	ATD3 ΔCO_2 23 070 kg y 5/17 edificios con reducción; los Δ distritales fueron positivos.	riedman pareado; Wilcoxon–Holm; Wilcoxon vs baseline.	,049787	= 0,6000	ATD3, descriptivo.	e rechaza HE20 en el trío; post hoc no localiza pares; hipótesis de cuatro algoritmos incompleta.	evalidar MATD3 con HAPPO comparable, semillas e intervalos de confianza.	NCOMPLETO

roblema	bjetivo	ipótesis	esarrollo Cap. IV	PI	esultado descriptivo	rueba inferencial		amaño del efecto	ejor MADRL	onclusión	ecomendación	stado
de Iquitos?	heterogénea de Iquitos.	de los algoritmos HAPPO, MASAC, MATD3 y MAAC produce un efecto diferencial estadísticamente significativo sobre las emisiones de CO_2 (eje E2) de la comunidad inteligente heterogénea de Iquitos.										
E.3. ¿En qué medida los algoritmos HAPPO, MASAC, MATD3 y MAAC producen efectos diferenciales sobre los costos energéticos (eje E3) y cuál presenta el mejor desempeño en la comunidad inteligente heterogénea de Iquitos?	E.3. Determinar y cuantificar los efectos diferenciales de los algoritmos HAPPO, MASAC, MATD3 y MAAC sobre los costos energéticos (eje E3) e identificar el algoritmo de mejor desempeño en la comunidad inteligente heterogénea de Iquitos.	E30. Los algoritmos HAPPO, MASAC, MATD3 y MAAC no producen efectos diferenciales estadísticamente significativos sobre los costos energéticos (eje E3) de la comunidad inteligente heterogénea de Iquitos. HE31. Al menos uno de los algoritmos HAPPO, MASAC, MATD3 y MAAC produce un efecto diferencial estadísticamente significativo sobre los costos energéticos (eje E3) de la comunidad inteligente heterogénea de Iquitos.	.9 E3; 4.10 tratamiento E3; 4.12 KPI; 4.15 correspondencia OE.3–E3.	KPI-gains; Δcosto distrital y por 17 edificios; BESS/EV/cargas.	AAC Δcosto 9 515 EUR y mediana gain −0,00268; no hubo ahorro distrital demostrado.	riedman pareado; Wilcoxon–Holm; Wilcoxon vs baseline.	,180092	= 0,1905 (débil)	AAC, descriptivo.	o se rechaza HE30 en el trío; el menor costo observado no equivale a ahorro demostrado.	riorizar MAAC para costo observado y repetir con semillas/HAPPO.	NCOMPLETO

Nota. Los p-valores principales corresponden a Friedman sobre KPI-gains emparejados por indicador. HAPPO participa en C3–C5, pero no en la inferencia C1–C2 por ausencia de KPI-gains finales comparables. Fuente: elaboración propia a partir de la corrida madrl_v3_20260627_164047 y sus artefactos canónicos.

Referencias bibliográficas

Las referencias se presentan en una única lista, ordenada alfabéticamente y conforme a APA 7.ª edición. Se conservaron únicamente las fuentes citadas o utilizadas en el documento;

las entradas repetidas, las versiones bibliográficas incompatibles y los subtítulos complementarios fueron eliminados.

Abels, A., Roijers, D., Lenaerts, T., Nowe, A., & Steckelmacher, D. (2019). Dynamic weights in multi-objective deep reinforcement learning. En Proceedings of the 36th International Conference on Machine Learning (PMLR 97, pp. 11-20). https://arxiv.org/abs/1809.07803

Agarwal, R., Schwarzer, M., Castro, P. S., Courville, A., & Bellemare, M. G. (2021). Deep reinforcement learning at the edge of the statistical precipice. En Advances in Neural Information Processing Systems, 34, 29304-29320. https://arxiv.org/abs/2108.13264

Akiba, T., Sano, S., Yanase, T., Ohta, T., & Koyama, M. (2019). Optuna: A next-generation hyperparameter optimization framework. En Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining (pp. 2623–2631). ACM. https://doi.org/10.1145/3292500.3330701

Antonanzas, J., Osorio, N., Escobar, R., Urraca, R., Martinez-de-Pison, F. J., & Antonanzas-Torres, F. (2021). Review of photovoltaic power forecasting. Solar Energy, 136, 78–111. https://doi.org/10.1016/j.solener.2016.06.069

Atrazhev, P. (2023). Multi-agent deep reinforcement learning for autonomous energy coordination in demand response methods for residential distribution networks [Master's thesis, University of Alberta].

Cao, J., Yu, T., Guo, H., & Cao, H. (2023). Grid carbon intensity forecasting for building energy management. IEEE Transactions on Smart Grid, 14(4), 2891–2903. https://doi.org/10.1109/TSG.2022.3228223

Chen, L., He, H., Jing, R., Xie, M., & Ye, K. (2024). Energy management in integrated energy system with electric vehicles as mobile energy storage: An approach using bi-level deep reinforcement learning. Energy, 307. https://doi.org/10.1016/j.energy.2024.132599

Chen, P. (2024). Multi-agent robust deep reinforcement learning for voltage and frequency control in electrical distribution systems with high penetration of PVs and BESSs [Tesis de PhD, Carleton University].

Chevarria Moscoso, M. (2024). Análisis de la generación hidroeléctrica en la central hidroeléctrica de Machupicchu aplicando métodos estocásticos y modelo de optimización

[Tesis, Universidad Nacional de Ingeniería]. Repositorio Institucional UNI. http://hdl.handle.net/20.500.14076/28894

Colas, C., Sigaud, O., & Oudeyer, P.-Y. (2019). A hitchhiker's guide to statistical comparisons of reinforcement learning algorithms. arXiv. https://arxiv.org/abs/1904.06979

Creswell, J. W., & Creswell, J. D. (2023). Research design: Qualitative, quantitative, and mixed methods approaches (6th ed.). SAGE Publications.

Dang, T., Zheng, Y., Yao, L., Li, Z., Gong, D., & Zhu, F. (2023). Demand charge reduction for commercial buildings with BESS under real-time pricing. Applied Energy, 330, 120318. https://doi.org/10.1016/j.apenergy.2022.120318

Demsar, J. (2006). Statistical comparisons of classifiers over multiple data sets. Journal of Machine Learning Research, 7, 1-30.

Dunn, O. J. (1964). Multiple comparisons using rank sums. Technometrics, 6(3), 241-252. https://doi.org/10.1080/00401706.1964.10490181

Electro Oriente S.A. (2023-2025). Facturas mensuales de edificios institucionales del SEAI Iquitos. Loreto, Peru.

Fang, X., Zhao, Q., Wang, J., Han, Y., & Li, Y. (2021). Multi-agent deep reinforcement learning for distributed energy management and strategy optimization of microgrid market. Sustainable Cities and Society, 74, 103163. https://doi.org/10.1016/j.scs.2021.103163

Felicetti, R., Iarlori, S., Monteriù, A., et al. (2024). Peak shaving and self-consumption maximization in home energy management systems: A combined integer programming and reinforcement learning approach. Computers & Electrical Engineering, 117, 109217. https://doi.org/10.1016/j.compeleceng.2024.109217

Felten, F., Talbi, E.-G., & Danoy, G. (2024). Multi-objective reinforcement learning based on decomposition: A taxonomy and framework. Journal of Artificial Intelligence Research, 79. https://arxiv.org/abs/2311.12495

Fonseca, T., Ferreira, L., Cabral, B., Severino, R., Nweye, K., Ghose, D., & Nagy, Z. (2024). EVLearn: Extending the CityLearn framework with electric vehicle simulation. arXiv. https://arxiv.org/abs/2404.06521

Fujimoto, S., van Hoof, H., & Meger, D. (2018). Addressing function approximation error in actor-critic methods (TD3). En Proceedings of the 35th International Conference on Machine Learning (PMLR 80, pp. 1587-1596). https://arxiv.org/abs/1802.09477

Gao, J., Li, Y., Wang, B., & Wu, H. (2023). Multi-microgrid collaborative optimization scheduling using an improved multi-agent soft actor-critic algorithm. Energies, 16(7), 3248. https://doi.org/10.3390/en16073248

Haarnoja, T., Zhou, A., Abbeel, P., & Levine, S. (2018). Soft Actor-Critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor. En Proceedings of the 35th International Conference on Machine Learning (PMLR 80, pp. 1861–1870). https://proceedings.mlr.press/v80/haarnoja18b.html

Henderson, P., Islam, R., Bachman, P., Pineau, J., Precup, D., & Meger, D. (2018). Deep reinforcement learning that matters. Proceedings of the AAAI Conference on Artificial Intelligence, 32(1). https://doi.org/10.1609/aaai.v32i1.11694

Hernández-Sampieri, R., & Mendoza, C. P. (2018). Metodología de la investigación: Las rutas cuantitativa, cualitativa y mixta. McGraw-Hill Education.

Hribar, J., Mohorčič, M., & Čampa, A. (2025). Improving energy autonomy of positive energy districts using multi-agent deep reinforcement learning. Scientific Reports, 15, 27798. https://doi.org/10.1038/s41598-025-12554-x

Hu, S., Zhong, Y., Gao, M., Wang, W., Dong, H., Liang, X., Li, Z., Chang, X., & Yang, Y. (2023). MARLlib: A scalable and efficient multi-agent reinforcement learning library. Journal of Machine Learning Research, 24(315), 1–23. https://www.jmlr.org/papers/v24/23-0378.html

International Electrotechnical Commission. (2021). IEC 61215-1:2021 — Terrestrial photovoltaic (PV) modules — Design qualification and type approval. IEC.

Iqbal, S., & Sha, F. (2019). Actor-Attention-Critic for multi-agent reinforcement learning. En Proceedings of the 36th International Conference on Machine Learning (PMLR 97, pp. 2961–2970). https://proceedings.mlr.press/v97/iqbal19a.html

Kathirgamanathan, A., Twardowski, K., Mangina, E., & Finn, D. P. (2020). A centralised soft actor critic deep reinforcement learning approach to district demand side management through CityLearn. En Proceedings of the 1st International Workshop on Reinforcement Learning for Energy Management in Buildings & Cities (RLEM 2020). ACM. https://doi.org/10.1145/3427773.3427869

Kuba, J. G., Chen, R., Wen, M., Wen, Y., Sun, F., Wang, J., & Yang, Y. (2021). Trust región policy optimisation in multi-agent reinforcement learning. arXiv. https://arxiv.org/abs/2109.11251

Li, Y., Wu, J., & Pan, Y. (2024). Deep reinforcement learning for online scheduling of photovoltaic systems with battery energy storage systems. Intelligent and Converged Networks, 5(1), 28–41. https://doi.org/10.23919/ICN.2024.0003

Liu, Y., Zhang, Q., & Guo, Y. (2022). Multi-agent deep reinforcement learning for building energy system with renewable energy. Applied Energy, 313, 118703. https://doi.org/10.1016/j.apenergy.2022.118703

Lowe, R., Wu, Y., Tamar, A., Harb, J., Abbeel, P., & Mordatch, I. (2017). Multi-agent actor-critic for mixed cooperative-competitive environments. En Advances in Neural Information Processing Systems 30 (pp. 6382–6393). https://proceedings.neurips.cc/paper/2017/hash/68a9750337a418a86fe06c1991a1d64c-Abstract.html

Lund, H., Østergaard, P. A., Connolly, D., & Mathiesen, B. V. (2017). Smart energy and smart energy systems. Energy, 137, 556–565. https://doi.org/10.1016/j.energy.2016.12.003

Ma, Q., Ye, Y., Liu, Z., Liu, X., & Strbac, G. (2025). Carbon cap based multi-energy sharing among heterogeneous microgrids using multi-agent safe reinforcement learning method with credit assignment and sequential update. Applied Energy, 393, 126018. https://doi.org/10.1016/j.apenergy.2025.126018

Ministerio del Ambiente del Perú [MINAM]. (2019). INFOCARBONO — RAGEI 2019 Energía. https://infocarbono.minam.gob.pe/

Montgomery, D. C. (2019). Design and analysis of experiments (10th ed.). Wiley.

Naumann, M., Schimpe, M., Keil, P., Hesse, H. C., & Jossen, A. (2021). Analysis and modeling of calendar aging of a commercial LiFePO4/graphite cell. Journal of Energy Storage, 36, 102160. https://doi.org/10.1016/j.est.2021.102160

Nweye, K. E. (2024). Data-driven modeling and control of grid-interactive communities [Tesis de PhD, The University of Texas at Austin].

Nweye, K., Kaspar, K., Buscemi, G., Fonseca, T., Pinto, G., Ghose, D., Duddukuru, S., Pratapa, P., Li, H., Mohammadi, J., Ferreira, L. L., Hong, T., Ouf, M., Capozzoli, A., & Nagy, Z. (2024). CityLearn v2: Energy-flexible, resilient, occupant-centric, and carbon-aware management of grid-interactive communities. Journal of Building Performance Simulation. https://doi.org/10.1080/19401493.2024.2418813

Nweye, K., et al. (2023b). Heterogeneous multi-agent reinforcement learning for grid-interactive communities. En Proceedings of the 10th ACM International Conference on Systems for Energy-Efficient Buildings, Cities, and Transportation. ACM. https://doi.org/10.1145/3600100.3626276

Nweye, K., Kaspar, K., Buscemi, G., Pinto, G., Li, H., Hong, T., Ouf, M., Capozzoli, A., & Nagy, Z. (2023c). CityLearn v2: An OpenAI Gym environment for demand response control benchmarking in grid-interactive communities. En Proceedings of the 10th ACM International Conference on Systems for Energy-Efficient Buildings, Cities, and Transportation (BuildSys '23). ACM. https://doi.org/10.1145/3600100.3626257

Nweye, K., Sankaranarayanan, S., & Nagy, Z. (2023a). MERLIN: Multi-agent offline and transfer learning for occupant-centric operation of grid-interactive communities. Applied Energy. https://arxiv.org/abs/2301.01148

Nweye, K., Liu, B., Stone, P., & Nagy, Z. (2022). Real-world challenges for multi-agent reinforcement learning in grid-interactive buildings. Energy and AI. https://doi.org/10.1016/j.egyai.2022.100202

Oliehoek, F. A., & Amato, C. (2016). A concise introduction to decentralized POMDPs. Springer. https://doi.org/10.1007/978-3-319-28929-8

Oliehoek, F. A., Spaan, M. T. J., Amato, C., & Whiteson, S. (2013). Incremental clustering and expansion for faster optimal planning in Dec-POMDPs. Journal of Artificial Intelligence Research, 46, 449–509. https://doi.org/10.1613/jair.3745

Organismo Supervisor de la Inversión en Energía y Minería [OSINERGMIN]. (2024). Resolución de Consejo Directivo N.° 0024-2024-OS/CD — Tarifas de Distribución Eléctrica MT-3/MT-4, Electro Oriente S.A.

Patterson, A., Neumann, S., White, M., & White, A. (2024). Empirical design in reinforcement learning. Journal of Machine Learning Research, 25. https://arxiv.org/abs/2304.01315

Peñalva Sánchez, J. J. (2024). Optimización de un sistema fotovoltaico híbrido y la predicción de la demanda energética y variables climáticas utilizando la inteligencia artificial [Tesis, Universidad Nacional de Ingeniería]. Repositorio Institucional UNI. http://hdl.handle.net/20.500.14076/27731

Rajagopalan, A., Dhiman, G., Soni, B., Alzahrani, A., & Almutairi, K. (2024). Capacity fade modeling of LiFePO4 battery for grid storage applications. Applied Energy, 358, 122547. https://doi.org/10.1016/j.apenergy.2023.122547

Ren, J., Gao, H., Wang, S., Zhao, L., Kang, Q., Ashan, A., Sun, Y., & Xiao, G. (2025). Multi-agent reinforcement learning-based joint design of low-carbon P2P market and bidding strategy in microgrids. arXiv. https://arxiv.org/abs/2604.02728

Reniers, J. M., Mulder, G., & Howey, D. A. (2022). Improving optimal control of grid-connected lithium-ion batteries through more accurate battery and degradation modelling. Journal of Power Sources, 542, 231776. https://doi.org/10.1016/j.jpowsour.2022.231776

Rezazadeh, F., & Bartzoudis, D. (2022). A federated DRL approach for smart micro-grid energy control with distributed energy resources. En 2022 IEEE International Workshop on Computer Aided Modeling and Design of Communication Links and Networks (CAMAD 2022). IEEE. https://arxiv.org/abs/2211.03430

Roijers, D. M., Vamplew, P., Whiteson, S., & Dazeley, R. (2013). A survey of multi-objective sequential decisión-making. Journal of Artificial Intelligence Research, 47, 67-113.

Rosero Bernal, D. G. (2022). Modelo de un sistema de administración de energía autónomo operado desde la nube para optimizar la gestión de un grupo de microrredes [Tesis, Universidad Distrital Francisco José de Caldas]. Dialnet. https://dialnet.unirioja.es/servlet/tesis?codigo=347742

Sarkar, S., Naug, A., Luna, R., Guillen, A., Gundecha, V., Ghorbanpour, S., Mousavi, S., Markovikj, D., & Babu, A. R. (2024). Carbon footprint reduction for sustainable data centers in real-time. En Proceedings of the AAAI Conference on Artificial Intelligence, 38. https://arxiv.org/abs/2403.14092

Shadish, W. R., Cook, T. D., & Campbell, D. T. (2002). Experimental and quasi-experimental designs for generalized causal inference. Houghton Mifflin.

Shojaeighadikolaei, A., Ghasemi, A., Jones, K., Dafalla, Y., Bardas, A. G., Ahmadi, R., & Hashemi, M. (2022). Distributed energy management and demand response in smart grids: A multi-agent deep reinforcement learning framework. arXiv. https://arxiv.org/abs/2211.15858

Shojaeighadikolaei, A., Talata, Z., & Hashemi, M. (2024). Centralized vs. decentralized multi-agent reinforcement learning for enhanced control of electric vehicle charging networks. arXiv. https://arxiv.org/abs/2404.12520

Silvestri, A. (2024). Reinforcement learning control for energy efficient buildings [Tesis de PhD, ETH Zurich]. https://doi.org/10.3929/ethz-b-000674480

Sutton, R. S., & Barto, A. G. (2018). Reinforcement learning: An introduction (2.ª ed.). MIT Press.

Tamoor, M., Bhatti, A. R., Butt, A. D., Bhatti, K. L., Miran, S., Hussain, M. I., Abubakar, M., & Imran, M. (2022). Temperature-dependent performance analysis of PV systems in tropical climates. Energy Reports, 8, 5447–5458. https://doi.org/10.1016/j.egyr.2022.04.015

Tranberg, B., Corradi, O., Lajoie, B., Gibon, T., Staffell, I., & Andresen, G. B. (2020). Real-time carbon accounting method for the European electricity markets. Energy Strategy Reviews, 26, 100399. https://doi.org/10.1016/j.esr.2019.100399

Vázquez-Canteli, J. R., Dey, S., Henze, G., & Nagy, Z. (2020). CityLearn: Standardizing research in multi-agent reinforcement learning for demand response and urban energy management. arXiv. https://arxiv.org/abs/2012.10504

Vázquez-Canteli, J. R., & Nagy, Z. (2019a). CityLearn v1.0: An OpenAI Gym environment for demand response with deep reinforcement learning. En Proceedings of the 6th ACM International Conference on Systems for Energy-Efficient Buildings, Cities, and Transportation (pp. 356–357). ACM. https://doi.org/10.1145/3360322.3360998

Wang, R. (2024). Real-time regulation for power system operational security enhancement using deep reinforcement learning [Tesis de PhD, The Hong Kong Polytechnic University].

Wu, J. (2024). Energy management system for renewable energy sources integrated microgrids [Tesis de PhD, Aalborg University]. https://doi.org/10.54337/aau743307355

Wu, J., Wang, Z., Han, J., Li, Q., Sun, R., Li, C., Cheng, Y., Zhou, B., Guo, J., & Long, B. (2025). A novel data-driven multi-agent reinforcement learning approach for voltage control under weak grid support. Sensors, 25(23), 7399. https://doi.org/10.3390/s25237399

Xie, J., Ajagekar, A., & You, F. (2023). Multi-agent attention-based deep reinforcement learning for demand response in grid-responsive buildings. Applied Energy, 342, 121213. https://doi.org/10.1016/j.apenergy.2023.121213

Xiong, S., Liu, D., Chen, Y., & Zhang, Y. (2024). A deep reinforcement learning approach based energy management strategy for home energy system considering the time-of-use

price and real-time control of energy storage system. Energy Reports, 11, 3501–3508. https://doi.org/10.1016/j.egyr.2024.001501

Xu, B., Oudalov, A., Ulbig, A., Andersson, G., & Kirschen, D. S. (2021). Modeling of lithium-ion battery degradation for cell life assessment. IEEE Transactions on Smart Grid, 12(3), 2192–2202. https://doi.org/10.1109/TSG.2017.2701083

Yao, Y., Wang, X., & Sun, J. (2023). Multi-agent reinforcement learning for smart community energy management. Energies, 17(20), 5211. https://doi.org/10.3390/en17205211

Ye, T., Huang, Y., Yang, W., Cai, G., Yang, Y., & Pan, F. (2025). Safe multi-agent deep reinforcement learning for decentralized low-carbon operation in active distribution networks and multi-microgrids. Applied Energy, 387. https://doi.org/10.1016/j.apenergy.2025.125339

Zhang, B. (2024). Modelling and optimization of multi-energy systems operation based on deep reinforcement learning [Tesis de PhD, Aalborg University]. https://doi.org/10.54337/aau763295893

Zhang, Y., Chen, X., Gu, Y., Li, Z., & Kai, W. (2023). Deep reinforcement learning-based battery conditioning hierarchical V2G coordination for multi-stakeholder benefits. arXiv. https://arxiv.org/abs/2308.00218

Zhong, Y., Kuba, J. G., Feng, X., Hu, S., Ji, J., & Yang, Y. (2024). Heterogeneous-agent reinforcement learning. Journal of Machine Learning Research, 25(32), 1–67. https://jmlr.org/papers/v25/23-0488.html

Zhou, M., Wan, J., Wang, H., et al. (2021). MALib: A parallel framework for population-based multi-agent reinforcement learning. Journal of Machine Learning Research, 24(1). https://arxiv.org/abs/2106.07551

Anexo A. Auditoría cuantitativa de los resultados reales de 50 episodios

Fuente única: https://drive.google.com/drive/folders/1ihH6RqL2KpevfCQEUXj7PP1aS2QYssAX, corrida madrl_v3_20260627_164047. La auditoría contabiliza 12 tratamientos, 600 episodios, 668 KPI distritales, 15.300 KPI por edificio y 204 resúmenes de comportamiento. No se inventaron valores ni se imputaron episodios.

A.1 Matriz de magnitudes primarias

Tabla A.1. Valores primarios completos por objetivo y algoritmo

Objetivo	Escenario	Algoritmo	Métrica	Baseline	Control	Δ	Efecto
E1	1	HAPPO	flexibility_composite	1,0000	1,1105	0,1105	-11,0541 %
E1	1	MAAC	flexibility_composite	1,0000	1,0124	0,0124	-1,2426 %
E1	1	MASAC	flexibility_composite	1,0000	1,0286	0,0286	-2,8553 %
E1	1	MATD3	flexibility_composite	1,0000	1,0009	0,0009	-0,0923 %
E2	2	HAPPO	carbon_emissions_total	9.144.881,2421	11.999.741,1091	2.854.859,8670	-31,2181 %
E2	2	MAAC	carbon_emissions_total	10.417.831,7705	10.558.754,0195	140.922,2490	-1,3527 %
E2	2	MASAC	carbon_emissions_total	9.088.297,6823	9.243.171,2982	154.873,6159	-1,7041 %
E2	2	MATD3	carbon_emissions_total	10.973.717,9654	11.019.732,7202	46.014,7548	-0,4193 %
E3	3	HAPPO	electricity_cost_total	7.155.283,9263	7.368.356,0819	213.072,1556	-2,9778 %
E3	3	MAAC	electricity_cost_total	7.093.803,1979	7.112.781,5002	18.978,3023	-0,2675 %
E3	3	MASAC	electricity_cost_total	7.106.081,2740	7.145.558,6895	39.477,4155	-0,5555 %
E3	3	MATD3	electricity_cost_total	9.646.089,5160	9.734.645,5970	88.556,0810	-0,9181 %

Nota. En OE.1 el baseline es 1 y el control es el compuesto de los tres ratios de flexibilidad.

A.2 Cobertura de matrices completas

Tabla A.2. Inventario numérico completo generado

Matriz	Filas/valores	Contenido
episode_metrics_50.csv	600 filas	Episodios 0–49 de 12 tratamientos

Matriz	Filas/valores	Contenido
district_all_kpis_long.csv	668 valores	KPI distritales disponibles
objective_all_kpis_numeric.csv	648 valores	KPI clasificados OE1–OE3
objective_target_scenario_kpis_numeric.csv	216 valores	E1/OE1, E2/OE2 y E3/OE3
objective_comparable_kpi_gains.csv	104 valores	Ganancias con baseline comparable
building_kpis_raw.csv	15.300 valores	75 KPI × 17 edificios × 12 tratamientos
building_behavior_raw.csv	204 filas	17 edificios × 12 tratamientos

Nota. Las matrices se encuentran en outputs/madrl_v3_20260627_164047/resumen_comparativo/estadistica/analisis_cuantitativo_completo_50_episodios.

A.3 Archivos de reproducibilidad estadística

outputs\madrl_v3_20260627_164047\resumen_comparativo\estadistica\analisis_cuantitativo_completo_50_episodios\complete_quantitative_audit.json

outputs\madrl_v3_20260627_164047\resumen_comparativo\estadistica\analisis_cuantitativo_completo_50_episodios\complete_quantitative_report.md

outputs\madrl_v3_20260627_164047\resumen_comparativo\estadistica\analisis_cuantitativo_completo_50_episodios\run_coverage_quantitative.csv

outputs\madrl_v3_20260627_164047\resumen_comparativo\estadistica\analisis_cuantitativo_completo_50_episodios\episode_descriptive_50.csv

outputs\madrl_v3_20260627_164047\resumen_comparativo\estadistica\analisis_cuantitativo_completo_50_episodios\primary_objective_values.csv

outputs\madrl_v3_20260627_164047\resumen_comparativo\estadistica\analisis_cuantitativo_completo_50_episodios\objective_effect_descriptive.csv

outputs\madrl_v3_20260627_164047\resumen_comparativo\estadistica\analisis_cuantitativo_completo_50_episodios\objective_impact_wilcoxon_holm.csv

outputs\madrl_v3_20260627_164047\resumen_comparativo\estadistica\analisis_cuantitativo_completo_50_episodios\objective_friedman_posthoc_holm.csv

outputs\madrl_v3_20260627_164047\resumen_comparativo\estadistica\analisis_cuantitativo_completo_50_episodios\global_ranking_topsis.csv

outputs\madrl_v3_20260627_164047\resumen_comparativo\estadistica\analisis_cuantitativo_completo_50_episodios\hypothesis_decisions_quantitative.csv

outputs\madrl_v3_20260627_164047\resumen_comparativo\estadistica\analisis_cuantitativo_completo_50_episodios\stored_delta_consistency_audit.csv

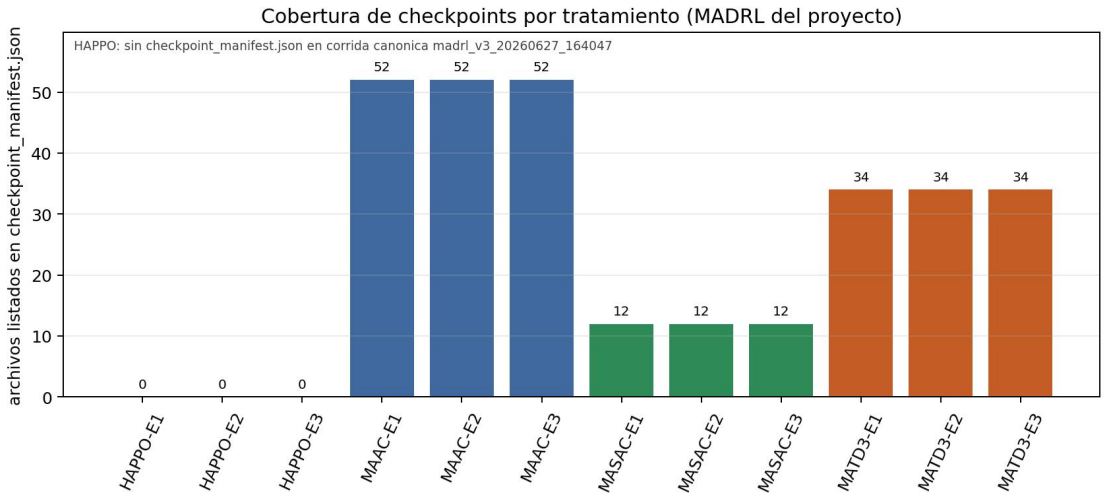
El script de cálculo es tools\run_complete_drive_kpi_objective_analysis.py y el script de integración documental es tools\update_word_quantitative_50episodes.py.

A.4 Evidencia gráfica conservada para trazabilidad

Las figuras siguientes proceden del documento maestro y se conservan para no perder la trazabilidad visual de la ejecución, los equipos y los resultados. Tienen carácter descriptivo o histórico. Cuando una figura muestre la cobertura previa de HAPPO, campos delta almacenados o pruebas inferenciales anteriores, prevalecen los valores recalculados de las Tablas 5.1–5.11 y A.1–A.2.

Figura A.1

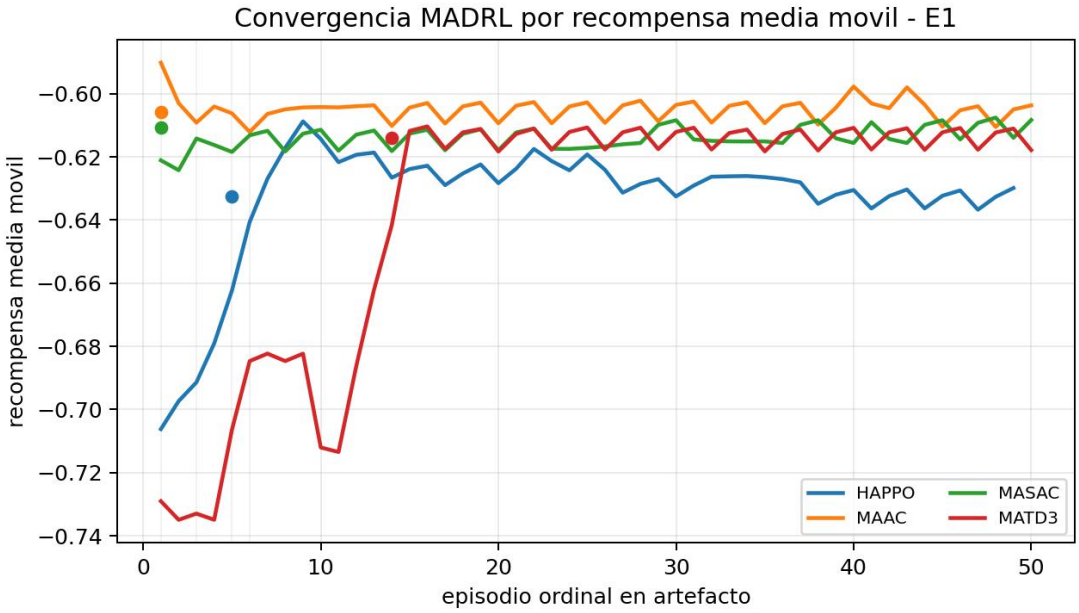
Cobertura de checkpoints por tratamiento



Nota. Evidencia gráfica conservada del documento maestro para trazabilidad. No sustituye los valores cuantitativos recalculados ni la decisión estadística final. Fuente: artefactos originales de la corrida canónica.

Figura A.2

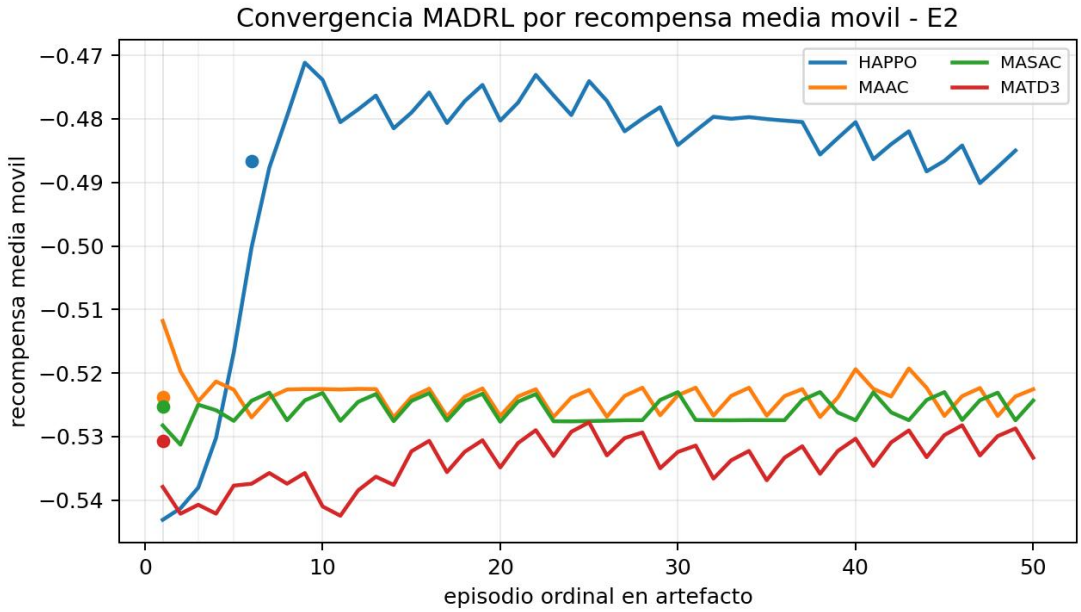
3-E1. Curva de convergencia por recompensa media móvil en E1



Nota. Evidencia gráfica conservada del documento maestro para trazabilidad. No sustituye los valores cuantitativos recalculados ni la decisión estadística final. Fuente: artefactos originales de la corrida canónica.

Figura A.3

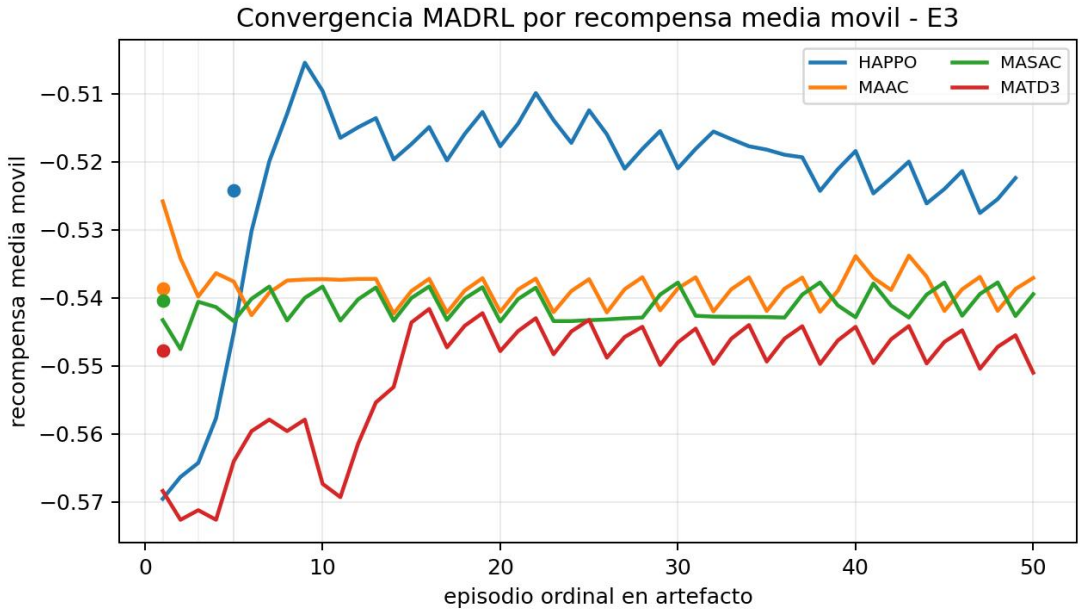
3-E2. Curva de convergencia por recompensa media móvil en E2



Nota. Evidencia gráfica conservada del documento maestro para trazabilidad. No sustituye los valores cuantitativos recalculados ni la decisión estadística final. Fuente: artefactos originales de la corrida canónica.

Figura A.4

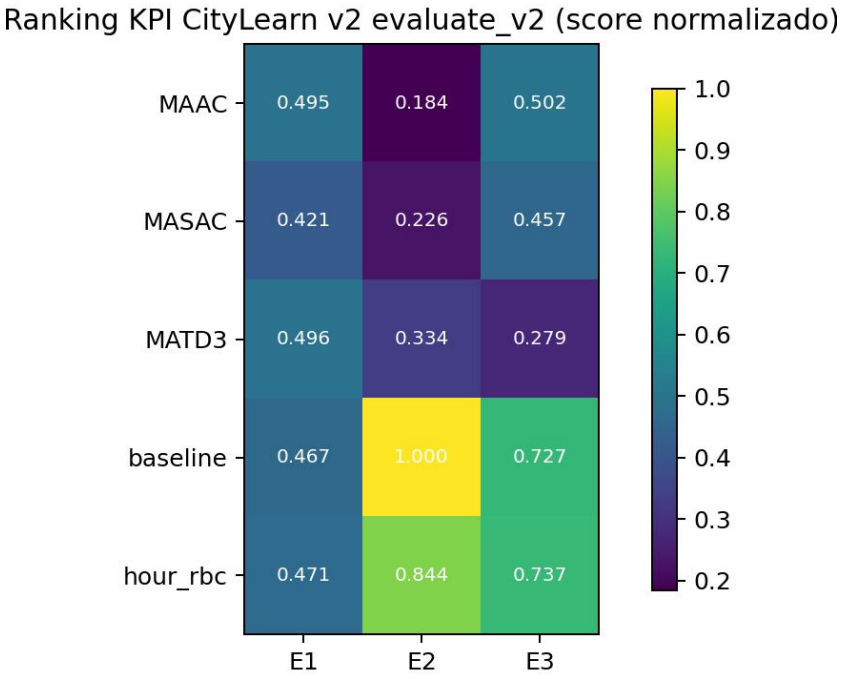
3-E3. Curva de convergencia por recompensa media móvil en E3



Nota. Evidencia gráfica conservada del documento maestro para trazabilidad. No sustituye los valores cuantitativos recalculados ni la decisión estadística final. Fuente: artefactos originales de la corrida canónica.

Figura A.5

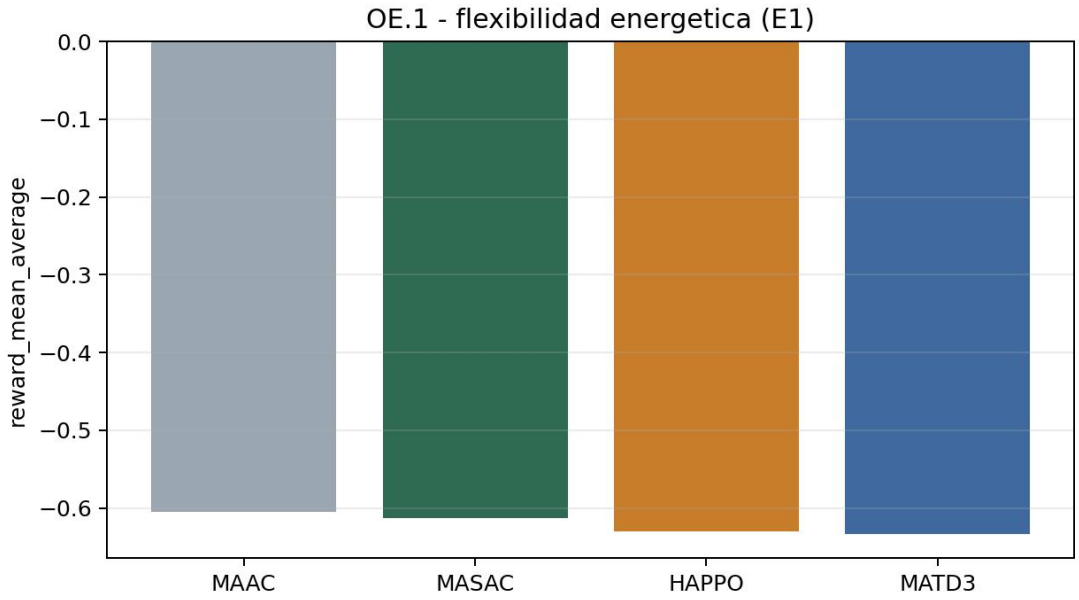
Mapa de calor del ranking KPI CityLearn v2 evaluate_v2



Nota. Evidencia gráfica conservada del documento maestro para trazabilidad. No sustituye los valores cuantitativos recalculados ni la decisión estadística final. Fuente: artefactos originales de la corrida canónica.

Figura A.6

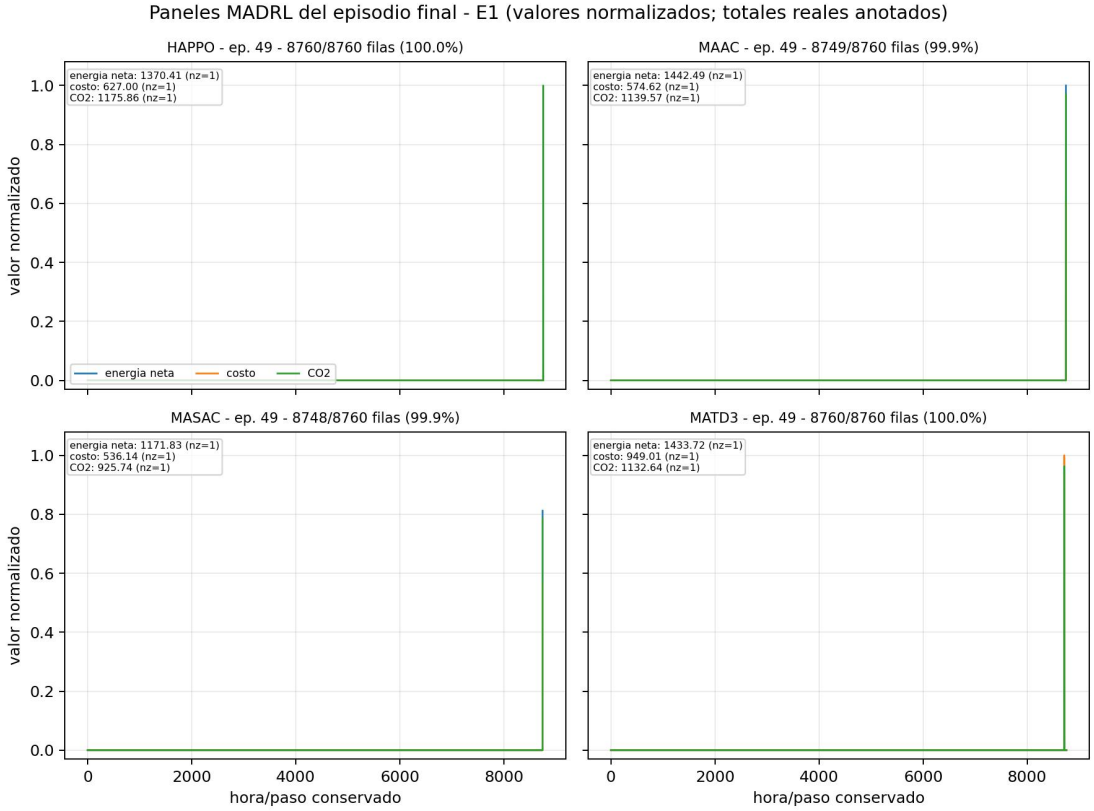
Comparación gráfica de la media por episodio para OE.1



Nota. Evidencia gráfica conservada del documento maestro para trazabilidad. No sustituye los valores cuantitativos recalculados ni la decisión estadística final. Fuente: artefactos originales de la corrida canónica.

Figura A.7

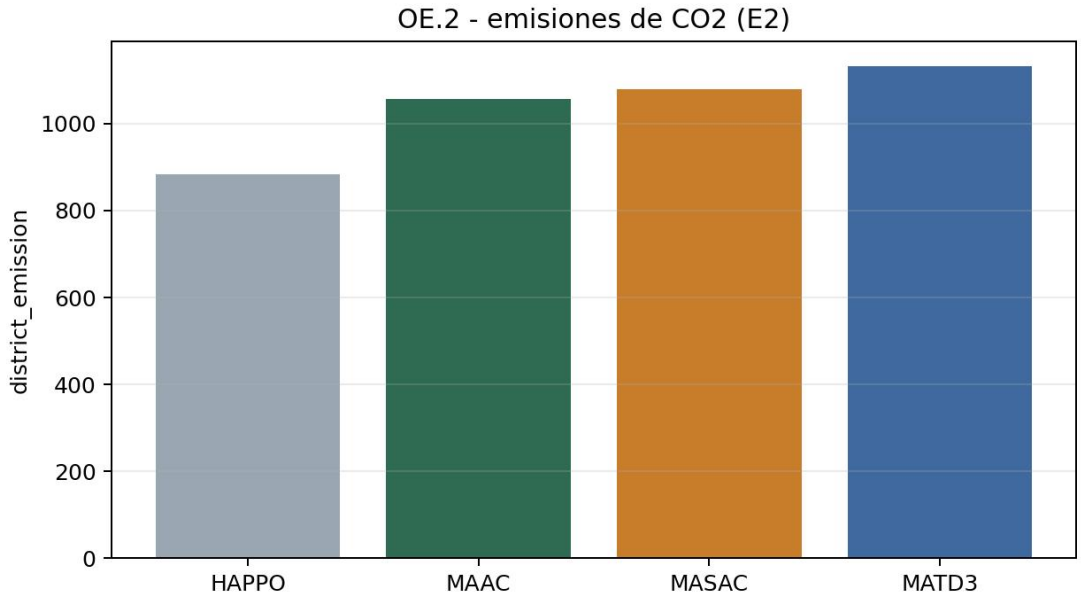
Paneles MADRL del episodio final para E1: valores normalizados y totales reales anotados por algoritmo



Nota. Evidencia gráfica conservada del documento maestro para trazabilidad. No sustituye los valores cuantitativos recalculados ni la decisión estadística final. Fuente: artefactos originales de la corrida canónica.

Figura A.8

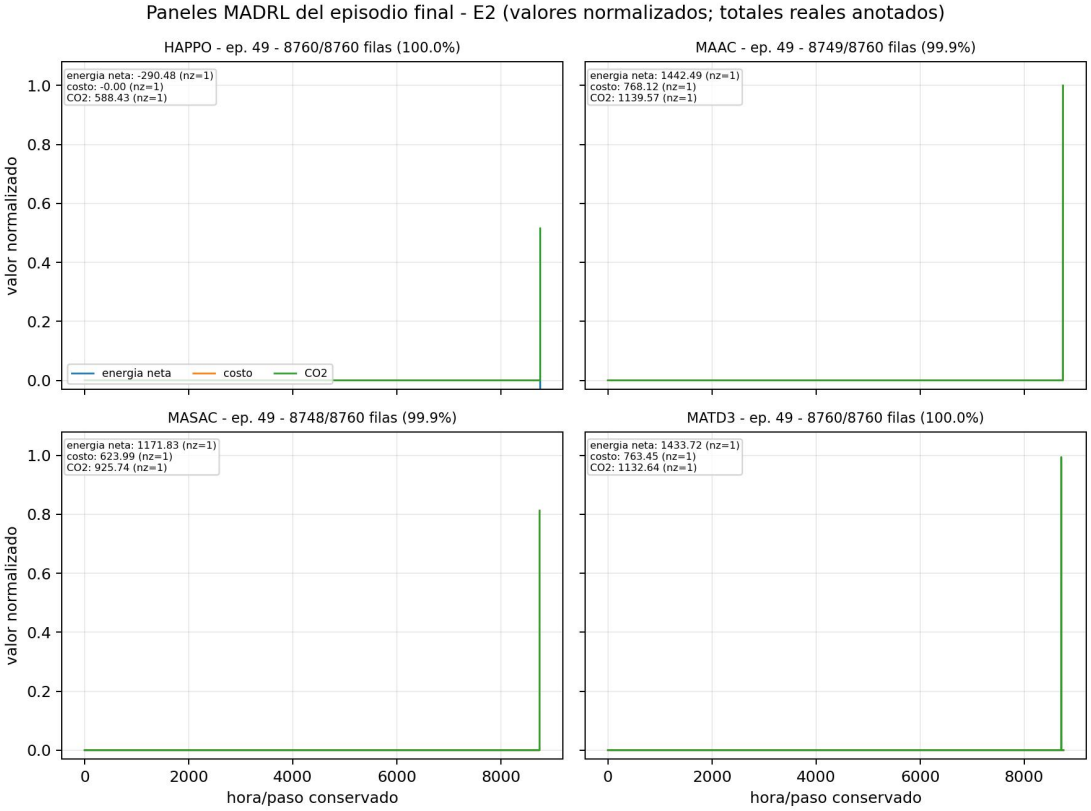
Comparación gráfica de la media por episodio para OE.2



Nota. Evidencia gráfica conservada del documento maestro para trazabilidad. No sustituye los valores cuantitativos recalculados ni la decisión estadística final. Fuente: artefactos originales de la corrida canónica.

Figura A.9

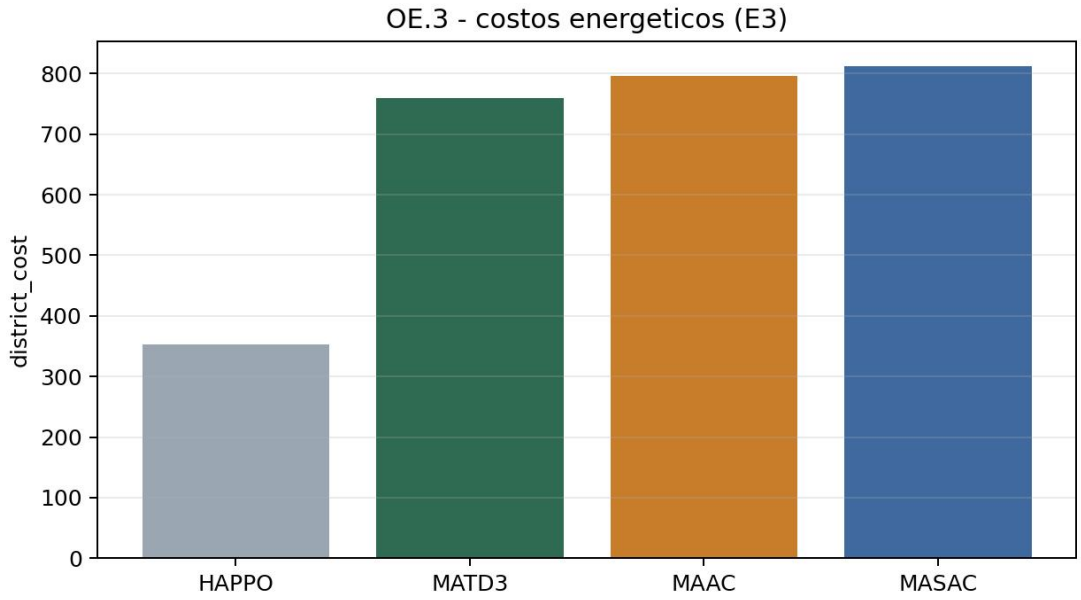
Paneles MADRL del episodio final para E2: valores normalizados y totales reales anotados por algoritmo



Nota. Evidencia gráfica conservada del documento maestro para trazabilidad. No sustituye los valores cuantitativos recalculados ni la decisión estadística final. Fuente: artefactos originales de la corrida canónica.

Figura A.10

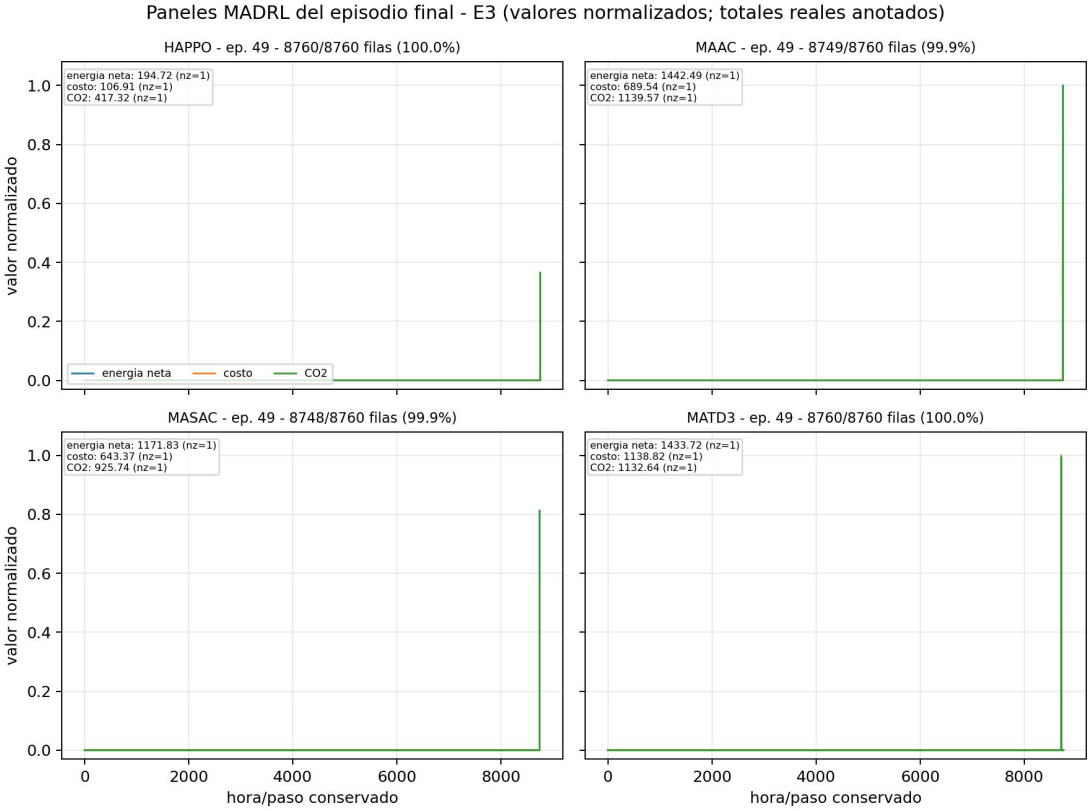
Comparación gráfica de la media por episodio para OE.3



Nota. Evidencia gráfica conservada del documento maestro para trazabilidad. No sustituye los valores cuantitativos recalculados ni la decisión estadística final. Fuente: artefactos originales de la corrida canónica.

Figura A.11

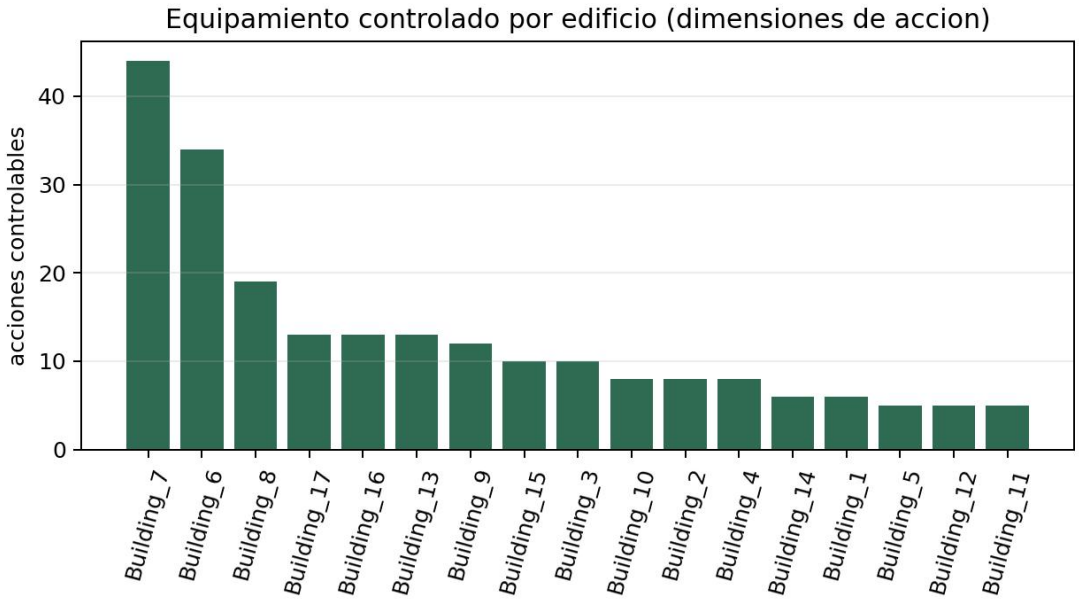
Paneles MADRL del episodio final para E3: valores normalizados y totales reales anotados por algoritmo



Nota. Evidencia gráfica conservada del documento maestro para trazabilidad. No sustituye los valores cuantitativos recalculados ni la decisión estadística final. Fuente: artefactos originales de la corrida canónica.

Figura A.12

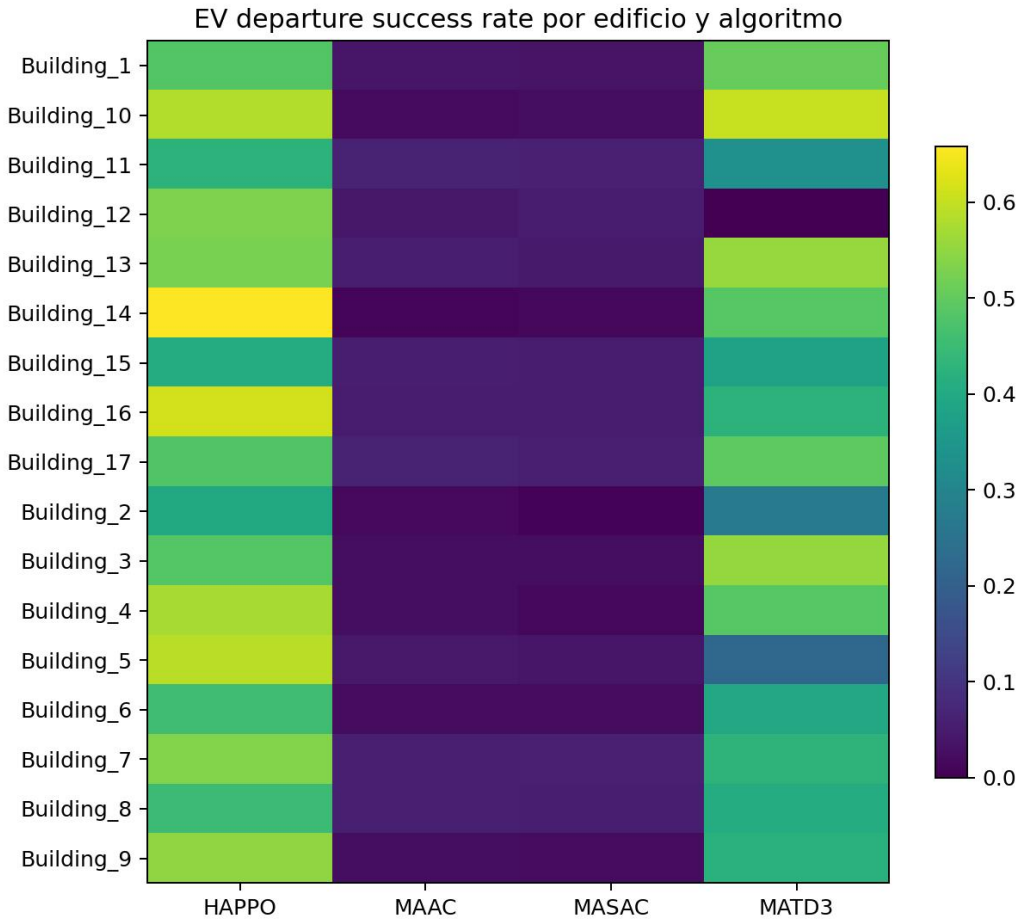
Dimensiones de acción controlable por edificio



Nota. Evidencia gráfica conservada del documento maestro para trazabilidad. No sustituye los valores cuantitativos recalculados ni la decisión estadística final. Fuente: artefactos originales de la corrida canónica.

Figura A.13

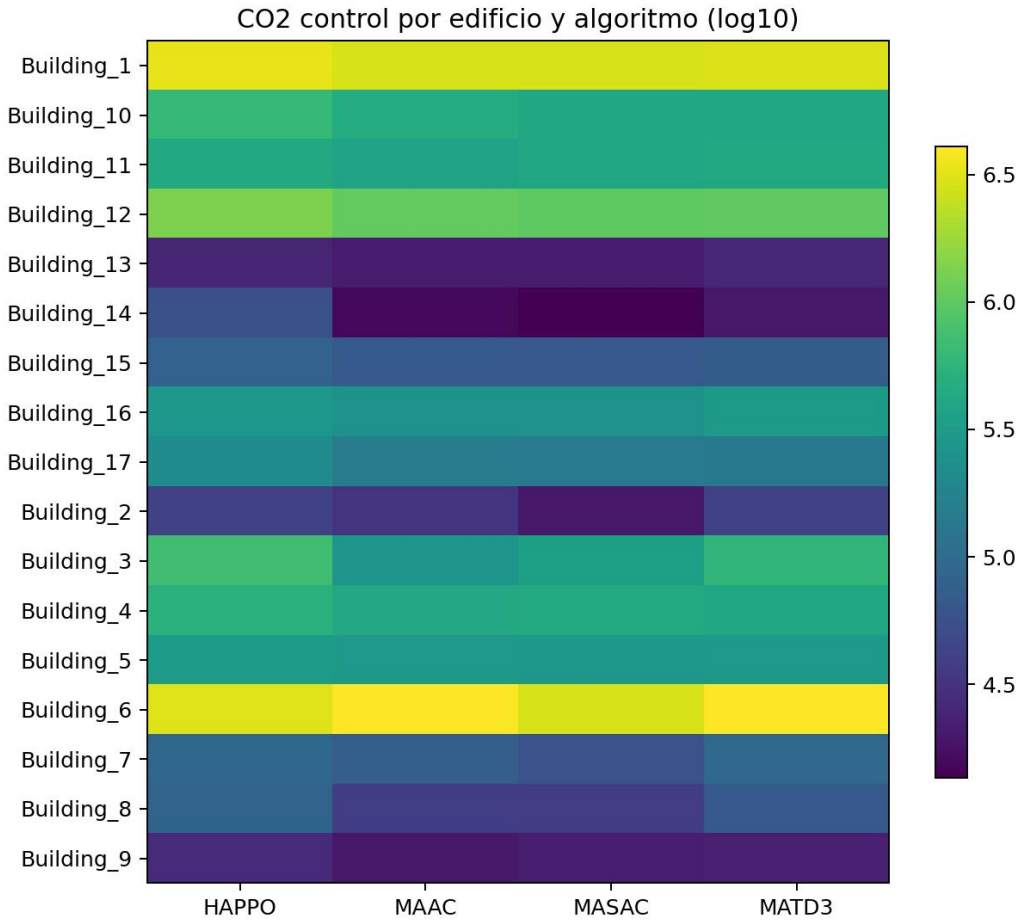
Éxito de salida EV por edificio y algoritmo



Nota. Evidencia gráfica conservada del documento maestro para trazabilidad. No sustituye los valores cuantitativos recalculados ni la decisión estadística final. Fuente: artefactos originales de la corrida canónica.

Figura A.14

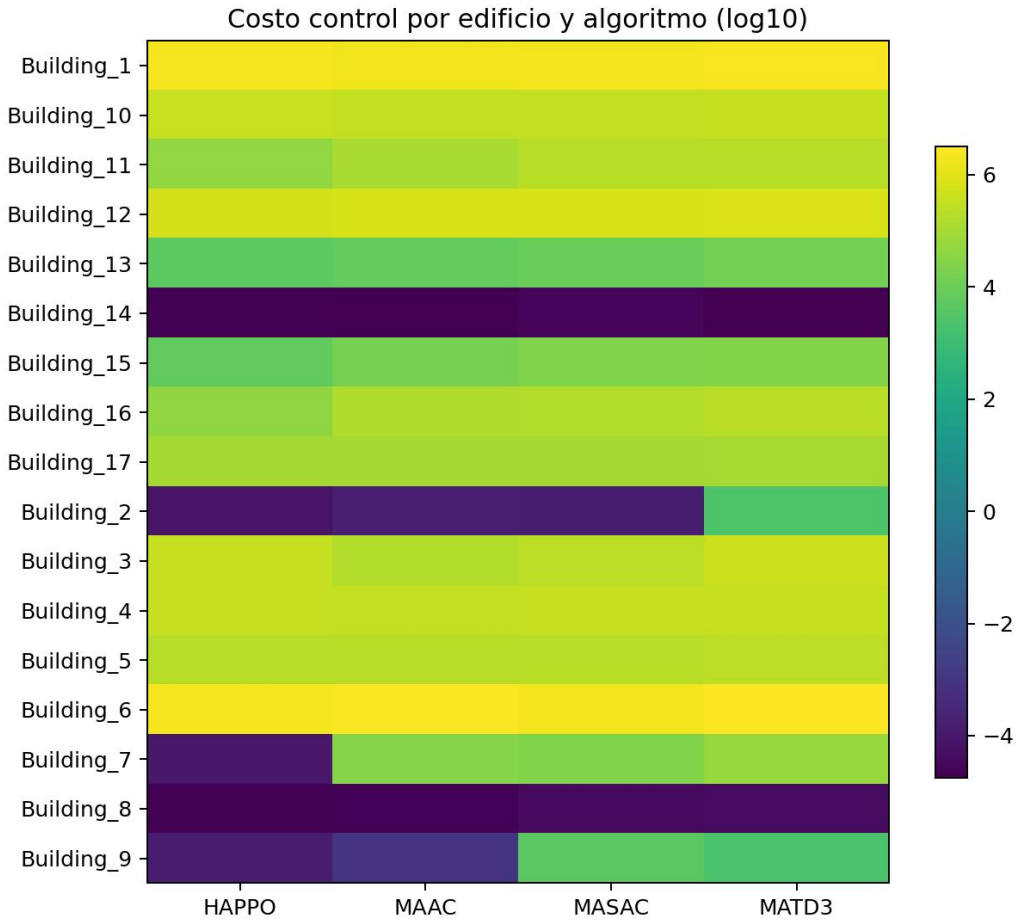
CO_2 control por edificio y algoritmo



Nota. Evidencia gráfica conservada del documento maestro para trazabilidad. No sustituye los valores cuantitativos recalculados ni la decisión estadística final. Fuente: artefactos originales de la corrida canónica.

Figura A.15

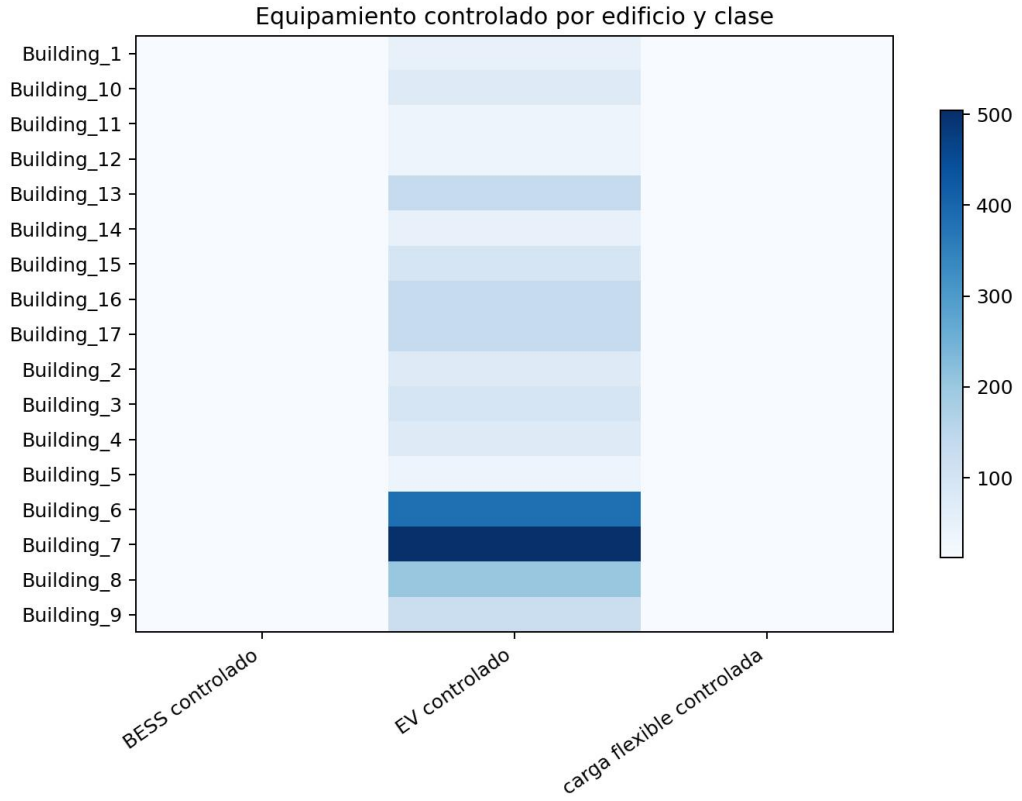
Costo control por edificio y algoritmo



Nota. Evidencia gráfica conservada del documento maestro para trazabilidad. No sustituye los valores cuantitativos recalculados ni la decisión estadística final. Fuente: artefactos originales de la corrida canónica.

Figura A.16

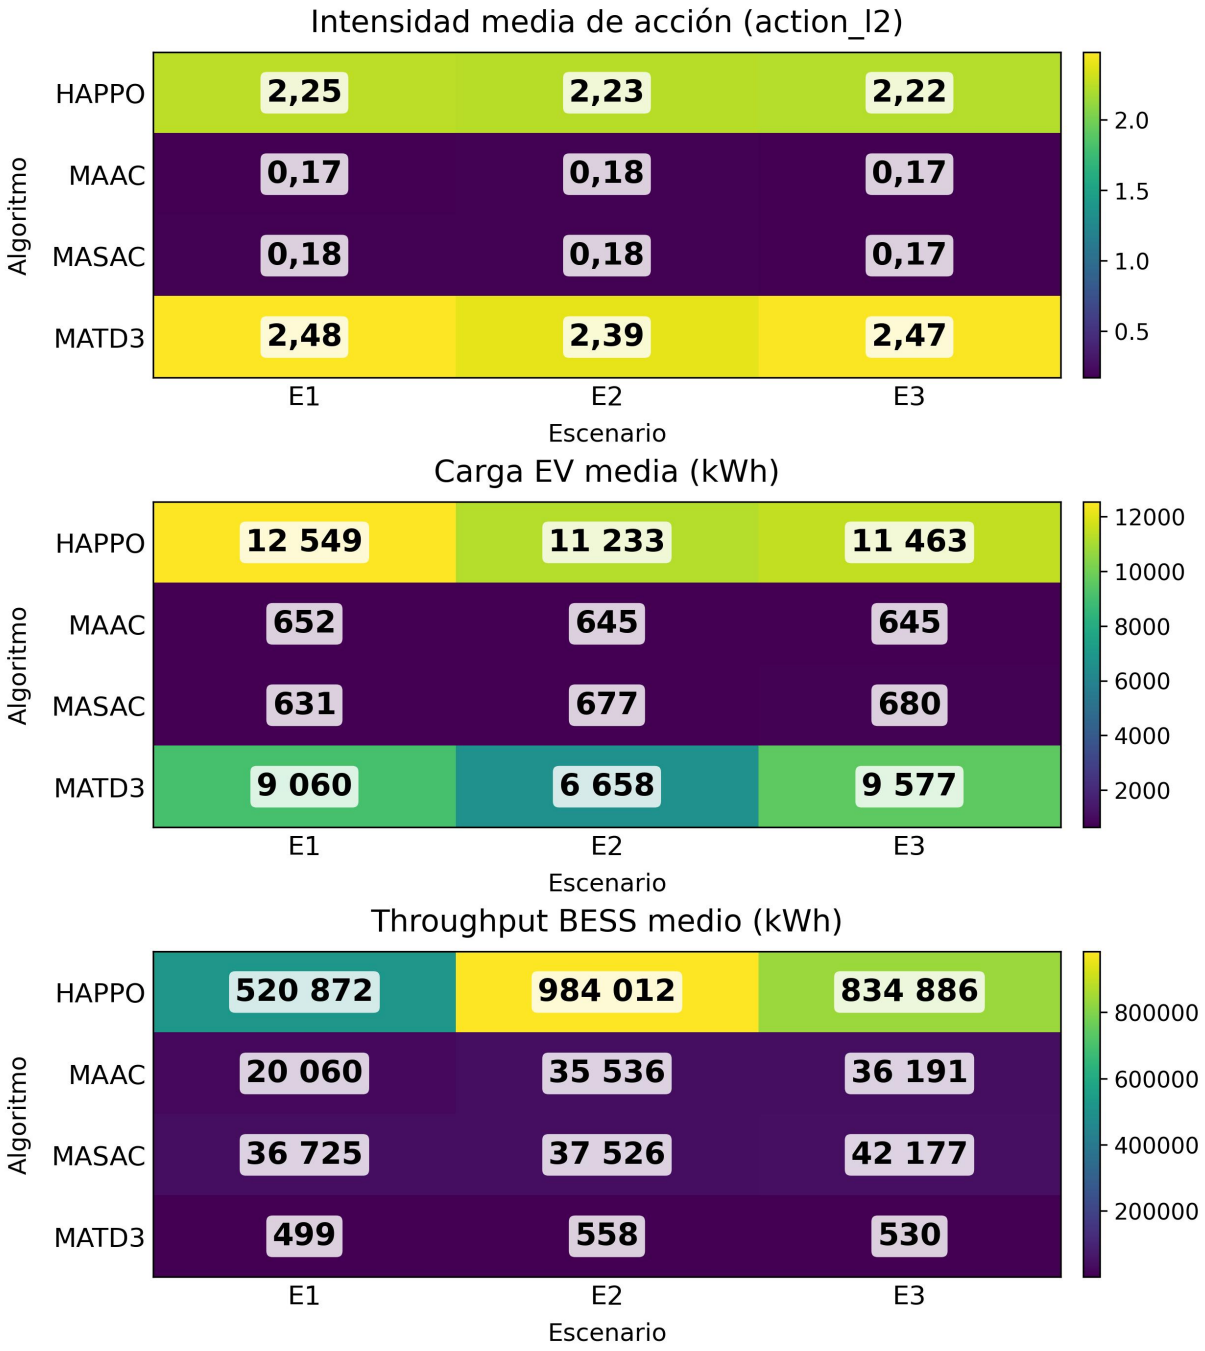
Equipamiento controlado por edificio y clase



Nota. Evidencia gráfica conservada del documento maestro para trazabilidad. No sustituye los valores cuantitativos recalculados ni la decisión estadística final. Fuente: artefactos originales de la corrida canónica.

Figura A.17

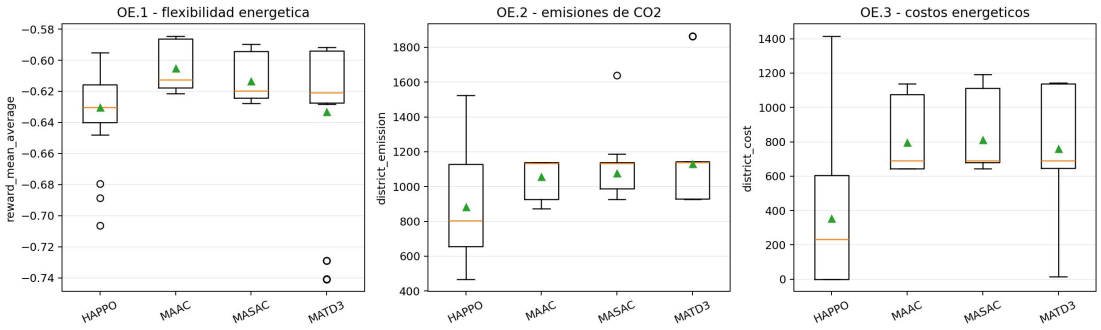
Políticas y acciones medias: action_l2 desde trace.csv y EV/BESS desde building_behavior_summary.csv



Nota. Evidencia gráfica conservada del documento maestro para trazabilidad. No sustituye los valores cuantitativos recalculados ni la decisión estadística final. Fuente: artefactos originales de la corrida canónica.

Figura A.18

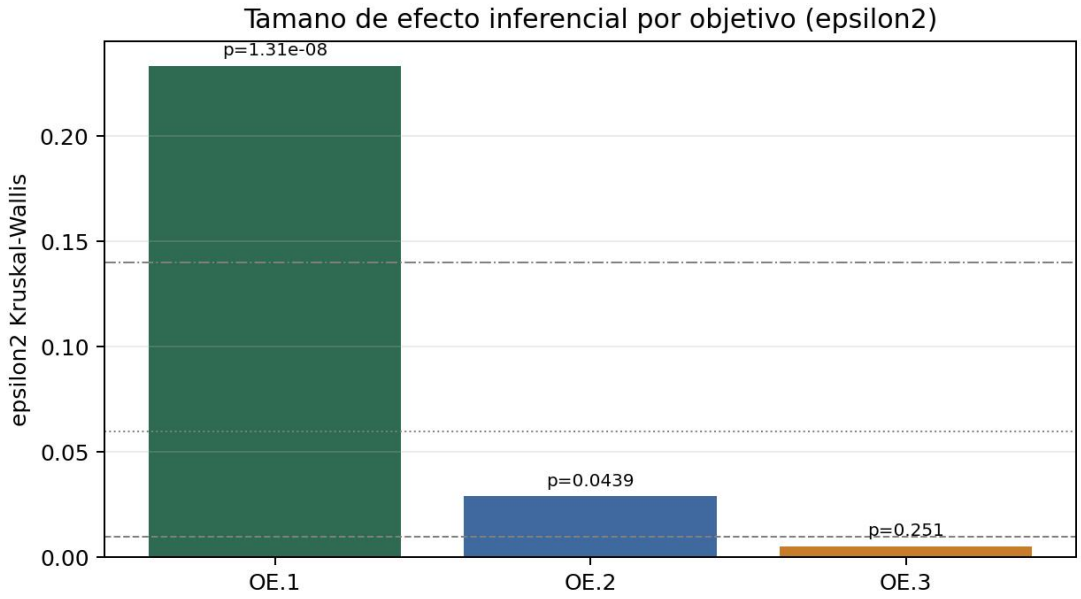
Distribución episódica por objetivo y algoritmo



Nota. Evidencia gráfica conservada del documento maestro para trazabilidad. No sustituye los valores cuantitativos recalculados ni la decisión estadística final. Fuente: artefactos originales de la corrida canónica.

Figura A.19

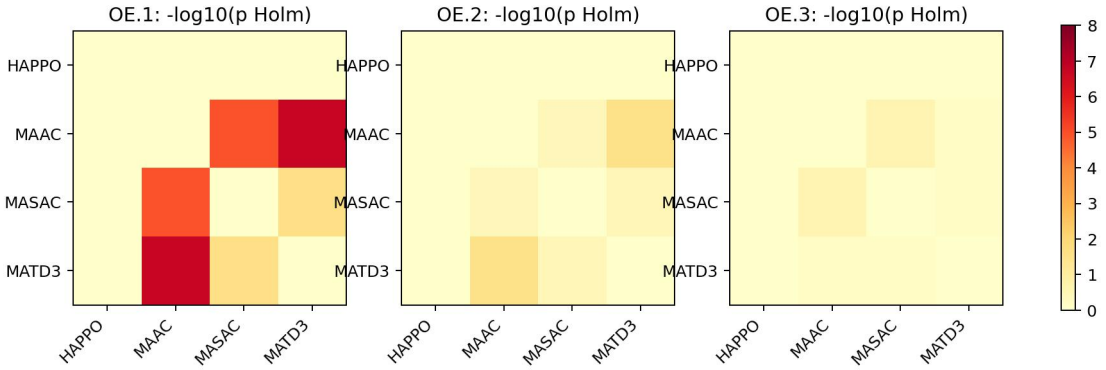
Tamaño de efecto inferencial por objetivo



Nota. Evidencia gráfica conservada del documento maestro para trazabilidad. No sustituye los valores cuantitativos recalculados ni la decisión estadística final. Fuente: artefactos originales de la corrida canónica.

Figura A.20

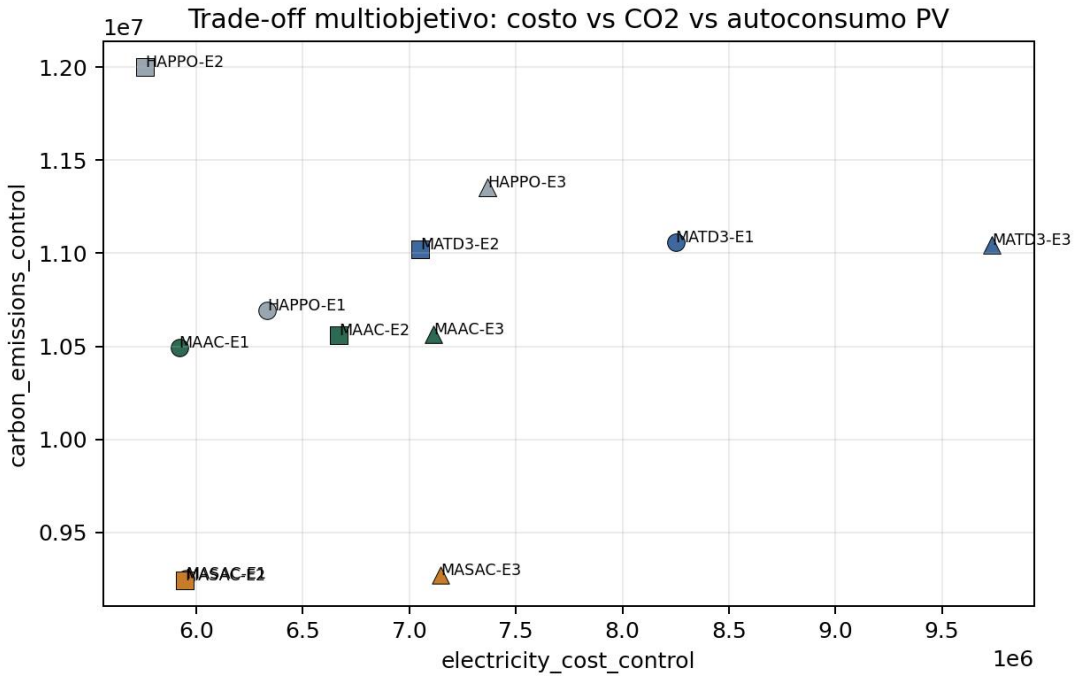
Matriz de p-valores Holm por objetivo



Nota. Evidencia gráfica conservada del documento maestro para trazabilidad. No sustituye los valores cuantitativos recalculados ni la decisión estadística final. Fuente: artefactos originales de la corrida canónica.

Figura A.21

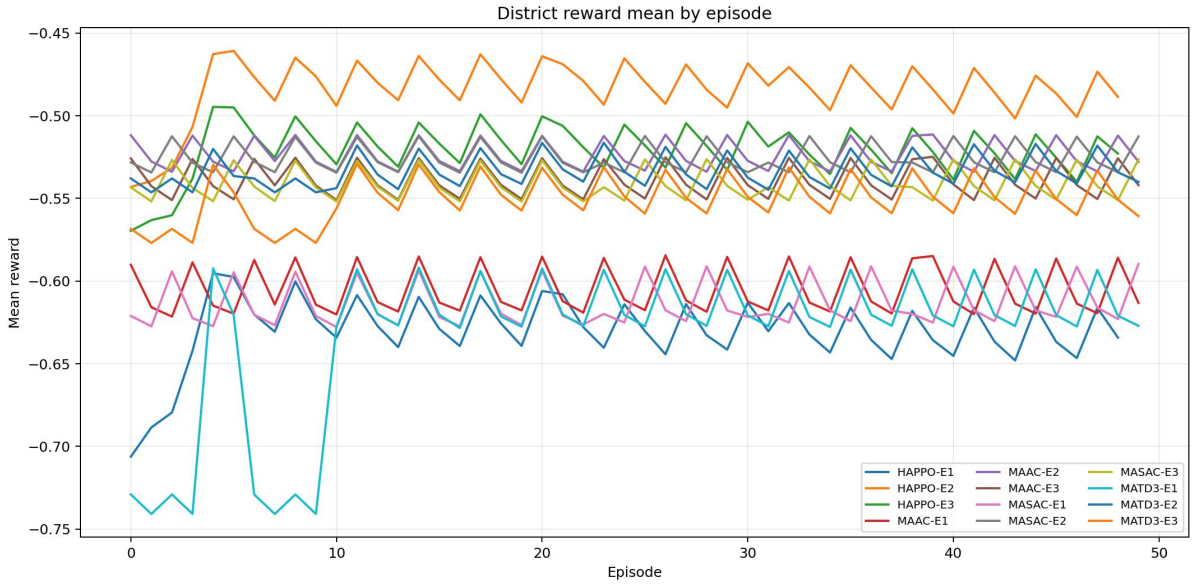
Trade-off multiobjetivo costo-CO_2-autoconsumo PV



Nota. Evidencia gráfica conservada del documento maestro para trazabilidad. No sustituye los valores cuantitativos recalculados ni la decisión estadística final. Fuente: artefactos originales de la corrida canónica.

Figura A.22

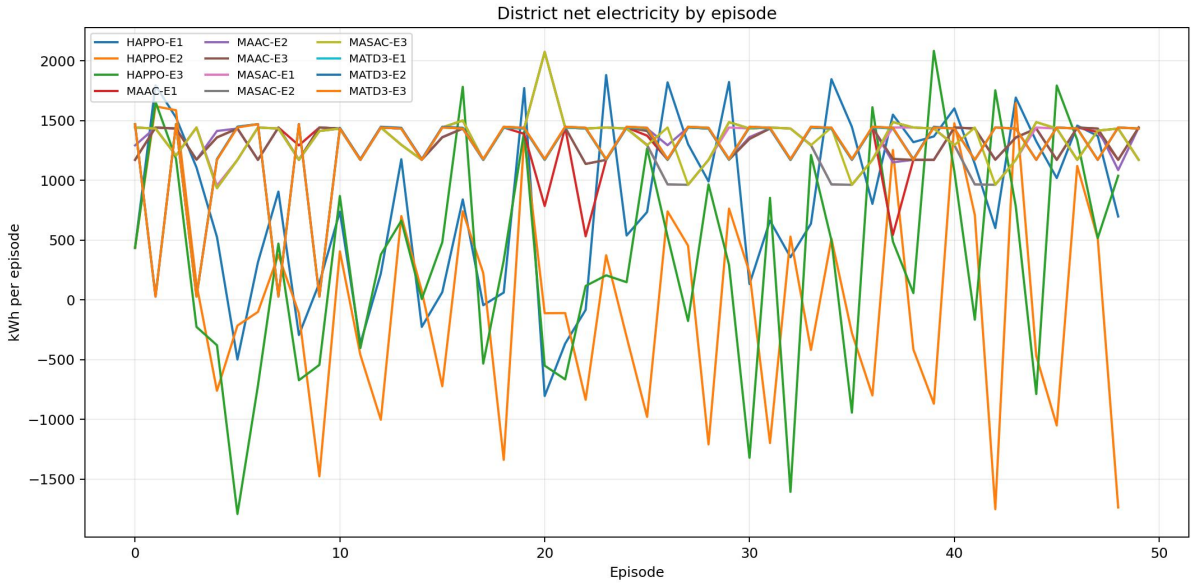
Evolución del reward distrital medio por episodio



Nota. Evidencia gráfica conservada del documento maestro para trazabilidad. No sustituye los valores cuantitativos recalculados ni la decisión estadística final. Fuente: artefactos originales de la corrida canónica.

Figura A.23

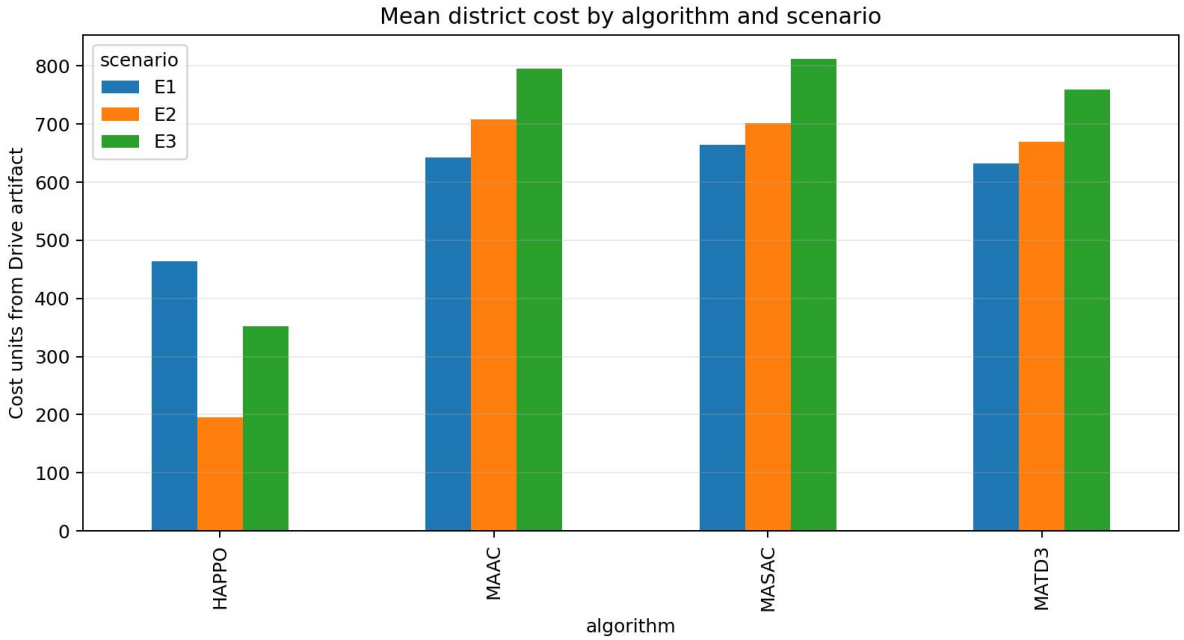
Energía neta distrital por episodio



Nota. Evidencia gráfica conservada del documento maestro para trazabilidad. No sustituye los valores cuantitativos recalculados ni la decisión estadística final. Fuente: artefactos originales de la corrida canónica.

Figura A.24

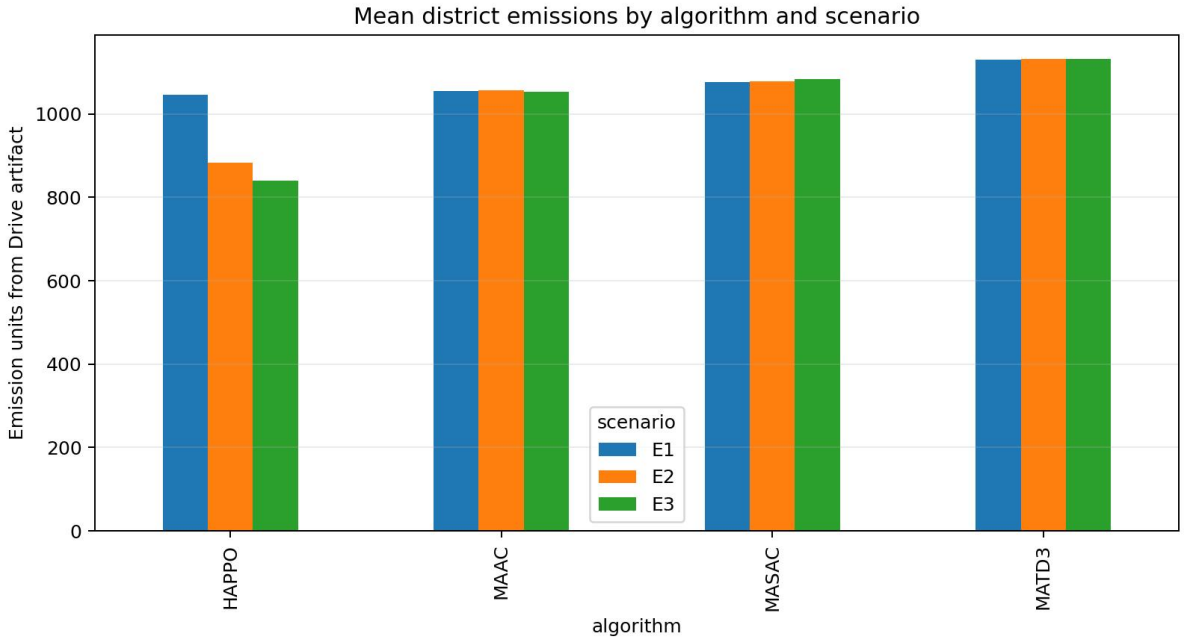
Costo distrital medio por algoritmo y escenario



Nota. Evidencia gráfica conservada del documento maestro para trazabilidad. No sustituye los valores cuantitativos recalculados ni la decisión estadística final. Fuente: artefactos originales de la corrida canónica.

Figura A.25

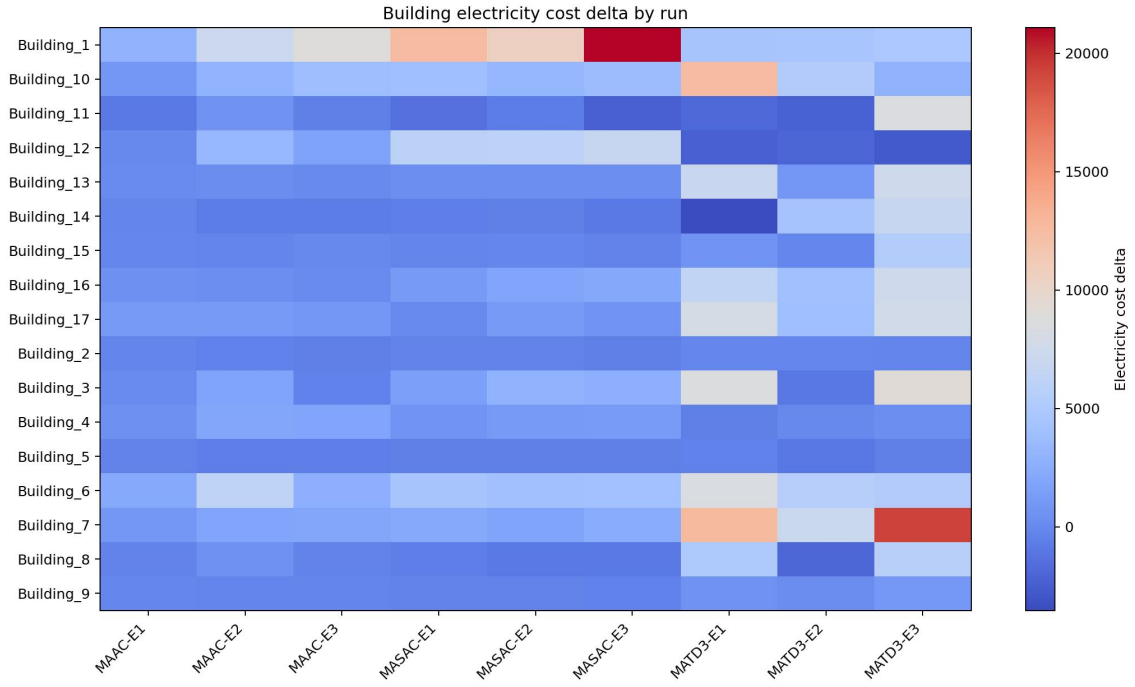
Emisiones distritales medias por algoritmo y escenario



Nota. Evidencia gráfica conservada del documento maestro para trazabilidad. No sustituye los valores cuantitativos recalculados ni la decisión estadística final. Fuente: artefactos originales de la corrida canónica.

Figura A.26

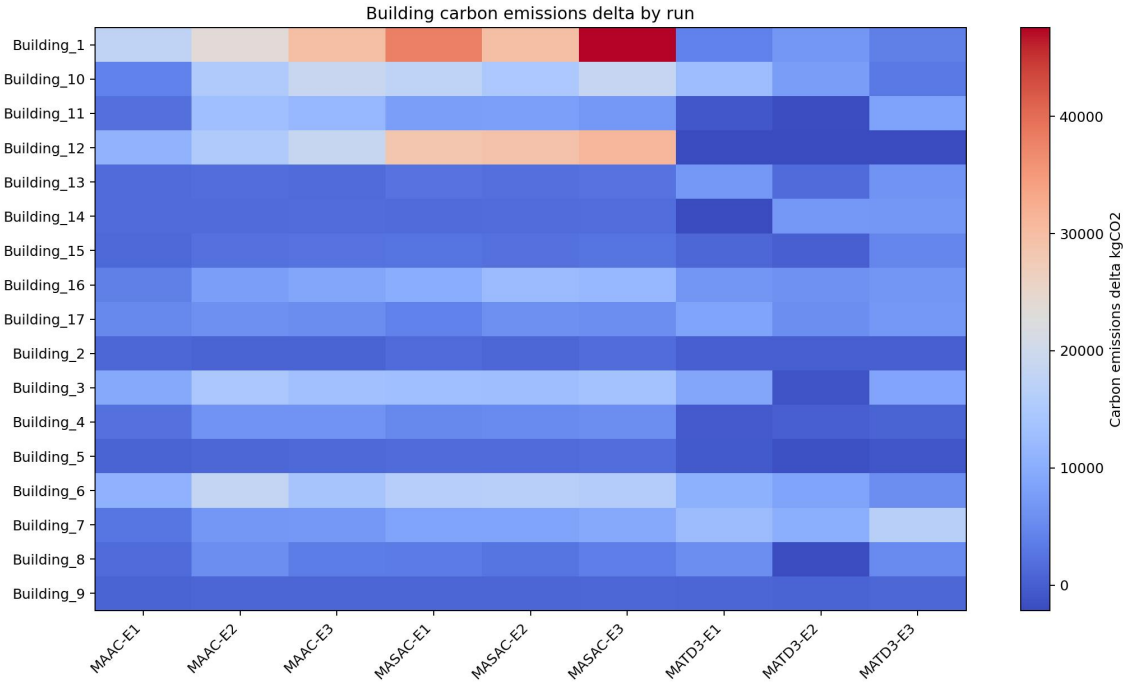
Delta de costo eléctrico por edificio y corrida completa



Nota. Evidencia gráfica conservada del documento maestro para trazabilidad. No sustituye los valores cuantitativos recalculados ni la decisión estadística final. Fuente: artefactos originales de la corrida canónica.

Figura A.27

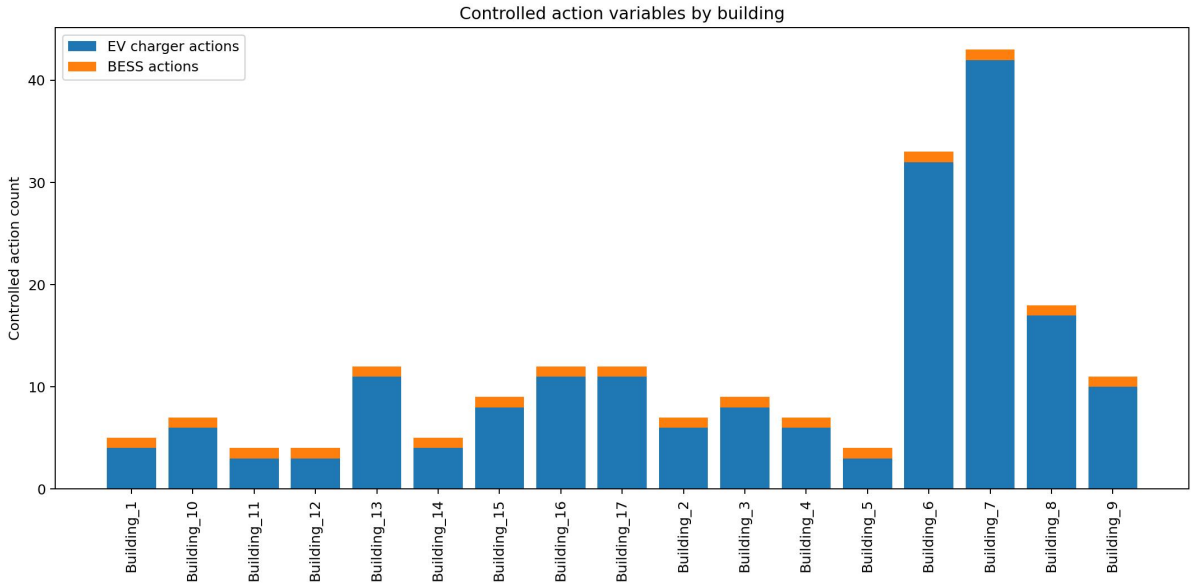
Delta de emisiones por edificio y corrida completa



Nota. Evidencia gráfica conservada del documento maestro para trazabilidad. No sustituye los valores cuantitativos recalculados ni la decisión estadística final. Fuente: artefactos originales de la corrida canónica.

Figura A.28

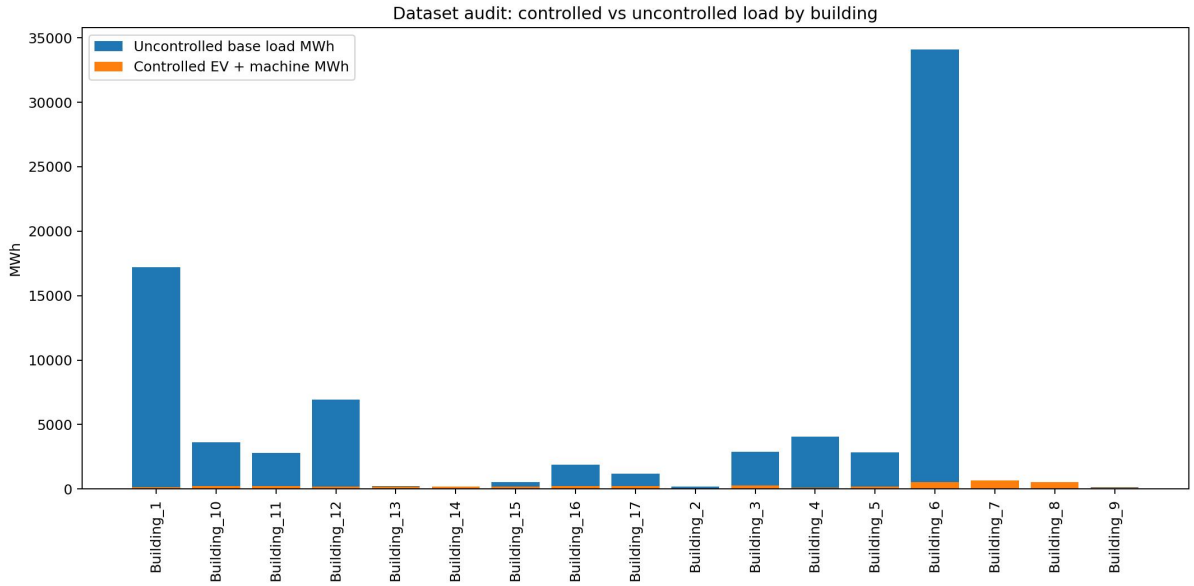
Variables de acción controladas por edificio



Nota. Evidencia gráfica conservada del documento maestro para trazabilidad. No sustituye los valores cuantitativos recalculados ni la decisión estadística final. Fuente: artefactos originales de la corrida canónica.

Figura A.29

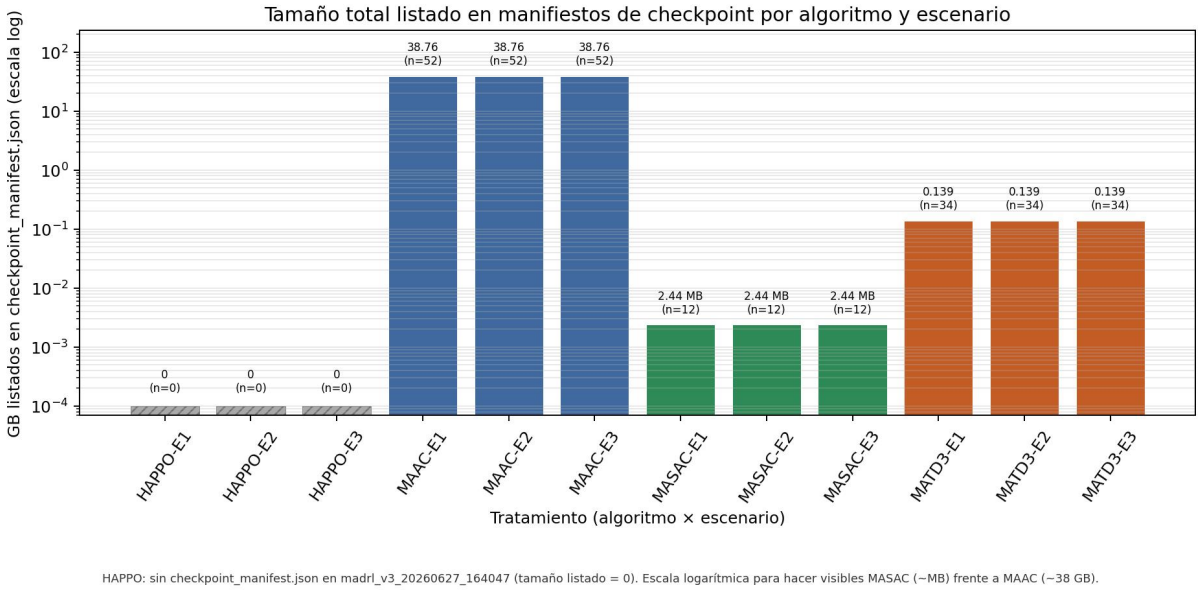
Carga controlada de escenario frente a carga base no controlada



Nota. Evidencia gráfica conservada del documento maestro para trazabilidad. No sustituye los valores cuantitativos recalculados ni la decisión estadística final. Fuente: artefactos originales de la corrida canónica.

Figura A.30

Tamaño total listado en manifiestos de checkpoint por algoritmo y escenario



Nota. Evidencia gráfica conservada del documento maestro para trazabilidad. No sustituye los valores cuantitativos recalculados ni la decisión estadística final. Fuente: artefactos originales de la corrida canónica.

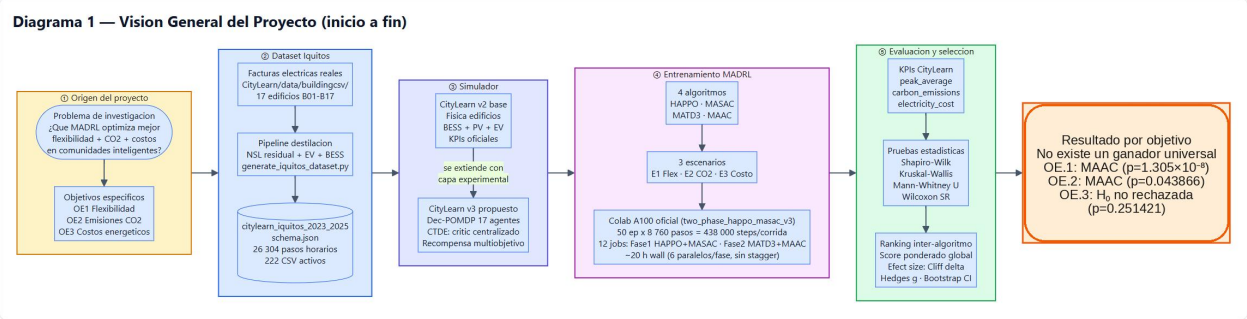
Anexo B. Diagramas de flujo y arquitectura del proyecto

Trazabilidad. Los nueve diagramas fueron renderizados desde los bloques Mermaid de docs/architecture/ARQUITECTURA_PROYECTO_DEFENSA.md. Se integran como evidencia visual de flujo del proyecto, arquitectura Dec-POMDP/CTDE, entrenamiento, evaluación, despliegue y capas de software.

Diagrama 1 — Vision General del Proyecto (inicio a fin)

Figura B.1

Diagrama 1 — Vision General del Proyecto (inicio a fin)



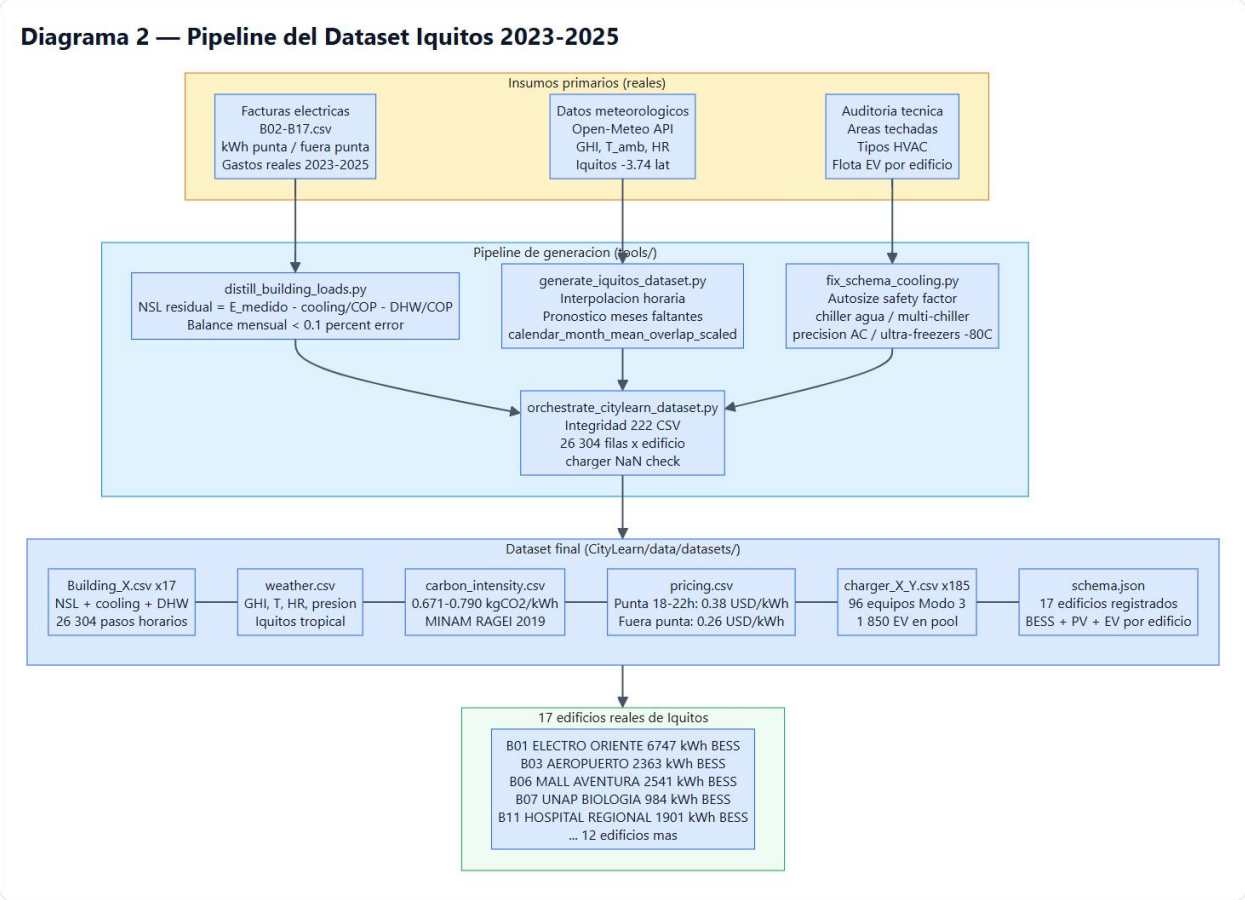
Nota. La figura representa el flujo, arquitectura o componente metodológico del sistema académico MADRL-CityLearn. Fuente: Elaboración propia a partir de la arquitectura del repositorio local, los scripts de construcción del datase, la formalización Dec-POMDP/CTDE y la configuración experimental MADRL; se fundamenta en Oliehoek y Amato (2016), Lowe et al. (2017), Iqbal y Sha (2019), Vázquez-Canteli et al. (2020) y Nweye et al. (2024).

Interpretación de la figura. El diagrama integra el flujo completo del proyecto: construcción del datase, entorno CityLearn, entrenamiento MADRL, evaluación, visualización y redacción académica. La evidencia utilizada comprende 12 tratamientos, 600 filas episódicas, 204 filas edificio-tratamiento y 294 archivos listados en manifiestos de checkpoint. No existe un ganador universal: la decisión depende del objetivo, de la cobertura inferencial y del KPI anual final.

Diagrama 2 — Pipeline del Dataset Iquitos 2023-2025

Figura B.2

Diagrama 2 — Pipeline del Dataset Iquitos 2023-2025



Nota. La figura representa el flujo, arquitectura o componente metodológico del sistema académico MADRL-CityLearn. Fuente: Elaboración propia a partir de la arquitectura del repositorio local, los scripts de construcción del datase, la formalización Dec-POMDP/CTDE y la configuración experimental MADRL; se fundamenta en Oliehoek y Amato (2016), Lowe et al. (2017), Iqbal y Sha (2019), Vázquez-Canteli et al. (2020) y Nweye et al. (2024).

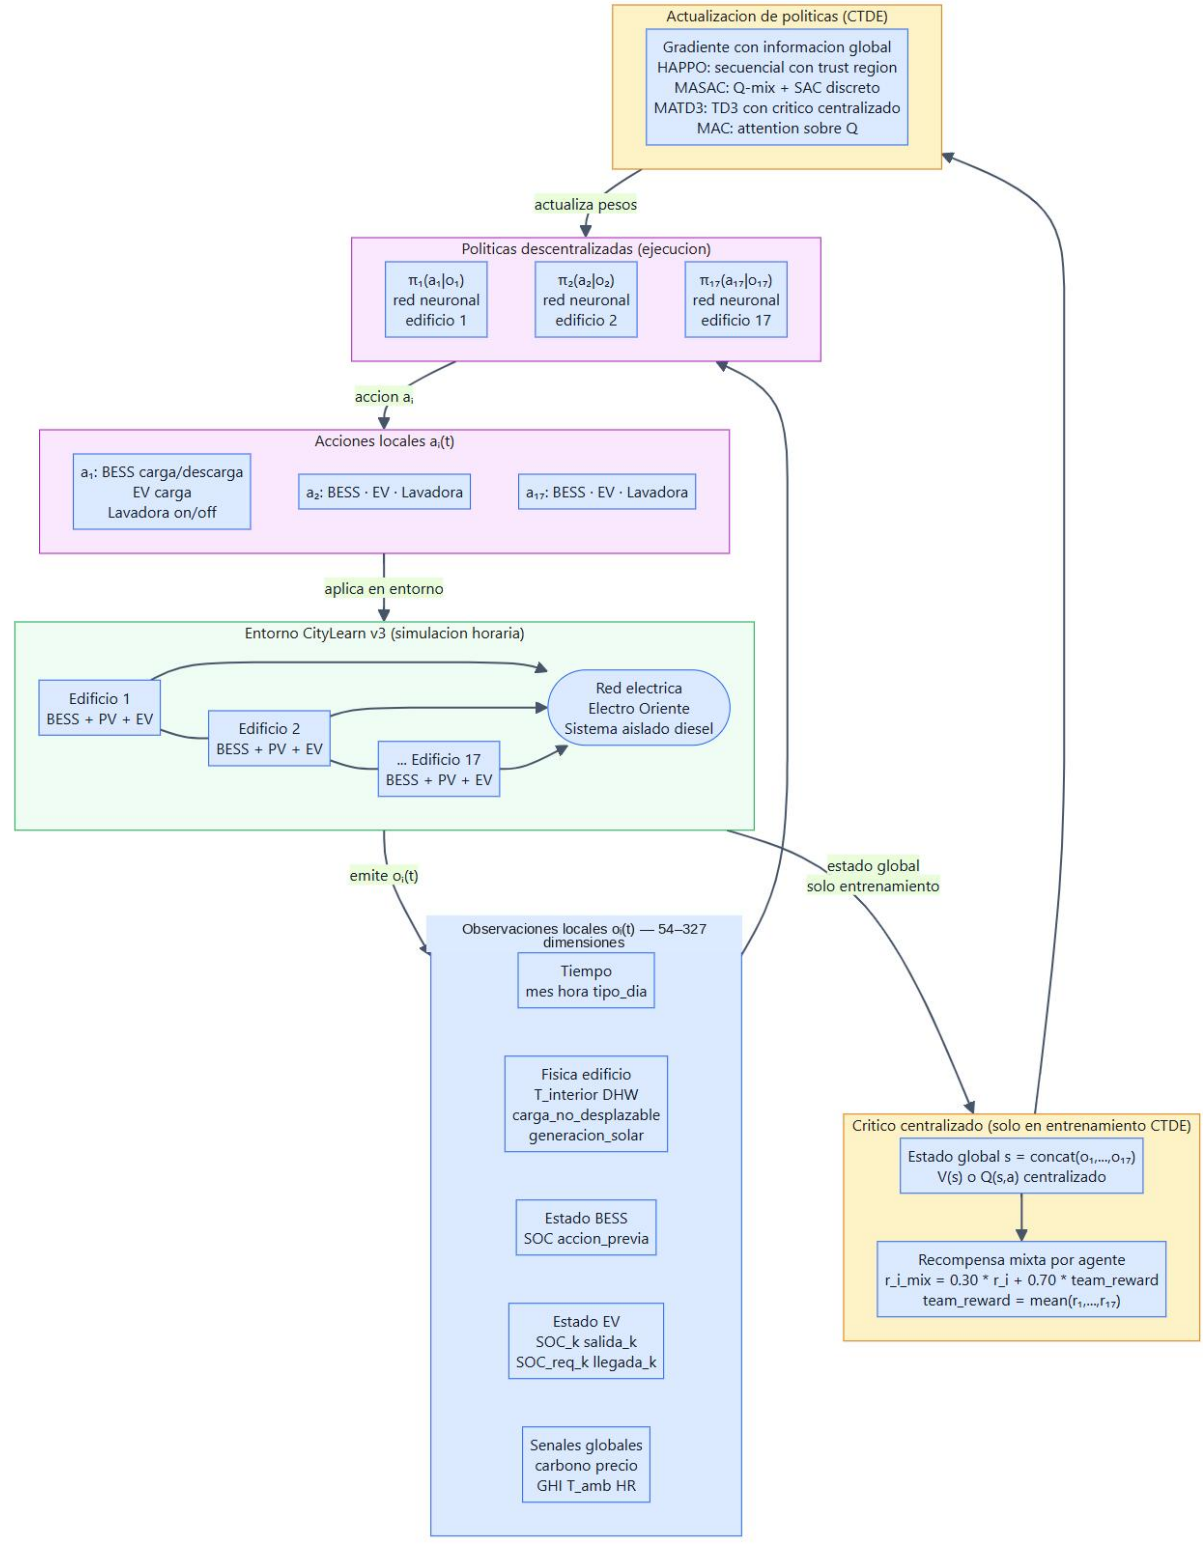
Interpretación de la figura. El diagrama muestra el pipeline del dataset Iquitos 2023-2025 y su transformación hacia el formato CityLearn. La interpretación se basa en 17 edificios/agentes y en la separación entre datos climáticos, demanda, precios, carbono y esquemas de observación-acción.

Diagrama 3 — Arquitectura Dec-POMDP y CTDE de los 17 Agentes

Figura B.3

Diagrama 3 — Arquitectura Dec-POMDP y CTDE de los 17 Agentes

Diagrama 3 — Arquitectura Dec-POMDP y CTDE de los 17 Agentes



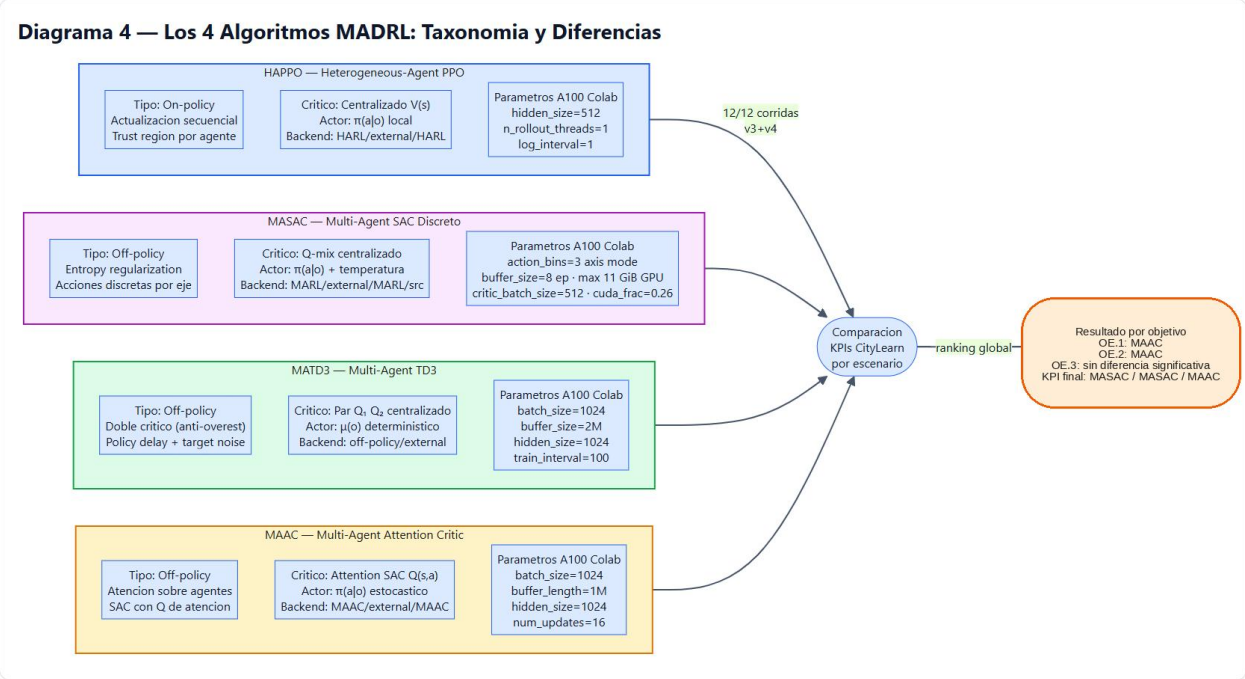
Nota. La figura representa el flujo, arquitectura o componente metodológico del sistema académico MADRL-CityLearn. Fuente: Elaboración propia a partir de la arquitectura del repositorio local, los scripts de construcción del datase, la formalización Dec-POMDP/CTDE y la configuración experimental MADRL; se fundamenta en Oliehoek y Amato (2016), Lowe et al. (2017), Iqbal y Sha (2019), Vázquez-Canteli et al. (2020) y Nweye et al. (2024).

Interpretación de la figura. El diagrama formaliza el problema como Dec-POMDP con ejecución descentralizada y entrenamiento centralizado. La comunidad opera con 17 agentes, observaciones locales heterogéneas de 54 a 327 dimensiones, dimensión global agregada de 1 856 y acciones locales de 5 a 44 por edificio (valores alineados a Cap. 2 Tabla 2.A y Cap. 4 §4.2).

Diagrama 4 — Los 4 Algoritmos MADRL: Taxonomia y Diferencias

Figura B.4

Diagrama 4 — Los 4 Algoritmos MADRL: Taxonomia y Diferencias



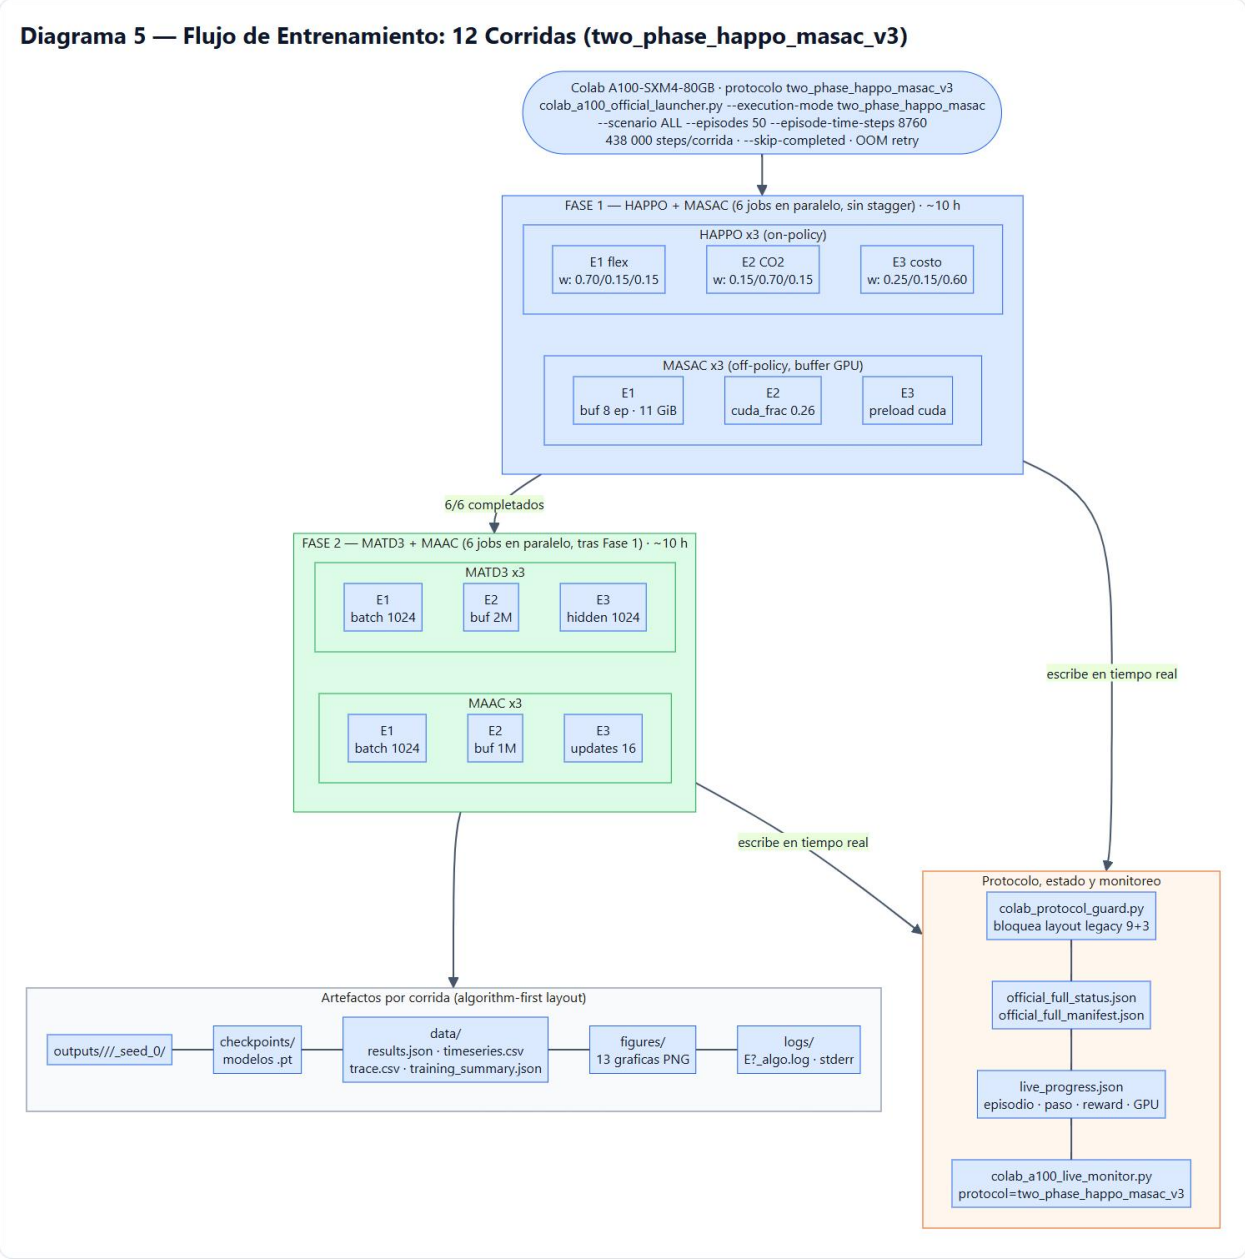
Nota. La figura representa el flujo, arquitectura o componente metodológico del sistema académico MADRL-CityLearn. Fuente: Elaboración propia a partir de la arquitectura del repositorio local, los scripts de construcción del datase, la formalización Dec-POMDP/CTDE y la configuración experimental MADRL; se fundamenta en Oliehoek y Amato (2016), Lowe et al. (2017), Iqbal y Sha (2019), Vázquez-Canteli et al. (2020) y Nweye et al. (2024).

Interpretación de la figura. El diagrama compara HAPPO, MAAC, MASAC y MATD3 como familias algorítmicas diferentes. La corrida comprende 12 tratamientos. MAAC lidera la muestra inferencial completa en OE.1 y OE.2; en OE.3 no se detectan diferencias significativas. Los KPI anuales finales favorecen a MASAC en OE.1 y OE.2 y a MAAC en OE.3, por lo que no se declara un ganador universal.

Diagrama 5 — Flujo de Entrenamiento: 12 Corridas (two_phase_happo_masac_v3)

Figura B.5

Diagrama 5 — Flujo de Entrenamiento: 12 Corridas (two_phase_happo_masac_v3)



Nota. La figura representa el flujo, arquitectura o componente metodológico del sistema académico MADRL-CityLearn. Fuente: Elaboración propia a partir de la arquitectura del repositorio local, los scripts de construcción del datase, la formalización Dec-POMDP/CTDE

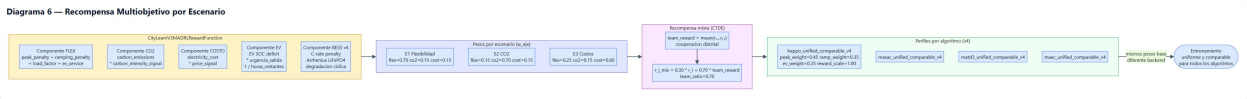
y la configuración experimental MADRL; se fundamenta en Oliehoek y Amato (2016), Lowe et al. (2017), Iqbal y Sha (2019), Vázquez-Canteli et al. (2020) y Nweye et al. (2024).

Interpretación de la figura. El diagrama resume el flujo de entrenamiento de las 12 corridas. La evidencia final conserva 600 filas episódicas materializadas, 105 051 filas de series finales, 15 504 registros de trace.csv y 294 archivos listados en manifiestos de checkpoint.

Diagrama 6 — Recompensa Multiobjetivo por Escenario

Figura B.6

Diagrama 6 — Recompensa Multiobjetivo por Escenario



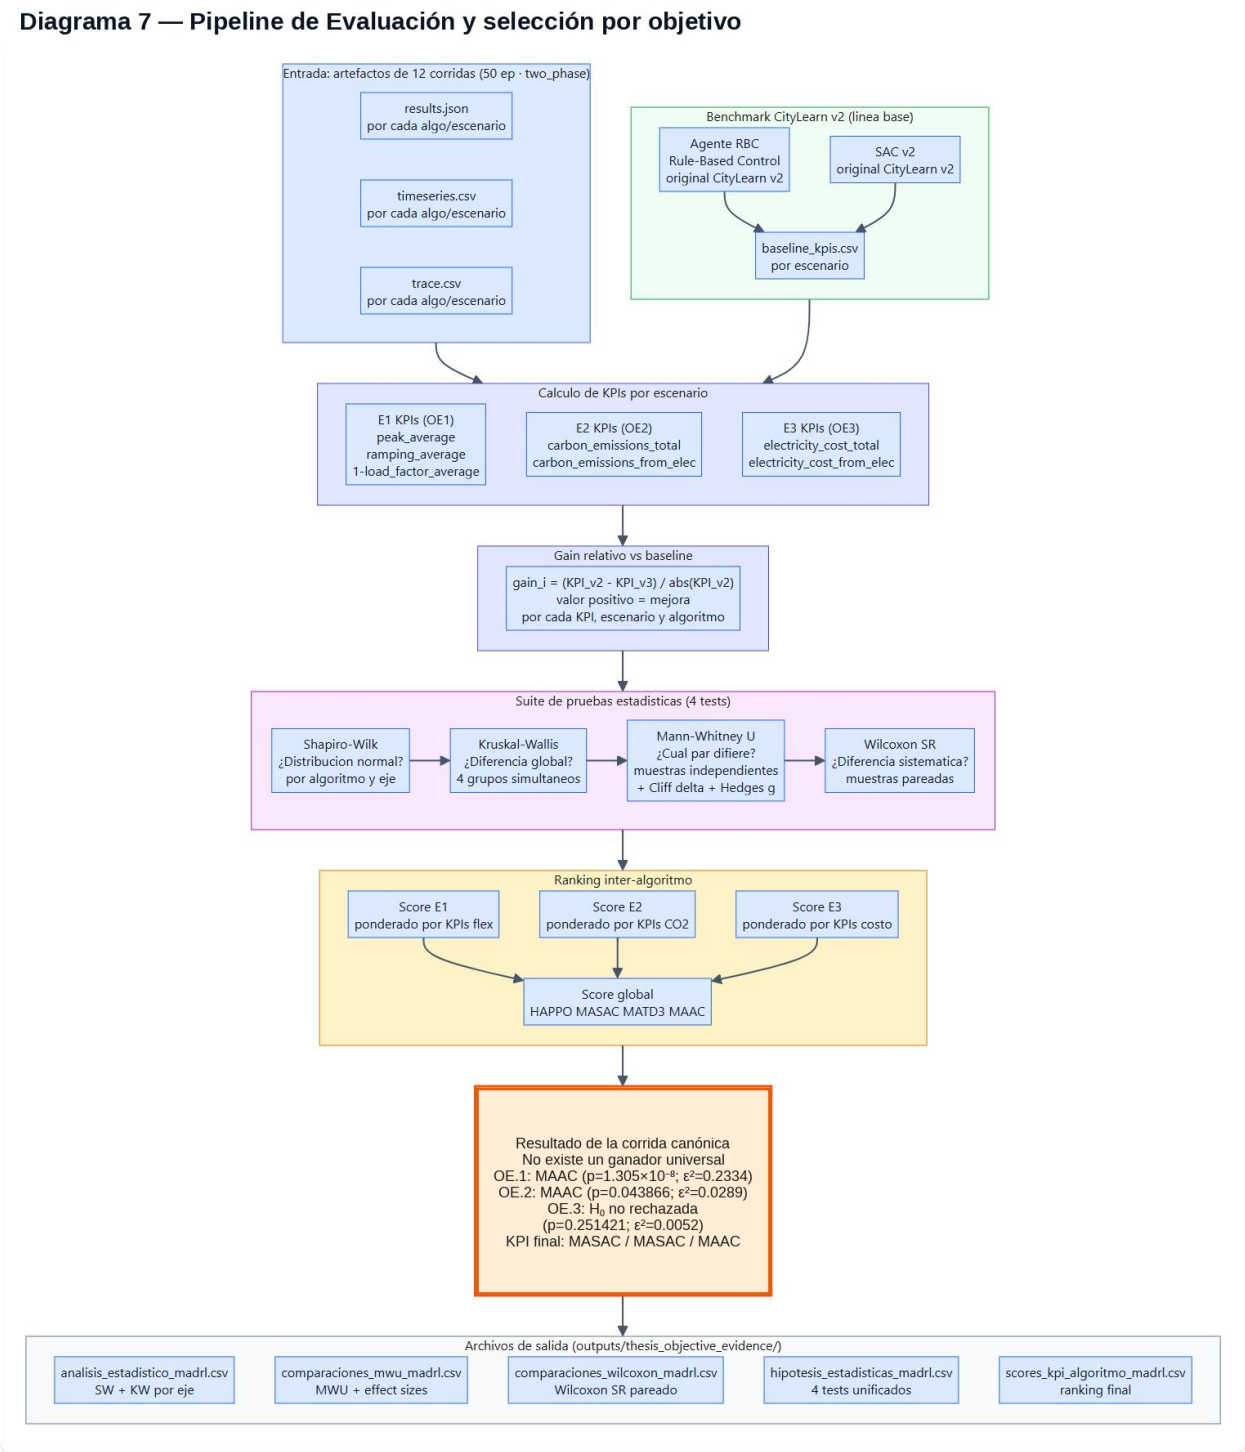
Nota. La figura representa el flujo, arquitectura o componente metodológico del sistema académico MADRL-CityLearn. Fuente: Elaboración propia a partir de la arquitectura del repositorio local, los scripts de construcción del datase, la formalización Dec-POMDP/CTDE y la configuración experimental MADRL; se fundamenta en Oliehoek y Amato (2016), Lowe et al. (2017), Iqbal y Sha (2019), Vázquez-Canteli et al. (2020) y Nweye et al. (2024).

Interpretación de la figura. El diagrama muestra la recompensa multiobjetivo por escenario: E1 prioriza flexibilidad, E2 prioriza CO_2 y E3 prioriza costos. Esta estructura vincula directamente las preguntas PE.1, PE.2 y PE.3 con los objetivos OE.1, OE.2 y OE.3.

Diagrama 7 — Pipeline de evaluación y selección por objetivo

Figura B.7

Diagrama 7 — Pipeline de evaluación y selección por objetivo



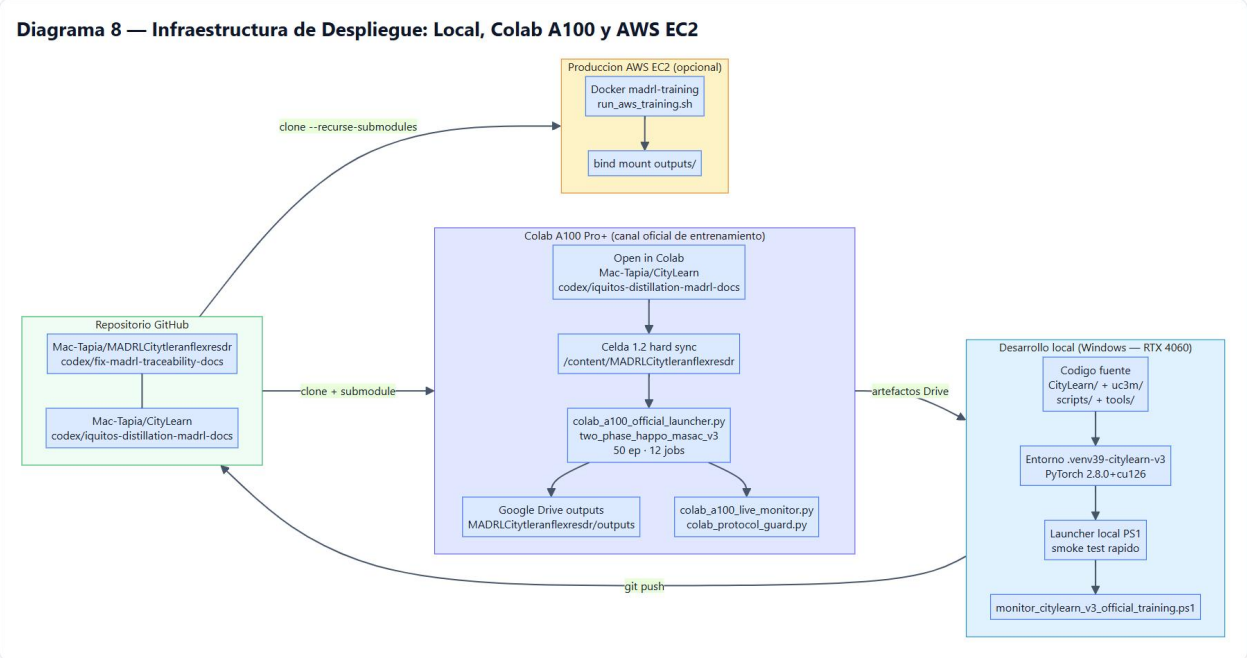
Nota. La figura representa el flujo, arquitectura o componente metodológico del sistema académico MADRL-CityLearn. Fuente: Elaboración propia a partir de la arquitectura del repositorio local, los scripts de construcción del datase, la formalización Dec-POMDP/CTDE y la configuración experimental MADRL; se fundamenta en Oliehoek y Amato (2016), Lowe et al. (2017), Iqbal y Sha (2019), Vázquez-Canteli et al. (2020) y Nweye et al. (2024).

Interpretación de la figura. El diagrama representa el pipeline de evaluación y selección por objetivo. La decisión integra estadística descriptiva, Friedman, Kendall W, Wilcoxon pareado con corrección de Holm, KPI CityLearn v2 y resultados por edificio. MATD3 presenta el menor deterioro relativo en OE.1 y OE.2; MAAC, el menor deterioro en OE.3 y el primer lugar TOPSIS global. La prueba global no demuestra un ganador estadístico único.

Diagrama 8 — Infraestructura de Despliegue: Local, Colab A100 y AWS EC2

Figura B.8

Diagrama 8 — Infraestructura de Despliegue: Local, Colab A100 y AWS EC2



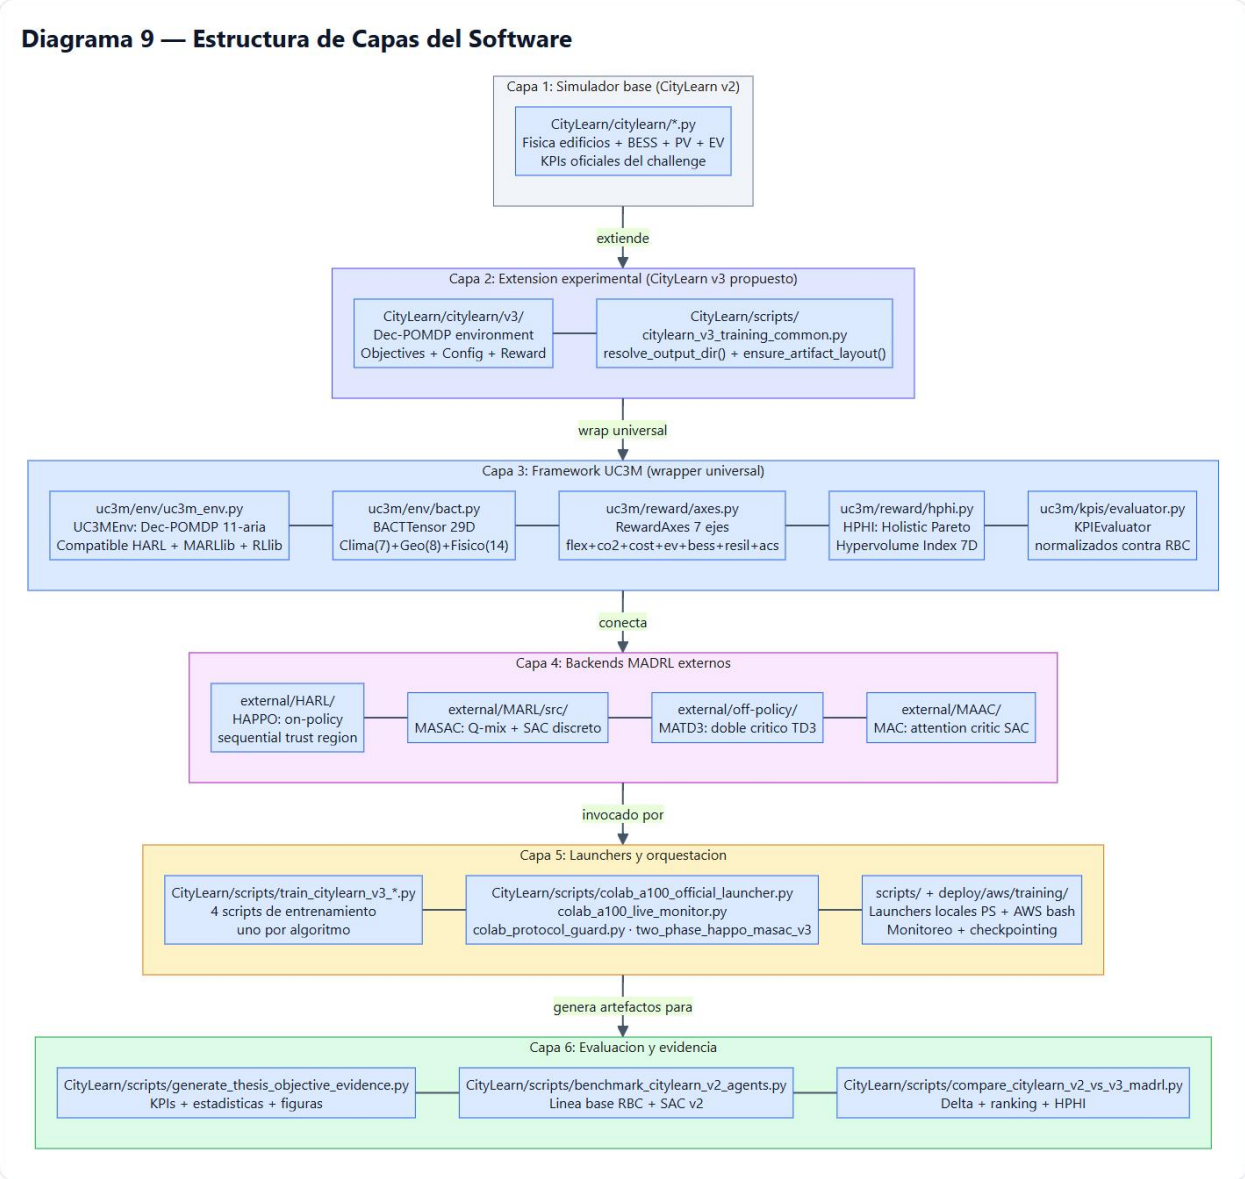
Nota. La figura representa el flujo, arquitectura o componente metodológico del sistema académico MADRL-CityLearn. Fuente: Elaboración propia a partir de la arquitectura del repositorio local, los scripts de construcción del datase, la formalización Dec-POMDP/CTDE y la configuración experimental MADRL; se fundamenta en Oliehoek y Amato (2016), Lowe et al. (2017), Iqbal y Sha (2019), Vázquez-Canteli et al. (2020) y Nweye et al. (2024).

Interpretación de la figura. El diagrama ubica la infraestructura de ejecución local, Colab A100 y AWS EC2 como soporte computacional del entrenamiento. Su función es explicar trazabilidad operacional y no introducir resultados externos a la carpeta Drive auditada.

Diagrama 9 — Estructura de Capas del Software

Figura B.9

Diagrama 9 — Estructura de Capas del Software



Nota. La figura representa el flujo, arquitectura o componente metodológico del sistema académico MADRL-CityLearn. Fuente: Elaboración propia a partir de la arquitectura del

repositorio local, los scripts de construcción del datase, la formalización Dec-POMDP/CTDE y la configuración experimental MADRL; se fundamenta en Oliehoek y Amato (2016), Lowe et al. (2017), Iqbal y Sha (2019), Vázquez-Canteli et al. (2020) y Nweye et al. (2024).

Interpretación de la figura. El diagrama sintetiza siete capas de software: datos, entorno, agentes MADRL, entrenamiento, evaluación, figuras y documento Word. La salida académica se reconstruye desde scripts locales y artefactos reales, incluyendo 12 tratamientos, 600 filas episódicas y 294 archivos listados en manifiestos de checkpoint, lo que reduce el riesgo de transcripción manual.