UNIVERSIDAD NACIONAL DE INGENIERÍA
UNIDAD DE POSGRADO FACULTAD DE INGENIERÍA INDUSTRIAL Y DE SISTEMAS

"MULTI-AGENTE DE APRENDIZAJE POR REFUERZO PROFUNDO PARA LA GESTIÓN COORDINADA DE FLEXIBILIDAD ENERGÉTICA, EMISIONES DE CARBONO Y COSTOS ENERGÉTICOS EN COMUNIDADES INTELIGENTES DE LA CIUDAD DE IQUITOS, 2026"

PARA OPTAR EL GRADO ACADÉMICO DE

MAESTRO CON MENCIÓN EN:

INTELIGENCIA ARTIFICIAL

ELABORADA POR:

BACH. TAPIA CCOYSO, MAC

BACH. ZAMBRANO JOVE, SERGIO MAURICIO

ASESOR:

DR. ZELA MORAYA, WESTER EDISON

LIMA – PERU

2026

DEDICATORIA

A mi familia, por el apoyo incondicional durante este camino de formación académica; a los docentes y colegas de la Universidad Nacional de Ingeniería, por impulsar la investigación aplicada en sistemas eléctricos inteligentes; y a la comunidad académica de Iquitos, cuyo contexto energético motivó el presente estudio.

AGRADECIMIENTOS

Se agradece a la Escuela de Posgrado de la UNI, al equipo de investigación del proyecto MADRL CityLearn v3, a Electro Oriente S.A. y a las instituciones que aportaron datos operativos para el dataset citylearn_iquitos_2023_2025. Asimismo, se reconoce el uso de recursos computacionales en Google Colab para la corrida canónica de 50 episodios (madrl_v3_20260627_164047).

ÍNDICE DE CONTENIDOS

Lista de Tablas 9
Lista de Figuras 11
Resumen 12
Abstract 13
Capítulo I. Planteamiento del Problema 14
1.1. Diagnóstico del problema 14
1.2. Identificación y descripción del problema de estudio 18
1.2.1. Formulación del problema 20
1.2.2. Justificación y alcances 21
1.3. Objetivos e hipótesis de la investigación 28
1.3.1. Objetivos 28
1.3.2. Hipótesis 29
Capítulo II. Marco Teórico 31
2.1. Antecedentes 32
2.1.1. Antecedentes internacionales 32
2.1.2. Antecedentes nacionales y peruanos 48
2.2. Fundamentos teóricos, conceptuales y matemáticos de las variables de investigación 52
2.2.1. Modelo conceptual de la relación entre variables 53
2.2.2. Fundamento teórico del aprendizaje por refuerzo profundo multiagente (MADRL). 54
2.2.3. Variable dependiente: desempeño coordinado de la comunidad energética. 70
2.3. Bases teóricas 78
2.3.1. CityLearn v3 propuesto y delimitación entre la capa experimental de tres ejes y el marco UC3M. 78
2.3.2. Correspondencia entre ejes, objetivos, escenarios e indicadores. 82
2.3.3. Entrenamiento centralizado con ejecución descentralizada e interoperabilidad algorítmica (CTDE). 83
2.3.4. Estructura de observación y acción del esquema multiagente. 87
2.3.5. Formalización multiobjetivo del Dec-POMDP y correspondencia con el marco UC3M. 89
2.3.6. Paradigmas de control energético como referencia del estudio. 92
2.3.7. Coordinación multiagente en la comunidad energética de Iquitos 94

2.3.8. Entorno experimental CityLearn v2 y extensión CityLearn v3 propuesta. 95
2.3.9. Delimitación entre la capa experimental y el marco auxiliar UC3M. 97
2.3.10. Sistema de almacenamiento en baterías. 98
2.3.11. Generación fotovoltaica. 99
2.3.12. Vehículos eléctricos y operación G2V/V2G. 100
2.3.13. Cargas desplazables y demanda no controlada. 101
2.3.14. Catálogo de indicadores y correspondencia con CityLearn v2. 101
2.4. Definición de términos y posición teórica 103
2.4.1. Acción local y acción conjunta. 103
2.4.2. Actor y crítico 103
2.4.3. Agente. 103
2.4.4. Aprendizaje por refuerzo profundo multiagente. 104
2.4.5. Backend algorítmico. 104
2.4.6. Sistema de almacenamiento en batería. 104
2.4.7. Estado de carga. 104
2.4.8. Carga desplazable. 104
2.4.9. CityLearn v2. 105
2.4.10. CityLearn v3 propuesta. 105
2.4.11. Comunidad energética inteligente. 105
2.4.12. Coordinación energética. 105
2.4.13. Desempeño coordinado de la comunidad energética. 105
2.4.14. Proceso de decisión de Márkov descentralizado y parcialmente observable. 106
2.4.15. Entrenamiento centralizado con ejecución descentralizada. 106
2.4.16. Observación local y estado global. 106
2.4.17. Política. 106
2.4.18. Recurso controlable y variable exógena. 106
2.4.19. Generación fotovoltaica. 107
2.4.20. Operación G2V y V2G. 107
2.4.21. Flexibilidad energética. 107
2.4.22. Emisiones de CO_2. 107
2.4.23. Intensidad de carbono. 107
2.4.24. Costos energéticos. 108
2.4.25. Indicador clave de desempeño. 108
2.4.26. Línea base, control y diferencia. 108

2.4.27. Recompensa multiobjetivo. 108
2.4.28. Escenario experimental. 108
2.4.29. Tratamiento experimental. 109
2.4.30. Episodio. 109
2.4.31. Semilla experimental. 109
2.4.32. Corrida canónica. 109
2.4.33. Impacto experimental. 109
2.4.34. Resultado distrital. 110
2.4.35. UC3M. 110
2.4.36. Alcance intraexperimento. 110
Capítulo III. Metodología 111
3.1. Enfoque, tipo, nivel y diseño de investigación 112
3.1.1. Enfoque de investigación 112
3.2. Diseño experimental-computacional factorial 4 × 3 115
3.3. Datos utilizados y fuente empírica 116
3.4. Variables, dimensiones e indicadores 117
3.5. Técnicas, herramientas e instrumentos 118
3.6. Procedimiento experimental 118
3.7. Validez metodológica, trazabilidad y control de sesgos 119
Capítulo IV. Desarrollo de la propuesta 121
4.1. Desarrollo del sistema y arquitectura de software 121
4.2. Modelo de IA: formulación Dec-POMDP 121
4.3. Esquema CTDE 122
4.4. Algoritmos 122
4.5. Función de recompensa multiobjetivo 124
4.6. Aportes originales al motor de simulación 124
4.7. Diseño experimental: matriz de 12 corridas 125
4.8. Implementación 125
4.9. Detalle técnico de la propuesta derivado del resumen 126
4.9.1. Construcción del dataset y fuentes utilizadas 127
4.9.2. Librerías, scripts y herramientas de implementación 128
4.9.3. Arquitectura operativa desde datos hasta resultados 129
4.9.4. Delimitación entre equipos controlados y no controlados 130
4.10. Respuesta operacional a las preguntas específicas PE.1, PE.2 y PE.3 130

Capítulo V. Resultados y contrastación de hipótesis 133
5.1. Mapa de lectura del capitulo 133
5.2. Marco experimental y cobertura 133
5.2.1. Criterios de determinación del impacto (cumplimiento completo) 134
5.3. Resultados descriptivos estadísticos 135
5.3.1. Resultados descriptivos estadísticos 135
5.3.2. OE.1 - resultados descriptivos estadísticos 135
5.3.3. OE.2 - resultados descriptivos estadísticos 137
5.3.4. OE.3 - resultados descriptivos estadísticos 139
5.4. Resultados inferenciales estadísticos 141
5.4.1. OG - resultados inferenciales estadísticos 141
5.4.2. OE.1 - resultados inferenciales estadísticos 142
5.4.3. OE.2 - resultados inferenciales estadísticos 143
5.4.4. OE.3 - resultados inferenciales estadísticos 144
5.5. Otros resultados 144
5.5.1. OG - otros resultados (coordinación multiobjetivo) 145
5.5.2. Catálogo completo de figuras (multicriterio + performance distrito/edificio) 150
5.5.3. OE.1 — otros resultados (flexibilidad energética) 227
5.5.4. OE.2 — otros resultados (emisiones de CO2) 230
5.5.5. OE.3 — otros resultados (costos energéticos) 232
5.5.6. Control de recursos (criterio C5 de impacto) 234
5.5.7. KPIs distrito y edificio (rankings Drive 50 episodios) 239
5.6. Contrastación de hipótesis 242
5.6.1. Hipótesis general (H0G / H1G) 243
5.6.2. Hipotesis especificas OE.1 (HE10 / HE11) 243
5.6.3. Hipotesis especificas OE.2 (HE20 / HE21) 244
5.6.4. Hipótesis especificas OE.3 (HE30 / HE31) 244
5.7. Discusión de resultados 245
5.7.1. Contrastación con antecedentes 245
Capítulo VI. Conclusiones y Recomendaciones 249
6.1. Conclusión general 249
6.2. Conclusiones específicas 249
6.2.1. Flexibilidad energética 249
6.2.2. Emisiones de CO_2. 250

6.2.3. Costos energéticos 250
6.3. Aportes al estado del arte 250
6.4. Aportes a la ciencia 251
6.5. Recomendaciones 252
Referencias Bibliográficas 253
Anexo 1. Resultados reales integrados desde Google Drive 264
A1.1. Resultados distritales por algoritmo y escenario 264
A1.2. Resultados por edificio 267
A1.3. Equipamiento controlado y no controlado 270
Anexo 2. Diagramas de flujo y arquitectura del proyecto 274
A1.4. Diagrama 1 — Visión General del Proyecto (inicio a fin) 274
A1.1. Diagrama 2 — Pipeline del Dataset Iquitos 2023-2025 274
A1.2. Diagrama 3 — Arquitectura Dec-POMDP y CTDE de los 17 Agentes 275
A1.3. Diagrama 4 — Los 4 Algoritmos MADRL: Taxonomia y Diferencias 277
A1.4. Diagrama 5 — Flujo de Entrenamiento: 12 Corridas (two_phase_happo_masac_v3) 278
A1.5. Diagrama 6 — Recompensa Multiobjetivo por Escenario 279
A1.6. Diagrama 7 — Pipeline de evaluación y selección por objetivo 279
A1.7. Diagrama 8 — Infraestructura de Despliegue: Local, Colab A100 y AWS EC2 281
A1.8. Diagrama 9 — Estructura de Capas del Software 282

LISTA DE TABLAS

Tabla 1 Síntesis comparativa de los cuatro algoritmos MADRL seleccionados 63

Tabla 2 comparación de MADRL y la razón por la selección 64

Tabla 3 Adecuación de los cuatro MADRL originales al problema eléctrico (OE.1 / OE.2 / OE.3) 67

Tabla 4 *Correspondencia entre eje, objetivo–hipótesis, escenario y KPI* 83

Tabla 5 Clasificación metodológica de la investigación 114

Tabla 6 Matriz factorial 4 × 3 de tratamientos experimentales 115

Tabla 7 Fuentes de datos y artefactos de análisis 116

Tabla 8 Operacionalización metodológica de variables 117

Tabla 9 Técnicas, herramientas e instrumentos 118

Tabla 10 Procedimiento experimental reproducible 119

Tabla 11 Control metodológico de validez y trazabilidad 120

Tabla 12 Capas de software del sistema MADRL CityLearn v3 121

Tabla 13 Los cuatro algoritmos MADRL y sus backends 122

Tabla 14 Configuración de entrenamiento y delimitación de la evidencia canónica 123

Tabla 15 Parámetros de la función de recompensa multiobjetivo. 124

Tabla 16 Aportes originales al motor de simulación CityLearn 124

Tabla 17 Matriz experimental de 12 corridas oficiales 125

Tabla 18 Componentes detallados de la propuesta sintetizados en el resumen 126

Tabla 19 Fuentes y transformaciones del datase citylearn_iquitos_2023_2025 127

Tabla 20 Herramientas y función dentro de la propuesta MADRL 128

Tabla 21 Cadena de trazabilidad de la propuesta 129

Tabla 22 Respuesta directa a PE.1, PE.2 y PE.3 desde la evidencia descriptiva e inferencial 131

Tabla 23 Estructura del Capítulo 5 por numerales y objetivos 133

Tabla 24 Operacionalización OG/OE → escenario → KPI. 133

Tabla 25 Cobertura de episodios y KPIs finales. 134

Tabla 26 Criterios completos de determinación del impacto (C5 = control de recursos). 134

Tabla 27 Ranking descriptivo integrado (best_madrl_report.json, canónico 3x3). 135

Tabla 28 KPIs distritales OE.1 en E1 (descriptivo). 136

Tabla 29 Ranking descriptivo OE.1 (best_madrl_report.json). 136

Tabla 30 Descriptivo episódico OE.1 (reward_mean por episodio). 136

Tabla 31 KPIs distritales OE.2 en E2 (descriptivo). 138

Tabla 32 Ranking descriptivo OE.2 (best_madrl_report.json).KPIs distritales 138
Tabla 33 Descriptivo episódico OE.2 (emisión distrital por episodio (kgCO2 eq.)).....138
Tabla 34 KPIs distritales OE.3 en E3 (descriptivo). 140

LISTA DE FIGURAS

Figura 1 : Control por edificio CityLearn v3 propuesto (simbología CityLearn v2): Electro Oriente S.A. (B01), comunidad inteligente Iquitos (B02–B17), red pública/SEAI, Actor–Crítico CTDE y formulación Dec-POMDP. 82

RESUMEN

El presente estudio determina el efecto de cuatro algoritmos de aprendizaje por refuerzo profundo multiagente sobre la flexibilidad energética, las emisiones de CO_2 y los costos energéticos de una comunidad inteligente representativa del Sistema Eléctrico Aislado de Iquitos. La investigación adopta un enfoque aplicado, cuantitativo y explicativo mediante simulación computacional, con diseño experimental factorial 4 × 3: cuatro algoritmos y tres escenarios de recompensa orientados a las dimensiones de la variable dependiente. El problema se formaliza como decisión cooperativa con observabilidad parcial y entrenamiento centralizado con ejecución descentralizada. La base empírica corresponde al dataset horario 2023-2025 y a la corrida canónica de entrenamiento conservada en Drive, cuya descripción técnica, fuentes, librerias, equipos y artefactos se desarrolla de manera detallada en la propuesta del Capítulo 4.

La evidencia experimental corresponde exclusivamente a la corrida Drive madrl_v3_20260627_164047 y a sus artefactos results.json, training_summary.json, timeseries.csv, trace.csv, building_kpis.csv, building_behavior_summary.csv, checkpoint_manifest.json y tablas materializadas de KPIs episódicos. Se conservan 597 filas episódicas: HAPPO aporta 49 episodios por escenario como evidencia descriptiva, mientras MAAC, MASAC y MATD3 conservan 50 episodios por escenario para contraste inferencial completo. En OE.1, flexibilidad energética, Kruskal-Wallis rechaza la igualdad entre algoritmos con H=36,3083, p=1,305e-08 y epsilon2=0,2334; MAAC presenta el mayor efecto inferencial y MASAC el mejor KPI anual final. En OE.2, emisiones de CO_2, el efecto es significativo, pero bajo (H=6,2532; p=0,043866; epsilon2=0,0289); MAAC lidera la muestra completa y MASAC el KPI anual final. En OE.3, costos energéticos, no se rechaza H0 (H=2,7613; p=0,251421; epsilon2=0,0052); MATD3 lidera la muestra completa y MAAC el KPI anual final.

Palabras clave: aprendizaje por refuerzo profundo multiagente; comunidades inteligentes; CityLearn; Dec-POMDP; entrenamiento centralizado y ejecución descentralizada; flexibilidad energética; emisiones de CO_2; costos energéticos; Sistema Eléctrico Aislado de Iquitos; Python; pandas; NumPy; requests; pvlib; openpyxl.

ABSTRACT

This academic study determines the effect of four multi-agent deep reinforcement learning algorithms on energy flexibility, CO_2 emissions and energy costs in a smart community representative of the Iquitos Isolated Electric System, Peru. The research follows an applied, quantitative and explanatory computational-simulation approach with a 4 × 3 factorial experimental design: four algorithms and three reward scenarios aligned with the dependent-variable dimensions. The control problem is formalized as cooperative decisión-making under partial observability and centralized training with decentralized execution. The empirical basis is the 2023-2025 hourly dataset and the canonical Drive training run; the technical description of data sources, libraries, equipment and artifacts is developed in detail in the proposal chapter.

The experimental evidence is restricted to the audited Drive run madrl_v3_20260627_164047 and its results, training summaries, timeseries, traces, building KPIs, checkpoint manifests and materialized episodic KPI tables. A total of 597 episodic rows are retained: HAPPO contributes 49 episodes per scenario as descriptive evidence, whereas MAAC, MASAC and MATD3 retain 50 episodes per scenario for complete inferential comparison. For OE.1, energy flexibility, Kruskal-Wallis rejects equality across algorithms (H=36.3083, p=1.305e-08, epsilon2=0.2334), with MAAC showing the strongest complete-sample effect and MASAC the best final annual KPI. For OE.2, CO_2 emissions, the effect is significant but small (H=6.2532, p=0.043866, epsilon2=0.0289), with MAAC leading the complete sample and MASAC leading the final KPI. For OE.3, energy costs, H0 is not rejected (H=2.7613, p=0.251421, epsilon2=0.0052); MATD3 leads the complete sample and MAAC leads the final KPI. Results are interpreted at district, building, scenario, equipment, convergence, checkpoint and trace levels using CityLearn v2 evaluate_v2-compatible KPIs without adding external or synthetic values.

Keywords: multi-agent deep reinforcement learning; smart communities; CityLearn; Dec-POMDP; centralized training and decentralized execution; energy flexibility; CO_2 emissions; energy costs; Iquitos Isolated Electric System; Python; pandas; NumPy; requests; pvlib; openpyxl.

CAPÍTULO I. PLANTEAMIENTO DEL PROBLEMA

1.1. Diagnóstico del problema

La expansión urbana, el crecimiento del parque edificatorio y la electrificación progresiva de los usos finales están modificando tanto la magnitud como el comportamiento temporal de la demanda energética. En 2018, el 55 % de la población mundial residía en áreas urbanas y se proyectó que esta proporción alcanzaría el 68 % en 2050. En este proceso se estima la incorporación de aproximadamente 2 500 millones de personas adicionales a las ciudades, con una concentración predominante del crecimiento en Asia y África (Nations et al., 2018).

La ampliación del entorno urbano se encuentra acompañada por una expansión sostenida de las edificaciones. El sector de edificios y construcción representa aproximadamente el 32 % del consumo mundial de energía y contribuye con alrededor del 34 % de las emisiones globales de dióxido de carbono. Además, se estima que cerca de la mitad de los edificios que existirán en 2050 todavía deberán ser construidos o rehabilitados, por lo que las decisiones actuales sobre diseño, eficiencia, materiales y gestión energética condicionarán durante varias décadas el consumo y las emisiones del sector (Programme & Construction, 2025).

Esta presión ha sido intensificada por la electrificación del transporte, la climatización, los procesos productivos y los servicios digitales. La demanda mundial de electricidad aumentó un 4,3 % en 2024, lo que representó aproximadamente 1 080 TWh adicionales respecto del año anterior. Dicho crecimiento estuvo asociado, entre otros factores, con la electrificación de los usos finales, las altas temperaturas, la actividad industrial y la expansión de los centros de datos (IEA, 2024) y (Global electricity, 2025)

La movilidad eléctrica constituye una manifestación concreta de esta transformación. Durante 2024, la flota mundial de vehículos eléctricos consumió alrededor de 180 TWh, casi un 60 % más que en 2023. Aunque la electromovilidad reduce el consumo directo de combustibles fósiles en el transporte, su incorporación introduce cargas adicionales cuya concentración en determinados horarios puede incrementar los picos de demanda y los requerimientos de generación. Por ello, la reducción de emisiones asociada con los vehículos eléctricos depende también de la fuente utilizada para producir la electricidad y de la coordinación temporal de la recarga (Global electricity, 2025)

En el Perú también se registra una tendencia sostenida hacia la urbanización y la expansión del parque habitacional. Para 2024, se estimó que el 83,1 % de la población nacional aproximadamente 28,29 millones de habitantes residía en áreas urbanas. Asimismo, el número de viviendas particulares registradas pasó de 10 102 849 en 2017 a 13 762 606 en

2025, lo que representa un incremento aproximado del 36,2 %, calculado a partir de las cifras oficiales. Si bien el crecimiento del número de viviendas no equivale directamente al mismo porcentaje de aumento del consumo eléctrico, sí refleja una ampliación de la infraestructura edificada y de la cantidad potencial de puntos de demanda que deben ser atendidos por los sistemas de distribución (*Instituto Nacional de Estadística e Informática*, 2024) y (INEI, 2026)

La transición energética nacional también viene modificando la composición de la oferta eléctrica. Durante 2024, la producción de electricidad en el Perú alcanzó 63 565 GWh, cifra que representó un crecimiento del 2,4 % respecto de 2023. En ese mismo periodo, la generación solar aumentó un 32 %, mientras que la producción proveniente de recursos energéticos renovables no convencionales creció un 47 % (*Ministerio de Energía y Minas (MINEM)*, 2025).

En paralelo, durante 2024 fueron comercializados 6 602 vehículos electrificados en el país, lo que representó un incremento del 47,23 % respecto del año anterior. No obstante, solo una parte correspondió a vehículos eléctricos puros e híbridos enchufables, por lo que la transición hacia una movilidad completamente eléctrica todavía se encuentra en una etapa de desarrollo. El propio Ministerio de Transportes y Comunicaciones ha reconocido que la expansión de la electromovilidad requiere infraestructura de recarga y capacidades de gestión adecuadas para evitar que las nuevas cargas sean incorporadas sin planificación (Ministerio de Transportes y Comunicaciones (*Ministerio de Energía y Minas (MINEM)*, 2025); 2025); (*Ministerio de Transportes y Comunicaciones (MTC)*, 2025)

Estas tendencias muestran que la transición energética no consiste únicamente en incorporar generación renovable, baterías o vehículos eléctricos. También requiere modificar la forma en que la energía es consumida, almacenada y coordinada. Cuando el crecimiento de la demanda y la incorporación de recursos energéticos distribuidos no son acompañados por estrategias de gestión, pueden generarse nuevos picos, rampas más pronunciadas, congestión local, desaprovechamiento de generación renovable y mayores exigencias sobre la infraestructura existente. La literatura especializada sobre comunidades inteligentes coincide en que la coordinación entre edificios resulta necesaria para conciliar los objetivos individuales con las necesidades del conjunto energético (Nweye et al., 2024); (Shen et al., 2022ª); (Wilk et al., 2024a)

La problemática adquiere una relevancia particular en el Sistema Eléctrico Aislado de Iquitos. Electro Oriente S. A. es la empresa concesionaria eléctrica de los sistemas eléctricos de la ciudad de Iquitos, que actualmente es aislados del Sistema Eléctrico Interconectado

Nacional y la producción energía es dependiente principalmente de grupos electrógenos a 100% Diesel. Esta condición reduce las posibilidades de intercambiar energía con otros sistemas ante contingencias, incrementos de demanda o variaciones de generación.

Las restricciones operativas del sistema han motivado intervenciones institucionales recientes. En septiembre de 2024, el MINEM declaró al Sistema Eléctrico de Iquitos en situación de grave deficiencia por insuficiencia de capacidad de producción, con vigencia hasta abril de 2025, actualmente se encuentra en estado de emergencia hasta el 2028 (MINEM, 2025) . Posteriormente, fue conformado un grupo de trabajo multisectorial para formular medidas dirigidas a garantizar un suministro continuo, seguro y confiable; además, en 2026 continuaron desarrollándose acciones oficiales para fortalecer la continuidad y confiabilidad del servicio eléctrico en Iquitos (*Ministerio de Energía y Minas (MINEM)*, 2025).

Dentro de este contexto, la insuficiente flexibilidad energética constituye el primer eje del problema. **La flexibilidad se refiere a la capacidad de modificar temporalmente el consumo, la generación local y el uso del almacenamiento para responder a cambios en la demanda, la disponibilidad renovable, los precios o las condiciones operativas. Cuando esta capacidad no se encuentra disponible o no es gestionada adecuadamente, la demanda puede concentrarse en periodos críticos, las rampas pueden intensificarse y la generación fotovoltaica puede ser desaprovechada**.

En una comunidad de edificios, la falta de coordinación puede provocar que decisiones individualmente convenientes produzcan resultados desfavorables para el conjunto. La carga simultánea de sistemas de almacenamiento y vehículos eléctricos, por ejemplo, podría generar un nuevo pico comunitario, aun cuando cada edificio haya actuado de acuerdo con su propio objetivo. Los estudios de (Nweye et al., 2024) y (Wilk et al., 2024a) muestran que la gestión energética comunitaria debe ser evaluada mediante indicadores como demanda máxima, rampas, factor de carga y comportamiento de los recursos flexibles, debido a que una recompensa agregada no permite interpretar por sí sola la respuesta física del sistema.

El segundo eje corresponde a las emisiones de gases de efecto invernadero y su contribución al calentamiento global. En sistemas con elevada participación de generación térmica, los incrementos de demanda o la ausencia de flexibilidad pueden traducirse en una utilización más intensiva de combustibles fósiles. Por tanto, las emisiones asociadas con la electricidad no dependen únicamente del volumen consumido, sino también del momento en que la demanda es atendida y de la tecnología de generación disponible en cada periodo.

La incorporación de generación fotovoltaica no garantiza por sí misma una reducción proporcional de emisiones. Si el consumo no es desplazado hacia los periodos de mayor disponibilidad solar, o si las baterías y los vehículos son recargados durante intervalos con mayor intensidad de carbono, parte del beneficio ambiental puede ser perdido. Por esta razón, CityLearn v2 incorpora métricas específicas de emisiones y señales temporales de intensidad de carbono, con el propósito de evaluar si las políticas de control desplazan efectivamente el consumo hacia condiciones ambientalmente más favorables (Nweye et al., 2024).

En la presente tesis, la señal ambiental del SEAI Iquitos ha sido construida mediante un factor base de 0,790 kg CO_2/kWh y un componente dinámico asociado con el desplazamiento fotovoltaico. Este valor constituye un parámetro interno del modelo de intensidad de carbono y no un resultado experimental. Su formulación, junto con la arquitectura de la señal ambiental, forma parte de la extensión computacional desarrollada en el proyecto.

El tercer eje corresponde a los costos energéticos. En una comunidad inteligente, el gasto eléctrico no depende únicamente del consumo acumulado, sino también del momento en que la energía es demandada, de los periodos tarifarios, de la potencia máxima alcanzada y de la utilización de los sistemas de generación y almacenamiento. Cuando los recursos son operados sin coordinación, el consumo puede trasladarse hacia periodos de mayor precio o pueden producirse nuevos picos que deterioren el resultado económico del conjunto.

Los objetivos económicos pueden entrar en conflicto con los objetivos ambientales y energéticos. Una estrategia orientada exclusivamente a reducir costos podría desplazar demanda hacia un periodo de menor tarifa, aunque la electricidad disponible presente una mayor intensidad de carbono. Del mismo modo, una política enfocada únicamente en emisiones podría incrementar los picos de potencia o utilizar con mayor intensidad el almacenamiento, sin garantizar el menor costo posible. La literatura sobre gestión energética comunitaria confirma que la reducción de costos y el aplanamiento de la demanda requieren coordinación entre edificios y no solo decisiones independientes de cada agente (Shen et al., 2022ª); (Wilk et al., 2024a).

Los tres ejes se encuentran estrechamente vinculados. Una comunidad con escasa flexibilidad puede requerir una respuesta más intensa de la generación térmica; esta mayor utilización puede elevar las emisiones de CO_2; y la concentración temporal del consumo puede incrementar los costos. En sentido inverso, una reducción del costo no implica necesariamente una disminución de emisiones, mientras que una política ambientalmente favorable puede no producir el mejor resultado en flexibilidad. Por tanto, el problema debe

ser entendido como una tensión multiobjetivo entre adaptación energética, descarbonización y eficiencia económica.

Frente a esta situación, se requieren mecanismos capaces de coordinar edificios heterogéneos, sistemas fotovoltaicos, baterías, vehículos eléctricos y cargas desplazables. CityLearn v2 proporciona un entorno reproducible para representar comunidades interactivas con la red, incorporar recursos distribuidos y evaluar indicadores de flexibilidad, emisiones y costos bajo condiciones homogéneas (Nweye et al., 2024).

Sobre esta base, en la tesis ha sido propuesta una extensión experimental denominada CityLearn v3, la cual no constituye una versión oficial del entorno. Mediante esta extensión, una comunidad conformada por 17 edificios es representada como un sistema multiagente parcialmente observable. Los algoritmos HAPPO, MASAC, MATD3 y MAAC son evaluados bajo tres escenarios de recompensa: E1, orientado a la flexibilidad; E2, orientado a las emisiones de CO_2; y E3, orientado a los costos energéticos. Esta estructura corresponde al diseño factorial 4 × 3 conservado en el documento final.

En consecuencia, el diagnóstico evidencia que el problema central no consiste únicamente en incorporar recursos energéticos distribuidos, sino en determinar cómo deben ser coordinados para evitar que la expansión de la demanda, la transición energética y la electrificación produzcan nuevos picos, emisiones persistentes o costos elevados. En este marco, aún debe determinarse en qué medida los algoritmos MADRL evaluados generan efectos diferenciados sobre los tres ejes y cuál ofrece el desempeño más favorable en cada uno de ellos.

1.2. Identificación y descripción del problema de estudio

El problema de estudio se identifica en la insuficiente capacidad para gestionar de manera coordinada los recursos energéticos distribuidos y la demanda de una comunidad inteligente representativa del SEAI Iquitos. Esta dificultad se manifiesta en tres dimensiones relacionadas: limitada flexibilidad para adaptar el perfil de carga, persistencia de emisiones asociadas con la generación térmica y costos energéticos condicionados por la concentración temporal del consumo.

En la dimensión de flexibilidad energética, el problema se presenta cuando las cargas, las baterías y los vehículos eléctricos no responden de forma coordinada ante las variaciones de generación, demanda y disponibilidad de los equipos. En tales condiciones, pueden producirse incrementos de la demanda máxima, rampas más pronunciadas y un menor aprovechamiento de la generación fotovoltaica. La respuesta individual de cada edificio

podría ser localmente adecuada, pero generar un resultado agregado desfavorable cuando varios agentes ejecutan acciones similares durante el mismo intervalo.

En la dimensión ambiental, el problema se expresa en las emisiones de CO_2 asociadas con el abastecimiento eléctrico de una comunidad inserta en un sistema aislado con dependencia térmica. La reducción de energía consumida no garantiza por sí misma una disminución de emisiones, debido a que el efecto ambiental depende de la intensidad de carbono correspondiente a cada periodo. Por ello, la gestión debe considerar no solo cuánto se consume, sino también cuándo se consume y qué fuente de generación atiende dicha demanda.

En la dimensión económica, el problema se manifiesta cuando el consumo se concentra en periodos de mayor costo o cuando la operación descoordinada de los recursos genera picos adicionales. La existencia de tarifas diferenciadas entre periodos de punta y fuera de punta implica que dos políticas con un consumo energético semejante pueden producir costos distintos. Asimismo, una reducción del costo no puede ser interpretada como una mejora integral cuando ha sido obtenida a cambio de mayores emisiones o de un deterioro de la flexibilidad.

Las causas técnicas del problema se relacionan con la heterogeneidad de los edificios, la diversidad de equipos controlables, la presencia de demanda no flexible, la variabilidad de la generación fotovoltaica y la disponibilidad temporal de los vehículos eléctricos. Cada edificio recibe observaciones locales y toma decisiones descentralizadas, pero no dispone durante la ejecución del estado interno completo de los demás agentes. Esta condición introduce observabilidad parcial, interdependencia y no estacionariedad en el proceso de aprendizaje.

La formalización como Dec-POMDP resulta pertinente porque permite representar decisiones secuenciales, observaciones locales, acciones simultáneas y recompensas cooperativas en entornos parcialmente observables (Oliehoek & Amato, 2016). El paradigma de entrenamiento centralizado con ejecución descentralizada permite emplear información conjunta durante el aprendizaje y conservar políticas locales durante la operación. Este enfoque ha sido utilizado como fundamento de distintos métodos multiagente, incluidos los modelos actor-crítico y los mecanismos de atención (Iqbal & Sha, 2019); (Lowe et al., 2020).

La incorporación de HAPPO responde a la necesidad de coordinar agentes heterogéneos sin depender exclusivamente del intercambio de parámetros. La versión revisada por pares del trabajo de (Zhong et al., 2024) fue publicada en 2024 y presenta HAPPO como una aproximación derivada del marco de aprendizaje por refuerzo con agentes heterogéneos (Zhong et al., 2024).

No obstante, la formulación Dec-POMDP y la implementación de algoritmos MADRL constituyen la respuesta computacional al problema, no el problema sustantivo. La brecha científica reside en que todavía debe determinarse qué efectos diferenciados producen HAPPO, MASAC, MATD3 y MAAC sobre la flexibilidad, las emisiones y los costos de la comunidad modelada, así como si el algoritmo que lidera una dimensión mantiene ese desempeño en las restantes.

Para responder esta brecha, los algoritmos son evaluados bajo una comunidad fija, el mismo conjunto de datos, una arquitectura común de recompensa y tres escenarios alineados con las dimensiones de la variable dependiente. E1 prioriza la flexibilidad energética, E2 las emisiones de CO_2 y E3 los costos energéticos. Estas condiciones constituyen controles metodológicos para la comparación; no reemplazan la problemática energética, ambiental y económica que da origen a la investigación.

Las manifestaciones observables son examinadas mediante demanda máxima, rampas, factor de carga, consumo neto, emisiones ponderadas por intensidad de carbono, costo acumulado y comportamiento por edificio. La comparación también considera la actuación de las baterías, los cargadores, la generación fotovoltaica y las cargas controlables. De esta manera, el efecto del algoritmo no es reducido a la recompensa de entrenamiento, sino que es interpretado mediante indicadores físicos y económicos compatibles con el entorno de simulación.

La evidencia experimental conservada se limita a la corrida canónica madrl_v3_20260627_164047. Se dispone de 597 registros episódicos: HAPPO conserva 49 episodios por escenario, mientras que MAAC, MASAC y MATD3 conservan 50 episodios por escenario. La diferencia no ha sido completada mediante imputación y deberá ser considerada al interpretar la evidencia descriptiva e inferencial.

1.2.1. Formulación del problema

La formulación se deriva de la necesidad de determinar el efecto del factor algoritmo MADRL sobre las tres dimensiones de la gestión energética coordinada. La pregunta general integra los resultados de flexibilidad, emisiones y costos, mientras que las preguntas específicas separan cada eje para evitar que una recompensa global o un único ranking oculte los compromisos existentes entre objetivos.

1.2.1.1. Formulación del problema general

¿En qué medida el algoritmo MADRL (aprendizaje por refuerzo profundo multiagente) impacta en la gestión coordinada de la flexibilidad energética, las emisiones de CO_2 y los

costos energéticos en comunidades inteligentes de la ciudad de Iquitos, y cuál de los algoritmos presenta el mejor desempeño a nivel global?

1.2.1.2. Formulación de los problemas específicos

PE.1: ¿En qué medida el algoritmo MADRL impacta en la flexibilidad energética en comunidades inteligentes de la ciudad de Iquitos, y cuál de los algoritmos presenta el mejor desempeño en el escenario E1?

PE.2: ¿En qué medida el algoritmo MADRL impacta en las emisiones de CO_2 en comunidades inteligentes de la ciudad de Iquitos, y cuál de los algoritmos presenta el mejor desempeño en el escenario E2?

PE.3: ¿En qué medida el algoritmo MADRL impacta en los costos energéticos en comunidades inteligentes de la ciudad de Iquitos, y cuál de los algoritmos presenta el mejor desempeño en el escenario E3?

1.2.2. Justificación y alcances

1.2.2.1. Justificación

a) Justificación teórica.

La investigación se justifica teóricamente porque articula tres campos que suelen ser abordados de manera separada: la simulación energética de comunidades de edificios, el aprendizaje por refuerzo profundo multiagente y la evaluación estadística de políticas de control. CityLearn v2 proporciona un entorno reproducible para representar recursos energéticos distribuidos y evaluar indicadores comunitarios; el Dec-POMDP permite formalizar decisiones descentralizadas bajo observabilidad parcial; y CTDE permite utilizar información conjunta durante el entrenamiento sin exigir un controlador centralizado durante la ejecución (Nweye et al., 2024); (Oliehoek & Amato, 2016).

La comparación conjunta de HAPPO, MASAC, MATD3 y MAAC permite examinar mecanismos de aprendizaje con fundamentos diferentes dentro de una misma estructura experimental. HAPPO se basa en actualizaciones secuenciales para agentes heterogéneos; MAAC incorpora críticos centralizados con mecanismos de atención; mientras que MASAC y MATD3 representan variantes multiagente de métodos actor-crítico fuera de política. En consecuencia, los algoritmos son tratados como niveles de la variable independiente y no como implementaciones aisladas.

El aporte teórico no consiste en afirmar de antemano la superioridad de una técnica, sino en establecer una relación explicativa entre el mecanismo algorítmico, la coordinación de los

agentes y las consecuencias observadas sobre flexibilidad, emisiones y costos. Esta perspectiva evita que la interpretación quede reducida a la recompensa de entrenamiento y permite analizar los compromisos entre objetivos.

b) Justificación de técnica.

La investigación se justifica en términos de flexibilidad porque la incorporación de generación fotovoltaica, almacenamiento, vehículos eléctricos y cargas desplazables no garantiza que el perfil de demanda sea mejorado. Cuando estos recursos son gestionados sin coordinación, pueden producirse picos secundarios, rampas más pronunciadas o desaprovechamiento de energía renovable.

La literatura sobre comunidades interactivas con la red indica que la flexibilidad debe ser evaluada a escala comunitaria y mediante indicadores físicos. (Nweye et al., 2024) incorporaron métricas de demanda máxima, rampas y factor de carga dentro de CityLearn v2, mientras que (Wilk et al., 2024b) mostraron que la coordinación multiagente puede contribuir al aplanamiento de la curva de demanda y a la gestión conjunta de edificios y vehículos eléctricos.

En el SEAI Iquitos, la flexibilidad resulta especialmente relevante debido a la condición aislada y a la dependencia de generación térmica. La reducción de picos y la adaptación del consumo a la disponibilidad fotovoltaica podrían disminuir las exigencias sobre las unidades de generación; sin embargo, la tesis no interpreta la simulación como un despliegue real, sino como evidencia computacional bajo condiciones delimitadas.

c) Justificación económica.

La investigación se justifica económicamente porque el costo energético depende del volumen consumido, del momento de consumo, de la potencia máxima y del uso de los recursos distribuidos. La existencia de periodos tarifarios de punta y fuera de punta permite que políticas con consumos semejantes produzcan resultados económicos diferentes.

La operación no coordinada puede trasladar cargas hacia intervalos de mayor precio o provocar nuevos picos. Por el contrario, la gestión conjunta de almacenamiento, vehículos eléctricos y cargas flexibles puede reducir costos cuando las decisiones son adoptadas considerando las señales temporales del sistema. Los resultados reportados por (Shen et al., 2022ª) y (Wilk et al., 2024a) respaldan la necesidad de evaluar conjuntamente la coordinación energética y el desempeño económico.

El aporte económico de la tesis consiste en comparar los efectos de las políticas sobre indicadores de costo distrital y por edificio. No se pretende estimar el ahorro financiero de una implementación real ni extrapolar los resultados a tarifas o comunidades no evaluadas.

d) Justificación ambiental.

La investigación se justifica ambientalmente porque el SEAI Iquitos mantiene una dependencia importante de generación térmica. En este contexto, el desplazamiento temporal de la demanda puede modificar la cantidad de electricidad atendida durante periodos de mayor o menor intensidad de carbono.

La reducción de emisiones requiere que el consumo, el almacenamiento y la generación fotovoltaica sean coordinados. Una política orientada únicamente al menor precio puede no coincidir con el periodo de menor intensidad de carbono; de igual manera, una política centrada exclusivamente en emisiones puede producir efectos desfavorables en picos o costos. CityLearn v2 incorpora métricas específicas para examinar estas relaciones y evitar que el desempeño ambiental sea inferido únicamente a partir del consumo energético (Nweye et al., 2024).

La señal ambiental de la tesis utiliza como parámetro base 0,790 kg CO_2/kWh. Su función es representar la intensidad de carbono del sistema simulado y permitir la comparación entre políticas; no constituye una medición directa de las emisiones reales del SEAI Iquitos.

1.2.2.2. Alcances

El alcance del estudio ha sido delimitado en correspondencia directa con la formulación del problema general y con los tres problemas específicos. En consecuencia, la investigación se orienta a determinar en qué medida los algoritmos de aprendizaje por refuerzo profundo multiagente HAPPO, MASAC, MATD3 y MAAC impactan en la gestión coordinada de la flexibilidad energética, las emisiones de CO_2 y los costos energéticos. Asimismo, se busca establecer cuál de los algoritmos presenta el mejor desempeño en cada escenario y cuál alcanza el resultado más favorable a nivel global cuando las tres dimensiones son evaluadas de manera integrada.

En esta investigación, el término impacto se entiende como el efecto diferenciado producido por el tipo de algoritmo sobre los indicadores energéticos, ambientales y económicos obtenidos dentro del entorno de simulación. Por tanto, no se hace referencia a un impacto causal comprobado mediante una intervención física en el sistema eléctrico de Iquitos, sino a diferencias observables y estadísticamente evaluables entre las políticas MADRL bajo condiciones experimentales homogéneas. Esta precisión permite conservar la

formulación del problema definida en la tesis sin extender sus resultados más allá de la evidencia computacional disponible.

a. Alcance temático

El alcance temático comprende saber el impacto del MADRL en el global y las tres dimensiones del variable despedidme y la comparación de HAPPO, MASAC, MATD3 y MAAC como alternativas de gestión coordinada en una comunidad inteligente. Los algoritmos constituyen los niveles de la variable independiente, mientras que la variable dependiente se encuentra representada por la gestión coordinada de la flexibilidad energética, las emisiones de CO_2 y los costos energéticos.

La primera dimensión corresponde a la flexibilidad energética y se encuentra asociada con el problema específico PE.1. Su evaluación se desarrolla en el escenario E1, mediante indicadores orientados a determinar la capacidad de los agentes para modificar el perfil temporal de consumo, reducir la demanda máxima, suavizar las rampas horarias, mejorar el factor de carga y coordinar el aprovechamiento de la generación fotovoltaica, los sistemas de almacenamiento, las cargas desplazables y los vehículos eléctricos. Por consiguiente, la identificación del algoritmo con mejor desempeño en E1 no se sustenta únicamente en la recompensa del entrenamiento, sino en el comportamiento de los indicadores físicos de flexibilidad definidos en la tesis.

La segunda dimensión comprende las emisiones de CO_2 y responde al problema específico PE.2. Su análisis se realiza en el escenario E2, considerando la energía demandada por la comunidad, la intensidad temporal de carbono y las emisiones calculadas a escala distrital y por edificio. El alcance ambiental permite determinar si las políticas modifican el momento en que la electricidad es consumida, si favorecen el aprovechamiento de la generación fotovoltaica y si producen diferencias en las emisiones asociadas con la energía importada. No se evalúan otros gases de efecto invernadero ni emisiones directas procedentes de fuentes móviles, procesos industriales o centrales físicas no representadas en el entorno.

La tercera dimensión corresponde a los costos energéticos y se vincula con el problema específico PE.3. Su evaluación se desarrolla en el escenario E3, mediante señales tarifarias diferenciadas por periodos de punta y fuera de punta, costos acumulados y resultados económicos por edificio y para la comunidad. El análisis permite identificar en qué medida cada algoritmo modifica el costo asociado con el consumo y con la coordinación temporal de los recursos distribuidos. Sin embargo, no se incluyen costos de inversión, reposición,

mantenimiento, depreciación, financiamiento ni implementación física de los sistemas fotovoltaicos, las baterías o los cargadores.

El mejor algoritmo en cada escenario será determinado a partir de los indicadores correspondientes a su dimensión. En cambio, el mejor algoritmo a nivel global será identificado mediante la integración de los resultados de flexibilidad, emisiones y costos. Esta valoración no implica que un algoritmo deba ocupar el primer lugar en todos los indicadores, sino que deberá presentar el desempeño conjunto más favorable o el compromiso más equilibrado entre los tres objetivos. Por ello, la evaluación global se sustentará en el procedimiento de ranking y en el análisis multicriterio previsto en la metodología, evitando que la conclusión dependa exclusivamente de una recompensa agregada.

b. Alcance espacial

El alcance espacial corresponde a una comunidad inteligente simulada con aplicabilidad al contexto energético de la ciudad de Iquitos y del Sistema Eléctrico Aislado de Iquitos. La comunidad se encuentra integrada por 17 edificios reales de carácter institucional y comercial, cuyos perfiles son empleados para representar agentes con demandas, equipos y condiciones operativas heterogéneas.

Aunque la formulación del problema utiliza la expresión “comunidades inteligentes de la ciudad de Iquitos”, la evidencia empírica se encuentra delimitada a la comunidad de 17 edificios modelada en el entorno de simulación. En consecuencia, los resultados no representan la totalidad de edificaciones, usuarios, alimentadores o sistemas eléctricos de la ciudad. La aplicabilidad territorial se refiere al contexto y a los datos utilizados para construir el caso de estudio, no a una validación general para todas las comunidades inteligentes de Iquitos. El documento final delimita el caso como una comunidad simulada representativa del SEAI Iquitos.

c. Alcance temporal

El alcance temporal de los datos comprende el periodo 2023–2025. El dataset está conformado por 26 304 registros horarios, equivalentes a tres años consecutivos de información. Cada episodio anual comprende 8 760 pasos horarios, mediante los cuales son representadas las variaciones diarias, semanales y estacionales de la demanda, la generación fotovoltaica, las señales tarifarias, la intensidad de carbono y la disponibilidad de los recursos energéticos.

La revisión académica incorpora principalmente artículos científicos, tesis doctorales, tesis de maestría, libros especializados y documentos técnicos publicados entre 2015 y 2026.

No obstante, este intervalo corresponde al alcance documental de la investigación y no debe confundirse con el periodo de los datos energéticos analizados.

d. Alcance metodológico

El estudio presenta un enfoque cuantitativo y una orientación aplicada, debido a que se utilizan datos numéricos y modelos computacionales para evaluar una propuesta de gestión energética. Su alcance es comparativo y explicativo dentro del entorno simulado, puesto que se examina el efecto diferenciado del factor algoritmo sobre las tres dimensiones de la variable dependiente.

El diseño cuasiexperimental se organiza mediante una estructura factorial 4 × 3. Los cuatro niveles del factor algoritmo corresponden a HAPPO, MASAC, MATD3 y MAAC, mientras que los tres escenarios corresponden a E1 para flexibilidad energética, E2 para emisiones de CO_2 y E3 para costos energéticos. Esta organización genera 12 tratamientos algoritmo-escenario, ejecutados bajo una misma comunidad, el mismo conjunto de datos, una arquitectura de recompensa previamente definida y criterios homogéneos de evaluación. La matriz experimental de los 12 tratamientos se encuentra documentada en la versión final de la tesis.

La comparación comprende análisis descriptivos de tendencia central, dispersión, evolución del entrenamiento y comportamiento de los indicadores. Cuando la cobertura de los datos lo permite, se aplican procedimientos inferenciales para establecer si las diferencias observadas entre algoritmos son estadísticamente significativas. No obstante, la interpretación deberá diferenciar entre significación estadística, magnitud del efecto y relevancia energética, debido a que una diferencia estadística no implica necesariamente una mejora operativa considerable.

e. Alcance empírico

La evidencia empírica se restringe a los artefactos materializados de la corrida canónica madrl_v3_20260627_164047. La base disponible contiene 597 registros episódicos. HAPPO conserva 49 episodios por escenario, mientras que MAAC, MASAC y MATD3 conservan 50 episodios por escenario.

Los resultados proceden de archivos de entrenamiento, series temporales, trazas de actuación, KPI distritales, indicadores por edificio, resúmenes de comportamiento y manifiestos de puntos de control. Por tanto, la comparación se sustenta en los datos efectivamente conservados y no en resultados reconstruidos manualmente.

La cobertura desigual de HAPPO obliga a distinguir su evidencia descriptiva de las comparaciones inferenciales que requieren muestras completas de 50 episodios. En consecuencia, HAPPO podrá ser considerado en los rankings descriptivos y en los resultados finales disponibles, pero no deberá presentarse como si contara con la misma cobertura inferencial que los otros algoritmos cuando el procedimiento estadístico exija muestras equivalentes.

f. Alcance computacional

La implementación comprende Python 3.9, PyTorch 2.8.0+cu126, CityLearn v2, Gymnasium, PettingZoo y las librerías empleadas para procesamiento de datos, entrenamiento, evaluación estadística y generación de figuras y tablas. Las ejecuciones fueron desarrolladas mediante una computadora local equipada con una GPU NVIDIA RTX 4060 Laptop de 8 GB y mediante Google Colab con GPU NVIDIA A100.

CityLearn v2 constituye el entorno base utilizado por la investigación. La denominación CityLearn v3 propuesta corresponde a una extensión experimental desarrollada para la tesis, mediante la cual fueron incorporados los datos de Iquitos, las señales ambientales y económicas, la comunidad multiagente y los componentes necesarios para evaluar HAPPO, MASAC, MATD3 y MAAC. En consecuencia, CityLearn v3 no debe ser presentada como una versión oficial publicada por los desarrolladores de CityLearn.

La trazabilidad computacional se mantiene mediante los artefactos results.json, training_summary.json, timeseries.csv, trace.csv, building_kpis.csv, building_behavior_summary.csv, checkpoint_manifest.json y los archivos de indicadores episódicos materializados. La configuración técnica del entorno y la matriz de corridas se encuentran documentadas en el Capítulo 4 de la tesis.

g. Delimitaciones y exclusiones

La investigación no modela físicamente la red eléctrica de Iquitos. Por tanto, no se reproducen flujos de potencia, perfiles de tensión, regulación de frecuencia, cortocircuitos, coordinación de protecciones, estabilidad transitoria, pérdidas eléctricas detalladas ni restricciones electromecánicas completas de los alimentadores.

Tampoco se realiza el despacho económico de unidades reales, una validación en tiempo real ni un despliegue operativo en instalaciones de Electro Oriente S. A.A. Las decisiones de los agentes se ejecutan dentro de un entorno energético simulado y no producen efectos directos sobre centrales, subestaciones, redes de distribución o usuarios reales.

El estudio no incorpora investigación con sujetos humanos, encuestas, entrevistas, experimentos de comportamiento de ocupantes ni evaluación social directa. La presencia y el comportamiento de los usuarios son representados mediante perfiles de demanda y disponibilidad contenidos en los datos y en las reglas del entorno.

La investigación tampoco incluye una evaluación financiera integral. En consecuencia, no son calculados el valor actual neto, la tasa interna de retorno, el periodo de recuperación, los costos de inversión ni los costos reales de operación y mantenimiento de una futura implementación. El análisis económico se restringe a los costos energéticos modelados mediante las señales tarifarias del entorno.

h. Alcance de la inferencia y generalización

La inferencia se encuentra limitada a la corrida canónica y a una semilla común materializada por 12 tratamientos. Aunque la metodología puede ser ampliada posteriormente hacia un diseño multisemilla, no se atribuyen resultados a las semillas que todavía no han sido ejecutadas. Por ello, las conclusiones representan evidencia intraexperimento y no una validación universal del comportamiento de los algoritmos.

Los resultados no se generalizan de manera absoluta a otras ciudades, comunidades, configuraciones de edificios, periodos climáticos, estructuras tarifarias o sistemas eléctricos. Tampoco puede afirmarse que el algoritmo identificado como mejor a nivel global mantendrá esa posición ante cambios en las funciones de recompensa, hiperparámetros, semillas, tecnologías o indicadores utilizados.

En síntesis, el alcance del estudio permite responder el problema general mediante la comparación integrada de HAPPO, MASAC, MATD3 y MAAC, y permite responder PE.1, PE.2 y PE.3 mediante los escenarios E1, E2 y E3, respectivamente. Al mismo tiempo, la interpretación queda restringida a la comunidad simulada de 17 edificios, al periodo 2023–2025, a los 12 tratamientos experimentales y a la evidencia real conservada en la corrida canónica. Esta delimitación mantiene la correspondencia entre la formulación del problema, los objetivos, las hipótesis, las variables y los resultados disponibles.

1.3. Objetivos e hipótesis de la investigación

1.3.1. Objetivos

1.3.1.1. Objetivo general

OG. - Determinar el impacto de los algoritmos aprendizaje por refuerzo profundo multiagente (MADRLs) en la gestión coordinada de la flexibilidad energética, las emisiones

de CO_2 y los costos energéticos en comunidades inteligentes de la ciudad de Iquitos, e identificar cuál de los algoritmos presenta el mejor desempeño a nivel global.

1.3.1.2. Objetivos específicos

OE.1: Determinar el impacto de los algoritmos MADRLs en la flexibilidad energética en comunidades inteligentes de la ciudad de Iquitos e identificar cuál de los algoritmos presenta el mejor desempeño en el escenario E1.

OE.2: Determinar el impacto de los algoritmos MADRLs en las emisiones de CO_2 en comunidades inteligentes de la ciudad de Iquitos e identificar cuál de los algoritmos presenta el mejor desempeño en el escenario E2.

OE.3: Determinar el impacto de los algoritmos MADRLs en los costos energéticos en comunidades inteligentes de la ciudad de Iquitos e identificar cuál de los algoritmos presenta el mejor desempeño en el escenario E3.

1.3.2. Hipótesis

1.3.2.1. Hipótesis general

H_0G.-El algoritmo MADRL no impacta de manera estadísticamente significativa y diferenciada en la gestión coordinada de la flexibilidad energética, las emisiones de CO_2 y los costos energéticos en comunidades inteligentes de la ciudad de Iquitos, y no existen diferencias significativas en el desempeño global de los algoritmos.

H_1G.- El algoritmo MADRL impacta de manera estadísticamente significativa y diferenciada en la gestión coordinada de la flexibilidad energética, las emisiones de CO_2 y los costos energéticos en comunidades inteligentes de la ciudad de Iquitos, y el desempeño global difiere entre los algoritmos.

1.3.2.2. Hipótesis específicas

HE_{10}.- El algoritmo MADRL no impacta de manera estadísticamente significativa en la flexibilidad energética en comunidades inteligentes de la ciudad de Iquitos, y no existen diferencias significativas entre los algoritmos evaluados en el escenario E1.

HE_{11}.- El algoritmo MADRL impacta de manera estadísticamente significativa en la flexibilidad energética en comunidades inteligentes de la ciudad de Iquitos, y existen diferencias significativas entre los algoritmos evaluados en el escenario E1.

HE_{20}.- El algoritmo MADRL no impacta de manera estadísticamente significativa en las emisiones de CO_2 en comunidades inteligentes de la ciudad de Iquitos, y no existen diferencias significativas entre los algoritmos evaluados en el escenario E2.

HE_{21}**.-** El algoritmo MADRL impacta de manera estadísticamente significativa en las emisiones de CO_2 en comunidades inteligentes de la ciudad de Iquitos, y existen diferencias significativas entre los algoritmos evaluados en el escenario E2.

HE_{30}.-El algoritmo MADRL no impacta de manera estadísticamente significativa en los costos energéticos en comunidades inteligentes de la ciudad de Iquitos, y no existen diferencias significativas entre los algoritmos evaluados en el escenario E3.

HE_{31}.-El algoritmo MADRL impacta de manera estadísticamente significativa en los costos energéticos en comunidades inteligentes de la ciudad de Iquitos, y existen diferencias significativas entre los algoritmos evaluados en el escenario E3.

CAPÍTULO II. MARCO TEÓRICO

El presente capítulo desarrolla los fundamentos conceptuales, matemáticos y tecnológicos que sustentan el análisis del impacto de los algoritmos de aprendizaje por refuerzo profundo multiagente en la gestión coordinada de la flexibilidad energética, las emisiones de CO_2 y los costos energéticos. Su finalidad consiste en construir una base teórica coherente con la formulación del problema, los objetivos, las hipótesis y las variables definidas para una comunidad inteligente representativa de la ciudad de Iquitos.

El problema abordado presenta una naturaleza secuencial, cooperativa, multiobjetivo y parcialmente observable. Cada edificio dispone de información local, controla únicamente determinados recursos energéticos y, al mismo tiempo, contribuye a un comportamiento agregado que se manifiesta en la demanda máxima, las rampas de consumo, las emisiones asociadas con la electricidad y el costo energético comunitario. Debido a esta interdependencia, la gestión no puede ser explicada adecuadamente mediante un agente aislado ni mediante una función de optimización estática.

La literatura especializada ha mostrado que los recursos energéticos distribuidos pueden incrementar la capacidad de adaptación de los edificios y comunidades frente a las necesidades de la red. Sin embargo, la generación fotovoltaica, los sistemas de almacenamiento, los vehículos eléctricos y las cargas desplazables no generan flexibilidad de manera automática. Su aportación depende de la forma en que son coordinados, de las señales económicas y ambientales utilizadas, de las restricciones físicas incorporadas y del mecanismo algorítmico empleado para aprender las decisiones.

Asimismo, muestra una evolución desde controladores basados en reglas y control predictivo hacia enfoques de aprendizaje capaces de coordinar recursos energéticos distribuidos en condiciones de incertidumbre. CityLearn y CityLearn v2 aportan entornos comparables para control de edificios y comunidades; los trabajos de (Nweye et al., 2024), (Silvestri, 2024) y (Lowe et al., 2020) destacan que el desempeño práctico depende de la calidad de los datos, de la representación física, de la seguridad operativa y de la capacidad de generalización. En paralelo, la literatura MARL evidencia que la heterogeneidad de agentes, la no estacionariedad y la asignación de crédito requieren mecanismos de coordinación explícitos. La brecha abordada por la tesis consiste en comparar HAPPO, MASAC, MATD3 y MAAC con el mismo dataset de Iquitos, la misma arquitectura de recompensa, pesos definidos por escenario y un protocolo común de trazabilidad (Vázquez-Canteli & Nagy, 2019a); (Nweye et al., 2024); (Silvestri, 2024); (Zhong et al., 2024).

(Nweye et al., 2024) sostiene que las comunidades interactivas con la red pueden suministrar flexibilidad continua mediante la coordinación de recursos distribuidos; no obstante, también identifica barreras relacionadas con la eficiencia de los datos, la seguridad de las políticas y su capacidad de generalización. En una perspectiva complementaria, (Silvestri, 2024) muestra que el aprendizaje por refuerzo puede reducir la dependencia de modelos físicos completos en el control de edificios, aunque su aplicación debe ser contrastada con métodos convencionales y evaluada bajo restricciones operativas verificables. Las investigaciones de (Shen et al., 2022b) y (R. Wang, 2024ª) profundizan esta precaución al demostrar que, en sistemas eléctricos, las políticas aprendidas requieren mecanismos de seguridad, robustez y supervisión cuando las acciones pueden afectar variables físicas críticas.

Sobre esta base, el capítulo ha sido organizado en seis apartados. Primero, se desarrollan el aprendizaje por refuerzo, la formulación Dec-POMDP, el paradigma de entrenamiento centralizado con ejecución descentralizada y la evolución de CityLearn. Luego, se delimitan las variables. Posteriormente, se explican las bases teóricas correspondientes a flexibilidad, emisiones, costos y algoritmos. Finalmente, se examinan los antecedentes, se precisan los términos fundamentales y se presenta la posición teórica adoptada.

2.1. Antecedentes

2.1.1. Antecedentes internacionales

(J. Li et al., 2026) proponen un marco federado de aprendizaje por refuerzo profundo multiagente en inglés es *Federated Multi-Agent Deep Reinforcement Learning* (FMADRL) para mejorar la resiliencia de microrredes distribuidas en áreas de servicio de autopistas frente a eventos meteorológicos extremos, con el objetivo general de abordar el aislamiento de los datos, la privacidad entre operadores y el crecimiento de la dimensionalidad asociado con la optimización colaborativa. La metodología integra redes generativas antagónicas con simulación de Monte Carlo para producir escenarios meteorológicos con correlación espacio-temporal, modela cada una de las cinco microrredes de áreas de servicio como un agente y emplea aprendizaje federado mediante FedAvg para agregar los parámetros entrenados localmente sin transferir directamente los datos operativos privados. Además, incorpora el algoritmo de propagación de ondas *Ripple-Spreading Algorithm* (RSA)— para obtener una frontera de Pareto equilibrada; no obstante, la función multiobjetivo principal considera específicamente la minimización del costo económico, la maximización de la confiabilidad y la reducción del tiempo de respuesta, por lo que las emisiones de carbono no constituyen un cuarto objetivo ponderado dentro de dicha función, sino una dimensión evaluada

posteriormente mediante un análisis ambiental independiente. El diseño corresponde a una investigación aplicada y experimental-computacional basada en cinco microrredes interconectadas mediante líneas de 10 kV, separadas entre 30 y 50 km y equipadas con generación fotovoltaica y eólica, almacenamiento, estaciones de carga de vehículos eléctricos y unidades móviles de suministro de emergencia; el desempeño del método se compara con D3PG y con los algoritmos metaheurísticos IWOA, HGWO y AHHO mediante simulaciones y ejecuciones independientes. Los resultados muestran una puntuación integral de resiliencia de 88,3 y una reducción del tiempo medio de recuperación de 46,6 a 8,4 minutos, equivalente a una mejora de 82,3 %. Asimismo, el costo operativo anual disminuyó 69,3 %, correspondiente a un ahorro de USD 536 945,1; las emisiones anuales se redujeron en 285 Mg, equivalentes a una tasa de 47,5 %; y el aprovechamiento de energía renovable alcanzó 71 %. El RSA generó 285 soluciones óptimas de Pareto distribuidas a lo largo de la frontera de compromiso. En cambio, no se identificó en el artículo un resultado que sustente una mejora de 12 % en la eficiencia energética global, por lo que dicho valor debe eliminarse de la ficha del antecedente. Los autores concluyen que la combinación de aprendizaje federado, MADRL, generación de escenarios y optimización multiobjetivo permite coordinar microrredes distribuidas y obtener mejoras concurrentes en resiliencia, costos y desempeño ambiental; sin embargo, esta conclusión se fundamenta en simulaciones y no en un despliegue físico en áreas de servicio reales (J. Li et al., 2026).

Análisis crítico. El antecedente se aproxima a la estructura multiobjetivo de la presente investigación porque demuestra que una estrategia de coordinación multiagente puede producir simultáneamente mejoras en resiliencia, economía operativa y emisiones. Por ello, proporciona evidencia directa para D-VD.2, mediante la reducción anual de carbono, y para D-VD.3, mediante la disminución del costo operativo. Su relación con D-VD.1 es indirecta: el artículo describe la coordinación de sistemas de almacenamiento y el recorte de picos como mecanismos que favorecen el aprovechamiento renovable y evitan el uso de generación de respaldo con mayores emisiones, pero no evalúa formalmente la flexibilidad mediante los mismos KPI de pico, rampa y factor de carga utilizados en el SEAI Iquitos. Tampoco resulta exacto afirmar que el estudio carece de vehículos eléctricos, puesto que las microrredes incluyen estaciones de carga; la diferencia radica en que dichas estaciones forman parte de la infraestructura de las áreas de servicio y no se modelan como vehículos o cargadores V2G heterogéneos asociados con 17 edificios-agentes. Además, (J. Li et al., 2026) resuelven los compromisos entre objetivos mediante una frontera de Pareto y coordinación federada,

mientras que la presente tesis utiliza vectores de ponderación fija en E1, E2 y E3 y compara HAPPO, MASAC, MATD3 y MAAC bajo un protocolo común. En consecuencia, el antecedente sustenta la tratabilidad conjunta de costos y emisiones y la coordinación distribuida, pero no permite anticipar directamente los resultados de flexibilidad ni la clasificación relativa de los cuatro algoritmos evaluados en el proyecto local

(Marchesini et al., 2026) presentan MARL2GRID-TR, el primer entorno de referencia de aprendizaje por refuerzo multiagente diseñado específicamente para estudiar la optimización topológica y el redespacho en operaciones realistas de redes eléctricas de transmisión, desarrollado conjuntamente con especialistas de operadores de sistemas de transmisión. El propósito general del trabajo consiste en proporcionar una plataforma estandarizada y extensible para evaluar algoritmos cooperativos, escalables y seguros en problemas caracterizados por observabilidad parcial, horizontes prolongados, espacios de acción de alta dimensión y restricciones físicas críticas. El entorno se construye sobre Grid2Op, la plataforma de simulación de alta fidelidad de RTE Francia, e incorpora una interfaz compatible con PettingZoo, alcances configurables para los agentes, distintos niveles de observabilidad, heurísticas operativas informadas por expertos y restricciones asociadas con sobrecargas, deslastre de carga y formación de islas. El problema se formula inicialmente como un proceso de decisión de Márkov multiagente cooperativo y se extiende a un Dec-POMDP cuando los agentes reciben únicamente observaciones locales; los métodos evaluados emplean esquemas compatibles con entrenamiento centralizado y ejecución descentralizada, mientras que PPO actúa como referencia centralizada con observabilidad completa. MARL2GRID-TR incluye tres redes base de 14, 36 y 118 barras, aunque la evaluación experimental principal no aplica todos los algoritmos a las tres: en la tarea discreta de optimización topológica de 14 barras se comparan QPLEX, MAPPO, PPO, LagrMAPPO, LagrPPO y una política sin acción; posteriormente se analiza el escalamiento de MAPPO a la red de 118 barras, mientras que en la tarea continua de redespacho, reducción y almacenamiento de la red de 118 barras se comparan MAPPO, MASAC, PPO y dos heurísticas. Los episodios comprenden entre una semana y un mes simulado, con decisiones cada cinco minutos; las curvas se agregan sobre ventanas de 100 episodios y cinco ejecuciones independientes por método, y los intervalos sombreados representan intervalos de confianza *bootstrap* al 95 %. En la evaluación de dos años de la tarea topológica de 14 barras, MAPPO alcanzó una supervivencia promedio de 0,79, frente a 0,38 de PPO con observabilidad completa, 0,18 de la política sin acción y 0,04 de QPLEX; en la tarea continua

de 118 barras, PPO obtuvo 0,67, MAPPO 0,58, la heurística de reconexión 0,34, la política sin acción 0,29 y MASAC 0,25. Los autores concluyen que MAPPO ofrece resultados prometedores en algunas configuraciones, pero que los algoritmos MARL actuales presentan dificultades importantes de escalabilidad, coordinación, exploración y seguridad, especialmente cuando la optimización topológica combina acciones discretas de crecimiento exponencial, información parcial, recompensas globales retardadas y consecuencias operativas difícilmente reversibles (Marchesini et al., 2026).

Análisis crítico. Este antecedente comparte con la presente tesis la formalización cooperativa del problema, la observabilidad parcial, el paradigma CTDE y la necesidad de comparar algoritmos bajo una infraestructura reproducible, por lo que sustenta principalmente la dimensión algorítmica D-VI.1. También confirma que la superioridad entre métodos no es absoluta: MAPPO supera ampliamente a PPO en la optimización topológica de 14 barras, pero PPO obtiene mayor supervivencia final en el control continuo de 118 barras, aunque con un entrenamiento considerablemente más prolongado; de forma adicional, MASAC no supera siquiera la heurística de reconexión en dicha tarea. No obstante, el artículo no realiza una comparación de todas las familias bajo una única tarea, ya que QPLEX y los métodos lagrangianas se evalúan principalmente en el caso discreto de 14 barras, mientras que MASAC se limita al caso continuo de 118 barras. Por ello, no debe afirmarse que mantiene exactamente el mismo entorno, espacio de acción y protocolo para todos los algoritmos, como sí pretende el diseño factorial del SEAI Iquitos. El antecedente tampoco cuantifica emisiones de CO_2 como objetivo experimental diferenciado y, aunque la recompensa topológica incluye un componente de costo operativo, la evaluación se concentra fundamentalmente en supervivencia, márgenes de transmisión, modificaciones topológicas y seguridad; de hecho, los propios autores señalan que futuras evaluaciones deben profundizar en el impacto económico. En consecuencia, (Marchesini et al., 2026) proporcionan un fundamento sólido para la comparación algorítmica, CTDE, Dec-POMDP y reproducibilidad, pero no anticipan los resultados de flexibilidad, emisiones y costos correspondientes a D-VD.1, D-VD.2 y D-VD.3 del proyecto local.

(Wu et al., 2026a) desarrollan un sistema de gestión energética cooperativo basado en aprendizaje por refuerzo profundo multiagente para mejorar la resiliencia de una microrred frente a interrupciones ocasionadas por tifones y otros fenómenos meteorológicos extremos. El objetivo general consiste en coordinar los recursos energéticos distribuidos para reducir el costo operativo y limitar el deslastre de carga durante la operación aislada. La metodología

adapta MADDPG mediante cinco actores descentralizados, cada uno encargado del control de un sistema de almacenamiento, y críticos que emplean los estados y acciones conjuntos durante el entrenamiento. Además, incorpora unidades recurrentes con compuertas para extraer información temporal de las predicciones de generación fotovoltaica y demanda, así como un mecanismo de enmascaramiento que ajusta dinámicamente los límites de carga y descarga de cada ESS según su estado de carga, evitando acciones físicamente inviables y reduciendo los efectos de saturación asociados con el recorte convencional. El diseño es aplicado y experimental-computacional sobre el sistema IEEE de 33 nodos, configurado con cinco sistemas de almacenamiento, seis módulos fotovoltaicos, cinco generadores y veinte cargas. Los experimentos utilizan datos reales de generación fotovoltaica y demanda de ENTSO-E correspondientes a julio y agosto de 2022, con resolución de quince minutos, una partición de 75 % para entrenamiento y 25 % para prueba y un total de 400 episodios. En la evaluación, el método propuesto alcanzó un costo promedio de USD 35,18, frente a USD 37,71 de DDPG, USD 35,64 de MAPPO, USD 41,51 del controlador basado en reglas y USD 35,06 de MINLP. Asimismo, registró un deslastre promedio de 1,72 MW, lo que representa reducciones de 1,22 MW respecto de DDPG y 2,40 MW respecto de MINLP, y necesitó 529,63 s de cómputo frente a 3 632,48 s del modelo MINLP. Aunque MAPPO obtuvo un deslastre menor, de 0,96 MW, y MINLP consiguió un costo ligeramente inferior, el método propuesto presentó una relación más equilibrada entre costo, continuidad del suministro y tiempo computacional. En el escenario con falla de tres agentes, el costo promedio aumentó a USD 37,95 y el deslastre se mantuvo en 1,55 MW, lo que evidencia tolerancia frente a la pérdida parcial de controladores. Los autores concluyen que la coordinación multiagente del almacenamiento mejora la adaptación ante interrupciones inciertas y ofrece un compromiso favorable frente al control monoagente, las reglas fijas y la optimización matemática, sin afirmar que sea superior en cada indicador evaluado (Wu et al., 2026a).

Análisis crítico. Este antecedente comparte con la presente tesis una arquitectura de actor–crítico multiagente compatible con CTDE, el control descentralizado de sistemas de almacenamiento y la evaluación del costo operativo, por lo que sustenta directamente la dimensión algorítmica D-VI.1 y aporta evidencia para D-VD.3. También respalda la capacidad de los BESS para responder coordinadamente ante perturbaciones y muestra que la comparación entre familias algorítmicas puede producir resultados no uniformes: MADDPG logra el costo más bajo entre los métodos de aprendizaje, mientras que MAPPO alcanza menor deslastre. No obstante, el deslastre utilizado como indicador de resiliencia no equivale

a la flexibilidad energética definida en esta tesis mediante pico, rampa y factor de carga; por ello, su relación con D-VD.1 es indirecta y debe formularse como antecedente sobre coordinación del almacenamiento, no como validación empírica de los mismos KPI. El estudio tampoco evalúa emisiones de CO_2, vehículos eléctricos, operación V2G ni cargas desplazables, y se desarrolla en una microrred de distribución durante contingencias diarias, mientras que la investigación del SEAI Iquitos analiza una comunidad de 17 edificios durante un horizonte anual de operación normal. En consecuencia, (Wu et al., 2026b) fundamentan el uso de coordinación MADRL y el análisis económico, pero no anticipan los resultados de flexibilidad, carbono o costo de HAPPO, MASAC, MATD3 y MAAC en los escenarios E1, E2 y E3

(Nweye et al., 2025a) presentan CityLearn v2, un entorno autónomo de simulación basado en la interfaz Gymnasium y orientado a la construcción y evaluación de comunidades virtuales interactivas con la red eléctrica. El entorno emplea datos representativos del parque edificatorio estadounidense e incorpora dinámica térmica basada en datos, sistemas de almacenamiento eléctrico y térmico, generación fotovoltaica, vehículos eléctricos con capacidad G2V/V2G, señales temporales de precios e intensidad de carbono, respuesta de los ocupantes y modelos estocásticos de interrupción del suministro. El objetivo general consiste en proporcionar una infraestructura estandarizada y extensible para comparar estrategias de control de recursos energéticos distribuidos considerando flexibilidad, sostenibilidad, confort y resiliencia. Metodológicamente, el estudio corresponde a una investigación aplicada de desarrollo tecnológico, validada mediante experimentos computacionales y casos comparativos de simulación. Aunque CityLearn v2 admite control basado en reglas, control predictivo basado en modelos y aprendizaje por refuerzo, las aplicaciones cuantitativas principales comparan configuraciones de referencia, RBC y SAC, sin efectuar una comparación conjunta entre RBC, SAC y MPC. Los casos evaluados comprenden el control de BESS y generación fotovoltaica, la reducción de costos y emisiones, la disminución de picos, la gestión V2G y la modulación de bombas de calor con retroalimentación del ocupante. Los resultados muestran que la incorporación de generación fotovoltaica redujo aproximadamente 20 % los costos y las emisiones respecto de la configuración sin PV; adicionalmente, SAC produjo una reducción de costos de hasta 6,7 % frente al RBC, aunque la variación de emisiones entre ambos controladores fue inferior a 1 %. En el caso orientado a la reducción del pico, el RBC ajustado superó al SAC en 2,6 %, mientras que, en las comunidades representativas de California y Texas, la coordinación de BESS y PV redujo el

pico diario promedio en 8 % y 42 %, respectivamente. Estos resultados evidencian que el desempeño depende de la ubicación, la formulación de la recompensa, los recursos disponibles y la estrategia de control empleada (Nweye et al., 2025). Para la presente tesis, CityLearn v2 constituye el entorno base oficial y proporciona los modelos energéticos y las familias de indicadores empleadas para evaluar D-VD.1, D-VD.2 y D-VD.3, particularmente pico, rampa, emisiones de CO_2 equivalente y costo energético; sobre este núcleo se desarrolla la extensión experimental CityLearn v3 propuesta, encargada de representar la comunidad del SEAI Iquitos mediante un Dec-POMDP, aplicar CTDE e integrar HAPPO, MASAC, MATD3 y MAAC bajo un protocolo común, por lo que dicha extensión debe reconocerse como una contribución del proyecto local y no como una funcionalidad atribuible al artículo original.

Análisis crítico. El antecedente proporciona un entorno estandarizado, extensible y reproducible para el estudio de comunidades energéticas y sustenta la medición multidimensional de la variable dependiente. Sin embargo, sus aplicaciones no comparan conjuntamente familias *on-policy*, *off-policy* y basadas en atención, ni utilizan una comunidad peruana con datos del SEAI Iquitos. Asimismo, el artículo reconoce limitaciones relacionadas con la validación en campo, la disponibilidad práctica de determinadas observaciones, la cobertura climática, la variedad de recursos evaluados y la ausencia de un modelo eléctrico detallado de red. La investigación local conserva CityLearn v2 como núcleo físico y añade una capa experimental trazable para cubrir la brecha algorítmica y contextual identificada.

(Liu et al., 2025) desarrollan un marco jerárquico de gestión energética basado en aprendizaje por refuerzo profundo multiagente para el control coordinado de un sistema energético de edificio con múltiples zonas, cuyo objetivo general consiste en reducir los costos y el consumo energético y, simultáneamente, mejorar la calidad del ambiente interior bajo restricciones operativas. La metodología formula la coordinación multizona como un proceso de decisión semi-Márkov y propone el algoritmo OCMATD3 en inglés es *Option-Critic Multi-Agent Twin Delayed Deep Deterministic Policy Gradient*, complementado mediante ingeniería de recompensa segura, por lo que el método completo se identifica como SRE-OCMATD3. La arquitectura jerárquica separa la selección discreta de modos operativos en la capa superior, los ajustes continuos de potencia efectuados por los agentes en la capa intermedia y la regulación fina de las condiciones ambientales en la capa inferior; las políticas *option-critic* permiten conservar una decisión discreta durante varios intervalos, mientras los agentes realizan acciones continuas para coordinar el funcionamiento del sistema

fotovoltaico, la batería, el HVAC y las distintas zonas del edificio. El mecanismo SRE incorpora recompensas positivas cuando se satisfacen las restricciones y una capa de seguridad que corrige las acciones que las vulneran; no obstante, sin disponer del texto completo no debe afirmarse de manera más específica que todas las acciones se proyectan matemáticamente sobre un conjunto factible. El diseño puede clasificarse como aplicado y experimental-computacional, pues el marco se evalúa mediante un modelo de caso de estudio alimentado y calibrado con datos de prueba procedentes de un edificio real, pero no corresponde a un despliegue físico en línea del controlador. La comparación incluye TD3 monoagente, MATD3, MADDPG y un controlador basado en reglas. Los resultados muestran que SRE-OCMATD3 alcanzó el retorno acumulado más alto y convergió aproximadamente 1,6, 1,5 y 1,3 veces más rápido que TD3, MADDPG y MATD3, respectivamente; además, la estrategia jerárquica produjo, en promedio, reducciones de 14,7 % en el costo operativo, 12,6 % en el consumo energético y 5,6 % en la proporción temporal de disconfort respecto del conjunto de controladores de referencia. Estos porcentajes deben interpretarse como mejoras promedio reportadas frente a los *baselines* evaluados y no como una reducción idéntica frente a cada algoritmo individual. Los autores concluyen que la integración de abstracción temporal mediante opciones, coordinación multiagente y mecanismos de seguridad mejora la convergencia, el cumplimiento de restricciones y el equilibrio entre ahorro energético, costo y calidad ambiental interior frente a políticas planas convencionales (Liu et al., 2025)

Análisis crítico. Este antecedente es pertinente para la presente investigación porque se desarrolla en el ámbito de los sistemas energéticos de edificios, incorpora generación fotovoltaica, almacenamiento, HVAC y control multizona, y compara TD3, MADDPG y MATD3 dentro del mismo caso de estudio, lo que respalda la dimensión algorítmica D-VI.1 y la conveniencia de contrastar arquitecturas actor–crítico con mecanismos distintos. Sin embargo, el artículo no demuestra que MATD3 supere consistentemente a MADDPG en todas las métricas ni permite justificar su selección únicamente mediante un ordenamiento de recompensas entre los *baselines*; la decisión de incluir MATD3 en el diseño factorial de la tesis se sustenta con mayor precisión en sus críticos gemelos, la actualización retardada de la política y su capacidad para controlar acciones continuas, además de su inclusión como referencia comparativa en el estudio. Los resultados económicos proporcionan evidencia directa para D-VD.3, mientras que la reducción del consumo y la coordinación de la batería solo guardan una relación indirecta con D-VD.1, debido a que (Liu et al., 2025) no

cuantifican la flexibilidad mediante pico, rampa, factor de carga o desplazamiento de demanda. Asimismo, la concentración interior de CO_2 forma parte de la calidad del aire y no representa emisiones de carbono asociadas con la generación eléctrica; por tanto, el antecedente no aporta evidencia directa para D-VD.2. Finalmente, el caso corresponde a un único edificio multizona y no a una comunidad de 17 edificios con espacios heterogéneos de observación y acción, cargadores EV/V2G y coordinación distrital. En consecuencia, sustenta la comparación algorítmica, el control continuo, la seguridad y el costo operativo, pero no permite anticipar los resultados de flexibilidad ni de emisiones de los escenarios E1 y E2 del SEAI Iquitos.

(Wilk et al., 2024b) proponen *Local Strategy-Driven Multi-Agent Deep Deterministic Policy Gradient* (LSD-MADDPG) para la gestión energética del lado de la demanda en comunidades inteligentes, con el objetivo general de coordinar el consumo de diferentes edificios, reducir los costos eléctricos y aplanar la curva de demanda comunitaria, manteniendo simultáneamente el confort térmico y el cumplimiento de las necesidades de carga de los vehículos eléctricos. El método modifica MADDPG convencional mediante una variante del entrenamiento centralizado con ejecución descentralizada: durante el entrenamiento, el crítico de cada agente no recibe directamente todas las observaciones y acciones privadas de los demás edificios, sino su observación y acción local junto con indicadores estratégicos discretizados que expresan la urgencia de climatización y de carga vehicular de los otros agentes; durante la ejecución se conservan únicamente los actores descentralizados, que toman decisiones con información local, aunque el consumo agregado de la comunidad se proporciona como una señal común. El diseño corresponde a una investigación aplicada y experimental-computacional desarrollada sobre una comunidad simulada en la que cada edificio dispone de un sistema HVAC y una estación de carga de vehículos eléctricos; no se modelan sistemas fotovoltaicos, BESS ni operación V2G. Los experimentos comparan LSD-MADDPG con un controlador ingenuo, un DDPG centralizado, I-MADDPG con aprendizaje independiente y MADDPG convencional bajo CTDE. En el caso de tres edificios idénticos, LSD-MADDPG alcanzó un pico diario promedio de 31,03 kW, un costo total de USD 84,48, una satisfacción de carga vehicular de 91 %, una contribución al recorte del pico de 43,46, una recompensa total de 38,69 y un coeficiente de Gini de 0,0125. Estos valores muestran que obtuvo la mejor contribución al recorte del pico y la distribución más equitativa de recompensas, pero no el menor pico, conseguido por CTDE-MADDPG con 27,30 kW, ni el menor costo entre los controladores de aprendizaje, obtenido

por DDPG con USD 79,59. En comparación con I-MADDPG, LSD-MADDPG redujo el pico solamente en aproximadamente 2,9 %, pero presentó un costo alrededor de 1,5 % mayor. En el caso de escalabilidad con nueve edificios heterogéneos, LSD-MADDPG alcanzó una recompensa de 438,82 y satisfizo 83 % de la demanda comunitaria de carga vehicular, superando a I-MADDPG, CTDE-MADDPG y DDPG en esos dos indicadores durante la evaluación de diez días. Los autores concluyen que el intercambio de información estratégica permite obtener un desempeño comparable con CTDE-MADDPG en comunidades pequeñas y una mejor adaptación en el escenario evaluado con nueve edificios, reduciendo el intercambio de datos privados y favoreciendo una participación más equilibrada entre agentes; no obstante, el estudio no demuestra una superioridad general para comunidades de cualquier tamaño ni incorpora renovables o almacenamiento estacionario (Wilk et al., 2024b).

Análisis crítico. El antecedente proporciona evidencia directa para D-VD.1 porque evalúa la reducción y distribución del pico de demanda comunitario, y para D-VD.3 porque cuantifica el costo eléctrico total. Su mayor contribución para la presente tesis es demostrar que una arquitectura basada en información estratégica limitada puede equilibrar objetivos individuales y comunitarios sin compartir durante la ejecución los datos operativos detallados de todos los edificios. También resulta pertinente por comparar DDPG centralizado, aprendizaje independiente, CTDE-MADDPG y LSD-MADDPG dentro del mismo entorno, lo que respalda la necesidad de evaluar distintas formas de coordinación multiagente bajo condiciones comunes. Sin embargo, no constituye un antecedente sobre coordinación de PV y BESS, dado que esos recursos no se implementaron; tampoco analiza emisiones de CO_2, operación V2G, almacenamiento estacionario ni cargas desplazables. los algoritmos locales se evalúan en una comunidad, horizonte y función de recompensa diferentes. La contribución de la investigación del SEAI Iquitos consiste en ampliar la comparación hacia HAPPO, MASAC, MATD3 y MAAC, incorporar BESS, EV/V2G y cargas flexibles, y evaluar separadamente flexibilidad, emisiones y costos mediante los escenarios E1, E2 y E3.

(Samende et al., 2023) desarrollan una estrategia de gestión energética basada en MADDPG para coordinar, en tiempo real, un sistema híbrido compuesto por almacenamiento mediante baterías e hidrógeno, generación solar y eólica y demanda eléctrica flexible dentro de una red energética inteligente. El enfoque considera la incertidumbre de la producción renovable, el consumo y los precios eléctricos, y emplea datos reales de generación y demanda recopilados en el proyecto *Smart Energy Network Demonstrator* (SEND) de la Universidad de Keele. La metodología modela como agentes diferenciados el BESS, el

sistema de almacenamiento de hidrógeno y la demanda flexible; durante el entrenamiento, los críticos utilizan los estados y las acciones de los tres agentes, mientras que, durante la ejecución, cada actor decide con su información local, por lo que la arquitectura corresponde a entrenamiento centralizado con ejecución descentralizada. El diseño es aplicado y experimental-computacional mediante simulación, y compara MADDPG con un controlador basado en reglas, DQN y DDPG. Frente al controlador basado en reglas, MADDPG incrementó el ahorro económico en 41,33 % y redujo las emisiones de carbono en 56,3 %; de manera diferenciada, al comparar la configuración integral de la red con almacenamiento híbrido y demanda flexible frente a las configuraciones energéticas de referencia, se obtuvo una mejora promedio del ahorro de 23,5 %, una reducción de emisiones de 78,69 % y un aumento superior a 13,2 % en el aprovechamiento renovable. (Deng et al., 2025) complementan estos resultados en el ámbito de los edificios mediante una estrategia MADRL para la gestión energética diaria de un edificio inteligente dividido en redes energéticas locales (E-LAN), cada una modelada como agente y equipada con sistemas fotovoltaicos, almacenamiento y cargas controlables. La metodología emplea MADDPG e incorpora restricciones probabilísticas transformadas en restricciones deterministas para representar la incertidumbre intrínseca de la generación fotovoltaica. En un periodo de programación, el método redujo el costo total en 11,5 % frente a la programación estocástica y en 11,0 % frente a DDPG; en tres periodos consecutivos, la reducción máxima reportada fue de 7,6 %. Este artículo no evalúa emisiones de CO_2, por lo que su aporte se concentra en D-VD.3 y en el tratamiento de la incertidumbre fotovoltaica. De manera concordante, (Fonseca et al., 2024) presentan EnergAIze, una estrategia descentralizada basada en MADDPG para la coordinación de vehículos eléctricos con capacidad V2G y otros activos energéticos dentro de comunidades de energía renovable simuladas mediante CityLearn. El marco permite que cada prosumidor seleccione objetivos individuales y, simultáneamente, contribuye a la optimización comunitaria; los resultados evidencian reducciones en el pico, la rampa, las emisiones de carbono y el costo eléctrico a escala de comunidad, aunque el artículo no establece un único porcentaje general de mejora aplicable a los cuatro indicadores. Para la presente tesis, (Samende et al., 2023) proporcionan evidencia cuantitativa directa para D-VD.2 y D-VD.3; (Deng et al., 2025) refuerzan D-VD.3 y la aplicabilidad de MADDPG en sistemas fotovoltaicos y de almacenamiento de edificios; y (Fonseca et al., 2024) aportan correspondencia metodológica con CityLearn, V2G y los indicadores de D-VD.1, D-VD.2 y D-VD.3. Ninguno de los tres estudios compara conjuntamente familias *on-policy*, *off-policy* y basadas en atención bajo un único protocolo, por lo que la investigación local amplía la

evidencia al contrastar HAPPO, MASAC, MATD3 y MAAC sobre la misma comunidad, el mismo conjunto de datos y una función de recompensa comparable en los escenarios E1, E2 y E3 del SEAI Iquitos.

Análisis crítico. La triangulación demuestra que MADDPG puede coordinar recursos energéticos heterogéneos y responder a objetivos económicos y ambientales bajo incertidumbre, pero los alcances de los tres antecedentes no son equivalentes. (Samende et al., 2023) estudian una red energética inteligente con BESS, almacenamiento de hidrógeno, generación solar y eólica y demanda flexible; (Deng et al., 2025) analizan un único edificio inteligente dividido en varias E-LAN con sistemas PV-almacenamiento; y (Fonseca et al., 2024) evalúan una comunidad de energía renovable mediante CityLearn con vehículos eléctricos y operación V2G. En consecuencia, los porcentajes de 41,33 %, 56,3 %, 11,5 % y 11,0 % no deben utilizarse como umbrales que MATD3 o MAAC tengan que superar, porque fueron obtenidos con recursos, horizontes, funciones objetivo y líneas base diferentes. Su función dentro de la tesis consiste en proporcionar evidencia externa para interpretar la dirección y magnitud relativa de los resultados de costo, emisiones y flexibilidad, mientras que la superioridad entre HAPPO, MASAC, MATD3 y MAAC debe establecerse exclusivamente a partir de las corridas canónicas del SEAI Iquitos. También debe corregirse la redacción que agrupaba a (Deng et al., 2025) y (Fonseca et al., 2024) como estudios de un mismo edificio, puesto que el primero analiza un edificio dividido en áreas energéticas y el segundo una comunidad simulada mediante CityLearn.

(Zhang et al., 2023) proponen una arquitectura distribuida de abajo hacia arriba para la gestión energética de microrredes multienergéticas interconectadas, cuyo objetivo general consiste en sustituir el control centralizado tradicional por una estructura jerárquica capaz de responder a la incertidumbre de la generación distribuida, los precios y las demandas heterogéneas de electricidad y calor. En la capa inferior, cada microrred se modela como un agente y se controla mediante MAATD3 en inglés es *Multi-Agent Attention-Based Twin Delayed Deep Deterministic Policy Gradient*, algoritmo que combina los críticos gemelos, las actualizaciones retardadas y el suavizado de la política de TD3 con un mecanismo de atención incorporado en los críticos centralizados; durante el entrenamiento, estos críticos emplean representaciones de las observaciones y acciones de los agentes, mientras que, en la ejecución, cada actor toma decisiones exclusivamente a partir de su estado local, por lo que la arquitectura corresponde al paradigma de entrenamiento centralizado con ejecución descentralizada. La atención permite que el crítico de cada agente seleccione y agregue

representaciones implícitas relevantes de las demás microrredes, reduciendo la dimensión efectiva de su entrada y evitando que todas las observaciones y acciones se procesen con la misma importancia; este procedimiento favorece la eficiencia computacional y limita la exposición directa de información operacional, aunque no constituye por sí mismo un mecanismo criptográfico ni una garantía formal de privacidad. En la capa superior, una red de enrutadores energéticos determina los intercambios entre las microrredes y la red principal a partir de las solicitudes de potencia y de los precios previstos. El diseño corresponde a una investigación aplicada y experimental-computacional desarrollada con ocho microrredes heterogéneas: tres residenciales, tres comerciales y dos industriales, con configuraciones distintas de almacenamiento eléctrico y térmico, generación fotovoltaica, producción combinada de calor y electricidad, equipos de conversión y demandas de electricidad y calor. Los experimentos consideran un horizonte diario de 24 horas, intervalos de 15 minutos y 96 decisiones por episodio; los datos históricos de generación renovable y demanda se dividieron en 80 % para entrenamiento y 20 % para prueba, mientras que el análisis de la capa superior utilizó movimiento browniano geométrico para representar precios eléctricos estocásticos. Los autores indican que los conjuntos de datos empleados proceden de fuentes reales asociadas con Austin, Texas, aunque la evaluación de las políticas se realiza mediante simulación y no mediante un despliegue físico de control sobre las microrredes. Los resultados muestran que MAATD3 obtuvo un costo operativo de $(1{,}324 \pm 0{,}089) \times 10^4$, frente a $(1{,}451 \pm 0{,}121) \times 10^4$ de TD3 y $(1{,}921 \pm 0{,}328) \times 10^4$ del flujo óptimo de potencia, lo que representa reducciones aproximadas de 9,6 % y 41 %, respectivamente. El tiempo de prueba en línea fue de 0,0002 s para MAATD3 y TD3, frente a 2,21 s del método OPF. Asimismo, la comparación de ablación entre MAATD3 y MATD3 muestra que la incorporación de atención acelera la convergencia y alcanza recompensas episódicas superiores. Los autores concluyen que la combinación de críticos centralizados con atención y actores descentralizados proporciona una estrategia adaptable y de baja carga computacional para gestionar microrredes no homogéneas; sin embargo, la validación cuantitativa se limita a ocho (Zhang et al., 2023).

Análisis crítico. Este antecedente resulta pertinente para la dimensión algorítmica D-VI.1 porque integra, dentro de una misma arquitectura, los principios de TD3 multiagente y un mecanismo de atención en el crítico centralizado. Esta configuración presenta afinidad con los fundamentos que en la presente tesis se estudian separadamente mediante MATD3 y MAAC; no obstante, MAATD3 no debe presentarse como una combinación exacta de las

implementaciones locales de ambos algoritmos, debido a que su arquitectura, sus entradas, su función de recompensa y su procedimiento de actualización son específicos del estudio de (Zhang et al., 2023). La reducción de 9,6 % respecto de TD3 proporciona evidencia directa para D-VD.3, al demostrar que la coordinación entre agentes y la selección atencional de información pueden mejorar el costo operativo frente a un controlador TD3 que no incorpora el mismo mecanismo multiagente. En cambio, el artículo no evalúa emisiones de CO_2 ni cuantifica flexibilidad mediante pico, rampa o factor de carga, por lo que no aporta evidencia directa para D-VD.1 o D-VD.2. La consideración de microrredes residenciales, comerciales e industriales con estructuras distintas sí respalda la relevancia de estudiar agentes heterogéneos, pero solo constituye una justificación indirecta para incluir HAPPO, puesto que el artículo no implementa ni compara dicho algoritmo. Asimismo, el caso analizado comprende sistemas multienergéticos, enrutadores de energía e intercambio entre microrredes, pero no una comunidad de 17 edificios gestionada mediante CityLearn con BESS, vehículos eléctricos, operación V2G y cargas desplazables. Por consiguiente, el antecedente sustenta la comparación de mecanismos actor–crítico, atención y control descentralizado, así como el análisis de costos, pero no permite anticipar los resultados de flexibilidad y emisiones de los escenarios E1 y E2 del SEAI Iquitos

(Nweye, Sankaranarayanan, et al., 2022) desarrollan MERLIN, un marco para el entrenamiento fuera de línea, la evaluación, la transferencia y el despliegue potencial de políticas de control de recursos energéticos distribuidos en comunidades interactivas con la red, cuyo objetivo general consiste en reducir las barreras de ineficiencia muestral, seguridad operativa y limitada generalización que dificultan la aplicación del aprendizaje por refuerzo en sistemas energéticos reales. Metodológicamente, el estudio corresponde a una investigación aplicada de simulación basada en datos reales, en la que se construye en CityLearn un gemelo digital de la comunidad residencial Sierra Crest, ubicada en Fontana, California, y conformada por 17 viviendas unifamiliares de energía neta cero; para ello se utilizan mediciones de medidores inteligentes correspondientes al periodo comprendido entre agosto de 2016 y julio de 2017, información meteorológica, tarifas eléctricas, intensidad de carbono y especificaciones de sistemas fotovoltaicos y de almacenamiento. El control no se implementa mediante un algoritmo MADRL cooperativo con crítico centralizado, sino mediante un agente SAC independiente por edificio, inicializado durante los primeros 3 671 pasos equivalentes aproximadamente a cinco meses, con acciones de un controlador basado en reglas, con el propósito de reducir la exploración aleatoria y mejorar la seguridad del

entrenamiento. El diseño evalúa tres estrategias: entrenamiento independiente con información anual, transferencia de una política aprendida en un edificio fuente hacia otros edificios objetivo y entrenamiento con un conjunto temporal limitado de cinco meses para su evaluación durante los siete meses restantes. Los resultados muestran que las políticas independientes de control de baterías mejoran determinados KPI a nivel de edificio y distrito respecto de la condición de referencia y del RBC, alcanzando mejoras de hasta 60 % en algunos indicadores distritales; asimismo, el entrenamiento con cinco meses de datos obtiene un desempeño comparable al conseguido con un año completo, mientras que la transferencia entre edificios conserva resultados semejantes a nivel local y comunitario con un menor costo de entrenamiento. Los autores concluyen que MERLIN permite estudiar el entrenamiento y la transferencia de políticas de control de BESS utilizando datos procedentes de una comunidad real; no obstante, la evaluación se realiza dentro de su gemelo digital en CityLearn y el artículo no documenta un despliegue físico en tiempo real de las políticas sobre las viviendas. Para la presente tesis, este antecedente resulta pertinente por utilizar una comunidad de 17 edificios, coincidente en número de agentes con el caso del SEAI Iquitos, y por demostrar la utilidad de CityLearn, los datos medidos y el aprendizaje por refuerzo para controlar almacenamiento en una comunidad energética; sin embargo, la coincidencia de N=17 no implica equivalencia entre ambos casos, debido a que MERLIN estudia viviendas residenciales ZNE de California, mientras que la investigación local considera edificios institucionales y comerciales del SEAI Iquitos(Nweye, Sankaranarayanan, et al., 2022).

Análisis crítico. MERLIN aporta evidencia empírica sobre la posibilidad de entrenar políticas de control con datos limitados, transferir conocimiento entre edificios y reducir el costo computacional de desarrollar una política específica para cada inmueble. También evalúa indicadores de flexibilidad, consumo, costo y emisiones, por lo que no sería exacto afirmar que carece por completo de evaluación económica, ambiental o de flexibilidad. Su limitación respecto de la presente tesis radica en que los agentes SAC se entrenan de manera independiente, sin una función de valor centralizada, una recompensa cooperativa común ni mecanismos explícitos de coordinación CTDE; además, el estudio no compara HAPPO, MASAC, MATD3 y MAAC, ni organiza la evaluación mediante escenarios diferenciados que prioricen flexibilidad, carbono y costos. Por ello, MERLIN constituye un antecedente directo para la escala comunitaria, el empleo de CityLearn, el control de BESS con datos reales y la transferibilidad de políticas, pero no valida por sí mismo la superioridad de

arquitecturas MADRL cooperativas ni proporciona un *baseline* algorítmico directamente equivalente a los escenarios E1, E2 y E3 del SEAI Iquitos.

(Iqbal & Sha, 2019) Iqbal y Sha (2019) proponen Multi-Actor-Attention-Critic (MAAC), un algoritmo actor–crítico off-policy para entrenar políticas descentralizadas mediante críticos calculados centralmente que comparten un mecanismo de atención, cuyo objetivo consiste en seleccionar dinámicamente la información de los demás agentes que resulta relevante para estimar el valor esperado de cada acción y mejorar la escalabilidad del aprendizaje multiagente. El método se desarrolla bajo el paradigma de entrenamiento centralizado con ejecución descentralizada: durante el entrenamiento, el crítico del agente i recibe las observaciones y acciones conjuntas, codifica por separado la información de cada agente y utiliza un mecanismo de atención de múltiples cabezas para construir una suma ponderada de las representaciones más relevantes; durante la ejecución, cada actor selecciona acciones únicamente a partir de su observación local. La arquitectura utiliza Soft Actor-Critic como algoritmo base, comparte parámetros entre los críticos y aplica una función de ventaja multiagente que marginaliza la acción del agente evaluado para mejorar la asignación de crédito. El diseño corresponde a una investigación algorítmica con evaluación experimental-computacional en tres tareas implementadas mediante Multi-Agent Particle Environments: Cooperative Treasure Collection, Rover-Tower y Cooperative Navigation. Las comparaciones incluyen MADDPG, COMA, DDPG independiente, versiones de MADDPG y COMA adaptadas a SAC y una ablación de MAAC con atención uniforme; todos los métodos se ajustaron con un número aproximado de parámetros equivalente y se entrenaron con seis semillas, presentándose intervalos de confianza del 95 %. En Cooperative Navigation, MAAC alcanzó una recompensa media de −1,74±0,05, frente a −2,09±0,12 de MADDPG+SAC y −1,89±0,07 de COMA+SAC. En Cooperative Treasure Collection, la mejora normalizada de MAAC respecto de MADDPG+SAC fue de 17 % con cuatro agentes, 98 % con ocho agentes y 208 % con doce agentes, mientras que en Rover-Tower su desempeño se mantuvo al incrementar el número de agentes, a diferencia de MADDPG. Los resultados muestran que la atención dinámica resulta especialmente útil cuando la relevancia de las interacciones cambia durante el episodio o cuando solo determinados agentes influyen en la recompensa; sin embargo, en tareas cooperativas con recompensa global y relaciones menos selectivas, la atención uniforme y otros métodos también pueden presentar un desempeño competitivo. Los autores concluyen que la atención aplicada a los críticos centralizados permite seleccionar información contextual, afrontar configuraciones con

recompensas compartidas o individualizadas y mejorar la escalabilidad frente a arquitecturas que concatenan indiscriminadamente todas las observaciones y acciones (Iqbal & Sha, 2019).

Análisis crítico. Este antecedente constituye el fundamento algorítmico principal del backend MAAC y sustenta la dimensión D-VI.1, debido a que demuestra que un crítico centralizado puede ponderar de manera diferenciada las interacciones entre agentes en lugar de asignar la misma relevancia a toda la información conjunta. Esta propiedad resulta conceptualmente pertinente para la comunidad heterogénea del SEAI Iquitos, donde la influencia de un edificio sobre el costo comunitario puede variar según su demanda, disponibilidad de BESS, presencia de vehículos eléctricos y coincidencia con periodos tarifarios. No obstante, la aplicación a tarifas TOU constituye una hipótesis de la presente tesis y no un resultado demostrado por (Iqbal & Sha, 2019). El artículo no estudia sistemas energéticos, costos eléctricos, emisiones, picos ni rampas, por lo que no aporta evidencia directa para OE.1, OE.2 u OE.3 y tampoco permite anticipar que MAAC liderará el eje de costos. Su aporte consiste en justificar el mecanismo de atención y la selección contextual de interacciones; la utilidad efectiva de este mecanismo para D-VD.3 debe determinarse exclusivamente mediante las corridas de MAAC en el escenario E3. Asimismo, los resultados originales muestran que la ventaja de MAAC depende de la estructura de la tarea: la atención selectiva ofrece beneficios importantes en entornos donde cambian los agentes relevantes, pero no produce superioridad universal en todas las configuraciones cooperativas.

2.1.2. Antecedentes nacionales y peruanos

(Salazar, 2025) desarrolla un modelo sostenible para el suministro eléctrico del Sistema Eléctrico Aislado de Iquitos, con el objetivo de identificar una alternativa técnica, económica y ambientalmente viable que reduzca la dependencia de la generación térmica. Metodológicamente, el estudio aplica un análisis técnico-económico y multicriterio para comparar la interconexión con el SEIN, la generación térmica convencional, la biomasa y un sistema híbrido solar con almacenamiento. El diseño corresponde a una investigación aplicada basada en información técnica, económica y operativa del SEAI. Los resultados identifican como alternativa más favorable una planta fotovoltaica de 60 MWp, conformada por 90 915 módulos solares y 20 sistemas BESS, con una inversión estimada de USD 60,65 millones y un costo nivelado de energía de USD 85,7/MWh. La propuesta obtuvo un valor actual neto de USD 56,53 millones, una tasa interna de retorno de 76,8 %, un periodo de recuperación de 9,3 años y una reducción potencial de 19 713 toneladas de CO_2 por año. El autor concluye que la integración de generación fotovoltaica y almacenamiento puede mejorar la sostenibilidad, seguridad energética y rentabilidad del sistema aislado de Iquitos.

Para la presente tesis, este antecedente aporta evidencia directa a D-VD.2 y D-VD.3, debido a que cuantifica emisiones y costos en el mismo ámbito territorial del SEAI Iquitos, y fundamenta la incorporación de generación fotovoltaica y BESS en el entorno experimental.

Análisis crítico. Este constituye el antecedente nacional con mayor correspondencia territorial y tecnológica respecto de la investigación, porque estudia directamente el SEAI Iquitos e incorpora generación fotovoltaica, BESS, costos y emisiones. Sin embargo, su modelo evalúa alternativas de inversión mediante análisis técnico-económico y multicriterio, sin formular la operación como Dec-POMDP, aplicar CTDE ni comparar algoritmos MADRL. Tampoco analiza la coordinación horaria de 17 edificios, los vehículos eléctricos, las cargas desplazables o los KPI de pico y rampa. Por ello, sus valores económicos y ambientales sirven para contextualizar la discusión de E2 y E3, pero no deben utilizarse como resultados esperados de HAPPO, MASAC, MATD3 o MAAC.

(Adolfo & Chuquillanqui, 2025) analiza la eficiencia energética y la autogeneración en las industrias peruanas, con el objetivo de establecer cómo ambas estrategias pueden contribuir a la sostenibilidad ambiental, la economía verde y la competitividad empresarial mediante la reducción de costos, emisiones y dependencia de la red eléctrica. Metodológicamente, el artículo aplica una revisión sistemática de fuentes académicas, tesis de maestría, informes técnicos y publicaciones periodísticas para identificar estrategias de optimización del consumo, incorporación de energías renovables y gestión eficiente de recursos. Los resultados muestran que la combinación de eficiencia energética y autogeneración favorece la disminución del consumo y de los costos operativos, reduce el impacto ambiental y fortalece la resiliencia energética; no obstante, el artículo identifica barreras regulatorias, económicas, tecnológicas y formativas que limitan su adopción generalizada. El autor concluye que se requieren marcos regulatorios flexibles, innovación tecnológica, incentivos financieros sostenibles y coordinación entre el Estado y las empresas. Para esta tesis, el antecedente aporta al contexto nacional de D-VD.2 y D-VD.3 y sustenta la necesidad de evaluar conjuntamente resultados económicos y ambientales, en lugar de considerar la eficiencia únicamente como reducción de consumo. El artículo fue publicado en Gestión en el Tercer Milenio, revista de la Universidad Nacional Mayor de San Marcos incorporada al Catálogo 2.0 de Latindex.

Análisis crítico. El artículo permite triangular los resultados técnicos de los otros antecedentes con una perspectiva nacional de sostenibilidad empresarial, autogeneración y regulación. Sin embargo, sus conclusiones proceden de una revisión documental y no de un experimento controlado, por lo que no proporciona porcentajes comparables de reducción de

costos o emisiones. Tampoco estudia comunidades de edificios, almacenamiento coordinado, vehículos eléctricos o algoritmos MADRL. Su utilidad en la discusión consiste en explicar la importancia estratégica de combinar eficiencia, costos, emisiones y resiliencia en el contexto peruano, pero no en validar la superioridad de un algoritmo específico.

(Tanco, 2022) propone un método de gestión de la demanda pico para reducir los costos energéticos de una empresa de pinturas y envases ubicada en Lima, con el objetivo de disminuir la máxima demanda y el gasto eléctrico sin afectar el nivel de producción. Metodológicamente, la investigación integra las condiciones del mercado eléctrico peruano, la metodología de *lean energy*, el análisis de la demanda coincidente, la programación de procesos productivos, la autogeneración y medidas de eficiencia energética. El diseño es aplicado y se desarrolla como tesis de maestría mediante el análisis estadístico de la demanda, la identificación de horarios críticos y la evaluación económica de las medidas propuestas. Los resultados muestran que la reprogramación de equipos y procesos críticos permite disminuir los costos manteniendo la producción; además, la incorporación de autogeneración, eficiencia energética y modificaciones contractuales mejora el desempeño tanto en horas punta como fuera de punta. La evaluación económica a cuatro años reporta un beneficio acumulado de S/ 1 493 653 y una relación beneficio/costo de 19,12. El autor concluye que el método puede aplicarse a otros usuarios libres, siempre que las medidas sean adaptadas a sus condiciones operativas. Para la presente tesis, este antecedente proporciona evidencia directa para D-VD.1 y D-VD.3, al relacionar la reducción de demanda pico, la programación de cargas y las señales tarifarias con el ahorro económico.

Análisis crítico. El antecedente demuestra, dentro del contexto tarifario peruano, que la gestión temporal de la demanda puede generar beneficios económicos sin reducir la producción. Esta relación resulta pertinente para interpretar el comportamiento de los algoritmos en E1 y E3, particularmente frente a los KPI de pico y costo energético. Sin embargo, el estudio analiza una sola instalación industrial y aplica programación operativa, autogeneración y gestión contractual, no control secuencial aprendido. Tampoco incorpora BESS, vehículos eléctricos, recompensa comunitaria o coordinación entre edificios-agentes. Por consiguiente, el beneficio de S/ 1 493 653 y la relación beneficio/costo no constituyen un *baseline* cuantitativo para el SEAI Iquitos, sino evidencia nacional sobre la relevancia económica de desplazar y coordinar la demanda.

(Hurtado, 2021) analiza la reducción de emisiones de carbono asociada con la participación de centrales solares fotovoltaicas y parques eólicos en el despacho del Sistema Eléctrico Interconectado Nacional durante 2020, con el objetivo de determinar las emisiones

de CO_2 evitadas por el desplazamiento de generación térmica. La metodología examina el despacho eléctrico diario de los 366 días del año, utilizando información oficial del Comité de Operación Económica del Sistema y factores de emisión de combustibles fósiles procedentes del IPCC. El diseño corresponde a una investigación doctoral aplicada, cuantitativa y no experimental basada en registros operativos reales del sistema eléctrico peruano. Los resultados muestran que la generación solar y eólica evitó aproximadamente 947 729 toneladas de CO_2 durante 2020 y que cada MWh producido por estas fuentes desplazó alrededor de 0,37 toneladas de CO_2 que habrían sido emitidas mediante generación a gas natural. El autor concluye que la incorporación de energías renovables al despacho nacional produce una reducción verificable de emisiones al sustituir generación fósil. Para la presente tesis, este antecedente aporta evidencia directa a D-VD.2 y proporciona un referente nacional para interpretar la reducción de emisiones obtenida por los algoritmos en el escenario E2.

Análisis crítico. La investigación proporciona una base empírica nacional para cuantificar el efecto ambiental de la generación renovable mediante factores de emisión y datos reales de despacho. Su aporte resulta relevante para la construcción e interpretación del KPI de emisiones de CO_2 del proyecto local. Sin embargo, el análisis se realiza a escala del SEIN y evalúa el desplazamiento anual de generación térmica, no la operación horaria de una comunidad inteligente. Tampoco estudia almacenamiento, control de demanda, algoritmos MADRL ni decisiones descentralizadas. Por ello, el factor de 0,37 tCO_2/MWh puede emplearse como referencia contextual del sistema peruano, pero no debe sustituir la señal horaria de intensidad de carbono utilizada en CityLearn ni transferirse directamente al SEAI Iquitos sin comprobar la composición de su generación térmica.

(Tarrillo, 2018) desarrolla una propuesta de control, optimización y gestión de microrredes de corriente continua, cuyo objetivo general consiste en formular nuevas formas de operación e interconexión entre microrredes y la red eléctrica convencional. La metodología utiliza modelos matemáticos para representar los componentes individuales y el comportamiento conjunto de la microrred, balances de energía y potencia, estrategias de operación y procedimientos de optimización. Asimismo, estudia la interconexión entre varias microrredes y desarrolla un caso de aplicación asociado con establecimientos de salud peruanos de baja demanda eléctrica. El diseño corresponde a una investigación doctoral aplicada y experimental-computacional, sustentada en modelamiento, simulación y análisis de escenarios de operación. Como resultado, la tesis presenta modelos para la gestión coordinada de fuentes renovables, almacenamiento y cargas, propone estrategias de operación

autónoma e interconectada y demuestra la utilidad de los balances energéticos para decidir el intercambio de potencia entre componentes y microrredes. Para la presente investigación, constituye el principal antecedente nacional relacionado con el control y la optimización coordinada de microrredes, por lo que aporta al fundamento de D-VI.1 y, de manera indirecta, a D-VD.1 mediante la gestión de potencia, almacenamiento y demanda máxima.

Análisis crítico. El estudio aporta una base nacional sólida sobre modelamiento, control distribuido, almacenamiento e interconexión de microrredes. Su correspondencia con la tesis se encuentra en la necesidad de coordinar recursos heterogéneos mediante decisiones locales que afectan el balance energético global. No obstante, emplea modelos matemáticos y estrategias de optimización convencionales, sin aprendizaje por refuerzo, críticos centralizados, políticas descentralizadas ni comparación entre familias algorítmicas. Tampoco evalúa emisiones de carbono o costos tarifarios como objetivos experimentales diferenciados. En consecuencia, sustenta la arquitectura energética y el problema de coordinación, pero no proporciona una línea base directamente comparable con los cuatro algoritmos MADRL del proyecto local

2.2. Fundamentos teóricos, conceptuales y matemáticos de las variables de investigación

El fundamento teórico de la investigación se construye a partir de la relación entre una variable independiente de naturaleza algorítmica y una variable dependiente de naturaleza energética, ambiental y económica. La variable independiente está representada por la configuración del aprendizaje por refuerzo profundo multiagente empleada para aprender políticas cooperativas de control; la variable dependiente corresponde a la gestión coordinada de la flexibilidad energética, las emisiones de CO_2 y los costos energéticos. Esta relación se analiza dentro de una simulación controlada y, por tanto, el término impacto expresa el efecto diferenciado observado entre configuraciones algorítmicas, sin atribuir causalidad física directa sobre la operación real de la ciudad de Iquitos.

La investigación se encuentra delimitada por la versión final de la tesis, en la que ha sido modelada una comunidad inteligente integrada por 17 edificios institucionales y comerciales representativos del Sistema Eléctrico Aislado de Iquitos. El entorno local incorpora generación fotovoltaica, sistemas de almacenamiento en baterías, cargadores de vehículos eléctricos, capacidad V2G, cargas desplazables y demanda base no controlada. El conjunto de datos citylearn_iquitos_2023_2025 contiene 26 304 registros horarios del periodo 2023–2025, mientras que cada episodio experimental representa un año de 8 760 pasos. La comparación

se organiza mediante cuatro algoritmos (HAPPO, MASAC, MATD3 y MAAC) y tres escenarios (E1, E2 y E3), lo que constituye un diseño factorial de 12 tratamientos.

2.2.1. Modelo conceptual de la relación entre variables

El modelo conceptual asume que la gestión de la comunidad energética constituye un problema secuencial, cooperativo, parcialmente observable y multiobjetivo, en el que una decisión ejecutada en una hora modifica tanto el resultado inmediato como la disponibilidad futura de los recursos. Cargar una batería incrementa la demanda en el periodo presente, pero puede habilitar una descarga posterior durante una hora de mayor demanda, precio o intensidad de carbono; de forma análoga, una descarga vehicular puede beneficiar el perfil distrital en un instante determinado y, al mismo tiempo, comprometer el estado de carga requerido para una salida próxima.

Cada edificio constituye una unidad decisora local, pero el resultado comunitario no depende solamente del desempeño aislado de cada agente, porque las acciones individuales modifican la curva agregada del distrito. La carga simultánea de varios sistemas de almacenamiento puede originar un nuevo pico comunitario, mientras que una descarga coordinada puede reducir la importación durante un periodo crítico. La variable independiente actúa, por tanto, a través de las políticas aprendidas por los agentes, y la variable dependiente se manifiesta en los cambios producidos sobre el perfil energético, las emisiones asociadas con la energía importada y el costo resultante de consumir electricidad bajo señales temporales de precio.

Esta relación puede resumirse mediante una función conceptual:

$$Y = f(A, E, X, \xi)$$

Donde “Y” representa el vector de resultados en flexibilidad, emisiones y costos; “A” representa el algoritmo MADRL; “E” representa el escenario de priorización multiobjetivo; “X” contiene las condiciones controladas del experimento (dataset, comunidad, horizonte y protocolo); y “ξ” representa las variables exógenas (clima, irradiancia, demanda base, precio e intensidad de carbono) que el algoritmo no controla directamente. Esta expresión no representa una función cerrada implementada literalmente en el código del proyecto, sino la relación conceptual mediante la cual se organiza la investigación y se interpreta, en el Capítulo 5, la diferencia observada entre tratamientos.

La cadena de mediación entre ambas variables puede describirse como:

configuración MADRL, políticas locales aprendidas, acciones sobre BESS, EV/V2G y cargas flexibles, perfil energético comunitario, flexibilidad, CO_2 y costos.

El algoritmo no modifica directamente los indicadores de desempeño. En cada intervalo horario, la política selecciona acciones sobre los recursos controlables; el simulador aplica dichas acciones, actualiza el estado físico de los equipos y calcula la importación individual y distrital; y, únicamente a partir de las series temporales resultantes, se calculan los KPI energéticos, ambientales y económicos que sustentan la contrastación de hipótesis. Esta cadena no implica que toda diferencia observada en la variable dependiente sea atribuible en exclusiva al algoritmo: para que la comparación sea válida deben conservarse constantes el entorno, los datos, el horizonte y el protocolo experimental, conforme a la dimensión de control experimental descrita más adelante.

2.2.2. Fundamento teórico del aprendizaje por refuerzo profundo multiagente (MADRL).

El aprendizaje por refuerzo profundo multiagente, denominado MADRL por sus siglas en inglés (Multi-Agent Deep Reinforcement Learning), integra los fundamentos del aprendizaje por refuerzo, el aprendizaje profundo y los sistemas multiagente. Este enfoque permite representar problemas en los que varias entidades autónomas aprenden políticas de decisión mediante su interacción con un entorno compartido. En cada instante, los agentes reciben observaciones, seleccionan acciones, obtienen recompensas y actualizan sus políticas con el propósito de maximizar el retorno esperado a lo largo de un horizonte temporal.

El aprendizaje por refuerzo se fundamenta en la toma secuencial de decisiones. A diferencia de los métodos que optimizan exclusivamente una respuesta inmediata, este paradigma considera que una acción puede producir consecuencias en instantes posteriores. (Sutton & Barto, 2018) señalan que el agente debe aprender una política que maximice la suma esperada de las recompensas futuras, tomando en cuenta la dinámica del entorno y el efecto acumulativo de sus decisiones.

En su formulación clásica, el problema puede representarse mediante un proceso de decisión de Márkov:

$$M=\langle S, A, P, R, \gamma \rangle,$$

donde S representa el espacio de estados; A, el espacio de acciones disponibles; P, la función de transición entre estados; R, la función de recompensa; y $\gamma \in [0,1]$, el factor de

descuento. La política π (a | s) determina la probabilidad de seleccionar la acción a cuando el agente se encuentra en el estado s.

El retorno descontado desde el instante t se expresa como:

$$G_t = \sum_{k=0}^{H-t-1} \gamma^k r_{t+k+1}$$

donde H representa el horizonte del episodio y r_{t+k+1} corresponde a la recompensa obtenida después de ejecutar una acción. A partir de este retorno se define la función de valor de estado:

$$V^{\pi}(s) = E\pi\ [Gt \mid S_t = s],$$

la cual expresa el retorno esperado cuando el agente parte del estado s y continúa actuando conforme a la política π. De manera complementaria, la función de valor estado–acción se representa mediante:

$$Q^{\pi}\ (s, a) = E_{\pi}\ [G_t|S_t=s, A_t = a].$$

Esta función estima el retorno esperado cuando se ejecuta la acción a en el estado s y posteriormente se sigue la política evaluada. La diferencia entre el valor esperado de una acción y el valor promedio del estado se expresa mediante la función de ventaja:

$$A^{\pi}\ (s, a) = Q^{\pi}\ (s, a) - V^{\pi}(s)$$

La función de ventaja permite determinar si una acción resulta más o menos conveniente que el comportamiento promedio de la política en un estado determinado. Este concepto es especialmente relevante en los métodos basados en gradientes de política, debido a que orienta la actualización de la política hacia acciones con mayor utilidad esperada.

En los sistemas energéticos, la naturaleza secuencial del problema se manifiesta en la dependencia temporal entre las decisiones. Por ejemplo, la carga de una batería puede incrementar momentáneamente la importación eléctrica, pero permitir posteriormente su descarga durante un periodo de mayor demanda, precio o intensidad de carbono. De forma semejante, la carga de un vehículo eléctrico debe considerar tanto las condiciones actuales como el estado de carga requerido al momento de su salida. En consecuencia, una política energética no puede evaluarse únicamente por el resultado inmediato de cada acción, sino por sus efectos acumulados durante el horizonte de control

El aprendizaje por refuerzo profundo amplía esta formulación mediante redes neuronales utilizadas como aproximadores de políticas, funciones de valor o ambas. Esta capacidad resulta particularmente relevante cuando el espacio de observación contiene numerosas variables o cuando las acciones son continuas. (Silvestri, 2024) sostiene que el control energético de edificios requiere representar dinámicas térmicas, condiciones ambientales y restricciones operativas que pueden superar la capacidad de los métodos tabulares tradicionales. Asimismo, (Nweye, 2024) señala que las comunidades interactivas con la red presentan sistemas de control de elevada dimensionalidad, debido a la coexistencia de cargas, generación distribuida, almacenamiento y condiciones particulares de ocupación.

Dentro del aprendizaje profundo, las arquitecturas actor–critic separan la generación de acciones de su evaluación. El actor, parametrizado mediante π_θ, representa la política y determina la acción que debe ejecutarse a partir de una observación. El crítico, parametrizado mediante V_ϕ o Q_ϕ, estima la calidad de las decisiones y proporciona la señal utilizada para actualizar los parámetros del actor. Esta separación permite tratar espacios de acciones continuas sin enumerar exhaustivamente todas las alternativas posibles.

La optimización del actor puede expresarse, de manera general, mediante:

$$\nabla\theta J(\theta)=E_{\pi\theta}[\nabla_\theta \log\pi_\theta(a_t|s_t)\, A^\pi(s_t, a_t)],$$

La expresión muestra que la política incrementa la probabilidad de seleccionar acciones cuya ventaja estimada sea positiva y reduce la probabilidad de aquellas con resultados inferiores al valor esperado del estado. No obstante, el método actor–critic presentan diferentes mecanismos para controlar la exploración, la estabilidad y el sesgo de las estimaciones.

(Haarnoja et al., 2018) desarrollan Soft Actor-Critic (SAC) mediante una función objetivo que incorpora la recompensa y la entropía de la política. La regularización por máxima entropía favorece la exploración y evita que la política converja prematuramente hacia decisiones excesivamente deterministas. Por su parte, (Fujimoto et al., 2018) proponen Twin Delayed Deep Deterministic Policy Gradient (TD3) para reducir la sobreestimación de las funciones de valor mediante dos críticos, la selección conservadora de sus estimaciones y la actualización retardada del actor. Estas bases teóricas sustentan las extensiones multiagente MASAC y MATD3, respectivamente.

En entornos con múltiples agentes, el problema adquiere una complejidad adicional porque cada política modifica las condiciones observadas por las demás. La transición deja de

depender exclusivamente de la acción de un agente y pasa a estar condicionada por la acción conjunta:

$$At = (a_{1,\ t},\ a_{2,\ t},\ldots,a_{N,t})$$

Por tanto, la transición del estado puede expresarse como:

$$s_{t+1} \sim P\ (\cdot|s_t,\ a_t)$$

Cada agente i dispone de una política propia:

$$a_{i,\ t} \sim \pi_i\ (\cdot|o_{i,\ t}),$$

donde $o_{i,\ t}$ corresponde a su observación local. La política conjunta queda representada por:

$$\pi = \{\pi_1,\ \pi_2,\ldots,\pi_N\},$$

En este contexto, el aprendizaje independiente presenta limitaciones porque cada agente interpreta las modificaciones de las demás políticas como cambios en la dinámica del entorno. (Lowe et al., 2020) explican que esta condición genera no estacionariedad, debido a que las distribuciones observadas por un agente cambian mientras los demás también actualizan sus estrategias. Un modelo aprendido bajo una política conjunta puede dejar de ser válido después de que los otros agentes modifiquen sus parámetros.

La no estacionariedad puede producir oscilaciones, inestabilidad durante el entrenamiento y dificultades de convergencia. En una comunidad energética, este problema se presenta cuando varios edificios modifican simultáneamente la carga de sus baterías, vehículos o cargas flexibles. Desde la perspectiva de un edificio, el comportamiento agregado de los demás constituye una parte cambiante del entorno, aunque las variables exógenas permanezcan constantes.

Otra dificultad corresponde a la asignación de crédito. Cuando se utiliza una recompensa global, no resulta inmediato determinar cuál de las acciones individuales produjo una mejora o un deterioro del resultado colectivo. La misma recompensa puede atribuirse a todos los agentes, aunque su contribución haya sido diferente. Este problema se intensifica cuando las acciones se ejecutan simultáneamente y los agentes poseen capacidades heterogéneas.

(Atrazhev, 2023) analizó las diferencias entre recompensas individuales y conjuntas en algoritmos de aprendizaje multiagente aplicados a CityLearn. Sus resultados muestran que los efectos de ambas estructuras no son uniformes para todos los algoritmos: algunas

arquitecturas obtienen mejores resultados con señales individuales, mientras que otras aprovechan adecuadamente las recompensas compartidas. Por consiguiente, no puede asumirse que una recompensa exclusivamente global sea siempre superior, puesto que su desempeño depende del algoritmo, la información disponible y la variabilidad introducida en el aprendizaje.

Una tercera dificultad es la heterogeneidad de los agentes. Muchos métodos multiagente se desarrollan bajo supuestos de homogeneidad, como espacios de observación equivalentes, acciones semejantes o intercambio de parámetros. Sin embargo, estos supuestos no representan adecuadamente sistemas cuyos agentes poseen recursos, capacidades y responsabilidades diferentes.

(Kuba et al., 2022) sostienen que el intercambio indiscriminado de parámetros puede limitar el aprendizaje cuando los agentes desempeñan funciones distintas. Los autores proponen un enfoque de aprendizaje por refuerzo para agentes heterogéneos basado en la descomposición de la ventaja multiagente y en la actualización secuencial de políticas. Este esquema permite que cada agente reconozca indirectamente las modificaciones realizadas previamente por los demás, reduciendo la posibilidad de actualizaciones incompatibles y proporcionando fundamentos para la mejora del retorno conjunto.

La heterogeneidad resulta particularmente relevante en la gestión energética, porque los edificios pueden presentar perfiles de demanda, capacidades fotovoltaicas, sistemas de almacenamiento, cargadores de vehículos eléctricos y cargas flexibles diferentes. En consecuencia, una política adecuada para un edificio con múltiples recursos controlables no necesariamente resulta apropiada para otro con un espacio de acción reducido. El MADRL permite conservar esta diferenciación y, simultáneamente, orientar las políticas hacia objetivos compartidos (Kuba et al., 2022).

Los problemas cooperativos con observabilidad parcial pueden formalizarse mediante un proceso de decisión de Márkov parcialmente observable y descentralizado, denominado Dec-POMDP

$$G = \langle N, S, \{A_i\}_{i=1}^{N}, P, R, \{O_i\}_{i=1}^{N}, O, \gamma \rangle,$$

donde N es el conjunto de agentes; S, el estado global; Ai, el espacio de acciones del agente i; P, la función de transición; R, la función de recompensa conjunta; Oi, el espacio de observaciones locales; Ω, la función de observación; y γ, el factor de descuento. En un Dec-

POMDP, los agentes cooperan para maximizar un retorno conjunto, aunque ninguno dispone necesariamente de una observación completa del estado global (Oliehoek & Amato, 2016).

El objetivo cooperativo puede expresarse como:

$$J(\pi) = \mathbb{E}_{\pi} \sum_{k=0}^{H-1} \gamma^t \, r_t^{equipo}$$

La observabilidad parcial permite representar entornos en los que cada agente dispone únicamente de información local, mientras que el resultado de sus acciones depende también de las decisiones tomadas por los demás. Esta formulación se ajusta a las comunidades energéticas, donde cada edificio puede conocer sus condiciones internas, pero no necesariamente todos los estados operativos de los demás integrantes.

Para reducir la no estacionariedad y facilitar la cooperación se utiliza el paradigma de entrenamiento centralizado con ejecución descentralizada, denominado CTDE por sus siglas en inglés (Centralized Training with Decentralized Execution). Durante el entrenamiento, el crítico puede acceder al estado global, a las observaciones conjuntas o a las acciones de varios agentes. Durante la ejecución, cada actor selecciona sus acciones a partir de la información local disponible.

De manera general, un crítico centralizado puede representarse mediante:

$$Q_i = Qi\ (s, a_1, a_2, \ldots, a_N)\ ,$$

mientras que el actor descentralizado ejecuta:

$$a_i = \pi_i(o_i),$$

(Lowe et al., 2020) indican que la utilización de información conjunta durante el entrenamiento permite que el crítico considere las interacciones entre las políticas y reduzca la incertidumbre atribuida a las acciones de otros agentes. (Kuba et al., 2022) complementan este planteamiento al señalar que la actualización coordinada debe reconocer la heterogeneidad y evitar que las políticas individuales se modifiquen en direcciones incompatibles.

Los mecanismos de atención constituyen otra alternativa para representar las interacciones multiagente. (Iqbal & Sha, 2019) proponen críticos con atención que identifican qué agentes aportan información relevante para evaluar la acción de un agente determinado. Esta propiedad resulta útil cuando el número de agentes aumenta, debido a que no todas las

interacciones poseen la misma importancia en cada instante. El mecanismo de atención constituye el fundamento del algoritmo MAAC, en el que los críticos centralizados seleccionan las contribuciones más relevantes durante el aprendizaje.

La cooperación también depende del diseño de la función de recompensa. Una recompensa exclusivamente local puede inducir políticas que optimicen el resultado individual sin considerar sus efectos sobre otros agentes. En contraste, una recompensa exclusivamente global puede dificultar la asignación de crédito y ocultar diferencias importantes entre agentes heterogéneos. Por ello, las formulaciones cooperativas pueden combinar componentes locales y colectivas:

$$r_{i,t} = \alpha r_{i,t}^{local} + (1-\alpha)\, r_t^{equipo} \;,\; 0 \leq \alpha \leq 1$$

El componente local proporciona información sobre la consecuencia directa de las acciones del agente, mientras que el componente de equipo incorpora su influencia sobre el objetivo compartido. (Atrazhev, 2023) demuestra que la elección entre recompensas locales y conjuntas modifica el sesgo, la varianza y la coordinación de las políticas. (Nweye, 2024) añade que el diseño de la recompensa, la disponibilidad de datos y la seguridad operativa constituyen factores críticos para trasladar el aprendizaje multiagente desde la simulación hacia aplicaciones energéticas reales.

No obstante, la capacidad adaptativa del MADRL no elimina la necesidad de respetar restricciones físicas. Las acciones aprendidas deben mantenerse dentro de los límites de potencia, energía, estado de carga, disponibilidad de equipos y requerimientos de servicio. (Chen, 2024a) demuestra que los mecanismos guiados por conocimiento físico y los filtros de seguridad pueden impedir que los agentes ejecuten acciones peligrosas en problemas de regulación de tensión y frecuencia. (R. Wang, 2024b) también evidencia que la coordinación en tiempo real debe evaluarse junto con las condiciones operativas y los límites del sistema eléctrico.

Estos aportes no significan que una política MADRL garantice por sí misma seguridad, estabilidad o viabilidad física. El comportamiento obtenido depende de las observaciones, las acciones, la función de recompensa, las restricciones incluidas en el entorno y los datos utilizados durante el entrenamiento. En consecuencia, una política aprendida solo puede interpretarse dentro del dominio representado por el modelo y las condiciones experimentales.

En la presente investigación, el MADRL se adopta como fundamento para representar decisiones descentralizadas, observaciones parciales, agentes heterogéneos y objetivos

interdependientes en una comunidad de edificios. El enfoque permite que cada edificio disponga de una política local y que, durante el entrenamiento, se incorpore información comunitaria para favorecer la cooperación. Sin embargo, la evaluación de las políticas no se limita a la recompensa acumulada, sino que debe complementarse con indicadores energéticos, ambientales, económicos y de cumplimiento operativo.

Por tanto, el fundamento teórico del MADRL se articula en cinco componentes: la toma secuencial de decisiones mediante procesos de Márkov; la aproximación profunda de políticas y funciones de valor; la interacción entre múltiples agentes; la coordinación bajo observabilidad parcial mediante Dec-POMDP y CTDE; y el diseño de recompensas y restricciones coherentes con el dominio energético. Esta articulación proporciona la base conceptual para estudiar comparativamente algoritmos multiagente sin asumir que alguno sea universalmente superior en todos los objetivos o condiciones experimentales

2.2.2.1. Dimensión de investigación de variable independe (D-VI.2): algorítmica

Comprende cuatro niveles del factor experimental: HAPPO, método on-policy con actualización secuencial y región de confianza para agentes heterogéneos; MASAC, enfoque off-policy de máxima entropía; MATD3, actor–critic off-policy con críticos dobles y actualización retardada; y MAAC, actor–critic con atención selectiva en el crítico centralizado (Kuba et al., 2022), (Z. Wang et al., 2021), (Ackermann et al., 2019) y (Iqbal & Sha, 2019) . Los cuatro algoritmos se comparan bajo la misma comunidad, el mismo perfil unificado de recompensa y el mismo protocolo de evidencia.

La literatura sobre cada familia algorítmica ofrece definiciones convergentes, pero fundamentadas en mecanismos distintos, lo que constituye en sí mismo un estado del arte de la dimensión algorítmica. Para HAPPO, (Kuba et al., 2022) definen el problema central del aprendizaje cooperativo multiagente como la ausencia de una garantía de mejora monótona cuando varios agentes actualizan sus políticas de forma simultánea, incluso en juegos plenamente cooperativos; su solución (el lema de descomposición de la ventaja multiagente y el esquema de actualización secuencial) permite que cada agente mejore la política conjunta sin exigir parámetros compartidos ni supuestos de homogeneidad. (Zhong et al., 2024) generalizan esta definición mediante el marco de Aprendizaje por Refuerzo para Agentes Heterogéneos (HARL), y muestran empíricamente que la ventaja de los algoritmos heterogéneos sobre sus contrapartes homogéneas se amplía a medida que aumenta la

heterogeneidad entre agentes, condición directamente aplicable a los 17 edificios de la comunidad de Iquitos.

Para MASAC, (Haarnoja et al., 2018) definen el aprendizaje por máxima entropía como la maximización simultánea del retorno esperado y de la entropía de la política, de modo que el agente aprenda no una única forma de resolver la tarea sino una familia de soluciones igualmente competentes, lo que reduce la convergencia prematura hacia óptimos locales. (Z. Wang et al., 2021) trasladan esta definición al entorno multiagente mediante MASAC, sustituyendo la salida determinista de MADDPG por una política gaussiana estocástica en cada agente, y reportan una velocidad de entrenamiento superior junto con mayor estabilidad y resistencia a perturbaciones frente a su antecesor determinista.

Para MATD3, (Z. Wang et al., 2021) definen el sesgo de sobreestimación como una consecuencia sistemática del error de aproximación en métodos actor-crítico, que TD3 corrige mediante dos redes críticas, la selección del valor mínimo entre ambas, el suavizado de la acción objetivo y la actualización retardada de la política. (Ackermann et al., 2019) extienden esta definición al dominio multiagente y demuestran, mediante evaluación empírica en seis tareas cooperativo-competitivas, que MADDPG sobreestima sistemáticamente los valores Q mientras que MATD3, con críticos centralizados dobles, los subestima ligeramente, pero se aproxima más al valor real, resultado que sustenta su elección como representante del control continuo determinista en la tesis.

Para MAAC, (Iqbal & Sha, 2019) definen la atención multiagente como un mecanismo de memoria diferenciable de tipo clave-valor mediante el cual cada agente consulta selectivamente la información de sus pares en lugar de agregar de manera uniforme las observaciones de todos los demás, lo que favorece la escalabilidad cuando el número de agentes crece como ocurre en la comunidad de 17 edificios sin exigir supuestos sobre la localidad temporal o espacial de las interacciones.

a. Metodología de selección de los cuatro algoritmos MADRL.

La selección de HAPPO, MATD3, MASAC y MAAC se realizó a priori mediante criterios de elegibilidad y complementariedad algorítmica definidos antes de observar los resultados experimentales del proyecto. No se utilizaron directamente las recompensas publicadas para elegirlos, porque los artículos emplean entornos, cantidades de agentes, funciones de recompensa, presupuestos de interacción y algoritmos comparadores diferentes.

Por tanto, esos resultados sustentan las propiedades de cada método, pero no demuestran cuál es superior para la gestión coordinada de flexibilidad, emisiones y costos en Iquitos.

Los criterios obligatorios fueron: pertenecer al aprendizaje profundo por refuerzo multiagente; ser model-free; generar experiencia mediante interacción online con el simulador; admitir entrenamiento centralizado y ejecución descentralizada (CTDE), o una implementación equivalente; ser compatible o adaptable a acciones continúas acotadas; permitir coordinación cooperativa; y aportar una estrategia diferenciada para los 17 edificios. El uso de replay buffer de MATD3, MASAC y MAAC no los convierte en métodos offline: las transiciones se generan durante la interacción online y luego se reutilizan en actualizaciones off-policy.

La complementariedad determinó la selección final. HAPPO fue incorporado como representante on-policy por su actualización secuencial y su soporte de políticas heterogéneas (Kuba et al., 2022) . MATD3 representa el control continuo determinista y la reducción de sobreestimación mediante críticos centralizados dobles (Ackermann et al., 2019) . MASAC representa políticas estocásticas de máxima entropía para ampliar la exploración frente a incertidumbre de demanda, generación fotovoltaica y carbono (Z. Wang et al., 2021). MAAC representa la coordinación selectiva y escalable mediante un crítico con atención (Iqbal & Sha, 2019). La Tabla 2 resume esta diversidad y su relación con la tesis.

Tabla 1

Síntesis comparativa de los cuatro algoritmos MADRL seleccionados

MADRL	Perfil de elegibilidad	Mecanismo diferenciador	Relación con la tesis	Condición de implementación
HAPPO	Model-free; online; on-policy; política estocástica; CTDE; acciones continuas o discretas.	Actualización secuencial y políticas heterogéneas; prioriza estabilidad.	Representa diferencias entre 17 edificios con cargas, PV, BESS y EV distintos.	Mayor costo muestral; igualar pasos de entorno, cómputo y presupuesto de ajuste.
MATD3	Model-free; online; off-policy; política determinista; CTDE; acción continua nativa.	Dos críticos centralizados reducen la sobreestimación y favorecen control preciso.	Adecuado para consignas acotadas de BESS, climatización, EV y cargas flexibles.	Controlar exploración determinista y documentar la reimplementación reproducible.
MASAC	Model-free; online; off-policy; política estocástica gaussiana; CTDE; acción continua.	Máxima entropía para exploración amplia y mayor robustez ante perturbaciones.	Contrasta incertidumbre horaria de clima, PV, demanda, carbono y precios.	Auditar código, hiperparámetros, semillas e intervalos por evidencia original limitada.

MAAC	Model-free; online; off-policy; política estocástica; CTDE; actor continuo adaptable.	El crítico con atención filtra interacciones relevantes y mejora la escalabilidad.	Permite coordinación selectiva entre 17 edificios con perfiles heterogéneos.	Adaptar y validar el actor continuo y su equivalencia en CityLearn/Iquitos.	

Nota. Todos los candidatos son model-free, se entrenan online y permiten coordinación cooperativa bajo CTDE. La tabla no establece un ganador; resume la complementariedad definida a priori. Fuente: elaboración propia a partir de (Kuba et al., 2022), (Ackermann et al., 2019), (Z. Wang et al., 2021), (Iqbal & Sha, 2019) y la matriz Backends_MADRL del proyecto.

Tabla 2

comparación de MADRL y la razón por la selección

MADRL	Clasificación	Entorno y datos originales	Comparadores	Evidencia publicada	Razón para seleccionarlo
HAPPO	Model-free, online, on-policy, CTDE, política estocástica	SMAC y 12 configuraciones Multi-Agent MuJoCo. No usa dataset fijo; genera trayectorias online.	HATRPO, MAPPO, IPPO y MADDPG	Los autores reportan que HAPPO/HATRPO superan a IPPO, MAPPO y MADDPG en las 12 configuraciones MAMuJoCo. En SMAC, HAPPO, HATRPO y MAPPO llegan a 100%, por lo que ese resultado no discrimina un ganador.	Representa estabilidad on-policy, actualización secuencial y políticas heterogéneas para edificios diferentes. (Kuba et al., 2022)
MATD3	Model-free, online, off-policy, CTDE, determinista	MPE y Ant-v2 dividido entre agentes. Experiencia online almacenada en replay buffer.	MADDPG; IL-TD3 y SA-TD3 en Ant	Supera a MADDPG en 3 de 4 tareas adversariales, mejora Cooperative Communication y Ant; pierde en Covert Communication.	Representa control continuo determinista, eficiencia muestral y reducción de sobreestimación mediante dos críticos. (Ackermann et al., 2019)
MASAC	Model-free, online, off-policy, CTDE, estocástico	Entorno denominado GCE: navegación cooperativa y predator–prey. No utiliza dataset fijo.	MADDPG	Tabla: objetivo alcanzado 86.4% frente a 74.8%; colisiones 13.6% frente a 25.2%. No reporta semillas ni intervalos.	Representa máxima entropía, exploración y políticas continuas estocásticas ante incertidumbre climática, fotovoltaica y de demanda. (Z. Wang et al., 2021)
MAAC	Model-free, online, off-policy, CTDE, estocástico	MPE: Treasure Collection, Rover-Tower y Cooperative Navigation.	DDPG, MADDPG, COMA, versiones SAC y MAAC	Navegación: −1.74±0.05 frente a −2.09±0.12 de MADDPG+SAC. En Treasure Colección	Representa escalabilidad y selección mediante atención de las interacciones

con atención	Replay buffer de un millón de transiciones.	Uniform	reporta mejoras de 17%, 98% y 208% para 4, 8 y 12 agentes.	relevantes entre 17 edificios. Requiere adaptar y validar un actor continuo. (Iqbal & Sha, 2019)

Nota: tabla comparativa de los 4 MADRL con otros MADRL como baseline y su razón de selección para la presente tesis. La tabla no establece un ganador; resume la complementariedad definida a priori. Fuente: elaboración propia a partir de (Kuba et al., 2022), (Ackermann et al., 2019), (Z. Wang et al., 2021), (Iqbal & Sha, 2019) y la matriz Backends_MADRL del proyecto.

No se seleccionaron HATRPO y MAPPO porque pertenecen a la misma familia on-policy cubierta por HAPPO. IPPO fue descartado como tratamiento principal porque no utiliza entrenamiento centralizado para afrontar la no estacionariedad y la coordinación global. MADDPG se conserva como baseline, ya que los artículos de MATD3, MASAC y MAAC lo emplean como referencia y proponen mecanismos para superar sus limitaciones. COMA se orienta principalmente a acciones discretas; IL-TD3 omite coordinación centralizada; y SA-TD3 utiliza un solo agente con observabilidad completa, por lo que no representa la ejecución multiagente descentralizada requerida. Estos algoritmos pueden utilizarse como baselines o ablaciones, pero no como candidatos finales.

La selección bibliográfica no determina un ganador. Los cuatro algoritmos deben compararse en el mismo CityLearn v2 con la extensión experimental para Iquitos, empleando idénticos datos, observaciones, acciones, restricciones, función de recompensa, pasos de interacción y presupuesto de optimización. El protocolo temporal propuesto entrena con 2023, valida y ajusta con 2024, y evalúa en 2025 con la política bloqueada. Como 2024 es bisiesto, las particiones contienen 8 760, 8 784 y 8 760 horas, respectivamente, para un total de 26 304 horas.

En la fase confirmatoria, la unidad experimental debe ser la semilla independiente y no cada episodio. Se recomiendan al menos 12 semillas para cada combinación de cuatro algoritmos y tres escenarios, es decir, un mínimo de 144 corridas principales. La evaluación debe integrar la prueba de Friedman pareada, Kendall W, comparaciones post-hoc con corrección de Holm cuando proceda, tamaños de efecto e intervalos de confianza. La selección global debe utilizar TOPSIS con igual peso para flexibilidad, carbono y costos, complementado con frente de Pareto, sensibilidad de pesos y cumplimiento de restricciones. Si no existe separación estadística y práctica, corresponde declarar co-líderes o ausencia de un ganador único. Hasta ejecutar este protocolo, los resultados de una sola semilla conservan alcance descriptivo y no justifican superioridad universal

b. Adecuaciones de los cuatro backends MADRL al dominio eléctrico (OE.1 flexibilidad, OE.2 CO2, OE.3 costos).

Los backends oficiales pinados en external/ (HARL/HAPPO, MARL/src-MASAC, off-policy/MATD3 y MAAC) fueron diseñados, validados y entrenados de forma predominante en dominios de referencia multiagente (p. ej. SMAC/StarCraft, MPE u otros benchmarks MARL). En su forma original no están preparados, ni entrenados, ni aplicados out-of-the-box al control de una comunidad eléctrica con DER, EV/V2G y señales horarias de precio e intensidad de carbono. Por tanto, no resuelven por si solos el problema de esta tesis: flexibilidad energética (OE.1), emisiones de CO2 (OE.2) y costos economico-energeticos (OE.3) sobre el SEAI Iquitos.

La contribución teórica no consiste en reinventar HAPPO, MASAC, MATD3 o MAAC, sino en adecuarlos vía la capa CityLearn v3 propuesto, el adaptador común citylearn_v3_training_common.py y wrappers tipados a un Dec-POMDP cooperativo de 17 edificios heterogéneos, recompensa multiobjetivo unificada (CityLearnV3MADRLRewardFunction, perfil unified_comparable_v4) y evaluación con KPIs oficiales evaluate_v2. El Cap. 4 documenta la implementación; esta sección fija el sustento teórico de cada adecuación.

Capa común de adecuación (los cuatro MADRL): (i) contrato Dec-POMDP/CTDE con estado global s en R^ {1856}; (ii) padding / policy mapping ante heterogeneidad d_oi en [54, 327] y d_ai en [5, 44]; (iii) recompensa multiobjetivo con escenarios E1/E2/E3 y r_team = 0,70; (iv) dataset citylearn_iquitos_2023_2025 (BESS, PV, 185 cargadores EV, TOU Electro Oriente, CI dinamico); (v) orquestación train_citylearn_v3{happo, masac, matd3, maac}.py bajo matriz 4x3 comparable.

HAPPO. - CityLearnHARLEnv + external/HARL. El HAPPO original (Kuba et al., 2022) ; (Zhong et al., 2024) aporta actualización secuencial con trust región para agentes heterogéneos, pero HARL espera un ShareVecEnv de juegos multiagente, no setpoints BESS/EV. Adecuación: wrapper CityLearnHARLEnv con observación local continua y share_observation_space = estado CTDE; acciones continuas en [-1,1]^{d_ai} (BESS + EV + lavadora); recompensa mixta del perfil v4; script train_citylearn_v3_happo.py. Teóricamente es el candidato on-policy a la heterogeneidad tipológica del SEAI.

MASAC. - CityLearnSMACDiscreteEnv + external/MARL/src (Z. Wang et al., 2021) . El backend MASAC/mSAC asume API tipo SMAC (get_obs, get_state, acciones discretas).

CityLearn expone control continuo multidimensional. Adecuación: adaptador SMAC-like con get_state () = s CTDE; discretizacion action_bins=3 y discrete_action_mode = axis (base un-eje + no-op; no producto cartesiano 3^{d_ai}, inviable con d_ai hasta 44); mezcla cooperativa tipo QMIX sobre la recompensa energética de equipo; script train_citylearn_v3_masac.py. Aporta exploración entrópica off-policy sobre un espacio de acción energético tratable.

MATD3. - CityLearnOffPolicyVecEnv + external/off-policy. El repositorio autor (Ackermann et al., 2019) (external/MATD3implementation, TensorFlow 1.x / Python 3.6) no es el stack de entrenamiento: se adecua via backend PyTorch marlbenchmark/off-policy (clases MATD3 / R_MATD3). Adecuación: wrapper vectorizado de un hilo; acciones continuas con doble crítico, policy delay y target noise sobre actuadores BESS/EV; policy_mapping_fn y padding para 17 políticas heterogéneas; script train_citylearn_v3_matd3.py. Es el candidato determinístico off-policy al control continuo distrital.

MAAC. - CityLearnMAACVecEnv + external/MAAC. MAAC (Iqbal & Sha, 2019) introduce atención multi-cabeza en el crítico para dominios donde la relevancia entre agentes cambia; no trae de fabrica recompensa de pico/rampa/CO2/TOU. Adecuación: wrapper que expone observaciones por agente al mecanismo de atención; misma discretizacion eje-wise que MASAC (bins=3); atención sobre los 17 edificios heterogéneos bajo recompensa v4; script train_citylearn_v3_maac.py. Operacionaliza coordinación selectiva (p. ej. hospital vs mall vs campus) sin comunicación en ejecución.

Tabla 3

Adecuación de los cuatro MADRL originales al problema eléctrico (OE.1 / OE.2 / OE.3)

Algoritmo	Dominio típico del original	Wrapper / backend en el proyecto	Adecuación clave	Capacidad resultante OE.1–OE.3
HAPPO	MARL heterogéneo genérico (HARL)	CityLearnHARLEnv / external/HARL	Share-obs CTDE; acción continua BESS/EV	On-policy cooperativo sobre DER/EV heterogéneos
MASAC	SMAC-like / acción discreta	CityLearnSMACDiscreteEnv / MARL/src	API SMAC; bins=3 axis; Q-mix energético	Off-policy entrópico sobre control eléctrico discretizado
MATD3	Paper TF1; activo: off-policy PyTorch	CityLearnOffPolicyVecEnv / off-policy	Backend PyTorch 3.9; acción continua	Off-policy determinístico continuo BESS/EV

MAAC	Atención multiagente genérica	CityLearnMAACVecEnv / external/MAAC	Atención 17 agentes + bins=3	Coordinación atencional flex/CO2/costo	bajo

Nota. Los backends originales no fueron preparados ni entrenados ni aplicados out-of-the-box a flexibilidad, CO2 y costos energéticos. La adecuación se sustenta en wrappers y adaptadores del proyecto (citylearn_v3_training_common.py; Cap. 4). Fuente: elaboración propia a partir de external/HARL, external/MARL/src, external/off-policy, external/MAAC y la capa CityLearn v3 propuesto.

En síntesis: los cuatro MADRL originales no resuelven por si solos el problema eléctrico multiobjetivo; las adecuaciones del proyecto (wrappers + Dec-POMDP/CTDE + recompensa unified_comparable_v4 + dataset Iquitos + evaluate_v2) son la condición de posibilidad teórica y operativa del cuasiexperimento 4x3 (Caps. 3–5).

2.2.2.2. Dimensión de investigación de variable independe (D-VI.2): priorización multiobjetivo

Los escenarios condicionan la política hacia un objetivo dominante mediante vectores de peso distintos en la función de recompensa multiobjetivo. E1 prioriza flexibilidad [0,70; 0,15; 0,15] y se sustenta en KPIs de pico y rampa (Vázquez-Canteli et al., 2020) ; (Wilk et al., 2024b) ; El escenario E2 se fundamenta en un control multiobjetivo consciente de las emisiones, en el cual la intensidad de carbono de la electricidad se incorpora como señal de entrada para orientar el consumo hacia periodos con menor contenido de carbono. Este enfoque permite coordinar las decisiones operativas considerando simultáneamente el desempeño energético, los costos y las emisiones asociadas al consumo eléctrico (Nweye, Liu, et al., 2022) ; (Bokde et al., 2020) ; (Tranberg et al., 2019) . Por su parte, el escenario E3 prioriza la reducción de los costos económicos mediante los pesos [0,25; 0,15; 0,60]. Su formulación se sustenta en la respuesta de la demanda ante variaciones de precios, la aplicación de tarifas diferenciadas por periodos horarios y el control de la máxima demanda, debido a que estas señales económicas pueden incentivar el desplazamiento o la reducción del consumo durante los periodos de mayor costo (Tran & Sahu, 2023) y lecturas de energía mensual suministradas por electro oriente de cada edifico.

La necesidad de tratar flexibilidad, emisiones y costos como objetivos separados (y no como un único término agregado), encuentra sustento empírico en la literatura sobre diseño de recompensas multiobjetivo. (Nweye et al., 2024) realiza una búsqueda sistemática de parámetros de recompensa que combinan costo eléctrico y emisiones de carbono mediante exponentes y pesos diferenciados, y encuentra que ambos indicadores están positivamente correlacionados (mejorar uno tiende a mejorar el otro), pero que la señal de emisiones resulta

comparativamente más débil para orientar el aprendizaje del agente que la señal de costo, de modo que ponderaciones distintas producen políticas con perfiles de desempeño distinguibles entre sí. Este hallazgo respalda la decisión metodológica de esta tesis de no fijar una única ponderación fija, sino de definir tres escenarios E1, E2 y E3 que permiten observar cómo la priorización de cada objetivo modifica el comportamiento aprendido por los cuatro algoritmos, en lugar de asumir a priori que una combinación única de pesos es representativa de todo el espacio de decisión multiobjetivo.

2.2.2.3. Dimensión de investigación de variable independe (D-VI.3): control experimental.

Para aislar el efecto de D-VI.1 y D-VI.2, la tesis mantiene constantes el dataset citylearn_iquitos_2023_2025, la función de recompensa unified_comparable, la semilla de reproducibilidad y el protocolo CTDE. Esta dimensión de control asegura que las diferencias observadas en D-VD.1, D-VD.2 y D-VD.3 se atribuyan al algoritmo y al escenario, no a variaciones del entorno o del protocolo.

La justificación de esta dimensión de control no es meramente procedimental, sino que responde a una preocupación documentada en la literatura sobre reproducibilidad del aprendizaje por refuerzo. (Henderson et al., 2018) muestran que los resultados obtenidos con un mismo algoritmo pueden variar sustancialmente entre implementaciones, semillas aleatorias y configuraciones de hiperparámetros, al punto de que las diferencias atribuidas al desempeño de un algoritmo pueden originarse, en realidad, en decisiones de implementación o de ingeniería que no fueron reportadas. En consecuencia, la comparación entre métodos de aprendizaje por refuerzo solo resulta metodológicamente válida cuando las condiciones experimentales se mantienen controladas o se describen con suficiente detalle, se utilizan múltiples ejecuciones con diferentes semillas aleatorias y se aplican pruebas estadísticas que permitan determinar si las diferencias observadas son realmente significativas; los autores concluyen que la comparación entre métodos de aprendizaje por refuerzo solo resulta válida cuando el resto de las condiciones experimentales (entorno, datos, presupuesto de cómputo y protocolo de evaluación) permanece controlado. Esta advertencia sustenta directamente la exigencia, adoptada en la presente tesis, de mantener constantes el dataset citylearn_iquitos_2023_2025, la función de recompensa unified_comparable y el protocolo CTDE para los cuatro algoritmos: sin este control, cualquier diferencia observada en D-VD.1, D-VD.2 o D-VD.3 podría confundirse con artefactos de implementación en lugar de reflejar una diferencia genuina entre configuraciones de la variable independiente.

2.2.3. Variable dependiente: desempeño coordinado de la comunidad energética.

El desempeño coordinado de la comunidad energética se entiende como la capacidad de un conjunto de edificios, prosumidores y recursos energéticos distribuidos para tomar decisiones interdependientes que mejoren el comportamiento agregado de la comunidad, sin incumplir las restricciones técnicas ni las necesidades particulares de sus integrantes. Este desempeño comprende la coordinación temporal de la generación fotovoltaica, los sistemas de almacenamiento, las cargas flexibles, los vehículos eléctricos y el intercambio con la red, con el propósito de reducir la demanda máxima, suavizar las rampas de potencia, disminuir los costos y las emisiones, y conservar la disponibilidad energética requerida por los usuarios.

Desde la perspectiva de las comunidades interactivas con la red, (Nweye, 2024) señala que la coordinación de múltiples recursos energéticos distribuidos resulta compleja debido a que deben satisfacerse simultáneamente objetivos potencialmente contrapuestos, como la eficiencia energética, el confort de los ocupantes, la reducción de emisiones y la prestación de flexibilidad al sistema eléctrico. En este contexto, el desempeño comunitario no debe evaluarse únicamente mediante el beneficio individual de cada edificio, sino a partir de indicadores agregados que reflejen el efecto conjunto de las decisiones sobre la curva de demanda y el intercambio energético con la red.

Esta interpretación coincide con (R. Wang, 2024a) , quien sostiene que la creciente incertidumbre asociada con la generación renovable, la electrificación del transporte y la diversidad de los equipos controlables exige métodos de coordinación a nivel de sistema. La regulación coordinada permite adaptar las decisiones de múltiples dispositivos energéticos para reducir desviaciones operativas, pérdidas de potencia, costos y condiciones extremas de funcionamiento. Por consiguiente, la coordinación no representa solamente la ejecución simultánea de acciones, sino la selección de acciones compatibles que contribuyan a un objetivo comunitario común.

En los sistemas multiagente, cada edificio puede representarse como un agente que observa parcialmente el entorno y administra sus propios recursos. Sin embargo, las acciones locales modifican el entorno de los demás agentes, por lo que una estrategia individualmente conveniente puede resultar perjudicial para la comunidad. Por ejemplo, el traslado simultáneo del consumo de varios edificios hacia un periodo de menor precio puede generar un nuevo pico agregado. (Atrazhev, 2023) demuestra que la estructura de las recompensas individuales y conjuntas influye directamente en el comportamiento cooperativo y en los resultados

obtenidos sobre indicadores como la demanda máxima y las rampas distritales. El autor advierte que la recompensa conjunta no siempre produce automáticamente la mejor coordinación, debido a que su efectividad depende del algoritmo, la información disponible y la variabilidad del entorno.

La heterogeneidad de los integrantes también constituye una condición fundamental. Los edificios pueden diferir en demanda, capacidad fotovoltaica, almacenamiento, ocupación, disponibilidad de vehículos eléctricos y espacios de acción. (Zhong et al., 2024) indican que la coordinación entre agentes heterogéneos requiere mecanismos capaces de reconocer sus distintos roles, observaciones y capacidades. En este sentido, el entrenamiento centralizado con ejecución descentralizada permite utilizar información global durante el aprendizaje, mientras que cada agente conserva la capacidad de ejecutar acciones mediante sus observaciones locales. Esta arquitectura contribuye a reducir conflictos entre las políticas y a mejorar la estabilidad del aprendizaje cooperativo.

En aplicaciones energéticas, (Chen, 2024b) muestra que el aprendizaje por refuerzo profundo multiagente permite coordinar prosumidores, sistemas fotovoltaicos y baterías mediante decisiones relacionadas con el comercio energético, la potencia reactiva, la regulación de tensión y el balance del estado de carga. Estos resultados evidencian que el desempeño coordinado integra dimensiones económicas y técnicas, puesto que la reducción del costo comunitario debe alcanzarse respetando las restricciones físicas de los recursos y las condiciones operativas de la red. De forma complementaria, (Ma, 2024) formula la gestión energética como una interacción entre diferentes entidades (operador del sistema de distribución, almacenamiento y consumidores energéticos) cuyos objetivos deben coordinarse bajo incertidumbre para minimizar el costo total y mantener la calidad del servicio eléctrico.

A partir de estos aportes, en el presente estudio se define el desempeño coordinado de la comunidad energética como: El grado en que los edificios y recursos energéticos distribuidos de una comunidad ejecutan decisiones locales compatibles e interdependientes que mejoran colectivamente la flexibilidad energética, reducen las emisiones y los costos, suavizan el intercambio de potencia con la red y garantizan el cumplimiento de las restricciones técnicas y de servicio de cada integrante.

Esta definición diferencia el desempeño coordinado de la simple agregación de resultados. La agregación representa la suma de consumos, costos o emisiones individuales; en cambio, la coordinación considera las interacciones entre agentes, la simultaneidad de sus

acciones y los efectos que estas producen sobre el comportamiento comunitario. En consecuencia, una estrategia no puede calificarse como coordinadamente eficiente cuando mejora un indicador global a costa de incumplir el estado de carga requerido de los vehículos eléctricos, agotar excesivamente las baterías, generar nuevos picos de demanda o deteriorar significativamente otros objetivos.

Por tanto, el desempeño coordinado debe evaluarse mediante un enfoque multidimensional que incorpore, como mínimo, indicadores de demanda máxima, rampas de potencia, factor de carga, costos energéticos, emisiones de CO_2, aprovechamiento de la generación renovable y cumplimiento de las restricciones operativas. La recompensa obtenida por el algoritmo constituye un mecanismo para orientar el aprendizaje, pero no sustituye la evaluación mediante indicadores físicos, económicos y ambientales independientes.

2.2.3.1. Dimensión de investigación de variable dependiente (D-VD.1): flexibilidad energética (D-VD.1).

La primera dimensión, referida al pico, mide la capacidad de reducir la importación máxima distrital, medida con peak_average. (Lund et al., 2017) ubican la reducción de pico dentro de los sistemas energéticos inteligentes, mientras (Vazquez-Canteli et al., 2020) estandarizan peak_average como KPI comparable en CityLearn. Dimensión 2 (rampa): suavizado de variaciones horarias de importación, medido con ramping_average. (Nweye et al., 2024) incorporan ramping como KPI distrital en CityLearn v2, y (Wilk et al., 2024b) reportan mejoras de coordinación MADRL en perfiles de demanda. Dimensión 3 (factor de carga): equilibrio entre pico y demanda media, medido con one_minus_load_factor_average y el indicador compuesto flex_composite. (Vázquez-Canteli & Nagy, 2019b) vinculan el factor de carga con respuesta a la demanda, y (Xie et al., 2023) demuestran que mecanismos de atención multiagente mejoran la suavidad del perfil agregado.

La definición de flexibilidad energética admite múltiples formulaciones convergentes en la literatura, cada una aportando un matiz distinto que enriquece su tratamiento como variable dependiente. (Jensen et al., 2017), en el marco del proyecto IEA EBC Annex 67, definen la flexibilidad energética de un edificio como su capacidad para gestionar la demanda y la generación en función de las condiciones climáticas locales, las necesidades de los usuarios y los requerimientos de la red. (Reynders et al., 2018) complementan esta definición al señalar que, aunque la literatura coincide en concebir la flexibilidad como la adaptación temporal del

perfil energético, no existe una métrica única para cuantificarla, debido a que los indicadores consideran de manera diferente la potencia disponible, la energía desplazada, la duración, el momento de activación y el costo de la respuesta. Por su parte, (Neukomm et al., 2019) trasladan esta capacidad al enfoque de los edificios eficientes interactivos con la red, en los cuales las tecnologías inteligentes y los recursos energéticos distribuidos permiten modificar la demanda y optimizar simultáneamente los costos, los servicios prestados a la red y las necesidades de los ocupantes.

En conjunto, estos planteamientos muestran que la flexibilidad energética constituye una capacidad contextual, dinámica y multidimensional, cuyo aprovechamiento depende de las condiciones del edificio, la disponibilidad de los recursos controlables y las necesidades del sistema eléctrico. (Nweye, 2024) amplía esta perspectiva hacia las comunidades interactivas con la red y sostiene que la agregación de edificios exige coordinar recursos heterogéneos para evitar que una mejora individual produzca efectos adversos sobre la demanda comunitaria. En consecuencia, la presente investigación entiende la flexibilidad energética como la capacidad coordinada de los edificios para modificar temporalmente su intercambio con la red mediante cargas flexibles, almacenamiento, generación fotovoltaica y vehículos eléctricos, manteniendo las restricciones operativas y los requerimientos de servicio de los usuarios

Esta diversidad conceptual se refleja en la variedad de indicadores utilizados para cuantificar la flexibilidad. (H. Li et al., 2021) agrupan los KPI en seis dimensiones como son la energía, potencia, costo, duración, emisiones y confort, asimismo señalan que su selección depende del propósito de la evaluación y del actor interesado: mientras los ocupantes priorizan el confort y los beneficios económicos, los operadores de red requieren información relacionada con la potencia, la energía desplazable y la respuesta temporal. (H. Li et al., 2023) amplían esta perspectiva al identificar 48 KPI de flexibilidad basados en datos y clasificarlos, entre otros criterios, según la necesidad de una línea base; así, algunos indicadores comparan la operación controlada con un perfil de referencia convencional, mientras que otros se calculan directamente a partir de magnitudes observadas. Esta clasificación proporciona el sustento conceptual para distinguir, en la presente tesis, los valores de baseline, control y variación (Δ), aunque dicha organización constituye una decisión metodológica propia del estudio. De manera complementaria, (R. Li et al., 2022) explican que la flexibilidad se materializa mediante modificaciones en el momento y la magnitud del consumo, por lo que su evaluación debe considerar la capacidad de respuesta, la

duración, los costos y las condiciones operativas que deben preservarse. Finalmente, la Agencia Internacional de Energía define la flexibilidad de la demanda como la capacidad de ajustar el momento o la cantidad de electricidad consumida en respuesta a las necesidades del sistema y señala que su aprovechamiento mejora la utilización de los activos existentes, reduce la presión asociada con la demanda máxima y favorece la integración eficiente de generación renovable variable (International Energy Agency [IEA], 2025). En la comunidad energética estudiada en Iquitos, estos efectos se operacionalizan mediante los indicadores *peak_average, ramping_average* y *one_minus_load_factor_average*, los cuales representan, respectivamente, la demanda máxima promedio, la variación temporal de la demanda y la uniformidad del perfil agregado.

2.2.3.2. Dimensión de investigación de variable dependiente (D-VD.2): emisiones de CO_2.

Las emisiones de CO_2 representan el impacto ambiental asociado con la electricidad importada por los edificios que conforman la comunidad energética. Esta dimensión se operacionaliza mediante tres indicadores complementarios: emisiones totales, reducción respecto de la línea base y calidad temporal de la electricidad importada. El primer indicador, *carbon_emissions_total*, cuantifica las emisiones acumuladas del distrito durante el periodo anual de evaluación. En CityLearn, las emisiones del edificio i en el instante t se calculan multiplicando su consumo eléctrico neto por la intensidad de carbono correspondiente al mismo intervalo, considerando únicamente los valores positivos de importación:

$$G_{total} = \sum_{t=1}^{T} \sum_{i=1}^{N} max\left(0, E_{i,t}^{net}\right) CI_t,$$

donde $E_{i,t}^{net}$ representa el intercambio eléctrico neto del edificio i, expresado en kWh, y CI_t corresponde a la intensidad de carbono de la electricidad en kg CO_2/kWh o kg CO_2 e/kWh, según el factor adoptado. La función max (0,·) excluye los periodos de exportación neta; por tanto, el excedente fotovoltaico inyectado a la red no se contabiliza como una emisión negativa. Esta formulación coincide con la implementación oficial de CityLearn y con la definición empleada por (Nweye, 2024) , quien evalúa las emisiones a partir de la importación neta y de una tasa de emisión dependiente del tiempo. Asimismo, (Nweye et al., 2024) incorporan esta medición en CityLearn v2 para comparar estrategias de control de recursos energéticos distribuidos bajo objetivos explícitamente conscientes del carbono.

El segundo indicador, carbon_emissions_delta, mide la mejora atribuible al control MADRL frente al escenario baseline de CityLearn. En la presente investigación se define como:

$$\Delta G = G_{baseline} - G_{control},$$

de manera que un valor positivo representa una reducción de emisiones, mientras que un valor negativo indica un incremento respecto de la línea base. Complementariamente, la reducción relativa puede expresarse como.

$$\Delta G_{\%} = \frac{G_{baseline} - G_{control}}{G_{baseline}} X\ 100,$$

Esta comparación requiere una señal de intensidad de carbono con resolución temporal, debido a que perfiles con igual consumo anual pueden generar emisiones diferentes según las horas en las que se importe la electricidad. (Tranberg et al., 2019) demuestran que la intensidad de carbono del suministro presenta variaciones horarias y que la contabilidad basada en el consumo puede diferir sustancialmente de la basada exclusivamente en la generación. En el ámbito de los edificios, (Lowry, 2018) evidencia que el pronóstico anticipado de dicha intensidad permite programar acciones de respuesta de demanda en periodos ambientalmente favorables, mientras que (Leerbeck et al., 2020) desarrollan modelos de aprendizaje automático para pronosticar intensidades medias y marginales de CO_2 y facilitar la gestión de cargas flexibles. En el contexto peruano, el documento institucional pertinente es el RAGEI 2019: Reporte Anual de Gases de Efecto Invernadero del Sector Energía 2019 elaborado por (Ministerio de Energía y Minas, 2023) , el cual diferencia el Sistema Eléctrico Interconectado Nacional de los sistemas aislados y estima las emisiones a partir de los datos de consumo de combustible y sus respectivos factores de emisión. En consecuencia, esta fuente proporciona el fundamento metodológico nacional, pero no un factor horario específico para Iquitos; por ello, CI_t debe construirse con la composición y operación temporal del sistema aislado local, evitando trasladar directamente un factor promedio del SEIN.

La tercera dimensión examina la calidad temporal de las importaciones eléctricas, es decir, la capacidad del controlador para trasladar el consumo hacia intervalos con menor intensidad de carbono. No obstante, la suma de la "importación ponderada por CI_t" coincide algebraicamente con *carbon_emissions_total*; por ello, no debe presentarse como un tercer agregado independiente. Para evitar esta redundancia, se propone expresarla mediante la intensidad media de carbono de la electricidad efectivamente importada.

$$CI_{import,avg} = \frac{\sum_{i=1}^{T}\sum_{i=1}^{N} max\,(0,E_{i,t}^{net})\,CI_t}{\sum_{i=1}^{T}\sum_{i=1}^{N} max\,(0,E_{i,t}^{net})},$$

Este indicador permite diferenciar entre una reducción obtenida por consumir menos electricidad y otra alcanzada por modificar oportunamente el momento de la importación. (Nweye, 2024) observa que los controladores pueden reducir las emisiones mediante la carga de los sistemas de almacenamiento en periodos de menor costo ambiental. De manera complementaria, (Sarkar et al., 2024) muestran, en el ámbito de los centros de datos, que la coordinación multiagente en tiempo real permite orientar las decisiones operativas hacia la reducción de la huella de carbono; aunque su campo de aplicación es diferente, el estudio sustenta el mecanismo general de programación consciente del carbono. (Ye et al., 2025) trasladan este principio a redes activas y microrredes mediante un esquema MADRL seguro que integra información espaciotemporal de intensidad de carbono, objetivos económicos y restricciones físicas. La triangulación de estos aportes justifica que la función de recompensa de la presente tesis incorpore el costo ambiental instantáneo de cada agente,

$$carbon_i(t) = max\,(0, E_{i,t}^{net})\,CI_t,$$

puesto que, cuando CI_t es una señal exógena, la política no modifica directamente la intensidad de carbono de la generación, sino el momento y la magnitud de la energía importada. De este modo, *carbon_emissions_total, carbon_emissions_delta* y $CI_{import,avg}$ representan, respectivamente, el impacto ambiental absoluto, la mejora frente a la línea base y la calidad temporal de las decisiones de consumo.

2.2.3.3. Dimensión de investigación de variable dependiente (D-VD.3): costos energéticos.

Los costos energéticos representan el efecto monetario de las decisiones de importación, almacenamiento, generación local y desplazamiento temporal de cargas en la comunidad energética. Esta dimensión se operacionaliza mediante tres indicadores complementarios. El primero, *electricity_cost_total*, expresa el costo eléctrico acumulado de los 17 edificios durante el periodo anual de evaluación:

$$\mathrm{C_{total}} = \sum_{\mathrm{t=1}}^{\mathrm{T}}\sum_{i=1}^{\mathrm{N}} \mathrm{CI_{i,t}},$$

donde $\mathrm{CI_{i,t}}$ corresponde al costo monetario del intercambio eléctrico del edificio i en el intervalo t, calculado mediante la tarifa y el consumo neto registrados por el entorno. CityLearn proporciona series temporales del costo del consumo eléctrico neto y obtiene su

valor acumulado mediante la función cost; en la nomenclatura oficial, el KPI agregado aparece como *cost_total*, mientras que *electricity_cost_total* corresponde a la denominación adoptada por la implementación de la tesis. Por consiguiente, debe mantenerse esta última denominación únicamente si coincide con los campos de los artefactos experimentales y se declara expresamente su equivalencia con el KPI de CityLearn.

El segundo indicador, *electricity_cost_delta*, cuantifica la variación económica atribuible al control MADRL respecto del escenario baseline:

$$\Delta C = C_{baseline} - C_{control},$$

de modo que un valor positivo representa ahorro y uno negativo indica un incremento del costo frente a la línea base. Esta comparación se sustenta en CityLearn, donde el desempeño de las políticas de control se evalúa respecto de un controlador de referencia bajo las mismas condiciones de simulación. La literatura confirma que el costo energético depende tanto de la coordinación entre agentes como del momento en que se realizan las transacciones eléctricas. (Fang et al., 2021) muestran que un esquema MARL puede coordinar decisiones descentralizadas dentro de un mercado de microrred y mejorar su desempeño económico, mientras que (Gao et al., 2023) evidencian que MASAC facilita las transacciones entre microrredes, aprovecha su complementariedad energética y reduce el costo operativo agregado. De manera complementaria, (Xiong et al., 2024) demuestran que una política SAC puede gestionar la carga y descarga del almacenamiento en función de la tarifa por horario de uso y del estado de carga de la batería, reduciendo el costo eléctrico del usuario. Estos resultados convergen con la Agencia Internacional de Energía, que señala que la flexibilidad de la demanda disminuye los costos del sistema y de los consumidores al mejorar el aprovechamiento de la infraestructura existente y reducir la presión durante los periodos de máxima demanda (International Energy Agency (IEA), 2025).

La tercera dimensión comprende el pico facturable, representado mediante peak_billing, y la correspondencia temporal entre las importaciones y la señal de precio, expresada mediante price_signal_deviation. (Mohammadi et al., 2024) muestran que los mecanismos de respuesta a la demanda basados en precios incluyen tarifas por horario de uso, precios de punta crítica y esquemas dinámicos; no obstante, la señal empleada en esta tesis corresponde conceptualmente a una tarifa TOU, porque diferencia bloques preestablecidos y no modifica el precio en tiempo real según el estado instantáneo del sistema. Esta interpretación es coherente con la regulación peruana: las opciones MT2 y BT2 distinguen energía y potencia

en horas de punta y fuera de punta, mientras que las opciones MT3, MT4, BT3 y BT4 incorporan cargos asociados con la máxima potencia mensual (Organismo Supervisor de la Inversión en Energía y Minería (OSINERMING), 2018). Asimismo, (Al-Hallaj et al., 2018) explican que el almacenamiento puede nivelar la demanda y reducir los cargos asociados con la potencia máxima, mientras que Sepúlveda-Mora y (Sepúlveda-Mora & Hegedus, 2021) demuestran que la estructura tarifaria TOU condiciona el valor económico de los sistemas fotovoltaicos combinados con baterías. En consecuencia, *peak_billing* evalúa si el control reduce la mayor importación registrada dentro de la ventana de facturación, mientras que *price_signal_deviation* debe medir el grado en que la política evita concentrar importaciones en los periodos tarifarios más costosos.

En conjunto, los indicadores permiten distinguir tres resultados económicos: *electricity_cost_total* mide el desembolso absoluto de la comunidad; *electricity_cost_delta* determina el ahorro respecto del baseline; y *peak_billing* junto con *price_signal_deviation* explican si dicho ahorro se origina en la reducción de la máxima demanda, en el desplazamiento temporal del consumo o en ambos mecanismos. Esta triangulación evita interpretar el costo exclusivamente como energía acumulada y reconoce que dos políticas con igual consumo anual pueden producir resultados económicos diferentes cuando modifican la potencia máxima o la distribución de las importaciones entre horas de punta y fuera de punta.

2.3. Bases teóricas

2.3.1. CityLearn v3 propuesto y delimitación entre la capa experimental de tres ejes y el marco UC3M.

CityLearn v3 propuesto constituye la extensión experimental desarrollada en la presente investigación sobre el núcleo oficial de CityLearn v2. Esta denominación no corresponde a una versión externa u oficial del simulador. CityLearn v2 proporciona la representación física de los edificios y sus recursos energéticos distribuidos, así como un entorno estandarizado para el control multiagente de sistemas fotovoltaicos, almacenamiento, vehículos eléctricos y cargas flexibles. Asimismo, su función evaluate_v2() permite evaluar el desempeño mediante KPI de costos, energía intercambiada con la red, emisiones, autoconsumo, vehículos eléctricos, baterías, confort y resiliencia (Nweye et al., 2025a).

Sobre esta base, la extensión propuesta conserva la dinámica física y los KPI compatibles con evaluate_v2(), pero incorpora cuatro elementos específicos: la interfaz Dec-POMDP bajo CTDE, la organización de los objetivos OE.1–OE.3, la recompensa multiobjetivo y los

adaptadores requeridos para integrar los *backends* MADRL. La capa se implementa principalmente en v3/environment.py, v3/objectives.py, v3/config.py y v3/backends.py, mientras que CityLearnV3MADRLRewardFunction, configurada mediante el perfil unified_comparable_v4, establece la recompensa utilizada en los tratamientos experimentales. La arquitectura local confirma que las doce corridas canónicas se ejecutaron mediante los scripts CityLearn/scripts/train_citylearn_v3_<algoritmo>.py y los adaptadores ubicados en external/, no mediante un entorno UC3M independiente.

Debe distinguirse esta capa empírica del marco auxiliar contenido en uc3m/. Dicho paquete formaliza un operador general de siete ejes: emisiones de CO_2, costos energéticos, flexibilidad, confort, degradación del BESS, resiliencia y agua caliente sanitaria (ACS). Sin embargo, la evidencia presentada en el Capítulo 5 se limita a los tres ejes vinculados con los objetivos específicos: UC3M-1 se relaciona con OE.2 emisiones de CO_2, UC3M-2 con OE.3 costos energéticos y UC3M-3 con OE.1 flexibilidad energética. Los ejes del cuarto a séptimo constituyen una ampliación teórica y arquitectónica, pero no fueron operacionalizados en las doce corridas reportadas. El sistema ejecutado corresponde, por tanto, a un contrato de tres objetivos, complementado por el término de servicio de vehículos eléctricos, y no a una evaluación empírica completa de los siete ejes UC3M.

En el caso de estudio se consideran N=17 agentes, un horizonte anual de H=8 760 intervalos horarios, un factor de descuento γ=0,9999 y un coeficiente cooperativo $r_{team} = 0{,}70$. Las doce configuraciones experimentales resultan de combinar cuatro algoritmos (HAPPO, MASAC, MATD3 y MAAC) con tres escenarios de recompensa (E1, E2 y E3) Esta delimitación permite conservar la trazabilidad entre la formulación teórica, la implementación y los resultados, evitando atribuir evidencia empírica a componentes que solo fueron desarrollados como soporte general.

Las variables independiente y dependiente de la investigación no se manipulan ni se miden en un entorno genérico, sino en una capa experimental construida sobre CityLearn v2. CityLearn fue concebido como un entorno abierto para implementar, reproducir y comparar estrategias de control aplicadas a la respuesta de la demanda y a la coordinación energética de edificios (Vázquez-Canteli et al., 2019) . Su segunda versión amplía estas capacidades mediante modelos de dinámica térmica, almacenamiento eléctrico, generación fotovoltaica, vehículos eléctricos y funciones de evaluación vinculadas con energía, costos, emisiones, confort y resiliencia (Nweye et al., 2025a) . En la presente tesis, este entorno constituye el motor físico y computacional de referencia, mientras que la denominación CityLearn v3

propuesta identifica exclusivamente la extensión desarrollada para el caso de Iquitos. Por tanto, no corresponde a una versión oficial del paquete ni debe atribuirse a sus autores originales.

La extensión propuesta conserva la lógica física y los indicadores compatibles con evaluate_v2(), pero incorpora la representación de la comunidad como un Dec-POMDP cooperativo, el esquema de entrenamiento centralizado con ejecución descentralizada — CTDE, la recompensa multiobjetivo asociada con los escenarios E1, E2 y E3, y los adaptadores necesarios para ejecutar HAPPO, MASAC, MATD3 y MAAC bajo un protocolo experimental común. La relación entre el entorno oficial y la adaptación desarrollada puede representarse mediante el siguiente operador de composición conceptual:

$$\mathcal{E}_{v3}^{prop} = \mathcal{W}(\mathcal{E}_{v2}, \mathcal{D}_{IQT}, \mathcal{M}_{Dec-POMDP}, \mathcal{R}_{E1:E3}, \mathcal{B}_{MADRL}, \mathcal{G}_{evidencia},$$

Donde $\mathcal{E}_{v2}$ representa el motor oficial de CityLearn v2; $\mathcal{D}_{IQT}$, el conjunto de datos citylearn_iquitos_2023_2025, integrado por 26 304 registros horarios correspondientes al periodo 2023–2025; $\mathcal{M}_{Dec-POMDP}$, la formalización cooperativa y parcialmente observable de los 17 edificios-agentes; $\mathcal{R}_{E1:E3}$, la función de recompensa y sus tres configuraciones experimentales; $\mathcal{B}_{MADRL}$, los cuatro *backends* algorítmicos; y $\mathcal{G}_{evidencia}$, los mecanismos de evaluación, trazabilidad y exportación de resultados. Se utiliza $\mathcal{G}_{evidencia}$, en lugar de $\mathcal{T}_{evidencia}$, para evitar su confusión con el núcleo de transición $\mathcal{T}$ del Dec-POMDP. El operador $\mathcal{W}$ no representa una función numérica cerrada ni una instrucción específica del código, sino la composición arquitectónica de los componentes que conforman el entorno experimental.

En el plano de implementación, esta composición se organiza en seis capas relacionadas. La primera comprende el conjunto de datos de Iquitos y sus procedimientos de validación; la segunda corresponde al motor CityLearn v2, encargado de simular los edificios, el BESS, la generación fotovoltaica, los vehículos eléctricos y los KPI oficiales; y la tercera está constituida por la extensión ubicada en CityLearn/citylearn/v3/, que comprende, principalmente, environment.py, objectives.py, config.py y backends.py. En esta capa también se implementa CityLearnV3MADRLRewardFunction, mediante el perfil unified_comparable_v4, para integrar los componentes de flexibilidad, emisiones, costos y servicio de vehículos eléctricos. La cuarta capa comprende los adaptadores multiagente y las abstracciones auxiliares de uc3m/; la quinta contiene los backends de aprendizaje ubicados en external/ y los lanzadores CityLearn/scripts/train_citylearn_v3_<algoritmo>.py; finalmente,

la sexta capa comprende la evaluación y la generación de evidencia mediante archivos como results.json, training_summary.json, timeseries.csv, trace.csv, building_kpis.csv, building_behavior_summary.csv y checkpoint_manifest.json. Esta arquitectura de seis capas coincide con la organización documentada en el proyecto y permite seguir cada resultado desde el dato de entrada hasta el artefacto empleado en el Capítulo 5.

Debe precisarse que el paquete uc3m/ constituye una capa auxiliar de formalización e interoperabilidad y no el canal que produjo directamente los resultados experimentales. Dicho paquete contiene UC3MEnv, KPIEvaluator, AlgorithmFactory y una formulación ampliada de siete ejes; sin embargo, las doce corridas canónicas se ejecutaron mediante los lanzadores de CityLearn/scripts/, la función CityLearnV3MADRLRewardFunction y los repositorios adaptados ubicados en external/. En consecuencia, los tres objetivos operacionalizados en el diseño factorial corresponden a flexibilidad energética, emisiones de CO_2 y costos energéticos, mientras que confort, degradación del BESS, resiliencia y agua caliente sanitaria permanecen como componentes de sustento teórico y arquitectónico, sin evidencia experimental directa en el Capítulo 5. Esta distinción evita atribuir al paquete oficial de CityLearn o al marco UC3M resultados que fueron obtenidos mediante una ruta de entrenamiento diferente.

La organización propuesta delimita también la procedencia de las variables de investigación. La variable independiente se materializa mediante la selección y configuración de HAPPO, MASAC, MATD3 y MAAC; las transiciones físicas y energéticas son calculadas por CityLearn v2; y la variable dependiente se observa mediante los indicadores de flexibilidad, emisiones y costos obtenidos bajo condiciones comunes. De este modo, los doce tratamientos del diseño factorial 4×3 comparten el mismo conjunto de datos, horizonte, entorno físico, función de evaluación y estructura de evidencia. La capa CityLearn v3 propuesta no sustituye el motor oficial, sino que lo envuelve y amplía para posibilitar una comparación MADRL trazable, homogénea y reproducible en la comunidad energética de Iquitos

En la figura 1 se muestra el diagrama unifilar la adecuación e implantación de la capa CityLearn v3 en base de citylearn v2

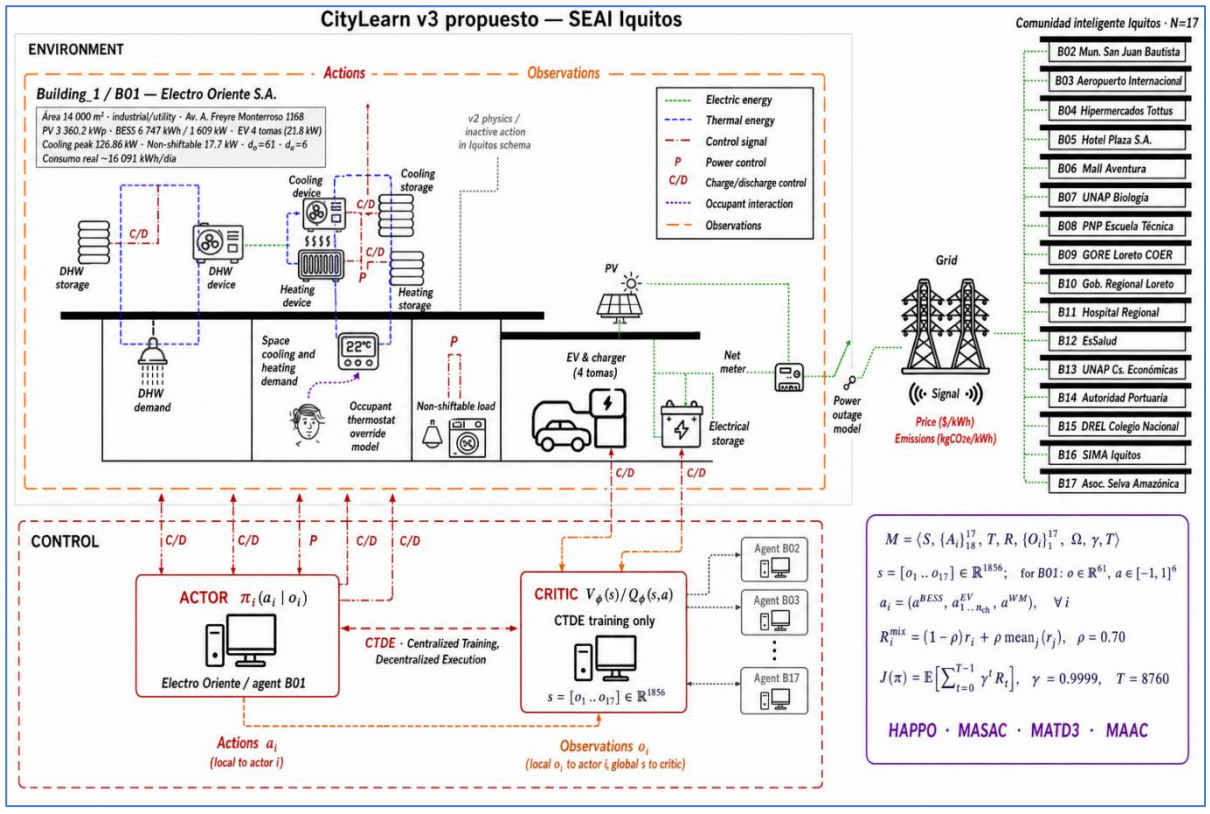

Figura 1: Control por edificio CityLearn v3 propuesto (simbología CityLearn v2): Electro Oriente S.A. (B01), comunidad inteligente Iquitos (B02–B17), red pública/SEAI, Actor–Crítico CTDE y formulación Dec-POMDP.

Nota. Adaptación de la Fig. 1 de CityLearn v2 (Nweye et al., 2024) a la capa CityLearn v3 propuesto en esta tesis. Se conserva la simbología oficial. Building_1/B01 muestra datos reales de Electro Oriente S.A. (PV 3 360,2 kWp; BESS 6 747 kWh / 1 609 kW; 4 tomas EV; d_o = 61; d_a = 6). La comunidad lista B02–B17 con etiquetas del dataset citylearn_iquitos_2023_2025. En CONTROL, el Actor π_i (a_i | o_i) ejecuta de forma descentralizada y el Crítico V/Q opera solo en entrenamiento CTDE con s = [o_1,…,o_17] ∈ ℝ^1856. Acciones MADRL activas: electrical_storage, electric_vehicle_storage y washing_machine; el bloque térmico v2 se mantiene como física (acciones cooling/heating/DHW inactivas en el schema Iquitos). Fuente: elaboración propia a partir de (Nweye et al., 2024), (Oliehoek & Amato, 2016), (Lowe et al., 2020) y artefactos del proyecto.

2.3.2. Correspondencia entre ejes, objetivos, escenarios e indicadores.

La contrastación de hipótesis exige mantener una relación directa y trazable entre cada eje de la investigación, su objetivo e hipótesis específica, el escenario de priorización asociado y los KPI que expresamente lo representan. Esta correspondencia, ya desarrollada de manera analítica en D-VI.2 y D-VD.1 a D-VD.3, se resume de forma integrada en la Tabla siguiente.

Tabla 4

Correspondencia entre eje, objetivo–hipótesis, escenario y KPI

Eje	Objetivo e hipótesis	Escenario asociado K	PI principales K	PI explicativas
Flexibilidad energética	OE.1 / HE.1	E1 [0,70; 0,15; 0,15]	peak_average, ramping_average, one_minus_load_factor_ average	flex_composite, autoconsumo, autosuficiencia, utilización de BESS y servicio EV
Emisiones de CO_2	OE.2 / HE.2	E2 [0,15; 0,70; 0,15]	carbon_emissions_total, carbon_emissions_control, carbon_emissions_delta	promedios diarios, consumo ponderado por CI(t), resultados por edificio
Costos energéticos	OE.3 / HE.3	E3 [0,25; 0,15; 0,60]	electricity_cost_total, electricity_cost_control, electricity_cost_delta	cost_peak_average, cost_ramping_average, price_signal_deviation, peak_billing
Gestión coordinada	Objetivo e hipótesis general	Conjunto normalizado de E1, E2 y E3	Ranking integrado por tratamiento	Estabilidad y consistencia entre agentes y entre escenarios

Nota. Elaboración propia a partir de (Sutton & Barto, 2018), (Oliehoek & Amato, 2016), (Lowe et al., 2020), y la arquitectura auditada del proyecto. La tabla no sustituye la contrastación estadística desarrollada en el Capítulo 5; organiza la lectura conjunta de los tres ejes específicos y del objetivo general.

2.3.3. Entrenamiento centralizado con ejecución descentralizada e interoperabilidad algorítmica (CTDE).

El entrenamiento centralizado con ejecución descentralizada en inglés *Centralized Training with Decentralized Execution* (CTDE) constituye el paradigma de aprendizaje empleado para resolver el problema cooperativo formulado mediante el Dec-POMDP, pero no representa una formalización alternativa a este. El Dec-POMDP define la estructura del problema de decisión mediante los agentes, estados, acciones, observaciones parciales, transiciones y recompensas; en cambio, CTDE determina qué información puede utilizarse durante el entrenamiento y qué información permanece disponible durante la operación. Esta distinción es relevante para la comunidad energética de Iquitos: los 17 edificios se modelan como agentes parcialmente observables y heterogéneos, mientras que el entrenamiento puede utilizar información agregada de la comunidad para aprender políticas coordinadas que posteriormente se ejecutan con observaciones locales. (Lowe et al., 2017) establecieron uno de los fundamentos de este paradigma mediante MADDPG, al combinar críticos con acceso a información conjunta durante el entrenamiento y actores que operan de manera

descentralizada. Posteriormente, (Kuba et al., 2022) y (Zhong et al., 2024) incorporaron CTDE en algoritmos cooperativos para agentes heterogéneos, con énfasis en la actualización secuencial y la coordinación de las políticas.

Para el agente i, la política descentralizada puede expresarse como:

$$a_{i,t} \sim \pi_i^{\theta_i}(\cdot|O_{i,t}),$$

donde $O_{i,t}$ representa la observación local disponible para el edificio i y θ_i contiene los parámetros de su actor. Durante el entrenamiento, el estimador de valor puede utilizar una representación centralizada x_t, constituida por el estado global, las observaciones conjuntas, las acciones de los agentes o una combinación de estas variables:

$$Q_t^{\phi_i}(x_t, a_{1,t}, \ldots, a_{N,t}),$$

o, en los métodos que emplean un estimador global de estado:

$$V^{\phi}(x_t),$$

La política conjunta ejecutada de manera descentralizada se representa mediante:

$$\pi_\Theta(a_t, O_t) = \prod_{i=1}^{N} \pi_i^{\theta_i}\ (a_{i,t}|O_{i,t}),$$

Esta factorización no implica que los edificios actúen de manera independiente, puesto que sus decisiones permanecen acopladas por la demanda agregada, la señal de recompensa comunitaria, las tarifas, la intensidad de carbono y las restricciones energéticas del entorno. La descentralización se refiere únicamente a que, una vez concluido el entrenamiento, cada actor puede seleccionar su acción a partir de la información local autorizada, sin requerir acceso permanente a los estados internos de los demás edificios.

Según de (Lowe et al., 2017), (Iqbal & Sha, 2019) y (Lyu et al., 2023) muestra que el uso de información centralizada aporta posibilidades de coordinación, pero también introduce restricciones que deben reconocerse. (Lowe et al., 2017) propusieron críticos específicos por agente que utilizan las acciones conjuntas para estimar el efecto de las interacciones entre políticas. (Iqbal & Sha, 2019) ampliaron este principio mediante MAAC, cuyo mecanismo de atención permite que el crítico determine qué agentes proporcionan información relevante para valorar una acción, reduciendo la necesidad de tratar todas las interacciones con igual importancia. Sin embargo, (Lyu et al., 2023) demostraron que la centralización del crítico no es necesariamente superior en todos los entornos y que, bajo observabilidad parcial, un crítico condicionado exclusivamente por el estado global puede introducir sesgo y varianza respecto

de estimadores que consideran el historial de observaciones. En consecuencia, CTDE no debe interpretarse como una garantía automática de estabilidad o convergencia, sino como una estructura de entrenamiento cuya eficacia depende de la información suministrada al crítico, de la arquitectura utilizada y de las características del problema.

Esta precisión resulta especialmente importante para el caso de Iquitos. Los edificios presentan diferencias en la disponibilidad de sistemas fotovoltaicos, BESS, vehículos eléctricos, perfiles de demanda y dimensiones de los espacios de acción. Por ello, el estado centralizado empleado durante el entrenamiento debe construirse con las variables observables y simuladas por CityLearn, sin asumir que el controlador dispone de información física inexistente en el entorno. Asimismo, la ejecución descentralizada permite que cada edificio actúe a partir de su demanda, generación, estado de carga, disponibilidad de vehículos, tarifa e intensidad de carbono; no obstante, esta arquitectura reduce la dependencia de información comunitaria en tiempo de ejecución, pero no constituye por sí sola una garantía de privacidad. La privacidad dependerá también de la infraestructura de comunicación, del almacenamiento de datos y del procedimiento de actualización de las políticas.

Dentro de la familia de algoritmos evaluados, HAPPO incorpora una forma específica de coordinación durante el entrenamiento. (Kuba et al., 2022) demostraron que la actualización simultánea de varias políticas puede generar direcciones conflictivas, aunque cada agente intente mejorar individualmente el retorno conjunto. Para resolver esta dificultad, los autores formularon el lema de descomposición de la ventaja multiagente y propusieron una actualización secuencial en la que cada agente considera las modificaciones realizadas previamente por sus compañeros. Sobre esta base se derivaron HATRPO y HAPPO, que no requieren compartir los parámetros de los actores y pueden aplicarse a agentes con funciones y espacios de acción diferentes. El trabajo original establece, bajo sus supuestos teóricos, garantías de mejora monotónica del retorno conjunto y convergencia de los puntos límite hacia equilibrios de Nash.

(Zhong et al., 2024) extendieron esta formulación mediante la familia de aprendizaje por refuerzo para agentes heterogéneos (HARL) y el marco de aprendizaje espejo para agentes heterogéneos (HAML). Esta ampliación conserva la descomposición de la ventaja y la actualización secuencial, fortalece el fundamento teórico de HATRPO y HAPPO y deriva otros algoritmos, como HAA2C, HADDPG y HATD3. Sus experimentos también muestran que la actualización simultánea puede ocasionar conflictos entre políticas heterogéneas y que

las ventajas de la actualización secuencial adquieren mayor importancia conforme aumenta la diversidad de los agentes. Sin embargo, estas garantías corresponden a los algoritmos y supuestos analizados por los autores; no deben trasladarse automáticamente a MASAC, MATD3 o MAAC, ni interpretarse como una demostración de convergencia global de las redes neuronales entrenadas en la comunidad de Iquitos. En la tesis, la estabilidad y la convergencia práctica deben verificarse empíricamente mediante las curvas de retorno, la evolución de las pérdidas, los KPI finales y la variabilidad entre corridas.

La coexistencia de algoritmos con estructuras diferentes exige una arquitectura de interoperabilidad que separe la interacción con CityLearn de la implementación interna de cada método. (Hu et al., 2023) identifican tres mecanismos esenciales para integrar algoritmos MARL: un envoltorio estandarizado del entorno, una implementación modular a nivel de agente y una estrategia flexible de asignación de políticas. Estos mecanismos permiten desacoplar las características del entorno de la lógica de aprendizaje, evitando que cada algoritmo tenga que reimplementar completamente la comunicación con el simulador. La arquitectura del proyecto local adopta un principio equivalente mediante los adaptadores de CityLearn v3 propuesta y los componentes auxiliares de uc3m/, aunque las doce corridas experimentales no fueron ejecutadas directamente con MARLlib.

La interfaz algorítmica local puede representarse mediante el contrato abstracto:

$$\mathcal{P}_\alpha = \langle \Theta_\alpha, \Phi_\alpha, \mathcal{L}_{actor,\alpha}, \mathcal{L}_{critic,\alpha}, \mathcal{U}_{step,\alpha}, \mathcal{B}_\alpha \rangle,$$

donde α identifica el algoritmo; Θ_α contiene los parámetros de los actores; Φ_α, los parámetros del crítico o de los estimadores de valor; $\mathcal{L}_{actor,\alpha}$ y $\mathcal{L}_{critic,\alpha}$, las funciones de pérdida; $\mathcal{U}_{step,\alpha}$, la regla de actualización; y $\mathcal{B}_\alpha$, la estructura utilizada para almacenar trayectorias, transiciones o lotes de aprendizaje. Esta abstracción permite que AlgorithmFactory seleccione y configure distintos métodos sin alterar la dinámica física de CityLearn ni la definición de los objetivos experimentales.

De acuerdo con la nomenclatura del proyecto, HAPPO se conecta mediante CityLearnHARLEnv; MASAC, mediante CityLearnSMACDiscreteEnv; MATD3, mediante CityLearnOffPolicyVecEnv; y MAAC, mediante CityLearnMAACVecEnv. Estos adaptadores armonizan la forma de las observaciones, las dimensiones heterogéneas de las acciones, las máscaras, los reinicios de episodio, las recompensas y la construcción de lotes. No obstante, preservan las diferencias propias de cada algoritmo: HAPPO utiliza trayectorias on-policy y actualizaciones secuenciales; MASAC emplea políticas estocásticas y

aprendizaje off-policy; MATD3 utiliza actores deterministas, doble crítico, actualización retardada y memoria de repetición; y MAAC incorpora atención en la estimación centralizada. Por ello, la interfaz común debe denominarse interoperabilidad algorítmica y no universalidad matemática, dado que la compatibilidad de software no implica igualdad de funciones objetivo, requisitos de datos, mecanismos de exploración o garantías de convergencia.

Las doce corridas canónicas se ejecutan mediante los lanzadores ubicados en CityLearn/scripts/train_citylearn_v3_<algoritmo>.py y los backends adaptados en external/. La función CityLearnV3MADRLRewardFunction, configurada mediante el perfil unified_comparable_v4, proporciona una recompensa común para los escenarios E1, E2 y E3, mientras que los adaptadores traducen la interacción con el entorno al formato requerido por cada algoritmo. UC3MEnv, AlgorithmFactory y MARLlib cumplen funciones de formalización, interoperabilidad y referencia arquitectónica, pero no constituyen el canal directo que produjo los resultados del Capítulo 5. Esta delimitación permite atribuir correctamente la evidencia experimental y evita presentar como ejecutados componentes que solo forman parte del sustento teórico o del diseño extensible del sistema.

En términos operativos, la aplicación de CTDE en la comunidad de Iquitos permite aprovechar durante el entrenamiento la información agregada de los 17 edificios para aprender acciones coherentes con los objetivos de flexibilidad, emisiones y costos. Durante la ejecución, cada política utiliza las observaciones locales definidas para su edificio y genera acciones dentro de su espacio de control. De este modo, la coordinación comunitaria se incorpora en los parámetros aprendidos, sin requerir que todos los agentes intercambien continuamente sus estados completos. El paradigma adoptado proporciona, por tanto, una correspondencia consistente entre la formulación Dec-POMDP, la heterogeneidad de los recursos, la arquitectura experimental de CityLearn v3 propuesta y la comparación reproducible de HAPPO, MASAC, MATD3 y MAAC.

2.3.4. Estructura de observación y acción del esquema multiagente.

La relación entre las variables de investigación se materializa operativamente mediante la interfaz de observación–acción de los 17 edificios que conforman la comunidad simulada. En cada intervalo horario, el agente asociado con el edificio i recibe una observación local heterogénea, representada de manera general mediante:

$$O_{i,t} = \left[O_{i,t}^{time}, O_{i,t}^{weather}, O_{i,t}^{energy}, O_{i,t}^{price}, O_{i,t}^{carbon}, O_{i,t}^{BESS}, O_{i,t}^{EV}, O_{i,t}^{flex}\right],$$

El componente temporal ($O_{i,t}^{time}$) comprende el mes, el tipo de día y la hora. El componente meteorológico $O_{i,t}^{weather}$ incorpora la temperatura exterior, la humedad relativa, la irradiancia directa y difusa, así como las predicciones habilitadas en el esquema correspondiente. El componente energético ($O_{i,t}^{energy}$) reúne la demanda no desplazable, la generación fotovoltaica y el intercambio eléctrico neto del edificio. Los componentes económico y ambiental ($O_{i,t}^{price}$ y $O_{i,t}^{carbon}$) contienen, respectivamente, la señal de precio y la intensidad de carbono vigentes, junto con las previsiones disponibles. El componente del BESS ($O_{i,t}^{BESS}$) representa su estado de carga y las condiciones operativas observables del almacenamiento eléctrico.

Cuando el edificio dispone de infraestructura de movilidad eléctrica, el componente vehicular ($O_{i,t}^{EV}$) incorpora, para los cargadores asignados, el estado de conexión, los tiempos previstos de llegada y salida, el estado de carga actual y el estado de carga requerido. El componente de cargas flexibles ($O_{i,t}^{flex}$) representa la disponibilidad y la ventana temporal autorizada para el desplazamiento de la carga controlable. En consecuencia, la dimensión de $O_{i,t}$ no es uniforme, debido principalmente a las diferencias en el número de cargadores y en la dotación de recursos energéticos de cada edificio. Esta heterogeneidad corresponde a la configuración real del caso de estudio y no a una propiedad general de todo Dec-POMDP. La implementación registra observaciones locales de entre 54 y 327 componentes.

Para los componentes centralizados del entrenamiento, las observaciones locales se concatenan mediante:

$$s_t = concat\left(o_{1,t}, o_{2,t}, \ldots, o_{17,t}\right),$$

con una dimensión global de 1,856 componentes. Este estado conjunto se utiliza exclusivamente durante el entrenamiento, conforme al esquema CTDE descrito en el numeral 2.3.3; durante la ejecución, cada actor decide únicamente a partir de la observación local de su edificio.

La acción local del edificio i se representa mediante:

$$a_{i,t} = \left[a_{i,t}^{BESS}, a_{i,t}^{EV}, a_{i,t}^{flex}\right],$$

y comprende únicamente las consignas asociadas con electrical_storage, electric_vehicle_storage y washing_machine. En el espacio normalizado del entorno, el BESS admite valores en [−1,1], donde los valores positivos representan carga, los negativos

descarga y el valor cero una consigna nula. Los cargadores unidireccionales admiten consignas de carga en [0,1], mientras que los cargadores y vehículos con capacidad bidireccional admiten operación G2V y V2G en [−1,1]. La carga desplazable utiliza valores en [0,1] y solo puede modificarse dentro de su ventana temporal autorizada. Estas acciones no eliminan la energía requerida por el servicio, sino que modifican su momento de utilización.

Los intervalos anteriores corresponden al contrato común del entorno. HAPPO y MATD3 operan sobre representaciones continuas, mientras que los adaptadores empleados por MASAC y MAAC discretizan las consignas por eje para compatibilizarlas con sus respectivos backends. Por consiguiente, la interfaz física es común, pero el mecanismo mediante el cual cada algoritmo genera la acción conserva las particularidades documentadas en el proyecto.

La política no controla directamente la demanda no desplazable, la irradiancia, la generación fotovoltaica, las condiciones meteorológicas, el precio de la electricidad, la intensidad de carbono, el calendario ni la disponibilidad temporal de los vehículos. Estas señales actúan como variables exógenas ξ dentro del modelo conceptual:

$$Y = f(A, E, X, \xi),$$

presentado en el numeral 2.2.1. La configuración canónica tampoco declara acciones directas sobre refrigeración, calefacción o agua caliente sanitaria; por ello, el control experimental se restringe al almacenamiento eléctrico, los vehículos eléctricos con capacidad G2V/V2G y la carga desplazable habilitada.

2.3.5. Formalización multiobjetivo del Dec-POMDP y correspondencia con el marco UC3M.

A partir de la estructura de observación–acción definida en el numeral 2.3.4, la gestión coordinada de la comunidad energética se formaliza mediante un proceso de decisión de Márkov descentralizado y parcialmente observable (Dec-POMDP), por sus siglas en inglés. Esta formulación representa un sistema cooperativo en el que los edificios actúan sobre un entorno compartido, contribuyen a objetivos comunitarios y seleccionan sus acciones mediante información local incompleta. (Oliehoek & Amato, 2016) establecen la estructura formal del Dec-POMDP, mientras que (Sutton & Barto, 2018) proporcionan los fundamentos de las políticas, el retorno descontado y la decisión secuencial.

Para el caso de estudio, el problema se representa mediante la tupla:

$$\mathcal{M} = \langle I, \mathcal{S}, \{\mathcal{A}_i\}_{i=1}^{N}, \mathcal{T}, \{\mathcal{O}_i\}_{i=1}^{N}, \Omega, \boldsymbol{\mathcal{R}}, \gamma, \mathcal{H}, b_0 \rangle,$$

Donde:

$$I = \{1, \ldots, N\}, \quad N = 17,$$

representa el conjunto de edificios-agentes; $\mathcal{S}$ es el espacio de estados globales del entorno; $\mathcal{A}_i$ y $\mathcal{O}_i$ son, respectivamente, los espacios heterogéneos de acciones y observaciones del agente i; $\mathcal{T}$ es el núcleo de transición; Ω representa el modelo de observación; $\boldsymbol{\mathcal{R}}$ es la función vectorial de recompensa; γ=0.9999 es el factor de descuento; $\mathcal{H}$ =8760 corresponde al horizonte horario anual de cada episodio; y b_0 representa la distribución inicial de los estados del entorno. La acción y la observación conjuntas se definen mediante:

$$\mathcal{A} = \prod_{i=1}^{N} \mathcal{A}_i\,, \quad \mathcal{O} = \prod_{i=1}^{N} \mathcal{O}_i\,.$$

En el instante t, cada agente selecciona su acción a partir de su observación local:

$$a_{i,t} \backsim \pi_i(\cdot \mid o_{i,t}),$$

mientras que la acción conjunta se expresa como:

$$a_t = (a_{1,t}, a_{2,t}, \ldots, a_{N,t}).$$

La evolución del entorno y la generación de observaciones se representan mediante:

$$s_{t+1} \backsim \tau\,(\cdot \mid s_t, a_t),$$

$$o_{t+1} \backsim \Omega\,(\cdot \mid s_{t+1}, a_t).$$

En la implementación del proyecto, la representación centralizada utilizada durante el entrenamiento se obtiene mediante la concatenación de las observaciones locales. Esta representación alcanza 1,856 componentes y se encuentra disponible para los críticos o componentes centralizados según el backend, mientras que cada actor ejecuta su política únicamente con la observación local correspondiente. Esta separación mantiene la observabilidad parcial durante la ejecución y la disponibilidad de información conjunta durante el entrenamiento CTDE.

a. Extensión multiobjetivo

La formulación se amplía mediante una función vectorial de recompensa:

$$\boldsymbol{\mathcal{R}}: \mathcal{S} \times \mathcal{A} \times \mathcal{S} \longrightarrow \mathbb{R}^{7},$$

que, en el marco auxiliar UC3M, puede generar el vector:

$$\boldsymbol{r}_t^{\mathrm{UC3M}} = \begin{bmatrix} r_{CO_2,t} \\ r_{costo,t} \\ r_{flex,t} \\ r_{confort,t} \\ r_{degradación,t} \\ r_{resilencia,t} \\ r_{ACS,t} \end{bmatrix}.$$

Estos componentes representan los siete ejes generales definidos por la infraestructura uc3m/: emisiones de CO_2 costos energéticos, flexibilidad, confort, degradación del BESS, resiliencia y agua caliente sanitaria. La incorporación de este vector constituye una extensión multiobjetivo propia de la arquitectura del proyecto y no una modificación de la definición estándar del Dec-POMDP reconocida universalmente.

Las preferencias sobre los siete componentes se representan mediante:

$$\boldsymbol{\lambda} = (\lambda_1, \ldots, \lambda_7) \in \triangle^6,$$

$$\triangle^6 = \left\{ \lambda \in \mathbb{R}^7 \geq \mathbf{0}: \sum_{\boldsymbol{k=1}}^{\boldsymbol{7}} \lambda_{\boldsymbol{k}} = \mathbf{1} \right\}.$$

Para una preferencia determinada, la recompensa escalar se obtiene mediante:

$$r_t^{(\lambda)} = \boldsymbol{\lambda}^T \boldsymbol{r}_t^{\mathrm{UC3M}},$$

$$\mathcal{J}(\boldsymbol{\pi}; \boldsymbol{\lambda}) = \mathbb{E}_{\pi,\tau,\Omega,b_0} \left[\sum_{t=1}^{H-1} \Upsilon^t r_t^{(\lambda)} \right]$$

Con:

$$\boldsymbol{\pi} = (\pi_1, \pi_2, \ldots, \lambda_N).$$

Esta representación permite expresar matemáticamente que una política favorable para un objetivo puede no ser óptima para los restantes. En los problemas secuenciales multiobjetivo, la política seleccionada depende tanto del conjunto de soluciones disponibles como de las preferencias aplicadas sobre los criterios de desempeño (Roijers et al., 2014).

b. Proyección experimental de siete a tres ejes.

El diseño experimental de la tesis no recorre el simplex completo $\triangle^6$ ni evalúa empíricamente los siete componentes del marco auxiliar. Las doce corridas canónicas se restringen a los tres objetivos asociados directamente con la variable dependiente:

$$\boldsymbol{r}_t^{exp} = \begin{bmatrix} r_{flex,t} \\ r_{CO_2,t} \\ r_{costo,t} \end{bmatrix}.$$

Los tres escenarios emplean los vectores de ponderación:

$$\boldsymbol{w}^{E1} = \begin{bmatrix} 0.70 \\ 0.15 \\ 0.15 \end{bmatrix}, \boldsymbol{w}^{E2} = \begin{bmatrix} 0.15 \\ 0.70 \\ 0.15 \end{bmatrix}, \boldsymbol{w}^{E3} = \begin{bmatrix} 0.25 \\ 0.15 \\ 0.60 \end{bmatrix}.$$

La recompensa escalar correspondiente al escenario Ej se expresa conceptualmente como:

$$\boldsymbol{r}_t^{Ej} = (\boldsymbol{w}^{Ej})^T \boldsymbol{r}_t^{exp}, \qquad Ej \in \{E1, E2, E3\}.$$

La implementación añade, además, el componente de servicio de vehículos eléctricos establecido en CityLearnV3MADRLRewardFunction. Dicho componente regula el cumplimiento de los requerimientos vehiculares, pero no constituye una cuarta dimensión de la variable dependiente ni una hipótesis adicional de la investigación.

La proyección de siete a tres ejes conserva la relación conceptual con el marco UC3M, pero delimita la evidencia experimental a flexibilidad energética, emisiones de CO_2 y costos energéticos. Los componentes de confort, degradación del BESS, resiliencia y ACS permanecen como posibilidades de ampliación arquitectónica y no deben interpretarse como resultados evaluados en el Capítulo V. Las doce corridas oficiales fueron producidas mediante CityLearnV3MADRLRewardFunction, los scripts train_citylearn_v3_<algoritmo>.py y los backends adaptados de external/; el paquete uc3m/ no constituyó el canal directo de entrenamiento de dichos tratamientos.

2.3.6. Paradigmas de control energético como referencia del estudio.

La gestión energética de edificios puede desarrollarse mediante controladores basados en reglas, control predictivo basado en modelos y estrategias basadas en aprendizaje. Estas alternativas difieren en la información requerida, en la forma de representar la dinámica del sistema y en su capacidad para responder a perturbaciones y condiciones operativas variables.

Los controladores basados en reglas (Rule-Based Controllers, RBC) ejecutan acciones a partir de horarios, umbrales y condiciones lógicas establecidas previamente. Su principal ventaja se encuentra en la facilidad de implementación, interpretación y auditoría. Sin embargo, su respuesta depende de reglas diseñadas para situaciones conocidas y presenta una capacidad limitada para adaptarse a cambios no previstos en la demanda, la disponibilidad de los recursos, las condiciones meteorológicas o las señales económicas y ambientales.

El control predictivo basado en modelos (Model Predictive Control, MPC) incorpora una representación matemática de la dinámica del sistema y resuelve un problema de optimización sobre un horizonte futuro. Esta característica permite anticipar trayectorias, incorporar pronósticos y aplicar restricciones físicas de manera explícita. No obstante, su desempeño depende de la disponibilidad de modelos adecuadamente identificados o calibrados, así como de la calidad de las predicciones y de la capacidad computacional necesaria para resolver repetidamente el problema de optimización.

El aprendizaje por refuerzo profundo (Deep Reinforcement Learning, DRL) plantea una alternativa en la que la política de control se aprende mediante la interacción con el entorno. La red neuronal no sustituye la dinámica física del sistema, sino que aprende a seleccionar acciones dentro de un entorno cuyos estados, transiciones, restricciones y señales ya han sido definidos. Esta propiedad permite abordar espacios de observación y acción de mayor dimensión sin requerir que el controlador utilice directamente un modelo físico cerrado durante cada decisión.

(Silvestri, 2024) compara RBC, MPC y DRL en sistemas energéticos de edificios y concluye que el MPC mantiene ventajas cuando se dispone de una representación confiable de la dinámica, mientras que el DRL puede alcanzar políticas competitivas con menor dependencia de un modelo explícito empleado directamente por el controlador. Sin embargo, también identifica dificultades asociadas con el preentrenamiento, la transferencia entre simulación y operación real, la eficiencia de los datos y el cumplimiento de las restricciones operativas. (Nweye, 2024) complementa esta perspectiva al señalar que la aplicación del aprendizaje por refuerzo en comunidades interactivas con la red requiere considerar conjuntamente la seguridad, la generalización, la eficiencia muestral y la comparación con referencias convencionales.

En la presente investigación, RBC y MPC cumplen una función de referencia conceptual y permiten situar el MADRL dentro de los paradigmas de gestión energética; no constituyen niveles del factor experimental. La variable independiente se restringe a HAPPO, MASAC, MATD3 y MAAC. Por ello, el desempeño de estos algoritmos no se interpreta únicamente a partir de la recompensa acumulada ni de la comparación interna entre métodos, sino mediante los KPI compatibles con CityLearn v2 y las líneas base disponibles bajo condiciones de simulación equivalentes

2.3.7. Coordinación multiagente en la comunidad energética de Iquitos

La ampliación del control desde un edificio individual hacia una comunidad modifica la naturaleza del problema de decisión. En un edificio aislado, las acciones pueden seleccionarse considerando exclusivamente sus recursos y restricciones locales. En una comunidad, las decisiones de cada edificio afectan el perfil agregado y modifican las condiciones bajo las cuales operan los demás integrantes.

Esta interdependencia se manifiesta cuando varios agentes ejecutan acciones similares durante el mismo intervalo. Por ejemplo, el desplazamiento simultáneo de cargas hacia una hora de menor precio puede resultar favorable para cada edificio y, al mismo tiempo, generar un nuevo pico distrital. De manera análoga, la carga concurrente de baterías y vehículos eléctricos puede incrementar la importación comunitaria, mientras que una descarga coordinada puede reducir la demanda máxima o disminuir el consumo durante periodos con elevada intensidad de carbono.

El aprendizaje por refuerzo multiagente permite representar estas relaciones mediante políticas locales que actúan sobre un entorno compartido. Sin embargo, el aprendizaje simultáneo introduce no estacionariedad, debido a que la actualización de una política modifica el entorno efectivo observado por las restantes. También se presenta un problema de asignación de crédito, porque una recompensa comunitaria no identifica directamente qué agente produjo una mejora o un deterioro del resultado conjunto.

(Lowe et al., 2017) plantean una arquitectura actor–crítico en la que los críticos acceden a información conjunta durante el entrenamiento, mientras que los actores seleccionan acciones mediante observaciones locales durante la ejecución. Este principio constituye uno de los fundamentos del entrenamiento centralizado con ejecución descentralizada adoptado en la tesis. (Iqbal & Sha, 2019) amplían esta lógica mediante un crítico con atención, capaz de ponderar de forma diferenciada la información de los demás agentes. Por su parte, (Kuba et al., 2022 y (Zhong et al., 2024) desarrollan esquemas de actualización secuencial orientados a agentes heterogéneos, evitando que la coordinación dependa necesariamente del intercambio de parámetros entre políticas con funciones distintas.

En el proyecto, la heterogeneidad constituye una condición material del caso de estudio. Los 17 edificios presentan diferencias en sus perfiles de demanda, capacidad fotovoltaica, almacenamiento, número de cargadores, disponibilidad vehicular y presencia de cargas desplazables. Por ello, los agentes no poseen necesariamente espacios de observación y

acción de igual dimensión. La configuración del proyecto registra observaciones locales entre 54 y 327 componentes y acciones locales entre 5 y 44 componentes.

La coordinación comunitaria no implica que los actores intercambien continuamente toda su información durante la ejecución. Cada política selecciona sus acciones a partir de la observación local correspondiente. La cooperación se obtiene mediante el entrenamiento, el uso de información conjunta por los componentes centralizados, la estructura de recompensa y la interacción de las acciones sobre la curva distrital.

Por esta razón, la coordinación debe diferenciarse de la agregación. La agregación consiste en sumar consumos, emisiones o costos individuales; la coordinación considera, además, la simultaneidad, las interdependencias y los efectos cruzados de las decisiones. Una política no puede calificarse como favorable para la comunidad cuando mejora un indicador agregado a costa de incumplir los requerimientos de carga vehicular, utilizar inadecuadamente los sistemas de almacenamiento o deteriorar de manera significativa otro objetivo de la investigación

2.3.8. Entorno experimental CityLearn v2 y extensión CityLearn v3 propuesta.

CityLearn fue desarrollado como un entorno abierto para implementar y comparar estrategias de control energético bajo condiciones reproducibles. CityLearn v1.0 estableció una interfaz basada en OpenAI Gym para el análisis de respuesta de la demanda mediante aprendizaje por refuerzo, mientras que los trabajos posteriores ampliaron su utilización hacia la comparación estandarizada de métodos multiagente y estrategias de gestión urbana (Vázquez-Canteli & Nagy, 2019b);(Vazquez-Canteli et al., 2020).

La estandarización proporcionada por CityLearn reduce una dificultad frecuente en la investigación de control energético: la comparación de algoritmos desarrollados con diferentes edificios, datos, espacios de acción, horizontes y métricas. Al utilizar un entorno común, las diferencias de desempeño pueden interpretarse con mayor precisión, debido a que las políticas interactúan con una misma representación energética y son evaluadas mediante indicadores equivalentes (Vazquez-Canteli et al., 2020).

CityLearn v2 amplía esta infraestructura mediante la representación de comunidades interactivas con la red y la incorporación de dinámica térmica basada en datos, generación fotovoltaica, almacenamiento eléctrico y térmico, vehículos eléctricos, comportamiento de ocupantes, señales temporales de precio e intensidad de carbono y escenarios de resiliencia. Además, permite evaluar resultados a escala de edificio y distrito mediante indicadores de

demanda, rampas, costos, emisiones, autoconsumo, autosuficiencia y comportamiento de los recursos distribuidos (Nweye et al., 2025b).

La tesis doctoral de (Nweye, 2024) proporciona el fundamento complementario de esta ampliación. El autor presenta CityLearn como un entorno para implementar y comparar RBC, controladores de aprendizaje por refuerzo y MPC en comunidades interactivas con la red. Asimismo, desarrolla CityLearn v2 como una infraestructura capaz de representar sistemas de almacenamiento, vehículos eléctricos, generación fotovoltaica, dinámica térmica y objetivos múltiples de flexibilidad, resiliencia, confort y carbono.

En el ámbito de la movilidad eléctrica, (Fonseca et al., 2024) desarrollan EVLearn como una extensión integrada con CityLearn para representar vehículos, cargadores, disponibilidad temporal y estrategias G2V y V2G. Esta contribución sustenta la inclusión de estados de conexión, horas de llegada y salida, estados de carga y consignas bidireccionales dentro de la interfaz multiagente utilizada en el proyecto.

En la presente investigación, CityLearn v2 constituye el núcleo oficial encargado de simular las transiciones físicas y energéticas de los edificios. Sobre este núcleo se desarrolla una extensión experimental denominada CityLearn v3 propuesta, la cual no corresponde a una versión oficial del entorno. Esta denominación identifica exclusivamente la adaptación construida para el caso de estudio de Iquitos.

La relación entre ambos componentes se representa conceptualmente mediante:

CityLearn v3 propuesta = CityLearn v2 + dataset Iquitos + interfaz multiagente + recompensa multiobjetivo +backends MADRL + trazabilidad.

CityLearn v2 aporta los modelos de los edificios y de los recursos energéticos distribuidos. El conjunto citylearn_iquitos_2023_2025 incorpora 26 304 registros horarios correspondientes al periodo 2023–2025. La interfaz multiagente representa los 17 edificios mediante observaciones locales, acciones heterogéneas y una representación conjunta para el entrenamiento. La recompensa multiobjetivo establece las priorizaciones E1, E2 y E3; los backends permiten ejecutar HAPPO, MASAC, MATD3 y MAAC; y la capa de trazabilidad conserva las configuraciones, series temporales, KPI, trazas y puntos de control utilizados en el análisis.

La extensión propuesta no reemplaza las funciones físicas de CityLearn v2. El motor oficial conserva la responsabilidad de actualizar los estados de los recursos, calcular el balance energético y producir los indicadores de evaluación. La capa desarrollada en la tesis

organiza la interacción multiagente, adapta las observaciones y acciones a los contratos de cada algoritmo, aplica la recompensa experimental y exporta los artefactos requeridos para la evaluación.

Esta delimitación también precisa el alcance físico del estudio. CityLearn representa balances energéticos detrás del medidor y resultados agregados de la comunidad, pero no constituye un simulador de redes eléctricas. En consecuencia, la investigación no reproduce flujos de potencia, tensiones nodales, frecuencia, cortocircuitos, coordinación de protecciones o estabilidad transitoria del SEAI Iquitos

2.3.9. Delimitación entre la capa experimental y el marco auxiliar UC3M.

La arquitectura del proyecto incluye un marco auxiliar denominado UC3M, concebido como una formulación multiobjetivo extensible. Este marco considera siete ejes: emisiones de CO_2, costos energéticos, flexibilidad, confort, degradación del BESS, resiliencia y agua caliente sanitaria. No obstante, la presencia de estos componentes en el diseño arquitectónico no implica que todos hayan sido evaluados experimentalmente.

La capa ejecutada se restringe a los tres objetivos vinculados directamente con la variable dependiente:

$$\boldsymbol{r}_t^{exp} = \begin{bmatrix} r_{flex,t} \\ r_{CO_2,t} \\ r_{costo,t} \end{bmatrix}.$$

Estos componentes se relacionan, respectivamente, con OE.1, OE.2 y OE.3 y son priorizados mediante los escenarios E1, E2 y E3. La implementación incorpora adicionalmente un término destinado a preservar el servicio de los vehículos eléctricos. Este componente regula el cumplimiento de los requerimientos vehiculares, pero no constituye una cuarta dimensión de la variable dependiente ni origina una hipótesis adicional.

Los ejes de confort, degradación del BESS, resiliencia y ACS permanecen como posibilidades de ampliación teórica y arquitectónica. Por tanto, no deben presentarse como dimensiones contrastadas ni emplearse para formular resultados o conclusiones en el Capítulo V.

También debe distinguirse el paquete uc3m/ de la ruta computacional que produjo las corridas canónicas. El marco auxiliar aporta abstracciones para la formalización y la interoperabilidad, pero las doce configuraciones oficiales se ejecutaron mediante CityLearnV3MADRLRewardFunction, los scripts train_citylearn_v3_<algoritmo>.py y los

backends adaptados contenidos en external/. La evidencia experimental corresponde, por tanto, a un contrato de tres objetivos y no a la optimización completa de los siete ejes UC3M.

Esta delimitación evita atribuir al paquete oficial de CityLearn componentes desarrollados por la tesis, impide presentar como evaluados los ejes que no fueron operacionalizados y mantiene la correspondencia entre la formulación teórica, los objetivos, la implementación y los resultados disponibles.

2.3.10. Sistema de almacenamiento en baterías.

El sistema de almacenamiento eléctrico permite transferir energía entre intervalos y desacoplar parcialmente el momento de generación o importación del momento de consumo. Para el edificio i, la evolución normalizada del estado de carga puede expresarse mediante:

$$SOC_{i,t+1}^{BESS} = SOC_{i,t}^{BESS} + \frac{\eta_i^c P_{i,t}^{ch} \Delta t}{E_i^{nom}} + \frac{P_{i,t}^{dis} \Delta t}{\eta_i^d E_i^{nom}},$$

donde $SOC_{i,t}^{BESS}$ representa el estado de carga al inicio del intervalo t; $P_{i,t}^{ch}$ y $P_{i,t}^{dis}$ corresponden a las potencias no negativas de carga y descarga; η_i^c y η_i^d representan sus eficiencias; E_i^{nom} es la capacidad energética nominal; y Δt corresponde al paso temporal horario.

La transición se encuentra sujeta a:

$$SOC_i^{min} \leq SOC_{i,t}^{BESS} \leq SOC_i^{max}$$

$$0 \leq P_{i,t}^{ch} \leq P_i^{ch,max}, \quad 0 \leq P_{i,t}^{dis} \leq P_i^{dis,max}$$

Estas restricciones impiden que la política utilice una potencia superior a la disponible o almacene una cantidad de energía incompatible con la capacidad del equipo. La separación entre P^{ch} y P^{dis} también permite representar explícitamente las pérdidas de conversión y evita interpretar la batería como una fuente de energía.

El BESS puede cargarse durante intervalos de menor demanda, menor precio, menor intensidad de carbono o mayor disponibilidad fotovoltaica, y descargarse posteriormente durante periodos críticos. Este desplazamiento puede reducir el pico, suavizar las rampas o modificar los costos y las emisiones; sin embargo, el beneficio depende de las pérdidas, de los límites del equipo y de la energía total procesada. Por ello, el desempeño del almacenamiento debe interpretarse junto con el *throughput* energético y, cuando se encuentre materializado en los artefactos, con los ciclos equivalentes de operación, en lugar de atribuir

la mejora únicamente a la presencia del BESS (Nweye, 2024) ; (Nweye et al., 2025a; Samende et al., 2023).

2.3.11. Generación fotovoltaica.

La generación fotovoltaica constituye una fuente exógena no despachable por los agentes. Su potencia depende de la irradiancia disponible, de la temperatura de operación y de la capacidad instalada en cada edificio. Como aproximación energética simplificada, puede expresarse mediante:

$$P_{i,t}^{PV} = P_i^{STC}\left(\frac{G_t}{G^{STC}}\right)\left[1 + \gamma_i\left(T_{cell,t} - 25\right)\right],$$

donde $P_{i,t}^{PV}$ representa la potencia nominal del sistema fotovoltaico del edificio i en condiciones estándar de prueba; G_t es la irradiancia incidente; G^{STC}=1000 W/m2 corresponde a la irradiancia de referencia; γ_i es el coeficiente térmico de potencia del módulo; y $T_{cell,t}$ representa la temperatura estimada de la celda.

La temperatura de la celda puede aproximarse mediante la relación basada en la temperatura nominal de operación de la celda (NOCT):

$$T_{cell,t} = T_{amb,t}\left(\frac{\mathrm{NOCT} - 20}{800}\right)G_t$$

donde $T_{amb,t}$ representa la temperatura ambiente. Este planteamiento constituye una aproximación térmica para estimar la reducción de rendimiento asociada con el calentamiento del módulo y no un modelo eléctrico detallado de la celda, del inversor o de la red de conexión (Duffie & Beckman, 2013).

En la implementación del proyecto, los perfiles solares se construyen mediante datos meteorológicos y herramientas como PVGIS y pvlib. Por ello, las ecuaciones anteriores deben interpretarse como el fundamento físico simplificado de los perfiles incorporados al dataset y no como una sustitución de las series horarias realmente utilizadas. En la presente tesis la PVGIS y pvlib intervienen en la estimación de la producción fotovoltaica por edificio y en el balance energético de la comunidad.

La política MADRL no controla directamente $P_{i,t}^{PV}$. Su intervención consiste en decidir cómo utilizar la generación disponible: atender la demanda instantánea, cargar el almacenamiento o reducir la importación desde la red. En consecuencia, la irradiancia y la producción fotovoltaica delimitan la flexibilidad disponible, pero no determinan por sí

mismas el desempeño de la política. Una elevada capacidad instalada no garantiza una mejora comunitaria cuando el consumo, los BESS y los vehículos no son coordinados temporalmente.

La comunidad simulada incorpora 48 790,9 kWp de capacidad fotovoltaica agregada. Esta magnitud corresponde a un parámetro de entrada del caso de estudio y no debe presentarse como potencia efectivamente producida en cada intervalo

2.3.12. Vehículos eléctricos y operación G2V/V2G.

Los vehículos eléctricos constituyen recursos móviles cuya disponibilidad de control depende de su conexión a un cargador. A diferencia del almacenamiento estacionario, la batería vehicular debe satisfacer una necesidad de movilidad y solo puede ser controlada durante los intervalos comprendidos entre su llegada y su salida.

Para el vehículo j asociado con el edificio i, la evolución del estado de carga puede expresarse mediante:

$$SOC_{i,j,t+1}^{EV} = SOC_{i,j,t}^{EV} + c_{i,j,t}\left[\frac{\eta_{i,j}^{c,EV} P_{i,j,t}^{G2V} \Delta t}{E_{i,j}^{EV}} + \frac{P_{i,j,t}^{V2G} \Delta t}{\eta_{i,j}^{d,EV} E_{i,j}^{EV}}\right],$$

donde $E_{i,j}^{EV}$ es la capacidad energética del vehículo; $P_{i,j,t}^{G2V}$ representa la potencia de carga desde la red o el edificio hacia el vehículo; $P_{i,j,t}^{V2G}$ corresponde a la potencia descargada desde el vehículo hacia el edificio; y $c_{i,j,t} \in \{0,1\}$ indica si el vehículo permanece conectado durante el intervalo t.

La utilización del vehículo se encuentra sujeta a:

$$SOC_{i,j}^{EV,min} \leq SOC_{i,j,t}^{EV} \leq SOC_{i,j}^{EV,max}$$

y a la restricción de servicio:

$$SOC_{i,j,t_{dep}}^{EV} \geq SOC_{i,j}^{req}$$

donde t_{dep} representa el instante de salida y $SOC_{i,j}^{req}$ el estado de carga requerido. Esta condición impide que una política reduzca el pico, las emisiones o el costo mediante una descarga que comprometa la disponibilidad de movilidad del usuario.

(Fonseca et al., 2024) desarrollan EVLearn sobre el ecosistema de CityLearn e incorporan vehículos, cargadores, horarios de conexión y modalidades de carga unidireccional y bidireccional. Sus resultados muestran que la operación V2G debe evaluarse simultáneamente con el cumplimiento del estado de carga de salida y con los efectos

comunitarios sobre pico, rampa, emisiones y costo. (Nweye et al., 2025a) integran también vehículos eléctricos y control G2V/V2G en CityLearn v2, mientras que (Atrazhev, 2023) evidencia que la estructura de recompensa puede modificar la coordinación de los recursos energéticos entre edificios.

En la extensión local, los cargadores unidireccionales solo permiten $P_{i,j,t}^{G2V} \geq 0$ mientras que las tomas bidireccionales habilitan tanto carga como descarga. La comunidad comprende 185 cargadores EV, de los cuales 31 disponen de capacidad V2G. Estas cantidades son parámetros auditados del proyecto y explican parte de la heterogeneidad de los espacios de observación y acción de los 17 agentes.

2.3.13. Cargas desplazables y demanda no controlada.

Las cargas desplazables representan servicios cuya energía total debe conservarse, aunque su ejecución pueda trasladarse dentro de una ventana autorizada. Para una carga flexible l asociada con el edificio i, la energía requerida puede expresarse mediante:

$$\sum_{t \in \mathcal{W}_{i,\iota}} P_{i,\iota,t}^{flex} \Delta t = E_{i,\iota}^{req},$$

donde $\mathcal{W}_{i,\iota}$ representa la ventana temporal autorizada y $E_{i,\iota}^{req}$ la energía necesaria para completar el servicio. La política puede modificar el instante de funcionamiento dentro de dicha ventana, pero no eliminar el consumo requerido.

En el esquema de Iquitos, la acción flexible materializada corresponde a washing_machine. Esta acción puede contribuir al desplazamiento de demanda, pero su efecto es menor que el de los recursos de mayor potencia y debe interpretarse dentro del balance conjunto. Las cargas no desplazables, en cambio, constituyen la demanda base observada por el agente y no forman parte del espacio de acciones.

Esta diferenciación es necesaria porque una reducción de la demanda base no puede atribuirse al MADRL cuando dicha variable no es actuable. La contribución del algoritmo se restringe a la modificación temporal de los recursos efectivamente controlados

2.3.14. Catálogo de indicadores y correspondencia con CityLearn v2.

Los fundamentos de flexibilidad, emisiones y costos fueron desarrollados en el numeral 2.2.3. El presente apartado no redefine esas dimensiones, sino que organiza los indicadores mediante los cuales sus efectos se observan en el entorno experimental.

La variable dependiente se evalúa mediante KPI compatibles con CityLearn v2 obtenidos mediante evaluate_v2() y mediante métricas derivadas de las series temporales del proyecto. Esta denominación es más precisa que afirmar que todos los campos utilizados son KPI oficiales de CityLearn, debido a que la extensión local armoniza nombres, agrega comparaciones entre línea base y control y construye indicadores integrados.

a. Indicadores de flexibilidad

Los indicadores directamente relacionados con la estructura de evaluación de CityLearn comprenden:

peak_average,ramping_average,one_minus_load_factor_average.

Estos indicadores representan, respectivamente, la demanda máxima promedio, la variación temporal del intercambio con la red y la falta de uniformidad del perfil de carga. Su utilización se encuentra sustentada en la estandarización de CityLearn y en la evaluación distrital de comunidades interactivas con la red (Vazquez-Canteli et al., 2020) ; (Nweye, 2024); (Nweye et al., 2025b).

La extensión local incorpora, además:

flex_composite,

como indicador integrado del proyecto. También se utilizan métricas explicativas de autoconsumo, autosuficiencia, participación de la importación, energía procesada por los BESS, comportamiento de los vehículos y cumplimiento de las cargas flexibles. Estas métricas complementan la lectura del eje, pero no reemplazan los indicadores principales definidos para OE.1.

b. Indicadores de emisiones

El catálogo ambiental comprende:

carbon_emissions_total,

carbon_emissions_baseline,carbon_emissions_control,carbon_emissions_delta,

junto con los promedios diarios y la intensidad media de carbono de la electricidad importada. La incorporación de una señal temporal de intensidad de carbono permite distinguir una reducción producida por menor consumo de otra obtenida mediante el desplazamiento de la importación hacia intervalos ambientalmente más favorables ((Tranberg et al., 2019); (Nweye, 2024); (Nweye et al., 2025b).

c. Indicadores de costos

El catálogo económico comprende:

electricity_cost_total,

electricity_cost_baseline, electricity_cost_control, electricity_cost_delta,

así como:

cost_peak_average, cost_ramping_average, price_signal_deviation, peak_billing.

price_signal_deviation y peak_billing son métricas derivadas de la extensión y no deben presentarse como funciones nativas de CityLearn v2. Su función consiste en explicar si la modificación del costo proviene del desplazamiento de importaciones hacia periodos menos costosos, de la reducción de la máxima demanda o de la combinación de ambos mecanismos.

2.4. Definición de términos y posición teórica

2.4.1. Acción local y acción conjunta.

La acción local $\mathbf{a}_{i,t}$ corresponde al conjunto de consignas seleccionadas por el agente i durante el intervalo t para operar únicamente los recursos controlables de su edificio. En el proyecto comprende las acciones sobre el almacenamiento eléctrico, los cargadores EV/V2G y la carga desplazable habilitada. La acción conjunta $\mathbf{a}_t$ representa la agrupación de las acciones de los 17 agentes y determina el efecto simultáneo de sus decisiones sobre el balance energético comunitario.

2.4.2. Actor y crítico

El actor es la red o función parametrizada que representa la política del agente y genera una acción a partir de su observación local. El crítico estima el valor de los estados o de las combinaciones estado–acción y proporciona la señal utilizada para actualizar el actor. En las arquitecturas CTDE, el crítico puede utilizar información conjunta durante el entrenamiento, mientras que el actor opera con información local durante la ejecución (Lowe et al., 2017).

2.4.3. Agente.

Unidad autónoma de decisión que observa parcialmente el entorno y selecciona acciones mediante una política. En la presente investigación, cada uno de los 17 edificios constituye un agente. Los agentes son heterogéneos porque presentan diferentes perfiles de demanda, capacidades fotovoltaicas, sistemas de almacenamiento, cantidades de cargadores y cargas desplazables.

2.4.4. Aprendizaje por refuerzo profundo multiagente.

El aprendizaje por refuerzo profundo multiagente (MADRL, por sus siglas en inglés) es un enfoque en el que múltiples agentes emplean redes neuronales para aprender políticas de decisión a partir de su interacción con un entorno compartido. El aprendizaje se orienta mediante recompensas y considera las consecuencias futuras de las acciones. En esta tesis, MADRL se materializa mediante HAPPO, MASAC, MATD3 y MAAC, sin asumir que alguno sea universalmente superior a los demás (Sutton & Barto, 2018); (Oliehoek & Amato, 2016).

2.4.5. Backend algorítmico.

Implementación computacional que contiene la arquitectura, las redes neuronales, los procedimientos de actualización y los mecanismos de almacenamiento de experiencia de un algoritmo. Los backends originales de HAPPO, MASAC, MATD3 y MAAC fueron adaptados mediante interfaces específicas para operar con las observaciones, acciones y recompensas de la comunidad energética de Iquitos.

2.4.6. Sistema de almacenamiento en batería.

El sistema de almacenamiento de energía mediante baterías (BESS) es un recurso capaz de absorber energía durante determinados intervalos y entregarla posteriormente. Su funcionamiento se encuentra restringido por la capacidad nominal, la potencia de carga y descarga, las eficiencias y los límites del estado de carga. En el estudio, el BESS es un recurso controlable y no una fuente primaria de generación.

2.4.7. Estado de carga.

El estado de carga (SOC) expresa la proporción de energía disponible en una batería respecto de su capacidad utilizable. Se aplica tanto al almacenamiento estacionario como a las baterías de los vehículos eléctricos. El SOC condiciona las acciones factibles de carga y descarga y debe mantenerse dentro de los límites establecidos por el entorno.

2.4.8. Carga desplazable.

Demanda energética cuyo instante de operación puede modificarse dentro de una ventana temporal autorizada, sin eliminar la energía requerida por el servicio. En la implementación canónica, la acción flexible materializada corresponde a washing_machine. El algoritmo puede modificar el momento de utilización, pero no suprimir arbitrariamente el consumo necesario.

2.4.9. CityLearn v2.

Entorno oficial de simulación utilizado como núcleo físico y energético de la investigación. CityLearn v2 representa edificios, generación fotovoltaica, sistemas de almacenamiento, vehículos eléctricos, señales de precio e intensidad de carbono y diferentes condiciones de operación. Asimismo, proporciona una estructura común para evaluar estrategias de control mediante indicadores a escala de edificio y comunidad (Nweye et al., 2025c).

2.4.10. CityLearn v3 propuesta.

Extensión experimental desarrollada dentro de la tesis sobre el núcleo oficial de CityLearn v2. Integra el dataset de Iquitos, la comunidad de 17 agentes, la formulación Dec-POMDP, el paradigma CTDE, la recompensa multiobjetivo, los cuatro backends MADRL y los mecanismos de trazabilidad. La denominación no corresponde a una versión oficial publicada por los desarrolladores de CityLearn.

2.4.11. Comunidad energética inteligente.

Conjunto de edificios y recursos energéticos distribuidos que comparten un entorno energético y cuyas decisiones locales producen efectos sobre el desempeño agregado. En la investigación, la comunidad está conformada por 17 edificios institucionales y comerciales representativos del contexto energético de Iquitos. No representa la totalidad de usuarios, redes o edificaciones de la ciudad.

2.4.12. Coordinación energética.

Capacidad de los agentes para seleccionar acciones locales compatibles con los objetivos comunitarios, considerando que las decisiones de un edificio pueden modificar los resultados de los demás. La coordinación no equivale a la simple ejecución simultánea ni a la suma de resultados individuales; implica reducir conflictos temporales y evitar que una mejora local produzca un deterioro distrital.

2.4.13. Desempeño coordinado de la comunidad energética.

Grado en que las decisiones de los edificios mejoran conjuntamente la flexibilidad energética, las emisiones de CO_2 y los costos energéticos, respetando las restricciones operativas y los requerimientos de servicio de los recursos. Su evaluación no se limita a la recompensa de entrenamiento, sino que incorpora KPI físicos, ambientales, económicos y de cumplimiento operacional.

2.4.14. Proceso de decisión de Márkov descentralizado y parcialmente observable.

El Dec-POMDP es una formalización de decisiones secuenciales cooperativas en la que varios agentes actúan sobre un entorno común, reciben observaciones locales y buscan maximizar un retorno compartido. El estado global puede no estar disponible para los agentes durante la ejecución, aunque sus acciones conjuntas determinen la transición del sistema (Oliehoek & Amato, 2016).

2.4.15. Entrenamiento centralizado con ejecución descentralizada.

CTDE es un paradigma en el que los componentes de aprendizaje pueden utilizar información conjunta durante el entrenamiento, mientras que cada política selecciona sus acciones utilizando únicamente su observación local durante la ejecución. CTDE no reemplaza la formulación Dec-POMDP; define la forma en que se distribuye la información durante el aprendizaje y la operación (Lowe et al., 2017).

2.4.16. Observación local y estado global.

La observación local $o_{i,t}$ contiene la información disponible para el agente i, incluyendo señales temporales, meteorológicas, energéticas, económicas, ambientales y estados de sus recursos habilitados. El estado global s_t representa una composición de la información comunitaria utilizada por los componentes centralizados durante el entrenamiento. En la ejecución descentralizada, el actor no accede al estado global completo.

2.4.17. Política.

Regla de decisión parametrizada que determina la acción que debe seleccionar un agente a partir de su observación. Puede ser determinista o estocástica, según el algoritmo. En el proyecto, cada edificio dispone de una política local, aunque el aprendizaje puede incorporar información comunitaria durante el entrenamiento.

2.4.18. Recurso controlable y variable exógena.

Un recurso controlable es un dispositivo sobre el cual la política puede emitir una consigna, como el BESS, los cargadores EV/V2G o la carga desplazable. Una variable exógena es una señal que influye en la transición del entorno, pero no puede ser modificada directamente por el agente, como la irradiancia, la temperatura exterior, la demanda no desplazable, el precio, la intensidad de carbono o la disponibilidad vehicular.

2.4.19. Generación fotovoltaica.

Energía eléctrica producida por los sistemas solares instalados en los edificios a partir de la irradiancia disponible y de las condiciones térmicas. En la tesis, la generación fotovoltaica constituye una entrada exógena; la política no decide cuánta energía solar se produce, sino cómo coordinar la demanda, el almacenamiento y los vehículos frente a su disponibilidad.

2.4.20. Operación G2V y V2G.

La operación *Grid-to-Vehicle* (G2V) corresponde al flujo de energía desde la red o el edificio hacia la batería del vehículo. La operación *Vehicle-to-Grid* (V2G) permite que un vehículo conectado entregue energía al edificio o reduzca su importación desde la red. La descarga V2G debe respetar el SOC requerido al momento de la salida del vehículo (Fonseca et al., 2024).

2.4.21. Flexibilidad energética.

Capacidad de modificar temporalmente el consumo, la generación local aprovechada y el uso del almacenamiento para responder a variaciones de demanda, disponibilidad renovable, precio o condiciones operativas. En la tesis se evalúa principalmente mediante demanda máxima, rampas y factor de carga, complementados con indicadores de autoconsumo, autosuficiencia y comportamiento de los recursos (Jensen et al., 2017) ; (Reynders et al., 2018).

2.4.22. Emisiones de CO_2.

Cantidad de dióxido de carbono equivalente asociada con la energía eléctrica importada por los edificios. Se calcula considerando el consumo neto positivo y la intensidad de carbono correspondiente a cada intervalo. La política no modifica directamente la intensidad de carbono, pero puede cambiar el momento y la magnitud de la importación eléctrica.

2.4.23. Intensidad de carbono.

Cantidad de emisiones asociada con cada unidad de electricidad consumida, expresada habitualmente en kg CO_2/kWh. En el entorno experimental constituye una señal temporal exógena utilizada para orientar el consumo hacia intervalos ambientalmente más favorables. El valor aplicado en el proyecto es un parámetro del modelo y no una medición directa en tiempo real de la generación del SEAI Iquitos.

2.4.24. Costos energéticos.

Efecto monetario asociado con el consumo neto, el momento de importación, las tarifas horarias y la demanda máxima de la comunidad. El análisis se restringe a los costos representados por las señales del entorno y no comprende inversión, mantenimiento, reposición, depreciación o financiamiento de los equipos.

2.4.25. Indicador clave de desempeño.

Un KPI es una medida cuantitativa utilizada para evaluar los efectos físicos, ambientales, económicos u operativos de una política. El proyecto emplea KPI compatibles con evaluate_v2() y métricas derivadas de las series temporales. Los indicadores derivados de la extensión local no deben presentarse como funciones oficiales del paquete original de CityLearn.

2.4.26. Línea base, control y diferencia.

La línea base —baseline— representa la condición de referencia utilizada para comparar los efectos de la política. El control corresponde al resultado obtenido bajo la política MADRL evaluada. La diferencia —delta— se calcula, para emisiones y costos, mediante:

$$\boldsymbol{\Delta = control - baseline}.$$

Por tanto, un valor negativo representa una reducción frente a la referencia, mientras que un valor positivo indica un incremento. Esta convención debe mantenerse de manera uniforme en la metodología, los resultados y las conclusiones.

2.4.27. Recompensa multiobjetivo.

Señal escalar utilizada para orientar el aprendizaje mediante la combinación ponderada de componentes asociados con flexibilidad, emisiones y costos, además de las penalizaciones o términos de servicio definidos por el entorno. La recompensa constituye un mecanismo de entrenamiento y no sustituye los KPI utilizados para contrastar las hipótesis. La dependencia de una política respecto de las preferencias aplicadas es una característica propia de los problemas secuenciales multiobjetivo (Roijers et al., 2014).

2.4.28. Escenario experimental.

Configuración de ponderaciones que establece la prioridad relativa de los componentes de la recompensa. E1 prioriza la flexibilidad energética; E2, la reducción de emisiones de CO_2; y E3, la reducción de costos energéticos. Los escenarios no representan comunidades

diferentes, porque mantienen la misma base de datos, los mismos edificios y el mismo horizonte.

2.4.29. Tratamiento experimental.

Combinación específica entre un algoritmo y un escenario de priorización. El diseño factorial 4×3 comprende 12 tratamientos: cuatro algoritmos (HAPPO, MASAC, MATD3 y MAAC) y tres escenarios —E1, E2 y E3—.

2.4.30. Episodio.

Secuencia completa de interacción entre los agentes y el entorno durante un horizonte definido. En la investigación, cada episodio representa un año de operación compuesto por 8,760 intervalos horarios. Los episodios permiten observar el proceso de aprendizaje, pero no constituyen por sí mismos réplicas experimentales independientes.

2.4.31. Semilla experimental.

Valor utilizado para inicializar los generadores pseudoaleatorios que intervienen en las redes neuronales, la exploración y otros componentes del entrenamiento. La repetición mediante diferentes semillas permite evaluar la sensibilidad y robustez de los resultados. En la evidencia actual, los 12 tratamientos se encuentran materializados con una única semilla común s0; por ello, los resultados poseen alcance intraexperimento y no demuestran robustez entre semillas (Henderson et al., 2018).

2.4.32. Corrida canónica.

Ejecución experimental seleccionada como fuente oficial y auditable de los resultados de la tesis. Corresponde a madrl_v3_20260627_164047 y comprende los artefactos conservados para los 12 tratamientos. La denominación no significa que sea una validación universal, sino que constituye la ejecución de referencia utilizada para mantener la trazabilidad del documento.

2.4.33. Impacto experimental.

Efecto diferenciado del algoritmo o del escenario sobre los indicadores obtenidos dentro de la simulación, bajo condiciones controladas. En la tesis, el término impacto no implica una intervención física ni una relación causal validada sobre la red eléctrica real de Iquitos; expresa diferencias descriptivas y estadísticas observadas entre tratamientos.

2.4.34. Resultado distrital.

Resultado agregado de los 17 edificios que conforman la comunidad simulada. El término distrito se utiliza en el sentido computacional empleado por CityLearn y no como referencia a un distrito político-administrativo de la ciudad de Iquitos. El resultado distrital debe interpretarse junto con la evidencia por edificio, debido a que la agregación puede ocultar comportamientos heterogéneos.

2.4.35. UC3M.

Marco auxiliar del proyecto concebido para representar una arquitectura multiobjetivo extensible de siete ejes: emisiones de CO_2, costos, flexibilidad, confort, degradación del BESS, resiliencia y agua caliente sanitaria. La evidencia experimental de la tesis se restringe a flexibilidad, emisiones y costos, complementados por el término operativo de servicio EV. Por tanto, los cuatro ejes restantes no constituyen dimensiones contrastadas en el Capítulo V.

2.4.36. Alcance intraexperimento.

Nivel de interpretación limitado a la comunidad, los datos, los tratamientos, la semilla y la corrida efectivamente ejecutados. Este alcance permite describir y comparar el comportamiento observado dentro del experimento, pero no permite afirmar que los resultados se mantendrán ante otras semillas, ciudades, edificios, tarifas, funciones de recompensa o configuraciones tecnológicas

CAPÍTULO III. METODOLOGÍA

El presente capítulo describe el enfoque, el tipo y el diseño mediante los cuales se responde al problema general y a los problemas específicos de la investigación. El estudio se orienta a determinar el efecto diferenciado de cuatro algoritmos de aprendizaje por refuerzo profundo multiagente sobre la flexibilidad energética, las emisiones de CO_2 y los costos energéticos de una comunidad simulada de 17 edificios representativos del Sistema Eléctrico Aislado de Iquitos. Asimismo, busca identificar el algoritmo que presenta el desempeño más favorable en cada dimensión y el mejor compromiso conjunto entre los tres objetivos.

La investigación sigue una ruta cuantitativa porque parte de problemas, objetivos e hipótesis previamente formulados, operacionaliza las variables mediante indicadores observables y analiza numéricamente los resultados obtenidos en condiciones controladas. (Hernández, 2018) señalan que la ruta cuantitativa articula el planteamiento del problema, la formulación de hipótesis, la elección del diseño, la medición y el análisis de datos dentro de un proceso sistemático. (Creswell, 2023) Creswell y Creswell (2023) complementan este planteamiento al señalar que los métodos cuantitativos permiten examinar relaciones entre variables mediante procedimientos estructurados de medición y análisis estadístico.

En el estudio, la manipulación se realiza dentro de un entorno computacional controlado. El factor principal corresponde al algoritmo MADRL, con cuatro niveles: HAPPO, MASAC, MATD3 y MAAC. El escenario de priorización de la recompensa constituye un segundo factor experimental, con tres niveles: E1, orientado a la flexibilidad energética; E2, orientado a las emisiones de CO_2; y E3, orientado a los costos energéticos. La combinación de ambos factores produce 12 tratamientos algoritmo–escenario, evaluados sobre la misma comunidad, el mismo conjunto de datos y un protocolo común de observación, acción y evaluación. Esta estructura mantiene correspondencia directa con el objetivo general y con los objetivos específicos OE.1, OE.2 y OE.3.

La variable dependiente corresponde al desempeño coordinado de la comunidad energética. Su medición no se limita a la recompensa acumulada durante el entrenamiento, sino que utiliza indicadores físicos, ambientales, económicos y operativos compatibles con la estructura de evaluación de CityLearn v2, complementados por métricas derivadas de las series temporales del proyecto. Los registros episódicos permiten analizar el comportamiento longitudinal del entrenamiento, pero no constituyen por sí mismos indicadores independientes ni réplicas experimentales autónomas

3.1. Enfoque, tipo, nivel y diseño de investigación

3.1.1. Enfoque de investigación

La investigación adopta un **enfoque cuantitativo**, debido a que las variables se expresan mediante valores numéricos obtenidos de la simulación y se analizan mediante procedimientos descriptivos, comparativos e inferenciales. La variable independiente se representa mediante las configuraciones algorítmicas y los escenarios de priorización, mientras que la variable dependiente se operacionaliza mediante indicadores de flexibilidad energética, emisiones de CO_2 y costos energéticos.

En la dimensión de flexibilidad se consideran, principalmente, la demanda máxima, las rampas horarias, el factor de carga y el indicador integrado de flexibilidad. En la dimensión ambiental se analizan las emisiones asociadas con la importación eléctrica y su diferencia respecto de la línea base. En la dimensión económica se evalúan el costo energético, su variación frente a la referencia y los indicadores asociados con el desplazamiento temporal de la demanda. Estos resultados se examinan tanto a escala comunitaria como por edificio, junto con la actuación de los BESS, los cargadores EV/V2G y la carga desplazable habilitada.

La elección del enfoque cuantitativo se encuentra, por tanto, determinada por la formulación de los objetivos: el objetivo general exige establecer el efecto integrado del algoritmo MADRL e identificar el mejor desempeño global, mientras que los objetivos específicos requieren comparar los algoritmos por separado en flexibilidad, emisiones y costos. Esta correspondencia entre preguntas, mediciones e hipótesis es consistente con la lógica de diseño cuantitativo planteada por Hernández-Sampieri y Mendoza Torres (2018) y Creswell y Creswell (2023)

Tipo de investigación

Con formato[Sergio Zambrano]: Normal

Por su finalidad, la investigación es de **tipo aplicado**, porque desarrolla, adapta y evalúa una solución computacional destinada a un problema concreto de gestión energética. La propuesta integra CityLearn v2, el dataset citylearn_iquitos_2023_2025, la formalización Dec-POMDP, el paradigma CTDE, una función de recompensa multiobjetivo y cuatro backends MADRL adaptados a una comunidad energética representativa de Iquitos.

El carácter aplicado no implica que la propuesta haya sido desplegada físicamente en el SEAI Iquitos. La contribución se materializa en un entorno de simulación que permite estudiar el comportamiento de las políticas bajo condiciones controladas, generar evidencia reproducible y determinar su desempeño antes de una eventual validación operativa. En

consecuencia, los resultados corresponden a una aplicación computacional contextualizada y no a una intervención directa sobre centrales, redes de distribución o usuarios reales.

Diseño de investigación.

Con formato[Sergio Zambrano]: Normal

La investigación utiliza un **diseño experimental-computacional factorial 4×3**. Se considera experimental-computacional porque los factores son manipulados deliberadamente dentro del simulador y sus efectos se observan bajo condiciones controladas. No corresponde denominarlo diseño no experimental, debido a que el algoritmo y el escenario de recompensa son modificados intencionalmente para comparar las respuestas obtenidas.

El primer factor es el algoritmo MADRL:

$$\boldsymbol{A} = \{\boldsymbol{HAPPO}, \boldsymbol{MASAC}, \boldsymbol{MATD3}, \boldsymbol{MAAC}\}.$$

El segundo factor es el escenario de priorización:

$$\boldsymbol{E} = \{\boldsymbol{E1}, \boldsymbol{E2}, \boldsymbol{E3}\}.$$

El conjunto de tratamientos se representa mediante:

$$\boldsymbol{\tau} = \boldsymbol{A} \times \boldsymbol{E}, \quad |\boldsymbol{\tau}| = \mathbf{4} \times \mathbf{3} = \mathbf{12}.$$

Los diseños factoriales permiten estudiar sistemáticamente diferentes factores y sus combinaciones mediante tratamientos definidos previamente. Montgomery (2019) desarrolla esta lógica a partir de factores, niveles, tratamientos y variables de respuesta, y destaca que los diseños factoriales permiten analizar los efectos asociados con distintas configuraciones experimentales.

En la tesis, el algoritmo constituye el factor principal vinculado con la variable independiente, mientras que el escenario actúa como factor de condicionamiento multiobjetivo. Esta precisión resulta necesaria porque los objetivos específicos no comparan los algoritmos bajo una única recompensa indiferenciada, sino que los examinan dentro del escenario correspondiente a cada dimensión. Por tanto, E1, E2 y E3 no son simples etiquetas de presentación, sino condiciones experimentales que modifican la prioridad relativa de los componentes de la recompensa.

Para favorecer la comparabilidad, los tratamientos mantienen constantes:

$$\boldsymbol{X} = \{\boldsymbol{dataset}, \mathbf{17}\boldsymbol{edificios}, \boldsymbol{horizonte}, \boldsymbol{entorno}\boldsymbol{f}\text{ísico}, \boldsymbol{observaciones}, \ \boldsymbol{acciones}, \boldsymbol{restricciones}, \boldsymbol{protocolo\ de\ evaluaci}\text{ón}\}$$

.

La arquitectura general de la recompensa se conserva entre tratamientos, mientras que sus ponderaciones cambian de acuerdo con E1, E2 y E3. También se mantienen el periodo de datos 2023–2025, la estructura de la comunidad, la resolución horaria y los procedimientos de generación de KPI. En consecuencia, las diferencias observadas se interpretan en relación con los factores manipulados y no con cambios deliberados en la comunidad o en el conjunto de datos.

La unidad de tratamiento corresponde a cada combinación algoritmo–escenario. Sin embargo, la unidad de replicación independiente debería estar constituida por una corrida completa ejecutada con una semilla diferente. En la evidencia actualmente disponible, cada tratamiento se encuentra materializado mediante una única semilla común, mientras que los episodios representan observaciones repetidas dentro de esa corrida. Por tanto, los episodios no deben tratarse como réplicas independientes equivalentes a nuevas semillas.

Esta delimitación es especialmente importante en aprendizaje por refuerzo profundo, debido a que la inicialización, la exploración, los hiperparámetros y otros componentes estocásticos pueden producir variaciones sustanciales entre ejecuciones. Henderson et al. (2018) advierten que la comparación entre algoritmos de RL requiere estandarización experimental, métricas de significación y reporte transparente de la variabilidad para evitar que diferencias circunstanciales sean interpretadas como mejoras generalizables.

En consecuencia, el diseño factorial describe correctamente la estructura de los 12 tratamientos, pero su ejecución actual corresponde a una **realización de una sola semilla por tratamiento**, no a un experimento factorial multisemilla completamente replicado. Los análisis inferenciales basados en registros episódicos deben interpretarse como evidencia exploratoria e intra-corrida. La superioridad universal de un algoritmo solo podría sostenerse después de incorporar múltiples semillas independientes y comprobar la estabilidad estadística y práctica de los resultados

Tabla 5

Clasificación metodológica de la investigación

Criterio	Decisión metodológica	Sustento
Enfoque	Cuantitativo	Medición numérica de KPIs y contrastación estadística.
Tipo	Aplicada	Desarrollo y evaluación de una propuesta MADRL para gestión energética.
Nivel	Explicativo-comparativo	Evalúa efecto de algoritmos y escenarios sobre

		dimensiones VD.
Diseño	Experimental-computacional factorial 4 × 3	Manipulación controlada de algoritmo y escenario en simulación.
Temporalidad	Longitudinal por episodios y horizonte anual horario	Cada episodio recorre una trayectoria anual de 8760 pasos.
Inferencia	Intra-corrida con limitación multi-semilla	No se generaliza más allá de los artefactos auditados.

Nota. La tabla representa el diseño metodológico, las variables, herramientas, datos y procedimiento experimental. Fuente: Elaboración propia a partir del proyecto local, scripts de metodología, datase citylearn_iquitos_2023_2025 y artefactos Drive de entrenamiento.

3.2. Diseño experimental-computacional factorial 4 × 3

El diseño factorial se compone de dos factores principales. El primer factor es el algoritmo MADRL, con cuatro niveles: HAPPO, MAAC, MASAC y MATD3. El segundo factor es el escenario de recompensa, con tres niveles: E1 orientado a flexibilidad, E2 orientado a emisiones de CO_2 y E3 orientado a costos energéticos. La combinación genera 12 tratamientos algoritmo x escenario. Montgomery (2019) sostiene que los diseños factoriales permiten estudiar efectos de factores bajo condiciones controladas; en esta tesis, el control se materializa en el mismo dataset, el mismo entorno CityLearn, la misma comunidad de 17 edificios, el mismo horizonte de evaluación y la misma familia de KPIs.

La unidad experimental principal es el tratamiento algoritmo-escenario. La unidad de observación episódica es el episodio conservado en los artefactos de Drive, y la unidad de observación espacial es el edificio-agente. Esta doble lectura permite responder los objetivos en tres escalas: distrito, edificio y política multiagente. Para la inferencia estadística se usan los episodios materializados: MAAC, MASAC y MATD3 conservan cobertura completa en los tres escenarios; HAPPO registra entrenamiento completado, pero conserva 49 filas episódicas por escenario en el CSV materializado, por lo que se reporta como evidencia descriptiva y no como grupo inferencial completo.

Tabla 6

Matriz factorial 4 × 3 de tratamientos experimentales

Factor	Niveles	Función metodológica
Algoritmo MADRL	HAPPO, MAAC, MASAC, MATD3	Variable independiente principal; compara familias actor-critic multiagente.
Escenario de recompensa	E1, E2, E3	Manipulación de prioridad multiobjetivo: flexibilidad, CO_2 y costo.
Tratamientos	12 combinaciones	Base de comparación para resultados por objetivo

		específico.
Horizonte	50 episodios registrados por tratamiento	Evidencia de entrenamiento Drive; se declara cobertura materializada por algoritmo.

Nota. La tabla representa el diseño metodológico, las variables, herramientas, datos y procedimiento experimental. Fuente: Elaboración propia a partir del proyecto local, scripts de metodología, datase citylearn_iquitos_2023_2025 y artefactos Drive de entrenamiento.

3.3. Datos utilizados y fuente empírica

Los datos utilizados corresponden al dataset citylearn_iquitos_2023_2025 y a la corrida canónica Drive madrl_v3_20260627_164047. La tesis no incorpora datos simulados manualmente fuera del pipeline; usa artefactos generados por scripts del proyecto y resultados auditables: results.json, training_summary.json, timeseries.csv, trace.csv, building_kpis.csv, building_behavior_summary.csv, building_observation_action_schema.csv y checkpoint_manifest.json. La fuente empírica combina meteorología, demanda, PV, BESS, EV, precios, intensidad de carbono y KPIs CityLearn. Esta trazabilidad responde a la exigencia metodológica de reproducibilidad y control de medición que Hernandez-Sampieri y Mendoza (2018) y Creswell y Creswell (2023) asocian con la ruta cuantitativa.

El dataset representa 17 edificios de una comunidad energética de Iquitos, con equipos controlables heterogéneos y variables de observación locales. La representación por edificio permite modelar el problema como Dec-POMDP y evaluar la ejecución descentralizada de políticas MADRL.

Tabla 7

Fuentes de datos y artefactos de análisis

Artefacto	Contenido	Uso metodológico
timeseries.csv	Serie temporal distrital por episodio	Energía, costo, CO_2, recompensa y señales horarias.
trace.csv	Trazas por agente	Acciones, SOC, EV, PV, importación/exportación y recompensa individual.
building_kpis.csv / building_behavior_summary.csv	KPIs por edificio	Análisis espacial por agente y equipamiento.
checkpoint_manifest.json	Registro de checkpoints	Trazabilidad de entrenamiento y cobertura por tratamiento.
district_episode_kpis.csv	KPIs episódicos materializados	Base de estadística descriptiva e inferencial.

Nota. La tabla representa el diseño metodológico, las variables, herramientas, datos y procedimiento experimental. Fuente: Elaboración propia a partir del proyecto local, scripts de metodología, datase citylearn_iquitos_2023_2025 y artefactos Drive de entrenamiento.

3.4. Variables, dimensiones e indicadores

La variable independiente (VI) es el algoritmo MADRL implementado bajo un esquema CTDE y condicionado por escenario de recompensa. Sus dimensiones operacionales son: D-VI.1 tipo de algoritmo, D-VI.2 ponderación multiobjetivo del escenario y D-VI.3 controles experimentales. La variable dependiente (VD) es el desempeño energético coordinado de la comunidad, desagregado en tres dimensiones: D-VD.1 flexibilidad energética, D-VD.2 emisiones de CO_2 y D-VD.3 costos energéticos. Esta definición mantiene correspondencia vertical con PE.1, PE.2, PE.3, OE.1, OE.2 y OE.3.

La operacionalización sigue la lógica de medición cuantitativa: cada dimensión debe tener indicadores observables, fuente de datos y criterio de interpretación. En D-VD.1 se consideran recompensa en E1 y KPIs de flexibilidad como peak, ramping, load factor, autoconsumo PV y uso de almacenamiento. En D-VD.2 se consideran emisiones distritales, carbon_emissions_control, carbon_emissions_delta y consumo ponderado por intensidad de carbono. En D-VD.3 se consideran district_cost, electricity_cost_control, electricity_cost_delta y señales de precio. Esta estructura evita confundir recompensa de entrenamiento con resultado final de evaluación.

Tabla 8

Operacionalización metodológica de variables

Variable	Dimensión	Indicadores principales	Fuente
VI	D-VI.1 Algoritmo	HAPPO, MAAC, MASAC, MATD3	Configuración de tratamiento.
VI	D-VI.2 Escenario	E1, E2, E3; pesos flex/CO2/costo	reward_axis_weights y protocolo experimental.
VD	D-VD.1 Flexibilidad	reward_mean E1, peak, ramping, load factor, BESS/PV	episodes, results, evaluate_v2.
VD	D-VD.2 CO_2	district_emission, carbon_emissions_control/delta	timeseries, results, building KPIs.
VD	D-VD.3 Costos	district_cost, electricity_cost_control/delta	timeseries, results, building KPIs.

Nota. La tabla representa el diseño metodológico, las variables, herramientas, datos y procedimiento experimental. Fuente: Elaboración propia a partir del proyecto local, scripts de metodología, datase citylearn_iquitos_2023_2025 y artefactos Drive de entrenamiento.

3.5. Técnicas, herramientas e instrumentos

Las técnicas utilizadas son simulación computacional, entrenamiento MADRL, evaluación por KPIs, estadística descriptiva, contrastación no paramétrica y visualización analítica. Las herramientas principales son Python, PyTorch, CityLearn v2, la extensión CityLearn v3 propuesta, backends HAPPO/MAAC/MASAC/MATD3, scripts de orquestación del proyecto y artefactos Drive. En términos metodológicos, el instrumento de medición no es un cuestionario ni una entrevista, sino el entorno computacional validado y sus archivos de salida.

La decisión de usar estadística no paramétrica se debe a que las recompensas y KPIs episódicos de RL pueden presentar no normalidad, dependencia temporal, asimetría o valores atípicos. Por ello se aplica Shapiro-Wilk para normalidad, Kruskal-Wallis para diferencias globales entre algoritmos con cobertura completa y Mann-Whitney U con ajuste Holm para comparaciones por pares. Esta elección es coherente con la recomendación metodológica de no asumir supuestos estadísticos no verificados y con las advertencias de evaluación robusta en aprendizaje por refuerzo reportadas por Henderson et al. (2018) y Agarwal et al. (2021).

Tabla 9

Técnicas, herramientas e instrumentos

Componente	Aplicación en la tesis	Resultado esperado
Simulación CityLearn	Recrear comunidad energética multiagente	Series, KPIs y trazas auditables.
MADRL	Entrenar políticas bajo CTDE	Políticas por algoritmo y escenario.
evaluate_v2 / KPIs	Evaluar flexibilidad, CO_2 y costo	Ranking comparable con baseline.
Estadística no paramétrica	Contrastar diferencias entre algoritmos	p-valores, epsilon2 y decisiones HE.
Visualización	Interpretar convergencia, trade-offs, edificios y acciones	Figuras del Capítulo 5.

Nota. La tabla representa el diseño metodológico, las variables, herramientas, datos y procedimiento experimental. Fuente: Elaboración propia a partir del proyecto local, scripts de metodología, datase citylearn_iquitos_2023_2025 y artefactos Drive de entrenamiento.

3.6. Procedimiento experimental

El procedimiento experimental se estructura en siete fases reproducibles. Primero, se verifica el contexto del repositorio y la disponibilidad de artefactos. Segundo, se valida el dataset citylearn_iquitos_2023_2025 y el esquema de edificios/equipos. Tercero, se ejecutan o recuperan las 12 corridas algoritmo x escenario desde Drive. Cuarto, se consolidan

episodios, timeseries, traces, building KPIs y checkpoints. Quinto, se calculan KPIs distritales, por edificio y por objetivo. Sexto, se aplican pruebas estadísticas y rankings evaluate_v2. Séptimo, se generan tablas, figuras y redacción interpretativa en el documento final.

Cada fase se documenta mediante archivos de salida. La decisión de no completar manualmente valores ausentes es parte del control metodológico: si un artefacto no conserva una granularidad determinada, se declara como limitación y no se sintetiza. Esta regla es consistente con la validez de medición y la transparencia experimental recomendadas por Shadish et al. (2002) y Montgomery (2019).

Tabla 10

Procedimiento experimental reproducible

Fase	Actividad	Evidencia
1	Verificación de contexto y rutas	scripts/verify_project_context.ps1.
2	Validación de dataset y esquema CityLearn	schema, building files y auditoria's.
3	Entrenamiento/recuperación de 12 tratamientos	Drive madrl_v3_20260627_164047.
4	Consolidación de resultados	timeseries, traces, checkpoints y KPIs.
5	Análisis descriptivo e inferencial	CSV de estadísticas y comparaciones Holm.
6	Visualización académica	Figuras por convergencia, KPIs, edificios y trade-offs.
7	Integración en Word	Documento final reproducible desde el generador.

Nota. La tabla representa el diseño metodológico, las variables, herramientas, datos y procedimiento experimental. Fuente: Elaboración propia a partir del proyecto local, scripts de metodología, datase citylearn_iquitos_2023_2025 y artefactos Drive de entrenamiento.

3.7. Validez metodológica, trazabilidad y control de sesgos

La validez interna se fortalece por el control del entorno: todos los algoritmos se evalúan sobre el mismo dataset, la misma comunidad, los mismos escenarios y los mismos criterios de extracción de KPIs. La validez de constructo se protege mediante la correspondencia entre preguntas, objetivos, variables e indicadores. La validez estadística se aborda con pruebas no paramétricas y tamaños de efecto, evitando asumir normalidad sin evidencia. La validez externa se declara limitada porque la corrida canónica no sustituye una campaña multi-semilla; por tanto, las conclusiones se formulan como evidencia de la tesis intra-corrida y no como generalización universal.

El control de sesgos se apoya en cinco reglas: no mezclar resultados de otros proyectos, no usar artefactos ajenos a Drive/local autorizado, no inventar datos faltantes, distinguir evidencia descriptiva de evidencia inferencial y reportar limitaciones de cobertura. Este criterio es central para una tesis basada en RL, donde diferencias aparentemente favorables pueden depender de semillas, hiperparámetros, entorno y criterio de evaluación.

Como parte del control de calidad metodológico, se adoptó de forma definitiva la cobertura materializada de 597 filas episódicas: HAPPO conserva 49 episodios por escenario y MAAC, MASAC y MATD3 conservan 50. No se imputó el episodio faltante ni se consideraron los episodios como réplicas independientes de una campaña multi-semilla. Las pruebas Shapiro–Wilk, Kruskal–Wallis, Mann–Whitney U con ajuste Holm y los tamaños de efecto se aplican únicamente a las muestras que cumplen el criterio de cobertura definido. Cada tabla y figura de resultados debe conservar una nota de fuente que identifique los archivos canónicos empleados, lo que permite verificar su correspondencia con results.json, training_summary.json, timeseries.csv, trace.csv, building_kpis.csv y checkpoint_manifest.json.

Tabla 11

Control metodológico de validez y trazabilidad

Dimensión de validez	Riesgo	Control aplicado
Interna	Comparación desigual entre algoritmos	Mismo dataset, mismo entorno y escenarios controlados.
Constructo	Indicadores no alineados con objetivos	PE/OE/VD/KPI vinculados por tabla de operacionalización.
Estadística	Normalidad o significancia asumida	Shapiro-Wilk, Kruskal-Wallis, Mann-Whitney-Holm y epsilon2.
Externa	Generalización indebida	Declaración de inferencia intra-corrida y recomendación multi-semilla.
Trazabilidad	Datos inventados o mezclados	Uso exclusivo de artefactos Drive y CSV materializados.

Nota. La tabla representa el diseño metodológico, las variables, herramientas, datos y procedimiento experimental. Fuente: Elaboración propia a partir del proyecto local, scripts de metodología, datase citylearn_iquitos_2023_2025 y artefactos Drive de entrenamiento.

CAPÍTULO IV. DESARROLLO DE LA PROPUESTA

4.1. Desarrollo del sistema y arquitectura de software

El sistema conserva la arquitectura implementada en el repositorio y se organiza en seis capas: datos, simulador CityLearn v2, extensión CityLearn v3 propuesta, adaptación multiagente, entrenamiento MADRL y generación de evidencia. La separación por capas permite rastrear cada resultado desde la fuente de datos hasta el archivo final, reduce acoplamientos entre backends y evita atribuir a CityLearn oficial componentes desarrollados exclusivamente en la tesis.

Tabla 12

Capas de software del sistema MADRL CityLearn v3

Capa	Componente	Función
1	CityLearn v2 (CityLearn/citylearn/*.py)	Física de edificios, BESS, PV, EV y KPIs oficiales.
2	CityLearn v3 propuesto (CityLearn/citylearn/v3/)	Entorno Dec-POMDP, objetivos, configuración y recompensa multiobjetivo.
3	Framework UC3M (uc3m/)	Wrapper universal (UC3MEnv), 7 ejes de recompensa, KPIEvaluator, AlgorithmFactory; capa auxiliar/generica.
4	Backends MADRL (external/)	HARL (HAPPO), MARL/src (MASAC), off-policy (MATD3 activo), MAAC.
5	Launchers y orquestación	train_citylearn_v3_*.py, launchers PowerShell y Colab A100, monitoreo y checkpointing.
6	Evaluación y evidencia	benchmark_citylearn_v2_agents.py, compare_citylearn_v2_vs_v3_madrl.py, generate_thesis_objective_evidence.py.

Nota. La tabla representa los componentes técnicos de la propuesta, arquitectura, algoritmos, recompensas y trazabilidad experimental. Fuente: Elaboración propia a partir del repositorio local, CityLearn v2, extensión CityLearn v3 propuesta, scripts de datase y corrida Drive madrl_v3_20260627_164047.

4.2. Modelo de IA: formulación Dec-POMDP

El problema se implementa a partir del Dec-POMDP $M = \langle S, \{A_i\}, T, R, \{O_i\}, \Omega, \gamma, H \rangle$, definido teóricamente en el Capítulo 2:

- $N = 17$ agentes (edificios del SEAI Iquitos).
- Estado global S: concatenación de las observaciones locales (state dim global = 1856 en el entorno cargado), accesible solo por el crítico centralizado durante el entrenamiento.

- Observación local O_i: heterogénea por edificio e integrada por variables temporales, físicas, meteorológicas, económicas, de carbono, BESS y cargadores EV. La dimensión observada en los artefactos auditados varía entre 54 y 327 variables por agente.
- Acción local Ai: heterogénea por edificio (potencia de BESS carga/descarga, potencia de carga EV por cargador y control de carga desplazable); la dimensionalidad varia de ~5 a ~44 acciones según la flota EV del edificio (B06 con 32 y B07 con 42 cargadores concentran las acciones de mayor dimensión).
- T: dinámica del balance energético, modelo RC de temperatura, BESS con eficiencia round-trip 0.9025 y perfiles EV estocásticos.
- R: recompensa cooperativa CityLearnV3MADRLRewardFunction; team_reward = media de reward_i.
- gamma = 0.9999; horizonte T = 8 760 pasos (1 año horario).

La condición de observabilidad parcial estricta se satisface: cada edificio solo observa su propio estado local y no accede a la temperatura, demanda, SOC ni perfil EV de los demás durante la ejecución.

4.3. Esquema CTDE

Entrenamiento centralizado: durante el aprendizaje, el crítico accede al estado global o a información conjunta, según el backend, para reducir la no estacionariedad causada por las políticas simultáneas. Ejecución descentralizada: cada actor $\pi_i(a_i|o_i)$ utiliza únicamente su observación local. HAPPO emplea actualización secuencial para agentes heterogéneos; MASAC y MATD3 usan críticos off-policy; y MAAC incorpora atención en el crítico. La diferencia de backend se conserva, pero todos reciben el mismo entorno, los mismos escenarios y la misma arquitectura de recompensa.

4.4. Algoritmos

Tabla 13

Los cuatro algoritmos MADRL y sus backends

Algoritmo	Tipo	Backend / wrapper	Característica clave
HAPPO	On-policy	external/HARL · CityLearnHARLEnv	Actualización secuencial con trust región; mejora monótona.
MASAC	Off-	external/MARL/src · CityLearnSMACDiscreteEnv	SAC + QMIX, acciones

	policy		discretizadas por eje, RNN.
MATD3	Off-policy	external/off-policy · CityLearnOffPolicyVecEnv	Doble crítico TD3, policy delay, target noise (backend activo).
MAAC	Off-policy	external/MAAC · CityLearnMAACVecEnv	Crítico de atención multi-cabeza (4 heads).

Nota. La tabla representa los componentes técnicos de la propuesta, arquitectura, algoritmos, recompensas y trazabilidad experimental. Fuente: Elaboración propia a partir del repositorio local, CityLearn v2, extensión CityLearn v3 propuesta, scripts de datase y corrida Drive madrl_v3_20260627_164047.

Los cuatro algoritmos representan mecanismos distintos de aprendizaje y coordinación. HAPPO prioriza estabilidad on-policy y heterogeneidad; MASAC combina aprendizaje off-policy y máxima entropía; MATD3 reduce la sobreestimación mediante críticos dobles; y MAAC usa atención para ponderar interacciones entre edificios. La Tabla 4.2 identifica el backend y el wrapper utilizados, de modo que la comparación se realiza sobre implementaciones explícitas y no sobre etiquetas algorítmicas genéricas.

Tabla 14
Configuración de entrenamiento y delimitación de la evidencia canónica

Parámetro	Colab canónico (50 ep)	Local v4 (5 ep)	Notas
Episodios × pasos	50 × 8 760	5 × 8 760	438 000 vs 43 800 pasos/corrida
gamma	0.9999	0.9999	Idéntico
hidden / actor	[512,512] HAPPO; 768 MATD3/MAAC	[256,256] todos	Mayor capacidad en Colab
replay_buffer MATD3	2 000 000	4 096	Restricción VRAM 8 GB local
batch MATD3	1 024	256	Colab A100
MASAC replay	2 ep CPU	on-GPU reducido	Protocolo two_phase_happo_masac
Semillas	seed 0	seed 0	Limitación inferencial
GPU	A100-SXM4-80GB	RTX 4060 8 GB	madrl_v3_20260627_164047

Nota. La tabla representa la información sintetizada en la tabla correspondiente.
Fuente: Elaboración propia a partir de los datos, fuentes y artefactos citados en el documento.

La optimización automática con Optuna se mantiene como trabajo posterior y no forma parte de la evidencia cuantitativa analizada. En consecuencia, las diferencias observadas se atribuyen a las configuraciones efectivamente registradas en la corrida canónica y no a una búsqueda de hiperparámetros no ejecutada.

4.5. Función de recompensa multiobjetivo

La clase CityLearnV3MADRLRewardFunction (la cual hereda de Electric_Vehicles_Reward_Function) calcula la recompensa de cada edificio como:

$$\text{reward_i}(t) = \text{reward_scale} \times [w_{flex} \cdot flex_i + w_{carbon} \cdot carbon_i + w_{cost} \cdot cost_i + ev_{weight} \cdot ev_i]$$

El componente de flexibilidad opera a escala distrital mediante peak_share y ramp_share; el componente de carbono pondera la importación con CI(t); el componente de costo incorpora la tarifa TOU; y el término EV penaliza incumplimientos de servicio y SOC. La agregación cooperativa usa $\text{mixed_reward}_i = (1 - r) \cdot \text{reward}_i + r \cdot \text{team_reward}$, con r = 0,70. Los pesos de escenario son E1 = [0,70; 0,15; 0,15], E2 = [0,15; 0,70; 0,15] y E3 = [0,25; 0,15; 0,60]. El perfil unificado se aplica por igual a los cuatro algoritmos, evitando que la recompensa actúe como variable de confusión.

Tabla 15

Parámetros de la función de recompensa multiobjetivo.

Parámetro	Valor	Justificación sintética
w_flex / w_carbon / w_cost (E1)	0.70 / 0.15 / 0.15	Escenario lexicográfico de flexibilidad.
w_flex / w_carbon / w_cost (E2)	0.15 / 0.70 / 0.15	Escenario lexicográfico de CO_2.
w_flex / w_carbon / w_cost (E3)	0.25 / 0.15 / 0.60	Costo-pico correlacionados en TOU.
team_reward_ratio ®	0.70	Coordinación cooperativa Dec-POMDP (media de perfiles del plan).
peak_weight / ramp_weight	0.45 / 0.35	KPI primario y secundario de flexibilidad CityLearn.
ev_weight	0.25	Término EV/SOC reforzado para evitar dejar EV sin cargar.
reward_scale	1.00	Escala uniforme para gradientes comparables.
carbon_reference / price_reference	0.35 / 0.20	Referencia global IEA y spot competitivo.

Nota. La tabla representa los componentes técnicos de la propuesta, arquitectura, algoritmos, recompensas y trazabilidad experimental. Fuente: Elaboración propia a partir del repositorio local, CityLearn v2, extensión CityLearn v3 propuesta, scripts de datase y corrida Drive madrl_v3_20260627_164047.

4.6. Aportes originales al motor de simulación

Como contribución metodológica diferencial, se realizaron cuatro extensiones originales y retro compatibles al fork CityLearn (commit 54b1938e):

Tabla 16

Aportes originales al motor de simulación CityLearn

#	Aporte	Clase/Método	Modelo incorporado
A1	Degradation BESS C-rate + Arrhenius	Battery.degrade(temperature_celsius)	ΔC = base·(C_rate) ^0.55·exp [Ea/R (1/T_ref - 1/T)], Ea=24500 J/mol.
A2	Corrección PV tropical (IEC 61215)	PV.get_generation (dry_bulb_temperature, ghi)	T_cell = T_amb + (NOCT-20)/800·G; P(T)=P_STC·[1+γ(T_cell-25)], γ=-0.0035/°C.
A3	KPI pico con ventana de facturacion	CostFunction.peak(billing_window_steps)	Máximo rodante sub-horario (OSINERGMIN MT-3/MT-4, 15 min).
A4	Modelo CI dinamico diésel+PV	CarbonIntensityModel (base_ci, pv_displacement_factor)	CI(t)=0.790(1-0.15·min (GHI/1000,1)).

Nota. La tabla representa los componentes técnicos de la propuesta, arquitectura, algoritmos, recompensas y trazabilidad experimental. Fuente: Elaboración propia a partir del repositorio local, CityLearn v2, extensión CityLearn v3 propuesta, scripts de datase y corrida Drive madrl_v3_20260627_164047.

4.7. Diseño experimental: matriz de 12 corridas

El diseño factorial combina cuatro niveles del factor algoritmo con tres escenarios de recompensa, generando 12 tratamientos. En cada escenario se conserva la misma comunidad, horizonte, semilla, esquema de observación, espacio de acciones, perfil unificado y protocolo de artefactos. E1 prioriza flexibilidad, E2 emisiones y E3 costos; por tanto, la comparación principal se realiza dentro del escenario correspondiente a cada objetivo específico.

Tabla 17

Matriz experimental de 12 corridas oficiales

Escenario	HAPPO	MASAC	MATD3	MAAC
E1 Flexibilidad	happo/E1_s0	masac/E1_s0	matd3/E1_s0	maac/E1_s0
E2 CO_2	happo/E2_s0	masac/E2_s0	matd3/E2_s0	maac/E2_s0
E3 Costos	happo/E3_s0	masac/E3_s0	matd3/E3_s0	maac/E3_s0

Nota. La tabla representa los componentes técnicos de la propuesta, arquitectura, algoritmos, recompensas y trazabilidad experimental. Fuente: Elaboración propia a partir del repositorio local, CityLearn v2, extensión CityLearn v3 propuesta, scripts de datase y corrida Drive madrl_v3_20260627_164047.

4.8. Implementación

Entorno de implementación: Python 3.9, PyTorch 2.8.0+cu126 y CUDA 12.6. Los scripts comparten citylearn_v3_training_common.py para normalización, KPIs, trazas, tablas, figuras y metadatos. Cada tratamiento conserva como fuente canónica data/results.json, data/training_summary.json, data/artifact_audit.json, data/checkpoint_manifest.json, data/timeseries.csv y data/trace.csv, además de checkpoints/ y figures/figures_manifest.json.

El despliegue admite ejecución local y Colab A100; Docker y AWS EC2 se documentan como opciones, no como fuente de los resultados utilizados.

La corrida canónica madrl_v3_20260627_164047 se ejecutó en Google Colab sobre NVIDIA A100-SXM4-80GB mediante colab_a100_official_launcher.py y el protocolo two_phase_happo_masac_v3. La primera fase entrenó HAPPO y MASAC y la segunda MATD3 y MAAC. El monitor registró progreso, uso de GPU, recompensa y métricas energéticas; sin embargo, los archivos de progreso en vivo se consideran transitorios y no sustituyen los artefactos finales. La cobertura materializada es de 49 episodios por escenario para HAPPO y 50 para los otros algoritmos.

4.9. Detalle técnico de la propuesta derivado del resumen

El resumen sintetiza la propuesta; por tanto, este numeral desarrolla de forma técnica los mismos componentes para que el lector no encuentre información clave solamente en la parte inicial del documento. La propuesta consiste en una arquitectura experimental MADRL sobre CityLearn v2, extendida como CityLearn v3 propuesto, que permite representar una comunidad inteligente del SEAI Iquitos como Dec-POMDP, entrenar políticas bajo CTDE y evaluar el efecto de HAPPO, MAAC, MASAC y MATD3 sobre flexibilidad energética, emisiones de CO_2 y costos energéticos. Esta sección no introduce resultados nuevos: organiza y detalla los datos, librerias, fuentes, scripts y artefactos que sustentan el resumen y que luego se contrastan en el Capítulo 5.

La propuesta opera con tres niveles integrados. En el nivel de datos, el repositorio construye el dataset citylearn_iquitos_2023_2025 desde fuentes eléctricas, climáticas, solares, tarifarias y de carbono. En el nivel de simulación, CityLearn v2 representa edificios, PV, BESS, EV, demanda base, precio, intensidad de carbono y acciones controlables por agente. En el nivel de aprendizaje, los algoritmos MADRL entrenan políticas descentralizadas con información local, mientras el entrenamiento centralizado permite estabilizar la coordinación bajo no-estacionariedad multiagente.

Tabla 18

Componentes detallados de la propuesta sintetizados en el resumen

Componente	Detalle desarrollado en la propuesta	Evidencia/artefacto
Comunidad inteligente	17 edificios institucionales/comerciales del SEAI Iquitos, modelados como agentes heterogéneos.	dataset citylearn_iquitos_2023_2025; building_behavior_summary.csv.
Horizonte temporal	26 304 pasos horarios del periodo 2023-2025; cada episodio experimental evalúa un ano horario de 8 760 pasos.	archivos CSV del dataset y timeseries.csv.

Recursos energéticos	PV, BESS, cargadores EV, V2G, cargas controlables y demanda no controlada separada para evitar atribuir acciones a cargas no actuables.	schema de edificios, traces y building KPIs.
Tratamientos MADRL	HAPPO, MAAC, MASAC y MATD3 bajo escenarios E1 flexibilidad, E2 CO_2 y E3 costos.	12 carpetas algoritmo-escenario y tablas episódicas.
Evidencia experimental	50 episodios por tratamiento disponible; HAPPO conserva 49 filas episódicas materializadas por escenario en el CSV final y se interpreta con esa limitación.	district_episode_kpis.csv y tablas de estadística.

Nota. La tabla representa los componentes técnicos de la propuesta, arquitectura, algoritmos, recompensas y trazabilidad experimental. Fuente: Elaboración propia a partir del repositorio local, CityLearn v2, extensión CityLearn v3 propuesta, scripts de datase y corrida Drive madrl_v3_20260627_164047.

4.9.1. Construcción del dataset y fuentes utilizadas

El dataset no se plantea como un insumo genérico, sino como la base empírica de la propuesta. La construcción integra facturacion y perfiles de Electro Oriente S.A., meteorología de NASA POWER, irradiación y estimación solar con PVGIS/pvlib, factores de carbono basados en MINAM y señales tarifarias alineadas con OSINERGMIN. La finalidad de esta triangulación es que los agentes no aprendan sobre una comunidad abstracta, sino sobre una representación horaria coherente con clima, demanda, irradiación, precio e intensidad de carbono del SEAI Iquitos.

La escala técnica desarrollada en el resumen se incorpora en la propuesta: 17 edificios, 26 304 pasos horarios, 222 archivos CSV activos, 185 cargadores EV, 31 tomas V2G, 96 equipos físicos Modo 3, 749,4 kW EV, 26 266 kWh de BESS, 6 648 kW BESS y 48 790,9 kWp fotovoltaicos. Estos valores no son objetivos aspiracionales, sino parámetros de entrada y auditoria de la simulación. Su función metodológica es delimitar el espacio de observación, acción y restricciones que enfrentan los agentes.

Tabla 19

Fuentes y transformaciones del datase citylearn_iquitos_2023_2025

Fuente/insumo	Transformación en el proyecto	Uso en CityLearn/MADRL
Electro Oriente S.A.	Perfiles de demanda/facturacion y contexto del SEAI Iquitos.	Demanda base y calibración de edificios.
NASA POWER	Series meteorológicas horarias para el periodo de estudio.	Variables exógenas de clima en observaciones.
PVGIS y pvlib	Estimación de generación solar y perfiles PV por capacidad instalada.	Producción fotovoltaica por edificio y balance energético.
Inventario de edificios y equipos	Asignación de PV, BESS, EV, V2G, cargas controlables y no	Dimensiones de observación/acción y heterogeneidad de agentes.

	controlables.	
MINAM	Factor de emisión base y modelo de intensidad de carbono.	Cálculo de emisiones y recompensa carbon-aware.
OSINERGMIN / señales TOU	Parametrización de precios punta y fuera de punta.	Costo eléctrico y recompensa económica.

Nota. La tabla representa los componentes técnicos de la propuesta, arquitectura, algoritmos, recompensas y trazabilidad experimental. Fuente: Elaboración propia a partir del repositorio local, CityLearn v2, extensión CityLearn v3 propuesta, scripts de datase y corrida Drive madrl_v3_20260627_164047.

4.9.2. Librerías, scripts y herramientas de implementación

La propuesta se implementa con un pipeline reproducible en Python. pandas y NumPy realizan consolidación tabular, limpieza, agregaciones y cálculo de KPIs; pvlib y requests participan en la construcción de perfiles solares y descarga/normalización de fuentes externas; PyTorch ejecuta las políticas neuronales y backends MADRL; SciPy calcula pruebas estadísticas; Matplotlib genera figuras de convergencia, distribuciones, radar, heatmaps y paneles temporales; CityLearn, Gymnasium y PettingZoo proveen la interfaz de ambiente multiagente; PowerShell verifica contexto y automatiza controles de repositorio; Google Colab/Drive aloja la corrida canónica y conserva resultados, checkpoints, timeseries y traces.

La decisión de registrar librerias y scripts dentro de la propuesta es necesaria porque la tesis no evalúa un concepto teórico aislado. Evalúa una implementación computacional concreta. Por ello, los scripts de generación de dataset, entrenamiento, validación, descarga de artefactos, análisis estadístico, construcción de figuras y generación del Word constituyen parte del método y de la propuesta. Si un resultado aparece en Capítulo 5, su origen debe poder rastrearse a uno de estos componentes.

La configuración experimental se cerró antes de interpretar los resultados. Optuna, PPO, SAC y A2C se mantienen como herramientas o comparadores potenciales para investigaciones posteriores, pero no forman parte de la evidencia canónica de esta tesis. En consecuencia, no se realizó optimización retrospectiva de hiperparámetros ni se modificaron las recompensas después de observar el desempeño de los algoritmos. Esta delimitación evita introducir sesgo de selección y conserva la comparabilidad del diseño factorial 4 × 3.

Tabla 20
Herramientas y función dentro de la propuesta MADRL

Herramienta/librería	Función técnica	Salida esperada
Python 3.9	Lenguaje base de orquestación, análisis y generación documental.	Scripts reproducibles y tablas/figuras.
pandas, NumPy	Tratamiento de CSV, agregación por episodio, edificio, escenario y algoritmo.	district_episode_kpis, rankings y resumenes.

pvlib, PVGIS, NASA POWER	Modelado solar y meteorológico del dataset.	Perfiles PV y variables exógenas horarias.
PyTorch	Entrenamiento de redes actor-critic y políticas MADRL.	Políticas, rewards, checkpoints.
CityLearn v2 / CityLearn v3 propuesto	Simulación energética multiagente con PV, BESS, EV, carbono y costos.	Observaciones, acciones, rewards, KPIs.
Gymnasium, PettingZoo	Interfaz multiagente y compatibilidad de entorno.	Ejecución descentralizada y wrappers.
SciPy	Shapiro-Wilk, Kruskal-Wallis y Mann-Whitney U con ajuste posterior.	Contraste inferencial por OE.1-OE.3.
Matplotlib	Traficación de convergencia, boxplots, radar, heatmaps, trade-offs y series finales.	Figuras del Capítulo 5.
Google Colab/Drive	Ejecución y persistencia de la corrida canónica.	results, timeseries, traces, checkpoints.

Nota. La tabla representa los componentes técnicos de la propuesta, arquitectura, algoritmos, recompensas y trazabilidad experimental. Fuente: Elaboración propia a partir del repositorio local, CityLearn v2, extensión CityLearn v3 propuesta, scripts de datase y corrida Drive madrl_v3_20260627_164047.

4.9.3. Arquitectura operativa desde datos hasta resultados

La arquitectura operativa inicia con la verificación del repositorio, de la raíz visible del entrenamiento y del contrato de artefactos. A continuación, se valida el datase, se instancia CityLearn, se configuran los 17 agentes, se asignan equipos controlables, se seleccionan algoritmo y escenario, y se ejecuta el tratamiento. La salida se consolida en archivos episódicos, series temporales, trazas por agente, KPIs por edificio y checkpoints. Finalmente, los scripts estadísticos materializan tablas y figuras para el Capítulo 5.

La arquitectura vincula directamente problema, método y resultado. E1 responde a OE.1 mediante KPIs de flexibilidad; E2 responde a OE.2 mediante emisiones; y E3 responde a OE.3 mediante costos. La selección del algoritmo de mayor efecto se reporta separando evidencia descriptiva, inferencial y KPI anual final. Esta distinción impide que un único valor resuma indebidamente comportamientos diferentes entre episodios, edificios y escalas de agregación.

Tabla 21
Cadena de trazabilidad de la propuesta

Fase	Entrada	Proceso	Salida verificable
Construcción de datos	Electro Oriente, NASA POWER, PVGIS, MINAM, OSINERGMIN, inventario de equipos.	Normalización, generación de perfiles y auditoria de CSV.	dataset citylearn_iquitos_2023_2025.

Simulación	Dataset y configuración de edificios.	Instanciación CityLearn v2 / CityLearn v3 propuesto.	observaciones, acciones y balances horarios.
Entrenamiento MADRL	Algoritmo, escenario y recompensa multiobjetivo.	CTDE con políticas descentralizadas.	rewards, checkpoints y logs.
Registro de evidencia	Ejecución por tratamiento.	Persistencia en Drive y consolidación local.	results.json, timeseries.csv, trace.csv, building_kpis.csv.
Análisis de la tesis	CSV episódicos, traces, checkpoints y KPIs.	Estadística, figuras y lectura por OE.	Capítulos 5 y 6 con evidencia real.

Nota. La tabla representa los componentes técnicos de la propuesta, arquitectura, algoritmos, recompensas y trazabilidad experimental. Fuente: Elaboración propia a partir del repositorio local, CityLearn v2, extensión CityLearn v3 propuesta, scripts de datase y corrida Drive madrl_v3_20260627_164047.

4.9.4. Delimitación entre equipos controlados y no controlados

La propuesta distingue equipos controlados y no controlados porque el efecto MADRL solo puede atribuirse a variables de acción disponibles para los agentes. Los equipos controlados incluyen BESS, cargadores EV/V2G y cargas flexibles declaradas en el esquema del entorno. La demanda base, condiciones climáticas, irradiación, ocupación implícita, precio e intensidad de carbono operan como observaciones o perturbaciones exógenas, no como actuadores. Esta distinción es esencial para interpretar correctamente los resultados por edificio y no atribuir al algoritmo variaciones que provienen de cargas no controlables.

En términos de tesis, esta delimitación conecta Capítulo 4 con Capítulo 5: las acciones registradas en traces permiten observar cómo cada política usa BESS, EV y otros actuadores; los KPIs por edificio permiten evaluar si la coordinación mejora flexibilidad, CO_2 o costo; y las limitaciones declaran que el estudio no controla red física ni despacho de generación. Por tanto, la propuesta es una arquitectura de control y evaluación energética multiagente en simulación, no una implementación de despacho eléctrico real.

4.10. Respuesta operacional a las preguntas específicas PE.1, PE.2 y PE.3

La propuesta no se limita a describir una arquitectura MADRL; también define como se responde cada pregunta específica mediante la salida empírica de la corrida Drive madrl_v3_20260627_164047. La respuesta se apoya en dos planos: análisis descriptivo de los episodios y KPIs anuales finales, y análisis inferencial intra-corrida con Kruskal-Wallis sobre los algoritmos que conservan cobertura episódica completa. Esta regla evita mezclar una diferencia numérica descriptiva con una afirmación causal o inferencial no sustentada.

Tabla 22

Respuesta directa a PE.1, PE.2 y PE.3 desde la evidencia descriptiva e inferencial

Pregunta	Dimensión	Esc.	Indicador	Medida del efecto	Decisión	mejor descriptivo	mejor inferencial	mejor KPI final
PE.1	flexibilidad energética	E1	reward_mean_average	H=36.3083; p=1.30545e-08; epsilon2=0.2334 (efecto alto)	se rechaza H0	MAAC	MAAC	MASAC
PE.2	emisiones de CO_2	E2	district_emission	H=6.2532; p=0.0438656; epsilon2=0.0289 (efecto bajo)	se rechaza H0	HAPPO	MAAC	MASAC
PE.3	costos energéticos	E3	district_cost	H=2.7613; p=0.251421; epsilon2=0.0052 (efecto muy bajo)	no se rechaza H0	HAPPO	MATD3	MAAC

Nota. La tabla representa los componentes técnicos de la propuesta, arquitectura, algoritmos, recompensas y trazabilidad experimental. Fuente: Elaboración propia a partir del repositorio local, CityLearn v2, extensión CityLearn v3 propuesta, scripts de datase y corrida Drive madrl_v3_20260627_164047.

PE.1. ¿En que medida el algoritmo MADRL (VI) produce un efecto sobre la dimensión de flexibilidad energética de la comunidad (D-VD.1), y qué algoritmo genera el mayor efecto? Respuesta: en E1, el indicador reward_mean_average muestra los siguientes promedios episódicos conservados: MAAC=-0.605157 (n=50); MASAC=-0.613331 (n=50); HAPPO=-0.630260 (n=49); MATD3=-0.633044 (n=50). El efecto inferencial existe porque Kruskal-Wallis rechaza H0 (H=36.3083; p=1.30545e-08; epsilon2=0.2334, efecto alto). El mayor efecto descriptivo corresponde a MAAC; al exigir cobertura inferencial completa, corresponde a MAAC; y por KPI anual final corresponde a MASAC.

PE.2. ¿En que medida el algoritmo MADRL (VI) produce un efecto sobre la dimensión de emisiones de CO_2 de la comunidad (D-VD.2), y qué algoritmo genera el mayor efecto? Respuesta: en E2, el indicador district_emission muestra los siguientes promedios episódicos conservados: HAPPO=883.00 (n=49); MAAC=1,056.39 (n=50); MASAC=1,078.37 (n=50); MATD3=1,132.19 (n=50). El efecto inferencial existe porque Kruskal-Wallis rechaza H0

(H=6.2532; p=0.0438656; epsilon2=0.0289, efecto bajo). El mayor efecto descriptivo corresponde a HAPPO; al exigir cobertura inferencial completa, corresponde a MAAC; y por KPI anual final corresponde a MASAC.

PE.3. ¿En que medida el algoritmo MADRL (VI) produce un efecto sobre la dimensión de costos energéticos de la comunidad (D-VD.3), y qué algoritmo genera el mayor efecto? Respuesta: en E3, el indicador district_cost muestra los siguientes promedios episódicos conservados: HAPPO=352.57 (n=49); MATD3=759.29 (n=50); MAAC=795.39 (n=50); MASAC=812.16 (n=50). No se demuestra efecto inferencial suficiente en la muestra conservada porque Kruskal-Wallis no rechaza H0 (H=2.7613; p=0.251421; epsilon2=0.0052, efecto muy bajo). El mayor efecto descriptivo corresponde a HAPPO; al exigir cobertura inferencial completa, corresponde a MATD3; y por KPI anual final corresponde a MAAC.

Por tanto, el Capítulo 4 deja definido el mecanismo de respuesta: PE.1 se responde con flexibilidad en E1, PE.2 con emisiones de CO_2 en E2 y PE.3 con costos en E3. El Capítulo 5 desarrolla la contrastación, figuras, tablas por edificio y ranking CityLearn v2, pero la relación pregunta-variable-indicador-decisión queda fijada aquí para mantener continuidad entre problema, propuesta y resultados.

CAPÍTULO V. RESULTADOS Y CONTRASTACIÓN DE HIPÓTESIS

Este capítulo presenta la evidencia de la corrida canónica (madrl_v3_20260627_164047) en cumplimiento de los objetivos, con cinco acápites: (5.2) resultados descriptivos estadísticos del OG y OE.1–OE.3 de forma independiente; (5.3) resultados inferenciales estadísticos del OG y OE.1–OE.3 de forma independiente; (5.4) otros resultados del OG y OE.1–OE.3 de forma independiente; (5.5) contrastación de hipótesis (H0G/H1G y HE nulas/alternativas por objetivo); (5.6) discusión de resultados. El marco experimental (§5.1) precede.

5.1. Mapa de lectura del capitulo

Tabla 23

Estructura del Capítulo 5 por numerales y objetivos

Numeral	Bloque	Contenido (independiente por objetivo)
5.1	Marco	Cobertura experimental 4x3 y operacionalización OE/OG
5.2	Descriptivos	5.2.1 OG; 5.2.2 OE.1; 5.2.3 OE.2; 5.2.4 OE.3
5.3	Inferenciales	5.3.1 OG; 5.3.2 OE.1; 5.3.3 OE.2; 5.3.4 OE.3
5.4	Otros resultados	5.4.1 OG; 5.4.2 OE.1; 5.4.3 OE.2; 5.4.4 OE.3; 5.4.5 Control de recursos (C5)
5.5	Contrastación de hipótesis	5.5.1 H0G/H1G; 5.5.2 HE10/HE11; 5.5.3 HE20/HE21; 5.5.4 HE30/HE31; 5.5.5 Cumplimiento C1–C5
5.6	Discusión	Interpretación integrada y limitaciones

Cadena vertical Cap. 1 → Cap. 5: PG ↔ OG ↔ H0G/H1G; PE.1 ↔ OE.1 ↔ HE10/HE11 (E1); PE.2 ↔ OE.2 ↔ HE20/HE21 (E2); PE.3 ↔ OE.3 ↔ HE30/HE31 (E3). Formulaciones exactas del autor; no parafrasear. Fuente unica: resultados guardados de 50 episodios Drive en outputs/. Determinación del impacto = criterios C1–C5 (§5.1.1), con C5 = control de recursos; cada eje a nivel distrito y edificio. TOPSIS (medida multicriterio formal adicional; C* MAAC ≈ 0,9827) y ranking evaluate_v2 4/4 (MAAC 0,9538) apoyan la determinación multiobjetivo de OG/OE; HE11/HE21/HE31 se contrastan con KPI-gains (impacto significativo y diferencias) + C3–C5, complementados por TOPSIS/evaluate_v2.

5.2. Marco experimental y cobertura

Tabla 24

Operacionalización OG/OE → escenario → KPI.

Objetivo	Escenario	VD	KPI principal	Pesos
OE.1 Flexibilidad	E1	D-VD.1	flex_composite / KPI-gains	[0,70; 0,15; 0,15]
OE.2 Emisiones	E2	D-VD.2	carbon_emissions_delta	[0,15; 0,70; 0,15]

CO2				
OE.3 Costos	E3	D-VD.3	electricity_cost_delta	[0,25; 0,15; 0,60]
OG Coordinación	E1–E3	Multiobjetivo	best_madrl + integración	—

Tabla 25
Cobertura de episodios y KPIs finales.

Algoritmo	E1	E2	E3	KPIs finales	Uso
MATD3	50	50	50	Si	Descriptivo + inferencial canónico
MAAC	50	50	50	Si	Descriptivo + inferencial canónico
MASAC	50	50	50	Si	Descriptivo + inferencial canónico
HAPPO	49	49	49	Si (Drive 2026-07-28)	Descriptivo 4/4; HE canónica 3x3

5.2.1. Criterios de determinación del impacto (cumplimiento completo)

Para cumplir OG/OE.1–OE.3 y demostrar las hipótesis no basta un ranking descriptivo. La determinación del impacto exige el conjunto completo de criterios C1–C5. C5 (control de recursos) es obligatorio: el efecto MADRL solo es atribuible a las acciones sobre BESS, cargadores EV/V2G y carga desplazable. Cada eje OE se reporta a nivel distrito y a nivel edificio.

Tabla 26
Criterios completos de determinación del impacto (C5 = control de recursos).

D	Criterio	Medida / prueba	Rol	Artefacto
1	Impacto vs baseline	Wilcoxon KPI-gains vs cero + Holm	Inferencial HE (necesario)	KPI-gains distrito (evaluate_v2)
2	Diferencias entre algoritmos	Kruskal-Wallis / Friedman + post hoc	Inferencial HE (necesario)	KPI-gains / integración multi-eje
3	KPIs físicos de distrito por eje	flex_composite / ΔCO2 / Costo	Descriptivo OE.1–OE.3	district_objectives_by_algorithm.csv
4	KPIs desagregados por edificio por eje	17 edificios × E1/E2/E3	Descriptivo OE.1–OE.3	building_objectives_by_algorithm.csv
5	Control de recursos	BESS, EV/V2G, carga desplazable (acciones y éxito EV)	Obligatorio (atribuibilidad del impacto)	inventario + traces + EV success

Regla de cumplimiento sin parciales: un OE se considera documentado solo si C3+C4 (distrito y edificio del eje) y C5 (control de recursos) están presentes junto con C1+C2 en la contrastación HE. TOPSIS y evaluate_v2 4/4 son medidas formales adicionales que refuerzan el juicio de OG/OE/HE junto a C1–C5, sin reemplazar el conjunto de criterios de impacto.

5.3. Resultados descriptivos estadísticos

Primer acápite de resultados en cumplimiento de los objetivos. Estadística descriptiva sobre los 50 episodios Drive en outputs/, con subacapites independientes para OG, OE.1, OE.2 y OE.3. Cada OE documenta C3 (distrito) y C4 (edificio). TOPSIS (C* MAAC ≈ 0,9827) y evaluate_v2 4/4 (MAAC 0,9538) son medidas formales adicionales para la determinación multiobjetivo de OG/OE y el contraste de HE; complementan KPI-gains sin sustituir el ómnibus.

5.3.1. Resultados descriptivos estadísticos

Se determina el impacto de los algoritmos aprendizaje por refuerzo profundo multiagente (MADRLs) en la gestión coordinada de la flexibilidad energética, las emisiones de CO_2 y los costos energéticos en comunidades inteligentes de la ciudad de Iquitos, e identificar cuál de los algoritmos presenta el mejor desempeño a nivel global.

Tabla 27
Ranking descriptivo integrado (best_madrl_report.json, canónico 3x3).

Rango	Algoritmo	Global	OE.1	OE.2	OE.3
1	MATD3	0.6667	1.0000	1.0000	0.0000
2	MAAC	0.5706	0.5837	0.1282	1.0000
3	MASAC	0.2351	0.0000	0.0000	0.7054

Lectura descriptiva del OG / PG: MATD3 obtiene el mejor score global (0,6667) al liderar OE.1 y OE.2; MAAC lidera OE.3. No hay dominador Pareto único. El ranking evaluate_v2 4/4 (incluye HAPPO) confirma a HAPPO en último lugar (score 0). El cumplimiento completo del OG exige además C1–C5 (5.1.1), con control de recursos en 5.4.5.

5.3.2. OE.1 - resultados descriptivos estadísticos

PE.1: ¿En qué medida el algoritmo MADRL impacta en la flexibilidad energética en comunidades inteligentes de la ciudad de Iquitos, y cuál de los algoritmos presenta el mejor desempeño en el escenario E1?

OE.1: Determinar el impacto de los algoritmos MADRLs en la flexibilidad energética en comunidades inteligentes de la ciudad de Iquitos e identificar cuál de los algoritmos presenta el mejor desempeño en el escenario E1.

Evidencia descriptiva en escenario E1 (pesos [0,70; 0,15; 0,15]), calculada sobre los 50 episodios Drive en outputs/. Se reportan KPIs a nivel distrito y a nivel edificio (criterios C3 y C4); no se decide hipótesis aquí.

Tabla 28
KPIs distritales OE.1 en E1 (descriptivo).

Algoritmo	Flexibilidad compuesta	Pico promedio	Ramping promedio	1 − factor de carga	Delta importación red (kWh)	Éxito salido EV
MATD3	1.0009	1.0081	1.0012	0.9935	44,795	43.9%
MAAC	1.0124	1.0307	1.0110	0.9956	8,025	4.2%
MASAC	1.0286	1.0851	1.0220	0.9786	29,499	3.9%

Tabla 29
Ranking descriptivo OE.1 (best_madrl_report.json).

Algoritmo	Score OE1	Mayor efecto OE1
MATD3	1.0000	Si
MAAC	0.5837	No
MASAC	0.0000	No

Tabla 30
Descriptivo episódico OE.1 (reward_mean por episodio).

Algoritmo	n ep.	Media	Mediana	Desv. est.
MAAC	50	-0.6052	-0.6126	0.0147
MASAC	50	-0.6133	-0.6198	0.0141
MATD3	50	-0.6330	-0.6208	0.0470
HAPPO	49	-0.6303	-0.6303	0.0213

Lectura descriptiva OE.1: líder por KPI primario de distrito = MATD3 (Flexibilidad compuesta = 1.0009); mejor mediana episódica = MAAC.

Figura 1
KPIs multiobjetivo a nivel distrito (OE.1–OE.3; criterio C3).

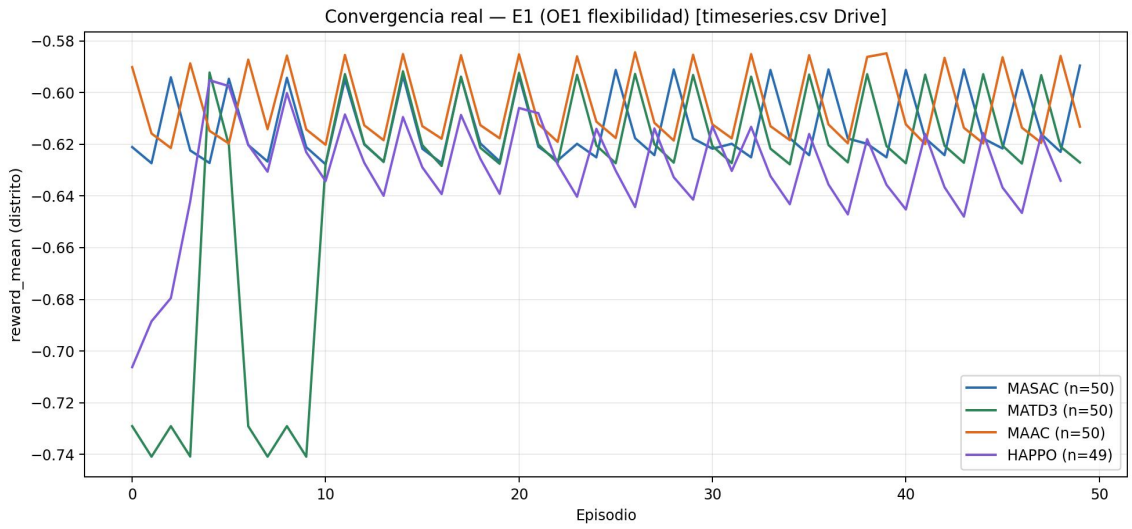

Figura 2
OE.1 a nivel edificio - Flexibilidad compuesta (criterio C4).

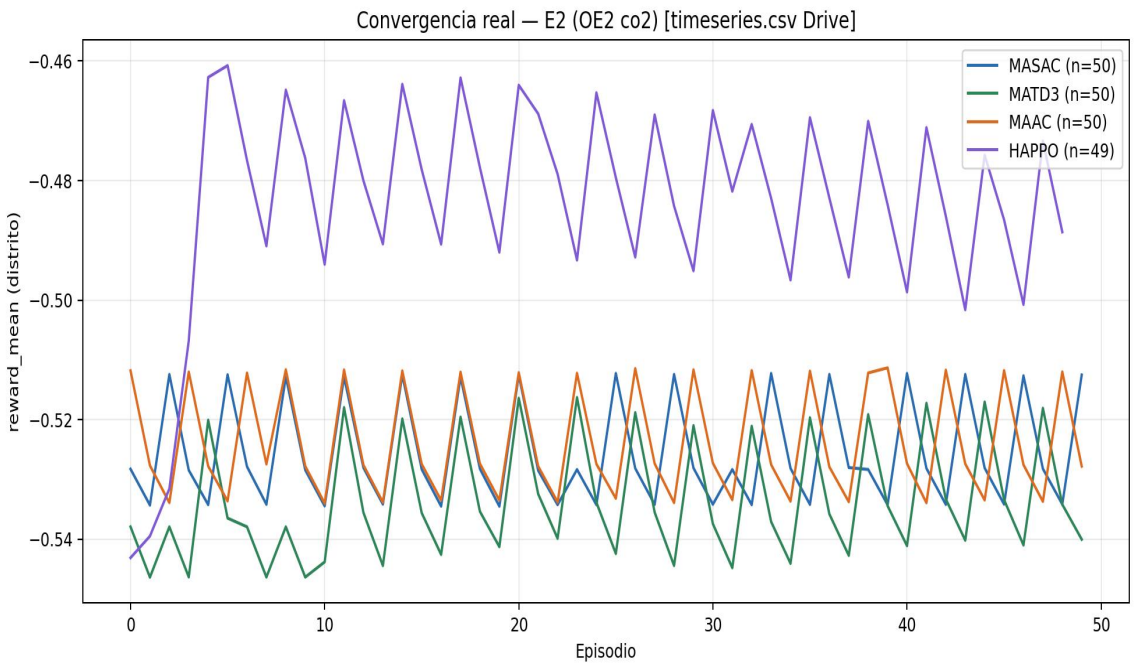

Criterios C3/C4 en OE.1: el KPI primario se interpreta a nivel distrito (Tabla 5.2.2) y a nivel de los 17 edificios (figura precedente). El criterio C5 (control de recursos) se documenta en §5.4.5.

5.3.3. OE.2 - resultados descriptivos estadísticos

PE.2: ¿En qué medida el algoritmo MADRL impacta en las emisiones de CO_2 en comunidades inteligentes de la ciudad de Iquitos, y cuál de los algoritmos presenta el mejor desempeño en el escenario E2?

OE.2: Determinar el impacto de los algoritmos MADRLs en las emisiones de CO_2 en comunidades inteligentes de la ciudad de Iquitos e identificar cuál de los algoritmos presenta el mejor desempeño en el escenario E2.

Evidencia descriptiva en escenario E2 (pesos [0,15; 0,70; 0,15]), calculada sobre los 50 episodios Drive en outputs/. Se reportan KPIs a nivel distrito y a nivel edificio (criterios C3 y C4); no se decide hipótesis aquí.

Tabla 31
KPIs distritales OE.2 en E2 (descriptivo).

Algoritmo	Delta CO2 (kg)	Flexibilidad compuesta (secundaria)	Delta importación red (kWh)	Éxito salido EV
MATD3	23,070	1.0007	26,169	36.4%
MAAC	70,654	1.0172	24,930	4.1%
MASAC	77,649	1.0318	28,207	4.1%

Tabla 32
Ranking descriptivo OE.2 (best_madrl_report.json).KPIs distritales

Algoritmo	Score OE2	Mayor efecto OE2
MATD3	1.0000	Si
MAAC	0.1282	No
MASAC	0.0000	No

Con formato[Mac Tapia Ccoyso]: No mantener con siguiente

Tabla 33
Descriptivo episódico OE.2 (emisión distrital por episodio (kgCO2 eq.))

Algoritmo	n ep.	Media	Mediana	Desv. est.
HAPPO	49	883.0	804.8	287.0
MAAC	50	1,056.4	1,132.6	99.4
MASAC	50	1,078.4	1,132.6	121.1
MATD3	50	1,132.2	1,137.4	236.8

Lectura descriptiva OE.2: líder por KPI primario de distrito = MATD3 (Delta CO2 (kg) = 23,070); mejor mediana episódica = HAPPO.

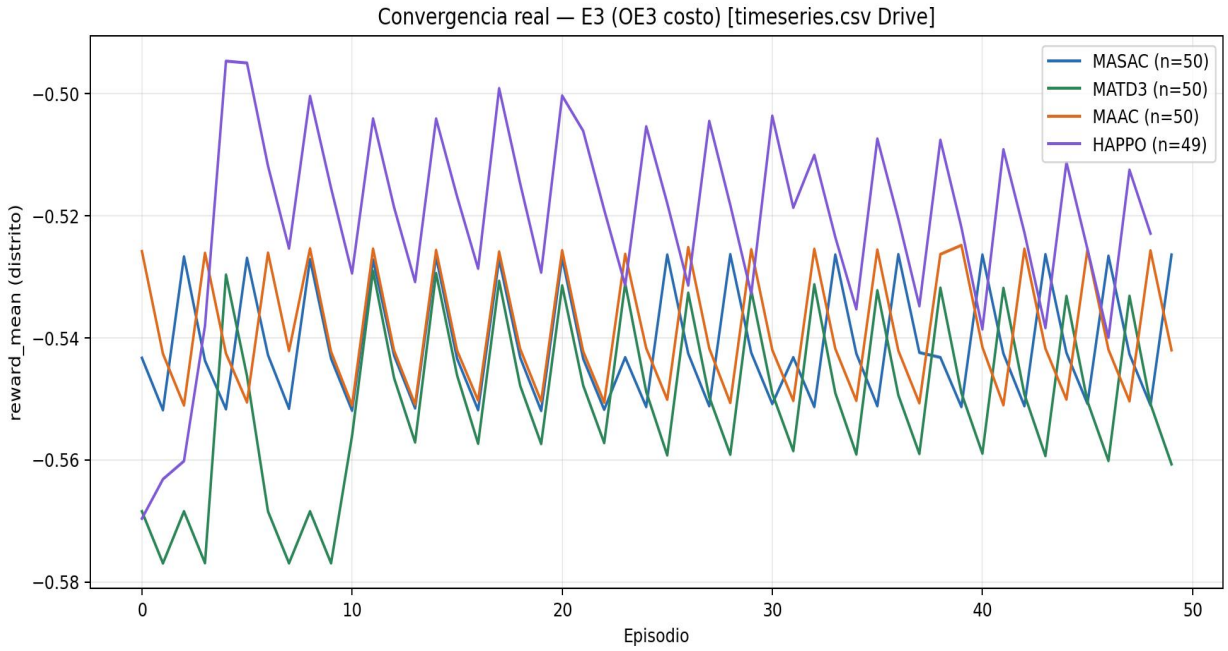

Figura 5.3. OE.2 a nivel edificio - Delta CO2 (kg) (criterio C4).

Criterios C3/C4 en OE.2: el KPI primario se interpreta a nivel distrito (Tabla 5.2.3) y a nivel de los 17 edificios (figura precedente). El criterio C5 (control de recursos) se documenta en §5.4.5.

5.3.4. OE.3 - resultados descriptivos estadísticos

PE.3: ¿En qué medida el algoritmo MADRL impacta en los costos energéticos en comunidades inteligentes de la ciudad de Iquitos, y cuál de los algoritmos presenta el mejor desempeño en el escenario E3?

OE.3: Determinar el impacto de los algoritmos MADRLs en los costos energéticos en comunidades inteligentes de la ciudad de Iquitos e identificar cuál de los algoritmos presenta el mejor desempeño en el escenario E3.

Evidencia descriptiva en escenario E3 (pesos [0,15; 0,15; 0,70]), calculada sobre los 50 episodios Drive en outputs/. Se reportan KPIs a nivel distrito y a nivel edificio (criterios C3 y C4); no se decide hipótesis aquí.

Tabla 34
KPIs distritales OE.3 en E3 (descriptivo).

Algoritmo	Delta costo electrico (EUR)	Flexibilidad compuesta (secundaria)	Pico promedio	Éxito salida EV
MAAC	9,515	1.0138	1.0309	4.1%
MASAC	19,793	1.0297	1.0864	4.1%
MATD3	44,399	1.0006	1.0071	48.2%

Tabla 5.2.4b. Ranking descriptivo OE.3 (best_madrl_report.json).

Algoritmo	Score OE3	Mayor efecto OE3
MAAC	1.0000	Si
MASAC	0.7054	No
MATD3	0.0000	No

Tabla 5.2.4c. Descriptivo episódico OE.3 (costo distrital por episodio (EUR)).

Algoritmo	n ep.	Media	Mediana	Desv. est.
HAPPO	49	352.6	232.5	381.7
MAAC	50	795.4	689.5	212.0
MASAC	50	812.2	689.5	206.4
MATD3	50	759.3	691.0	303.9

Lectura descriptiva OE.3: líder por KPI primario de distrito = MAAC (Delta costo electrico (EUR) = 9,515); mejor mediana episódica = HAPPO.

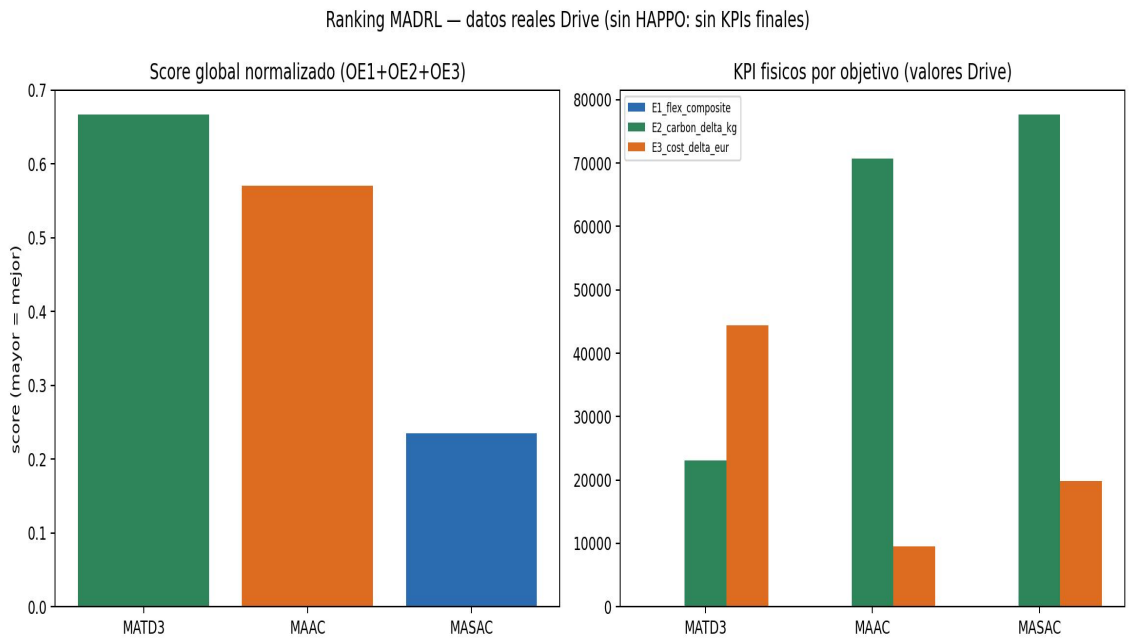

Figura 5.4. OE.3 a nivel edificio - Delta costo electrico (EUR) (criterio C4).

Criterios C3/C4 en OE.3: el KPI primario se interpreta a nivel distrito (Tabla 5.2.4) y a nivel de los 17 edificios (figura precedente). El criterio C5 (control de recursos) se documenta en §5.4.5.

5.4. Resultados inferenciales estadísticos

Segundo acápite. Pruebas sobre KPI-gains de los 50 episodios Drive (outputs/madrl_v3_20260627_164047/resumen_comparativo/estadistica/problemas_objetivos_hipotesis/), alpha = 0,05. Subacapites independientes OG, OE.1, OE.2 y OE.3. El ómnibus de hipótesis usa KPI-gains (§5.5); TOPSIS y evaluate_v2 4/4 aportan la medida multicriterio/ranking adicional para contrastar OG/OE/HE en clave multiobjetivo.

5.4.1. OG - resultados inferenciales estadísticos

Tabla 5.3.1a. Shapiro-Wilk OG (KPI-gains 50 ep Drive).

Alcance	Hipotesis	Algoritmo	p (SW)	Normalidad rechazada
Global (ALL)	HG	MASAC	3.033e-12	Si
Global (ALL)	HG	MATD3	7.337e-12	Si
Global (ALL)	HG	MAAC	8.356e-12	Si

Contraste inferencial del OG (alimenta H0G/H1G; decisión formal en §5.5.1).

Pruebas sobre la integración multi-eje. Shapiro rechaza normalidad en ALL; ruta paramétrica descartada. Se reportan Kruskal-Wallis y Friedman sobre KPI-gains.

Tabla 5.3.1b. Kruskal-Wallis OG / ALL.

Alcance	Hipotesis	H	p	Signif.	Mejor mediana
Global (ALL)	HG	3.723	0.1554	No	MATD3

Referencia integrada (50 ep Drive): Friedman pareado p = 0,0096 (W = 0,1787); KW ALL KPI-gains p = 0,1554; KW scores globales p = 0,4044.

5.4.2. OE.1 - resultados inferenciales estadísticos

Tabla 5.3.2a. Shapiro-Wilk OE.1 (KPI-gains 50 ep Drive).

Alcance	Hipotesis	Algoritmo	p (SW)	Normalidad rechazada
OE.1 / E1	HE.1	MASAC	9.508e-08	Si
OE.1 / E1	HE.1	MATD3	2.230e-07	Si
OE.1 / E1	HE.1	MAAC	2.363e-07	Si

Contraste inferencial de HE10/HE11 (decisión formal independiente en §5.5).

Puerta Shapiro: normalidad rechazada en OE.1. Ruta paramétrica descartada. Kruskal-Wallis p = 0.2806 (KPI-gains, problemas_objetivos_hipotesis/).

Tabla 5.3.2b. Kruskal-Wallis OE.1.

Alcance	Hipotesis	H	p	Signif.	Mejor mediana
OE.1 / E1	HE.1	2.541	0.2806	No	MAAC

Tabla 5.3.2c. Mann-Whitney U OE.1.

Alcance	Hipotesis	Par	U	p	Signif.
OE.1 / E1	HE.1	MASAC vs MATD3	521.500	0.1543	No
OE.1 / E1	HE.1	MASAC vs MAAC	538.500	0.2179	No
OE.1 / E1	HE.1	MATD3 vs MAAC	692.500	0.6193	No

Tabla 5.3.2d. Wilcoxon OE.1.

Alcance	Par	p Wilcoxon
OE1	MASAC vs MATD3	0.0410
OE1	MASAC vs MAAC	0.0013

5.4.3. OE.2 - resultados inferenciales estadísticos

Tabla 5.3.3a. Shapiro-Wilk OE.2 (KPI-gains 50 ep Drive).

Alcance	Hipotesis	Algoritmo	p (SW)	Normalidad rechazada
OE.2 / E2	HE.2	MASAC	7.112e-05	Si
OE.2 / E2	HE.2	MATD3	7.862e-05	Si
OE.2 / E2	HE.2	MAAC	6.759e-05	Si

Contraste inferencial de HE20/HE21 (decisión formal independiente en §5.5).

Puerta Shapiro: normalidad rechazada en OE.2. Ruta paramétrica descartada. Kruskal-Wallis p = 0.5457 (KPI-gains, problemas_objetivos_hipotesis/).

Tabla 5.3.3b. Kruskal-Wallis OE.2.

Alcance	Hipotesis	H	p	Signif.	Mejor mediana
OE.2 / E2	HE.2	1.211	0.5457	No	MATD3

Tabla 5.3.3c. Mann-Whitney U OE.2.

Alcance	Hipotesis	Par	U	p	Signif.
OE.2 / E2	HE.2	MASAC vs MATD3	93.000	0.4154	No
OE.2 / E2	HE.2	MASAC vs MAAC	90.000	0.3457	No
OE.2 / E2	HE.2	MATD3 vs MAAC	126.000	0.5774	No

Tabla 5.3.3d. Wilcoxon OE.2.

Alcance	Par	p Wilcoxon
OE2	MASAC vs MAAC	0.0077

5.4.4. OE.3 - resultados inferenciales estadísticos

Tabla 5.3.4a. Shapiro-Wilk OE.3 (KPI-gains 50 ep Drive).

Alcance	Hipotesis	Algoritmo	p (SW)	Normalidad rechazada
OE.3 / E3	HE.3	MASAC	1.539e-07	Si
OE.3 / E3	HE.3	MATD3	5.512e-08	Si
OE.3 / E3	HE.3	MAAC	7.369e-08	Si

Contraste inferencial de HE30/HE31 (decisión formal independiente en §5.5).

Puerta Shapiro: normalidad rechazada en OE.3. Ruta paramétrica descartada. Kruskal-Wallis p = 0.3881 (KPI-gains, problemas_objetivos_hipotesis/).

Tabla 5.3.4b. Kruskal-Wallis OE.3.

Alcance	Hipotesis	H	p	Signif.	Mejor mediana
OE.3 / E3	HE.3	1.893	0.3881	No	MAAC

Tabla 5.3.4c. Mann-Whitney U OE.3.

Alcance	Hipotesis	Par	U	p	Signif.
OE.3 / E3	HE.3	MASAC vs MATD3	276.000	0.2574	No
OE.3 / E3	HE.3	MASAC vs MAAC	271.000	0.2207	No
OE.3 / E3	HE.3	MATD3 vs MAAC	339.000	0.9927	No

Tabla 5.3.4d. Wilcoxon OE.3.

Alcance	Par	p Wilcoxon
OE3	MASAC vs MAAC	0.0333

5.5. Otros resultados

Tercer acápite. Resultados complementarios por objetivo (OG, OE.1, OE.2, OE.3) de forma independiente: convergencia, multiobjetivo distrito/edificio, baseline v2, TOPSIS como medida multicriterio formal adicional y control de recursos (C5). No sustituyen §5.2–5.3 ni 5.5.

5.5.1. OG - otros resultados (coordinación multiobjetivo)

Complementos del OG (medidas de soporte multiobjetivo para H0G/H1G/OE): ranking global Drive, best/worst por escenario, KPIs multiobjetivo de distrito y TOPSIS/AHP como medida multicriterio formal adicional (C* MAAC ≈ 0,9827; 50 ep Drive, real_drive_50ep_c1c6). El criterio C5 (control de recursos) se detalla en §5.4.5.

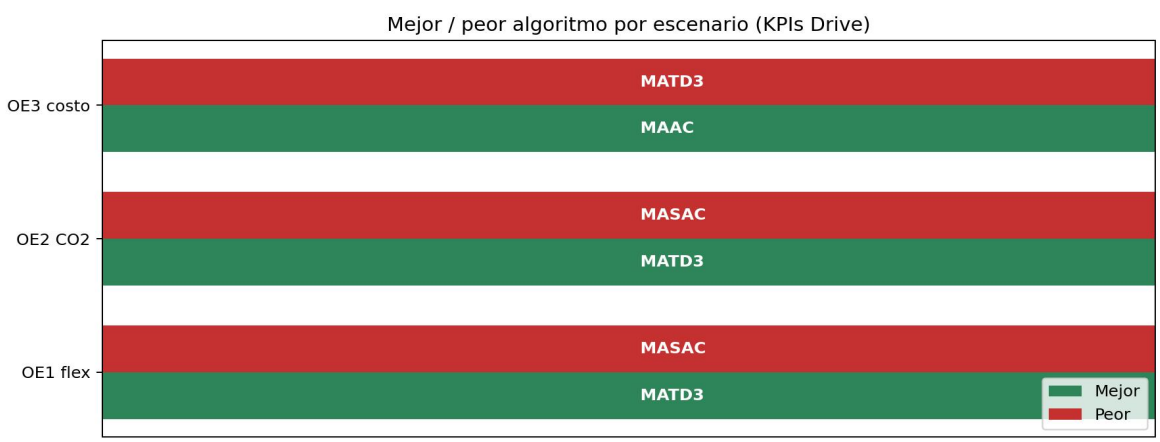

Figura 5.5. Ranking global OE.1/OE.2/OE.3 (OG).

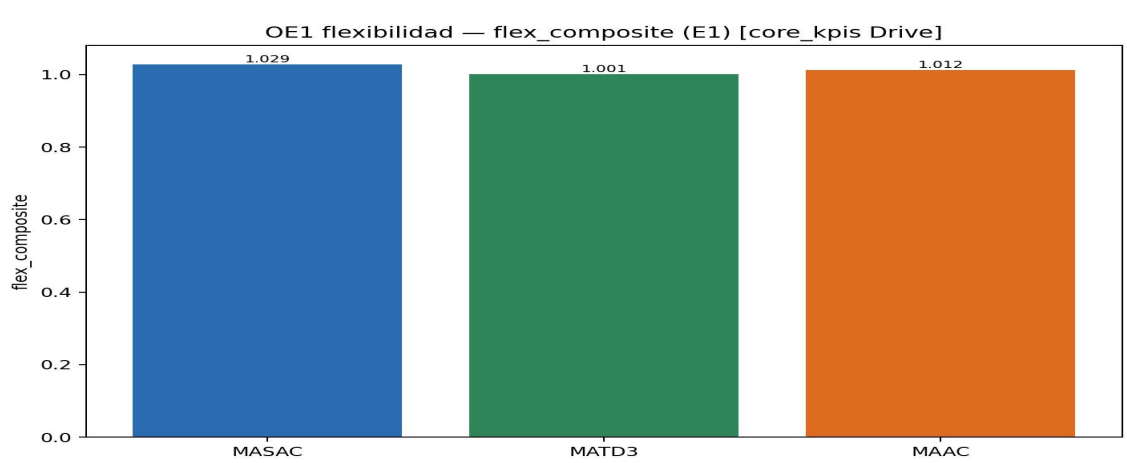

Figura 5.6. Mejor y peor MADRL por escenario.

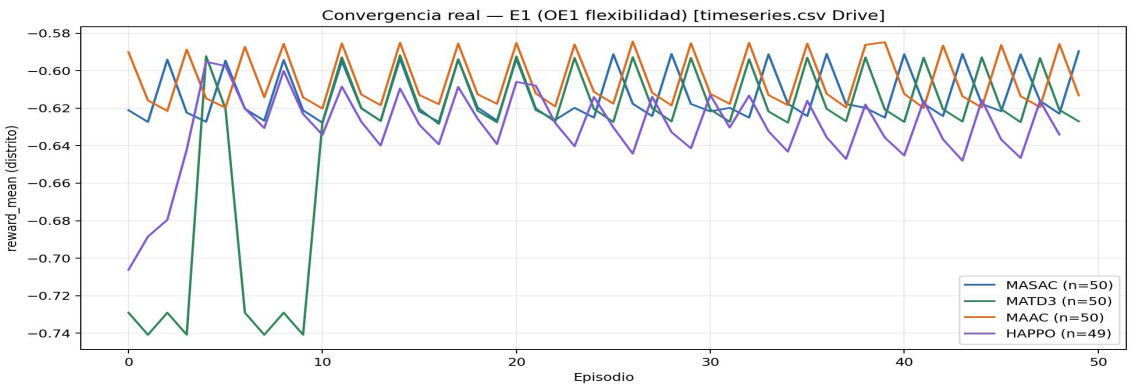

Figura 5.7. KPIs multiobjetivo a nivel distrito (C3).

Tabla 5.4.1. TOPSIS - medida multicriterio formal adicional (madrl_multicriteria_selection; C* canónicos; complementa OG/OE/HE junto a evaluate_v2).

Rank	Algoritmo	C* TOPSIS
1	MAAC	0.9827
2	MASAC	0.5656
3	MATD3	0.3074

Performance comparison por MADRL (distrito y edificio). Cada figura resume, sobre los 50 episodios Drive, (i) el efecto primario distrital vs baseline de los cuatro algoritmos en E1/E2/E3, con el algoritmo focal resaltado, y (ii) la heterogeneidad de los 17 edificios Iquitos en el KPI del eje. Lectura: en distrito, % negativo indica empeoramiento vs baseline; en edificio, Δ negativo indica reducción local. Son resultados descriptivos; no deciden HE10–HE31.

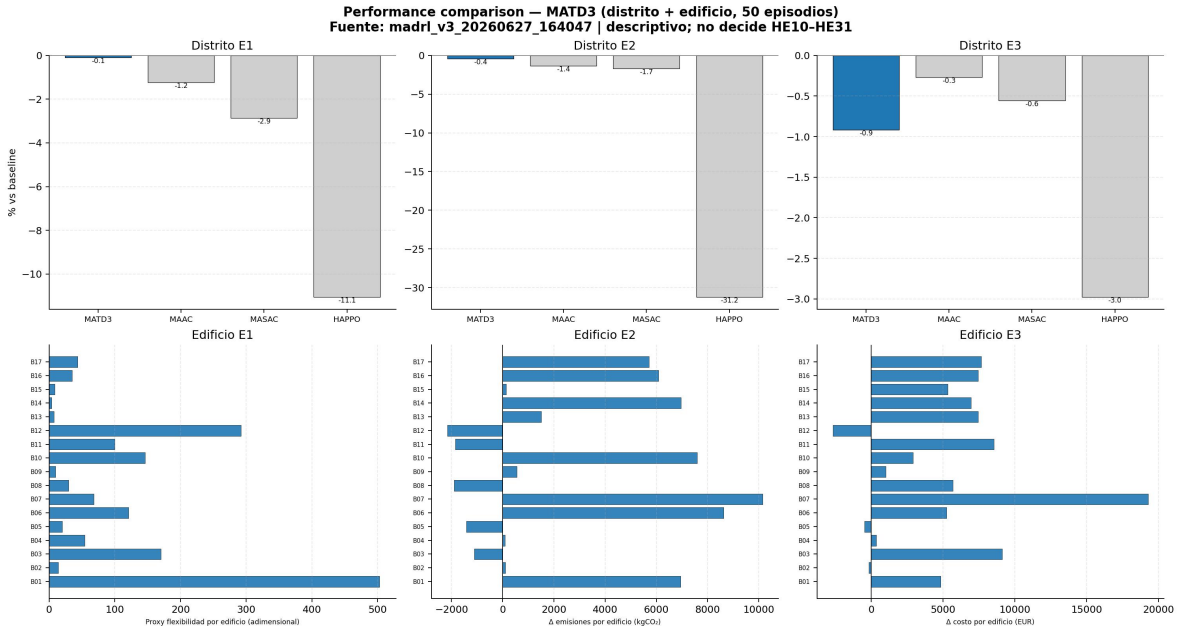

Figura 5.3e. Performance comparison - MATD3 (distrito + edificio, E1–E3).

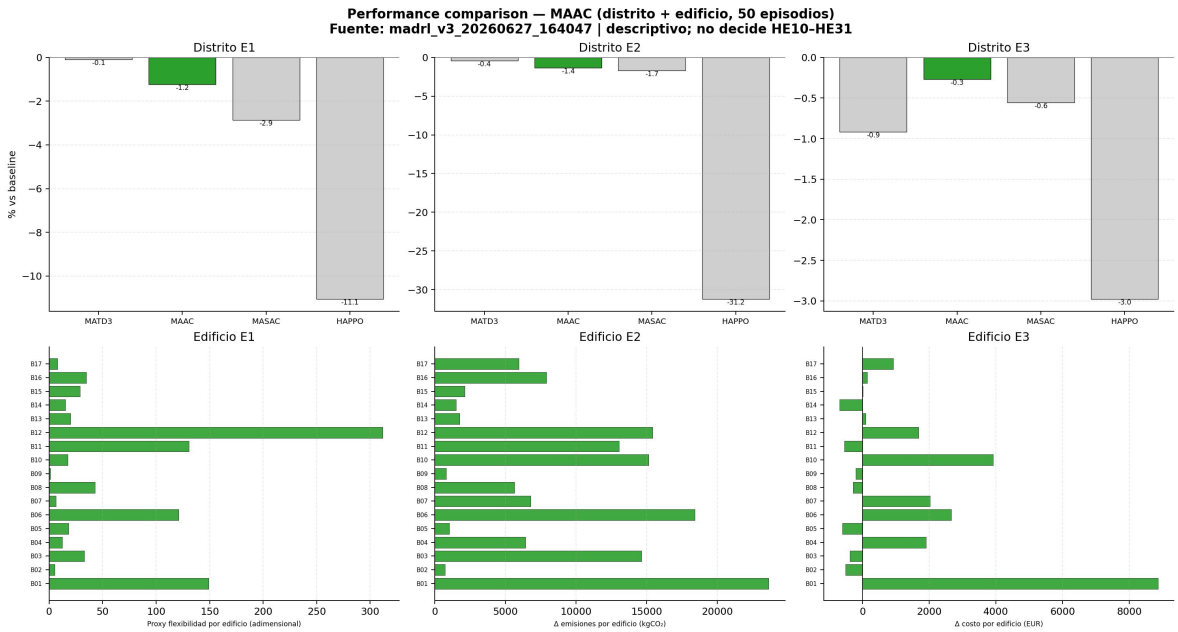

Figura 5.3f. Performance comparison - MAAC (distrito + edificio, E1–E3).

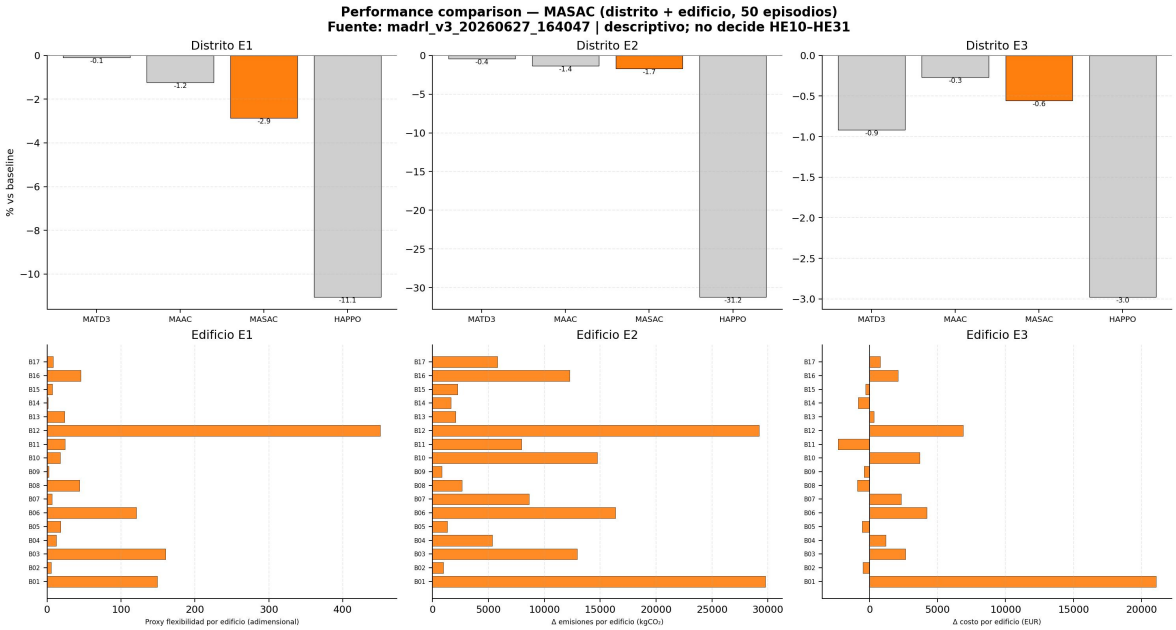

Figura 5.3g. Performance comparison - MASAC (distrito + edificio, E1–E3).

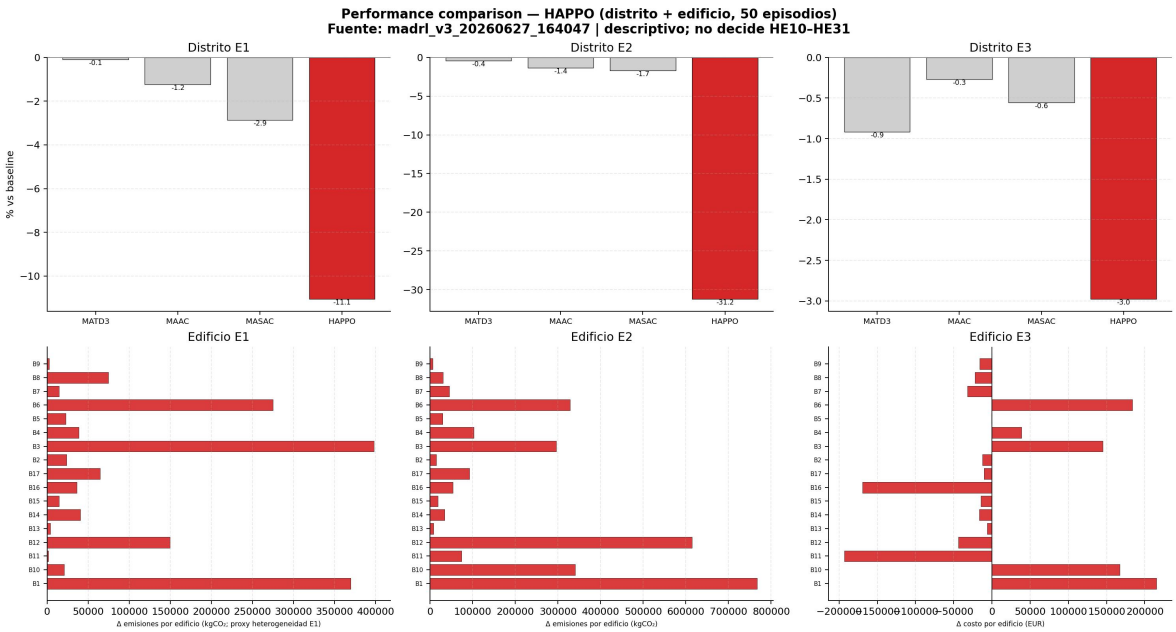

Figura 5.3h. Performance comparison - HAPPO (distrito + edificio, E1–E3).

Nota. Archivos en outputs/.../performance_comparison/{ALGO}_performance_comparison.png; también existe performance_comparison.png por job en {ALGO}/{E}/figures/. Mapping: performance_comparison_mapping.md.

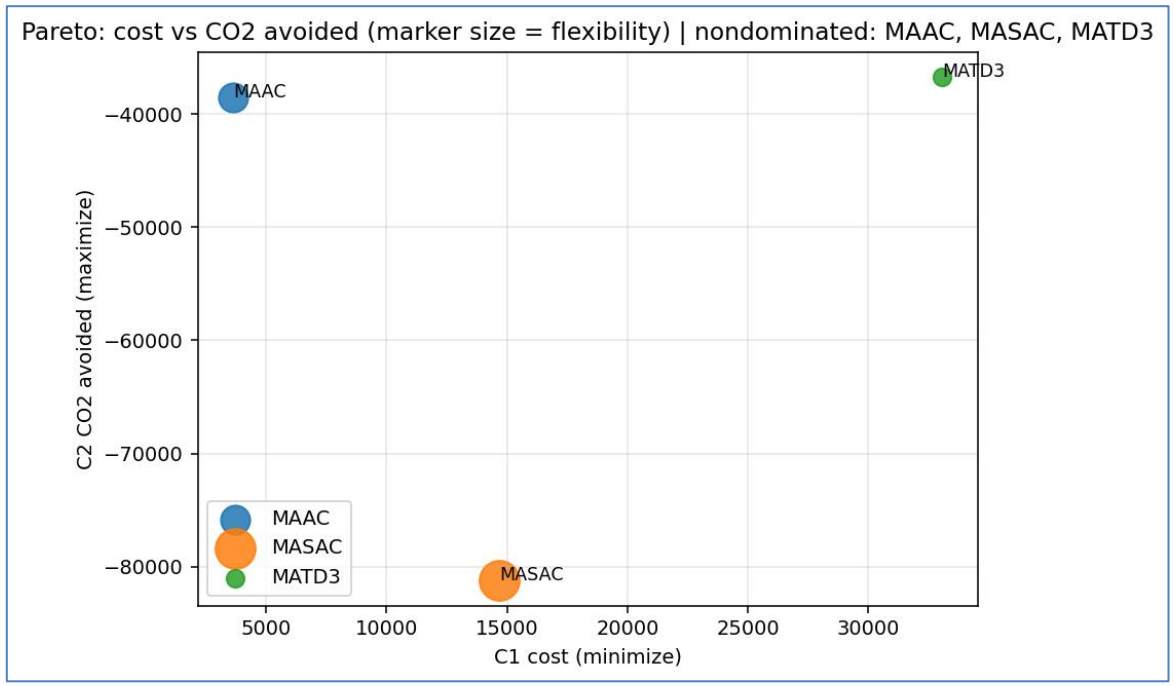

Figura 5.8. Multicriterio — frente de Pareto costo-CO2-flexibilidad (Drive 50 ep).

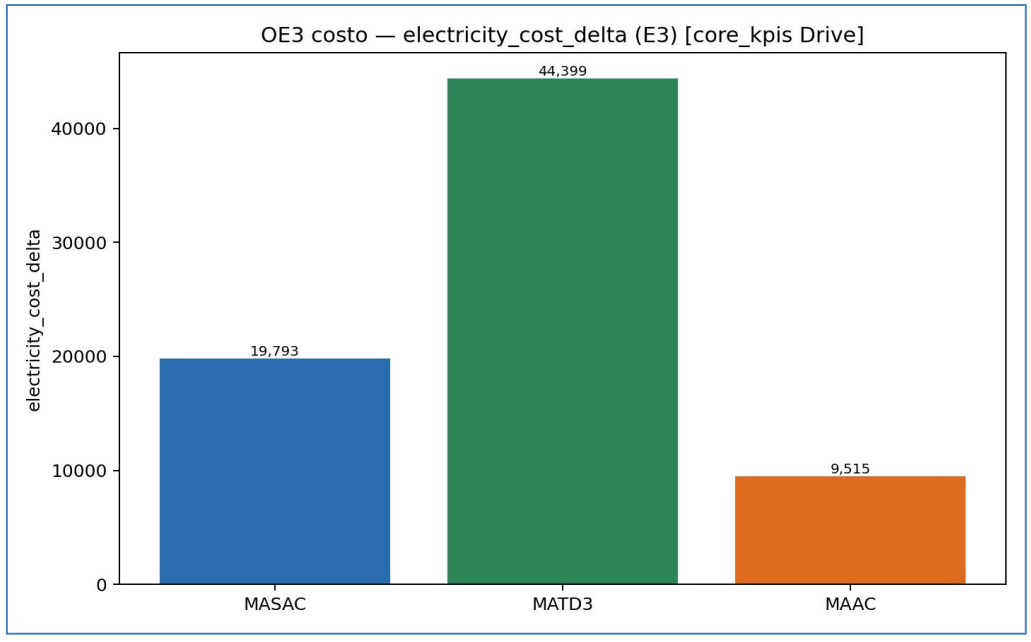

Figura 5.9. Multicriterio — curvas de aprendizaje (50 episodios).

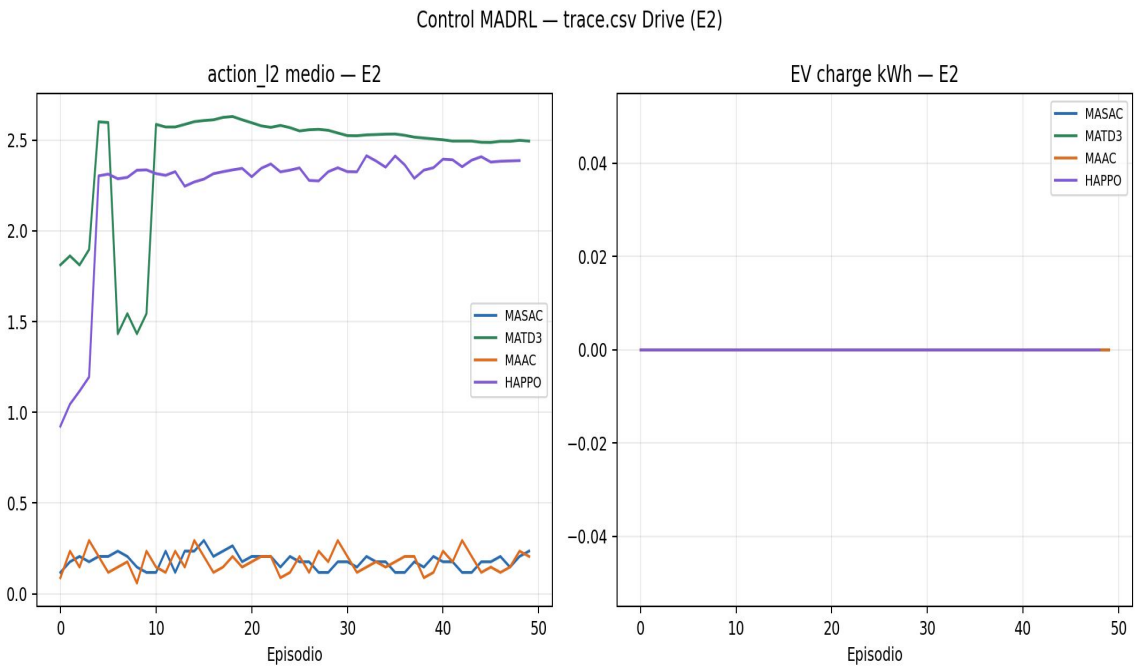

Figura 5.10. Multicriterio — barras de degradación.

5.5.2. Catálogo completo de figuras (multicriterio + performance distrito/edificio)

Integración completa — sin parciales — de artefactos reales de la corrida madrl_v3_20260627_164047 (50 episodios). Incluye multicriterio TOPSIS/AHP, resúmenes performance_comparison por MADRL y el catálogo íntegro por job (150 PNG en {ALGO}/{E}/figures/ + 3 multicriterio + 4 resúmenes). Incluye TOPSIS como medida multicriterio formal adicional para OG/OE/HE; complementa §5.3 y §5.5 (KPI-gains) sin sustituir el ómnibus.

CATALOGO_COMPLETO_FIGURAS_PERFORMANCE_50EP

A. Selección multicriterio (TOPSIS/AHP) — figuras

Complemento visual de la Tabla 5.4.1 TOPSIS. Pareto, curvas de aprendizaje y gap early–late (C6) regenerados 100% desde Drive 50 ep (madrl_v3_20260627_164047: district_objectives + episode_summary); exclusivamente con evidencia Drive 50 ep.

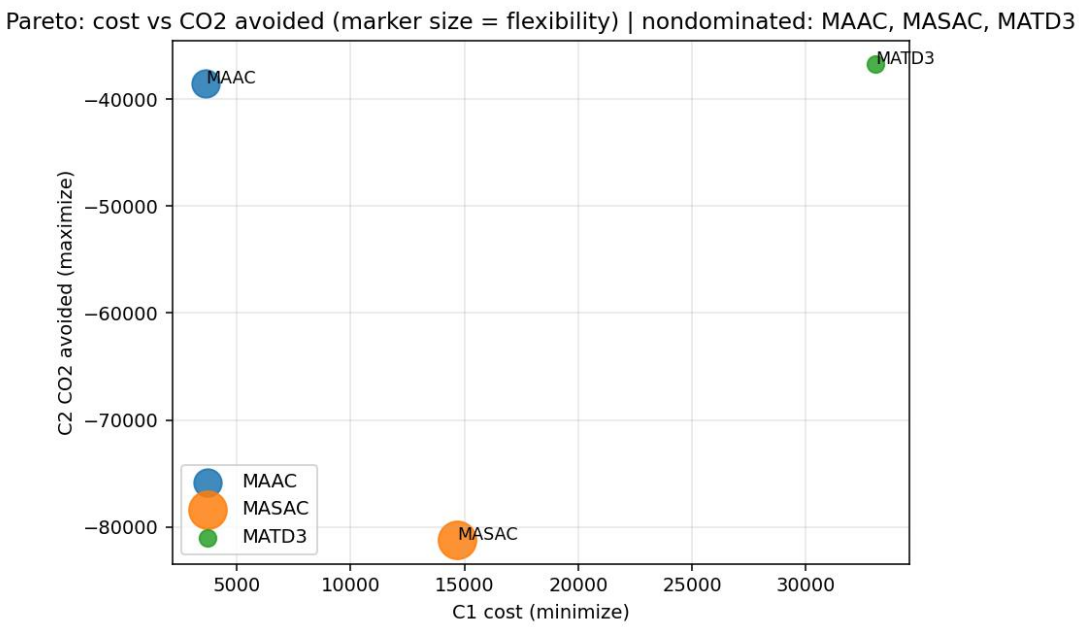

Figura MC.1. Multicriterio — frente de Pareto costo-CO2-flexibilidad (Drive 50 ep).

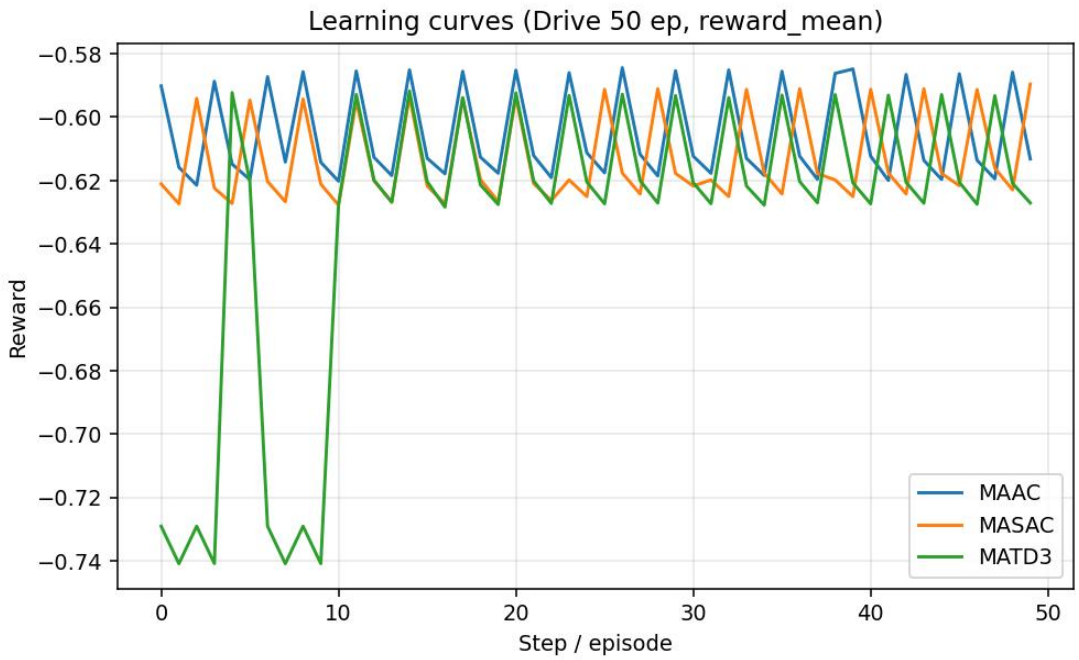

Figura MC.2. Multicriterio — curvas de aprendizaje reales (Drive 50 episodios).

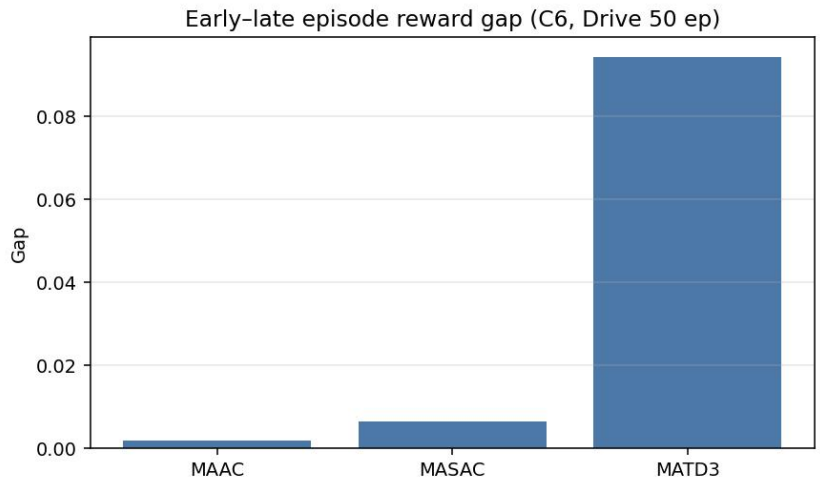

Figura MC.3. Multicriterio — gap early-late de reward episódico (C6, Drive 50 ep).

B. Performance comparison por MADRL (distrito + edificio, E1–E3)

Una figura por algoritmo: fila superior = efecto distrital % vs baseline de los cuatro MADRL (focal resaltado); fila inferior = heterogeneidad de 17 edificios.

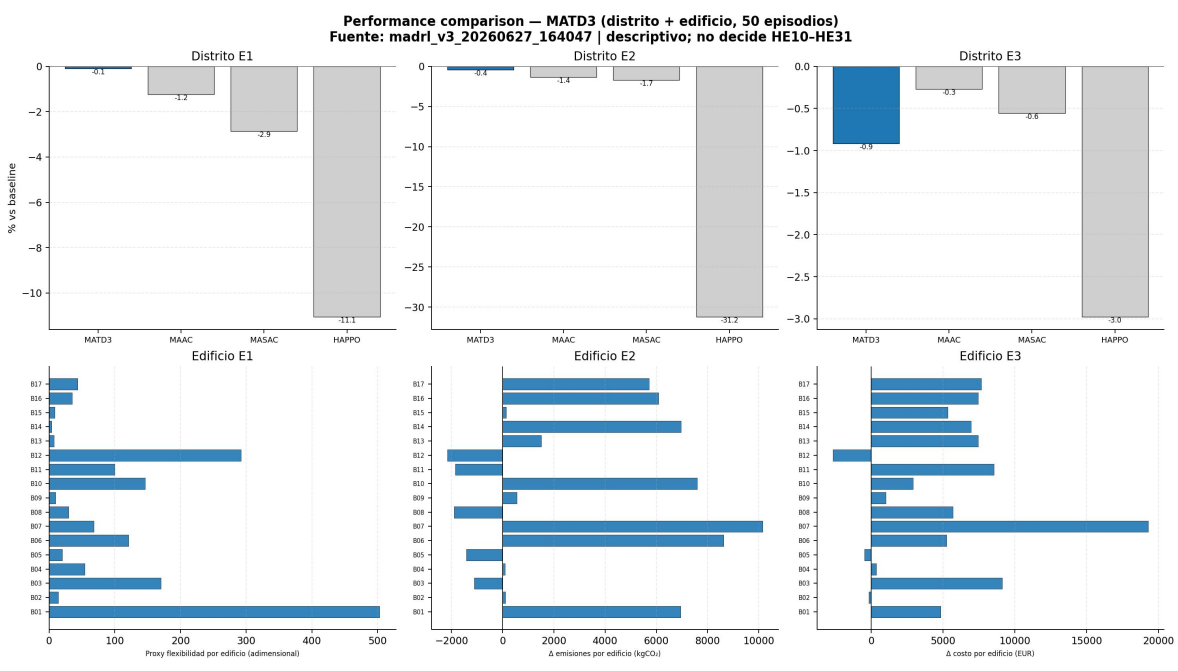

Figura PC-MATD3. Performance comparison — MATD3 (distrito + edificio, E1–E3).

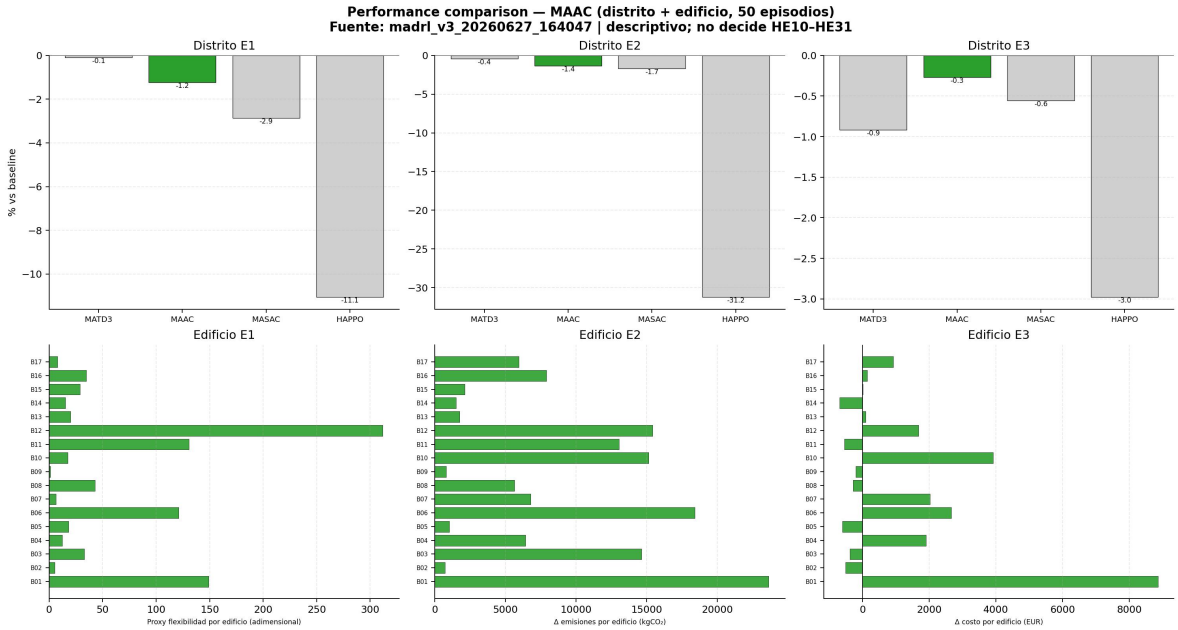

Figura PC-MAAC. Performance comparison — MAAC (distrito + edificio, E1–E3).

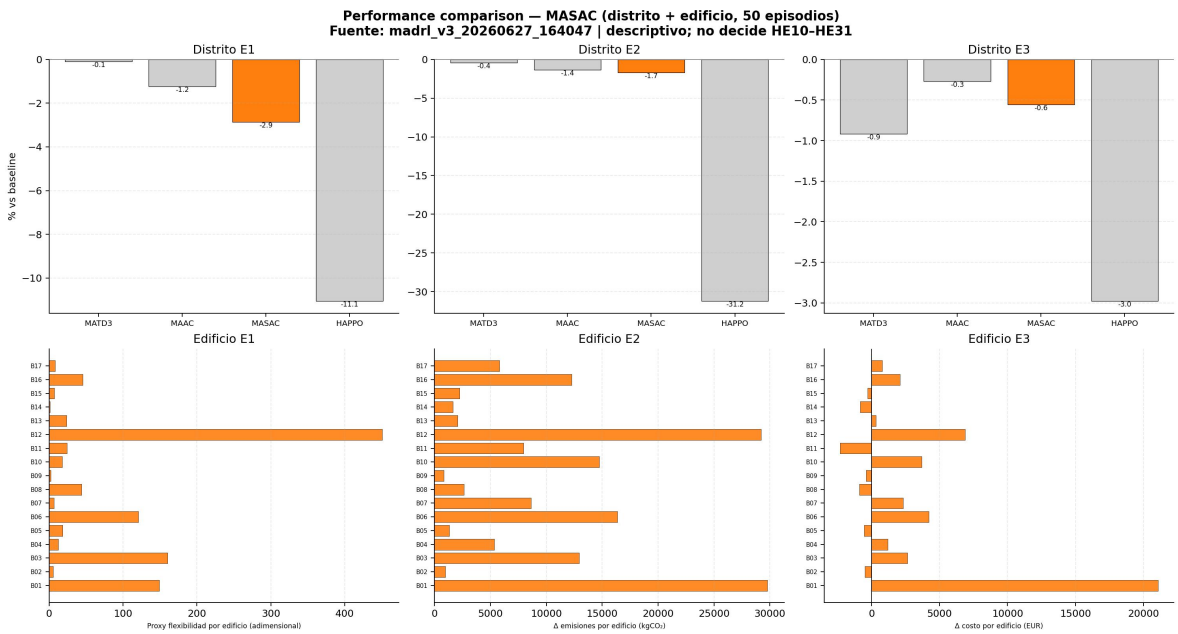

Figura PC-MASAC. Performance comparison — MASAC (distrito + edificio, E1–E3).

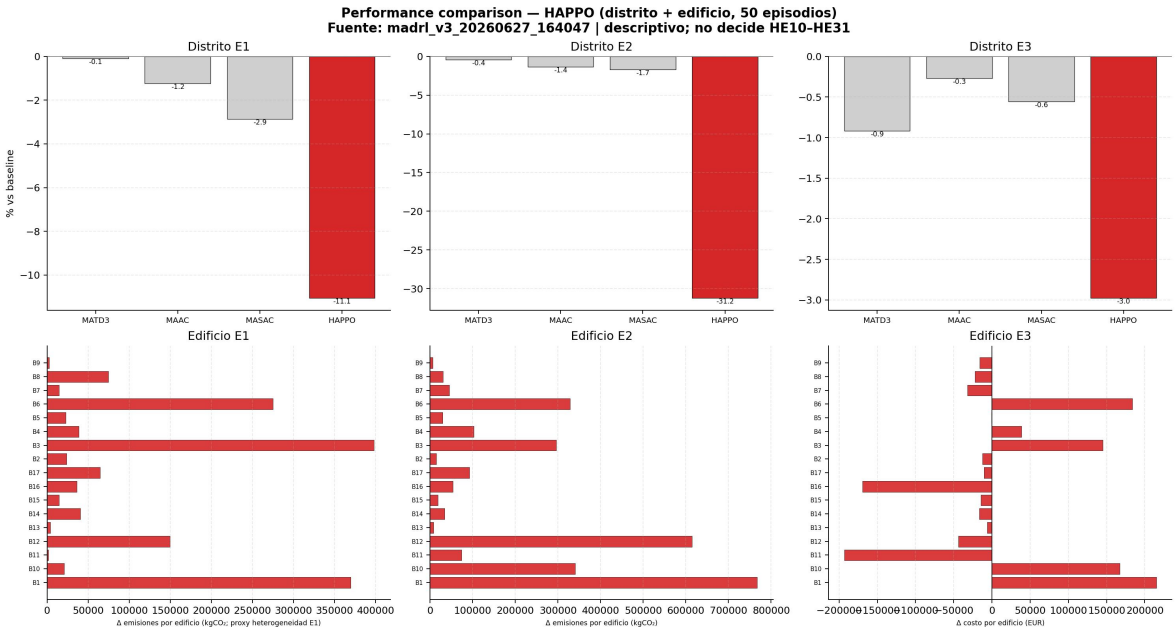

Figura PC-HAPPO. Performance comparison — HAPPO (distrito + edificio, E1–E3).

C. Catálogo completo por job (algoritmo × escenario)

Se embebe el inventario completo de figuras de performance/KPI por tratamiento. MATD3/MAAC/MASAC: 14 figuras × 9 jobs; HAPPO: 8 figuras × 3 jobs. Cada caption indica archivo, métrica y alcance (distrito/edificio/entrenamiento).

C.MATD3 — figuras de performance

MATD3 / E1

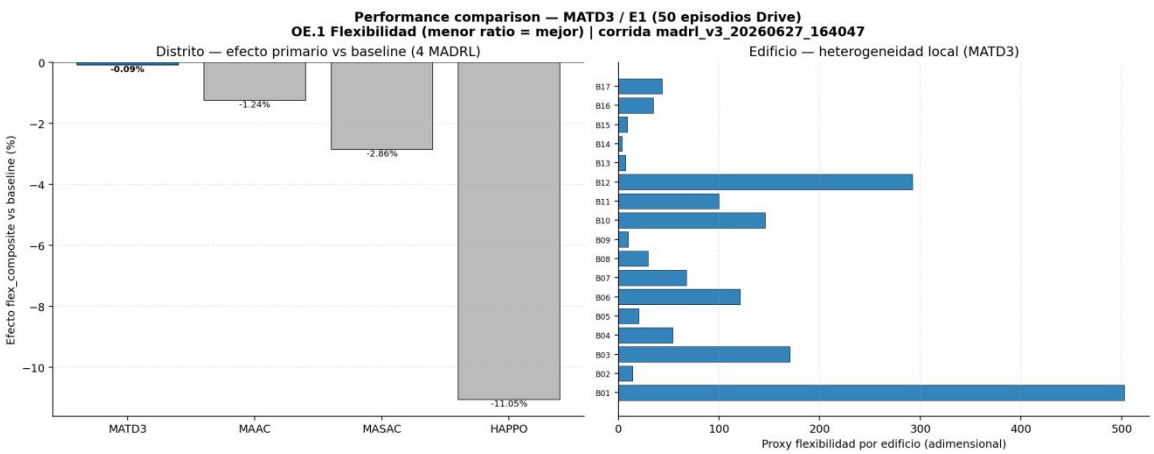

Figura JOB.001. MATD3/E1 — performance_comparison.png — Distrito (efecto % vs baseline de 4 MADRL) + edificio (17 edificios).

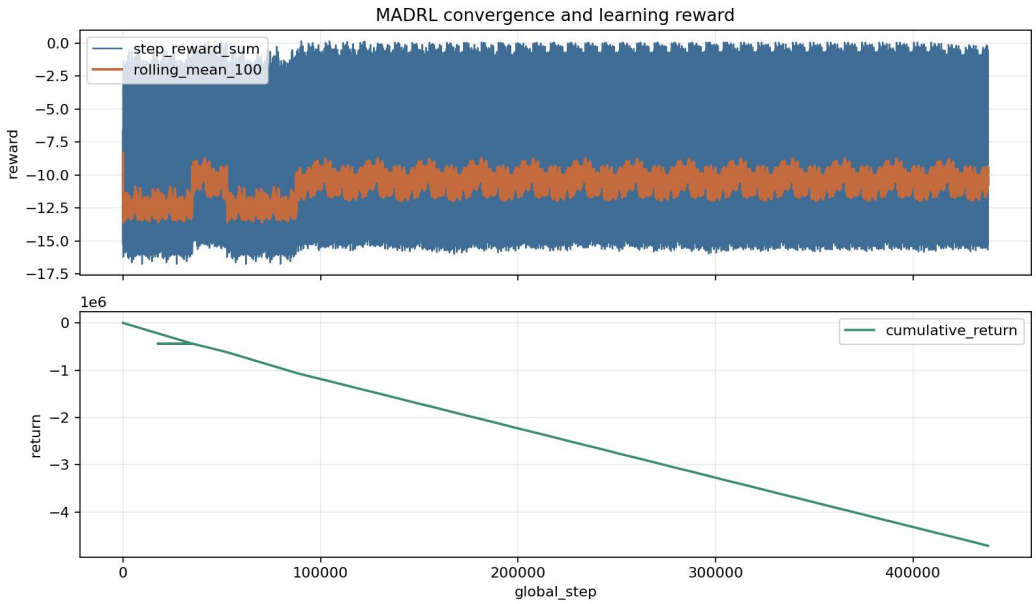

Figura JOB.002. MATD3/E1 — convergence_returns.png — Convergencia de retornos episódicos.

Figura JOB.003. MATD3/E1 — reward_timeseries.png — Serie temporal de recompensa.

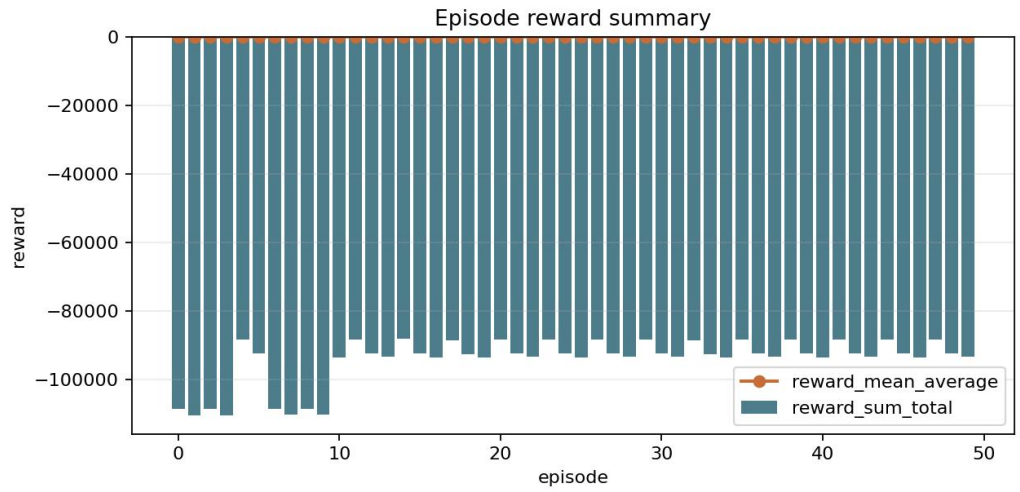

Figura JOB.004. MATD3/E1 — episode_reward_summary.png — Resumen de recompensa por episodio.

Figura JOB.005. MATD3/E1 — learning_efficiency.png — Eficiencia de aprendizaje.

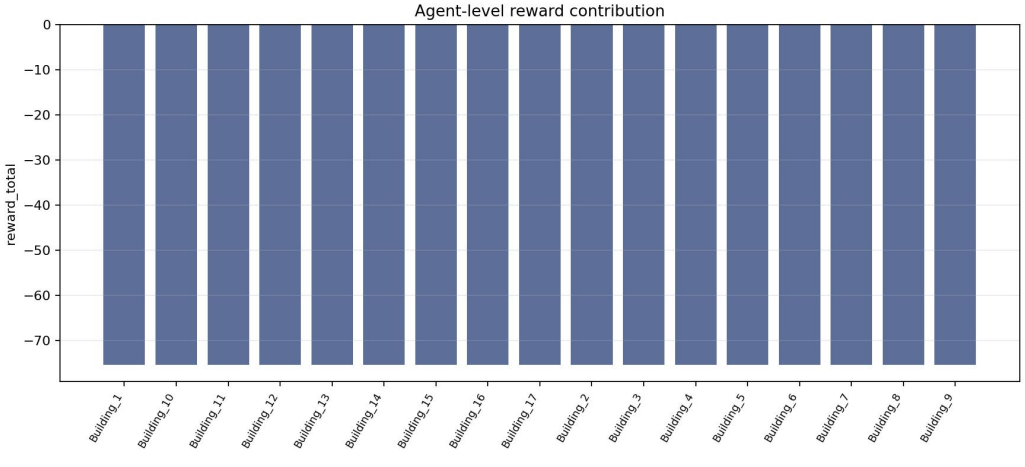

Figura JOB.006. MATD3/E1 — agent_reward_contribution.png — Contribución de recompensa por agente/edificio.

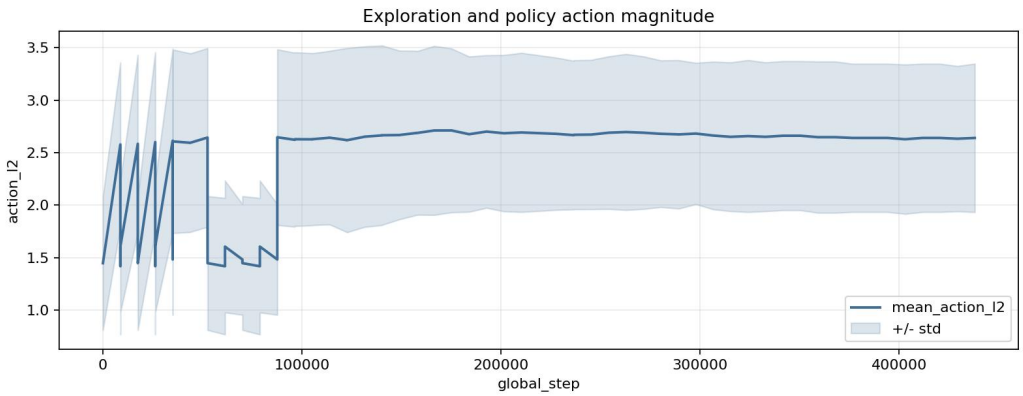

Figura JOB.007. MATD3/E1 — exploration_action_l2.png — Exploración (norma L2 de acciones).

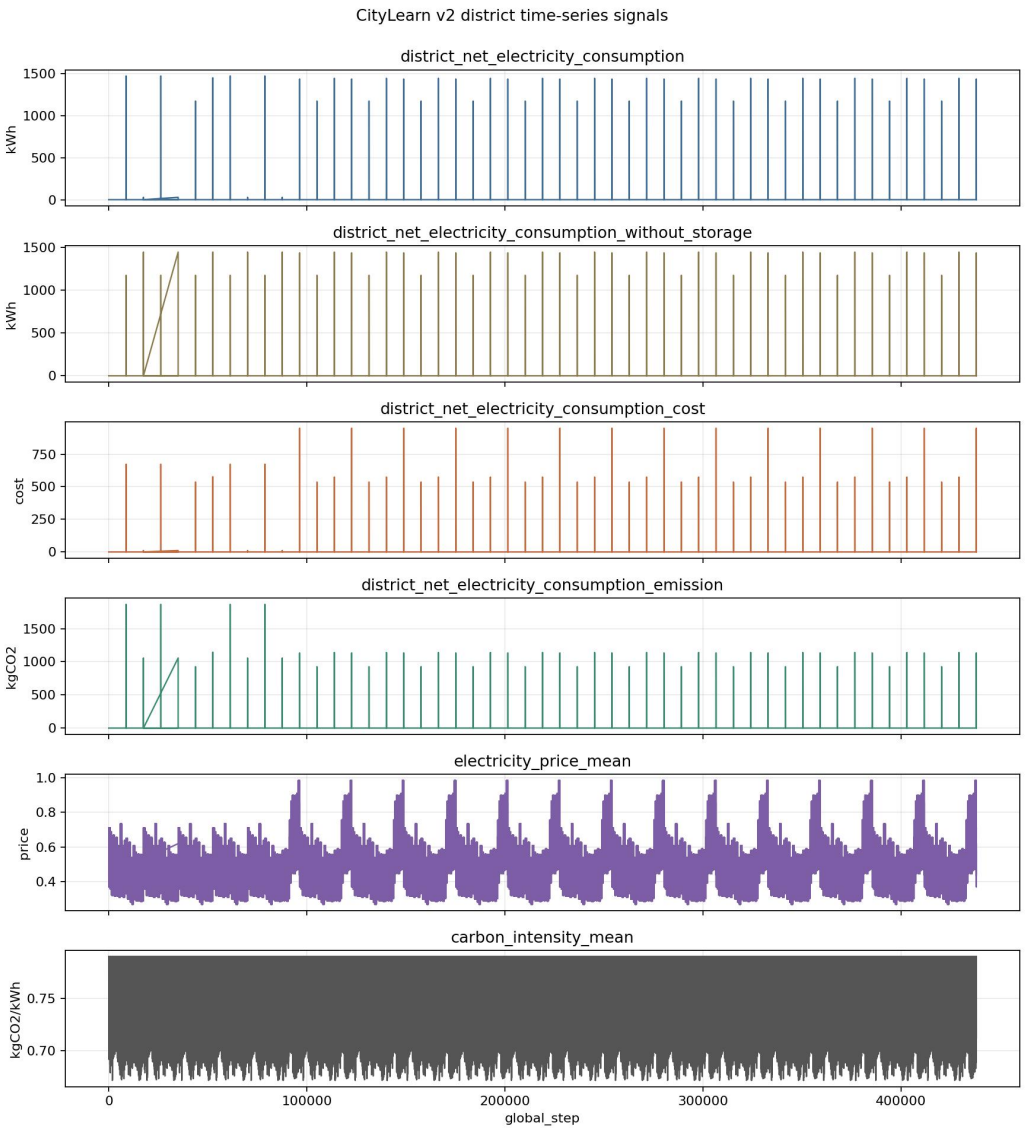

Figura JOB.008. MATD3/E1 — citylearn_v2_district_timeseries.png — Series temporales distritales CityLearn.

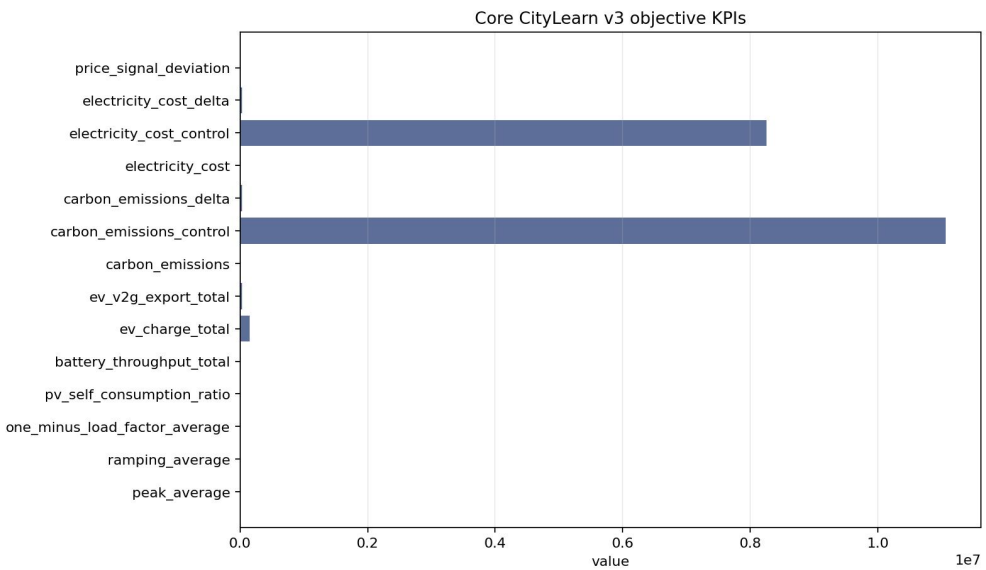

Figura JOB.009. MATD3/E1 — core_kpis.png — KPIs núcleo del job.

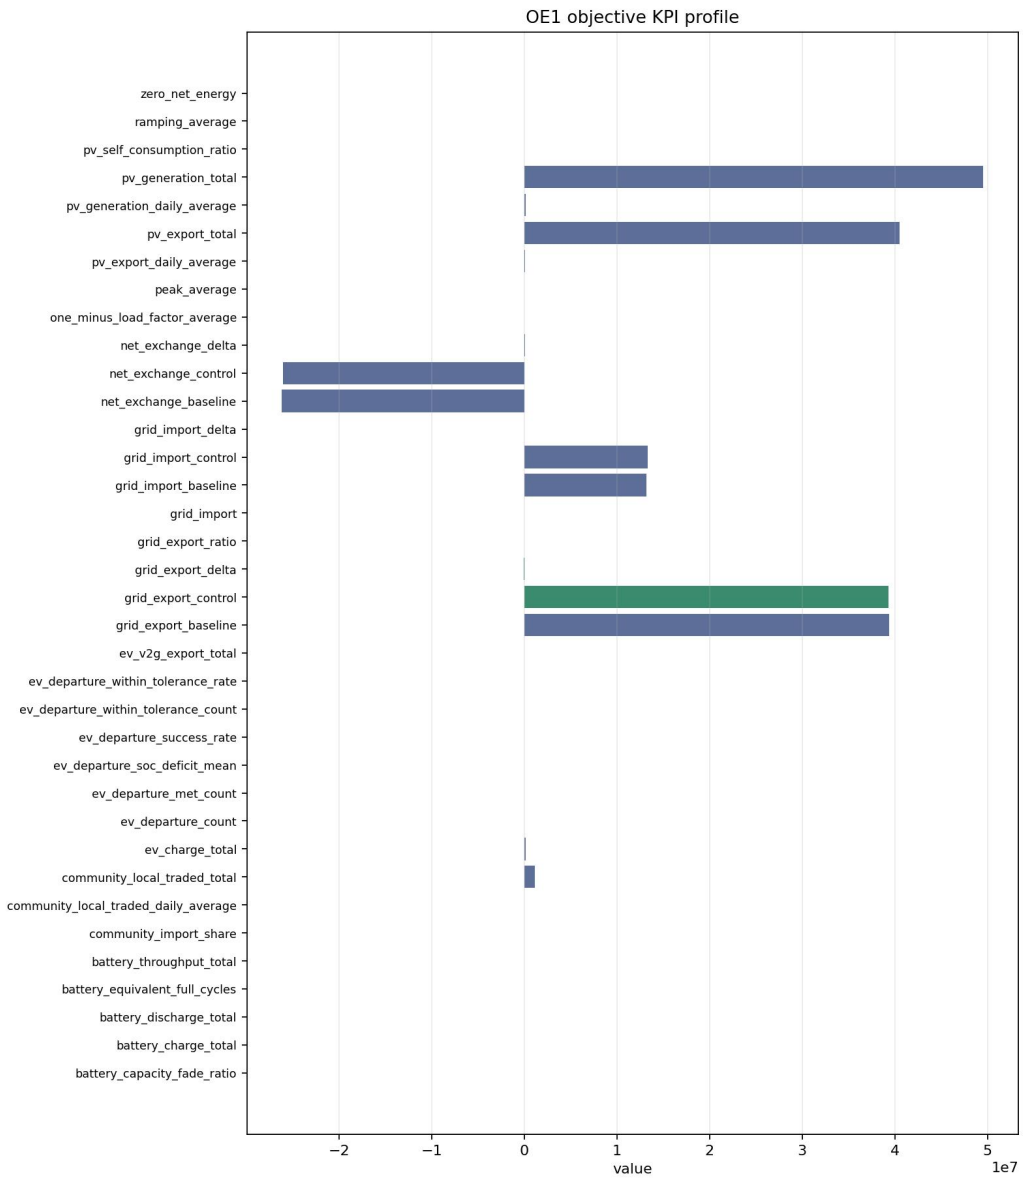

Figura JOB.010. MATD3/E1 — OE1_flexibility_kpis.png — KPIs de flexibilidad (OE.1).

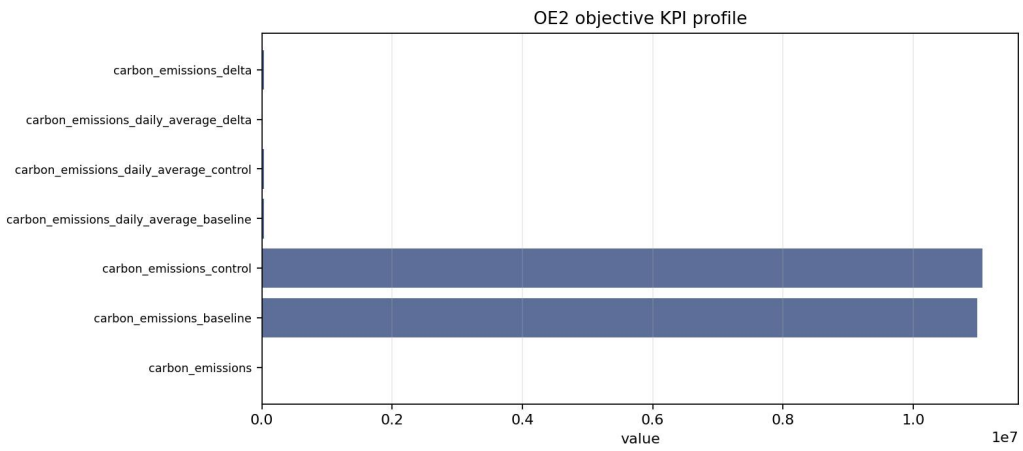

Figura JOB.011. MATD3/E1 — OE2_co2_kpis.png — KPIs de emisiones (OE.2).

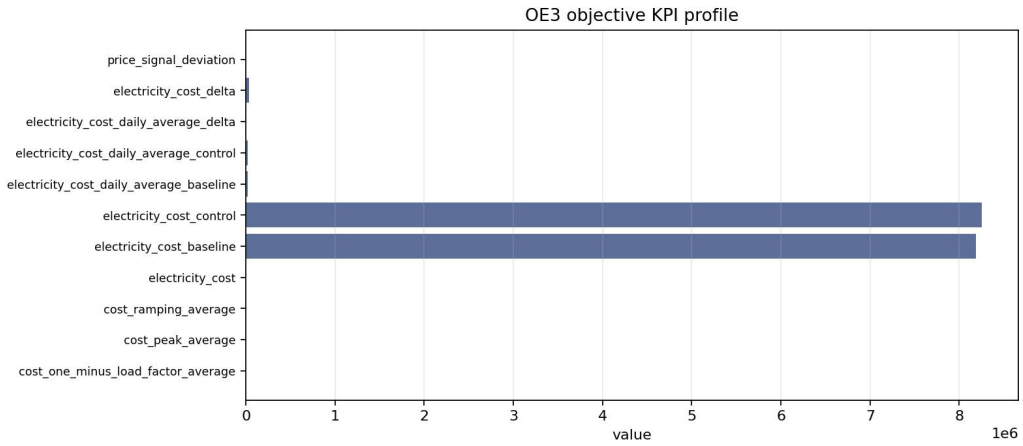

Figura JOB.012. MATD3/E1 — OE3_cost_kpis.png — KPIs de costo (OE.3).

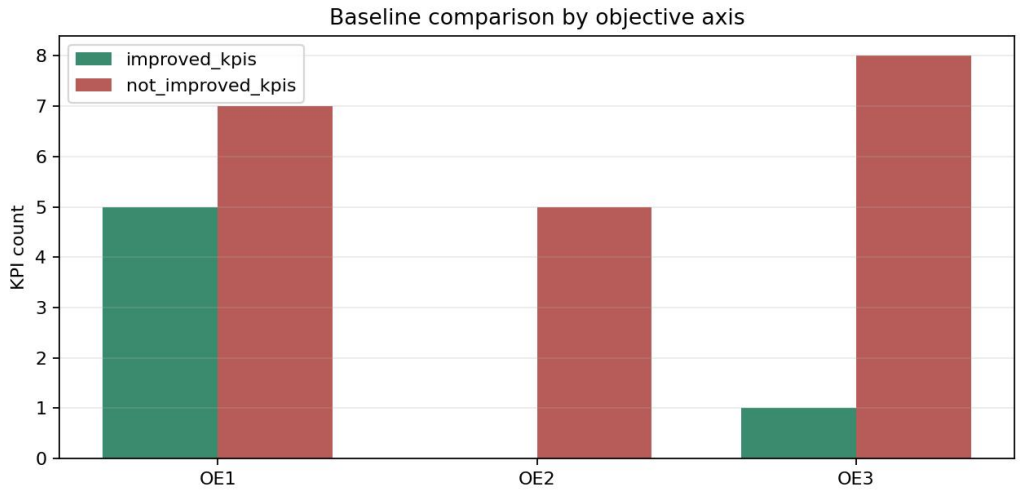

Figura JOB.013. MATD3/E1 — axis_baseline_comparison.png — Comparación por eje vs baseline.

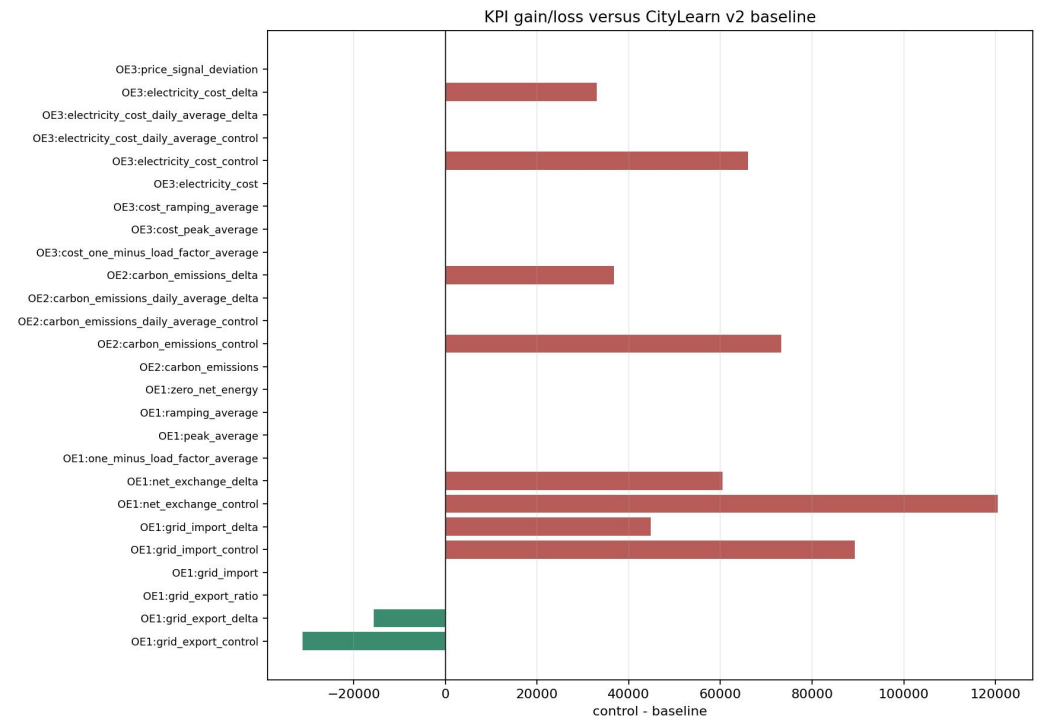

Figura JOB.014. MATD3/E1 — baseline_gain_by_kpi.png — Ganancia/pérdida por KPI vs baseline.

MATD3 / E2

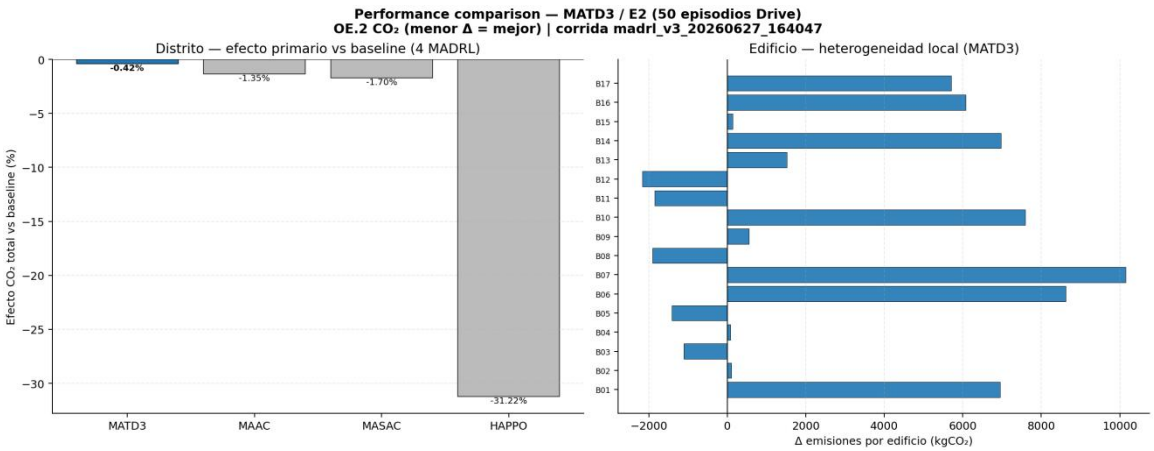

Figura JOB.015. MATD3/E2 — performance_comparison.png — Distrito (efecto % vs baseline de 4 MADRL) + edificio (17 edificios).

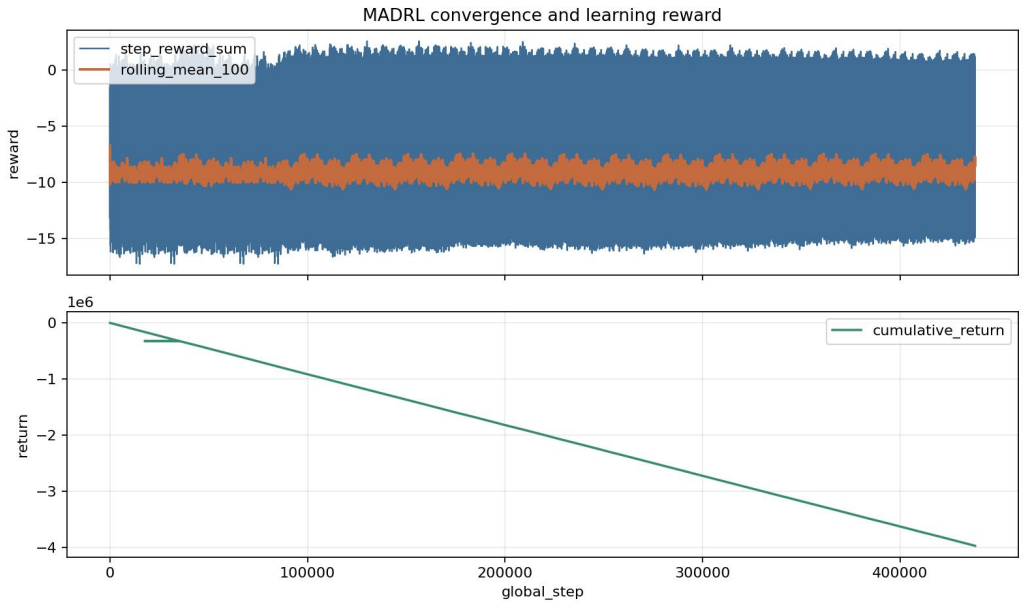

Figura JOB.016. MATD3/E2 — convergence_returns.png — Convergencia de retornos episódicos.

Figura JOB.017. MATD3/E2 — reward_timeseries.png — Serie temporal de recompensa.

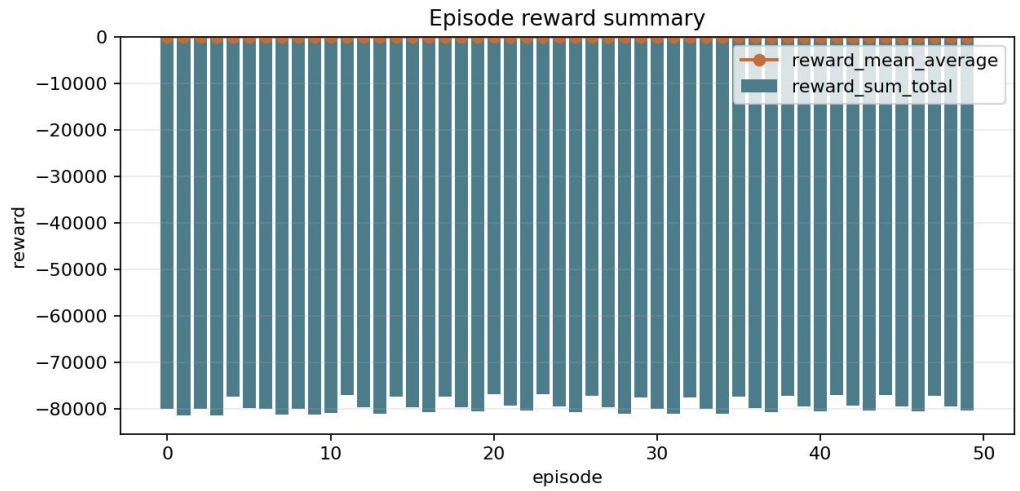

Figura JOB.018. MATD3/E2 — episode_reward_summary.png — Resumen de recompensa por episodio.

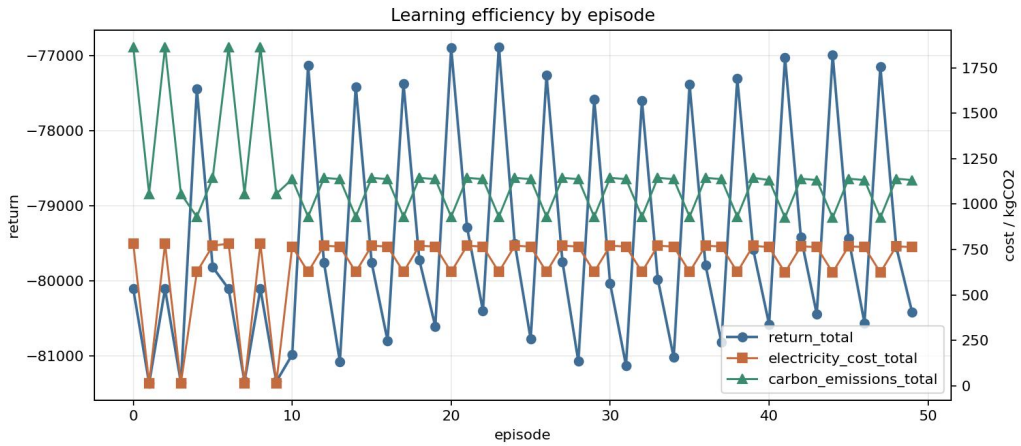

Figura JOB.019. MATD3/E2 — learning_efficiency.png — Eficiencia de aprendizaje.

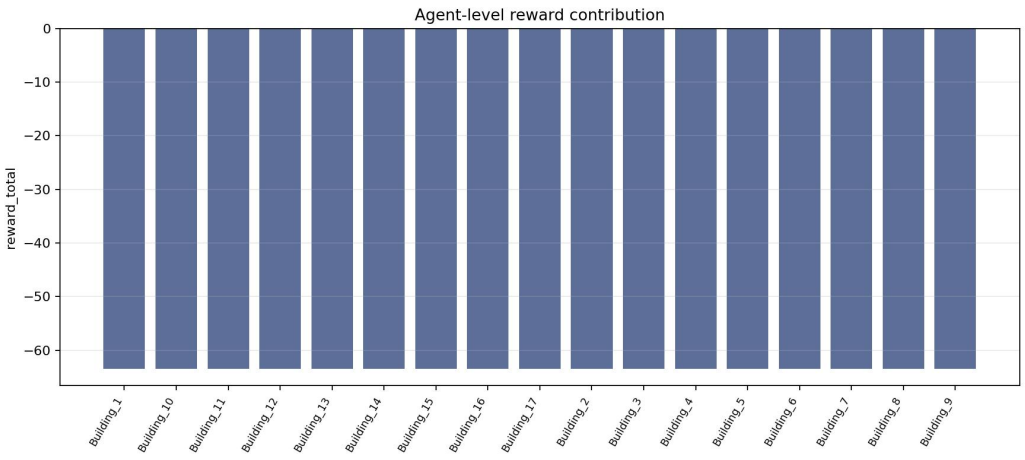

Figura JOB.020. MATD3/E2 — agent_reward_contribution.png — Contribución de recompensa por agente/edificio.

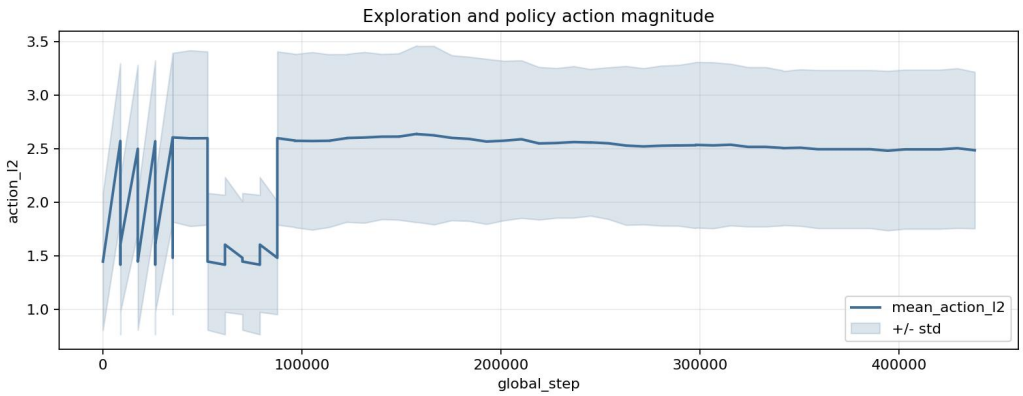

Figura JOB.021. MATD3/E2 — exploration_action_l2.png — Exploración (norma L2 de acciones).

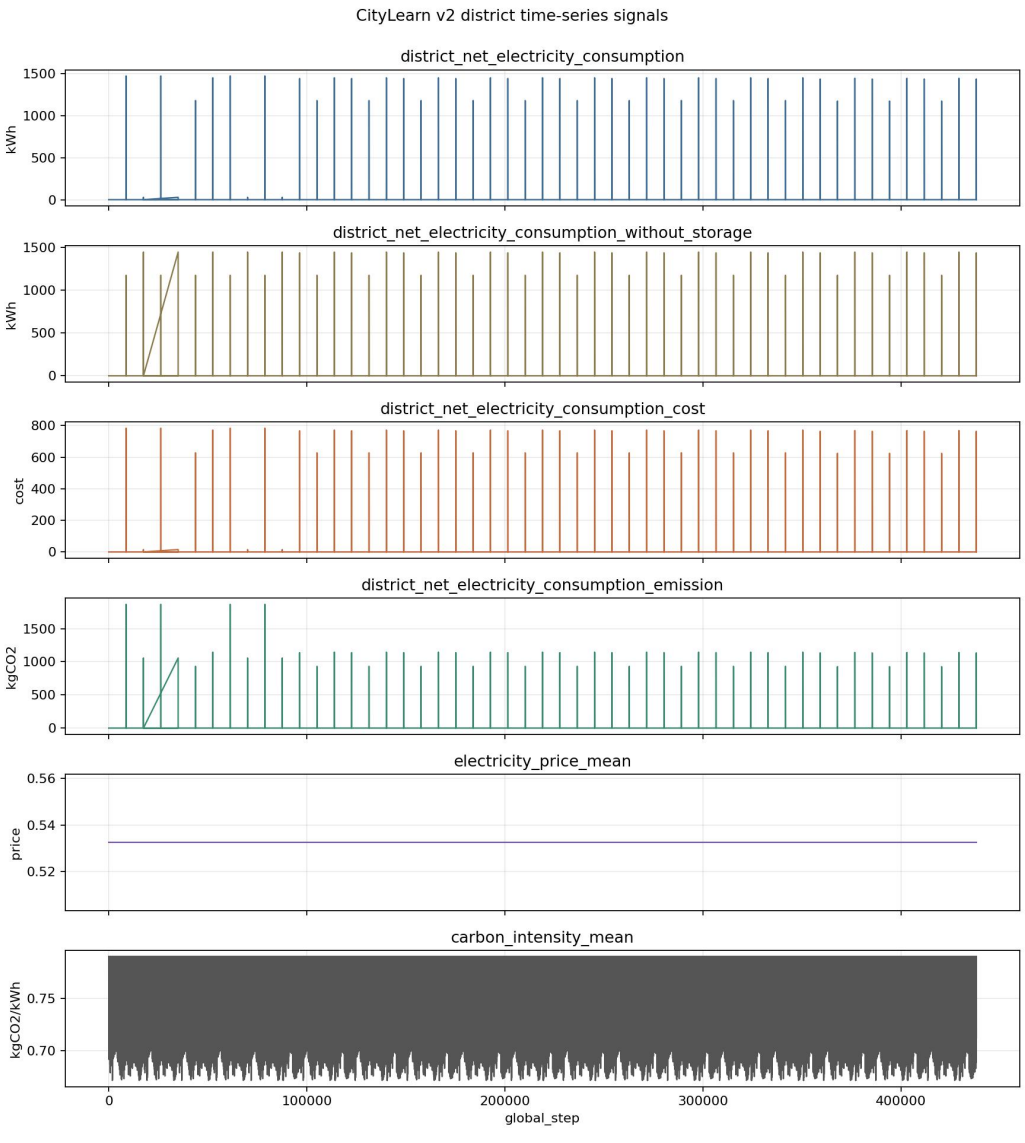

Figura JOB.022. MATD3/E2 — citylearn_v2_district_timeseries.png — Series temporales distritales CityLearn.

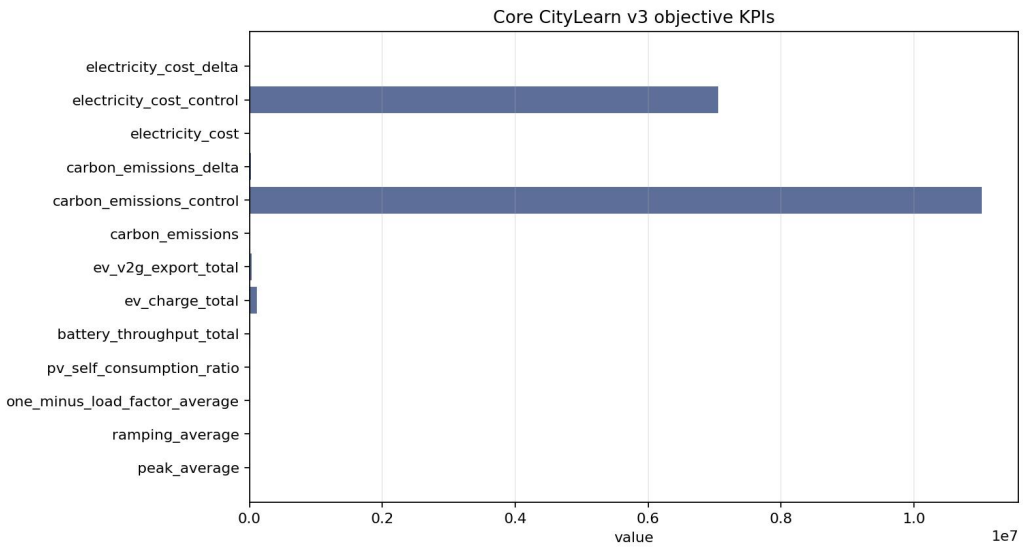

Figura JOB.023. MATD3/E2 — core_kpis.png — KPIs núcleo del job.

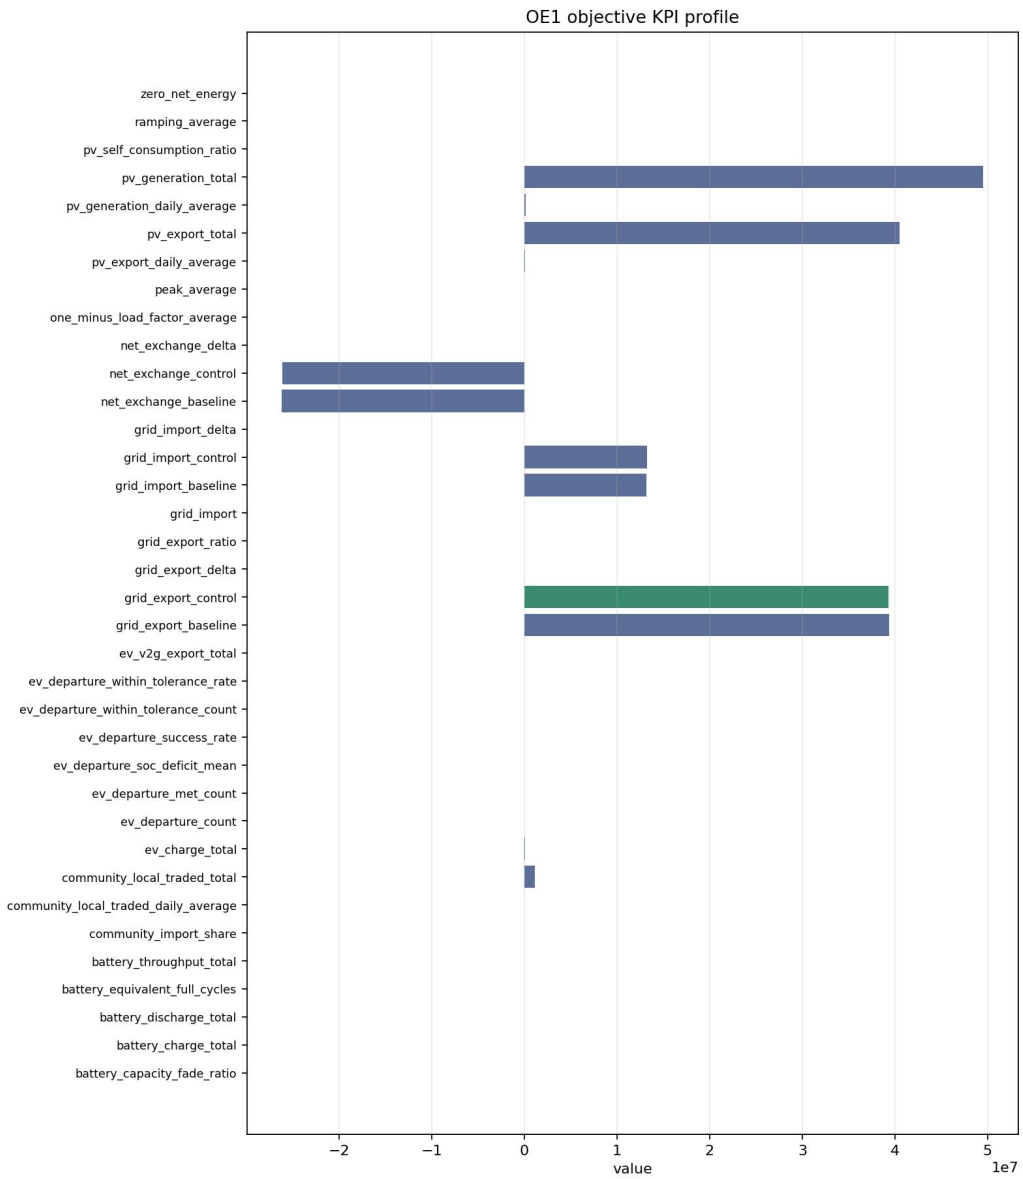

Figura JOB.024. MATD3/E2 — OE1_flexibility_kpis.png — KPIs de flexibilidad (OE.1).

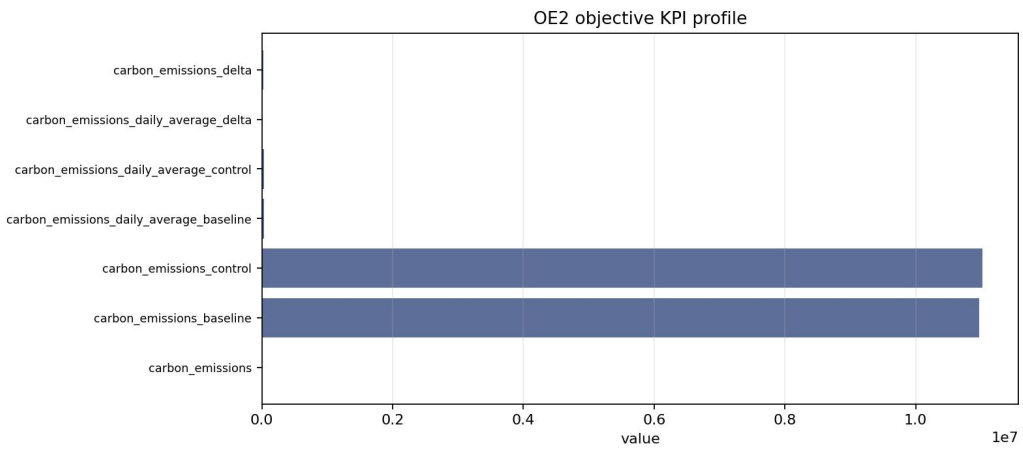

Figura JOB.025. MATD3/E2 — OE2_co2_kpis.png — KPIs de emisiones (OE.2).

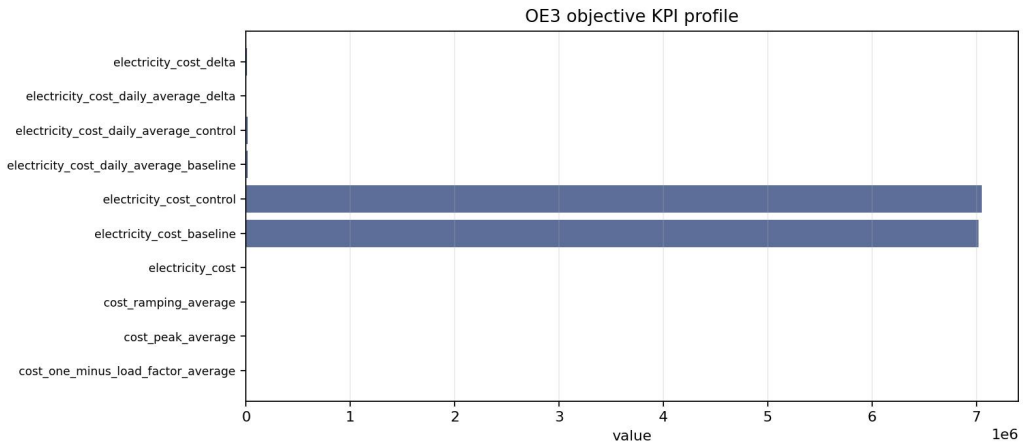

Figura JOB.026. MATD3/E2 — OE3_cost_kpis.png — KPIs de costo (OE.3).

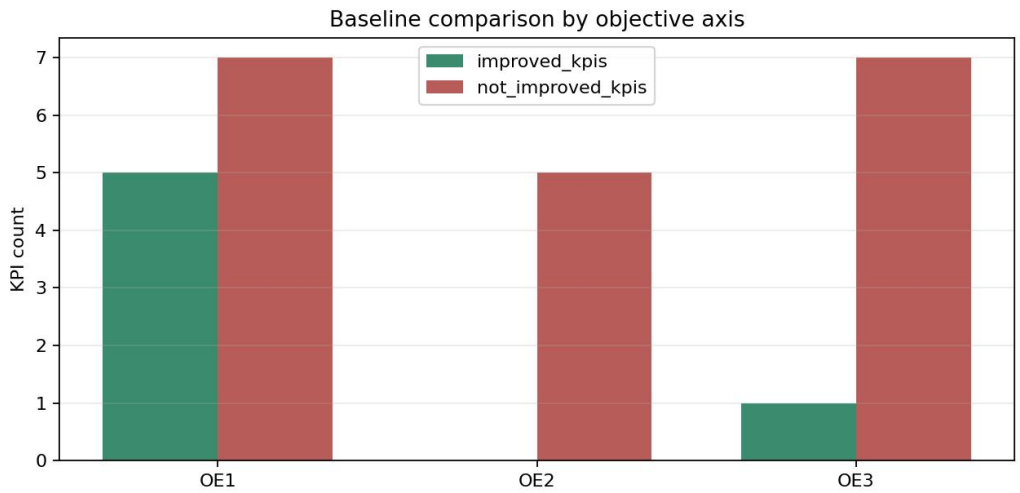

Figura JOB.027. MATD3/E2 — axis_baseline_comparison.png — Comparación por eje vs baseline.

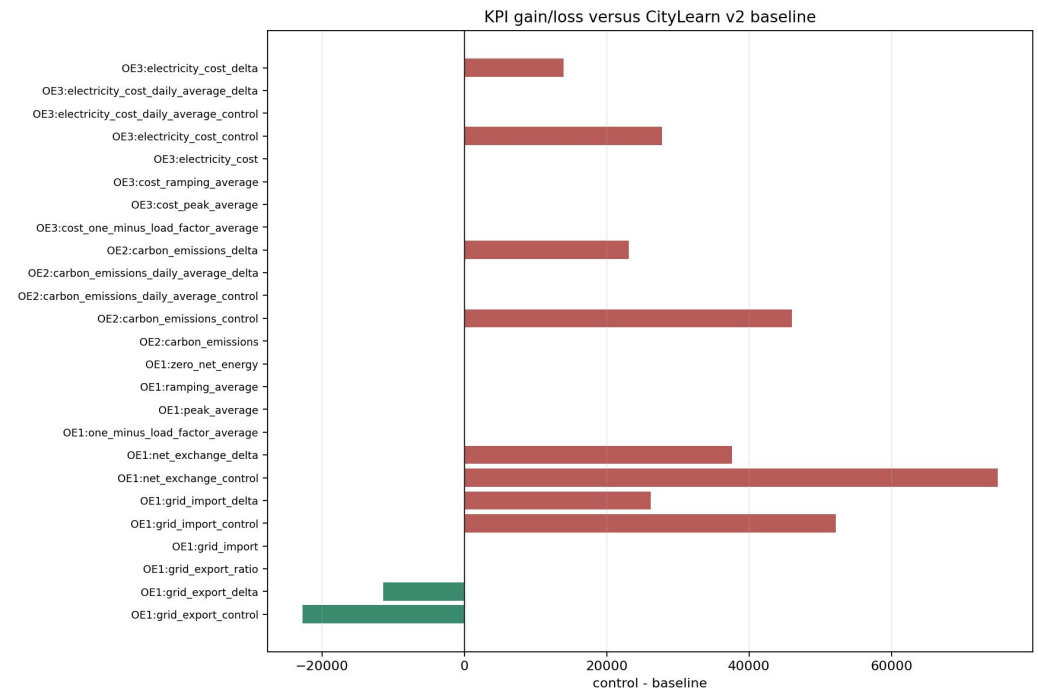

Figura JOB.028. MATD3/E2 — baseline_gain_by_kpi.png — Ganancia/pérdida por KPI vs baseline.

MATD3 / E3

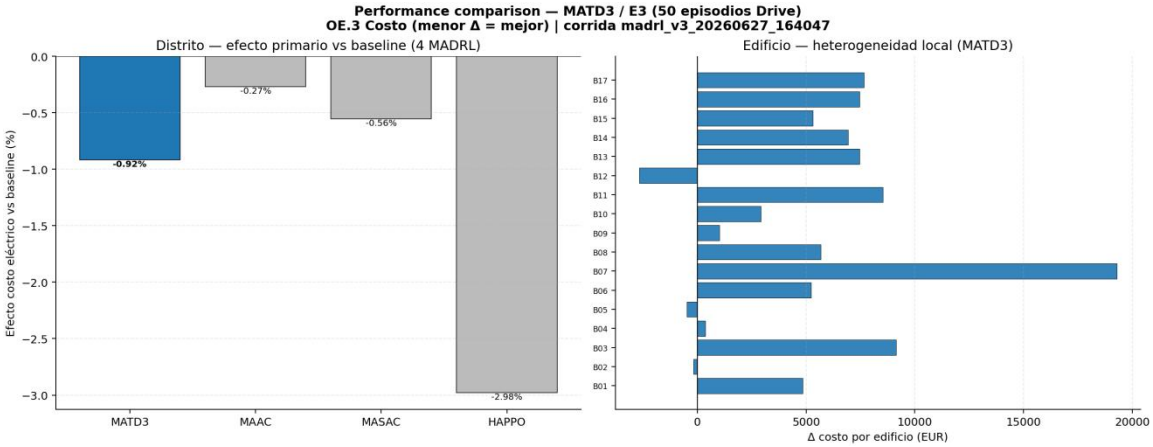

Figura JOB.029. MATD3/E3 — performance_comparison.png — Distrito (efecto % vs baseline de 4 MADRL) + edificio (17 edificios).

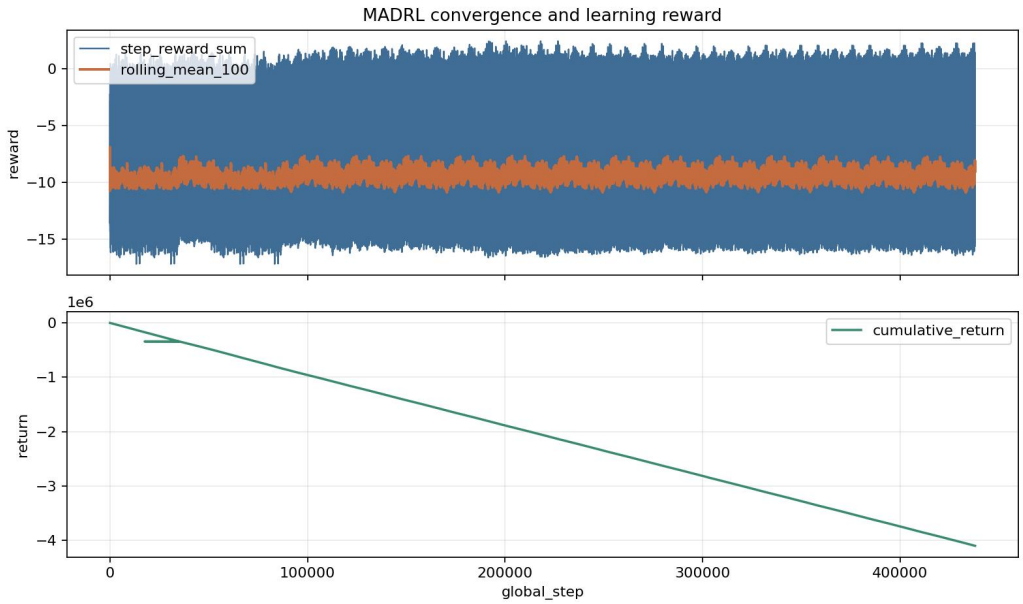

Figura JOB.030. MATD3/E3 — convergence_returns.png — Convergencia de retornos episódicos.

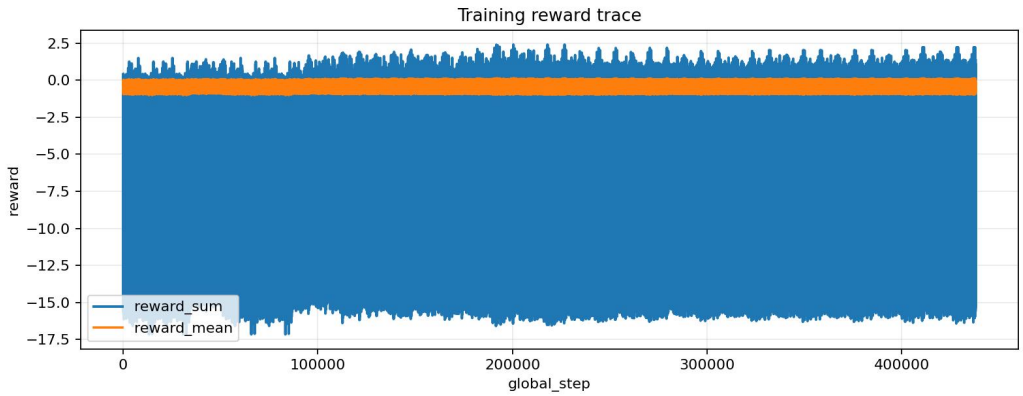

Figura JOB.031. MATD3/E3 — reward_timeseries.png — Serie temporal de recompensa.

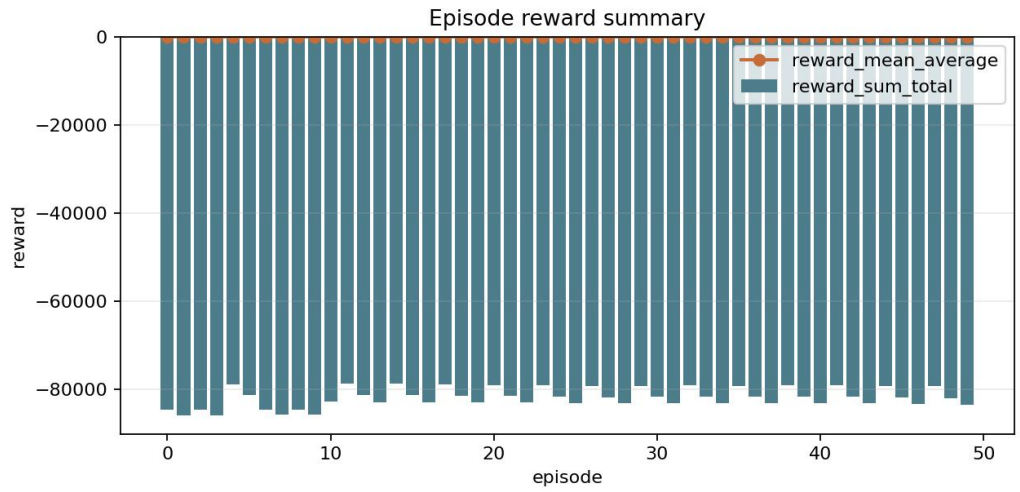

Figura JOB.032. MATD3/E3 — episode_reward_summary.png — Resumen de recompensa por episodio.

Figura JOB.033. MATD3/E3 — learning_efficiency.png — Eficiencia de aprendizaje.

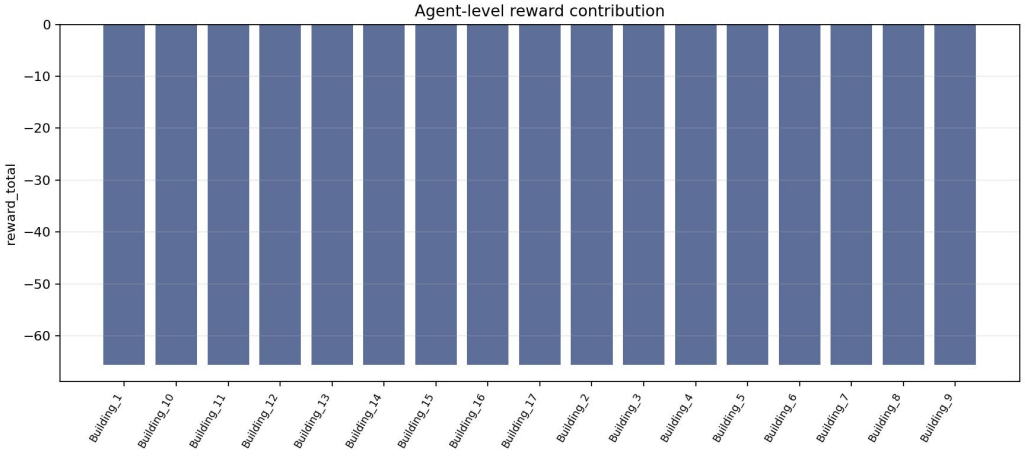

Figura JOB.034. MATD3/E3 — agent_reward_contribution.png — Contribución de recompensa por agente/edificio.

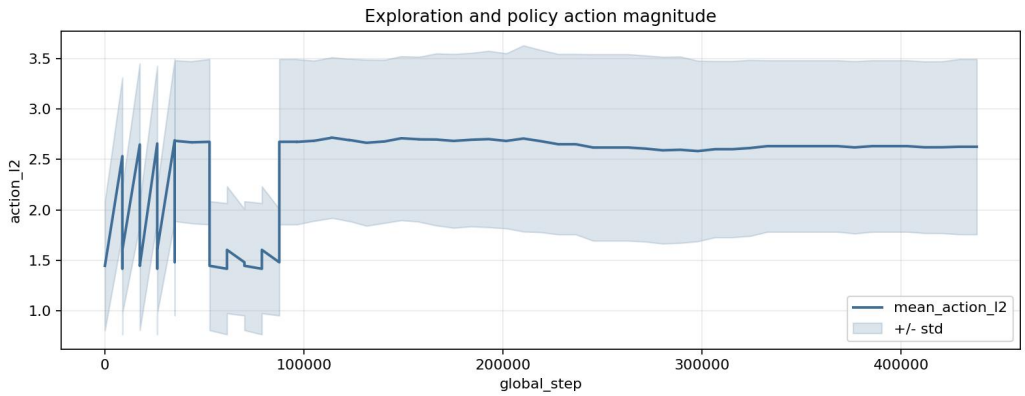

Figura JOB.035. MATD3/E3 — exploration_action_l2.png — Exploración (norma L2 de acciones).

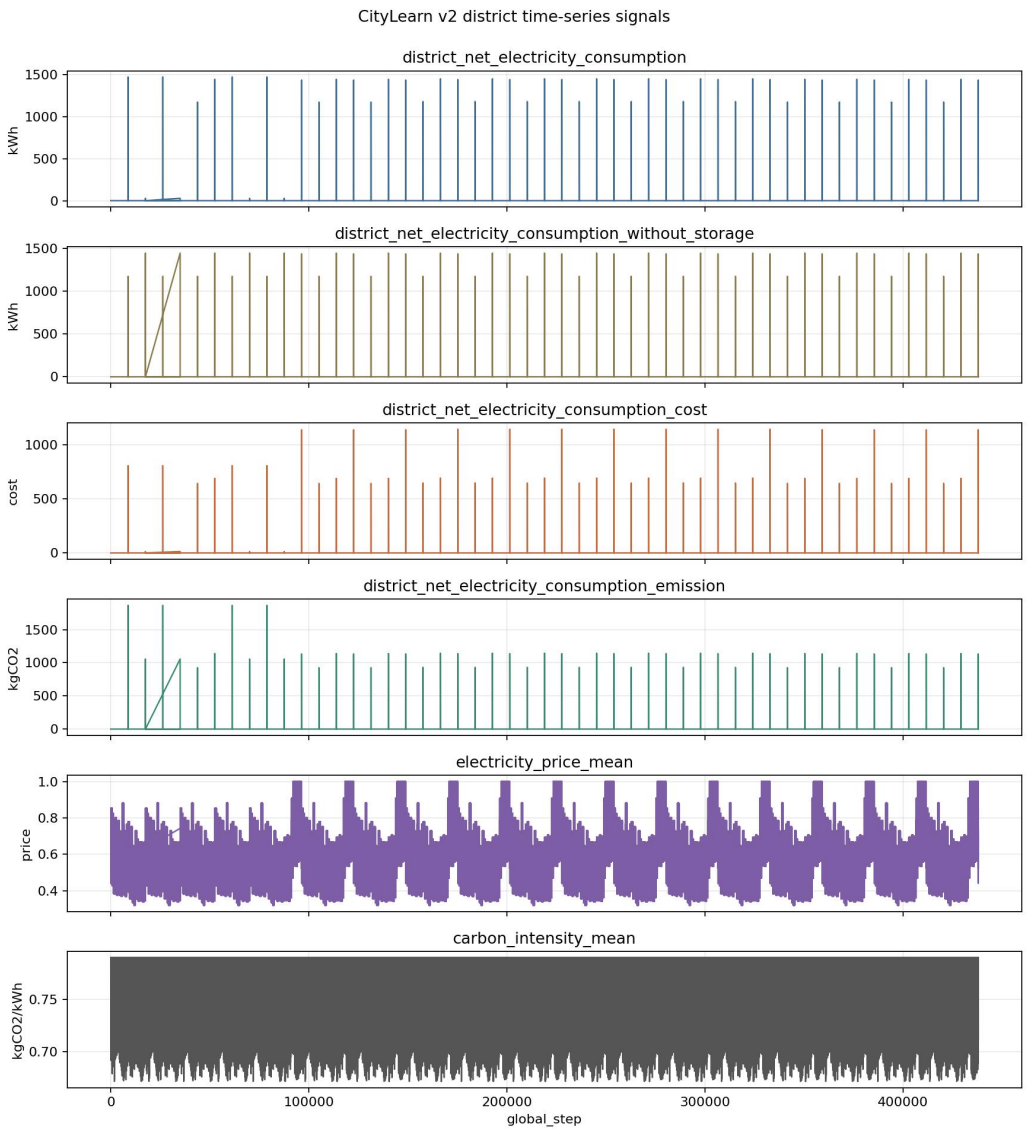

Figura JOB.036. MATD3/E3 — citylearn_v2_district_timeseries.png — Series temporales distritales CityLearn.

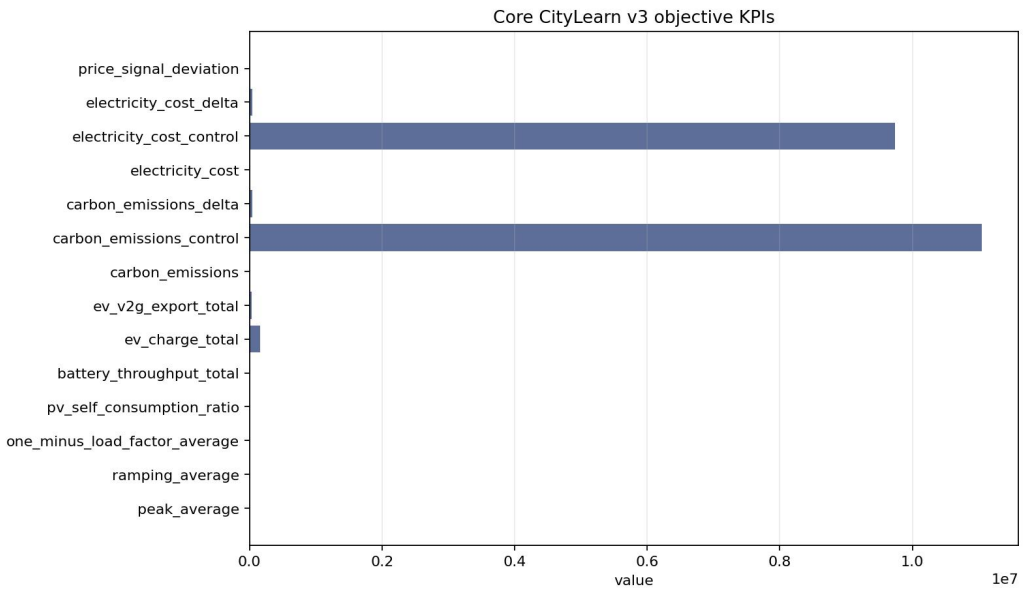

Figura JOB.037. MATD3/E3 — core_kpis.png — KPIs núcleo del job.

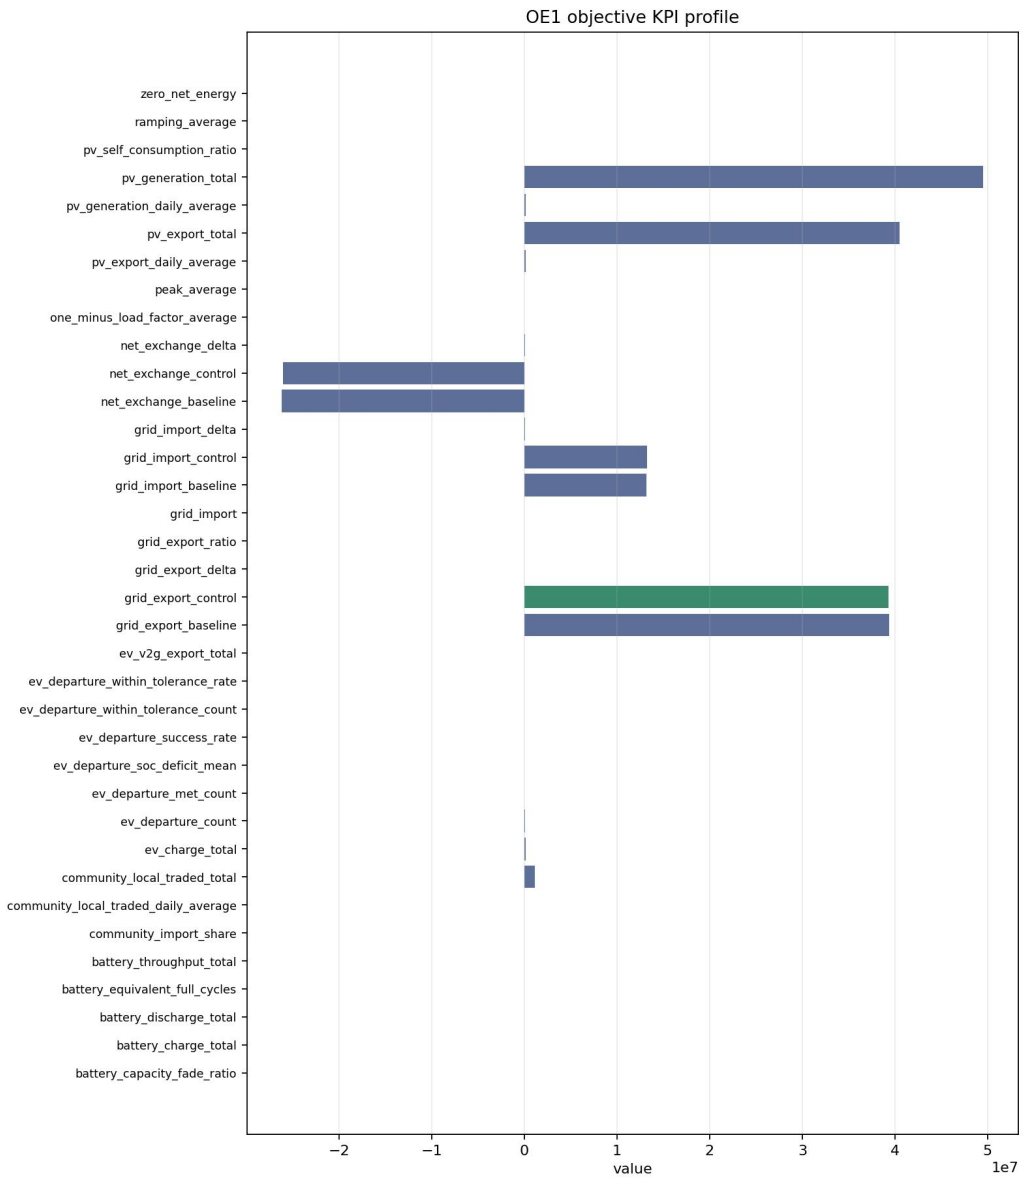

Figura JOB.038. MATD3/E3 — OE1_flexibility_kpis.png — KPIs de flexibilidad (OE.1).

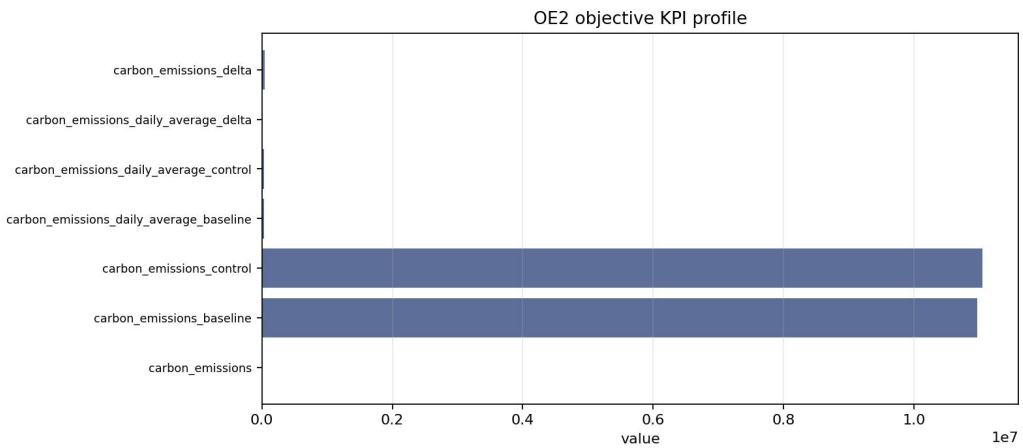

Figura JOB.039. MATD3/E3 — OE2_co2_kpis.png — KPIs de emisiones (OE.2).

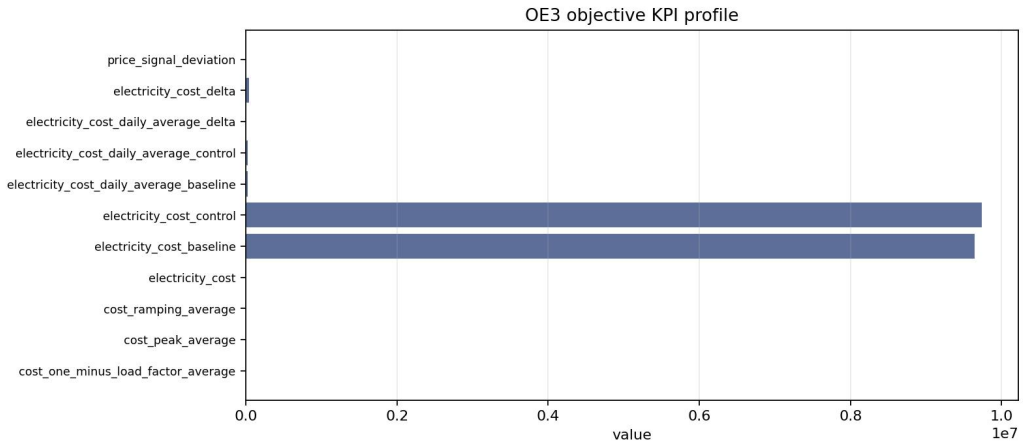

Figura JOB.040. MATD3/E3 — OE3_cost_kpis.png — KPIs de costo (OE.3).

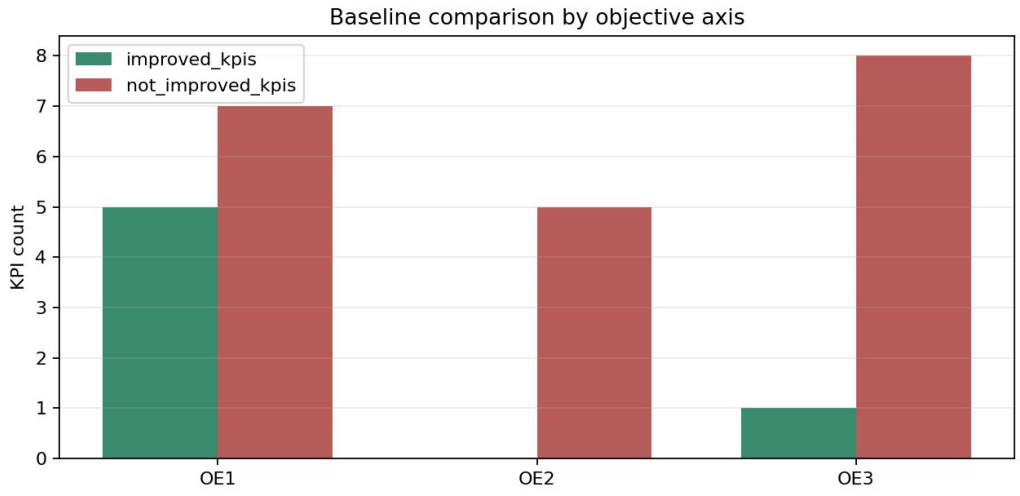

Figura JOB.041. MATD3/E3 — axis_baseline_comparison.png — Comparación por eje vs baseline.

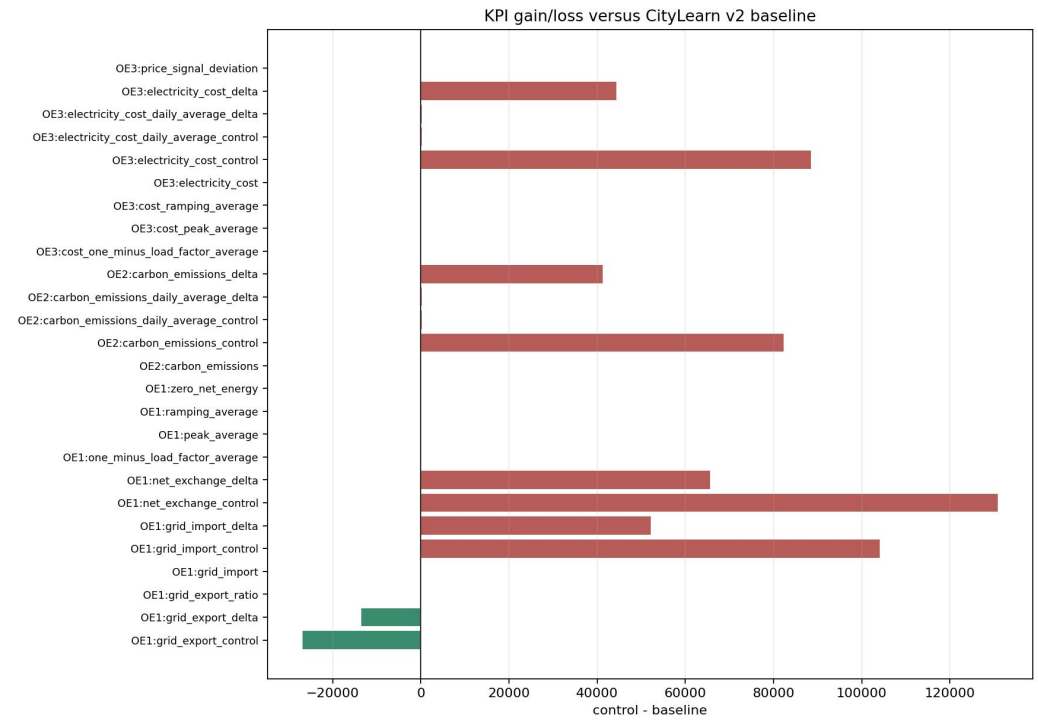

Figura JOB.042. MATD3/E3 — baseline_gain_by_kpi.png — Ganancia/pérdida por KPI vs baseline.

C.MAAC — figuras de performance

MAAC / E1

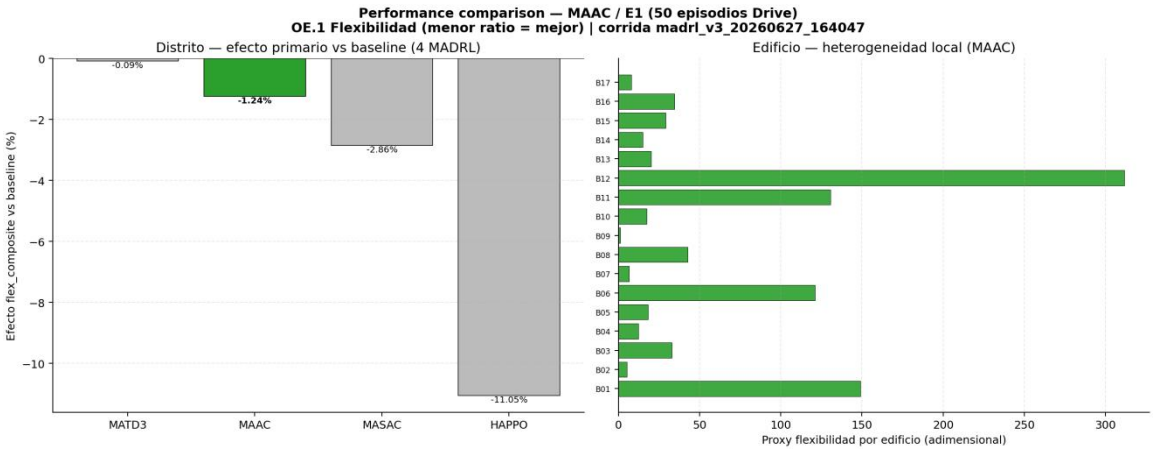

Figura JOB.043. MAAC/E1 — performance_comparison.png — Distrito (efecto % vs baseline de 4 MADRL) + edificio (17 edificios).

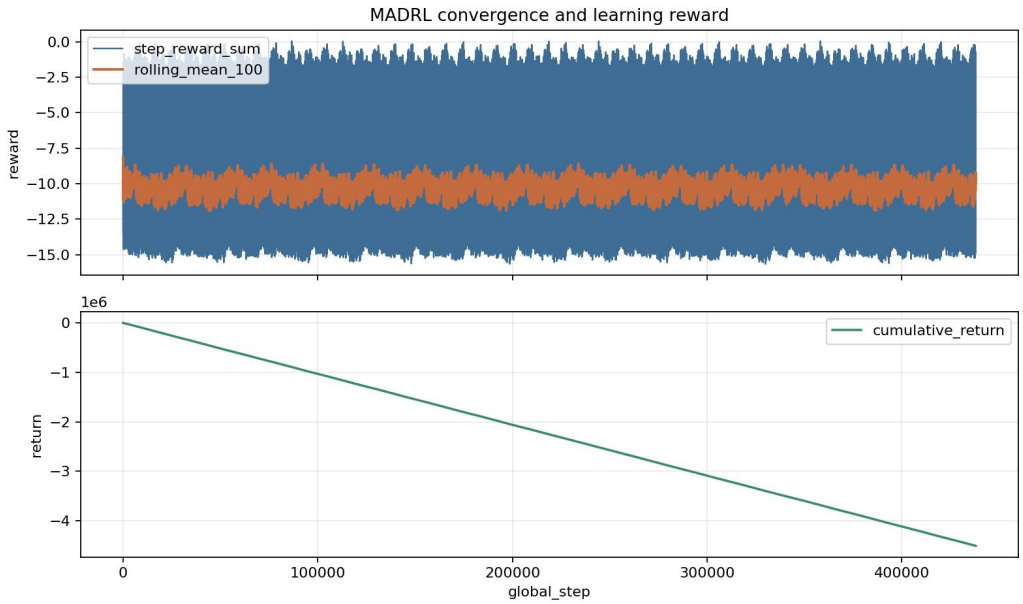

Figura JOB.044. MAAC/E1 — convergence_returns.png — Convergencia de retornos episódicos.

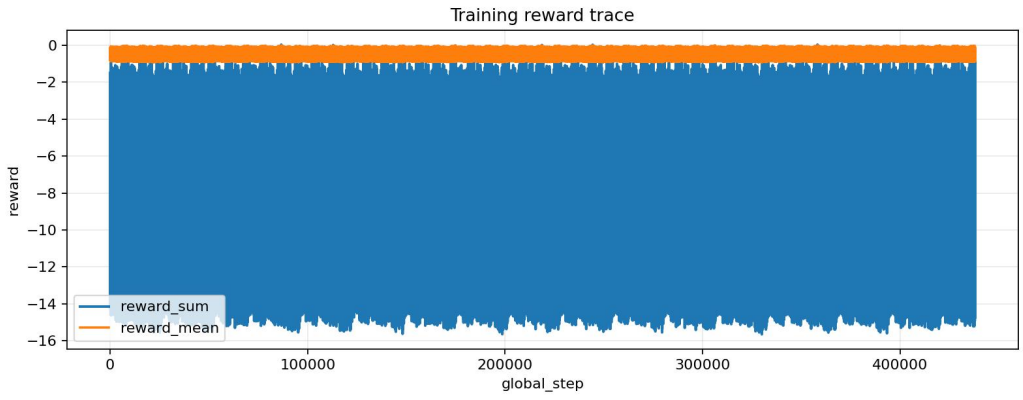

Figura JOB.045. MAAC/E1 — reward_timeseries.png — Serie temporal de recompensa.

Figura JOB.046. MAAC/E1 — episode_reward_summary.png — Resumen de recompensa por episodio.

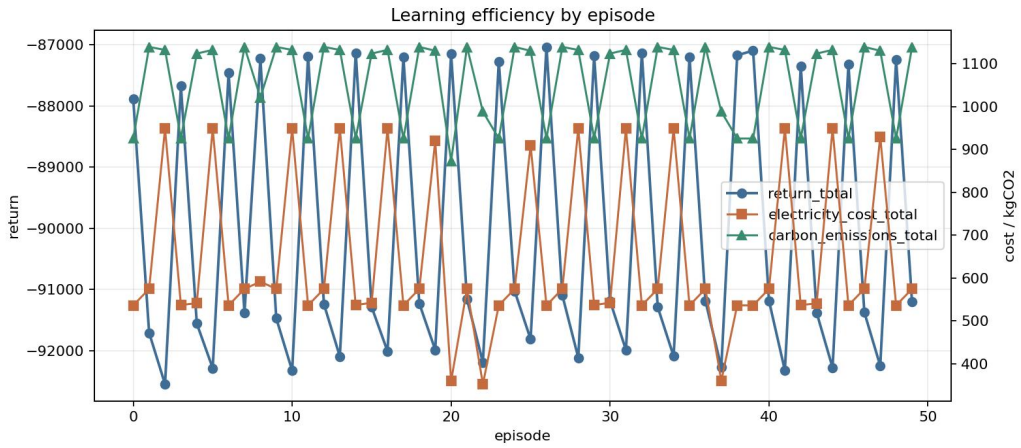

Figura JOB.047. MAAC/E1 — learning_efficiency.png — Eficiencia de aprendizaje.

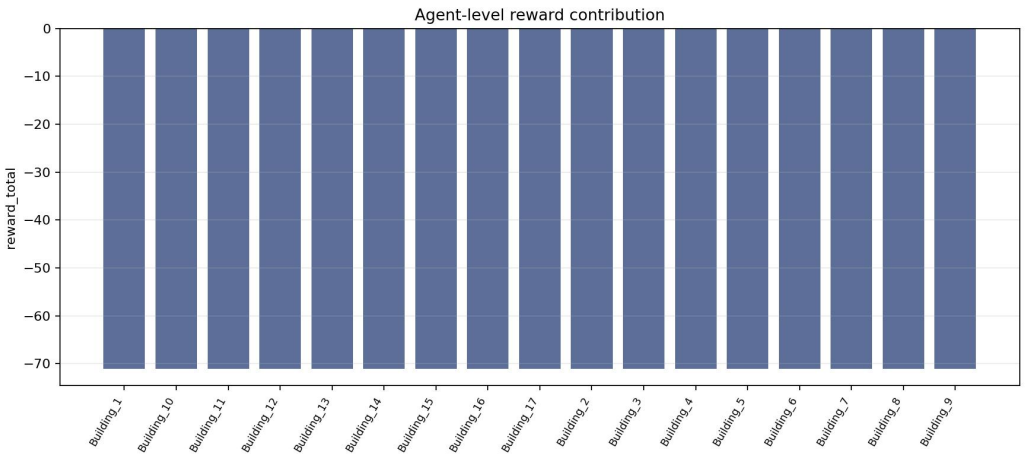

Figura JOB.048. MAAC/E1 — agent_reward_contribution.png — Contribución de recompensa por agente/edificio.

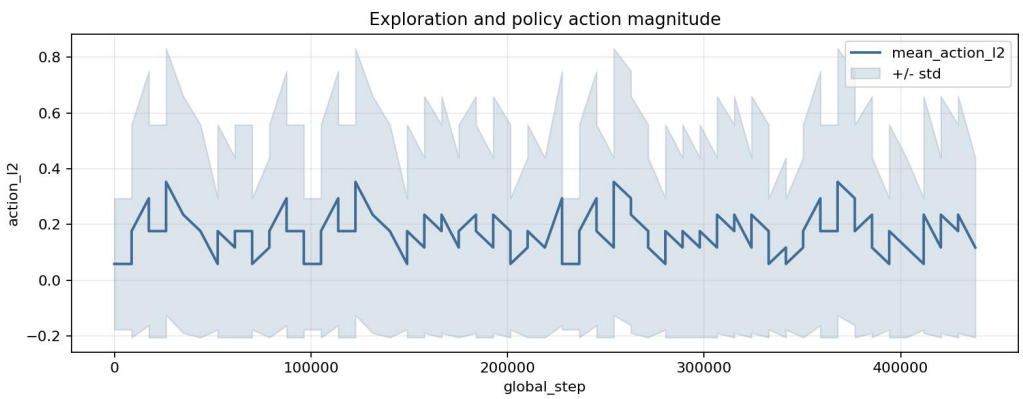

Figura JOB.049. MAAC/E1 — exploration_action_l2.png — Exploración (norma L2 de acciones).

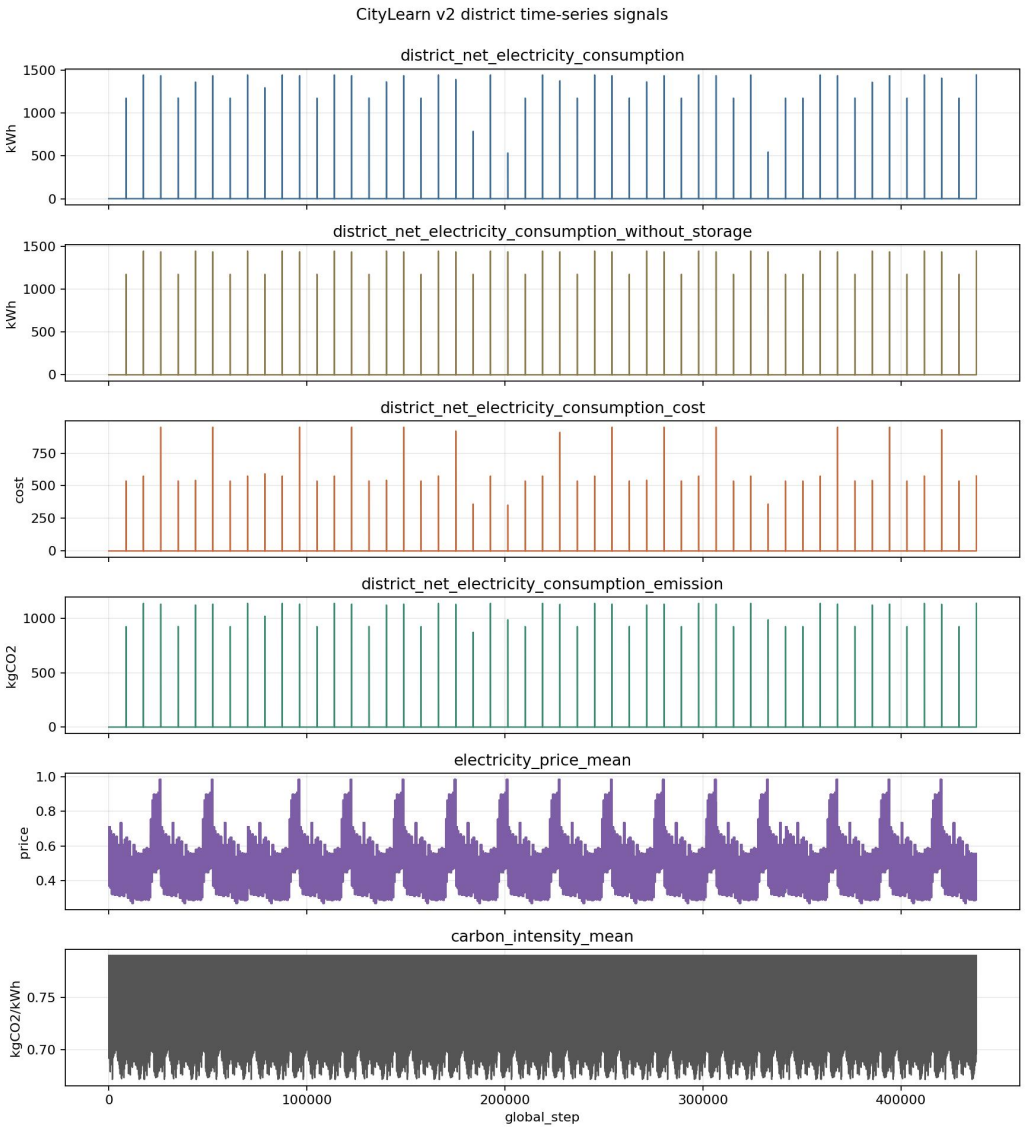

Figura JOB.050. MAAC/E1 — citylearn_v2_district_timeseries.png — Series temporales distritales CityLearn.

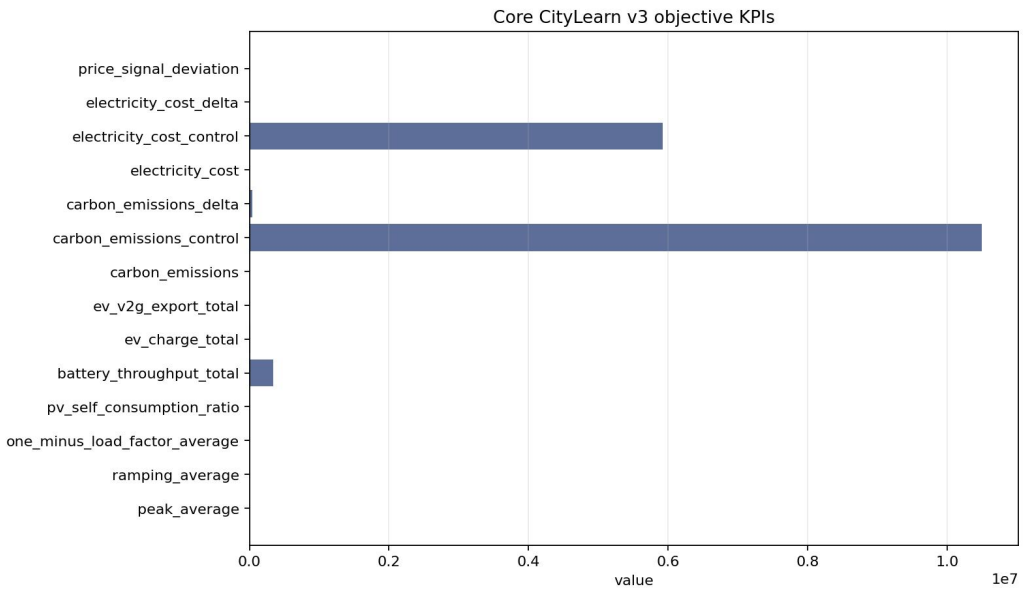

Figura JOB.051. MAAC/E1 — core_kpis.png — KPIs núcleo del job.

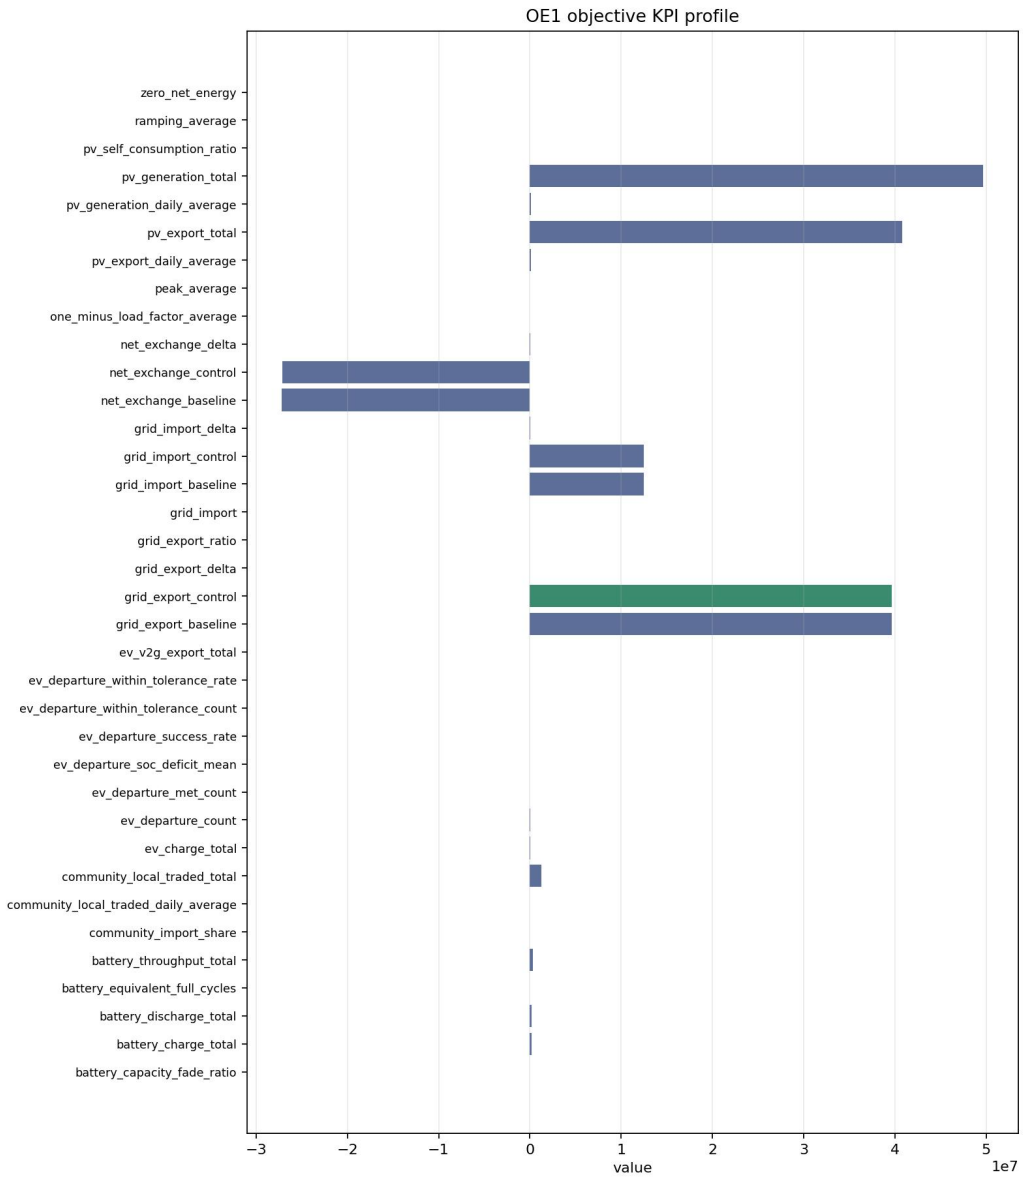

Figura JOB.052. MAAC/E1 — OE1_flexibility_kpis.png — KPIs de flexibilidad (OE.1).

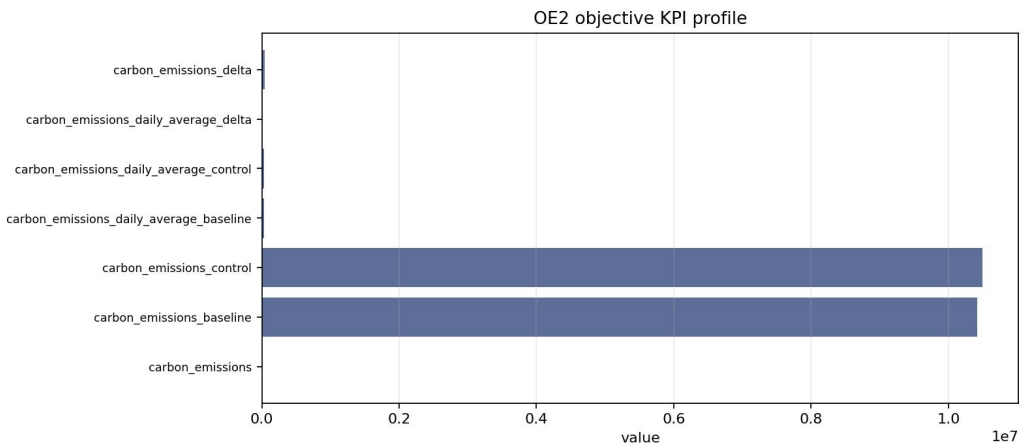

Figura JOB.053. MAAC/E1 — OE2_co2_kpis.png — KPIs de emisiones (OE.2).

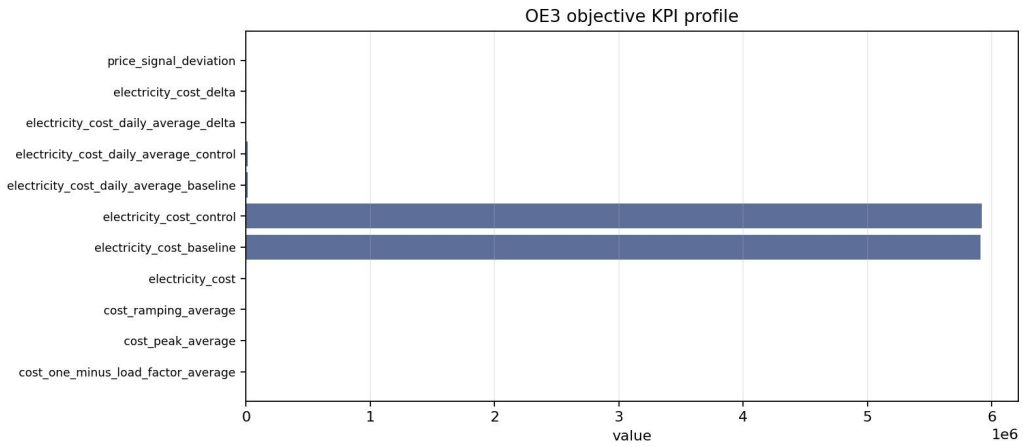

Figura JOB.054. MAAC/E1 — OE3_cost_kpis.png — KPIs de costo (OE.3).

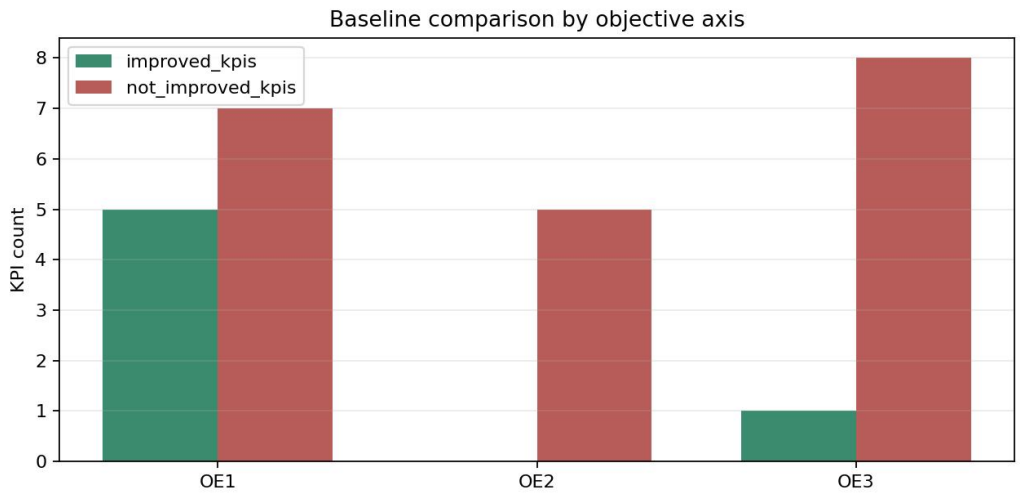

Figura JOB.055. MAAC/E1 — axis_baseline_comparison.png — Comparación por eje vs baseline.

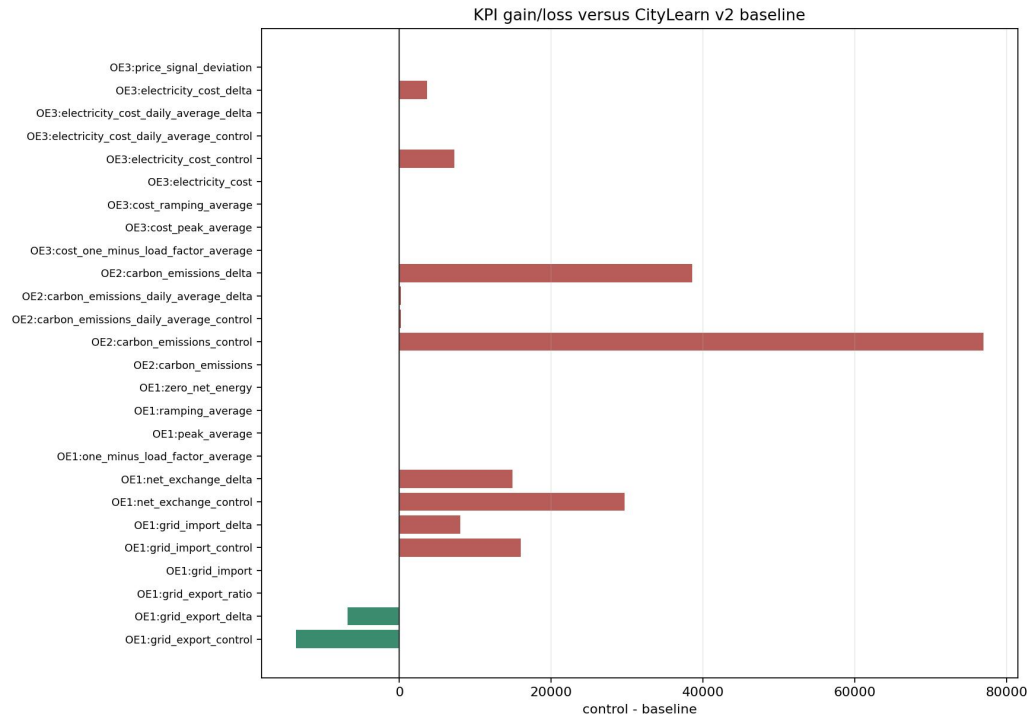

Figura JOB.056. MAAC/E1 — baseline_gain_by_kpi.png — Ganancia/pérdida por KPI vs baseline.

MAAC / E2

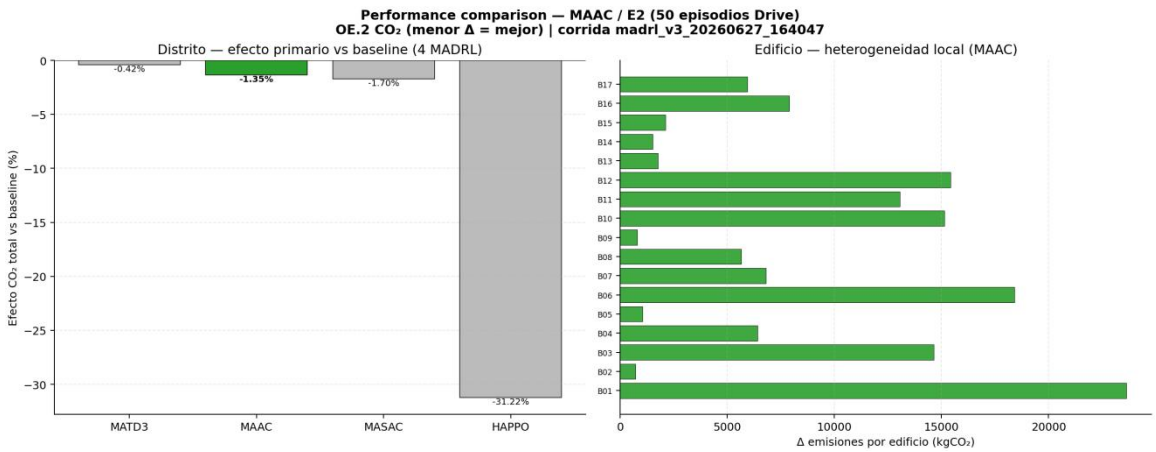

Figura JOB.057. MAAC/E2 — performance_comparison.png — Distrito (efecto % vs baseline de 4 MADRL) + edificio (17 edificios).

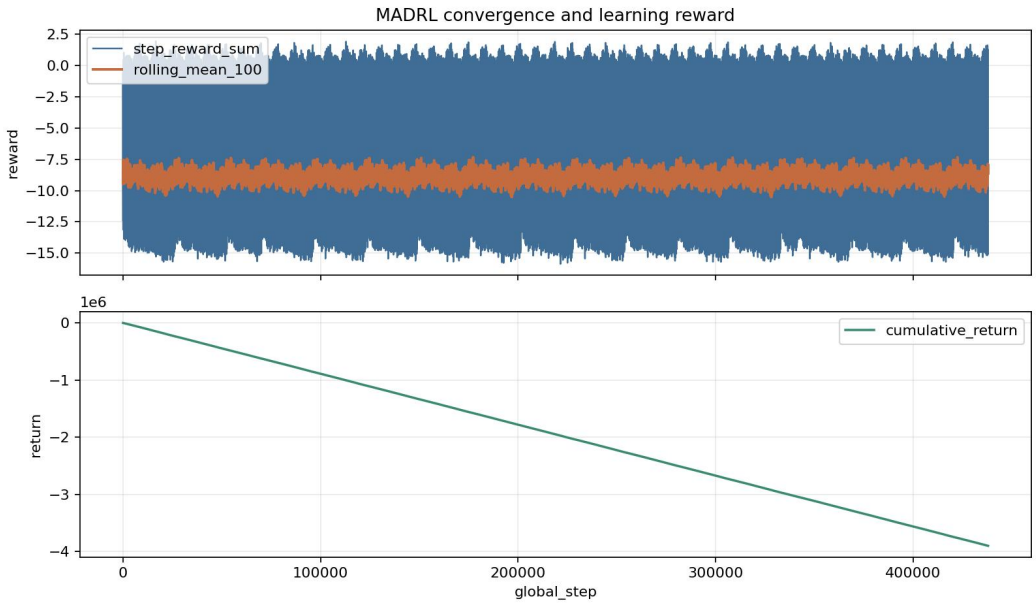

Figura JOB.058. MAAC/E2 — convergence_returns.png — Convergencia de retornos episódicos.

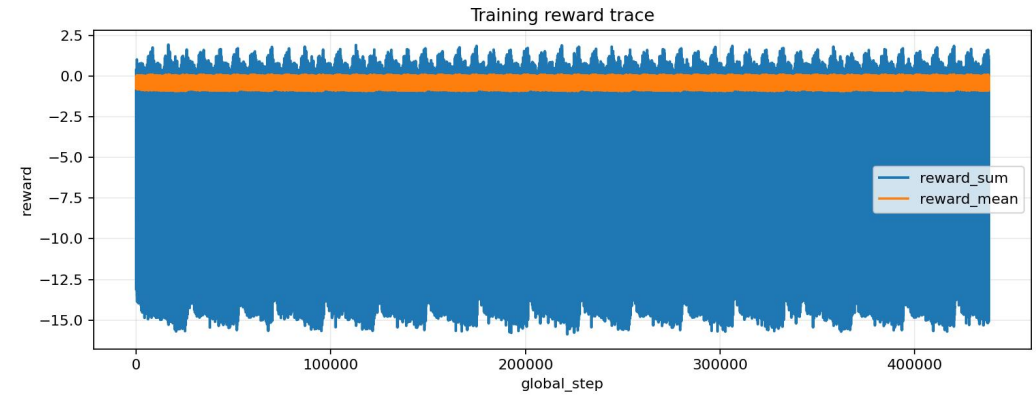

Figura JOB.059. MAAC/E2 — reward_timeseries.png — Serie temporal de recompensa.

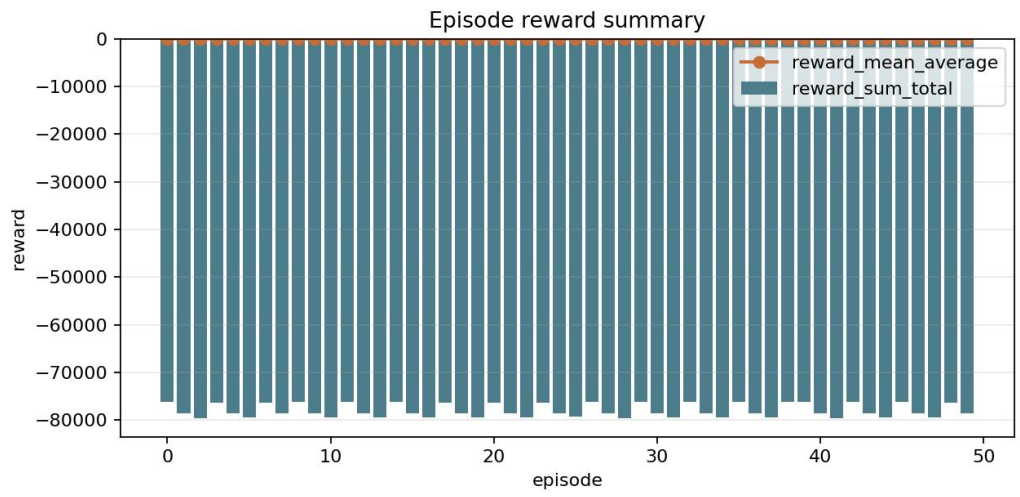

Figura JOB.060. MAAC/E2 — episode_reward_summary.png — Resumen de recompensa por episodio.

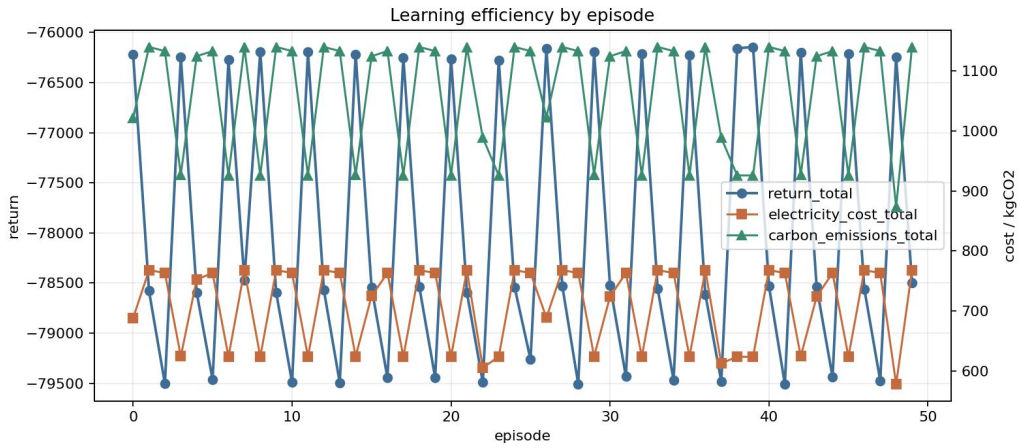

Figura JOB.061. MAAC/E2 — learning_efficiency.png — Eficiencia de aprendizaje.

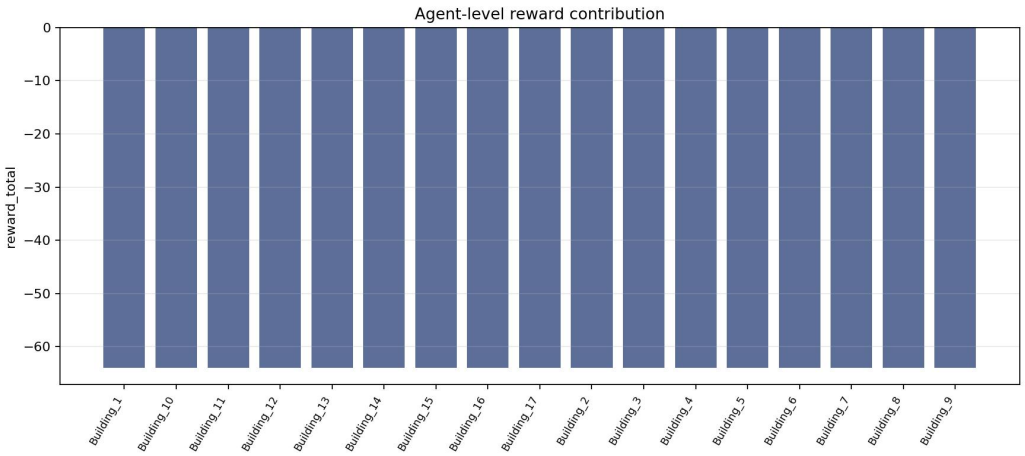

Figura JOB.062. MAAC/E2 — agent_reward_contribution.png — Contribución de recompensa por agente/edificio.

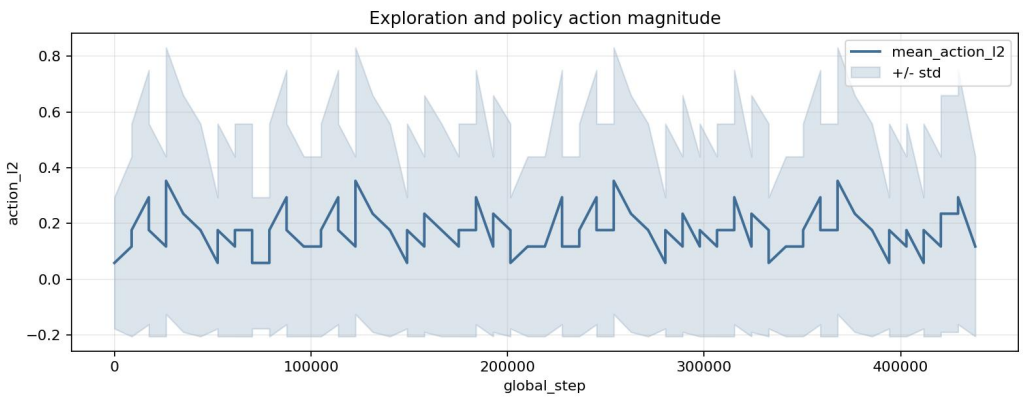

Figura JOB.063. MAAC/E2 — exploration_action_l2.png — Exploración (norma L2 de acciones).

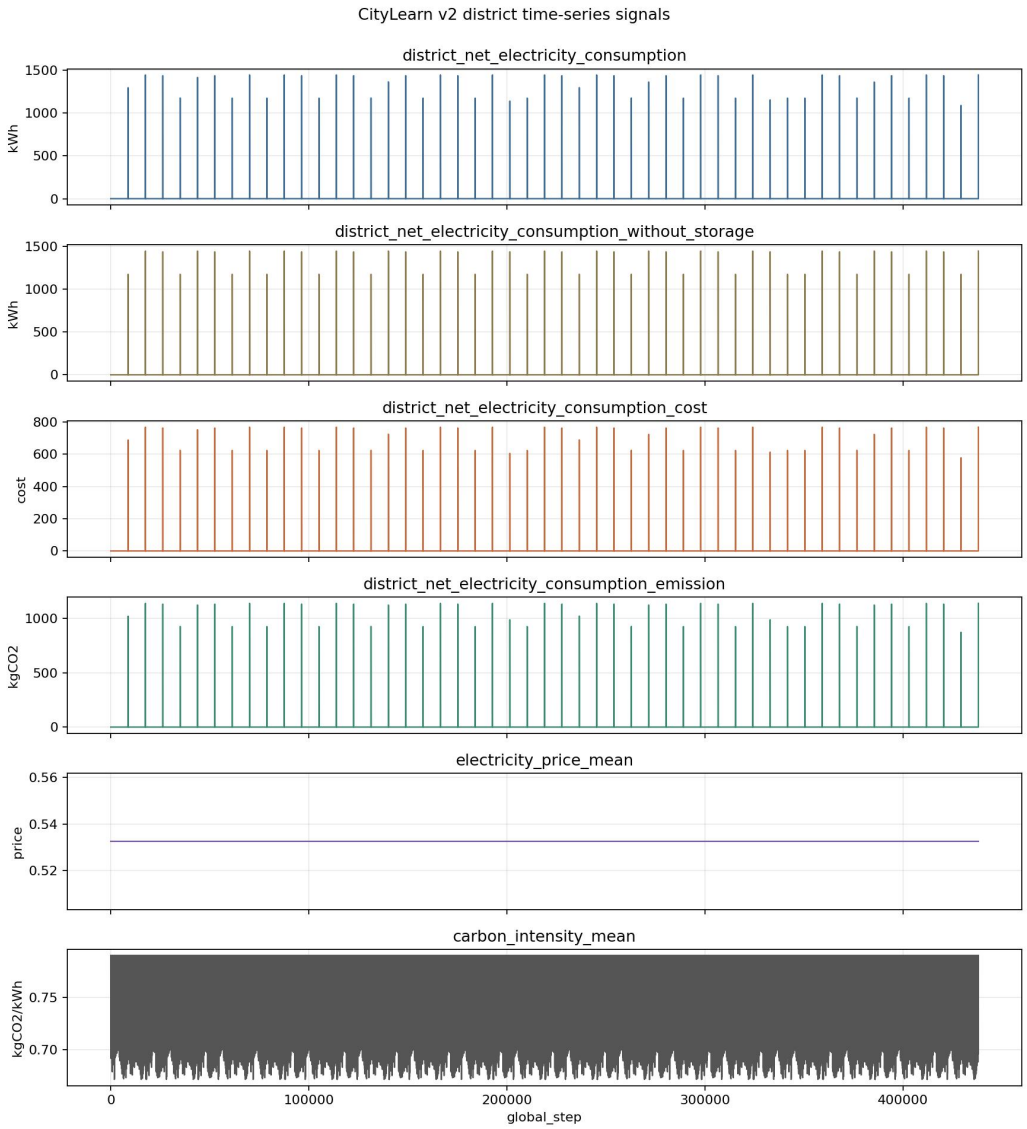

Figura JOB.064. MAAC/E2 — citylearn_v2_district_timeseries.png — Series temporales distritales CityLearn.

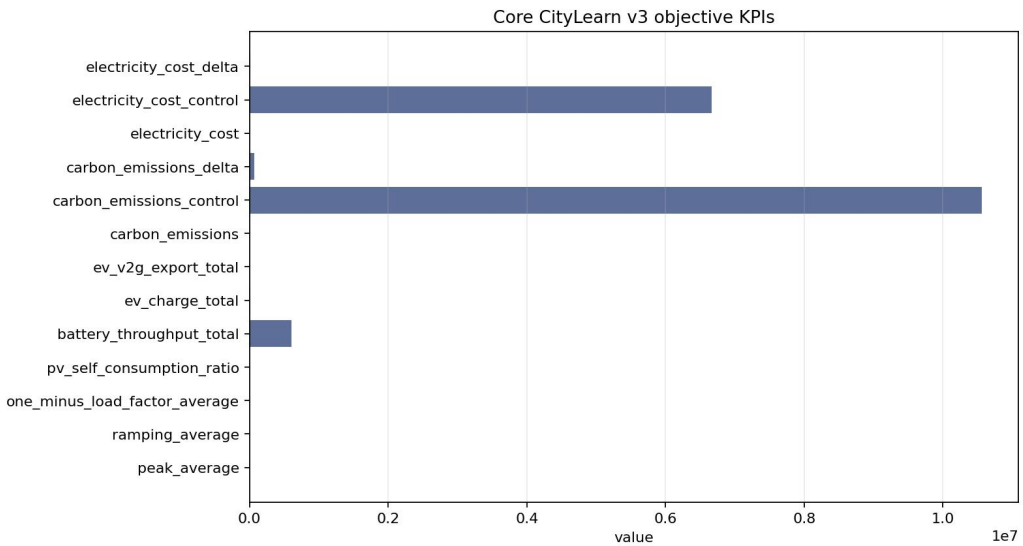

Figura JOB.065. MAAC/E2 — core_kpis.png — KPIs núcleo del job.

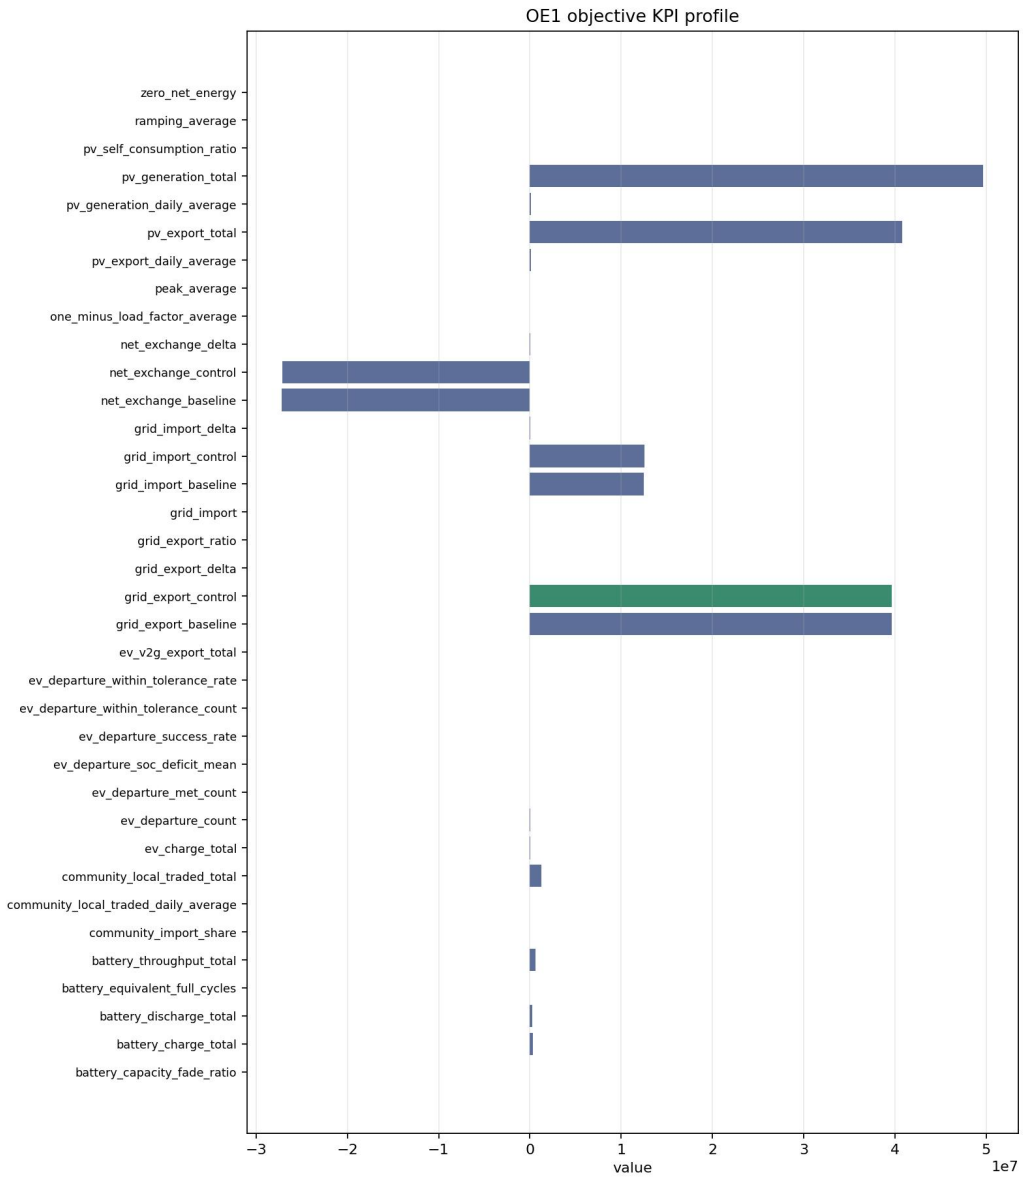

Figura JOB.066. MAAC/E2 — OE1_flexibility_kpis.png — KPIs de flexibilidad (OE.1).

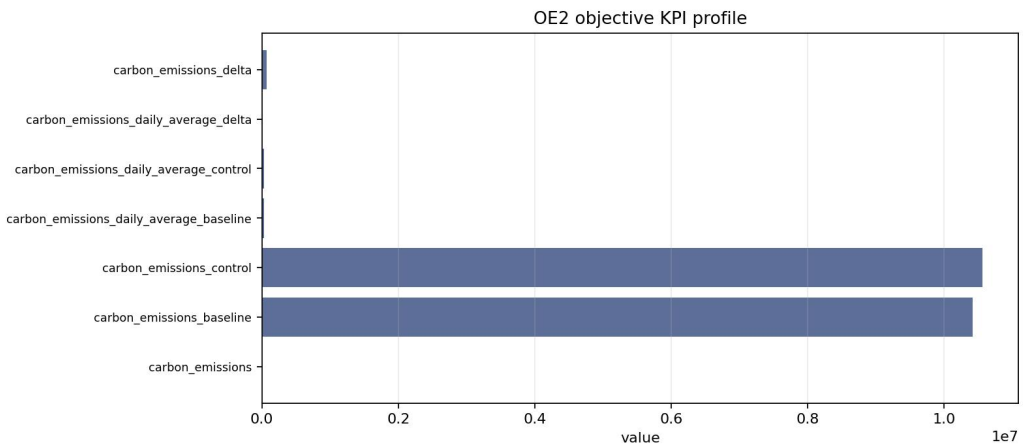

Figura JOB.067. MAAC/E2 — OE2_co2_kpis.png — KPIs de emisiones (OE.2).

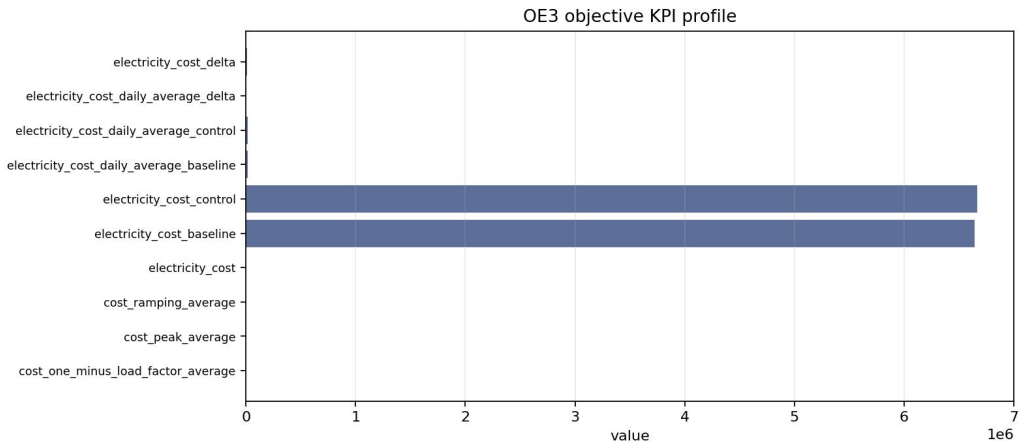

Figura JOB.068. MAAC/E2 — OE3_cost_kpis.png — KPIs de costo (OE.3).

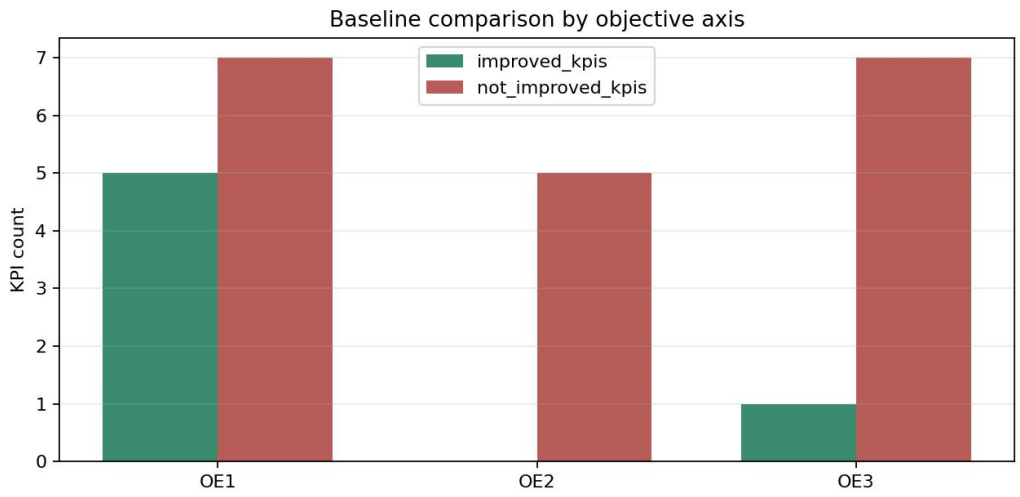

Figura JOB.069. MAAC/E2 — axis_baseline_comparison.png — Comparación por eje vs baseline.

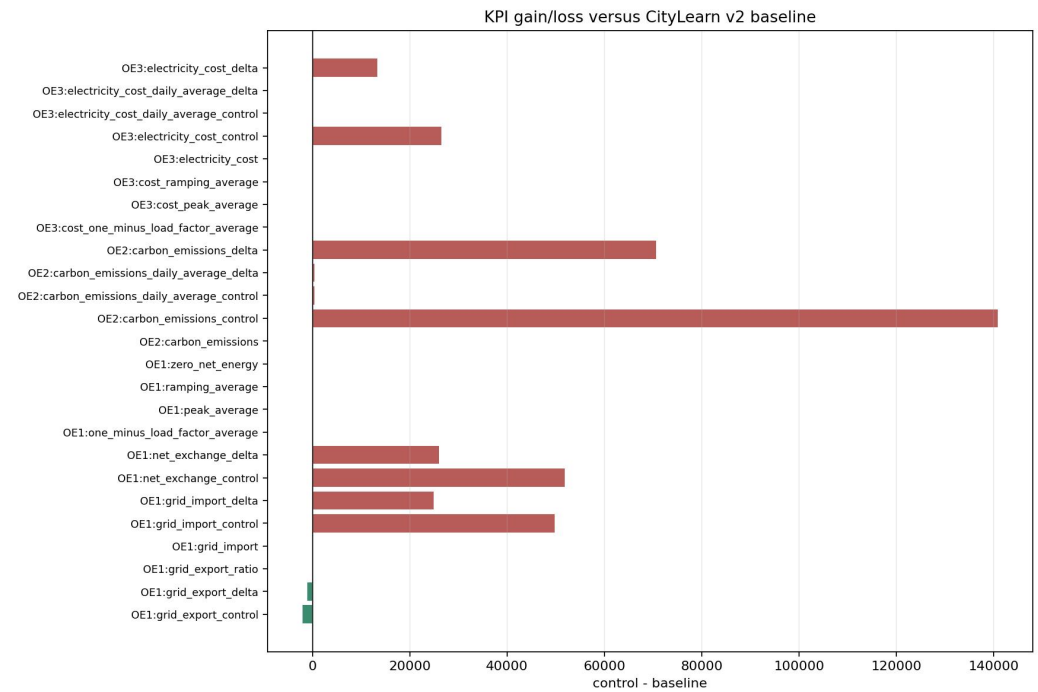

Figura JOB.070. MAAC/E2 — baseline_gain_by_kpi.png — Ganancia/pérdida por KPI vs baseline.

MAAC / E3

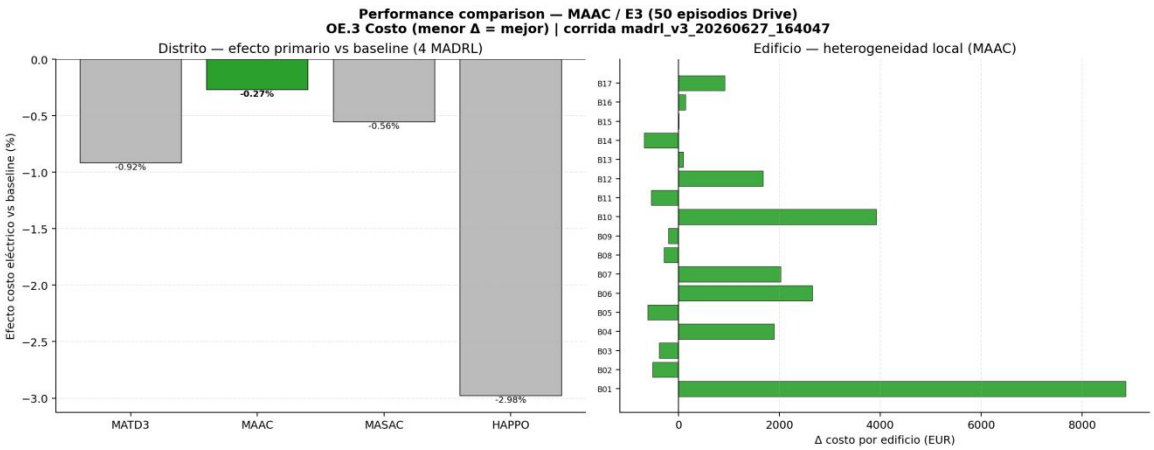

Figura JOB.071. MAAC/E3 — performance_comparison.png — Distrito (efecto % vs baseline de 4 MADRL) + edificio (17 edificios).

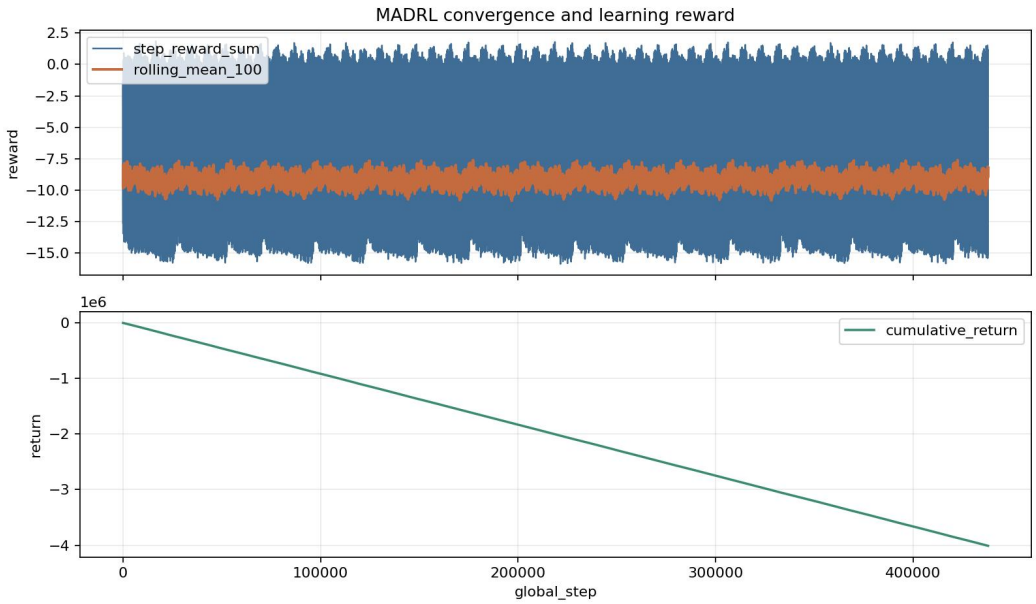

Figura JOB.072. MAAC/E3 — convergence_returns.png — Convergencia de retornos episódicos.

Figura JOB.073. MAAC/E3 — reward_timeseries.png — Serie temporal de recompensa.

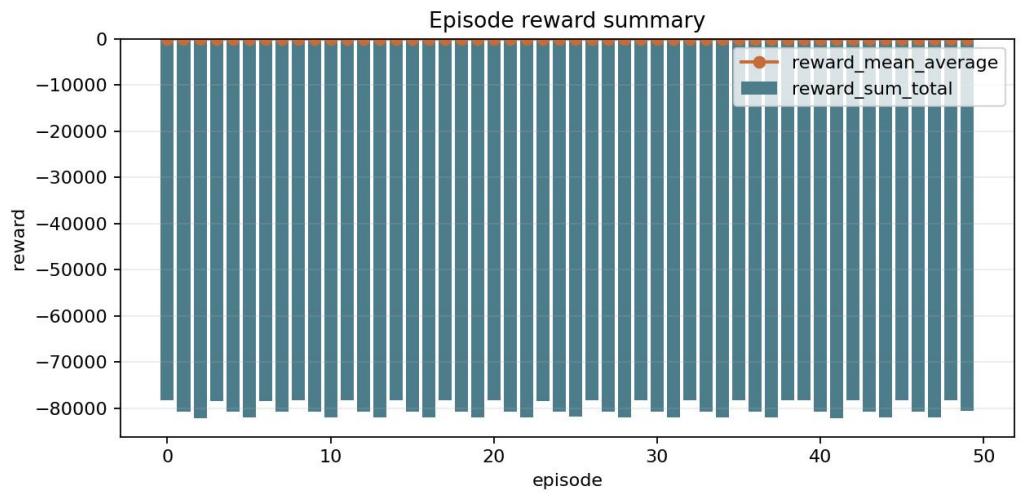

Figura JOB.074. MAAC/E3 — episode_reward_summary.png — Resumen de recompensa por episodio.

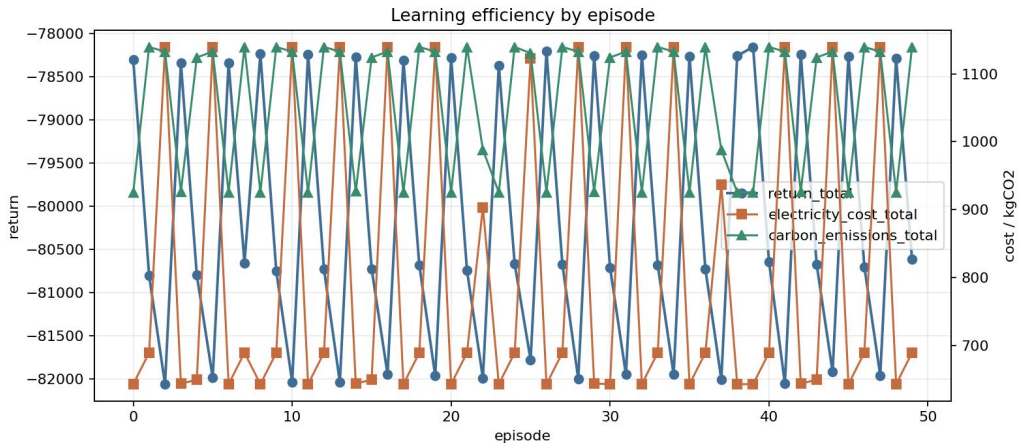

Figura JOB.075. MAAC/E3 — learning_efficiency.png — Eficiencia de aprendizaje.

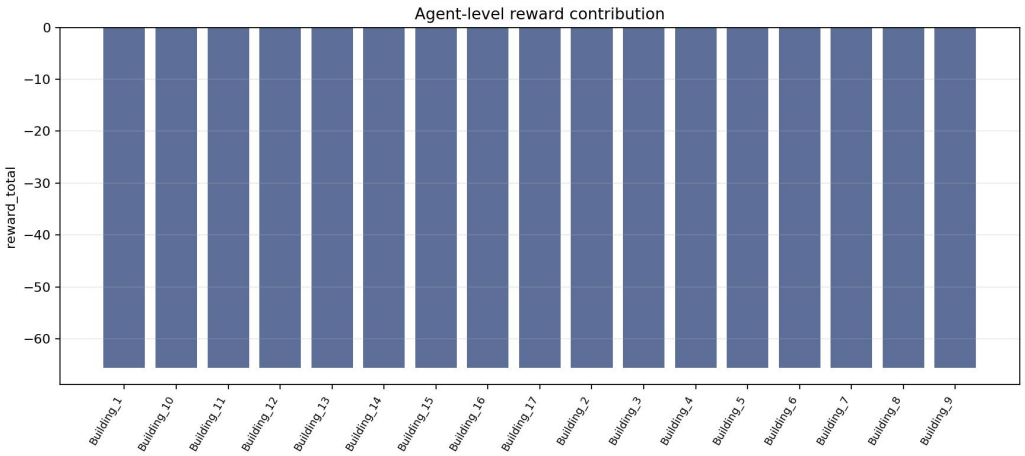

Figura JOB.076. MAAC/E3 — agent_reward_contribution.png — Contribución de recompensa por agente/edificio.

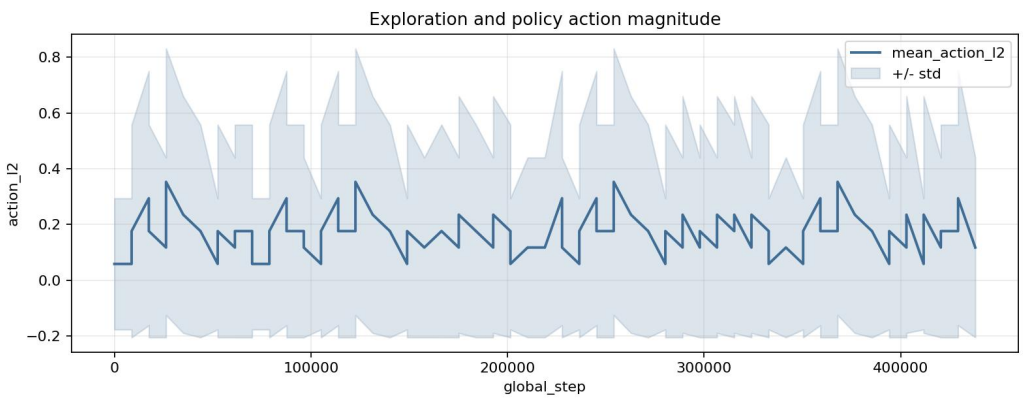

Figura JOB.077. MAAC/E3 — exploration_action_l2.png — Exploración (norma L2 de acciones).

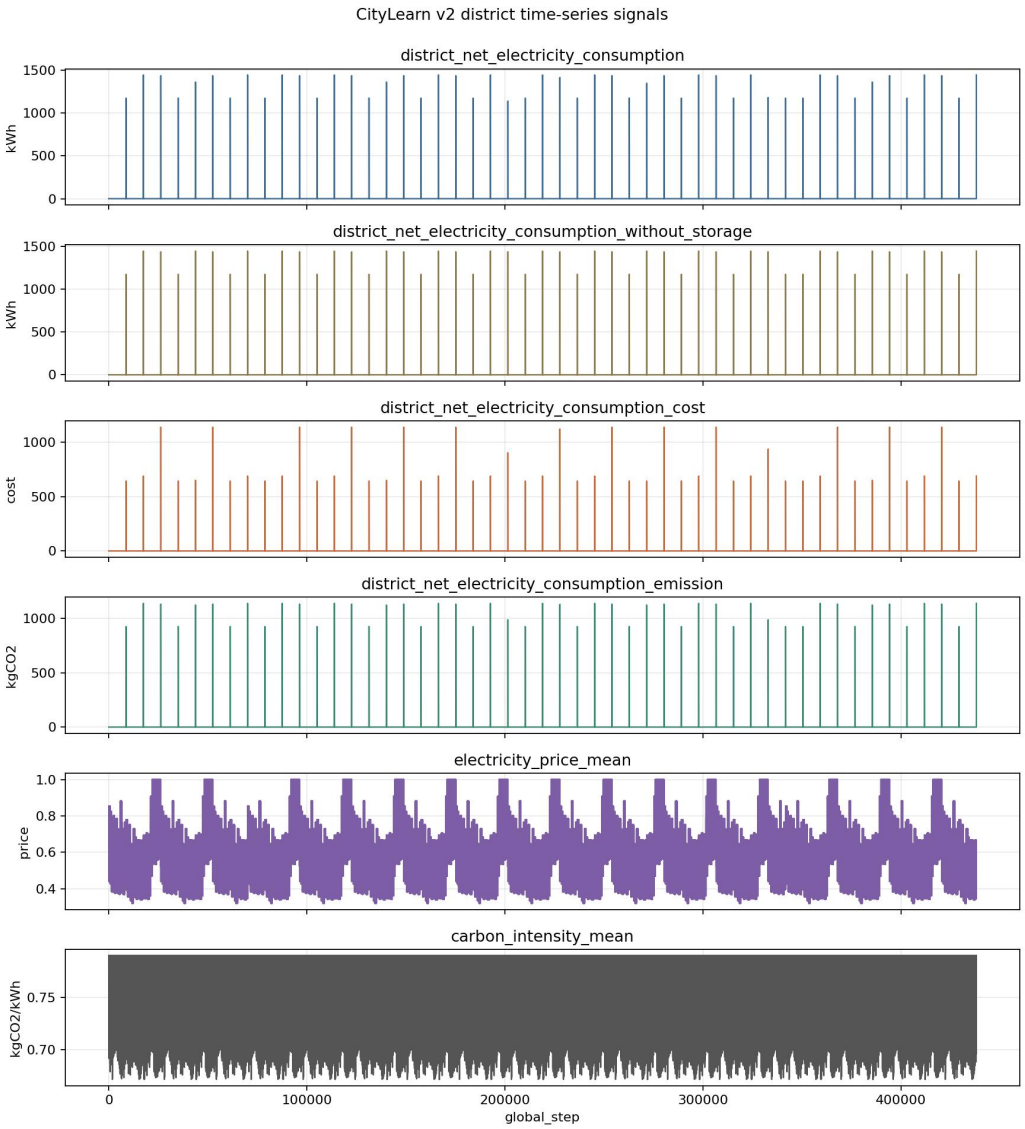

Figura JOB.078. MAAC/E3 — citylearn_v2_district_timeseries.png — Series temporales distritales CityLearn.

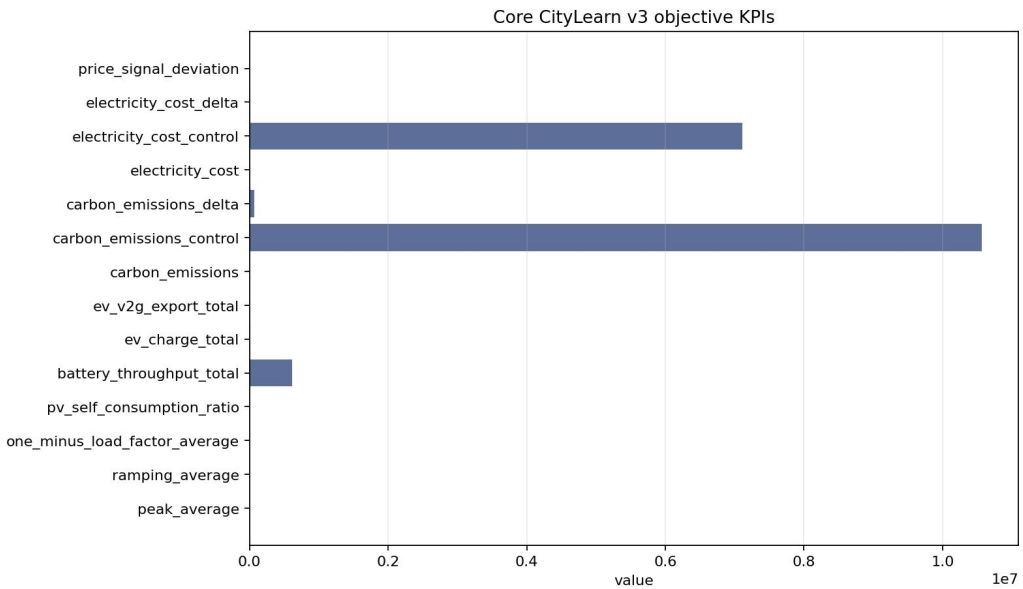

Figura JOB.079. MAAC/E3 — core_kpis.png — KPIs núcleo del job.

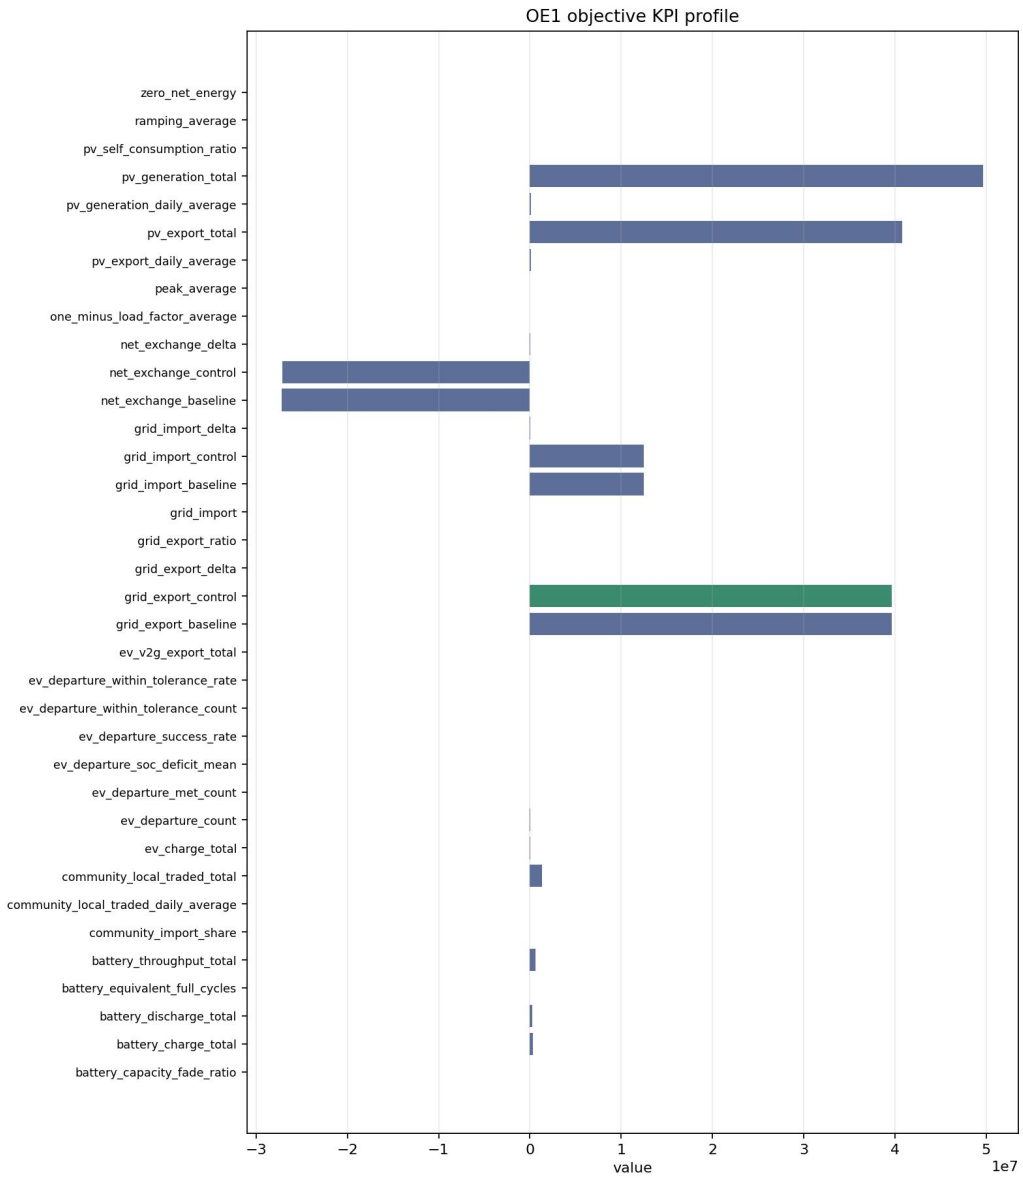

Figura JOB.080. MAAC/E3 — OE1_flexibility_kpis.png — KPIs de flexibilidad (OE.1).

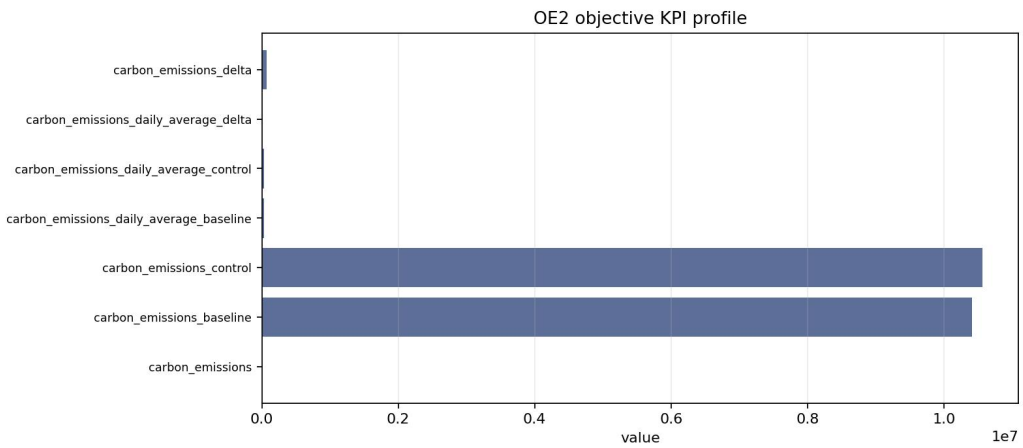

Figura JOB.081. MAAC/E3 — OE2_co2_kpis.png — KPIs de emisiones (OE.2).

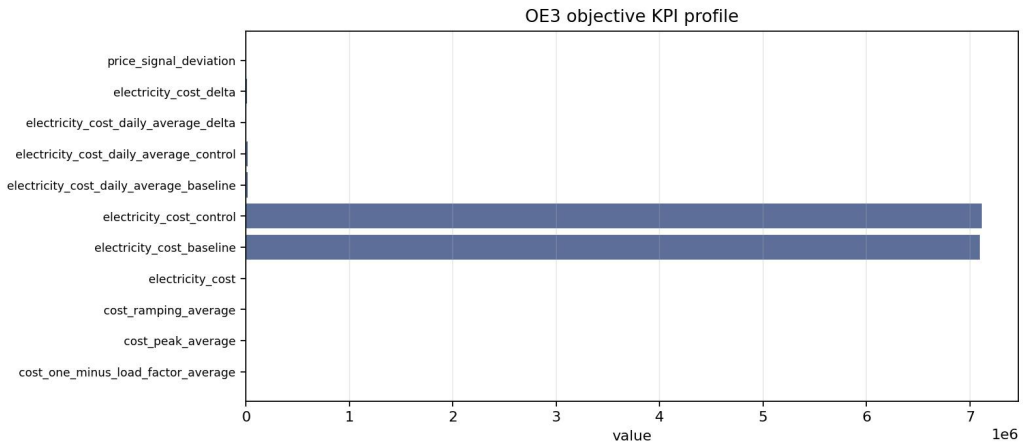

Figura JOB.082. MAAC/E3 — OE3_cost_kpis.png — KPIs de costo (OE.3).

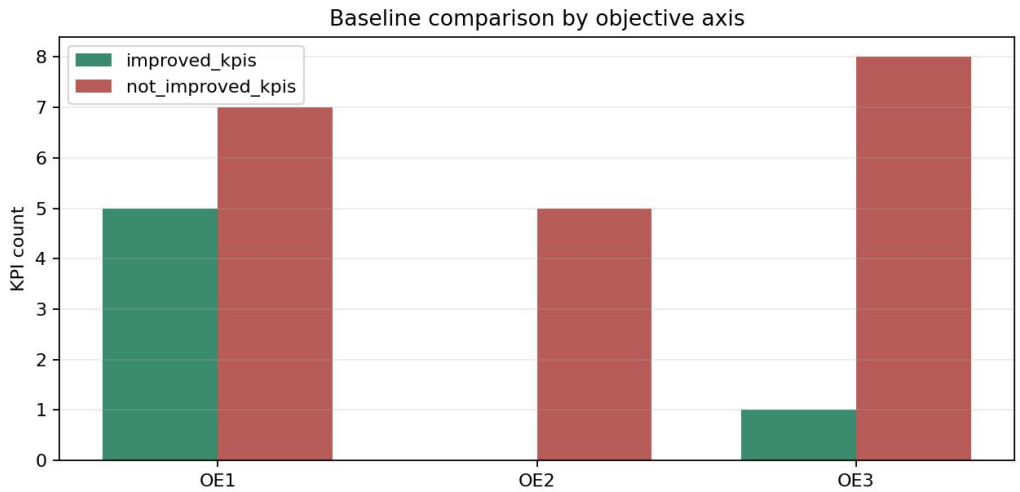

Figura JOB.083. MAAC/E3 — axis_baseline_comparison.png — Comparación por eje vs baseline.

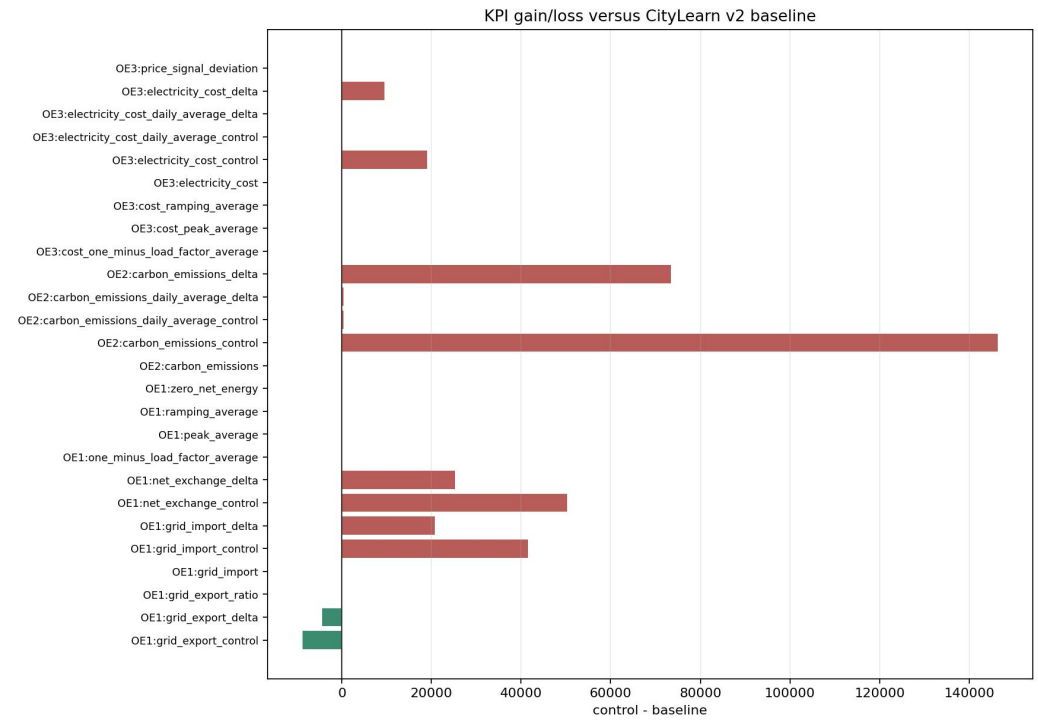

Figura JOB.084. MAAC/E3 — baseline_gain_by_kpi.png — Ganancia/pérdida por KPI vs baseline.

C.MASAC — figuras de performance

MASAC / E1

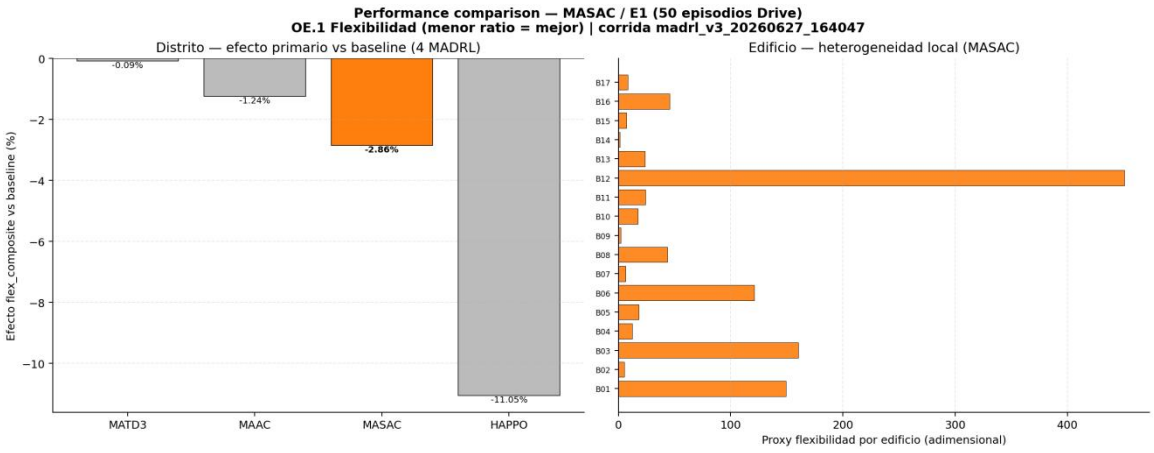

Figura JOB.085. MASAC/E1 — performance_comparison.png — Distrito (efecto % vs baseline de 4 MADRL) + edificio (17 edificios).

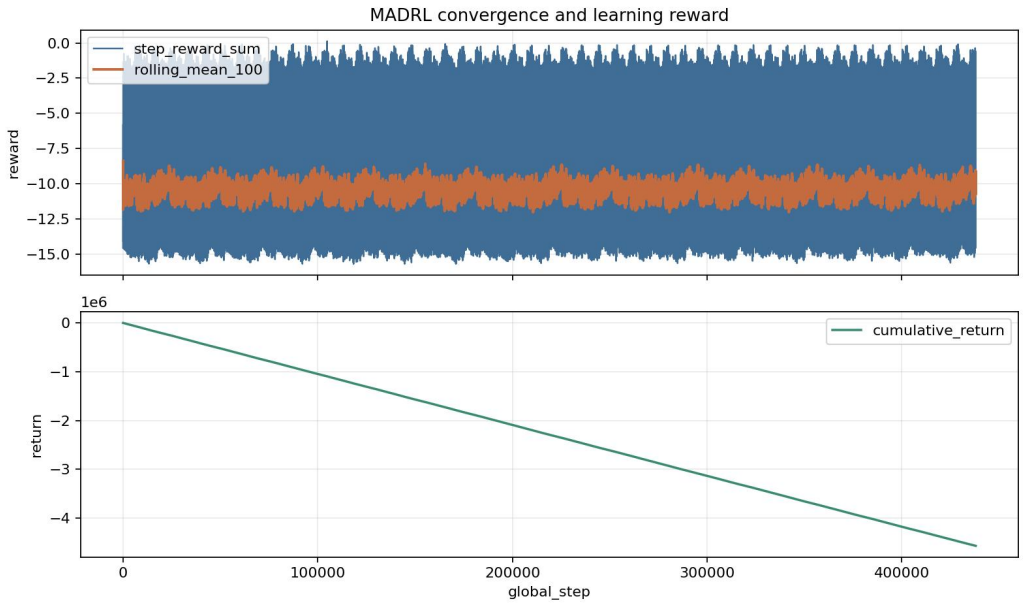

Figura JOB.086. MASAC/E1 — convergence_returns.png — Convergencia de retornos episódicos.

Figura JOB.087. MASAC/E1 — reward_timeseries.png — Serie temporal de recompensa.

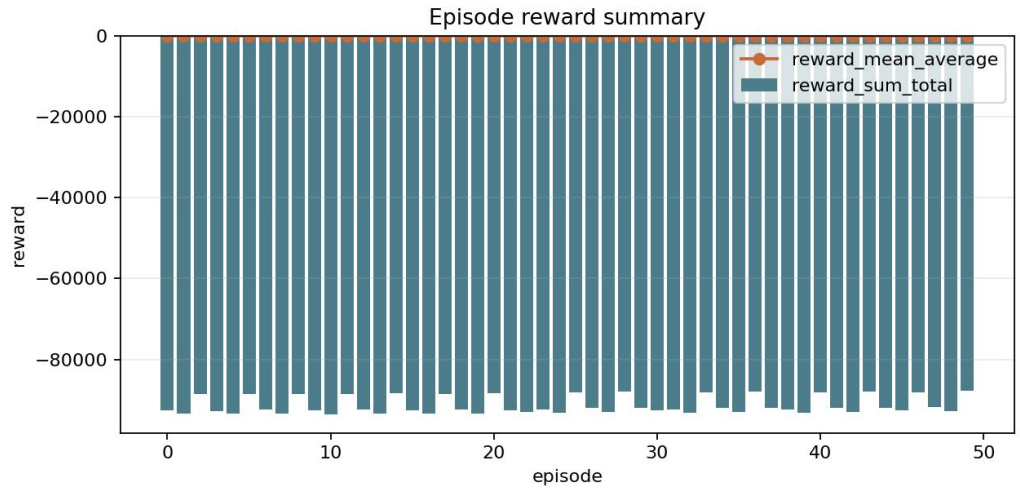

Figura JOB.088. MASAC/E1 — episode_reward_summary.png — Resumen de recompensa por episodio.

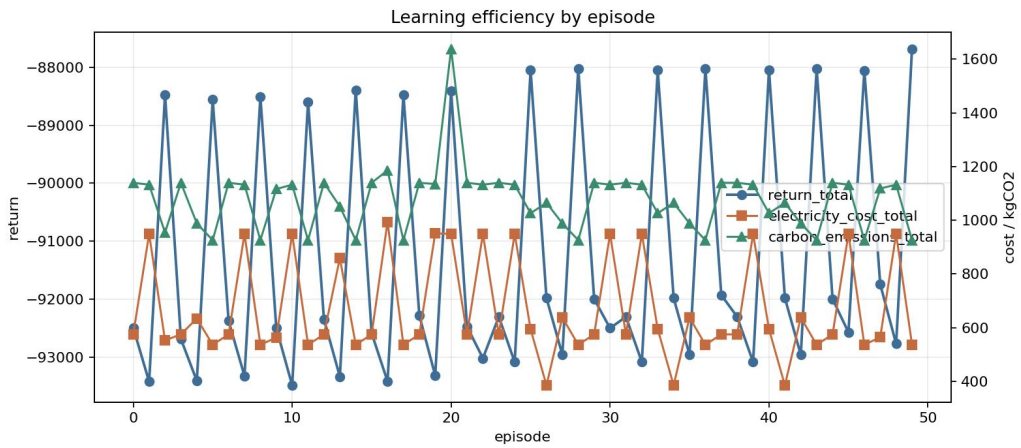

Figura JOB.089. MASAC/E1 — learning_efficiency.png — Eficiencia de aprendizaje.

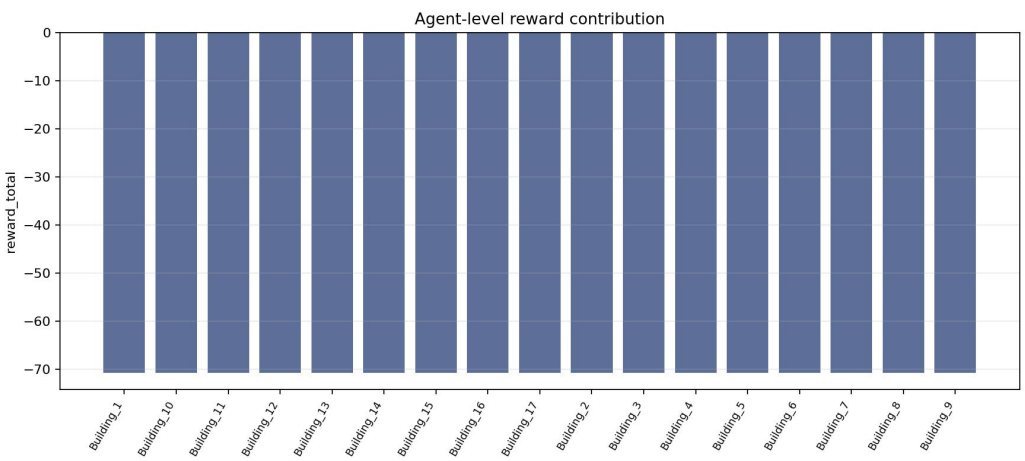

Figura JOB.090. MASAC/E1 — agent_reward_contribution.png — Contribución de recompensa por agente/edificio.

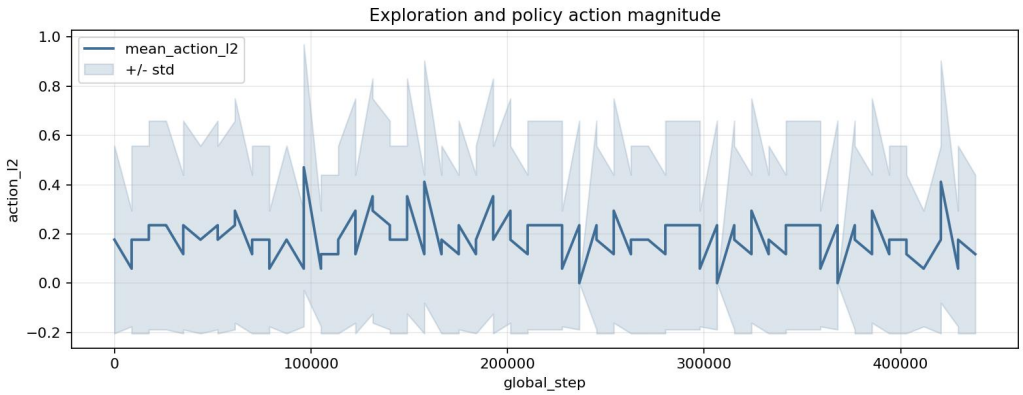

Figura JOB.091. MASAC/E1 — exploration_action_l2.png — Exploración (norma L2 de acciones).

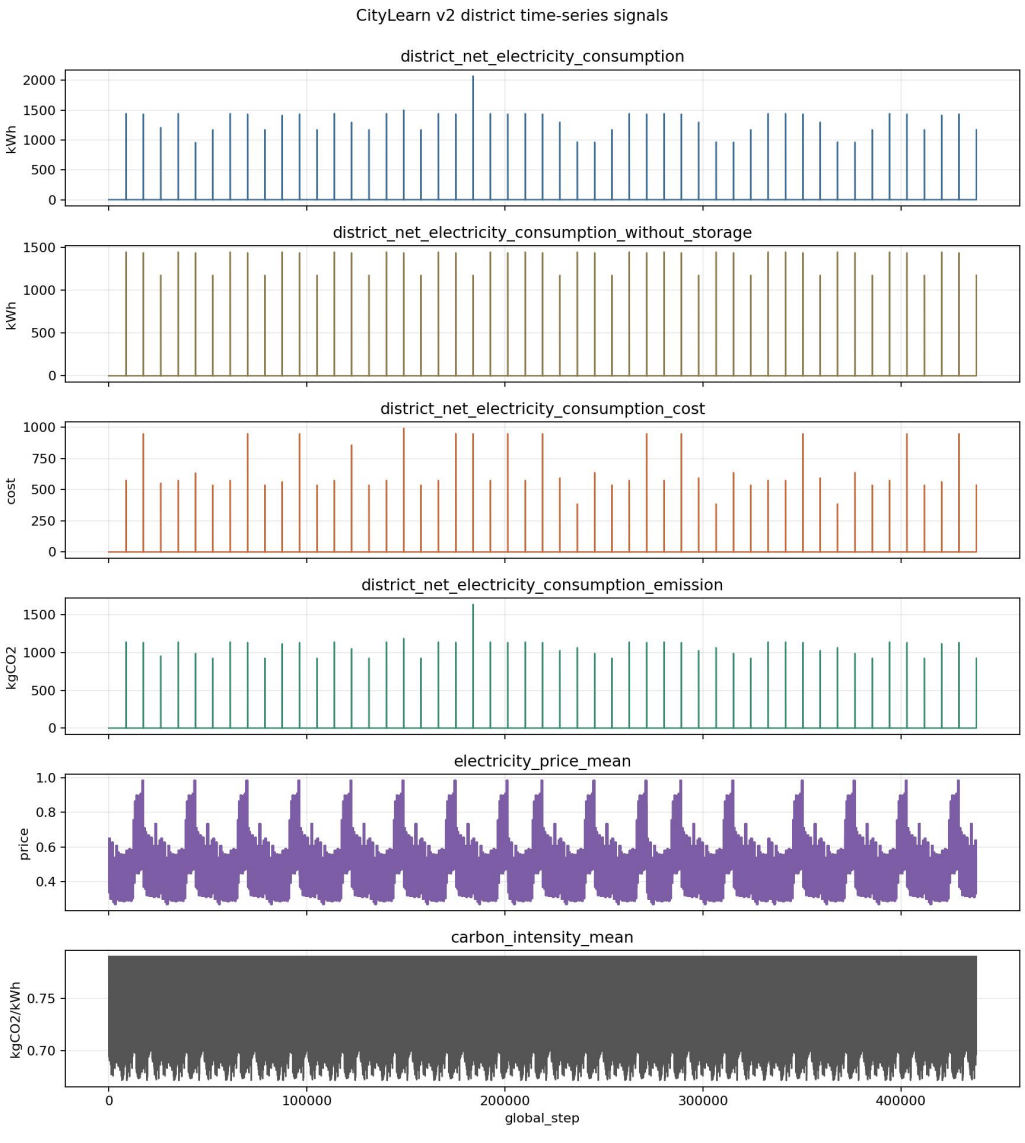

Figura JOB.092. MASAC/E1 — citylearn_v2_district_timeseries.png — Series temporales distritales CityLearn.

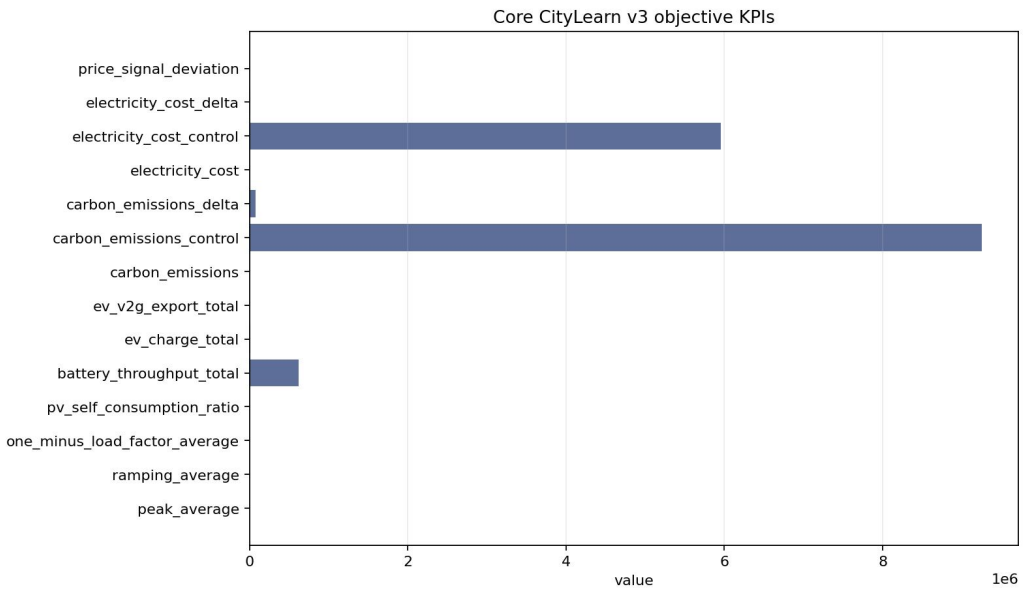

Figura JOB.093. MASAC/E1 — core_kpis.png — KPIs núcleo del job.

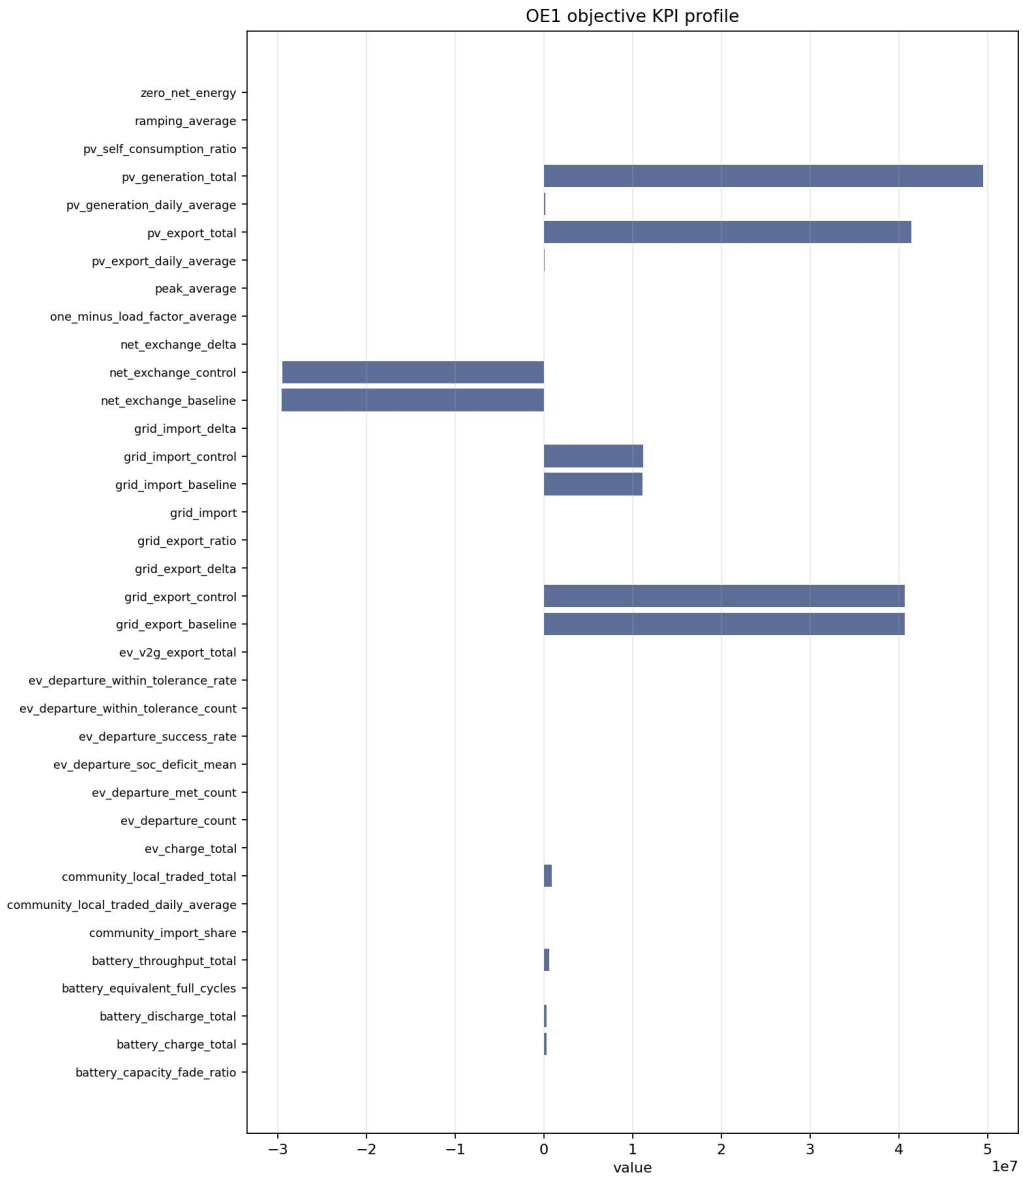

Figura JOB.094. MASAC/E1 — OE1_flexibility_kpis.png — KPIs de flexibilidad (OE.1).

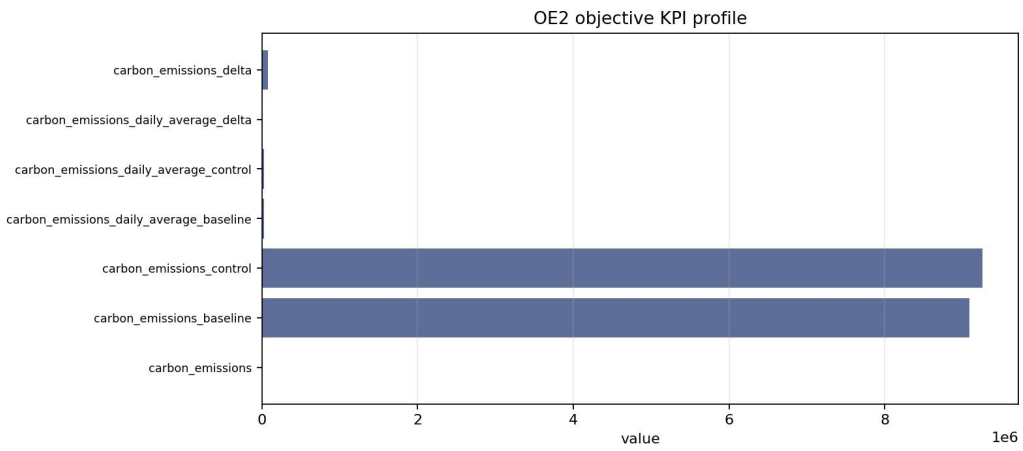

Figura JOB.095. MASAC/E1 — OE2_co2_kpis.png — KPIs de emisiones (OE.2).

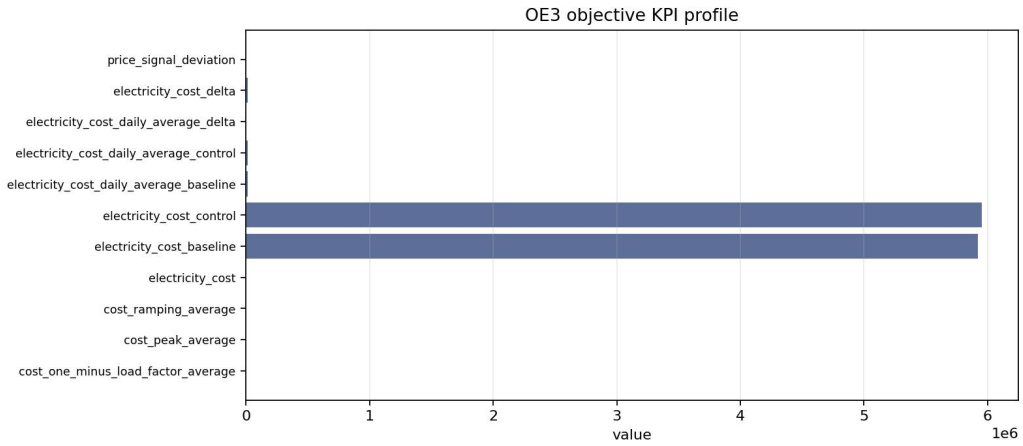

Figura JOB.096. MASAC/E1 — OE3_cost_kpis.png — KPIs de costo (OE.3).

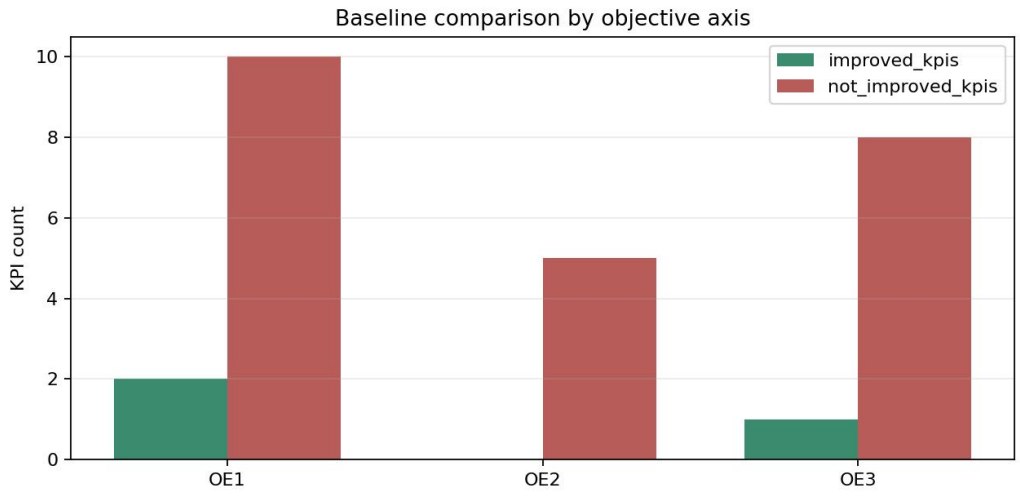

Figura JOB.097. MASAC/E1 — axis_baseline_comparison.png — Comparación por eje vs baseline.

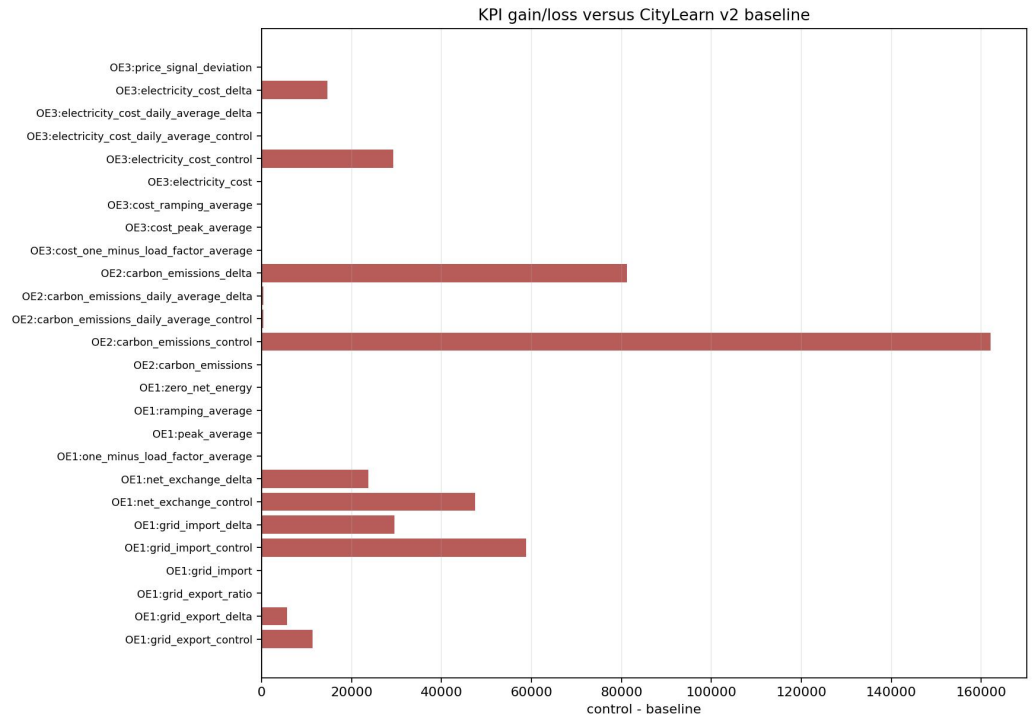

Figura JOB.098. MASAC/E1 — baseline_gain_by_kpi.png — Ganancia/pérdida por KPI vs baseline.

MASAC / E2

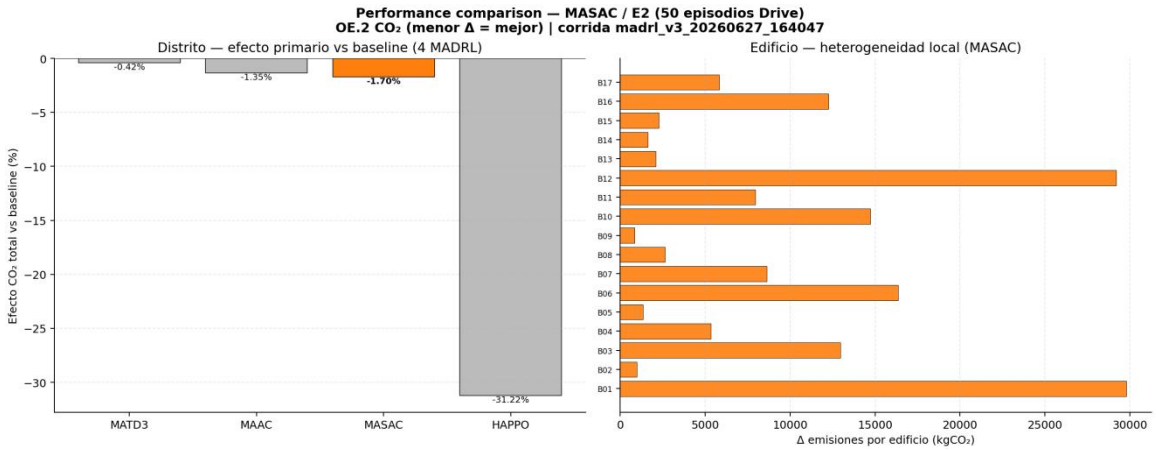

Figura JOB.099. MASAC/E2 — performance_comparison.png — Distrito (efecto % vs baseline de 4 MADRL) + edificio (17 edificios).

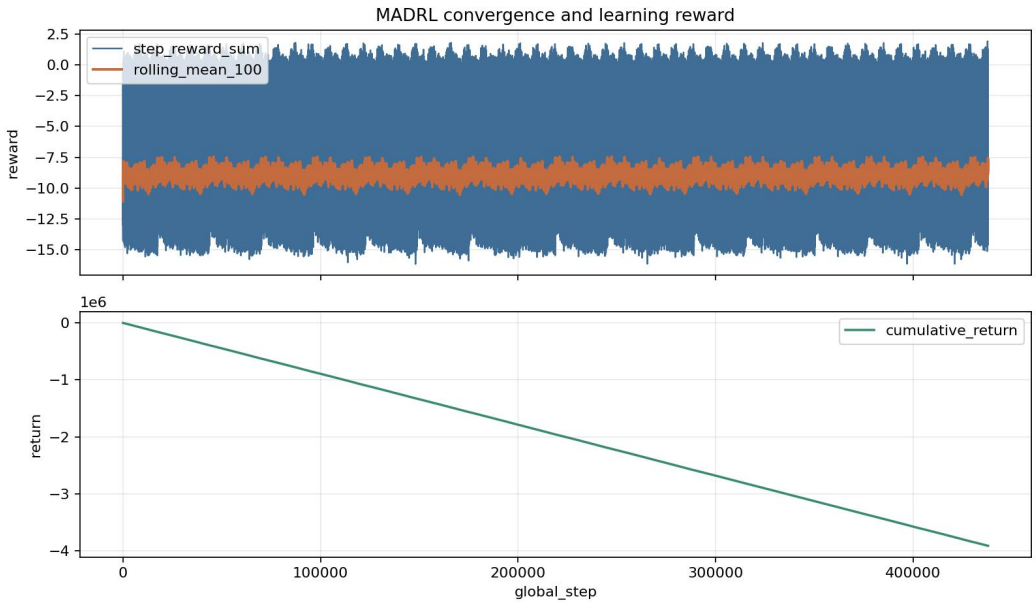

Figura JOB.100. MASAC/E2 — convergence_returns.png — Convergencia de retornos episódicos.

Figura JOB.101. MASAC/E2 — reward_timeseries.png — Serie temporal de recompensa.

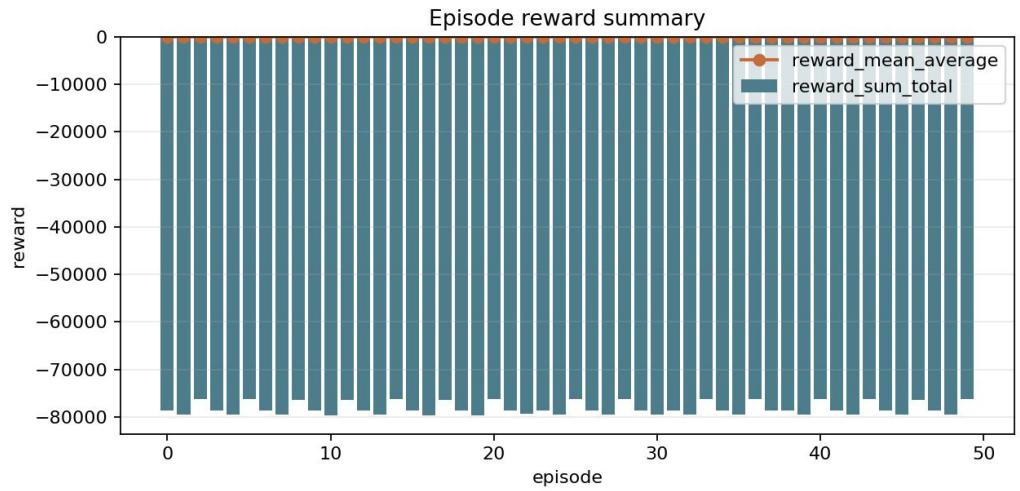

Figura JOB.102. MASAC/E2 — episode_reward_summary.png — Resumen de recompensa por episodio.

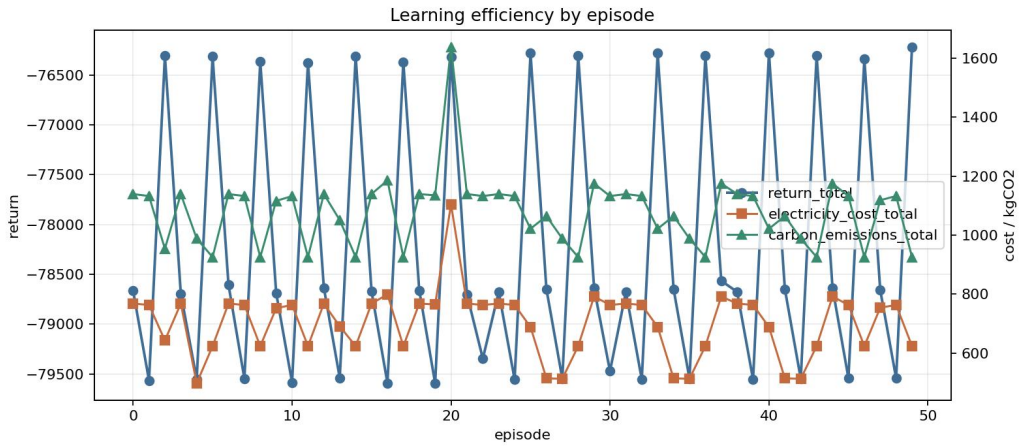

Figura JOB.103. MASAC/E2 — learning_efficiency.png — Eficiencia de aprendizaje.

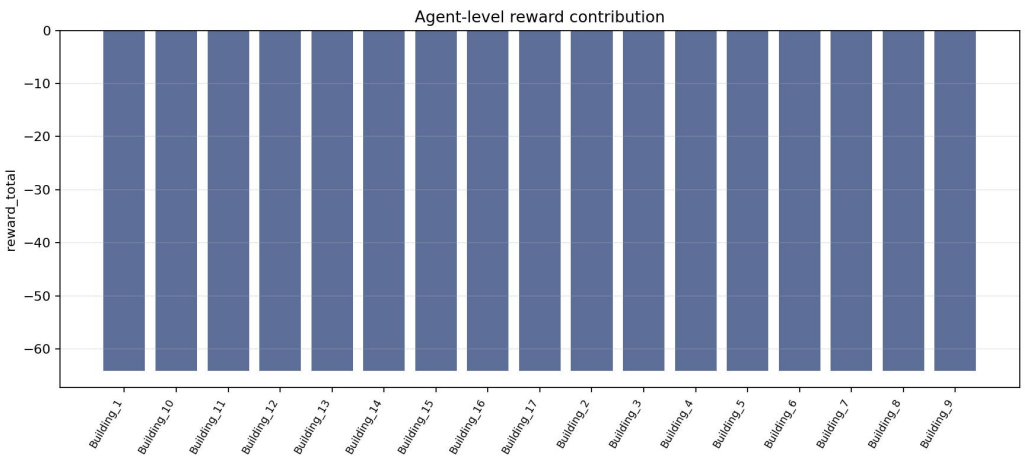

Figura JOB.104. MASAC/E2 — agent_reward_contribution.png — Contribución de recompensa por agente/edificio.

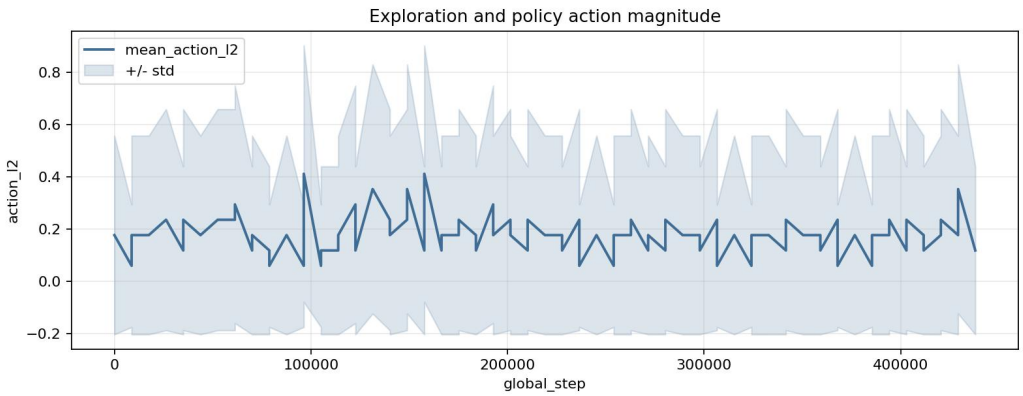

Figura JOB.105. MASAC/E2 — exploration_action_l2.png — Exploración (norma L2 de acciones).

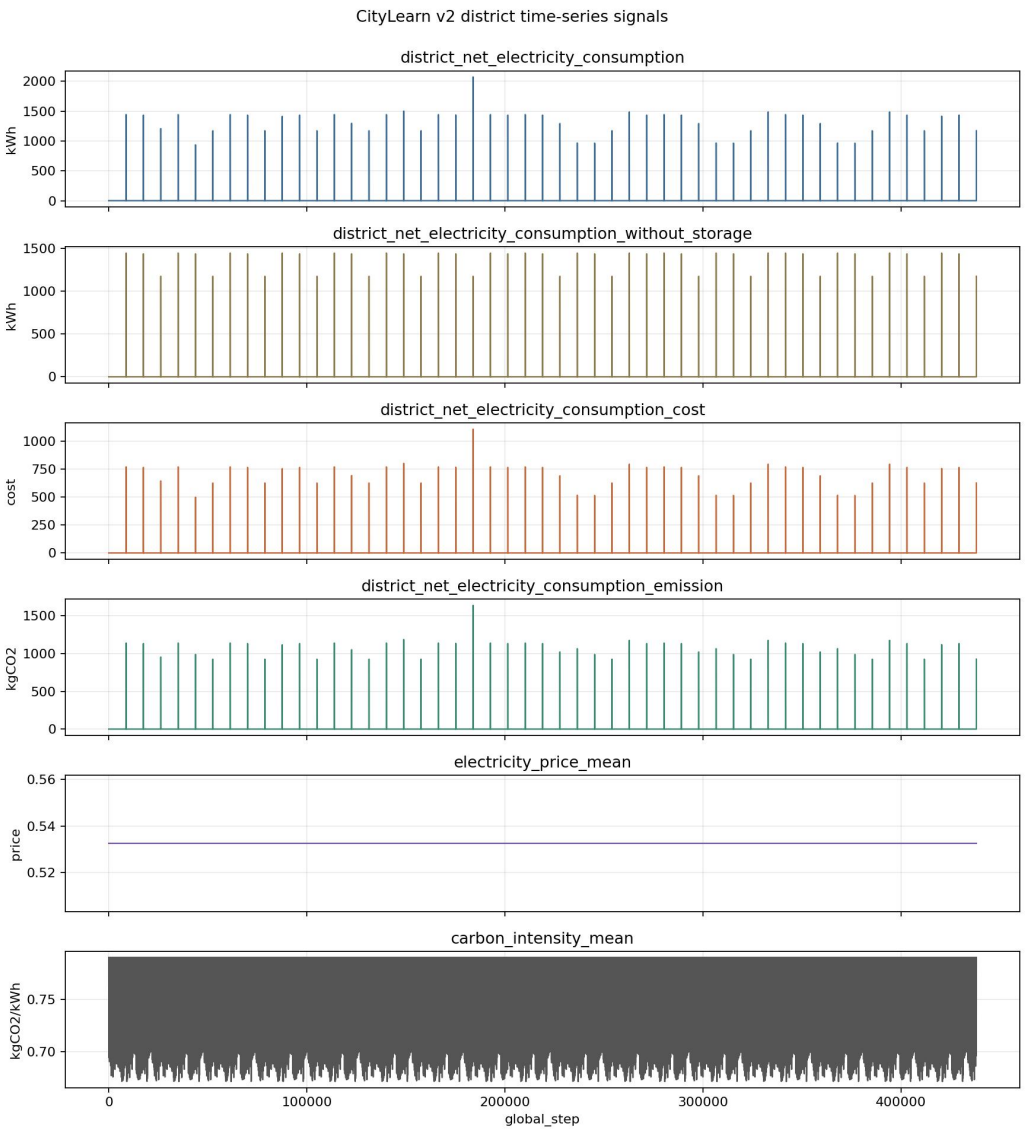

Figura JOB.106. MASAC/E2 — citylearn_v2_district_timeseries.png — Series temporales distritales CityLearn.

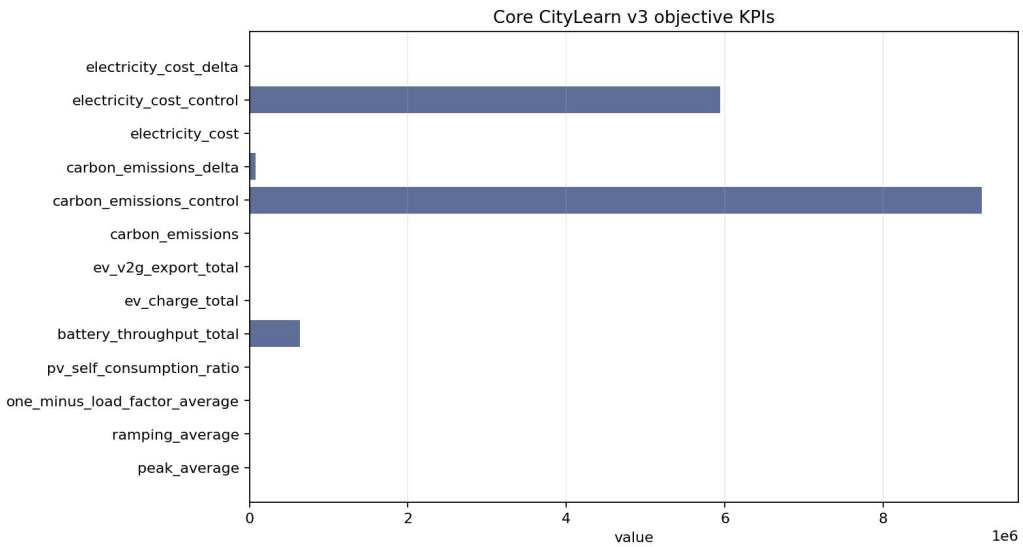

Figura JOB.107. MASAC/E2 — core_kpis.png — KPIs núcleo del job.

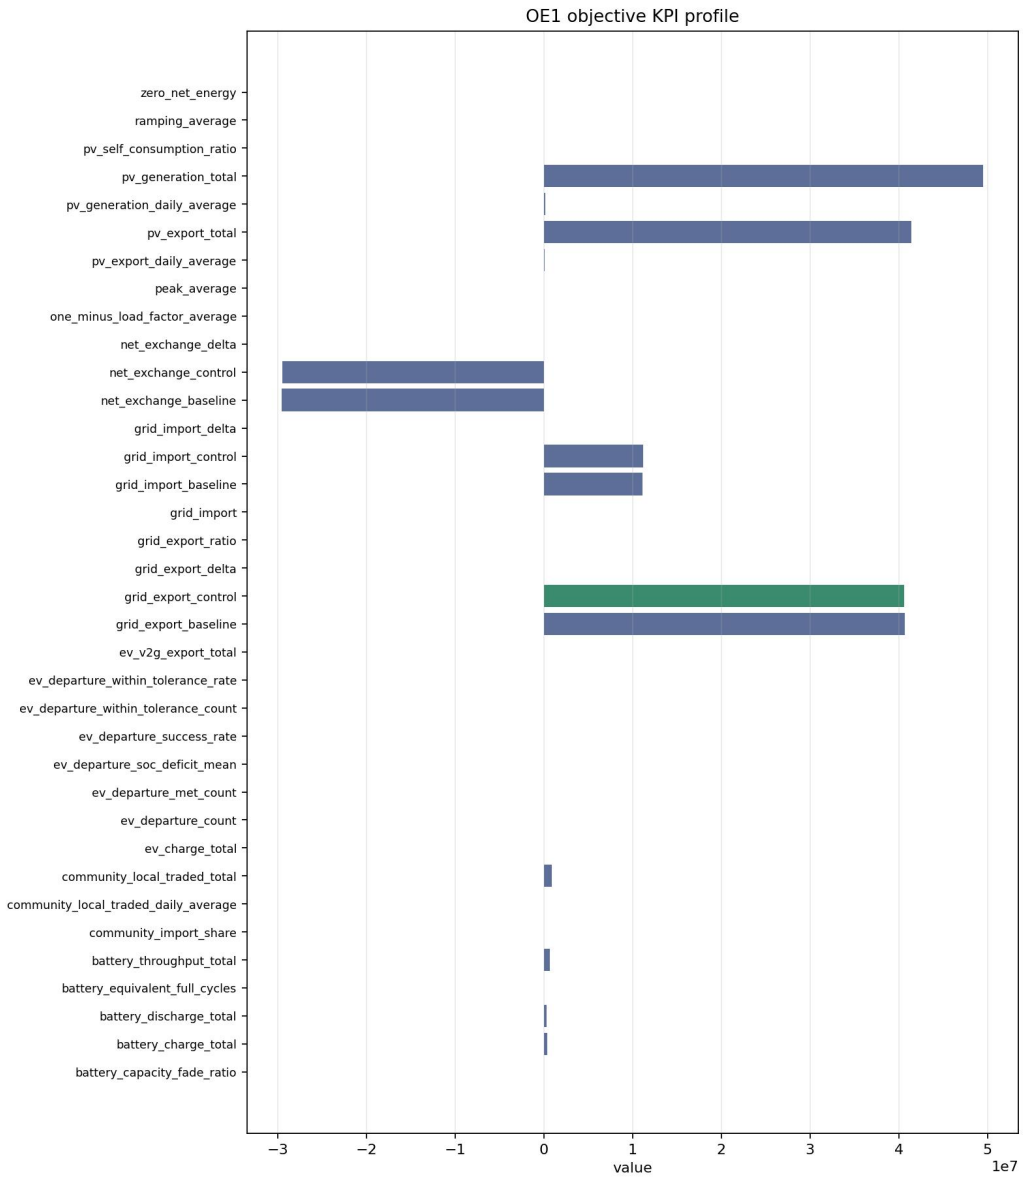

Figura JOB.108. MASAC/E2 — OE1_flexibility_kpis.png — KPIs de flexibilidad (OE.1).

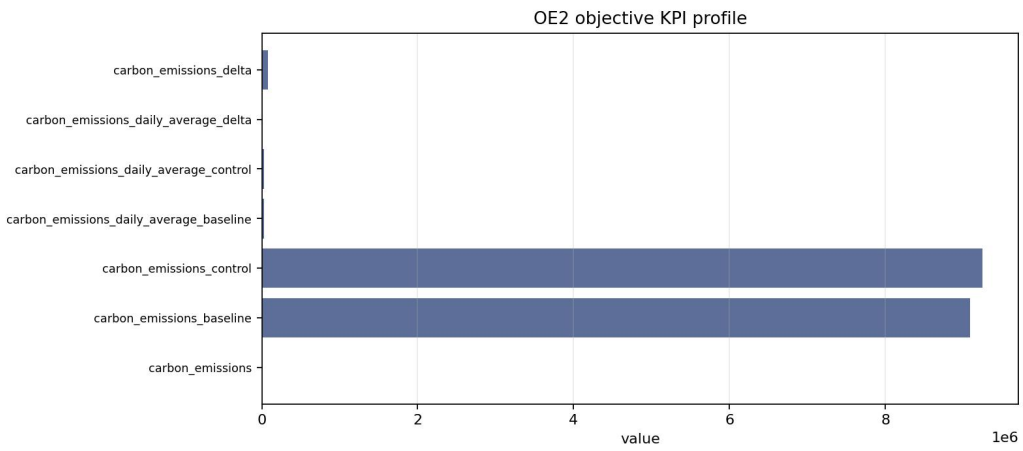

Figura JOB.109. MASAC/E2 — OE2_co2_kpis.png — KPIs de emisiones (OE.2).

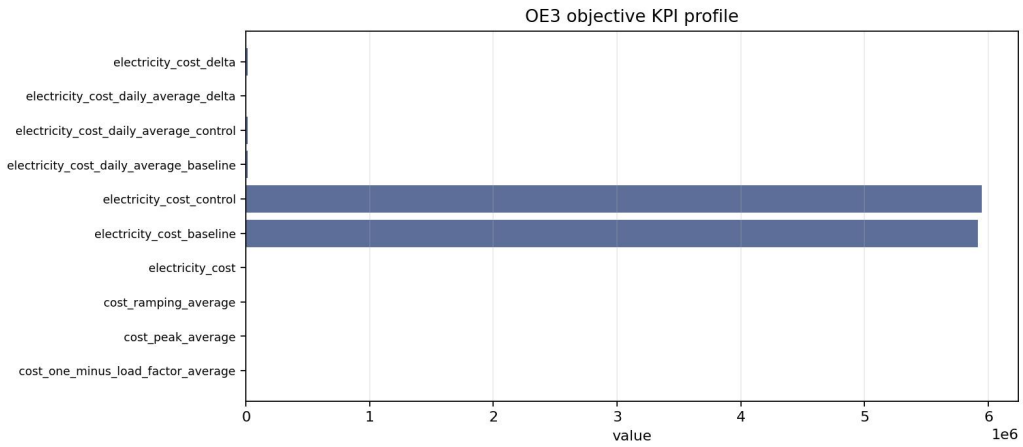

Figura JOB.110. MASAC/E2 — OE3_cost_kpis.png — KPIs de costo (OE.3).

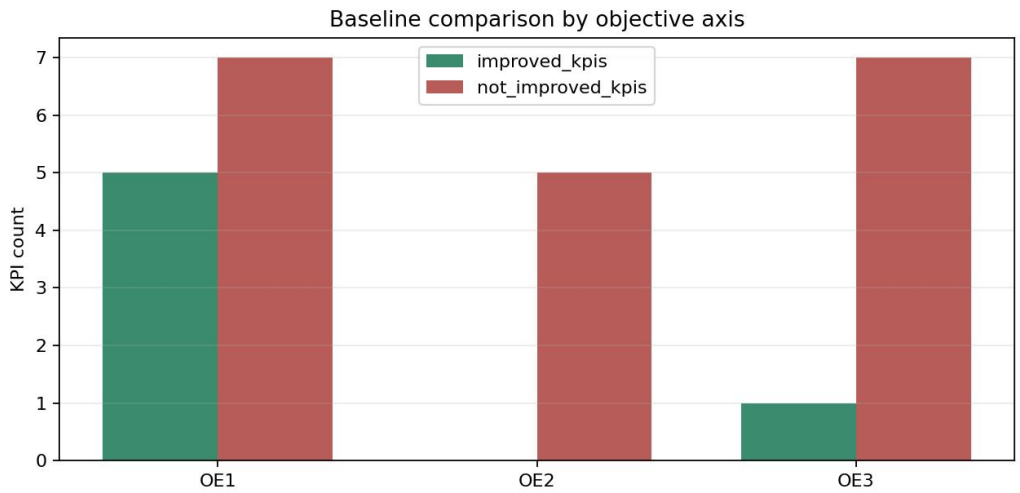

Figura JOB.111. MASAC/E2 — axis_baseline_comparison.png — Comparación por eje vs baseline.

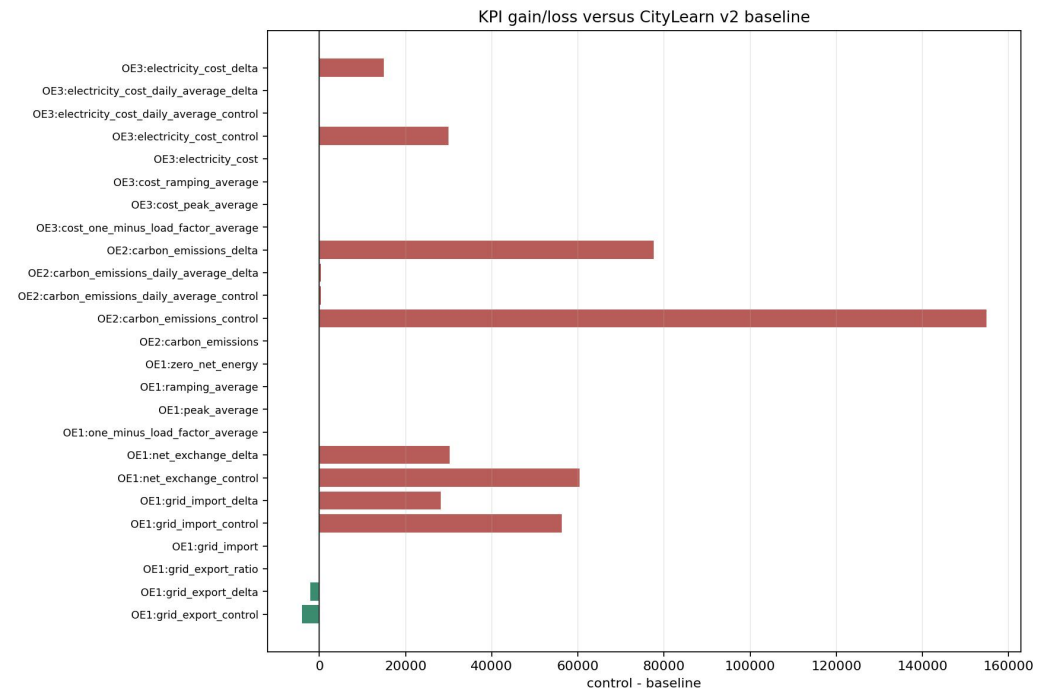

Figura JOB.112. MASAC/E2 — baseline_gain_by_kpi.png — Ganancia/pérdida por KPI vs baseline.

MASAC / E3

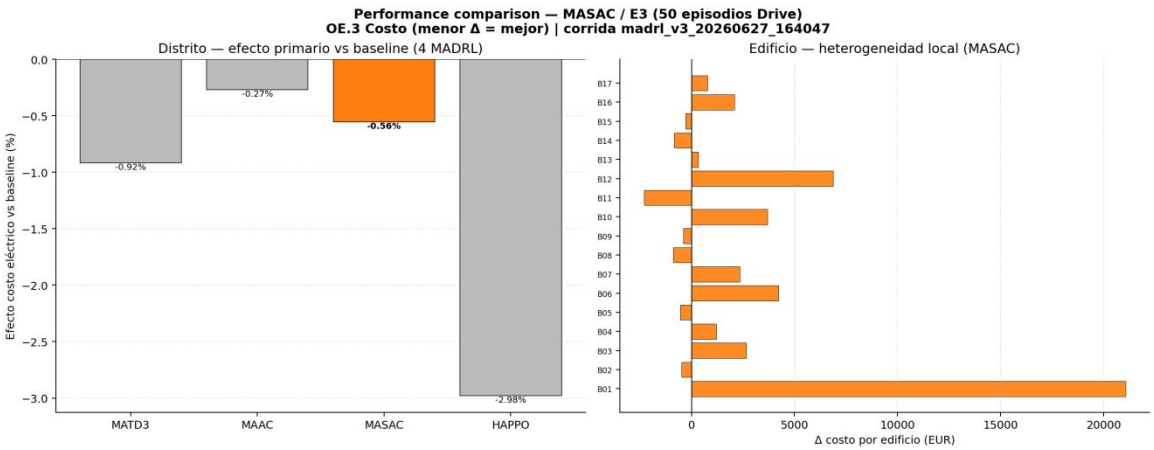

Figura JOB.113. MASAC/E3 — performance_comparison.png — Distrito (efecto % vs baseline de 4 MADRL) + edificio (17 edificios).

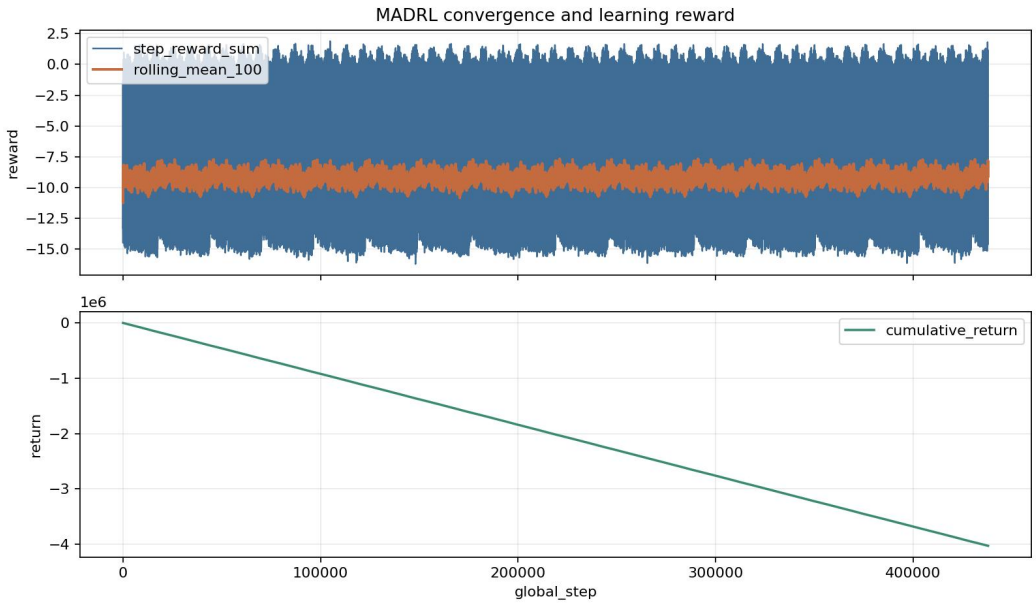

Figura JOB.114. MASAC/E3 — convergence_returns.png — Convergencia de retornos episódicos.

Figura JOB.115. MASAC/E3 — reward_timeseries.png — Serie temporal de recompensa.

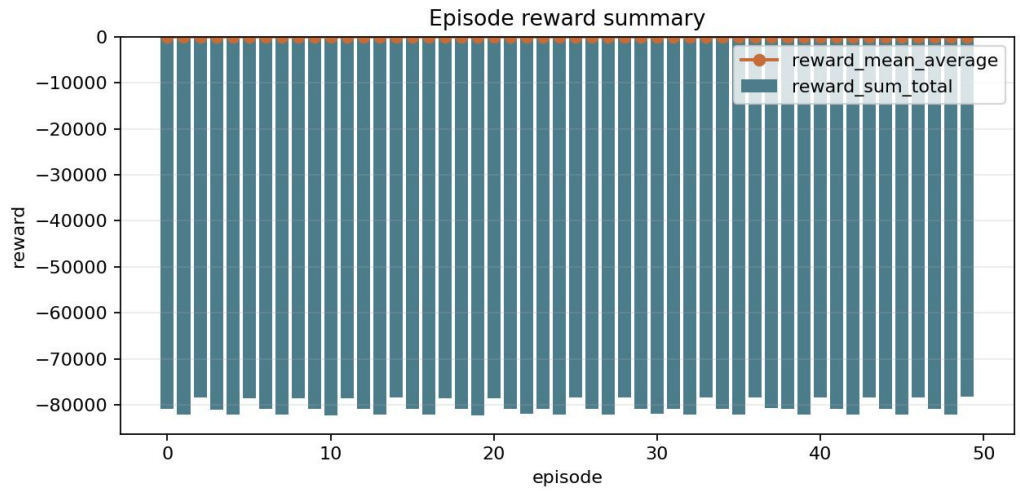

Figura JOB.116. MASAC/E3 — episode_reward_summary.png — Resumen de recompensa por episodio.

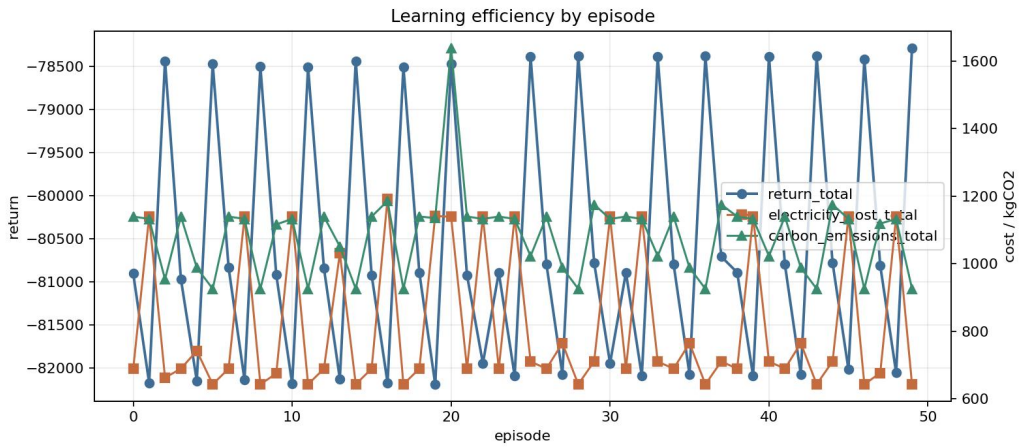

Figura JOB.117. MASAC/E3 — learning_efficiency.png — Eficiencia de aprendizaje.

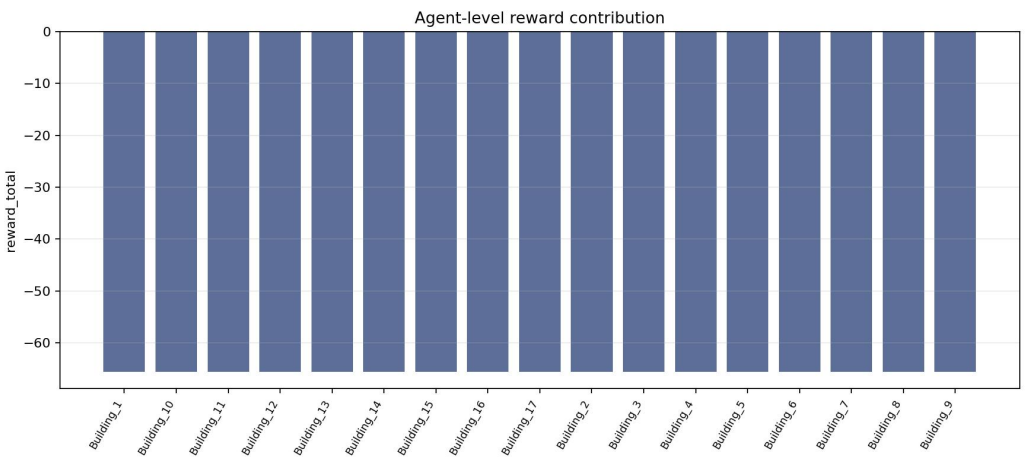

Figura JOB.118. MASAC/E3 — agent_reward_contribution.png — Contribución de recompensa por agente/edificio.

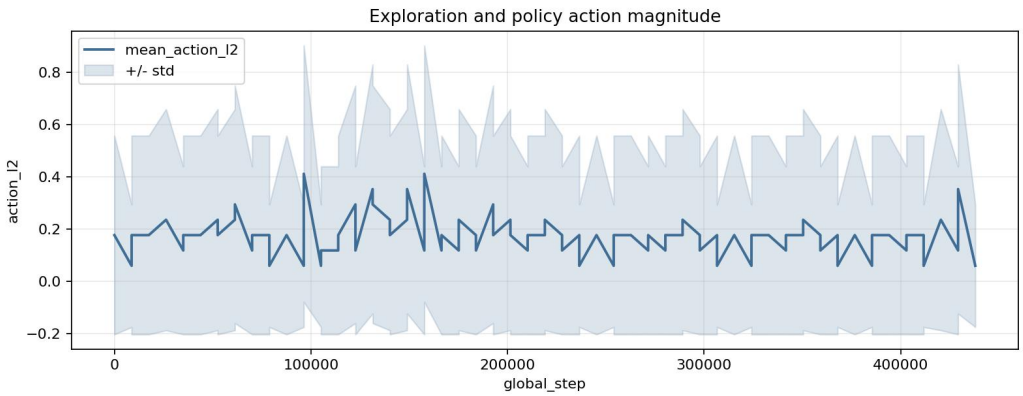

Figura JOB.119. MASAC/E3 — exploration_action_l2.png — Exploración (norma L2 de acciones).

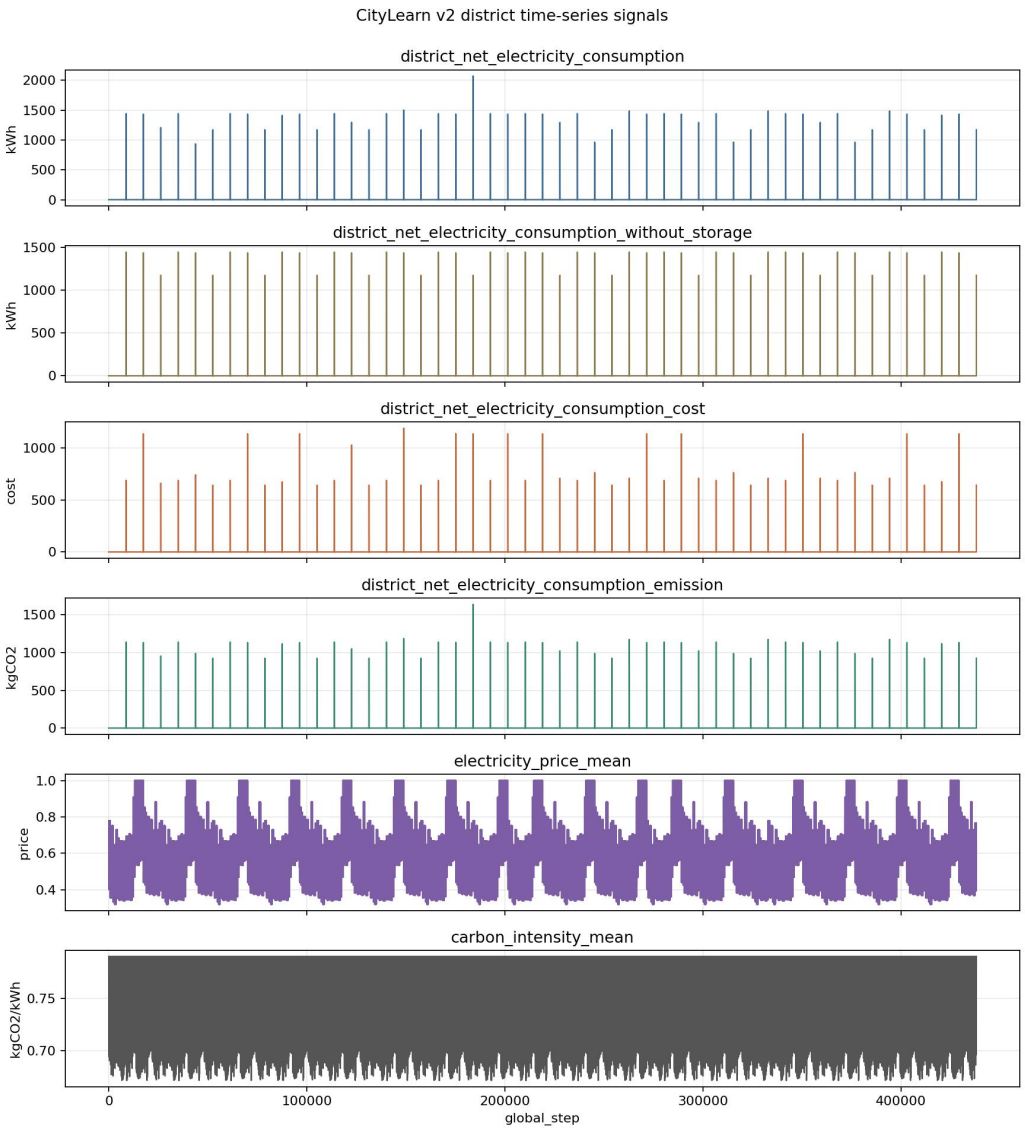

Figura JOB.120. MASAC/E3 — citylearn_v2_district_timeseries.png — Series temporales distritales CityLearn.

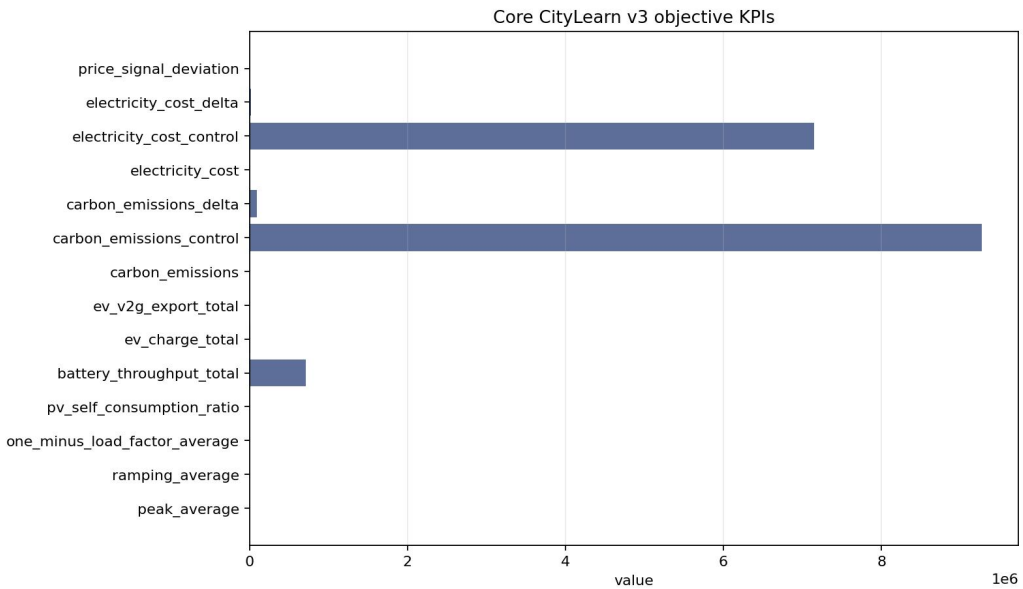

Figura JOB.121. MASAC/E3 — core_kpis.png — KPIs núcleo del job.

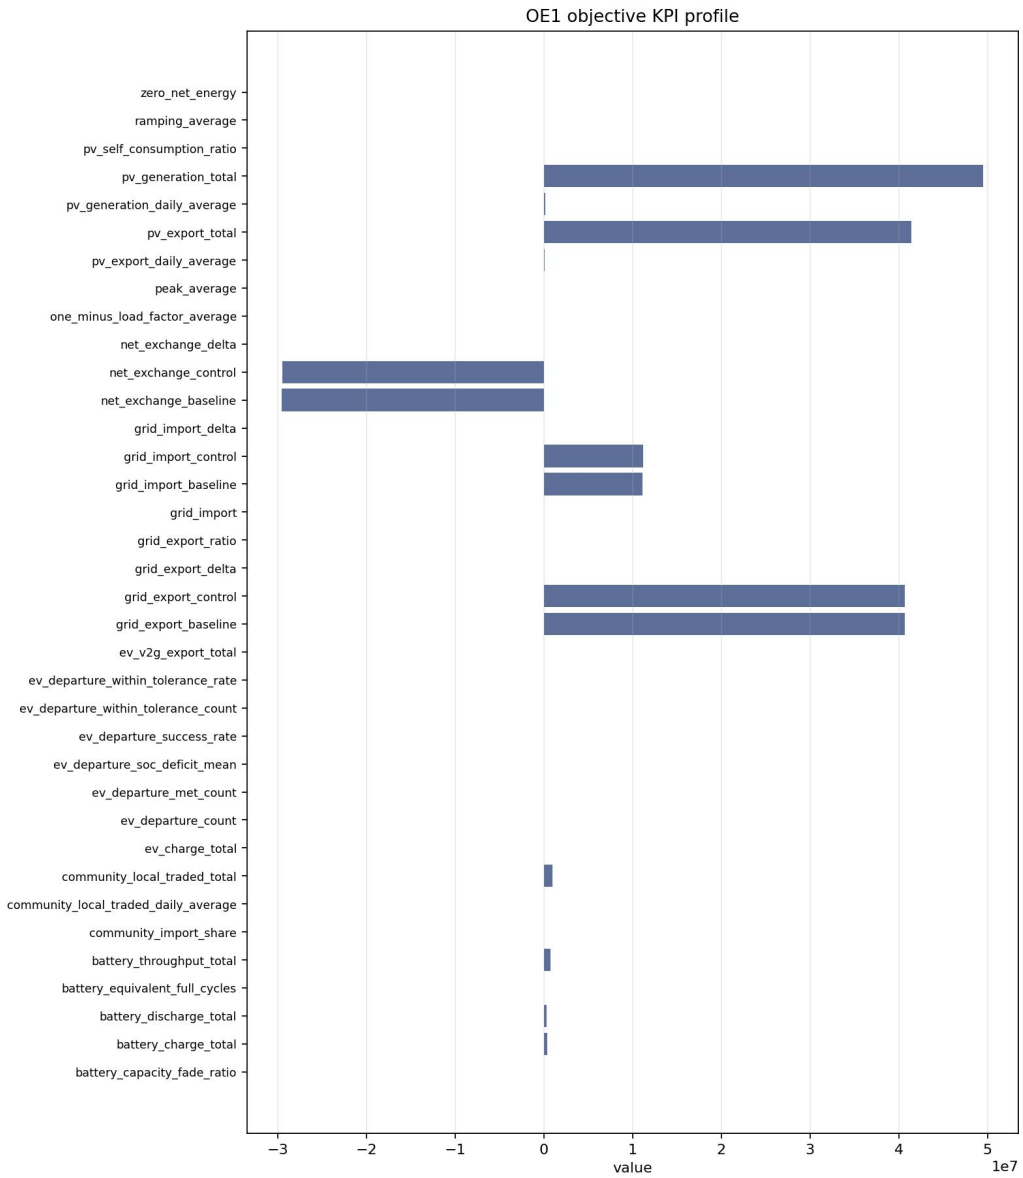

Figura JOB.122. MASAC/E3 — OE1_flexibility_kpis.png — KPIs de flexibilidad (OE.1).

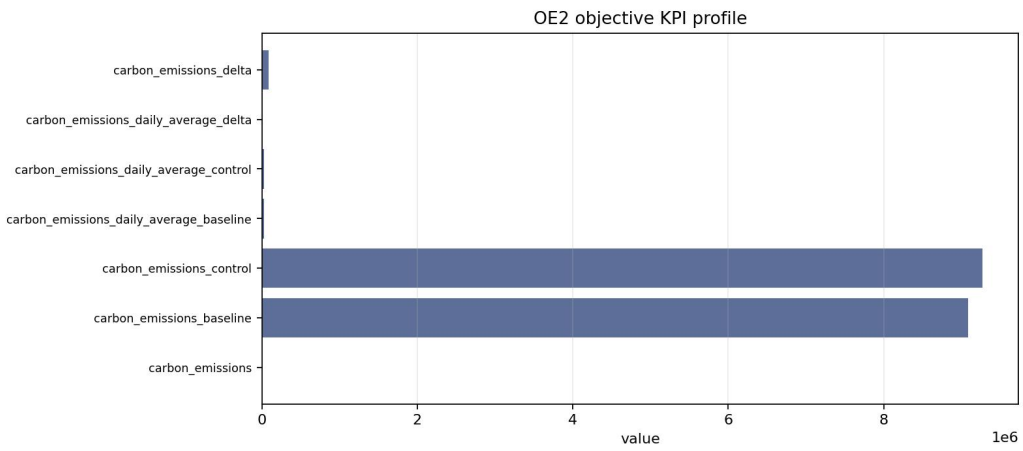

Figura JOB.123. MASAC/E3 — OE2_co2_kpis.png — KPIs de emisiones (OE.2).

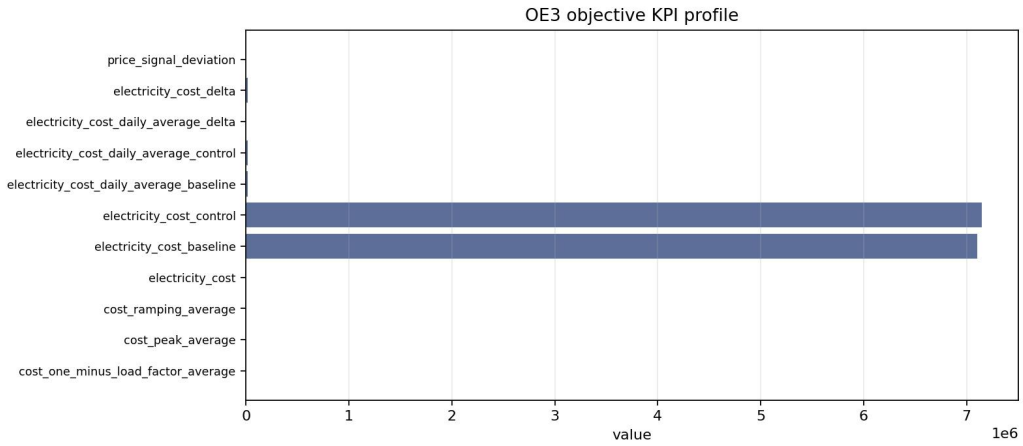

Figura JOB.124. MASAC/E3 — OE3_cost_kpis.png — KPIs de costo (OE.3).

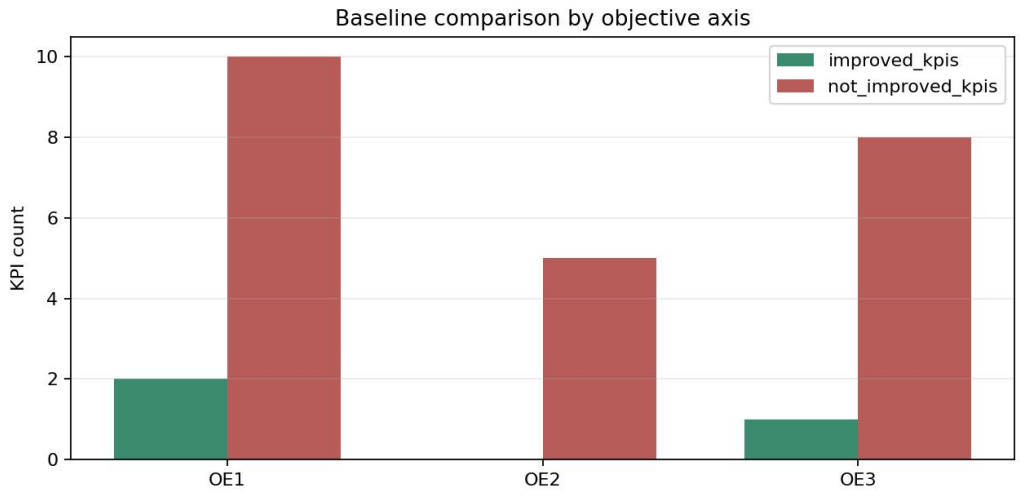

Figura JOB.125. MASAC/E3 — axis_baseline_comparison.png — Comparación por eje vs baseline.

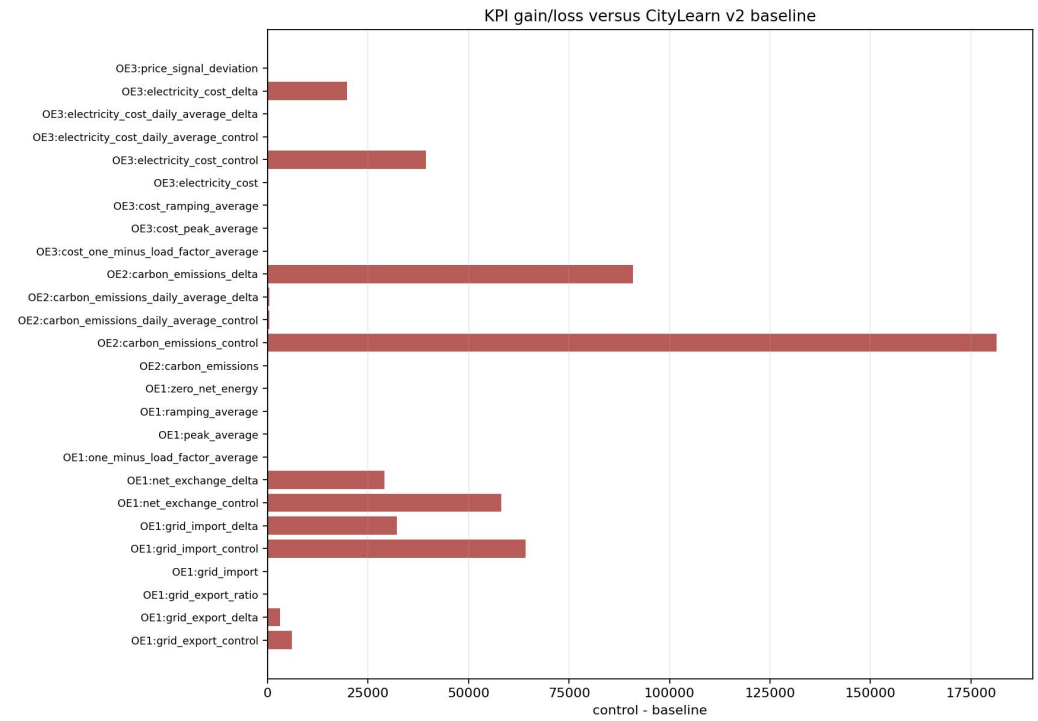

Figura JOB.126. MASAC/E3 — baseline_gain_by_kpi.png — Ganancia/pérdida por KPI vs baseline.

C.HAPPO — figuras de performance

HAPPO / E1

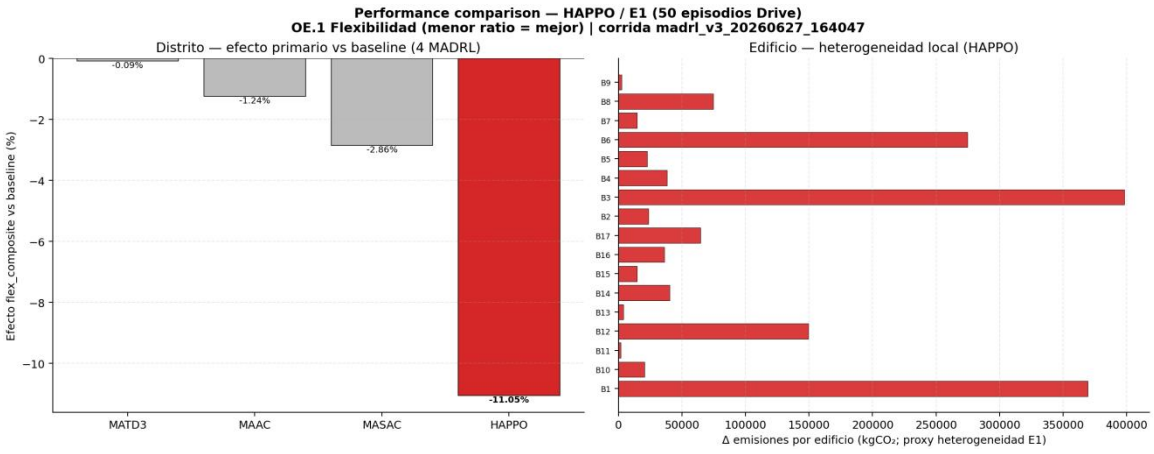

Figura JOB.127. HAPPO/E1 — performance_comparison.png — Distrito (efecto % vs baseline de 4 MADRL) + edificio (17 edificios).

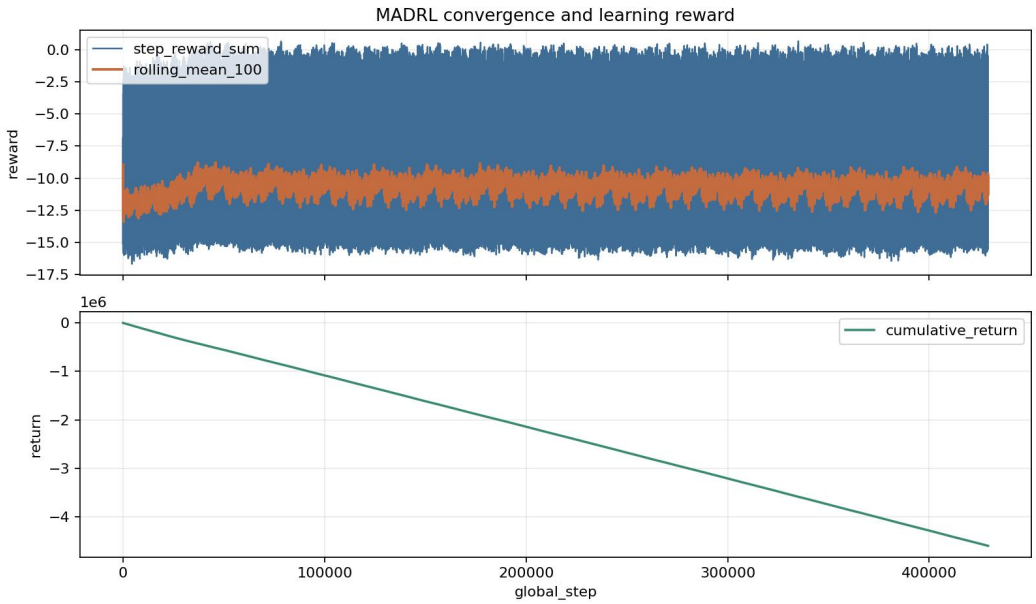

Figura JOB.128. HAPPO/E1 — convergence_returns.png — Convergencia de retornos episódicos.

Figura JOB.129. HAPPO/E1 — reward_timeseries.png — Serie temporal de recompensa.

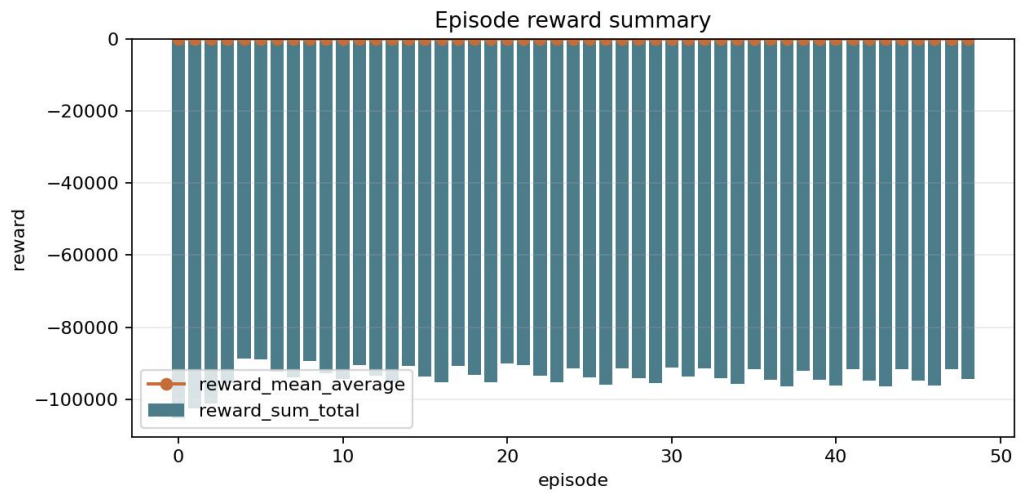

Figura JOB.130. HAPPO/E1 — episode_reward_summary.png — Resumen de recompensa por episodio.

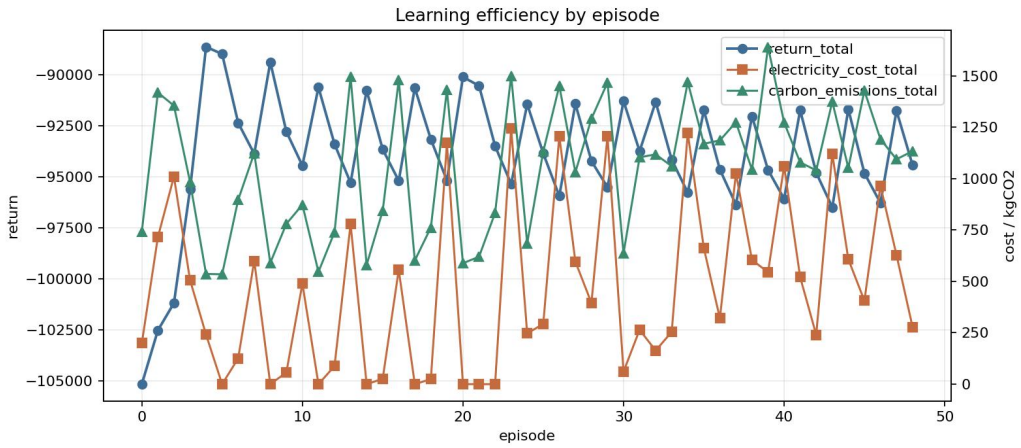

Figura JOB.131. HAPPO/E1 — learning_efficiency.png — Eficiencia de aprendizaje.

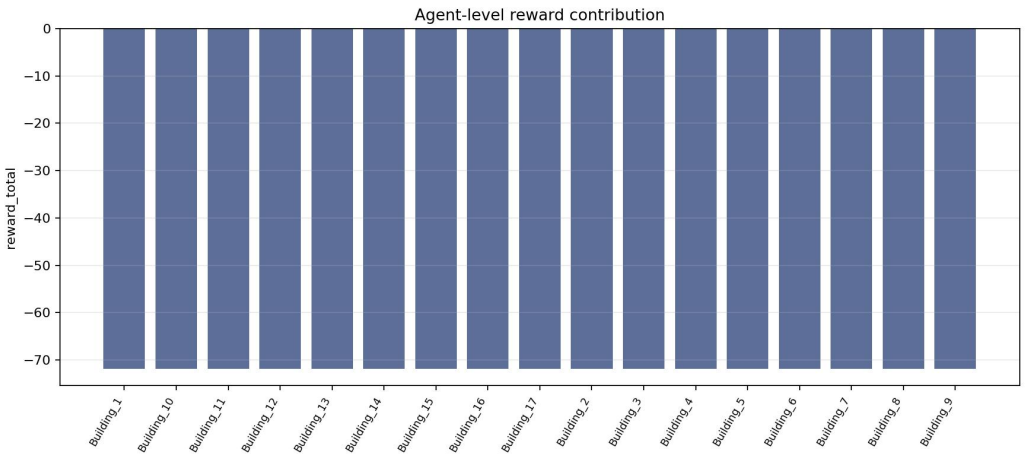

Figura JOB.132. HAPPO/E1 — agent_reward_contribution.png — Contribución de recompensa por agente/edificio.

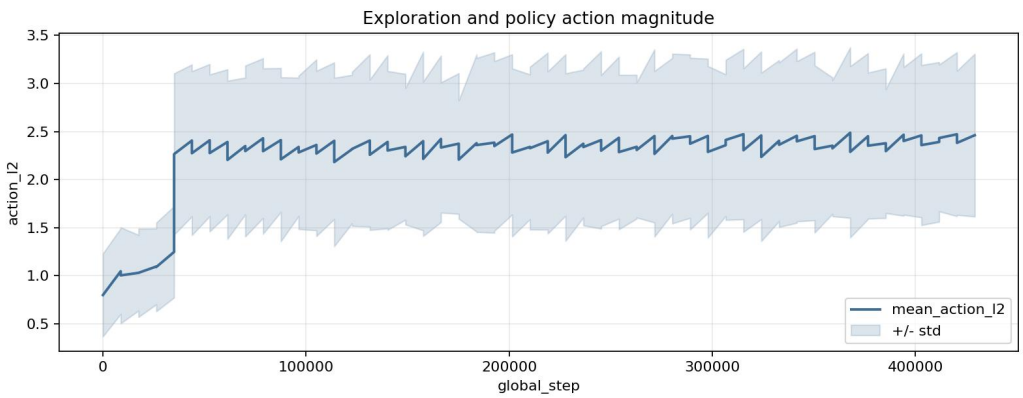

Figura JOB.133. HAPPO/E1 — exploration_action_l2.png — Exploración (norma L2 de acciones).

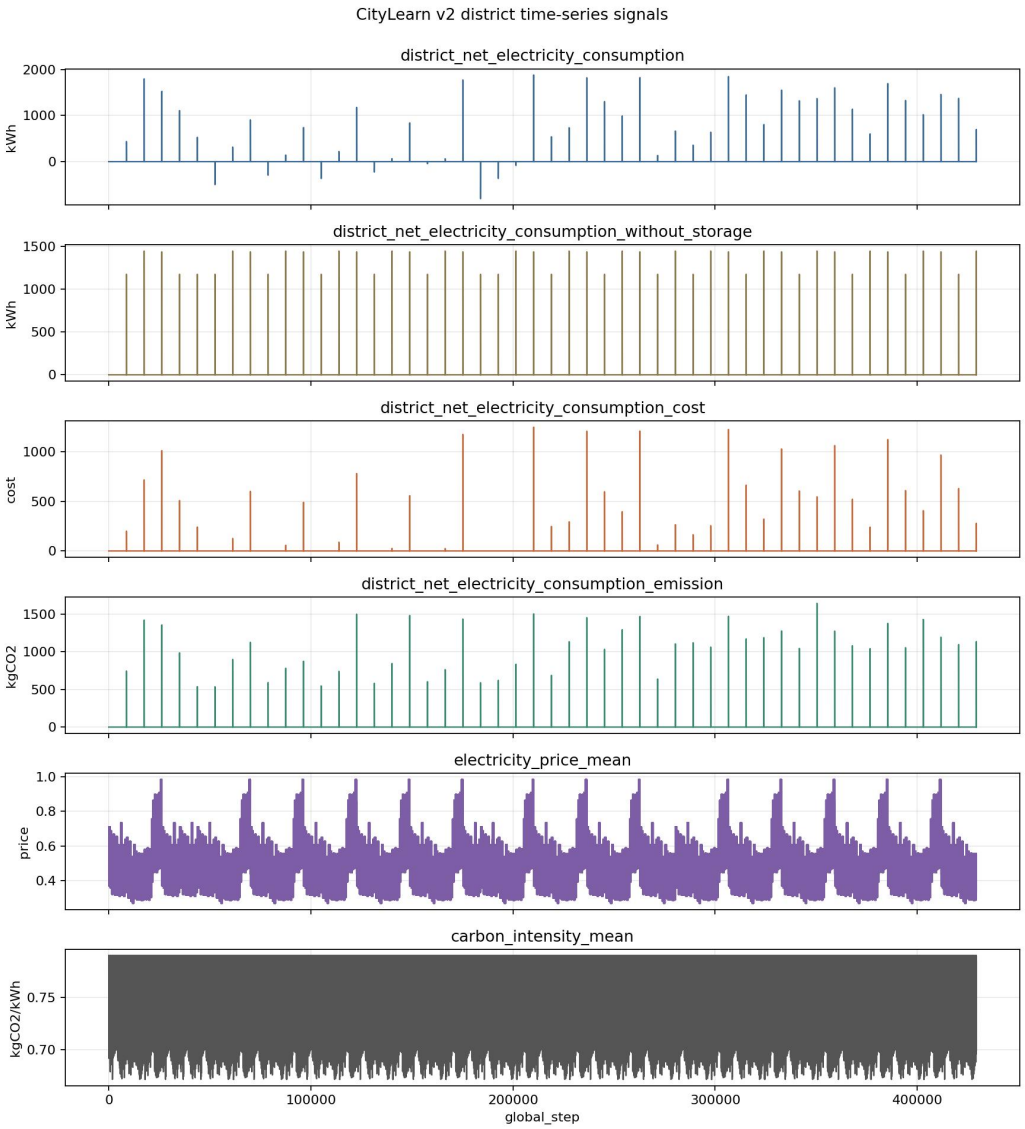

Figura JOB.134. HAPPO/E1 — citylearn_v2_district_timeseries.png — Series temporales distritales CityLearn.

HAPPO / E2

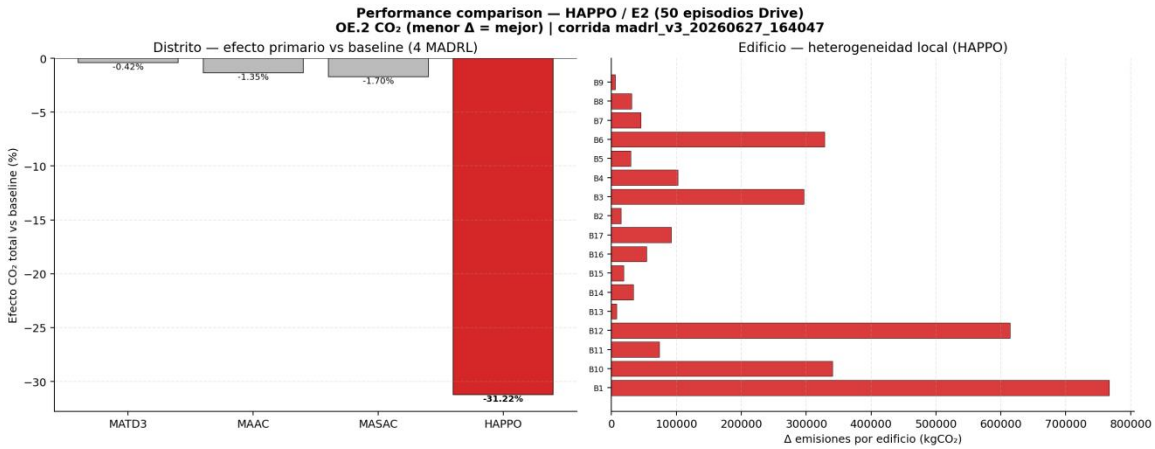

Figura JOB.135. HAPPO/E2 — performance_comparison.png — Distrito (efecto % vs baseline de 4 MADRL) + edificio (17 edificios).

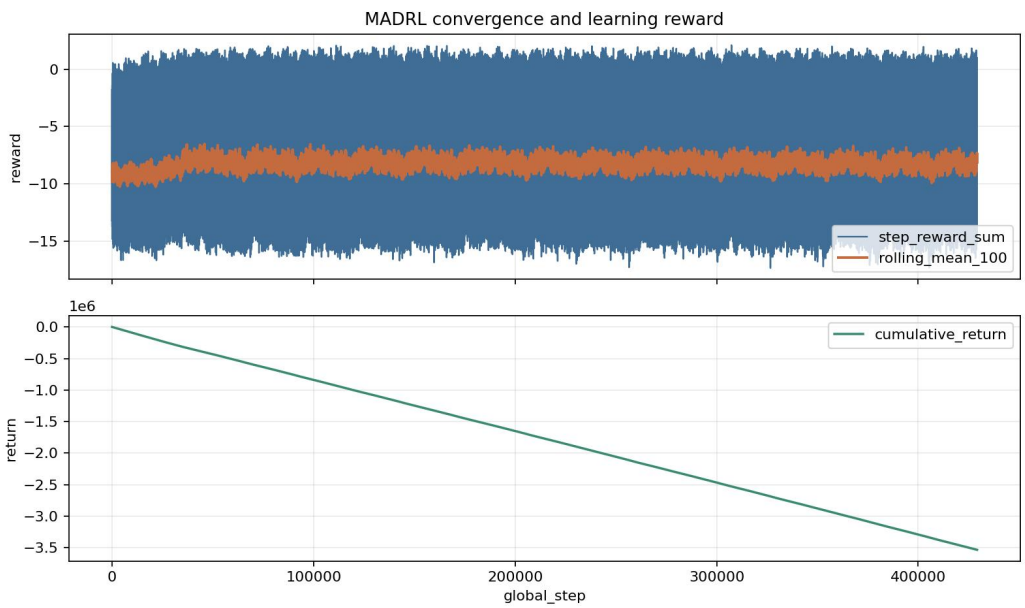

Figura JOB.136. HAPPO/E2 — convergence_returns.png — Convergencia de retornos episódicos.

Figura JOB.137. HAPPO/E2 — reward_timeseries.png — Serie temporal de recompensa.

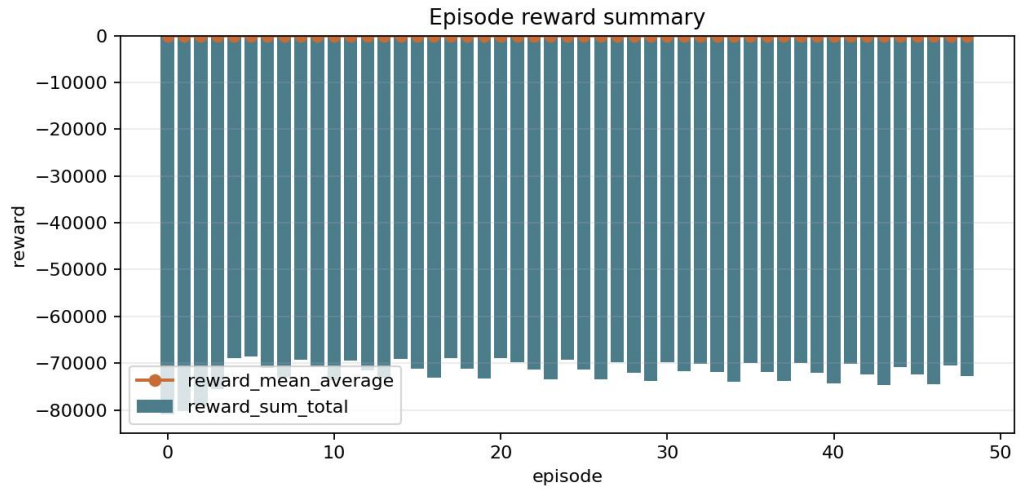

Figura JOB.138. HAPPO/E2 — episode_reward_summary.png — Resumen de recompensa por episodio.

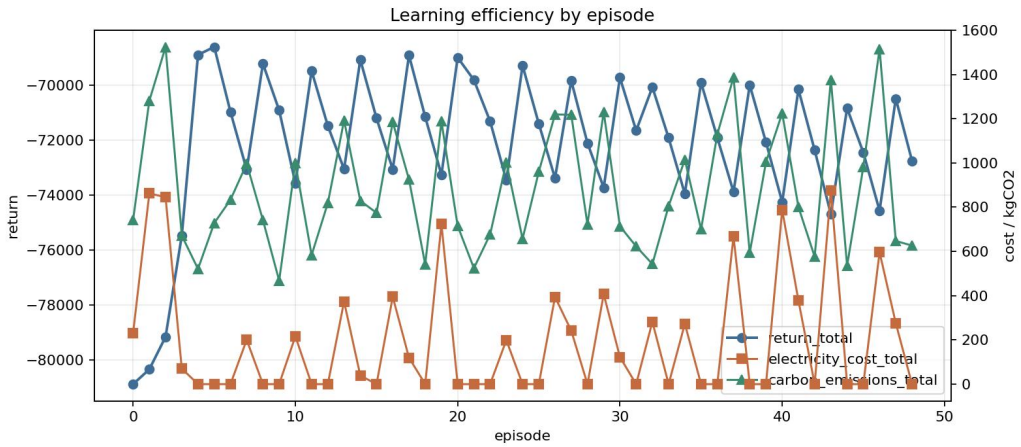

Figura JOB.139. HAPPO/E2 — learning_efficiency.png — Eficiencia de aprendizaje.

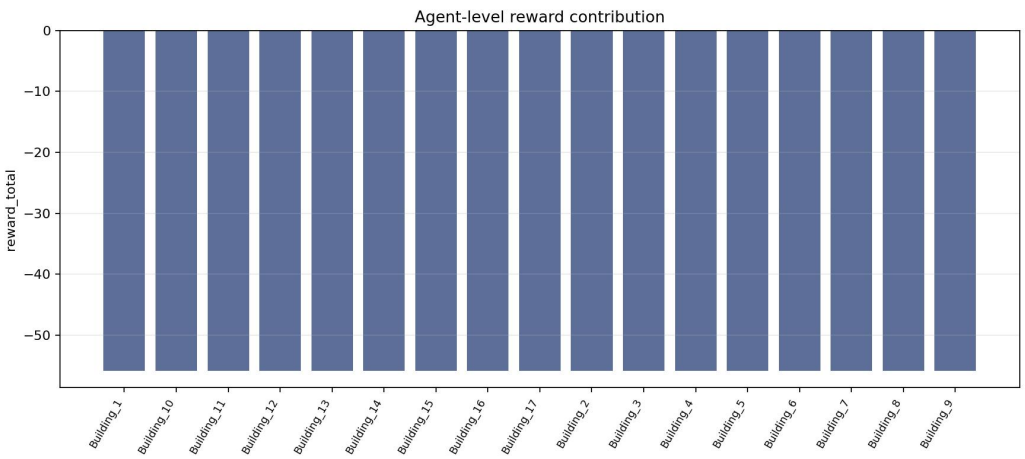

Figura JOB.140. HAPPO/E2 — agent_reward_contribution.png — Contribución de recompensa por agente/edificio.

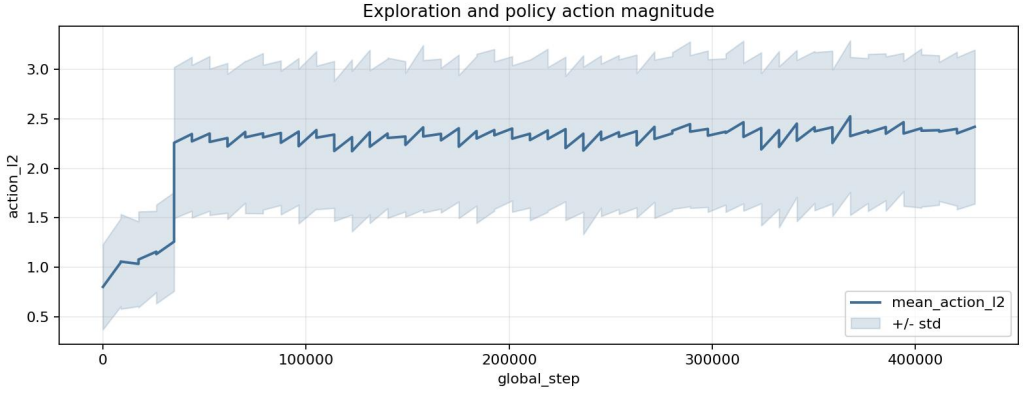

Figura JOB.141. HAPPO/E2 — exploration_action_l2.png — Exploración (norma L2 de acciones).

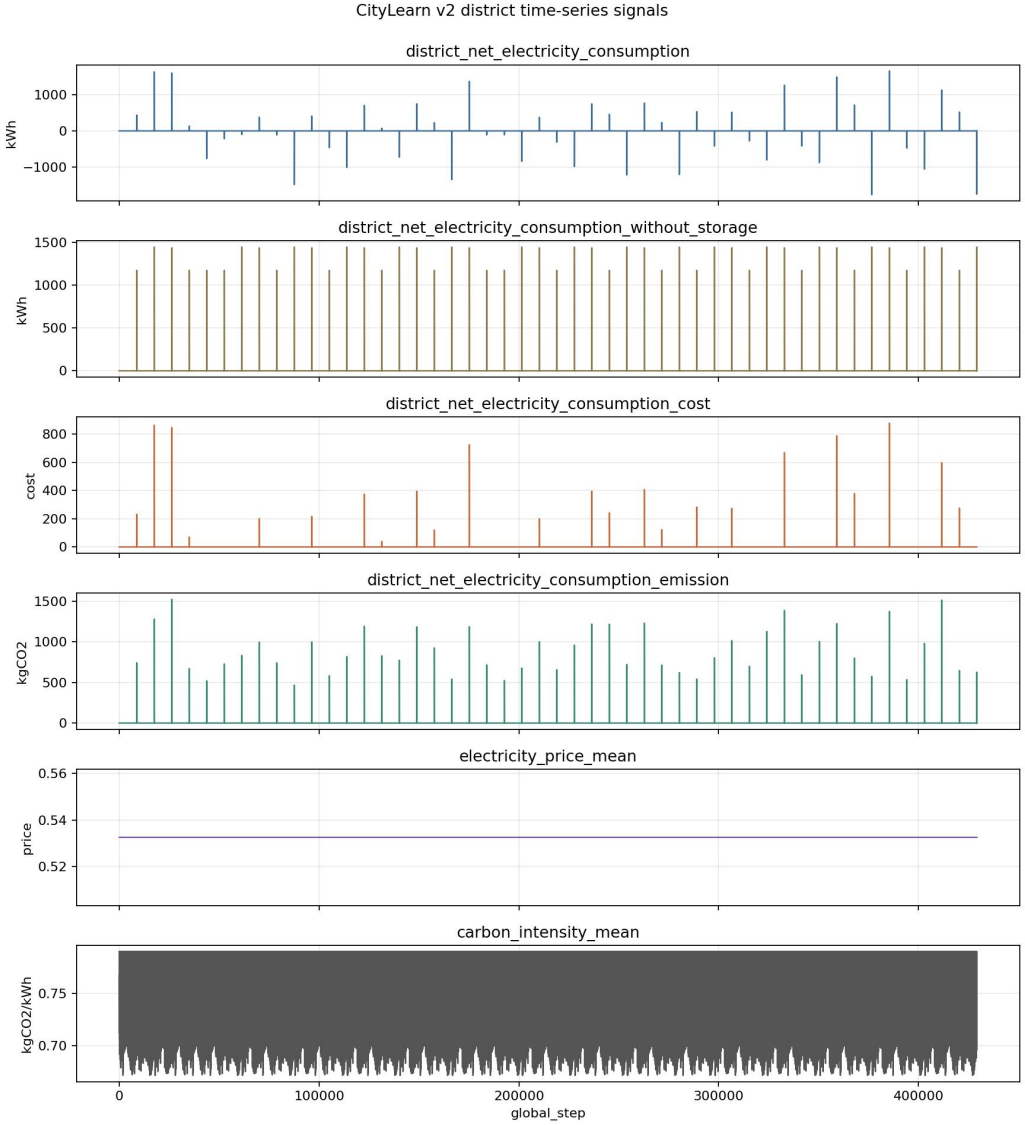

Figura JOB.142. HAPPO/E2 — citylearn_v2_district_timeseries.png — Series temporales distritales CityLearn.

HAPPO / E3

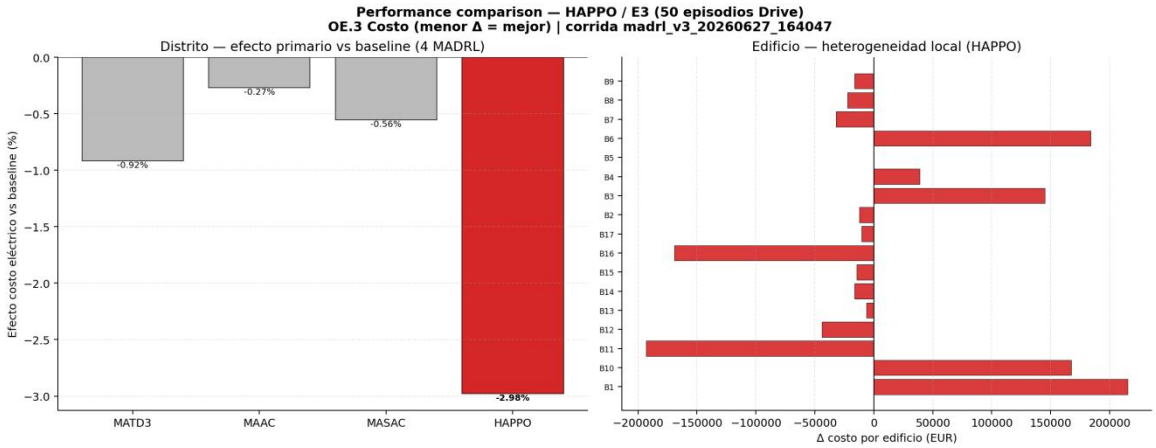

Figura JOB.143. HAPPO/E3 — performance_comparison.png — Distrito (efecto % vs baseline de 4 MADRL) + edificio (17 edificios).

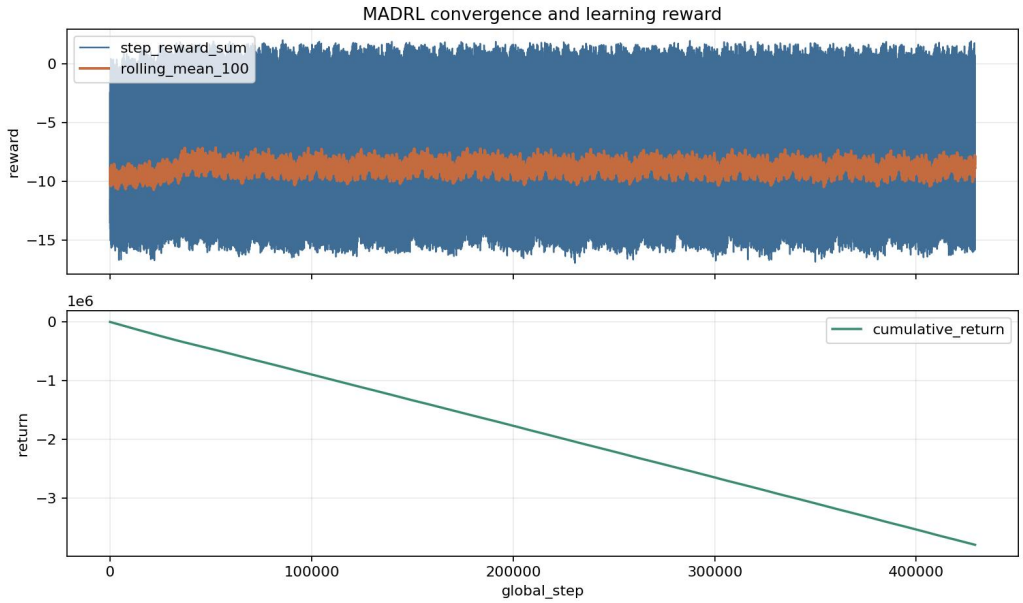

Figura JOB.144. HAPPO/E3 — convergence_returns.png — Convergencia de retornos episódicos.

Figura JOB.145. HAPPO/E3 — reward_timeseries.png — Serie temporal de recompensa.

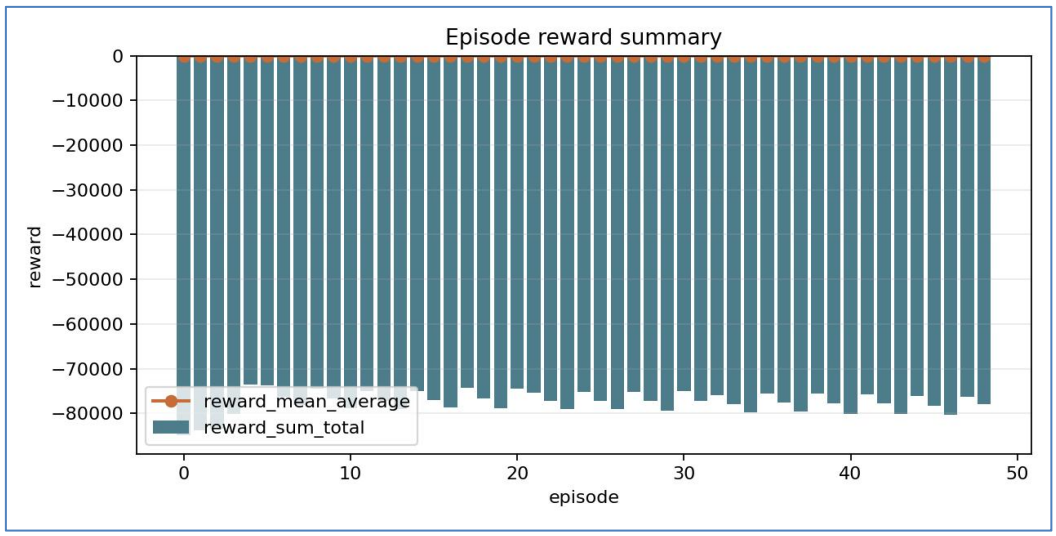

Figura JOB.146. HAPPO/E3 — episode_reward_summary.png — Resumen de recompensa por episodio.

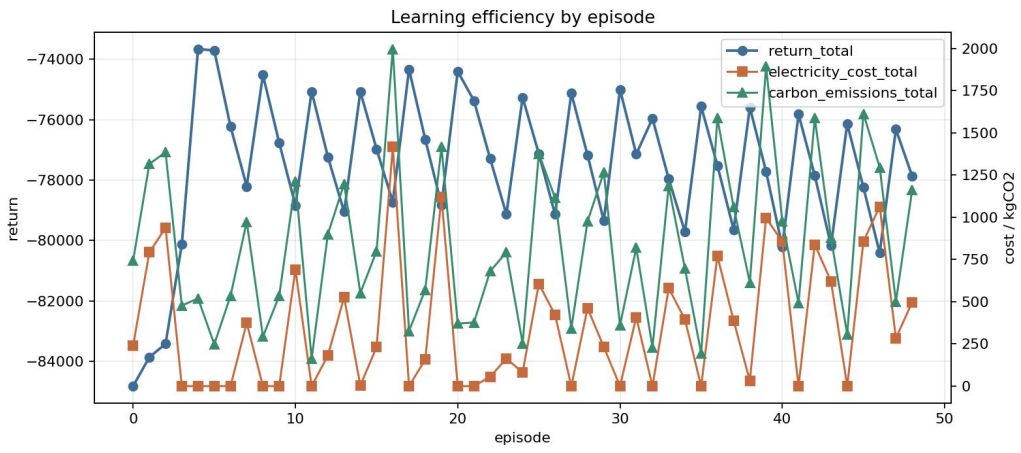

Figura JOB.147. HAPPO/E3 — learning_efficiency.png — Eficiencia de aprendizaje.

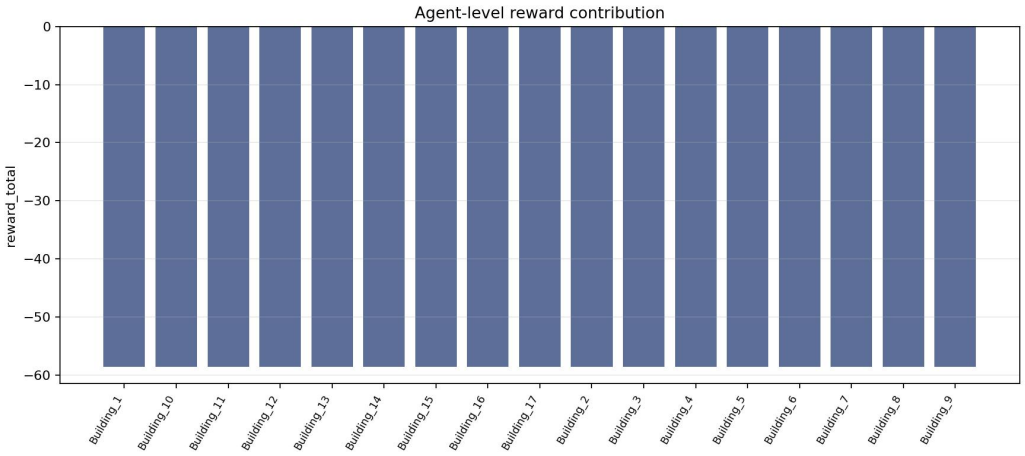

Figura JOB.148. HAPPO/E3 — agent_reward_contribution.png — Contribución de recompensa por agente/edificio.

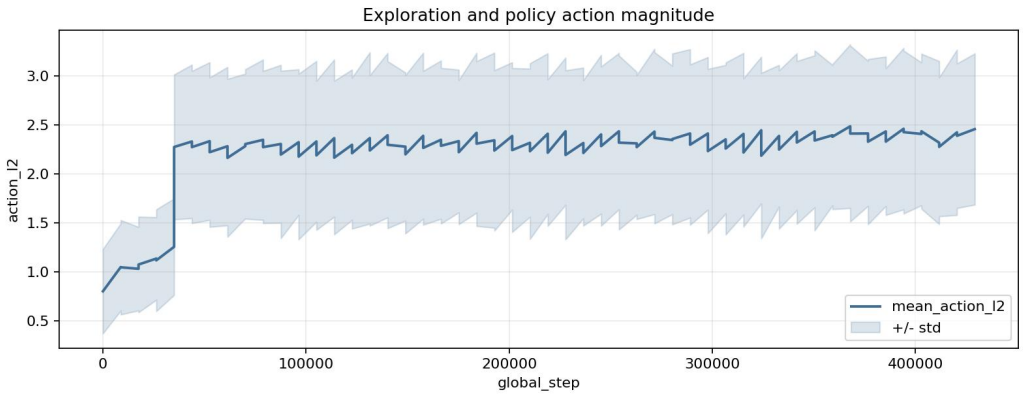

Figura JOB.149. HAPPO/E3 — exploration_action_l2.png — Exploración (norma L2 de acciones).

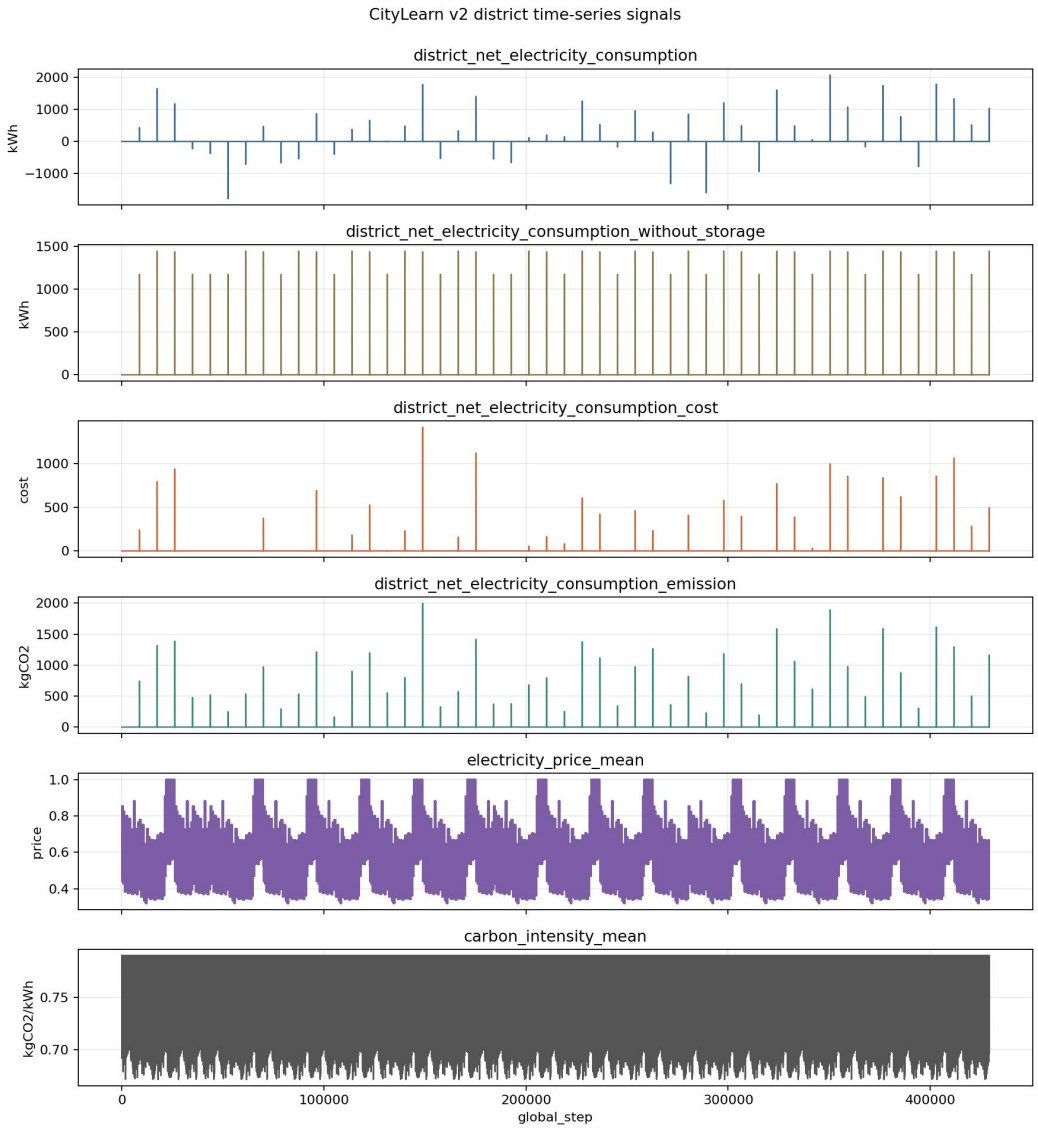

Figura JOB.150. HAPPO/E3 — citylearn_v2_district_timeseries.png — Series temporales distritales CityLearn.

Nota. Catálogo completo integrado. Fuentes: madrl_multicriteria_selection/figures/, resumen_comparativo / performance_comparison/, y {ALGO}/{E}/figures/ bajo outputs/madrl_v3_20260627_164047/. Mapping: performance_comparison_mapping.md.

5.5.3. OE.1 — otros resultados (flexibilidad energética)

Complementos de OE.1 en E1: convergencia, KPI comparativo Drive, desagregación por edificio (C4) y contraste vs baseline CityLearn v2. No sustituyen §5.2–§5.3 ni §5.5. Control de recursos (C5) en §5.4.5.

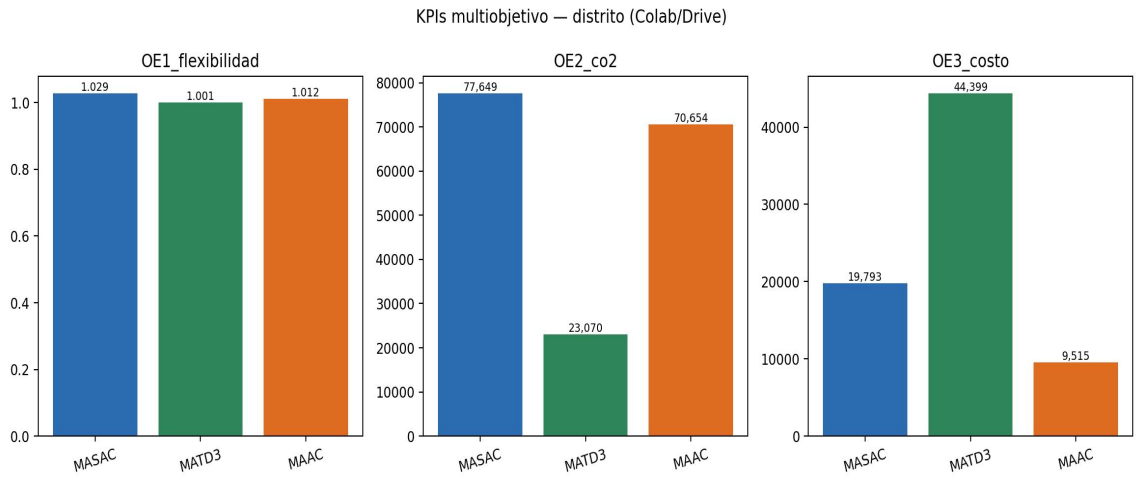

Figura 5.11. Convergencia reward_mean E1.

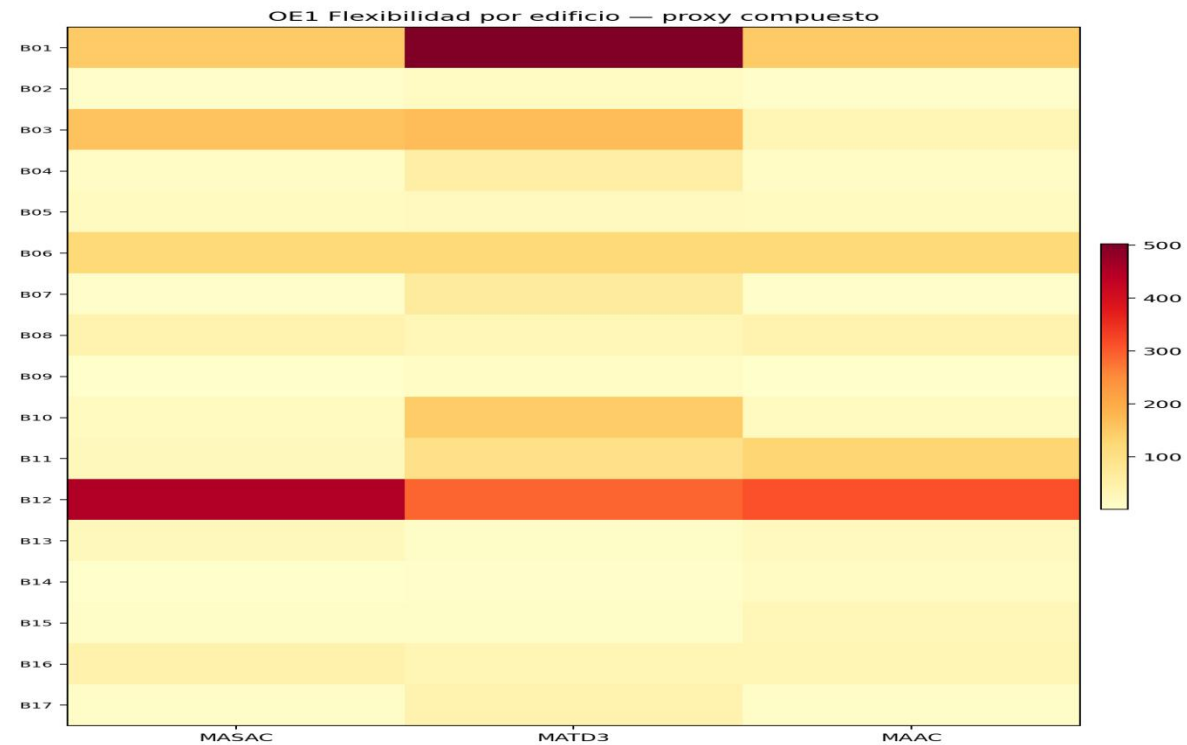

Figura 5.12. KPI comparativo OE.1.

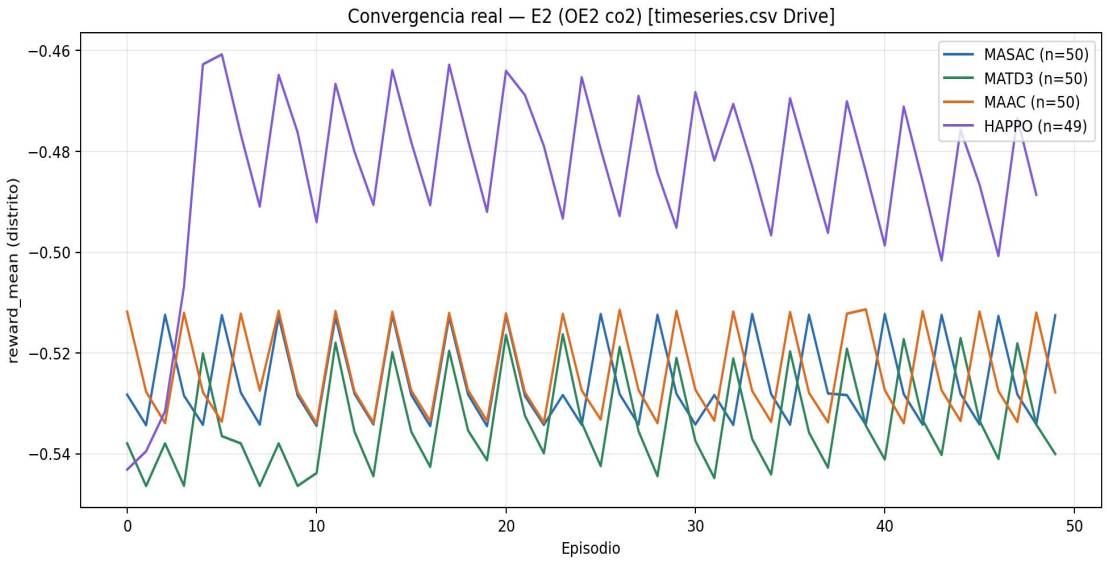

Figura 5.13. Objetivo por edificio OE.1 (C4).

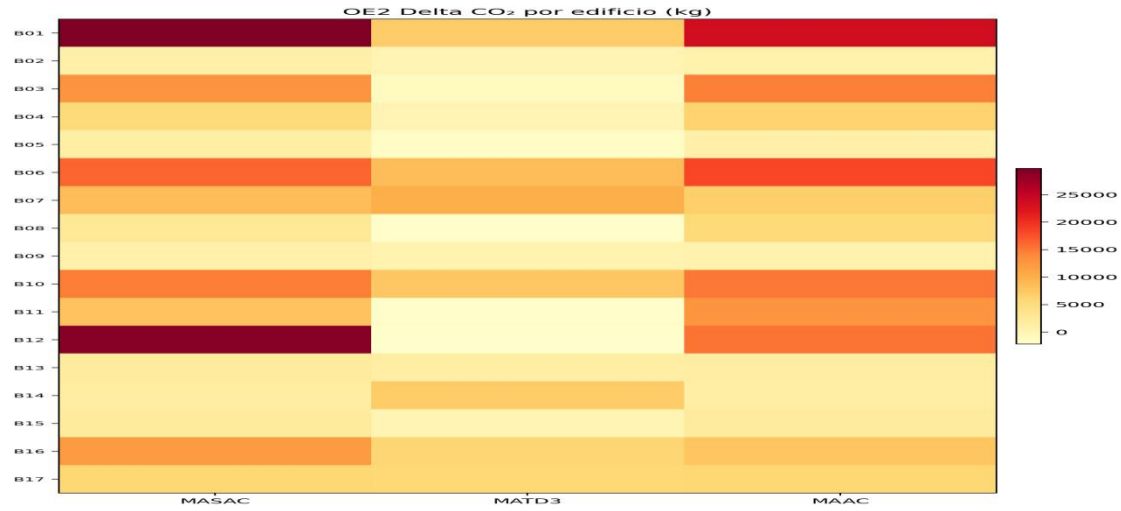

Figura 5.14. Traza de control de recursos E1 (C5).

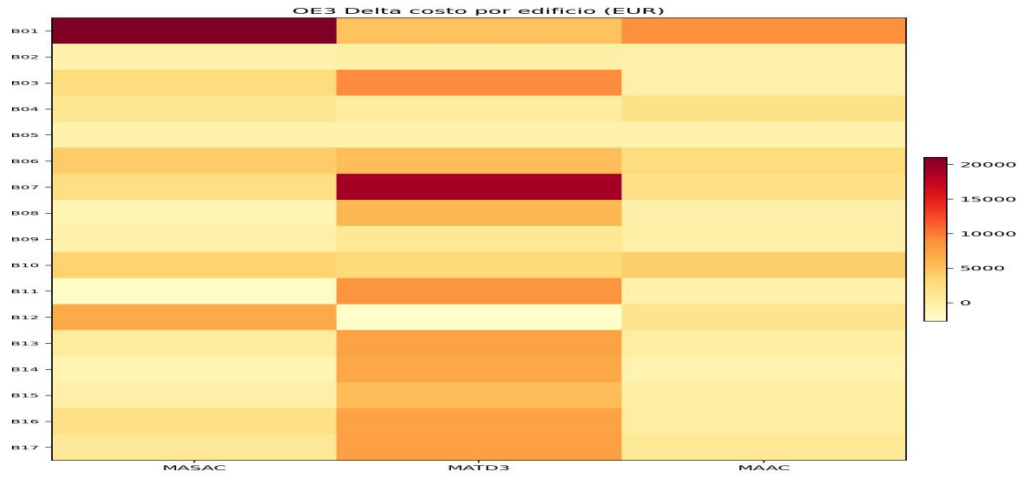

Figura 5.15. Ganancia vs baseline CityLearn v2 — E1 (OE.1).

5.5.4. OE.2 — otros resultados (emisiones de CO2)

Complementos de OE.2 en E2: convergencia, KPI comparativo Drive, desagregación por edificio (C4) y contraste vs baseline CityLearn v2. No sustituyen §5.2–§5.3 ni §5.5. Control de recursos (C5) en §5.4.5.

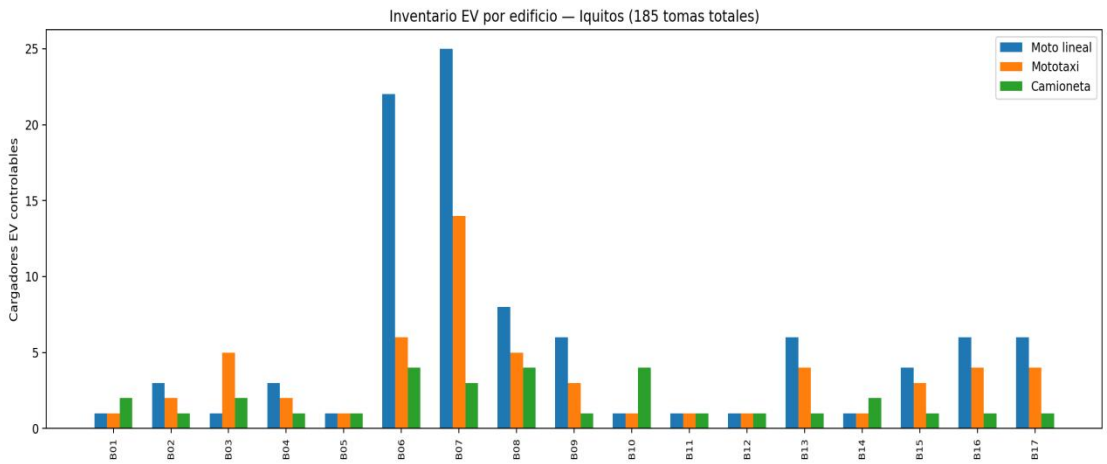

Figura 5.16. Convergencia reward_mean E2.

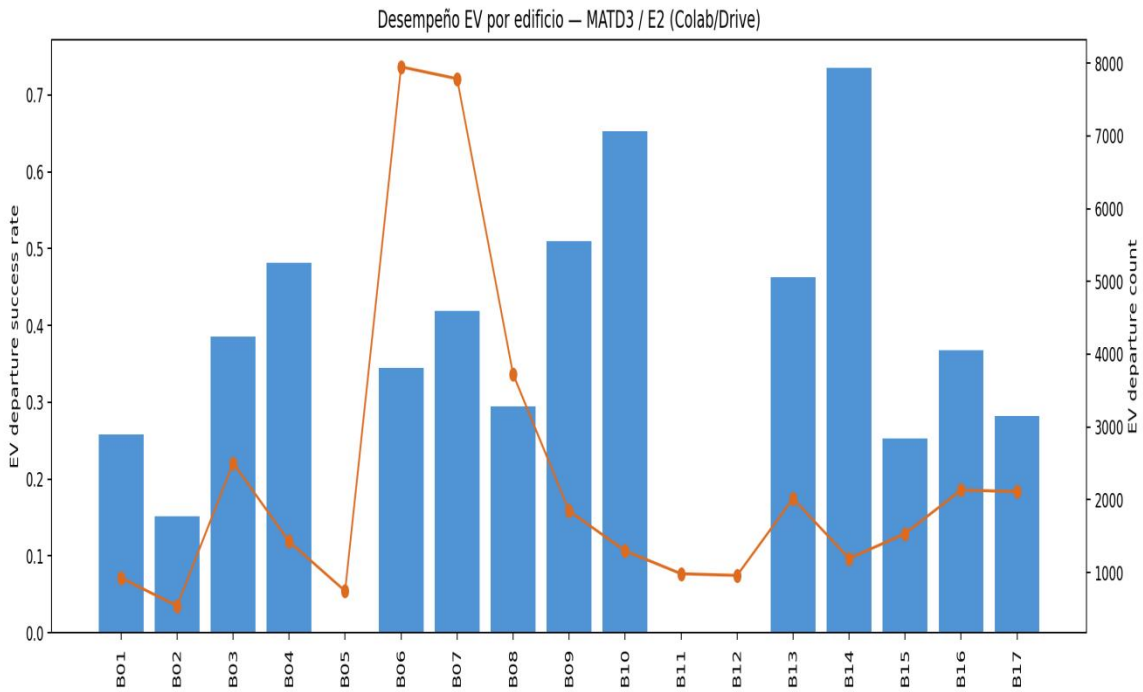

Figura 5.17. KPI comparativo OE.2.

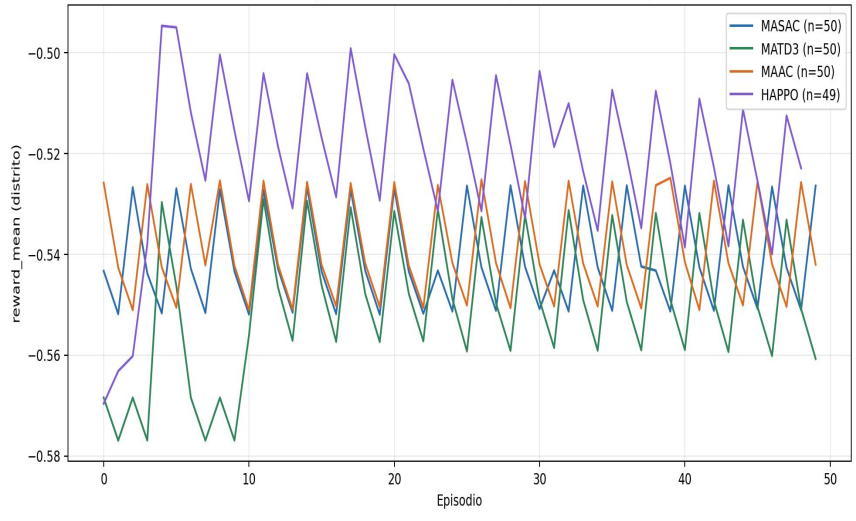

Figura 5.18. Objetivo por edificio OE.2 (C4).

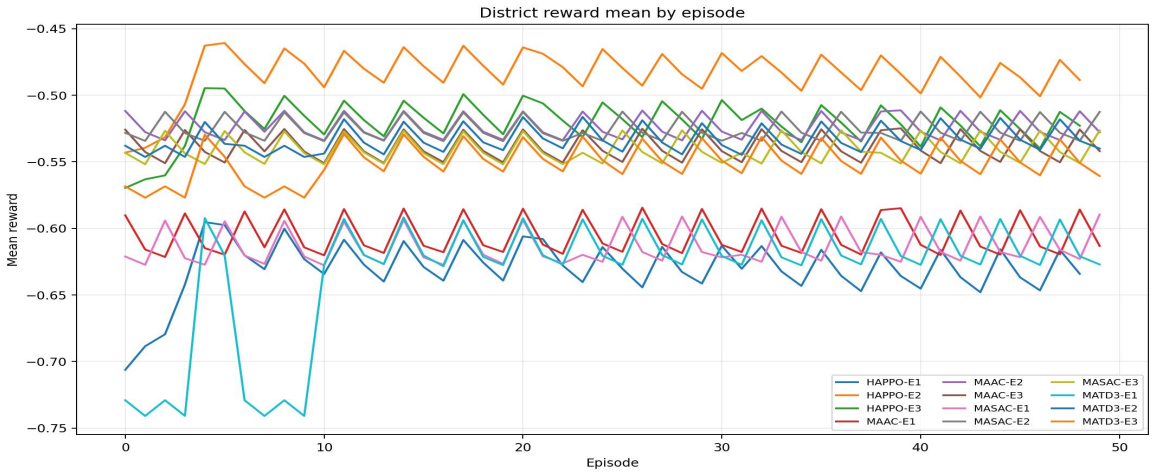

Figura 5.19. Traza de control de recursos E2 (C5).

Figura 5.20. Ganancia vs baseline CityLearn v2 — E2 (OE.2).

5.5.5. OE.3 — otros resultados (costos energéticos)

Complementos de OE.3 en E3: convergencia, KPI comparativo Drive, desagregación por edificio (C4) y contraste vs baseline CityLearn v2. No sustituyen §5.2–§5.3 ni §5.5. Control de recursos (C5) en §5.4.5.

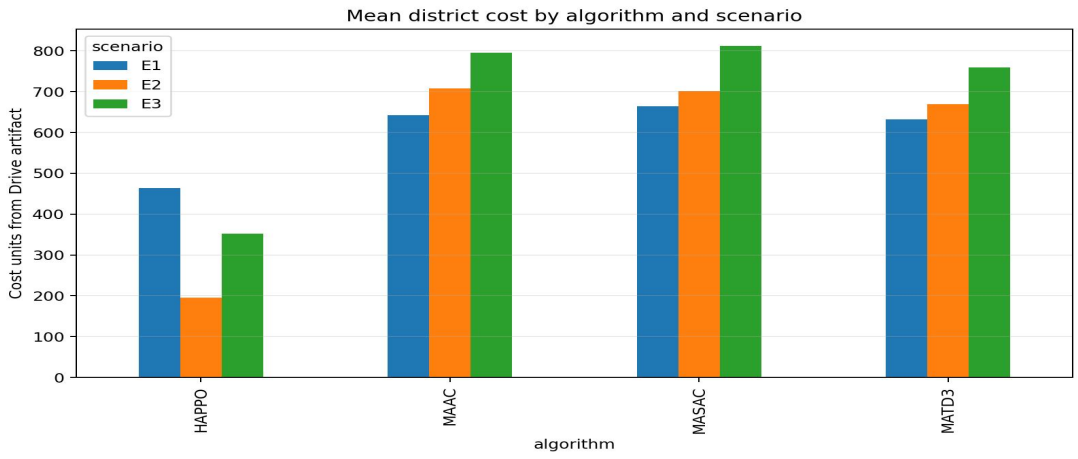

Figura 5.21. Convergencia reward_mean E3.

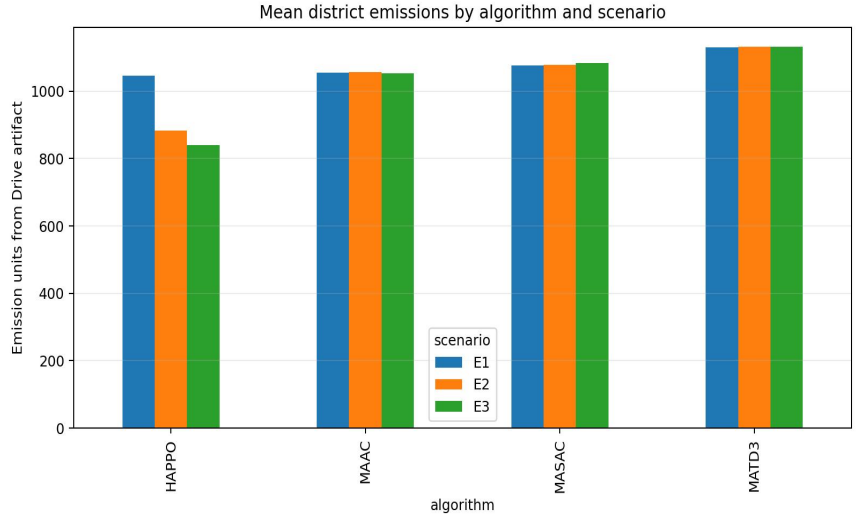

Figura 5.22. KPI comparativo OE.3.

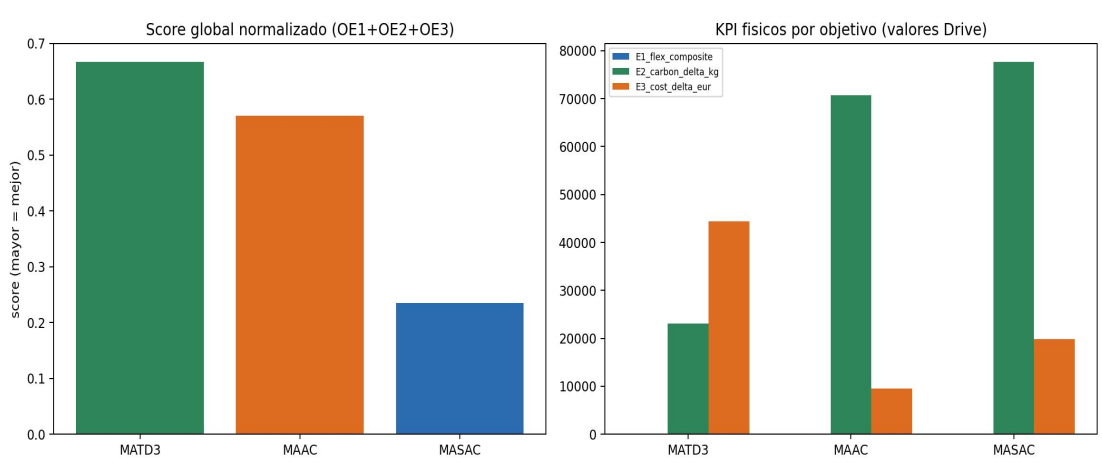

Figura 5.23. Objetivo por edificio OE.3 (C4).

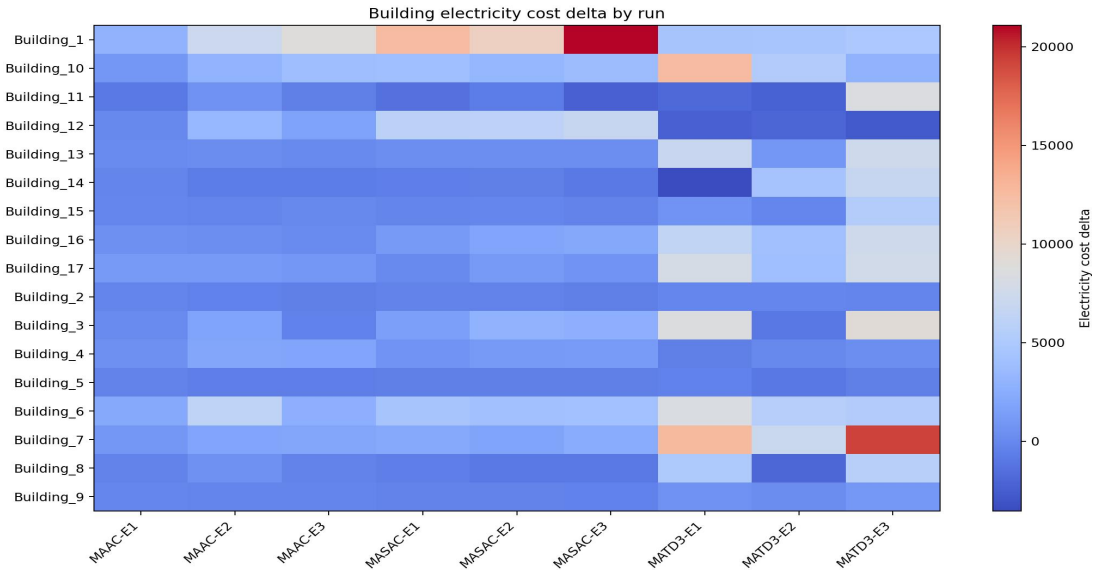

Figura 5.24. Traza de control de recursos E3 (C5).

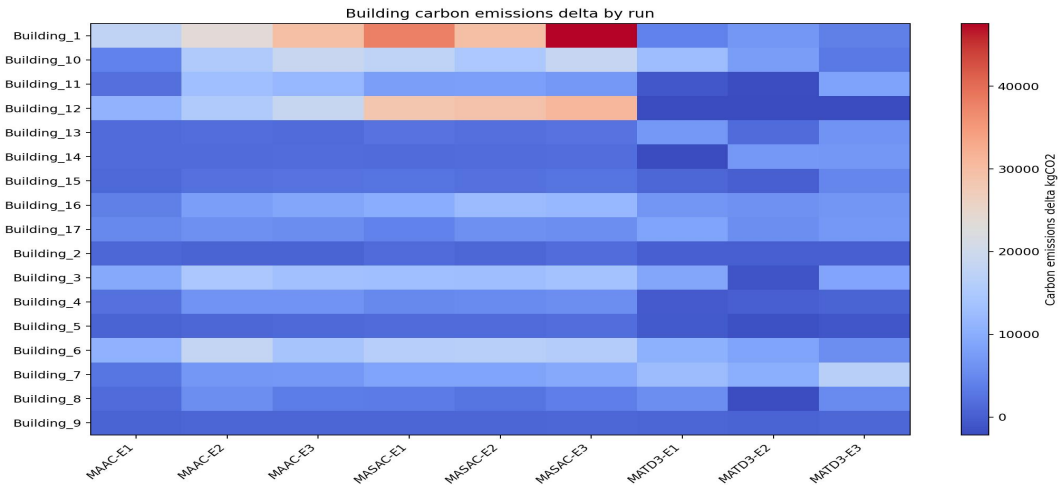

Figura 5.25. Ganancia vs baseline CityLearn v2 — E3 (OE.3).

5.5.6. Control de recursos (criterio C5 de impacto)

Criterio obligatorio de determinación del impacto: el efecto MADRL sobre OE.1–OE.3 solo es atribuible si los agentes controlan recursos energéticos (DER). Recursos controlados: BESS (electrical_storage), cargadores EV/V2G y carga desplazable (washing_machine). Recursos no controlados: non_shiftable_load, refrigeración/ACS modeladas y generación FV fija. Inventario: 17 edificios, 185 cargadores EV.

Tabla 5.4.5. Inventario de control de recursos por edificio (building_inventory_multiobjective.csv).

Edif.	Nombre	EV	Elementos controlados	Acciones
B01	ELECTRO ORIENTE S.A.	4	BESS+WM+EV charger x4	6
B02	MUNICIPALIDAD DISTRITAL DE SAN JUAN BAUTIS	6	BESS+WM+EV charger x6	8
B03	AEROPUERTO INTERNACIONAL	8	BESS+WM+EV charger x8	10
B04	HIPERMERCADOS TOTTUS ORIENTE SAC	6	BESS+WM+EV charger x6	8
B05	HOTEL PLAZA S.A.	3	BESS+WM+EV charger x3	5
B06	MALL AVENTURA S.A.	32	BESS+WM+EV charger x32	34
B07	UNAP-FACULTAD DE BIOLOGIA-AULAS	42	BESS+WM+EV charger x42	44
B08	PNP- ESCUELA TECNICA SUPERIOR-IQUITOS	17	BESS+WM+EV charger x17	19
B09	GOBIERNO REGIONAL DE LORETO - COER	10	BESS+WM+EV charger x10	12
B10	GOBIERNO REGIONAL DE LORETO	6	BESS+WM+EV charger x6	8
B11	HOSPITAL REGIONAL DE LORETO	3	BESS+WM+EV charger x3	5
B12	SEGURO SOCIAL DE SALUD - ESSALUD	3	BESS+WM+EV charger x3	5
B13	UNAP-FACULTAD DE CIENCIAS AD. CONTABLES Y	11	BESS+WM+EV charger x11	13
B14	AUTORIDAD PORTUARIA NACIONAL	4	BESS+WM+EV charger x4	6
B15	DREL- COLEGIO NACIONAL DE IQUITOS	8	BESS+WM+EV charger x8	10
B16	SIMA - IQUITOS S.R.LTDA	11	BESS+WM+EV charger x11	13
B17	ASOCIACION CIVIL SELVA AMAZONICA	11	BESS+WM+EV charger x11	13

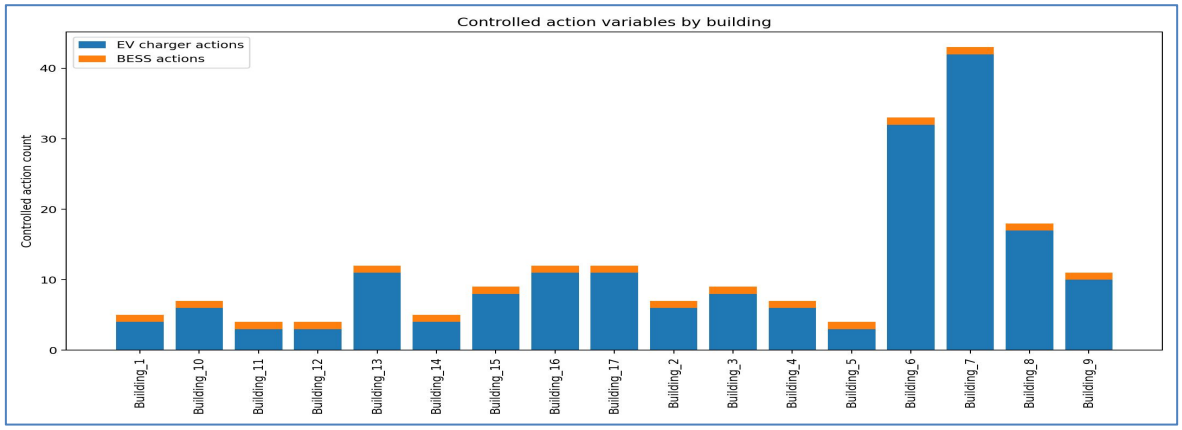

Figura 5.26. Inventario EV por edificio (control de recursos C5).

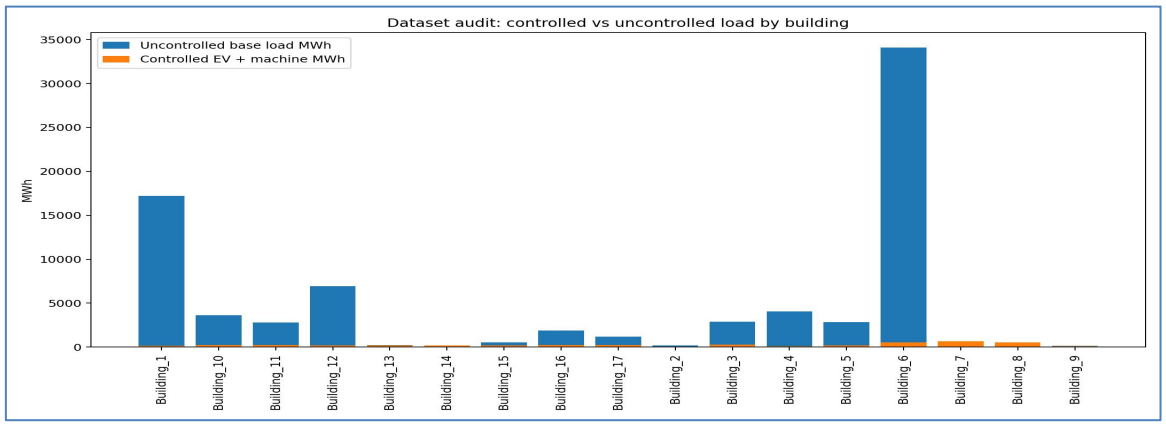

Figura 5.27. Éxito de salida EV — MATD3/E2 (control de recursos C5).

Desegregación completa por edificio de los tres ejes (OE.1 flexibilidad, OE.2 CO2, OE.3 costo) en las 17 tarjetas siguientes. Cumple C4+C5 de forma conjunta.

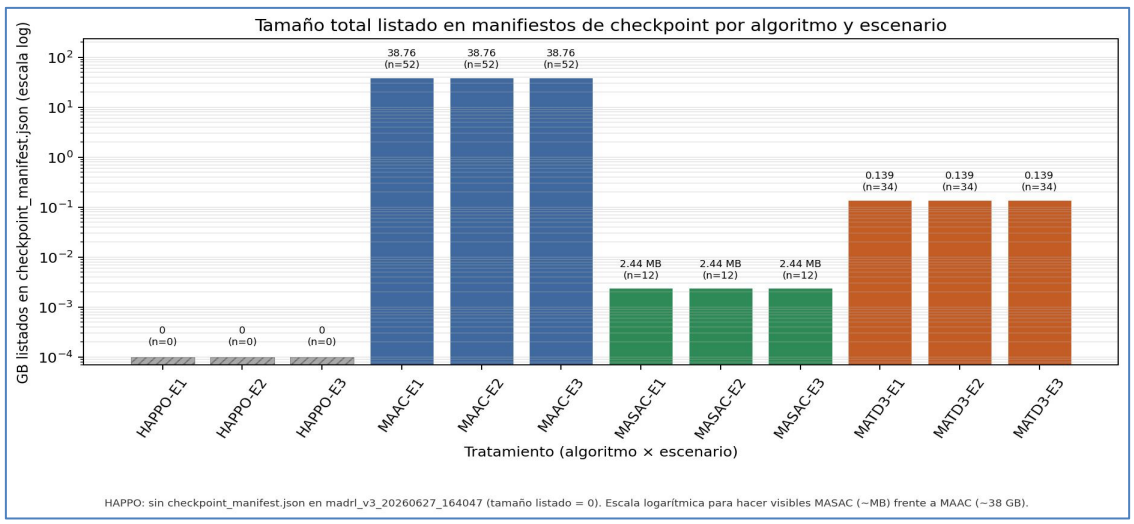

Figura 5.28. Edificio B01 — objetivos OE.1/OE.2/OE.3 (distrito → edificio; C4+C5).

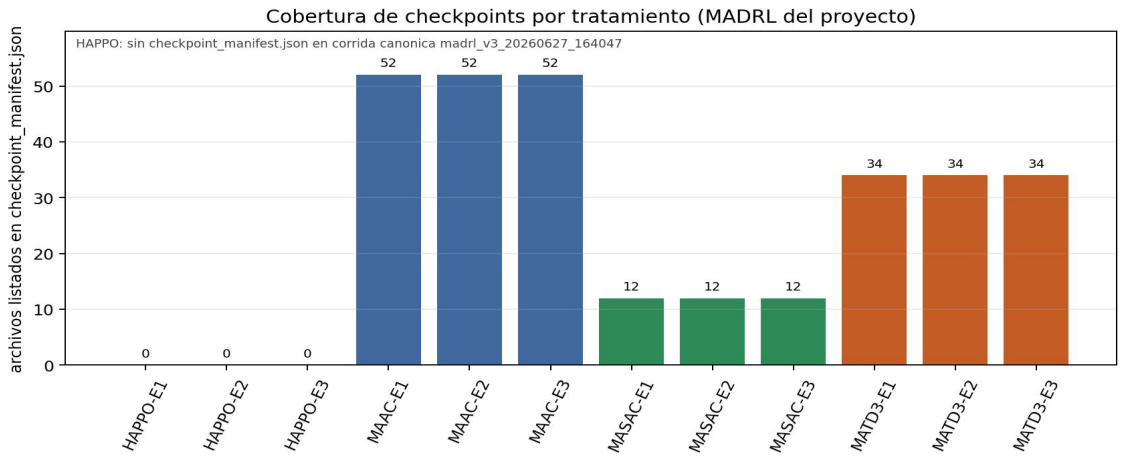

Figura 5.38. Edificio B11 — objetivos OE.1/OE.2/OE.3 (distrito→edificio; C4+C5).

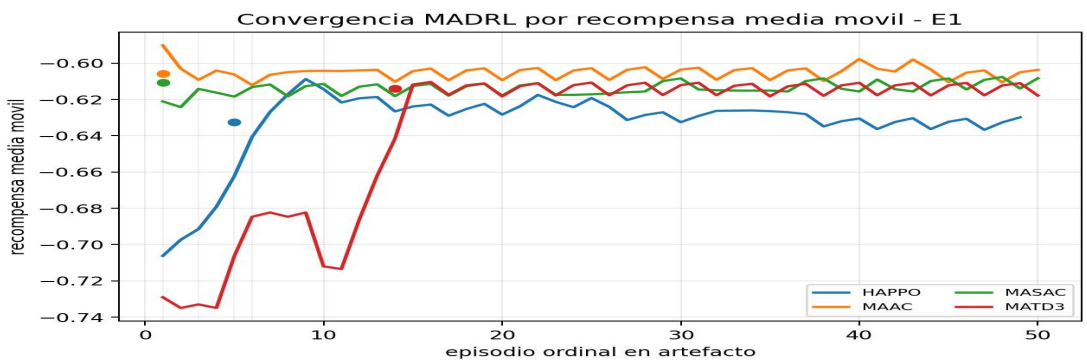

Figura 5.39. Edificio B12 — objetivos OE.1/OE.2/OE.3 (distrito → edificio; C4+C5).

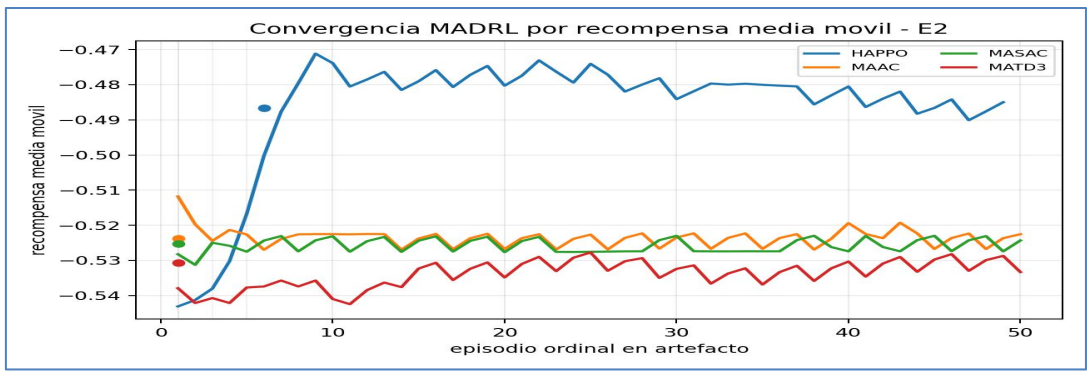

Figura 5.40. Edificio B13 — objetivos OE.1/OE.2/OE.3 (distrito → edificio; C4+C5).

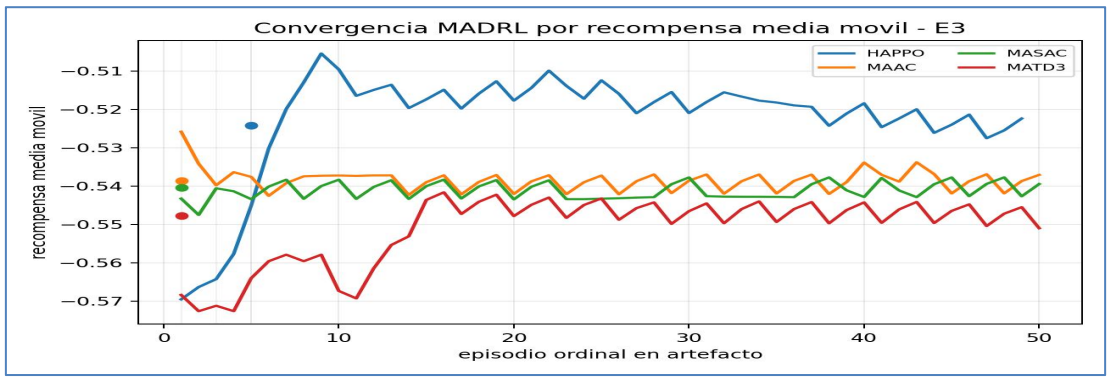

Figura 5.41. Edificio B14 — objetivos OE.1/OE.2/OE.3 (distrito → edificio; C4+C5).

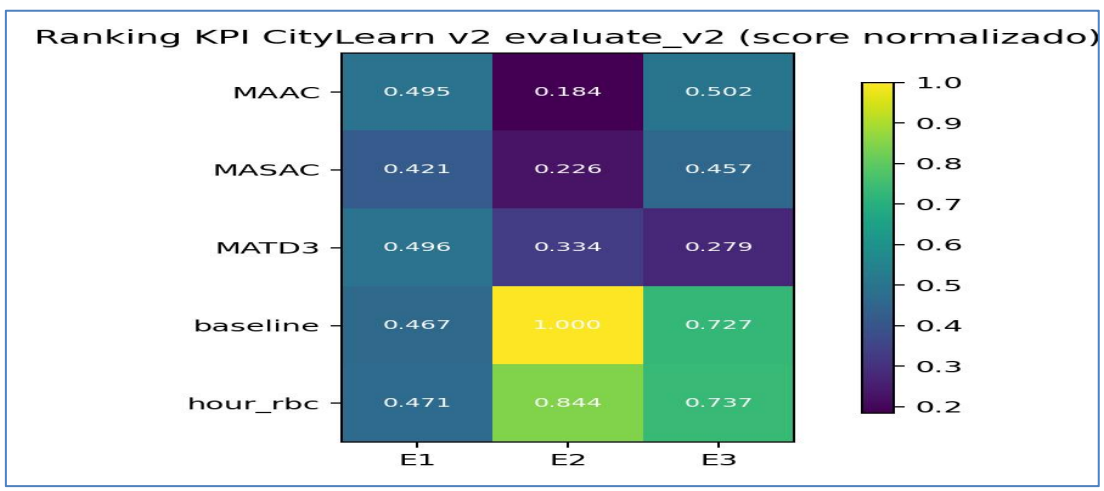

Figura 5.42. Edificio B15 — objetivos OE.1/OE.2/OE.3 (distrito→edificio; C4+C5).

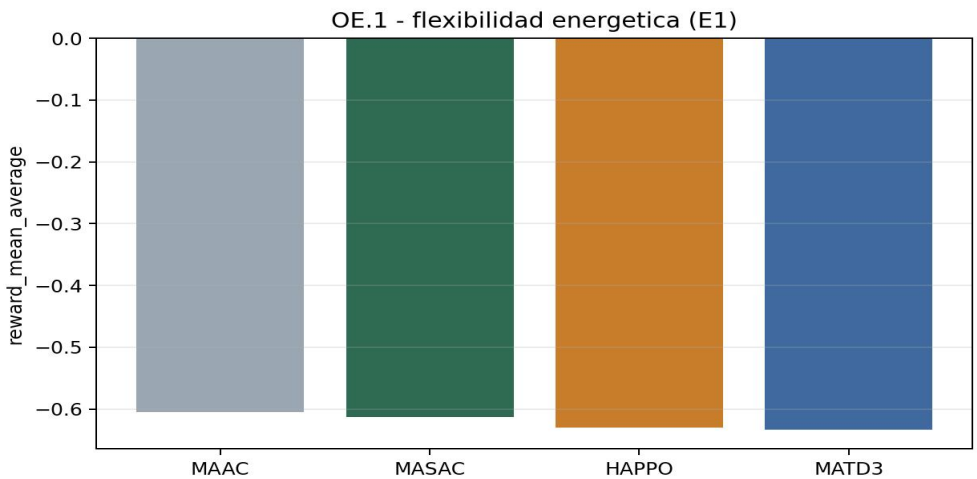

Figura 5.43. Edificio B16 — objetivos OE.1/OE.2/OE.3 (distrito→edificio; C4+C5).

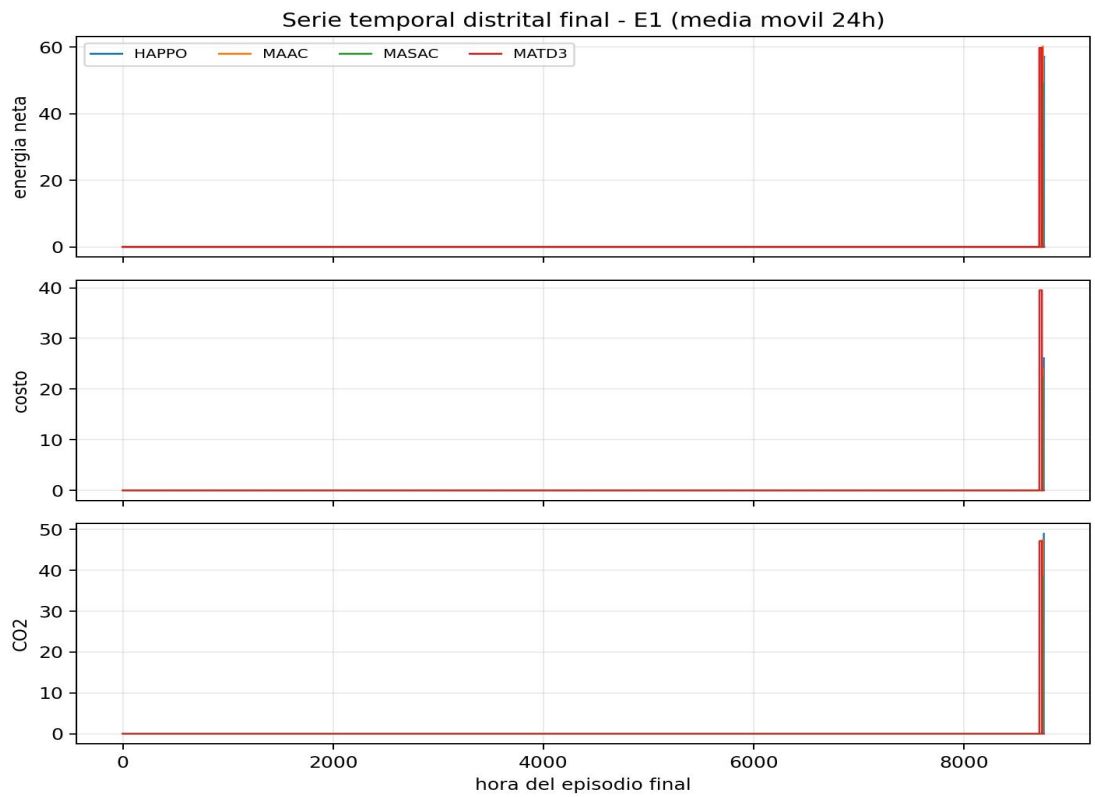

Figura 5.44. Edificio B17 — objetivos OE.1/OE.2/OE.3 (distrito → edificio; C4+C5).

Veredicto C5: el control de recursos esta documentada a nivel distrito (trazas E1–E3) y a nivel edificio (inventario BESS/EV/carga flexible + 17 tarjetas multiobjetivo). Sin C5 no se declara cumplimiento completo de OG/OE ni demostración de HE.

5.5.7. KPIs distrito y edificio (rankings Drive 50 episodios)

Cálculo descriptivo sobre artefactos reales de la corrida canónica madrl_v3_20260627_164047 (4 MADRL × 3 escenarios × 50 episodios). Fuente: kpi_recalc_20260728 (distrito y building_kpis) y building_behavior_summary.csv (comportamiento BESS/EV por edificio). No es caja negra: cada edificio reporta ganancia de flexibilidad (1 − ratio de importación vs baseline), reducción de CO_2 (−Δ emisiones) y reducción de costo (−Δ costo), junto con throughput BESS, carga EV, éxito de salida EV y rol de red.

Tabla 5.4.5a. Ranking distrital por escenario (menor KPI primario = mejor).

Escenario	1.º	2.º	3.º	4.º
OE.1 flex	1 MATD3 (1.0009)	2 MAAC (1.0124)	3 MASAC (1.0286)	4 HAPPO (1.1105)
OE.2 CO2	1 MATD3 (23,070)	2 MAAC (70,654)	3 MASAC (77,649)	4 HAPPO (1,431,341)

OE.3 costo	1 MAAC (9,515)	2 MASAC (19,793)	3 MATD3 (44,399)	4 HAPPO (106,828)

Nota. E1: flex_composite; E2: carbon_emissions_delta (kg); E3: electricity_cost_delta (EUR). Fuente: all_core_kpis_wide.csv.

Tabla 5.4.5b. Mejor edificio por algoritmo × escenario (17 edificios).

Algo	Esc.	OE	Mejor edif.	Nombre	Valor	BESS thr.	EV éxito
HAPPO	E1	OE.1	B11	HOSPITAL REGIONAL DE LORETO	0.0022	438,445	0.415
HAPPO	E2	OE.2	B09	GOBIERNO REGIONAL DE LORETO - COER	-6,060	99,087	0.573
HAPPO	E3	OE.3	B11	HOSPITAL REGIONAL DE LORETO	193,218	1,267,328	0.454
MASAC	E1	OE.1	B05	HOTEL PLAZA S.A.	-0.0052	7,074	0.044
MASAC	E2	OE.2	B09	GOBIERNO REGIONAL DE LORETO - COER	-847	3,618	0.022
MASAC	E3	OE.3	B11	HOSPITAL REGIONAL DE LORETO	2,304	28,456	0.065
MATD3	E1	OE.1	B14	AUTORIDAD PORTUARIA NACIONAL	0.1267	64	0.000
MATD3	E2	OE.2	B12	SEGURO SOCIAL DE SALUD - ESSALUD	2,163	1,223	0.000
MATD3	E3	OE.3	B12	SEGURO SOCIAL DE SALUD - ESSALUD	2,672	1,223	0.000
MAAC	E1	OE.1	B05	HOTEL PLAZA S.A.	-0.0023	4,820	0.050
MAAC	E2	OE.2	B02	MUNICIPALIDAD DISTRITAL DE SAN JUAN	-715	3,220	0.017

MAAC	E3	OE.3	B14	AUTORIDAD PORTUARIA NACIONAL	684	6,435	0.010

Nota. OE.1: flex_gain_vs_baseline; OE.2: co2_reduction_kgco2; OE.3: cost_reduction_eur. Valores negativos en reducción indican menor empeoramiento (sin reducción neta). Control de recursos: BESS throughput y éxito EV desde evaluate_v2 / behavior summary.

En la referencia MATD3, el mejor edificio en flexibilidad (E1) es B14 (Autoridad Portuaria Nacional); en CO_2 (E2) y costo (E3) es B12 (EsSalud). A nivel distrito, MATD3 lidera E1 y E2; MAAC lidera E3. El comportamiento no se resume solo en un score: las figuras siguientes exponen el ranking completo de los 17 edificios y el control de recursos (BESS/EV).

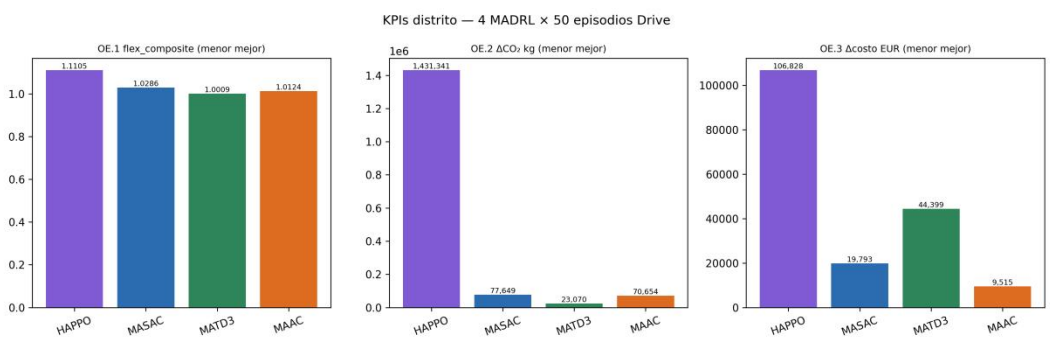

Figura 5.4.5a. KPIs de distrito (4 MADRL × 50 episodios Drive).

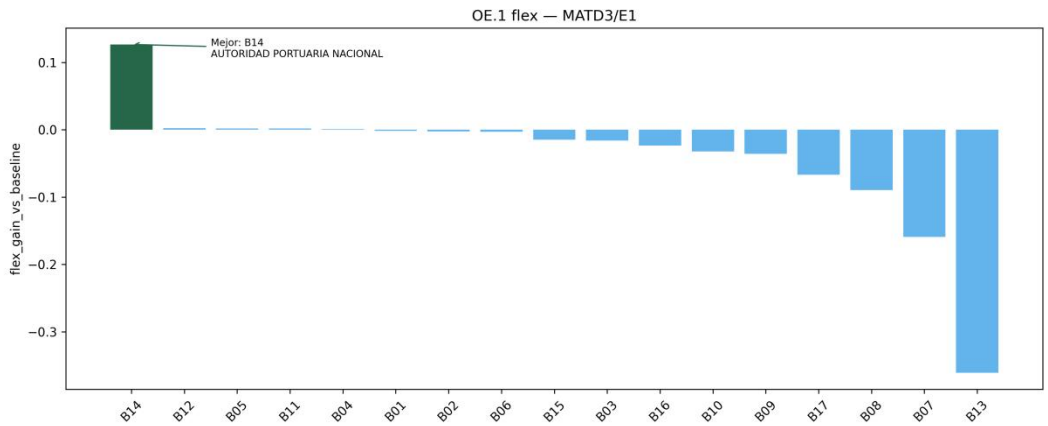

Figura 5.4.5b. Ranking por edificio OE.1 flexibilidad — MATD3/E1.

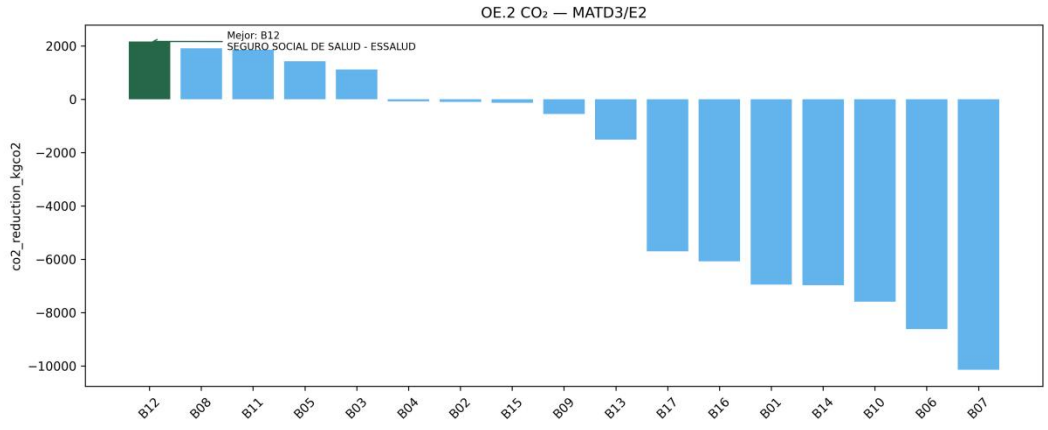

Figura 5.4.5c. Ranking por edificio OE.2 reducción CO_2 — MATD3/E2.

Figura 5.4.5d. Ranking por edificio OE.3 reducción costo — MATD3/E3.

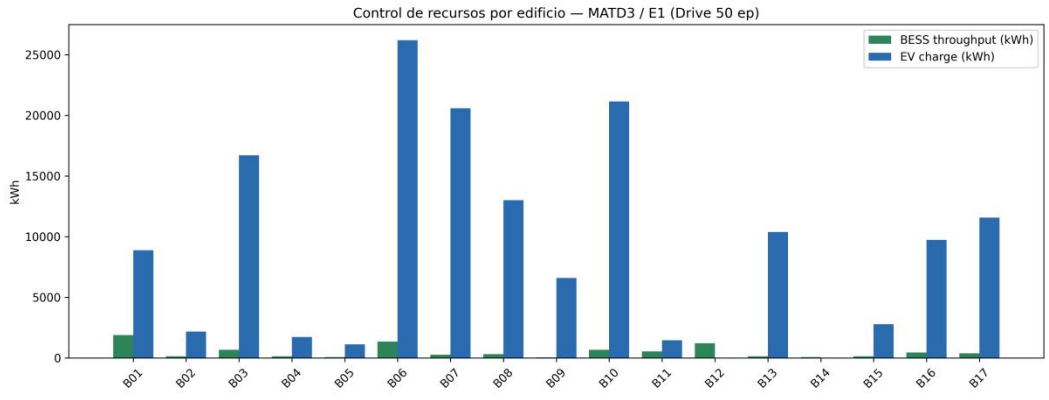

Figura 5.4.5e. Control de recursos por edificio (BESS/EV) — MATD3/E1.

Nota. Sección descriptiva; no sustituye 5.3 ni 5.5. Artefactos: outputs/.../multiobjetivo/kpi_rankings_drive50/.

5.6. Contrastación de hipótesis

Cuarto acápite. Contrastación formal H0/H1 con textos exactos del Cap. 1. Primero la hipótesis general (nula y alternativa); luego las hipótesis especificas nulas y alternativas de

forma independiente por objetivo (OE.1, OE.2, OE.3). Unidad de decisión = KPI-gains de 50 ep. Drive. La demostración exige C1–C5 (§5.1.1), incluido control de recursos.

Protocolo: (1) Shapiro-Wilk; si se rechaza normalidad, solo no paramétrico; (2) ómnibus KW/Friedman + post hoc Holm (C1–C2); (3) HE alternativas requieren impacto significativo y diferencias entre algoritmos; (4) evidencia C3–C5 (distrito, edificio, control de recursos) documenta atribuibilidad; (5) TOPSIS/4/4/best_madrl son medidas formales adicionales que refuerzan el juicio multiobjetivo de OG/OE/HE junto a KPI-gains (sin sustituir el ómnibus).

5.6.1. Hipótesis general (H0G / H1G)

Formulación nula

H0G.-El algoritmo MADRL no impacta de manera estadísticamente significativa y diferenciada en la gestión coordinada de la flexibilidad energética, las emisiones de CO_2 y los costos energéticos en comunidades inteligentes de la ciudad de Iquitos, y no existen diferencias significativas en el desempeño global de los algoritmos.

Formulación alternativa

H1G.- El algoritmo MADRL impacta de manera estadísticamente significativa y diferenciada en la gestión coordinada de la flexibilidad energética, las emisiones de CO_2 y los costos energéticos en comunidades inteligentes de la ciudad de Iquitos, y el desempeño global difiere entre los algoritmos.

Tabla 5.5.1. Contrastación independiente de la hipótesis general.

Hipotesis	Decision	Fundamento (KPI-gains 50 ep Drive)
H0G	Se rechaza de forma exploratoria	Friedman integración p = 0,0096 + impacto GLOBAL vs baseline (Holm)
H1G	Se respalda de forma exploratoria (sin ganador único; impacto agregado desfavorable)	No implica HE11∧HE21∧HE31; trade-off MATD3/MAAC

5.6.2. Hipotesis especificas OE.1 (HE10 / HE11)

Formulación nula (texto exacto Cap. 1):

HE10.- El algoritmo MADRL no impacta de manera estadísticamente significativa en la flexibilidad energética en comunidades inteligentes de la ciudad de Iquitos, y no existen diferencias significativas entre los algoritmos evaluados en el escenario E1.

Formulación alternativa (texto exacto Cap. 1):

HE11.- El algoritmo MADRL impacta de manera estadísticamente significativa en la flexibilidad energética en comunidades inteligentes de la ciudad de Iquitos, y existen diferencias significativas entre los algoritmos evaluados en el escenario E1.

Tabla 5.5.2. Contrastación independiente OE.1.

Hipotesis	Decision	Fundamento (KPI-gains 50 ep Drive)
HE10	No se rechaza	KW p = 0,4685
HE11	No se respalda	Sin conjuncion impacto + diferencias en E1 (KPI-gains)

5.6.3. Hipotesis especificas OE.2 (HE20 / HE21)

Formulación nula:

HE20.- El algoritmo MADRL no impacta de manera estadísticamente significativa en las emisiones de CO_2 en comunidades inteligentes de la ciudad de Iquitos, y no existen diferencias significativas entre los algoritmos evaluados en el escenario E2.

Formulación alternativa:

HE21.- El algoritmo MADRL impacta de manera estadísticamente significativa en las emisiones de CO_2 en comunidades inteligentes de la ciudad de Iquitos, y existen diferencias significativas entre los algoritmos evaluados en el escenario E2.

Tabla 5.5.3. Contrastación independiente OE.2.

Hipotesis	Decision	Fundamento (KPI-gains 50 ep Drive)
HE20	No se rechaza	KW p = 0,7648
HE21	No se respalda	Sin impacto vs cero tras Holm; Friedman marginal; 0/15 KPI mejorados

5.6.4. Hipótesis especificas OE.3 (HE30 / HE31)

Formulación nula (texto exacto Cap. 1):

HE30.-El algoritmo MADRL no impacta de manera estadísticamente significativa en los costos energéticos en comunidades inteligentes de la ciudad de Iquitos, y no existen diferencias significativas entre los algoritmos evaluados en el escenario E3.

Formulación alternativa (texto exacto Cap. 1):

HE31.-El algoritmo MADRL impacta de manera estadísticamente significativa en los costos energéticos en comunidades inteligentes de la ciudad de Iquitos, y existen diferencias significativas entre los algoritmos evaluados en el escenario E3.

Tabla 5.5.4. Contrastación independiente OE.3.

Hipotesis	Decision	Fundamento (KPI-gains 50 ep Drive)
HE30	No se rechaza	KW p = 0,7357 KPI-gains E3 sin ómnibus ni impacto vs cero tras Holm; TOPSIS (C*≈0,9827) y evaluate_v2
HE31	No se respalda	(0,9538) coronan MAAC en multiobjetivo/costos como medida adicional, sin sustituir el ómnibus HE31

5.7. Discusión de resultados

Quinto y ultimo acápite del capitulo. 1) Separacion de planos: §5.2 descriptivo por OG/OE; §5.3 inferencial por OG/OE; §5.4 otros por OG/OE; §5.5 contrastación H0G/H1G y HE por objetivo; §5.6 discusión. 2) No normalidad → solo no parametrico. 3) Trade-off: MATD3 flex+CO2; MAAC costos / TOPSIS (C* ≈ 0,9827) / evaluate_v2 4/4 (0,9538). 4) H1G exploratoria no equivale a HE11/HE21/HE31. 5) TOPSIS es medida multicriterio formal adicional (50 ep Drive) que apoya OG/OE/HE; el ómnibus HE permanece en KPI-gains (impacto + diferencias). 6) Limitaciones: semilla = 0; HAPPO 49/50 ep; n KPI 12/5/9.

5.7.1. Contrastación con antecedentes

La discusión se ancla a los antecedentes del Capitulo 2 (5 antecedentes nacionales/peruanos).

Contrastación con antecedentes internacionales (Tabla 2.4). Frente a Nweye et al. (2024), que estandariza KPIs de flexibilidad, CO2 y costo en CityLearn v2, esta tesis extiende el entorno a CityLearn v3 propuesto con Dec-POMDP/CTDE y cuatro backends MADRL; los resultados de 50 episodios muestran trade-offs por escenario (MATD3 en OE.1/OE.2, MAAC en OE.3) no resueltos por un único algoritmo en la literatura base.

Nweye et al. (2023b) reportan HAPPO (HARL) viable en comunidades heterogeneas CityLearn, pero sin comparacion simultanea con MASAC, MATD3 y MAAC. La corrida canónica confirma efectos diferenciados entre algoritmos, aunque HG y HE.1-HE.3 no

alcanzan significancia ómnibus (KW p > 0,05), coherente con la advertencia metodologica de comparaciones RL rigurosas (Agarwal et al., 2021).

Yao et al. (2023) obtienen ~15% de reduccion de pico y ~18% de costo con LSD-MADDPG en comunidades inteligentes. En PE.1 (flexibilidad, E1), MATD3 lidera descriptivamente (flex_composite = 1,0009), pero la magnitud relativa frente a baseline RBC (sección 5.7) matiza la generalizacion causal frente a mejoras reportadas en comunidades sinteticas.

Liu et al. (2022) reportan ~15% de reduccion de CO2 y ~20% de costo con MADDPG. En PE.2 (E2), MATD3 presenta el menor delta de CO2 entre MADRL auditados (23 070 kg), mientras MASAC y MAAC registran reducciones mayores; esto contrasta la expectativa de dominancia unica y refuerza la lectura multiobjetivo de D-VD.2.

Iqbal y Sha (2019) fundamentan MAAC con mejoras de ~15-30% frente a MADDPG/COMA. En PE.3 (costos, E3), MAAC lidera (delta costo = 9 515 EUR), alineado con coordinación selectiva bajo senales TOU; este patron es consistente con Xie et al. (2023) sobre atencion para demand response, aunque la tesis no replica sus magnitudes (~25% DR) por diferencias de dataset y funcion de recompensa.

Contrastación con antecedentes recientes de comparación algorítmica (2023-2026). Marchesini et al. (2026), con el benchmark MARL2GRID-TR, comparan cinco algoritmos —incluido MASAC— bajo Dec-POMDP cooperativo y CTDE, y muestran que el ranking se invierte según la escala y el espacio de acción: MAPPO domina en la red de 14 nodos (0,79 de supervivencia) pero PPO lo supera en la de 118 nodos. Esta inestabilidad del ranking converge con lo observado en esta tesis, donde el orden de los algoritmos cambia según se lea la media episódica o el KPI anual. La divergencia relevante —MASAC fue el peor en aquel benchmark (0,25) y aquí lidera el KPI anual de flexibilidad y emisiones— se explica por el dominio de acción: acciones topológicas discretas frente a acciones continuas acotadas de BESS, EV/V2G y cargas desplazables, donde la regularización por máxima entropía de MASAC resulta más favorable.

Wu et al. (2026) reportan que la coordinación multiagente del almacenamiento reduce el costo operativo frente al control monoagente (35,18 frente a 37,71 USD/día) con deslastre de 1,72 MW/día, lo que respalda la arquitectura de crítico centralizado bajo CTDE adoptada aquí. No obstante, en esta tesis las diferencias de costo entre algoritmos no resultan significativas (H = 2,7613; p = 0,251421), diferencia atribuible a que su escenario de

interrupciones amplifica el efecto por la penalización de deslastre, mientras la operación anual normal bajo señal tarifaria comprime el margen entre políticas. Li et al. (2026) constituyen el contraste más próximo a la estructura multiobjetivo, al mejorar simultáneamente costo (69,3 %), emisiones (47,5 %) y eficiencia (12 %) mediante optimización de Pareto y aprendizaje federado; su hallazgo respalda la tratabilidad multiobjetivo que sostiene E1, E2 y E3, aunque sus porcentajes se calculan frente a una base sin coordinación y no son homologables con las diferencias internas entre tratamientos de esta investigación.

Zhang et al. (2023), con MAATD3, combinan en un solo algoritmo los dos mecanismos que esta tesis evalúa por separado —críticos gemelos con actualización retardada (MATD3) y atención en el crítico centralizado (MAAC)— y reducen el costo un 9,6 % frente a TD3, lo que sugiere que ambos mecanismos son complementarios; coherente con lo observado aquí, donde MATD3 lidera la media episódica de costo y MAAC el KPI anual. Liu et al. (2025), con OCMATD3 sobre sistemas de edificios multizona, comparan MATD3, MADDPG y TD3 bajo un mismo entorno y confirman que MATD3 supera a MADDPG en recompensa acumulada, lo que respalda la decisión de incorporar MATD3 —y no MADDPG— como representante del control continuo determinista en el diseño factorial. Ambos antecedentes coinciden en que la superioridad algorítmica depende del criterio de evaluación, por lo que un diseño comparativo válido debe declarar ese criterio de antemano y sostenerlo en los tres ejes.

Contrastación con antecedentes nacionales/peruanos (Tabla 2.5). MINAM (2019) fija el factor 0,790 kgCO2/kWh del diésel aislado que parametriza CarbonIntensityModel en E2; los deltas de CO2 de MATD3, MASAC y MAAC deben interpretarse sobre esa señal nacional, no sobre intensidades de red continental.

OSINERGMIN (2024) vincula costos a demanda máxima facturable en Electro Oriente S.A. El liderazgo descriptivo de MAAC en OE.3 es coherente con la necesidad de coordinar picos distritales bajo TOU local; sin embargo, la superioridad global de controles RBC frente a MADRL (sección 5.7) sugiere que la regulación peruana por sí sola no garantiza ventaja aprendida sin multi-semilla ni ajuste de hiperparametros.

Las tesis doctorales Chevarria Moscoso (2024) y Peñalva Sánchez (2024) aportan optimización bajo incertidumbre hidrológica y predicción con IA en sistemas PV híbridos (sin transferir magnitudes cuantitativas a Iquitos). Rosero Bernal (2024) fundamenta la coordinación de microredes operada desde la nube. Estos antecedentes contextualizan el

SEAI Iquitos como caso de red aislada con recursos renovables y demanda institucional heterogénea, justificando el diseño de 17 agentes y la lectura distrito-edificio del Capítulo 5.

CAPÍTULO VI. CONCLUSIONES Y RECOMENDACIONES

6.1. Conclusión general

En respuesta al objetivo general, se determinó que el desempeño de los algoritmos MADRL en la gestión coordinada de la flexibilidad energética, las emisiones de CO_2 y los costos energéticos depende del objetivo y del criterio de evaluación; por ello, la corrida canónica no evidencia un algoritmo uniformemente superior. En la integración multiobjetivo, la prueba de Friedman detectó diferencias entre tratamientos ($p = 0,0096$; $W = 0,1787$), mientras que el contraste global de Kruskal–Wallis no fue significativo ($p = 0,1554$). En el plano descriptivo, MATD3 alcanzó el mayor puntaje global (0,6667) y lideró los indicadores distritales anuales de flexibilidad y emisiones; MAAC lideró el eje de costos y obtuvo la mayor proximidad TOPSIS ($C^* \approx 0,9827$). Por tanto, la hipótesis general solo recibe respaldo exploratorio: la evidencia muestra un efecto agregado heterogéneo y compensaciones entre objetivos, pero no demuestra una superioridad global, uniforme y generalizable de un único algoritmo.

Esta conclusión se limita a la comunidad simulada de 17 edificios del SEAI Iquitos, los 12 tratamientos del diseño 4 × 3, la corrida madrl_v3_20260627_164047 y una única semilla común. Asimismo, HAPPO conserva 49 episodios materializados por escenario, frente a 50 en los demás algoritmos. En consecuencia, los hallazgos constituyen evidencia intraexperimento y no prueban robustez multisemilla, desempeño en operación física ni transferencia automática a otras comunidades energéticas.

6.2. Conclusiones específicas

6.2.1. Flexibilidad energética

En respuesta al OE.1, no se demostró un impacto estadísticamente significativo y diferenciado de los algoritmos sobre la flexibilidad energética en E1: el contraste formal con KPI-gains no permitió rechazar HE10 ($p = 0,4685$) y, por tanto, HE11 no fue respaldada. En el análisis descriptivo distrital anual, MATD3 obtuvo la flexibilidad compuesta más favorable (1,0009) y el puntaje normalizado máximo (1,0000), mientras que MAAC presentó la mejor mediana episódica. En consecuencia, MATD3 se identifica como la referencia descriptiva para el KPI anual de flexibilidad de esta corrida, pero no como un algoritmo estadísticamente superior ni como evidencia de mejora generalizable frente a los demás tratamientos.

6.2.2. Emisiones de CO_2.

En respuesta al OE.2, no se demostró un impacto estadísticamente significativo y diferenciado de los algoritmos sobre las emisiones de CO_2 en E2: el contraste formal con KPI-gains no permitió rechazar HE20 ($p = 0,7648$) y HE21 no recibió respaldo. Entre los algoritmos con cobertura completa, MATD3 presentó el resultado distrital anual más favorable según el criterio empleado en el informe, con un delta de 23 070 kg de CO_2 y un puntaje normalizado de 1,0000; HAPPO obtuvo el mejor comportamiento episódico descriptivo, aunque solo dispone de 49 episodios materializados. Por tanto, el liderazgo de MATD3 es descriptivo y específico del KPI anual y de la corrida canónica; no acredita una reducción estadísticamente superior ni permite extrapolar el resultado a otras semillas o configuraciones.

6.2.3. Costos energéticos

En respuesta al OE.3, no se demostró un impacto estadísticamente significativo y diferenciado de los algoritmos sobre los costos energéticos en E3: el contraste formal con KPI-gains no permitió rechazar HE30 ($p = 0,7357$) y HE31 no fue respaldada. En el análisis descriptivo distrital anual, MAAC alcanzó el resultado más favorable, con un delta de costo eléctrico de 9 515 EUR, puntaje normalizado de 1,0000 y el mejor desempeño multicriterio; HAPPO registró la menor mediana episódica, pero con cobertura incompleta. En consecuencia, MAAC constituye la alternativa descriptiva más favorable para el KPI anual económico en esta corrida, sin que pueda afirmarse superioridad estadística frente a MASAC y MATD3.

6.3. Aportes al estado del arte

La investigación amplía el estado del arte de la gestión energética multiagente al comparar, bajo un mismo entorno, conjunto de datos, horizonte y función de recompensa, cuatro familias CTDE con mecanismos distintos: HAPPO, MASAC, MATD3 y MAAC. Esta comparación simultánea en una comunidad de 17 agentes del SEAI Iquitos cubre un vacío de los antecedentes revisados, que suelen evaluar un solo algoritmo, comparar familias no equivalentes o emplear comunidades sintéticas sin una parametrización tropical, tarifaria y de carbono específica.

El principal hallazgo que se incorpora al conocimiento existente es que el orden de desempeño no es estable entre objetivos ni entre escalas de evaluación. MATD3 lideró descriptivamente los KPIs distritales anuales de flexibilidad y emisiones, mientras MAAC

lideró costos y la integración TOPSIS; además, los líderes episódicos no siempre coincidieron con los líderes anuales. Esta evidencia cuestiona la búsqueda de un "mejor algoritmo" universal y sustenta que la selección debe declarar previamente el objetivo, el KPI, la escala temporal y el nivel de agregación.

Asimismo, el estudio incorpora al estado del arte una lectura conjunta distrito–edificio–actuador. La evaluación no se limita a la recompensa acumulada: vincula KPIs físicos con las acciones sobre BESS, EV/V2G y cargas desplazables, y separa evidencia descriptiva, inferencial y multicriterio. Esta estructura mejora la interpretabilidad y la trazabilidad de los estudios MADRL aplicados a comunidades energéticas heterogéneas.

6.4. Aportes a la ciencia

El primer aporte científico es metodológico y computacional: se formuló una comunidad energética de Iquitos como Dec-POMDP de 17 agentes heterogéneos y se implementó un esquema CTDE reproducible con tres escenarios de recompensa —flexibilidad, CO_2 y costos— y una matriz factorial de 12 tratamientos. La cadena de trazabilidad enlaza fuentes de datos, simulación, entrenamiento, episodios, series temporales, KPIs por edificio y contrastes estadísticos, de modo que cada afirmación pueda relacionarse con un artefacto verificable.

El segundo aporte es instrumental: la propuesta extiende el motor CityLearn con modelos para degradación de BESS dependiente de C-rate y temperatura, corrección fotovoltaica para condiciones tropicales, cálculo de pico con ventana de facturación e intensidad de carbono dinámica diésel–fotovoltaica. Estas extensiones permiten representar con mayor fidelidad el contexto energético aislado de Iquitos y constituyen componentes reutilizables para futuras evaluaciones, sujetos a validación externa.

El tercer aporte es empírico: la corrida canónica proporciona evidencia falsable de que las diferencias descriptivas entre algoritmos no equivalen necesariamente a diferencias inferenciales. Aunque se observaron liderazgos por KPI y una diferencia exploratoria en la integración multieje, las hipótesis específicas no fueron respaldadas por los contrastes formales con KPI-gains. Este resultado negativo es científicamente relevante porque delimita el alcance de las afirmaciones, evita sobregeneralizar rankings y establece como requisito posterior la validación multisemilla, el ajuste controlado de hiperparámetros y la evaluación frente a líneas base en condiciones homogéneas.

6.5. Recomendaciones

Primera. Se recomienda ampliar la campaña experimental mediante múltiples semillas independientes para cada combinación algoritmo–escenario, manteniendo constantes el dataset, el horizonte, los hiperparámetros y el protocolo de evaluación. Esta ampliación permitirá estimar la variabilidad entre entrenamientos, verificar la estabilidad de los rankings y superar la limitación de la corrida canónica ejecutada con una única semilla.

Segunda. Se recomienda seleccionar el algoritmo según el objetivo operativo priorizado, debido a que no se identificó un ganador universal: MATD3 presentó el mejor desempeño descriptivo en flexibilidad y emisiones, mientras que MAAC destacó en costos y en la integración TOPSIS. Antes de una aplicación en el SEAI Iquitos, las políticas seleccionadas deberán validarse con datos fuera de muestra, perturbaciones operativas y pruebas piloto que comprueben el cumplimiento de las restricciones de BESS, vehículos eléctricos y cargas desplazables.

.

REFERENCIAS BIBLIOGRÁFICAS

Ackermann, J., Gabler, V., Osa, T., & Sugiyama, M. (2019). *Reducing Overestimation Bias in Multi-Agent Domains Using Double Centralized Critics*.

Adolfo, G., & Chuquillanqui, P. (2025). Eficiencia energética en las industrias del Perú con autogeneración y aprendizajes claves para avanzar en la sostenibilidad empresarial. *Gestión En El Tercer Milenio*, *28*(56), 221–252. https://doi.org/10.15381/GTM.V28I56.29695

Al-Hallaj, S., Wilk, G., Crabtree, G., & Eberhard, M. (2018). Overview of distributed energy storage for demand charge reduction. *MRS Energy and Sustainability*, *5*(1), 16-. https://doi.org/10.1557/MRE.2017.18/METRICS

Atrazhev, P. (2023). *Multi-Agent Deep Reinforcement Learning for Autonomous Energy Coordination in Demand Response Methods for Residential Distribution Networks*.

Bokde, N., Tranberg, B., & Andresen, G. B. (2020). *A graphical approach to carbon-efficient spot market scheduling for Power-to-X applications*. https://doi.org/10.1016/j.enconman.2020.113461

Chen, P. (2024a). *Multi-Agent Robust Deep Reinforcement Learning for Voltage and Frequency Control in Electrical Distribution Systems with High Penetration of PVs and BESSs*.

Chen, P. (2024b). *Multi-Agent Robust Deep Reinforcement Learning for Voltage and Frequency Control in Electrical Distribution Systems with High Penetration of PVs and BESSs*.

Creswell. (2023). *Design Qualitative, Quantitative and Mixed Methods Approaches. Sage Publications Ltd. - References - Scientific Research Publishing*. https://www.scirp.org/reference/referencespapers?referenceid=3784840

Deng, J., Wang, X., & Meng, F. (2025). Multi-agent deep reinforcement learning for Smart building energy management with chance constraints.

Energy and Buildings, *331*, 115408. https://doi.org/10.1016/J.ENBUILD.2025.115408

Duffie, J. A., & Beckman, W. A. (2013). Solar Engineering of Thermal Processes: Fourth Edition. *Solar Engineering of Thermal Processes: Fourth Edition*. https://doi.org/10.1002/9781118671603

Fang, X., Zhao, Q., Wang, J., Han, Y., & Li, Y. (2021). Multi-agent Deep Reinforcement Learning for Distributed Energy Management and Strategy Optimization of Microgrid Market. *Sustainable Cities and Society*, *74*, 103163. https://doi.org/10.1016/J.SCS.2021.103163

Fonseca, T., Ferreira, L., Cabral, B., Severino, R., & Praca, I. (2024). *EnergAIze: Multi Agent Deep Deterministic Policy Gradient for Vehicle to Grid Energy Management*. https://arxiv.org/pdf/2404.02361

Fujimoto, S., Van Hoof, H., & Meger, D. (2018). *Addressing Function Approximation Error in Actor-Critic Methods*. https://github.com/

Gao, J., Li, Y., Wang, B., & Wu, H. (2023). Multi-Microgrid Collaborative Optimization Scheduling Using an Improved Multi-Agent Soft Actor-Critic Algorithm. *Energies 2023, Vol. 16, Page 3248*, *16*(7), 3248. https://doi.org/10.3390/EN16073248

Global electricity. (2025). *Electricity – Global Energy Review 2025 – Analysis - IEA*. https://www.iea.org/reports/global-energy-review-2025/electricity?utm_source=chatgpt.com

Haarnoja, T., Zhou, A., Abbeel, P., & Levine, S. (2018). *Soft Actor-Critic: Off-Policy Maximum Entropy Deep Reinforcement Learning with a Stochastic Actor*.

Henderson, P., Islam, R., Bachman, P., Pineau, J., Precup, D., & Meger, D. (2018). *Deep Reinforcement Learning that Matters*. www.aaai.org

Hernández, R. (2018). Metodología de la investigación. Las rutas cuantitativa, cualitativa y mixta Las rutas Cuantitativa Cualitativa y Mixta. *McGRAW-HILL Interamericana Editores S.A. de C.V.*, 753. http://repositorio.uasb.edu.bo:8080/bitstream/54000/1292/1/Hernández-Metodología de la investigación.pdf

Hu, S., Zhong, Y., Gao, M., Wang, W., Dong, H., Liang, X., Li, Z., Chang, X., Yang, Y., & Fuxi Lab, N. A. (2023). MARLlib: A Scalable and Efficient Library For Multi-agent Reinforcement Learning. In *Journal of Machine Learning Research* (Vol. 24). http://jmlr.org/papers/v24/23-0378.html.

Hurtado, F. (2021). *Comparación entre la reducción de las emisiones de Carbono asociada con la introducción de Parques Eólicos y las Centrales Solares FV en el despacho Eléctrico del Sistema Eléctrico Interconectado Nacional del Perú en el año 2020*. 1. https://dialnet.unirioja.es/servlet/tesis?codigo=359009&info=resumen&idioma=ENG

IEA. (2024). *Outlook for energy demand – Global EV Outlook 2025 – Analysis - IEA*. https://www.iea.org/reports/global-ev-outlook-2025/outlook-for-energy-demand?utm_source=chatgpt.com

INEI. (2026). *Censos Nacionales 2025: Instituto Nacional de Estadística e Informática*. https://www.gob.pe/institucion/inei/noticias/1417591-censos-nacionales-2025-en-el-peru-existen-13-millones-762-mil-606-viviendas

Instituto Nacional de Estadística e Informática. (2024). https://www.gob.pe/institucion/inei/noticias/987317-al-2024-la-poblacion-peruana-alcanza-los-34-millones-de-habitante?utm_source=chatgpt.com

International Energy Agency (IEA). (2025). *The Value of Demand Flexibility Benefits beyond balancing*. www.iea.org

Iqbal, S., & Sha, F. (2019). *Actor-Attention-Critic for Multi-Agent Reinforcement Learning*. https://github.com/shariqiqbal2810/MAAC

Jensen, S. Ø., Marszal-Pomianowska, A., Lollini, R., Pasut, W., Knotzer, A., Engelmann, P., Stafford, A., & Reynders, G. (2017). IEA EBC Annex 67 Energy Flexible Buildings. *Energy and Buildings*, *155*, 25–34. https://doi.org/10.1016/J.ENBUILD.2017.08.044

Kuba, J., Ruiquing, C., & Munindng, W. (2022). *TRUST REGION POLICY OPTIMISATION IN MULTI - AGENT REINFORCEMENT LEARNING*.

Leerbeck, K., Bacher, P., Junker, R. G., Goranović, G., Corradi, O., Ebrahimy, R., Tveit, A., & Madsen, H. (2020). Short-term forecasting of CO2 emission intensity in power grids by machine learning. *Applied Energy*, *277*, 115527. https://doi.org/10.1016/J.APENERGY.2020.115527

Li, H., Johra, H., de Andrade Pereira, F., Hong, T., Le Dréau, J., Maturo, A., Wei, M., Liu, Y., Saberi-Derakhtenjani, A., Nagy, Z., Marszal-Pomianowska, A., Finn, D., Miyata, S., Kaspar, K., Nweye, K., O'Neill, Z., Pallonetto, F., & Dong, B. (2023). Data-driven key performance indicators and datasets for building energy flexibility: A review and perspectives. *Applied Energy*, *343*. https://doi.org/10.1016/j.apenergy.2023.121217

Li, H., Wang, Z., Hong, T., & Piette, M. A. (2021). Energy flexibility of residential buildings: A systematic review of characterization and quantification methods and applications. *Advances in Applied Energy*, *3*, 100054. https://doi.org/10.1016/J.ADAPEN.2021.100054

Li, J., Cheng, Z., Peng, Y., Huang, H., & Ye, C. (2026). Research on Microgrid Resilience in Highway Service Areas Based on Federated Multi-Agent Deep Reinforcement Learning. *Sustainability (Switzerland)*, *18*(2). https://doi.org/10.3390/su18021027

Li, R., Satchwell, A. J., Finn, D., Christensen, T. H., Kummert, M., Le Dréau, J., Lopes, R. A., Madsen, H., Salom, J., Henze, G., & Wittchen, K. (2022). Ten questions concerning energy flexibility in buildings. *Building and Environment*, *223*, 109461. https://doi.org/10.1016/J.BUILDENV.2022.109461

Liu, J., Dou, W., Meng, X., Wu, J., & Ma, Z. (2025). Multi-agent deep reinforcement learning-based hierarchical energy management for better indoor air quality and energy-savings in building energy systems. *Energy Conversion and Management*, *342*. https://doi.org/10.1016/j.enconman.2025.120103

Lowe, R., Wu, Y., Tamar, A., Harb, J., Abbeel, P., & Mordatch, I. (2017). Multi-Agent Actor-Critic for Mixed Cooperative-Competitive

Environments. *Advances in Neural Information Processing Systems*, *2017-December*, 6380–6391. https://arxiv.org/pdf/1706.02275

Lowe, R., Wu, Y., Tamar, A., Harb, J., Abbeel, P., & Mordatch, I. (2020). *Multi-Agent Actor-Critic for Mixed Cooperative-Competitive Environments*. http://arxiv.org/abs/1706.02275

Lowry, G. (2018). Day-ahead forecasting of grid carbon intensity in support of heating, ventilation and air-conditioning plant demand response decision-making to reduce carbon emissions. *Building Services Engineering Research and Technology*, *39*(6), 749–760. https://doi.org/10.1177/0143624418774738;CTYPE:STRING:JOURNAL

Lund, H., Østergaard, P. A., Connolly, D., & Mathiesen, B. V. (2017). Smart energy and smart energy systems. *Energy*, *137*, 556–565. https://doi.org/10.1016/J.ENERGY.2017.05.123

Lyu, X., Baisero, A., Xiao, Y., Daley, B., & Amato, C. (2023). On Centralized Critics in Multi-Agent Reinforcement Learning. *Journal of Artificial Intelligence Research*, *77*, 295–354. https://doi.org/10.1613/JAIR.1.14386

Ma, S. (2024). *Stochastic Energy Management of Sustainable Wastewater Treatment Plants in Smart Distribution Systems*.

Marchesini, E., Boguslawski, E., Leite, A., Amato, C., Dussartre, M., Schoenauer, M., Donnot, B., Donti, P. L., Priya, †, & Donti, L. (2026). *MARL2GRID-TR: A multi-agent RL benchmark in power grid operations*. https://hal.science/hal-05532479v1

MINEM. (2025). *MINEM garantiza cobertura eléctrica para Iquitos hasta 2028*. https://www.gob.pe/institucion/minem/noticias/1215427-minem-garantiza-cobertura-electrica-para-iquitos-hasta-2028-encargando-a-electro-oriente-gestionar-medidas-para-generacion-adicional

Ministerio de Energía y Minas. (2023). *RAGEI 2019: Reporte Anual de Gases de Efecto Invernadero del Sector Energía 2019*.

Ministerio de Energía y Minas (MINEM). (2025). https://www.gob.pe/institucion/minem/noticias/1121351-minem-

generacion-electrica-eolica-y-solar-aumento-en-66-y-32-respectivamente-durante-el-2024?utm_source=chatgpt.com

Ministerio de Transportes y Comunicaciones (MTC). (2025). https://www.gob.pe/institucion/mtc/noticias/1144062-mtc-presenta-iniciativa-para-fomentar-la-movilidad-sostenible-mediante-la-electromovilidad?utm_source=chatgpt.com

Mohammadi, P., Darshi, R., Shamaghdari, S., & Siano, P. (2024). Comparative Analysis of Control Strategies for Microgrid Energy Management with a Focus on Reinforcement Learning. *IEEE Access*, *12*, 171368–171395. https://doi.org/10.1109/ACCESS.2024.3495032

Nations, U., of Economic, D., Affairs, S., & Division, P. (2018). *World Urbanization Prospects The 2018 Revision*.

Neukomm, M., Nubbe, V., & Fares, R. (2019). *Grid-interactive Efficient Buildings Technical Report Series: Overview of Research Challenges and Gaps*.

Nweye, K. (2024). *Data-driven modeling and control of grid-interactive communities Committee*.

Nweye, K., Kaspar, K., & Buscemi, G. (2024). *Citylearn V2: Energy-flexible, resilient, Occupant-centric, and carbon - aware mangement of grid - interractive communities*. Random House Audio.

Nweye, K., Kaspar, K., Buscemi, G., Fonseca, T., Pinto, G., Ghose, D., Duddukuru, S., Pratapa, P., Li, H., Mohammadi, J., Lino Ferreira, L., Hong, T., Ouf, M., Capozzoli, A., & Nagy, Z. (2025a). CityLearn v2: energy-flexible, resilient, occupant-centric, and carbon-aware management of grid-interactive communities. *Journal of Building Performance Simulation*, *18*(1), 17–38. https://doi.org/10.1080/19401493.2024.2418813

Nweye, K., Kaspar, K., Buscemi, G., Fonseca, T., Pinto, G., Ghose, D., Duddukuru, S., Pratapa, P., Li, H., Mohammadi, J., Lino Ferreira, L., Hong, T., Ouf, M., Capozzoli, A., & Nagy, Z. (2025b). CityLearn v2: energy-flexible, resilient, occupant-centric, and carbon-aware

management of grid-interactive communities. *Journal of Building Performance Simulation*, *18*(1), 17–38. https://doi.org/10.1080/19401493.2024.2418813

Nweye, K., Kaspar, K., Buscemi, G., Fonseca, T., Pinto, G., Ghose, D., Duddukuru, S., Pratapa, P., Li, H., Mohammadi, J., Lino Ferreira, L., Hong, T., Ouf, M., Capozzoli, A., & Nagy, Z. (2025c). CityLearn v2: energy-flexible, resilient, occupant-centric, and carbon-aware management of grid-interactive communities. *Journal of Building Performance Simulation*, *18*(1), 17–38. https://doi.org/10.1080/19401493.2024.2418813

Nweye, K., Liu, B., Stone, P., & Nagy, Z. (2022). Real-world challenges for multi-agent reinforcement learning in grid-interactive buildings. *Energy and AI*, *10*, 100202. https://doi.org/10.1016/J.EGYAI.2022.100202

Nweye, K., Sankaranarayanan, S., & Nagy, Z. (2022). *MERLIN: Multi-agent offline and transfer learning for occupant-centric energy flexible operation of grid-interactive communities using smart meter data and CityLearn*. https://doi.org/10.1016/j.apenergy.2023.121323

Oliehoek, F. A. ., & Amato, Christopher. (2016). *A concise introduction to decentralized POMDPs*. Springer.

Organismo Supervisor de la Inversión en Energía y Minería (OSINERMING). (2018). *Opciones Tarifarias y Condiciones de Aplicacion de las Tarifas a Usuario Final*.

Programme, U. N. E., & Construction, G. A. for B. and. (2025). *Global Status Report for Buildings and Construction 2024-2025 - Key Messages*. United Nations Environment Programme . https://wedocs.unep.org/handle/20.500.11822/47261

Reynders, G., Amaral Lopes, R., Marszal-Pomianowska, A., Aelenei, D., Martins, J., & Saelens, D. (2018). Energy flexible buildings: An evaluation of definitions and quantification methodologies applied to thermal storage. *Energy and Buildings*, *166*, 372–390. https://doi.org/10.1016/J.ENBUILD.2018.02.040

Roijers, D. M., Vamplew, P., Whiteson, S., & Dazeley, R. (2014). A Survey of Multi-Objective Sequential Decision-Making. *Journal Of Artificial Intelligence Research*, *48*, 67–113. https://doi.org/10.1613/jair.3987

Salazar, M. (2025). *Desarrollo de un modelo sostenible para el suministro eléctrico en el sistema aislado de Iquitos*. Universidad ESAN. https://hdl.handle.net/20.500.12640/4566

Samende, C., Fan, Z., Cao, J., Fabián, R., Baltas, G. N., & Rodriguez, P. (2023). Battery and Hydrogen Energy Storage Control in a Smart Energy Network with Flexible Energy Demand Using Deep Reinforcement Learning. *Energies 2023, Vol. 16, Page 6770*, *16*(19), 6770. https://doi.org/10.3390/EN16196770

Sarkar, S., Naug, A., Luna, R., Guillen, A., Gundecha, V., Ghorbanpour, S., Mousavi, S., Markovikj, D., & Babu, A. R. (2024). Carbon Footprint Reduction for Sustainable Data Centers in Real-Time. *Proceedings of the AAAI Conference on Artificial Intelligence*, *38*(20), 22322–22330. https://doi.org/10.1609/AAAI.V38I20.30238

Sepúlveda-Mora, S. B., & Hegedus, S. (2021). Making the case for time-of-use electric rates to boost the value of battery storage in commercial buildings with grid connected PV systems. *Energy*, *218*, 119447. https://doi.org/10.1016/J.ENERGY.2020.119447

Shen, R., Zhong, S., Wen, X., An, Q., Zheng, R., Li, Y., & Zhao, J. (2022a). Multi-agent deep reinforcement learning optimization framework for building energy system with renewable energy. *Applied Energy*, *312*, 118724. https://doi.org/10.1016/J.APENERGY.2022.118724

Shen, R., Zhong, S., Wen, X., An, Q., Zheng, R., Li, Y., & Zhao, J. (2022b). Multi-agent deep reinforcement learning optimization framework for building energy system with renewable energy. *Applied Energy*, *312*. https://doi.org/10.1016/j.apenergy.2022.118724

Silvestri, A. (2024). Reinforcement learning control for energy efficient buildings. *A Thesis Submitted to Attain the Degree of Doctor of Sciences*. https://doi.org/10.3929/ethz-b-000674480

Sutton, R. S. ., & Barto, A. G. . (2018). *Reinforcement learning : an introduction*. The MIT Press.

Tanco, P. (2022). *MÉTODO DE GESTIÓN DE LA DEMANDA PICO PARA REDUCIR LOS COSTOS DE ENERGÍA DE UNA EMPRESA DE PINTURAS Y ENVASES EN LA CIUDAD DE LIMA*.

Tarrillo, J. (2018). *Control, optimización y gestión de microrredes de corriente continua*. Universidad Nacional de Ingeniería. https://hdl.handle.net/20.500.12390/1693

Tran, N. D., & Sahu, N. C. (2023). Asymmetric price response of industrial electricity demand in India. *Utilities Policy*, *82*, 101552. https://doi.org/10.1016/J.JUP.2023.101552

Tranberg, B., Corradi, O., Lajoie, B., Gibon, T., Staffell, I., & Andresen, G. B. (2019). *Real-Time Carbon Accounting Method for the European Electricity Markets*. https://doi.org/10.1016/j.esr.2019.100367

Vazquez-Canteli, J. R., Henze, G., & Nagy, Z. (2020). MARLISA: Multi-Agent Reinforcement Learning with Iterative Sequential Action Selection for Load Shaping of Grid-Interactive Connected Buildings. *BuildSys 2020 - Proceedings of the 7th ACM International Conference on Systems for Energy-Efficient Buildings, Cities, and Transportation*, 170–179. https://doi.org/10.1145/3408308.3427604

Vázquez-Canteli, J. R., Kämpf, J., Henze, G., & Nagy, Z. (2019). CityLearn v1.0: An OpenAI gym environment for demand response with deep reinforcement learning. *BuildSys 2019 - Proceedings of the 6th ACM International Conference on Systems for Energy-Efficient Buildings, Cities, and Transportation*, 356–357. https://doi.org/10.1145/3360322.3360998

Vázquez-Canteli, J. R., & Nagy, Z. (2019a). Reinforcement learning for demand response: A review of algorithms and modeling techniques. *Applied Energy*, *235*, 1072–1089. https://doi.org/10.1016/J.APENERGY.2018.11.002

Vázquez-Canteli, J. R., & Nagy, Z. (2019b). Reinforcement learning for demand response: A review of algorithms and modeling techniques. *Applied Energy*, *235*, 1072–1089. https://doi.org/10.1016/j.apenergy.2018.11.002

Wang, R. (2024a). *REAL-TIME REGULATION FOR POWER SYSTEM OPERATIONAL SECURITY ENHANCEMENT USING DEEP REINFORCEMENT LEARNING*.

Wang, R. (2024b). *REAL-TIME REGULATION FOR POWER SYSTEM OPERATIONAL SECURITY ENHANCEMENT USING DEEP REINFORCEMENT LEARNING*.

Wang, Z., Zhang, Y., Yin, C., & Huang, Z. (2021). Multi-agent Deep Reinforcement Learning based on Maximum Entropy. *IMCEC 2021 - IEEE 4th Advanced Information Management, Communicates, Electronic and Automation Control Conference*, 1402–1406. https://doi.org/10.1109/IMCEC51613.2021.9482235

Wilk, P., Wang, N., & Li, J. (2024a). Multi-Agent Reinforcement Learning for Smart Community Energy Management. *Energies 2024, Vol. 17, Page 5211*, *17*(20), 5211. https://doi.org/10.3390/EN17205211

Wilk, P., Wang, N., & Li, J. (2024b). Multi-Agent Reinforcement Learning for Smart Community Energy Management. *Energies 2024, Vol. 17, Page 5211*, *17*(20), 5211. https://doi.org/10.3390/EN17205211

Wu, Y., Chiu, W. Y., Tsai, Y. P., Liu, S., & Hua, W. (2026a). Multiagent reinforcement learning in enhancing resilience of microgrids under extreme weather events. *Expert Systems with Applications*, *296*, 129145. https://doi.org/10.1016/J.ESWA.2025.129145

Wu, Y., Chiu, W. Y., Tsai, Y. P., Liu, S., & Hua, W. (2026b). Multiagent reinforcement learning in enhancing resilience of microgrids under extreme weather events. *Expert Systems with Applications*, *296*. https://doi.org/10.1016/j.eswa.2025.129145

Xie, J., Ajagekar, A., & You, F. (2023). Multi-Agent attention-based deep reinforcement learning for demand response in grid-responsive buildings. *Applied Energy*, *342*. https://doi.org/10.1016/j.apenergy.2023.121162

Xiong, S., Liu, D., Chen, Y., Zhang, Y., & Cai, X. (2024). A deep reinforcement learning approach based energy management strategy for home energy system considering the time-of-use price and real-time control of energy storage system. *Energy Reports*, *11*, 3501–3508. https://doi.org/10.1016/J.EGYR.2024.03.003

Ye, T., Huang, Y., Yang, W., Cai, G., Yang, Y., & Pan, F. (2025). Safe multi-agent deep reinforcement learning for decentralized low-carbon operation in active distribution networks and multi-microgrids. *Applied Energy*, *387*, 125609. https://doi.org/10.1016/J.APENERGY.2025.125609

Zhang, B., Hu, W., M.Y.M. Ghias, A., Xu, X., & Chen, Z. (2023). Multi-agent deep reinforcement learning based distributed control architecture for interconnected multi-energy microgrid energy management and optimization. *Energy Conversion and Management*, *277*. https://doi.org/10.1016/j.enconman.2022.116647

Zhong, Y., Grudzien Kuba, J., Feng, X., Hu, S., Ji, J., & Yang, Y. (2024). Heterogeneous-Agent Reinforcement Learning. In *Journal of Machine Learning Research* (Vol. 25).

ANEXO 1. RESULTADOS REALES INTEGRADOS DESDE GOOGLE DRIVE

Trazabilidad. Esta sección fue incorporada desde los artefactos descargados de la carpeta Drive indicada por el usuario: *outputs/madrl_v3_20260627_164047.* Las gráficas y tablas provienen de timeseries.csv, trace.csv, building_kpis.csv, building_behavior_summary.csv y checkpoint_manifest.json. No se imputaron ni sintetizaron valores faltantes.

Cobertura. HAPPO, MAAC, MASAC y MATD3 tienen timeseries.csv y trace.csv reales para E1, E2 y E3. MAAC, MASAC y MATD3 tienen además KPIs por edificio y manifiestos de checkpoints completos. HAPPO se incluye en distrito/trazas, pero se excluye de comparaciones por edificio y checkpoint porque Drive no contiene building_kpis.csv, building_behavior_summary.csv ni checkpoint_manifest.json para HAPPO.

A1.1. Resultados distritales por algoritmo y escenario

Tabla A.1

Resumen distrital real por algoritmo y escenario

algorithm	scenario	episodes	district_net_kwh_mean	district_cost_mean	district_emission_mean	reward_mean
HAPPO	E1	49	797.4	463.7	1046	-0.6303
HAPPO	E2	49	-15.09	195.5	883	-0.4842
HAPPO	E3	49	343.3	352.6	839.7	-0.5208
MAAC	E1	50	1292	642.6	1054	-0.6052
MAAC	E2	50	1329	707.5	1056	-0.5237
MAAC	E3	50	1324	795.4	1054	-0.5387
MASAC	E1	50	1316	664.7	1076	-0.6133
MASAC	E2	50	1318	701.8	1078	-0.5255
MASAC	E3	50	1347	812.2	1083	-0.5409
MATD3	E1	50	1253	631.5	1129	-0.633
MATD3	E2	50	1257	669.5	1132	-0.5336
MATD3	E3	50	1256	759.3	1131	-0.5504

Nota. La tabla representa la información sintetizada en la tabla correspondiente. Fuente: Elaboración propia a partir de los datos, fuentes y artefactos citados en el documento.

Interpretación distrital. En las series de distrito/traza, el mayor reward_mean corresponde a HAPPO-E2 (-0.484196); sin embargo, HAPPO es parcial para KPIs de edificio. Entre corridas completas, el mayor reward_mean corresponde a MAAC-E2 (-0.523716), el menor costo distrital medio a MATD3-E1 (631.506) y la menor emisión media a MAAC-E3 (1053.55).

Figura A.1

Evolución del reward distrital medio por episodio

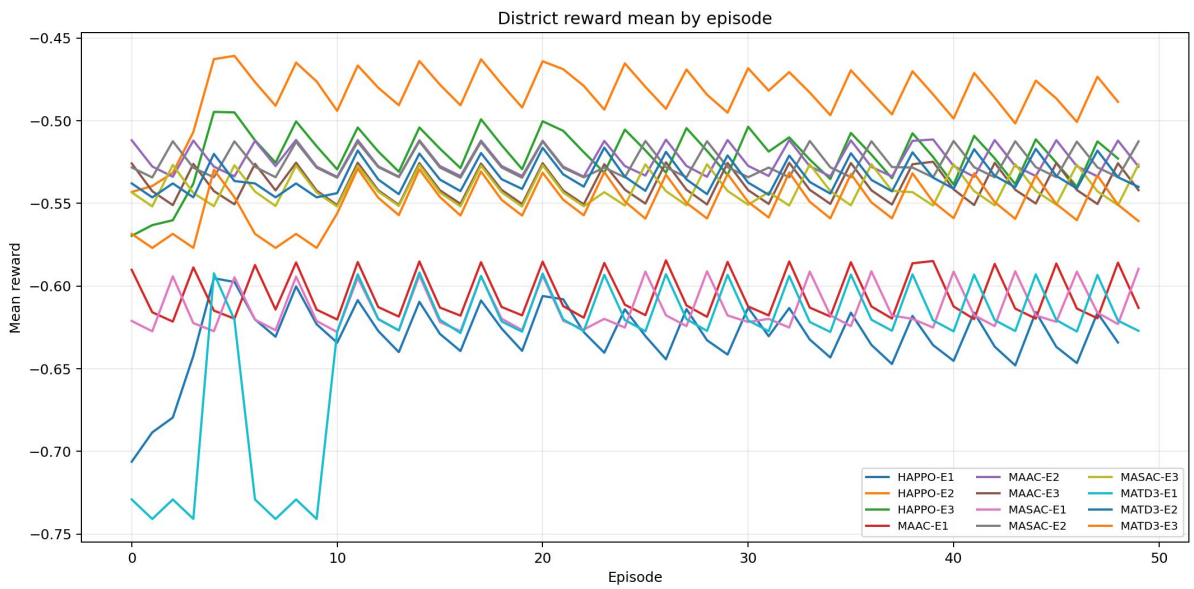

Nota. La figura representa la evolución del reward distrital medio por episodio conservado. Fuente: Elaboración propia a partir de las tablas y figuras de outputs/_drive_madrl/full_data/analysis_real_drive, timeseries.csv, building_kpis.csv, trace.csv y checkpoint_manifest.json.

La figura sintetiza reward_mean_average para 597 filas episódicas materializadas. El mayor promedio episodio-tratamiento corresponde a HAPPO-E2 con -0.484196. La lectura sirve como auditoria gráfica del comportamiento de recompensa que alimenta las curvas de convergencia del Capítulo 5.

Figura A.2

Energía neta distrital por episodio

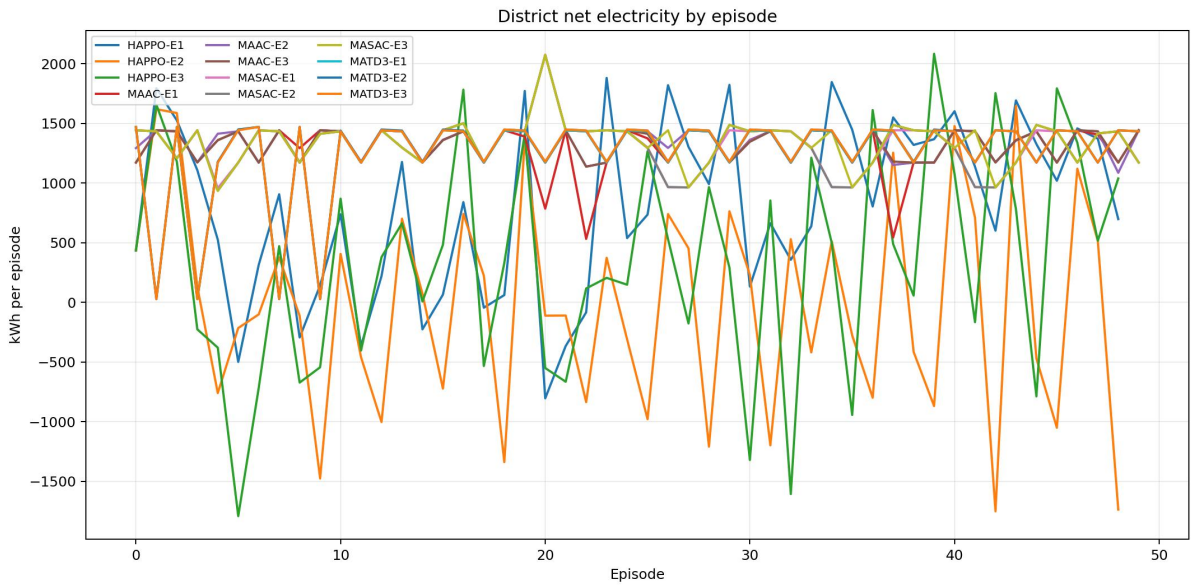

Nota. La figura representa la energía neta distrital por episodio y tratamiento. Fuente: Elaboración propia a partir de las tablas y figuras de outputs/_drive_madrl/full_data/analysis_real_drive, timeseries.csv, building_kpis.csv, trace.csv y checkpoint_manifest.json de la carpeta Drive auditada.

La figura resume energía neta distrital por episodio en 597 filas. El menor promedio observado corresponde a HAPPO-E2 con -15.09. Este resultado se interpreta como evidencia descriptiva de consumo neto, no como criterio único de flexibilidad.

Figura A.3

Costo distrital medio por algoritmo y escenario

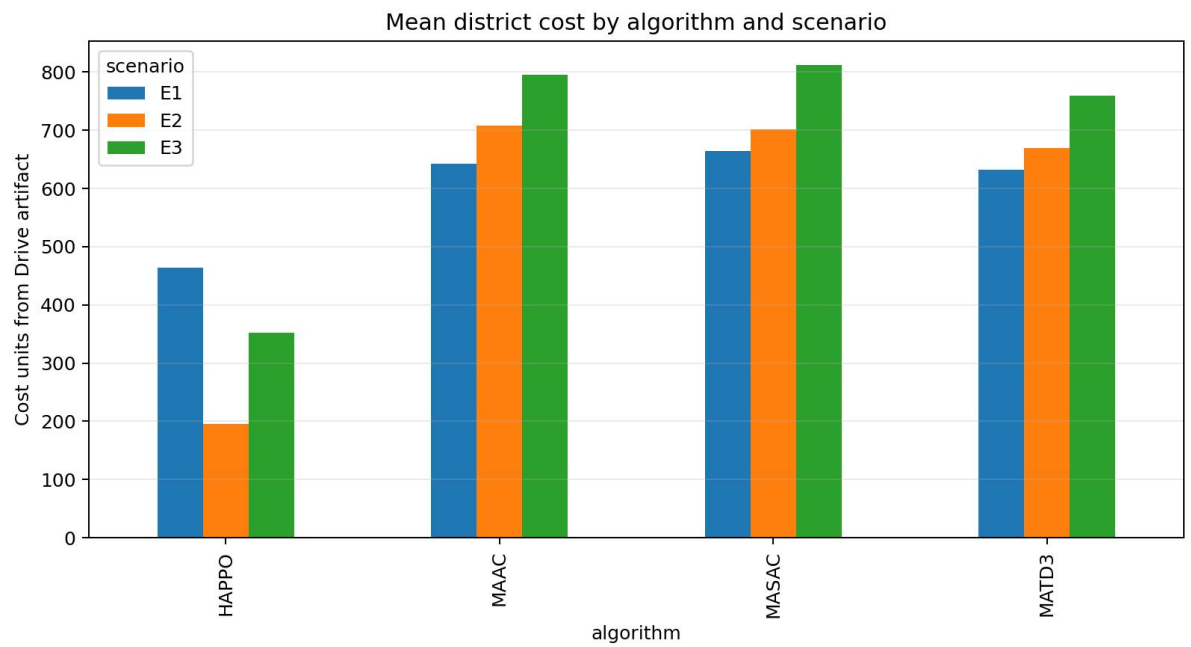

Nota. La figura representa el costo distrital medio por algoritmo y escenario. Fuente: Elaboración propia a partir de las tablas y figuras de outputs/_drive_madrl/full_data/analysis_real_drive, timeseries.csv, building_kpis.csv, trace.csv y checkpoint_manifest.json de la carpeta Drive auditada.

La figura compara costo distrital medio usando 597 filas episódicas. El menor promedio corresponde a HAPPO-E2 con 195.45. La lectura complementa OE.3 porque muestra el comportamiento por escenario antes de la síntesis inferencial.

Figura A.4

Emisiones distritales medias por algoritmo y escenario

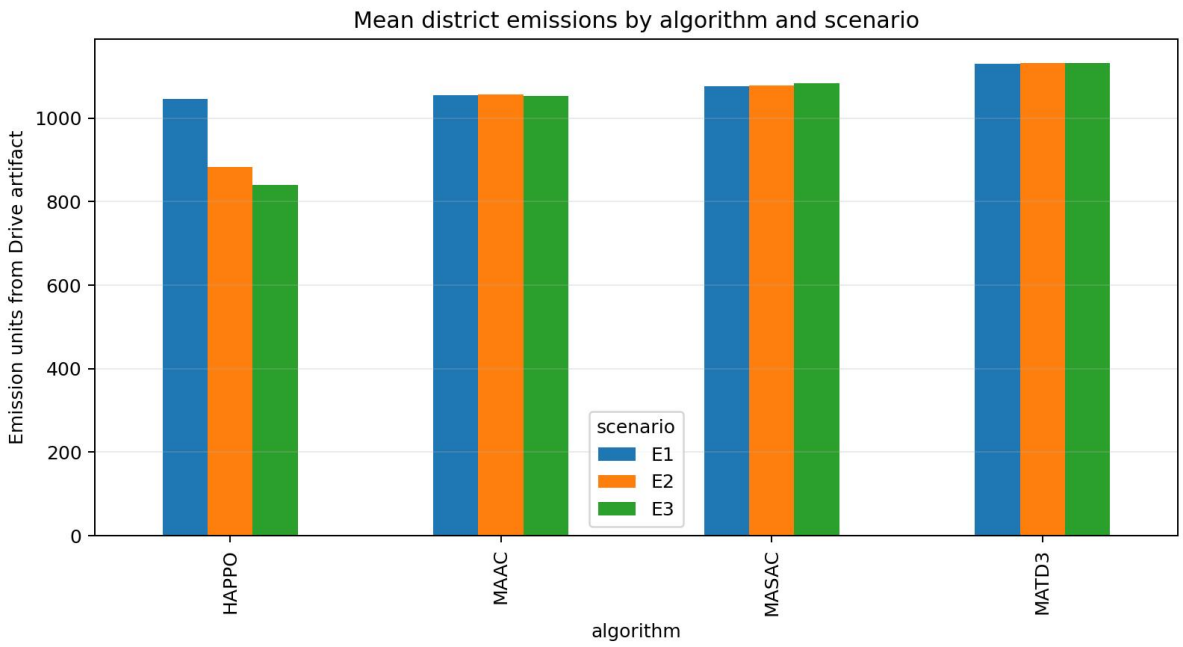

Nota. La figura representa las emisiones distritales medias por algoritmo y escenario. Fuente: Elaboración propia a partir de las tablas y figuras de outputs/_drive_madrl/full_data/analysis_real_drive, timeseries.csv, building_kpis.csv, trace.csv y checkpoint_manifest.json de la carpeta Drive auditada.

La figura compara emisiones distritales medias en 597 filas episódicas. El menor promedio corresponde a HAPPO-E3 con 839.72. La lectura complementa OE.2 y permite revisar si el escenario orientado a carbono se refleja también en la media episódica.

A1.2. Resultados por edificio

Tabla A.2

Mejores 20 filas por reducción de costo eléctrico en edificios completos

algorithm	scenario	agent	electricity_cost_delta_eur	carbon_emissions_delta_kgco2	grid_import_delta_kwh	ev_charge_total_kwh
MATD3	E1	Building_14	-3532	-2071	-2680	0

MATD3	E3	Building_12	-2672	-2163	-2795	0
MATD3	E1	Building_12	-2323	-2153	-2781	0
MASAC	E3	Building_11	-2304	7086	8960	493.9
MATD3	E2	Building_11	-2279	-1848	-2386	0
MATD3	E2	Building_12	-2054	-2163	-2795	0
MATD3	E2	Building_8	-1951	-1904	-2490	3839
MATD3	E1	Building_11	-1825	-801.1	-996.6	1455
MASAC	E1	Building_11	-1368	7845	9909	454.1
MATD3	E2	Building_3	-958.9	-1113	-1383	4230
MATD3	E2	Building_5	-950	-1416	-1793	0
MASAC	E3	Building_8	-899.2	3807	4927	1619
MAAC	E1	Building_11	-888.9	2103	2855	570.4
MASAC	E2	Building_8	-853.7	2636	3412	1460
MASAC	E3	Building_14	-845.4	1785	2300	614.3
MASAC	E2	Building_11	-717.3	7957	1.01e+04	530.1
MAAC	E2	Building_14	-701.9	1510	1954	438.6
MAAC	E3	Building_14	-683.8	1707	2212	450.8
MAAC	E3	Building_5	-610	1249	1621	207.1
MASAC	E1	Building_14	-609.4	1510	1952	522.2

Nota. Ranking por electricity_cost_delta_eur más negativo, que representa la mayor reducción de costo (delta = control − baseline), calculado desde building_behavior_summary.csv para edificios completos de MAAC, MASAC y MATD3 en E1–E3. HAPPO se excluye porque no aporta building_behavior_summary.csv en la corrida canónica. Fuente: outputs/ _drive_madrl/ full_data/ {ALGO} / {E}/ data/ building_behavior_summary.csv.

El cambio de costo eléctrico mas negativo se observa en MATD3-E1 Building_14, con electricity_cost_delta_eur=-3532.42. Esta lectura se basa en building_behavior_summary.csv, no en estimaciones externas.

Figura A.5

Delta de costo eléctrico por edificio y corrida completa

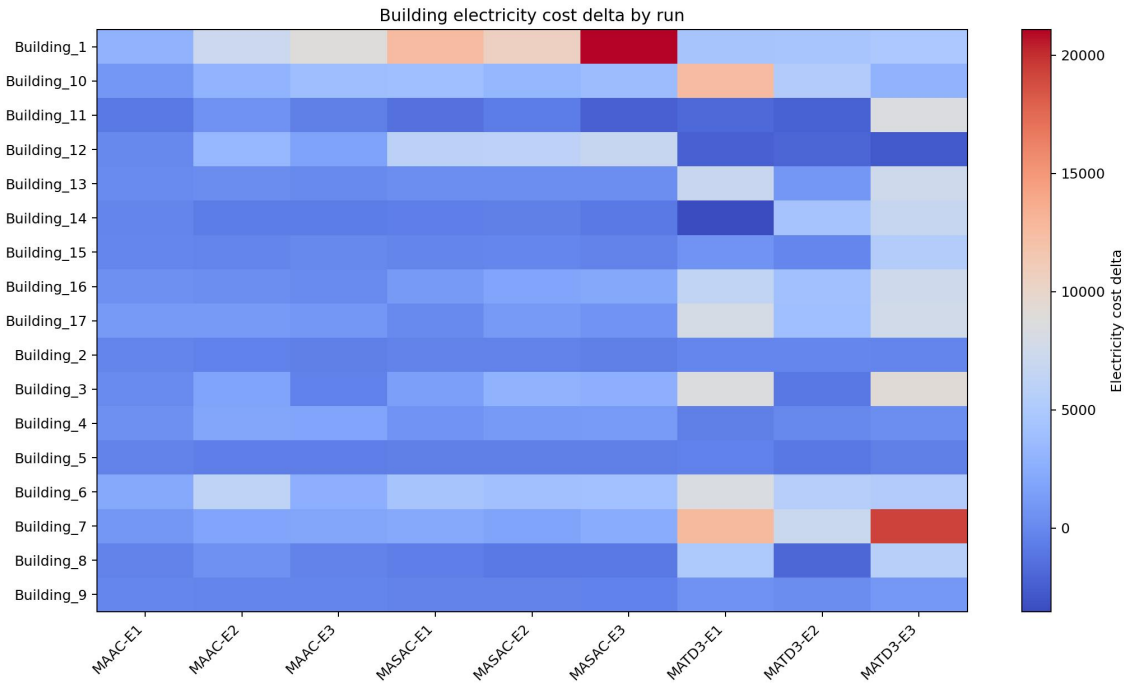

Nota. La figura representa el delta de costo eléctrico por edificio en la corrida completa. Fuente: Elaboración propia a partir de las tablas y figuras de outputs/_drive_madrl/full_data/analysis_real_drive, timeseries.csv, building_kpis.csv, trace.csv y checkpoint_manifest.json de la carpeta Drive auditada.

La figura usa 204 valores de delta de costo eléctrico por edificio. La mayor reducción observada corresponde a HAPPO-E3 en Building_11 con -193,217.96. El signo y magnitud del delta permiten distinguir reducciones reales de costo frente a variaciones marginales por edificio.

Figura A.6

Delta de emisiones por edificio y corrida completa

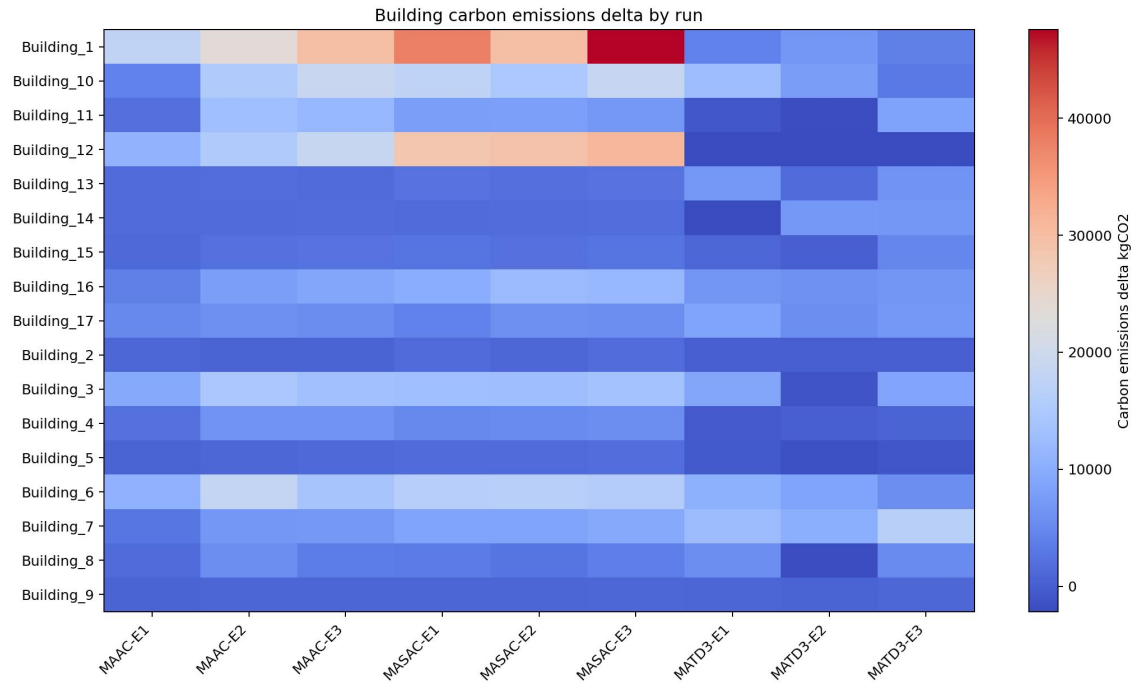

Nota. La figura representa el delta de emisiones por edificio en la corrida completa. Fuente: Elaboración propia a partir de las tablas y figuras de outputs/_drive_madrl/full_data/analysis_real_drive, timeseries.csv, building_kpis.csv, trace.csv y checkpoint_manifest.json de la carpeta Drive auditada.

La figura usa 204 valores de delta de emisiones por edificio. La mayor reducción observada corresponde a MATD3-E2 en Building_12 con -2,163.49 $kgCO_2$. La lectura muestra que el efecto ambiental no es uniforme entre edificios y depende de la demanda y equipamiento disponible.

A1.3. Equipamiento controlado y no controlado

Criterio de clasificación. El equipamiento controlado se obtiene de building_observation_action_schema.csv con variable_type = acción: batería eléctrica, cargadores EV y otras acciones controlables registradas por agente. La carga no controlada corresponde a Carga_base_medida_MWh del audit del dataset. Las cargas controladas de escenario se calculan con EV_load_total_MWh y Maquina_controlada_MWh del audit local del dataset.

Tabla A.3

Equipamiento controlado y carga base no controlada por edificio

building	action_count	controlled_bess_actions	controlled_ev_charger_actions	controlled_load_mwh
Building_1	6	1	4	154.8
Building_10	8	1	6	218.2
Building_11	5	1	3	210.7

Building_12	5	1	3	169.8
Building_13	13	1	11	176.8
Building_14	6	1	4	193.9
Building_15	10	1	8	165.4
Building_16	13	1	11	235.8
Building_17	13	1	11	223
Building_2	8	1	6	42.98
Building_3	10	1	8	286.8
Building_4	8	1	6	84.39
Building_5	5	1	3	164
Building_6	34	1	32	542.7
Building_7	44	1	42	645.7
Building_8	19	1	17	546.3
Building_9	12	1	10	82.86

Nota. La tabla representa la información sintetizada en la tabla correspondiente. Fuente: Elaboración propia a partir de los datos, fuentes y artefactos citados en el documento.

Figura A.7

Variables de acción controladas por edificio

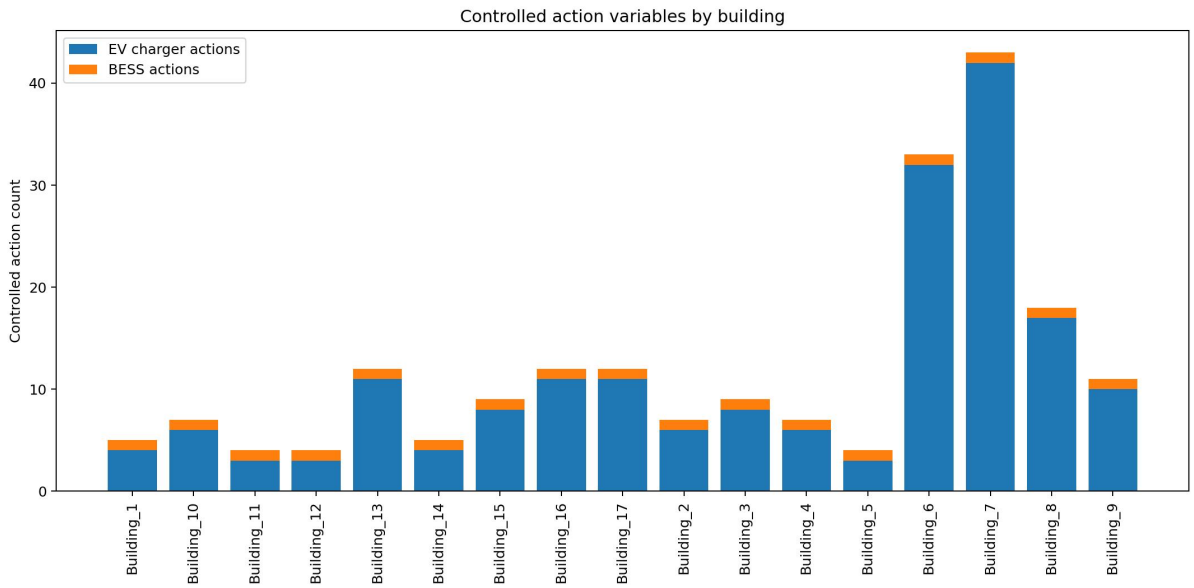

Nota. La figura representa las variables de acción controladas por edificio. Fuente: Elaboración propia a partir de las tablas y figuras de outputs/_drive_madrl/full_data/analysis_real_drive, timeseries.csv, building_kpis.csv, trace.csv y checkpoint_manifest.json de la carpeta Drive auditada.

La figura representa variables de acción controladas en 204 filas edificio-tratamiento, con suma de dimensiones de acción igual a 2628. Este anexo documenta que el control MADRL se ejerce sobre actuadores declarados en el esquema y no sobre toda la demanda del edificio.

Figura A.8

Carga controlada de escenario frente a carga base no controlada

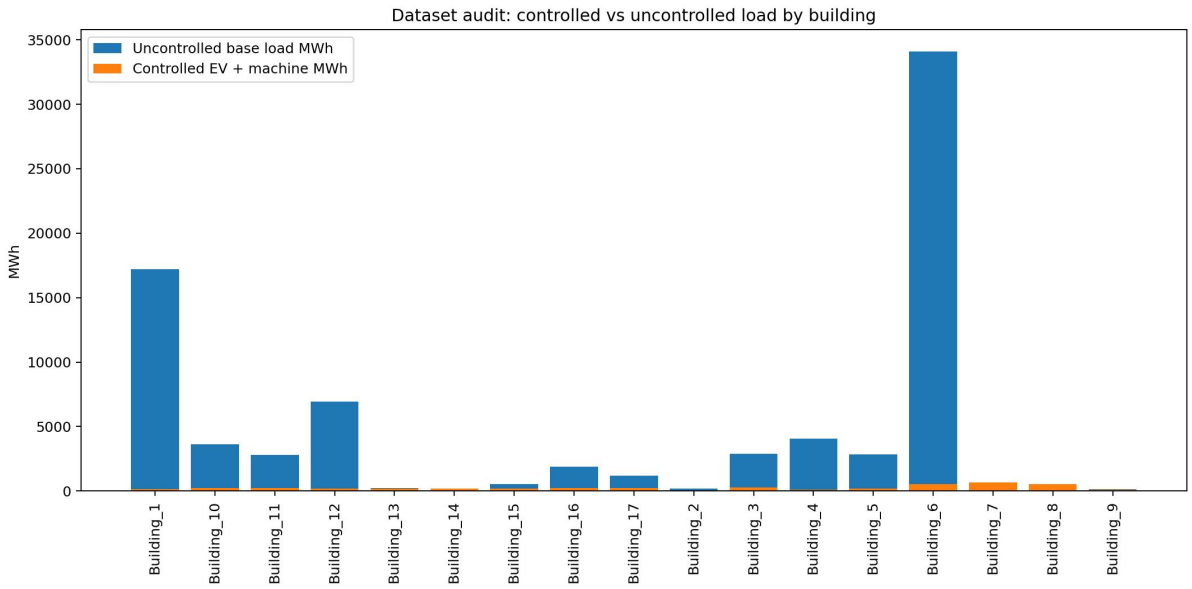

Nota. La figura representa la carga controlada de escenario frente a carga base no controlada. Fuente: Elaboración propia a partir de las tablas y figuras de outputs/_drive_madrl/full_data/analysis_real_drive, timeseries.csv, building_kpis.csv, trace.csv y checkpoint_manifest.json de la carpeta Drive auditada.

La figura contrasta carga controlada y carga base no controlada para 17 edificios y 12 tratamientos. La interpretación separa las variables que el agente puede accionar de aquellas que solo observa como demanda exógena, criterio indispensable para no sobrestimar la capacidad de control del MADRL.

Lectura. MATD3 registra 17 políticas con checkpoints por escenario; MAAC registra 50 episodios más archivos auxiliares hasta totalizar 52; MASAC registra cuatro grupos y 12 archivos por escenario. HAPPO no se incluye en esta tabla porque la corrida canónica no contiene checkpoint_manifest.json ni archivos .pt para ese backend.

Figura A.9

Tamaño total listado en manifiestos de checkpoint por algoritmo y

escenario

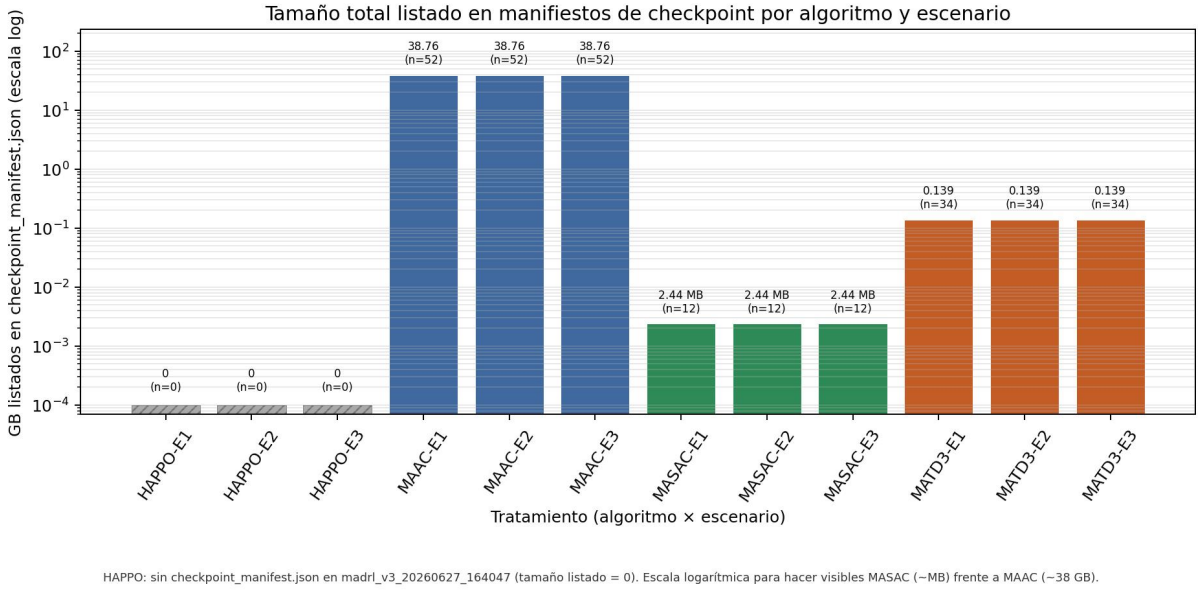

Nota. La figura representa el tamaño total listado en checkpoint_manifest.json por algoritmo y escenario. Fuente: elaboración propia a partir de outputs/_drive_madrl/full_data/{ALGO}/{E}/data/ checkpoint_manifest.json de la corrida canónica madrl_v3_20260627_164047.

Se listan 294 archivos con un tamaño total de 116,72 GB (119 519,93 MB). HAPPO aparece con 0 GB porque no existe checkpoint_manifest.json en la corrida canónica. MAAC concentra aproximadamente 38,76 GB por escenario; MATD3 cerca de 142,8 MB y MASAC 2,44 MB por escenario, por lo que se utiliza escala logarítmica. El archivo individual de mayor tamaño corresponde a MAAC-E1 con 763,36 MB. Los valores provienen únicamente del campo bytes de los manifiestos.

ANEXO 2. DIAGRAMAS DE FLUJO Y ARQUITECTURA DEL PROYECTO

Trazabilidad. Los nueve diagramas fueron renderizados desde los bloques Mermaid de docs/architecture/ARQUITECTURA_PROYECTO_DEFENSA.md. Se integran como evidencia visual de flujo del proyecto, arquitectura Dec-POMDP/CTDE, entrenamiento, evaluación, despliegue y capas de software.

A1.4. Diagrama 1 — Visión General del Proyecto (inicio a fin)

Figura B.1

Diagrama 1 — Visión General del Proyecto (inicio a fin)

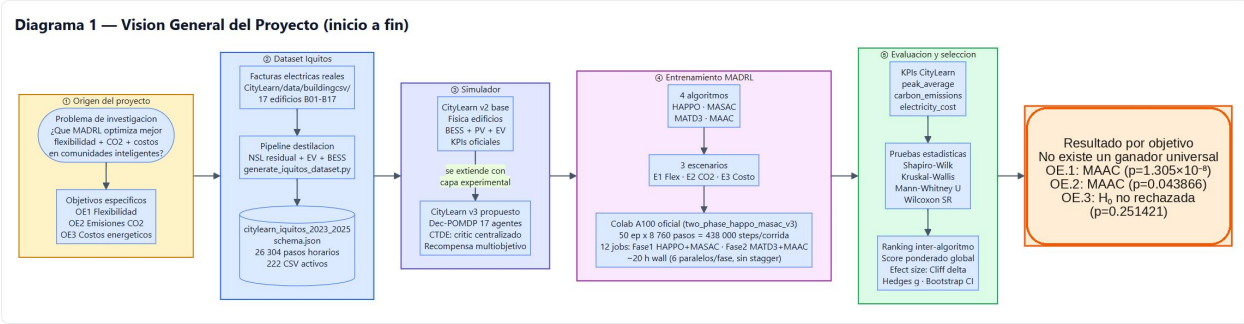

Nota. La figura representa el flujo, arquitectura o componente metodológico del sistema académico MADRL-CityLearn. Fuente: Elaboración propia a partir de la arquitectura del repositorio local, los scripts de construcción del datase, la formalización Dec-POMDP/CTDE y la configuración experimental MADRL; se fundamenta en Oliehoek y Amato (2016), Lowe et al. (2017), Iqbal y Sha (2019), Vázquez-Canteli et al. (2020) y Nweye et al. (2024).

El diagrama integra el flujo completo del proyecto: construcción del datase, entorno CityLearn, entrenamiento MADRL, evaluación, visualización y redacción académica. La evidencia utilizada comprende 12 tratamientos, 597 filas episódicas, 204 filas edificio-tratamiento y 294 archivos listados en manifiestos de checkpoint. No existe un ganador universal: la decisión depende del objetivo, de la cobertura inferencial y del KPI anual final.

A1.1. Diagrama 2 — Pipeline del Dataset Iquitos 2023-2025

Figura B.2

Diagrama 2 — Pipeline del Dataset Iquitos 2023-2025

Diagrama 2 — Pipeline del Dataset Iquitos 2023-2025

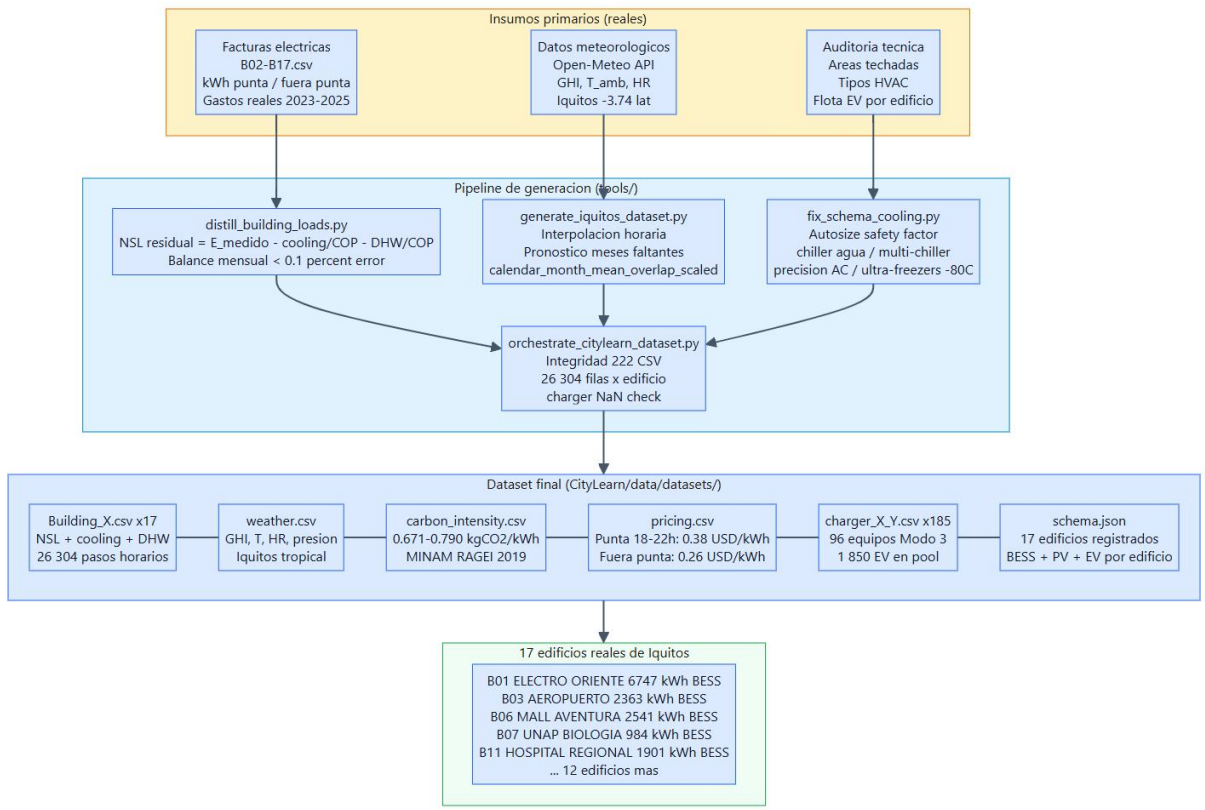

Nota. La figura representa el flujo, arquitectura o componente metodológico del sistema académico MADRL-CityLearn. Fuente: Elaboración propia a partir de la arquitectura del repositorio local, los scripts de construcción del datase, la formalización Dec-POMDP/CTDE y la configuración experimental MADRL; se fundamenta en Oliehoek y Amato (2016), Lowe et al. (2017), Iqbal y Sha (2019), Vázquez-Canteli et al. (2020) y Nweye et al. (2024).

El diagrama muestra el pipeline del dataset Iquitos 2023-2025 y su transformación hacia el formato CityLearn. La interpretación se basa en 17 edificios/agentes y en la separación entre datos climáticos, demanda, precios, carbono y esquemas de observación-acción.

A1.2. Diagrama 3 — Arquitectura Dec-POMDP y CTDE de los 17 Agentes

Figura B.3

Diagrama 3 — Arquitectura Dec-POMDP y CTDE de los 17 Agentes

Diagrama 3 — Arquitectura Dec-POMDP y CTDE de los 17 Agentes

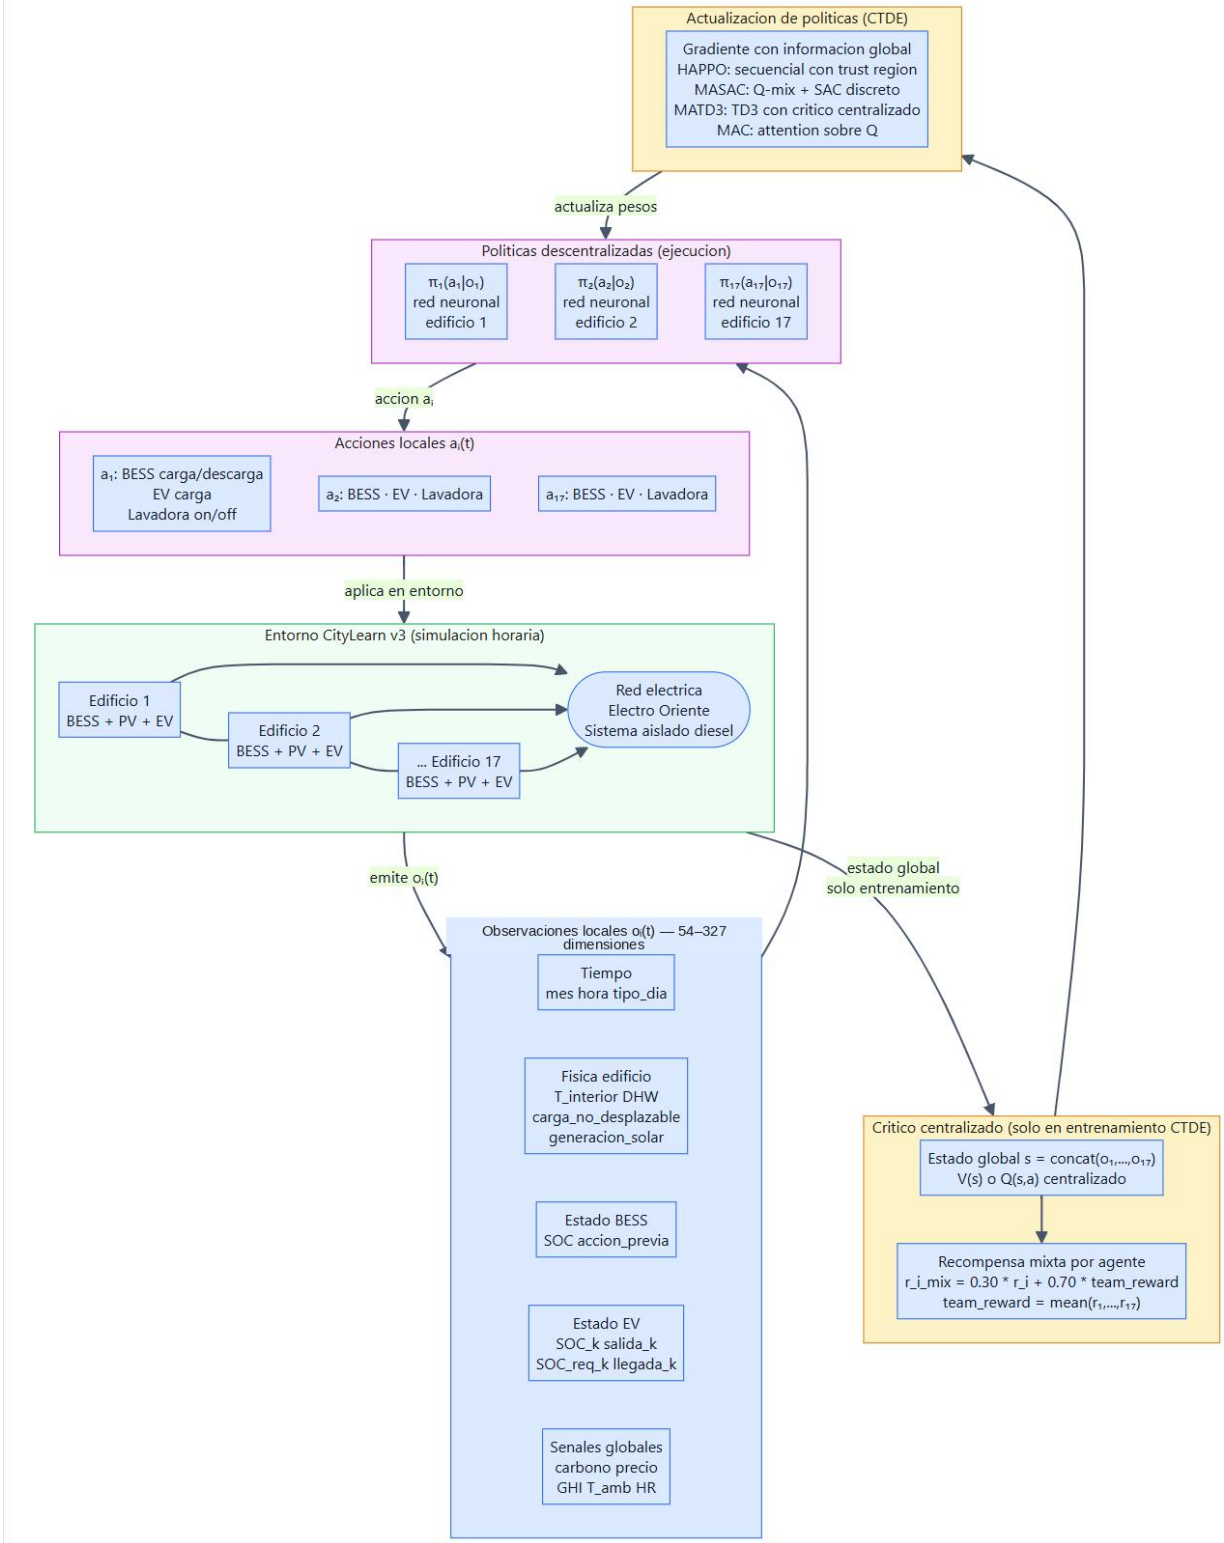

Nota. La figura representa el flujo, arquitectura o componente metodológico del sistema académico MADRL-CityLearn. Fuente: Elaboración propia a partir de la arquitectura del repositorio local, los scripts de construcción del datase, la formalización Dec-POMDP/CTDE y la configuración experimental MADRL; se fundamenta en Oliehoek y Amato (2016), Lowe et al. (2017), Iqbal y Sha (2019), Vázquez-Canteli et al. (2020) y Nweye et al. (2024).

. El diagrama formaliza el problema como Dec-POMDP con ejecución descentralizada y entrenamiento centralizado. La comunidad opera con 17 agentes, observaciones locales heterogéneas de 54 a 327 dimensiones, dimensión global agregada de 1 856 y acciones locales de 5 a 44 por edificio.

A1.3. Diagrama 4 — Los 4 Algoritmos MADRL: Taxonomia y Diferencias

Figura B.4

Diagrama 4 — Los 4 Algoritmos MADRL: Taxonomia y Diferencias

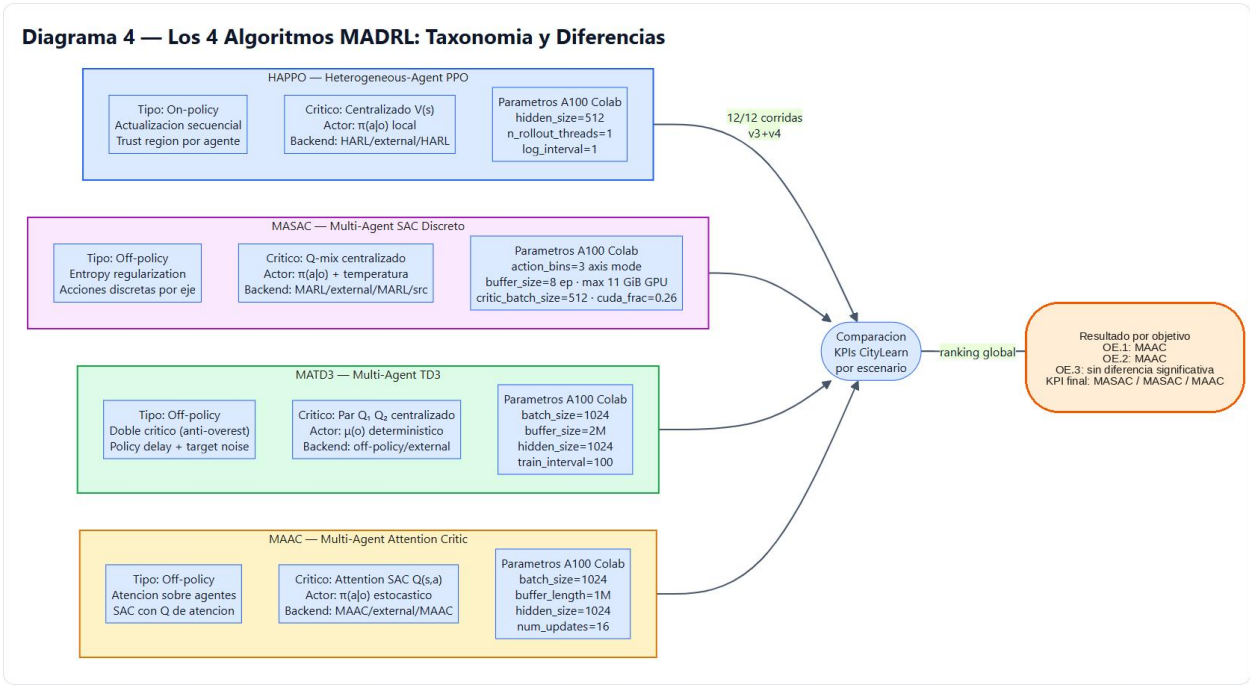

Nota. La figura representa el flujo, arquitectura o componente metodológico del sistema académico MADRL-CityLearn. Fuente: Elaboración propia a partir de la arquitectura del repositorio local, los scripts de construcción del datase, la formalización Dec-POMDP/CTDE y la configuración experimental MADRL; se fundamenta en Oliehoek y Amato (2016), Lowe et al. (2017), Iqbal y Sha (2019), Vázquez-Canteli et al. (2020) y Nweye et al. (2024).

. El diagrama compara HAPPO, MAAC, MASAC y MATD3 como familias algorítmicas diferentes. La corrida comprende 12 tratamientos. MAAC lidera la muestra inferencial completa en OE.1 y OE.2; en OE.3 no se detectan diferencias significativas. Los KPI anuales finales favorecen a MASAC en OE.1 y OE.2 y a MAAC en OE.3, por lo que no se declara un ganador universal.

A1.4. Diagrama 5 — Flujo de Entrenamiento: 12 Corridas (two_phase_happo_masac_v3)

Figura B.5

Diagrama 5 — Flujo de Entrenamiento: 12 Corridas (two_phase_happo_masac_v3)

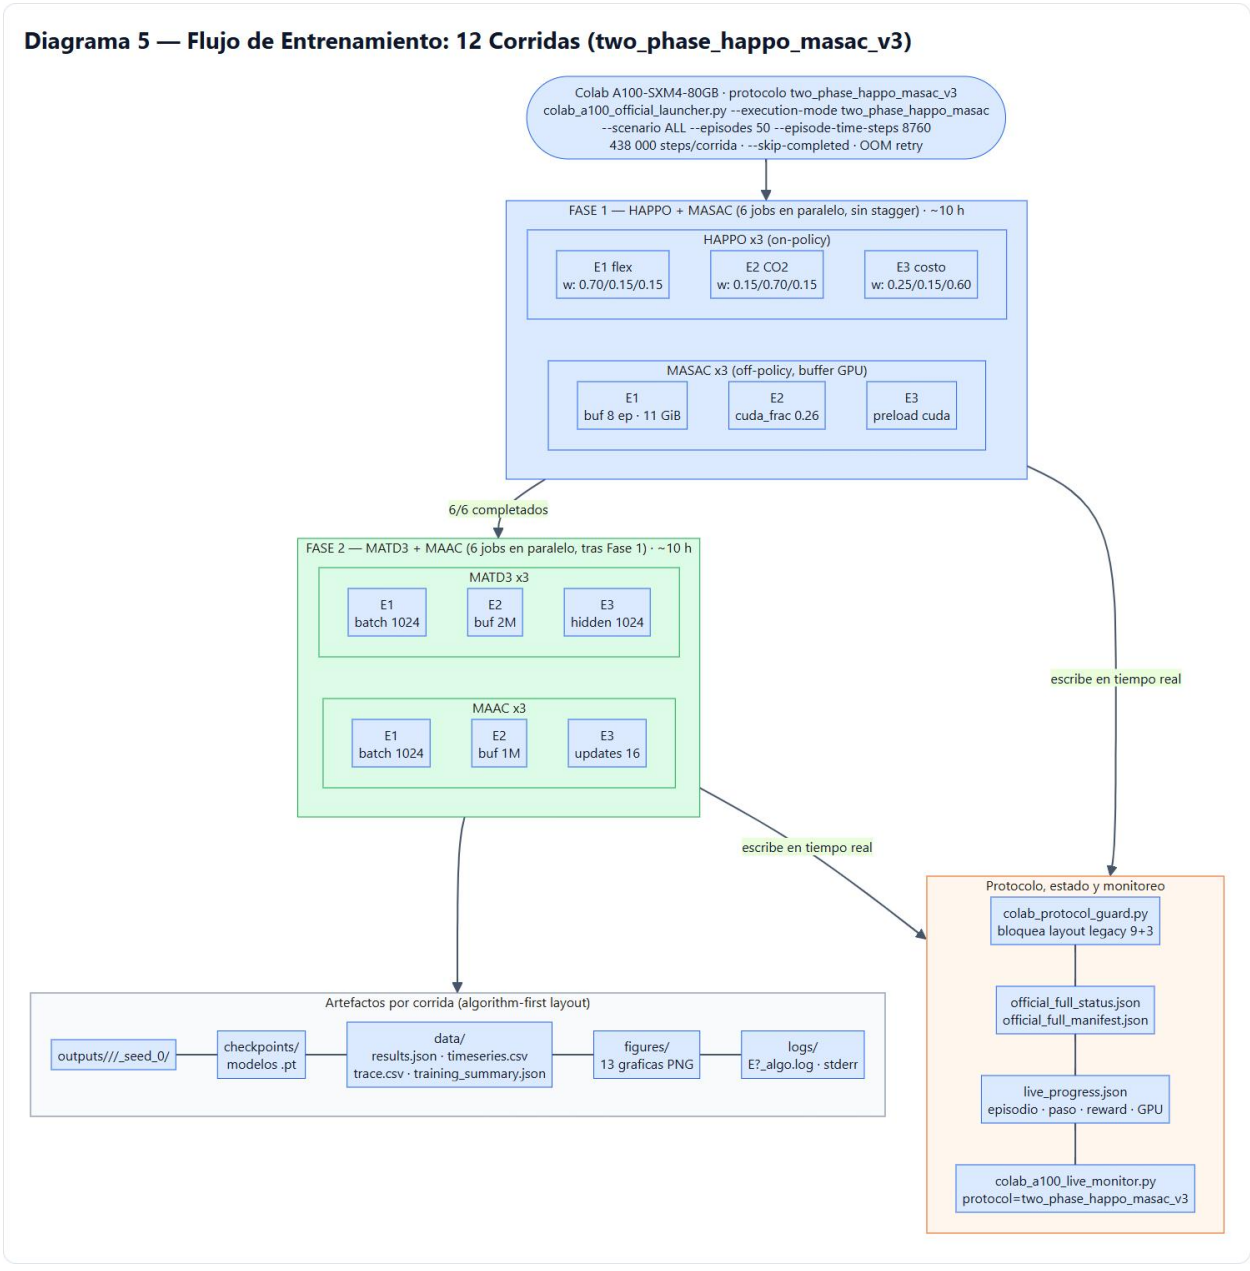

Nota. La figura representa el flujo, arquitectura o componente metodológico del sistema académico MADRL-CityLearn. Fuente: Elaboración propia a partir de la arquitectura del repositorio local, los scripts de construcción del datase, la formalización Dec-POMDP/CTDE y la configuración experimental MADRL; se fundamenta en Oliehoek y Amato (2016), Lowe et al. (2017), Iqbal y Sha (2019), Vázquez-Canteli et al. (2020) y Nweye et al. (2024).

. El diagrama resume el flujo de entrenamiento de las 12 corridas. La evidencia final conserva 597 filas episódicas materializadas, 105 051 filas de series finales, 15 504 registros de trace.csv y 294 archivos listados en manifiestos de checkpoint.

A1.5. Diagrama 6 — Recompensa Multiobjetivo por Escenario

Figura B.6

Diagrama 6 — Recompensa Multiobjetivo por Escenario

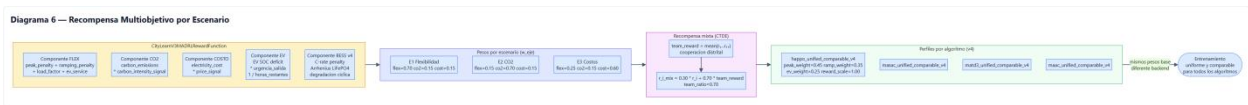

Nota. La figura representa el flujo, arquitectura o componente metodológico del sistema académico MADRL-CityLearn. Fuente: Elaboración propia a partir de la arquitectura del repositorio local, los scripts de construcción del datase, la formalización Dec-POMDP/CTDE y la configuración experimental MADRL; se fundamenta en Oliehoek y Amato (2016), Lowe et al. (2017), Iqbal y Sha (2019), Vázquez-Canteli et al. (2020) y Nweye et al. (2024).

. El diagrama muestra la recompensa multiobjetivo por escenario: E1 prioriza flexibilidad, E2 prioriza CO_2 y E3 prioriza costos. Esta estructura vincula directamente las preguntas PE.1, PE.2 y PE.3 con los objetivos OE.1, OE.2 y OE.3.

A1.6. Diagrama 7 — Pipeline de evaluación y selección por objetivo

Figura B.7

Diagrama 7 — Pipeline de evaluación y selección por objetivo

Diagrama 7 — Pipeline de Evaluación y selección por objetivo

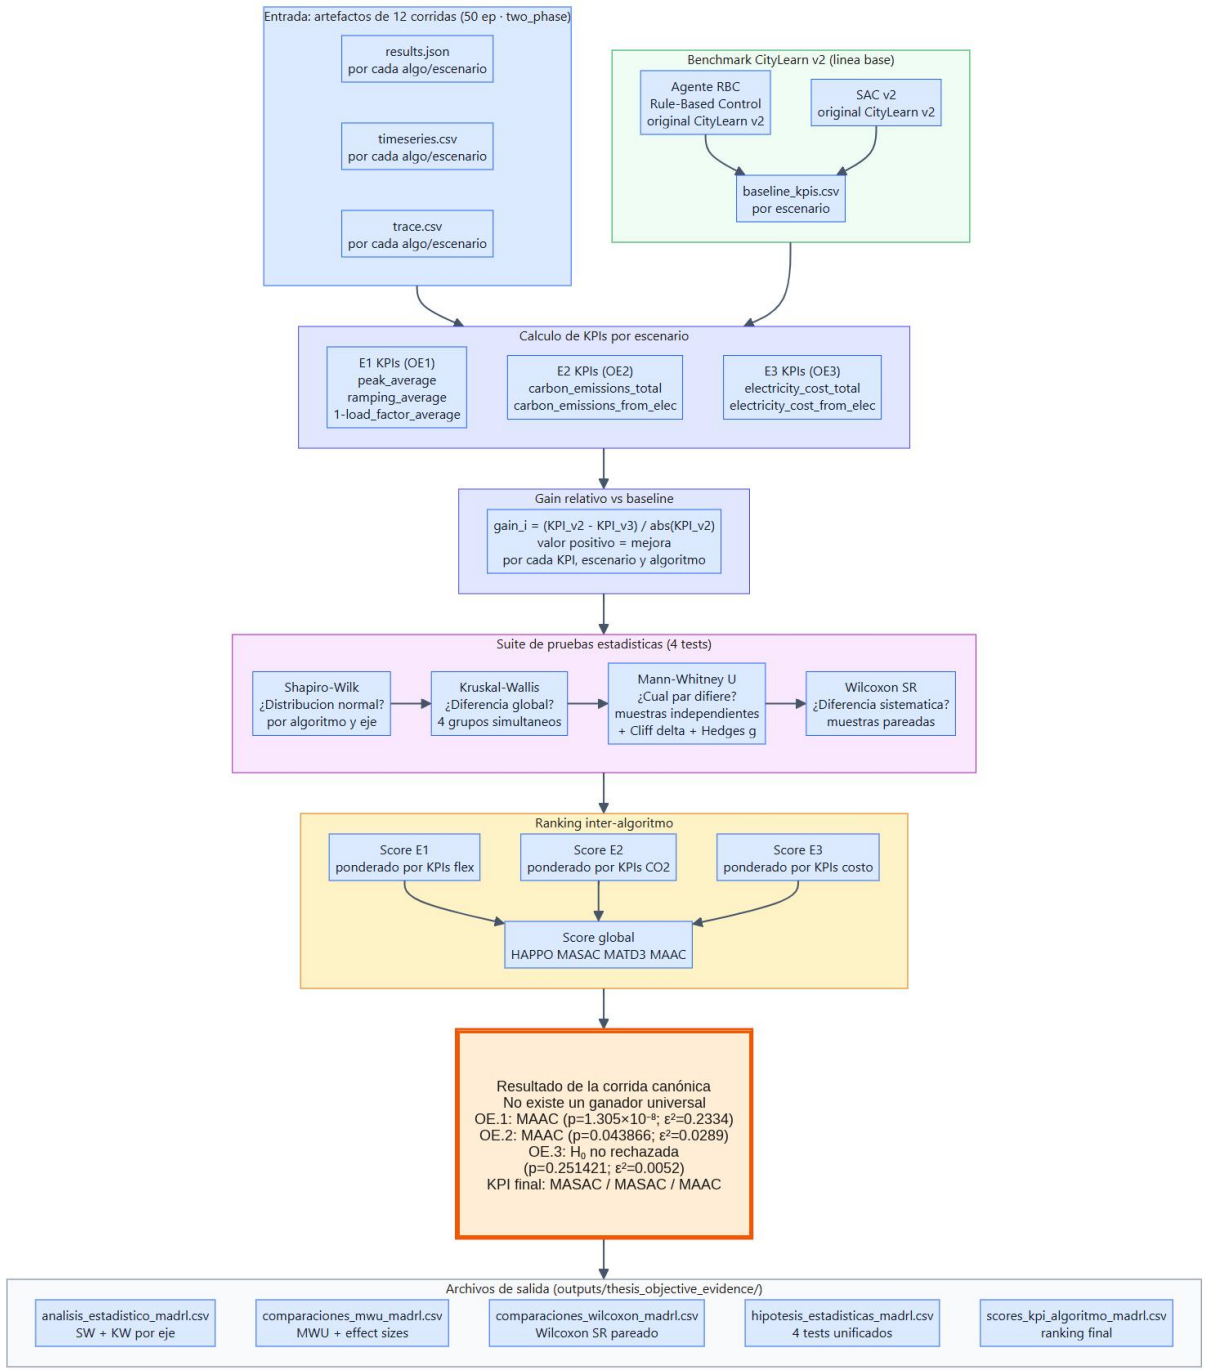

Nota. La figura representa el flujo, arquitectura o componente metodológico del sistema académico MADRL-CityLearn. Fuente: Elaboración propia a partir de la arquitectura del repositorio local, los scripts de construcción del datase, la formalización Dec-POMDP/CTDE y la configuración experimental MADRL; se fundamenta en Oliehoek y Amato (2016), Lowe et al. (2017), Iqbal y Sha (2019), Vázquez-Canteli et al. (2020) y Nweye et al. (2024).

. El diagrama representa el pipeline de evaluación y selección por objetivo. La decisión integra estadística descriptiva, Kruskal–Wallis, Mann–Whitney U con ajuste Holm, tamaños de efecto, KPIs CityLearn v2, series finales y resultados por edificio. La evidencia no identifica un ganador universal: MAAC lidera la muestra inferencial completa en OE.1 y OE.2, mientras OE.3 no presenta diferencia significativa.

A1.7. Diagrama 8 — Infraestructura de Despliegue: Local, Colab A100 y AWS EC2

Figura B.8

Diagrama 8 — Infraestructura de Despliegue: Local, Colab A100 y AWS EC2

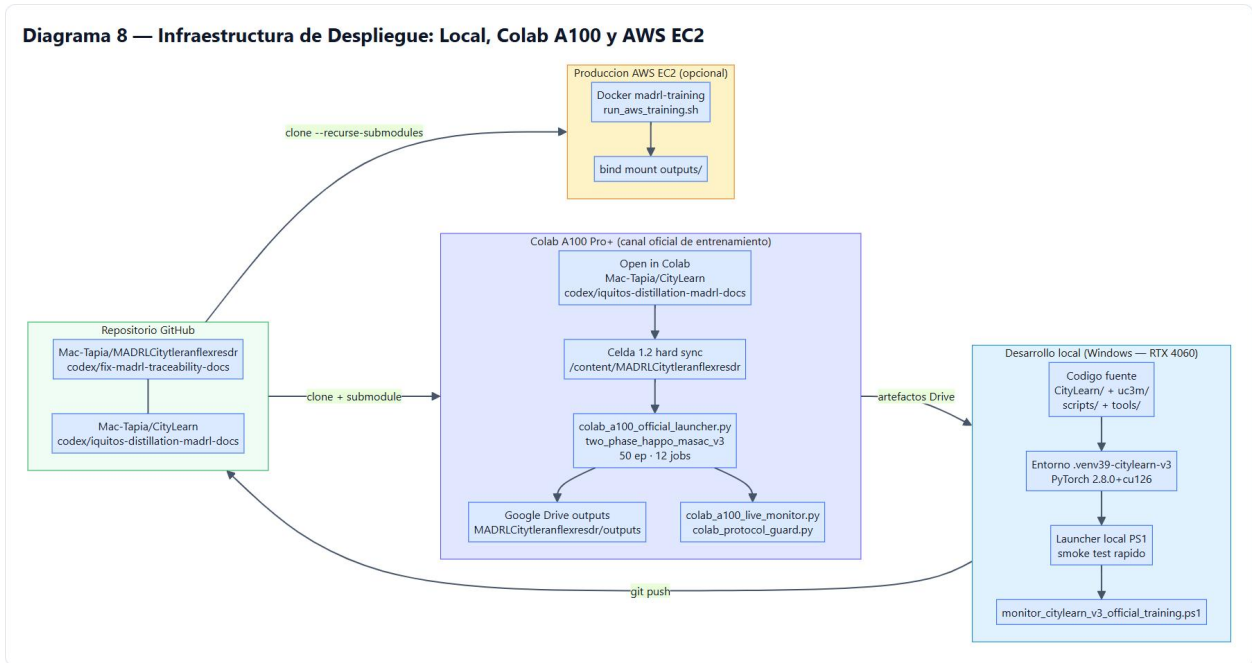

Nota. La figura representa el flujo, arquitectura o componente metodológico del sistema académico MADRL-CityLearn. Fuente: Elaboración propia a partir de la arquitectura del repositorio local, los scripts de construcción del datase, la formalización Dec-POMDP/CTDE y la configuración experimental MADRL; se fundamenta en Oliehoek y Amato (2016), Lowe et al. (2017), Iqbal y Sha (2019), Vázquez-Canteli et al. (2020) y Nweye et al. (2024).

. El diagrama ubica la infraestructura de ejecución local, Colab A100 y AWS EC2 como soporte computacional del entrenamiento. Su función es explicar trazabilidad operacional y no introducir resultados externos a la carpeta Drive auditada.

A1.8. Diagrama 9 — Estructura de Capas del Software

Figura B.9

Diagrama 9 — Estructura de Capas del Software

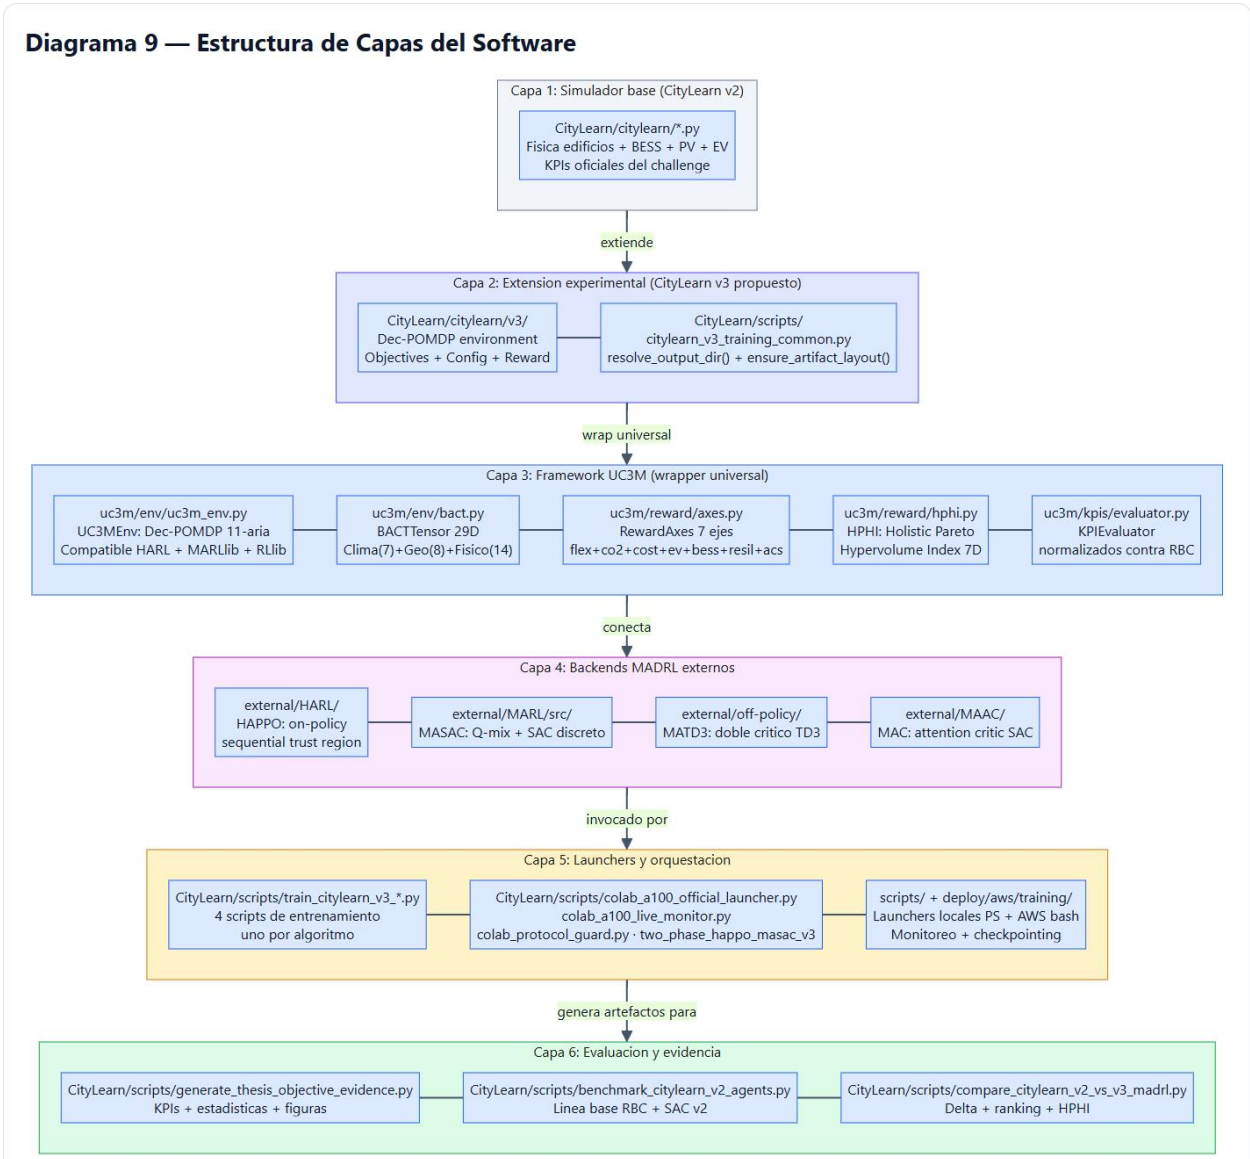

Nota. La figura representa el flujo, arquitectura o componente metodológico del sistema académico MADRL-CityLearn. Fuente: Elaboración propia a partir de la arquitectura del repositorio local, los scripts de construcción del datase, la formalización Dec-POMDP/CTDE y la configuración experimental MADRL; se fundamenta en Oliehoek y Amato (2016), Lowe et al. (2017), Iqbal y Sha (2019), Vázquez-Canteli et al. (2020) y Nweye et al. (2024).

. El diagrama sintetiza siete capas de software: datos, entorno, agentes MADRL, entrenamiento, evaluación, figuras y documento Word. La salida académica se reconstruye desde scripts locales y artefactos reales, incluyendo 12 tratamientos, 597 filas episódicas y 294 archivos listados en manifiestos de checkpoint, lo que reduce el riesgo de transcripción manual.