

Cooperación, Coordinación y Control Distrital MADRL

Fecha: 2026-06-12 Proyecto: MADRLCitytleranflexresdr Sección tesis: Capítulo III §3.2.4, §3.2.5, §3.3.2, §3.3.3

1. KPIs por Escenario de Entrenamiento

Cada escenario evalúa **todos los KPIs** del entorno CityLearn al final del episodio, aunque el entrenamiento priorice uno. Los KPIs son computados a nivel **distrital** (suma o promedio sobre los 17 edificios y 8 760 pasos del episodio), no por edificio individual. Los nombres exactos de los KPIs corresponden a los definidos en la API oficial de CityLearn v2 (Nweye et al., 2024) y empleados como estándar de benchmarking en el CityLearn Challenge (Nweye et al., 2023).

Escenario	OE	w_eje	KPI primario de evaluación	KPIs secundarios evaluados
E1	OE.1 Flexibilidad	0.70	peak_average · ramping_average · 1-load_factor_average	carbon_emissions_total · electricity_cost_total
E2	OE.2 Emisiones CO ₂	0.70	carbon_emissions_total · carbon_emissions_from_electrical_consumption	peak_average · electricity_cost_total
E3	OE.3 Costos	0.60	electricity_cost_total · electricity_cost_from_electrical_consumption	peak_average · carbon_emissions_total

Distinción crítica: los KPIs de evaluación son los del entorno CityLearn (computados independientemente de la función de recompensa), no las componentes del reward. Esta separación garantiza comparabilidad entre escenarios aunque los pesos de entrenamiento sean distintos (Vázquez-Canteli et al., 2020; Nweye et al., 2024).

KPI de recompensa (seguimiento de entrenamiento, no de evaluación)

Extraídos de `live_progress.json` y `trace.csv` durante el entrenamiento:

reward_mean	← retorno promedio del episodio
flex_component_mean	← componente flex de la recompensa
co2_component_mean	← componente carbono
cost_component_mean	← componente costo
ev_component_mean	← componente EV
team_reward_mean	← promedio distrital de recompensas

Estos se usan para seguimiento de convergencia, no para el ranking inter-algoritmo final.

2. Qué ES el MADRL — Definición Operativa

Edificio (agente) ≠ MADRL

Edificio → quién decide (la entidad que actúa)

MADRL → cómo aprendió a decidir, y cómo los 17 aprenden coordinadamente

El **edificio es el agente**: tiene una red neuronal π_i que mapea su observación local a su acción local. En ejecución, solo corre esa política — MADRL ya no "corre". Esta propiedad corresponde al paradigma de Proceso de Decisión de Markov Parcialmente Observable Descentralizado (Dec-POMDP), donde la ejecución es descentralizada aunque el entrenamiento puede ser centralizado (Oliehoek & Amato, 2016).

El **MADRL es el framework algorítmico** que entrena las 17 políticas simultáneamente con mecanismos de coordinación bajo el paradigma CTDE — Centralized Training with Decentralized Execution (Lowe et al., 2017). Cuando el entrenamiento termina, MADRL produjo 17 redes neuronales calibradas para trabajar juntas.

Qué tiene cada edificio-agente

Observación local $o_i(t)$:
[mes, hora, tipo_día, T_interior, demanda_enfriamiento, DHW,
carga_no_desplazable, generación_solar,
BESS_SOC, P_BESS_acción,
EV_estado_k, EV_salida_k, EV_SOC_requerido_k, EV_llegada_estimada_k,
intensidad_carbono, precio_electricidad,
GHI, T_ambiente, HR]
→ dimensiones: 54-327 por edificio según cantidad de cargadores EV

Acción local $a_i(t)$:
[P_BESS ∈ [-P_max, +P_max] kW,
P_EV_cargador_k ∈ [0, P_nominal_k] kW por toma,
acción_lavadora ∈ {operar, diferir}]
→ dimensiones: 2-44 por edificio

Red neuronal π_i : $o_i \rightarrow a_i$ (MLP o RNN según el backend)

Qué añade MADRL sobre 17 DRL independientes

Problema sin MADRL	Solución MADRL
Todos los edificios descargan BESS al mismo tiempo (misma señal de precio) → pico de exportación	Crítico centralizado aprende que la acción individual es mala cuando el distrito está en ese estado
Agente que mejora localmente puede perjudicar al distrito	$mixed_reward_i = 0.30 \cdot reward_i + 0.70 \cdot team_reward$ — 70% del gradiente es señal distrital
Sin garantía de que mejoras individuales sean compatibles	HAPPO: actualización secuencial garantiza mejora monótona de la política conjunta (Kuba et al., 2021)

Problema sin MADRL	Solución MADRL
Sin ponderación de influencia entre agentes	MAAC: atención aprende cuánto influye cada edificio en el valor distrital (Iqbal & Sha, 2019)

3. Cooperación, Coordinación y Comunicación — Dónde Ocurre Cada Cosa

3.1 Durante entrenamiento — aquí está TODA la cooperación real

Mecanismo	Qué hace	Algoritmo
Crítico centralizado $Q(s, a_1, \dots, a_{17})$ o $V(s)$	Ve estado global $s = [o_1, \dots, o_{17}]$ — evalúa si la acción conjunta es buena para el distrito (Lowe et al., 2017)	HAPPO, MATD3, MAAC
QMIX mixing network	Combina Q-values individuales en Q global con propiedad IGM: $\text{argmax } Q_{\text{total}} = (\text{argmax } Q_1, \dots, \text{argmax } Q_{17})$ — la acción distrital óptima coincide con cada agente maximizando su propio Q (Rashid et al., 2018)	MASAC
team_reward = $(1/N) \sum_i \text{reward}_i$	Señal colectiva del desempeño distrital	Todos
mixed_reward_i = $0.30 \cdot \text{reward}_i + 0.70 \cdot \text{team_reward}$	70% del gradiente de cada agente refleja el rendimiento del distrito (Kuba et al., 2021)	Todos
Actualización secuencial (HAPPO)	Actualiza π_1 , luego π_2 condicionado al nuevo $\pi_1, \dots, \pi_{17}$ al final. Garantiza que ninguna actualización individual deteriora la política conjunta (Kuba et al., 2021; Hu et al., 2023)	HAPPO
Mecanismo de atención (MAAC)	Crítico de cada agente pondera contribuciones de los otros 16 con 4 cabezas de atención (Iqbal & Sha, 2019)	MAAC

3.2 Durante ejecución — NO hay comunicación

Ejecución: $\pi_i(a_i | o_i) \leftarrow$ solo observación local del edificio i

Los 17 agentes actúan **completamente independientes** en tiempo de inferencia. No hay red de comunicación, no hay mensajes entre edificios, no hay acceso al estado de otros agentes. La coordinación fue **internalizada** en los pesos de la red neuronal durante el entrenamiento CTDE (Lowe et al., 2017; Oliehoek & Amato, 2016).

Esta propiedad es la que hace el sistema desplegable en edificios reales sin infraestructura de comunicación especial.

3.3 Coordinación implícita a través del entorno físico

Tres fuentes de coordinación que no requieren mensajes explícitos:

1. **Señales compartidas:** todos los edificios observan el mismo `electricity_price(t)` y `carbon_intensity(t)`. En hora punta todos tienen incentivo a descargar BESS → reducción colectiva sin coordinación explícita.
2. **Internalización CTDE:** durante 43 800 pasos de entrenamiento el crítico centralizado evaluó miles de combinaciones de acciones conjuntas. La política aprendida tiene codificado implícitamente "qué hacen los otros en este contexto de precio/clima".
3. **Física del entorno** (único canal implícito en ejecución):

```
district_import(t) =  $\sum_i \max(0, \text{net\_load\_i}(t))$ 
peak_share(t)      =  $\text{district\_import}(t) / 17$ 
ramp_share(t)      =  $|\text{district\_import}(t) - \text{district\_import}(t-1)| / 17$ 
```

Si 16 edificios descargan BESS y reducen `district_import(t)`, el edificio 17 recibe menor penalización flex vía `team_reward`. Este es el único "mensaje" entre agentes en ejecución: el estado compartido de la red eléctrica.

4. Control a Nivel Distrito — Cómo los 17 Agentes Producen Control Emergente

4.1 No existe un agente distrital

No hay controlador central, no hay maestro enviando setpoints, no hay jerarquía de control. El control distrital es un **comportamiento emergente** de los 17 agentes descentralizados actuando en el mismo entorno físico.

4.2 Loop de control distrital en cada paso horario t

```
1. Cada edificio  $i$  observa  $o_i$  local
2.  $\pi_i(a_i | o_i) \rightarrow$  acción local (BESS, EV, lavadora)
3. Entorno ejecuta las 17 acciones simultáneamente
4. Entorno computa:
   net_load_i(t)      =  $\text{import\_i}(t) - \text{export\_i}(t)$ 
   district_import(t) =  $\sum_i \max(0, \text{net\_load\_i}(t))$  ← señal distrital
   peak_share(t)      =  $\text{district\_import}(t) / 17$ 
   ramp_share(t)      =  $|\text{district\_import}(t) - \text{district\_import}(t-1)| / 17$ 
5. reward_function computa  $\text{reward\_i}(t)$ 
   → flex_component usa peak_share y ramp_share ← efecto distrital entra aquí
6.  $\text{team\_reward}(t) = \text{mean}(\text{reward\_i}(t))$  ← promedia los 17
7.  $\text{mixed\_reward\_i} = 0.30 \cdot \text{reward\_i} + 0.70 \cdot \text{team\_reward}$ 
8. [entrenamiento] gradiente actualiza  $\pi_i$  usando  $\text{mixed\_reward\_i}$ 
9.  $t+1$ : cada edificio actúa de nuevo
```

4.3 Mecanismo distrital por algoritmo

HAPPO — garantía matemática de mejora distrital:

El Surrogate Objective garantiza $J(\pi_{\text{new}}) \geq J(\pi_{\text{old}})$ sobre la política **conjunta** (Kuba et al., 2021; Hu et al., 2023). Cada actualización individual de π_i está condicionada a que no deteriore el rendimiento conjunto mediante el ratio de importancia por secuencia de agentes. El crítico centralizado $v(s)$ donde $s = [o_1, \dots, o_{17}]$ evalúa el valor del estado completo del distrito.

MASAC + QMIX — descomposición distrital:

$$Q_{\text{total}}(s, a_1, \dots, a_{17}) = f(Q_1(o_1, a_1), \dots, Q_{17}(o_{17}, a_{17}), s)$$

con $\partial Q_{\text{total}} / \partial Q_i \geq 0$ (monotónica)

Propiedad IGM (*Individual-Global-Max*): $\arg\max Q_{\text{total}} = (\arg\max Q_1, \dots, \arg\max Q_{17})$ (Rashid et al., 2018). En ejecución, cada edificio actúa greedy local y el resultado es globalmente óptimo — sin comunicación. El razonamiento distrital queda codificado en los pesos de la red de mezcla monótona.

MATD3 — doble crítico conjunto:

Dos críticos $Q_1(s, a_1, \dots, a_{17})$ y $Q_2(s, a_1, \dots, a_{17})$ evalúan la acción conjunta de los 17 edificios, extendiendo el paradigma de doble crítico de TD3 (Fujimoto et al., 2018) al entorno multiagente con estado global compartido (Hu et al., 2023). El estimador pesimista $\min(Q_1, Q_2)$ evita sobreestimar el valor distrital. El gradiente del actor de cada edificio i es:

$$\nabla_{\{\theta_i\}} J = E[\nabla_{\{a_i\}} Q_1(s, a_1, \dots, a_i, \dots, a_{17}) \cdot \nabla_{\{\theta_i\}} \pi_i(o_i)]$$

El edificio i aprende a mejorar el Q **distrital**, no su Q individual.

MAAC — atención distrital dinámica:

$$v_i = f(\text{encode}(o_i, a_i), \text{attention-pool}(\{\text{encode}(o_j, a_j) : j \neq i\}))$$

El crítico de cada edificio aprende a ponderar la influencia de los otros 16 mediante mecanismos de auto-atención multi-cabeza (Iqbal & Sha, 2019). Edificios con mayor impacto distrital (B01 BESS 6 747 kWh, B06 32 cargadores, B07 42 cargadores) recibirán mayor peso de atención de los demás, reflejando su contribución relativa a la dinámica del distrito.

4.4 Comportamiento distrital emergente

Sin MADRL (baseline):

Pico = $\sum_i \text{pico}_i$ (todos sincronizan)
 Ramping violento (17 sinc)
 EV carga al llegar
 BESS reactivo

Con MADRL entrenado:

Pico < $\sum_i \text{pico}_i$ (descarga escalonada)
 Ramping suavizado
 EV carga en valle / solar disponible
 BESS anticipa pico distrital

Por escenario:

E1 → crítico penaliza peak_share → agentes aprenden a coordinar descarga en punta
 E2 → crítico penaliza import × CI → agentes aprenden a importar cuando CI es baja
 E3 → crítico penaliza import × precio → agentes aprenden arbitraje TOU

5. Determinación del Mejor MADRL Global (O.G.)

5.1 Problema de la determinación global

Los escenarios E1/E2/E3 entrenan con vectores de peso distintos. El algoritmo que "gana" E1 fue entrenado para maximizar flex — no es un ganador justo en los otros ejes. La determinación de O.G. requiere un método de agregación inter-eje que no favorezca el eje de entrenamiento de ningún algoritmo.

5.2 Score_OG — ranking integrado multiobjetivo

Paso 1 — Extracción de KPIs por eje y algoritmo:

```
KPI_flex(a) ← peak_average           de a/E1_seed_0/data/results.json  (↓ mejor)
KPI_co2(a)  ← carbon_emissions_total de a/E2_seed_0/data/results.json  (↓ mejor)
KPI_cost(a) ← electricity_cost_total  de a/E3_seed_0/data/results.json  (↓ mejor)
```

Paso 2 — Normalización min-max inter-algoritmo (invirtiendo a "mayor = mejor"):

```
KPI_flex_norm(a) = 1 - [KPI_flex(a) - min_a KPI_flex] / [max_a KPI_flex - min_a KPI_flex]
KPI_co2_norm(a)  = 1 - [KPI_co2(a) - min_a KPI_co2] / [max_a KPI_co2 - min_a KPI_co2]
KPI_cost_norm(a) = 1 - [KPI_cost(a) - min_a KPI_cost] / [max_a KPI_cost - min_a KPI_cost]
```

Paso 3 — Score global con pesos iguales [1/3, 1/3, 1/3]:

```
Score_OG(a) = (1/3)·KPI_flex_norm(a) + (1/3)·KPI_co2_norm(a) + (1/3)·KPI_cost_norm(a)
```

Justificación de pesos iguales: el O.G. exige gestión *coordinada* sin preferencia a priori por ningún eje (Roijers et al., 2013, JAIR; Felten et al., 2024, JAIR arXiv:2311.12495).

5.3 Análisis de dominancia de Pareto (complementario)

El algoritmo **a** **domina de Pareto** al algoritmo **b** si:

```
KPI_flex_norm(a) ≥ KPI_flex_norm(b)  Y
KPI_co2_norm(a)  ≥ KPI_co2_norm(b)    Y
KPI_cost_norm(a) ≥ KPI_cost_norm(b)   Y
∃ eje k : KPI_k_norm(a) > KPI_k_norm(b)
```

Si existe un algoritmo no dominado → es el ganador inequívoco de O.G. (Roijers et al., 2013). Si ninguno domina (frente de Pareto, lo que ocurre cuando ningún algoritmo es mejor en todos los ejes simultáneamente) → el Score_OG con pesos iguales decide.

5.4 Ranking de Borda (verificación no paramétrica)

Para cada eje e, asignar rango $r_e(a) \in \{1,2,3,4\}$ donde rango 1 = mejor KPI:

$$\text{Borda}(a) = r_{\text{flex}}(a) + r_{\text{co2}}(a) + r_{\text{cost}}(a)$$

El algoritmo con menor Borda score es el mejor coordinado (O.G.). El ranking de Borda es un método de votación por posición ampliamente utilizado en optimización multiobjetivo para sintetizar múltiples criterios sin necesidad de asignar pesos explícitos, lo que lo hace adecuado como verificación no paramétrica del Score_OG (Rojiers et al., 2013; Felten et al., 2024). El ranking Borda y el Score_OG deben coincidir; si divergen, reportar ambos y discutir en §3.4.

5.5 Protocolo estadístico para O.G

- **Kruskal-Wallis** sobre Score_OG de los 5 episodios por algoritmo: H_0 = todos equivalentes; si $p < 0.05$ existe diferencia significativa global (Kruskal & Wallis, 1952). Prueba no paramétrica adecuada dado que no se asume normalidad en los retornos de RL.
- **Mann-Whitney U** par-a-par (6 pares) sobre Score_OG con corrección Bonferroni $\alpha' = 0.05/6 = 0.0083$ (Mann & Whitney, 1947). La corrección Bonferroni controla el error tipo I ante comparaciones múltiples.
- **Effect size** ϵ^2 (eta-cuadrado de Kruskal-Wallis): pequeño ≥ 0.01 , mediano ≥ 0.06 , grande ≥ 0.14 . El effect size complementa el p-valor indicando la magnitud práctica de la diferencia, no solo su significancia estadística.

6. Desagregación por Edificio — Control Individual y Contribución al Distrito

6.1 KPIs por edificio i

Extraídos de `{algo}/{scenario}_seed_0/data/timeseries.csv`:

```
peak_i      = max_t ( net_load_i(t) )
co2_i       = Σ_t max(0, import_i(t)) · CI(t)
cost_i      = Σ_t max(0, import_i(t)) · p(t)
self_suff_i = 1 - Σ_t import_i(t) / Σ_t non_shiftable_load_i(t)
bess_util_i = Σ_t |P_bess_i(t)| / (T · P_bess_max_i)
ev_served_i = Σ_t EV_sessions_completed_i(t) / EV_sessions_total_i
```

6.2 Métricas de coordinación distrital

```
district_import(t) = Σ_i max(0, net_load_i(t))
peak_district      = max_t district_import(t)
peak_share_i(t)    = net_load_i(t) / district_import(t)
ramp_district(t)   = |district_import(t) - district_import(t-1)|
```

6.3 Contribución individual — análisis counterfactual

```
Δpeak_i = peak_district_sin_i - peak_district_con_i
Δco2_i = co2_district_sin_i - co2_district_con_i
Δcost_i = cost_district_sin_i - cost_district_con_i
```

"sin_i" = política ganadora con el agente i en modo pasivo (sin BESS, sin control EV). Cuantifica cuánto aporta cada edificio a la coordinación distrital. Este análisis contrafactual es análogo al baseline contrafactual propuesto en COMA para cuantificar la contribución individual de cada agente en MADRL (Foerster et al., 2018).

6.4 Edificios críticos para la coordinación

Edificios con mayor Δpeak_i esperado por tamaño de DER:

Edificio	BESS kWh	EV tomas	Factor crítico
B01 ELECTRO ORIENTE	6 747	4	BESS más grande del distrito
B06 MALL AVENTURA	2 541	32	Mayor concentración de cargadores EV
B07 UNAP BIOLOGÍA	984	42	Mayor número de tomas EV
B11 HOSPITAL LORETO	1 901	3	Carga base constante 24h (healthcare)
B12 ESSALUD	4 346	3	Segundo BESS más grande

7. Resumen Conceptual

```
ENTRENAMIENTO (donde ocurre la cooperación):
  Crítico centralizado → ve s = [o1,...,o17]
  QMIX (MASAC) → mezcla Q-values con garantía IGM
  team_reward → señal colectiva del distrito
  mixed_reward (70/30) → 70% gradiente = señal de equipo
  Actualiz. secuencial → HAPPO garantiza mejora conjunta
  Atención (MAAC) → ponderación dinámica de agentes

EJECUCIÓN (donde NO hay comunicación):
  πi(ai | oi) → solo observación local
  Coordinación → internalizada durante CTDE

ENTORNO (canal físico siempre activo):
  district_import(t) → única "señal" compartida en ejecución
  team_reward → propaga efecto colectivo a gradientes individuales

PREGUNTA DE TESIS:
  ¿Cuál algoritmo (HAPPO/MASAC/MATD3/MAAC) produce las 17 políticas
  que mejor coordinan flexibilidad, CO2 y costos de forma simultánea?
  → Score_OG = mean(KPI_flex_norm, KPI_co2_norm, KPI_cost_norm)
  → Verificado con dominancia de Pareto, ranking de Borda y suite estadística
```


8. Referencias Académicas

- Felten, F., Alegre, L. N., Nowe, A., Bazzan, A. L. C., Talbi, E.-G., Danoy, G., & Majeri, P. (2024). A toolkit for reliable benchmarking and research in multi-objective reinforcement learning. *Journal of Artificial Intelligence Research*. arXiv:2311.12495.
- Foerster, J., Farquhar, G., Afouras, T., Nardelli, N., & Whiteson, S. (2018). Counterfactual multi-agent policy gradients. *Proceedings of the AAAI Conference on Artificial Intelligence*, 32(1). [COMA — baseline contrafactual multiagente]
- Fujimoto, S., van Hoof, H., & Meger, D. (2018). Addressing function approximation error in actor-critic methods. *Proceedings of the 35th International Conference on Machine Learning (ICML 2018)*, PMLR 80:1587–1596. [TD3 — base de MATD3]
- Hu, J., Zhu, Y., Wang, H., Bhatt, A., Garg, A., & Wen, Y. (2023). HARL: Heterogeneous-agent reinforcement learning. *Journal of Machine Learning Research*. arXiv:2304.09870. [HAPPO y MATD3 implementación multiagente]
- Iqbal, S., & Sha, F. (2019). Actor-attention-critic for multi-agent reinforcement learning. *Proceedings of the 36th International Conference on Machine Learning (ICML 2019)*, PMLR 97:2961–2970. [MAAC]
- Kruskal, W. H., & Wallis, W. A. (1952). Use of ranks in one-criterion variance analysis. *Journal of the American Statistical Association*, 47(260), 583–621. [Prueba Kruskal-Wallis]
- Kuba, J. G., Chen, R., Wen, M., Wen, Y., Sun, F., Wang, J., & Yang, Y. (2021). Trust region policy optimisation in multi-agent reinforcement learning. arXiv:2109.11251. [HAPPO]
- Lowe, R., Wu, Y., Tamar, A., Harb, J., Abbeel, P., & Mordatch, I. (2017). Multi-agent actor-critic for mixed cooperative-competitive environments. *Advances in Neural Information Processing Systems*, 30. [MADDPG/CTDE paradigma]
- Mann, H. B., & Whitney, D. R. (1947). On a test of whether one of two random variables is stochastically larger than the other. *The Annals of Mathematical Statistics*, 18(1), 50–60. [Prueba Mann-Whitney U]
- Nweye, K., Sankaranarayanan, S., & Nagy, Z. (2023). MARTINI: Multi-agent reinforcement learning-based intelligent control for residential buildings. *Proceedings of the NeurIPS 2022 Competitions and Demonstrations Track*, PMLR 220:85–103. [CityLearn Challenge KPI standard]
- Nweye, K., Sankaranarayanan, S., & Nagy, Z. (2024). CityLearn v2: Energy-flexible, resilient, and occupant-centric control of grid-interactive communities. *Journal of Building Performance Simulation*. arXiv:2405.03848. [CityLearn v2 KPI API oficial]
- Oliehoek, F. A., & Amato, C. (2016). *A concise introduction to decentralized POMDPs*. Springer. [Dec-POMDP formalismo]
- Rashid, T., Samvelyan, M., de Witt, C. S., Farquhar, G., Foerster, J., & Whiteson, S. (2018). QMIX: Monotonic value function factorisation for deep multi-agent reinforcement learning. *Proceedings of the 35th International Conference on Machine Learning (ICML 2018)*, PMLR 80:4295–4304. [QMIX, propiedad IGM]
- Roijers, D. M., Vamplew, P., Whiteson, S., & Farquhar, R. (2013). A survey of multi-objective sequential decision-making. *Journal of Artificial Intelligence Research*, 48, 67–113.
- Vázquez-Canteli, J. R., Kämpf, J., Henze, G., & Nagy, Z. (2020). CityLearn v1.0: An OpenAI gym environment for demand response with deep reinforcement learning. *Proceedings of the 6th ACM*

International Conference on Systems for Energy-Efficient Buildings, Cities and Transportation (BuildSys 2019), 356–357. [CityLearn KPIs baseline, separación evaluación/recompensa]