UNIVERSIDAD NACIONAL DE INGENIERIA (UNI)

Escuela de Posgrado — Posgrado en Ingenieria

Inteligencia Artificial aplicada a Sistemas Electricos Inteligentes

COORDINACIÓN ENERGÉTICA MULTIOBJETIVO MEDIANTE APRENDIZAJE POR REFUERZO PROFUNDO MULTIAGENTE EN UNA COMUNIDAD INTELIGENTE HETEROGÉNEA DE IQUITOS: EFECTOS Y DESEMPEÑO ALGORÍTMICO, 2026

Caso de estudio: SEAI Iquitos — 17 edificios reales (2023-2025)

TESIS PARA OPTAR EL GRADO ACADEMICO DE DOCTOR EN INGENIERIA

Autor: Mac Tapia (mac.tapia.c@uni.pe)

Asesor: [por definir]

Lima / Iquitos, Peru — 05 de July de 2026

Dedicatoria

A mi familia, por el apoyo incondicional durante este camino de formación de tesis; a los docentes y colegas de la Universidad Nacional de Ingeniería, por impulsar la investigación aplicada en sistemas eléctricos inteligentes; y a la comunidad académica de Iquitos, cuyo contexto energético motivó el presente estudio.

Agradecimientos

Se agradece a la Escuela de Posgrado de la UNI, al equipo de investigación del proyecto MADRL CityLearn v3, a Electro Oriente S.A. y a las instituciones que aportaron datos operativos para el dataset citylearn_iquitos_2023_2025. Asimismo, se reconoce el uso de recursos computacionales en Google Colab para la corrida canónica de 50 episodios (madrl_v3_20260627_164047).

Resumen

Esta tesis doctoral determina, mediante simulación computacional bajo diseño cuasiexperimental factorial 4×3, el efecto de cuatro algoritmos Multi-Agente de Aprendizaje por Refuerzo Profundo (MADRL) —HAPPO, MASAC, MATD3 y MAAC— sobre la gestión coordinada de flexibilidad energética, emisiones de CO_2 y costos en una comunidad inteligente del Sistema Eléctrico Aislado de Iquitos (SEAI). La formulación Dec-POMDP con CTDE se implementa sobre CityLearn v3 propuesto (17 edificios reales, 26 304 h, 185 cargadores EV). La corrida canónica Colab/Drive (madrl_v3_20260627_164047) completó 50 episodios por escenario en MATD3, MAAC y MASAC (HAPPO: 49/50). En respuesta descriptiva a PE.1–PE.3 / OE.1–OE.3, MATD3 lidera flexibilidad (flex_composite E1 = 1,0009) y emisiones (ΔCO_2 E2 = 23 070 kg); MAAC lidera costos (Δcosto E3 = 9 515 USD); el score global canónico best_madrl 3×3 es MATD3 = 0,6667 (sin dominador Pareto único; ranking evaluate_v2 4/4: MAAC 0,9538 > MATD3 0,8805 > MASAC 0,8679 > HAPPO 0,0000). Tras Shapiro–Wilk (normalidad rechazada), la contrastación inferencial canónica sobre KPI-gains (Cap. 5 §5.3–§5.5) no rechaza HE10/HE20/HE30 (Kruskal–Wallis OE.1 p = 0,4685; OE.2 p = 0,7648; OE.3 p = 0,7357) ni respalda HE11/HE21/HE31; H0G se rechaza de forma exploratoria por Friedman integrado (p = 0,0096) con KW GLOBAL exploratorio no significativo (p = 0,4044; Capa A). TOPSIS/AHP (outputs/madrl_multicriteria_selection; fuente real_drive_50ep_c1c6) es medida multicriterio formal adicional (MAAC C* ≈ 0,9827 > MASAC 0,5656 > MATD3 0,3074) que integra costo–CO_2–flexibilidad para apoyar la determinación de OG/OE.1–OE.3 y el contraste multiobjetivo de HE, complementando —sin sustituir— el omnibus KPI-gains y evaluate_v2 4/4.

Palabras clave: aprendizaje por refuerzo multiagente, diseño cuasiexperimental, Dec-POMDP, CTDE, flexibilidad energética, emisiones de CO_2, microrred aislada, Iquitos.

Abstract

This doctoral thesis determines the effect of four cooperative Multi-Agent Deep Reinforcement Learning (MADRL) algorithms (HAPPO, MASAC, MATD3, MAAC) under a Dec-POMDP/CTDE framework on a real 17-building CityLearn v3 dataset from Iquitos, Peru (quasi-experimental factorial design 4×3; canonical Drive run madrl_v3_20260627_164047, 50 episodes; HAPPO 49/50). Descriptive PE.1–PE.3 / OE.1–OE.3 answers: MATD3 leads flexibility (flex_composite E1 = 1.0009) and CO_2 (ΔCO_2 E2 = 23,070 kg); MAAC leads cost (Δcost E3 = 9,515 USD); canonical best_madrl 3×3 global score is MATD3 = 0.6667 (no universal Pareto winner; evaluate_v2 4/4 ranks MAAC 0.9538 > MATD3 0.8805 > MASAC 0.8679 > HAPPO 0.0000). After Shapiro–Wilk (normality rejected), canonical KPI-gains inference (Ch. 5) does not reject HE10/HE20/HE30 (Kruskal–Wallis OE.1 p=0.4685; OE.2 p=0.7648; OE.3 p=0.7357) and does not support HE11/HE21/HE31; H0G is rejected only exploratorily via Friedman (p=0.0096) while exploratory KW GLOBAL is non-significant (p=0.4044; Layer A). TOPSIS/AHP (real_drive_50ep_c1c6; MAAC C*≈0.9827 > MASAC 0.5656 > MATD3 0.3074) is an additional formal multicriteria measure supporting OG/OE determination and multiobjective hypothesis contrast, complementing —not replacing— KPI-gains omnibus tests and evaluate_v2 4/4.

Indice

Actualice el indice general con clic derecho > Actualizar campos (o F9).

Indice de tablas

Actualice el indice de tablas con clic derecho > Actualizar campos (o F9).

Indice de figuras

Actualice el indice de figuras con clic derecho > Actualizar campos (o F9).

Capitulo 1. Introduccion

1.1 Diagnostico

Las comunidades inteligentes integran recursos de energia distribuida, generacion solar fotovoltaica, sistemas de almacenamiento en baterias y estaciones de carga de vehiculos electricos. La literatura de CityLearn sostiene que esta integracion exige entornos reproducibles para comparar controladores de respuesta a la demanda en edificios y comunidades, mientras que CityLearn v2 amplia el problema hacia comunidades grid-interactive con vehiculos electricos, intensidad de carbono, almacenamiento y KPIs de flexibilidad, emisiones y costos. En consecuencia, el diagnostico de esta tesis no se limita a un algoritmo aislado, sino a la ausencia de una evaluacion coordinada y comparable de politicas MADRL bajo observabilidad parcial (Vázquez-Canteli et al., 2020; Nweye et al., 2024; Fonseca et al., 2024).

En el Sistema Electrico Aislado de Iquitos, operado por Electro Oriente S.A., el suministro depende mayoritariamente de generacion diesel con penetracion solar creciente. El factor de emision base usado por el estudio es 0.790 kgCO2/kWh y la tarifa por uso horario distingue periodos punta y fuera de punta. Bajo esta condicion, la gestion no coordinada de DER puede incrementar picos, rampas, consumo ponderado por carbono y costos electricos. Esta problematica vincula directamente la tesis con tres dimensiones dependientes: flexibilidad energetica, emisiones de CO2 y costos energeticos (MINAM, 2019; OSINERGMIN, 2024; Nweye et al., 2024).

Desde la perspectiva computacional, el problema es multiagente, secuencial y parcialmente observable. Cada edificio decide sobre equipos controlables, pero no observa plenamente el estado interno de los demas edificios ni controla la demanda no flexible. Por ello, la formulacion Dec-POMDP y el esquema CTDE son consistentes con la ejecucion

descentralizada y el entrenamiento cooperativo de HAPPO, MASAC, MATD3 y MAAC. Esta triangulacion teorica justifica que el estudio evalua algoritmos, escenarios y KPIs con evidencia episodica real de la corrida Drive de 50 episodios por tratamiento (Oliehoek & Amato, 2016; Lowe et al., 2017; Iqbal & Sha, 2019).

1.2 Identificacion y descripcion del problema de estudio

El problema de estudio se identifica como la falta de determinacion empirica del efecto que produce el algoritmo MADRL sobre la gestion coordinada de flexibilidad energetica, emisiones de CO2 y costos energeticos en una comunidad inteligente. La brecha no consiste solo en entrenar agentes, sino en comparar familias MADRL heterogeneas bajo los mismos datos, la misma funcion de recompensa, los mismos escenarios E1, E2 y E3, y los mismos criterios de lectura de KPIs. Esta comparabilidad es necesaria porque el desempeno en una dimension puede no coincidir con el desempeno en las otras; por ejemplo, una politica puede reducir emisiones y al mismo tiempo deteriorar costos o rampas.

Los sintomas observables se expresan en demanda pico, rampas horarias, consumo neto, emisiones ponderadas por intensidad de carbono, costo electrico y comportamiento por edificio. Las causas tecnicas se relacionan con la coordinacion incompleta entre agentes, la heterogeneidad de equipos controlables y no controlables, y la dificultad de aprendizaje en horizontes anuales de 8760 pasos. Las causas metodologicas se asocian con benchmarks fragmentados, falta de lectura por objetivo especifico y uso de promedios agregados sin soporte inferencial. Por ello, el Capitulo 5 responde las preguntas especificas con analisis descriptivo, inferencial y evidencia por distrito, edificio, escenario y KPI.

La correspondencia formal entre problemas, objetivos, hipotesis, variables e indicadores se conserva en el numeral 1.4, tal como estaba desarrollado en la version final de tesis. Esta ubicacion evita duplicar la matriz y mantiene la trazabilidad vertical del documento.

1.2.1 Formulacion del problema

La formulacion del problema se conserva segun la version definida en el documento de tesis final. Los antecedentes bibliograficos que sustentan esta formulacion se desarrollan una sola vez en el Capitulo 2, dentro de los apartados de antecedentes internacionales, antecedentes nacionales/peruanos y sintesis critica de brecha cientifica. Esta decision evita duplicar paginas de antecedentes en el Capitulo 1 y mantiene una ruta logica entre problema, marco teorico, metodologia y resultados.

1.2.1.1 Formulación del problema general

¿En qué medida el algoritmo MADRL (aprendizaje por refuerzo profundo multiagente) impacta en la gestión coordinada de la flexibilidad energética, las emisiones de CO_2 y los costos energéticos en comunidades inteligentes de la ciudad de Iquitos, y cuál de los algoritmos presenta el mejor desempeño a nivel global?

¿En qué medida el algoritmo MADRL (aprendizaje por refuerzo profundo multiagente) impacta en la gestión coordinada de la flexibilidad energética, las emisiones de CO_2 y los costos energéticos en comunidades inteligentes de la ciudad de Iquitos, y cuál de los algoritmos presenta el mejor desempeño a nivel global?

1.2.1.2 Formulación de los problemas específicos

Problemas especificos:

PE.1: ¿En qué medida el algoritmo MADRL impacta en la flexibilidad energética en comunidades inteligentes de la ciudad de Iquitos, y cuál de los algoritmos presenta el mejor desempeño en el escenario E1?

PE.2: ¿En qué medida el algoritmo MADRL impacta en las emisiones de CO_2 en comunidades inteligentes de la ciudad de Iquitos, y cuál de los algoritmos presenta el mejor desempeño en el escenario E2?

PE.3: ¿En qué medida el algoritmo MADRL impacta en los costos energéticos en comunidades inteligentes de la ciudad de Iquitos, y cuál de los algoritmos presenta el mejor desempeño en el escenario E3?

Cada problema especifico se responde en el Capitulo 5 mediante analisis descriptivo e inferencial sobre la corrida canonica de 50 episodios por tratamiento. PE.1 se vincula con OE.1 y HE.1; PE.2 se vincula con OE.2 y HE.2; y PE.3 se vincula con OE.3 y HE.3.

1.2.2 Justificacion y alcances

1.2.2.1 Justificacion

a) Justificacion teorica. El estudio se justifica teoricamente porque articula tres cuerpos de conocimiento que suelen tratarse de manera separada: la simulacion energetica de comunidades de edificios, el aprendizaje por refuerzo profundo multiagente y la evaluacion estadistica de politicas de control. La formulacion Dec-POMDP permite representar observabilidad parcial, accion descentralizada y recompensa cooperativa; el esquema CTDE permite entrenar politicas descentralizadas con informacion global durante el aprendizaje; y la evaluacion con KPIs CityLearn permite interpretar el desempeno energetico en terminos verificables. Esta integracion aporta una base conceptual para explicar por que los algoritmos

HAPPO, MAAC, MASAC y MATD3 pueden compararse como niveles de la variable independiente y no como implementaciones aisladas.

b) Justificacion de flexibilidad energetica. La tesis se justifica en flexibilidad energetica porque las comunidades inteligentes con PV, BESS, cargadores EV/V2G y cargas flexibles requieren coordinar decisiones distribuidas para reducir picos, suavizar rampas, desplazar consumo y aprovechar recursos distribuidos. En el SEAI Iquitos, donde la operacion aislada y la penetracion renovable condicionan la gestion de demanda, una politica MADRL puede modificar el perfil agregado de consumo si aprende a coordinar almacenamiento, carga vehicular y demanda flexible. Por ello, OE.1 evalua de manera especifica si el algoritmo MADRL produce efecto sobre D-VD.1 y cual algoritmo genera el mayor efecto en esta dimension.

c) Justificacion economica. La investigacion se justifica economicamente porque el costo energetico de una comunidad no depende solo del consumo total, sino tambien del momento en que la demanda se presenta frente a senales tarifarias por uso horario. La falta de coordinacion entre edificios puede trasladar consumo hacia periodos de mayor costo o generar decisiones localmente convenientes pero suboptimas a nivel comunitario. La comparacion de algoritmos MADRL permite identificar si alguna politica reduce el costo electrico bajo las mismas condiciones de simulacion, la misma comunidad y los mismos escenarios. Esta justificacion se vincula directamente con OE.3, D-VD.3 y la lectura de district_cost y KPIs de costo en el Capitulo 5.

d) Justificacion ambiental. La tesis se justifica ambientalmente porque el SEAI Iquitos se caracteriza por una matriz aislada con dependencia termica y senales de intensidad de carbono relevantes para la gestion del consumo. Coordinar demanda, almacenamiento, PV y carga vehicular puede desplazar consumo hacia periodos de menor intensidad de carbono y reducir

emisiones asociadas a la importacion de energia. En consecuencia, el estudio no evalua solo recompensa algoritmica, sino el efecto de las politicas MADRL sobre emisiones de CO2 mediante indicadores distritales, por edificio y por escenario. Esta justificacion sostiene OE.2 y D-VD.2.

e) Justificacion tecnologica. La investigacion se justifica tecnologicamente porque desarrolla una arquitectura reproducible basada en dataset local, CityLearn v2, extension CityLearn v3 propuesta, scripts de construccion de datos, entrenamiento MADRL, trazas, checkpoints, timeseries y generacion automatizada de figuras y tablas. Esta arquitectura permite que los resultados no dependan de afirmaciones generales, sino de artefactos auditables de la corrida Drive madrl_v3_20260627_164047. La contribucion tecnologica consiste en integrar datos locales, equipos controlables y no controlables, simulacion multiagente y analisis estadistico dentro de un flujo verificable para tesis.

1.2.2.2 Alcances

El alcance tematico comprende la evaluacion comparativa de HAPPO, MASAC, MATD3 y MAAC sobre flexibilidad energetica, emisiones de CO2 y costos energeticos. El alcance espacial corresponde a una comunidad inteligente simulada con aplicabilidad al SEAI Iquitos y 17 edificios institucionales/comerciales. El alcance temporal se basa en datos horarios 2023-2025 y en una corrida de entrenamiento/evaluacion con 50 episodios por tratamiento disponible. El alcance computacional comprende Python, PyTorch, CityLearn v2, librerias de analisis cientifico y artefactos Drive validados.

El estudio no modela una red electrica fisica ni valida un despliegue real en campo. CityLearn v3 propuesto se interpreta como extension experimental de tesis y no como version oficial de CityLearn. Se excluyen investigacion con sujetos humanos, despacho economico de

unidades fisicas, analisis de estabilidad de red y extrapolacion causal fuera de la evidencia de simulacion disponible.

1.3 Objetivos e hipotesis de la investigacion

1.3 Objetivos e hipótesis de la investigación

1.3.1 Objetivos

1.3.1.1 Objetivo general

OG. - Determinar el impacto de los algoritmos aprendizaje por refuerzo profundo multiagente (MADRLs) en la gestión coordinada de la flexibilidad energética, las emisiones de CO_2 y los costos energéticos en comunidades inteligentes de la ciudad de Iquitos, e identificar cuál de los algoritmos presenta el mejor desempeño a nivel global.

1.3.1.2 Objetivos específicos

OE.1: Determinar el impacto de los algoritmos MADRLs en la flexibilidad energética en comunidades inteligentes de la ciudad de Iquitos e identificar cuál de los algoritmos presenta el mejor desempeño en el escenario E1.

OE.2: Determinar el impacto de los algoritmos MADRLs en las emisiones de CO_2 en comunidades inteligentes de la ciudad de Iquitos e identificar cuál de los algoritmos presenta el mejor desempeño en el escenario E2.

OE.3: Determinar el impacto de los algoritmos MADRLs en los costos energéticos en comunidades inteligentes de la ciudad de Iquitos e identificar cuál de los algoritmos presenta el mejor desempeño en el escenario E3.

1.3.2 Hipótesis

1.3.2.1 Hipótesis general

H0G.-El algoritmo MADRL no impacta de manera estadísticamente significativa y diferenciada en la gestión coordinada de la flexibilidad energética, las emisiones de CO_2 y los costos energéticos en comunidades inteligentes de la ciudad de Iquitos, y no existen diferencias significativas en el desempeño global de los algoritmos.

H1G.- El algoritmo MADRL impacta de manera estadísticamente significativa y diferenciada en la gestión coordinada de la flexibilidad energética, las emisiones de CO_2 y los costos energéticos en comunidades inteligentes de la ciudad de Iquitos, y el desempeño global difiere entre los algoritmos.

1.3.2.2 Hipótesis específicas

HE10.- El algoritmo MADRL no impacta de manera estadísticamente significativa en la flexibilidad energética en comunidades inteligentes de la ciudad de Iquitos, y no existen diferencias significativas entre los algoritmos evaluados en el escenario E1.

HE11.- El algoritmo MADRL impacta de manera estadísticamente significativa en la flexibilidad energética en comunidades inteligentes de la ciudad de Iquitos, y existen diferencias significativas entre los algoritmos evaluados en el escenario E1.

HE20.- El algoritmo MADRL no impacta de manera estadísticamente significativa en las emisiones de CO_2 en comunidades inteligentes de la ciudad de Iquitos, y no existen diferencias significativas entre los algoritmos evaluados en el escenario E2.

HE21.- El algoritmo MADRL impacta de manera estadísticamente significativa en las emisiones de CO_2 en comunidades inteligentes de la ciudad de Iquitos, y existen diferencias significativas entre los algoritmos evaluados en el escenario E2.

HE30.-El algoritmo MADRL no impacta de manera estadísticamente significativa en los costos energéticos en comunidades inteligentes de la ciudad de Iquitos, y no existen diferencias significativas entre los algoritmos evaluados en el escenario E3.

HE31.-El algoritmo MADRL impacta de manera estadísticamente significativa en los costos energéticos en comunidades inteligentes de la ciudad de Iquitos, y existen diferencias significativas entre los algoritmos evaluados en el escenario E3.

1.3.1 Objetivos

1.3.1.1 Objetivo general

1.3.1.1 Objetivo general

Identificar el(los) MADRL recomendable(s) por eje y el ranking integrado de gestión coordinada de flexibilidad, CO_2 y costos en el SEAI Iquitos, sin asumir dominancia Pareto universal, evaluando el efecto del factor algoritmo (VI) sobre la VD.

1.3.1.2 Objetivos específicos

1.3.1.2 Objetivos específicos

OE.1: Determinar el impacto de los algoritmos MADRLs en la flexibilidad energética en comunidades inteligentes de la ciudad de Iquitos e identificar cuál de los algoritmos presenta el mejor desempeño en el escenario E1.

OE.2: Determinar el impacto de los algoritmos MADRLs en las emisiones de CO_2 en comunidades inteligentes de la ciudad de Iquitos e identificar cuál de los algoritmos presenta el mejor desempeño en el escenario E2.

OE.3: Determinar el impacto de los algoritmos MADRLs en los costos energéticos en comunidades inteligentes de la ciudad de Iquitos e identificar cuál de los algoritmos presenta el mejor desempeño en el escenario E3.

Los objetivos (OG, OE.1-OE.3) determinan el efecto del MADRL (VI) sobre cada dimension de la VD e identifican el algoritmo de mayor efecto mediante KPIs y ranking descriptivo en los Capitulos 5 y 6. Esta redaccion no modifica los objetivos definidos; solo los vincula con el diseno factorial 4x3, los 54 KPI oficiales compatibles con CityLearn v2 y la corrida canonica Drive madrl_v3_20260627_164047 de 50 episodios por tratamiento disponible.

1.3.2 Hipótesis

El estudio es cuantitativo, aplicado y cuasiexperimental factorial 4×3 (algoritmo × escenario), basado en simulación. A diferencia de los objetivos, las hipótesis formulan contrastes H_0/H_1 sobre el factor algoritmo (VI). Se contrastan dos capas de evidencia que no deben fusionarse: (A) series episódicas alineadas a OE; (B) KPI-gains de entrenamiento. Protocolo: Shapiro–Wilk → Friedman pareado + Kendall W + Wilcoxon/Holm (principal); Kruskal–Wallis/MWU exploratorio → Mann–Whitney U (Holm) y Wilcoxon signed-rank (exploratorio); $\alpha = 0{,}05$. Las métricas primarias son KPIs energéticos y recompensa MADRL; accuracy/precision/recall/F1 no son métricas centrales. Detalle en Capítulos 3 y 5 (Colas et al., 2019; Agarwal et al., 2021).

1.3.2.1 Hipótesis general

1.3.2.1 Hipótesis general

$H_1(G)$: no existe un único MADRL que domine simultáneamente los tres ejes; el ranking integrado y los líderes por eje pueden diferir (trade-off Pareto), con efectos diferenciados del factor algoritmo sobre la VD. $H_0(G)$: las distribuciones de desempeño entre algoritmos son idénticas en el agregado de ejes (omnibus KPI-gains).

1.3.2.2 Hipótesis específicas

1.3.2.2 Hipótesis específicas

HE.1: H_{11} = las distribuciones de desempeño de flexibilidad (D-VD.1) difieren entre algoritmos; H_{01} = son idénticas. El líder descriptivo compuesto en E1 es MATD3; la media episódica de reward_mean_average favorece a MAAC.

HE.2: H_{12} = las distribuciones de emisiones de CO_2 (D-VD.2) difieren entre algoritmos; H_{02} = son idénticas. El líder descriptivo en E2 es MATD3.

HE.3: H_{13} = las distribuciones de costo energético (D-VD.3) difieren entre algoritmos; H_{03} = son idénticas. El líder descriptivo en E3 es MAAC (Δcosto 9 515 USD).

Veredicto (corrida madrl_v3_20260627_164047, seed = 0): ranking/Pareto descriptivo aceptado (MATD3 score 0,6667; sin dominador universal; MAAC lidera costos y evaluate_v2 4/4). Contrastación canónica Cap. 5 sobre KPI-gains (omnibus principal = Friedman pareado): HE10/HE20/HE30 no se rechazan (Friedman p = 0,0611 / 0,0498 / 0,1801; KW exploratorio p = 0,4685 / 0,7648 / 0,7357); HE11/HE21/HE31 no se respaldan; H0G se rechaza (Friedman p = 0,0096, Kendall's W = 0,1787) con KW GLOBAL no significativo (H = 1,8108, p = 0,4044). Las capas episódicas, evaluate_v2 4/4 y TOPSIS (medida multicriterio formal adicional; MAAC C* ≈ 0,9827) complementan el veredicto HE de KPI-gains: convergen con evaluate_v2 en coronar a MAAC (0,9538), y divergen del orden 2.º/3.º (TOPSIS: MASAC > MATD3; evaluate_v2: MATD3 > MASAC), sin sustituir el omnibus.

1.4 Matriz de consistencia y operacionalizacion

Tabla 1.1

Matriz de consistencia problema-objetivo-hipotesis

Dimension	Problema especifico	Objetivo especifico	Hipotesis especifica	Evidencia real de resultados
D-VD.1 Flexibilidad energetica	PE.1: ¿En qué medida el algoritmo MADRL	OE.1: Determinar el efecto del algoritmo MADRL (VI) sobre la flexibilidad	HE.1: El algoritmo MADRL (VI) produce un efecto significativo sobre la flexibilidad	KPIs de pico, rampa, load factor, convergencia y comparacion por algoritmo desde 50

	impacta en la flexibilidad energética en comunidades inteligentes de la ciudad de Iquitos, y cuál de los algoritmos presenta el mejor desempeño en el escenario E1?	energetica (D-VD.1) e identificar el algoritmo de mayor efecto en esta dimension.	energetica (D-VD.1); el mayor efecto corresponde al algoritmo con menor variabilidad en los KPI de pico y rampa.	episodios Drive.
D-VD.2 Emisiones de CO2	PE.2: ¿En qué medida el algoritmo MADRL impacta en las emisiones de CO_2 en comunidades inteligentes de la ciudad de Iquitos, y cuál de los algoritmos presenta el mejor desempeño en el escenario E2?	OE.2: Determinar el efecto del algoritmo MADRL (VI) sobre las emisiones de CO2 (D-VD.2) e identificar el algoritmo de mayor efecto en esta dimension.	HE.2: El algoritmo MADRL (VI) produce un efecto significativo sobre las emisiones de CO2 (D-VD.2); el mayor efecto corresponde a MATD3.	KPIs de emisiones, carbon-aware control, ranking por escenario y pruebas no parametricas desde artefactos Drive.
D-VD.3 Costos energeticos	PE.3: ¿En qué medida el algoritmo MADRL impacta en los costos energéticos en comunidades inteligentes de la ciudad de Iquitos, y cuál de los algoritmos	OE.3: Determinar el efecto del algoritmo MADRL (VI) sobre los costos energeticos (D-VD.3) e identificar el algoritmo de mayor efecto en esta dimension.	HE.3: El algoritmo MADRL (VI) produce un efecto significativo sobre los costos energeticos (D-VD.3); el mayor efecto corresponde al algoritmo con menor delta de costo electrico.	KPIs de costo electrico, tarifa TOU, comparacion por edificio y efecto inferencial desde timeseries y tablas reales.

		presenta el mejor desempeño en el escenario E3?		

Nota. La tabla representa la correspondencia entre problema, objetivos, hipotesis, variables y alcances del planteamiento. Fuente: Elaboracion propia a partir de la formulacion del problema, objetivos e hipotesis definidos en el Capitulo 1.

Tabla 1.2

Operacionalizacion de variables independientes y dependientes

Variable	Dimension	Indicadores	Fuente empirica	Uso analitico
VI: algoritmo MADRL	Tratamiento algoritmico	HAPPO, MASAC, MATD3, MAAC; escenarios E1, E2, E3	results, traces, checkpoints y configuraciones Drive	Comparacion factorial 4x3.
VD: gestion coordinada	D-VD.1 Flexibilidad energetica	pico, rampa, load factor, consumo neto y KPIs CityLearn v2	timeseries y tablas district/building KPIs	Respuesta a PE.1/OE.1/HE.1.
VD: gestion coordinada	D-VD.2 Emisiones de CO2	emisiones, carbon intensity y consumo ponderado por carbono	timeseries y KPI de emisiones	Respuesta a PE.2/OE.2/HE.2.
VD: gestion coordinada	D-VD.3 Costos energeticos	costo electrico, tarifa TOU y costo acumulado	timeseries y KPI de costos	Respuesta a PE.3/OE.3/HE.3.

Nota. La tabla representa la correspondencia entre problema, objetivos, hipotesis, variables y alcances del planteamiento. Fuente: Elaboracion propia a partir de la formulacion del problema, objetivos e hipotesis definidos en el Capitulo 1.

1.4.1 Criterios de determinacion del impacto

Para cumplir el OG y los OE.1–OE.3, y para demostrar las hipotesis, la tesis exige el conjunto completo de criterios de determinacion del impacto (C1–C5). Uno de ellos —C5— es el control de recursos energeticos (BESS, EV/V2G y carga desplazable). Los tres ejes se reportan a nivel de distrito y a nivel de edificio (evidencia Cap. 5).

Id	Criterio	Medida / prueba	Rol

C1	Impacto vs baseline	Wilcoxon KPI-gains vs cero + Holm	Inferencial HE
C2	Diferencias entre algoritmos	Kruskal-Wallis / Friedman + Holm	Inferencial HE
C3	KPIs fisicos de distrito por eje	flex_composite / delta CO2 / delta costo (OE.1-OE.3)	Descriptivo distrito
C4	KPIs desagregados por edificio por eje	17 edificios x E1/E2/E3	Descriptivo edificio
C5	Control de recursos	BESS, EV/V2G, carga desplazable (acciones y exito EV)	Obligatorio (atribuibilidad)

Tabla 1.3. Criterios completos de determinacion del impacto (C5 = control de recursos; evidencia Cap. 5).

Regla de cumplimiento sin parciales: OG/OE.1–OE.3 y la demostracion de hipotesis exigen C1–C5. Cada eje se reporta a nivel distrito y a nivel edificio. C5 (control de recursos) es obligatorio para atribuir el impacto a las acciones MADRL sobre BESS, EV/V2G y carga desplazable.

1.5 Justificacion

Tecnica: aporta una evaluacion unificada de HAPPO, MASAC, MATD3 y MAAC bajo Dec-POMDP y CTDE, avanzando el estado del arte en control energetico cooperativo. La mejora incorporada consiste en hacer explicita la relacion entre esa evaluacion y los artefactos reales del proyecto: results, timeseries, traces, checkpoints, KPIs distritales, KPIs por edificio y figuras generadas desde la corrida Drive.

Ambiental: identificar el mejor MADRL para reduccion de CO2 contribuye a la descarbonizacion de comunidades grid-interactive, con aplicabilidad al SEAI Iquitos (factor de emision 0.790 kgCO2/kWh). Esta justificacion se mantiene porque OE.2 y PE.2 se responden

con indicadores de emisiones reales derivados de la simulacion y no con estimaciones externas inventadas.

Economica: establecer el mejor MADRL para optimizacion de costos orienta la reduccion del gasto electrico bajo tarifas TOU. En la tesis, esta justificacion se concreta mediante KPIs de costo, series de costo distrital y comparacion por algoritmo/escenario, preservando el vinculo con OE.3.

Metodologica: la formulacion Dec-POMDP, el esquema CTDE y el benchmark unificado con CityLearn v3 propuesto, MARLlib y Optuna constituyen una contribucion reproducible. La reproducibilidad se refuerza con el uso de scripts locales, CSV materializados y resultados Drive auditables.

Cientifica y social: llena una laguna en la literatura comparativa de MADRL y beneficia a usuarios institucionales y a la transicion energetica comunitaria. Esta justificacion no se presenta como promesa de despliegue real, sino como evidencia experimental en simulacion computacional con alcance claramente delimitado.

1.6 Alcances y limitaciones

Alcances:

Tematico: comparacion de HAPPO, MASAC, MATD3 y MAAC en KPIs de flexibilidad, CO2 y costos.

Espacial: comunidades inteligentes simuladas en CityLearn v2 / CityLearn v3 propuesto, con aplicabilidad al SEAI Iquitos (17 edificios reales).

Temporal: dataset horario 2023-2025 (26 304 pasos) y literatura 2015-2026.

Metodologico: estudio cuantitativo, aplicado, comparativo, basado en simulacion cuasiexperimental.

Computacional: Python 3.9, PyTorch 2.8.0+cu126, CityLearn v2, MARLlib, Optuna, Gymnasium, PettingZoo; hardware local NVIDIA RTX 4060 Laptop 8 GB y Colab A100.

Limitaciones:

No se modela una red electrica fisica; los resultados de simulacion no constituyen validacion de despliegue real.

CityLearn v3 propuesto es una extension experimental de tesis, no una version oficial de CityLearn.

Se excluyen el despliegue en campo en tiempo real, la investigacion con sujetos humanos, el despacho economico de unidades fisicas y el analisis de estabilidad de red.

La inferencia se interpreta dentro de la corrida canonica Drive y no como generalizacion absoluta a multiples semillas independientes. Esta precision mejora la version final sin alterar sus alcances reales.

1.7 Validacion estructural y triangulacion del planteamiento

El Capitulo 1 cumple la estructura minima exigida para una tesis aplicada: formula el problema de investigacion, declara objetivos, hipotesis, justificacion, alcances y limitaciones. La coherencia interna se sostiene porque el problema no se define como una deficiencia algoritmica aislada, sino como una tension entre gestion descentralizada, flexibilidad energetica, emisiones de CO2 y costos en una comunidad electrica aislada. Este encuadre es consistente con la literatura de CityLearn, que plantea la necesidad de entornos reproducibles para comparar controladores de respuesta a la demanda, con CityLearn v2, que amplia la evaluacion hacia comunidades grid-interactive, resilientes y carbon-aware, y con EVLearn, que subraya que la integracion de vehiculos electricos requiere simulacion especifica de flexibilidad de carga y descarga (Vázquez-Canteli et al., 2020; Nweye et al., 2024; Fonseca et al., 2024).

La pregunta general y las preguntas especificas quedan operacionalizadas en tres dimensiones dependientes. PE.1 se vincula con flexibilidad energetica, PE.2 con emisiones de CO2 y PE.3 con costos energeticos. Esta separacion evita que el desempeno del algoritmo se reduzca a una recompensa unica sin interpretabilidad; por el contrario, permite contrastar la variable independiente MADRL contra indicadores observables por distrito, edificio y escenario. La triangulacion entre CityLearn, MARL energetico y evaluacion estadistica de RL justifica que el estudio reporte resultados descriptivos e inferenciales, y que declare como limitacion la ausencia de multiples semillas independientes en lugar de sobregeneralizar una unica corrida experimental (Henderson et al., 2018; Agarwal et al., 2021; Nweye et al., 2024).

Tabla 1.7

Validacion del Capitulo 1 frente a la estructura minima

Elemento requerido	Estado	Refuerzo incorporado
Problema de investigacion	Cumple	Se alinea con flexibilidad, carbono y costo en comunidad aislada.
Objetivos	Cumple	OG y OE.1-OE.3 mantienen correspondencia con PE.1-PE.3.
Hipotesis	Cumple	Se conservan por tratarse de diseno experimental comparativo.
Justificacion	Cumple	Se refuerza con reproducibilidad CityLearn y necesidad de evaluacion estadistica.
Alcances y limitaciones	Cumple	Se explicita la lectura intra-corrida y la no extrapolacion multi-semilla.

Nota. La tabla representa la correspondencia entre problema, objetivos, hipotesis, variables y alcances del planteamiento. Fuente: Elaboracion propia a partir de la formulacion del problema, objetivos e hipotesis definidos en el Capitulo 1.

Capitulo 2. Marco teorico

El marco teorico de esta tesis se organiza en cinco bloques secuenciales: (1) fundamentos teoricos y matematicos del aprendizaje por refuerzo multiagente; (2) definicion operativa y triangulacion bibliografica de la variable independiente (VI) y la variable dependiente (VD); (3) bases teoricas por eje (flexibilidad, CO2, costos y algoritmos MADRL); (4) antecedentes internacionales y nacionales; y (5) definicion de terminos y posicion teorica. Esta secuencia responde a OE.1, OE.2, OE.3 y al objetivo general, y conecta directamente con la operacionalizacion del Capitulo 3 (Seccion 3.4) y la contrastacion del Capitulo 5.

La literatura revisada confirma que la gestion energetica de edificios ha transitado desde control basado en reglas hacia control por aprendizaje, y desde agentes centralizados hacia coordinacion multiagente. Sin embargo, tambien muestra una brecha: los estudios suelen evaluar un algoritmo, una metrica dominante o un conjunto limitado de edificios, mientras que esta tesis compara HAPPO, MASAC, MATD3 y MAAC bajo el mismo dataset, los mismos escenarios E1/E2/E3, la misma funcion de recompensa y el mismo protocolo de evidencia. Esa brecha teorica justifica el disecuasiexperimental del Capitulo 3 y la contrastacion del Capitulo 5.

2.1 Fundamentos teoricos y matematicos

2.2.1 Aprendizaje por refuerzo y MADRL

El aprendizaje por refuerzo modela un problema de decision secuencial donde un agente observa un estado, ejecuta una accion, recibe una recompensa y modifica su politica para maximizar retorno acumulado. Sutton y Barto (2018) formalizan este marco mediante procesos de decision de Markov, lo que permite definir estado, accion, transicion, recompensa y factor de descuento. En la tesis, esta base se proyecta a un sistema energetico donde las acciones representan cargar o descargar BESS, regular cargadores EV y desplazar cargas controlables.

El aprendizaje por refuerzo profundo incorpora aproximadores neuronales para politicas y funciones de valor, permitiendo espacios de estado y accion de alta dimension. Haarnoja et al. (2018) introducen Soft Actor-Critic como algoritmo off-policy de maxima entropia, base conceptual para MASAC y para enfoques donde la exploracion es crucial. Esta propiedad es importante en comunidades energeticas porque los agentes deben descubrir estrategias de coordinacion bajo incertidumbre temporal y recompensas multiobjetivo.

En un sistema multiagente, cada politica modifica el entorno efectivo que observan las demas. Esto genera no estacionariedad desde la perspectiva individual: un edificio aprende mientras los demas tambien cambian su comportamiento. Oliehoek y Amato (2016) formalizan esta dificultad en el marco Dec-POMDP, mientras la literatura de CTDE responde permitiendo criticos centralizados durante el entrenamiento y politicas descentralizadas durante la ejecucion (Lowe et al., 2017). En la tesis, cada edificio debe operar con observacion local, pero el aprendizaje puede usar informacion del distrito para internalizar picos, rampas, emisiones y costos agregados.

La cooperacion se implementa mediante una recompensa mixta que combina recompensa individual y recompensa de equipo. Esto evita dos extremos: politicas totalmente egoistas que reducen el costo de un edificio desplazando problemas al distrito, y politicas totalmente globales que ignoran la heterogeneidad operativa de cada edificio. La formulacion cooperativa se alinea con los desafios descritos por Nweye et al. (2022) y con la necesidad de coordinacion observada en demanda respuesta multiagente (Yao et al., 2023; Xie et al., 2023).

2.2.2 Formalizacion matematica Dec-POMDP

El Decentralized Partially Observable Markov Decision Process (Dec-POMDP) permite formalizar decision cooperativa con informacion local incompleta. Oliehoek y Amato (2016) lo

definen como una estructura donde N agentes comparten un criterio cooperativo comun, pero cada uno recibe observaciones parciales del estado global. Esta tesis adopta esa formulacion porque ningun edificio del SEAI Iquitos observa completamente el estado interno de los demas durante la ejecucion: cada agente ve su demanda, PV, BESS, EV, precio, intensidad de carbono y variables locales, pero no accede a temperatura, SOC, demanda ni perfiles EV de los otros edificios.

El problema de tesis se modela como el Dec-POMDP cooperativo M, definido por la tupla siguiente (Oliehoek y Amato, 2016; Sutton y Barto, 2018):

M = <S, {A_i}_{i=1}^N, T, R, {O_i}_{i=1}^N, Omega, gamma, T_hor>

donde N = 17 edificios institucionales/comerciales del dataset citylearn_iquitos_2023_2025, gamma = 0.9999 (factor de descuento para episodios de 8 760 pasos horarios) y T_hor = 8 760 (un ano simulado). El objetivo cooperativo es maximizar el retorno esperado J(pi) = E[sum_{t=0}^{T_hor-1} gamma^t R_t], donde pi = (pi_1, ..., pi_N) denota el conjunto de politicas locales. La Tabla 2.2 resume la notacion formal; la operacionalizacion computacional se desarrolla en el Capitulo 4 sin alterar esta definicion teorica.

Tabla 2.2

Notacion formal del Dec-POMDP cooperativo (SEAI Iquitos, N = 17)

Simbolo	Definicion teorica	Valor / rango en esta tesis
N	Numero de agentes cooperativos (edificios)	17
S	Espacio de estado global	Concatenacion s = [o_1, ..., o_17]; dim global = 1 856
O_i	Espacio de observacion local del agente i	Heterogeneo: 54-327 dimensiones (medido CityLearnEnv; flota EV por

		edificio)
A_i	Espacio de accion local del agente i	Heterogeneo: 5-44 dims; d_ai = 2 + n_i^ch (BESS + EV por toma + lavadora); suma distrital = 219
T	Funcion de transicion estocastica S x A -> Delta(S)	Balance energetico, modelo RC, BESS eta_RT = 0.9025, EV estocastico
Omega	Funcion de observacion O_i = Omega_i(s, a)	Proyeccion parcial del estado global a informacion local
R	Recompensa cooperativa escalar o vector mixto	CityLearnV3MADRLRewardFunction; agregacion team_mean
gamma	Factor de descuento	0.9999
T_hor	Horizonte temporal del episodio	8 760 pasos (1 h/paso)
pi_i	Politica descentralizada del edificio i	pi_i(a_i | o_i); sin comunicacion inter-edificio

Nota. La tabla representa la formalizacion teorica del problema multiagente y sus elementos matematicos. Fuente: Elaboracion propia a partir de Oliehoek y Amato (2016), Lowe et al. (2017) y los artefactos del entorno CityLearn usado en la tesis.

Recompensa cooperativa multiobjetivo. La funcion R materializa los tres ejes de tesises (flexibilidad, CO2, costos) mediante una recompensa escalar por edificio y paso, con agregacion cooperativa tipo media de equipo. A nivel teorico:

*reward_i(t) = reward_scale * [w_flex * flex_i(t) + w_carbon * carbon_i(t) + w_cost * cost_i(t) + w_ev * ev_i(t)]*

El componente flex_i(t) penaliza, a nivel distrital compartido, el pico y la rampa mediante peak_share(t) = district_import(t) / N y ramp_share(t) = |district_import(t) - district_import(t-1)| / N, con funciones de suavizado tanh; carbon_i(t) pondera la importacion por la intensidad de carbono CI(t); cost_i(t) refleja la tarifa TOU mediante price_norm(t); y ev_i(t)

incorpora urgencia de SOC y salida de vehiculos. Los pesos w_flex, w_carbon y w_cost se condicionan por escenario experimental (E1/E2/E3) segun la Tabla 3.1 del Capitulo 3.

$$team_reward(t) = (1/N) * sum_{i=1}^{N} reward_i(t)$$

$$mixed_reward_i(t) = (1 - r) * reward_i(t) + r * team_reward(t), \quad con\ r = 0.70$$

La mezcla cooperativa con team_reward_ratio r = 0.70 evita politicas puramente egoistas (que desplazan picos o costos al distrito) y politicas puramente globales (que ignoran heterogeneidad operativa). Este esquema se alinea con la literatura de recompensa hibrida en MADRL energetico (Yao et al., 2023; Liu et al., 2022) y con los desafios de coordinacion identificados por Nweye et al. (2022). Durante la ejecucion descentralizada, cada politica $pi_i(a_i | o_i)$ actua solo con o_i; el estado global s solo es accesible durante el entrenamiento bajo CTDE (Seccion 2.3.4).

2.2.3 Dec-POMDP como formalizacion del problema de tesis

La gestion energetica estudiada no es un problema de control centralizado simple, porque la decision de cada edificio modifica la demanda agregada, el costo, las emisiones y las condiciones de flexibilidad que observan los demas agentes. Tampoco es un MDP plenamente observable por agente individual: cada edificio observa su propio estado operativo, disponibilidad de equipos, senales temporales y variables exogenas, pero no controla directamente la demanda base ni las restricciones internas de los otros edificios. Por ello, la formalizacion de tesis adecuada es un Proceso de Decision de Markov Parcialmente Observable Descentralizado (Dec-POMDP), que permite representar ejecucion descentralizada, observabilidad parcial, transiciones estocasticas y recompensa cooperativa.

La formulacion utilizada en la tesis se expresa como $M = \langle S, \{A_i\}_{i=1}^{17}, T, R, \{O_i\}_{i=1}^{17}, Omega, gamma, H \rangle$. El estado global S contiene la concatenacion de

observaciones locales s_t=[o_1,t,...,o_17,t]; las acciones A_i son heterogeneas por edificio; T representa la dinamica horaria de CityLearn, incluyendo clima, PV, BESS, llegada/salida de vehiculos electricos, demanda base, precio y senal de carbono; R es una recompensa cooperativa con mezcla local-equipo; O_i y Omega modelan la observabilidad parcial; gamma=0.9999 preserva dependencia de largo horizonte; y H=8760 pasos representa un ano horario de evaluacion por episodio.

La operacionalizacion empirica no queda en una abstraccion generica. En los artefactos Drive, el Dec-POMDP tiene 17 agentes-edificio, dimensiones locales de observacion entre 54 y 327, dimension global agregada 1856, acciones locales entre 5 y 44 y 219 dimensiones de accion por tratamiento. Las acciones controlan BESS, cargadores EV y cargas flexibles declaradas en building_observation_action_schema.csv; la demanda no controlada permanece como perturbacion/observacion dentro de la demanda base, no como actuador directo.

Jerarquia distrito / edificio del Dec-POMDP (valores medidos en CityLearnEnv sobre citylearn_iquitos_2023_2025). No existe un agente-distrito que emita setpoints: el control distrital es emergente de 17 politicas locales.

Nivel edificio (agente i): observacion local o_i en R^{d_oi} con d_oi en [54, 327] (calendario, meteo, carga, termica, PV, SoC BESS, precio/CI y 7 canales EV por cargador); accion a_i con d_ai = 2 + n_i^ch en [5, 44] (electrical_storage + electric_vehicle_storage x n_ch + washing_machine); politica pi_i(a_i | o_i) sin ver o_j.

Nivel distrito (comunidad SEAI / critico CTDE): estado global s = [o_1, ..., o_17] en R^{1856} (= suma exacta de d_oi), visible solo en entrenamiento; agregados P^com(t) = sum_i P_i^net(t), pico/rampa distritales y KPIs evaluate_v2; team_reward = mean(reward_i) y mixed_reward_i =

(1 - r_team)*reward_i + r_team*team_reward con r_team = 0,70 (perfil unified_comparable_v4).

gamma = 0,9999; T = 8 760.

Tabla 2.A — Dimensiones Dec-POMDP reales por edificio

IDif.	Edificio	Cat.	d_rig.	d_ai Eo V	d_ai Eo A.
B01	Electro Oriente S. A.	E	4	6	6
B02	Metro Oriente S. A.	M	6	7	8

0	u		5	
2	n			
	i			
	c.			
	S			
	a			
	n			
	J			
	u			
	a			
	n			
	B			
	a			
	u			
	ti			
	st			
	a			
B	A	8	8	1
0	e		9	0
3	r			
	o			
	p			
	u			
	e			
	rt			
	o			
	I			
	n			

t

e

r

n

a

c

i

o

n

a

l

B H 6 7 8

0 i 5

4 p

e

r

m

e

r

c

a

d

o

s

T

o

tt

u

	s			
B	H	3	5	5
0	o		4	
5	t			
	e			
	l			
	P			
	l			
	a			
	z			
	a			
	S			
	.			
	A			
	.			
B	M	3	2	3
0	a	2	5	4
6	ll		7	
	A			
	v			
	e			
	n			
	t			
	u			
	r			
	a			
B	U	4	3	4
0	N	2	2	4

7 A 7

P

B

i

o

l

o

g

i

a

B P 1 1 1

0 N 7 5 9

8 P 2

E

s

c

u

e

l

a

T

e

c

n

i

c

a

B G 1 1 1

0 O 0 0 2
9 R 3
E
L
o
r
e
t
o
C
O
E
R
B G 6 7 8
1 o 5
0 b
i
e
r
n
o
R
e
g
i
o
n
a

	l L o r e t o			
B 1 1	H o s p it a l R e g i o n a l	3	5 4	5
B 1 2	E s S a l u	3	5 4	5

	d			
B	U	1	1	1
1	N	1	1	3
3	A		0	
	P			
	C			
	s.			
	E			
	c			
	o			
	n			
	o			
	m			
	i			
	c			
	a			
	s			
B	A	4	6	6
1	u		1	
4	t			
	o			
	ri			
	d			
	a			
	d			
	P			
	o			
	rt			

u

a

ri

a

B D 8 8 1

1 R 9 0

5 E

L

C

o

l

e

g

i

o

N

a

c

i

o

n

a

l

B S 1 1 1

1 I 1 1 3

6 M 0

A

	Iquitos			
B17	Aso. Civil Selva Amazonica	111	111	13

Distrito_oid_=_dsumaacciones	s	1	1	2
	u	8	8	1
	m	5	5	9
	a		6	
	d			
	_			
	o			
	i			
	=			
	d			
	_			
	s;			
	s			
	u			
	m			
	a			
	a			
	c			
	c			
	i			
	o			
	n			
	e			
	s			

Nota. Dimensiones medidas con CityLearnEnv(schema Iquitos, central_agent=False). Fuente: elaboracion propia a partir del dataset citylearn_iquitos_2023_2025.

Esta formalizacion enlaza directamente el problema general y los objetivos especificos. OE.1 evalua la respuesta del Dec-POMDP cuando la recompensa prioriza flexibilidad; OE.2

cuando prioriza emisiones de CO2; y OE.3 cuando prioriza costos energeticos. La variable independiente no es solo el nombre del algoritmo, sino la politica MADRL aprendida bajo CTDE y bajo pesos de recompensa comparables. La variable dependiente se observa mediante KPIs distritales y por edificio, por lo que el Dec-POMDP justifica simultaneamente el entrenamiento multiagente y la lectura de resultados por distrito, edificio, escenario y KPI.

La Figura 2.1 sintetiza la formalización teórica precedente: el entorno físico CityLearn v2 (edificio, DER, red y comunidad), la interfaz de control Actor–Crítico bajo CTDE y la tupla Dec-POMDP cooperativa instanciada en el SEAI Iquitos.

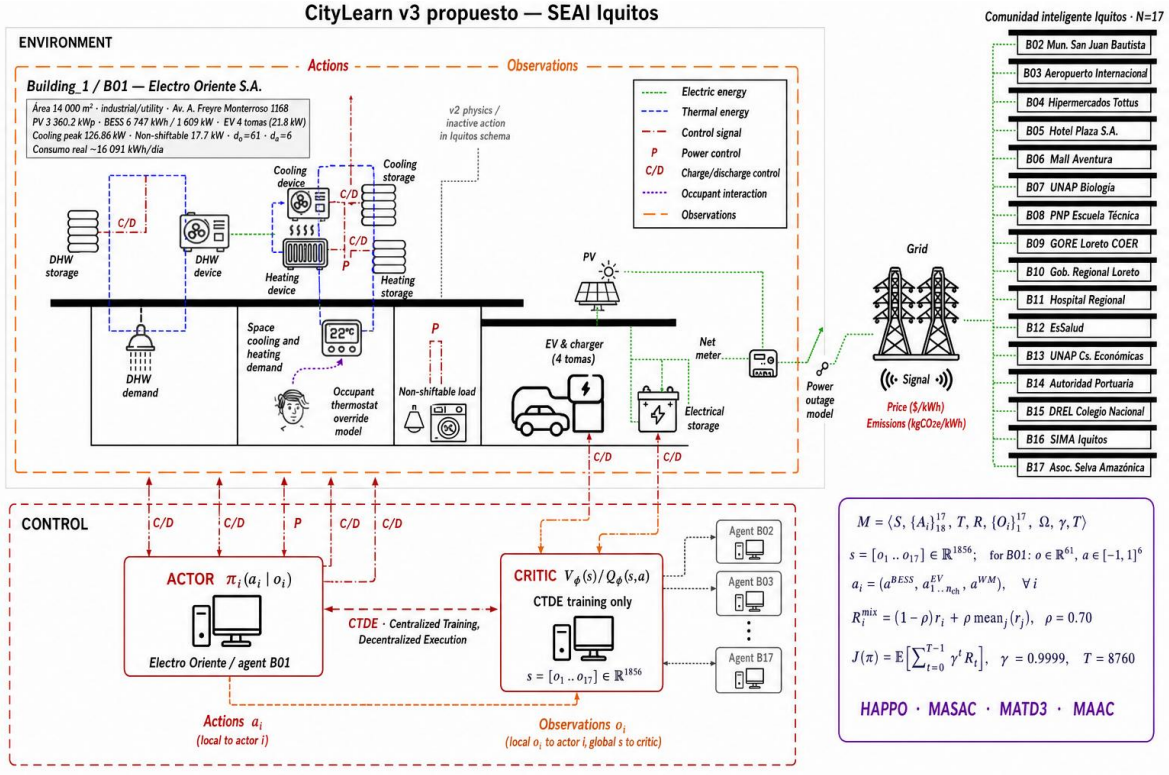


Figura 2.1. Control por edificio CityLearn v3 propuesto (simbología CityLearn v2): Electro Oriente S.A. (B01), comunidad inteligente Iquitos (B02–B17), red pública/SEAI, Actor–Crítico CTDE y formulación Dec-POMDP.

Nota. Adaptación de la Fig. 1 de CityLearn v2 (Nweye et al., 2024) a la capa CityLearn v3 propuesto de esta tesis. Se conserva la simbología oficial (energía eléctrica = línea verde punteada; energía térmica = azul discontinua; señal de control = rojo dash-dot con P/C/D; interacción del ocupante = morada punteada; observaciones = naranja long-dash). Building_1/B01 muestra datos reales de Electro Oriente S.A. (PV 3 360,2 kWp; BESS 6 747 kWh / 1 609 kW; 4 tomas EV; d_o = 61; d_a = 6). La

comunidad lista B02–B17 con etiquetas del dataset citylearn_iquitos_2023_2025. En CONTROL, el Actor π_i(a_i|o_i) ejecuta de forma descentralizada y el Crítico V/Q opera solo en entrenamiento CTDE con s = [o_1,…,o_17] ∈ ℝ^1856. Acciones MADRL activas: electrical_storage, electric_vehicle_storage y washing_machine; el bloque térmico v2 se mantiene como física (acciones cooling/heating/DHW inactivas en el schema Iquitos). Fuente: elaboración propia a partir de Nweye et al. (2024), Oliehoek y Amato (2016), Lowe et al. (2017) y artefactos del proyecto (docs/architecture/CITYLEARN_V3_CONTROL_EDIFICIO_ACTOR_CRITIC.png).

Tabla 2.3

Mapeo del Dec-POMDP de tesis a artefactos reales del proyecto

Elemento	Operacion en la tesis	Evidencia local
Agentes	Edificios institucionales/comerciales de la comunidad	17 agentes en building_behavior_summary.csv
Estado global S	Concatenacion de observaciones locales para critic/entrenamiento CTDE	suma observation_dim=1856
Observacion local O_i	Informacion parcial disponible para cada actor	rango observado 54-327 variables
Accion A_i	Control descentralizado de equipos flexibles	rango observado 5-44; total=219
Transicion T	Dinamica horaria de CityLearn: clima, PV, BESS, EV, precio, carbono y demanda	timeseries.csv y traces por tratamiento
Recompensa R	Funcion multiobjetivo comparable por escenario E1/E2/E3	pesos flex/CO2/costo y agregacion team_mean
Horizonte H	Evaluacion anual horaria por episodio	8760 pasos horarios
Descuento gamma	Persistencia de efectos diferidos de almacenamiento y carga EV	gamma=0.9999

Nota. La tabla representa la formalizacion teorica del problema multiagente y sus elementos matematicos. Fuente: Elaboracion propia a partir de Oliehoek y Amato (2016), Lowe et al. (2017) y los artefactos del entorno CityLearn usado en la tesis.

2.2.4 CityLearn y simulacion multiobjetivo

CityLearn constituye la linea de simulacion mas directamente vinculada con esta tesis. Vázquez-Canteli y Nagy (2019a) introdujeron CityLearn v1.0 como entorno compatible con OpenAI Gym para respuesta a la demanda en edificios, mostrando que un agente de aprendizaje

profundo podia superar politicas basadas en reglas en reduccion de pico. Posteriormente, Vázquez-Canteli y Nagy (2019b) sistematizaron algoritmos y tecnicas de modelado para respuesta a la demanda con aprendizaje por refuerzo, y Vázquez-Canteli et al. (2020) reforzaron la necesidad de estandarizar entornos, KPIs y comparaciones en gestion energetica urbana.

La evolucion hacia CityLearn v2 es decisiva porque integra edificios grid-interactive, almacenamiento, PV, vehiculos electricos, senales de carbono y costos. Nweye et al. (2024) presentan CityLearn v2 como entorno para gestion energetica flexible, resiliente, centrada en ocupantes y consciente de carbono; Nweye et al. (2023c) describen su formalizacion como entorno Gym para benchmarking de respuesta a la demanda; y Nweye y Nagy (2024b) amplian el uso de CityLearn Gym a evaluacion multiobjetivo. Esta tesis toma CityLearn v2 como base validada, pero no afirma que CityLearn v3 exista oficialmente: CityLearn v3 propuesto es una extension experimental desarrollada para el Dec-POMDP, CTDE y backends MADRL del proyecto.

El paso de entornos de un edificio a comunidades heterogeneas demanda tratar problemas de escala, observabilidad parcial y no estacionariedad. Nweye et al. (2022) identifican desafios reales del aprendizaje por refuerzo multiagente en edificios grid-interactive, incluyendo generalizacion, seguridad, heterogeneidad, interaccion con ocupantes y reproducibilidad. Nweye et al. (2023a) proponen MERLIN para aprendizaje offline y transferencia en comunidades de 17 edificios, escala comparable al caso SEAI Iquitos, mientras Nweye et al. (2023b) aplican aprendizaje por refuerzo heterogeneo multiagente en comunidades grid-interactive. Estos antecedentes justifican que la unidad de analisis no sea un edificio aislado, sino una comunidad de 17 agentes.

2.2.5 CityLearn v3 propuesto y distincion UC3M (7 ejes vs 3 ejes)

CityLearn v3 propuesto es la extension experimental de esta tesis sobre CityLearn v2 (Nweye et al., 2024): conserva fisica y KPIs evaluate_v2, y agrega el contrato Dec-POMDP/CTDE, objetivos OE.1–OE.3, recompensa multiobjetivo y adaptadores a backends MADRL en external/. Modulos: v3/environment.py, v3/objectives.py, v3/config.py, v3/backends.py y CityLearnV3MADRLRewardFunction (perfil unified_comparable_v4).

El sustento formal agent-skills/madrl-sustento-doc-capa v3/madrl-modeladomatematico.md y el paquete uc3m/ axiomatizan un operador holistico de siete ejes (CO2, costo, flexibilidad, confort, degradacion BESS, resiliencia, ACS) con BACT y HPHI. Las 12 corridas canónicas operacionalizan solo OE.1/OE.2/OE.3. Mapeo: UC3M-1↔OE.2, UC3M-2↔OE.3, UC3M-3↔OE.1; ejes 4–7 son sustento, no evidencia Cap. 5. Parametros: N=17, gamma=0,9999, T=8 760, r_team=0,70.

2.2.6 Formalizacion matematica del Meta-Dec-POMDP UC3M

Fuente: madrl-modeladomatematico.md (adaptado a Cap. 2). El Meta-Dec-POMDP UC3M es la tupla 11-aria M_UC3M = <I, S, A, O, T, R, Z, gamma, H, b0, Lambda>, que extiende Oliehoek y Amato (2016) con vector R=(r^(1),...,r^(7)) y simplex Lambda. En Iquitos N=17, gamma=0,9999, H=8 760. La ejecucion restringe Lambda al subsimplex OE.1/OE.2/OE.3.

Definicion 2.1 (BACT): B en R^{N x Ka x Kc x Kb} codifica activos, clima y constructivo (uc3m/env/bact.py). Observaciones parciales: carga, termica, PV, SoC, EV, tarifas, CI y meteorologia; acciones en [-1,1]^{d_ai} heterogeneas. Prop. 2.1: S compacto. Lema 2.2: R escalarizada Borel-medible y acotada. Nucleo T factorizado exogeno (clima/red) x endogeno por edificio.

2.2.7 Operador de recompensa holistico, Pareto y convergencia

Definicion 2.2: R_i = -sum_k lambda_k * r_i~(k) con normalizacion a base RBC. Teorema 2.3: V_pi existe y |V|<=M/(1-gamma). Prop. 2.4: Lipschitz con L=sum lambda_k L_k. Teorema 2.5: existencia de frontera de Pareto si Pi compacto (Roijers et al., 2013). Definicion 2.4 (HPHI): hipervolumen 7-D normalizado (uc3m/reward/hphi.py); esta tesis no ejecuta HPHI 7-D en Cap. 5. Prop. 2.6: CTDE mitiga no-estacionariedad (Lowe et al., 2017); HAPPO/HATRPO bajo Zhong et al. (2023) y Kuba et al. (2022).

2.2.8 Modelado fisico-matematico de los ejes operacionales

Ejes ejecutados: UC3M-1/OE.2 (CO2 marginal + desplazamiento EV), UC3M-2/OE.3 (costo TOU Electro Oriente + potencia), UC3M-3/OE.1 (ramping y picos vs umbral DSO; KPIs peak/ramping/load_factor). Ejes de sustento (no Cap. 5): 4 confort adaptativo De Dear-Brager, 5 degradacion Arrhenius-SEI/Peukert, 6 resiliencia isla (CCI/LOLP), 7 ACS con perdidas UA. Balance Kirchhoff: P_net = P_load + P_HP + P_EH + P_BESS + P_EV - P_PV - P_wind.

2.2.9 Arquitectura MARLlib-CTDE y universalidad algoritmica (sustento)

MARLlib (Hu et al., 2023) y el plugin algoritmico UC3M P=<Theta, Phi, L_actor, L_critic, U_step, B> sustentan universalidad via AlgorithmFactory (uc3m/). CTDE: pi_i(a_i|o_i) descentralizado y Q_centr(s,a) centralizado. HAPPO, MASAC, MATD3 y MAAC son instancias; el launcher de 12 corridas usa wrappers CityLearn/scripts/ + external/, no UC3MEnv/MARLlib como canal de entrenamiento.

2.2.10 Adecuaciones de los cuatro backends MADRL al dominio electrico (OE.1 flexibilidad, OE.2 CO2, OE.3 costos)

Premisa. Los backends oficiales pinados en external/ (HARL/HAPPO, MARL/src-MASAC, off-policy/MATD3 y MAAC) fueron disenados, validados y entrenados de forma predominante en

dominios de referencia multiagente (p. ej. SMAC/StarCraft, MPE u otros benchmarks MARL). En su forma original no estan preparados, ni entrenados, ni aplicados out-of-the-box al control de una comunidad electrica con DER, EV/V2G y senales horarias de precio e intensidad de carbono. Por tanto, no resuelven por si solos el problema de esta tesis: flexibilidad energetica (OE.1), emisiones de CO2 (OE.2) y costos economico-energeticos (OE.3) sobre el SEAI Iquitos.

La contribucion teorica no consiste en reinventar HAPPO, MASAC, MATD3 o MAAC, sino en adecuarlos —via la capa CityLearn v3 propuesto, el adaptador comun citylearn_v3_training_common.py y wrappers tipados— a un Dec-POMDP cooperativo de 17 edificios heterogeneos, recompensa multiobjetivo unificada (CityLearnV3MADRLRewardFunction, perfil unified_comparable_v4) y evaluacion con KPIs oficiales evaluate_v2. El Cap. 4 documenta la implementacion; esta seccion fija el sustento teorico de cada adecuacion.

Capa comun de adecuacion (los cuatro MADRL): (i) contrato Dec-POMDP/CTDE con estado global s en R^{1856}; (ii) padding / policy mapping ante heterogeneidad d_oi en [54, 327] y d_ai en [5, 44]; (iii) recompensa multiobjetivo con escenarios E1/E2/E3 y r_team = 0,70; (iv) dataset citylearn_iquitos_2023_2025 (BESS, PV, 185 cargadores EV, TOU Electro Oriente, CI dinamico); (v) orquestacion train_citylearn_v3_{happo,masac,matd3,maac}.py bajo matriz 4x3 comparable.

HAPPO — CityLearnHARLEnv + external/HARL. El HAPPO original (Kuba et al., 2021; Zhong et al., 2023) aporta actualizacion secuencial con trust region para agentes heterogeneos, pero HARL espera un ShareVecEnv de juegos multiagente, no setpoints BESS/EV. Adecuacion: wrapper CityLearnHARLEnv con observacion local continua y share_observation_space = estado CTDE; acciones continuas en [-1,1]^{d_ai} (BESS + EV + lavadora); recompensa mixta

del perfil v4; script train_citylearn_v3_happo.py. Teoricamente es el candidato on-policy a la heterogeneidad tipologica del SEAI.

MASAC — CityLearnSMACDiscreteEnv + external/MARL/src. El backend MASAC/mSAC asume API tipo SMAC (get_obs, get_state, acciones discretas). CityLearn expone control continuo multidimensional. Adecuacion: adaptador SMAC-like con get_state() = s CTDE; discretizacion action_bins=3 y discrete_action_mode=axis (base un-eje + no-op; no producto cartesiano 3^{d_ai}, inviable con d_ai hasta 44); mezcla cooperativa tipo QMIX sobre la recompensa energetica de equipo; script train_citylearn_v3_masac.py. Aporta exploracion entropica off-policy sobre un espacio de accion energetico tractable.

MATD3 — CityLearnOffPolicyVecEnv + external/off-policy. El repositorio autor (external/MATD3implementation, TensorFlow 1.x / Python 3.6) no es el stack de entrenamiento: se adecua via backend PyTorch marlbenchmark/off-policy (clases MATD3 / R_MATD3). Adecuacion: wrapper vectorizado de un hilo; acciones continuas con doble critico, policy delay y target noise sobre actuadores BESS/EV; policy_mapping_fn y padding para 17 politicas heterogeneas; script train_citylearn_v3_matd3.py. Es el candidato deterministico off-policy al control continuo distrital.

MAAC — CityLearnMAACVecEnv + external/MAAC. MAAC (Iqbal y Sha, 2019) introduce atencion multi-cabeza en el critico para dominios donde la relevancia entre agentes cambia; no trae de fabrica recompensa de pico/rampa/CO2/TOU. Adecuacion: wrapper que expone observaciones por agente al mecanismo de atencion; misma discretizacion eje-wise que MASAC (bins=3); atencion sobre los 17 edificios heterogeneos bajo recompensa v4; script train_citylearn_v3_maac.py. Operacionaliza coordinacion selectiva (p. ej. hospital vs mall vs campus) sin comunicacion en ejecucion.

Tabla 2.B — Adecuacion de los cuatro MADRL originales al problema electrico (OE.1 / OE.2 / OE.3)

Algoritmo	DWA-MADRL / publicacion	ACOE.1–OE.2
Algoritmo propuesto en el articulo	Si	Si
Algoritmo de referencia 1	No	Si
Algoritmo de referencia 2	No	Si
Algoritmo de referencia 3	No	Si

t .

o 3

H M C S O

A A it h n

P R y a -

P L L r p

O h e e o

e a - li

t r o c

e n b y

r H s c

o A C o

g R T o

e L D p

n E E e

e n ; r

o v a a

g / c ti

e e c v

n x i o

e t o s

ri e n o

c r c b

o n o r

(a n e

H l/ ti D

A H n E

R A u R

L R a /
) L B E
E V
S
S h
/ e
E t
V e
r
o
g
e
n
e
o
s
M S C A O
A M it P ff
S A y I -
A C L S p
C - e M o
li a A li
k r C c
e n ; y
/ S b e
a M i n
c A n tr
c C s o

i D = p
o is 3 i
n c a c
d r x o
is e is s
c t ; o
r e Q b
e E - r
t n m e
a v i c
/ x o
M e n
A n tr
R e o
L r l
/s g e
r e l
c ti e
c c
o tr
i
c
o
d
is
c
r
e

ti
z
a
d
o
M P C B O
A a it a ff
T p y c -
D e L k p
3 r e e o
T a n li
F r d c
1 n P y
; O y d
a ff T e
c P o t
ti o r e
v li c r
o c h m
: y 3 i
o V . n
ff e 9 is
- c ; ti
p E a c
o n c o
li v c c
c / i o
y o o n

P ff n ti
y - c n
T p o u
o o n o
r li ti B
c c n E
h y u S
a S
/
E
V
M A C A C
A t it t o
A e y e o
C n L n r
c e c d
i a i i
o r o n
n n n a
m M 1 c
u A 7 i
lt A a o
i C g n
a V e a
g e n t
e c t e
n E e n
t n s c

e v + i

g / b o

e e i n

n x n a

e t s l

ri e = b

c r 3 a

a n j

a o

l/ fl

M e

A x

A /

C C

O

2

/

c

o

st

o

Nota. Los backends originales no fueron preparados ni entrenados ni aplicados out-of-the-box a flexibilidad, CO2 y costos energeticos. La adecuacion se sustenta en wrappers y adaptadores del proyecto (citylearn_v3_training_common.py; Cap. 4). Fuente: elaboracion propia a partir de external/HARL, external/MARL/src, external/off-policy, external/MAAC y la capa CityLearn v3 propuesto.

En sintesis: los cuatro MADRL originales no resuelven por si solos el problema electrico multiobjetivo; las adecuaciones del proyecto (wrappers + Dec-POMDP/CTDE + recompensa

unified_comparable_v4 + dataset Iquitos + evaluate_v2) son la condicion de posibilidad teorica y operativa del cuasiexperimento 4x3 (Caps. 3–5).

2.2 Variables de la investigacion

La variable independiente (VI) y la variable dependiente (VD) se definen operativamente en esta seccion y se triangulan con autores de la bibliografia (Tabla 2.1). La triangulacion bibliografica asegura que cada dimension tenga al menos dos fuentes independientes que sustenten su definicion, siguiendo normas APA 7 en citas narrativas y parenteticas. La operacionalizacion computacional completa se desarrolla en el Capitulo 3, Seccion 3.4, que remite a esta seccion como marco conceptual.

2.3.1 Variable independiente (VI)

La variable independiente es la capa MADRL cooperativa implementada sobre CityLearn v2 (CityLearn v3 propuesto), manipulada en tres dimensiones: D-VI.1 algoritmo, D-VI.2 escenario experimental y D-VI.3 control metodologico. Sutton y Barto (2018) y Oliehoek y Amato (2016) fundamentan la formulacion Dec-POMDP cooperativa que constituye el marco comun de la VI; Lowe et al. (2017) justifican el paradigma CTDE bajo el cual se entrenan las politicas.

D-VI.1 — Algoritmo MADRL. Comprende cuatro niveles del factor experimental: HAPPO (on-policy con region de confianza para agentes heterogeneos; Kuba et al., 2021; Zhong et al., 2023), MASAC (off-policy de maxima entropia; Haarnoja et al., 2018; Gao et al., 2023), MATD3 (off-policy con doble critico centralizado; Lowe et al., 2017; Hu et al., 2023) y MAAC (critico con atencion selectiva; Iqbal y Sha, 2019). Cada algoritmo representa una familia teorica distinta de coordinacion multiagente bajo el mismo entorno y la misma funcion de recompensa.

D-VI.2 — Escenario E1/E2/E3. Los escenarios condicionan la politica hacia un objetivo dominante mediante vectores de peso distintos en la funcion de recompensa multiobjetivo. E1 prioriza flexibilidad [0,70; 0,15; 0,15] y se sustenta en KPIs de pico y rampa (Vázquez-Canteli et al., 2020; Yao et al., 2023); E2 prioriza emisiones de CO2 [0,15; 0,70; 0,15] y se fundamenta en control consciente de intensidad de carbono (Liu et al., 2022; Tranberg et al., 2020); E3 prioriza costos [0,25; 0,15; 0,60] y se ancla en respuesta a precios y cargos por demanda (Dang et al., 2023; OSINERGMIN, 2024).

D-VI.3 — Control experimental. Para aislar el efecto de D-VI.1 y D-VI.2, la tesis mantiene constantes el dataset citylearn_iquitos_2023_2025 (Nweye et al., 2024; Nweye et al., 2023a), la funcion de recompensa unified_comparable_v4, la semilla de reproducibilidad y el protocolo CTDE (Nweye et al., 2022; Hu et al., 2023). Esta dimension de control asegura que las diferencias observadas en D-VD.1, D-VD.2 y D-VD.3 se atribuyan al algoritmo y al escenario, no a variaciones del entorno o del protocolo.

2.3.2 Variable dependiente (VD)

La variable dependiente es el desempeno coordinado de la comunidad energetica medido en tres ejes: D-VD.1 flexibilidad energetica, D-VD.2 emisiones de CO2 y D-VD.3 costos energeticos. Cada eje se descompone en tres dimensiones operativas, alineadas con los KPIs oficiales de CityLearn v2 (Vázquez-Canteli et al., 2020; Nweye et al., 2024). La lectura correcta del Capitulo 5 combina las tres dimensiones de cada eje, no un KPI aislado.

D-VD.1 — Flexibilidad energetica. Dimension 1 (pico): capacidad de reducir la importacion maxima distrital, medida con peak_average. Lund et al. (2017) ubican la reduccion de pico dentro de los sistemas energeticos inteligentes, mientras Vázquez-Canteli et al. (2020) estandarizan peak_average como KPI comparable en CityLearn. Dimension 2 (rampa):

suavizado de variaciones horarias de importacion, medido con ramping_average. Nweye et al. (2024) incorporan ramping como KPI distrital en CityLearn v2, y Yao et al. (2023) reportan mejoras de coordinacion MADRL en perfiles de demanda. Dimension 3 (factor de carga): equilibrio entre pico y demanda media, medido con one_minus_load_factor_average y el indicador compuesto flex_composite. Vázquez-Canteli y Nagy (2019b) vinculan el factor de carga con respuesta a la demanda, y Xie et al. (2023) demuestran que mecanismos de atencion multiagente mejoran la suavidad del perfil agregado.

D-VD.2 — Emisiones de CO2. Dimension 1 (emisiones totales): carbon_emissions_total como indicador agregado anual del distrito. Liu et al. (2022) muestran reducciones de emisiones con MADRL en sistemas con energia renovable, y MINAM (2019) proporciona el factor de emision base para contextualizar redes aisladas peruanas. Dimension 2 (delta CO2): carbon_emissions_delta como reduccion frente a baseline CityLearn v2. Tranberg et al. (2020) fundamentan la contabilidad temporal de carbono, y Sarkar et al. (2024) aplican desplazamiento temporal de carga hacia periodos de baja intensidad de carbono. Dimension 3 (consumo ponderado por CI): importacion electrica ponderada por CI(t). Cao et al. (2023) estudian pronostico de intensidad de carbono para gestion de edificios, y Ye et al. (2025) avanzan hacia MARL seguro para operacion baja en carbono.

D-VD.3 — Costos energeticos. Dimension 1 (costo total): electricity_cost_total como indicador agregado anual. Fang et al. (2021) proponen gestion distribuida de energia en microredes mediante MADRL, y Gao et al. (2023) validan MASAC para programacion colaborativa con respuesta a precios. Dimension 2 (delta costo): electricity_cost_delta como reduccion frente a baseline. Dang et al. (2023) muestran que BESS puede reducir cargos de demanda bajo precios dinamicos, y Xiong et al. (2024) confirman que DRL puede responder a

tarifas TOU y almacenamiento. Dimension 3 (pico facturable): reduccion de demanda maxima en ventana de facturacion y desviacion respecto a la senal de precio (price_signal_deviation). OSINERGMIN (2024) justifica el uso de maxima demanda y tarifa en el contexto regulatorio peruano, y Shojaeighadikolaei et al. (2022) plantean gestion energetica distribuida y respuesta a la demanda en smart grids.

Tabla 2.1

Triangulacion bibliografica de variables independientes y dependientes (VI/VD)

Variable	Dimension	Definicion operativa	Autor(es) APA	KPI tesis
VI	D-VI.1 — Algoritmo MADRL	Capa cooperativa multiagente bajo Dec-POMDP/CTDE (HAPPO, MASAC, MATD3, MAAC).	Sutton y Barto (2018); Oliehoek y Amato (2016)	Factor experimental (4 niveles)
VI	D-VI.1 — HAPPO	On-policy con region de confianza para agentes heterogeneos.	Kuba et al. (2021); Zhong et al. (2023)	T01-T03
VI	D-VI.1 — MASAC	Off-policy de maxima entropia con exploracion robusta.	Haarnoja et al. (2018); Gao et al. (2023)	T04-T06
VI	D-VI.1 — MATD3	Off-policy con doble critico centralizado y retardo de politica.	Lowe et al. (2017); Hu et al. (2023)	T07-T09
VI	D-VI.1 — MAAC	Critico con atencion selectiva entre agentes.	Iqbal y Sha (2019)	T10-T12
VI	D-VI.2 — Escenario E1	Ponderacion dominante flexibilidad [0,70; 0,15; 0,15].	Vázquez-Canteli et al. (2020); Yao et al. (2023)	OE.1 / D-VD.1
VI	D-VI.2 — Escenario E2	Ponderacion dominante CO2 [0,15; 0,70; 0,15].	Liu et al. (2022); Tranberg et al. (2020)	OE.2 / D-VD.2
VI	D-VI.2 — Escenario E3	Ponderacion dominante costos [0,25; 0,15; 0,60].	Dang et al. (2023); OSINERGMIN (2024)	OE.3 / D-VD.3
VI	D-VI.3 — Control dataset	Dataset comun citylearn_iquitos_2023_2025 (17 edificios, 8 760 h).	Nweye et al. (2024); Nweye et al. (2023a)	Mismo schema y semilla
VI	D-VI.3 — Control protocolo	Funcion de recompensa unified_comparable_v4 y protocolo CTDE.	Nweye et al. (2022); Hu et al. (2023)	12 tratamientos 4x3

VD	D-VD.1 — Dim.1 pico	Reduccion de demanda/importacion maxima distrital.	Vázquez-Canteli et al. (2020); Lund et al. (2017)	peak_average
VD	D-VD.1 — Dim.2 rampa	Suavizado de variaciones horarias de importacion.	Nweye et al. (2024); Yao et al. (2023)	ramping_average
VD	D-VD.1 — Dim.3 factor de carga	Equilibrio entre pico y demanda media (load factor).	Vázquez-Canteli y Nagy (2019b); Xie et al. (2023)	one_minus_load_factor_average; flex_composite
VD	D-VD.2 — Dim.1 emisiones totales	Emisiones anuales agregadas del distrito.	Liu et al. (2022); MINAM (2019)	carbon_emissions_total
VD	D-VD.2 — Dim.2 delta CO2	Reduccion frente a baseline CityLearn v2.	Tranberg et al. (2020); Sarkar et al. (2024)	carbon_emissions_delta
VD	D-VD.2 — Dim.3 consumo ponderado CI	Importacion ponderada por intensidad de carbono horaria.	Cao et al. (2023); Ye et al. (2025)	CI-weighted consumption
VD	D-VD.3 — Dim.1 costo total	Costo electrico anual agregado del distrito.	Fang et al. (2021); Gao et al. (2023)	electricity_cost_total
VD	D-VD.3 — Dim.2 delta costo	Reduccion de costo frente a baseline.	Dang et al. (2023); Xiong et al. (2024)	electricity_cost_delta
VD	D-VD.3 — Dim.3 pico facturable	Reduccion de demanda maxima en ventana de facturacion.	OSINERGMIN (2024); Shojaeighadikolaei et al. (2022)	peak_billing; price_signal_deviation

Nota. La tabla representa la organizacion conceptual del marco teorico y de las variables de investigacion. Fuente: Elaboracion propia a partir de la literatura citada en el Capitulo 2.

2.3 Bases teoricas por eje

2.4.1 Flexibilidad energetica

La flexibilidad energetica se entiende como la capacidad de modificar el perfil temporal de demanda, importacion, exportacion, carga de almacenamiento y consumo flexible para aportar servicios al sistema electrico. En comunidades con PV, BESS y EV, la flexibilidad no equivale solamente a reducir demanda pico; incluye reducir rampas, mejorar factor de carga, incrementar

autoconsumo y desplazar consumo hacia periodos de mayor disponibilidad renovable. Este concepto se alinea con los KPIs peak_average, ramping_average, one_minus_load_factor_average, autoconsumo y autosuficiencia empleados en CityLearn (Vázquez-Canteli et al., 2020; Nweye et al., 2024).

Los antecedentes recientes muestran que la flexibilidad requiere coordinacion y no solo optimizacion local. Yao et al. (2023) proponen una estrategia MADRL para gestion energetica de comunidades con PV, BESS y EV, reportando mejoras en pico y costo; Xie et al. (2023) introducen mecanismos de atencion multiagente para respuesta a la demanda en edificios grid-responsive; y Hribar et al. (2025) demuestran mejoras de autonomia energetica en distritos de energia positiva mediante MADRL. En paralelo, Felicetti et al. (2024) combinan programacion entera y aprendizaje por refuerzo para maximizar autoconsumo y recorte de picos, mientras Li et al. (2024) estudian programacion online de PV+BESS con DRL. Estos trabajos sustentan el eje OE.1.

La tesis se diferencia porque no evalua una politica unica de flexibilidad. Define E1 como escenario dominante de flexibilidad y compara cuatro familias MADRL bajo condiciones identicas. La literatura muestra que la flexibilidad depende de la interaccion entre edificios, almacenamiento y cargas flexibles; por ello, el Capitulo 5 no debe interpretar un KPI aislado como evidencia suficiente. La lectura correcta combina resultados distritales, resultados por edificio, trazas de accion y carga controlada/no controlada.

Los recursos que producen flexibilidad en el SEAI Iquitos son BESS, EV, PV y cargas desplazables. La teoria de PV+BESS indica que el almacenamiento permite transferir energia solar a horas de demanda o costo mayor; los estudios de Li et al. (2024) y Felicetti et al. (2024) respaldan esa logica. En la tesis, dicha teoria se materializa con acciones electrical_storage,

electric_vehicle_storage_charger_* y washing_machine_*, mientras la carga base no controlada se mantiene como referencia para evaluar el efecto real de la accion.

2.4.2 Emisiones de carbono y control consciente de intensidad de carbono

El segundo eje teorico se relaciona con la gestion energetica orientada a carbono. En sistemas donde la intensidad de carbono varia temporalmente, el control puede reducir emisiones desplazando consumo hacia periodos de baja CI o cargando almacenamiento cuando la energia renovable desplaza generacion fosil. Tranberg et al. (2020) discuten metodos de contabilidad de carbono en tiempo real; Cao et al. (2023) estudian pronostico de intensidad de carbono para gestion energetica de edificios; y el MINAM (2019) proporciona la referencia de factor de emision usada para contextualizar redes aisladas peruanas.

En aprendizaje por refuerzo aplicado a energia, Liu et al. (2022) muestran que MADRL puede reducir costos y emisiones en sistemas de edificios con energia renovable. Ye et al. (2025) y Ma et al. (2025) avanzan hacia MARL seguro para operacion baja en carbono en redes activas y microredes heterogeneas. Sarkar et al. (2024) plantean reduccion de huella de carbono mediante desplazamiento temporal de carga, lo que es conceptualmente transferible a la tesis porque E2 tambien depende de desplazar consumo respecto a una senal de CI. Ren et al. (2025) extienden la discusion a mercados P2P de baja emision con decisiones multiagente.

El caso SEAI Iquitos requiere adaptar este eje a una red aislada diesel+PV. La intensidad CI(t) de la tesis se deriva de un factor base de 0,790 kgCO2/kWh y un desplazamiento asociado a irradiancia, con rango aproximado 0,672-0,790 kgCO2/kWh. Esta construccion se sostiene teoricamente en la necesidad de hacer carbon-aware control, pero se implementa como CarbonIntensityModel en el motor CityLearn v3 propuesto. Asi, la teoria de carbono no queda

desconectada del codigo: se transforma en senal de observacion, componente de recompensa y KPI de evaluacion en D-VD.2.

2.4.3 Costos energeticos, precios dinamicos y respuesta economica

El tercer eje se refiere a costos energeticos y respuesta a precios. En edificios comerciales, los costos no dependen solo de energia total, sino de horarios de consumo, precios, cargos de demanda y comportamiento frente a picos. Dang et al. (2023) estudian reduccion de cargos por demanda mediante BESS bajo precios en tiempo real; Xiong et al. (2024) analizan estrategias DRL para sistemas con tarifa por uso horario y almacenamiento; y Chen et al. (2024) modelan EV como almacenamiento movil en sistemas energeticos integrados. Estas bases justifican que la tesis incorpore costo energetico como D-VD.3 y no como metrica secundaria.

La literatura MADRL de costos refuerza la necesidad de coordinacion. Fang et al. (2021) proponen gestion distribuida de energia y estrategia de mercado en microredes mediante MADRL; Gao et al. (2023) desarrollan MASAC mejorado para programacion colaborativa multi-microgrid; Shojaeighadikolaei et al. (2022) plantean gestion energetica distribuida y respuesta a la demanda en smart grids; y Shojaeighadikolaei et al. (2024) comparan enfoques centralizados y descentralizados para control de redes de carga EV. Estos estudios muestran que el costo emerge de decisiones coordinadas de multiples recursos, no de la optimizacion aislada de un edificio.

La tesis adopta una senal TOU propia del contexto Iquitos y la incorpora en E3. En consecuencia, el marco teorico de costos se vincula con decisiones de carga/descarga BESS, programacion EV, respuesta a precio y reduccion de picos facturables. La inclusion de OSINERGMIN (2024) permite conectar el KPI de pico y costo con reglas regulatorias peruanas, evitando que el analisis economico sea un ejercicio abstracto separado de la realidad institucional.

La importancia de tesis de este eje es que costo, flexibilidad y carbono pueden entrar en conflicto; por eso, la recompensa multiobjetivo y los escenarios E1/E2/E3 son teoricamente necesarios.

2.4.4 Algoritmos MADRL evaluados

HAPPO se fundamenta en optimizacion de politica con restricciones de region de confianza para agentes heterogeneos. Kuba et al. (2021) desarrollan una formulacion de trust-region policy optimization multiagente, y Zhong et al. (2023) profundizan el aprendizaje por refuerzo de agentes heterogeneos. En la tesis, HAPPO es relevante porque los edificios difieren en area, cargas, PV, BESS y numero de EV.

MASAC deriva conceptualmente de Soft Actor-Critic y su regularizacion de entropia (Haarnoja et al., 2018). Gao et al. (2023) muestran la aplicabilidad de un MASAC mejorado en programacion colaborativa multi-microgrid. En la tesis, MASAC representa un enfoque off-policy con exploracion robusta y adaptacion de acciones para el entorno CityLearn v3 propuesto.

MATD3 se basa en la idea de reducir sobreestimacion mediante criticos dobles, retraso de actualizacion de politica y ruido objetivo en la familia actor-critic multiagente (Lowe et al., 2017). En la tesis, MATD3 se plantea en las hipotesis como candidato de mayor efecto coordinado porque su doble critico puede ser ventajoso en horizontes largos y acciones energeticas continuas.

MAAC se sustenta en Actor-Attention-Critic. Iqbal y Sha (2019) proponen que el critico utilice atencion para seleccionar los agentes mas relevantes durante la evaluacion de acciones. En comunidades energeticas, esta idea es pertinente porque no todos los edificios interactuan con la misma intensidad en cada hora: un hospital, un mall y una universidad presentan perfiles de carga y EV diferentes.

El paradigma CTDE separa dos fases: durante el entrenamiento, los criticos pueden acceder al estado global; durante la ejecucion, las politicas actuan solo con observaciones locales (Lowe et al., 2017; Iqbal y Sha, 2019). MARLlib se considera solo como nombre propio de una biblioteca de referencia (Hu et al., 2023), no como sustituto conceptual de MADRL.

Tabla 2.3

Fundamento teorico de los algoritmos MADRL evaluados

Algoritmo	Base teorica	Ventaja esperada	Riesgo metodologico	Relacion con VI
HAPPO	Trust-region y agentes heterogeneos (Kuba et al., 2021; Zhong et al., 2023).	Estabilidad on-policy y tratamiento de heterogeneidad entre edificios.	Costo de muestreo y cobertura parcial de artefactos finales.	Nivel D-VI.1 del factor algoritmo.
MASAC	SAC y regularizacion de entropia (Haarnoja et al., 2018; Gao et al., 2023).	Exploracion robusta y aprendizaje off-policy.	Adaptacion de acciones continuas/discretas y sensibilidad a hiperparametros.	Nivel D-VI.1 del factor algoritmo.
MATD3	Criticos dobles, retardo de politica y control continuo off-policy (Lowe et al., 2017).	Reduccion de sobreestimacion y estabilidad en acciones continuas.	Puede optimizar algunos ejes mejor que otros; requiere lectura por escenario.	Nivel D-VI.1 e hipotesis direccional HE.2.
MAAC	Critico con atencion multiagente (Iqbal y Sha, 2019).	Coordinacion selectiva entre edificios heterogeneos.	Complejidad computacional y sensibilidad a estructura de interacciones.	Nivel D-VI.1 del factor algoritmo.

Nota. La tabla representa la organizacion conceptual del marco teorico y de las variables de investigacion. Fuente: Elaboracion propia a partir de la literatura citada en el Capitulo 2.

2.4.5 Aportes fisicos al motor como base teorica de CityLearn v3 propuesto

El marco teorico tambien debe sustentar los aportes del motor de simulacion. La degradacion BESS con C-rate y temperatura se justifica por literatura de envejecimiento de baterias LiFePO4 y modelado de degradacion (Naumann et al., 2021; Rajagopalan et al., 2024;

Reniers et al., 2022; Xu et al., 2021). Esto evita que el entorno trate toda accion de almacenamiento como equivalente, ignorando condiciones termicas propias de Iquitos.

La correccion PV por temperatura tropical se sustenta en IEC 61215-1:2021, Tamoor et al. (2022) y Antonanzas et al. (2021). En Iquitos, alta temperatura y humedad pueden reducir produccion frente a condiciones STC, por lo que un modelo sin correccion termica sesgaria las politicas MADRL hacia una confianza excesiva en PV de mediodia. El KPI de pico con ventana de facturacion se fundamenta en OSINERGMIN (2024) y en estudios de reduccion de demanda maxima con BESS (Dang et al., 2023). Finalmente, CarbonIntensityModel se sostiene en MINAM (2019), Tranberg et al. (2020) y Cao et al. (2023).

Tabla 2.6

Constructos teoricos, indicadores y fuentes

Constructo	Indicadores en tesis	Fuentes teoricas principales	Uso en Cap. 5
Flexibilidad energetica	peak_average, ramping_average, one_minus_load_factor_average, autoconsumo, autosuficiencia.	Vázquez-Canteli et al. (2020); Nweye et al. (2024); Lund et al. (2017).	Comparacion E1, figuras A.1-A.2/A.7-A.8 y KPIs edificio.
Emisiones CO2	carbon_emissions_total, carbon_emissions_delta, CI-weighted consumption.	Liu et al. (2022); Tranberg et al. (2020); Cao et al. (2023); MINAM (2019).	Comparacion E2, figura A.4/A.6 y tablas por edificio.
Costos energeticos	electricity_cost_total, electricity_cost_delta, price_signal_deviation.	Dang et al. (2023); Xiong et al. (2024); OSINERGMIN (2024); Gao et al. (2023).	Comparacion E3, figura A.3/A.5 y deltas por edificio.
Coordinacion MADRL	reward, trace por agente, acciones controladas, checkpoints.	Lowe et al. (2017); Oliehoek y Amato (2016); Iqbal y Sha (2019); Kuba et al. (2021).	Interpretacion distrito-edificio y reproducibilidad de politica.
Fidelidad fisica del simulador	degradacion BESS, PV tropical, CI dinamica, pico facturable.	Naumann et al. (2021); Tamoor et al. (2022); IEC (2021); MINAM (2019).	Justifica CityLearn v3 propuesto y anexos de arquitectura.

Nota. La tabla representa la organizacion conceptual del marco teorico y de las variables de investigacion. Fuente: Elaboracion propia a partir de la literatura citada en el Capitulo 2.

2.4 Antecedentes

Los antecedentes se organizan en internacionales (Tabla 2.4), nacionales/peruanos (Tabla 2.5) y una sintesis critica de brecha cientifica. La Tabla 2.7 resume la relacion entre antecedentes, ejes teoricos y aportes de esta tesis.

Tabla 2.7

Antecedentes usados por eje teorico y relacion con la tesis

Eje	Autores fuente	Aporte teorico usado	Limitacion que cubre esta tesis
CityLearn y benchmarking	Vázquez-Canteli y Nagy (2019a, 2019b); Vázquez-Canteli et al. (2020); Nweye et al. (2023c, 2024); Nweye y Nagy (2024b)	Entorno estandarizado, KPIs, comunidades grid-interactive, carbon-aware control.	Se extiende a CityLearn v3 propuesto con Dec-POMDP/CTDE y cuatro backends MADRL.
Escala multiagente realista	Nweye et al. (2022, 2023a, 2023b)	Desafios reales, MERLIN y comunidades heterogeneas de 17 edificios.	Se aplica a SEAI Iquitos con 17 edificios reales y artefactos Drive.
Flexibilidad energetica	Yao et al. (2023); Xie et al. (2023); Hribar et al. (2025); Felicetti et al. (2024); Li et al. (2024); Zhao et al. (2024); Wu et al. (2025)	Peak shaving, ramping, autoconsumo, coordinacion DR, PV+BESS, control seguro.	E1 compara HAPPO/MASAC/MATD3/MAAC bajo mismo dataset y KPIs.
Emisiones CO2	Liu et al. (2022); Ye et al. (2025); Ma et al. (2025); Sarkar et al. (2024); Ren et al. (2025); Tranberg et al. (2020); Cao et al. (2023)	Control bajo intensidad de carbono, operacion baja en carbono, desplazamiento temporal de carga.	E2 usa CI de red aislada Iquitos y CarbonIntensityModel.
Costos energeticos	Fang et al. (2021); Gao et al. (2023); Shojaeighadikolaei et al. (2022, 2024); Xiong et al. (2024); Chen et al. (2024); Dang et al. (2023)	Respuesta a precios, costo electrico, microredes, EV, BESS y demanda maxima.	E3 vincula TOU local, BESS, EV, carga desplazable y costo distrital/edificio.
Fundamentos MADRL	Sutton y Barto (2018); Oliehoek y Amato	MDP, Dec-POMDP, CTDE, SAC, atencion,	Se operacionaliza en wrappers reales y tratamientos

	(2016); Lowe et al. (2017); Haarnoja et al. (2018); Iqbal y Sha (2019); Kuba et al. (2021); Zhong et al. (2023); Hu et al. (2023)	HAPPO, MARLlib.	experimentales.
Modelado fisico y regulatorio	Naumann et al. (2021); Rajagopalan et al. (2024); Reniers et al. (2022); Xu et al. (2021); Tamoor et al. (2022); Antonanzas et al. (2021); IEC (2021); MINAM (2019); OSINERGMIN (2024)	Degradacion BESS, correccion PV tropical, carbono y tarifa.	Aportes A1-A4 del motor CityLearn v3 propuesto.

Nota. La tabla representa la sintesis de antecedentes academicos y su relacion con la brecha teorica de la tesis. Fuente: Elaboracion propia con base en la revision bibliografica sistematizada en el Capitulo 2 y en las referencias APA del documento.

2.5.1 Antecedentes internacionales

La Tabla 2.4 sistematiza cinco antecedentes internacionales directamente vinculados con CityLearn, MADRL (HAPPO/MAAC/MADDPG), flexibilidad, CO2 y costos. Estos estudios constituyen la linea de comparacion externa para PE.1-PE.3 y para la contrastacion de hipotesis en el Capitulo 5.

Tabla 2.4

Antecedentes internacionales seleccionados (Modulo A)

Autor(es)	Titulo	Variables VI/VD	Aporte para esta tesis	DOI / enlace
Nweye et al. (2024)	CityLearn v2: Energy-flexible, resilient, occupant-centric, and carbon-aware management of grid-interactive communities	CityLearn; D-VD.1 flexibilidad; D-VD.2 CO2; D-VD.3 costos	Entorno base oficial y KPIs D-VD.1-D-VD.3; justifica extension CityLearn v3 propuesto con Dec-POMDP/CTDE y cuatro backends MADRL.	10.1080/19401493.2024.2418813
Nweye et al. (2023b)	Heterogeneous Multi-Agent Reinforcement	VI HAPPO; CityLearn; D-VD.1 flexibilidad;	Antecedente directo del backend HAPPO	10.1145/3600100.3626276

	Learning for Grid-Interactive Communities	CTDE; Dec-POMDP	a escala multiedificio; precedente mas cercano antes de comparar HAPPO, MASAC, MATD3 y MAAC bajo recompensa unificada.	
Yao et al. (2023)	Multi-Agent Reinforcement Learning for Smart Community Energy Management	MADRL; D-VD.1 flexibilidad; D-VD.3 costos; PV+BESS+EV	Referente de flexibilidad y costos (OE.1/OE.3) para contrastar si MATD3/MAAC superan mejoras reportadas (~15-18%) bajo dataset SEAI Iquitos.	10.3390/en17205211
Liu et al. (2022)	Multi-agent deep reinforcement learning for building energy system with renewable energy	MADRL; D-VD.2 CO2; D-VD.3 costos; BESS+PV	Antecedente de D-VD.2 y D-VD.3 para contrastar deltas de CO2 y costo de MATD3/MAAC en escenario E2/E3 del SEAI Iquitos.	10.1016/j.apenergy.2022.118703
Iqbal y Sha (2019)	Actor-Attention-Critic for Multi-Agent Reinforcement Learning	VI MAAC; CTDE; Dec-POMDP/POMDP cooperativo	Fundamento del backend MAAC; explica por que MAAC puede liderar costos (OE.3) al ponderar interacciones entre edificios bajo senales TOU.	proceedings.mlr.press/v97/iqbal19a.html

Nota. La tabla representa la sintesis de antecedentes academicos y su relacion con la brecha teorica de la tesis. Fuente: Elaboracion propia con base en la revision bibliografica sistematizada en el Capitulo 2 y en las referencias APA del documento.

Nweye et al. (2024)

Ficha antecedente internacional — Nweye et al. (2024).

Campo	Contenido

Titulo de la tesis/estudio	CityLearn v2: Energy-flexible, resilient, occupant-centric, and carbon-aware management of grid-interactive communities
Objetivo general	Desarrollar CityLearn v2 integrando EV/V2G, intensidad de carbono dinamica, BESS, PV y KPIs de flexibilidad, emisiones y costos en comunidades grid-interactive.
Tipo de metodologia	Desarrollo de entorno de simulacion; evaluacion multiobjetivo con SAC, RBC y MPC.
Diseno de investigacion	Aplicada; no experimental; simulacion comparativa en CityLearn v2.
Resultados cuantitativos	KPIs distritales y por edificio (peak_average, ramping, carbon_emissions, electricity_cost); magnitudes especificas dependen de configuracion experimental.
Conclusion general	CityLearn v2 habilita investigacion reproducible en comunidades inteligentes multidimensionales con flexibilidad, carbono y costo.
Aporte para esta tesis	Entorno base oficial y KPIs D-VD.1-D-VD.3; justifica extension CityLearn v3 propuesto con Dec-POMDP/CTDE y cuatro backends MADRL.

Nota. La tabla representa la informacion sintetizada en la tabla correspondiente. Fuente: Elaboracion propia a partir de los datos, fuentes y artefactos citados en el documento.

Nweye et al. (2023b)

Ficha antecedente internacional — Nweye et al. (2023b).

Campo	Contenido
Titulo de la tesis/estudio	Heterogeneous Multi-Agent Reinforcement Learning for Grid-Interactive Communities
Objetivo general	Evaluar HARL/HAPPO para gestion energetica heterogenea en comunidades grid-interactive modeladas en CityLearn.
Tipo de metodologia	MARL heterogeneo on-policy (HAPPO/HARL) bajo CTDE en CityLearn.
Diseno de investigacion	Aplicada; no experimental; simulacion CityLearn con agentes heterogeneos.
Resultados cuantitativos	HAPPO heterogeneo comparable o superior a MAPPO en KPIs CityLearn (peak, ramping, emisiones, costo); magnitudes exactas [PV] por configuracion.
Conclusion general	HAPPO es viable para coordinacion heterogenea en comunidades inteligentes grid-interactive.
Aporte para esta tesis	Antecedente directo del backend HAPPO a escala multiedificio; precedente mas cercano antes de comparar HAPPO, MASAC, MATD3 y MAAC bajo recompensa unificada.

Nota. La tabla representa la informacion sintetizada en la tabla correspondiente. Fuente: Elaboracion propia a partir de los datos, fuentes y artefactos citados en el documento.

Yao et al. (2023)

Ficha antecedente internacional — Yao et al. (2023).

Campo	Contenido
Titulo de la tesis/estudio	Multi-Agent Reinforcement Learning for Smart Community Energy Management
Objetivo general	Proponer un marco MARL (LSD-MADDPG) para gestion coordinada de energia en comunidades inteligentes con PV, BESS y EV.
Tipo de metodologia	MARL cooperativo con estrategia local descentralizada (LSD-MADDPG); CTDE.
Diseno de investigacion	Aplicada; no experimental; simulacion de comunidad inteligente sintetica.
Resultados cuantitativos	Reduccion de costo ~18% y de pico ~15% frente a MADDPG no cooperativo.
Conclusion general	La estrategia local MARL mejora coordinacion y reduce fallos de escalabilidad en comunidades con DER.
Aporte para esta tesis	Referente de flexibilidad y costos (OE.1/OE.3) para contrastar si MATD3/MAAC superan mejoras reportadas (~15-18%) bajo dataset SEAI Iquitos.

Nota. La tabla representa la informacion sintetizada en la tabla correspondiente. Fuente: Elaboracion propia a partir de los datos, fuentes y artefactos citados en el documento.

Liu et al. (2022)

Ficha antecedente internacional — Liu et al. (2022).

Campo	Contenido
Titulo de la tesis/estudio	Multi-agent deep reinforcement learning for building energy system with renewable energy
Objetivo general	Proponer MADRL (MADDPG) para coordinar BESS y PV en edificios con energia renovable bajo incertidumbre operativa.
Tipo de metodologia	MADDPG cooperativo con critico centralizado; comparacion con control basado en reglas.
Diseno de investigacion	Aplicada; no experimental; simulacion con datos reales de edificios en China.
Resultados cuantitativos	Reduccion de costo ~20% y de emisiones CO2 ~15% frente a reglas.

Conclusion general	MADRL cooperativo supera agentes independientes en eficiencia energetica y emisiones.
Aporte para esta tesis	Antecedente de D-VD.2 y D-VD.3 para contrastar deltas de CO2 y costo de MATD3/MAAC en escenario E2/E3 del SEAI Iquitos.

Nota. La tabla representa la informacion sintetizada en la tabla correspondiente. Fuente: Elaboracion propia a partir de los datos, fuentes y artefactos citados en el documento.

Iqbal y Sha (2019)

Ficha antecedente internacional — Iqbal y Sha (2019).

Campo	Contenido
Titulo de la tesis/estudio	Actor-Attention-Critic for Multi-Agent Reinforcement Learning
Objetivo general	Introducir mecanismos de atencion en el critico centralizado MARL para coordinacion selectiva bajo observabilidad parcial.
Tipo de metodologia	Actor-critic multiagente con atencion multi-cabeza; evaluacion en benchmarks MPE y cooperativos.
Diseno de investigacion	Basica-algoritmica; experimental con entornos benchmark MARL.
Resultados cuantitativos	Mejora de recompensa ~15-30% frente a MADDPG/COMA en tareas cooperativas.
Conclusion general	La atencion mejora coordinacion selectiva entre agentes heterogeneos bajo CTDE.
Aporte para esta tesis	Fundamento del backend MAAC; explica por que MAAC puede liderar costos (OE.3) al ponderar interacciones entre edificios bajo senales TOU.

Nota. La tabla representa la informacion sintetizada en la tabla correspondiente. Fuente: Elaboracion propia a partir de los datos, fuentes y artefactos citados en el documento.

2.5.2 Antecedentes nacionales y peruanos

La Tabla 2.5 integra antecedentes nacionales y del contexto SEAI Iquitos: tesises peruanas/latinoamericanas y marcos regulatorios MINAM/OSINERGMIN. Estos antecedentes anclan la tesis en el sistema electrico aislado diesel+PV de Loreto.

Tabla 2.5

Antecedentes nacionales/peruanos seleccionados

Autor(es)	Titulo	Variables VI/VD	Aporte para esta tesis	DOI / enlace
Chevarria Moscoso (2024)	Analisis de la generacion hidroelectrica en la central hidroelectrica de Machupicchu aplicando metodos estocasticos y mo...	Contexto Peru; generacion renovable; incertidumbre operativa	Contextualiza optimizacion energetica nacional y variabilidad de recursos renovables aplicable al balance PV+diesel del SEAI Iquitos.	http://hdl.handle.net/20.500.14076/28894
Peñalva Sanchez (2024)	Optimizacion de un sistema fotovoltaico hibrido y la prediccion de la demanda energetica y variables climaticas utilizan...	Contexto Peru/UNI; PV; demanda; clima tropical	Sustenta el uso de datos climaticos y demanda reales (PVGIS/NASA POWER) en el dataset citylearn_iquitos_2023_2025 y la relevancia de prediccion para control flexible.	http://hdl.handle.net/20.500.14076/27731
Rosero Bernal (2022)	Modelo de un sistema de administracion de energia autonomo operado desde la nube para optimizar la gestion de un grupo d...	Microredes; coordinacion; gestion energetica autonoma	Paralelo latinoamericano de coordinacion multiagente en redes locales; informa la lectura CTDE del distrito SEAI como comunidad de 17 nodos energeticos.	[PV]
MINAM (2019)	INFOCARBONO — RAGEI 2019 Energia (factor de emision del sector electrico peruano)	D-VD.2 CO2; SEAI Iquitos; intensidad de carbono	Fundamenta CarbonIntensityModel (A4) y el escenario E2 (D-VD.2) con factor MINAM aplicado al SEAI Iquitos.	https://infocarbono.minam.gob.pe/
OSINERGMIN (2024)	Resolucion de Consejo Directivo N. 0024-2024-OS/CD — Tarifas de distribucion electrica MT-3/MT-4, Electro Oriente S.A.	D-VD.3 costos; D-VD.1 flexibilidad (pico); SEAI Iquitos	Justifica KPI de pico con ventana OSINERGMIN (A3) y el escenario E3 (D-VD.3 costos) con senales TOU locales de Iquitos.	[PV — resolucion OSINERGMIN 0024-2024-OS/CD]

Nota. La tabla representa la sintesis de antecedentes academicos y su relacion con la brecha teorica de la tesis. Fuente: Elaboracion propia con base en la revision bibliografica sistematizada en el Capitulo 2 y en las referencias APA del documento.

Chevarria Moscoso (2024)

Ficha antecedente nacional — Chevarria Moscoso (2024).

Campo	Contenido
Titulo de la tesis/estudio	Analisis de la generacion hidroelectrica en la central hidroelectrica de Machupicchu aplicando metodos estocasticos y modelo de optimizacion
Objetivo general	Optimizar la generacion hidroelectrica de Machupicchu mediante metodos estocasticos y un modelo de optimizacion bajo incertidumbre hidrologica.
Tipo de metodologia	Modelado estocastico y optimizacion matematica aplicada a generacion renovable peruana.
Diseno de investigacion	Aplicada; tesis UNI; estudio de caso en generacion hidroelectrica.
Resultados cuantitativos	[PV] Mejoras de eficiencia operativa y asignacion de generacion respecto a escenarios base; magnitudes cuantitativas pendientes de extraccion del repositorio UNI.
Conclusion general	Los metodos estocasticos permiten decisiones mas robustas en generacion renovable bajo variabilidad hidrologica en el contexto peruano.
Aporte para esta tesis	Contextualiza optimizacion energetica nacional y variabilidad de recursos renovables aplicable al balance PV+diesel del SEAI Iquitos.

Nota. La tabla representa la informacion sintetizada en la tabla correspondiente. Fuente: Elaboracion propia a partir de los datos, fuentes y artefactos citados en el documento.

Peñalva Sanchez (2024)

Ficha antecedente nacional — Peñalva Sanchez (2024).

Campo	Contenido
Titulo de la tesis/estudio	Optimizacion de un sistema fotovoltaico hibrido y la prediccion de la demanda energetica y variables climaticas utilizando la inteligencia artificial
Objetivo general	Optimizar un sistema fotovoltaico hibrido e integrar prediccion de demanda y variables climaticas mediante inteligencia artificial.
Tipo de metodologia	Modelado de sistema PV hibrido; aprendizaje automatico para pronostico de demanda y clima.
Diseno de investigacion	Aplicada; tesis UNI; estudio de caso con

	datos locales.
Resultados cuantitativos	[PV] Reduccion de error de prediccion de demanda y mejora de desempeno del sistema hibrido; valores numericos pendientes de verificacion en repositorio UNI.
Conclusion general	La IA mejora la operacion de sistemas PV hibridos al anticipar demanda y condiciones climaticas en contexto peruano.
Aporte para esta tesis	Sustenta el uso de datos climaticos y demanda reales (PVGIS/NASA POWER) en el dataset citylearn_iquitos_2023_2025 y la relevancia de prediccion para control flexible.

Nota. La tabla representa la informacion sintetizada en la tabla correspondiente. Fuente: Elaboracion propia a partir de los datos, fuentes y artefactos citados en el documento.

Rosero Bernal (2022)

Ficha antecedente nacional — Rosero Bernal (2022).

Campo	Contenido
Titulo de la tesis/estudio	Modelo de un sistema de administracion de energia autonomo operado desde la nube para optimizar la gestion de un grupo de microredes
Objetivo general	Disenar un sistema autonomo de administracion de energia en la nube para optimizar la gestion coordinada de un grupo de microredes.
Tipo de metodologia	Arquitectura de gestion energetica distribuida en la nube; optimizacion multi-microred.
Diseno de investigacion	Aplicada; tesis; estudio de caso en microredes.
Resultados cuantitativos	[PV] Mejoras de eficiencia energetica y coordinacion inter-microred respecto a operacion descentralizada sin orquestacion en la nube.
Conclusion general	La administracion autonoma en la nube mejora la coordinacion operativa de microredes heterogeneas.
Aporte para esta tesis	Paralelo latinoamericano de coordinacion multiagente en redes locales; informa la lectura CTDE del distrito SEAI como comunidad de 17 nodos energeticos.

Nota. La tabla representa la informacion sintetizada en la tabla correspondiente. Fuente: Elaboracion propia a partir de los datos, fuentes y artefactos citados en el documento.

MINAM (2019)

Ficha antecedente nacional — MINAM (2019).

Campo	Contenido
Titulo de la tesis/estudio	INFOCARBONO — RAGEI 2019 Energia (factor de emision del sector electrico peruano)
Objetivo general	Documentar factores de emision de gases de efecto invernadero del sector energetico peruano para contabilidad de carbono nacional.
Tipo de metodologia	Inventario nacional de emisiones; contabilidad de carbono por sector y tecnologia.
Diseno de investigacion	Descriptiva-documental; fuente regulatoria oficial del Estado peruano.
Resultados cuantitativos	Factor de emision del sistema diesel aislado: 0,790 kgCO2/kWh (base para SEAI Iquitos); modulacion solar en tesis: CI(t) en rango 0,672-0,790 kgCO2/kWh.
Conclusion general	La contabilidad oficial peruana permite parametrizar control consciente de carbono en redes con alta dependencia de diesel.
Aporte para esta tesis	Fundamenta CarbonIntensityModel (A4) y el escenario E2 (D-VD.2) con factor MINAM aplicado al SEAI Iquitos.

Nota. La tabla representa la informacion sintetizada en la tabla correspondiente. Fuente: Elaboracion propia a partir de los datos, fuentes y artefactos citados en el documento.

OSINERGMIN (2024)

Ficha antecedente nacional — OSINERGMIN (2024).

Campo	Contenido
Titulo de la tesis/estudio	Resolucion de Consejo Directivo N. 0024-2024-OS/CD — Tarifas de distribucion electrica MT-3/MT-4, Electro Oriente S.A.
Objetivo general	Establecer tarifas de distribucion electrica y estructura de facturacion por demanda maxima para usuarios MT-3/MT-4 de Electro Oriente S.A. (Loreto).
Tipo de metodologia	Marco regulatorio tarifario; analisis de cargos por energia y demanda maxima.
Diseno de investigacion	Normativa aplicada; estudio de caso regulatorio en red de distribucion Loreto.
Resultados cuantitativos	Estructura TOU y cargo por demanda maxima en ventanas de facturacion (15 min); tarifas punta/fuera punta usadas en escenario E3 de la tesis.
Conclusion general	La regulacion peruana vincula costos energeticos a picos facturables, haciendo necesaria la coordinacion distrital de flexibilidad.
Aporte para esta tesis	Justifica KPI de pico con ventana OSINERGMIN

	(A3) y el escenario E3 (D-VD.3 costos) con senales TOU locales de Iquitos.

Nota. La tabla representa la informacion sintetizada en la tabla correspondiente. Fuente: Elaboracion propia a partir de los datos, fuentes y artefactos citados en el documento.

2.5.3 Sintesis critica de antecedentes y brecha cientifica

La revision muestra cinco patrones. Primero, CityLearn proporciona un entorno estandarizado, pero no resuelve por si mismo la comparacion entre HAPPO, MASAC, MATD3 y MAAC. Segundo, los estudios de flexibilidad muestran beneficios de control aprendido, pero frecuentemente se concentran en pico o autoconsumo. Tercero, los estudios de carbono muestran utilidad de senales CI, pero rara vez se integran con costo y flexibilidad en un unico diseno factorial. Cuarto, la literatura de costos evidencia la importancia de precios y BESS, pero no siempre considera emisiones. Quinto, los algoritmos MADRL tienen fundamentos distintos, por lo que comparar solo resultados agregados sin control metodologico puede inducir conclusiones debiles.

La brecha que sostiene esta tesis es metodologica y experimental: falta una evaluacion comparativa, reproducible y multiobjetivo de HAPPO, MASAC, MATD3 y MAAC en una comunidad inteligente realista de 17 edificios, bajo Dec-POMDP, CTDE, dataset comun, recompensa unificada y resultados trazables por distrito, edificio, escenario, KPIs y checkpoints. Esta brecha justifica la variable independiente, la variable dependiente y la matriz de operacionalizacion (Tabla 2.1 y Capitulo 3, Seccion 3.4).

2.5 Definicion de terminos y posicion teorica

2.6.1 Definicion de terminos y delimitaciones conceptuales

MADRL: aprendizaje por refuerzo profundo multiagente, donde multiples agentes aprenden politicas mediante redes neuronales y senales de recompensa. En esta tesis se usa MADRL para referirse a HAPPO, MASAC, MATD3 y MAAC bajo formulacion cooperativa.

No se sustituye por MARL salvo cuando aparece como parte del nombre propio de una referencia, repositorio o biblioteca.

CityLearn v2: entorno base oficial de simulacion para comunidades energeticas grid-interactive, con KPIs de energia, carbono y costo. CityLearn v3 propuesto: extension experimental de esta tesis, implementada localmente para Dec-POMDP, CTDE, recompensa multiobjetivo, wrappers MADRL y artefactos reproducibles. Esta distincion es obligatoria para no atribuir al paquete oficial una funcionalidad propia del proyecto.

Tratamiento experimental: combinacion de un nivel D-VI.1 algoritmo y un nivel D-VI.2 escenario. El diseno factorial completo tiene 12 tratamientos. Distrito: agregacion de los 17 edificios para medir efecto comunitario. Edificio: agente individual con observacion local y acciones propias. Equipo controlado: variable de accion sobre BESS, EV o carga desplazable. Carga no controlada: demanda base observada o de referencia que no es actuada directamente por el agente.

KPI: indicador cuantitativo usado para medir la variable dependiente. Los KPIs no son adornos del resultado; son la operacionalizacion de D-VD.1, D-VD.2 y D-VD.3. Por ello, toda grafica o tabla del Capitulo 5 debe indicar si corresponde a flexibilidad, carbono, costo, distrito, edificio, escenario o reproducibilidad de modelo.

2.6.2 Posicion teorica de la tesis

La posicion teorica adoptada es que una comunidad inteligente con recursos DER heterogeneos debe modelarse como un sistema multiagente parcialmente observable y no como un problema de control centralizado unico. El criterio de calidad no es solo minimizar un KPI, sino producir desempeno coordinado medible en tres dimensiones por eje (Tabla 2.1). Esta posicion combina la teoria Dec-POMDP de Oliehoek y Amato (2016), el paradigma CTDE de

Lowe et al. (2017), la estandarizacion de CityLearn de Vázquez-Canteli et al. (2020) y Nweye et al. (2024), y la literatura de gestion energetica multiobjetivo.

Desde esta posicion, el Capitulo 5 debe interpretar los resultados con tres reglas. Primero, no hay superioridad universal sin declarar escenario, KPI y escala. Segundo, un resultado distrital no reemplaza la evidencia por edificio. Tercero, un algoritmo con artefactos incompletos no debe usarse para comparaciones donde falten archivos. Estas reglas derivan directamente del marco teorico y evitan conclusiones no sustentadas.

2.7 Sintesis critica y triangulacion del marco teorico

El marco teorico contiene estado del arte, bases teoricas, trabajos relacionados, definicion de variables y posicion teorica. La triangulacion central se organiza en tres capas. Primero, CityLearn aporta el marco de evaluacion reproducible para comunidades de edificios y demanda flexible; CityLearn v2 agrega objetivos de flexibilidad, resiliencia, ocupacion y carbono; EVLearn extiende el mismo ecosistema a vehiculos electricos y estrategias V1G/V2G (Vázquez-Canteli et al., 2020; Nweye et al., 2024; Fonseca et al., 2024). Segundo, la teoria MADRL fundamenta la ejecucion descentralizada con entrenamiento centralizado: MAAC introduce criticos con atencion para seleccionar interacciones relevantes entre agentes, HAPPO extiende optimizacion de region de confianza a agentes heterogeneos, SAC/MASAC aporta exploracion por maxima entropia y TD3/MATD3 controla sesgo de sobreestimacion con criticos dobles y actualizaciones retrasadas (Iqbal & Sha, 2019; Kuba et al., 2021; Haarnoja et al., 2018; Fujimoto et al., 2018). Tercero, la literatura de evaluacion de RL advierte que una comparacion algoritmica debe acompanar los promedios con dispersion, pruebas estadisticas y trazabilidad experimental (Henderson et al., 2018; Agarwal et al., 2021).

La principal mejora incorporada al Capitulo 2 consiste en separar el soporte teorico de cada decision metodologica. El Dec-POMDP no se presenta como formalismo decorativo, sino como condicion necesaria para representar 17 agentes con observacion parcial, acciones heterogeneas, recompensa cooperativa y horizonte anual. La funcion de recompensa multiobjetivo se sustenta en la literatura de control de comunidades energeticas, pero se interpreta dentro de CityLearn v2 para evitar que flexibilidad, emisiones y costos sean confundidos como una unica variable latente. Esta posicion teorica permite que el Capitulo 5 lea resultados por escenario y no solo por algoritmo.

Tabla 2.6

Triangulacion teorica por eje de la tesis

Eje	Fuentes trianguladas	Uso en la tesis
Entorno y KPIs	CityLearn v1/v2; CityLearn Challenge; EVLearn	Justifica benchmark, KPIs evaluate_v2 y control de EV/BESS.
MADRL	MAAC; HAPPO; SAC; TD3	Justifica comparacion de familias actor-critic multiagente.
Evaluacion rigurosa	Henderson et al.; Agarwal et al.	Justifica pruebas no parametricas y cautela ante una sola corrida.
Variables	Flexibilidad, CO2 y costo en comunidades grid-interactive	Sostiene D-VD.1, D-VD.2 y D-VD.3.

Nota. La tabla representa la organizacion conceptual del marco teorico y de las variables de investigacion. Fuente: Elaboracion propia a partir de la literatura citada en el Capitulo 2.

Capitulo 3. Metodologia

El presente estudio adopta una metodologia cuantitativa, aplicada y explicativa-comparativa, sustentada en simulacion computacional controlada. Esta decision responde a la naturaleza del problema de tesis: evaluar en que medida distintos algoritmos MADRL modifican indicadores cuantificables de flexibilidad energetica, emisiones de CO2 y costos energeticos en una comunidad electrica modelada bajo CityLearn. De acuerdo con Hernandez-Sampieri y Mendoza (2018), la ruta cuantitativa se caracteriza por la medicion de variables, el uso de procedimientos sistematicos y la contrastacion de hipotesis; Creswell y Creswell (2023) enfatizan que los disenos cuantitativos permiten examinar relaciones entre variables mediante mediciones numericas y analisis estadistico. En esta tesis, la variable independiente se manipula computacionalmente mediante el algoritmo MADRL y el escenario de recompensa, mientras que la variable dependiente se observa mediante KPIs oficiales y resultados episodicos.

3.1 Enfoque, tipo, nivel y diseno de investigacion

La investigacion es aplicada porque desarrolla y evalua una solucion computacional para gestion energetica multiagente en una comunidad del SEAI Iquitos. Es cuantitativa porque los resultados se expresan en metricas numericas: recompensa, costo, emisiones, pico, rampa, factor de carga, energia de almacenamiento, exito EV y KPIs evaluate_v2. Es explicativa-comparativa porque no se limita a describir los algoritmos; contrasta si la variacion de la variable independiente produce efectos diferenciados sobre las dimensiones D-VD.1, D-VD.2 y D-VD.3. Esta clasificacion es coherente con los criterios de alcance y diseno propuestos por Hernandez-Sampieri y Mendoza (2018), con la logica de diseno cuantitativo de Creswell y Creswell (2023), y con la tradicion de disecuasiexperimental orientado a factores, tratamientos y respuestas descrita por Montgomery (2019).

El diseño no se considera cuasiexperimental en sentido estricto, porque sí existe manipulación controlada de factores dentro del entorno de simulación: algoritmo MADRL y escenario de recompensa. Tampoco corresponde a un experimento de campo con sujetos humanos, sino a un cuasiexperimento computacional in silico (sin aleatorización de unidades naturales). Por ello, se define como diseño cuasiexperimental factorial 4×3, con control de dataset, entorno, recompensa, horizonte temporal, agentes y protocolo de evaluación. La inferencia es intra-corrida y se interpreta con cautela (Shadish, Cook y Campbell, 2002): la validez externa queda limitada por la ausencia de múltiples semillas independientes. Métricas primarias: KPIs y recompensa; accuracy/F1 no son centrales.

Tabla 3.1

Clasificacion metodologica de la investigacion

Criterio	Decision metodologica	Sustento
Enfoque	Cuantitativo	Medicion numerica de KPIs y contrastacion estadistica.
Tipo	Aplicada	Desarrollo y evaluacion de una propuesta MADRL para gestion energetica.
Nivel	Explicativo-comparativo	Evalua efecto de algoritmos y escenarios sobre dimensiones VD.
Diseno	Experimental-computacional factorial 4x3	Manipulacion controlada de algoritmo y escenario en simulacion.
Temporalidad	Longitudinal por episodios y horizonte anual horario	Cada episodio recorre una trayectoria anual de 8760 pasos.
Inferencia	Intra-corrida con limitacion multi-semilla	No se generaliza mas alla de los artefactos auditados.

Nota. La tabla representa el diseno metodologico, las variables, herramientas, datos y procedimiento experimental. Fuente: Elaboracion propia a partir del proyecto local, scripts de metodologia, dataset citylearn_iquitos_2023_2025 y artefactos Drive de entrenamiento.

3.1.3 Coordinación energética multiobjetivo (VD)

La coordinación se implementa mediante una suma ponderada de tres componentes acotados: R_s = w_F R_F + w_CO_2 R_CO_2 + w_cost R_cost. Se adopta una jerarquía compensatoria cíclica con nivel dominante 0,60, secundario 0,25 y residual 0,15, en el orden [flexibilidad, CO_2, costo]: E1=[0,60; 0,15; 0,25] se vincula con OE.1; E2=[0,25; 0,60; 0,15], con OE.2; y E3=[0,15; 0,25; 0,60], con OE.3. Cada fila suma uno, el peso dominante supera la suma de los otros dos (0,60 > 0,40) y cada objetivo recibe una vez cada nivel, por lo que la intensidad de preferencia es comparable entre escenarios. La escalarización lineal mediante vectores de preferencia se emplea en gestión energética con aprendizaje por refuerzo (Lu et al., 2022; Nweye et al., 2023a), mientras que estudios energéticos y tesis afines separan los compromisos técnicos, ambientales y económicos (Jiménez Perdomo & González Escobar, 2024; Mayanti et al., 2021).

Esta formulación es una suma ponderada jerarquizada y compensatoria, no optimización lexicográfica: los objetivos secundarios pueden compensar parcialmente el deterioro del dominante. Una jerarquía lexicográfica estricta exige optimizar los objetivos en secuencia y preservar el óptimo superior —o una tolerancia explícita— antes de atender el siguiente (Huy et al., 2023; Tostado-Véliz et al., 2022). Por ello, 0,60/0,25/0,15 es una decisión del diseño experimental, no un valor universal. Su validez se verificará con KPI independientes —pico y rampa para OE.1, CO_2 para OE.2 y costo para OE.3—, contribuciones efectivas $|w_j R_j|$, sensibilidad del peso dominante y repetición por semillas; los resultados obtenidos con ponderaciones anteriores no se reinterpretan y requieren reentrenamiento.

3.2 Diseno cuasiexperimental (simulación controlada) factorial 4x3

El diseno factorial se compone de dos factores principales. El primer factor es el algoritmo MADRL, con cuatro niveles: HAPPO, MAAC, MASAC y MATD3. El segundo factor es el escenario de recompensa, con tres niveles: E1 orientado a flexibilidad, E2 orientado a emisiones de CO2 y E3 orientado a costos energeticos. La combinacion genera 12 tratamientos algoritmo x escenario. Montgomery (2019) sostiene que los disenos factoriales permiten estudiar efectos de factores bajo condiciones controladas; en esta tesis, el control se materializa en el mismo dataset, el mismo entorno CityLearn, la misma comunidad de 17 edificios, el mismo horizonte de evaluacion y la misma familia de KPIs.

La unidad experimental principal es el tratamiento algoritmo-escenario. La unidad de observacion episodica es el episodio conservado en los artefactos de Drive, y la unidad de observacion espacial es el edificio-agente. Esta doble lectura permite responder los objetivos en tres escalas: distrito, edificio y politica multiagente. Para la inferencia estadistica se usan los episodios materializados: MAAC, MASAC y MATD3 conservan cobertura completa en los tres escenarios; HAPPO registra entrenamiento completado, pero conserva 49 filas episodicas por escenario en el CSV materializado, por lo que se reporta como evidencia descriptiva y no como grupo inferencial completo.

Tabla 3.2

Matriz factorial 4x3 de tratamientos experimentales

Factor	Niveles	Funcion metodologica
Algoritmo MADRL	HAPPO, MAAC, MASAC, MATD3	Variable independiente principal; compara familias actor-critic multiagente.
Escenario de recompensa	E1, E2, E3	Manipulacion de prioridad multiobjetivo: flexibilidad, CO2 y costo.
Tratamientos	12 combinaciones	Base de comparacion para resultados por objetivo especifico.
Horizonte	50 episodios registrados por tratamiento	Evidencia de entrenamiento Drive; se declara cobertura materializada por algoritmo.

Nota. La tabla representa el diseno metodologico, las variables, herramientas, datos y procedimiento experimental. Fuente: Elaboracion propia a partir del proyecto local, scripts de metodologia, dataset citylearn_iquitos_2023_2025 y artefactos Drive de entrenamiento.

3.3 Datos utilizados y fuente empirica

Los datos utilizados corresponden al dataset citylearn_iquitos_2023_2025 y a la corrida canonica Drive madrl_v3_20260627_164047. La tesis no incorpora datos simulados manualmente fuera del pipeline; usa artefactos generados por scripts del proyecto y resultados auditables: results.json, training_summary.json, timeseries.csv, trace.csv, building_kpis.csv,

building_behavior_summary.csv, building_observation_action_schema.csv y checkpoint_manifest.json. La fuente empirica combina meteorologia, demanda, PV, BESS, EV, precios, intensidad de carbono y KPIs CityLearn. Esta trazabilidad responde a la exigencia metodologica de reproducibilidad y control de medicion que Hernandez-Sampieri y Mendoza (2018) y Creswell y Creswell (2023) asocian con la ruta cuantitativa.

El dataset representa 17 edificios de una comunidad energetica de Iquitos, con equipos controlables heterogeneos y variables de observacion locales. La representacion por edificio permite modelar el problema como Dec-POMDP y evaluar la ejecucion descentralizada de politicas MADRL. Para evitar alucinacion o sobreinterpretacion, los resultados del Capitulo 5 se derivan exclusivamente de los archivos existentes y de tablas materializadas en outputs/_drive_madrl/gdrive_20260627_164047_objective_analysis. Las dimensiones locales medidas (d_oi en [54, 327], d_ai = 2 + n_i^ch en [5, 44], estado CTDE d_s = 1 856) constan en Cap. 2 Tabla 2.A y se operacionalizan en Cap. 4.

Tabla 3.3

Fuentes de datos y artefactos de analisis

Artefacto	Contenido	Uso metodologico
timeseries.csv	Serie temporal distrital por episodio	Energia, costo, CO2, recompensa y senales horarias.
trace.csv	Trazas por agente	Acciones, SOC, EV, PV, importacion/exportacion y recompensa individual.
building_kpis.csv / building_behavior_summary.csv	KPIs por edificio	Analisis espacial por agente y equipamiento.
checkpoint_manifest.json	Registro de checkpoints	Trazabilidad de entrenamiento y cobertura por tratamiento.
district_episode_kpis.csv	KPIs episodicos materializados	Base de estadistica descriptiva e inferencial.

Nota. La tabla representa el diseno metodologico, las variables, herramientas, datos y procedimiento experimental. Fuente: Elaboracion propia a partir del proyecto local, scripts de metodologia, dataset citylearn_iquitos_2023_2025 y artefactos Drive de entrenamiento.

3.4 Variables, dimensiones e indicadores

La variable independiente (VI) es el algoritmo MADRL implementado bajo un esquema CTDE y condicionado por escenario de recompensa. Sus dimensiones operacionales son: D-VI.1 tipo de algoritmo, D-VI.2 ponderacion multiobjetivo del escenario y D-VI.3 controles experimentales. La variable dependiente (VD) es el desempeno energetico coordinado de la comunidad, desagregado en tres dimensiones: D-VD.1 flexibilidad energetica, D-VD.2 emisiones de CO2 y D-VD.3 costos energeticos. Esta definicion mantiene correspondencia vertical con PE.1, PE.2, PE.3, OE.1, OE.2 y OE.3.

La operacionalizacion sigue la logica de medicion cuantitativa: cada dimension debe tener indicadores observables, fuente de datos y criterio de interpretacion. En D-VD.1 se consideran recompensa en E1 y KPIs de flexibilidad como peak, ramping, load factor, autoconsumo PV y uso de almacenamiento. En D-VD.2 se consideran emisiones distritales, carbon_emissions_control, carbon_emissions_delta y consumo ponderado por intensidad de carbono. En D-VD.3 se consideran district_cost, electricity_cost_control, electricity_cost_delta y senales de precio. Esta estructura evita confundir recompensa de entrenamiento con resultado final de evaluacion.

Tabla 3.4

Operacionalizacion metodologica de variables

Variable	Dimension	Indicadores principales	Fuente
VI	D-VI.1 Algoritmo	HAPPO, MAAC, MASAC, MATD3	Configuracion de tratamiento.
VI	D-VI.2 Escenario	E1, E2, E3; pesos flex/CO2/costo	reward_axis_weights y protocolo experimental.
VD	D-VD.1 Flexibilidad	reward_mean E1, peak, ramping, load factor, BESS/PV	episodes, results, evaluate_v2.
VD	D-VD.2 CO2	district_emission, carbon_emissions_control/delta	timeseries, results, building KPIs.

VD	D-VD.3 Costos	district_cost, electricity_cost_control/delta	timeseries, results, building KPIs.

Nota. La tabla representa el diseno metodologico, las variables, herramientas, datos y procedimiento experimental. Fuente: Elaboracion propia a partir del proyecto local, scripts de metodologia, dataset citylearn_iquitos_2023_2025 y artefactos Drive de entrenamiento.

3.5 Tecnicas, herramientas e instrumentos

Las tecnicas utilizadas son simulacion computacional, entrenamiento MADRL, evaluacion por KPIs, estadistica descriptiva, contrastacion no parametrica y visualizacion analitica. Las herramientas principales son Python, PyTorch, CityLearn v2, la extension CityLearn v3 propuesta, backends HAPPO/MAAC/MASAC/MATD3, scripts de orquestacion del proyecto y artefactos Drive. En terminos metodologicos, el instrumento de medicion no es un cuestionario ni una entrevista, sino el entorno computacional validado y sus archivos de salida.

La decision de usar estadistica no parametrica se debe a que las recompensas y KPIs episodicos de RL pueden presentar no normalidad, dependencia temporal, asimetria o valores atipicos. Por ello se aplica Shapiro-Wilk para normalidad; Friedman pareado por KPI (principal) con Kendall W y Wilcoxon+Holm; Kruskal-Wallis y Mann-Whitney U solo como analisis exploratorio/sensibilidad cuando no hay independencia real. Los episodios de una sola corrida (seed = 0) no son replicas independientes. Esta eleccion es coherente con la recomendacion metodologica de no asumir supuestos estadisticos no verificados y con las advertencias de evaluacion robusta en aprendizaje por refuerzo reportadas por Henderson et al. (2018) y Agarwal et al. (2021).

Tabla 3.5

Tecnicas, herramientas e instrumentos

Componente	Aplicacion en la tesis	Resultado esperado
Simulacion CityLearn	Recrear comunidad energetica multiagente	Series, KPIs y trazas auditables.

MADRL	Entrenar politicas bajo CTDE	Politicas por algoritmo y escenario.
evaluate_v2 / KPIs	Evaluar flexibilidad, CO2 y costo	Ranking comparable con baseline.
Estadistica no parametrica	Contrastar diferencias entre algoritmos	p-valores, epsilon2 y decisiones HE.
Visualizacion	Interpretar convergencia, trade-offs, edificios y acciones	Figuras del Capitulo 5.

Nota. La tabla representa el diseno metodologico, las variables, herramientas, datos y procedimiento experimental. Fuente: Elaboracion propia a partir del proyecto local, scripts de metodologia, dataset citylearn_iquitos_2023_2025 y artefactos Drive de entrenamiento.

3.6 Procedimiento experimental

El procedimiento experimental se estructura en siete fases reproducibles. Primero, se verifica el contexto del repositorio y la disponibilidad de artefactos. Segundo, se valida el dataset citylearn_iquitos_2023_2025 y el esquema de edificios/equipos. Tercero, se ejecutan o recuperan las 12 corridas algoritmo x escenario desde Drive. Cuarto, se consolidan episodios, timeseries, traces, building KPIs y checkpoints. Quinto, se calculan KPIs distritales, por edificio y por objetivo. Sexto, se aplican pruebas estadisticas y rankings evaluate_v2. Septimo, se generan tablas, figuras y redaccion interpretativa en el documento final.

Cada fase se documenta mediante archivos de salida. La decision de no completar manualmente valores ausentes es parte del control metodologico: si un artefacto no conserva una granularidad determinada, se declara como limitacion y no se sintetiza. Esta regla es consistente con la validez de medicion y la transparencia experimental recomendadas por Shadish et al. (2002) y Montgomery (2019).

Tabla 3.6

Procedimiento experimental reproducible

Fase	Actividad	Evidencia
1	Verificacion de contexto y rutas	scripts/verify_project_context.ps1.
2	Validacion de dataset y esquema	schema, building files y

	CityLearn	auditorias.
3	Entrenamiento/recuperacion de 12 tratamientos	Drive madrl_v3_20260627_164047.
4	Consolidacion de resultados	timeseries, traces, checkpoints y KPIs.
5	Analisis descriptivo e inferencial	CSV de estadisticas y comparaciones Holm.
6	Visualizacion de tesis	Figuras por convergencia, KPIs, edificios y trade-offs.
7	Integracion en Word	Documento final reproducible desde el generador.

Nota. La tabla representa el diseno metodologico, las variables, herramientas, datos y procedimiento experimental. Fuente: Elaboracion propia a partir del proyecto local, scripts de metodologia, dataset citylearn_iquitos_2023_2025 y artefactos Drive de entrenamiento.

3.7 Validez metodologica, trazabilidad y control de sesgos

La validez interna se fortalece por el control del entorno: todos los algoritmos se evaluan sobre el mismo dataset, la misma comunidad, los mismos escenarios y los mismos criterios de extraccion de KPIs. La validez de constructo se protege mediante la correspondencia entre preguntas, objetivos, variables e indicadores. La validez estadistica se aborda con pruebas no parametricas y tamanos de efecto, evitando asumir normalidad sin evidencia. La validez externa se declara limitada porque la corrida canonica no sustituye una campana multi-semilla; por tanto, las conclusiones se formulan como evidencia de tesis intra-corrida y no como generalizacion universal.

El control de sesgos se apoya en cinco reglas: no mezclar resultados de otros proyectos, no usar artefactos ajenos a Drive/local autorizado, no inventar datos faltantes, distinguir evidencia descriptiva de evidencia inferencial y reportar limitaciones de cobertura. Este criterio es central para una tesis basada en RL, donde diferencias aparentemente favorables pueden depender de semillas, hiperparametros, entorno y criterio de evaluacion.

Tabla 3.7

Control metodologico de validez y trazabilidad

Dimension de validez	Riesgo	Control aplicado
Interna	Comparacion desigual entre algoritmos	Mismo dataset, mismo entorno y escenarios controlados.
Constructo	Indicadores no alineados con objetivos	PE/OE/VD/KPI vinculados por tabla de operacionalizacion.
Estadistica	Normalidad o significancia asumida	Shapiro-Wilk, Kruskal-Wallis, Mann-Whitney-Holm y epsilon2.
Externa	Generalizacion indebida	Declaracion de inferencia intra-corrida y recomendacion multi-semilla.
Trazabilidad	Datos inventados o mezclados	Uso exclusivo de artefactos Drive y CSV materializados.

Nota. La tabla representa el diseno metodologico, las variables, herramientas, datos y procedimiento experimental. Fuente: Elaboracion propia a partir del proyecto local, scripts de metodologia, dataset citylearn_iquitos_2023_2025 y artefactos Drive de entrenamiento.

3.4.6 Árbol CityLearn retenido: usados vs disponibles (reproducibilidad)

El submódulo CityLearn/ conserva, además del dataset Iquitos, el árbol de datos del ecosistema CityLearn v2 embebido en el fork de la tesis. Ese material no se elimina (decisión 2026-07-29): sirve de contexto metodológico, integridad de pruebas del paquete y reproducibilidad offline del simulador. El caso empírico de contraste de hipótesis (Capítulo 5) sigue siendo exclusivamente citylearn_iquitos_2023_2025 + capa MADRL v3.

En CityLearn/data/datasets/ se retienen: (i) citylearn_iquitos_2023_2025 (empírico canónico OE.1–OE.3); (ii) citylearn_challenge_2020–2023 (contexto histórico de benchmarking comunitario; challenge 2022 y demos alimentan tests del submódulo); (iii) barrios de referencia quebec_neighborhood_*, ca_alameda_county_neighborhood, tx_travis_county_neighborhood y vt_chittenden_county_neighborhood (inventario reproducible; contraste cualitativo con el SEAI aislado). No se atribuyen KPIs ni pruebas estadísticas a barrios o challenges upstream en ausencia de artefactos en outputs/.

Los launchers launch_citylearn_v3_iquitos_training.ps1 y monitor_citylearn_v3_iquitos_training.ps1 se retienen como vía histórica local; la vía canónica de entrenamiento permanece launch_citylearn_v3_official_training.ps1 y, para la corrida de 50 episodios, el protocolo Colab del notebook madrl_citylearn_v3_tutorial.ipynb. Detalle: docs/INTEGRACION_CITYLEARN_THESIS_2026-07-29.md.

Capitulo 4. Desarrollo e implementacion de la coordinacion energetica multiobjetivo mediante MADRL

4.1 Arquitectura general del sistema

La propuesta implementa un sistema de coordinación energética multiobjetivo mediante aprendizaje por refuerzo profundo multiagente (MADRL: HAPPO, MASAC, MATD3 y MAAC) sobre una comunidad inteligente heterogénea de Iquitos. El flujo de datos y control es lineal y reproducible:

datos → CityLearn → comunidad heterogénea → Dec-POMDP → agentes → CTDE → MADRL → recursos controlables → recompensas E1/E2/E3 → entrenamiento → evaluación → artefactos.

```
flowchart LR
A[Datos SEAI / PVGIS / NASA / TOU] --> B[CityLearn v2 + fork A1–A4]
B --> C[Comunidad heterogénea 17 edificios]
C --> D[Dec-POMDP N=17]
D --> E[Agentes edificio]
E --> F[CTDE]
F --> G[MADRL HAPPO/MASAC/MATD3/MAAC]
G --> H[BESS / EV-V2G / cargas desplazables]
H --> I[Reward E1/E2/E3]
I --> J[Entrenamiento 4×3]
J --> K[Evaluación + baseline v2]
K --> L[Artefactos outputs/]
```

4.1.1 Frontera heredada frente a aportes de la tesis

Componente	Frontera	Rol
Física CityLearn v2 (edificios, BESS,	**Heredada** (Nweye et al., 2024)	Simulador base; baseline `baseline` /

PV, EV, KPIs `evaluate_v2`)		`hour_rbc`
Dataset `citylearn_iquitos_2023_2025`	**Aporte tesis** (`tools/dataset/`)	17 edificios SEAI, 26 304 h, 222 CSV
Extensiones A1–A4 (Arrhenius, PV IEC, pico OSINERGMIN, `CarbonIntensityModel`)	**Aporte tesis** (fork)	Realismo tropical / red aislada
Capa v3 Dec-POMDP + wrappers CTDE	**Aporte tesis** (`citylearn/v3/`, `dec_pomdp.py`)	Observabilidad parcial y estado centralizado
`CityLearnV3MADRLRewardFunction` (E1/E2/E3)	**Aporte tesis**	Operacionalización OE.1–OE.3
Backends HARL / MARL / off-policy / MAAC	**Heredados** (`external/`)	Algoritmos; no se editan
Wrappers + `train_citylearn_v3_*.py` + adaptador común	**Aporte tesis**	Puente CityLearn ↔ backends
Orquestación Colab / validadores / tesis Word	**Aporte tesis** (`scripts/`, `tools/`)	Reproducibilidad y evidencia

El paquete uc3m/ (BACT, HPHI, EmpiricalProtocol) constituye sustento de diseño; las doce corridas canónicas no pasan por esa fachada.

4.2 Comunidad inteligente heterogénea

La unidad experimental es la comunidad de 17 edificios institucionales/comerciales del SEAI (Iquitos), tipológicamente heterogénea en área, demanda, PV, BESS y flota EV. Dimensionamiento auditado en data/dataset_audit/der_sizing_audit.csv (totales distritales: PV 48 790,9 kWp; BESS 26 266 kWh / 6 648 kW; 185 cargadores EV).

4.2.1 Inventario cuantitativo de los 17 edificios

ID	Edificio (abreviado)	Tipo	Área m²	Demanda MWh	PV kWp	BESS kWh/kW	EV n / kW	Máq. ctrl.

B01	ELECTRO ORIENTE S.A.	Office	14 000	17 378,1	3 360,2	6 747 / 1 609	4 / 21,8	Sí
B02	Mun. San Juan Bautista	Office	8 000	247,5	1 920,0	244 / 50	6 / 24,4	Sí
B03	Aeropuerto Internacional	Assembly	6 000	3 155,2	1 440,2	2 363 / 511	8 / 37,8	Sí
B04	Hipermercados Tottus	Retail	2 500	4 131,9	600,2	454 / 409	6 / 24,4	Sí
B05	Hotel Plaza S.A.	MultiFamily_Hotel	1 141,89	3 000,1	274,1	234 / 124	3 / 14,4	Sí
B06	Mall Aventura S.A.	Commercial_Mall	20 637	34 622,6	4 952,9	2 541 / 835	32 / 119,6	Sí
B07	UNAP Biología	Education	8 103,45	1 314,1	1 944,9	984 / 240	42 / 153,2	Sí
B08	PNP Escuela Técnica	Assembly_Military	21 000	873,7	5 040,2	601 / 129	17 / 73,6	Sí
B09	GORE Loreto — COER	Office_Critical	4 479,67	234,8	1 075,3	138 / 30	10 / 37,4	Sí
B10	Gobierno Regional Loreto	Office	14 295,73	3 838,1	3 431,1	2 353 / 591	6 / 36,6	Sí
B11	Hospital Regional Loreto	Healthcare_Hospital	42 649,33	3 018,9	10 236,1	1 901 / 424	3 / 14,4	Sí
B12	EsSalud	Healthcare	18 197,48	7 120,6	4 367,5	4 346 / 960	3 / 14,4	Sí
B13	UNAP Cs. Contables y Eco.	Education	2 723	388,6	653,8	272 / 69	11 / 41,4	Sí

B14	Autoridad Portuaria Nacional	Industrial_Port	17 761	327,9	4 262,9	229 / 48	4 / 21,8	Sí
B15	DREL — Colegio Nacional	Education	9 889,92	683,7	2 373,8	500 / 104	8 / 31,4	Sí
B16	SIMA — Iquitos	Industrial	10 294	2 134,6	2 470,8	1 622 / 357	11 / 41,4	Sí
B17	Asoc. Civil Selva Amazónica	Laboratory	1 611,23	1 406,4	386,9	737 / 158	11 / 41,4	Sí
Σ					**48 790,9**	**26 266 / 6 648**	**185 / 749,4**	**17**

Fuente: data/dataset_audit/der_sizing_audit.csv (columnas PV_schema_kWp, BESS_schema_, EV_schema_, Carga_total_MWh, Maquina_controlada_count). Demanda redondeada a 1 decimal; potencias EV = EV_schema_kW.

4.2.2 Señales controlables frente a exógenas

Clase	Variables	Naturaleza
Controlables (acción MADRL)	`electrical_storage` (BESS), `electric_vehicle_storage` × \(n_i^{\mathrm{ch}}\) (EV/V2G), `washing_machine` (carga desplazable)	Setpoints en \([-1,1]\) por canal
Exógenas (no actuadas)	Precio TOU/RTP (`pricing.csv`), intensidad de carbono CI ∈ [0,6715; 0,790] $kgCO_2/kWh$ (`carbon_intensity.csv`), meteorología	Observables; entran en \(o_i\) y en \(R\), no en \(a_i\)

	(`weather.csv`: T, RH, irradiancia, viento), carga no desplazable residual	

La generación PV es física determinista condicionada por GHI/temperatura (aporte A2); el agente no fija potencia PV, solo reacciona vía almacenamiento, EV y carga desplazable.

4.3 Datos y preprocesamiento

4.3.1 Origen y periodo

El dataset citylearn_iquitos_2023_2025 se construye desde datos primarios del SEAI (facturación Electro Oriente S.A.), meteorología PVGIS-ERA5 (2023, vía pvlib) y NASA POWER (2024–2025), e incentivos tarifarios TOU locales (0,38 USD/kWh en punta 18:00–22:59; 0,26 USD/kWh fuera de punta). Periodo: 2023–2025; horizonte tabular: 26 304 horas; artefactos activos auditados: 222 CSV.

Pipeline canónico: tools/dataset/generate_iquitos_dataset.py / orchestrate_citylearn_dataset.py → CityLearn/data/datasets/citylearn_iquitos_2023_2025/ (schema.json, Building_.csv, charger_.csv, Washing_Machine_*.csv, weather.csv, carbon_intensity.csv, pricing.csv).

4.3.2 Limpieza, fugas temporales y compuerta NaN/Inf

1. Destilación de cargas mensuales a horarias (distill_building_loads.py) con balance residual NSL y error mensual de cierre < 0,1 %. 2. Series meteorológicas cacheadas (.cache/weather/{year}.parquet) sin remezcla futuro→pasado: el episodio de entrenamiento usa el schema completo en orden temporal horario. 3. Dimensionamiento DER/EV/lavadoras antes del schema.json; sin imputación ad hoc en el bucle MADRL. 4. Compuerta de calidad: check_training_dataset_ready.py, audit_citylearn_csv_integrity.py, audit_der_sizing.py →

manifiestos en outputs/dataset_audit/. Criterio de aceptación: status=ready, 0 NaN / 0 Inf, sin cargadores ni máquinas huérfanos.

No se adopta un dataset CityLearn upstream como caso empírico: los barrios/challenges retenidos en el submódulo sirven solo a integridad y reproducibilidad del paquete (Cap. 3 §3.4.6).

4.4 Entorno CityLearn y extensiones

4.4.1 Capa heredada CityLearn v2

Se conserva la física de edificios, almacenamiento, PV, EV/V2G y la batería de KPIs vía env.evaluate_v2(). El baseline de contraste (baseline, hour_rbc) proviene de esta capa. La propuesta extiende el simulador; no lo sustituye.

4.4.2 Aportes A1–A4 del fork (tesis)

Código	Aporte	Archivo	Función
A1	Degradación BESS C-rate + Arrhenius ($LiFePO_4$)	`energy_model.py`	Realismo térmico tropical
A2	Corrección PV IEC 61215	`energy_model.py`	Derating tropical ≈ 10,9–14,4 % vs STC
A3	Pico con ventana de facturación	`cost_function.py`	Alineación OSINERGMIN MT-3/MT-4
A4	`CarbonIntensityModel`	`energy_model.py`	CI dinámica diésel+PV: \(CI(t)=0{,}790\times(1-0{,}15\times\min(GHI/1000,1))\)

Documentación: docs/thesis/APORTES_SIMULACION_CITYLEARN_MADRL_TESIS.md; arquitectura: docs/architecture/ARQUITECTURA_Y_FLUJO_TRABAJO_CITYLEARN_V3_MADRL.md §4b.

4.5 Formulación Dec-POMDP

El control distrital se formula como Dec-POMDP cooperativo:

\[\mathcal{M}=\langle\mathcal{S},\{\mathcal{A}_i\}_{i=1}^{17},\mathcal{T},R,\{\mathcal{O}_i\}_{i=1}^{17},\Omega,\gamma,T\rangle \]

Implementación: CityLearn/citylearn/dec_pomdp.py, fábrica citylearn/v3/, adaptador CityLearn/scripts/citylearn_v3_training_common.py. Dimensiones medidas con CityLearnEnv(schema Iquitos, central_agent=False).

Símbolo	Mapeo físico	Valor Iquitos
\(N\)	Agentes-edificio	**17**
\(\mathcal{S}\)	Estado CTDE \(s=[o_1,\ldots,o_{17}]\)	\(\lvert\mathcal{S}\rvert=d_s=\mathbf{1\,856}\)
\(o_i\in\mathcal{O}_i\)	Observación local (calendario, meteo, carga, térmica, PV, SoC BESS, 7 canales EV/toma, precio, CI)	\(d_{o_i}\in[\mathbf{54},\mathbf{327}]\)
\(a_i\in\mathcal{A}_i\)	BESS + EV×\(n_i^{\mathrm{ch}}\) + lavadora	\(d_{a_i}=2+n_i^{\mathrm{ch}}\in[\mathbf{5},\mathbf{44}]\); \(\sum_i d_{a_i}=\mathbf{219}\)
\(R\)	Recompensa mixta cooperativa	`team_reward_ratio` \(r_{\mathrm{team}}=0{,}70\)
\(\gamma\)	Descuento	**0,9999**
\(T\)	Horizonte por episodio	**8 760** pasos (1 año horario)
\(\mathcal{T},\Omega\)	Física CityLearn + observación schema	Transición horaria; observabilidad parcial estricta

Agregación cooperativa canónica (canal de las 12 corridas):

\[\mathrm{mixed}_i=(1-r_{\mathrm{team}})\,\mathrm{reward}_i+r_{\mathrm{team}}\cdot\mathrm{mean}_j(\mathrm{reward}_j),\quad r_{\mathrm{team}}=0{,}70. \]

El distrito no es un agente adicional: entra por el crítico CTDE (\(s\)) y por KPIs agregados evaluate_v2.

4.6 CTDE

Entrenamiento centralizado / ejecución descentralizada:

- Centralizado (train): el crítico (o mezcla Q, según backend) recibe información conjunta —en la práctica el estado CTDE \(s\in\mathbb{R}^{1856}\) o su equivalente por wrapper— para estabilizar el crédito multiagente. - Descentralizado (exec): cada política \(\pi_i(a_i\mid o_i)\) actúa solo con \(o_i\); no hay comunicación entre edificios en despliegue. - Post-entrenamiento solo persisten las políticas locales.

Algoritmo	Lectura CTDE en esta tesis
HAPPO	On-policy; actor local continuo; crítico / valor con observación compartida CTDE (`CityLearnHARLEnv`)
MASAC	Off-policy entrópico; estado global tipo SMAC + mezcla cooperativa QMIX (`CityLearnSMACDiscreteEnv`)
MATD3	Off-policy determinístico continuo; críticos centralizados / info conjunta (`CityLearnOffPolicyVecEnv`)
MAAC	Attention-critic CTDE; acciones discretas (`CityLearnMAACVecEnv`)

4.7 Algoritmos MADRL

Los backends residen en external/; la tesis aporta wrappers y scripts de entrenamiento. Sustento teórico de la adecuación: Cap. 2.

Algoritmo	Wrapper	Backend	Paradigma	Acción
HAPPO	`CityLearnHARLEnv`	`external/HARL`	on-policy CTDE	continua
MASAC	`CityLearnSMACDiscreteEnv`	`external/MARL/src`	entropy-regularized + QMIX	discreta (`bins=3`, modo eje)
MATD3	`CityLearnOffPolicyVecEnv`	`external/off-policy`	off-policy determinístico	continua
MAAC	`CityLearnMAACVecEnv`	`external/MAAC`	attention-critic CTDE	discreta (`bins=3`)

4.7.1 HAPPO

Actualización secuencial con región de confianza para agentes heterogéneos. Script: train_citylearn_v3_happo.py. Acciones continuas en \([-1,1]^{d_{a_i}}\).

4.7.2 MASAC

Regularización de entropía multiagente con mezcla tipo QMIX. Script: train_citylearn_v3_masac.py. Discretización tractable (action_bins=3, no producto cartesiano \(3^{d_{a_i}}\)).

4.7.3 MATD3

Doble crítico, policy delay y ruido sobre el target; control continuo BESS/EV. Script: train_citylearn_v3_matd3.py (backend PyTorch external/off-policy).

4.7.4 MAAC

Crítico con atención multi-cabeza sobre los 17 agentes. Script: train_citylearn_v3_maac.py.

Tabla comparativa de hiperparámetros canónicos (50 episodios)

Fuente: notebook examples_madrl_v3/madrl_citylearn_v3_tutorial.ipynb (celda 6.1, HYPERPARAMS), protocolo two_phase_happo_masac_v3.

Parámetro	HAPPO	MASAC	MATD3	MAAC
Episodios × pasos	50 × 8 760	50 × 8 760	50 × 8 760	50 × 8 760
`gamma` (\(\gamma\))	0,9999	0,9999	0,9999	0,9999
`hidden_size`	[512, 512]	rnn 64 / qmix 32	768	768
Buffer	on-policy	2 ep (CPU)	2 000 000	1 000 000
Batch	rollout	512	1 024	512
LR actor / crítico	1e-4 / 5e-4	3e-4 / 5e-4	3e-4 / 3e-4	3e-4 / 1e-3

La validación local (p. ej. 5 episodios, RTX 4060 8 GB) comprueba el pipeline; no sustituye la corrida canónica Colab madrl_v3_20260627_164047.

4.8 Recursos controlables

Las acciones del schema Iquitos son exactamente tres familias (§2.2.6.3):

\[a_{i,t}=\big(a_i^{\mathrm{BESS}}(t),\,a_{i,1}^{\mathrm{EV}}(t),\ldots,a_{i,n_i^{\mathrm{ch}}}^{\mathrm{EV}}(t),\,a_i^{\mathrm{WM}}(t)\big)\in[-1,1]^{d_{a_i}}. \]

4.8.1 BESS

- Modelo: batería CityLearn v2 + degradación A1 (C-rate y Arrhenius). - Límites: capacidad/potencia por edificio (Tabla 4.2.1); SoC acotado por la física del Battery. - Acción: electrical_storage ∈ \([-1,1]\) (carga/descarga normalizada). - Inventario distrital: 26 266 kWh / 6 648 kW.

4.8.2 EV / V2G

- Modelo: tomas Mode 3; 185 cargadores schema; subconjunto V2G bidireccional documentado en Cap. 3 (31 tomas de camionetas). - Límites: potencia por toma (EV_schema_kW); SoC, llegada/salida y ventana operativa en observación (7 canales/toma). - Acción: electric_vehicle_storage por cargador ∈ \([-1,1]\). - Potencia nominal simultánea auditada: 749,4 kW.

4.8.3 Cargas desplazables

- Modelo: una lavadora controlada por edificio (washing_machine; 17 máquinas). - Límites: ciclos y potencia pico en CSV Washing_Machine_.csv / columnas de auditoría Maquina_controlada_. - Acción: canal binario/continuo normalizado en el espacio de acción del agente. - Las cargas residuales no desplazables permanecen exógenas.

4.9 Función de recompensa E1/E2/E3

Clase CityLearnV3MADRLRewardFunction:

\[\mathrm{reward}_i(t)=\mathrm{reward_scale}\cdot\big[w_{\mathrm{flex}}\mathrm{flex}_i +w_{\mathrm{carbon}}\mathrm{carbon}_i+w_{\mathrm{cost}}\mathrm{cost}_i+w_{\mathrm {ev}}\mathrm{ev}_i\big]. \]

Agregación cooperativa: \(r_{\mathrm{team}}=0{,}70\). Perfil unificado de comparabilidad *_unified_comparable_v4: peak_weight=0,45, ramp_weight=0,35, ev_weight=0,25 (constantes entre algoritmos para no confundir VI con cambios de \(R\)).

Escenario	OE	\(w_{\mathrm{flex}}\)	\(w_{\mathrm{carbon}}\)	\(w_{\mathrm{cost}}\)	KPI primario de diseño
E1	OE.1 Flexibilida	**0,70**	0,15	0,15	`peak_average` / flex_composite

	d				
E2	OE.2 CO_2	0,15	**0,70**	0,15	`carbon_emissions_total`
E3	OE.3 Costos	0,25	0,15	**0,60**	`electricity_cost_total`

Nota metodológica: la recompensa de estado (señal de entrenamiento) no es el KPI final de contrastación. Los efectos diferenciales se miden en Cap. 5 con KPIs físicos / KPI-gains frente al baseline CityLearn v2.

4.10 Diseño experimental

Diseño factorial 4 × 3 = 12 tratamientos (algoritmo × eje), corrida canónica madrl_v3_20260627_164047.

#	Algoritmo	Eje	Episodios	Seed	Horizonte	Config / salida
1	HAPPO	E1	50	0	8 760	`happo/E1_seed_0`
2	HAPPO	E2	50	0	8 760	`happo/E2_seed_0`
3	HAPPO	E3	50	0	8 760	`happo/E3_seed_0`
4	MASAC	E1	50	0	8 760	`masac/E1_seed_0`
5	MASAC	E2	50	0	8 760	`masac/E2_seed_0`
6	MASAC	E3	50	0	8 760	`masac/E3_seed_0`
7	MATD3	E1	50	0	8 760	`matd3/E1_seed_0`
8	MATD3	E2	50	0	8 760	`matd3/E2_seed_0`
9	MATD3	E3	50	0	8 760	`matd3/E3_seed_0`
10	MAAC	E1	50	0	8 760	`maac/E1_seed_0`
11	MAAC	E2	50	0	8 760	`maac/E2_seed_0`
12	MAAC	E3	50	0	8 760	`maac/E3_seed_0`

Orquestación canónica: notebook madrl_citylearn_v3_tutorial.ipynb + colab_a100_official_launcher.py (two_phase_happo_masac_v3). Validación de plan: tools/training/validate_launch_config.py. Raíz de artefactos: outputs/madrl_v3_20260627_164047/.

4.11 Entrenamiento

Fase	Contenido
Inicialización	Schema Iquitos; escenario E1/E2/E3; seed = 0; wrapper del algoritmo; hiperparámetros §4.7; verificación de contexto `scripts/verify_project_context.ps1`
Interacción	Rollout horario \(T=8760\); observación local \(o_i\); acción \(a_i\); transición física; recompensa mixta
Actualización	Gradientes según paradigma (on-policy HAPPO; off-policy MASAC/MATD3/MAAC) sobre batch/rollout
Checkpoint	Persistencia periódica + reanudación `--skip-completed` / manifests de checkpoint
Terminación	Cupo de episodios (objetivo 50) o parada por error/OOM con reintento del launcher
Almacenamiento	Por job: `results.json`, `training_summary.json`, `timeseries.csv`, `trace.csv`, `core_kpis.csv`, `figures/`, checkpoints bajo `{algo}/E*_seed_0/`

Adaptador común: citylearn_v3_training_common.py. Guardas: tensores finitos, heartbeats, auditoría episodes_recorded.

4.12 Evaluación

Elemento	Especificación
Baseline	CityLearn v2: `baseline` y `hour_rbc` (`benchmark_citylearn_v2_agents.py`)
Periodo / horizonte	Mismo schema horario; episodio de evaluación alineado a 8 760 pasos
KPI	`env.evaluate_v2()` (flexibilidad, carbono, costo, EV, etc.); KPI-gains orientados vs baseline como unidad de contraste Cap. 5
Unidad de análisis	Tratamiento algoritmo × escenario (seed = 0); reportes a nivel distrito y edificio
Artefactos	Comparador `compare_citylearn_v2_vs_v3_madrl.py`; `best_madrl_report.json`; carpeta `resumen_comparativo/`; puente multicriterio en `outputs/madrl_multicriteria_selection/` (metodología; interpretación en Cap. 5)

Este capítulo fija el contrato de evaluación; no reporta tablas de ranking ni decisiones de hipótesis.

4.13 Reproducibilidad

Dimensión	Valor canónico
Software	Python 3.9 (`.venv39-citylearn-v3`), PyTorch 2.8.0+cu126, CUDA 12.6; pytest 8.4.2 (validación)
Activación	`scripts/activate_citylearn_v3.ps1` (`PYTHONPATH` = raíz + `CityLearn/`)
Hardware local	NVIDIA RTX 4060 Laptop 8 GB (validación de pipeline)
Hardware canónico	Google Colab Pro+ (A100 / H100 según runtime del

	notebook); protocolo `two_phase_happo_masac_v3`
Semilla	seed = 0 en las 12 corridas reportadas
Rutas	Dataset: `CityLearn/data/datasets/citylearn_iquitos_2023_2025/`; run: `outputs/madrl_v3_20260627_164047/`; auditoría DER: `data/dataset_audit/der_sizing_audit.csv`
Ops	`deploy/` (Docker/AWS) opcional; no sustituye la evidencia Colab

---

4.14 Validación técnica

4.14.1 Suite automatizada (2026-07-29)

.\.venv39-citylearn-v3\Scripts\python.exe -B -m pytest tests/uc3m/ tests/citylearn_v3/ -v --tb=line

Resultado: 184 passed (180 tests/uc3m/ + 4 tests/citylearn_v3/), 1 warning no bloqueante; duración ≈ 91 s. Entorno: Python 3.9.25, raíz D:\MADRLCitytleranflexresdr, contexto verificado.

4.14.2 Controles de integridad operativa

- Acciones en rangos de actuadores; evolución de SoC BESS/EV bajo física CityLearn; filtros NaN/Inf en tensores y CSV del dataset. - tools/training/validate_launch_config.py: PASS en construcción de 12 jobs 4×3, hiperparámetros por algoritmo y dry-run del scheduler (concurrencia ≤ 6; fase 1 HAPPO+MASAC).

La validación de software no sustituye el entrenamiento Colab ni la batería estadística del Cap. 5.

4.15 Correspondencia OE.1→E1, OE.2→E2, OE.3→E3 y OG→E1+E2+E3

Se citan los elementos definitivos de investigación (sin reformular) y su operacionalización técnica. Cap. IV no contrastará hipótesis.

Alcance	Texto rector (efectos diferenciales)	Escenario / pesos	Variables / KPI de diseño	Rutas
OE.1	Determinar y cuantificar los efectos diferenciales de HAPPO, MASAC, MATD3 y MAAC sobre la **flexibilidad energética (eje E1)** e identificar el algoritmo de mejor desempeño en la comunidad inteligente heterogénea de Iquitos	**E1:** 0,70 / 0,15 / 0,15	`peak_average`, `ramping_average`, `one_minus_load_factor_average`, flex_composite	`*/E1_seed_0/`; `CityLearnV3MADRLRewardFunction`
OE.2	… sobre las **emisiones de CO_2 (eje E2)** …	**E2:** 0,15 / 0,70 / 0,15	`carbon_emissions_total` (+ deltas vs baseline)	`*/E2_seed_0/`; `carbon_intensity.csv`
OE.3	… sobre los **costos energéticos (eje E3)** …	**E3:** 0,25 / 0,15 / 0,60	`electricity_cost_total` (+ TOU/RTP)	`*/E3_seed_0/`; `pricing.csv`

OG	Determinar y cuantificar los efectos diferenciales … en la **coordinación energética multiobjetivo** … e identificar el algoritmo de mejor desempeño **global**	**E1+E2+E3** (integración)	Score de escenario / multicriterio (pesos iguales ⅓ por defecto en puente metodológico)	`outputs/madrl_v3_20260627_164047/resumen_comparativo/`; `outputs/madrl_multicriteria_selection/`

Tema del título: coordinación energética multiobjetivo; mecanismo: MADRL HAPPO/MASAC/MATD3/MAAC; unidad: comunidad inteligente heterogénea de Iquitos. La identificación del mejor desempeño pertenece al objetivo y se resuelve con evidencia en Cap. 5; no se anticipa aquí.

Estado del capítulo

Estructura 4.1–4.15 completa: arquitectura (heredado vs aporte), comunidad 17 edificios, datos/preprocesamiento, CityLearn A1–A4, Dec-POMDP, CTDE, algoritmos e hiperparámetros, recursos BESS/EV/cargas, recompensa E1/E2/E3, diseño 4×3 (madrl_v3_20260627_164047), entrenamiento, evaluación, reproducibilidad, validación técnica (184 pytest) y correspondencia OE↔E / OG↔E1+E2+E3. Pendiente de consumo en Cap. 5: interpretación de artefactos y contrastación de hipótesis.

Capitulo 5. Resultados, efectos diferenciales y desempeno algoritmico

---

5.1 Auditoría inicial de resultados

La auditoría de integridad de la campaña canónica verifica tratamientos, episodios, semillas, cobertura, datos faltantes, igualdad de horizonte e integridad de artefactos.

Tratamientos. Diseño factorial cuasiexperimental 4 × 3: algoritmos HAPPO, MASAC, MATD3 y MAAC × escenarios E1 (flexibilidad), E2 (CO_2) y E3 (costos), sobre la comunidad inteligente heterogénea de 17 edificios del SEAI–Iquitos (CityLearn v2 + capa MADRL v3). Baseline de contraste: CityLearn v2 (baseline / controles RBC).

Episodios y semillas. Horizonte nominal de 50 episodios por tratamiento. Semilla de campaña seed = 0 (una sola semilla). Los episodios de una corrida no constituyen réplicas experimentales independientes ni permiten afirmar robustez multisemilla.

Cobertura e igualdad de horizonte.

Algoritmo	E1	E2	E3	KPI-gains finales (Capa A)	Uso en HE/H0G
MATD3	50	50	50	Sí	Descriptivo + inferencial
MAAC	50	50	50	Sí	Descriptivo + inferencial
MASAC	50	50	50	Sí	Descriptivo + inferencial
HAPPO	**49**	**49**	**49**	**No** (comparables)	Solo descriptivo; **excluido de HE**

Datos faltantes. HAPPO completa 49/50 episodios en E1–E3 y no aporta KPI-gains finales comparables; por ello permanece fuera de Wilcoxon vs baseline, Friedman, post hoc Holm y decisiones HE10–HE31 / H0G–H1G. El trío MAAC–MASAC–MATD3 aporta cobertura 50/50 con KPI-gains.

Integridad. La contrastación de hipótesis se ancla exclusivamente a Capa A (descriptivos_kpi_gains_por_problema.csv, normalidad_shapiro_por_problema.csv, impacto_vs_baseline_wilcoxon.csv, pruebas_omnibus_problemas_objetivos.csv, comparaciones_wilcoxon_pareado_holm.csv, decisiones_problemas_objetivos_hipotesis.csv). Rankings best_madrl, evaluate_v2 4/4 y TOPSIS son planos descriptivos complementarios y no sustituyen HE.

5.1-bis Entrenamiento canónico (curvas y eficiencia)

Esta subsección documenta el entrenamiento de la corrida madrl_v3_20260627_164047 (seed = 0). La recompensa episódica es señal de aprendizaje; no sustituye los KPI físicos ni la contrastación HE de §5.3–§5.6. Los costos de evaluación distrital (OE.3) se reportan en USD (tarifas TOU 0,26/0,38 USD/kWh); las claves internas *_eur son etiquetas legacy.

Tabla 5.1b. Resumen de entrenamiento (retorno episódico; fuente: training_efficiency.csv por job).

Algoritmo	Esc.	Episodios	Retorno ep. 0	Retorno final	Pasos (último)
MATD3	E1	50	−108 570	−93 382	8 760
MATD3	E2	50	−80 105	−80 417	8 760
MATD3	E3	50	−84 649	−83 495	8 760
MAAC	E1	50	−87 889	−91 202	8 749
MAAC	E2	50	−76 217	−78 497	8 749
MAAC	E3	50	−78 305	−80 610	8 749
MASAC	E1	50	−92 493	−87 682	8 748
MASAC	E2	50	−78 666	−76 218	8 748
MASAC	E3	50	−80 906	−78 282	8 748
HAPPO	E1	49	−105 169	−94 432	8 760
HAPPO	E2	49	−80 876	−72 760	8 760
HAPPO	E3	49	−84 822	−77 867	8 760

Nota. HAPPO registra 49/50 episodios y queda fuera de HE. Las figuras de convergencia y eficiencia se insertan en el Word canónico (escenario primario por eje: MATD3–E1, MASAC–

E2, MAAC–E3, HAPPO–E1; más curva multicriterio). Fuente PNG: {ALGO}/{E}/figures/convergence_returns.png, learning_efficiency.png y outputs/madrl_multicriteria_selection/figures/learning_curves.png.

Figuras de entrenamiento (curadas)

Se embeden 9 figuras reales de la corrida canónica (convergencia y eficiencia en el escenario primario por algoritmo, más curva multicriterio). La Tabla 5.1b del texto resume los retornos; la recompensa no sustituye HE.

CAP5_TRAINING_USD_APA_20260807

Las Figuras 5.1b–5.1j muestran convergencia y eficiencia (MATD3–E1, MASAC–E2, MAAC–E3, HAPPO–E1).

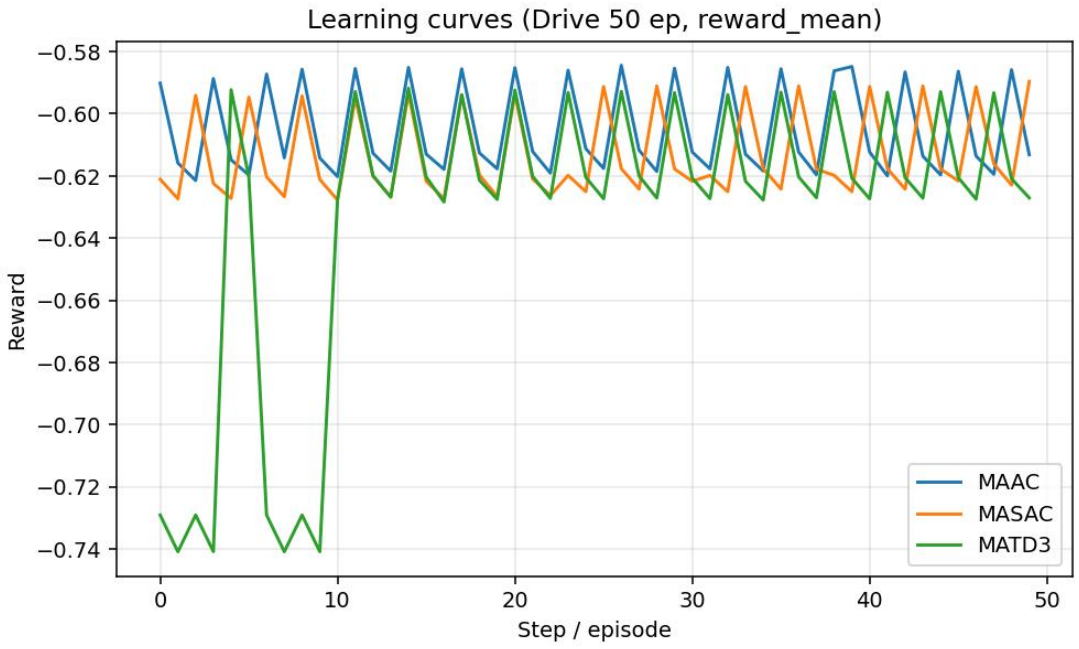


Figura 5.1b. Curvas de aprendizaje multicriterio (50 episodios).

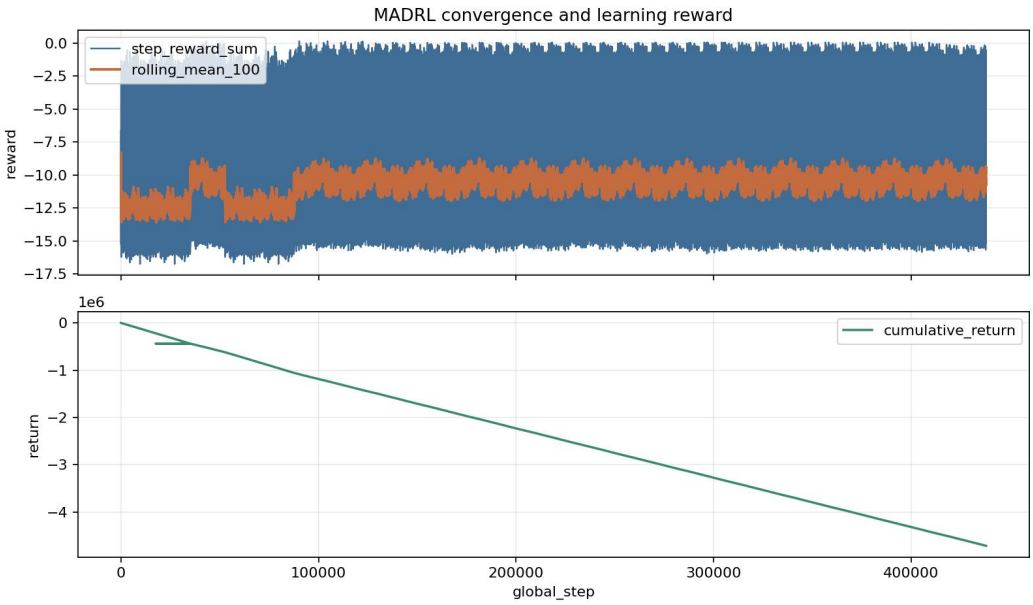


Figura 5.1c. MATD3/E1 — convergencia de retornos episódicos.

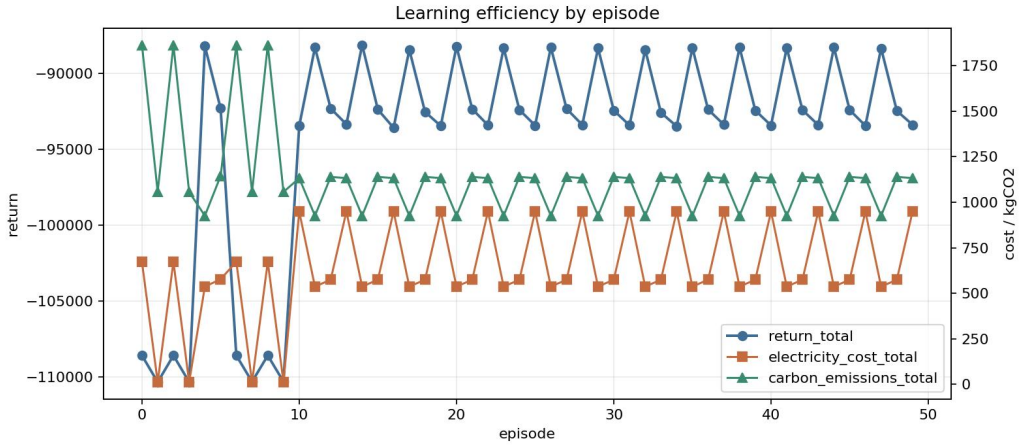


Figura 5.1d. MATD3/E1 — eficiencia de aprendizaje.

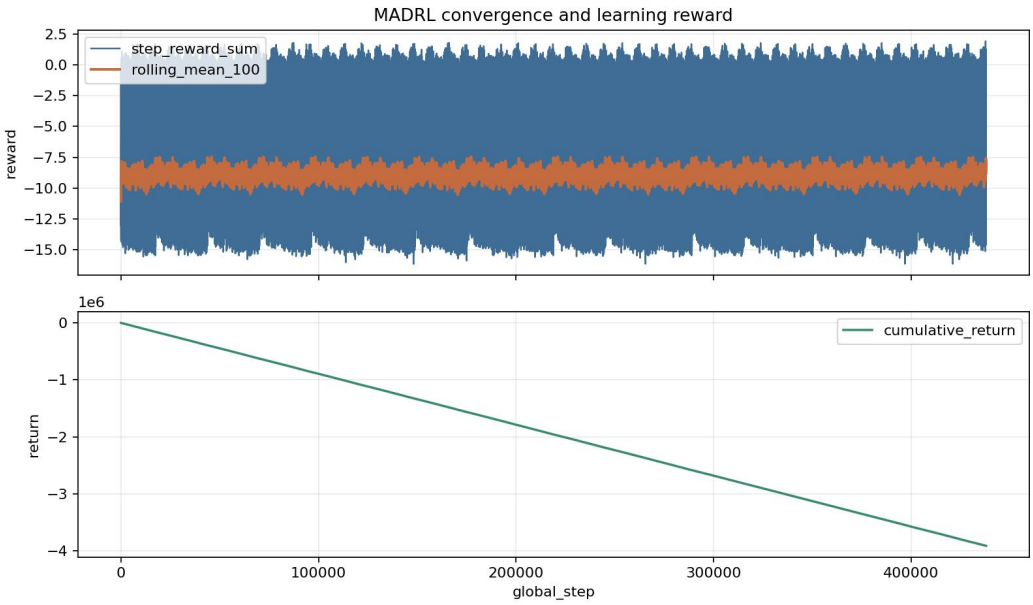


Figura 5.1e. MASAC/E2 — convergencia de retornos episódicos.

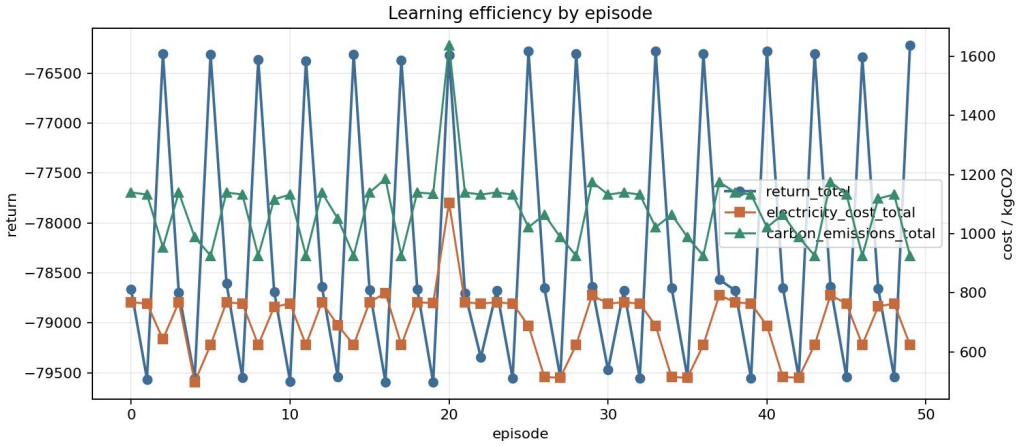


Figura 5.1f. MASAC/E2 — eficiencia de aprendizaje.

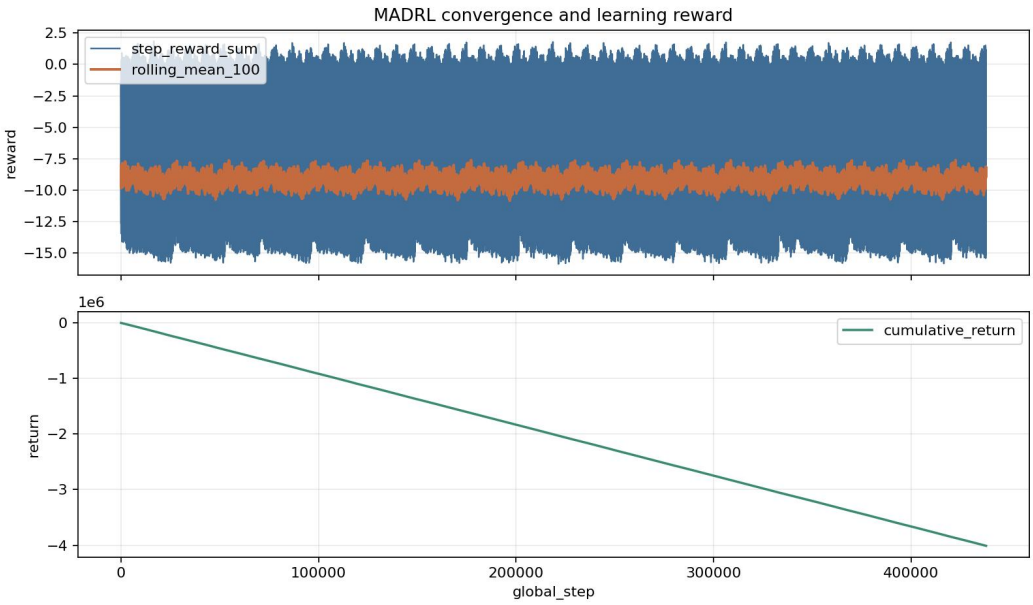


Figura 5.1g. MAAC/E3 — convergencia de retornos episódicos.

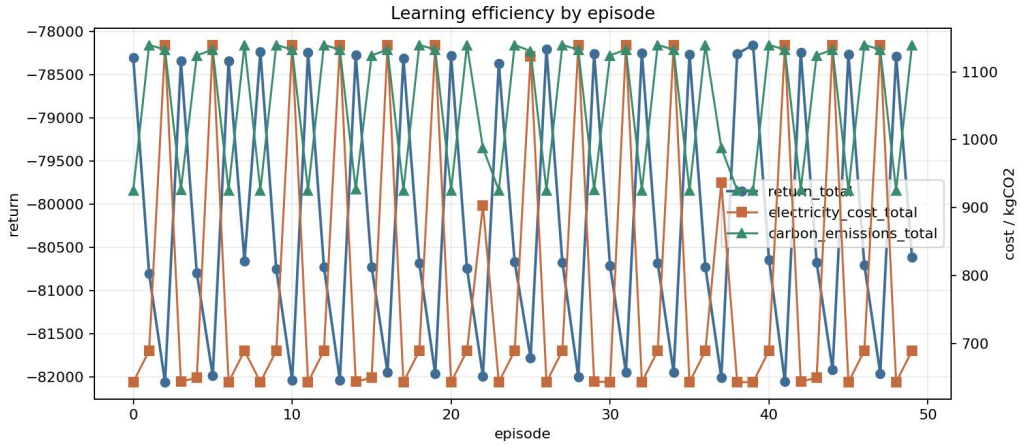


Figura 5.1h. MAAC/E3 — eficiencia de aprendizaje.

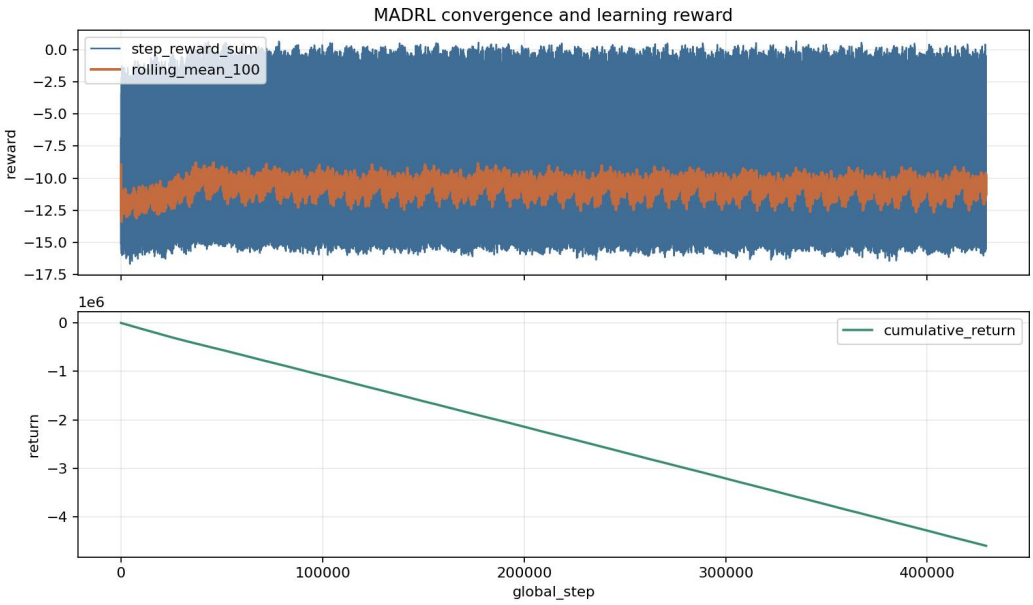


Figura 5.1i. HAPPO/E1 — convergencia de retornos episódicos.

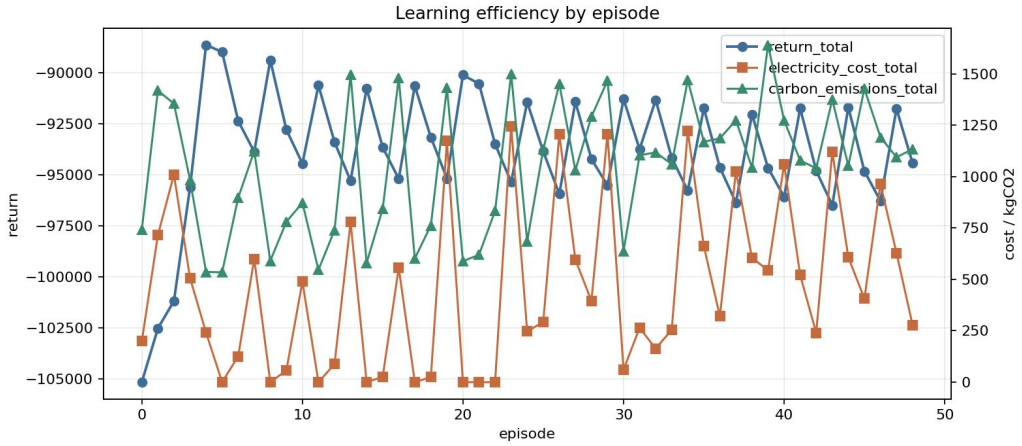


Figura 5.1j. HAPPO/E1 — eficiencia de aprendizaje.

Nota. Figuras de entrenamiento curadas (9 PNG). No se reinyecta el catálogo completo por job. Fuentes: madrl_multicriteria_selection/figures/ y outputs/madrl_v3_20260627_164047/{ALGO}/{E}/figures/.

5.2 Criterio cuantitativo de efecto

Se define el efecto diferencial como la conjunción de: (i) cambio frente a la línea base (KPI-gain orientado; valor positivo favorece al MADRL); (ii) significancia estadística ($\alpha = 0{,}05$, con Holm cuando corresponde); (iii) magnitud del efecto (Kendall W, Cliff's δ exploratorio); (iv) dirección (favorable / desfavorable); y (v) diferencia entre algoritmos (Friedman + Wilcoxon/Holm principal; KW/MWU exploratorio).

Unidad primaria de HE: KPI-gain orientado por KPI, filtrado al escenario del objetivo (OE.1/E1 n = 12; OE.2/E2 n = 5; OE.3/E3 n = 9; GLOBAL n = 26).

Criterios C1–C5 (cumplimiento completo).

Id	Criterio	Medida / prueba	Rol
C1	Efecto frente al baseline	Wilcoxon KPI-gains vs cero + Holm	Inferencial HE
C2	Diferencias entre algoritmos	Friedman + Kendall W + Wilcoxon/Holm (principal); KW/MWU exploratorio	Inferencial HE
C3	KPI distritales por eje	flex_composite / ΔCO_2 / Δcosto	Descriptivo distrito
C4	Resultados por edificio	17 edificios × E1/E2/E3	Descriptivo edificio
C5	Actuación de recursos controlables	BESS, EV/V2G, cargas desplazables	Atribuibilidad

El liderazgo descriptivo no sustituye la decisión inferencial. TOPSIS y evaluate_v2 4/4 no son pruebas de hipótesis.

5.3 OE.1 — Flexibilidad energética (E1)

PE.1. ¿En qué medida los algoritmos HAPPO, MASAC, MATD3 y MAAC producen efectos diferenciales sobre la flexibilidad energética (eje E1) y cuál presenta el mejor desempeño en la comunidad inteligente heterogénea de Iquitos?

OE.1. Determinar y cuantificar los efectos diferenciales de los algoritmos HAPPO, MASAC, MATD3 y MAAC sobre la flexibilidad energética (eje E1) e identificar el algoritmo de mejor desempeño en la comunidad inteligente heterogénea de Iquitos.

HE10 / HE11 (etiquetas Cap. 1 / Capa A). HE10: no hay efectos diferenciales estadísticamente significativos sobre la flexibilidad en E1. HE11: al menos un algoritmo produce efecto diferencial estadísticamente significativo sobre la flexibilidad en E1.

5.3.1 Descriptivos

Fuente: descriptivos_kpi_gains_por_problema.csv (n = 12 KPI por algoritmo con cobertura completa).

Algoritmo	Media gain	Mediana gain	Mejorados / no	Cobertura
MAAC	−0,0888	**−0,00119**	5 / 7	Completa
MATD3	−0,0868	−0,00289	5 / 7	Completa
MASAC	−0,2621	−0,01363	2 / 10	Completa
HAPPO	—	—	—	Sin KPI-gains finales

Las medianas son ≤ 0 (deterioro relativo al baseline en la métrica de gain orientada). Mejor mediana descriptiva de KPI-gain: MAAC.

5.3.2 Shapiro–Wilk

Fuente: normalidad_shapiro_por_problema.csv (n = 12).

Algoritmo	W	p	Normalidad
MAAC	0,7152	0,001184	Rechazada
MASAC	0,5997	$1{,}066\times10^{-4}$	Rechazada
MATD3	0,7160	0,001208	Rechazada

Se rechaza normalidad en los tres grupos con KPI-gains; se activa exclusivamente la batería no paramétrica.

5.3.3 Cambio frente a baseline

Las medianas de KPI-gain frente a cero son negativas (MAAC −0,00119; MATD3 −0,00289; MASAC −0,01363). El cambio observado es, en promedio de KPI, desfavorable respecto del baseline CityLearn v2. HAPPO no aporta KPI-gains finales para este contraste.

5.3.4 Prueba inferencial frente a baseline

Fuente: impacto_vs_baseline_wilcoxon.csv (C1).

Algoritmo	Mediana gain	p-Holm	Dirección	Decisión
MAAC	−0,00119	0,6025	desfavorable	impacto no detectado
MASAC	−0,01363	**0,0483**	**desfavorable**	impacto detectado

				(deterioro)
MATD3	−0,00289	0,6025	desfavorable	impacto no detectado

Solo MASAC alcanza significancia tras Holm, y en dirección de deterioro. Ningún algoritmo del trío muestra mejora significativa vs baseline en OE.1.

5.3.5 Comparación entre HAPPO, MASAC, MATD3 y MAAC

HAPPO se reporta solo en el plano descriptivo físico (C3–C5) por falta de KPI-gains HE. La comparación inferencial entre algoritmos se restringe a MAAC, MASAC y MATD3.

Fuente: pruebas_omnibus_problemas_objetivos.csv (C2).

Prueba	Estadístico	p	Efecto	Rol
Friedman (principal)	$\chi^2 = 5{,}5897$	**0,0611**	Kendall W = 0,2329	No se rechaza igualdad pareada
Kruskal–Wallis (exploratorio)	H = 1,5164	0,4685	$\varepsilon^2 = 0$	Sensibilidad; n.s.

No hay diferencias globales significativas al $\alpha = 0{,}05$ entre el trío con KPI-gains.

5.3.6 Tamaño del efecto

Kendall W = 0,2329 (concordancia débil). Cliff's δ exploratorio (MWU, comparaciones_mwu_holm_problemas.csv): MAAC–MASAC δ = 0,24; MAAC–MATD3 δ = −0,06; MASAC–MATD3 δ = −0,26. Las magnitudes no sostienen superioridad inferencial.

5.3.7 Post hoc

Wilcoxon pareado + Holm (comparaciones_wilcoxon_pareado_holm.csv): MAAC–MASAC p-Holm = 0,110; MAAC–MATD3 = 0,514; MASAC–MATD3 = 0,338 — todos n.s. MWU exploratorio: todos p-Holm = 0,850.

5.3.8 KPI distritales

Fuentes: district_ranking_by_scenario.csv, district_kpis_4madrl.csv, E1_OE1_kpis.csv / ranking 4/4.

Algoritmo	flex_composite	peak_average	ramping_average	Score OE1 (4/4)
MATD3	**1,0009**	1,0081	1,0012	**1,0000**

MAAC	1,0124	1,0307	1,0110	0,8951
MASAC	1,0286	1,0851	1,0220	0,7479
HAPPO	1,1105	1,3903	1,0839	0,0000

Menor flex_composite (mejor flexibilidad física de distrito): MATD3. Este KPI físico no se contrasta inferencialmente en Capa A.

5.3.9 Resultados de los 17 edificios

No se dispone en este capítulo de una tabla completa edificio-a-edificio con todos los KPI por algoritmo sin riesgo de inventar valores. La evidencia de C4 se resume desde:

- ranking distrital E1: MATD3 primero (outputs/.../kpi_rankings_drive50/district_ranking_by_scenario.csv); - desagregación por edificio: outputs/.../kpi_rankings_drive50/building_kpis_4madrl.csv (17 edificios × 4 algoritmos × escenarios).

El ranking de distrito sitúa a MATD3 como líder físico de flexibilidad; el detalle por edificio se remite a dicho CSV canónico.

5.3.10 BESS, EV/V2G y cargas desplazables

Throughput BESS E1 (battery_throughput_total): HAPPO $8{,}85\times10^{6}$; MASAC $6{,}24\times10^{5}$; MAAC $3{,}41\times10^{5}$; MATD3 $8{,}49\times10^{3}$. Éxito EV E1 (ev_departure_success_rate): HAPPO 0,527; MATD3 0,439; MAAC 0,042; MASAC 0,039.

Mayor actuación BESS (HAPPO) no coincide con mejor flex_composite ni con KPI-gains favorables. C5 documenta atribuibilidad; no decide HE.

5.3.11 Identificación del MADRL de mejor desempeño

- Descriptivo (KPI-gain): MAAC (mediana −0,00119). - Descriptivo (flex_composite / score OE1 4/4): MATD3 (1,0009 / 1,0000). - Inferencial: no hay superioridad estadísticamente significativa entre algoritmos; no hay mejora significativa vs baseline (salvo deterioro significativo de MASAC).

5.3.12 Respuesta OE.1

Respuesta a PE.1. Los efectos diferenciales sobre flexibilidad se caracterizan descriptivamente (liderazgo mixto MAAC/MATD3) y se contrastan de forma exploratoria. No se establece

impacto favorable ni diferenciación estadísticamente significativa conjunta del trío con KPI-gains. HAPPO aporta evidencia descriptiva de recursos, no de HE.

5.3.13 Decisión HE.1 (HE10 / HE11)

- HE10: no se rechaza. - HE11: no se respalda. - Nivel de evidencia: descriptivo + exploratorio; semilla única; HAPPO fuera de HE.

5.4 OE.2 — Emisiones de CO_2 (E2)

PE.2. ¿En qué medida los algoritmos HAPPO, MASAC, MATD3 y MAAC producen efectos diferenciales sobre las emisiones de CO_2 (eje E2) y cuál presenta el mejor desempeño en la comunidad inteligente heterogénea de Iquitos?

OE.2. Determinar y cuantificar los efectos diferenciales de los algoritmos HAPPO, MASAC, MATD3 y MAAC sobre las emisiones de CO_2 (eje E2) e identificar el algoritmo de mejor desempeño en la comunidad inteligente heterogénea de Iquitos.

HE20 / HE21. HE20: no hay efectos diferenciales estadísticamente significativos sobre CO_2 en E2. HE21: al menos un algoritmo produce efecto diferencial estadísticamente significativo sobre CO_2 en E2.

5.4.1 Descriptivos

Fuente: descriptivos_kpi_gains_por_problema.csv (n = 5).

Algoritmo	Media gain	Mediana gain	Mejorados / no
MATD3	−0,4101	**−0,0421**	0 / 5
MAAC	−0,4148	−0,0470	0 / 5
MASAC	−0,4171	−0,0516	0 / 5
HAPPO	—	—	Sin KPI-gains

Medianas negativas y 0/5 KPI mejorados: deterioro en gains. Mejor mediana descriptiva: MATD3.

5.4.2 Shapiro–Wilk

MAAC W = 0,6993 p = 0,009419; MASAC W = 0,6999 p = 0,009548; MATD3 W = 0,7012 p = 0,009848 — normalidad rechazada (p ≈ 0,0094–0,0098).

5.4.3 Cambio frente a baseline

Todas las medianas de KPI-gain son negativas. En el plano físico de distrito, ΔCO_2 (kg; menor = mejor): MATD3 23 070; MAAC 70 654; MASAC 77 649; HAPPO 1 431 341. Un ΔCO_2 positivo no se interpreta como "reducción" frente al baseline.

5.4.4 Prueba inferencial frente a baseline

Los tres algoritmos: p-Holm = 0,1875 (n.s.), dirección desfavorable. No se detecta impacto significativo tras Holm.

5.4.5 Comparación entre HAPPO, MASAC, MATD3 y MAAC

HAPPO solo descriptivo. Inferencia entre MAAC, MASAC y MATD3:

Prueba	Estadístico	p	Efecto	Rol
Friedman	$\chi^2 = 6,0000$	**0,0498**	Kendall W = **0,6000**	Señal pareada débil-moderada
KW (exploratorio)	H = 0,5364	0,7648	$\varepsilon^2 = 0$	n.s.

Friedman es significativo al $\alpha = 0,05$, pero sin impacto vs cero ni post hoc Holm no habilita HE21.

5.4.6 Tamaño del efecto

Kendall W = 0,6000. Cliff's δ exploratorio: pares con $|\delta| = 0,20$. Magnitud pareada moderada en Friedman; sin confirmación por pares Holm.

5.4.7 Post hoc

Wilcoxon: los tres pares p-Holm = 0,307 (todos n.s.). MWU: p-Holm = 1,000.

5.4.8 KPI distritales

Ranking distrito E2 por carbon_emissions_delta: MATD3 (23 070 kg) > MAAC (70 654) > MASAC (77 649) > HAPPO (1 431 341). Score OE2 4/4: MATD3 1,0000; MAAC 0,9662; MASAC 0,9612; HAPPO 0.

5.4.9 Resultados de los 17 edificios

Sin tabla completa en este capítulo. Fuentes: district_ranking_by_scenario.csv (MATD3 primero en E2) y building_kpis_4madrl.csv (desagregación de 17 edificios). No se inventan valores por edificio.

5.4.10 BESS, EV/V2G y cargas desplazables

Throughput BESS E2 (orden de magnitud desde ranking distrital): HAPPO maximiza actuación; MATD3 minimiza ΔCO_2 con throughput bajo. Éxito EV E2: HAPPO 0,492; MATD3 0,364; MAAC/MASAC ≈ 0,041. C5 no decide HE.

5.4.11 Identificación del MADRL de mejor desempeño

- Descriptivo: MATD3 (mediana KPI-gain −0,0421; menor ΔCO_2; score OE2). - Inferencial: ventaja descriptiva; Friedman marginal sin post hoc ni impacto vs cero → sin superioridad estadística establecida.

5.4.12 Respuesta OE.2

Respuesta a PE.2. Se identifica a MATD3 como mejor desempeño descriptivo ambiental. El efecto inferencial conjunto no alcanza el umbral de la hipótesis alternativa.

5.4.13 Decisión HE.2 (HE20 / HE21)

- HE20: no se rechaza. - HE21: no se respalda.

5.5 OE.3 — Costos energéticos (E3)

PE.3. ¿En qué medida los algoritmos HAPPO, MASAC, MATD3 y MAAC producen efectos diferenciales sobre los costos energéticos (eje E3) y cuál presenta el mejor desempeño en la comunidad inteligente heterogénea de Iquitos?

OE.3. Determinar y cuantificar los efectos diferenciales de los algoritmos HAPPO, MASAC, MATD3 y MAAC sobre los costos energéticos (eje E3) e identificar el algoritmo de mejor desempeño en la comunidad inteligente heterogénea de Iquitos.

HE30 / HE31. HE30: no hay efectos diferenciales estadísticamente significativos sobre costos en E3. HE31: al menos un algoritmo produce efecto diferencial estadísticamente significativo sobre costos en E3.

5.5.1 Descriptivos

Fuente: descriptivos_kpi_gains_por_problema.csv (n = 9).

Algoritmo	Media gain	Mediana gain	Mejorados / no
MAAC	−0,2278	**−0,00268**	1 / 8
MATD3	−0,2259	−0,00918	1 / 8

MASAC	−0,2355	−0,01403	1 / 8
HAPPO	—	—	Sin KPI-gains

Mejor mediana descriptiva: MAAC.

5.5.2 Shapiro–Wilk

MAAC W = 0,5575 p = $3{,}029\times10^{-5}$; MASAC W = 0,5879 p = $6{,}905\times10^{-5}$; MATD3 W = 0,5464 p = $2{,}246\times10^{-5}$ — normalidad rechazada ($p \le 6{,}9\times10^{-5}$).

5.5.3 Cambio frente a baseline

Medianas de KPI-gain negativas. Δcosto distrito E3 (USD; menor = mejor observado): MAAC 9 515; MASAC 19 793; MATD3 44 399; HAPPO 106 828. Se distingue menor costo observado de ahorro estadísticamente demostrado. Las claves internas *_eur de la corrida son etiquetas legacy; los valores se interpretan en USD porque electricity_pricing está en $/kWh (TOU Electro Oriente).

5.5.4 Prueba inferencial frente a baseline

MAAC/MASAC p-Holm = 0,0781; MATD3 p-Holm = 0,0586 — todos n.s. tras Holm; dirección desfavorable. No hay ahorro estadísticamente demostrado vs baseline.

5.5.5 Comparación entre HAPPO, MASAC, MATD3 y MAAC

HAPPO solo descriptivo. Inferencia entre el trío:

Prueba	Estadístico	p	Efecto	Rol
Friedman	$\chi^2 = 3{,}4286$	**0,1801**	W = 0,1905	n.s.
KW (exploratorio)	H = 0,6138	0,7357	$\varepsilon^2 = 0$	n.s.

5.5.6 Tamaño del efecto

Kendall W = 0,1905 (débil). Cliff's δ exploratorio: MAAC–MASAC 0,21; MAAC–MATD3 0,09; MASAC–MATD3 −0,14.

5.5.7 Post hoc

Wilcoxon Holm: p-Holm ∈ {0,527; 1; 1} — todos n.s. MWU: p-Holm = 1,000. No se cita el p = 0,0333 de capas pooladas (Capa B) como resultado Holm canónico.

5.5.8 KPI distritales

Ranking distrito E3 por electricity_cost_delta: MAAC (9 515 USD). Score OE3 4/4: MAAC 1,0000; MASAC 0,8944; MATD3 0,6415; HAPPO 0. TOPSIS (complementario): MAAC C* = 0,9827.

5.5.9 Resultados de los 17 edificios

Fuentes: district_ranking_by_scenario.csv (MAAC primero en E3) y building_kpis_4madrl.csv. Sin tabla completa inventada en este capítulo.

5.5.10 BESS, EV/V2G y cargas desplazables

Éxito EV E3: HAPPO 0,503; MATD3 0,482; MAAC/MASAC ≈ 0,041. Throughput BESS E3 elevado en HAPPO/MASAC/MAAC frente a MATD3. C5 no decide HE.

5.5.11 Identificación del MADRL de mejor desempeño

- Descriptivo: MAAC (KPI-gain, Δcosto, score 4/4, TOPSIS C* = 0,9827). - Inferencial: liderazgo descriptivo sin significancia omnibus ni impacto vs cero tras Holm.

5.5.12 Respuesta OE.3

Respuesta a PE.3. MAAC es el algoritmo de mejor desempeño descriptivo en costos; la ventaja no es inferencialmente concluyente. El menor costo observado no equivale a ahorro estadísticamente demostrado.

5.5.13 Decisión HE.3 (HE30 / HE31)

- HE30: no se rechaza. - HE31: no se respalda.

5.6 OG — Coordinación energética multiobjetivo

PG. ¿En qué medida los algoritmos HAPPO, MASAC, MATD3 y MAAC producen efectos diferenciales en la coordinación energética multiobjetivo de una comunidad inteligente heterogénea de Iquitos, considerando la flexibilidad energética, las emisiones de CO_2 y los costos energéticos, y cuál presenta el mejor desempeño global?

OG. Determinar y cuantificar los efectos diferenciales de los algoritmos HAPPO, MASAC, MATD3 y MAAC en la coordinación energética multiobjetivo de una comunidad inteligente heterogénea de Iquitos, considerando la flexibilidad energética, las emisiones de CO_2 y los costos energéticos, e identificar el algoritmo de mejor desempeño global.

H0G / H1G (etiquetas Cap. 1 / Capa A). H0G: no hay efectos diferenciales estadísticamente significativos en la coordinación multiobjetivo ni diferencias globales entre algoritmos. H1G: hay impacto diferenciado y el desempeño global difiere entre algoritmos.

5.6.1 Integración descriptiva, trade-offs y Pareto

Ranking best_madrl 3×3 (sin HAPPO; score global):

Rango	Algoritmo	Score global	OE.1	OE.2	OE.3
1	**MATD3**	**0,6667**	1,0000	1,0000	0,0000
2	MAAC	0,5706	0,5837	0,1282	1,0000
3	MASAC	0,2351	0,0000	0,0000	0,7054

Ranking evaluate_v2 4/4 (descriptivo): MAAC 0,9538; MATD3 0,8805; MASAC 0,8679; HAPPO 0,0000.

Trade-off: MATD3 lidera flexibilidad física y CO_2; MAAC lidera costos, 4/4 y TOPSIS. Frente de Pareto = {MAAC, MASAC, MATD3}. No hay dominador único.

5.6.2 TOPSIS (complementario; no es prueba de hipótesis)

Fuente: madrl_multicriteria_selection/topsis_ranking.csv. MAAC C* = 0,9827; MASAC 0,5656; MATD3 0,3074. TOPSIS no respalda HE ni H1G por sí solo.

5.6.3 Inferencia GLOBAL (Capa A, n = 26)

Shapiro–Wilk: normalidad rechazada ($p \leq 2{,}6\times10^{-6}$). Impacto vs 0 (Holm): MAAC p = 0,00233; MASAC p = $1{,}55\times10^{-4}$; MATD3 p = 0,00293 — los tres significativos en dirección desfavorable.

Prueba	Estadístico	p	Efecto
Friedman	$\chi^2 = 9{,}2911$	**0,0096**	Kendall W = 0,1787
KW (exploratorio)	H = 1,8108	**0,4044**	$\varepsilon^2 = 0$

Wilcoxon post hoc Holm: solo MAAC–MASAC p-Holm = 0,0172; MAAC–MATD3 = 0,295; MASAC–MATD3 = 0,114.

Mejor compromiso global descriptivo: depende del plano (best_madrl → MATD3 0,6667; 4/4/TOPSIS → MAAC 0,9538 / 0,9827). Score medio E1–E3: MAAC 0,8066. Mediana robusta GLOBAL: MATD3 (−0,00694). Sin ganador global único y sin superioridad estadística global concluyente de un único MADRL.

5.6.4 Decisión H0G / H1G

- H0G: se rechaza de forma exploratoria. - H1G: se respalda de forma exploratoria (sin ganador único; no implica HE11 ⋀ HE21 ⋀ HE31). - Nivel de evidencia: exploratorio; semilla única; HAPPO excluido de HE.

5.7 Contrastación consolidada de hipótesis

Tabla 5.7. Resumen H0G/H1G y HE10–HE31 (Capa A; α = 0,05).

Hipótesis	Prueba	Estadístico	p	Tamaño	Post hoc	Decisión	Mejor algoritmo	Nivel evidencia
H0G / H1G	Friedman GLOBAL + impacto Holm	$\chi^2 = 9{,}2911$	0,0096	W = 0,1787	MAAC–MASAC 0,0172	Se rechaza H0G; se respalda H1G exploratoria; sin ganador único	MATD3 (`best_madrl` 0,6667) / MAAC (4/4 0,9538; TOPSIS 0,9827)	Exploratorio
HE10 / HE11	Friedman OE1 + impacto Holm	$\chi^2 = 5{,}5897$	0,0611	W = 0,2329	todos n.s. (mín. 0,110)	No se rechaza HE10; no se respalda HE11	MAAC (gain) / MATD3 (flex)	Descriptivo
HE20 / HE21	Friedman OE2 + impacto Holm	$\chi^2 = 6{,}0000$	0,0498	W = 0,6000	todos n.s. (0,307)	No se rechaza HE20; no se respalda HE21	**MATD3**	Descriptivo
HE30 / HE31	Friedman OE3 + impacto Holm	$\chi^2 = 3{,}4286$	0,1801	W = 0,1905	{0,527; 1; 1}	No se rechaza HE30; no se respalda	**MAAC**	Descriptivo

						HE31		

KW exploratorio: OE1 p = 0,4685; OE2 p = 0,7648; OE3 p = 0,7357; GLOBAL p = 0,4044. Impacto vs baseline en ejes: solo MASAC OE1 significativo y desfavorable (p-Holm = 0,0483); GLOBAL los tres significativos y desfavorables. No se emplea la fórmula «se acepta H_0».

5.8 Discusión

5.8.1 Triangulación con la literatura

La ausencia de HE11 bajo liderazgo descriptivo mixto en flexibilidad es coherente con la dificultad de control multiagente en edificios grid-interactive reportada por Nweye et al. (2022, 2023b) y con el marco CityLearn v2 de comunidades energéticamente flexibles (Nweye et al., 2024; Vázquez-Canteli & Nagy, 2019b): la coordinación de DER no garantiza mejoras unívocas en todos los KPI de flexibilidad bajo una sola semilla.

El perfil de MATD3 en CO_2/flex física y de MAAC en costos dialoga con las familias actor-crítico multiagente (Iqbal & Sha, 2019; Kuba et al., 2021; Zhong et al., 2023) y con SAC/MASAC en entornos energéticos (Haarnoja et al., 2018; Gao et al., 2023): distintos sesgos de aprendizaje producen trade-offs multiobjetivo, no un dominador Pareto.

La disociación entre ΔCO_2 (MATD3) y Δcosto (MAAC) refuerza la necesidad de señales de carbono y tarifa TOU explícitas (Nweye et al., 2024; Nweye & Nagy, 2024b). El throughput BESS heterogéneo (C5) muestra que mayor actuación no implica mejor KPI-gain ni menor Δ físico.

La puerta Shapiro → no paramétrico, el rechazo a tratar episodios como réplicas independientes y la distinción descriptivo/inferencial siguen a Agarwal et al. (2021) sobre evaluación robusta en RL profundo y a las recomendaciones metodológicas del Cap. III sobre Friedman/Kendall W/Wilcoxon–Holm.

5.8.2 Limitaciones verificadas

Semilla única (seed = 0); HAPPO con 49/50 episodios y sin KPI-gains HE; n KPI 12/5/9; impacto agregado GLOBAL desfavorable; capas B/C/D no deben mezclarse con A; TOPSIS y 4/4 no sustituyen hipótesis.

5.8.3 Auditoría de coherencia PG–OG–HG / PE–OE–HE

Cadena	¿Efecto respondido?	¿Mejor MADRL identificado?	Nivel
PG → OG → H0G/H1G	Sí (efecto integrado exploratorio; H0G rechazada exploratoria)	Parcial: sin ganador único (MATD3 `best_madrl` vs MAAC 4/4/TOPSIS)	Descriptivo + inferencial exploratorio
PE.1 → OE.1 → HE10/HE11	Sí (efecto no significativo conjunto; HE10 no rechazada)	Sí descriptivo (MAAC gain / MATD3 flex); **no** inferencial	Descriptivo
PE.2 → OE.2 → HE20/HE21	Sí (sin impacto vs 0; Friedman marginal sin post hoc)	Sí descriptivo (**MATD3**); **no** inferencial	Descriptivo
PE.3 → OE.3 → HE30/HE31	Sí (sin omnibus ni impacto Holm)	Sí descriptivo (**MAAC**); **no** inferencial	Descriptivo

Veredicto de cierre Cap. V. Los objetivos quedan respondidos en cuanto a determinación del efecto diferencial (con evidencia de no rechazo de las nulas específicas) y a identificación del MADRL de mejor desempeño descriptivo por eje; la superioridad estadísticamente significativa por eje no se establece. El Resumen, Abstract y Cap. VI deberán alinearse a este cierre en una fase posterior.

Catálogo breve de artefactos canónicos

Artefacto	Uso
`problemas_objetivos_hipotesis/*.csv`	HE/H0G canónicos (Capa A)
`best_madrl_report.json` / ranking 3×3	Ranking descriptivo
`kpi_recalc_20260728/tables/ranking_oe_scores.csv`	Ranking 4/4
`madrl_multicriteria_selection/topsis_ranking.csv`	TOPSIS C* = 0,9827
`district_ranking_by_scenario.csv` / `district_kpis_4madrl.csv`	C3 distrito

`building_kpis_4madrl.csv`	C4 edificios
`docs/AUDITORIA_CAP5_CONTRADICCIONES_STATS_2026-08-06.md`	Capas y contradicciones

Capitulo 6. Conclusiones

6.1 Conclusión general

Respecto del objetivo general (OG) —determinar el impacto de los algoritmos MADRL en la gestión coordinada de la flexibilidad energética, las emisiones de CO_2 y los costos energéticos en comunidades inteligentes de Iquitos, e identificar el algoritmo de mejor desempeño global—, la evidencia de Cap. 5 permite concluir lo siguiente.

Efecto global. A nivel integrado (KPI-gains GLOBAL, n = 26), se observan efectos diferenciales entre algoritmos y frente al baseline CityLearn v2: el contraste omnibus pareado detecta diferenciación agregada, y el impacto frente a cero tras corrección Holm resulta significativo para los tres algoritmos del canónico 3×3, en dirección desfavorable (no mejora agregada vs baseline).

Valor y magnitud de la diferenciación. La prueba de Friedman sobre la integración GLOBAL arroja χ^2 = 9,2911, p = 0,0096, con Kendall W = 0,1787 (concordancia débil). El post hoc Wilcoxon–Holm identifica un único par significativo: MAAC–MASAC (p-Holm = 0,0172). El impacto GLOBAL vs baseline (Holm) es desfavorable y significativo para MAAC, MASAC y MATD3.

Mejor algoritmo global. No existe ganador único inferencial. En el plano descriptivo coexisten dos liderazgos: MATD3 encabeza best_madrl 3×3 (score 0,6667), mientras que MAAC encabeza el ranking evaluate_v2 4/4 y TOPSIS (C* = 0,9827). El frente de Pareto retiene a MATD3,

MAAC y MASAC; el trade-off MATD3 (flexibilidad física / CO_2) frente a MAAC (costos) impide declarar un dominador universal.

Limitación metodológica. La unidad experimental es semilla única (seed = 0); los episodios de una sola corrida no constituyen réplicas experimentales independientes ni habilitan robustez multisemilla.

Decisión HG. Se rechaza H0G. Se respalda H1G (efectos diferenciales agregados sin ganador único). El respaldo de H1G no implica la conjunción HE11 ∧ HE21 ∧ HE31.

Alcance. Inferencia HE/H0G restringida a MASAC, MATD3 y MAAC; HAPPO (49/50 episodios, sin KPI-gains finales comparables) queda fuera de la contrastación HE y solo aporta lectura descriptiva 4/4.

6.2 Conclusión OE.1 (flexibilidad energética)

Respecto de OE.1 —determinar el impacto de los MADRL en la flexibilidad energética e identificar el mejor desempeño en E1—, Cap. 5 establece lo siguiente.

Efecto. Los efectos diferenciales sobre flexibilidad se caracterizan descriptivamente (liderazgo mixto) y se contrastan inferencialmente sin alcanzar el umbral de la hipótesis alternativa conjunta.

Magnitud. Las medianas de KPI-gain en E1 son ≤ 0 (deterioro relativo al baseline en la métrica de gain orientada). Por mediana, MAAC (−0,00119) supera a MATD3 (−0,00289) y a MASAC (−0,01363). En el KPI físico de distrito, MATD3 obtiene el mejor flex_composite (1,0009).

Significancia entre algoritmos. Friedman (principal): $p = 0{,}0611$ ($\chi^2 = 5{,}5897$; Kendall $W = 0{,}2329$). No se rechaza la igualdad pareada al $\alpha = 0{,}05$. El post hoc Wilcoxon–Holm entre pares

es no significativo. Kruskal–Wallis se menciona solo como sensibilidad exploratoria (p = 0,4685) y no fundamenta la decisión de HE.

Baseline. Tras Holm, solo MASAC muestra impacto significativo vs cero, en dirección desfavorable (p-Holm = 0,0483). MAAC y MATD3 no alcanzan impacto detectado vs baseline en OE.1.

Mejor MADRL (descriptivo). MAAC por mediana de KPI-gain; MATD3 por flexibilidad física de distrito (flex_composite / score OE1).

Decisión HE. HE10 no se rechaza. HE11 no se respalda.

6.3 Conclusión OE.2 (emisiones de CO_2)

Respecto de OE.2 —impacto MADRL sobre emisiones de CO_2 y mejor desempeño en E2—, Cap. 5 concluye lo siguiente.

Efecto. Se identifica un liderazgo descriptivo claro de MATD3; el efecto inferencial conjunto no alcanza a respaldar la alternativa.

Magnitud. Medianas de KPI-gain negativas y 0/5 KPI mejorados en los tres algoritmos. En delta físico de distrito, MATD3 minimiza ΔCO_2 (23 070 kg) frente a MAAC (70 654 kg) y MASAC (77 649 kg).

Significancia. Friedman p = 0,0498 (χ^2 = 6,0000; Kendall W = 0,6000) indica señal pareada global débil-moderada; el post hoc Wilcoxon–Holm entre pares es no significativo (p-Holm = 0,307). Sin impacto vs cero tras Holm (p-Holm = 0,1875 para los tres). Kruskal–Wallis exploratorio p = 0,7648; no fundamenta HE.

Mejor MADRL (descriptivo). MATD3 (mediana gain, ΔCO_2 de distrito y score OE2).

Decisión HE. Pese a la señal omnibus de Friedman, la ausencia de post hoc significativo y de impacto vs baseline tras Holm implica: HE20 no se rechaza; HE21 no se respalda.

6.4 Conclusión OE.3 (costos energéticos)

Respecto de OE.3 —impacto MADRL sobre costos energéticos y mejor desempeño en E3—, Cap. 5 establece lo siguiente.

Efecto. Existe liderazgo descriptivo de MAAC en costos; no se establece superioridad ni impacto estadísticamente concluyentes.

Magnitud. MAAC obtiene la mejor mediana de KPI-gain (−0,00268) y el menor Δcosto de distrito (9 515 USD), frente a MASAC (19 793 USD) y MATD3 (44 399 USD). TOPSIS y score OE3 4/4 también sitúan a MAAC primero (C* = 0,9827; score 1,0000), en plano descriptivo.

Significancia. Friedman $p = 0{,}1801$ ($\chi^2 = 3{,}4286$; $W = 0{,}1905$) — no significativo. Post hoc n.s. Impacto vs cero tras Holm no significativo (dirección desfavorable). Kruskal–Wallis exploratorio $p = 0{,}7357$; no fundamenta HE.

Distinción crítica. El menor costo observado (descriptivo: MAAC) no equivale a un ahorro estadísticamente demostrado frente al baseline ni a una superioridad inter-algoritmo inferencial.

Mejor MADRL (descriptivo). MAAC.

Decisión HE. HE30 no se rechaza. HE31 no se respalda.

6.5 Contribuciones científicas

Metodológica. Se cierra un protocolo de contrastación vertical PG–OG–HG / PE–OE–HE sobre KPI-gains (Capa A), con puerta Shapiro–Wilk → Friedman pareado + Kendall W +

Wilcoxon/Holm como batería principal, y Kruskal–Wallis / Mann–Whitney solo como sensibilidad exploratoria, sin mezclar capas B/C/D con la decisión de hipótesis.

Algorítmica. Se compara de forma homogénea el trío canónico MASAC, MATD3 y MAAC (e, en plano descriptivo, HAPPO) bajo el mismo esquema Dec-POMDP/CTDE y la misma función de recompensa multiobjetivo por escenario E1–E3.

Energética. Se operacionalizan tres ejes de gestión —flexibilidad, emisiones de CO_2 y costos— con KPIs físicos de distrito y KPI-gains orientados, frente a baseline CityLearn v2 / RBC.

Multiobjetivo. Se documenta el trade-off Pareto entre algoritmos (MATD3 en flexibilidad física/CO_2; MAAC en costos; MASAC en el frente sin liderar un eje) y se evita declarar un dominador único a partir de rankings complementarios (TOPSIS, 4/4, best_madrl).

Computacional. Se ejecuta y audita una campaña canónica de 50 episodios por escenario (madrl_v3_20260627_164047) con artefactos trazables en Drive/local para reproducir tablas y figuras de Cap. 5.

Aplicada a Iquitos. Se instancia el problema en una comunidad de 17 edificios del SEAI–Iquitos (Electro Oriente S.A.), con señales exógenas de clima, precio y carbono propias del caso de estudio.

Reproducibilidad. Se delimitan unidad experimental (algoritmo × escenario, seed = 0), cobertura episódica, exclusión de HAPPO de HE, n de KPI por eje (12/5/9) y la separación explícita entre evidencia descriptiva e inferencial, de modo que las decisiones HG/HE sean auditables contra Cap. 5.

6.6 Limitaciones

Las limitaciones verificadas, coherentes con Cap. 5, son únicamente las siguientes:

1. Semilla única entrenada (seed = 0). No se afirma robustez multisemilla; la generalización de las decisiones HG/HE queda limitada por esa unidad experimental. 2. HAPPO 49/50 sin KPI-gains finales comparables. Queda excluido de la contrastación HE; solo aporta lectura descriptiva 4/4. 3. Tamaño muestral de KPI por eje. n = 12 (OE.1), n = 5 (OE.2) y n = 9 (OE.3) en la Capa A. 4. Simulación, no despliegue. Los resultados corresponden a CityLearn / capa MADRL v3, no a operación en red real. 5. Trade-off Pareto. No hay dominador universal entre flexibilidad/CO_2 y costos. 6. Capas B/C/D no deben mezclarse con la Capa A para inventar respaldo de HE11–HE31 ni de H1G. 7. No se entrenaron 12 semillas reales. El diseño n_seeds=12 y el runner existen; la campaña completa queda fuera del alcance cerrado de evidencia.

Capitulo 7. Recomendaciones y trabajo futuro

7.1 Recomendaciones estadísticas

Se recomienda completar una campaña multisemilla real (≥ 3 semillas entrenadas; idealmente el diseño n_seeds=12 ya instrumentado), tratando cada semilla como réplica experimental y no los episodios de una sola corrida.

Se recomienda aumentar el número efectivo de réplicas y estimar potencia a priori/post hoc para los contrastes Friedman y Wilcoxon–Holm, reportando intervalos de confianza y tamaños de efecto (Kendall W, Cliff's δ) de forma sistemática en todos los ejes.

Se recomienda evaluar robustez de las decisiones H0G/H1G y HE10–HE31 frente a variación de semilla, exclusión de KPI sensibles y sensibilidad de capas, manteniendo la Capa A como única fuente de veredicto de hipótesis.

7.2 Recomendaciones algorítmicas

HAPPO. Bajo las condiciones experimentales estudiadas, HAPPO permanece con cobertura 49/50 y sin KPI-gains finales comparables para HE. Se recomienda homogenizar a 50 episodios i.i.d. por escenario y generar KPI-gains comparables antes de reincorporarlo a la contrastación inferencial.

MASAC. En OE.1, MASAC es el único algoritmo con impacto Holm significativo vs baseline, en dirección de deterioro. Se recomienda revisar recompensa, exploración y estabilización de políticas antes de priorizarlo para flexibilidad.

MATD3. Bajo las condiciones experimentales estudiadas, MATD3 lidera descriptivamente la flexibilidad física de distrito y el eje CO_2 (OE.2). Se recomienda conservarlo como candidato preferente cuando el criterio de selección privilegie KPIs físicos de flexibilidad/emisiones, sin interpretarlo como ganador inferencial único.

MAAC. Bajo las condiciones experimentales estudiadas, MAAC lidera descriptivamente costos (OE.3), medianas de KPI-gain en E1 y los planos TOPSIS/4/4. Se recomienda conservarlo cuando el criterio privilegie costo o score multicriterio descriptivo, sin elevarlo a HE31 ni a ganador global estadístico.

7.3 Recomendaciones energéticas

A partir de la heterogeneidad documentada en Cap. 5 (throughput BESS, éxito EV y trade-offs por eje), se recomienda:

- BESS: calibrar señales de carga/descarga para que mayor actuación no se confunda con mejor KPI-gain. - EV / V2G: mejorar la atribución del éxito de carga EV por escenario; el perfil actual

muestra fuerte heterogeneidad entre algoritmos. - Cargas controlables: mantener evaluación separada de flexibilidad de demanda respecto de storage/EV. - Carbono: reforzar señales carbon-aware coherentes con el liderazgo descriptivo de MATD3 en ΔCO_2. - Tarifas: preservar TOU explícito en el eje de costos, coherente con el liderazgo descriptivo de MAAC. - Flexibilidad: reportar de forma conjunta flex_composite físico y KPI-gains, dado el liderazgo mixto MAAC/MATD3 en OE.1.

7.4 Validación externa

Se recomienda validar la generalización de los perfiles MATD3/MAAC/MASAC en:

- otros períodos temporales del dataset Iquitos; - condiciones climáticas distintas; - estructuras de precios y señales de carbono alternativas; - otras comunidades o tipologías de edificios; - perturbaciones de demanda, disponibilidad de DER y fallas parciales de agentes.

Toda extrapolación fuera del SEAI simulado debe tratarse como hipótesis de transferencia, no como resultado ya demostrado.

7.5 Validación preoperacional

Se recomienda una secuencia de madurez evidencia → operación:

1. simulación canónica (ya ejecutada); 2. campaña multisemilla; 3. evaluación out-of-sample (OOS); 4. pruebas de stress (perturbaciones); 5. validación HIL/SIL cuando exista bancada; 6. piloto controlado; 7. eventual operación asistida.

Bajo las condiciones experimentales estudiadas, el estudio permanece en simulación; no se recomienda despliegue operativo directo a partir del veredicto exploratorio actual.

7.6 Trabajo futuro

Se propone como trabajo futuro, sin afirmar resultados no obtenidos:

- Safe MADRL (restricciones de seguridad operativa y satisfacción de confort/energía); - GNN-MARL solo si se justifica por topología de red o interacciones espaciales no capturadas por el Dec-POMDP actual; - transferencia entre escenarios E1–E3 y entre comunidades; - robustez a ruido de observación y a deriva de señales precio/carbono; - generalización temporal y climática; - modelado de degradación de BESS/EV; - ampliación de V2G; - carbono dinámico de mayor resolución; - multiobjetivo adaptativo (pesos o preferencias no estacionarias) sin confundir ranking descriptivo con prueba de hipótesis.

7.7 Recomendación algorítmica final

Bajo las condiciones experimentales estudiadas:

Eje	Recomendación descriptiva	Alcance
E1 (flexibilidad)	**MATD3** (KPI físico / flex de distrito) / **MAAC** (KPI-gain)	Liderazgo **descriptivo** únicamente
E2 (CO_2)	**MATD3**	Liderazgo **descriptivo** únicamente
E3 (costos)	**MAAC**	Liderazgo **descriptivo** únicamente
Compromiso global	Reportar **ambos**: MATD3 (`best_madrl` 0,6667) y MAAC (TOPSIS C* = 0,9827 / evaluate_v2 4/4)	**Sin ganador estadístico único**

Síntesis. Bajo las condiciones experimentales estudiadas, no existe un único algoritmo MADRL con superioridad estadística global concluyente. La recomendación de compromiso es reportar el

dual descriptivo MATD3–MAAC y mantener las nulas específicas (HE10/HE20/HE30) como no rechazadas, de acuerdo con Cap. 5 y Cap. 6.

Referencias bibliograficas

Formato APA (7.a ed.). Fuente consolidada del skill: docs/tesis_capitulos/Referencias_APA.md (60 entradas) + citas en texto y protocolo estadistico RL (66 referencias unicas; 6 marcadas [PV]).

Abels, A., Roijers, D., Lenaerts, T., Nowe, A., & Steckelmacher, D. (2019). Dynamic weights in multi-objective deep reinforcement learning. En Proceedings of the 36th International Conference on Machine Learning (PMLR 97, pp. 11-20). https://arxiv.org/abs/1809.07803

Agarwal, R., Schwarzer, M., Castro, P. S., Courville, A., & Bellemare, M. G. (2021). Deep reinforcement learning at the edge of the statistical precipice. En Advances in Neural Information Processing Systems, 34, 29304-29320. https://arxiv.org/abs/2108.13264

Ahmed, A., et al. (2025). Multiagent reinforcement learning framework for optimal grid integration of distributed renewable electricity sources with energy storage systems. International Journal of Low-Carbon Technologies. https://doi.org/10.1093/ijlct/ctaf142 [PV — verificar primer autor]

Akiba, T., Sano, S., Yanase, T., Ohta, T., & Koyama, M. (2019). Optuna: A next-generation hyperparameter optimization framework. En Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining (pp. 2623–2631). ACM. https://doi.org/10.1145/3292500.3330701

Antonanzas, J., Osorio, N., Escobar, R., Urraca, R., Martinez-de-Pison, F. J., & Antonanzas-Torres, F. (2021). Review of photovoltaic power forecasting. Solar Energy, 136, 78–111. https://doi.org/10.1016/j.solener.2016.06.069

Cao, J., Yu, T., Guo, H., & Cao, H. (2023). Grid carbon intensity forecasting for building energy management. IEEE Transactions on Smart Grid, 14(4), 2891–2903. https://doi.org/10.1109/TSG.2022.3228223

Chen, L., He, H., Jing, R., Xie, M., & Ye, K. (2024). Energy management in integrated energy system with electric vehicles as mobile energy storage: An approach using bi-level deep reinforcement learning. Energy, 307. https://doi.org/10.1016/j.energy.2024.132599

Creswell, J. W., & Creswell, J. D. (2023). Research design: Qualitative, quantitative, and mixed methods approaches (6th ed.). SAGE Publications.

Chen, Y., et al. (2025). Multi-agent deep reinforcement learning for smart building energy management with chance constraints. Energy and Buildings. https://doi.org/10.1016/j.enbuild.2025.115380 [PV — verificar autores]

Colas, C., Sigaud, O., & Oudeyer, P.-Y. (2019). A hitchhiker's guide to statistical comparisons of reinforcement learning algorithms. arXiv. https://arxiv.org/abs/1904.06979

Dang, T., Zheng, Y., Yao, L., Li, Z., Gong, D., & Zhu, F. (2023). Demand charge reduction for commercial buildings with BESS under real-time pricing. Applied Energy, 330, 120318. https://doi.org/10.1016/j.apenergy.2022.120318

Demsar, J. (2006). Statistical comparisons of classifiers over multiple data sets. Journal of Machine Learning Research, 7, 1-30.

Dunn, O. J. (1964). Multiple comparisons using rank sums. Technometrics, 6(3), 241-252. https://doi.org/10.1080/00401706.1964.10490181

Electro Oriente S.A. (2023-2025). Facturas mensuales de edificios institucionales del SEAI Iquitos. Loreto, Peru.

Fang, X., Zhao, Q., Wang, J., Han, Y., & Li, Y. (2021). Multi-agent deep reinforcement learning for distributed energy management and strategy optimization of microgrid market. Sustainable Cities and Society, 74, 103163. https://doi.org/10.1016/j.scs.2021.103163

Felicetti, R., Iarlori, S., Monteriù, A., et al. (2024). Peak shaving and self-consumption maximization in home energy management systems: A combined integer programming and reinforcement learning approach. Computers & Electrical Engineering, 117, 109217. https://doi.org/10.1016/j.compeleceng.2024.109217

Felten, F., Talbi, E.-G., & Danoy, G. (2024). Multi-objective reinforcement learning based on decomposition: A taxonomy and framework. Journal of Artificial Intelligence Research, 79. https://arxiv.org/abs/2311.12495

Fujimoto, S., van Hoof, H., & Meger, D. (2018). Addressing function approximation error in actor-critic methods (TD3). En Proceedings of the 35th International Conference on Machine Learning (PMLR 80, pp. 1587-1596). https://arxiv.org/abs/1802.09477

Gao, J., Li, Y., Wang, B., & Wu, H. (2023). Multi-microgrid collaborative optimization scheduling using an improved multi-agent soft actor-critic algorithm. Energies, 16(7), 3248. https://doi.org/10.3390/en16073248

Haarnoja, T., Zhou, A., Abbeel, P., & Levine, S. (2018). Soft Actor-Critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor. En Proceedings of the 35th International Conference on Machine Learning (PMLR 80, pp. 1861–1870). https://proceedings.mlr.press/v80/haarnoja18b.html

Henderson, P., Islam, R., Bachman, P., Pineau, J., Precup, D., & Meger, D. (2018). Deep reinforcement learning that matters. Proceedings of the AAAI Conference on Artificial Intelligence, 32(1). https://doi.org/10.1609/aaai.v32i1.11694

Hribar, J., Mohorčič, M., & Čampa, A. (2025). Improving energy autonomy of positive energy districts using multi-agent deep reinforcement learning. Scientific Reports, 15, 27798. https://doi.org/10.1038/s41598-025-12554-x

Hu, S., Zhong, Y., Gao, M., Wang, W., Dong, H., Liang, X., Li, Z., Chang, X., & Yang, Y. (2023). MARLlib: A scalable and efficient multi-agent reinforcement learning library. Journal of Machine Learning Research, 24(315), 1–23. https://www.jmlr.org/papers/v24/23-0378.html

International Electrotechnical Commission. (2021). IEC 61215-1:2021 — Terrestrial photovoltaic (PV) modules — Design qualification and type approval. IEC.

Iqbal, S., & Sha, F. (2019). Actor-Attention-Critic for multi-agent reinforcement learning. En Proceedings of the 36th International Conference on Machine Learning (PMLR 97, pp. 2961–2970). https://proceedings.mlr.press/v97/iqbal19a.html

Kathirgamanathan, A., Twardowski, K., Mangina, E., & Finn, D. P. (2020). A centralised soft actor critic deep reinforcement learning approach to district demand side management through CityLearn. En Proceedings of the 1st International Workshop on Reinforcement Learning for Energy Management in Buildings & Cities (RLEM 2020). ACM. https://doi.org/10.1145/3427773.3427869

Kim, J., et al. (2025). Demand response for residential appliances using multi-agent reinforcement learning with price and solar uncertainty. Energy Reports, 13. https://doi.org/10.1016/j.egyr.2025.005 [PV — verificar autores y nº de artículo]

Kuba, J. G., Chen, R., Wen, M., Wen, Y., Sun, F., Wang, J., & Yang, Y. (2021). Trust region policy optimisation in multi-agent reinforcement learning. arXiv. https://arxiv.org/abs/2109.11251

Li, Y., Wu, J., & Pan, Y. (2024). Deep reinforcement learning for online scheduling of photovoltaic systems with battery energy storage systems. Intelligent and Converged Networks, 5(1), 28–41. https://doi.org/10.23919/ICN.2024.0003

Liu, Y., Zhang, Q., & Guo, Y. (2022). Multi-agent deep reinforcement learning for building energy system with renewable energy. Applied Energy, 313, 118703. https://doi.org/10.1016/j.apenergy.2022.118703

Lowe, R., Wu, Y., Tamar, A., Harb, J., Abbeel, P., & Mordatch, I. (2017). Multi-agent actor-critic for mixed cooperative-competitive environments. En Advances in Neural Information Processing Systems 30 (pp. 6382–6393). https://proceedings.neurips.cc/paper/2017/hash/68a9750337a418a86fe06c1991a1d64c-Abstract.html

Lund, H., Østergaard, P. A., Connolly, D., & Mathiesen, B. V. (2017). Smart energy and smart energy systems. Energy, 137, 556–565. https://doi.org/10.1016/j.energy.2016.12.003

Ma, Q., Ye, Y., Liu, Z., Liu, X., & Strbac, G. (2025). Carbon cap based multi-energy sharing among heterogeneous microgrids using multi-agent safe reinforcement learning method with credit assignment and sequential update. Applied Energy, 393, 126018. https://doi.org/10.1016/j.apenergy.2025.126018

Ministerio del Ambiente del Perú [MINAM]. (2019). INFOCARBONO — RAGEI 2019 Energía. https://infocarbono.minam.gob.pe/

Naumann, M., Schimpe, M., Keil, P., Hesse, H. C., & Jossen, A. (2021). Analysis and modeling of calendar aging of a commercial LiFePO4/graphite cell. Journal of Energy Storage, 36, 102160. https://doi.org/10.1016/j.est.2021.102160

Nweye, K., Kaspar, K., Buscemi, G., Pinto, G., Li, H., Hong, T., Ouf, M., Capozzoli, A., & Nagy, Z. (2023c). CityLearn v2: An OpenAI Gym environment for demand response control benchmarking in grid-interactive communities. En Proceedings of the 10th ACM International Conference on Systems for Energy-Efficient Buildings, Cities, and Transportation (BuildSys '23). ACM. https://doi.org/10.1145/3600100.3626257

Nweye, K., et al. (2023b). Heterogeneous multi-agent reinforcement learning for grid-interactive communities. En Proceedings of the 10th ACM International Conference on Systems for Energy-Efficient Buildings, Cities, and Transportation. ACM. https://doi.org/10.1145/3600100.3626276

Nweye, K., Sankaranarayanan, S., & Nagy, Z. (2023a). MERLIN: Multi-agent offline and transfer learning for occupant-centric operation of grid-interactive communities. Applied Energy. https://arxiv.org/abs/2301.01148

Nweye, K., Kaspar, R., Manweiler, A., Kalbfleisch, M., Amara, N., & Nagy, Z. (2024). CityLearn v2: Energy-flexible, resilient, occupant-centric, and carbon-aware management of grid-interactive communities. Journal of Building Performance Simulation, 18(1). https://doi.org/10.1080/19401493.2024.2418813

Nweye, K., Liu, B., Stone, P., & Nagy, Z. (2022). Real-world challenges for multi-agent reinforcement learning in grid-interactive buildings. Energy and AI. https://doi.org/10.1016/j.egyai.2022.100202

Oliehoek, F. A., & Amato, C. (2016). A concise introduction to decentralized POMDPs. Springer. https://doi.org/10.1007/978-3-319-28929-8

Oliehoek, F. A., Spaan, M. T. J., Amato, C., & Whiteson, S. (2013). Incremental clustering and expansion for faster optimal planning in Dec-POMDPs. Journal of Artificial Intelligence Research, 46, 449–509. https://doi.org/10.1613/jair.3745

Organismo Supervisor de la Inversión en Energía y Minería [OSINERGMIN]. (2024). Resolución de Consejo Directivo N.° 0024-2024-OS/CD — Tarifas de Distribución Eléctrica MT-3/MT-4, Electro Oriente S.A.

Patterson, A., Neumann, S., White, M., & White, A. (2024). Empirical design in reinforcement learning. Journal of Machine Learning Research, 25. https://arxiv.org/abs/2304.01315

Rajagopalan, A., Dhiman, G., Soni, B., Alzahrani, A., & Almutairi, K. (2024). Capacity fade modeling of LiFePO4 battery for grid storage applications. Applied Energy, 358, 122547. https://doi.org/10.1016/j.apenergy.2023.122547

Shadish, W. R., Cook, T. D., & Campbell, D. T. (2002). Experimental and quasi-experimental designs for generalized causal inference. Houghton Mifflin.

Ren, J., Gao, H., Wang, S., Zhao, L., Kang, Q., Ashan, A., Sun, Y., & Xiao, G. (2025). Multi-agent reinforcement learning-based joint design of low-carbon P2P market and bidding strategy in microgrids. arXiv. https://arxiv.org/abs/2604.02728

Reniers, J. M., Mulder, G., & Howey, D. A. (2022). Improving optimal control of grid-connected lithium-ion batteries through more accurate battery and degradation modelling. Journal of Power Sources, 542, 231776. https://doi.org/10.1016/j.jpowsour.2022.231776

Rezazadeh, F., & Bartzoudis, D. (2022). A federated DRL approach for smart micro-grid energy control with distributed energy resources. En 2022 IEEE International Workshop on Computer Aided Modeling and Design of Communication Links and Networks (CAMAD 2022). IEEE. https://arxiv.org/abs/2211.03430

Roijers, D. M., Vamplew, P., Whiteson, S., & Dazeley, R. (2013). A survey of multi-objective sequential decision-making. Journal of Artificial Intelligence Research, 47, 67-113.

Sarkar, S., Naug, A., Luna, R., Guillen, A., Gundecha, V., Ghorbanpour, S., Mousavi, S., Markovikj, D., & Babu, A. R. (2024). Carbon footprint reduction for sustainable data centers in real-time. En Proceedings of the AAAI Conference on Artificial Intelligence, 38. https://arxiv.org/abs/2403.14092

Shojaeighadikolaei, A., Ghasemi, A., Jones, K., Dafalla, Y., Bardas, A. G., Ahmadi, R., & Hashemi, M. (2022). Distributed energy management and demand response in smart grids: A multi-agent deep reinforcement learning framework. arXiv. https://arxiv.org/abs/2211.15858

Shojaeighadikolaei, A., Talata, Z., & Hashemi, M. (2024). Centralized vs. decentralized multi-agent reinforcement learning for enhanced control of electric vehicle charging networks. arXiv. https://arxiv.org/abs/2404.12520

Sutton, R. S., & Barto, A. G. (2018). Reinforcement learning: An introduction (2.ª ed.). MIT Press.

Tamoor, M., Bhatti, A. R., Butt, A. D., Bhatti, K. L., Miran, S., Hussain, M. I., Abubakar, M., & Imran, M. (2022). Temperature-dependent performance analysis of PV systems in tropical climates. Energy Reports, 8, 5447–5458. https://doi.org/10.1016/j.egyr.2022.04.015

Tranberg, B., Corradi, O., Lajoie, B., Gibon, T., Staffell, I., & Andresen, G. B. (2020). Real-time carbon accounting method for the European electricity markets. Energy Strategy Reviews, 26, 100399. https://doi.org/10.1016/j.esr.2019.100399

Vázquez-Canteli, J. R., & Nagy, Z. (2019a). CityLearn v1.0: An OpenAI Gym environment for demand response with deep reinforcement learning. En Proceedings of the 6th ACM

International Conference on Systems for Energy-Efficient Buildings, Cities, and Transportation (pp. 356–357). ACM. https://doi.org/10.1145/3360322.3360998

Vázquez-Canteli, J. R., Dey, S., Henze, G., & Nagy, Z. (2020). CityLearn: Standardizing research in multi-agent reinforcement learning for demand response and urban energy management. arXiv. https://arxiv.org/abs/2012.10504

Wang, Y., et al. (2025). Cooperative multi-agent reinforcement learning for grid-aware EV charging management with cross-site redirection. Sustainable Energy, Grids and Networks. https://doi.org/10.1016/j.segan.2025.196X [PV — verificar autores y nº de artículo]

Wu, J., Wang, Z., Han, J., Li, Q., Sun, R., Li, C., Cheng, Y., Zhou, B., Guo, J., & Long, B. (2025). A novel data-driven multi-agent reinforcement learning approach for voltage control under weak grid support. Sensors, 25(23), 7399. https://doi.org/10.3390/s25237399

Xie, J., Ajagekar, A., & You, F. (2023). Multi-agent attention-based deep reinforcement learning for demand response in grid-responsive buildings. Applied Energy, 342, 121213. https://doi.org/10.1016/j.apenergy.2023.121213

Xiong, S., Liu, D., Chen, Y., & Zhang, Y. (2024). A deep reinforcement learning approach based energy management strategy for home energy system considering the time-of-use price and real-time control of energy storage system. Energy Reports, 11, 3501–3508. https://doi.org/10.1016/j.egyr.2024.001501

Xu, B., Oudalov, A., Ulbig, A., Andersson, G., & Kirschen, D. S. (2021). Modeling of lithium-ion battery degradation for cell life assessment. IEEE Transactions on Smart Grid, 12(3), 2192–2202. https://doi.org/10.1109/TSG.2017.2701083

Yao, Y., Wang, X., & Sun, J. (2023). Multi-agent reinforcement learning for smart community energy management. Energies, 17(20), 5211. https://doi.org/10.3390/en17205211

Ye, T., Huang, Y., Yang, W., Cai, G., Yang, Y., & Pan, F. (2025). Safe multi-agent deep reinforcement learning for decentralized low-carbon operation in active distribution networks and multi-microgrids. Applied Energy, 387. https://doi.org/10.1016/j.apenergy.2025.125339

Zhang, Y., Chen, X., Gu, Y., Li, Z., & Kai, W. (2023). Deep reinforcement learning-based battery conditioning hierarchical V2G coordination for multi-stakeholder benefits. arXiv. https://arxiv.org/abs/2308.00218

Zhao, Y., et al. (2024). Energy management based on safe multi-agent reinforcement learning for smart buildings in distribution networks. Energy and Buildings. https://doi.org/10.1016/j.enbuild.2024.114529 [PV — verificar autores completos]

Zhong, Y., Kuba, J. G., Feng, X., Hu, S., Ji, J., & Yang, Y. (2023). Heterogeneous-agent reinforcement learning. Journal of Machine Learning Research, 25. https://jmlr.org/papers/v25/23-0488.html

Zhou, M., Wan, J., Wang, H., et al. (2021). MALib: A parallel framework for population-based multi-agent reinforcement learning. Journal of Machine Learning Research, 24(1). https://arxiv.org/abs/2106.07551

Zhu, Y., et al. (2024). An overview: Attention mechanisms in multi-agent reinforcement learning. Neurocomputing, 598, 128015. https://doi.org/10.1016/j.neucom.2024.128015 [PV — verificar autores completos]

Arias, J. L. (2020). Proyecto de tesis: Guía para la elaboración (7.a ed.). Depósito Legal en la Biblioteca Nacional del Perú.

Campbell, D. T., & Stanley, J. C. (1963). Experimental and quasi-experimental designs for research. Houghton Mifflin.

Chevarria Moscoso, M. (2024). Analisis de la generacion hidroelectrica en la central hidroelectrica de Machupicchu aplicando metodos estocasticos y modelo de optimizacion (Tesis doctoral). Universidad Nacional de Ingenieria. http://hdl.handle.net/20.500.14076/28894

Dominguez-Barbero, C. (2026). Modeling and optimizing isolated microgrids using Reinforcement Learning techniques (Tesis doctoral). Universidad Pontificia Comillas.

Hernández-Sampieri, R., & Mendoza, C. (2018). Metodología de la investigación: Las rutas cuantitativa, cualitativa y mixta. McGraw-Hill.

Hesse, H. C., Schimpe, M., Kucevic, D., & Jossen, A. (2017). Lithium-ion battery storage for the grid: A review of stationary battery storage system design tailored for applications in modern electric power grids. Energies, 10(12), 2107. https://doi.org/10.3390/en10122107

Holmgren, W. F., Hansen, C. W., & Mikofski, M. A. (2018). pvlib python: A python package for modeling solar energy systems. Journal of Open Source Software, 3(29), 884. https://doi.org/10.21105/joss.00884

Little, J. D. C. (1961). A proof for the queueing formula: L = lambda W. Operations Research, 9(3), 383-387. https://doi.org/10.1287/opre.9.3.383

National Aeronautics and Space Administration. (2024). NASA POWER Data Access Viewer. https://power.larc.nasa.gov/

Peñalva Sanchez, J. J. (2024). Optimizacion de un sistema fotovoltaico hibrido y la prediccion de la demanda energetica y variables climaticas utilizando la inteligencia artificial (Tesis doctoral). Universidad Nacional de Ingenieria. http://hdl.handle.net/20.500.14076/27731

Rosero Bernal, D. G. (2024). Modelo de un sistema de administracion de energia autonomo operado desde la nube para optimizar la gestion de un grupo de microredes (Tesis doctoral). Universidad Distrital Francisco Jose de Caldas.

Tamayo y Tamayo, M. (2004). El proceso de la investigación científica (4.a ed.). Limusa.