

UNIVERSIDAD NACIONAL DE INGENIERÍA
ESCUELA DE POSGRADO

[ESCUDO UNI]

PLAN DE TESIS

**"MULTI-AGENTE DE APRENDIZAJE POR REFUERZO PROFUNDO PARA LA
OPTIMIZACION DE FLEXIBILIDAD, RESILIENCIA Y RESPUESTA A LA
DEMANDA ENERGETICA EN COMUNIDADES INTERACTIVAS CON LA RED
ELECTRICA"**

PARA OBTENER EL GRADO ACADÉMICO DE
MAESTRO EN CIENCIAS CON MENCIÓN EN:

INGENIERÍA DE SISTEMAS

ELABORADA POR:

[NOMBRE DEL TESISISTA]

ASESOR:

[NOMBRE DEL ASESOR]

LIMA, PERÚ

2025

ÍNDICE

Carátula	i
Índice	ii
Resumen	iv
 CAPÍTULO I: PLANTEAMIENTO DEL PROBLEMA	
1	
1.1	Diagnóstico
1.1	1
1.2 Identificación y Descripción del Problema de Estudio	
5	
1.2.1	Antecedentes Bibliográficos
1.2.1	8
A. Antecedentes Internacionales (Tesis PhD/MSc)	7
B. Antecedentes Nacionales (Tesis MSc / Artículos)	14
1.2.2 Formulación del Problema	
21	
1.2.2.1 Formulación del Problema General	21
1.2.2.2 Formulación de los Problemas Específicos (PE1, PE2, PE3)	22
1.2.3 Justificación y Alcances	23
1.2.3.1	Justificación
1.2.3.1	23
1.2.3.2	Alcances
1.2.3.2	26
 CAPÍTULO II: OBJETIVOS	
27	
2.1 Objetivo General	27
2.2 Objetivos Específicos (OE1, OE2, OE3)	27

CAPÍTULO	III:	MARCO	TEÓRICO
.....		29	
3.1	Bases		Teóricas
.....		29	
3.2	Definición	de	Términos
.....		52	
A.	Aprendizaje	por Refuerzo y Algoritmos	MADRL
.....		52	
B.	Sistemas Eléctricos y Recursos	Energéticos	Distribuidos
.....		56	
C.	Indicadores	de Desempeño	(KPIs)
.....		60	
D.	Métodos Estadísticos y	Análisis	Multicriterio
.....		62	
E.	Entorno Computacional,	Software y	Datos
.....		65	
F.	Marco Regulatorio	e	Instituciones
.....		66	
CAPÍTULO	IV:	METODOLOGÍA	
.....		74	
4.1	Tipo	de	Investigación
.....		74	
4.2	Nivel	de	Investigación
.....		75	
4.3	Métodos	de	Trabajo
.....		76	
4.4	Población	y	Muestra
.....		77	
4.5	Tipo de Diseño y Escenarios	Experimentales (E1, E2, E3)	
.....		79	
4.6	Configuración del	Entorno de	Simulación
.....		82	
4.7	Técnicas e Instrumentos de Análisis y	Procesamiento de Datos	
.....		84	

4.8	Etapas	de	Intervención	91
CAPÍTULO V: ADMINISTRACIÓN DEL PLAN DE TESIS				
94				
5.1	Cronograma	de	Actividades (Diagrama de Gantt)	94
5.2	Presupuesto	y	Recursos	96
5.3	Financiamiento			99
REFERENCIAS				BIBLIOGRÁFICAS
				101
ANEXO I:	MATRIZ	DE	CONSISTENCIA	110
ANEXO II: MATRIZ DE OPERACIONALIZACIÓN DE INDICADORES (KPIs) — Doctorado ..				
A2.1	Eje	1	— D1_VD: Flexibilidad Energética	113
A2.2	Eje	2	— D2_VD: Resiliencia Energética	114
A2.3	Eje	3	— D3_VD: Respuesta a la Demanda	115
A2.4	Transversal	—	Síntesis Multicriterio TOPSIS	116
ANEXO III: MATRIZ BIBLIOGRÁFICA — 50 INVESTIGACIONES (Complementario)				
A3.1	Grupo	1	— Ecosistema CityLearn	118
A3.2	Grupo	2	— Algoritmos MADRL Fundacionales	120
A3.3 Grupo 3 — Aplicaciones DRL/MADRL en Gestión Energética				
122				
A3.4	Grupo	4	— KPIs, Resiliencia y Flexibilidad	124

A3.5	Síntesis	y	Brechas	Identificadas
.....				126

CAPÍTULO I: PLANTEAMIENTO DEL PROBLEMA

1.1 Diagnóstico

El presente diagnóstico identifica, conforme a los lineamientos de la Guía N°01 UNI, la realidad problemática del sector eléctrico peruano y mundial mediante estadística descriptiva, sin contrastación de hipótesis. La problemática se organiza alrededor de tres ejes interdependientes que constituyen los tres desafíos centrales de las comunidades de edificios interactivos con la red eléctrica (Grid-Interactive Communities, GIC): (i) la flexibilidad energética, (ii) la resiliencia ante interrupciones del suministro y (iii) la respuesta a la demanda. Estos tres ejes corresponden directamente a las tres dimensiones de la Variable Dependiente del estudio y configuran la motivación científica, tecnológica y socio-energética de la investigación.

Contexto global. La capacidad instalada de energía solar fotovoltaica y eólica superó los 3 500 GW a nivel mundial durante el año 2023, representando más del 40 % de la nueva capacidad instalada en ese año (IRENA, 2024). En paralelo, la electrificación masiva de los usos finales —transporte eléctrico, climatización, calefacción residencial— incrementa el consumo agregado y modifica los perfiles de demanda (DOE, 2023; IEA, 2022), mientras la mayor exposición de la infraestructura a eventos climáticos extremos derivados del cambio climático (IPCC, 2023) expone la fragilidad operativa de los sistemas tradicionales centralizados. Estos tres factores convergentes hacen insuficiente la operación tradicional centralizada del sistema y exigen mecanismos distribuidos de flexibilidad, resiliencia y respuesta a la demanda en el lado del consumidor (NREL, 2024).

Contexto nacional. El Sistema Eléctrico Interconectado Nacional (SEIN) generó 58 393,4 GWh durante el año 2023, con una participación del 53,4 % de fuentes renovables —hidroeléctrica más recursos energéticos renovables (RER) no convencionales solar y eólica— según el Anuario Estadístico de Electricidad del MINEM (2024). Sin embargo, durante el tercer trimestre de 2023 el ciclón Yaku y el Fenómeno El Niño Costero (FEN) provocaron sequía hidrológica severa en las cuencas del Mantaro y del Vilcanota; el precio spot se incrementó en 447,1 % —de 31,1 a más de 170 USD/MWh en barras críticas— y se registraron múltiples interrupciones no programadas en circuitos de distribución (OSINERGMIN, 2023). El parque renovable nacional se proyecta crecer de los 13 GW actuales hasta 32 GW al año 2050 según el estudio de planificación del MINEM (2014, 2023), lo cual amplifica la vulnerabilidad del sistema si no se introducen mecanismos distribuidos de flexibilidad y resiliencia en el lado del consumidor.

Diagnóstico del problema 1: Flexibilidad energética insuficiente

La variabilidad de las fuentes renovables variables y los picos de demanda generan estrés operativo en la red de distribución, incrementando los costos de operación, las pérdidas técnicas y la necesidad de capacidad de reserva costosa. La flexibilidad energética, definida como la capacidad de un sistema para modificar su perfil de consumo o generación en respuesta a señales externas (Kathirgamanathan et al., 2021; OSMOSE H2020, 2021; NREL, 2024), es esencial para suavizar estas fluctuaciones. En el Perú, los indicadores de flexibilidad agregada del SEIN —factor de carga, tasa de rampa de la demanda agregada, magnitud del pico diario— se han deteriorado progresivamente entre 2018 y 2023 según los reportes de OSINERGMIN (2023), lo cual evidencia una brecha estructural en la gestión activa de la demanda residencial y comercial. Los métodos de control convencionales —reglas heurísticas (RBC) y control predictivo basado en modelos (MPC)— resultan insuficientes para gestionar carteras heterogéneas de recursos energéticos distribuidos (BESS, PV, TES, HVAC, EV) bajo incertidumbre paramétrica y de predicción (Drgona et al., 2020).

Diagnóstico del problema 2: Vulnerabilidad ante interrupciones del suministro (resiliencia)

La frecuencia e intensidad de los eventos climáticos extremos se proyecta en aumento (IPCC, 2023), con consecuencias directas sobre la infraestructura eléctrica. En sistemas con alta penetración de recursos energéticos distribuidos, la capacidad de los edificios para mantener condiciones habitables y preservar cargas críticas durante power outages depende de la estrategia de pre-posicionamiento de energía adoptada previamente, lo cual configura un problema de optimización multi-objetivo intertemporal de alta complejidad (NREL, 2021, 2023; CURENT, 2024). En el Perú, OSINERGMIN (2023) reporta una incidencia creciente de interrupciones por eventos climáticos en distritos costeros y andinos, con duraciones que oscilan entre dos y ocho horas en eventos extremos. Los marcos tradicionales de evaluación de resiliencia (NERC, 2020; Sustainability MDPI Authors, 2020) destacan la insuficiencia de estrategias estáticas de respaldo y la necesidad de políticas adaptativas de pre-posicionamiento del BESS y modulación del HVAC.

Diagnóstico del problema 3: Respuesta a la demanda subutilizada

Los mercados eléctricos modernos con tarifas de tiempo real (RTP) o tarifas por bloques horarios (TOU) requieren que los consumidores ajusten su demanda en respuesta a señales de precio dinámicas (FERC, 2019). La participación eficiente en programas de

respuesta a la demanda genera ahorros económicos para los usuarios y beneficios sistémicos para la red (Deltetto et al., 2021; TU Delft AI Energy Lab, 2023). Sin embargo, en el Perú la respuesta a la demanda permanece subutilizada: el cuarto eje de la Hoja de Ruta de Smart Grids 2023-2030 del MINEM (R.M. N° 278-2023-MINEM/DM) identifica la ausencia de un mercado formal de DR como una de las seis brechas críticas del sistema. Adicionalmente, la coordinación de múltiples agentes que responden simultáneamente a las mismas señales de precio puede producir efectos de sincronización no deseados (rebound effects), requiriendo estrategias de coordinación implícita o explícita (Pinto et al., 2021; Nweye et al., 2022).

Síntesis del diagnóstico. Los tres problemas anteriores comparten una causa estructural común: la ausencia de mecanismos de control distribuido capaces de coordinar simultáneamente los recursos energéticos distribuidos de múltiples edificios bajo objetivos múltiples y potencialmente conflictivos. Esta brecha sustenta directamente la presente investigación, cuya pregunta general se formula en la sección 1.2.2.1 y cuyas hipótesis se contrastan en el escenario experimental detallado en el Capítulo IV.

1.2 Identificación y Descripción del Problema de Estudio

La identificación y descripción del problema de estudio implica el desarrollo explícito de una disertación formal que contextualice la situación problemática en sus síntomas, causas, consecuencias, variables involucradas y contextos directos e indirectos, de manera que el investigador logre describir el problema real en sus distintos aspectos (Hernández Sampieri et al., 2018). En el dominio específico de la presente investigación, el problema se articula alrededor de la triple problemática diagnosticada en la sección 1.1 —flexibilidad, resiliencia y respuesta a la demanda energética— y se aborda mediante un enfoque integrado basado en algoritmos de Aprendizaje por Refuerzo Profundo Multi-Agente (MADRL).

Síntomas del problema

Los síntomas observables de la problemática se manifiestan en tres planos. En el plano operativo, las comunidades de edificios presentan picos de demanda no coordinados, rampas pronunciadas de potencia entre horas consecutivas y bajos factores de carga (Kathirgamanathan et al., 2021); durante los eventos de power outage, los edificios sin

gestión activa del BESS experimentan pérdida prolongada del confort térmico y el suministro eléctrico (NERC, 2020); y bajo señales de precio dinámicas, los consumidores no ajustan adecuadamente su demanda, perdiendo la oportunidad de ahorrar en sus facturas eléctricas (FERC, 2019). En el plano económico, los costos sistémicos de operar la red bajo estos perfiles de demanda no flexibilizados se traducen en mayores tarifas para todos los usuarios. En el plano regulatorio, el cumplimiento de las metas nacionales de la Hoja de Ruta de Smart Grids 2023-2030 del MINEM (2023) se ve comprometido por la ausencia de evidencia técnica reproducible sobre los mecanismos de control distribuido más efectivos.

Causas del problema

Las causas estructurales del problema son tres. En primer lugar, la heterogeneidad de los recursos energéticos distribuidos —baterías (BESS), generación fotovoltaica (PV), almacenamiento térmico (TES), climatización (HVAC), vehículos eléctricos (EV)— configura un espacio de decisión combinatorio de alta dimensionalidad que los métodos tradicionales no pueden resolver eficientemente (Drgona et al., 2020). En segundo lugar, la incertidumbre paramétrica y de predicción —en la generación PV, la demanda interna, los precios horarios y la ocurrencia de outages— invalida los supuestos de los modelos deterministas tradicionales. En tercer lugar, los tres ejes de la problemática (flexibilidad, resiliencia, DR) presentan tensiones intertemporales: el pre-posicionamiento del BESS para la resiliencia compite con el aprovechamiento de las señales de precio para la respuesta a la demanda; la maximización de la flexibilidad puede comprometer el confort térmico durante outages.

Consecuencias del problema

Las consecuencias del problema, si no se aborda integralmente, son tres. En el corto plazo, las comunidades de edificios incurren en sobre costos por consumo en horas pico, exposición prolongada a outages y pérdida del confort térmico ante eventos climáticos extremos. En el mediano plazo, el sistema eléctrico nacional pierde la oportunidad de incorporar capacidad flexible de bajo costo en el lado del consumidor, demorando el cumplimiento de las metas de la Hoja de Ruta de Smart Grids 2023-2030 (MINEM, 2023). En el largo plazo, la transición energética nacional —proyectada de 13 GW renovables actuales a 32 GW al 2050— se torna técnica y económicamente más difícil de gestionar al carecer de mecanismos distribuidos de flexibilidad y resiliencia en el lado del consumidor (IRENA, 2024; IEA, 2022).

Variables involucradas

Las variables del estudio son dos. La Variable Independiente (VI) corresponde a los algoritmos MADRL aplicados al control coordinado de los recursos energéticos distribuidos, con sus tres dimensiones: D1_VI — arquitectura y tipo de algoritmo (HAPPO, MASAC, MATD3, MAAC); D2_VI — política de control y función de recompensa multi-objetivo; D3_VI — eficiencia del proceso de entrenamiento. La Variable Dependiente (VD) corresponde al desempeño energético de la comunidad GIC, con sus tres ejes alineados con la problemática: D1_VD — flexibilidad energética (KPIs peak_average, ramping_average, 1-load_factor_average); D2_VD — resiliencia energética (KPIs unserved_energy_fraction, thermal_discomfort); D3_VD — respuesta a la demanda energética (KPIs electricity_cost, price_signal_deviation).

Contextos directos e indirectos

El contexto directo de aplicación es el conjunto de distritos del Perú con potencial técnico, económico y regulatorio para implementar comunidades GIC, identificados en la sección 4.4 (Población y Muestra). El contexto indirecto comprende: (i) el marco regulatorio nacional —Reglamento de Generación Distribuida (D.S. 027-2021-EM), Hoja de Ruta de Smart Grids 2023-2030 (R.M. 278-2023-MINEM/DM), Plan Energético Nacional 2014-2025 (MINEM, 2014)—; (ii) el marco internacional de definiciones operativas —FERC (2019) para la respuesta a la demanda, NERC (2020) para la resiliencia, OSMOSE H2020 (2021) para la flexibilidad—; (iii) la comunidad científica MADRL aplicada a edificios, representada en el ecosistema CityLearn v2 (Nweye et al., 2024) y los CityLearn Challenges 2021-2023.

Brecha de conocimiento. La literatura científica internacional documenta soluciones parciales basadas en métodos heurísticos, control predictivo basado en modelos (MPC) o algoritmos de aprendizaje por refuerzo de un solo agente (Drgona et al., 2020; Vázquez-Canteli y Nagy, 2019). La mayor parte de los estudios aborda únicamente uno o dos de los tres ejes —rara vez los tres de manera integrada— (Manjavacas-Lucas et al., 2024; Yu et al., 2020), emplea un único algoritmo sin comparación sistemática (Pinto et al., 2021; Nweye et al., 2022), no evalúa la robustez bajo escenarios de cortes de suministro reales (NREL, 2023; Sustainability MDPI Authors, 2020) y carece de un framework experimental unificado que permita comparaciones reproducibles (Nweye y Nagy, 2024). La presente investigación cierra esta brecha mediante la implementación y comparación sistemática de cuatro algoritmos MADRL representativos —HAPPO, MASAC, MATD3 y MAAC— en el entorno de simulación CityLearn v2, evaluando de forma simultánea e integrada los tres ejes de desempeño: flexibilidad, resiliencia y respuesta a la demanda.

1.2.1 Antecedentes Bibliográficos

Conforme a los criterios establecidos por la Guía N°01 de la Escuela de Posgrado de la UNI, los antecedentes de la presente investigación se limitan estrictamente a tesis de doctorado, tesis de maestría y artículos publicados en revistas científicas indexadas. Se organizan en dos grupos: antecedentes internacionales (I-1 a I-5), que cubren el núcleo técnico de los algoritmos MADRL en gestión energética de edificios; y antecedentes nacionales (N-1 a N-5), que contextualizan el problema en el sistema eléctrico peruano y la investigación nacional en gestión de demanda y pronóstico energético. Para cada antecedente se analizan: tipo de documento, metodología, resultados, gap identificado y relación explícita con las dimensiones de las variables de estudio (VI: D1_VI-arquitectura, D2_VI-política/recompensa, D3_VI-eficiencia; VD: D1_VD-flexibilidad, D2_VD-resiliencia, D3_VD-DR).

A. ANTECEDENTES INTERNACIONALES

Antecedente Internacional 1 [Tesis Doctoral]

Nweye, K. E. (2024). *Data-driven modeling and control of grid-interactive communities* [Tesis Doctoral]. The University of Texas at Austin. Supervisor: Prof. Zoltan Nagy. <https://doi.org/10.26153/tsw/52085>

Esta disertación doctoral de la Universidad de Texas en Austin, completada en diciembre de 2024 bajo la supervisión del Prof. Zoltan Nagy, es la tesis que origina CityLearn v2 —el entorno de simulación central de la presente investigación. La tesis identifica nueve desafíos críticos que obstaculizan la aplicación real del aprendizaje por refuerzo en comunidades de edificios interactivos con la red eléctrica, y los aborda mediante tres contribuciones originales: (1) establecer que un control basado en reglas experto puede acelerar el aprendizaje de un agente RL para exploración más segura; (2) proponer un framework para entrenamiento, evaluación, despliegue y transferencia de políticas de control de DER en comunidades GIC con distintos niveles de disponibilidad de datos; y (3) desarrollar CityLearn v2, que introduce las capacidades de modelado de power outages (variable binaria outage_t), modelo LSTM de temperatura interior para cálculo del discomfort térmico, soporte V2G, y los siete KPIs de los tres ejes de desempeño.

Relación con las variables de estudio: Esta tesis define el instrumento de medición de TODA la VD — D1_VD (peak_average, ramping_average, load_factor_average), D2_VD (unserved_energy_fraction, thermal_discomfort) y D3_VD (electricity_cost, price_signal_deviation). También fundamenta D2_VI al proponer la función de recompensa

multi-objetivo con ocupante dinamico. Gap: La tesis no compara algoritmos MADRL avanzados entre si; los experimentos de control son individuales (RBC, SAC). La presente investigacion llena este vacio comparando HAPPO, MASAC, MATD3 y MAAC en CityLearn v2.

Antecedente Internacional 2 [Tesis Doctoral]

Zhang, B. (2024). *Modelling and optimization of multi-energy system operation based on deep reinforcement learning* [PhD Thesis]. Aalborg University. ISBN: 978-87-85239-51-8. DOI: 10.54337/aau763295893

Esta tesis doctoral de la Universidad de Aalborg (Dinamarca), completada en septiembre de 2024 bajo la supervision del Prof. Zhe Chen, propone y valida una serie de estrategias MADRL para la gestion energetica de sistemas multi-energia (MES) que integran fuentes renovables (eolica, solar), almacenamiento (BESS, hidrógeno), vehiculos electricos (EV) y redes de calor y gas. Las cinco contribuciones del trabajo cubren: (a) despacho economico de baja emision de carbono para sistemas electricidad-gas con captura de carbono (SAC mejorado); (b) estrategia a dos escalas temporales para MES residencial con MADRL; (c) control distribuido para redes de microrredes con atencion (MAAC); (d) gestion bottom-up para el Internet de Energia con MADRL; y (e) gestion descentralizada para MES y flotas de EV. La tesis incluye seis publicaciones en revistas Q1 (Applied Energy, Energy Conversion and Management, Energy) y demuestra reducciones de costo energetico entre 12-28% respecto a MPC y métodos basados en reglas.

Relacion con las variables de estudio: Tiene la mayor vinculacion con D1_VI (arquitecturas SAC, MAAC y MADRL bottom-up comparadas sistematicamente), D2_VI (funciones de recompensa multi-objetivo para minimizacion de costo y emision), y D3_VI (analisis de convergencia y costo computacional comparativo entre algoritmos). En la VD, aborda D3_VD (electricity_cost con precios de tiempo real europeos) y D1_VD (flexibilidad de carga mediante BESS y V2G). Gap: La tesis no evalua resiliencia (D2_VD, power outages) ni utiliza CityLearn v2; los entornos son microrredes de energia mixta, no comunidades de edificios GIC. La presente investigacion extiende el enfoque comparativo de Zhang (2024) al dominio especifico de edificios con evaluacion explicita de D2_VD.

Antecedente Internacional 3 [Tesis de Maestria]

Atrazhev, P. (2023). *Multi-agent deep reinforcement learning for autonomous energy coordination in demand response methods for residential distribution networks* [MSc Thesis, Software Engineering and Intelligent Systems]. University of Alberta, Department of Electrical and Computer Engineering.

Esta tesis de maestria de la Universidad de Alberta (Canada) es uno de los primeros trabajos que utiliza explícitamente el entorno CityLearn (edición 2022) como banco de pruebas para comparar algoritmos MARL en el contexto de respuesta a la demanda residencial. La investigación compara cuatro algoritmos CTDE: MAPPO, QMIX, MAA2C e IPPO, variando tanto el algoritmo como la función de recompensa (individual vs. conjunta) y la longitud del episodio (25-50 pasos). Los resultados revelan comportamientos asimétricos: MAPPO y QMIX aprovechan la mayor varianza de las recompensas individuales para mejorar las políticas conjuntas, mientras que VDN y MAA2C se degradan. También se demuestra que los métodos de descomposición de valor requieren información adicional de estado para coordinar eficazmente a los agentes.

Relación con las variables de estudio: Es el antecedente más directamente comparable a la presente investigación en términos de metodología: ambos comparan algoritmos MARL en CityLearn con control estadístico. La tesis aporta evidencia sobre D1_VI (arquitectura de algoritmos MARL en CityLearn), D2_VI (diseño de funciones de recompensa individual vs. conjunta) y D3_VI (impacto de la longitud del episodio sobre la convergencia). En la VD, aborda D3_VD (reducción del costo de energía) y D1_VD (aplanamiento del perfil de demanda). El gap fundamental es que Atrazhev (2023) no evalúa los algoritmos HAPPO, MASAC ni MATD3 —que son los más avanzados disponibles actualmente— ni incluye D2_VD (resiliencia, power outages). La presente investigación extiende directamente la comparación de algoritmos al conjunto HAPPO-MASAC-MATD3-MAAC en CityLearn v2 con las tres dimensiones de la VD.

Antecedente Internacional 4 [Tesis de Maestría]

Nguyen, D. H. (2024). *The role of reinforcement learning control for optimizing building energy management systems* [MSc Thesis, Smart Energy Programme]. University of Vaasa. Supervisor: Mazaher Karimi. Evaluator: Kimmo Kauhaniemi.

Esta tesis de maestría de la Universidad de Vaasa (Finlandia) desarrolla un framework basado en el algoritmo SAC para la gestión energética inteligente en edificios interactivos con la red, con énfasis en la integración de vehículos eléctricos (EV) como recursos energéticos distribuidos. El framework propuesto permite a los prosumidores reducir costos energéticos, mejorar la estabilidad de la red, optimizar la utilización de energía renovable y mantener el confort de los usuarios. Los resultados de simulación muestran mejoras significativas en eficiencia de costos, reducción de emisiones de CO₂ y resiliencia de la red respecto a estrategias de control convencionales (MPC, RBC). La tesis proporciona además una revisión sistemática de los principios fundamentales del RL y sus aplicaciones en sistemas de potencia, demand response y control operacional.

Relacion con las variables de estudio: Esta tesis vincula directamente el aprendizaje por refuerzo (VI) con los tres ejes de la VD: D1_VD (flexibilidad mediante control de BESS y EV), D2_VD (resiliencia de la red bajo escenarios de alta penetracion renovable) y D3_VD (reduccion de costo y desviacion de señales de precio). En la VI, proporciona un analisis comparativo entre SAC y algoritmos baseline (MPC, RBC) que permite calibrar las expectativas de desempeño de MASAC —el equivalente multi-agente de SAC— en la presente investigacion. El gap identificado es que la tesis evalua un único agente SAC sin comparacion con otros algoritmos avanzados de RL y sin el paradigma multi-agente (CTDE). La presente investigacion extiende el enfoque de Nguyen (2024) al escenario multi-agente con CityLearn v2 y la comparacion sistematica de cuatro algoritmos.

Antecedente Internacional 5 [Tesis de Maestria]

Rahman, M. A. (2025). *Optimizing smart grid flexibility and resilience with demand response, renewable integration and energy storage* [MSc Thesis, Smart Energy Programme]. University of Vaasa. Supervisor: Hannu Laaksonen. Co-supervisor: Hosna Khajeh.

Esta tesis de maestria de la Universidad de Vaasa (Finlandia) examina explicitamente como la integracion de sistemas fotovoltaicos (PV), sistemas de almacenamiento en baterias (BESS) y tecnicas de respuesta a la demanda (DR) pueden mejorar tanto la flexibilidad como la resiliencia de las redes inteligentes de distribucion. El estudio se realiza bajo el proyecto EU-PEAK en dos redes de distribucion finlandesas: 02_Porkholm (rural) y 03_Centrum (semiurbana), utilizando datos horarios de medidores inteligentes y un framework de simulacion en Python. Los resultados muestran que el despliegue estrategico del BESS cerca de nodos con alta sensibilidad de voltaje y alta demanda mejora significativamente el peak shaving y la confiabilidad de la red. Para la gestion de DR en el lado de la demanda, la combinacion de termostatos inteligentes, señales TOU y optimizacion de calefaccion puede reducir los picos de demanda hasta en un 20%. Los marcos de evaluación de KPIs de flexibilidad utilizados por Rahman (2025) son consistentes con los reportados en OSMOSE H2020 (2021) y NREL (2024).

Relacion con las variables de estudio: Este es el antecedente que mas directamente aborda de forma conjunta D1_VD (flexibilidad) y D2_VD (resiliencia) —las dos dimensiones menos estudiadas de forma integrada en la literatura peruana y latinoamericana. La tesis evalua el efecto del BESS y el DR sobre ambas dimensiones simultaneamente, estableciendo trade-offs cuantificados entre ellas que son directamente comparables con los resultados esperados de la presente investigacion. En la VI, la tesis usa algoritmos de optimizacion heuristica (no MARL), lo que establece un baseline no-RL respecto al cual los algoritmos

MADRL de la presente investigación deben demostrar superioridad. Gap: No usa RL ni MADRL; no evalúa D3_VI (eficiencia de entrenamiento); el entorno de simulación no es CityLearn v2. La presente investigación provee exactamente este complemento: los mismos objetivos de flexibilidad y resiliencia, pero con algoritmos MADRL y evaluación estadística formal.

B. ANTECEDENTES NACIONALES

Antecedente Nacional 1 [Tesis de Maestría]

Vadillo Gutierrez, J. C. (2020). *Medición de la respuesta de la demanda a la señal de precios a través de soluciones de redes inteligentes* [Tesis de Maestría en Ciencias de la Ingeniería Mecánica y Eléctrica con Mención en Energía]. Universidad Nacional Pedro Ruiz Gallo (UNPRG), Lambayeque, Perú.

Esta tesis de maestría de la Universidad Nacional Pedro Ruiz Gallo de Lambayeque investiga la medición empírica de la respuesta de la demanda a señales de precios en el contexto de las soluciones de redes inteligentes (smart grids) aplicadas al sistema eléctrico peruano. El trabajo desarrolla un modelo para cuantificar cómo los consumidores finales —residenciales e industriales— modifican su patrón de consumo ante variaciones en el precio de la electricidad, utilizando datos reales del Sistema Eléctrico Interconectado Nacional (SEIN). La investigación evalúa distintos mecanismos de señal de precio (RTP, TOU) y su elasticidad en el contexto del marco tarifario del OSINERGMIN, identificando las condiciones bajo las cuales la respuesta a la demanda es económicamente viable para los usuarios peruanos y beneficiosa para el operador del sistema.

Relación con las variables de estudio: Es el antecedente nacional más directamente relevante para D3_VD (respuesta a la demanda: electricity_cost, price_signal_deviation). La tesis establece la base empírica peruana sobre cómo un cambio en la señal de precio modifica el consumo, lo que es exactamente el mecanismo que los agentes MADRL aprenden a explotar en los escenarios E1 y E3 de la presente investigación. Los datos sobre elasticidad precio-demanda del SEIN peruano permiten calibrar la magnitud esperada del KPI price_signal_deviation. Gap: La investigación es puramente descriptiva y empírica —no implementa ningún algoritmo de control automatizado ni de aprendizaje por refuerzo para optimizar la respuesta. La presente investigación proporciona exactamente la dimensión de automatización inteligente que falta en Vadillo Gutierrez (2020): los agentes MADRL aprenden autónomamente a responder a las señales de precio sin intervención manual.

Antecedente Nacional 2 [Tesis de Maestría]

Davila Perez, J. M. (2024). *Cuantificación a corto plazo de la Demanda Eléctrica en redes eléctricas de distribución a través de clientes regulados y libres en la región Lambayeque* [Tesis de Maestria en Ciencias de la Ingenieria Mecanica y Electrica con Mencion en Energia]. Universidad Nacional Pedro Ruiz Gallo (UNPRG), Lambayeque, Peru.

Esta tesis de maestria de la UNPRG desarrolla un modelo de pronóstico de corto plazo de la demanda electrica en las redes de distribucion de la region Lambayeque, diferenciando entre clientes regulados y libres (no regulados). La investigacion utiliza datos historicos de la empresa de distribucion de la region y aplica metodos estadisticos y de inteligencia artificial para generar pronosticos horarios con horizonte de 24-48 horas. El trabajo identifica los factores determinantes de la variabilidad de la demanda en el contexto peruano —temperatura, dias habiles, actividad industrial— y evalua la precision de los modelos generados mediante indicadores como el Error Cuadratico Medio (RMSE) y el Error Porcentual Absoluto Medio (MAPE). Los resultados muestran que la diferenciacion entre clientes regulados y libres mejora significativamente la precision del pronostico respecto a modelos agregados.

Relacion con las variables de estudio: Esta tesis establece la caracterizacion de la demanda electrica en el contexto peruano que es relevante para D3_VD (demand response: perfil de demanda que los agentes MADRL deben moldear) y D1_VD (peak demand: magnitud de los picos de demanda que se busca reducir). La distincion entre clientes regulados y libres en Perú es directamente analogica a la distincion entre edificios con distintos perfiles de DER en CityLearn v2: ambos contextos presentan heterogeneidad de usuarios que complica la coordinacion. Los datos de perfil de demanda de Lambayeque sirven como referencia para validar cualitativamente los perfiles del EULP utilizados en CityLearn v2. Gap: La tesis no implementa ninguna estrategia de control o DR automatizado; el pronostico es el fin en si mismo. La presente investigacion cierra este vacio utilizando pronosticos de demanda como inputs para los agentes MADRL que ejecutan las estrategias de DR automaticamente.

Antecedente Nacional 3 [Articulo Cientifico]

Gonzales Chavez, S. (2014). *Pronostico eficiente de la demanda diaria del sistema electrico interconectado del Peru mediante analisis estocastico ARIMA con sucesos externos*. TECNIA: Revista de la Universidad Nacional de Ingenieria, 24(1). <https://revistas.uni.edu.pe/index.php/tecnia>

Este articulo cientifico, publicado en TECNIA — la revista de investigacion de la Universidad Nacional de Ingenieria (UNI) — constituye una referencia fundamental para el pronostico de la demanda del SEIN y es un hito en la investigacion energetica peruana. El

trabajo formula y calibra modelos ARIMA con sucesos externos (eventos climaticos, feriados, cambios estacionales) para el pronostico de corto plazo de la demanda diaria total del SEIN, asi como de sus subsistemas (Centro, Norte y Sur). Los modelos son evaluados mediante el Error Absoluto Porcentual Medio (MAPE) y comparados con metodos alternativos, demostrando la eficacia del enfoque ARIMA con variables exogenas para capturar la no-estacionariedad de la demanda electrica peruana y los efectos de eventos excepcionales como el Fenomeno El Nino.

Relacion con las variables de estudio: Aunque publicado en 2014, este articulo constituye la referencia historica fundacional en pronostico de demanda del SEIN desde la UNI, directamente relevante para D3_VD (el perfil de demanda que la respuesta a la demanda busca modificar) y D1_VD (la magnitud de los picos que la flexibilidad energetica debe suavizar). El articulo establece la base metodologica para comprender como los sucesos externos —en particular el Fenomeno El Nino— afectan la demanda del SEIN, lo que conecta directamente con la justificacion de D2_VD (resiliencia ante eventos extremos). La inclusion de este articulo como antecedente de referencia historica es admitida por la Guia N°01 UNI cuando el antecedente es un referente tecnico fundacional en el campo. Gap: El modelo ARIMA es puramente predictivo —no proporciona ningun mecanismo de control adaptativo que permita modificar el perfil de demanda en respuesta a los eventos predichos. La presente investigacion proporciona exactamente este componente de control inteligente mediante MADRL.

Antecedente Nacional 4 [Articulo Cientifico]

Vilca-Tinta, C. W., Torres-Cruz, F., & Quispe-Morales, J. J. (2024). *Optimization of energy consumption forecasting in Puno using parallel computing and ARIMA models: An innovative approach to big data processing.* arXiv:2408.00014. Universidad Nacional del Altiplano, Puno, Peru.

Este articulo de investigacion de la Universidad Nacional del Altiplano (UNAP) de Puno, Peru, presenta una metodologia innovadora para el pronostico eficiente del consumo energetico en la region de Puno utilizando computacion paralela y modelos ARIMA. El trabajo aborda el desafio de la gestion de grandes volumenes de datos de consumo historico —un problema relevante en el contexto de la expansion de la medicion inteligente en el Peru— y demuestra que la implementacion paralela del modelo ARIMA puede mejorar la velocidad de computo en un 68.4% respecto a la implementacion secuencial, manteniendo la precision de los pronosticos. El estudio tambien analiza los factores que determinan la variabilidad del consumo energetico en la region de Puno (temperatura,

actividad minera, estacionalidad), que es una region con alta penetracion de energia renovable (hidro y solar) y con desafios de resiliencia ante eventos del Fenomeno El Nino.

Relacion con las variables de estudio: Este articulo es relevante para D3_VD (demand response: pronostico de demanda como input para algoritmos de DR) y, mas especificamente, para la dimensión metodologica de D3_VI (eficiencia computacional: el analisis de velocidad de procesamiento en Vilca-Tinta et al. 2024 es analogo al analisis de eficiencia de entrenamiento de los algoritmos MADRL). La region de Puno, con alta penetracion de hidro y solar, y con riesgo de cortes por El Nino, es representativa de los desafios de D2_VD (resiliencia) a nivel regional peruano. Gap: El articulo usa ARIMA (metodo estadistico clasico) en lugar de MADRL; el enfoque es pronostico de consumo, no control adaptativo de la demanda. La presente investigacion representa el paso natural siguiente: utilizar los pronosticos generados por modelos como el de Vilca-Tinta et al. como inputs para los agentes MADRL que ejecutan automaticamente las estrategias de control.

Antecedente Nacional 5 [Articulo Cientifico]

Morla Morales Taquiri, O. (2015). *Propuesta para la optimizacion del diseño y operacion de sistemas fotovoltaicos autonomos a instalarse en el Peru, basado en redes electricas inteligentes.* TECNIA: Revista de la Universidad Nacional de Ingenieria, 25(2). <https://revistas.uni.edu.pe/index.php/tecnia>

Este articulo cientifico de la revista TECNIA de la Universidad Nacional de Ingenieria (UNI) propone un framework de optimizacion para el diseño y la operacion de sistemas fotovoltaicos autonomos en el contexto peruano, integrando principios de redes electricas inteligentes (smart grids). El trabajo evalua los componentes tecnologicos clave —paneles PV, inversores, sistemas de almacenamiento en baterias (BESS) y controladores de carga— y desarrolla un modelo de optimizacion para el dimensionamiento optimo de BESS en funcion de los perfiles de demanda y los recursos solares disponibles en distintas regiones del Peru (costa, sierra, selva). El articulo analiza el impacto de las variables climaticas (irradiancia solar, temperatura) sobre el rendimiento del sistema y propone estrategias de control basadas en logica difusa para maximizar la utilizacion de la energia solar y minimizar la dependencia de la red de distribucion.

Relacion con las variables de estudio: Esta referencia es la mas proxima al contexto tecnico especifico de la presente investigacion dentro de la literatura cientifica peruana indexada. Establece la base conceptual peruana para: D1_VD (flexibilidad: optimizacion de BESS para reduccion de dependencia de la red), D2_VD (resiliencia: operacion autonoma de sistemas PV+BESS durante cortes de suministro, equivalente funcional al escenario

islanded mode de CityLearn v2) y D3_VD (reduccion de costos de energia mediante uso optimo de generacion solar). El articulo propone un BESS controlado por logica difusa — un metodo de control basado en reglas— que es directamente comparable en terminos de desempeño con el control por MADRL que propone la presente investigacion. Gap: El modelo de control propuesto es estatico (basado en reglas difusas predefinidas), sin capacidad de aprendizaje adaptativo. Los algoritmos MADRL de la presente investigacion superan esta limitacion aprendiendo politicas de control optimas directamente de la interaccion con el entorno sin necesidad de reglas predefinidas.

N°	Año	Autor(es) / Institucion	Tipo y Titulo	Resultado Principal	Gap Identificado	Variables	Control la Inves
ANTECEDENTES INTERNACIONALES (Tesis PhD / MSc)							
I-1	2024	Nweye, K.E. / UT Austin (PhD)	Tesis PhD: Data-driven modeling and control of grid-interactive communities	Origen de CityLearn v2: LSTM temperatura, power outages, V2G, 7 KPIs flexibilidad-resiliencia-DR.	No compara algoritmos MADRL avanzados; solo RBC y SAC individual.	D1_VD, D2_VD, D3_VD (todos KPIs)	Define central + la VD. comparac MASAC-M MAAC.
I-2	2024	Zhang, B. / Aalborg Univ. Denmark (PhD)	Tesis PhD: Modelling and Optimization of MES Operation Based on DRL. DOI:10.54337/aau763295893	Estrategias MADRL (SAC, MAAC) para MES con BESS. Reduccion costo 12-28% vs MPC. 6 publicaciones Q1.	Sin resiliencia (D2_VD). Sin CityLearn v2. Enfocado en microrredes, no edificios GIC.	D1_VI (SAC,MAAC), D2_VI, D3_VI, D3_VD	Valida MA algoritmo con BE comparac algoritmica
I-3	2023	Atrazhev, P. / U. Alberta Canada (MSc)	Tesis MSc: MARL for Autonomous Energy Coordination in DR Residential Networks	MAPPO, QMIX, MAA2C, IPPO comparados en CityLearn 2022. Recompensa individual vs conjunta.	Sin HAPPO/MASAC/MATD3. Sin D2_VD (resiliencia). Sin CityLearn v2.	D1_VI, D2_VI, D3_VI, D1_VD, D3_VD	Precedent metodolog cercano: c MARL en Brecha: avanzados
I-4	2024	Nguyen, D.H. / U. Vaasa Finland (MSc)	Tesis MSc: Role of RL Control for Optimizing Building Energy Management Systems	SAC para edificios con EVs. Mejoras en costo, CO2 y resiliencia de red vs MPC y RBC.	Unico agente SAC. Sin comparacion multi-algoritmo MADRL. Sin CTDE.	D2_VI, D3_VI, D1_VD, D2_VD, D3_VD	Valida SA ejes en ed comparac multi-agen investigac
I-5	2025	Rahman, M.A. / U. Vaasa Finland (MSc)	Tesis MSc: Optimizing Smart Grid Flexibility and Resilience with DR, RES and Energy Storage	BESS+PV+DR reduce pico demanda 20%. Analisis conjunto flexibilidad (D1_VD) y resiliencia (D2_VD).	Sin RL ni MADRL. Algoritmo heuristico estatico. Sin CityLearn v2.	D1_VD (flexibilidad), D2_VD (resiliencia), D3_VD	Unico que D1_VD+D conjuntam Baseline comparac

ANTECEDENTES NACIONALES — Peru (Tesis MSc / Articulos Cientificos Indexados)							
N-1	2020	Vadillo Gutierrez, J.C. / UNPRG, Lambayeque (MSc)	Tesis Maestria: Medicion de la respuesta de la demanda a la señal de precios en redes inteligentes	Modelo empirico de elasticidad precio-demanda en el SEIN peruano bajo señales RTP y TOU.	Sin algoritmo de control automatizado. Enfoque descriptivo-empirico. Sin MADRL.	D3_VD (DR: precio-demanda Peru)	Establece empirica D3_VD. magnitud price_signal en Peru.
N-2	2024	Davila Perez, J.M. / UNPRG, Lambayeque (MSc)	Tesis Maestria: Cuantificacion a corto plazo de Demanda Electrica en distribucion, Lambayeque	Modelo pronostico demanda 24-48h. Diferenciacion clientes regulados vs libres. Mejora MAPE 23%.	Sin DR ni control automatizado. Solo pronostico sin intervencion de agentes.	D1_VD (peak demand Peru), D3_VD	Caracteriz demanda Analogia heterogen edificios e v2.
N-3	2014	Gonzales Chavez, S. / UNI, Lima (Art. TECNIA)	Articulo TECNIA-UNI: Pronostico eficiente demanda diaria SEIN mediante ARIMA con sucesos externos	Modelos ARIMA con exogenas (El Nino, feriados) para SEIN. MAPE <2.5% en pronostico diario.	Modelo predictivo estatico. Sin control de demanda. Solo ARIMA, sin RL.	D3_VD (perfil demanda SEIN), D1_VD (picos)	Referencia fundacion demanda Justifica vulnerabilidad Nino (D2_
N-4	2024	Vilca-Tinta et al. / UNAP Puno, Peru (Art. arXiv)	Articulo: Optimization of Energy Consumption Forecasting in Puno using Parallel Computing and ARIMA	Computacion paralela reduce tiempo pronostico 68.4% manteniendo precision ARIMA para Puno-Peru.	Metodo estadistico clasico. Sin control ni MADRL. Solo pronostico de consumo.	D3_VD (demanda Puno-Peru), D3_VI (eficiencia computacional)	Articulo investigad peruanos gestion regional. resiliencia ante El Ni
N-5	2015	Morla Morales Taquiri, O. / UNI, Lima (Art. TECNIA)	Articulo TECNIA-UNI: Optimizacion de sistemas fotovoltaicos autonomos en Peru con redes inteligentes	Framework optimizacion BESS+PV en Peru. Control logica difusa para maximizar uso solar.	Control estatico por reglas difusas. Sin aprendizaje adaptativo. Sin multi-agente.	D1_VD (flexibilidad BESS), D2_VD (operacion isla), D3_VD	Articulo BESS+PV Establece control po MADRL de

Tabla 1. Resumen de antecedentes: 5 internacionales (tesis PhD/MSc) y 5 nacionales (tesis MSc y articulos científicos) 2014-2025.

Sintesis de Brechas Identificadas y Posicion de la Investigacion

Del analisis de los 10 antecedentes validos —cinco tesis doctorales/maestria internacionales y cinco tesis maestria/articulos científicos nacionales— emergen cuatro brechas estructurales que la presente investigacion cierra de forma integrada. La primera brecha, identificada en los antecedentes internacionales I-1 a I-5, es la ausencia de una comparacion sistematica de los cuatro algoritmos MADRL mas avanzados (HAPPO, MASAC, MATD3, MAAC) en CityLearn v2: Nweye (2024) define el entorno pero no compara algoritmos; Atrazhev (2023) compara MARL en CityLearn pero sin

HAPPO/MASAC/MATD3; Zhang (2024) compara DRL en microrredes pero sin aplicación a edificios GIC ni D2_VD; Nguyen (2024) evalúa SAC individual sin MARL; Rahman (2025) establece baselines heurísticos sin RL. Estos hallazgos se corroboran con tesis doctorales recientes en gestión energética con RL: Vázquez-Canteli (2019) en UT Austin, Brandi (2022) en Politecnico di Torino, Biemann (2024) en DTU; y con tesis de maestría: Charbonnier (2024) en Oxford, Costea (2026) en Polito, Häkkinen (2024) en Aalto, Frommel Araujo (2022) en UDELAR y Ramos Illán (2024) en UPM.

La segunda brecha es la evaluación integrada de D1_VD (flexibilidad), D2_VD (resiliencia) y D3_VD (DR) simultáneamente: Rahman (2025) combina D1_VD y D2_VD pero sin RL; los demás antecedentes internacionales abordan como máximo dos dimensiones. La tercera brecha es la conexión entre el MADRL de frontera y el contexto energético peruano: los antecedentes nacionales N-1 a N-5 establecen la demanda, flexibilidad y perfil de resiliencia del SEIN, pero ninguno propone ni evalúa algoritmos MADRL como solución tecnológica. La cuarta brecha es la validación estadística formal (ANOVA/Kruskal-Wallis, tamaño del efecto, TOPSIS) en el marco de un diseño experimental con control de semillas aleatorias: ningún antecedente —ni internacional ni nacional— aplica este nivel de rigor estadístico a la comparación de algoritmos MADRL en edificios. La presente investigación es la primera en cerrar las cuatro brechas de forma simultánea e integrada, aportando evidencia que es transferible tanto a la comunidad científica internacional como al sector eléctrico peruano en el marco de la Hoja de Ruta de Redes Inteligentes 2023-2030. La trayectoria nacional peruana en investigación de demanda eléctrica está representada por publicaciones en TECNIA-UNI (Gonzales Chávez, 2014; Morla Morales Taquiri, 2015), aplicaciones industriales pioneras (Ojeda Sarmiento y Pajares, 2008), tesis de maestría en UNPRG (Vadillo Gutierrez, 2020; Dávila Pérez, 2024) y artículos de pronóstico regional (Vilca-Tinta et al., 2024), enmarcadas en los planes nacionales del MINEM (2014, 2023).

1.2.2 Formulación del Problema

La formulación del problema se estructura en un problema general (PG) que recoge integralmente los tres ejes de la Variable Dependiente (VD), y tres problemas específicos (PE1, PE2, PE3) formulados como peldaños paralelos, uno por cada eje de la VD. La estructura paralela entre las tres formulaciones específicas garantiza la simetría metodológica de la investigación. El carácter cooperativo y multi-objetivo de los algoritmos MADRL aplicados, así como los detalles operacionales (escenarios experimentales, KPIs específicos, hiperparámetros y pruebas estadísticas), se desarrollan en el Capítulo III (Marco Teórico, Bases Teóricas) y en el Capítulo IV (Diseño Metodológico, Procesamiento y Análisis de Datos).

1.2.2.1 Formulación del Problema General

PG: ¿De que manera los algoritmos Multi-Agente de Aprendizaje por Refuerzo Profundo (MADRL) optimizan la flexibilidad, la resiliencia y la respuesta a la demanda energetica en comunidades de edificios interactivos con la red electrica?

1.2.2.2 Formulación de los Problemas Específicos

PE1 — Eje 1: FLEXIBILIDAD ENERGETICA

PE1: ¿De que manera los algoritmos MADRL optimizan la flexibilidad energetica en comunidades de edificios interactivos con la red electrica?

PE2 — Eje 2: RESILIENCIA ENERGETICA

PE2: ¿De que manera los algoritmos MADRL optimizan la resiliencia energetica en comunidades de edificios interactivos con la red electrica?

PE3 — Eje 3: RESPUESTA A LA DEMANDA ENERGETICA

PE3: ¿De que manera los algoritmos MADRL optimizan la respuesta a la demanda energetica en comunidades de edificios interactivos con la red electrica?

1.2.3 Justificación y Alcances

La justificación articula las razones por las cuales esta investigación contribuye al conocimiento científico, a la práctica tecnológica y a las metas socio-energéticas del Perú; los alcances delimitan su perímetro de aplicabilidad espacial, temporal y conceptual.

1.2.3.1 Justificación

a) Justificación Científica

La presente investigación realiza una contribución científica original al campo del MADRL aplicado a la gestión energética de edificios en al menos tres dimensiones. Primero, proporciona el primer estudio comparativo sistemático y estadísticamente fundamentado de los cuatro algoritmos MADRL más representativos de las familias on-policy (HAPPO) y off-policy (MASAC, MATD3, MAAC) bajo el mismo entorno experimental (CityLearn v2), con control de semillas aleatorias y pruebas de significancia estadística (Shapiro-Wilk, ANOVA/Kruskal-Wallis, Tukey/Dunn). Segundo, genera conocimiento inédito sobre las interacciones entre los tres ejes de desempeño —flexibilidad, resiliencia y DR— bajo

diferentes configuraciones algorítmicas, identificando sinergias y trade-offs que no son observables en estudios que abordan estos aspectos de forma aislada. Tercero, el framework metodológico propuesto es reproducible y extensible a otros entornos y algoritmos, contribuyendo a la comunidad científica con un protocolo de evaluación estandarizado.

b) Justificación Tecnológica

Desde la perspectiva tecnológica, la investigación genera artefactos de software funcionales —implementaciones calibradas de HAPPO, MASAC, MATD3 y MAAC en CityLearn v2— que pueden ser adoptados directamente por operadores de sistemas de distribución, gestores de edificios inteligentes y desarrolladores de sistemas de gestión energética (EMS). La plataforma CityLearn v2, de código abierto y basada en el estándar Gymnasium (OpenAI), garantiza la reproducibilidad y la interoperabilidad con el ecosistema Python de ciencia de datos e inteligencia artificial (PyTorch, Weights & Biases). Esta elección tecnológica maximiza la transferibilidad de los resultados al sector industrial.

c) Justificación Social y Energética

El Perú enfrenta desafíos energéticos particulares que hacen especialmente relevante esta investigación. El Plan Nacional de Energía 2014-2025 del Ministerio de Energía y Minas (MINEM, 2014) establece objetivos de expansión de las FERV que elevarán la penetración de energía solar y eólica en la matriz eléctrica nacional hasta el 20% en 2025. Esta transición requerirá mecanismos de flexibilidad y respuesta a la demanda que actualmente no están implementados de forma eficiente en el sistema eléctrico peruano. Paralelamente, eventos climáticos como El Niño han demostrado la vulnerabilidad del sistema de transmisión frente a eventos extremos, resaltando la necesidad de soluciones de resiliencia a nivel de distribución y edificios. La investigación proporciona evidencia técnica para el diseño de políticas de DR e incentivos a la flexibilidad que OSINERGMIN y MINEM podrían implementar en el marco regulatorio peruano. La urgencia de esta transformación queda evidenciada en los reportes recientes del IPCC (2023) sobre cambio climático y de IRENA (2024) sobre la capacidad renovable instalada globalmente, así como en la estrategia para edificios interactivos con la red del U.S. Department of Energy (DOE, 2023) y los marcos energéticos de la International Energy Agency (IEA, 2022).

d) Justificación Metodológica

La investigación aporta un framework metodológico innovador que integra la simulación computacional avanzada (CityLearn v2), el control estadístico riguroso (múltiples semillas, pruebas de normalidad, análisis de varianza, corrección de comparaciones múltiples) y la

toma de decisiones multicriterio (TOPSIS). Este framework es replicable para cualquier nuevo algoritmo MADRL que se desee comparar, constituyendo un protocolo de benchmarking que la comunidad puede adoptar y extender. La publicación del código, los resultados y los datos experimentales en repositorios públicos garantizará la máxima transparencia y reproducibilidad científica.

1.2.3.2 Alcances

Alcance temático: La investigación se circunscribe a la aplicación de algoritmos MADRL para la gestión energética de comunidades de edificios residenciales/comerciales interactivos con la red eléctrica, evaluando específicamente los algoritmos HAPPO, MASAC, MATD3 y MAAC. No se extiende al diseño de nuevos algoritmos ni a la optimización de la arquitectura de las redes neuronales mediante búsqueda de arquitectura neural (NAS).

Alcance espacial: La investigación se desarrolla en el entorno de simulación computacional CityLearn v2, utilizando datos de carga del End Use Load Profiles (EULP) para el parque edilicio de los Estados Unidos, que sirve como proxy de edificios comerciales y residenciales modernos con características representativas de comunidades energéticas avanzadas.

Alcance temporal: El estudio evalúa el desempeño de los algoritmos en un horizonte de simulación de 12 meses para entrenamiento y 3 meses para evaluación, con paso temporal horario, lo que representa 8,760 y 2,160 pasos de tiempo respectivamente. El período de ejecución del proyecto de investigación comprende 12 meses.

Limitaciones: (1) Los resultados son válidos para el entorno de simulación CityLearn v2 y los parámetros configurados; la transferibilidad a sistemas reales requiere validación adicional. (2) El estudio no considera aspectos de ciberseguridad ni privacidad de datos. (3) Los modelos de edificios están basados en datos del parque edilicio de EE.UU., lo que puede limitar la representatividad para el contexto peruano. (4) El alcance computacional está limitado por los recursos de GPU disponibles, estableciendo un máximo de $n=10$ semillas por configuración experimental.

CAPÍTULO II: OBJETIVOS

2.1 OBJETIVO GENERAL

OG: Aplicar algoritmos Multi-Agente de Aprendizaje por Refuerzo Profundo (MADRL) para optimizar la flexibilidad, la resiliencia y la respuesta a la demanda energetica en comunidades de edificios interactivos con la red electrica.

2.2 OBJETIVOS ESPECÍFICOS

Los objetivos especificos se formulan como peldanos paralelos, uno por cada eje de la Variable Dependiente, manteniendo simetria estructural con los problemas especificos (PE1-PE3) y las hipotesis especificas (HE1-HE3). El caracter cooperativo y multi-objetivo de los algoritmos MADRL se documenta en el Capitulo III (Bases Teoricas) y los procedimientos operacionales —escenarios experimentales, KPIs, pruebas estadisticas e instrumentos— en el Capitulo IV (Procesamiento y Analisis de Datos).

OE1 — Eje 1: FLEXIBILIDAD ENERGETICA

OE1: Aplicar algoritmos MADRL para optimizar la flexibilidad energetica en comunidades de edificios interactivos con la red electrica.

OE2 — Eje 2: RESILIENCIA ENERGETICA

OE2: Aplicar algoritmos MADRL para optimizar la resiliencia energetica en comunidades de edificios interactivos con la red electrica.

OE3 — Eje 3: RESPUESTA A LA DEMANDA ENERGETICA

OE3: Aplicar algoritmos MADRL para optimizar la respuesta a la demanda energetica en comunidades de edificios interactivos con la red electrica.

CAPÍTULO III: MARCO TEÓRICO

3.1 BASES TEÓRICAS

Las bases teóricas de la presente investigación se desarrollan con el rigor formal exigido por una investigación de nivel posgrado, articulando de manera bidireccional la Variable Independiente (algoritmos MADRL, con sus tres dimensiones D1_VI, D2_VI y D3_VI) con la Variable Dependiente (desempeño energético en comunidades GIC, con sus tres dimensiones o ejes D1_VD, D2_VD y D3_VD). Para cada dimensión se presentan los fundamentos matemáticos formales —proposiciones, teoremas y resultados de la literatura científica—, se demuestran los puentes lógicos entre VI y VD que sustentan las hipótesis específicas, y se trianguliza la información mediante la convergencia de al menos tres fuentes independientes por cada afirmación crítica. La estructura general comprende un Bloque A —fundamentos matemáticos del MARL y formalización de la VI—, un Bloque B —operacionalización matemática de la VD y articulación con la VI—, un Bloque C —demostración formal de las hipótesis— y un Bloque D —el entorno CityLearn v2 como instrumento de medición de las variables.

BLOQUE A — Fundamentos matemáticos de la Variable Independiente (algoritmos MADRL).

Formalización del Problema MARL como Dec-POMDP

Definición 3.1 (Juego de Markov Parcialmente Observable Descentralizado, Dec-POMDP). Un Dec-POMDP cooperativo se define formalmente como la séptupla $M = \langle N, S, \{A_i\}_{i=1}^N, P, R, \{O_i\}_{i=1}^N, \gamma \rangle$, donde $N \in \mathbb{N}$ es el número de agentes, S es el espacio de estados global, A_i es el espacio de acciones del agente i , $P: S \times A \times S \rightarrow [0,1]$ es la función de transición markoviana definida sobre el producto cartesiano $A = A_1 \times \dots \times A_N$, $R: S \times A \rightarrow \mathbb{R}$ es la función de recompensa común para todos los agentes en el caso cooperativo, O_i es el espacio de observaciones del agente i con función de observación $\Omega_i: S \rightarrow O_i$, y $\gamma \in [0,1]$ es el factor de descuento (Lowe et al., 2017; Yu et al., 2022; Zhong et al., 2024).

Cada agente i mantiene una política estocástica $\pi_i(a_i | o_i; \theta_i)$ parametrizada por $\theta_i \in \Theta_i$, donde $o_i = \Omega_i(s)$ es la observación local. La política conjunta se denota $\pi_\theta = (\pi_1, \dots, \pi_N)$ con $\theta = (\theta_1, \dots, \theta_N)$. El objetivo del aprendizaje cooperativo consiste en encontrar la política conjunta óptima π_{θ^*} que maximice la función de valor conjunta:

$$J(\pi_\theta) = E_{\{s_0 \sim p_0, a_t \sim \pi_\theta, s_{t+1} \sim P\}} [\sum_{t=0}^{\infty} \gamma^t R(s_t, a_t)]$$

Proposición 3.1 (No estacionariedad inducida por la actualización conjunta). En el régimen multi-agente, cuando cada agente i actualiza su política π_i de manera independiente, la dinámica efectiva percibida por cualquier agente $j \neq i$ es no estacionaria, pues la distribución conjunta de las acciones a_{-i} cambia con cada paso de optimización. Formalmente, sea $P_{\text{eff}}^j(o_j' | o_j, a_j; \pi_{-i})$ la transición efectiva percibida por j ; entonces P_{eff}^j depende paramétricamente de las políticas $\{\pi_k\}_{k \neq j}$, lo cual viola el supuesto markoviano en la perspectiva individual del agente (Lowe et al., 2017; Iqbal y Sha, 2019). Esta no estacionariedad motiva la introducción del paradigma de Entrenamiento Centralizado con Ejecución Descentralizada (CTDE).

D1_VI — Arquitectura y Tipo de Algoritmo

La primera dimensión de la VI corresponde a las características arquitectónicas del algoritmo MADRL: tipo de gradiente (on-policy vs. off-policy), naturaleza de la política (determinista vs. estocástica), presencia o ausencia de mecanismos de atención, y tratamiento de la heterogeneidad entre agentes. La presente investigación opera D1_VI mediante la selección de cuatro algoritmos representativos —HAPPO, MASAC, MATD3 y MAAC— cuyas formulaciones matemáticas se presentan a continuación.

a) HAPPO — Heterogeneous-Agent Proximal Policy Optimization

Teorema 3.1 (Mejora Monótona Heterogénea — HAMI; Kuba et al., 2021; Zhong et al., 2024). Sea π una política conjunta y sean $\pi_{-i\{1:k\}} = (\pi_{-i_1}, \dots, \pi_{-i_k}, \pi_{-i_{k+1}}, \dots, \pi_{-i_N})$ una secuencia de políticas en la cual los agentes $i_1, \dots, i_k$ han sido actualizados secuencialmente. Si para cada $k = 1, \dots, N$ la política actualizada π_{-i_k} satisface:

$$J(\pi_{-i\{1:k\}}) - J(\pi_{-i\{1:k-1\}}) \geq E_{\{s \sim \rho_{\{\pi_{-i\{1:k-1\}}\}}\}}[A_{i_k}^{\pi_{-i\{1:k-1\}}}(s, \pi_{-i_k})] - C \cdot D_{\{KL\}}^{\{max\}}(\pi_{-i_k} \parallel \pi_{-i_k})$$

entonces la mejora monótona conjunta $J(\pi) \geq J(\pi)$ está garantizada, donde A_i^{π} es la ventaja del agente i bajo la política π , $D_{\{KL\}}^{\{max\}}$ es la divergencia KL máxima entre las políticas previa y actualizada del agente i_k , y C es una constante dependiente del horizonte y γ . La demostración completa puede consultarse en Zhong et al. (2024, Sección 4).

La función objetivo de HAPPO se deriva del teorema HAMI mediante una aproximación clipped del ratio de importancia:

$$L_{\text{HAPPO}}^{i_k}(\theta_{i_k}) = E_{\{(s,a) \sim \pi_{\text{old}}\}} [\min(\rho_{i_k}(\theta_{i_k}) \hat{A}_{i_k}, \text{clip}(\rho_{i_k}(\theta_{i_k}), 1-\epsilon, 1+\epsilon) \hat{A}_{i_k})]$$

donde $p_{i_k}(\theta_{i_k}) = \pi_{i_k}(a_{i_k}|o_{i_k}; \theta_{i_k}) / \pi_{i_k}^{\text{old}}(a_{i_k}|o_{i_k})$ es el ratio de importancia y $\hat{A}_{i_k}$ es la estimación generalizada de ventaja (GAE) de Schulman et al. (2017). La triangulación de fuentes para HAPPO incluye la formalización original (Kuba et al., 2021), la consolidación teórica en JMLR (Zhong et al., 2024), las guías prácticas de implementación (Yu et al., 2022) y las aplicaciones a edificios (Atrazhev, 2023; Charbonnier, 2024).

b) MASAC — Multi-Agent Soft Actor-Critic

MASAC extiende SAC (Haarnoja et al., 2018) al régimen multi-agente preservando el principio de máxima entropía. La política óptima estocástica del agente i se obtiene mediante:

$$\pi_i^* = \operatorname{argmax}_{\pi_i} E_{s,a \sim \pi} [\sum_{t=0}^{\infty} \gamma^t (R(s_t, a_t) + \alpha H(\pi_i(\cdot|o_{i,t})))]$$

donde $H(\pi_i(\cdot|o_i)) = -E_{a_i \sim \pi_i} [\log \pi_i(a_i|o_i)]$ es la entropía de Shannon de la política individual y $\alpha > 0$ es el coeficiente de temperatura, ajustado dinámicamente mediante gradiente sobre la restricción de entropía objetivo $\bar{H}$ (Haarnoja et al., 2018; Fu et al., 2025). Las funciones Q estimadas por dos críticos centralizados $Q_{\phi_1}(s, a)$ y $Q_{\phi_2}(s, a)$ se utilizan en la actualización del actor mediante el operador min para mitigar el sesgo de sobreestimación, herencia conceptual de TD3 (Fujimoto et al., 2018).

Lema 3.1 (Exploración intrínseca por entropía). La inclusión del término entrópico $\alpha H(\pi_i)$ en el objetivo garantiza que la política óptima no colapse a una distribución de Dirac sobre la acción greedy, propiedad crucial en escenarios donde la exploración es necesaria para descubrir estrategias de pre-posicionamiento del BESS no triviales. Este resultado se demuestra rigurosamente en Haarnoja et al. (2018, Apéndice A) y se extiende al caso multi-agente híbrido en Fu et al. (2025).

c) MATD3 — Multi-Agent Twin Delayed Deep Deterministic Policy Gradient

MATD3 extiende TD3 (Fujimoto et al., 2018) al paradigma CTDE preservando las tres innovaciones técnicas que lo distinguen: doble crítico, actualización retardada del actor y suavizado de la política objetivo. La actualización del crítico utiliza el target conservador:

$$y(r, s', d) = r + \gamma (1-d) \min_{j=1,2} Q_{\phi_j^{\text{target}}}(s', \mu_{\theta^{\text{target}}}(o')) + \epsilon_{\text{clipped}}$$

donde $\epsilon_{\text{clipped}} = \text{clip}(N(0, \tilde{\sigma}), -c, +c)$ es el ruido gaussiano truncado para suavizado de target, μ_{θ} es la política determinista parametrizada y los subíndices target denotan las redes lentas. La actualización del actor se realiza cada d_{actor} pasos del crítico (típicamente $d_{\text{actor}} = 2$), reduciendo la varianza del gradiente de política conforme demuestran Fujimoto et al. (2018) y Wang et al. (2024).

Proposición 3.2 (Reducción del sesgo de sobreestimación). En cualquier MDP con espacio de acción continuo, el estimador $\min_{j=1,2} Q_{\{\varphi_j\}}$ satisface $E[\min_j Q_{\{\varphi_j\}}(s,a)] \leq E[Q_{\{\varphi_j\}}(s,a)]$ para $j \in \{1,2\}$; combinado con la actualización retardada del actor y el suavizado de target, este estimador converge a una vecindad ε -óptima del valor verdadero Q^* con probabilidad $1-\delta$ bajo condiciones estándar de aproximación estocástica (Fujimoto et al., 2018, Teorema 1).

d) MAAC — Multi-Agent Actor-Critic with Attention

MAAC (Iqbal y Sha, 2019) introduce un mecanismo de atención multi-cabezal en el crítico centralizado, permitiendo que el agente i ponderare de forma adaptativa la información relevante de cada agente $j \neq i$. Formalmente, sea h_j el vector de codificación de la observación-acción (o_j, a_j) del agente j ; entonces el crítico de i computa:

$$Q_i(s, a) = f_i(g_i(o_i, a_i), x_i), \quad x_i = \sum_{j \neq i} \alpha_{\{ij\}} v_j$$

donde $\alpha_{\{ij\}} = \text{softmax}_j(K_j^T W_q^T W_k h_i / \sqrt{d_k})$ son los pesos de atención y $v_j = W_v h_j$ son las representaciones de valor. Las matrices W_q, W_k, W_v se aprenden conjuntamente con los parámetros de la red. Esta arquitectura permite a MAAC modelar dependencias espaciales entre los edificios sin imponer una estructura de comunicación predefinida (Iqbal y Sha, 2019; Xie et al., 2023; Brandi, 2022).

D2 VI — Política de Control y Función de Recompensa Multi-objetivo

La segunda dimensión de la VI corresponde a la naturaleza de la política aprendida y a la estructura de la función de recompensa multi-objetivo. La política π_θ asigna probabilidades a las acciones (caso estocástico, MASAC) o determina directamente la acción (caso determinista, MATD3) en función del estado observado. La distinción entre políticas estocásticas y deterministas tiene consecuencias formales sobre la exploración del espacio de soluciones, como se establece en el siguiente teorema.

Teorema 3.2 (Equivalencia entre exploración estocástica y robustez ante perturbaciones; Haarnoja et al., 2018). Una política π_i estocástica que maximiza el objetivo regularizado por entropía es ε -robusta ante perturbaciones del entorno con distribución acotada por $TV(P_{\text{real}}, P_{\text{modelado}}) \leq \delta$, donde δ depende monótonamente del coeficiente de temperatura α . Es decir, la política estocástica de máxima entropía no sólo explora mejor durante el entrenamiento, sino que mantiene un desempeño cota inferior garantizado bajo perturbaciones del entorno durante la ejecución.

Para la presente investigación, la función de recompensa multi-objetivo se construye como combinación lineal ponderada de los términos asociados a cada eje de la VD:

$$R(s, a) = w_F \cdot r_F(s, a) + w_R \cdot r_R(s, a) + w_D \cdot r_D(s, a)$$

donde $w_F + w_R + w_D = 1$ son los pesos de los componentes de flexibilidad (r_F), resiliencia (r_R) y demand response (r_D). Cada componente se normaliza respecto a la línea base RBC (Rule-Based Control) para garantizar que las magnitudes de los gradientes de política sean comparables a través de los tres ejes:

$$r_F = -(peak_t/peak^{RBC} + ramping_t/ramping^{RBC})$$

$$r_R = -(UEF_t + \beta \cdot TD_t/TD^{RBC}), \quad \beta = 0,1$$

$$r_D = -(EC_t/EC^{RBC} + \lambda \cdot PSD_t/PSD^{RBC}), \quad \lambda = 0,05$$

Esta operacionalización es coherente con las recomendaciones de Yu et al. (2020) sobre normalización de recompensas multi-objetivo en DRL para gestión energética y con la práctica establecida en CityLearn v2 (Nweye et al., 2024).

D3 VI — Eficiencia del Proceso de Entrenamiento

La tercera dimensión de la VI corresponde a la eficiencia computacional del proceso de entrenamiento, operacionalizada mediante tres métricas: la velocidad de convergencia (número de pasos de interacción hasta alcanzar el 95 % del rendimiento asintótico), la estabilidad (varianza de la curva de aprendizaje sobre las diez semillas) y el costo computacional (horas-GPU acumuladas hasta convergencia). La diferencia teórica fundamental entre los cuatro algoritmos en esta dimensión radica en la naturaleza on-policy vs. off-policy.

Proposición 3.3 (Eficiencia de muestra de algoritmos off-policy). Bajo condiciones estándar de ergodicidad del Dec-POMDP, los algoritmos off-policy con experience replay (MASAC, MATD3, MAAC) requieren menos interacciones con el entorno para alcanzar un nivel de desempeño equivalente que los algoritmos on-policy (HAPPO), con un factor de eficiencia teóricamente acotado por la razón $|B|/|\tau|$, donde $|B|$ es el tamaño del replay buffer y $|\tau|$ es la longitud del rollout on-policy (Fujimoto et al., 2018; Haarnoja et al., 2018). Empíricamente, esta razón se estabiliza típicamente entre 3 y 10 para tareas de control continuo de complejidad moderada.

Para la calibración de hiperparámetros, la presente investigación adopta el framework Optuna (Akiba et al., 2019), que implementa el algoritmo Tree-structured Parzen Estimator (TPE) como meta-optimizador bayesiano. El TPE modela la distribución condicional $p(\theta | y)$ mediante dos kernels gaussianos separados —uno para configuraciones con desempeño superior al cuantil y y otro para las configuraciones inferiores—, y selecciona la siguiente configuración a evaluar maximizando la razón de las densidades, lo cual

proporciona una exploración eficiente del espacio de hiperparámetros (Akiba et al., 2019; Costea, 2026).

BLOQUE B — Operacionalización matemática de la Variable Dependiente y articulación con la VI.

D1 VD — Flexibilidad Energética

Definición 3.2 (Flexibilidad energética; Kathirgamanathan et al., 2021; OSMOSE H2020, 2021; NREL, 2024). La flexibilidad energética de una comunidad de edificios se define como la capacidad de modificar su perfil agregado de demanda en respuesta a señales sistémicas (precios, balance generación-demanda, instrucciones del operador), preservando los niveles de servicio interno (confort térmico, suministro de calor sanitario) dentro de los rangos aceptables. Esta capacidad se cuantifica mediante tres KPIs operacionales calculados sobre el período de evaluación T :

$$KPI_1 \text{ (peak_average): } PA = (1/N) \sum_{b=1}^N \max_{t \in [0, T]} P_{\{b, t\}} / \max_{t \in [0, T]} P_{\{b, t\}}^{RBC}$$

$$KPI_2 \text{ (ramping_average): } RA = (1/N) \sum_{b=1}^N (1/(T-1)) \sum_{t=1}^{T-1} |P_{\{b, t+1\}} - P_{\{b, t\}}| / RA_b^{RBC}$$

$$KPI_3 \text{ (1 - load_factor): } LF^c = 1 - \text{mean}_t(P_{\{b, t\}}) / \max_t(P_{\{b, t\}}), \text{ promediado por edificio}$$

Los tres KPIs son funciones decrecientes monótonas de la flexibilidad: valores menores indican mejor desempeño. Esta operacionalización tiene triangulación documentada en Kathirgamanathan et al. (2021) para el marco europeo, OSMOSE H2020 (2021) para el dominio público de KPIs en sistemas eléctricos y NREL (2024) para el contexto estadounidense.

Articulación con $D1_VI \Rightarrow D1_VD$ (puente lógico para HE1). La arquitectura del algoritmo MADRL —dimensión $D1_VI$ — condiciona la calidad del comportamiento coordinado de los agentes que controlan los recursos distribuidos (BESS, TES, HVAC) y, en consecuencia, determina los valores observados de PA, RA y LF^c en el escenario E1. Concretamente, se postula que HAPPO, gracias al teorema HAMI (Teorema 3.1) que garantiza la mejora monótona conjunta bajo actualizaciones secuenciales heterogéneas, exhibirá la ventaja competitiva en comunidades con DER heterogéneos. Este puente lógico $VI \rightarrow VD$ constituye la base teórica de la hipótesis específica HE1 y se contrasta empíricamente en el escenario E1 mediante la ANOVA o Kruskal-Wallis sobre los tres KPIs descritos.

D2 VD — Resiliencia Energética

Definición 3.3 (Resiliencia energética; NERC, 2020; NREL, 2021; CURENT, 2024). La resiliencia energética es la capacidad del sistema para absorber perturbaciones del suministro eléctrico, adaptarse a las condiciones degradadas y recuperarse minimizando el impacto sobre los ocupantes. Esta dimensión se operacionaliza mediante dos KPIs evaluados durante los eventos de power outage del escenario E2:

KPI_4 (UEF, unserved_energy_fraction):

$$UEF = \frac{\sum_{t: \text{outage}_t = 1} \max(0, D_t - G_t^{\text{local}}) - \text{desc}_{\text{BESS},t}}{\sum_{t: \text{outage}_t = 1} D_t}$$

KPI_5 (TD, thermal_discomfort):

$$TD = \sum_{t=1}^T [\max(0, T_{\text{int},t} - T_{\text{max}}) + \max(0, T_{\text{min}} - T_{\text{int},t})]$$

donde D_t es la demanda en el instante t , G_t^{local} es la generación local PV, $\text{desc}_{\text{BESS},t}$ es la descarga del BESS, outage_t es la variable binaria de corte de suministro y $T_{\text{int},t}$ es la temperatura interior estimada por el modelo LSTM de CityLearn v2 (Nweye et al., 2024). Los umbrales de confort $T_{\text{min}} = 20$ °C y $T_{\text{max}} = 26$ °C se adoptan según ASHRAE 55. La triangulación de la operacionalización incluye el marco NERC (2020) para la definición conceptual, NREL (2021) para los KPIs cuantitativos, CURENT (2024) para los métodos de cuantificación y Sustainability MDPI Authors (2020) para la revisión sistemática.

Articulación con $D2_VI \Rightarrow D2_VD$ (puente lógico para HE2). La política de control aprendida —dimensión $D2_VI$ — y, en particular, la función de recompensa multi-objetivo (Sección 3.1.3) determinan la magnitud del pre-posicionamiento prospectivo del BESS y, por ende, los valores observados de UEF y TD durante los eventos de outage. Por el Teorema 3.2, la política estocástica de máxima entropía de MASAC mantiene un desempeño cota inferior garantizado ante perturbaciones del entorno (los outages son perturbaciones puntuales del operador del entorno). Este resultado matemático sustenta teóricamente la expectativa de superioridad de MASAC en $D2_VD$ y constituye la base de la hipótesis HE2.

D3_VD — Respuesta a la Demanda Energética

Definición 3.4 (Respuesta a la Demanda; FERC, 2019; Deltetto et al., 2021; TU Delft AI Energy Lab, 2023). La respuesta a la demanda (DR) consiste en cambios en el uso eléctrico por parte del consumidor final en respuesta a cambios en el precio de la electricidad o a pagos de incentivos diseñados para inducir reducciones de demanda durante períodos de precios altos o riesgos de confiabilidad. La dimensión $D3_VD$ se operacionaliza mediante:

$$KPI_6 (EC, electricity_cost): EC = \sum_{t=1}^T C_t \cdot P_t \cdot \Delta t \quad (\text{normalizado por } EC^{\text{RBC}})$$

$$KPI_7 (PSD, price_signal_deviation): PSD = (1/T) \sum_{t=1}^T |P_t - f(C_t)|$$

donde C_t es la tarifa en tiempo real, P_t es la potencia neta importada y $f(C_t)$ es la trayectoria de demanda esperada bajo seguimiento perfecto de la señal de precio. La triangulación incluye la definición regulatoria oficial (FERC, 2019), los estudios empíricos en clusters de edificios (Deltetto et al., 2021) y las extensiones al ámbito residencial multi-agente (TU Delft AI Energy Lab, 2023). En el contexto peruano, la operacionalización se enmarca en la Hoja de Ruta de Smart Grids 2023-2030 (MINEM, 2023) y en los datos de precio spot reportados por OSINERGMIN (2023).

Articulación con $D3_VI \Rightarrow D3_VD$ (puente lógico para HE3). La eficiencia del proceso de entrenamiento —dimensión $D3_VI$ — condiciona la calidad asintótica de la política aprendida para la respuesta a señales de precio dinámicas. Por la Proposición 3.3, los algoritmos off-policy con experience replay (MASAC, MATD3, MAAC) presentan ventajas teóricas de eficiencia de muestra que se traducen en mejor desempeño en el escenario E3 dadas iguales restricciones de presupuesto computacional. Específicamente, MATD3 combina la eficiencia off-policy con la robustez del doble crítico (Proposición 3.2), lo cual sustenta teóricamente la expectativa de su superioridad en $D3_VD$ y constituye la base de la hipótesis HE3.

BLOQUE C — Demostración formal de las hipótesis específicas.

Cadena Lógica de Demostración VI $\Rightarrow$ VD

La presente investigación adopta el método hipotético-deductivo: las hipótesis específicas se derivan formalmente de los fundamentos matemáticos del Bloque A y se contrastan empíricamente sobre los KPIs operacionalizados en el Bloque B. La demostración deductiva sigue la estructura formal: (1) premisa matemática del MARL $\rightarrow$ (2) consecuencia teórica sobre el comportamiento del algoritmo $\rightarrow$ (3) predicción operacional sobre los KPIs $\rightarrow$ (4) contraste empírico estadístico $\rightarrow$ (5) decisión sobre la hipótesis.

Demostración (HE1, Eje 1: $D1_VI \Rightarrow D1_VD$). Premisa: el Teorema 3.1 (HAMI) establece que HAPPO satisface mejora monótona heterogénea bajo actualizaciones secuenciales (Zhong et al., 2024). Consecuencia teórica: en una comunidad con N edificios heterogéneos, HAPPO converge a una política conjunta π^* que satisface $J(\pi^*) \geq J(\pi')$ para toda política π' obtenida sin actualización heterogénea (incluyendo políticas obtenidas por MASAC, MATD3 o MAAC con tratamiento homogéneo). Predicción operacional: la política π_HAPPO^* induce trayectorias de potencia neta $\{P_{b,t}\}$ con menor varianza intertemporal y menor magnitud de pico en el escenario E1. Contraste empírico: ANOVA o Kruskal-Wallis ($\alpha = 0,05$) sobre $\{PA, RA, 1-LF\}$ con $\eta^2_p \geq 0,06$. Decisión: HE1 no se rechaza si HAPPO

presenta mejora estadísticamente significativa sobre los demás algoritmos en al menos dos de los tres KPIs.

Demostración (HE2, Eje 2: $D2_VI \Rightarrow D2_VD$). Premisa: el Teorema 3.2 (Haarnoja et al., 2018) establece que la política estocástica de máxima entropía es ϵ -robusta ante perturbaciones del entorno con cota $TV(P_real, P_modelado) \leq \delta$. Consecuencia teórica: los eventos de power outage del escenario E2 representan perturbaciones que activan la cota de robustez; MASAC, dotado de exploración estocástica intrínseca, mantiene desempeño cota inferior garantizado. Predicción operacional: MASAC presenta menor UEF y TD durante los outages que los algoritmos deterministas (MATD3) y on-policy (HAPPO). Contraste empírico: ANOVA o Kruskal-Wallis ($\alpha = 0,05$) sobre {UEF, TD} con $\eta^2_p \geq 0,06$. Decisión: HE2 no se rechaza si MASAC presenta reducción estadísticamente significativa de UEF mayor o igual al 25 % respecto al baseline RBC.

Demostración (HE3, Eje 3: $D3_VI \Rightarrow D3_VD$). Premisa: la Proposición 3.3 (eficiencia de muestra off-policy) y la Proposición 3.2 (reducción del sesgo de sobreestimación con doble crítico) establecen las ventajas teóricas de MATD3. Consecuencia teórica: MATD3 alcanza el rendimiento asintótico óptimo con menor número de pasos de interacción y mantiene estimaciones conservadoras del valor Q en espacios de acción continuos. Predicción operacional: MATD3 presenta la mejor combinación de costo eléctrico (EC) y seguimiento de la señal de precio (PSD) en el escenario E3, con relación monótona positiva entre la eficiencia del entrenamiento ($D3_VI$) y los KPIs de DR ($D3_VD$). Contraste empírico: correlación de Spearman $\rho \geq 0,5$ con $p < 0,05$ entre métricas de entrenamiento y KPIs de DR; ANOVA o Kruskal-Wallis sobre los KPIs. Decisión: HE3 no se rechaza si MATD3 reduce EC en al menos 18 % respecto al baseline RBC con correlación ρ significativa.

BLOQUE D — Instrumento de medición: CityLearn v2.

CityLearn v2 — Arquitectura, Modelos Físicos y Capacidades

CityLearn v2 (Nweye et al., 2024) es un entorno de simulación de comunidades de edificios interactivos con la red eléctrica que implementa la interfaz Gymnasium (sucesora de OpenAI Gym) y constituye el estándar de facto en investigación MARL aplicada a gestión energética. Su arquitectura modular permite la configuración flexible de comunidades de N edificios heterogéneos equipados con un subconjunto configurable de DER. La trayectoria del ecosistema CityLearn comprende la versión original como entorno OpenAI Gym (Vázquez-Canteli et al., 2019), la estandarización para MARL (Vázquez-Canteli et al., 2020), GridLearn como extensión a redes eléctricas (Pigott et al., 2022), las soluciones ganadoras de las competiciones científicas CityLearn 2021–2023 (Khattar y Jin, 2023;

CHESCA Team, 2024; Motoki et al., 2023) y la versión v2 actual (Nweye et al., 2024). MARLEM (Salazar et al., 2026) extiende el ecosistema MADRL hacia el dominio de recursos energéticos distribuidos a escala de distribución.

Modelo de carga de edificio. Los perfiles horarios de demanda se basan en el End Use Load Profiles (EULP, Wilson et al., 2022) del NREL, que proporciona perfiles de consumo realistas para el parque edilicio estadounidense con resolución horaria para 8 760 h/año, segmentados por condado, clima ASHRAE y tipología edilicia.

Modelo de generación solar PV. La generación PV instantánea se calcula como $P_{PV}(t) = P_{nom} \cdot \eta_{inv} \cdot GHI(t) \cdot [1 + \alpha_T (T_{cell}(t) - 25 \text{ }^{\circ}\text{C})]$, donde $GHI(t)$ es la irradiancia global horizontal del dataset NREL TMY3, η_{inv} es la eficiencia del inversor, α_T es el coeficiente de temperatura del panel y T_{cell} se estima del modelo NOCT.

Modelo dinámico del BESS. La dinámica de la carga del BESS se modela en tiempo discreto como:

$$SoC_{t+1} = SoC_t + (\eta_c \cdot P_{c,t} - P_{d,t} / \eta_d) \cdot \Delta t / E_{max}$$

sujeto a $SoC_{min} \leq SoC_t \leq SoC_{max}$, $0 \leq P_{c,t} \leq P_{c,max}$, $0 \leq P_{d,t} \leq P_{d,max}$, donde SoC_t es el estado de carga, $P_{c,t}$ y $P_{d,t}$ son las potencias instantáneas de carga y descarga, η_c y η_d son las eficiencias respectivas, y E_{max} es la capacidad nominal.

Modelo LSTM de temperatura interior. CityLearn v2 incorpora un modelo LSTM preentrenado que predice la temperatura interior $T_{int,t+1}$ en función de las acciones de setpoint del HVAC, la temperatura exterior y las cargas internas. Este modelo captura la inercia térmica del edificio con realismo físico superior a los modelos RC simples (Nweye et al., 2024), lo cual es crucial para la evaluación rigurosa del KPI thermal_discomfort durante los outages del escenario E2.

La presente investigación utiliza, en consecuencia, CityLearn v2 como instrumento único de medición para los siete KPIs de la Variable Dependiente, garantizando la comparabilidad estricta de los cuatro algoritmos MADRL evaluados y la reproducibilidad del estudio mediante la fijación de las semillas aleatorias ($n = 10$ por celda algoritmo-escenario, según el diseño de la Sección 4.4).

3.2 DEFINICIÓN DE TÉRMINOS

La presente sección consolida la terminología técnica empleada a lo largo del plan de tesis, organizada en seis categorías temáticas que reflejan los dominios de conocimiento

involucrados: (A) términos del aprendizaje por refuerzo y los algoritmos MADRL; (B) sistemas eléctricos y recursos energéticos distribuidos; (C) indicadores de desempeño (KPIs); (D) métodos estadísticos y de análisis multicriterio; (E) entorno computacional, software y datos; y (F) marco regulatorio e instituciones. Cada término se define operacionalmente en el contexto específico de la presente investigación.

A. Aprendizaje por Refuerzo y Algoritmos MADRL

Actor-crítico: Familia de algoritmos de RL que combina dos redes neuronales: el actor $\pi_\theta(a|s)$, que aproxima la política y selecciona acciones, y el crítico $Q_\phi(s,a)$ o $V_\phi(s)$, que aproxima la función de valor y guía la actualización del actor (Lowe et al., 2017).

ARIMA (AutoRegressive Integrated Moving Average): Modelo estadístico clásico para el pronóstico de series temporales que combina componentes autorregresivos, de integración (diferenciación) y de media móvil; utilizado como referencia comparativa de pronóstico de demanda (Vilca-Tinta et al., 2024; Gonzales Chávez, 2014).

BESS (Battery Energy Storage System): Sistema de almacenamiento de energía basado en baterías electroquímicas (típicamente iones de litio) que permite almacenar energía eléctrica durante períodos de bajo precio o alta generación renovable y liberarla durante períodos de alta demanda o precio elevado (IEA, 2022).

CTDE (Centralized Training, Decentralized Execution): Paradigma de entrenamiento en MARL donde los agentes tienen acceso al estado global y a las acciones conjuntas durante el entrenamiento, pero ejecutan sus políticas de forma descentralizada basándose únicamente en observaciones locales durante la operación (Lowe et al., 2017; Yu et al., 2022).

DDPG (Deep Deterministic Policy Gradient): Algoritmo de RL off-policy para espacios de acción continuos, basado en política determinista $\mu_\theta(s)$ y crítico $Q_\phi(s,a)$, precursor de TD3 y MATD3 (Fujimoto et al., 2018).

Dec-POMDP (Decentralized Partially Observable MDP): Formalización matemática del problema MARL cooperativo en el cual cada agente observa solo una parte del estado global y debe coordinarse con los demás para maximizar una recompensa común (Lowe et al., 2017; Zhong et al., 2024).

DRL (Deep Reinforcement Learning): Aprendizaje por refuerzo que utiliza redes neuronales profundas como aproximadores funcionales de la política y/o la función de valor, lo cual permite abordar espacios de estado y acción de alta dimensionalidad (Yu et al., 2020).

Entropía de la política: Medida formal de la aleatoriedad de la política estocástica, definida como $H(\pi) = -E_{\{a \sim \pi\}}[\log \pi(a|s)]$; su maximización fomenta la exploración y proporciona robustez ante perturbaciones del entorno (Haarnoja et al., 2018).

Función de valor: Función $V^\pi(s) = E[\sum \gamma^t r_t | s_0 = s]$ que cuantifica el retorno esperado descontado al partir del estado s siguiendo la política π ; su forma estado-acción $Q^\pi(s,a)$ es central en los algoritmos actor-crítico.

Función de ventaja (advantage): Función $A^\pi(s,a) = Q^\pi(s,a) - V^\pi(s)$ que mide cuánto mejor es tomar la acción a en el estado s respecto al promedio de la política; estimada mediante GAE (Schulman et al., 2017).

GAE (Generalized Advantage Estimation): Estimador de la función de ventaja que combina diferencias temporales de múltiples horizontes mediante un parámetro $\lambda \in [0,1]$ que balancea sesgo y varianza (Schulman et al., 2017).

HAMI (Heterogeneous-Agent Monotonic Improvement Theorem): Teorema fundacional de HAPPO que establece las condiciones bajo las cuales la actualización secuencial heterogénea de políticas garantiza la mejora monótona de la función de valor conjunta (Kuba et al., 2021; Zhong et al., 2024).

HAPPO (Heterogeneous-Agent PPO): Algoritmo MADRL on-policy que extiende PPO al escenario multi-agente heterogéneo mediante el Teorema HAMI, garantizando la mejora monótona de la política conjunta mediante actualización secuencial de políticas individuales (Kuba et al., 2021; Zhong et al., 2024).

HATRPO (Heterogeneous-Agent TRPO): Variante trust-region de HAPPO que utiliza una restricción dura sobre la divergencia KL en lugar del clipping; comparte las mismas garantías teóricas formalizadas en el HAMI (Kuba et al., 2021).

MAAC (Multi-Agent Actor-Critic with Attention): Algoritmo MADRL que incorpora un mecanismo de atención multi-cabezal en el crítico centralizado, permitiendo que cada agente pondere dinámicamente las contribuciones de los demás para la estimación de su función Q (Iqbal y Sha, 2019).

MADDPG (Multi-Agent DDPG): Algoritmo MADRL precursor que extiende DDPG con crítico centralizado, considerado el primer algoritmo CTDE (Lowe et al., 2017).

MADRL (Multi-Agent Deep Reinforcement Learning): Subdisciplina del aprendizaje por refuerzo que combina redes neuronales profundas con múltiples agentes interactuando en un entorno compartido, aprendiendo políticas de control adaptativas sin requerir modelos explícitos del sistema (Lowe et al., 2017; Zhong et al., 2024).

MAPPO (Multi-Agent PPO): Versión multi-agente de PPO con crítico centralizado, demostrada eficaz en juegos cooperativos por Yu et al. (2022); precursor homogéneo de HAPPO.

MARL (Multi-Agent Reinforcement Learning): Aprendizaje por refuerzo aplicado a sistemas con múltiples agentes que interactúan, cooperan y/o compiten en un entorno compartido, formalizado mediante juegos de Markov o Dec-POMDP (Lowe et al., 2017).

MASAC (Multi-Agent Soft Actor-Critic): Algoritmo MADRL off-policy que extiende SAC al contexto multi-agente, incorporando el principio de entropía máxima para fomentar la exploración y proporcionar robustez ante perturbaciones (Fu et al., 2025).

MATD3 (Multi-Agent Twin Delayed DDPG): Algoritmo MADRL off-policy que extiende TD3 al contexto multi-agente, incorporando doble red crítica, actualización retardada del actor y suavizado de la política objetivo para mitigar el sesgo de sobreestimación del valor Q (Fujimoto et al., 2018; Wang et al., 2024).

MDP (Markov Decision Process): Proceso estocástico de decisión secuencial donde la dinámica del sistema satisface la propiedad de Markov (el estado futuro depende sólo del estado actual y la acción tomada, no del historial).

MERLIN (Multi-agent Energy Reinforcement Learning INtelligence): Framework MADRL offline + transfer learning para gestión energética de comunidades de edificios (Nweye et al., 2023).

MMDP (Multi-agent Markov Decision Process): Variante del MDP en el cual el espacio de acciones es producto cartesiano de los espacios individuales $A = A_1 \times \dots \times A_N$; usado en MADRL cuando los agentes observan el estado global completo.

Off-policy: Característica de los algoritmos de RL que aprenden la política óptima a partir de transiciones generadas por una política distinta (típicamente una versión anterior almacenada en el replay buffer); proporciona alta eficiencia de muestra (MASAC, MATD3, MAAC).

On-policy: Característica de los algoritmos de RL que aprenden la política óptima exclusivamente a partir de transiciones generadas por la política actual; proporciona estabilidad teórica pero menor eficiencia de muestra (HAPPO, PPO, MAPPO).

Optuna: Framework de optimización de hiperparámetros que implementa el algoritmo Tree-structured Parzen Estimator (TPE) como meta-optimizador bayesiano (Akiba et al., 2019).

POMDP (Partially Observable MDP): MDP en el cual el agente no observa directamente el estado, sino una observación parcial mediante una función de observación $O(s)$; base de Dec-POMDP en MARL.

Política (policy) π_θ : Mapeo del estado o la observación a una distribución de probabilidad sobre las acciones (caso estocástico) o a una acción específica (caso determinista), parametrizado por θ ; objetivo del aprendizaje en RL.

PPO (Proximal Policy Optimization): Algoritmo de RL on-policy con objetivo clipped que limita la magnitud de actualización de la política, equilibrando estabilidad y eficiencia de muestra (Schulman et al., 2017).

Recompensa (reward) $R(s,a)$: Señal escalar que el entorno proporciona al agente tras la ejecución de una acción a en el estado s ; en MADRL cooperativo es común a todos los agentes.

Replay buffer: Estructura de datos que almacena tuplas de transición $(s, a, r, s', done)$ generadas durante el entrenamiento; permite el aprendizaje off-policy mediante el muestreo aleatorio de transiciones pasadas.

RL (Reinforcement Learning): Paradigma de aprendizaje automático en el cual un agente aprende una política óptima mediante interacción secuencial con un entorno, recibiendo recompensas que indican la calidad de sus decisiones (Sutton y Barto, 2018).

SAC (Soft Actor-Critic): Algoritmo de RL off-policy basado en el principio de entropía máxima que combina actor estocástico, doble crítico y ajuste automático del coeficiente de temperatura α (Haarnoja et al., 2018); base teórica de MASAC.

TD3 (Twin Delayed Deep Deterministic Policy Gradient): Mejora de DDPG que introduce doble crítico, actualización retardada del actor y suavizado de la política objetivo (Fujimoto et al., 2018); base teórica de MATD3.

TPE (Tree-structured Parzen Estimator): Algoritmo de optimización bayesiana implementado en Optuna que modela la distribución condicional $p(\theta|y)$ mediante kernels gaussianos separados para configuraciones superiores e inferiores (Akiba et al., 2019).

Trust region: Familia de métodos de optimización que restringen la magnitud de la actualización de los parámetros mediante una región de confianza definida por la divergencia KL o el clipping; PPO, TRPO, HAPPO y HATRPO pertenecen a esta familia.

B. Sistemas Eléctricos y Recursos Energéticos Distribuidos

ASHRAE 55: Norma de la American Society of Heating, Refrigerating and Air-Conditioning Engineers que establece las condiciones ambientales aceptables para el confort térmico

humano ($T_{\min} = 20\text{ }^{\circ}\text{C}$, $T_{\max} = 26\text{ }^{\circ}\text{C}$ bajo condiciones estándar de humedad y velocidad de aire).

CityLearn v2: Entorno de simulación de código abierto para la gestión energética de comunidades de edificios interactivos con la red eléctrica, que implementa la interfaz Gymnasium y proporciona modelos de BESS, PV, HVAC con LSTM de temperatura, TES, EV y soporte para power outages (Nweye et al., 2024).

CPP (Critical Peak Pricing): Esquema tarifario en el cual el precio de la electricidad se incrementa significativamente durante un número limitado de eventos críticos al año, anunciados con anticipación a los usuarios.

DER (Distributed Energy Resources): Conjunto de recursos de generación, almacenamiento y gestión de demanda instalados en el lado del consumidor, incluyendo paneles solares PV, BESS, vehículos eléctricos, sistemas HVAC controlables y almacenamiento térmico (IRENA, 2024).

DLC (Direct Load Control): Programa DR basado en incentivos que permite al operador del sistema apagar o reducir directamente cargas específicas del consumidor durante eventos críticos, a cambio de una compensación económica.

Discomfort térmico: Magnitud agregada de la desviación de la temperatura interior fuera de la banda de confort definida por la norma ASHRAE 55, calculada como suma de las desviaciones absolutas hora por hora durante el período de evaluación.

EV (Electric Vehicle): Vehículo eléctrico capaz de cargarse desde la red (G2V) y, en algunos casos, devolver energía a ella (V2G); en CityLearn v2 se modela como recurso flexible de almacenamiento adicional al BESS.

EULP (End-Use Load Profiles): Dataset del National Renewable Energy Laboratory (NREL) que proporciona perfiles horarios de consumo eléctrico realistas para el parque edilicio de Estados Unidos, segmentados por condado, clima ASHRAE y tipología edilicia (Wilson et al., 2022).

FEN (Fenómeno El Niño): Evento climático recurrente del Pacífico Sur que provoca alteraciones meteorológicas significativas en el Perú, incluida sequía hidrológica que afecta la generación hidroeléctrica del SEIN; documentado por OSINERGMIN (2023) y MINEM (2024).

GHI (Global Horizontal Irradiance): Componente principal del recurso solar utilizada para calcular la generación PV, expresada en W/m^2 ; obtenida del dataset NREL TMY3 en CityLearn v2.

GIC (Grid-Interactive Community): Comunidad de edificios capaces de interactuar bidireccionalmente con la red eléctrica, exportando excedentes de generación local, modulando su demanda en respuesta a señales de precio y operando en modo isla durante interrupciones del suministro.

HVAC (Heating, Ventilation and Air Conditioning): Sistema de climatización de edificios que controla la temperatura, humedad y calidad del aire interior; constituye típicamente el 40-60 % de la demanda eléctrica en edificios comerciales (DOE, 2023).

MES (Multi-Energy System): Sistema energético integrado que combina vectores eléctricos con calor, gas y/o hidrógeno; abordado en la tesis doctoral de referencia Zhang (2024).

Microgrid (microrred): Subsistema eléctrico autónomo capaz de operar conectado a la red principal o aislado, con generación distribuida, almacenamiento y cargas controlables propias.

Net metering: Esquema de medición bidireccional que permite a los consumidores con generación local PV inyectar excedentes a la red y compensarlos con su consumo; varía según la regulación nacional.

NOAA (National Oceanic and Atmospheric Administration): Agencia federal de Estados Unidos cuya base de datos meteorológicos se utiliza como entrada del modelo LSTM de temperatura interior en CityLearn v2.

NOCT (Nominal Operating Cell Temperature): Temperatura nominal de operación del módulo PV bajo condiciones estándar (irradiancia 800 W/m², temperatura ambiente 20 °C, velocidad de viento 1 m/s); parámetro del modelo PV en CityLearn v2.

Peak demand (demanda pico): Valor máximo de potencia demandada por el sistema durante un período de tiempo determinado; minimizar el peak demand es uno de los objetivos centrales de la flexibilidad energética.

Peak shaving: Estrategia de gestión de demanda orientada a reducir los picos de consumo mediante el desplazamiento o la disminución temporal de cargas, generalmente apoyada en BESS.

Power outage: Interrupción del suministro eléctrico que desconecta al edificio de la red de distribución, forzando la operación en modo isla con los recursos energéticos locales (BESS, PV) como única fuente de energía.

PV (Photovoltaic): Tecnología de generación eléctrica solar basada en el efecto fotovoltaico; modelada en CityLearn v2 mediante datos de irradiancia (NREL TMY3) y parámetros físicos del panel (eficiencia, coeficiente de temperatura, NOCT).

Ramping: Tasa instantánea de cambio de la potencia neta entre dos pasos de tiempo consecutivos; un ramping elevado dificulta la operación del sistema eléctrico y se penaliza en la función de recompensa.

RER (Recursos Energéticos Renovables): Categoría regulatoria peruana que agrupa fuentes renovables no convencionales (solar, eólica, biomasa, geotérmica), reportada en el Anuario Estadístico del MINEM (2024).

RES (Renewable Energy Sources): Equivalente anglosajón de RER; término utilizado en la literatura científica internacional.

Resiliencia energética: Capacidad de un sistema eléctrico de absorber perturbaciones, adaptarse a condiciones degradadas y recuperarse de interrupciones minimizando el impacto sobre los ocupantes y las cargas críticas (NERC, 2020; NREL, 2021).

RTP (Real-Time Pricing): Esquema tarifario en el cual el precio de la electricidad varía hora a hora según las condiciones del mercado mayorista, transmitiendo la señal económica del operador al consumidor final.

SEIN (Sistema Eléctrico Interconectado Nacional): Sistema eléctrico nacional del Perú; reporta 58 393 GWh de generación en 2023 con 53 % de fuentes renovables (MINEM, 2024).

Smart grid: Red eléctrica inteligente que incorpora tecnologías digitales de comunicación, medición y control para optimizar el flujo bidireccional de electricidad entre generadores, redes de transmisión y distribución, y consumidores finales (MINEM, 2023).

SoC (State of Charge): Estado de carga del BESS, expresado como porcentaje (o fracción) de la capacidad nominal E_{max} ; variable de estado central en la dinámica del BESS.

TES (Thermal Energy Storage): Sistema de almacenamiento térmico, típicamente basado en agua caliente o cambio de fase, que desacopla la generación de calor de su uso final.

TMY3 (Typical Meteorological Year 3): Dataset del NREL con datos meteorológicos típicos representativos para distintas localidades de Estados Unidos; utilizado por CityLearn v2 para modelar la generación PV.

TOU (Time-Of-Use): Esquema tarifario en el cual el precio de la electricidad varía por bloques horarios (típicamente pico, intermedio y valle), conocidos por el consumidor con anticipación.

V2G (Vehicle-to-Grid): Capacidad de los EV para devolver energía a la red eléctrica mediante el uso bidireccional de su batería como recurso de almacenamiento distribuido (Nweye et al., 2024).

G2V (Grid-to-Vehicle): Esquema unidireccional de carga del EV desde la red eléctrica.

C. Indicadores de Desempeño (KPIs)

KPI (Key Performance Indicator): Indicador cuantitativo de desempeño que permite evaluar el grado de cumplimiento de un objetivo; en la presente investigación se agrupan en tres ejes (D1_VD, D2_VD, D3_VD) con un total de siete KPIs.

peak_average: KPI de flexibilidad (D1_VD) que mide el valor medio de los picos máximos de demanda por edificio durante el período de evaluación, normalizado por el baseline RBC. Valores menores indican mejor desempeño (Kathirgamanathan et al., 2021).

ramping_average: KPI de flexibilidad (D1_VD) que mide la tasa media de cambio absoluto de la potencia neta entre pasos consecutivos, promediada por edificio y normalizada por el baseline RBC. Cuantifica la suavidad del perfil de demanda (Nweye et al., 2024).

Load factor: Razón entre la demanda promedio y la demanda pico durante el período evaluado; un valor cercano a 1 indica perfil plano y eficiente. La presente investigación reporta su complemento ($1 - \text{load_factor}$) como KPI a minimizar.

Load shifting: Estrategia operacional asociada a la flexibilidad: desplazamiento temporal de cargas eléctricas de períodos de alta demanda o precio a períodos de menor demanda o precio.

UEF (unserved_energy_fraction): KPI de resiliencia (D2_VD) que mide la fracción de energía demandada que no logra ser servida durante eventos de power outage, debido a insuficiencia del BESS y la generación local. Valores cercanos a cero indican alta resiliencia (NREL, 2021).

thermal_discomfort (TD): KPI de resiliencia (D2_VD) que mide la suma de desviaciones absolutas de la temperatura interior fuera de la banda de confort ASHRAE 55, expresado en grado-hora; estimado por el modelo LSTM de CityLearn v2 (Nweye et al., 2024).

electricity_cost (EC): KPI de respuesta a la demanda (D3_VD) que mide el costo monetario total del consumo eléctrico durante el período de evaluación, normalizado por el baseline RBC. Valores menores indican mejor desempeño económico (FERC, 2019).

price_signal_deviation (PSD): KPI de respuesta a la demanda (D3_VD) que mide la desviación absoluta media entre la potencia neta observada y la trayectoria óptima esperada bajo seguimiento perfecto de la señal de precio; cuantifica la capacidad de respuesta a las señales del mercado.

D. Métodos Estadísticos y Análisis Multicriterio

ANOVA (Analysis of Variance): Prueba paramétrica que evalúa si las medias de tres o más grupos provienen de una misma distribución, mediante el estadístico $F = MS_{\text{between}}/MS_{\text{within}}$; supone normalidad y homocedasticidad (Hernández Sampieri et al., 2018).

Bonferroni (corrección): Procedimiento de ajuste del nivel de significancia α para múltiples comparaciones, dividiendo α por el número de contrastes pareados; controla la inflación del error tipo I.

Bootstrap: Método de remuestreo no paramétrico que genera B réplicas de la muestra original para estimar la distribución muestral de un estadístico ($B = 10\,000$ en la presente investigación) y construir intervalos de confianza.

Boxplot: Diagrama de cajas que resume gráficamente los percentiles P25, P50 (mediana) y P75 de una distribución, junto con los valores atípicos; los notched CIs permiten la inspección visual de diferencias entre grupos.

Cohen (umbrales): Criterios de Cohen (1988) para interpretar el tamaño del efecto: pequeño ($\eta^2 = 0,01$), mediano ($\eta^2 = 0,06$) y grande ($\eta^2 = 0,14$).

Dunn (prueba de): Prueba post-hoc no paramétrica empleada tras Kruskal-Wallis cuando la prueba principal rechaza H_0 ; identifica diferencias específicas entre pares de grupos.

Eta-cuadrado parcial (η^2_p): Tamaño del efecto bajo ANOVA, definido como $\eta^2_p = SS_{\text{between}} / SS_{\text{total}}$; cuantifica la magnitud práctica de la diferencia, complementando la significancia estadística (Cohen, 1988).

Epsilon-cuadrado (ϵ^2): Tamaño del efecto bajo Kruskal-Wallis, definido como $\epsilon^2 = (H - k + 1)/(n - k)$; análogo no paramétrico de η^2_p .

IC95 (Intervalo de Confianza al 95 %): Rango de valores que, con probabilidad del 95 %, contiene el parámetro poblacional verdadero; reportado para todas las medias y diferencias.

Kruskal-Wallis: Prueba no paramétrica equivalente a ANOVA cuando los datos no satisfacen los supuestos de normalidad u homocedasticidad; utiliza el estadístico H y se aplica sobre los rangos.

Levene (prueba de): Prueba estadística para verificar la igualdad de varianzas entre grupos (homocedasticidad), prerequisite del ANOVA paramétrico clásico.

MAPE (Mean Absolute Percentage Error): Error porcentual absoluto medio, métrica de evaluación de modelos de pronóstico de demanda eléctrica utilizada por Gonzales Chávez (2014) y Vilca-Tinta et al. (2024).

p-valor: Probabilidad de observar el estadístico de prueba (o uno más extremo) bajo el supuesto de que H_0 es verdadera; $p < \alpha$ conduce al rechazo de H_0 .

RMSE (Root Mean Square Error): Raíz del error cuadrático medio, métrica de evaluación de pronósticos.

Shapiro-Wilk: Prueba de normalidad recomendada para muestras pequeñas ($n < 30$) por su mayor potencia estadística respecto a Kolmogorov-Smirnov o Anderson-Darling (Razali y Wah, 2011).

Spearman (ρ): Coeficiente de correlación de rangos, no paramétrico; mide la asociación monótona entre dos variables en el rango $[-1, +1]$.

Tamaño del efecto: Magnitud cuantitativa de la diferencia o asociación, complementaria al p-valor; reportado como η^2_p , ε^2 o p según la prueba aplicada (Cohen, 1988).

TOPSIS (Technique for Order of Preference by Similarity to Ideal Solution): Método de análisis multicriterio que selecciona la alternativa más cercana a la solución ideal positiva A^+ y más lejana de la solución ideal negativa A^- (Hwang y Yoon, 1981).

Tukey HSD (Honestly Significant Difference): Prueba post-hoc paramétrica utilizada tras un ANOVA significativo; controla la tasa de error familiar mediante intervalos de confianza simultáneos.

Welch (ANOVA de): Variante de ANOVA robusta a violaciones de la homocedasticidad; se aplica cuando la prueba de Levene rechaza la igualdad de varianzas.

E. Entorno Computacional, Software y Datos

Gymnasium: Biblioteca Python que define la interfaz estándar de entornos de RL (sucesora de OpenAI Gym); CityLearn v2 implementa esta interfaz.

LSTM (Long Short-Term Memory): Tipo de red neuronal recurrente capaz de capturar dependencias temporales de largo plazo; CityLearn v2 utiliza un modelo LSTM preentrenado para predecir la temperatura interior del edificio (Nweye et al., 2024).

MARLlib: Biblioteca Python para algoritmos MARL construida sobre Ray RLLib que ofrece implementaciones de referencia de los principales algoritmos cooperativos y competitivos (Yu et al., 2022).

MPC (Model Predictive Control): Control predictivo basado en modelos explícitos de la dinámica del sistema; baseline tradicional de comparación frente al MADRL (Drgona et al., 2020).

Python: Lenguaje de programación principal de la implementación; versión 3.11 utilizada en la investigación.

PyTorch: Framework de aprendizaje profundo de código abierto utilizado para implementar las redes neuronales actor-crítico de los cuatro algoritmos MADRL.

RBC (Rule-Based Control): Control basado en reglas heurísticas predefinidas; baseline mínimo de comparación en CityLearn v2 y referente para la normalización de los KPIs.

Weights & Biases (W&B): Plataforma para el seguimiento de experimentos de aprendizaje automático que registra métricas, hiperparámetros y artefactos durante el entrenamiento, facilitando la reproducibilidad.

F. Marco Regulatorio e Instituciones

CAISO (California Independent System Operator): Operador independiente del sistema eléctrico de California (EE.UU.); fuente del dataset de tarifas RTP utilizado en CityLearn v2.

DGE (Dirección General de Electricidad del MINEM-Perú): Autoridad nacional encargada de la electricidad y emisora del Anuario Estadístico de Electricidad (MINEM, 2024).

DGEE (Dirección General de Eficiencia Energética del MINEM-Perú): Autoridad emisora de la Hoja de Ruta de Smart Grids 2023-2030 (MINEM, 2023).

DOE (U.S. Department of Energy): Departamento de Energía de Estados Unidos; fuente de la estrategia de edificios interactivos con la red (Grid-Interactive Efficient Buildings, GEB, 2023).

FERC (Federal Energy Regulatory Commission): Comisión federal reguladora de la energía de Estados Unidos; emisora de la definición regulatoria oficial de la respuesta a la demanda (FERC, 2019).

IEA (International Energy Agency): Agencia internacional de la energía; fuente de los reportes globales sobre transición energética (IEA, 2022).

IPCC (Intergovernmental Panel on Climate Change): Panel intergubernamental de cambio climático de las Naciones Unidas; fuente del Sexto Informe de Evaluación (IPCC, 2023).

IRENA (International Renewable Energy Agency): Agencia internacional de energías renovables; fuente del reporte anual de capacidad renovable instalada (IRENA, 2024).

MINEM (Ministerio de Energía y Minas del Perú): Ministerio sectorial peruano; rector del Plan Energético Nacional 2014-2025 y la Hoja de Ruta de Smart Grids 2023-2030.

NERC (North American Electric Reliability Corporation): Corporación norteamericana de confiabilidad eléctrica; emisora del marco de resiliencia para sistemas eléctricos de gran tamaño (NERC, 2020).

NREL (National Renewable Energy Laboratory): Laboratorio nacional de energías renovables de Estados Unidos; fuente del dataset EULP, los reportes de resiliencia y los marcos de KPIs de flexibilidad.

OSINERGMIN (Organismo Supervisor de la Inversión en Energía y Minería): Regulador peruano del sector energético; emisor de los informes sectoriales trimestrales y la regulación tarifaria del SEIN.

Articulación Complementaria de Hipótesis y Variables

Conforme a los lineamientos de la Guía N°01 UNI (numerales 5.1 y 6.2), la formulación de hipótesis no constituye un numeral obligatorio del Capítulo III, pero se articula aquí de manera complementaria al Marco Teórico y a la formulación del problema (sección 1.2.2.2) para garantizar la trazabilidad metodológica que será desarrollada operativamente en el Capítulo IV — Metodología (sección 4.7 Técnicas e Instrumentos de Análisis y Procesamiento de Datos).

Hipótesis del Estudio

Las hipótesis se formulan en simetría estructural con los problemas (PE) y objetivos (OE), tanto en el nivel general como en los tres específicos. La hipótesis general (HG) recoge integralmente los tres ejes de la VD; las hipótesis específicas (HE1, HE2, HE3) constituyen peldaños paralelos, uno por cada eje. El procedimiento de contrastación estadística (pruebas de hipótesis, tamaño del efecto, post-hoc, ranking multicriterio) se detalla en el Capítulo IV — Diseño Metodológico (Sección 4.7 Técnicas e Instrumentos de Análisis y Procesamiento de Datos).

Hipótesis General (HG)

HG: Los algoritmos Multi-Agente de Aprendizaje por Refuerzo Profundo (MADRL) optimizan significativamente la flexibilidad, la resiliencia y la respuesta a la demanda energética en comunidades de edificios interactivos con la red eléctrica.

Hipótesis Específicas (HE) — Peldaños por Eje de la VD

HE1 — Eje 1: FLEXIBILIDAD ENERGETICA

HE1: Los algoritmos MADRL optimizan significativamente la flexibilidad energetica en comunidades de edificios interactivos con la red electrica.

HE2 — Eje 2: RESILIENCIA ENERGETICA

HE2: Los algoritmos MADRL optimizan significativamente la resiliencia energetica en comunidades de edificios interactivos con la red electrica.

HE3 — Eje 3: RESPUESTA A LA DEMANDA ENERGETICA

HE3: Los algoritmos MADRL optimizan significativamente la respuesta a la demanda energetica en comunidades de edificios interactivos con la red electrica.

Tabla 2A. Matriz de Articulacion: Eje de la VD → PE → OE → HE

Eje de la VD	Problema (PE)	Objetivo (OE)	Hipotesis (HE)	Articulacion
INTEGRAL (General)	PG: De que manera los algoritmos MADRL optimizan la flexibilidad, resiliencia y respuesta a la demanda energetica en comunidades de edificios interactivos con la red electrica?	OG: Aplicar algoritmos MADRL para optimizar la flexibilidad, resiliencia y respuesta a la demanda energetica en comunidades de edificios interactivos con la red electrica.	HG: Los algoritmos MADRL optimizan significativamente la flexibilidad, resiliencia y respuesta a la demanda energetica en comunidades de edificios interactivos con la red electrica.	PG ↔ OG ↔ HG (integral 3 ejes)
EJE 1 Flexibilidad	PE1: De que manera los algoritmos MADRL optimizan la flexibilidad energetica en comunidades de edificios interactivos con la red electrica?	OE1: Aplicar algoritmos MADRL para optimizar la flexibilidad energetica en comunidades de edificios interactivos con la red electrica.	HE1: Los algoritmos MADRL optimizan significativamente la flexibilidad energetica en comunidades de edificios interactivos con la red electrica.	PE1 ↔ OE1 ↔ HE1 (eje flexibilidad)
EJE 2 Resiliencia	PE2: De que manera los algoritmos MADRL optimizan la resiliencia energetica en comunidades de edificios interactivos con la red electrica?	OE2: Aplicar algoritmos MADRL para optimizar la resiliencia energetica en comunidades de edificios interactivos con la red electrica.	HE2: Los algoritmos MADRL optimizan significativamente la resiliencia energetica en comunidades de edificios interactivos con la red electrica.	PE2 ↔ OE2 ↔ HE2 (eje resiliencia)
EJE 3 Resp. Demanda	PE3: De que manera los algoritmos MADRL optimizan la respuesta a la demanda energetica en comunidades de edificios interactivos con la red electrica?	OE3: Aplicar algoritmos MADRL para optimizar la respuesta a la demanda energetica en comunidades de edificios interactivos con la red electrica.	HE3: Los algoritmos MADRL optimizan significativamente la respuesta a la demanda energetica en comunidades de edificios interactivos con la red electrica.	PE3 ↔ OE3 ↔ HE3 (eje DR)

Tabla 2A. Articulacion lineal del problema, objetivo e hipotesis en los niveles general y especifico, organizada por los tres ejes de la Variable Dependiente. Los detalles operacionales (KPIs, escenarios E1-E2-E3, hiperparametros, pruebas estadisticas) se desarrollan en el Capitulo IV.

Variables del Estudio

Tabla 2. Operacionalización de variables de la investigación.

Variable	Def. Conceptual	Def. Operacional	Dimensión	Indicadores / KPIs	Escala
VI: Algoritmos MADRL (HAPPO, MASAC, MATD3, MAAC)	Conjunto de algoritmos de aprendizaje por refuerzo profundo multi-agente que aprenden políticas de control cooperativas sin modelo explícito del sistema.	Cuatro implementaciones en CityLearn v2/MARLlib evaluadas bajo el mismo protocolo experimental (hiperparámetros estandarizados, n=10 semillas).	D1_VI: Arquitectura y tipo de algoritmo	Tipo (on/off-policy), familia (PPO/SAC/TD3/AC), número de parámetros, profundidad de red.	Nominal (4 categorías): HAPPO, MASAC, MATD3, MAAC
			D2_VI: Política de control y función de recompensa	Función de recompensa multi-objetivo (pesos w1-w6), entropía de la política, mecanismo de exploración.	Razón: entropía [nats], pesos recompensa [0,1]
			D3_VI: Eficiencia del entrenamiento	Episodios hasta convergencia, σ^2 entre semillas, tiempo GPU/episodio, actor/critic loss.	Razón: episodios [#], tiempo [s], loss [adimensional]
VD: Desempeño en gestión energética de comunidades GIC	Nivel de optimización alcanzado por los algoritmos MADRL en la gestión de los DER de una comunidad de edificios interactivos con la red.	Valores numéricos de KPIs normalizados calculados por CityLearn v2 sobre el horizonte de evaluación (2,160 h).	D1_VD: Flexibilidad energética	peak_average [pu], ramping_average [pu], 1-load_factor_average [pu]	Razón: valores normalizados [0,∞), referencia RBC=1
			D2_VD: Resiliencia energética	unserved_energy_fraction [pu], thermal_discomfort [°C·h]	Razón: UEF ∈ [0,1]; TD ≥ 0 °C·h
			D3_VD: Respuesta a la demanda	electricity_cost [\$/período], price_signal_deviation [pu]	Razón: costo [\$/kWh·h]; desviación [pu]

Fuente: Elaboración propia basada en Nweye et al. (2023) y Zhong et al. (2024).

CAPÍTULO IV: METODOLOGÍA

4.1 TIPO DE INVESTIGACIÓN

La presente investigación es de tipo aplicada, cuantitativa y transversal. Es aplicada porque se orienta a la solución de un problema específico de gestión energética de comunidades de edificios mediante la implementación y evaluación de algoritmos MADRL en un entorno de simulación realista, generando conocimiento directamente utilizable por los actores del sector energético (Hernández Sampieri et al., 2018). A diferencia de la investigación básica o pura, que busca generar conocimiento teórico sin aplicación inmediata, la investigación aplicada genera productos tecnológicos —en este caso, implementaciones calibradas de cuatro algoritmos MADRL en CityLearn v2— que pueden ser adoptados directamente por practitioners.

Es cuantitativa porque los datos recolectados son numéricos y los KPIs de evaluación (peak_average, ramping_average, unserved_energy_fraction, thermal_discomfort, electricity_cost, price_signal_deviation) son métricas cuantificables que se someten a análisis estadístico inferencial para la verificación de hipótesis (Hernández Sampieri et al., 2018). La naturaleza cuantitativa de la investigación es inherente a la naturaleza de los algoritmos de aprendizaje por refuerzo, que generan series temporales de recompensas y KPIs numéricamente precisos.

Es transversal porque la comparación de los cuatro algoritmos se realiza en un punto específico del espacio de diseño (hiperparámetros fijos, entorno configurado, horizonte de evaluación definido), sin seguimiento longitudinal de la evolución de los sistemas en el tiempo real. Aunque el entrenamiento de los agentes implica una secuencia temporal de interacciones, la evaluación comparativa se realiza una vez concluido el entrenamiento, comparando el desempeño de los algoritmos maduros en un período de evaluación común.

4.2 NIVEL DE INVESTIGACIÓN

El nivel de la investigación es explicativo-comparativo. Es explicativo porque va más allá de la mera descripción o correlación de variables: busca establecer relaciones causales entre las características de los algoritmos MADRL (variable independiente: arquitectura, política, eficiencia de entrenamiento) y el desempeño en gestión energética (variable dependiente: flexibilidad, resiliencia, DR), respondiendo a la pregunta de por qué cada algoritmo produce un nivel diferente de desempeño en cada dimensión (Dankhe, 1986). Los estudios explicativos son los que mayor solidez y rigor científico generan, aunque son también los más complejos de diseñar y ejecutar.

Es comparativo porque el diseño experimental contempla la comparación sistemática de cuatro tratamientos (los cuatro algoritmos MADRL) bajo condiciones controladas (mismo entorno, mismos hiperparámetros base, mismo hardware), utilizando pruebas estadísticas formales para determinar si las diferencias observadas son estadísticamente significativas o atribuibles al azar. Esta dimensión comparativa es la que permite identificar el algoritmo óptimo para cada escenario y objetivo, respondiendo directamente a los problemas específicos PE1 a PE4.

El nivel explicativo-comparativo se justifica sobre el nivel correlacional en tanto que el diseño experimental con manipulación directa de la variable independiente (elección del algoritmo) y control de variables confusoras (semilla aleatoria, hardware, entorno) permite atribuir causalmente las diferencias en los KPIs al algoritmo y no a factores externos. Esto supera el nivel correlacional, que solo podría establecer que existe una asociación entre el tipo de algoritmo y el desempeño, sin poder establecer la dirección causal.

4.3 MÉTODOS DE TRABAJO

La presente investigación combina cuatro métodos articulados que permiten generar evidencia válida y reproducible. En primer lugar, el método experimental computacional considera a cada algoritmo MADRL como un tratamiento experimental que se aplica al mismo entorno de simulación CityLearn v2 (Nweye et al., 2024) bajo condiciones controladas; el experimento se replica diez veces con semillas aleatorias distintas para cada combinación algoritmo-escenario, lo que proporciona la distribución empírica de los KPIs necesaria para las pruebas estadísticas y se alinea con las prácticas de reproducibilidad establecidas en la literatura MARL (Yu et al., 2022).

En segundo lugar, el método comparativo permite que los cuatro algoritmos se evalúen bajo un framework experimental unificado, lo cual garantiza que las diferencias observadas sean atribuibles al algoritmo y no a diferencias en la configuración del experimento. Este framework incluye protocolos estandarizados de preprocesamiento de datos, configuración del entorno, entrenamiento, evaluación y registro de resultados, siguiendo el enfoque comparativo de Atrazhev (2023) en CityLearn.

En tercer lugar, el método estadístico inferencial transforma los datos crudos de KPIs en evidencia interpretable mediante un pipeline secuencial que se desarrolla en detalle en la sección 4.7. Este pipeline contempla la estadística descriptiva, la verificación de los supuestos paramétricos (Shapiro-Wilk y Levene), la prueba inferencial principal (ANOVA o Kruskal-Wallis según el cumplimiento de los supuestos), el reporte del tamaño del efecto y las pruebas post-hoc, y culmina en la síntesis multicriterio TOPSIS (Hwang y Yoon, 1981).

Finalmente, el método hipotético-deductivo articula los hallazgos con la teoría: la investigación parte de hipótesis teóricamente fundamentadas sobre las diferencias esperadas entre los algoritmos, deriva predicciones observables en términos de KPIs y las somete a contraste empírico. La no refutación de las hipótesis bajo las condiciones experimentales fortalece la base teórica del MADRL para la gestión energética de comunidades GIC.

4.4 POBLACIÓN Y MUESTRA

La sección 4.4, conforme a los lineamientos de la Guía N°01 UNI, define con precisión la población de referencia y la muestra de unidades experimentales sobre las cuales se evaluarán los algoritmos MADRL propuestos. La operacionalización es coherente con el carácter aplicado y cuasiexperimental de la investigación, articulando un dominio empírico real (los distritos del Perú con potencial de implementación de comunidades GIC) con un escenario controlado de simulación reproducible (la configuración estándar de CityLearn v2).

Población de Estudio

La población de la presente investigación está constituida por los distritos del Perú con potencial técnico, económico y regulatorio para implementar comunidades de edificios interactivos con la red eléctrica (Grid-Interactive Communities, GIC). Conforme al Anuario Estadístico de Electricidad del MINEM (2024) y a la Hoja de Ruta de Smart Grids 2023-2030 (MINEM, 2023), se trata de los distritos urbanos y semiurbanos del Sistema Eléctrico Interconectado Nacional (SEIN) que cumplen simultáneamente cuatro criterios de inclusión: (i) tarifa BT5B o BT4 que admite mecanismos de respuesta a la demanda; (ii) penetración local de generación distribuida fotovoltaica mayor o igual al 5 % de la demanda residencial; (iii) infraestructura de medición inteligente desplegada o en proceso conforme al Reglamento de Generación Distribuida (D.S. N° 027-2021-EM); y (iv) histórico de eventos de interrupción del suministro (corte programado o no programado) reportado por OSINERGMIN (2023) durante los últimos cinco años. Bajo estos criterios, la población estimada comprende aproximadamente 432 distritos a nivel nacional, distribuidos en las regiones de Lima, Callao, Arequipa, Cusco, La Libertad, Lambayeque, Piura, Ica, Junín y Loreto, con concentración mayoritaria en el área metropolitana de Lima (Vadillo Gutierrez, 2020; Dávila Pérez, 2024; Vilca-Tinta et al., 2024).

Muestra

La muestra de la investigación corresponde a la configuración estándar del entorno de simulación CityLearn v2 (Nweye et al., 2024), seleccionada de manera intencional —no probabilística— por su pertinencia técnica y su carácter de banco de pruebas reconocido a nivel internacional para investigaciones MADRL en gestión energética de edificios. La muestra está conformada por diecisiete (17) edificios heterogéneos que representan distintas tipologías edilicias del End-Use Load Profiles del NREL (EULP, Wilson et al., 2022): edificios residenciales unifamiliares, edificios residenciales multifamiliares y edificios comerciales pequeños. Cada uno de los 17 edificios se modela con su consumo eléctrico horario, su demanda de calefacción y agua caliente, su sistema HVAC con modelo LSTM de temperatura interior, su sistema fotovoltaico (PV) y su batería de almacenamiento (BESS) cuando corresponde, conforme a la configuración predeterminada del entorno CityLearn v2.

Adicionalmente, la muestra incluye una flota de vehículos eléctricos (EV) integrada al entorno mediante el módulo de EV Charging de CityLearn v2, capaz de operar en los esquemas Grid-to-Vehicle (G2V) y Vehicle-to-Grid (V2G). Cada EV se modela con su perfil estocástico de llegada y salida, su capacidad de batería y su preferencia de carga al regreso al edificio. La integración de los EV permite evaluar el efecto de los recursos energéticos distribuidos móviles sobre los tres ejes de la Variable Dependiente, particularmente sobre la flexibilidad (D1_VD) y la resiliencia (D2_VD) durante los eventos de power outage simulados en el escenario E2.

Unidad de Análisis y Tamaño de Muestra

La unidad de análisis de la investigación es la combinación específica algoritmo × escenario × semilla, donde algoritmo $\in$ {HAPPO, MASAC, MATD3, MAAC}, escenario $\in$ {E1 — flexibilidad bajo TOU sin cortes; E2 — resiliencia bajo cortes 2h/4h/8h; E3 — combinado bajo RTP con cortes aleatorios} y semilla $\in$ {1, 2, 3, 4, 5, 6, 7, 8, 9, 10}. Cada unidad de análisis genera un vector de los siete KPIs operacionales (peak_average, ramping_average, 1-load_factor_average, unserved_energy_fraction, thermal_discomfort, electricity_cost, price_signal_deviation), evaluados sobre el periodo de simulación de 8 760 horas (un año completo) por edificio.

El tamaño total de la muestra experimental es de 4 algoritmos × 3 escenarios × 10 semillas = 120 unidades experimentales, equivalentes a 120 entrenamientos completos de los algoritmos MADRL en CityLearn v2 sobre los 17 edificios y la flota de EVs. Esta cantidad

permite alcanzar una potencia estadística de 0,80 con tamaño del efecto mediano ($\eta^2 = 0,06$) y nivel de significancia $\alpha = 0,05$ conforme a las tablas de Cohen (1988), garantizando la validez interna del análisis comparativo y la reproducibilidad mediante la fijación de las semillas aleatorias (Yu et al., 2022; Atrazhev, 2023).

4.5 TIPO DE DISEÑO

El diseño de investigación es cuasiexperimental con simulación computacional. Es cuasiexperimental porque el investigador manipula activamente la variable independiente (selección del algoritmo MADRL) y controla las variables confusoras (entorno, hiperparámetros, hardware), pero no es posible la asignación aleatoria de los 'sujetos' (los algoritmos son tratamientos fijos, no muestras de una población de agentes). La simulación computacional garantiza la reproducibilidad exacta de las condiciones experimentales, eliminando la variabilidad asociada a experimentos con sistemas reales.

Los tres escenarios experimentales se diseñan siguiendo la metodología establecida por Nweye et al. (2024) en CityLearn v2 y la práctica comparativa de Atrazhev (2023). Cada escenario aísla operativamente una de las tres dimensiones de la Variable Dependiente, lo cual permite un análisis estadístico riguroso eje por eje y, posteriormente, un análisis transversal multicriterio.

El primer escenario, denominado E1 (Flexibilidad), evalúa la dimensión D1_VD bajo condiciones de operación normal. En este escenario, los cinco edificios de la comunidad operan bajo una tarifa de tiempo real (RTP) con resolución horaria y sin eventos de interrupción del suministro, mientras que los recursos distribuidos —BESS, almacenamiento térmico (TES) y HVAC— se encuentran plenamente disponibles. El objetivo principal consiste en maximizar la flexibilidad mediante la carga del BESS durante las horas de bajo precio y su descarga durante las horas pico (Kathirgamanathan et al., 2021; OSMOSE H2020, 2021). Los KPIs primarios de este escenario son `peak_average`, `ramping_average` y el complemento del factor de carga ($1 - \text{load_factor_average}$).

El segundo escenario, denominado E2 (Resiliencia), evalúa la dimensión D2_VD bajo condiciones operativas adversas. Los cinco edificios operan bajo tarifa fija, mientras que se introducen eventos programados de corte del suministro eléctrico con duraciones variables de dos, cuatro y ocho horas, distribuidos aleatoriamente durante el periodo de evaluación; la probabilidad de ocurrencia diaria se calibra según las estadísticas de interrupciones reales del SEIN reportadas por OSINERGMIN (2023). El objetivo de los agentes consiste en minimizar la energía no servida y el discomfort térmico mediante el pre-

posicionamiento prospectivo del BESS, conforme a los marcos de evaluación de resiliencia de NREL (2021), CURENT (2024) y la revisión de Sustainability MDPI Authors (2020). Los KPIs primarios son la fracción de energía no servida (UEF) y el discomfort térmico.

El tercer escenario, denominado E3 (Combinado), evalúa simultáneamente la dimensión D3_VD —respuesta a la demanda— y la integración global de las tres dimensiones de la VD. Los cinco edificios operan bajo señales de precio en tiempo real (RTP) con posibilidad de cortes aleatorios del suministro, lo cual representa las condiciones operativas más realistas que enfrentaría una comunidad GIC en un sistema eléctrico vulnerable. Este escenario requiere que los agentes aprendan a equilibrar de manera simultánea los tres objetivos —flexibilidad, resiliencia y respuesta a la demanda—, lo que lo convierte en el escenario más desafiante y en el que determina el ranking multicriterio TOPSIS final (Hwang y Yoon, 1981). La complejidad operativa de E3 es coherente con la reportada por Nweye et al. (2023) en el framework MERLIN y por Pinto et al. (2021) en clusters de edificios.

Algoritmo	E1 — Flexibilidad	E2 — Resiliencia	E3 — Combinado	Total unidades
HAPPO	10 semillas	10 semillas	10 semillas	30 unidades
MASAC	10 semillas	10 semillas	10 semillas	30 unidades
MATD3	10 semillas	10 semillas	10 semillas	30 unidades
MAAC	10 semillas	10 semillas	10 semillas	30 unidades
TOTAL	40 experimentos	40 experimentos	40 experimentos	120 unidades totales

Tabla 5. Diseño experimental: algoritmo × escenario × semillas.

4.6 TÉCNICAS E INSTRUMENTOS DE RECOLECCIÓN DE DATOS

La técnica principal de recolección de datos es la simulación computacional en CityLearn v2, instrumentada con registro automático de KPIs y curvas de aprendizaje mediante Weights & Biases. La configuración exacta del entorno de simulación es la siguiente:

Hiperparámetro	HAPPO	MASAC	MATD3	MAAC
Tasa de aprendizaje (actor)	3×10^{-4}	3×10^{-4}	3×10^{-4}	3×10^{-4}
Tasa de aprendizaje (crítico)	1×10^{-3}	1×10^{-3}	1×10^{-3}	1×10^{-3}

Factor de descuento (γ)	0.99	0.99	0.99	0.99
Tamaño de lote (batch)	256	256	256	256
Memoria replay	N/A	1×10^6	1×10^6	N/A
Coef. entropía (α)	N/A	Auto	N/A	N/A
Clipping PPO (ϵ)	0.2	N/A	N/A	0.2
Suavizado target (τ)	N/A	0.005	0.005	N/A
Actualización retardada	N/A	N/A	2	N/A
Cabezas de atención	N/A	N/A	N/A	4
Capas ocultas (actor)	[256,256]	[256,256]	[256,256]	[256,256]
Capas ocultas (crítico)	[512,512]	[512,512]	[512,512]	[256,256]
Episodios entrenamiento	8,760	8,760	8,760	8,760
Pasos evaluación	2,160	2,160	2,160	2,160
Semillas aleatorias	10	10	10	10

Tabla 6. Hiperparámetros de configuración de los cuatro algoritmos MADRL.

La configuración del entorno CityLearn v2 (Nweye et al., 2024) comprende: 5 edificios heterogéneos con BESS (capacidad 6.4 kWh, $\eta_c = \eta_d = 0.90$), paneles PV (4 kWp por edificio), sistema HVAC con modelo LSTM de temperatura, y almacenamiento térmico TES en los edificios comerciales. El dataset de carga corresponde al EULP (Wilson et al., 2022) para clima Cfa (subtropical húmedo), con datos horarios de temperatura exterior del NOAA. La tarifa RTP corresponde a datos horarios de precios del mercado mayorista de California (CAISO, 2022), normalizada al rango de la tarifa eléctrica industrial peruana para la justificación social del estudio. La búsqueda y optimización de hiperparámetros se realiza mediante el framework Optuna (Akiba et al., 2019), que implementa optimización bayesiana basada en TPE (Tree-structured Parzen Estimator) y poda adaptativa de configuraciones no prometedoras. Esta configuración de simulación es coherente con los entornos de referencia para active network management (Henry y Ernst, 2021) y con los enfoques de gestión PV-ESS residencial (Sim et al., 2021).

4.7 TÉCNICAS E INSTRUMENTOS DE ANÁLISIS Y PROCESAMIENTO DE DATOS

El pipeline estadístico de la presente investigación sigue una secuencia formal de siete pasos articulada por los tres ejes de la VD. Cada eje se evalúa mediante el flujo: Datos -> Estadística descriptiva -> Verificación de supuestos -> Prueba inferencial -> Tamaño del efecto -> Post-hoc -> Síntesis multicriterio. La elección de cada método se justifica

conforme a Hernandez Sampieri et al. (2018) y los lineamientos APA 7ma ed. para reportes estadísticos.

Pipeline Estadístico Completo

El pipeline estadístico se ejecuta en siete fases secuenciales que transforman los datos crudos de KPIs en evidencia inferencial robusta. La descripción a continuación articula cada fase indicando su finalidad, el método elegido y la justificación de la elección conforme a Hernández Sampieri et al. (2018) y a las recomendaciones APA séptima edición sobre reporte de resultados estadísticos.

La primera fase corresponde a la estadística descriptiva, en la cual se calculan, para cada KPI y para cada combinación algoritmo-escenario sobre las diez semillas, la media muestral (M), la desviación estándar (DE), el error estándar ($EE = DE/\sqrt{n}$), el coeficiente de variación ($CV = DE/M \times 100 \%$), los percentiles P25, P50 (mediana) y P75, y el intervalo de confianza al 95 % para la media. Estos estadísticos se visualizan mediante diagramas de cajas con muescas (boxplots con notched confidence intervals) que facilitan la detección visual de diferencias entre algoritmos.

La segunda fase verifica el supuesto de normalidad mediante la prueba de Shapiro-Wilk con un nivel de significancia $\alpha = 0,05$. La hipótesis nula sostiene que los datos provienen de una distribución normal y la hipótesis alternativa, que no lo hacen. La elección de Shapiro-Wilk frente a Kolmogorov-Smirnov o Anderson-Darling se fundamenta en su mayor potencia estadística para muestras pequeñas con $n < 30$, según el estudio comparativo de Razali y Wah (2011). Cuando el p-valor resulta mayor o igual a 0,05, se asume normalidad y se procede por la rama paramétrica del pipeline; en caso contrario, se aplica la rama no paramétrica.

La tercera fase verifica el supuesto de homocedasticidad mediante la prueba de Levene cuando se ha confirmado la normalidad. La hipótesis nula afirma la igualdad de varianzas entre los cuatro grupos de algoritmos. Levene se elige por su robustez frente a violaciones moderadas de la normalidad. Si el p-valor es mayor o igual a 0,05, se procede con un ANOVA paramétrico clásico; si es menor, se opta por un ANOVA de Welch que no requiere igualdad de varianzas.

La cuarta fase corresponde a la prueba inferencial principal. Cuando se cumplen los supuestos de normalidad y homocedasticidad, se aplica un ANOVA de una vía y se reportan el estadístico F , los grados de libertad (gl_1, gl_2) y el p-valor. Cuando los supuestos no se cumplen, se aplica la prueba de Kruskal-Wallis y se reportan el estadístico H , los grados de libertad ($gl = k - 1$) y el p-valor. En ambos casos, la hipótesis nula sostiene que

los cuatro algoritmos producen la misma distribución del KPI evaluado, y el nivel de significancia es $\alpha = 0,05$.

La quinta fase reporta el tamaño del efecto. Bajo ANOVA, se calcula la eta-cuadrado parcial $\eta^2_p = SS_{\text{between}} / SS_{\text{total}}$ y se interpreta según los umbrales de Cohen (1988): pequeño (0,01), mediano (0,06) y grande (0,14). Bajo Kruskal-Wallis, se reporta la épsilon-cuadrado $\varepsilon^2 = (H - k + 1) / (n - k)$. Esta fase cumple con la guía APA séptima edición de reportar siempre el tamaño del efecto junto con la significancia estadística, evitando la sobreinterpretación de resultados con p-valores significativos pero efectos triviales.

La sexta fase aplica pruebas post-hoc cuando la prueba principal rechaza la hipótesis nula ($p < 0,05$). Bajo ANOVA se utiliza la prueba Tukey HSD (Honestly Significant Difference), que controla la tasa de error familiar mediante intervalos de confianza simultáneos. Bajo Kruskal-Wallis se utiliza la prueba de Dunn con corrección de Bonferroni, que controla la inflación del error tipo I asociado a múltiples comparaciones (en este caso, seis contrastes pareados para cuatro algoritmos). Se reportan, para cada par de algoritmos, la diferencia de medias, su intervalo de confianza al 95 % y el p-valor ajustado.

La séptima y última fase corresponde a la síntesis multicriterio mediante el método TOPSIS (Hwang y Yoon, 1981) y a su validación por bootstrap. Los siete KPIs normalizados se agregan en seis pasos: la construcción de la matriz de decisión; la normalización vectorial $r_{ij} = x_{ij} / \sqrt{\sum x_{ij}^2}$; la ponderación $v_{ij} = w_j \cdot r_{ij}$ con pesos $w_j = 1/3$ por eje; la determinación de las soluciones ideales positiva A^+ (máximo para los KPIs a maximizar y mínimo para los KPIs a minimizar) y negativa A^- ; el cálculo de las distancias euclidianas d_i^+ y d_i^- a las soluciones ideales; y la obtención del coeficiente de cercanía relativa $C_i^* = d_i^- / (d_i^+ + d_i^-)$. La significancia estadística de la diferencia entre el algoritmo top-1 y los algoritmos restantes se evalúa mediante bootstrap con $B = 10\,000$ réplicas, lo cual genera intervalos de confianza al 95 % para C_i^* y prueba de hipótesis no paramétrica de rangos.

Articulación Secuencial del Pipeline

La articulación lógica del pipeline puede describirse como un flujo bifurcado: a partir de los datos brutos —diez observaciones por celda algoritmo-escenario—, la primera fase calcula la estadística descriptiva y la segunda fase verifica la normalidad. Si la prueba de Shapiro-Wilk no rechaza la normalidad, el flujo continúa por la rama paramétrica con la prueba de Levene, el ANOVA, el cálculo de eta-cuadrado parcial y la prueba post-hoc Tukey HSD. Si la prueba de Shapiro-Wilk rechaza la normalidad, el flujo continúa por la rama no

paramétrica con Kruskal-Wallis, épsilon-cuadrado y Dunn con corrección de Bonferroni. Ambas ramas convergen en la séptima fase, en la cual la síntesis multicriterio TOPSIS y la validación bootstrap producen el ranking final de los cuatro algoritmos junto con sus intervalos de confianza al 95 % para el coeficiente C_i^* .

Articulación del Pipeline con los Ejes de la VD

El pipeline se aplica de manera diferenciada según el eje de la VD evaluado, conforme a las hipótesis específicas formuladas:

Eje VD	KPIs evaluados	Prueba principal	Tamaño del efecto	Post-hoc	Hipótesis a contrastar
Eje D1_VD 1	peak_average; ramping_average; load_factor	ANOVA o Kruskal-Wallis ($\alpha=0.05$)	η^2_p (umbral 0.06)	Tukey HSD o Dunn-Bonferroni	HE1: HAPPO superior; η^2_p -cuadrado ≥ 0.06 en ≥ 2 KPIs
Eje D2_VD 2	unserved_energy_fraction; thermal_discomfort	ANOVA o Kruskal-Wallis ($\alpha=0.05$)	η^2_p o ϵ^2	Tukey HSD o Dunn-Bonferroni	HE2: MASAC superior; reducción UEF $\geq 25\%$ vs RBC
Eje D3_VD 3	electricity_cost; price_signal_deviation	Spearman rho + ANOVA/KW	rho de Spearman (rho ≥ 0.5)	Tukey HSD o Dunn-Bonferroni	HE3: MATD3 superior; rho ≥ 0.5 ; cost -18% vs RBC
Transversal	C_i^* TOPSIS (síntesis 7 KPIs)	Bootstrap B=10,000	IC95% de C_i^*	Rank-test de Friedman	HE4: Algoritmo top-1 con $C_i^* > 0.7$ ($p<0.05$)

Tabla 7. Articulación del pipeline estadístico con los tres ejes de la VD.

Visualización de Resultados

La presentación de los resultados sigue las recomendaciones APA séptima edición para la visualización estadística. Las curvas de aprendizaje muestran la recompensa media de cada algoritmo y su intervalo de confianza al 95 % en función de los episodios de entrenamiento, lo cual permite comparar la velocidad de convergencia y la estabilidad. Los diagramas de cajas con muescas resumen la distribución de los siete KPIs por algoritmo y escenario, facilitando la identificación visual de diferencias entre grupos. Los gráficos de radar comparan, en una sola figura, el desempeño multidimensional de los cuatro algoritmos sobre los siete KPIs normalizados. Los mapas de calor presentan los p-valores ajustados de las pruebas post-hoc para cada par algoritmo-KPI, lo cual permite identificar rápidamente las diferencias estadísticamente significativas. Finalmente, el diagrama radial TOPSIS sintetiza el ranking final mostrando los coeficientes de cercanía relativa C_i^* junto con sus intervalos de confianza al 95 % derivados del bootstrap.

Dimensión	KPI	Fórmula / Definición	Rango / Referencia	Escenario	Hipótesis asociada
D1_VD Flexibilidad	peak_average	Potencia pico media / Referencia RBC	$[0, \infty)$; RBC=1; <1 mejor	E1, E3	H1
	ramping_average	ΔP media horaria / Referencia RBC	$[0, \infty)$; RBC=1; <1 mejor	E1, E3	H1
	1-load_factor_avg	$1 - (\text{demanda_media}/\text{pico_media})$	$[0, 1]$; 0 ideal (perfil plano)	E1, E3	H1
D2_VD Resiliencia	unserved_energy_fraction	Energía no servida / Demanda total outage	$[0, 1]$; 0 ideal	E2, E3	H2
	thermal_discomfort	Σ desviación temperatura interior $[\text{°C} \cdot \text{h}]$	≥ 0 ; 0 ideal	E2, E3	H2
D3_VD Resp. Demanda	electricity_cost	$\Sigma(\text{precio_t} \times \text{potencia_t})$ [\$/período]	<0 ideal (exportación)	E1, E3	H3
	price_signal_deviation	Correlación inversa demanda-precio	$[0, \infty)$; 0 ideal	E1, E3	H3

Tabla 4. KPIs de evaluación por dimensión de la variable dependiente.

4.8 ETAPAS DE INTERVENCIÓN DEL ESTUDIO

Nº	Etapas	Actividades	Productos	Duración
1	Revisión bibliográfica sistemática	Búsqueda en Scopus, WoS, IEEE Xplore, ArXiv. Selección de referencias con PRISMA. Análisis de antecedentes y síntesis del estado del arte.	Tabla de antecedentes; marco teórico preliminar; gaps identificados.	Meses 1-2
2	Configuración del entorno CityLearn v2	Instalación y configuración de Python 3.11, PyTorch, CityLearn v2, MARLlib, W&B. Preparación de datasets EULP y NOAA. Definición de los 3 escenarios experimentales.	Entorno de simulación validado; scripts de configuración; protocolo experimental documentado.	Mes 2-3
3	Implementación y calibración HAPPO	Integración HAPPO en CityLearn v2 vía MARLlib. Búsqueda de hiperparámetros (grid search). Validación de convergencia en 3 semillas preliminares.	Implementación HAPPO validada; hiperparámetros calibrados; curvas de aprendizaje preliminares.	Meses 3-4
4	Implementación y calibración MASAC	Integración MASAC en CityLearn v2. Calibración del coeficiente de temperatura α automático. Validación de convergencia.	Implementación MASAC validada; análisis de eficiencia de muestra vs HAPPO.	Mes 4
5	Implementación y calibración MATD3	Integración MATD3 en CityLearn v2. Calibración de delayed update y target smoothing. Comparación de estabilidad vs MASAC.	Implementación MATD3 validada; análisis de bias-variance tradeoff.	Mes 5
6	Implementación y calibración MAAC	Integración MAAC en CityLearn v2. Calibración del número de cabezas	Implementación MAAC validada; visualización de	Mes 5-6

		de atención h. Análisis de la interpretabilidad del mecanismo de atención.	pesos de atención; análisis de coordinación emergente.	
7	Experimentación completa (120 runs)	Ejecución de los 120 experimentos (4 alg × 3 esc × 10 semillas) en GPU. Registro automático de KPIs y curvas de aprendizaje en W&B. Control de calidad de datos.	Dataset completo de KPIs; learning curves; checkpoints de modelos; logs de entrenamiento.	Meses 6-8
8	Análisis estadístico y ranking TOPSIS	Pipeline estadístico: Shapiro-Wilk → ANOVA/Kruskal-Wallis → post-hoc → tamaño del efecto → TOPSIS. Generación de visualizaciones (boxplots, radar, heatmaps).	Tablas de resultados estadísticos; ranking TOPSIS; figuras para publicación.	Meses 8-9
9	Redacción, revisión y publicación	Redacción de la tesis. Preparación de artículo para journal Q1 (Applied Energy o Energy and Buildings). Revisión del asesor y correcciones. Presentación final.	Tesis completa; artículo científico sometido; repositorio GitHub público con código y datos.	Meses 9-12

Tabla 8. Etapas de intervención del estudio.

CAPÍTULO V: ADMINISTRACIÓN DEL PLAN DE TESIS

5.1 CRONOGRAMA

El cronograma de actividades se estructura en 12 meses de ejecución, organizados según las 9 etapas definidas en la sección 4.8. El diagrama de Gantt siguiente presenta la distribución temporal de las actividades:

Etapas / Actividad	M1	M2	M3	M4	M5	M6	M7	M8	M9	M10	M11	M12
E1: Revisión bibliográfica sistemática	■	■										
E2: Configuración entorno CityLearn v2	■	■	■									
E3: Implementación y calibración HAPPO			■	■								
E4: Implementación y calibración MASAC				■								
E5: Implementación y calibración MATD3					■							
E6: Implementación y calibración MAAC					■	■						
E7: Experimentación completa (120 runs)						■	■	■				
E8: Análisis estadístico y TOPSIS								■	■			
E9: Redacción, revisión y publicación									■	■	■	■

Figura 7 / Tabla 8. Diagrama de Gantt — Cronograma de actividades (12 meses).

Leyenda: ■ = período de ejecución de la etapa.

5.2 PRESUPUESTO

Ítem	Descripción	Unidad	Cantidad	P. Unit. (S/)	Total (S/)
A. EQUIPOS Y BIENES DURADEROS					
1	Laptop high-performance (i9, 32GB RAM, RTX 4060)	Unidad	1	6,500	6,500
2	Disco SSD externo 2TB para backup de datos experimentales	Unidad	1	350	350
B. MATERIALES E INSUMOS					

3	Material de escritorio (papel, útiles, impresiones)	Conjunto	1	200	200
4	Licencia software estadístico (SPSS / R + paquetes)	Año	1	300	300
C. SERVICIOS TECNOLÓGICOS					
5	Google Colab Pro+ (GPU A100, 6 meses de uso intensivo)	Mes	6	150	900
6	AWS EC2 p3.2xlarge (V100 GPU, 200 h experimentación)	Hora	200	15	3,000
7	Weights & Biases Team (tracking de experimentos, 12 meses)	Mes	12	50	600
8	Acceso Scopus / WoS (biblioteca UNI + suplemento)	Global	1	0	0
D. SERVICIOS Y REPRESENTACIÓN INSTITUCIONAL					
9	Asesoría especializada (honorario asesor temático)	Sesión	24	100	2,400
10	Traducción y revisión en inglés del artículo científico	Servicio	1	800	800
11	APC — Article Processing Charge (Applied Energy, Q1)	Global	1	2,800	2,800
12	Inscripción congreso ECOS 2026 o IEEE ISGT LA 2026	Global	1	1,200	1,200
E. PASAJES Y VIÁTICOS					
13	Pasaje aéreo Lima-Bogotá-Lima (congreso internacional)	Global	1	1,800	1,800
14	Alojamiento y viáticos congreso (5 días)	Día	5	200	1,000
TOTAL GENERAL					S/ 21,850

Tabla 7. Presupuesto detallado de la investigación.

5.3 FINANCIAMIENTO

El financiamiento de la investigación se estructurará en dos fuentes complementarias. La primera fuente corresponde al autofinanciamiento del investigador, que cubrirá los rubros A (equipos) y B (materiales), por un monto estimado de S/ 6,850. El investigador dispone de los equipos informáticos propios necesarios para la fase de desarrollo del código y los experimentos preliminares.

La segunda fuente corresponde al financiamiento concursable externo, para el cual se contempla postular a las siguientes convocatorias: (1) FONDECYT-CONCYTEC (Fondo Nacional de Desarrollo Científico, Tecnológico y de Innovación Tecnológica): modalidad de

Proyectos de Investigación Básica y Aplicada para Maestría, con financiamiento máximo de S/ 30,000, que cubre los rubros C (servicios tecnológicos), D (servicios institucionales) y E (pasajes y viáticos); (2) Fondo de Investigación de la Escuela de Posgrado UNI: para el financiamiento parcial de los servicios de GPU en nube; y (3) Beca de movilidad internacional CONCYTEC: para la participación en el congreso internacional de difusión de resultados.

El investigador asume el compromiso de gestionar activamente las postulaciones a las convocatorias mencionadas en el primer trimestre del proyecto (meses 1-3), garantizando la disponibilidad de recursos para la fase de experimentación intensiva (meses 6-8). En caso de no obtener financiamiento externo, el investigador contempla como alternativa el uso de créditos gratuitos de Google Colab Pro y las GPUs de la Facultad de Ingeniería de Sistemas de la UNI, negociando acceso mediante el convenio de colaboración institucional.

REFERENCIAS

La lista de referencias se presenta en formato APA 7.^a edición y abarca artículos científicos indexados en Q1/Q2 (Applied Energy, Energy, IEEE Transactions, Energy and Buildings, Sustainability, Energies), tesis doctorales (PhD) y de maestría (MSc) de universidades reconocidas (UT Austin, Aalborg, Politecnico di Torino, DTU, Oxford, UPM, Aalto, Vaasa, UNPRG, UDELAR), reportes técnicos institucionales (NREL, MINEM, OSINERGMIN, IEA, NERC, FERC), preprints arXiv revisados, y trabajos de competiciones científicas (NeurIPS CityLearn Challenge). Las 72 referencias provienen de la matriz bibliográfica sistemática de 50 investigaciones estructurada para la tesis y se complementan con referencias metodológicas fundacionales.

Akiba, T., Sano, S., Yanase, T., Ohta, T., & Koyama, M. (2019). Optuna: A next-generation hyperparameter optimization framework. En Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD '19) (pp. 2623-2631). Association for Computing Machinery. <https://arxiv.org/pdf/1907.10902>

Atrazhev, P. (2023). Multi-agent deep reinforcement learning for autonomous energy coordination in demand response methods for residential distribution networks [Tesis de maestría, University of Alberta]. ERA — University of Alberta Education and Research Archive.

Biemann, M. (2024). Building energy flexibility with reinforcement learning [Tesis doctoral, Technical University of Denmark]. DTU Orbit. https://backend.orbit.dtu.dk/ws/files/337521744/Marco_Biemann.pdf

Brandi, S. (2022). Deep reinforcement learning for energy management in buildings [Tesis doctoral, Politecnico di Torino]. PORTO — Publications Open Repository Torino. https://iris.polito.it/retrieve/4e97dba8-d973-4197-b92b-b4641caa2cd0/PhD_Thesis_Brandi.pdf

California Independent System Operator [CAISO]. (2022). Real-time and day-ahead market data archives [Conjunto de datos]. CAISO Open Access Same-time Information System (OASIS). <http://oasis.caiso.com>

Charbonnier, J. (2024). Machine learning techniques for optimisation of energy utilisation in smart grids [Tesis de maestría, University of Oxford]. Oxford Research Archive (ORA). <https://ora.ox.ac.uk/objects/uuid:4acf19ee-76b3-4e71-a424-259cd9e2d6f5>

CHESCA Team. (2024). Winning the 2023 CityLearn Challenge: A community-based hierarchical energy systems coordination algorithm (CHESCA). HAL Open Science. <https://hal.science/hal-04685791v1/document>

Cohen, J. (1988). Statistical power analysis for the behavioral sciences (2.^a ed.). Lawrence Erlbaum Associates.

Costea, D. E. (2026). Reinforcement learning techniques for energy management in smart buildings [Tesis de maestría, Politecnico di Torino]. Webthesis Politecnico di Torino. <https://webthesis.biblio.polito.it/40396/1/tesi.pdf>

Curent / University of Tennessee. (2024). Methods for analysis and quantification of power system resilience [Reporte técnico]. Center for Ultra-Wide-Area Resilient Electric Energy Transmission Networks (CURENT). https://curent.utk.edu/wp-content/uploads/2024/07/Journal_PS_01-1.pdf

Dankhe, G. L. (1986). Investigación y comunicación. En C. Fernández-Collado y G. L. Dankhe (Eds.), *La comunicación humana: Ciencia social* (pp. 385-454). McGraw-Hill.

Deltetto, D., Coraci, D., Pinto, G., Piscitelli, M. S., y Capozzoli, A. (2021). Exploring the potentialities of deep reinforcement learning for incentive-based demand response in a cluster of small commercial buildings. *Energies*, 14(10), 2933. <https://doi.org/10.3390/en14102933>

U.S. Department of Energy [DOE]. (2023). Grid-interactive efficient buildings technical report [Reporte técnico]. DOE Office of Energy Efficiency and Renewable Energy. <https://www.energy.gov/eere/buildings>

Dávila Pérez, J. M. (2024). Cuantificación a corto plazo de la demanda eléctrica en redes eléctricas de distribución a través de clientes regulados y libres en la región Lambayeque [Tesis de maestría, Universidad Nacional Pedro Ruiz Gallo]. Repositorio Institucional UNPRG.

Drgona, J., Arroyo, J., Cupeiro Figueroa, I., Blum, D., Arendt, K., Kim, D., Olle, E. P., Oravec, J., Wetter, M., Vrabie, D. L., y Helsen, L. (2020). All you need to know about model predictive control for buildings. *Annual Reviews in Control*, 50, 190-232. <https://doi.org/10.1016/j.arcontrol.2020.09.001>

Federal Energy Regulatory Commission [FERC]. (2019). Demand response and advanced metering [Reporte técnico]. FERC Staff Report. <https://www.ferc.gov>

Frommel Araujo, J. (2022). Reducción del consumo energético en sistemas HVAC utilizando aprendizaje por refuerzo [Tesis de grado, Universidad de la República]. Colibrí — Repositorio Institucional UDELAR. <https://www.colibri.udelar.edu.uy/jspui/bitstream/20.500.12008/32599/1/Fro22.pdf>

Fu, J., Wang, X., Liu, B., y otros. (2025). Hybrid multi-agent soft actor-critic. En *Proceedings of the 4th Conference on Lifelong Learning Agents (CoLLAs 2025)*. PMLR. <https://raw.githubusercontent.com/mlresearch/v270/main/assets/fu25c/fu25c.pdf>

Fujimoto, S., Hoof, H., y Meger, D. (2018). Addressing function approximation error in actor-critic methods. En *Proceedings of the 35th International Conference on Machine Learning (ICML 2018)* (Vol. 80, pp. 1587-1596). PMLR.

Gonzales Chávez, S. (2014). Pronóstico eficiente de la demanda diaria del sistema eléctrico interconectado del Perú mediante análisis estocástico ARIMA con sucesos externos. *TECNIA — Revista de la Universidad Nacional de Ingeniería*, 24(1). <https://revistas.uni.edu.pe/index.php/tecnia>

Haarnoja, T., Zhou, A., Abbeel, P., y Levine, S. (2018). Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor. En *Proceedings of the 35th International Conference on Machine Learning (ICML 2018)* (Vol. 80, pp. 1861-1870). PMLR.

Henry, R., y Ernst, D. (2021). Gym-ANM: Reinforcement learning environments for active network management tasks in electricity distribution systems. *SoftwareX*, 16, 100850. <https://doi.org/10.1016/j.softx.2021.100850>

Hernández Sampieri, R., Fernández Collado, C., y Baptista Lucio, P. (2018). *Metodología de la investigación* (6.^a ed.). McGraw-Hill Education.

Hwang, C.-L., y Yoon, K. (1981). *Multiple attribute decision making: Methods and applications — A state-of-the-art survey*. Springer-Verlag.

Häkkinen, J. (2024). Demand response program for reducing power consumption peaks in residential distribution networks using reinforcement learning [Tesis de maestría, Aalto University]. Aaltodoc. <https://aaltodoc.aalto.fi/bitstreams/895c63d8-a84d-43e3-bf5f-ca764503c1d0/download>

Intergovernmental Panel on Climate Change [IPCC]. (2023). *Climate change 2023: Synthesis report. Contribution of Working Groups I, II and III to the Sixth Assessment Report of the IPCC* [Informe técnico]. IPCC. <https://www.ipcc.ch/report/ar6/syr/>

International Energy Agency [IEA]. (2022). *Electricity grids and secure energy transitions* [Reporte técnico]. IEA Publications. <https://www.iea.org>

International Renewable Energy Agency [IRENA]. (2024). *Renewable capacity statistics 2024* [Reporte estadístico]. IRENA. <https://www.irena.org>

Iqbal, S., y Sha, F. (2019). Actor-attention-critic for multi-agent reinforcement learning. En *Proceedings of the 36th International Conference on Machine Learning (ICML 2019)* (Vol. 97, pp. 2961-2970). PMLR. <https://arxiv.org/pdf/1810.02912>

Kathirgamanathan, A., De Rosa, M., Mangina, E., y Finn, D. P. (2021). Towards standardising market-independent indicators for quantifying energy flexibility in buildings. *Applied Energy*, 281, 115936. <https://doi.org/10.1016/j.apenergy.2020.115936>

Khattar, V., y Jin, M. (2023). Winning the CityLearn Challenge: Adaptive optimization with evolutionary search under trajectory-based guidance. *Proceedings of the AAAI Conference on Artificial Intelligence*, 37(12), 14286-14294. <https://doi.org/10.1609/aaai.v37i12.26671>

Kuba, J. G., Chen, R., Wen, M., Wen, Y., Sun, F., Wang, J., y Yang, Y. (2021). Trust region policy optimisation in multi-agent reinforcement learning. *arXiv*. <https://arxiv.org/pdf/2109.11251>

Lowe, R., Wu, Y., Tamar, A., Harb, J., Abbeel, P., y Mordatch, I. (2017). Multi-agent actor-critic for mixed cooperative-competitive environments. En *Advances in Neural Information Processing Systems* 30 (NeurIPS 2017) (pp. 6379-6390). Curran Associates. <https://papers.neurips.cc/paper/7217-multi-agent-actor-critic-for-mixed-cooperative-competitive-environments.pdf>

Manjavacas-Lucas, A., Campoy-Nieves, A., Jiménez-Raboso, J., Molina-Solana, M., y Gómez-Romero, J. (2024). Experimental evaluation of deep reinforcement learning algorithms for HVAC control in buildings. *Artificial Intelligence Review*, 57. <https://doi.org/10.1007/s10462-024-10819-x>

Marot, A., Donnot, B., Romero, C., y otros. (2021). Learning to run a power network challenge: A retrospective analysis. En *Proceedings of the NeurIPS 2020 Competition and Demonstration Track* (PMLR Vol. 133, pp. 112-132). <https://proceedings.mlr.press/v133/marot21a/marot21a.pdf>

Ministerio de Energía y Minas del Perú [MINEM]. (2023). Hoja de Ruta de Redes Eléctricas Inteligentes (Smart Grids) en la Distribución 2023-2030 (R.M. N.º 278-2023-MINEM/DM). Dirección General de Eficiencia Energética. <https://www.gob.pe/minem>

Ministerio de Energía y Minas del Perú [MINEM]. (2024). Anuario estadístico de electricidad 2023 [Reporte estadístico]. Dirección General de Electricidad. <https://www.gob.pe/minem>

Ministerio de Energía y Minas del Perú [MINEM]. (2014). Plan energético nacional 2014-2025 [Plan estratégico]. Lima, Perú. <https://www.gob.pe/minem>

Motoki, M., Khongnawang, S., Ibrahim, M., y Nweye, K. (2023). 1st place solution: NeurIPS 2023 CityLearn Challenge — Forecasting track [Repositorio técnico]. GitHub. <https://github.com/mattmotoki/1st-place-solution-neurips-citylearn2023-forecasting>

National Renewable Energy Laboratory [NREL]. (2021). Power system resilience evaluation framework and metrics review (NREL/TP-5D00-80817) [Reporte técnico]. <https://docs.nrel.gov/docs/fy22osti/80817.pdf>

National Renewable Energy Laboratory [NREL]. (2023). Multi-agent reinforcement learning for distribution system resilience (NREL/TP-5D00-84636) [Reporte técnico]. <https://docs.nrel.gov/docs/fy23osti/84636.pdf>

National Renewable Energy Laboratory [NREL]. (2024). Developing energy flexibility in clusters of buildings: A critical analysis of barriers from planning to operation (NREL/TP-5500-87702) [Reporte técnico]. <https://docs.nrel.gov/docs/fy24osti/87702.pdf>

Nguyen, D. H. (2024). The role of reinforcement learning control for optimizing building energy management systems [Tesis de maestría, University of Vaasa]. Osuva — University of Vaasa Open Repository.

North American Electric Reliability Corporation [NERC]. (2020). Resilience framework for the bulk power system [Reporte técnico]. NERC Publications.

Nweye, K. E. (2024). Data-driven modeling and control of grid-interactive communities [Tesis doctoral, The University of Texas at Austin]. Texas ScholarWorks. <https://doi.org/10.26153/tsw/52085>

Nweye, K., Kaspar, K., Buscemi, G., Pinto, G., Li, H., Hong, T., Ouf, M., Capozzoli, A., y Nagy, Z. (2023). A framework for the design of representative neighborhoods for energy flexibility assessment in CityLearn. En *Proceedings of Building Simulation 2023: 18th Conference of IBPSA* (pp. 3351-3358). IBPSA. https://publications.ibpsa.org/proceedings/bs/2023/papers/bs2023_1404.pdf

- Nweye, K., Liu, B., Stone, P., y Nagy, Z. (2022). Real-world challenges for multi-agent reinforcement learning in grid-interactive buildings. *Energy and AI*, 10, 100202. <https://doi.org/10.1016/j.egyai.2022.100202>
- Nweye, K., Sankaranarayanan, S., Mohanty, S., Chakraborty, D., Hong, T., Dey, S., y otros. (2023). The CityLearn Challenge 2022: Overview, results, and lessons learned. En *Proceedings of the NeurIPS 2022 Competitions Track* (PMLR Vol. 220, pp. 85-103). <https://proceedings.mlr.press/v220/nweye23a/nweye23a.pdf>
- Nweye, K., Sankaranarayanan, S., y Nagy, Z. (2023). MERLIN: Multi-agent offline and transfer learning for occupant-centric operation of grid-interactive communities. *Applied Energy*, 346, 121323. <https://doi.org/10.1016/j.apenergy.2023.121323>
- Nweye, K., Wu, B., Park, H., Gao, G., Kaspar, K., Buscemi, G., Pinto, G., Ghose, D., Duddukuru, S., Pratapa, P., Li, H., Mohammadi, J., Ferreira, L. L., Hong, T., Ouf, M., Capozzoli, A., y Nagy, Z. (2024). CityLearn v2: Energy-flexible, resilient, occupant-centric, and carbon-aware management of grid-interactive communities. *Journal of Building Performance Simulation*, 1-22. <https://doi.org/10.1080/19401493.2024.2418813>
- Nweye, K., y Nagy, Z. (2024). Applications in CityLearn Gym environment for multi-agent reinforcement learning and demand response. En *Proceedings of the SimBuild 2024 Conference* (Vol. 11, pp. 417-428). IBPSA-USA. https://publications.ibpsa.org/proceedings/simbuild/2024/papers/simbuild2024_2283.pdf
- Ojeda Sarmiento, J., y Pajares, F. (2008). Sistema de gestión de demanda y consumo de energía eléctrica [Reporte técnico]. Departamento de Mejora Continua, Southern Peru Copper Corporation. <https://arxiv.org/abs/0809.2421>
- Organismo Supervisor de la Inversión en Energía y Minería [OSINERGMIN]. (2023). Informe sectorial Perú: Sector electricidad — Tercer trimestre 2023 [Reporte sectorial]. Gerencia de Regulación de Tarifas. <https://www2.osinergmin.gob.pe>
- OSMOSE H2020. (2021). KPIs measuring the value of flexibility (Deliverable 2.5) [Reporte de proyecto]. Horizon 2020 OSMOSE Project. https://www.osmose-h2020.eu/wp-content/uploads/2021/03/OSMOSE_WP2_KPIs-measuring-the-value-of-flexibility.pdf
- Parvania, M., y otros. (2021). Resilient operation of distribution grids using deep reinforcement learning [Manuscrito].
- Pigott, A., Crozier, C., Baker, K., y Nagy, Z. (2022). GridLearn: Multiagent reinforcement learning for grid-aware building energy management. *Electric Power Systems Research*, 213, 108521. <https://arxiv.org/pdf/2110.06396>
- Pinto, G., Piscitelli, M. S., Vázquez-Canteli, J. R., Nagy, Z., y Capozzoli, A. (2021). Coordinated energy management for a cluster of buildings through deep reinforcement learning. *Energy*, 229, 120725. <https://doi.org/10.1016/j.energy.2021.120725>

- PowerGridworld Team / NREL. (2021). PowerGridworld: A framework for multi-agent reinforcement learning in power systems (NREL/CP-5D00-81401). arXiv. <https://arxiv.org/pdf/2111.05969>
- Rahman, M. A. (2025). Optimizing smart grid flexibility and resilience with demand response, renewable integration and energy storage [Tesis de maestría, University of Vaasa]. Osuva — University of Vaasa Open Repository.
- Ramos Illán, C. (2024). Gestión óptima de una microrred eléctrica basada en aprendizaje por refuerzo profundo [Trabajo fin de máster, Universidad Politécnica de Madrid]. Archivo Digital UPM. https://oa.upm.es/82952/1/TFM_CARLOS_ILLAN.pdf
- Razali, N. M., y Wah, Y. B. (2011). Power comparisons of Shapiro-Wilk, Kolmogorov-Smirnov, Lilliefors and Anderson-Darling tests. *Journal of Statistical Modeling and Analytics*, 2(1), 21-33.
- Salazar, R., y otros. (2026). MARLEM: A multi-agent reinforcement learning simulation platform for distributed energy resources. *Applied Energy*, 388, 127xxx. <https://doi.org/10.1016/j.apenergy.2026.127xxx>
- Schulman, J., Wolski, F., Dhariwal, P., Radford, A., y Klimov, O. (2017). Proximal policy optimization algorithms. arXiv. <https://arxiv.org/abs/1707.06347>
- Sim, M. K., y otros. (2021). Deep reinforcement learning for optimal energy management of photovoltaic-energy storage systems in residential houses. En *Proceedings of Building Simulation 2021* (pp. 30879). IBPSA. https://publications.ibpsa.org/proceedings/bs/2021/papers/bs2021_30879.pdf
- Sustainability MDPI Authors. (2020). Power systems resilience metrics: A comprehensive review of challenges and outlook. *Sustainability*, 12(22), 9698. <https://doi.org/10.3390/su12229698>
- TU Delft AI Energy Lab. (2023). MARL-iDR: Multi-agent reinforcement learning for incentive-based residential demand response. arXiv. <https://arxiv.org/pdf/2304.04086>
- Vadillo Gutierrez, J. C. (2020). Medición de la respuesta de la demanda a la señal de precios a través de soluciones de redes inteligentes [Tesis de maestría, Universidad Nacional Pedro Ruiz Gallo]. Repositorio Institucional UNPRG.
- Vilca-Tinta, C. W., Torres-Cruz, F., y Quispe-Morales, J. J. (2024). Optimization of energy consumption forecasting in Puno using parallel computing and ARIMA models: An innovative approach to big data processing. arXiv. <https://arxiv.org/abs/2408.00014>
- Vázquez-Canteli, J. R. (2019). Reinforcement learning for demand response: Intelligent energy management for the grid of the future [Tesis doctoral, The University of Texas at Austin]. Texas ScholarWorks. <https://repositories.lib.utexas.edu/items/154f2920-10bc-47e0-a9d6-41f614e476e6>
- Vázquez-Canteli, J. R., Dey, S., Henze, G., y Nagy, Z. (2020). CityLearn: Standardizing research in multi-agent reinforcement learning for demand response and urban energy management. arXiv. <https://arxiv.org/pdf/2012.10504>
- Vázquez-Canteli, J. R., Kämpf, J., Henze, G., y Nagy, Z. (2019). CityLearn v1.0: An OpenAI Gym environment for demand response with deep reinforcement learning. En *Proceedings of the 6th ACM*

International Conference on Systems for Energy-Efficient Buildings, Cities, and Transportation (BuildSys 2019) (pp. 356-357). ACM. <https://doi.org/10.1145/3360322.3360998>

Vázquez-Canteli, J. R., y Nagy, Z. (2019). Reinforcement learning for demand response: A review of algorithms and modeling techniques. *Applied Energy*, 235, 1072-1089. <https://doi.org/10.1016/j.apenergy.2018.11.002>

Wang, J., y otros. (2024). Mutual information regularized offline multi-agent reinforcement learning with TD3+BC policy learning. *Knowledge-Based Systems*, 286, 111388. <https://doi.org/10.1016/j.knosys.2024.111388>

Wilson, E. J. H., Parker, A., Fontanini, A., Present, E., Reyna, J. L., Adhikari, R., y Wang, W. (2022). End-use load profiles for the U.S. building stock: Market segmentation, simulation methodology, and validation (NREL/TP-5500-80889) [Reporte técnico]. National Renewable Energy Laboratory. <https://www.nrel.gov/buildings/end-use-load-profiles.html>

Yu, C., Velu, A., Vinitsky, E., Gao, J., Wang, Y., Bayen, A., y Wu, Y. (2022). The surprising effectiveness of PPO in cooperative multi-agent games. En *Advances in Neural Information Processing Systems 35: Datasets and Benchmarks Track (NeurIPS 2022)*. Curran Associates. <https://arxiv.org/pdf/2103.01955>

Yu, L., Qin, S., Zhang, M., Shen, C., Jiang, T., y Guan, X. (2020). A review of deep reinforcement learning for smart building energy management. *arXiv*. <https://arxiv.org/pdf/2008.05074>

Zhang, B. (2024). Modelling and optimization of multi-energy system operation based on deep reinforcement learning [Tesis doctoral, Aalborg University]. Aalborg University Open Publishing. <https://doi.org/10.54337/aa763295893>

Zhong, Y., Kuba, J. G., Feng, X., Hu, S., Cohen, J., y Foerster, J. N. (2024). Heterogeneous-agent reinforcement learning. *Journal of Machine Learning Research*, 25(1), 1-67. <https://www.jmlr.org/papers/volume25/23-0488/23-0488.pdf>

ANEXO I: MATRIZ DE CONSISTENCIA

Titulo: "Multi-Agente de Aprendizaje por Refuerzo Profundo para la optimizacion de flexibilidad, resiliencia y respuesta a la demanda energetica en comunidades interactivas con la red electrica"

La matriz de consistencia que se presenta a continuación articula linealmente los componentes esenciales de la presente investigación según los tres ejes de la Variable Dependiente. La lectura horizontal de cada fila permite verificar la coherencia interna entre el problema (PE), el objetivo (OE) y la hipótesis (HE) específicos, así como su alineación con las variables y dimensiones declaradas, los indicadores operacionales (KPIs), el diseño metodológico aplicable y el escenario experimental correspondiente. Esta organización facilita la trazabilidad metodológica completa de la investigación y permite a los evaluadores verificar la consistencia interna del plan de tesis.

Eje VD	Problema (PE)	Objetivo (OE)	Hipotesis (HE)	Variables/Dimensiones	KPIs operacionales	Dis. metod.
INTEGRAL (3 ejes)	PG: De que manera los algoritmos MADRL optimizan la flexibilidad, resiliencia y respuesta a la demanda energetica en comunidades de edificios interactivos con la red electrica?	OG: Aplicar algoritmos MADRL para optimizar la flexibilidad, resiliencia y respuesta a la demanda energetica en comunidades de edificios interactivos con la red electrica.	HG: Los algoritmos MADRL optimizan significativamente la flexibilidad, resiliencia y respuesta a la demanda energetica en comunidades de edificios interactivos con la red electrica.	VI: Algoritmos MADRL (D1_VI: arquitectura; D2_VI: politica/recompensa; D3_VI: eficiencia) VD: Desempeno energetico (D1_VD: flexibilidad; D2_VD: resiliencia; D3_VD: DR)	7 KPIs integrados; sintesis multicriterio TOPSIS	Aplicad. cuantita transver cuasiex con s Detalle
EJE 1 Flexibilidad	PE1: De que manera los algoritmos MADRL optimizan la flexibilidad energetica en comunidades de edificios interactivos con la red electrica?	OE1: Aplicar algoritmos MADRL para optimizar la flexibilidad energetica en comunidades de edificios interactivos con la red electrica.	HE1: Los algoritmos MADRL optimizan significativamente la flexibilidad energetica en comunidades de edificios interactivos con la red electrica.	VI dim.: D1_VI, D2_VI, D3_VI VD dim.: D1_VD (flexibilidad)	peak_average ramping_average 1 load_factor_average	ANOVA Wallis - Tukey/D tamano Detalle 4.7.
EJE 2 Resiliencia	PE2: De que manera los algoritmos MADRL optimizan la resiliencia energetica en comunidades de edificios interactivos	OE2: Aplicar algoritmos MADRL para optimizar la resiliencia energetica en comunidades de edificios interactivos	HE2: Los algoritmos MADRL optimizan significativamente la resiliencia energetica en comunidades de edificios interactivos con la red electrica.	VI dim.: D1_VI, D2_VI, D3_VI VD dim.: D2_VD (resiliencia)	unserved_energy_fraction thermal_discomfort	ANOVA Wallis - + tan efecto. Sec. 4.7

	con la red eléctrica?	con la red eléctrica.				
EJE Resp. Demanda	3 PE3: De que manera los algoritmos MADRL optimizan la respuesta a la demanda energética en comunidades de edificios interactivos con la red eléctrica?	OE3: Aplicar algoritmos MADRL para optimizar la respuesta a la demanda energética en comunidades de edificios interactivos con la red eléctrica.	HE3: Los algoritmos MADRL optimizan significativamente la respuesta a la demanda energética en comunidades de edificios interactivos con la red eléctrica.	VI dim.: D1_VI, D2_VI, D3_VI VD dim.: D3_VD (DR)	electricity_cost price_signal_deviation	Correlación Spearman ANOVA Detalle 4.7.

Tabla A1.1. Matriz de consistencia organizada por los tres ejes de la Variable Dependiente.

Elaboración propia.

ANEXO II: MATRIZ DE OPERACIONALIZACIÓN DE INDICADORES (KPIS)

Nota — De acuerdo con la Guía N°01 UNI (numeral 5.1), la Matriz de Operacionalización de Variables es de presentación obligatoria solamente para los Planes de Tesis de Doctorado. En la presente investigación de Maestría se incluye como complemento opcional al Anexo I (Matriz de Consistencia), pues fortalece la trazabilidad metodológica entre las hipótesis específicas y los KPIs operacionales que serán medidos durante la fase experimental.

La matriz de operacionalización que se presenta en este anexo desarrolla en detalle los siete indicadores que conforman la Variable Dependiente, conforme a los lineamientos de la Guía N°01 de la Escuela de Posgrado de la UNI. Para cada indicador se especifican su definición conceptual, su fórmula matemática, la unidad de medida, el rango de valores admisibles, la dirección de optimización (sea minimización o maximización), el instrumento de medición empleado, la fuente de datos correspondiente, la técnica de cálculo aplicable, la hipótesis específica con la que se vincula y la prueba estadística que se utilizará para su contraste. Esta operacionalización rigurosa garantiza la replicabilidad del estudio y permite la verificación independiente de los resultados.

A2.1 EJE 1 — D1_VD: FLEXIBILIDAD ENERGÉTICA

Definición conceptual: Capacidad de la comunidad de edificios para modular su perfil agregado de demanda en respuesta a señales sistémicas, mediante el uso coordinado de BESS, TES y modulación del HVAC. Es la dimensión de la VD asociada a la operación eficiente del sistema de distribución en condiciones normales (sin interrupciones).

KPI	Formula matematica	Unidad	Rango	Direccion (mejor)	Instrumento	Fuente de datos	Tecnica de calculo
peak_average	$PA = (1/N) \sum_b \max_t (P_{b,t}) / \max_t (P_{b,t}^{RBC})$	Adimensional (ratio)	[0, +inf)	< 1 (menor mejor)	CityLearn KPI engine v2	EULP (perfiles horarios) + simulacion CityLearn v2	Maximo de potencia importada por edificio en evaluacion (2,160 h) normalizado por baseline RBC
ramping_average	$RA = (1/N) \sum_b (1/T) \sum_t P_{b,t} - P_{b,t-1} / RA_{RBC}$	Adimensional (ratio)	[0, +inf)	< 1 (menor mejor)	CityLearn KPI engine v2	Series temporales potencia neta $P_{b,t}$ cada hora	Promedio absoluto de la primera diferencia de la potencia neta horaria
1 - load_factor_avg	$1 - LF = 1 - \text{mean}(P_{b,t}) / \max(P_{b,t})$, promediado entre N edificios	Adimensional	[0, 1]	-> 0 (perfil plano)	CityLearn KPI engine v2	Series temporales potencia neta horaria por edificio	1 menos el cociente entre demanda media y demanda pico, promediado por edificio

Hipotesis asociada: HE1 (Eje 1 $D1_VD \leftrightarrow OE1 \leftrightarrow PE1$). Escenario: E1 (TOU sin cortes). Prueba estadistica: ANOVA o Kruskal-Wallis ($\alpha=0.05$) + Tukey/Dunn post-hoc + eta-cuadrado.

A2.2 EJE 2 — D2_VD: RESILIENCIA ENERGETICA

Definicion conceptual: Capacidad de la comunidad de edificios para absorber perturbaciones en el suministro electrico (power outages), adaptarse a condiciones degradadas y recuperarse minimizando el impacto sobre los ocupantes (NERC, 2020). Es la dimension de la VD asociada a la operacion en modo isla con DER locales.

KPI	Formula matematica	Unidad	Rango	Direccion (mejor)	Instrumento	Fuente de datos	Tecnica de calculo
unserved_energy_fraction (UEF)	$UEF = \frac{\sum_{t:outage_t=1} [(D_t - G_{local_t} - desc_BESS_t)]}{\sum_{t:outage_t=1} D_t}$	Adimensional (fraccion)	[0, 1]	-> 0 (alta resiliencia)	CityLearn KPI engine v2	Variable outage_t binaria balance energetico horario	Energia servida acumulada menos energia demandada durante cortes; $\max(.,0)$
thermal_discomfort (TD)	$TD = \sum_t [\max(0, T_{in_t} - T_{max}) + \max(0, T_{min} - T_{in_t})]$	°C·h (grado-hora)	[0, +inf)	-> 0 (confort optimo)	Modelo LSTM CityLearn v2	Datos meteorologicos NOAA + cargas internas EULP	Suma de desviaciones absolutas de $T_{interior}$ fuera de banda ASHRAE (T_min=18°C, T_max=26°C)

Hipotesis asociada: HE2 (Eje 2 D2_VD ↔ OE2 ↔ PE2). Escenario: E2 (cortes programados 2h/4h/8h). Prueba estadística: ANOVA o Kruskal-Wallis ($\alpha=0.05$) + eta-cuadrado.

A2.3 EJE 3 — D3_VD: RESPUESTA A LA DEMANDA

Definicion conceptual: Cambios en el uso electrico por parte del consumidor final en respuesta a cambios en el precio de la electricidad o a pagos de incentivos (FERC, 2019). Es la dimension de la VD asociada a la coordinacion entre la demanda flexible y los mecanismos de mercado.

KPI	Formula matematica	Unidad	Rango	Direccion (mejor)	Instrumento	Fuente de datos	Tecnica de calculo
electricity_cost (EC)	$EC = \frac{\sum_t (C_t \cdot P_t) \cdot \Delta t}{EC_{del\ baseline\ RBC}}$	USD ratio (vs RBC)	[0, +inf]	< 1 (ahorro vs RBC)	CityLearn KPI engine v2	Tarifa horaria CAISO 2022 + serie potencia neta importada P _t	Producto entre precio horario de electricidad y potencia neta horaria, integrado en el periodo de evaluacion
price_signal_deviation (PSD)	$PSD = \frac{1}{T} \sum_t P_t - f(C_t) $, donde f(C _t) es la demanda esperada bajo seguimiento perfecto	kW (potencia)	[0, +inf]	-> 0 (seguimiento perfecto)	CityLearn KPI engine v2	Series temporales precio C _t y potencia P _t	Diferencia absoluta media entre la demanda observada y la trayectoria optima en respuesta al precio

Hipotesis asociada: HE3 (Eje 3 D3_VD ↔ OE3 ↔ PE3). Escenario: E3 (RTP). Prueba estadística: Correlacion de Spearman (ρ) + ANOVA o Kruskal-Wallis sobre KPIs.

A2.4 TRANSVERSAL — Sintesis Multicriterio TOPSIS

Definicion conceptual: Indice agregado que sintetiza el desempeno integral del algoritmo en los tres ejes de la VD mediante el metodo Technique for Order Preference by Similarity to Ideal Solution (Hwang & Yoon, 1981). Permite identificar el algoritmo con la mejor combinacion global de flexibilidad, resiliencia y respuesta a la demanda.

Indicador	Formula	Tipo	Rango	Direccion	Tecnica de calculo	Hipotesis
Ci* (Coef. cercania relativa)	$Ci^* = \frac{d_i^-}{(d_i^+ + d_i^-)}$ donde: $d_i^+ = \sqrt{\sum_j (w_j(v_{ij} - v_j^*)^2)}$ (distancia a	Adimensional	[0, 1]	-> 1 (optimo integral)	Pipeline TOPSIS sobre 7 KPIs normalizados; pesos w _j = 1/3 por eje (w _{flex} =w _{res} =w _{dr} =1/3)	HE4

	la solución ideal positiva) $d_i = \sqrt{\sum_j w_j (v_{ij} - v_j^-)^2}$ (distancia a la solución ideal negativa) $v_{ij} =$ matriz normalizada y ponderada					
--	---	--	--	--	--	--

Tabla A2.4 Síntesis multicriterio. Hipótesis asociada: HE4 (Transversal ↔ OE4 ↔ PE4). Escenario: E3 combinado. Prueba estadística: Bootstrap B=10,000 replicas + rank-test.

ANEXO III: MATRIZ BIBLIOGRÁFICA — 50 INVESTIGACIONES SOBRE MADRL EN GESTIÓN ENERGÉTICA

Nota — El presente Anexo III es un complemento opcional al plan de tesis, no exigido por la Guía N°01 UNI. Su inclusión fortalece la fundamentación bibliográfica y la triangulación de fuentes para la sección 1.2.1 (Antecedentes Bibliográficos) y para las Bases Teóricas (sección 3.1). Consolida sistemáticamente cincuenta investigaciones —tesis doctorales, tesis de maestría y artículos científicos indexados— clasificadas en cuatro grupos temáticos según su contribución principal.

El presente anexo consolida la matriz bibliográfica sistemática de cincuenta investigaciones que sustentan el estado del arte y el marco metodológico de la presente tesis. Las investigaciones se han clasificado por su contribución principal en cuatro grupos temáticos: el ecosistema CityLearn y su evolución (12 investigaciones), los algoritmos MADRL fundacionales y sus extensiones (10 investigaciones), las aplicaciones de DRL/MADRL a gestión energética y respuesta a la demanda (16 investigaciones), y los marcos teóricos sobre KPIs, resiliencia y flexibilidad (12 investigaciones). Esta clasificación permite identificar con precisión las brechas que la presente investigación aborda y los antecedentes que respaldan cada decisión metodológica.

A3.1 Grupo 1 — Ecosistema CityLearn

Las investigaciones de este grupo documentan la evolución del entorno CityLearn desde su versión original (Vázquez-Canteli et al., 2019) hasta la versión 2 utilizada en la presente investigación (Nweye et al., 2024). Incluye además los tres CityLearn Challenges (2021, 2022, 2023) cuyas soluciones ganadoras (Khattar y Jin, 2023; CHESCA Team, 2024; Motoki et al., 2023) proporcionan referentes técnicos para la calibración de hiperparámetros y diseño de funciones de recompensa.

N°	Año	Autores / Institución	Título / Aporte	Tipo	Vínculo con la tesis
1	2024	Nweye et al. — UT Austin, Polito, LBNL, Concordia	CityLearn v2: gestión de comunidades GIC con flexibilidad, resiliencia, ocupante y carbono	Artículo Q1 / arXiv	Define el entorno y los 7 KPIs de la VD
2	2020	Vázquez-Canteli et al. — UT Austin	CityLearn: estandarización de MARL para DR y gestión urbana	ACM BuildSys / arXiv	Estandarización metodológica de la comparación MARL
3	2019	Vázquez-Canteli et al. — UT Austin	CityLearn v1.0: entorno OpenAI Gym para DR con DRL	ACM BuildSys	Versión original del entorno (referente histórico)
4	2024	Nweye y Nagy — UT Austin	Aplicaciones en CityLearn para MARL y DR	IBPSA SimBuild	Casos de uso comparativos del entorno
5	2023	Nweye et al. — UT Austin	CityLearn Challenge 2022: lecciones aprendidas	PMLR / NeurIPS Competitions	Benchmark de referencia y lecciones técnicas
6	2024	CHESCA Team — equipo ganador	Coordinación jerárquica comunitaria — solución ganadora 2023	HAL / Competition	Estrategia jerárquica para comunidades GIC
7	2023	Motoki et al. — equipo ganador	1° lugar — track de pronóstico CityLearn 2023	GitHub / NeurIPS Track	Modelos de pronóstico complementarios
8	2023	Khattar y Jin — VT	Ganador CityLearn 2021: optimización adaptativa	AAAI 2023 / arXiv	Métodos evolutivos como baseline
9	2023	Nweye, Sankaranarayanan, Nagy — UT Austin	MERLIN: MARL offline y transfer learning para GIC	Applied Energy 346	Antecedente directo del aprendizaje offline en GIC
10	2022	Pigott, Crozier, Baker, Nagy	GridLearn: MARL consciente de la red eléctrica	arXiv / EPSR	Extensión a redes eléctricas (AC power flow)
11	2023	PNNL — IBPSA	Framework para vecindarios representativos en CityLearn	IBPSA Building Sim	Generación sintética de comunidades
12	2024	OpenReview / arXiv	Generalización del control de baterías en edificios net-zero con FRL	Preprint	Federated RL como alternativa MARL

A3.2 Grupo 2 — Algoritmos MADRL fundacionales

Las investigaciones de este grupo proporcionan las bases teóricas de los cuatro algoritmos comparados en la presente tesis. Lowe et al. (2017) introducen el paradigma CTDE con MADDPG; Iqbal y Sha (2019) proponen el mecanismo de atención del crítico (MAAC); Yu et al. (2022) demuestran la efectividad del PPO en juegos cooperativos (MAPPO); Kuba et al. (2021) y Zhong et al. (2024) formalizan HAPPO mediante el teorema de mejora monótona heterogénea; Fu et al. (2025) extienden el SAC al caso multi-agente híbrido (MASAC); y Wang et al. (2024) consolidan TD3 multi-agente para escenarios offline.

N°	Año	Autores	Algoritmo / Aporte	Fuente	Vínculo con la tesis
13	2017	Lowe et al. — OpenAI	MADDPG: actor-crítico multi-agente cooperativo-competitivo	NeurIPS 30	Fundamento del paradigma CTDE (D1_VI)
14	2019	Iqbal y Sha	MAAC: actor-attention-critic para MARL	ICML 36 / PMLR 97	Fundamento de MAAC (algoritmo evaluado en la tesis)
15	2022	Yu et al.	MAPPO: efectividad de PPO en juegos cooperativos	NeurIPS 35 D&B	Fundamento de MAPPO; baseline comparativo
16	2021	Kuba et al.	HAPPO/HATRPO: trust-region multi-agente	arXiv 2109.11251	Algoritmo HAPPO evaluado en la tesis
17	2024	Zhong et al.	Heterogeneous-agent RL: teorema HAMI	JMLR 25(1)	Demostración formal de convergencia HAPPO (D1_VI)
18	2025	Fu et al. — CoLLAs	MASAC híbrido: soft actor-critic multi-agente	PMLR 270	Algoritmo MASAC evaluado en la tesis
19	2024	Wang et al. — KBS	TD3 multi-agente con regularización por información mutua	Knowledge-Based Systems	Algoritmo MATD3 evaluado en la tesis
20	2018	Schulman et al. (PPO) — referencia teórica	PPO: algoritmo single-agent base	arXiv 1707.06347	Base on-policy de HAPPO/MAPPO
21	2018	Haarnoja et al. (SAC) — referencia teórica	SAC: soft actor-critic con entropía máxima	ICML 35	Base off-policy de MASAC (D2_VI)
22	2018	Fujimoto et al. (TD3) — referencia teórica	TD3: doble crítico para reducir sobreestimación	ICML 35	Base determinista de MATD3 (D2_VI)

A3.3 Grupo 3 — Aplicaciones DRL/MADRL en gestión energética

Las investigaciones de este grupo aplican técnicas de DRL y MADRL a problemas de gestión energética en edificios y microrredes. Comprenden tesis doctorales (Vázquez-Canteli, 2019; Brandi, 2022; Biemann, 2024; Zhang, 2024) y de maestría (Costea, 2026; Charbonnier, 2024; Häkkinen, 2024; Frommel Araujo, 2022; Atrazhev, 2023; Ramos Illán, 2024; Nguyen, 2024; Rahman, 2025; Vadillo Gutierrez, 2020; Dávila Pérez, 2024), así como artículos de aplicación específica.

N°	Año	Autor / Institución	Aplicación	Tipo	Vínculo con la tesis
23	2019	Vázquez-Canteli — UT Austin	RL para DR: gestión inteligente de la red	Tesis doctoral	Tesis fundacional del entorno CityLearn
24	2022	Brandi — Polito	DRL para gestión energética en edificios	Tesis doctoral	DRL aplicado a edificios — referente
25	2024	Biemann — DTU	Flexibilidad de edificios con RL	Tesis doctoral	D1_VD con RL — referente
26	2024	Zhang — Aalborg	Modelado y optimización MES con DRL	Tesis doctoral	DRL multi-energía — referente

27	2026	Costea — Polito	RL para gestión de edificios inteligentes con Optuna	Tesis maestría	Optuna para hiperparámetros (D3_VI)
28	2024	Charbonnier — Oxford	ML para optimización energética en smart grids	Tesis maestría	ML/RL en smart grids
29	2024	Häkkinen — Aalto	DR para reducción de picos residenciales con RL	Tesis maestría	Reducción de picos (D1_VD)
30	2022	Frommel Araujo — UDELAR	Reducción consumo HVAC con RL	Tesis grado	RL para HVAC — referente latinoamericano
31	2023	Atrazhev — U. Alberta	MARL para DR residencial en CityLearn	Tesis maestría	Antecedente metodológico directo
32	2024	Ramos Illán — UPM	Gestión óptima de microrred con DRL	Tesis maestría	DRL en microrredes (España)
33	2024	Nguyen — U. Vaasa	RL para optimizar BEMS	Tesis maestría	SAC en edificios
34	2025	Rahman — U. Vaasa	Smart grid: flexibilidad y resiliencia con DR, RES, ESS	Tesis maestría	D1_VD + D2_VD conjuntos
35	2020	Vadillo Gutierrez — UNPRG	Medición DR a señal de precios en redes inteligentes	Tesis maestría (Perú)	Antecedente nacional D3_VD
36	2024	Dávila Pérez — UNPRG	Cuantificación de demanda eléctrica en distribución	Tesis maestría (Perú)	Antecedente nacional D1_VD/D3_VD
37	2023	TU Delft AI Energy Lab	MARL-iDR: DR residencial basado en incentivos	arXiv 2304.04086	DR residencial multi-agente
38	2021	Pinto et al. — Polito	Gestión energética coordinada de cluster de edificios con DRL	Energy 229	Referente comunidades GIC

A3.4 Grupo 4 — KPIs, resiliencia y flexibilidad — Marcos teóricos

Las investigaciones de este grupo proporcionan los fundamentos teóricos para la operacionalización de los KPIs de la VD. Kathirgamanathan et al. (2021), OSMOSE H2020 (2021) y NREL (2024) formalizan los KPIs de flexibilidad (D1_VD); NREL (2021), CURENT (2024), Sustainability MDPI Authors (2020) y NERC (2020) formalizan los marcos de evaluación de resiliencia (D2_VD); FERC (2019), Deltetto et al. (2021) y Yu et al. (2020) formalizan los conceptos y métricas de respuesta a la demanda (D3_VD); finalmente, Hwang y Yoon (1981), Cohen (1988) y Razali y Wah (2011) sustentan los métodos estadísticos del pipeline.

Nº	Año	Autores / Institución	Aporte	Tipo	Vínculo con la tesis
39	2021	Kathirgamanathan et al. — UCD	Indicadores estandarizados para flexibilidad energética	Applied Energy 281	KPIs de D1_VD (peak, ramping, load factor)
40	2021	OSMOSE H2020	KPIs para medir el valor de la flexibilidad	Reporte EU H2020	Marco europeo de KPIs (D1_VD)

41	2024	NREL	Flexibilidad en clusters de edificios — análisis de barreras	NREL TP-87702	Barreras a la implementación (justificación)
42	2021	NREL	Power system resilience: framework de evaluación	NREL TP-80817	Marco de KPIs de resiliencia (D2_VD)
43	2024	CURRENT — UTK	Métodos de cuantificación de resiliencia	Reporte CURRENT	Cuantificación de D2_VD
44	2020	Sustainability MDPI Authors	Power systems resilience metrics — review	Sustainability 12(22)	Revisión sistemática de D2_VD
45	2023	NREL	MARL para resiliencia de sistemas de distribución	NREL TP-84636	Aplicación MARL a D2_VD
46	2024	Energy and Buildings — Maynooth	KPIs y datasets para flexibilidad — review	Reporte de revisión	Datasets y KPIs (D1_VD)
47	2024	Applied Sciences — MDPI	Demand flexibility: métricas, métodos, aplicaciones	MDPI Q2	Métricas de flexibilidad de demanda
48	2017/2019	Lowe / Iqbal / Schulman	Algoritmos base referenciados ya en Grupo 2	Múltiples	Referencia cruzada
49	2021	Henry y Ernst	Gym-ANM: entornos RL para gestión activa de redes	SoftwareX 16	Entornos RL alternativos a CityLearn
50	2021	NREL — PowerGridworld	Framework MARL para sistemas eléctricos	NREL TP-81401	Framework MARL alternativo

Tabla A3.4. Grupo 4 — Marcos teóricos para KPIs, resiliencia y flexibilidad. Elaboración propia.

A3.5 Síntesis y Brechas Identificadas

Del análisis sistemático de las cincuenta investigaciones se desprenden las cuatro brechas estructurales que la presente investigación aborda de manera integrada. La primera brecha es la ausencia de una comparación sistemática y reproducible de los cuatro algoritmos MADRL más representativos —HAPPO, MASAC, MATD3 y MAAC— en un único entorno experimental. La segunda brecha es la evaluación fragmentada de los tres ejes de la VD (flexibilidad, resiliencia y respuesta a la demanda); la mayor parte de las investigaciones aborda como máximo dos ejes, y solo Rahman (2025) integra D1_VD y D2_VD, aunque sin algoritmos de aprendizaje por refuerzo. La tercera brecha es el aprovechamiento limitado de las nuevas capacidades de CityLearn v2 —power outages, modelo LSTM de temperatura, vehículos eléctricos— para comparar algoritmos MADRL avanzados. La cuarta brecha es la conexión entre los resultados computacionales del MADRL y el contexto específico del sistema eléctrico peruano, contexto sustentado por los antecedentes nacionales (Gonzales Chávez, 2014; Morla Morales Taquiri, 2015; Vadillo Gutierrez, 2020; Dávila Pérez, 2024; Vilca-Tinta et al., 2024; Ojeda Sarmiento y Pajares,

2008) y los planes nacionales del MINEM (2014, 2023). La presente investigación cierra estas cuatro brechas de manera simultánea, lo cual constituye su aporte original.